

# Guia de Estudo — InvestiGator

Da estaca zero à defesa: aprender a tese como se a tivesse escrito

Henrique J. S. Santos

Orientador: Prof. Luís Gomes    Coorientador: Rafael Silva

MEIA, Instituto Superior de Engenharia do Porto

Material de preparação para a defesa

# Como usar este guia

- Foi feito para quem **não sabe nada de IA**. Começa do zero.
- **Uma ideia por slide**. Primeiro a *intuição* (com analogias), só depois o detalhe.
- Lê **pela ordem**: cada parte prepara a seguinte.
- No fim, deves conseguir responder com confiança a "porquê isto?" em cada passo da tese.

Estuda este guia a par com a própria tese e com os slides de defesa (slides/).

## O percurso

- 1 IA do zero (só o que a tese usa)
- 2 O problema e a contribuição
- 3 O sistema (dados, partes, fluxo)
- 4 Os dados, a olho
- 5 O código, módulo a módulo
- 6 Workflow ponta a ponta
- 7 Avaliação e decisões
- 8 Perguntas do júri

# A tese em três frases (o teu *pitch*)

## Se só decorares isto, já defendes a ideia central

- 1 Construí o **InvestiGator**, um sistema que avisa um investidor de retalho quando há um *movimento de mercado invulgar* ou uma *notícia relevante*, e **explica** cada alerta de forma rastreável (evento, raciocínio, fontes, precedentes históricos).
- 2 A contribuição é de **Engenharia de IA**: não inventei algoritmos; *integrei, apliquei e avaliei criticamente* componentes existentes num sistema funcional, explicável e reproduzível.
- 3 **Não prevejo preços**. Mostro o que aconteceu *depois* de notícias parecidas no passado, como evidência, com honestidade sobre as limitações.

# O que é Inteligência Artificial? E *Machine Learning*?

## Inteligência Artificial (IA)

Fazer com que um computador resolva tarefas que pareceriam precisar de "inteligência" humana (decidir, reconhecer, recomendar).

## Machine Learning (ML)

Em vez de escrever *regras à mão*, o computador *aprende padrões a partir de dados*.

### Analogia

*Regras à mão*: explicar a alguém, passo a passo, como reconhecer um gato.

*ML*: mostrar mil fotos de gatos e deixar a pessoa aprender o padrão sozinha.

Nesta tese, a "aprendizagem" já vem **pronta** (modelos pré-treinados). Ver o slide seguinte.

# O que esta tese É — e o que **NÃO** é (muito importante)

## O que usa

- Um **embedder de texto pré-treinado** (SBERT) — só para *usar*, não para treinar.
- **Estatística** simples (z-score: média e desvio-padrão).
- **Similaridade do cosseno** (comparar vetores).
- **Event study** (aritmética de retornos).
- **UM modelo treinado por mim**: a *triagem de materialidade* (regressão logística; RQ4). Simples de propósito — ver a parte da Avaliação.
- **Explicabilidade** (mostrar a evidência).

## O que **NÃO** usa (e porquê)

- ✗ Treinar redes neurais profundas (épocas, backprop, CNNs)
- ✗ Visão computacional, imagens, segmentação
- ✗ Prever preços ou direção (nunca!)


*Porquê?* A contribuição principal é **integrar componentes existentes**; o modelo que treino é pequeno, transparente e avaliado contra baselines — não é deep learning, é ML clássico defensável.

Se o júri perguntar por treino: "treino UM classificador de triagem (RQ4), com protocolo temporal e anti-lookahead testado — e reporto que a baseline de volatilidade ganhou."

# Ideia-chave 1: transformar texto em *números* (*embeddings*)

Um computador não "lê" palavras; compara *números*. Um **embedding** transforma cada título de notícia num **vetor** (uma lista de números = um ponto num espaço).

A magia: títulos com **significado parecido** ficam **perto** uns dos outros nesse espaço.




**Porquê isto importa:** para encontrar notícias passadas *parecidas* com uma nova, basta procurar os pontos *mais próximos*.

# Como medir "perto"? *Similaridade do cosseno*

Mede-se o **ângulo** entre dois vetores:

- ângulo pequeno  $\Rightarrow$  cosseno  $\approx 1$  (muito parecidos);
- ângulo reto  $\Rightarrow$  cosseno  $\approx 0$  (não relacionados).

Usa-se o ângulo (e não a distância) porque só interessa a *direção* do significado, não o tamanho do vetor.




# De onde vêm os vetores? *SBERT* (e *Transformer*), em intuição

**SBERT** (Sentence-BERT) é um modelo **já treinado** por outros, que lê uma frase e devolve o seu vetor de significado. O **Transformer** é a arquitetura que o tornou possível (lê a frase inteira e "presta atenção" às palavras que importam).

**Nesta tese usamo-lo pronto** (inferência): damos-lhe um título, recebemos o vetor. Não o treinamos.

*Porquê SBERT e não um LLM gigante?* Capta significado, é **barato**, **reproduzível** e **gratuito**, e dá vetores diretamente comparáveis.





## Ideia-chave 2: estatística para "isto é invulgar?"

**Média** ( $\mu$ ): o valor típico dos últimos dias.

**Desvio-padrão** ( $\sigma$ ): o quanto costuma oscilar (a *volatilidade*).

**z-score**: a quantos desvios-padrão está o movimento de hoje:

$$z = \frac{r - \mu}{\sigma}$$

*Normalizar* pela volatilidade é o truque: a mesma queda de  $-3,2\%$  é dramática numa ação calma e banal numa volátil.

### Exemplo (da tese)

Queda de  $-3,2\%$  hoje:

- ação **calma** ( $\sigma = 0,40\%$ ):  $z \approx -8,1 \Rightarrow$  anomalia clara
- ação **volátil** ( $\sigma = 1,50\%$ ):  $z \approx -2,2 \Rightarrow$  dia normal


Um limiar fixo em % trataria as duas igual; o z-score não.

### Ideia-chave 3: *retornos e event study* (medir o impacto, sem ver o futuro)

**Log-return:** a variação diária do preço (em %).

**Event study:** depois de uma notícia, medimos o retorno acumulado a **+1, +3 e +5 dias** a partir do *fecho* do primeiro dia de negociação.

**Anti-lookahead** (regra de ouro de honestidade): só olhamos para *depois* do evento. Nunca usamos o futuro para "prever". Medimos um *resultado*, não uma previsão.



## Ideia-chave 4: *recuperação* e como se mede (precision@k)

**Recuperação** (Information Retrieval): ordenar notícias passadas pela semelhança a uma nova e mostrar as ***k* melhores** (ex.:  $k = 5$ ).

**precision@k**: das  $k$  recuperadas, que fração é *relevante*? Usamos "mesmo setor" como proxy automático de relevância.

Comparamos sempre com **baselines** para o número ter significado:

- **aleatório** (o "chão" sem perícia),
- **recência** (só as mais recentes),
- **lexical** (sobreposição de palavras).

### Intuição

"Das 5 notícias passadas que mostrei, quantas eram mesmo do mesmo tema?"

Bater o aleatório e o lexical é a prova de que os *embeddings* acrescentam valor real.

## Ideia-chave 5: explicabilidade (XAI) e confiança

**Transparente vs caixa-preta:** ou o modelo é interpretável por desenho, ou é opaco e explicamo-lo *a posteriori* (LIME/SHAP). O InvestiGator escolhe **transparente por desenho**.

**Fidelidade:** a explicação reflete *exatamente* o que o sistema calculou (não é uma aproximação).

**Confiança calibrada:** queremos que o utilizador confie *na medida certa* — nem ignorar um bom aviso, nem confiar cegamente. Por isso mostramos *evidência verificável*, não uma narrativa.

### Raciocínio Baseado em Casos (CBR)

A ideia familiar por trás do motor: como um médico que se lembra de *doentes parecidos* do passado.

**Recuperar** casos semelhantes → **reutilizar** o que aconteceu como evidência. Paramos aqui (não "prevemos").

# Glossário (os termos que vais ouvir)

- **Embedding**: texto  $\rightarrow$  vetor de significado.
- **Cosseno**: medida de semelhança (ângulo).
- **SBERT**: modelo pré-treinado que cria embeddings de frases.
- **z-score**: nº de desvios-padrão face à norma recente.
- **Volatilidade**: o quanto uma ação costuma oscilar ( $\sigma$ ).
- **Event study**: medir o retorno após um evento.
- **Anti-lookahead**: nunca usar o futuro.
- **precision@k**: acerto nas  $k$  melhores.
- **Baseline**: método simples de comparação.
- **XAI / fidelidade**: explicação fiel ao cálculo.
- **CBR**: raciocínio por casos análogos.

Tens agora as bases. As próximas partes aplicam *exatamente* estes conceitos à tese.

Já tens as **bases de IA** de que esta tese precisa.

A seguir: *o problema e a contribuição*, depois *o sistema* (dados, partes, fluxo), o *código* e a *avaliação*.


# Para quem é? E qual é o problema?

**Investidor de retalho:** uma pessoa comum que investe (não um profissional).

O problema é a **sobrecarga de informação**: milhares de ações mexem-se e as notícias chegam sem pausa. As ferramentas que ajudam a interpretar isto são **institucionais, opacas, ou ambas**.

E este investidor é guiado pela **atenção**: reage a movimentos extremos e a notícias salientes. Logo, faz sentido intervir *exatamente nesses momentos*, com **contexto e explicação**.


milhares de preços  
+ notícias  
sem pausa



investidor sozinho

sem as ferramentas que bancos e fundos têm

## A resposta: dois gatilhos, sempre com explicação



O alerta não é uma notificação seca: traz a **cadeia de raciocínio completa**, que o investidor pode **seguir e verificar**.



# O que faz — e o que **não** faz

## Faz

- Deteta movimentos invulgares e explica-os.
- Para uma notícia, mostra **precedentes históricos** reais e o impacto que tiveram.
- Expõe toda a evidência (rastreável).

## Não faz (por desenho)

- ✗ Prever preços.
- ✗ Trading automático / conselho.
- ✗ APIs pagas (só gratuitas).

É uma escolha de **honestidade e defensibilidade**: medir o passado como evidência, nunca prometer o futuro.

# A contribuição: *Engenharia* de IA


A contribuição **não** é inventar algoritmos. É **integrar, aplicar e avaliar criticamente** componentes existentes num sistema funcional, explicável e reproduzível. Três contribuições concretas:

- 1 Uma **metodologia** reproduzível de correlação notícia→impacto (embeddings + event study, sem lookahead).
- 2 O **InvestiGator**, um sistema de alertas **explicável** cuja cadeia de raciocínio é toda exposta ao utilizador e *fiel por construção*.
- 3 Uma **avaliação crítica e honesta** de cada componente em dados reais, contra baselines, com limitações reportadas.

## Defesa em 1 frase


"Usar modelos e ferramentas existentes é o trabalho de engenharia: o valor está no sistema coerente, explicável e reproduzível, não num algoritmo novo."

# Arquitetura num relance



Componentes de **responsabilidade única**, ligados por um **esquema comum**. Dois gatilhos convergem num único passo de explicação antes de enviar.

# O modelo de dados (os objetos e as relações)



**Ideia central:** um *caso* = uma notícia passada + o que aconteceu ao preço a seguir. **NewsItem** (live) e **NewsRecord** (histórico) partilham o mesmo esquema, por isso são diretamente comparáveis.


# Os componentes e o que cada um faz

| Componente           | Responsabilidade           | Entrada → saída                    |
|----------------------|----------------------------|------------------------------------|
| Dados de mercado     | preços, log-returns        | ticker → retornos diários          |
| Notícias             | obter e normalizar         | ticker → NewsItem(s)               |
| Embedder             | título → vetor             | título → embedding                 |
| Base de conhecimento | guardar/recuperar casos    | título → top- <i>k</i> casos       |
| Detetor de anomalias | sinalar movimento invulgar | retornos → AnomalyResult           |
| Motor de correlação  | cosseno + event study      | título, KB → precedentes + impacto |
| Motor de explicação  | montar o alerta fiel       | objetos → texto do alerta          |
| Entrega              | enviar ao utilizador       | texto → Telegram                   |

Cada componente tem **uma** responsabilidade: é o que permite testar offline e trocar peças.

# Os dois gatilhos, lado a lado

## Gatilho de mercado:



## Gatilho de notícia:



Ambos terminam no **motor de explicação**, que monta o alerta a partir dos objetos calculados.

# Que dados? Duas camadas

## Histórica (offline)

**FNSPID**: notícias alinhadas a preços diários.

*Data card*: 15 ações grandes, 5 setores (tecnologia, banca, energia, saúde, consumo), 2018–2023. Licença CC BY-SA 4.0 (atribuição obrigatória).

## Live

Preços (yfinance) + notícias (Finnhub/RSS), só APIs **gratuitas**.

A avaliação usa um corpus **real e recente** (3 714 títulos) construído pelo mesmo processo; o FNSPID multi-ano fica como trabalho futuro.

As duas camadas partilham o **mesmo esquema** (data, ticker, título)  $\Rightarrow$  o novo é comparável com o histórico.

# A estrutura de pastas (o repositório)

Onde vive cada coisa:

DIMEIA/

|               |                                      |
|---------------|--------------------------------------|
| thesis/       | a dissertacao (LaTeX, 6 capitulos)   |
| investigator/ | o sistema (um pacote por componente) |
| data/samples/ | amostras pequenas (CSV, JSONL)       |
| scripts/      | dados, figuras, avaliacao, build     |
| slides/       | slides de defesa + este guia         |
| docs/         | documentacao e provas de rigor       |

Os dados grandes **não** são versionados (recriados por script); só ficam pequenas amostras.



# Os dados a olho: notícias (CSV) e um caso (JSON)

**Notícias de entrada** (news\_sample.csv) — três colunas:

```
date,ticker,headline
```

```
2023-01-09,AAPL,Apple expands services revenue as iPhone demand...
```

```
2023-05-25,NVDA,Nvidia guidance surges on soaring demand for AI...
```

**Um "caso" na base de conhecimento** (kb\_sample.jsonl, uma linha):

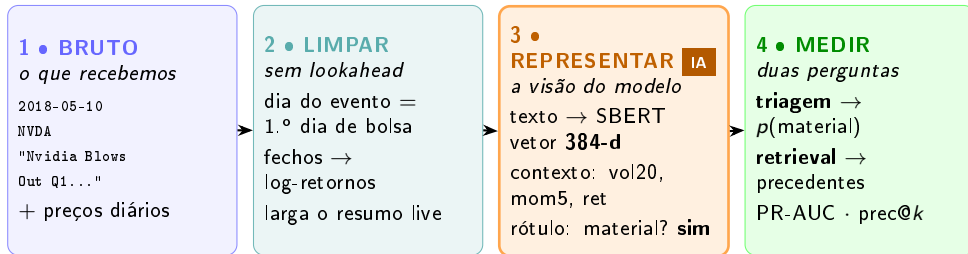
```
{ "date": "2023-01-09", "ticker": "AAPL",  
  "headline": "Apple expands services revenue...",  
  "impacts": { "1": 0.0045, "3": 0.0250, "5": 0.0445 },  
  "embedding": [0.0, 0.0, ..., 0.333]    // 64 numeros }
```

# O JSON de um caso, campo a campo

- **date, ticker, headline**: a notícia (igual ao esquema live).
- **impacts**: o que o preço fez **depois** — retorno acumulado a +1, +3 e +5 dias (ex.: +0,45%, +2,50%, +4,45%). *Esta é a "etiqueta" de evidência.*
- **embedding**: o vetor de significado do título (aqui 64 números do baseline; com SBERT seriam centenas). É o que permite comparar por cosseno.

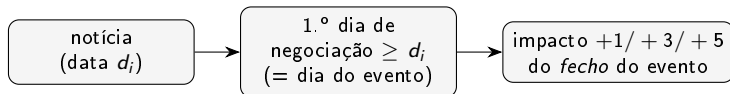
Um caso junta as **três coisas** de que o sistema precisa: *o que se disse, o que aconteceu e como comparar.*

# Os dados em todas as fases — um título real



Valores reais (Nvidia, 10 Mai 2018). A “IA” é a fase **REPRESENTAR**: o texto vira um vetor de 384 números, o evento vira features de contexto, o resultado vira um rótulo.

## Como nasce um caso (alinhamento + impacto, sem lookahead)



- Mede-se a partir do **fecho** (não da abertura): não se credita um salto já no preço de abertura.
- Só se olha para a **frente** (anti-lookahead): é *evidência* do que aconteceu, não previsão.
- Sem preços alinhados, ou janela fora dos dados  $\Rightarrow$  a notícia é descartada (não inventada).

Já sabes **o problema**, **o sistema** e **os dados**.

A seguir: *o código módulo a módulo* (linha a linha) e o *workflow ponta a ponta* com exemplos reais.

# O código num relance

- **Um pacote por componente** (mercado, deteção, correlação, base de conhecimento, explicação, entrega). Cada um faz *uma* coisa.
- **Lógica pura separada de I/O**: os cálculos (z-score, cosseno, impacto) não precisam de rede nem do modelo pesado  $\Rightarrow$  testam-se offline e rápido.
- **Programado a interfaces**: o Embedder é abstrato, com 2 implementações trocáveis.

Nos slides seguintes: cada módulo com um *snippet simplificado mas fiel*, linha a linha, e um exemplo concreto de valores.

# Detetor de anomalias — o z-score

```
def detect_latest(returns, window=20, threshold=3.0):  
    recent = returns[-window-1 : -1]      # 20 dias ANTERIORES (sem hoje)  
    mu, sigma = mean(recent), std(recent)  
    z = (returns[-1] - mu) / sigma         # quantos desvios-padroao e' hoje  
    return AnomalyResult(is_anomaly = abs(z) > threshold,  
                          z_score=z, mean=mu, std=sigma, window=window, ...)
```

- **recebe** a série de retornos; **devolve** um AnomalyResult (decisão + todas as quantidades).
- **recent**: só dias *antes* de hoje  $\Rightarrow$  **sem lookahead**.
- **Exemplo (TSLA)**:  $\mu = -0,92\%$ ,  $\sigma = 2,73\%$ , hoje =  $+19,82\% \Rightarrow z = +7,61 \Rightarrow$  anomalia.

# Similaridade do cosseno + top- $k$

```
def cosine_similarities(query, matrix):      # query: 1 vetor; matrix: N vetores
    return (matrix @ query) / (row_norms(matrix) * norm(query))
```

```
def top_k_similar(query, matrix, k=5):
    sims = cosine_similarities(query, matrix)
    return indices_of_largest(sims, k)        # os k mais parecidos (+ score)
```

- **recebe** o vetor da notícia nova e a matriz de vetores da KB; **devolve** os índices dos  **$k$  mais semelhantes** e o seu score (0 a 1).
- `matrix @ query` é o produto interno; dividir pelas normas dá o **cosseno** (o ângulo).
- **Exemplo:** para a consulta da Nvidia, os 5 maiores scores apontam para notícias de chips de IA.



# Event study — o impacto pós-evento

```
def post_event_returns(close, event_idx, horizons=(1,3,5)):
    p0 = close[event_idx]                # fecho do dia do evento
    return { h: close[event_idx + h]/p0 - 1    # retorno acumulado a +h dias
            for h in horizons }
```

- **recebe** a série de fechos e a posição do evento; **devolve** {1:..., 3:..., 5:...}.
- Mede sempre **para a frente**, a partir do **fecho** ( $p_0$ ). Se faltar dados  $\Rightarrow$  NaN (não inventa).
- **Exemplo (AAPL)**: +1d = +0,45%, +3d = +2,50%, +5d = +4,45%.

# Embedder — uma interface, duas implementações

```
class Embedder(Protocol):          # "contrato": tem dim e encode()
    dim: int
    def encode(self, texts) -> matriz (n, dim): ...

class HashingEmbedder:             # baseline SEM dependencias (reprodutivel, p/ testes)
class SbertEmbedder:               # SBERT pre-treinado (a abordagem da tese, inferencia)
class OnnxMiniLMEmbedder:          # o MESMO MiniLM em ONNX (producao: leve, sem torch)
```

- Todos cumprem o mesmo contrato  $\Rightarrow$  a KB e a recuperação funcionam com qualquer um.
- Por isso podemos **comparar** MiniLM vs MPNet vs lexical de forma **justa** (só troca o embedder).
- O HashingEmbedder permite correr tudo **sem a stack pesada** (torch).
- O OnnxMiniLMEmbedder leva o modelo da tese para a **produção** ( $\sim 23$  MB, CPU): paridade com o SBERT **validada** (cosseno médio 0,992; 96% dos vizinhos top-3 comuns — docs/evaluation/onnx\_minilm\_validation.md).

# Base de conhecimento — construir e recuperar

```
class HistoricalKB:
    def build(news, prices, embedder):          # 1 "caso" por noticia
        for (date, ticker, headline) in news:
            e = first_trading_day >= date      # alinhar ao evento
            impacts = post_event_returns(prices[ticker], e)
            emb      = embedder.encode([headline])[0]
            add NewsRecord(date, ticker, headline, impacts, emb)

    def find_precedents(query_text, embedder, top_k=5):
        q = embedder.encode([query_text])[0]
        return top_k_similar(q, all_embeddings) # -> [(NewsRecord, score), ...]
```


**build** (offline) cria a memória de casos; **find\_precedents** (live) devolve os mais parecidos com a notícia nova. É o **núcleo** do sistema (raciocínio baseado em casos).

# Motor de explicação — o alerta *fiel*

```
def explain_news_impact(ticker, headline, precedents, horizon=1):  
    vals = [impacto[horizon] de cada precedente]  
    linhas = [f"intervalo {min(vals):.2%}...{max(vals):.2%} (media {mean(vals):.2%})"]  
    for (rec, score) in precedents:                                # mostra CADA precedente  
        linhas += [f"{rec.date} {rec.ticker} (sim {score:.2f}) {rec.impacts[...]:.2%}"]  
    linhas += ["Nota: resultado passado, NAO e' previsao."]   
    return "\n".join(linhas)
```

- O texto é montado **a partir dos próprios objetos calculados**  $\Rightarrow$  **fiel por construção** (não pode divergir da lógica).
- Mostra **cada** precedente (não só a média) e termina sempre com o **aviso de não-previsão**.

## Workflow (1/3): construir a memória, uma vez (offline)



Resultado: uma base de **casos** (*notícia*  $\rightarrow$  *impacto* + *vetor*), pronta a ser consultada. Feita **uma vez**; depois é só usar.

## Workflow (2/3): gatilho de mercado — TSLA, 24-10-2024 (real)

- 1 Preços live  $\rightarrow$  log-return de hoje:  $r = +19,82\%$  (movimento de  $\approx +22\%$ ).
- 2 Janela dos 20 dias anteriores:  $\mu = -0,92\%$ ,  $\sigma = 2,73\%$ .
- 3  $z = (19,82 - (-0,92))/2,73 = +7,61$ .
- 4  $|7,61| > 3 \Rightarrow$  **anomalia**. O alerta expõe  $r, \mu, \sigma$ , janela e limiar, e traduz: " $\approx 7,6 \times$  a oscilação diária típica desta ação".

### Porque é convincente

Reprodutível por `scripts/evaluate_anomaly.py` (janela fixa). O mesmo valor sai sempre.

## Workflow (3/3): gatilho de notícia — Nvidia (real)

Consulta: *"Nvidia raises guidance on surging demand for AI data-centre accelerators"* → embedding → cosseno top-5 → alerta:

News alert NVDA - 5 manchetes semelhantes

intervalo 1d: -3,46%...-0,46% (media -1,97%)

```
> -3,46% 1d MSFT (sim 0.68) "Qualcomm debuts AI data center chips..."
> -1,64% 1d NVDA (sim 0.68) "Qualcomm debuts AI data center chips..."
> -2,65% 1d META (sim 0.68) "Qualcomm debuts AI data center chips..."
> -0,46% 1d GOOGL (sim 0.64) "...bigger than Nvidia..."
> -1,64% 1d NVDA (sim 0.58) "...NVIDIA..."
```

Resultados passados observados - NAO e' previsao.

Todos falam de **chips de IA para data-center**, mesmo vindo de empresas diferentes (**cross-ticker**): a recuperação é por **significado**, não pelo nome da empresa.

# A nota mais honesta (e a pergunta certa do júri)

## Um título *positivo* deu precedentes *negativos* ( $-1,97\%$ ). Engana?

A semelhança capta o **tema** ("chips de IA"), **não a direção** (o sentimento). Por isso um título positivo pode recuperar um *cluster* de ameaça competitiva, com desfechos negativos.

A média é **evidência sobre um tema**, **não uma previsão** para este caso. É por isso que o alerta:

- mostra sempre os precedentes **um a um** (não só a média);
- termina com o **aviso de não-previsão** (evita a *sobre-confiança*).

Melhorias futuras: de-duplicar precedentes e **sinalizar quando o cluster discorda na direção**.



Já viste **o código** e o **workflow** com exemplos reais.

A seguir: *correr a app* tu mesmo (1 comando), depois *a avaliação*, as *decisões* e as *perguntas do júri*.

# Deixar de ser "caixa preta": a app são *duas funções*

Não há magia. A app é dois pontos de entrada (funções que já viste):

- **Gatilho de notícia** — corre **offline**, com a base de conhecimento de amostra que está no repositório. **Não precisa de chaves nem de internet**. É o melhor para experimentar.
- **Gatilho de mercado** — busca preços ao vivo (precisa de internet); não envia nada.

## O mais importante

Fiz-te um comando único que corre os dois e mostra o resultado, **sem configurar nada**: `python scripts/demo.py`. Vê o próximo slide.

# Passo 1: um comando, e vê a app a funcionar

A partir da pasta do projeto:

```
$ python scripts/demo.py
```

```
==== GATILHO DE NOTICIA (offline, base de conhecimento de amostra) ====
```

```
News alert for NVDA (NVIDIA)
```

```
"Nvidia demand surges on AI chip orders"
```

```
3 similar past headlines - 5-day moves ranged +3,55%...+10,89%
```

```
(average +6,46%):
```

```
> +3,55% 5d NVDA 2023-05-25 "Nvidia guidance surges..." (sim 0.60)
```

```
> +10,89% 5d MSFT 2023-04-25 "Microsoft cloud growth..." (sim 0.38)
```

```
> +4,93% 5d NVDA 2023-06-13 "Nvidia unveils new AI..." (sim 0.38)
```

```
Observed past outcomes - not a price prediction.
```

```
==== GATILHO DE MERCADO (precos ao vivo; nao envia) ====
```

```
No anomaly for AAPL today (z-score +0.89, within +-3).
```

**Nada é enviado.** O gatilho de notícia dá *sempre* o mesmo resultado (determinístico).

## Passo 1 explicado: o que aconteceu, linha a linha

- 1 A consulta *“Nvidia demand surges on AI chip orders”* virou um **vetor** (embedding).
- 2 Comparou-se por **coseno** com todos os casos da base → os **3 mais parecidos**.
- 3 Para cada um, leu-se o **impacto +5d** já guardado (evidência do passado).
- 4 Intervalo +3,55%... + 10,89% e média = +6,46% (o mesmo +6,5% do Cap. 3!), com o **aviso de não-previsão**.

É *exatamente* o pipeline dos slides anteriores — agora a correr no teu computador.

## Passo 2: mudar um parâmetro e ver mudar (o "e se?")

Mesma consulta, mas `top_k=5`, `horizon=1`:

```
News alert NVDA - 5 manchetes; 1d: +0,45%...+7,24% (media +3,40%)
```

- NVDA (sim 0.60) +1d +2,54% "Nvidia guidance surges..."
- MSFT (sim 0.38) +1d +7,24% "Microsoft cloud growth..."
- NVDA (sim 0.38) +1d +4,81% "Nvidia unveils new AI..."
- JPM (sim 0.31) +1d +1,95% "JPMorgan acquires..." <- menos parecido
- AAPL (sim 0.25) +1d +0,45% "Apple expands services..." <- menos parecido

**O que mudou:** `top_k=5`  $\Rightarrow$  5 precedentes (os 2 últimos com semelhança *baixa*); `horizon=1`  $\Rightarrow$  olha a +1 dia (média +3,40%). Assim respondes a "e se aumentasse o *k*?" com um facto, não um palpite.

## Passo 3: ver que tudo funciona (os testes)

```
$ bash scripts/verify.sh
..... [100%] 47 passed
All checks passed! (ruff: estilo OK)
```

- Cada peça (z-score, cosseno, event study, KB, explicação) tem **testes automáticos** que correm **offline**, rápido.
- Se o júri perguntar "como sei que não inventaste?", a resposta é: **os testes** e os **scripts de avaliação** reproduzem os números.

# E o Telegram / notícias ao vivo?

- Enviar para o **Telegram** e buscar **notícias ao vivo** precisa de chaves (gratuitas) num ficheiro `.env` (nunca versionado). Passos exatos: `docs/design/how_to_run.md`.
- Mas **não precisas disso para estudar**: a demo acima já prova o caminho todo, offline.
- **Dica (Windows)**: a consola pode rebentar com os emojis do alerta; a demo já força UTF-8 para isso não acontecer.

## Resumo de "como corro a app"

```
python scripts/demo.py (ver a app) · bash scripts/verify.sh (ver que funciona) · docs/design/how_to_run.md  
(tudo o resto, incluindo Telegram).
```

## Mais um exemplo: quando o baseline *falha* (e porquê)

Consulta de **banca**, com o encoder *baseline* (só palavras) da demo:

```
run_news_trigger('JPM', 'Bank profits jump as interest rates rise', top_k=3)
News alert JPM - 3 manchetes; 5d: -14,86%...+4,45% (media -2,99%)
- AAPL (sim 0.25) +5d +4,45% "Apple expands services..."
- JPM (sim 0.15) +5d +1,44% "JPMorgan acquires failed bank..."
- TSLA (sim 0.14) +5d -14,86% "Tesla margins narrow..."
```

Os scores são **baixos** e os precedentes **maus**. Porquê? O baseline só vê **sobreposição de palavras**: "Bank profits...interest rates" não partilha palavras com "JPMorgan...banking turmoil". É o **problema de vocabulário** — e é *exatamente* isto que o **SBERT** resolve (capta *significado*, não palavras iguais). Por isso a versão real da tese usa SBERT.



# Constrói a tua própria base de conhecimento

Queres os teus exemplos? Constrói uma KB a partir de um CSV `date,ticker,headline`:


```
# baseline (rapido, offline):  
python scripts/build_kb.py --news data/finnhub_news.csv --out data/kb.jsonl  
# SBERT (significado real; precisa da stack pesada de ML):  
python scripts/build_kb.py --news ... --out data/kb_sbert.jsonl --sbert
```

- Para cada título: alinha ao 1.º dia de negociação, busca preços, mede o impacto +1/ +3/ +5 e gera o embedding ⇒ **um caso por título**.
- Consulta depois com `run_news_trigger(..., kb_path=..., embedder=...)`.
- **Regra:** consulta com o *mesmo* embedder com que construístes (mesma dimensão/modelo).

# Como avaliamos — sem nos enganarmos

- O plano foi **fixado antes** de correr qualquer experiência (uma mini "pré-registo"): não se escolhe a métrica depois para favorecer o resultado.
- **Recuperação:** *precision@k* (acerto nas  $k$  melhores), contra **3 baselines** (aleatório, recência, lexical), média de **5 seeds**.
- **Anomalias:** argumento **sem rótulo** (consistência da taxa de disparo entre ações); o  $F_1$  contra um proxy é só *suporte*.
- **Honestidade:** sem previsão nem trading  $\Rightarrow$  métricas de lucro estão *fora de âmbito* por desenho.

# Recuperação: SBERT bate todas as baselines




P@5 (cross-ticker):

- SBERT-MiniLM **0,514**
- SBERT-MPNet **0,538**
- lexical 0,346
- aleatório 0,240
- recência 0,126

**Leitura:**  $\approx 2,1\times$  o acaso e bem acima do lexical  
 $\Rightarrow$  o valor vem do *significado*, não de palavras iguais. Desvios pequenos ( $\sim 0,01$ )  $\Rightarrow$  robusto.

# Recuperação por setor: onde acrescenta mais




O justo é o **lift** (ganho sobre o acaso), não o valor bruto:

- energia **+0,377**, saúde **+0,348** (vocabulário distintivo)
- consumo **+0,100** (notícias genéricas)

A tecnologia tem P@5 bruta alta (0,712) só porque **domina o corpus** (taxa-base 0,429).

# Anomalias: consistente em todo o mercado



O limiar fixo dispara  $\sim 1\%$  numa ação calma e  $\sim 35\%$  numa volátil; o **z-score** fica  $\sim 2\text{--}3\%$  em *todas*.

Amplitude da taxa: **0,015** (z-score) vs **0,344** (fixo)  $\Rightarrow > 20\times$  mais consistente. Este é o argumento **sem rótulo**. O  $F_1$  (0,516 vs 0,218) é suporte.

E desafiámos a regra com um detetor **aprendido** (Isolation Forest, causal, mesma informação): perdeu —  $F_1$  **0,271 vs 0,530**. A escolha simples fica validada por *comparação*.

# Triagem de materialidade — o modelo que EU treinei (RQ4)

## A pergunta que o modelo responde

Chegam dezenas de notícias por dia. **Quais merecem alerta?** O modelo estima  $P(\text{segue-se um movimento ANORMAL})$  — *materialidade*, nunca direção nem preço.

- **Rótulo (sem anotar à mão):** material se  $|\text{retorno do ticker} - \text{retorno do SPY}| \geq 2\%$  nos 3 dias úteis *depois* do evento — calculado pelo NOSSO event study.
- **Features (só passado):** volatilidade dos 20 dias *antes*, momentum 5d, retorno do próprio dia, comprimento do título, setor, embedding SBERT do título.
- **Anti-batota testado:** um teste unitário *muda os preços do futuro* e verifica que as features NÃO mudam (e o rótulo sim). É a resposta pronta à pergunta nº 1 do júri.

Corpus: FNSPID 2018–2023, **79 753** exemplos, 14/15 tickers (a Meta é "FB" no corpus).

# Como se treina sem batota — e como se mede

- **Split temporal** por dias únicos (70/15/15): treino no passado, teste no futuro — nunca ao contrário. **Embargo** de 5 dias entre blocos (nenhuma janela de rótulo atravessa).
- **Calibração (Platt)**: uma sigmóide ajustada SÓ na validação transforma scores em *probabilidades honestas* ("70%" acontece ~70% das vezes).
- **6 famílias**: alertar- sempre (chão) · LR só-volatilidade (a baseline decisiva) · LR contexto/texto/ambos · gradient boosting (teto).

## As métricas, em palavras

**PR-AUC**: qualidade do ranking com classes desequilibradas; o chão é a prevalência.

**Precisão@5/dia**: das 5 melhores por dia (o que um humano aguenta), quantas foram materiais — mede a *fadiga de alertas*.

**Brier**: erro quadrático das probabilidades (menor = mais honesto).

*Pré-compromisso*: se o modelo não bater a baseline de volatilidade, **reporta-se na mesma**.

# O resultado honesto — e porque é BOM para a defesa

| Modelo                    | PR-AUC       | P@5/dia      |
|---------------------------|--------------|--------------|
| Alertar-sempre            | 0,378        | 0,163        |
| <b>LR só-volatilidade</b> | <b>0,542</b> | <b>0,632</b> |
| LR só-contexto            | 0,538        | 0,632        |
| LR contexto+texto         | 0,496        | 0,585        |
| Gradient boosting         | 0,469        | 0,551        |
| LR só-texto               | 0,439        | 0,572        |

- **Como mecanismo, funciona:** dentro de 5 alertas/dia, a precisão quase **quadruplica** (0,632 vs 0,163), com probabilidades calibradas (Brier 0,218 vs 0,622).
- **O veredicto:** nenhum modelo que lê o texto bateu a volatilidade  $\Rightarrow$  o sinal está no *contexto de mercado*, não nas palavras do título.
- É a **2.ª** comparação justa "aprendido vs simples" que a escolha transparente vence (a 1.ª foi IF vs z-score) — honestidade que *fortalece* a tese.

E depois do deploy? O loop de pós-validação (a minha ideia de "RL", na forma defensável)

Cada decisão fica registada; dias depois, quando a janela fecha, é rotulada com o que *realmente* aconteceu  $\Rightarrow$  precisão/calibração ao vivo + dados novos para retreinar. Não é RL clássico (os alertas não movem o mercado) — é aprendizagem contínua com rótulos atrasados.



# “E se juntarmos MAIS critérios?” — a ablação de features (RQ4-ext)

Pergunta natural do júri: *já que o contexto manda, mais contexto ajuda?* Testei **5 sinais novos** (baratos, sem novas fontes, todos anti-lookahead):

- regime do mercado (SPY)
- momento a 20 dias
- vol20/vol60 (expansão)
- reação padronizada ( $|z|$ )
- risco de queda

| Modelo                          | PR-AUC       |
|---------------------------------|--------------|
| Contexto v1 (âncora)            | 0,537        |
| <b>Contexto v1 + 5 features</b> | <b>0,535</b> |

- **Nenhuma ajudou** ( $\Delta = -0,002$ ). A âncora reproduz o congelado (0,537 vs 0,538).
- *Porquê*: a volatilidade rolante já absorve quase tudo o que estes sinais carregam.
- A **mesma lição** do texto, pelo lado oposto — reportada tal como caiu; produção intocada.

**Transformar “adicionei features” em ciência**: uma ablação diz *quais* valem e *quais não*.  
scripts/train\_triage\_ext.py

# Ameaças à validade (ditas antes que perguntem)

- **Construção:** relevância por *setor* é um proxy; o rótulo de anomalia é volatilidade-relativo (por isso a consistência sem-rótulo tem primazia).
- **Interna:** match trivial é removido (cross-ticker); sem lookahead; resta o *confundimento* (mercado global), que as janelas curtas limitam.
- **Externa:** 15 ações grandes, US, janela recente  $\Rightarrow$  não generaliza a small-caps/outras mercados sem mais dados.
- **Estatística:** 5 seeds, desvios reportados; gap grande face ao desvio, mas é amostra modesta.

# Decisões de desenho: porquê isto e não outra coisa

| Decisão     | Escolhido                         | Alternativa            | Porquê (rejeição)                                |
|-------------|-----------------------------------|------------------------|--------------------------------------------------|
| Deteção     | z-score (rolling)                 | Isolation Forest, deep | transparência; sinal 1-D não justifica opacidade |
| Recuperação | SBERT + cosseno                   | léxico, word2vec, LLM  | significado, barato, reproduzível                |
| Impacto     | event study (retorno <i>raw</i> ) | CAR (ajustado)         | observável; sem modelo opaco a explicar          |
| Explicação  | transparente + precedentes        | só LIME/SHAP           | fiel por construção, não aproximação             |
| Avaliação   | precision@k <i>cross-ticker</i>   | —                      | padrão; evita match trivial pelo nome            |

Princípio único: **simplicidade defensável**. Onde duas opções empatam, escolhe-se a mais *transparente*, porque o sistema é para um não-especialista.

## "E se mudássemos...?" (sensibilidade dos parâmetros)

- **Janela do z-score** (10/20/60 dias):  $F_1$  vs proxy = 0,385/0,516/0,678. Janela maior  $\Rightarrow$  baseline de volatilidade mais estável (mas acaba por saturar).
- **Limiar  $k$**  (=3): maior  $\Rightarrow$  menos alertas (mais seletivo); menor  $\Rightarrow$  mais alertas (mais ruído).
- **top- $k$**  (=5): quantos precedentes mostrar; um alerta só comporta uns poucos.
- **Horizonte** (+1/ +3/ +5): janelas curtas limitam o confundimento de mercado; mais longo  $\Rightarrow$  mais ruído alheio à notícia.

Saber estes *trade-offs* é a melhor resposta a "e se aumentasse este valor?".

# O produto, HOJE — o que está ao vivo (e como mostrar)

Não é só uma tese em papel: o sistema **corre** em produção, de graça, sem servidor próprio.

- **Painel único** — `investigator.streamlit.app`: UMA página, uma **aba por ticker** da watchlist. Cada aba mostra o "background risk" (o TEU modelo de triagem, RQ4, pontua TODOS os dias, mesmo sem notícia), o gráfico anotado com cada evento detetado, e a tabela de histórico — tudo lido do MESMO registo que o canal recebeu (nunca recalculado).
- **Retrieval semântico** — o MESMO MiniLM da tese em **ONNX** (~23 MB, sem torch; paridade com o SBERT validada — cosseno médio 0,992) sobre uma fatia curada de 2.016 manchetes FNSPID 2018–2023.
- **Canal Telegram** — varredura automática com **filtro de relevância**, chão de similaridade, teto de 2 alertas/ticker/dia e **resumo diário ao fecho**; corre também **finis de semana (só notícias)**.



# Perguntas difíceis do júri (1/2)

## **Isto não é só usar bibliotecas?**

Sim, e numa tese de *Engenharia* de IA é isso que se pede: a contribuição é a integração, a metodologia notícia→impacto e a avaliação honesta. O núcleo é **CBR** (raciocínio baseado em casos), não ad hoc.

## **Porquê não um LLM / deep learning?**

Defensibilidade: para uma série de retornos e títulos curtos, o ganho não compensa a perda de transparência e o custo. LLMs ficam como trabalho futuro (infraestrutura pronta: FAISS para escala).

## **A precision@5 de ~0,51 é boa?**

É  $\sim 2,1\times$  o acaso e acima do lexical, com desvio pequeno (5 seeds). É honesta e **preliminar** (corpus recente; FNSPID multi-ano é o passo seguinte).

## **O proxy de setor não é fraco?**

É automático, sim — por isso é limitação explícita e por isso dou primazia ao argumento **sem rótulo**.

# Perguntas difíceis do júri (2/2)

## Como garantem que não há lookahead?

O z-score usa só dias anteriores; o impacto mede-se só *depois* do evento, do fecho do 1.º dia de negociação  $\geq$  data. Está em código e testado.

## Como sei que a explicação é verdadeira?

É renderizada dos mesmos objetos calculados  $\Rightarrow$  **fiel por construção**; um teste automático confirma que reproduz exatamente os precedentes, sem inventar.

## Um título positivo deu precedentes negativos. Engana?

A semelhança capta **tema, não direção**; a média é evidência sobre um tema, não previsão. Mostro os precedentes um a um e aviso que não é previsão (evita sobre-confiança).

## Usaram IA para escrever a tese?

Sim, declarado honestamente; dirigi o trabalho, revi e validei tudo; as decisões e o conteúdo são da minha responsabilidade.

# Guião oral — a abertura de 3 minutos (1/2)

Para decorar a **estrutura**, não as palavras. Lê em voz alta 3× antes da defesa.

## Problema + o que é ( $\approx 1$ min)

"Um investidor de retalho vive em sobrecarga: milhares de ações e notícias em contínuo, e as ferramentas que interpretam esses sinais são institucionais ou opacas. A minha dissertação constrói e avalia o **InvestiGator**: um sistema de alertas financeiros **explicável por desenho**, para o mercado norte-americano, entregue no Telegram.

Tem dois gatilhos. Um **movimento abrupto** dispara uma anomalia estatística — um z-score rolante sem lookahead — explicada em linguagem simples. Uma **notícia nova** é comparada, por embeddings de frases, com uma base de notícias históricas, e o alerta mostra os precedentes mais parecidos e o impacto que **de facto** tiveram: evidência do passado, nunca previsão. Este motor de correlação notícia-mercado é o núcleo da tese."



# Guião oral — a abertura de 3 minutos (2/2)

## Avaliação + honestidade ( $\approx 1$ min)

"Avaliei cada componente contra baselines em dados reais. A recuperação semântica atinge  $\text{precision@5}$  de 0,51 contra 0,35 da baseline lexical e 0,24 do acaso. O detetor normalizado pela volatilidade dispara de forma consistente onde um limiar fixo não consegue. E fui além de aplicar componentes: **treinei e calibrei um modelo de triagem de materialidade** sobre 79.753 exemplos de seis anos. O resultado é honesto nos dois sentidos: nenhum modelo que lê o texto bateu a baseline de só-volatilidade — e reporto isso tal como caiu — mas, dentro de um orçamento realista de cinco alertas por dia, a triagem quase **quadruplica** a precisão. Duas vezes dei a um método aprendido uma comparação justa contra a escolha transparente, e duas vezes a escolha transparente venceu: o desenho 'simplicidade defensável' ficou validado com evidência, não com fé."

## Produto ( $\approx 30$ s) + fecho

"O sistema está **ao vivo**: painel público, canal Telegram com varredura automática, bot interativo. Tudo com APIs gratuitas, tudo reproduzível por scripts versionados, com as limitações declaradas." *Fecho universal*: "Preferi um resultado modesto e verdadeiro a um impressionante e frágil — por isso consigo defender cada número desta tese."

# Guião oral — 15 segundos por pergunta de investigação

**RQ1 (deteção transparente)** — "Sim. O z-score rolante tem taxa de disparo consistente entre ações (amplitude 0,015 vs 0,344 de um limiar fixo) e explica-se com média, desvio e janela. Desafiei-o com um método aprendido — Isolation Forest — e o z-score venceu (F1 0,530 vs 0,271)."

**RQ2 (recuperação + impacto)** — "Sim. SBERT dá precision@5 de 0,51 cross-ticker, contra 0,35 lexical e 0,24 aleatório; o impacto é medido com janelas de estudo de evento (+1/+3/+5 dias), sem lookahead, e mostrado como evidência, não como previsão."

**RQ3 (explicações)** — "Fiéis **por construção**: o texto do alerta é gerado diretamente dos objetos calculados, por isso não pode divergir da computação. A utilidade para investidores reais precisa de um estudo humano, que declaro como limitação, não como resultado."

**RQ4 (triagem aprendida)** — "Não na hipótese do texto; sim no mecanismo. Nenhum modelo com texto bateu a só-volatilidade (PR-AUC 0,542 contra 0,496). Mas com orçamento de 5 alertas/dia a triagem sobe a precisão de 0,163 para 0,632, com probabilidades calibradas — treinei, avaliei com protocolo temporal estrito, e reporte o resultado tal como é."

# Perguntas difíceis do júri (3/4) — o modelo e o produto

## O vosso modelo treinado perdeu para a volatilidade. É um fracasso?

Não — a comparação foi **pré-comprometida** no protocolo: escrevi, antes de treinar, que o resultado seria reportado tal como caísse. A RQ4 fica respondida com evidência (o sinal está no contexto de mercado, não no texto, com esta representação); e a triagem vale como mecanismo (0,632 vs 0,163 no orçamento diário). Uma tese que só mostra vitórias é menos credível.

## Como garantem que a triagem não vê o futuro?

Três camadas: (1) convenção de features fixada — tudo calculável no fecho do dia do evento; (2) split temporal por dias únicos com embargo de 5 dias; (3) um **teste unitário que muda os preços do futuro** e verifica que nenhuma feature muda (e que o rótulo muda). Verificação executável, não promessa.

## O alerta de hoje não é igual à figura da tese. Porquê?

O formato de produção foi **compactado depois** de os estudos ficarem congelados (revisão de usabilidade); os CAMPOS são os mesmos, por isso a fidelidade não muda. O Cap. 4 regista a evolução numa frase; o CS3 é registo experimental congelado.

## A app mudou para um painel único — invalida a tese?

Não: a tese nunca prende uma estrutura de UI (verificado: menciona "an interactive dashboard" uma vez + um mockup do formato de mensagem). O pivô é de produto; a ciência avaliada é a mesma.

# Perguntas difíceis do júri (4/4) — método e integridade

## Porquê não "RL a sério" (a ideia do trabalho futuro)?

Porque não há MDP: os meus alertas não afetam o mercado — não existe o ciclo ação→ambiente→recompensa. A forma defensável da ideia é o **loop de pós-validação**: cada decisão real é rotulada dias depois com o desfecho verdadeiro e alimenta retreino.

## Porquê cross-ticker na avaliação de retrieval?

É uma **escolha de avaliação** deliberada: proibir o próprio ticker força o teste a medir semelhança *temática* (o que interessa), não memorização do nome da empresa.

## Isto é mesmo reproduzível?

Cada número da tese sai de um script versionado com seed fixa; re-corremos os 3 scripts de avaliação e os números reproduziram-se exatamente; o retreino do modelo produz ficheiros bit-idênticos; o CI corre 145 testes em runner limpo a cada push.

## Como sei que as citações são reais?

Protocolo de verificação: as 52 referências foram verificadas uma a uma (DOI/arXiv/ISBN/fonte primária) com registo em docs/decisions/page\_audit.md — zero fabricação.

## A vossa KB é de 2018–2023 — os precedentes não estão desatualizados?

Era a limitação mais sentida em produção, e foi corrigida como **iteração informada pelo uso**: o sistema agora cresce uma **KB viva** (cada manchete relevante vira caso dias depois, com o impacto real), ordena com **decaimento por idade** e mostra a idade de cada precedente. A avaliação formal da KB viva fica como trabalho futuro (Cap. 6 di-lo) — mas o mecanismo está construído e a correr.

# O mapa dos números congelados (decorar esta tabela)

| Número                                                                                                 | O que é                                                                                                                                                                                                                                                                                                                                                                                                  | Onde                                                                                                                          |
|--------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| P@5 0,514 $\pm$ 0,015<br>0,538<br>0,015 vs 0,344<br>F1 0,530 vs 0,271<br>z = +7,61<br>+6,46%<br>-1,97% | SBERT-MiniLM vs 0,346 lexical / 0,240 acaso / 0,126 recência<br>P@5 do SBERT-MPNet (melhor, mais pesado)<br>amplitude da taxa de disparo: z-score vs limiar fixo<br>z-score vs Isolation Forest causal (o simples ganha)<br>anomalia real TSLA 24-10-2024 (exemplo trabalhado)<br>impacto médio +5d do exemplo Nvidia/AI (demo reproduz)<br>CS3: título positivo, cluster negativo (tema $\neq$ direção) | Cap. 5, evaluation_results<br>idem<br>Cap. 5, evaluation_anomaly<br>idem<br>Cap. 5 (CS1)<br>Cap. 3, scripts/demo.py<br>Cap. 5 |
| PR-AUC 0,542 vs 0,496<br>0,632 vs 0,163<br>79.753 / 2.016<br>0,992 / 96%<br>86 pp; 52/52               | RQ4: só-volatilidade bate todos os modelos com texto<br>precisão@5-alertas/dia: triagem vs alertar-sempre ( $\approx 4\times$ )<br>exemplos FNSPID do treino / fatia curada na app pública<br>paridade ONNX $\leftrightarrow$ SBERT (cosseno médio; vizinhos top-3)<br>tese 0 erros; todas as citações verificadas                                                                                       | Cap. 5 (CS4)<br>idem<br>kb_fnspid_build<br>onnx_minilm_validation<br>page_audit                                               |
| <i>Extensão CS1 (2026-07-13; corrida nova, protocolo congelado reutilizado — não muda os de cima):</i> |                                                                                                                                                                                                                                                                                                                                                                                                          |                                                                                                                               |
| F1 0,280<br>F1 0,664 vs 0,516<br>944 $\rightarrow$ 42<br>54%                                           | LOF causal (o 2.º detetor aprendido; também perde para 0,530)<br>$\sigma$ EWMA bate $\sigma$ rolling no proxy (achado honesto!)<br>funil real de produção em 5 dias (seletividade 22:1)<br>exemplo trabalhado: P do alerta META real = o valor enviado                                                                                                                                                   | evaluation_anomaly_ext<br>idem<br>alert_funnel<br>triage_worked_example                                                       |

# Extensão do CS1 — LOF e EWMA (e um achado honesto)

**Porquê:** o júri podia perguntar "citaram o LOF mas não o testaram" e "porquê não GARCH?". Resposta nova: **testámos** (mesmo protocolo causal congelado; ficheiros de avaliação NOVOS — os congelados ficam intactos).

- **LOF** (density-based): recall altíssimo (0,989) mas precisão 0,163 → F1 **0,280**; taxas inconsistentes entre tickers (amplitude 0,183). O z-score transparente (0,530) **ganha aos DOIS** detetores aprendidos com a mesma informação.
- **EWMA** ( $\lambda = 0,94$ , RiskMetrics — o 1.<sup>o</sup> passo na direção do GARCH): **surpresa honesta** — com o MESMO recall, quase elimina metade dos falsos positivos (precisão 0,568 vs 0,381) → F1 **0,664 vs 0,516**. Mecanismo: com clustering de volatilidade, a janela rolling dilui um choque por 20 pesos iguais; a EWMA absorve-o logo e não re-alerta os dias seguintes.
- **Decisão:** a regra implantada continua a rolling ("média e desvio de 20 dias" explica-se a um leigo numa frase); o ganho fica REGISTADO como trabalho futuro **já validado** — a adoção é 1 linha de config. É a marca da tese: reportar o que os dados dizem, mesmo quando contraria a expectativa.

*Se o júri perguntar "porquê não GARCH?": "Testámos o primeiro degrau (EWMA) — melhora o proxy e está registado; o degrau completo perde a explicabilidade que é o requisito nº 1."*

# A vida de UM alerta real (decorar este fio) + o funil

O alerta **META, 12-07-2026** ("Zuckerberg: AI bets haven't come to fruition yet"), do feed ao telemóvel (tese: Tabela 4.3 + Tabela 3.4):

- 1 **Fetch** Finnhub → **relevância** (menciona a empresa; não é boilerplate)
- 2 **Captura** na KB viva (embedding MiniLM 384-d; matura a +5d) → **frescura**  $\leq 2d$
- 3 **Retrieval** cosseno  $\times$  decaimento de idade → top-3 (sims 0,46–0,51) → **chão**  $0,51 \geq 0,45$  → aviso "BOTH directions" (sinais mistos)
- 4 **Triagem**: vol20 (+0,409) + setor (+0,303) → logit +0,699 →  $\sigma$  → Platt → **P = 54%  $\geq 0,5$**  — o MESMO valor que saiu no canal (reprodução exata)
- 5 **Teto/dedup** → enviado + registado no histórico partilhado → o dashboard marca-o no gráfico

O funil em agregado (números reais, 5 dias ao vivo): **944** manchetes relevantes capturadas (nos 10 tickers) → gates → **42** alertas (3 tickers) = **seletividade 22:1**. As notícias fluem para todos; os alertas só acontecem onde há precedente forte E triagem material — anti-fadiga por desenho. (Tese: Fig. 4.6, o funil; Apêndice A: o pipeline completo numa página rotada.)

# Feito com — só ferramentas gratuitas e dados abertos

## Fontes de dados & APIs

FNSPID (Hugging Face) yfinance Finnhub RSS SPY (proxy do mercado)

## Aprendizagem automática

Sentence-BERT / MiniLM scikit-learn PyTorch (CPU) calibração Platt ONNX Runtime

## Produto & entrega

Telegram Bot API Streamlit Plotly

## Engenharia & infraestrutura

Python 3.12 GitHub Actions (cron) pytest + ruff joblib

**Sem APIs pagas, sem GPUs, sem servidor sempre ligado** — reproduzível num portátil.



## Plano B — se algo falhar no dia da defesa

- **Sem wifi/projetor:** `python scripts/demo.py` é offline e determinística (reproduz o +6,46%); este guia tem o output real captado em slides.
- **App dormente ou privada:** mostrar o canal Telegram no telemóvel (mensagens reais, com data) ou o screenshot genuíno da tese (Fig. 4.5).
- **Branco sobre um número:** a tabela do slide anterior; cada linha diz o ficheiro de avaliação onde o número vive.
- **Pergunta impossível:** "Não tenho esse resultado medido; a metodologia para o obter seria [...] — e prefiro dizer isso a inventar um número." (Honestidade é a marca da tese.)

*O fecho universal:* "Preferi um resultado modesto e verdadeiro a um impressionante e frágil."

# Checklist final: defender com calma

Consigo responder a tudo isto?

- O que é a tese? (3 frases)
- Porque importa o problema?
- Porquê esta metodologia?
- O que acontece em cada fase?
- Porque o código faz isto?
- E se mudasse este parâmetro?
- Porque bate as baselines?
- Limitações e trabalho futuro?

## Defesa em 3 frases (decorar)

Construí um sistema que avisa o investidor de retalho e **explica** cada alerta com precedentes reais. A contribuição é de **engenharia de IA**: integrar, aplicar e avaliar componentes num todo explicável e reproduzível. **Não prevejo**; mostro evidência do passado, com honestidade sobre os limites.

# Onde continuar a estudar (mapa dos materiais)

**Este guia é a fonte ÚNICA de estudo** (decisão de 2026-07-11: guião oral, perguntas do júri, números e plano B vivem AQUI). As outras peças:

- **Ver a app:** `python scripts/demo.py` — os dois gatilhos, offline, num comando.
- **Correr tudo o resto:** `docs/design/how_to_run.md` (Telegram, notícias ao vivo, construir a KB) — começa no §0.0.
- **A tese:** `thesis/main.pdf` — o documento que vais defender (os números vêm daqui).
- **Slides da defesa (EN):** `slides/main.pdf` — a versão curta para o dia.
- **Notebook:** `notebooks/investigator_walkthrough.ipynb` — os 3 componentes com as tuas mãos, célula a célula.

## Sugestão de estudo

Lê este guia → corre `demo.py` → relê o capítulo da tese sobre a parte que correste → pratica o **guião oral** e as **perguntas do júri** (secção Defesa). Repete nas partes que ainda parecem "caixa preta".

Agora conheces a tese **de fio a pavio**.

Problema · bases de IA · dados · código · workflow · avaliação · decisões · defesa.

Estuda a par da tese e dos slides; volta às partes que precisares. Boa defesa.