

Alertas Financeiros Explicáveis para Investidores de Retalho

Integração de Detecção Estatística de Anomalias e Correlação Notícia–Mercado

Henrique J. S. Santos

Orientador: Prof. Luís Gomes Coorientador: Rafael Silva

MEIA, Instituto Superior de Engenharia do Porto

Defesa

O problema

- A maioria dos norte-americanos possui ações; muitos negociam agora através de aplicações sem comissões.
- O mercado acionista dos EUA atingiu **62,2 bilhões de dólares** (fim de 2024).
- Os investidores de retalho enfrentam movimentos de preço e notícias *contínuos*, **sem** as ferramentas dos bancos e dos fundos.
- A IA que se espalha pelas finanças é largamente **opaca**, má opção para quem tem de agir e viver com o resultado.

As ferramentas gratuitas não respondem a **nenhuma** das três; reportam a percentagem, que é onde a pergunta 1 *começa*. Um terminal Bloomberg responde às três, por cerca de 2.000 dólares por mês. A lacuna não é falta de dados, que são abundantes e gratuitos. É falta de **contexto que se possa verificar**.

As três perguntas


Quando uma posição se mexe, toda a gente faz as mesmas três:

- ❶ Isto é *invulgar para esta ação*?
- ❷ É a *empresa*, ou é o mercado?
- ❸ Já *aconteceu antes*, e o que se seguiu?

O que o InvestiGator faz (e não faz)

Não prevê preços. Explica.

Para cada movimento abrupto ou notícia relevante, mostra *o que* foi detetado, *como*, as *fontes*, e quais os *eventos passados* que se assemelham, com o que aconteceu aos preços a seguir.




Questões de investigação

- RQ1** Podem métodos estatísticos **transparentes** detetar movimentos abruptos de forma consistente o suficiente para serem úteis, mantendo-se explicáveis?
- RQ2** Pode um motor notícia–mercado recuperar precedentes **genuinamente análogos** e quantificar o seu impacto **sem lookahead**, melhor do que linhas de base triviais?
- RQ3** Podem as explicações ser **fiéis** ao que o sistema calcula, e úteis a um investidor de retalho?
- RQ4** Pode um **modelo supervisionado**, treinado sobre notícias históricas e contexto de mercado, **priorizar** utilmente que notícias merecem um alerta, para além das linhas de base de volatilidade — **nunca** prevendo a direção?


Contribuição: *Engenharia* de Inteligência Artificial

Não um novo algoritmo: a **integração, aplicação e avaliação crítica disciplinadas** de componentes existentes — mais **um modelo treinado pelo autor** (triagem de materialidade) — num sistema funcional, explicável e reproduzível.




Componentes de responsabilidade única, esquema comum; dois gatilhos convergem num só passo de explicação.

O modelo de dados — os objetos



Um *caso* = uma manchete passada + o que aconteceu ao seu preço. **NewsItem** ao vivo e **NewsRecord** histórico partilham o esquema, pelo que uma manchete nova é diretamente comparável.

Os dados, em cada fase — uma manchete real



Todos os valores são genuínos (Nvidia, 10 Mai 2018). A "IA" é o passo **REPRESENTAR**: o texto torna-se um embedding de 384 dimensões, o evento torna-se features de contexto, o resultado torna-se um rótulo.

Gatilho de mercado: transparente por desenho

z-score deslizando, sem lookahead:

$$z_t = \frac{r_t - \mu_t}{\sigma_t}, \quad \text{assinalar se } |z_t| > k$$

μ_t, σ_t sobre a janela *antes* de t . Cada quantidade é exposta à explicação.

Exemplo trabalhado (real)

TSLA, 24 Out 2024 (pós-resultados):
 $\mu = -0.92\%$, $\sigma = 2.73\%$, $r = +19.8\%$
 $\Rightarrow z = +7.61$ (assinalado a $k = 3$).

Um limiar de % fixa trataria uma ação calma e uma volátil de igual modo; o z-score não.

Pergunta 2: é a empresa, ou é o mercado?

Um modelo de mercado de dois fatores, estimado **só com dados anteriores ao dia que se explica**:

$$r_t = \alpha + \beta_m r_t^m + \beta_s \tilde{r}_t^s + \varepsilon_t$$

O fator de setor é **ortogonalizado** contra o mercado (um ETF e o índice são colineares; sem isso a atribuição perde sentido).

Os betas são **encolhidos pela precisão**, não cortados: uma estimativa ruidosa de 20 dias é puxada para o seu prior, uma limpa fica intacta.

Real, do sistema ao vivo

AMZN -1,84% hoje

= -1,66% mercado · -0,37% setor · +0,19%
empresa

“Moveu-se com o mercado inteiro.”

A ação caiu quase dois por cento e a contribuição própria da empresa foi **positiva**. Para o detentor de longo prazo, a saída mais valiosa que um sistema pode dar é muitas vezes **permissão para ignorar**.

As componentes somam o movimento observado por construção, por isso a linha não pode mentir.

O que vigia — e porque duas das doze não são tecnológicas



Até Agosto de 2026 a watchlist tinha **dez** nomes, e **nove estavam no XLK**. A pergunta “foi o setor?” vinha quase sempre com a mesma resposta — não por ser essa a resposta, mas porque a watchlist não dava ao fator de setor nada por onde variar. **A XOM (energia) e a JNJ (saúde) entraram para corrigir isso**, e o efeito apareceu logo no que o sistema produziu ao vivo: **XOM $-0,98\%$ num dia em que o seu setor fez $+0,93\%$** — o setor a puxar ao *contrário*, coisa que nove nomes tecnológicos não podiam ter mostrado.

Isto é uma alteração à *avaliação*, não à disposição do ecrã.

Gatilho de notícias: recuperar precedentes análogos, medir impacto

- 1 Fazer o embedding da manchete (Sentence-BERT).
- 2 Similaridade do cosseno vs a base de conhecimento.
- 3 Devolver os top- k precedentes.
- 4 Medir o seu impacto a +1/ +3/ +5 dias, a partir do fecho do dia do evento (**sem lookahead**).

Raciocínio baseado em casos: evidência, não uma previsão.

Exemplo trabalhado (real)

Consulta: "Nvidia demand surges on AI chip orders"


→ NVDA guidance (sim 0.60) +5d +3.5%

→ MSFT cloud-AI (sim 0.38) +5d +10.9%

→ NVDA accelerator (sim 0.38) +5d +4.9%

Correspondência **cross-ticker** (MSFT); média +5d $\approx$ +6.5%.

Resultado 1: a deteção de anomalias é consistente em todo o mercado




- Amplitude da taxa de disparo em 15 tickers: **0.015** (z-score) vs **0.344** (% fixa).
- $> 20\times$ mais consistente, um argumento **sem rótulos**.
- Vs indicador de movimentos extremos: $F_1 = 0.516$ vs 0.218.
- Ablação de janela: F_1 0.385 / 0.516 / 0.678 (10/20/60 d).

Resultado 2: a recuperação semântica bate todas as linhas de base

Método	P@5	P@10
SBERT (MiniLM)	0.514	0.478
SBERT (MPNet)	0.538	0.506
Lexical	0.346	0.314
Recência	0.126	0.106
Aleatório	0.240	0.240

Cross-ticker, 3,714 manchetes, 5 sementes ($\pm \sim 0.01$).



Ganho maior onde o vocabulário é distintivo (energia, saúde).

Validado à escala no FNSPID multi-ano ($\sim 80k$ manchetes): **P@5** 0.595; consistência de direção 0.71 no chão do acaso 0.69 (tema, não direção).

Resultado 3: as explicações são fiéis por construção

- Cada alerta é composto *diretamente* a partir dos objetos calculados.
- Por isso o texto **não pode divergir** do cálculo.
- Verificado por um teste automático (o alerta reproduz a data/ticker/impacto de cada precedente).
- Cada alerta termina com um aviso de não-previsão.

Alerta real (gatilho de notícias)

```
News alert -- NVDA
"Nvidia raises guidance...AI data-centre"
Avg 1-day move:  -1.97% (over 5; 3 shown)
- MSFT (0.68) +1d -3.46%
- META (0.68) +1d -2.65%
- GOOGL (0.64) +1d -0.46%
observed past outcome, not a prediction
```

Resultado 3b: a mesma garantia, para linguagem gerada

Um modelo de linguagem foi acrescentado **estritamente como narrador**: pode redigir a evidência, nunca fornecê-la. Uma guarda valida cada resposta antes da entrega e **descarta-a inteira** perante:

- um número ausente da evidência,
- um valor com o **sinal** invertido,
- formulação preditiva ou de conselho,
- uma atribuição que contradiga a calculada.

A garantia é propriedade **do sistema**, não do modelo portar-se bem.

Dois números, de propósito

Pré-guarda: o modelo cru violou a evidência em alguns casos.

⇒ *é por isto que a guarda existe.*

Entregue: zero violações.

⇒ *é a guarda que está em julgamento.*

Ressalva honesta: o segundo é em parte circular, já que o mesmo verificador decide e avalia. O contrapeso é um corpus de red team: um exercício independente partiu o *primeiro* desenho (uma blocklist) com 29 contornos reproduzidos. O espaço de paráfrases é ilimitado e qualquer lista dele é finita, por isso a guarda foi reconstruída como **vocabulário fechado**. Esses ataques são hoje testes de regressão

Resultado 4: triagem aprendida — treinada, calibrada, honesta

- **Tarefa:** P (movimento anormal segue a notícia) — materialidade, **nunca** direção. Rótulos do nosso próprio estudo de evento ($|\text{ticker} - \text{SPY}| \geq 2\%$ em $(d, d+3]$).
- **Corpus:** FNSPID 2018–2023, 79,753 exemplos; split temporal por dia + embargo; calibração só na validação.
- **Anti-lookahead:** um teste unitário *muda os preços futuros* — features inalteradas, rótulo muda.

Modelo	PR-AUC	P@5/dia
Sempre (base)	0.378	0.163
Volatilidade LR	0.542	0.632
Contexto LR	0.538	0.632
Contexto+texto LR	0.496	0.585
Gradient boosting	0.469	0.551

O veredicto honesto (pré-comprometido)

Dentro de um orçamento de 5 alertas/dia, a triagem quase **quadruplica a precisão** (0.632 vs 0.163) *em dados retidos do corpus de treino* — mas **nenhum modelo de texto bateu a volatilidade**. Uma ablação de seguimento juntou *cinco* features de contexto baratas (regime de mercado, momentum, reação padronizada, risco de queda): PR-AUC 0.535, de novo **sem ganho**. Um re-teste *justo* (C afinado, texto reduzido por PCA, um encoder de domínio FinBERT) continua a não bater a volatilidade, pelo que o negativo é **robusto**, não um artefacto de sub-ajuste. O sinal é o contexto de

O defeito que mostrou que o modelo nunca decidia

O que aconteceu. A Nvidia subiu com força na sequência de um anúncio de fornecimento. O canal levou nesse dia **duas histórias menores** da Nvidia e **nunca levou essa**.

Porquê. O tecto diário de dois alertas por empresa era servido **por ordem de chegada**. Duas histórias irrelevantes de manhã esgotavam o orçamento; a da tarde caía **sem deixar rasto em log nenhum**.

A parte incómoda

O instrumento já lá estava. A triagem existe para ordenar por materialidade, e eleva a precisão de 0.163 para 0.632 num orçamento de 5 alertas — e **o tecto nunca a consultava**. A pontuação era medida e depois ignorada.

A primeira correcção não funcionou, e é essa a parte interessante. Ordenar o tecto por pontuação só reordena candidatas presentes *ao mesmo tempo*, e a varredura emite uma manchete por empresa por ciclo — duas histórias a disputar a mesma quota nunca coexistem. Ao longo do dia a ordem continuou a ser a de chegada. Quem governa o tecto é um **piso escalonado**: o k -ésimo alerta do dia exige mais (0.49, depois 0.64), ambos *derivados* do varrimento de custo,

Resultado 5: o que o sistema *não* sabe

Quatro estudos que examinam o sistema por fora. Cada um termina numa decisão de **não** mudar a produção, tomada com base na evidência. O quarto, convergência multi-sinal, adaptado do **worldmonitor.app** por recomendação do coorientador: fundir quatro sinais independentes bateu o melhor deles num orçamento de alertas em três, pelo que fica como medição. O seu subproduto, um detetor de **volume** a custo zero em dados, fica.

Tipos de evento

Agrupámos os embeddings contra uma rubrica escrita *antes* de agrupar.

Concordância (corrigida para o acaso): evento **0.358** > ticker 0.188 > setor 0.130.

Logo o espaço *codifica* tipo de evento, mais do que assunto. Mas a separação é fraca (silhueta 0.084) $\Rightarrow$ **não** ligado à recuperação: um tipo errado deita fora precedentes válidos em silêncio.

Garantia conformal

Cobertura livre de distribuição sobre o modelo *congelado* (PR-AUC reproduzida exatamente primeiro).

Aguenta-se a 90%/80%; **parte-se a 95%** sob divisão temporal. Cobertura mais apertada apoia-se na cauda, e a cauda move-se primeiro.

O preço: para prometer 90%, decisão definida em apenas **39,5%** das manchetes.

Deriva, medida

A limitação que andávamos a *afirmar*, finalmente dimensionada.


Volatilidade pré-evento PSI **0.281** (significativa); features de retorno 0.020 / 0.014 (estáveis).

A prevalência do rótulo *oscila* (0.385 $\rightarrow$ 0.470 $\rightarrow$ 0.378), não tem tendência. Dá um **gatilho de re-treino** em vez de uma intuição.

Porque é que isto vale mais do que outro número positivo

O produto, ao vivo

Uma captura genuína, não um mockup. **Cada cartão abre com uma frase, e só depois os números que a sustentam.**



- **A raridade é uma contagem, não uma probabilidade** — “apenas 5 dos últimos 249 dias se moveram tanto”. Converter z numa probabilidade exigiria normalidade; as caudas são pesadas, logo falharia nos dias que interessam.
- **A quietude é evidenciada, não afirmada** — um dia calmo mostra a contagem que o torna calmo.
- **Quando as duas medidas discordam, mostram-se as duas** — Microsoft: abaixo do limiar face aos seus 20 dias, e ainda assim só 5 em 249 se moveram tanto

Feito com — ferramentas gratuitas e dados abertos, de ponta a ponta

Fontes de dados & APIs



FNSPID (Hugging Face)



yfinance



Finnhub



feeds RSS

SPY (proxy de mercado)

Aprendizagem automática



Sentence-BERT / MiniLM



scikit-learn



PyTorch (CPU)

calibração de Platt



ONNX Runtime

Produto & entrega



Telegram Bot API



Streamlit



Plotly

Engenharia & infraestrutura



Python 3.12



GitHub Actions (cron)



pytest + ruff

joblib

Sem APIs pagas, sem GPUs, sem servidor sempre ligado — reproduível num portátil.

Resultado 9: o gate foi medido em produção, e não transferiu

Cada decisão de triagem é registada e, dias depois, rotulada com o que o preço fez — a mesma regra do treino. Sobre **530** decisões maturadas:

Os alertas que o gate...	eram materiais
manteve ($p \geq 0.5$)	0.592
suprimiu ($p < 0.5$)	0.647

O gate está do lado *errado*, embora não significativamente ($z = -1,28$, $p = 0,20$).

Porquê, e não é um modelo avariado — é um modelo redundante. A materialidade nas decisões registadas corre a 0.626 contra 0.378 no treino, porque só se registam decisões para manchetes que *já* passaram os filtros de relevância e frescura. As etapas baratas a montante já tinham removido o que a etapa aprendida foi treinada para remover. **Um modelo avaliado isolado e implantado atrás de filtros nunca foi avaliado na distribuição que ia ver.** O gate fica ligado como controlo de *volume* (suprime $\sim 3/5$) e por ser a parte instrumentada —

Qual das falhas é?

Duas falhas parecem iguais aqui e pedem correcções opostas. Se a pontuação ainda **ordena**, recalibra-se (dois parâmetros). Se não ordena, recalibrar não serve — a sigmóide é **monótona**, preserva a ordem exactamente.

Medido: **ROC-AUC** 0.494, IC de cluster
[0.391, 0.601] sobre 145 unidades (ticker, dia).

Centrado no acaso. **Não há ordem para preservar.**

Limitações (enunciadas com clareza)

- A relevância é um **indicador aproximado por mesmo setor**, não um juízo humano.
- O corpus de recuperação é uma janela **recente** da camada gratuita (entretanto validada à escala no FNSPID, P@5 0.595); o estudo de *triagem* usou de facto o FNSPID multi-ano (14/15 tickers — a Meta é “FB” no corpus).
- O impacto de precedente mostrado é um retorno pós-evento **bruto** (os rótulos de triagem são ajustados ao mercado).
- A similaridade é **temática, não direcional**: um agrupamento pode misturar movimentos de subida/descida, pelo que a média é *evidência* ao nível do tema, não uma previsão. *Testámos* a correção óbvia (filtrar por tipo de evento) e ela não se sustenta — ver Resultado 5.
- **A confiança é fina, e está agora quantificada**: garantir 90% de cobertura deixa uma decisão definida em apenas **39,5%** das manchetes.
- **A deriva treino/implantação é medida, não apenas alegada**: concentrada na volatilidade (PSI 0.281), e cíclica em vez de com tendência.
- **Ainda sem estudo humano de utilidade** (utilidade da RQ3 em aberto).
- Por desenho: **sem previsão de preços, sem negociação**, pelo que as métricas de lucro

Conclusões

- **RQ1 (sim):** o z-score transparente deteta de forma consistente em todo o mercado e explica cada marca.
- **RQ2 (sim, validada à escala):** a recuperação semântica muito acima das linhas de base (P@5 0.595 no FNSPID multi-ano); impacto medido sem lookahead.
- **RQ3 (fiel sim; útil em aberto):** as explicações não podem divergir do cálculo; a utilidade para humanos é trabalho futuro.
- **RQ4 (não no texto; mecanismo sim *offline*):** a triagem $\approx 4\times$ de precisão dentro do orçamento em dados retidos, mas a volatilidade ficou imbatida — o *segundo* teste justo “aprendido vs simples” que a escolha transparente venceu (o primeiro: Isolation Forest vs z-score, F_1 0.271 vs 0.530). Medido em produção, o mesmo gate ordena ao acaso (Resultado 9), pelo que a afirmação sobre o mecanismo é de conjunto de avaliação e é enunciada como tal.

Contribuição

Um sistema de alertas financeiros funcional, **explicável e reprodutível** para investidores de retalho — componentes existentes mais um modelo de triagem treinado pelo autor,

InvestiGator

Alertas financeiros explicáveis para investidores de retalho

Perguntas são bem-vindas.

Perguntas antecipadas

- **Porquê não prever preços?** Eficiência de mercado (Fama 1970): as notícias públicas são absorvidas depressa; nós *medimos* reações, honestamente.
- **Porquê z-score, não Isolation Forest/GARCH?** Transparência para um sinal de baixa dimensão — e *testámo-lo*: uma Isolation Forest causal sobre a mesma informação perdeu (F_1 0.271 vs 0.530).
- **O vosso modelo treinado perdeu para a linha de base da volatilidade. Fracasso?** Não: a comparação foi *pré-comprometida* e responde à RQ4 com evidência. A triagem dá $\approx 4\times$ de precisão dentro do orçamento em dados retidos, e a variante em produção usa exatamente as features que carregam o sinal.
- **Então o ML funciona em produção?** *Como selector não, e medi-o* (ROC-AUC 0.494). Como controlo de volume sim. A razão é instrutiva: os filtros a montante já tinham removido o que ele foi treinado para remover, portanto é redundante e não avariado — uma lição sobre colocar um componente aprendido *dentro* de uma pipeline.
- **O sistema aprende automaticamente?** Não. Faz *inferência* com pesos fixos e *recolhe rótulos*; o re-treino é possível e está documentado, mas nunca correu. Chamar-lhe aprendizagem contínua seria exagero.
- **Como sabem que o modelo de triagem nunca vê o futuro?** Um teste unitário muda os preços pós-evento e verifica que as features ficam inalteradas enquanto o rótulo muda; split temporal por dia único com um embargo de cinco dias.
- **Porquê precisão@k e um proxy de setor?** Métrica padrão de recuperação ordenada; objetiva, reproduzível; a relevância humana é trabalho futuro.

Perguntas antecipadas (continuação)

- **“Zero violações entregues” não é circular, se é o vosso próprio verificador a avaliar?** Em parte é, e a tese di-lo. Por isso não é o único teste: um red team independente partiu a guarda *anterior* com 29 contornos reproduzidos, construídos sem ver o desenho atual, e esses ataques são hoje testes de regressão.
- **Então construíram um sistema multi-agente?** Não, e não o vou reivindicar. Um modelo a chamar algumas funções não é multi-agente. O narrador é uma **função pura** da evidência para um parágrafo.
- **Porquê excluir os price targets de analistas? São gratuitos.** Porque importar a previsão de outra pessoa para um sistema definido por não prever é uma contradição. Preferiu-se a coerência à cobertura, e está enunciado como posição no Capítulo 6.
- **Porquê nenhuma funcionalidade de carteira?** As posições são dados financeiros pessoais, e “as tuas maiores posições são uma só aposta” é aconselhamento, seja qual for a redação. Isso atravessa a fronteira de que a afirmação ética depende.
- **De onde vem o limiar de triagem 0,5?** Originalmente de lado nenhum, que era o problema honesto. Varrê-lo sob um rácio de custo explícito mostrou que assumia implicitamente que uma falha custa aproximadamente o mesmo que um falso alarme; sob custos iguais o ótimo fica onde a constante já estava. Vindicado, mas agora *derivado*.
- **Os vossos alertas chegam horas atrasados.** Medido: mediana de cerca de três horas, e a causa é o agendador gratuito, não o método. O caminho sempre-ligado está escrito e custa cerca de um minuto; implantá-lo ficou fora do âmbito da avaliação, e o número honesto está **à vista no produto** em vez de