

Alertas Financeiros Explicáveis para Investidores de Retalho

Integração de Detecção Estatística de Anomalias e Correlação Notícia–Mercado

Henrique J. S. Santos

Orientador: Prof. Luís Gomes Coorientador: Rafael Silva

MEIA, Instituto Superior de Engenharia do Porto

Defesa

O problema

- A maioria dos norte-americanos possui ações; muitos negociam agora através de aplicações sem comissões.
- O mercado acionista dos EUA atingiu **62,2 bilhões de dólares** (fim de 2024).
- Os investidores de retalho enfrentam movimentos de preço e notícias *contínuos*, **sem** as ferramentas dos bancos e dos fundos.
- A IA que se espalha pelas finanças é largamente **opaca**, má opção para quem tem de agir e viver com o resultado.


Dois desafios distintos

- 1 Distinguir um movimento *genuinamente* invulgar da volatilidade comum.
- 2 Ler o que uma notícia pode *significar*, a partir de como eventos semelhantes se comportaram antes.

O que o InvestiGator faz (e não faz)

Não prevê preços. Explica.

Para cada movimento abrupto ou notícia relevante, mostra *o que* foi detetado, *como*, as *fontes*, e quais os *eventos passados* que se assemelham, com o que aconteceu aos preços a seguir.




Questões de investigação

- RQ1** Podem métodos estatísticos **transparentes** detetar movimentos abruptos de forma consistente o suficiente para serem úteis, mantendo-se explicáveis?
- RQ2** Pode um motor notícia–mercado recuperar precedentes **genuinamente análogos** e quantificar o seu impacto **sem lookahead**, melhor do que linhas de base triviais?
- RQ3** Podem as explicações ser **fiéis** ao que o sistema calcula, e úteis a um investidor de retalho?
- RQ4** Pode um **modelo supervisionado**, treinado sobre notícias históricas e contexto de mercado, **priorizar** utilmente que notícias merecem um alerta, para além das linhas de base de volatilidade — **nunca** prevendo a direção?


Contribuição: *Engenharia* de Inteligência Artificial

Não um novo algoritmo: a **integração, aplicação e avaliação crítica disciplinadas** de componentes existentes — mais **um modelo treinado pelo autor** (triagem de materialidade) — num sistema funcional, explicável e reproduzível.




Componentes de responsabilidade única, esquema comum; dois gatilhos convergem num só passo de explicação.

O modelo de dados — os objetos



Um *caso* = uma manchete passada + o que aconteceu ao seu preço. **NewsItem** ao vivo e **NewsRecord** histórico partilham o esquema, pelo que uma manchete nova é diretamente comparável.

Os dados, em cada fase — uma manchete real



Todos os valores são genuínos (Nvidia, 10 Mai 2018). A “IA” é o passo **REPRESENTAR**: o texto torna-se um embedding de 384 dimensões, o evento torna-se features de contexto, o resultado torna-se um rótulo.

Gatilho de mercado: transparente por desenho

z-score deslizando, sem lookahead:

$$z_t = \frac{r_t - \mu_t}{\sigma_t}, \quad \text{assinalar se } |z_t| > k$$

μ_t, σ_t sobre a janela *antes* de t . Cada quantidade é exposta à explicação.

Exemplo trabalhado (real)

TSLA, 24 Out 2024 (pós-resultados):
 $\mu = -0.92\%$, $\sigma = 2.73\%$, $r = +19.8\%$
 $\Rightarrow z = +7.61$ (assinalado a $k = 3$).

Um limiar de % fixa trataria uma ação calma e uma volátil de igual modo; o z-score não.

Gatilho de notícias: recuperar precedentes análogos, medir impacto

- 1 Fazer o embedding da manchete (Sentence-BERT).
- 2 Similaridade do cosseno vs a base de conhecimento.
- 3 Devolver os top- k precedentes.
- 4 Medir o seu impacto a +1/ +3/ +5 dias, a partir do fecho do dia do evento (**sem lookahead**).

Raciocínio baseado em casos: evidência, não uma previsão.

Exemplo trabalhado (real)

Consulta: "Nvidia demand surges on AI chip orders"


→ NVDA guidance (sim 0.60) +5d +3.5%

→ MSFT cloud-AI (sim 0.38) +5d +10.9%

→ NVDA accelerator (sim 0.38) +5d +4.9%

Correspondência **cross-ticker** (MSFT); média +5d $\approx$ +6.5%.

Resultado 1: a deteção de anomalias é consistente em todo o mercado




- Amplitude da taxa de disparo em 15 tickers: **0.015** (z-score) vs **0.344** (% fixa).
- $> 20\times$ mais consistente, um argumento **sem rótulos**.
- Vs indicador de movimentos extremos: $F_1 = 0.516$ vs 0.218.
- Ablação de janela: F_1 0.385 / 0.516 / 0.678 (10/20/60 d).

Resultado 2: a recuperação semântica bate todas as linhas de base

Método	P@5	P@10
SBERT (MiniLM)	0.514	0.478
SBERT (MPNet)	0.538	0.506
Lexical	0.346	0.314
Recência	0.126	0.106
Aleatório	0.240	0.240

Cross-ticker, 3,714 manchetes, 5 sementes ($\pm \sim 0.01$).



Ganho maior onde o vocabulário é distintivo (energia, saúde).

Validado à escala no FNSPID multi-ano ($\sim 80k$ manchetes): **P@5** 0.595; consistência de direção 0.71 no chão do acaso 0.69 (tema, não direção).

Resultado 3: as explicações são fiéis por construção

- Cada alerta é composto *diretamente* a partir dos objetos calculados.
- Por isso o texto **não pode divergir** do cálculo.
- Verificado por um teste automático (o alerta reproduz a data/ticker/impacto de cada precedente).
- Cada alerta termina com um aviso de não-previsão.

Alerta real (gatilho de notícias)

```
News alert -- NVDA
"Nvidia raises guidance...AI data-centre"
Avg 1-day move:  -1.97% (over 5; 3 shown)
- MSFT (0.68) +1d -3.46%
- META (0.68) +1d -2.65%
- GOOGL (0.64) +1d -0.46%
observed past outcome, not a prediction
```

Resultado 4: triagem aprendida — treinada, calibrada, honesta


- **Tarefa:** P (movimento anormal segue a notícia) — materialidade, **nunca** direção. Rótulos do nosso próprio estudo de evento ($|\text{ticker} - \text{SPY}| \geq 2\%$ em $(d, d+3]$).
- **Corpus:** FNSPID 2018–2023, 79,753 exemplos; split temporal por dia + embargo; calibração só na validação.
- **Anti-lookahead:** um teste unitário *muda os preços futuros* — features inalteradas, rótulo muda.

Modelo	PR-AUC	P@5/dia
Sempre (base)	0.378	0.163
Volatilidade LR	0.542	0.632
Contexto LR	0.538	0.632
Contexto+texto LR	0.496	0.585
Gradient boosting	0.469	0.551

O veredicto honesto (pré-comprometido)

Dentro de um orçamento de 5 alertas/dia, a triagem quase **quadruplica a precisão** (0.632 vs 0.163) — mas **nenhum modelo de texto bateu a volatilidade**. Uma ablação de seguimento juntou *cinco* features de contexto baratas (regime de mercado, momentum, reação padronizada, risco de queda): PR-AUC 0.535, de novo **sem ganho**. Um re-teste *justo* (C afinado, texto reduzido por PCA, um encoder de domínio FinBERT) continua a não bater a volatilidade, pelo que o negativo é **robusto**, não um artefacto de sub-ajuste. O sinal é o contexto de mercado; reportado tal como se revelou.

O produto, ao vivo



- Uma página, uma aba por ticker da watchlist — uma captura genuína, não um mockup.
- Risco de fundo do modelo de triagem treinado, todos os dias, sem precisar de notícia.
- Gráfico anotado com os eventos detetados + uma tabela de histórico — o **mesmo** registo que o canal Telegram recebeu.
- Apenas camada gratuita: GitHub Actions (cron) + Streamlit Community Cloud.

Feito com — ferramentas gratuitas e dados abertos, de ponta a ponta

Fontes de dados & APIs

FNSPID (Hugging Face)

yfinance

Finnhub

feeds RSS

SPY (proxy de mercado)

Aprendizagem automática

Sentence-BERT / MiniLM

scikit-learn

PyTorch (CPU)

calibração de Platt

ONNX Runtime

Produto & entrega

Telegram Bot API

Streamlit

Plotly

Engenharia & infraestrutura

Python 3.12

GitHub Actions (cron)

pytest + ruff

joblib

Sem APIs pagas, sem GPUs, sem servidor sempre ligado — reproduzível num portátil.

Limitações (enunciadas com clareza)

- A relevância é um **indicador aproximado por mesmo setor**, não um juízo humano.
- O corpus de recuperação é uma janela **recente** da camada gratuita (entretanto validada à escala no FNSPID, P@5 0.595); o estudo de *triagem* usou de facto o FNSPID multi-ano (14/15 tickers — a Meta é “FB” no corpus).
- O impacto de precedente mostrado é um retorno pós-evento **bruto** (os rótulos de triagem são ajustados ao mercado).
- A similaridade é **temática, não direcional**: um agrupamento pode misturar movimentos de subida/descida, pelo que a média é *evidência* ao nível do tema, não uma previsão.
- **Ainda sem estudo humano de utilidade** (utilidade da RQ3 em aberto).
- Por desenho: **sem previsão de preços, sem negociação**, pelo que as métricas de lucro estão fora de âmbito.

Todos os resultados são reproduzíveis a partir de scripts versionados (re-correr: números idênticos).

Conclusões

- **RQ1 (sim):** o z-score transparente deteta de forma consistente em todo o mercado e explica cada marca.
- **RQ2 (sim, validada à escala):** a recuperação semântica muito acima das linhas de base (P@5 0.595 no FNSPID multi-ano); impacto medido sem lookahead.
- **RQ3 (fiel sim; útil em aberto):** as explicações não podem divergir do cálculo; a utilidade para humanos é trabalho futuro.
- **RQ4 (não no texto; sim no mecanismo):** a triagem $\approx 4\times$ de precisão dentro do orçamento, mas a volatilidade ficou imbatida — o *segundo* teste justo “aprendido vs simples” que a escolha transparente venceu (o primeiro: Isolation Forest vs z-score, F_1 0.271 vs 0.530).

Contribuição

Um sistema de alertas financeiros funcional, **explicável e reprodutível** para investidores de retalho — componentes existentes mais um modelo de triagem treinado pelo autor, engendrados num todo transparente, com uma avaliação honesta.

InvestiGator

Alertas financeiros explicáveis para investidores de retalho

Perguntas são bem-vindas.

Perguntas antecipadas

- **Porquê não prever preços?** Eficiência de mercado (Fama 1970): as notícias públicas são absorvidas depressa; nós *medimos* reações, honestamente.
- **Porquê z-score, não Isolation Forest/GARCH?** Transparência para um sinal de baixa dimensão — e *testámo-lo*: uma Isolation Forest causal sobre a mesma informação perdeu (F_1 0.271 vs 0.530).
- **O vosso modelo treinado perdeu para a linha de base da volatilidade. Fracasso?** Não: a comparação foi *pré-comprometida* e responde à RQ4 com evidência; a triagem ainda dá $\approx 4\times$ de precisão dentro do orçamento vs alertar sempre, e a variante em produção usa exatamente as features que carregam o sinal.
- **Como sabem que o modelo de triagem nunca vê o futuro?** Um teste unitário muda os preços pós-evento e verifica que as features ficam inalteradas enquanto o rótulo muda; split temporal por dia único com um embargo de cinco dias.
- **Porquê precisão@k e um proxy de setor?** Métrica padrão de recuperação ordenada; objetiva, reprodutível; a relevância humana é trabalho futuro.
- **Restrição cross-ticker?** Uma escolha de *avaliação* para evitar auto-correspondências triviais; o alerta ao vivo mostra os precedentes mais similares, seja qual for a empresa.
- **Uma manchete positiva recuperou precedentes negativos (−1.97%). Enganador?** A similaridade capta o *tema*, não a direção; a média é **evidência** ao nível do tema, mostrada com cada precedente e um aviso de não-previsão. Trabalho futuro: de-duplicar precedentes e sinalizar divergência de direção.
- **É reprodutível?** Sim: sementes fixas, dependências fixadas, scripts versionados; re-correr reproduz cada