

# Alertas Financeiros Explicáveis para Investidores de Retalho

## Integração de Detecção Estatística de Anomalias e Correlação Notícia–Mercado

Henrique J. S. Santos

Orientador: Prof. Luís Gomes    Coorientador: Rafael Silva

MEIA, Instituto Superior de Engenharia do Porto

Defesa

# O problema

- A maioria dos norte-americanos possui ações; muitos negociam agora através de aplicações sem comissões.
- O mercado acionista dos EUA atingiu **62,2 bilhões de dólares** (fim de 2024).
- Os investidores de retalho enfrentam movimentos de preço e notícias *contínuos*, **sem** as ferramentas dos bancos e dos fundos.
- A IA que se espalha pelas finanças é largamente **opaca**, má opção para quem tem de agir e viver com o resultado.

As ferramentas gratuitas não respondem a **nenhuma** das três; reportam a percentagem, que é onde a pergunta 1 *começa*. Um terminal Bloomberg responde às três, por cerca de 2.000 dólares por mês. A lacuna não é falta de dados, que são abundantes e gratuitos. É falta de **contexto que se possa verificar**.

## As três perguntas


Quando uma posição se mexe, toda a gente faz as mesmas três:

- 1 Isto é *invulgar para esta ação*?
- 2 É a *empresa*, ou é o mercado?
- 3 Já *aconteceu antes*, e o que se seguiu?

# O que o InvestiGator faz (e não faz)

**Não prevê preços. Explica.**

Para cada movimento abrupto ou notícia relevante, mostra *o que* foi detetado, *como*, as *fontes*, e quais os *eventos passados* que se assemelham, com o que aconteceu aos preços a seguir.




## Questões de investigação

- RQ1** Podem métodos estatísticos **transparentes** detetar movimentos abruptos de forma consistente o suficiente para serem úteis, mantendo-se explicáveis?
- RQ2** Pode um motor notícia–mercado recuperar precedentes **genuinamente análogos** e quantificar o seu impacto **sem lookahead**, melhor do que linhas de base triviais?
- RQ3** Podem as explicações ser **fiéis** ao que o sistema calcula, e úteis a um investidor de retalho?
- RQ4** Pode um **modelo supervisionado**, treinado sobre notícias históricas e contexto de mercado, **priorizar** utilmente que notícias merecem um alerta, para além das linhas de base de volatilidade — **nunca** prevendo a direção?


Contribuição: *Engenharia* de Inteligência Artificial

Não um novo algoritmo: a **integração, aplicação e avaliação crítica disciplinadas** de componentes existentes — mais **um modelo treinado pelo autor** (triagem de materialidade) — num sistema funcional, explicável e reproduzível.




Componentes de responsabilidade única, esquema comum; dois gatilhos convergem num só passo de explicação.

# O modelo de dados — os objetos



Um *caso* = uma manchete passada + o que aconteceu ao seu preço. **NewsItem** ao vivo e **NewsRecord** histórico partilham o esquema, pelo que uma manchete nova é diretamente comparável.

# Os dados, em cada fase — uma manchete real



Todos os valores são genuínos (Nvidia, 10 Mai 2018). A "IA" é o passo **REPRESENTAR**: o texto torna-se um embedding de 384 dimensões, o evento torna-se features de contexto, o resultado torna-se um rótulo.

# Gatilho de mercado: transparente por desenho

z-score deslizando, sem lookahead:

$$z_t = \frac{r_t - \mu_t}{\sigma_t}, \quad \text{assinalar se } |z_t| > k$$

$\mu_t, \sigma_t$  sobre a janela *antes* de  $t$ . Cada quantidade é exposta à explicação.

## Exemplo trabalhado (real)

TSLA, 24 Out 2024 (pós-resultados):  
 $\mu = -0.92\%$ ,  $\sigma = 2.73\%$ ,  $r = +19.8\%$   
 $\Rightarrow z = +7.61$  (assinalado a  $k = 3$ ).

Um limiar de % fixa trataria uma ação calma e uma volátil de igual modo; o z-score não.



## Pergunta 2: é a empresa, ou é o mercado?

Um modelo de mercado de dois fatores, estimado **só com dados anteriores ao dia que se explica**:

$$r_t = \alpha + \beta_m r_t^m + \beta_s \tilde{r}_t^s + \varepsilon_t$$

O fator de setor é **ortogonalizado** contra o mercado (um ETF e o índice são colineares; sem isso a atribuição perde sentido).

Os betas são **encolhidos pela precisão**, não cortados: uma estimativa ruidosa de 20 dias é puxada para o seu prior, uma limpa fica intacta.

Real, do sistema ao vivo

**AMZN** -1,84% hoje

= -1,66% mercado · -0,37% setor · +0,19%  
**empresa**

*“Moveu-se com o mercado inteiro.”*

A ação caiu quase dois por cento e a contribuição própria da empresa foi **positiva**. Para o detentor de longo prazo, a saída mais valiosa que um sistema pode dar é muitas vezes **permissão para ignorar**.

As componentes somam o movimento observado por construção, por isso a linha não pode mentir.

# Gatilho de notícias: recuperar precedentes análogos, medir impacto

- 1 Fazer o embedding da manchete (Sentence-BERT).
- 2 Similaridade do cosseno vs a base de conhecimento.
- 3 Devolver os top- $k$  precedentes.
- 4 Medir o seu impacto a +1/ +3/ +5 dias, a partir do fecho do dia do evento (**sem lookahead**).

*Raciocínio baseado em casos: evidência, não uma previsão.*

## Exemplo trabalhado (real)

Consulta: "Nvidia demand surges on AI chip orders"


→ NVDA guidance (sim 0.60) +5d +3.5%

→ MSFT cloud-AI (sim 0.38) +5d +10.9%

→ NVDA accelerator (sim 0.38) +5d +4.9%

Correspondência **cross-ticker** (MSFT); média +5d  $\approx$  +6.5%.

# Resultado 1: a deteção de anomalias é consistente em todo o mercado




- Amplitude da taxa de disparo em 15 tickers: **0.015** (z-score) vs **0.344** (% fixa).
- $> 20\times$  mais consistente, um argumento **sem rótulos**.
- Vs indicador de movimentos extremos:  $F_1 = 0.516$  vs 0.218.
- Ablação de janela:  $F_1$  0.385 / 0.516 / 0.678 (10/20/60 d).

## Resultado 2: a recuperação semântica bate todas as linhas de base

| Método         | P@5   | P@10  |
|----------------|-------|-------|
| SBERT (MiniLM) | 0.514 | 0.478 |
| SBERT (MPNet)  | 0.538 | 0.506 |
| Lexical        | 0.346 | 0.314 |
| Recência       | 0.126 | 0.106 |
| Aleatório      | 0.240 | 0.240 |

Cross-ticker, 3,714 manchetes, 5 sementes ( $\pm \sim 0.01$ ).



Ganho maior onde o vocabulário é distintivo (energia, saúde).

Validado à escala no FNSPID multi-ano ( $\sim 80k$  manchetes): **P@5** 0.595; consistência de direção 0.71 no chão do acaso 0.69 (tema, não direção).

## Resultado 3: as explicações são fiéis por construção

- Cada alerta é composto *diretamente* a partir dos objetos calculados.
- Por isso o texto **não pode divergir** do cálculo.
- Verificado por um teste automático (o alerta reproduz a data/ticker/impacto de cada precedente).
- Cada alerta termina com um aviso de não-previsão.

### Alerta real (gatilho de notícias)

```
News alert -- NVDA
"Nvidia raises guidance...AI data-centre"
Avg 1-day move:  -1.97% (over 5; 3 shown)
- MSFT (0.68) +1d -3.46%
- META (0.68) +1d -2.65%
- GOOGL (0.64) +1d -0.46%
observed past outcome, not a prediction
```

## Resultado 3b: a mesma garantia, para linguagem gerada

Um modelo de linguagem foi acrescentado **estritamente como narrador**: pode redigir a evidência, nunca fornecê-la. Uma guarda valida cada resposta antes da entrega e **descarta-a inteira** perante:

- um número ausente da evidência,
- um valor com o **sinal** invertido,
- formulação preditiva ou de conselho,
- uma atribuição que contradiga a calculada.

A garantia é propriedade **do sistema**, não do modelo portar-se bem.

### Dois números, de propósito

**Pré-guarda:** o modelo cru violou a evidência em alguns casos.

⇒ *é por isto que a guarda existe.*

**Entregue:** zero violações.

⇒ *é a guarda que está em julgamento.*

**Ressalva honesta:** o segundo é em parte circular, já que o mesmo verificador decide e avalia. O contrapeso é um corpus de red team: um exercício independente partiu o *primeiro* desenho (uma blocklist) com 29 contornos reproduzidos. O espaço de paráfrases é ilimitado e qualquer lista dele é finita, por isso a guarda foi reconstruída como **vocabulário fechado**. Esses ataques são hoje testes de regressão


## Resultado 4: triagem aprendida — treinada, calibrada, honesta

- **Tarefa:**  $P(\text{movimento anormal segue a notícia})$  — materialidade, **nunca** direção. Rótulos do nosso próprio estudo de evento ( $|\text{ticker} - \text{SPY}| \geq 2\%$  em  $(d, d+3]$ ).
- **Corpus:** FNSPID 2018–2023, 79,753 exemplos; split temporal por dia + embargo; calibração só na validação.
- **Anti-lookahead:** um teste unitário *muda os preços futuros* — features inalteradas, rótulo muda.

| Modelo                 | PR-AUC       | P@5/dia      |
|------------------------|--------------|--------------|
| Sempre (base)          | 0.378        | 0.163        |
| <b>Volatilidade LR</b> | <b>0.542</b> | <b>0.632</b> |
| Contexto LR            | 0.538        | 0.632        |
| Contexto+texto LR      | 0.496        | 0.585        |
| Gradient boosting      | 0.469        | 0.551        |

### O veredicto honesto (pré-comprometido)

Dentro de um orçamento de 5 alertas/dia, a triagem quase **quadruplica a precisão** (0.632 vs 0.163) — mas **nenhum modelo de texto bateu a volatilidade**. Uma ablação de seguimento juntou *cinco* features de contexto baratas (regime de mercado, momentum, reação padronizada, risco de queda): PR-AUC 0.535, de novo **sem ganho**. Um re-teste *justo* (C afinado, texto reduzido por PCA, um encoder de domínio FinBERT) continua a não bater a volatilidade, pelo que o negativo é **robusto**, não um artefacto de sub-ajuste. O sinal é o contexto de mercado; reportado tal como se revelou.



Uma captura genuína, não um mockup. **Três ecrãs, um por pergunta:**

- **Today** — a watchlist ordenada por quão longe do normal, com a repartição mercado/setor/empresa **na própria linha**. Sem clicar.
- **Ticker** — gráfico, decomposição por extenso, e os alertas *exatamente* como o canal Telegram os recebeu. Nunca recalculados.
- **Method** — os números congelados, incluindo o resultado negativo.

A promessa aparece **uma** vez, como identidade da página. O valor de latência é **medido** e está simplesmente ausente quando os carimbos não existem.



# Feito com — ferramentas gratuitas e dados abertos, de ponta a ponta

## Fontes de dados & APIs

FNSPID (Hugging Face)

yfinance

Finnhub

feeds RSS

SPY (proxy de mercado)

## Aprendizagem automática

Sentence-BERT / MiniLM

scikit-learn

PyTorch (CPU)

calibração de Platt

ONNX Runtime

## Produto & entrega

Telegram Bot API

Streamlit

Plotly

## Engenharia & infraestrutura

Python 3.12

GitHub Actions (cron)

pytest + ruff

joblib

Sem APIs pagas, sem GPUs, sem servidor sempre ligado — reproduzível num portátil.

## Limitações (enunciadas com clareza)

- A relevância é um **indicador aproximado por mesmo setor**, não um juízo humano.
- O corpus de recuperação é uma janela **recente** da camada gratuita (entretanto validada à escala no FNSPID, P@5 0.595); o estudo de *triagem* usou de facto o FNSPID multi-ano (14/15 tickers — a Meta é “FB” no corpus).
- O impacto de precedente mostrado é um retorno pós-evento **bruto** (os rótulos de triagem são ajustados ao mercado).
- A similaridade é **temática, não direcional**: um agrupamento pode misturar movimentos de subida/descida, pelo que a média é *evidência* ao nível do tema, não uma previsão.
- **Ainda sem estudo humano de utilidade** (utilidade da RQ3 em aberto).
- Por desenho: **sem previsão de preços, sem negociação**, pelo que as métricas de lucro estão fora de âmbito.

Todos os resultados são reproduzíveis a partir de scripts versionados (re-correr: números idênticos).

# Conclusões

- **RQ1 (sim):** o z-score transparente deteta de forma consistente em todo o mercado e explica cada marca.
- **RQ2 (sim, validada à escala):** a recuperação semântica muito acima das linhas de base (P@5 0.595 no FNSPID multi-ano); impacto medido sem lookahead.
- **RQ3 (fiel sim; útil em aberto):** as explicações não podem divergir do cálculo; a utilidade para humanos é trabalho futuro.
- **RQ4 (não no texto; sim no mecanismo):** a triagem  $\approx 4\times$  de precisão dentro do orçamento, mas a volatilidade ficou imbatida — o *segundo* teste justo “aprendido vs simples” que a escolha transparente venceu (o primeiro: Isolation Forest vs z-score,  $F_1$  0.271 vs 0.530).

## Contribuição

Um sistema de alertas financeiros funcional, **explicável e reproduzível** para investidores de retalho — componentes existentes mais um modelo de triagem treinado pelo autor, engendrados num todo transparente, com uma avaliação honesta.

# InvestiGator

Alertas financeiros explicáveis para investidores de retalho

Perguntas são bem-vindas.

# Perguntas antecipadas

- **Porquê não prever preços?** Eficiência de mercado (Fama 1970): as notícias públicas são absorvidas depressa; nós *medimos* reações, honestamente.
- **Porquê z-score, não Isolation Forest/GARCH?** Transparência para um sinal de baixa dimensão — e *testámo-lo*: uma Isolation Forest causal sobre a mesma informação perdeu ( $F_1$  0.271 vs 0.530).
- **O vosso modelo treinado perdeu para a linha de base da volatilidade. Fracasso?** Não: a comparação foi *pré-comprometida* e responde à RQ4 com evidência; a triagem ainda dá  $\approx 4\times$  de precisão dentro do orçamento vs alertar sempre, e a variante em produção usa exatamente as features que carregam o sinal.
- **Como sabem que o modelo de triagem nunca vê o futuro?** Um teste unitário muda os preços pós-evento e verifica que as features ficam inalteradas enquanto o rótulo muda; split temporal por dia único com um embargo de cinco dias.
- **Porquê precisão@k e um proxy de setor?** Métrica padrão de recuperação ordenada; objetiva, reprodutível; a relevância humana é trabalho futuro.
- **Restrição cross-ticker?** Uma escolha de *avaliação* para evitar auto-correspondências triviais; o alerta ao vivo mostra os precedentes mais similares, seja qual for a empresa.
- **Uma manchete positiva recuperou precedentes negativos (−1.97%). Enganador?** A similaridade capta o *tema*, não a direção; a média é **evidência** ao nível do tema, mostrada com cada precedente e um aviso de não-previsão. Trabalho futuro: de-duplicar precedentes e sinalizar divergência de direção.
- **É reprodutível?** Sim: sementes fixas, dependências fixadas, scripts versionados; re-correr reproduz cada

## Perguntas antecipadas (continuação)

- **“Zero violações entregues” não é circular, se é o vosso próprio verificador a avaliar?** Em parte é, e a tese di-lo. Por isso não é o único teste: um red team independente partiu a guarda *anterior* com 29 contornos reproduzidos, construídos sem ver o desenho atual, e esses ataques são hoje testes de regressão.
- **Então construíram um sistema multi-agente?** Não, e não o vou reivindicar. Um modelo a chamar algumas funções não é multi-agente. O narrador é uma **função pura** da evidência para um parágrafo.
- **Porquê excluir os price targets de analistas? São gratuitos.** Porque importar a previsão de outra pessoa para um sistema definido por não prever é uma contradição. Preferiu-se a coerência à cobertura, e está enunciado como posição no Capítulo 6.
- **Porquê nenhuma funcionalidade de carteira?** As posições são dados financeiros pessoais, e “as tuas maiores posições são uma só aposta” é aconselhamento, seja qual for a redação. Isso atravessa a fronteira de que a afirmação ética depende.
- **De onde vem o limiar de triagem 0,5?** Originalmente de lado nenhum, que era o problema honesto. Varrê-lo sob um rácio de custo explícito mostrou que assumia implicitamente que uma falha custa aproximadamente o mesmo que um falso alarme; sob custos iguais o ótimo fica onde a constante já estava. Vindicado, mas agora *derivado*.
- **Os vossos alertas chegam horas atrasados.** Medido: mediana de cerca de três horas, e a causa é o agendador gratuito, não o método. O caminho sempre-ligado está escrito e custa cerca de um minuto; implantá-lo ficou fora do âmbito da avaliação, e o número honesto está **à vista no produto** em vez de