



Instituto Superior de
Engenharia do Porto



DEPARTAMENTO DE ENGENHARIA
INFORMÁTICA

Explicar sem prever: deteção de anomalias e recuperação de precedentes em alertas financeiros verificáveis

Henrique José da Silva Santos

Aluno nº: 1180934

**Dissertação para obtenção do Grau de
Mestre em Engenharia de Inteligência Artificial**

Orientador: Luís Gomes

Co-Orientador: Rafael Silva

Júri:

Presidente:

[Nome do Presidente, Categoria, Escola]

Vogais:

[Nome do Vogal 1, Categoria, Escola]

[Nome do Vogal 2, Categoria, Escola]

Porto, setembro de 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim. As exceções estão explicitamente reconhecidas na secção onde são abordadas as considerações éticas, a Secção 3.8.3. A Secção 3.8.4, que se lhe segue, declara como as ferramentas de Inteligência Artificial foram utilizadas e para que finalidade.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, setembro de 2026

Dedicatória

À minha família.

Resumo

Quando o preço de uma ação se move de forma abrupta, o investidor particular necessita de determinar se o movimento é invulgar, se a sua origem é a empresa ou o mercado, e se existem precedentes. As aplicações gratuitas apresentam a variação percentual, e as poucas que vão além disso não expõem a evidência que as sustenta; os terminais profissionais respondem, e não estão acessíveis a este investidor.

Esta dissertação apresenta o InvestiGator, um sistema de alertas financeiros assente exclusivamente em fontes de dados gratuitas, que responde às três questões e expõe a evidência de cada resposta. O sistema integra quatro técnicas: deteção de anomalias por z-score deslizante, decomposição do retorno em mercado, setor e empresa com encolhimento do beta, recuperação de precedentes por semelhança semântica com medição do desfecho observado, e um modelo supervisionado de triagem treinado sobre um conjunto de dados próprio.

Três técnicas foram comparadas com linhas de base transparentes. A deteção normalizada pela volatilidade revela-se consistente entre empresas; a recuperação semântica supera a taxa-base nos cinco setores avaliados; o modelo de triagem não supera uma linha de base apenas com volatilidade, resultado negativo reportado e analisado.

Por desenho, o sistema não produz previsões de preço.

Palavras-chave: Inteligência Artificial Explicável, Alertas Financeiros, Deteção de Anomalias, Recuperação Semântica, Investidor Particular

Abstract

When a stock price moves abruptly, retail investors need to determine whether the movement is unusual, whether its origin lies with the company or the market, and whether comparable precedents exist. Free applications display the percentage change, and the few that go further do not expose the evidence behind them; professional terminals do answer them, and are not accessible to this investor profile.

This dissertation presents InvestiGator, a financial alerting system built exclusively on free data sources, which answers the three questions and exposes the evidence supporting each answer. The system integrates four techniques: anomaly detection through a rolling z-score, decomposition of returns into market, sector and company components with beta shrinkage, precedent retrieval by semantic similarity with measurement of the observed outcome, and a supervised triage model trained on a purpose-built dataset.

Three techniques were compared with transparent baselines. Volatility-normalised detection proves consistent across companies; semantic retrieval outperforms the base rate in every sector assessed; the triage model does not outperform a volatility-only baseline, a negative result that is reported and analysed.

By design, the system does not produce price forecasts.

Keywords: Explainable Artificial Intelligence, Financial Alerts, Anomaly Detection, Semantic Retrieval, Retail Investor

Agradecimentos

Ao Prof. Luís Gomes, orientador, e a Rafael Silva, coorientador, pelas conversas que definiram a direção deste trabalho, pelos exemplos que me deram a ver o que já existe na área, e pela orientação na redação do documento. Parte das decisões aqui descritas foi tomada depois de uma dessas conversas.

À minha família, pelo apoio ao longo destes meses.

Aos colegas da Sistrade, e à Sistrade, pela flexibilidade que tornou possível conciliar este mestrado com o trabalho, e pelas conversas sobre a aplicação ao longo da sua construção.

A quem acompanha o canal e classifica os alertas que recebe. Esse retorno é a única informação deste trabalho que não veio de uma medição automática.

Índice

Lista de Figuras	xi
Lista de Tabelas	xiii
Lista de Excertos	xv
Lista de Símbolos	xvii
Lista de Acrónimos	xviii
Como ler esta tese	1
1 Introdução	2
1.1 Contextualização	2
1.2 Descrição do problema	3
1.3 Objetivos e questões de investigação	4
1.4 Contribuições científicas	5
1.5 Estrutura do documento	6
2 Estado da arte	7
2.1 O investidor particular e o problema da atenção	7
2.2 Ferramentas de informação financeira para o retalho	9
2.3 Detecção de anomalias em séries temporais financeiras	11
2.4 Representação de texto e recuperação semântica	12
2.4.1 Recuperação com geração, e por que razão o sistema para antes dela	16
2.4.2 Corpora de notícias financeiras e rótulos de setor	16
2.5 Estudos de evento e decomposição de retornos	16
2.6 Raciocínio baseado em casos	17
2.7 Explicabilidade e confiança em sistemas automáticos	19
2.8 Aprendizagem automática em ambiente de produção	21
2.9 Síntese e posicionamento do trabalho	22
3 Métodos e materiais	24
3.1 Metodologia de investigação	24
3.2 Conjuntos de dados	25
3.3 Detecção de movimentos invulgares	26
3.4 Decomposição do movimento observado	28
3.5 Recuperação de precedentes	30
3.5.1 Ajuste do codificador por materialidade comparável	32
3.6 Triagem de notícias	34
3.7 Ferramentas e infraestrutura	36
3.8 Desafios tecnológicos e sociais	36

3.8.1	Privacidade e proteção de dados	37
3.8.2	Segurança	37
3.8.3	Questões éticas e sociais	37
3.8.4	Utilização de ferramentas de inteligência artificial	38
4	Implementação: InvestiGator	39
4.1	Arquitetura do sistema	39
4.1.1	Comunicação entre componentes	40
4.2	Aquisição de dados	40
4.2.1	Cotações	41
4.2.2	Notícias	41
4.2.3	Base histórica e base implantada	42
4.3	Percurso de um acontecimento	42
4.3.1	Percurso iniciado por notícia	42
4.3.2	Percurso iniciado por movimento de preço	43
4.4	Política de decisão	44
4.4.1	Seletividade observada	44
4.4.2	Limiares e a sua proveniência	46
4.5	Construção da explicação	46
4.5.1	Discordância entre a afirmação e a evidência	50
4.5.2	Aplicação web	51
4.6	Implantação e operação	54
4.6.1	Crescimento da base de casos	55
4.7	Ciclo de vida do componente aprendido	56
4.7.1	Componentes desenvolvidos e componentes consumidos	57
4.7.2	O elo em falta: arquitetura de retreino	57
4.8	A camada de inteligência	59
4.8.1	O contrato: a linguagem não produz factos	59
4.8.2	Dois níveis de garantia, e o mais fraco é este	59
4.8.3	O que foi medido, e o que não se afirma	60
5	Casos de estudo	61
5.1	Desenho experimental e métricas	61
5.2	Deteção consistente entre empresas	63
5.2.1	Procedimento	63
5.2.2	Resultado	63
5.2.3	O que a medida principal não exclui	63
5.2.4	Comparação com detetores aprendidos	64
5.2.5	Duas comparações que não confirmam as escolhas implantadas	65
5.2.6	Limites da conclusão	67
5.3	Recuperação de precedentes	67
5.3.1	Procedimento	67
5.3.2	Resultado	68
5.3.3	A alternativa trivial que o valor agregado esconde	69
5.3.4	Comportamento à escala e sob restrição de anterioridade	70
5.3.5	Limites da conclusão	71
5.4	Ajuste do codificador por materialidade comparável	72
5.4.1	A medição que motiva a pergunta	72
5.4.2	A primeira tentativa colapsou o codificador	72

5.4.3	Resultado	73
5.4.4	Sob restrição de anterioridade	73
5.4.5	Limites da conclusão	74
5.5	Triagem de notícias	74
5.5.1	Procedimento	74
5.5.2	Resultado	75
5.5.3	Três verificações à montagem experimental	76
5.5.4	Utilidade sob a restrição de orçamento	77
5.5.5	Ablação das entradas do modelo	78
5.5.6	O texto como acréscimo e não como substituto	80
5.5.7	Limites da conclusão	81
5.6	O que permanece mensurável na decomposição	82
5.7	O sistema em operação	83
5.7.1	O que a porta de decisão estava a separar	83
5.7.2	O desempenho do modelo sobre as decisões que tomou	86
5.7.3	Deriva das distribuições	88
5.7.4	O sistema completo contra as alternativas existentes	89
5.7.5	Utilidade percebida dos alertas entregues	91
5.8	Síntese dos resultados	91
6	Conclusões	94
6.1	Conclusões principais	94
6.2	As respostas às questões de investigação	95
6.2.1	Deteção de movimentos invulgares	95
6.2.2	Recuperação de precedentes	97
6.2.3	Triagem de notícias	98
6.2.4	Comparabilidade de materialidade	99
6.3	Objetivos alcançados	100
6.4	Limitações	100
6.5	Trabalho futuro	105
6.6	Considerações finais	107
	Bibliografia	109
A	Reprodutibilidade	115
A.1	Artefactos conservados	115
A.2	Origem de cada resultado	116
A.3	Matriz de evidência	116
A.4	Dados, licenças e atribuição	119
A.5	Infraestrutura: o que entra no sistema, e a que custo	119

Lista de Figuras

1.1	O mesmo acontecimento, com e sem contexto	3
1.2	Capitalização do mercado acionista dos EUA	3
1.3	Os dois gatilhos do sistema	4
2.1	Três gerações de representação de texto	13
2.2	O ciclo do raciocínio baseado em casos, e onde o sistema para	18
2.3	As duas vias para a explicabilidade	19
3.1	As quatro decisões do sistema	25
3.2	A janela deslizante do z-score	27
3.3	Um movimento repartido em três parcelas	30
3.4	Frases como pontos num espaço	31
3.5	A janela do estudo de evento e as duas decisões que a fixam	32
3.6	As nove entradas, por nível	34
3.7	Divisão temporal com embargo	35
4.1	Arquitetura do InvestiGator	40
4.2	Etapas do percurso iniciado por notícia	43
4.3	Seletividade do sistema por empresa	45
4.4	Distribuição completa das avaliações por ponto de decisão	46
4.5	Os nove pontos de decisão, a origem do seu valor e o que cada um elimina	48
4.6	Alerta entregue ao canal	50
4.7	Estado do dia na aplicação web	52
4.8	Evidência de uma empresa	53
4.9	Registo de uma decisão de não comunicar	54
4.10	Ciclo de crescimento da base de casos	55
4.11	Ciclo de vida do componente aprendido	56
4.12	Arquitetura de retreino desenhada e não executada	58
4.13	A travessia de uma pergunta até ao facto que a sustenta	60
5.1	A forma comum aos quatro casos de estudo	61
5.2	As duas medidas da primeira questão	64
5.3	A regra transparente contra dois detetores aprendidos	65
5.4	Dois estimadores de volatilidade sobre o mesmo protocolo	66
5.5	Ablação à dimensão da janela	67
5.6	Recuperação: o método contra sete alternativas	68
5.7	Recuperação por setor e sob a restrição temporal	70
5.8	Tema e direção não são a mesma propriedade	72
5.9	Triagem: pontos e intervalos sobre o mesmo bloco de teste	75
5.10	O resultado sob nove definições alternativas de rótulo	77
5.11	O desempate alfabético não é uma referência aleatória	77
5.12	O modelo comparado com subconjuntos das entradas	79

5.13	Os três acréscimos, com intervalo de confiança	80
5.14	A decomposição discrimina entre empresas no mesmo dia	82
5.15	O que a porta de decisão separava	83
5.16	O modelo sobre as decisões que tomou em produção	87
5.17	Deslocamento das distribuições de entrada	88
5.18	O sistema contra as alternativas já disponíveis	89
6.1	As ocasiões em cada sentido	95
6.2	As quatro questões de investigação e as respostas obtidas	96
6.3	O percurso de cada questão até à resposta	97
6.4	As linhas futuras, por aquilo que as desbloqueia	106
6.5	A fronteira daquilo que o trabalho estabelece	108
A.1	As peças externas, por etapa do percurso	120

Lista de Tabelas

2.1	As ferramentas existentes contra as três perguntas	9
2.2	Abordagens de representação de texto	14
2.3	Posicionamento do trabalho face à literatura	22
3.1	Conjuntos de dados utilizados	26
3.2	Conjuntos de empresas	27
4.1	Caracterização das três fontes de notícias	41
4.2	Límiars da política de decisão e a sua proveniência	47
4.3	Os dois níveis de garantia sobre o texto entregue	60
5.1	As medidas utilizadas e o valor que cada uma tem sem informação	62
5.2	Diagnóstico de degeneração dos codificadores ajustados	72
5.3	Resultado do ajuste por materialidade comparável	73
5.4	Seletividade da porta em duas janelas	84
5.5	As três políticas de decisão	86
5.6	Cada escolha, contra a alternativa que não ficou	92
6.1	As limitações e o trabalho que as encerraria	101
A.1	Cada resultado e o procedimento que o produz	117
A.2	Matriz de evidência	118
A.3	Custo mensal da operação	120

Lista de Excertos

3.1	A janela que exclui o dia avaliado	28
3.2	O teste que muda o futuro	35
4.1	A repartição aditiva que a mensagem enuncia	51

Lista de Símbolos

P_t	Preço de fecho da sessão t	Eq. 3.1
r_t	Retorno logarítmico do dia t , $\ln(P_t/P_{t-1})$	Eq. 3.1
μ, σ	Média e desvio-padrão dos retornos da janela anterior ao dia	Eq. 3.1
z_t	Raridade do retorno do dia t face à janela anterior	Eq. 3.1
$r_m, \tilde{r}_s$	Retorno diário do mercado e retorno do setor ortogonalizado face ao mercado	Eq. 3.2
β_m, β_s	Sensibilidade histórica da ação ao mercado e ao setor	Eq. 3.2
ε	Parte do retorno que não é explicada nem pelo mercado nem pelo setor	Eq. 3.2
$\hat{\beta}$	Estimativa do beta obtida por regressão sobre a janela	Eq. 3.3
β_{ref}	Beta de referência para onde a estimativa é encolhida	Eq. 3.3
$SE(\hat{\beta})$	Erro-padrão da estimativa do beta	Eq. 3.3
σ_{ref}^2	Variância de referência que fixa a força do encolhimento	Eq. 3.3
w	Peso do encolhimento de Vasicek, entre zero e um	Eq. 3.3
$\cos$	Semelhança do cosseno entre dois vetores de frase	Secção 3.5
h	Meia-vida do decaimento por recência aplicado aos precedentes	Secção 3.5
k	Número de precedentes recuperados e apresentados	Secção 3.5
p_{bruta}	Pontuação de triagem antes da calibração	Eq. 3.4
$p_{\text{calibrada}}$	Pontuação de triagem depois da calibração de Platt	Eq. 3.4
a, b	Parâmetros aprendidos da calibração de Platt	Eq. 3.4
P, C	Precisão e cobertura	Secção 5.1
F_1	Média harmónica da precisão e da cobertura, $2PC/(P + C)$	Secção 5.1

Lista de Acrônimos

- ARCH** Autoregressive Conditional Heteroscedasticity.
- BERT** Bidirectional Encoder Representations from Transformers.
- FNSPID** Financial News and Stock Price Integration Dataset.
- GARCH** Generalized Autoregressive Conditional Heteroscedasticity.
- HTTP** HyperText Transfer Protocol.
- IA** Inteligência Artificial.
- LIME** Local Interpretable Model-agnostic Explanations.
- ONNX** Open Neural Network Exchange.
- PR-AUC** Precision-Recall Area Under the Curve.
- PSI** Population Stability Index.
- QI** Questão de Investigação.
- ROC-AUC** Receiver Operating Characteristic Area Under the Curve.
- SBERT** Sentence-BERT.
- SHAP** SHapley Additive exPlanations.

Como ler esta tese

Este documento descreve um sistema que responde a três perguntas de um investidor particular, e mede quanto vale cada uma das respostas. Tem cerca de cem páginas de corpo, e nem todos os leitores procuram a mesma coisa. Esta página propõe quatro percursos.

Quem quer saber o que o trabalho conclui pode ler o Capítulo 1, que enuncia as três perguntas, e depois a Secção 6.2, onde cada uma recebe a sua resposta com o alcance delimitado. São cerca de dez páginas, e a Figura 6.3 resume o percurso de cada questão numa só imagem.

Quem quer saber como foi medido deve ler o Capítulo 3, que descreve as quatro técnicas e a disciplina temporal que impede cada uma de usar informação que ainda não existia, e em seguida a Secção 5.1, que fixa as métricas e, o que mais importa, o valor que cada uma assume na ausência de informação.

Quem quer saber como o sistema funciona deve ler o Capítulo 4. O percurso de uma notícia está na Secção 4.3, a política que decide o silêncio na Secção 4.4, e a camada que compõe o texto entregue na Secção 4.5.

Quem quer verificar deve ir ao Apêndice A. A Tabela A.1 liga cada resultado reportado à secção que o produz, e a Tabela A.2 enumera cada afirmação substantiva com o estado em que ficou depois de medida, incluindo as que foram retiradas.

Três convenções atravessam o documento e vale a pena enunciá-las antes de começar. Nenhum número foi escrito à mão: cada um é produzido por um procedimento automático e o texto cita o ficheiro que o contém. Nenhuma comparação é apresentada sem o valor que um método sem informação obteria, porque uma percentagem lida sozinha conduz à conclusão errada, e o documento regista três ocasiões em que isso quase sucedeu. E cada resultado é acompanhado do que dele *não* decorre, que é o passo que distingue uma avaliação de uma demonstração.

Capítulo 1

Introdução

Este capítulo apresenta a contextualização do trabalho descrito nesta dissertação, o problema que motiva a sua realização, as questões de investigação e os objetivos definidos, as contribuições científicas e a organização do documento. Quem o leia fica a saber que problema o trabalho resolve, para quem, e o que o sistema recusa fazer por decisão e não por limitação.

1.1 Contextualização

A aquisição de ações tornou-se uma operação de baixa fricção, acessível através de aplicações móveis e sem custos de corretagem significativos. A maioria dos adultos norte-americanos detém hoje ações, diretamente ou através de fundos e planos de reforma (Gallup 2025), num mercado cuja capitalização excede os 62 biliões de dólares (SIFMA 2025), conforme representado na Figura 1.2.

A facilidade de acesso não se estendeu, contudo, à interpretação da informação. Quando o preço de um ativo se move, o investidor particular dispõe de instrumentos limitados para determinar o significado desse movimento.

O comportamento deste segmento é objeto de investigação corrente, e dois resultados recentes delimitam o problema tratado nesta dissertação. O primeiro é o de que a atenção do investidor particular constitui hoje uma quantidade medida, cujos indicadores são discutidos e comparados na literatura (Cahill, Zhangxin Liu e Smales 2025): aquilo que determina o que o investidor observa é estudado como variável, e não como acaso. O segundo é o de que a participação do investidor particular no mercado, e as condições em que negocia, permanecem tema de revisão ativa (Ernst e Spatt 2026). O Capítulo 2 desenvolve os mecanismos comportamentais que esta literatura documenta, e que explicam por que razão a ausência de contexto é mais onerosa para este público do que para um profissional.

Interessa reter deste conjunto o que delimita o problema. Os sinais que captam a atenção do investidor chegam-lhe sem contexto, e a decisão que se lhes segue é tomada sob condições que a literatura documenta como desfavoráveis. Três questões concretas permanecem por responder no momento em que o investidor observa um movimento de preço:

1. **o movimento é invulgar?** Uma variação de quatro por cento representa um acontecimento raro numa empresa de baixa volatilidade e um dia comum numa empresa volátil;
2. **a origem do movimento é a empresa ou o mercado?** Uma descida que acompanha o mercado e uma descida isolada correspondem a situações distintas;

3. **existem precedentes, e qual foi o seu desfecho?** A existência de dias comparáveis no passado, e do que se lhes seguiu, permite situar o movimento observado.

As aplicações gratuitas correntes apresentam a variação percentual e não respondem a nenhuma das três. Existem produtos recentes que declaram ir além disso, e a Secção 2.2 nomeia-os: o que as respectivas páginas descrevem é um resumo em linguagem natural, e não os casos passados individualizados com o desfecho medido. Os terminais de informação financeira profissional respondem às três, e não estão disponíveis em regime gratuito nem acessível ao perfil de investidor em causa. A lacuna não decorre da indisponibilidade de dados, que existem em quantidade e são gratuitos, mas da ausência de contexto verificável construído sobre eles.

A Figura 1.1 apresenta a diferença sobre um acontecimento concreto.

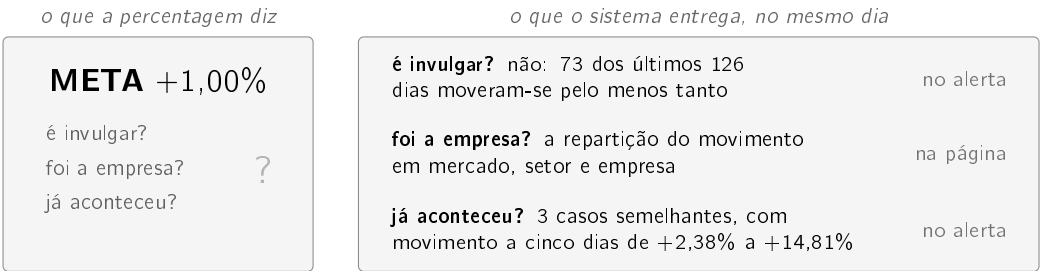


Figura 1.1: O mesmo dia da mesma empresa, à esquerda como uma cotação o apresenta e à direita como o sistema o entrega. Os valores da direita são reproduzidos do alerta enviado ao canal a 8 de setembro de 2026, e não construídos para o efeito. A terceira coluna indica onde vive cada resposta, e a distinção não é acessória: o alerta responde à primeira e à terceira perguntas no momento em que interrompe o leitor, ao passo que a repartição depende do fecho do dia e por isso é apresentada na aplicação, como mostra a Figura 4.8.




Figura 1.2: Capitalização do mercado acionista dos Estados Unidos, 2015–2024, em bilhões de dólares. Elaborado a partir dos dados do SIFMA Capital Markets Fact Book (SIFMA 2025).

1.2 Descrição do problema

Esta dissertação apresenta o InvestiGator, um sistema de alertas financeiros construído exclusivamente sobre fontes de dados gratuitas, que monitoriza um conjunto de empresas, deteta acontecimentos que se afastam do comportamento habitual de cada uma e emite alertas acompanhados da explicação e da evidência que os sustentam.

O sistema dispõe de dois gatilhos, representados na Figura 1.3: um movimento de preço invulgar para a empresa em causa, ou a chegada de uma notícia relevante sobre ela. Em ambos os casos, a mensagem entregue identifica o acontecimento, o critério pelo qual foi considerado invulgar, a proveniência dos dados utilizados e os casos passados semanticamente próximos, com o comportamento observado do preço após cada um deles.

Uma decisão de desenho atravessa o sistema e condiciona todas as restantes: **o sistema não produz previsões de preço**. Não indica direção futura, não emite recomendações de compra ou venda e não apresenta alvos de preço. Esta restrição tem duas justificações. A primeira é de verificabilidade: uma afirmação sobre um acontecimento passado pode ser confirmada contra o registo no momento em que é lida, ao passo que uma previsão só é avaliável depois de a decisão do investidor já ter sido tomada. A segunda é teórica: a hipótese dos mercados eficientes, na sua forma semiforte, torna improvável a antecipação sistemática de movimentos a partir de informação publicamente disponível. O Capítulo 2 desenvolve-a e identifica a literatura correspondente. Esta dissertação não testa essa hipótese nem se apoia nela para estabelecer qualquer conclusão.




Figura 1.3: Os dois gatilhos do sistema e a saída que produzem. O investidor recebe um alerta acompanhado da evidência que permite verificá-lo, e não apenas a notificação de que o preço se moveu.

1.3 Objetivos e questões de investigação

O objetivo geral desta dissertação é desenhar, construir e avaliar um sistema de alertas financeiros explicável para investidores particulares, utilizando exclusivamente fontes de dados gratuitas.

Deste objetivo decorrem quatro questões de investigação, cada uma associada a uma medição e a um critério de sucesso definidos antes da execução das experiências:

- **QI1, deteção.** Consegue um método estatístico simples e transparente detetar movimentos invulgares de forma consistente entre empresas com volatilidades distintas, e fazê-lo melhor do que uma regra de limiar fixo?
- **QI2, precedentes.** Consegue o sistema recuperar notícias de outra empresa do mesmo setor melhor do que as alternativas textuais e de ordenação avaliadas, e conservar vantagem sobre o acaso quando se exigem notícias anteriores à consulta?
- **QI3, triagem.** Consegue um modelo treinado decidir que notícias justificam um alerta melhor do que uma linha de base baseada apenas em volatilidade?
- **QI4, comparabilidade.** Consegue o ajuste contrastivo do codificador, treinado para aproximar notícias cuja *magnitude* de movimento subsequente é semelhante, melhorar a comparabilidade de materialidade dos precedentes recuperados sem custo na relevância temática?

A quarta questão exige uma justificação, porque toca a restrição fundadora deste trabalho. O sistema não prevê, e treinar um codificador sobre desfechos observados poderia parecer contrariar essa restrição. A distinção decisiva é entre *direção* e *magnitude*: o que a restrição proíbe é afirmar para onde o preço vai, e o objetivo de treino desta questão é a magnitude do movimento, tomada em valor absoluto. O que um codificador assim ajustado produz não é uma afirmação sobre a notícia em análise, mas uma organização da base de casos que aproxima notícias de materialidade comparável. Para que a distinção seja verificável e não apenas declarada, a experiência inclui um segundo braço, treinado sobre o retorno *com sinal*: se a direção fosse tão aprendível como a magnitude, os dois braços seriam indistinguíveis e o argumento cairia.

A segunda questão do investidor, relativa à separação entre a componente de mercado e a componente específica da empresa, é tratada por uma técnica descrita no Capítulo 3 mas não dá origem a uma questão de investigação. A razão é metodológica: a repartição de um movimento não possui um valor de referência observável contra o qual possa ser comparada, uma vez que essa quantidade existe apenas relativamente a um modelo. A Secção 5.6 estabelece o que, apesar disso, permanece mensurável nessa técnica.

Estas questões concretizam-se em quatro objetivos:

1. construir o sistema completo, desde a aquisição de dados até à entrega do alerta;
2. avaliar os componentes, com linhas de base transparentes para deteção, recuperação e triagem;
3. garantir que as explicações apresentadas são fiéis ao que o sistema calculou;
4. reportar os resultados obtidos, incluindo os que não confirmem as expectativas iniciais.

1.4 Contribuições científicas

Tratando-se de uma dissertação em Engenharia de Inteligência Artificial (IA), a contribuição não reside na formulação de um algoritmo novo, mas na seleção, integração e avaliação crítica de técnicas estabelecidas até constituírem um sistema funcional, explicável e reproduzível. Identificam-se cinco contribuições:

1. **Um sistema completo em funcionamento**, com os dois gatilhos, assente em fontes gratuitas e efetivamente implantado, e não uma demonstração laboratorial.
2. **Um método reproduzível para medir o comportamento do preço na sequência de notícias semanticamente próximas**, combinando recuperação por semelhança de frases com janelas de estudo de evento, sem utilização de informação posterior ao momento da decisão. O Capítulo 2 identifica as duas linhas de trabalho de que provêm.
3. **Um conjunto de dados próprio e um modelo treinado sobre ele**, com 79 753 exemplos construídos a partir do corpus público Financial News and Stock Price Integration Dataset (FNSPID) (Dong, Fan e Peng 2024) e de séries de preços, com o modelo, a calibração e as métricas conservados como artefactos versionados.
4. **Uma avaliação dos componentes, com linhas de base para três das quatro técnicas**, incluindo o resultado que contraria a hipótese inicial, reportado como tal.

5. **Um resultado negativo sobre a aprendizagem de materialidade a partir do texto**, obtido com um protocolo fixado antes da execução e com um diagnóstico que rejeita representações degeneradas antes de qualquer métrica ser interpretada. A primeira tentativa produziu exactamente essa degeneração, e o diagnóstico apanhou-a; o Capítulo 5 reporta as duas.

1.5 Estrutura do documento

O Capítulo 2 apresenta o estado da arte, caracterizando o público-alvo, as ferramentas atualmente disponíveis e as áreas técnicas de onde provêm os componentes utilizados. O Capítulo 3 descreve os dados e as quatro técnicas que constituem o sistema. O Capítulo 4 descreve a arquitetura do InvestiGator e o percurso de uma notícia desde a recolha até à entrega. O Capítulo 5 apresenta o desenho experimental e os resultados obtidos para cada questão de investigação. O Capítulo 6 sintetiza as respostas, identifica as limitações do trabalho e enuncia as linhas de desenvolvimento futuro.

Cada mecanismo descrito é ilustrado sobre um caso real, com os valores efetivamente calculados pelo sistema, e não sobre exemplos construídos para o efeito. Uma das doze empresas, a AMD, reaparece em três papéis distintos ao longo do documento, e serve de fio a quem quiser seguir um nome só: é o movimento que a Secção 3.4 reparte nas suas três parcelas, é a empresa que a porta de decisão deixava passar em todas as avaliações registadas, e é uma das que o modelo pontua sem nunca as ter observado no treino. São três momentos da mesma empresa e não do mesmo acontecimento.

Duas categorias de material aparecem em inglês, e enunciam-se aqui para que não sejam lidas como descuido. A primeira são os títulos de notícia citados e os identificadores de empresa, que provêm de fontes em inglês e são reproduzidos sem tradução: traduzi-los quebraria a correspondência com o material que o leitor pode consultar, que é a propriedade que este trabalho existe para preservar. A segunda são as capturas da aplicação, cuja interface é redigida em inglês por decisão de produto, pela razão que a Secção 4.5 desenvolve; uma captura traduzida mostraria um ecrã que não existe. Tudo o resto, incluindo o texto desenhado no interior das figuras, está em português.

Capítulo 2

Estado da arte

Este capítulo apresenta o enquadramento científico e tecnológico do trabalho. Caracteriza-se primeiro o público a que o sistema se dirige e as limitações que definem o problema; examinam-se depois as soluções atualmente disponíveis; percorrem-se por fim as áreas técnicas de onde provêm os componentes utilizados, situando a contribuição desta dissertação em relação a cada uma. Quem o leia fica a saber que as três perguntas do investidor já têm resposta na literatura, e por que razão nenhuma ferramenta gratuita as junta.

2.1 O investidor particular e o problema da atenção

Esta secção caracteriza o comportamento documentado do público a que o sistema se dirige, uma vez que são as limitações desse comportamento, e não a dimensão do mercado, que delimitam o problema tratado.

O Capítulo 1 estabeleceu a escala do universo em causa. A caracterização que falta é de comportamento, e começa por uma observação que contraria a representação corrente do investidor particular como agente que apenas reage em pânico. Durante a queda de março de 2020, os investidores particulares de uma plataforma sem comissões aumentaram as suas posições agregadas em vez de reduzirem a exposição (Welch 2022). Trata-se de um público que decide com regularidade, e que por isso beneficia de melhor informação no momento da decisão.

A literatura de finanças comportamentais estabelece que essas decisões se afastam de forma sistemática do ideal racional (Barberis e Thaler 2003). Duas regularidades condicionam diretamente o desenho de um sistema de alertas. A primeira é a aversão à perda (Kahneman e Tversky 1979), já enunciada no capítulo anterior, e cuja consequência para este trabalho é que o custo da ausência de contexto é assimétrico: é maior precisamente quando a informação é desfavorável.

A segunda é o efeito da atenção, e é a que fundamenta o problema. Barber e Odean (2008) estabelecem que os investidores particulares são compradores líquidos das ações que lhes captam a atenção, identificadas por três indicadores observáveis, que são a presença em notícias, o volume de transação anormal e o retorno extremo num único dia. O mecanismo proposto pelos autores é o do problema de procura: perante um número muito elevado de alternativas, o investidor não avalia todas e a sua escolha recai sobre o subconjunto que lhe foi tornado visível.

Os autores delimitam o alcance da afirmação, que respeita a um desequilíbrio agregado entre compras e vendas, sem abranger um comportamento universal, e reportam a conclusão que justifica este trabalho: o padrão de aquisição assim formado não gera retornos superiores.

A base empírica são registos de corretoras norte-americanas entre 1991 e 1999, anteriores à negociação por telemóvel e à ausência de comissões, pelo que o que se assume transferível é o mecanismo e não os valores medidos. A centralidade da atenção neste processo é de tal ordem que se tornou mensurável através do volume de pesquisas na internet (Da, Engelberg e Gao 2011).

Os três indicadores identificados pela literatura são calculados por este sistema, mas o estatuto de cada um difere. A notícia e o movimento extremo constituem os dois gatilhos descritos no Capítulo 1 e podem, por si, originar um alerta. O volume é calculado e apresentado como contexto, e não interrompe o utilizador. A razão desta assimetria é empírica e está reportada na Secção 5.8: a combinação do volume com os restantes sinais melhorou a triagem em apenas um de três orçamentos considerados, resultado que não sustenta a introdução de uma terceira via de interrupção. A ideia de fundir sinais de origens distintas num indicador único provém de um painel de informação em tempo real com essa arquitetura (*World Monitor* 2026), sugerido pelo coorientador deste trabalho, e entra na dissertação na condição em que foi avaliada, ou seja como alternativa medida e não adotada.

Há, sobre este ponto, evidência de campo mais recente e mais próxima do objeto deste trabalho, e que aponta em sentido desfavorável. C.-W. Liu, Chen e Wen (2023) acompanharam 20 904 investidores particulares de uma plataforma de fundos de investimento em Taiwan, entre janeiro de 2017 e junho de 2020, dos quais 932 ativaram os alertas de preço da própria plataforma. Estimando o efeito por diferenças em diferenças, quantificam-no numa degradação do desempenho da carteira da ordem de um ponto percentual em seis meses. Os dois mecanismos que identificam são o aumento de cerca de 7% no número de transações e o facto de os fundos que o investidor mexeu depois da adesão terem desempenho pior do que os que não mexeu. A leitura dos autores é a de que o alerta dirige a atenção para a volatilidade de curto prazo e induz negociação em excesso.

O resultado é incómodo para uma dissertação que constrói um sistema de alertas, e é por isso que consta do corpo do texto e não de uma nota. Convém, ainda assim, ser exato quanto ao que foi medido. O alerta estudado dispara quando o preço de um fundo atravessa um limiar definido pelo próprio investidor e comunica-lhe o preço atual, sem qualquer indicação sobre a causa; é o alerta de limiar que a Secção 2.2 volta a encontrar nas aplicações das corretoras. O mecanismo de dano que os autores descrevem — negociação por realimentação do preço, por oposição ao uso de informação sobre o valor da empresa — é precisamente o que se instala quando ao destinatário se entrega um número e mais nada. Os próprios autores concluem que melhorar o acesso à informação não basta, e que é preciso atender também à capacidade de a processar.

Esta dissertação toma o resultado como razão de desenho e não como validação do desenho que já tinha. Dele decorrem duas opções. A primeira é que o alerta transporta a evidência que o justifica, em vez de comunicar apenas que um limiar foi atravessado. A segunda é que a quantidade de alertas é limitada por decisão explícita, e não pelo que os dados produzirem, conforme a Secção 4.4. Se estas duas opções bastam para evitar o efeito que C.-W. Liu, Chen e Wen (2023) mediram é matéria por demonstrar, e o Capítulo 6 retoma-a nesses termos.

Do lado das instituições financeiras, a adoção de inteligência artificial deixou de ser experimental, como documenta o inquérito a empresas do setor conduzido pelo Cambridge Centre for Alternative Finance (2026). Esse inquérito não mede a população dos produtos destinados ao investidor particular, pelo que não sustenta afirmações sobre ela; a caracterização

dessa população assenta no que os próprios fornecedores declaram, e é objeto da secção seguinte.

2.2 Ferramentas de informação financeira para o retalho

Esta secção examina as soluções atualmente disponíveis, avaliando cada uma contra um critério fixo, que são as três perguntas enunciadas no Capítulo 1. A Tabela 2.1 apresenta o resultado dessa avaliação.

Tabela 2.1: As categorias de ferramenta existentes avaliadas contra as três perguntas do Capítulo 1. A classificação *parcial* indica que a ferramenta fornece matéria-prima para a resposta e deixa a interpretação ao utilizador.

Ferramenta	É invulgar?	Empresa ou mercado?	Já aconteceu?	Custo
Aplicação da corretora	não	não	não	incluído
Agregador de notícias	não	não	não	gratuito
Aplicação de sentimento	parcial	não	não	gratuito ou baixo
Gestor automático de carteira	não	não	não	percentagem da carteira
Terminal profissional	sim	sim	sim	não publicado
Este trabalho	sim	sim	sim	gratuito

A tabela evidencia o essencial. A única ferramenta existente que responde às três perguntas é também a mais dispendiosa de todas. O problema não é, portanto, de natureza científica, mas de acesso: as respostas são conhecidas e estão condicionadas a uma subscrição incompatível com o perfil de investidor em causa.

Três categorias merecem exame individual, uma vez que cada uma falha por uma razão distinta e essas razões informam decisões tomadas nos capítulos seguintes.

A aplicação da corretora é o instrumento de acesso mais imediato ao preço, e é aquele cuja documentação pública descreve o menor conjunto de indicadores. Apresenta a variação percentual do dia e um gráfico de preço. Não indica se essa variação é elevada para aquela ação em particular, não separa a componente de empresa da componente de mercado e não dispõe de memória de acontecimentos comparáveis.

Os alertas de preço destas aplicações partilham a limitação de forma mais acentuada. Disparam quando um limiar fixo é atravessado, critério que ignora a volatilidade própria de cada ação e produz por isso alertas frequentes nas empresas agitadas e raros nas calmas. Comunicam ainda que um nível foi ultrapassado, e nunca porquê. Esta observação determina a opção metodológica descrita na Secção 3.3, que substitui o limiar absoluto por uma medida relativa à norma recente de cada empresa, e cuja diferença é quantificada na Secção 5.2.

As aplicações de sentimento classificam notícias como positivas ou negativas e apresentam o resultado dessa classificação. O que fornecem é uma leitura da notícia e não do movimento: uma classificação fortemente negativa indica que algo terá acontecido, e não estabelece se a variação do preço é elevada para aquela ação, que é a primeira pergunta. É neste sentido restrito que a Tabela 2.1 lhes atribui uma resposta parcial, e não avançam além dela. A

Secção 5.3 apresenta ainda uma medição própria segundo a qual o tema de uma notícia e a direcção do movimento que se lhe segue coincidem com menos frequência do que a intuição sugere, o que limita o alcance de uma pontuação de sentimento como indicador de impacto.

Os gestores automáticos de carteira respondem sobretudo a uma pergunta distinta, a da distribuição de capital por um conjunto de ativos. A literatura reconhece-lhes benefícios genuínos, embora não uniformes: D'Acunto, Prabhala e Rossi (2019) medem uma melhoria da diversificação e uma redução da volatilidade nos investidores que detinham menos de cinco ações antes da adesão, ao passo que para os que já detinham mais de dez o efeito sobre a diversificação é próximo de nulo. A contenção de enviesamentos comportamentais é o benefício mais consistentemente reportado (Cardillo e Chiappini 2024; D'Acunto, Prabhala e Rossi 2019). A diferença face a este trabalho é de objeto e não de transparência: um gestor automático recomenda uma carteira e executa-a, ao passo que este sistema não formula recomendações e entrega evidência sobre um acontecimento concreto. Acresce que a prestação de aconselhamento sobre investimentos constitui atividade regulada, fronteira que o presente trabalho evita por desenho, conforme discutido na Secção 3.8.3.

Existem, por fim, produtos recentes que declaram responder exatamente à pergunta tratada nesta dissertação. O Robinhood Cortex, anunciado em março de 2025, declara na página do próprio fornecedor destinar-se a responder à questão de saber por que razão uma ação está a subir ou a descer num dado dia (Robinhood Markets 2025). Os momentos-chave do Google Finance, apresentados em junho de 2026, propõem-se explicar por que razão uma ação se moveu (Google 2026). Trata-se da mesma pergunta, formulada por organizações com recursos e base de utilizadores incomparavelmente maiores.

A diferença situa-se no que as respetivas páginas declaram ser entregue. Ambas descrevem um resumo em linguagem natural, e nenhuma descreve a apresentação dos casos passados individualizados, com datas, semelhanças medidas e comportamento observado do preço após cada um, que é o que este trabalho entrega. A distinção reivindicada não é de fluência, mas de verificabilidade, e respeita ao que as páginas declaram: os produtos não foram testados, pelo que nada se afirma sobre o que efetivamente entregam.

Até aqui esta secção examinou produtos. Falta a literatura académica, e omiti-la deixaria a afirmação de lacuna assente na inspeção de páginas de fornecedores, que é base frágil. A classe de sistema aqui em causa — vigiar acontecimentos e notificar o investidor particular — é tratada em investigação publicada há cerca de duas décadas, e o exemplo mais desenvolvido é o *MoFIN DSS* de Muntermann (2009). O paralelo é próximo ao ponto de ser desconfortável: também se dirige ao investidor particular, também parte da observação de que este reage às notícias com mais intensidade e menos rapidez do que o investidor institucional, também é construído e avaliado segundo o paradigma de investigação por desenho que a Secção 3.1 adota, e também publica a avaliação num artigo de revista.

Vale a pena precisar o que esse sistema faz, porque é dessa precisão que sai o posicionamento deste trabalho. Sobre 425 comunicados de empresas alemãs publicados entre 2003 e 2005, e séries de preços intradiárias ao minuto, o autor ajusta por regressão dois modelos: um estima o efeito de preço que se seguirá ao comunicado, e o outro estima durante quanto tempo esse efeito se mantém. O comunicado é notificado ao investidor quando o efeito estimado excede o efeito médio observado. A avaliação é uma simulação *ex ante* do excedente do consumidor, ou seja mede a oportunidade económica que a notificação abre, e não a qualidade daquilo que é comunicado. O utilizador recebe a indicação de que um comunicado é relevante e não recebe a razão pela qual o é.

Três consequências para esta dissertação. A primeira é que a lacuna não pode ser enunciada como ausência de sistemas de alerta para o investidor particular, porque eles existem e estão publicados; tem de ser enunciada como diferença de postura epistémica, entre estimar o que vai acontecer e explicar o que já aconteceu, e como diferença naquilo que é entregue com o alerta. A segunda é que a medida de relevância de Muntermann (2009) é um retorno anormal *em valor absoluto*, ajustado pelo mercado e corrigido pelo comportamento habitual da própria ação — ou seja magnitude, e não direção. É, no essencial, a mesma grandeza que a Secção 3.3 mede, com duas diferenças que interessam: aqui é medida depois do facto, e serve para explicar em vez de antecipar. Que um trabalho publicado em 2009 tenha chegado à magnitude, e não à direção, como definição operacional de acontecimento relevante para este público é um apoio independente a uma opção que esta dissertação tomou por outra via. A terceira é que aquele trabalho avaliou o artefacto por simulação e remeteu explicitamente para investigação futura o estudo com utilizadores reais, exatamente a limitação que o Capítulo 6 enuncia a respeito deste. Não é atenuante, mas situa o problema: trata-se de uma dificuldade da área e não de uma omissão isolada.

A objecção mais razoável ao trabalho consiste em perguntar por que razão um assistente de inteligência artificial genérico não resolveria o mesmo problema. Não foi realizada uma comparação com nenhum desses assistentes, pelo que o que se segue é um argumento de desenho e não um resultado. Um assistente que não disponha de acesso externo a dados de mercado não dispõe de três elementos. O primeiro é a volatilidade recente da ação, que permite determinar se uma variação é elevada. O segundo é a separação entre a componente de mercado e a componente específica da empresa. O terceiro é uma base de casos passados sobre a qual efetuar uma recuperação.

Quanto a este último ponto, um modelo de linguagem recorda casos vistos durante o treino, o que não constitui recuperação e não é verificável pelo leitor. Existem modelos de grande dimensão especializados em texto financeiro, cuja capacidade está documentada (Li et al. 2023). A saída de qualquer deles permanece uma afirmação que se lê com facilidade e não se confere.

A literatura de explicabilidade dá razões para desconfiar dela. Lipton (2018) argumenta que a interpretabilidade não designa uma propriedade única e que um sistema deve declarar qual delas oferece. Rudin (2019) argumenta que uma explicação produzida sobre um modelo opaco é uma aproximação que pode induzir em erro. Nenhum dos dois trata de texto gerado por modelos de linguagem, pelo que a transposição é do autor e o que dela se retira é uma razão de desenho e não um resultado da literatura. É esta a razão pela qual a linguagem nunca produz factos neste sistema: os números provêm dos componentes que os calcularam, e o texto é composto a partir deles, conforme descrito na Secção 4.5.

2.3 Detecção de anomalias em séries temporais financeiras

Esta secção situa a primeira decisão do sistema no campo da deteção de anomalias e enuncia as famílias de método consideradas.

A deteção de anomalias constitui uma área estabelecida, com uma taxonomia consolidada que separa os métodos pela forma como definem normalidade (Chandola, Banerjee e Kumar 2009; Pang et al. 2021). Três famílias são relevantes para séries temporais financeiras.

A família estatística define normalidade a partir da distribuição local dos próprios dados, estimada numa janela deslizando, e assinala como anómalas as observações que dela se

afastam além de um limiar. A explicação de uma deteção coincide com o cálculo que a produziu, o que a torna integralmente comunicável ao utilizador. Em contrapartida, supõe que a distribuição dos retornos é localmente estável.

A família aprendida não supervisionada define normalidade a partir da estrutura geométrica dos dados. O Isolation Forest (F. T. Liu, Ting e Zhou 2008) identifica como anómalos os pontos que uma partição aleatória isola com poucos cortes; o Local Outlier Factor (Breunig et al. 2000) identifica-os pela densidade reduzida face à dos seus vizinhos. Ambos dispensam rótulos e captam padrões multivariados que uma regra sobre uma única série não capta, ao custo de a decisão deixar de ser enunciável numa frase.

A família profunda aprende um modelo de normalidade através de uma rede (Pang et al. 2021). Oferece maior capacidade de representação, exige volumes de dados superiores e afasta-se do requisito de explicabilidade que estrutura este trabalho.

Uma restrição prática condiciona toda esta escolha. Em domínios financeiros vizinhos, como a deteção de fraude, os métodos não supervisionados ocupam posição central precisamente porque anomalias rotuladas são escassas e os padrões se alteram ao longo do tempo (Ahmed, Mahmood e Islam 2016). A mesma condição verifica-se aqui: não existe um conjunto de dados em que tenha sido registado, dia a dia, que movimentos justificariam um alerta. Esta ausência determina a forma como o Capítulo 5 pode avaliar o componente, e é a razão pela qual a avaliação assenta num critério derivado dos próprios dados em vez de um julgamento humano.

A suposição de estabilidade local em que a família estatística assenta é confrontada e não escondida. Os modelos de volatilidade condicional, introduzidos por Engle (1982) e generalizados por Bollerslev (1986), formalizam o agrupamento de volatilidade, ou seja a tendência de os períodos calmos e os períodos agitados ocorrerem em séries. Ambos os artigos formalizam o fenómeno sobre séries de inflação, pelo que a sua transposição para retornos de ações não é assumida: a Secção 5.2 mede-a nos dados deste trabalho, comparando a janela de pesos iguais com uma variante que atribui maior peso às observações recentes. Uma janela deslizante acompanha parcialmente o fenómeno, uma vez que a norma contra a qual cada dia é comparado é reestimada diariamente a partir do passado próximo. A escolha não elimina o problema, e a medição referida quantifica o que custa mantê-la.

A comparação entre a família estatística e a família aprendida não permanece no plano do argumento. O Capítulo 5 executa ambas sobre os mesmos dados e reporta o resultado obtido.

2.4 Representação de texto e recuperação semântica

Esta secção percorre as formas de representar texto que tornam possível comparar notícias por significado, e enuncia o critério de avaliação da recuperação que delas decorre.

A comparação de notícias por significado depende inteiramente da representação adotada, e essa representação atravessou três gerações, esquematizadas na Figura 2.1 e detalhadas na Tabela 2.2.

A primeira geração representa um documento pela frequência dos termos que contém. O modelo de espaço vetorial (Salton, Wong e C. S. Yang 1975) é transparente e computacionalmente barato, e é cego a sinónimos: os termos “rose” e “gained” constituem, para esta representação, símbolos sem relação. Dentro da mesma geração existe uma segunda




Figura 2.1: As três gerações de representação de texto. Cada uma resolve uma limitação identificada na anterior, e a terceira é a que permite comparar duas frases diretamente pela posição dos respectivos vetores.

linha, oriunda de um quadro probabilístico distinto, a das funções de ordenação de que o BM25 (Robertson e Zaragoza 2009) é o representante corrente; ambas permanecem linhas de base fortes em recuperação de informação e partilham aquela cegueira. Em texto financeiro existe ainda uma variante especializada, os léxicos de domínio, que corrigem o facto de os dicionários de sentimento genéricos interpretarem incorretamente palavras correntes na linguagem financeira (Loughran e McDonald 2011). São integralmente transparentes, e ficam limitados ao vocabulário que foi compilado.

A segunda geração representa cada palavra como um vetor num espaço onde a proximidade traduz uso semelhante, aprendido a partir do contexto local (Mikolov et al. 2013) ou da coocorrência global (Pennington, Socher e Manning 2014). Esta representação aproxima sinónimos, resolvendo a limitação anterior, e introduz uma nova: cada palavra recebe um vetor único, independentemente da frase em que ocorre.

A terceira geração remove essa limitação. O Transformer (Vaswani et al. 2017) tornou viável o processamento da frase completa com dependências de longo alcance, e o Bidirectional Encoder Representations from Transformers (BERT) (Devlin et al. 2019) produziu representações contextuais, nas quais o vetor de uma palavra depende das que a rodeiam. Um passo adicional é necessário para o problema aqui tratado: comparar duas frases com um modelo dessa natureza exigiria processá-las conjuntamente, uma vez por par, o que não é praticável sobre uma base com dezenas de milhares de casos. O Sentence-BERT (SBERT) (Reimers e Gurevych 2019) resolve esta questão produzindo um vetor por frase, calculado uma única vez, de modo que a comparação passa a ser uma operação aritmética entre vetores já existentes.

A contribuição do SBERT que importa a este trabalho não reside na arquitetura mas no objetivo de treino: os vetores são aprendidos de forma que a distância entre dois deles traduza semelhança de sentido. Os autores reportam que um codificador da família BERT utilizado diretamente para comparar frases produz representações fracas para esse fim, ficando por vezes atrás da média simples de vetores de palavra (Reimers e Gurevych 2019). Daqui decorre que um codificador ajustado a outra tarefa não herda esta propriedade pelo facto de ter sido treinado no domínio adequado.

Para texto financeiro existem modelos treinados especificamente para o domínio (A. H. Huang, Wang e Y. Yang 2023; Zhuang Liu et al. 2020). A suposição natural é a de que sejam superiores nesta tarefa por essa razão. A suposição não é automaticamente verdadeira, e a Secção 5.3 mede-a em vez de a assumir.

O trabalho inscreve-se na literatura mais vasta de processamento de linguagem natural aplicado a finanças. A revisão de Kearney e S. Liu (2014) cobre o estado dessa área

Tabela 2.2: As abordagens consideradas para representar notícias financeiras, com a representação que cada uma produz e as implicações da sua adoção.

Abordagem	Representação	Forças e limitações
Contagem de termos (Robertson e Zaragoza 2009; Salton, Wong e C. S. Yang 1975)	Frequência ponderada de palavras	Transparente e rápida; cega a sinónimos
Léxicos financeiros (Loughran e McDonald 2011)	Listas de palavras com polaridade atribuída	Totalmente transparente; limitada ao vocabulário compilado
Vetores de palavra (Mikolov et al. 2013; Pennington, Socher e Manning 2014)	Um vetor fixo por palavra	Aproxima sinónimos; um só sentido por palavra
Vetores de frase (Devlin et al. 2019; Reimers e Gurevych 2019)	Um vetor por frase, sensível ao contexto	Compara frases diretamente; modelo maior e menos legível internamente
Modelos de domínio (A. H. Huang, Wang e Y. Yang 2023; Zhuang Liu et al. 2020)	Como acima, ajustada a texto financeiro	Vocabulário do domínio; superioridade nesta tarefa não é automática
Modelos de grande dimensão (Li et al. 2023)	Geração de texto sobre conhecimento amplo	Capacidade elevada; dispendiosos, opacos e fora da restrição de gratuidade

até 2014, dominado pelos léxicos de domínio e por classificadores supervisionados sobre contagens de palavras; as representações contextuais de frase utilizadas neste trabalho são posteriores e não constam dessa revisão. Existe ainda uma linha de investigação substancial que utiliza texto para antecipar movimentos de preço (Ding et al. 2015; Xing, Cambria e Welsch 2018). O presente trabalho situa-se fora dessa linha por opção de desenho: o texto é aqui empregue para localizar casos anteriores comparáveis, cujo desfecho já ocorreu e já foi medido, e não para gerar uma previsão.

Um trabalho recente dessa linha merece exame individual, por ser o mais próximo daquilo que aqui se faz. Du et al. (2024) treinam uma rede de tripletos sobre mensagens de redes sociais e séries de preços, e apresentam ao utilizador, junto de cada previsão, o caso histórico mais semelhante com o mesmo desfecho e o mais semelhante com desfecho oposto. É recuperação de análogos usada como explicação, sobre os mesmos materiais que este trabalho usa, e é por isso o vizinho publicado mais próximo.

As diferenças são, ainda assim, de fundo, e vale a pena enunciá-las porque delimitam a contribuição. O rótulo que organiza os tripletos é a direção do movimento do dia seguinte, e a tarefa avaliada é prevê-la; a magnitude entra apenas para definir uma faixa morta em torno de zero. O codificador de frases é usado congelado, como camada de entrada de uma rede convolucional e de uma rede recorrente com atenção, que são essas sim treinadas — ou seja o espaço em que as notícias são comparadas não é alterado. E a explicação é demonstrada por três estudos de caso com mapas de atenção, sem medição da sua qualidade e sem participantes.

Há naquele trabalho um resultado próprio que merece registo, porque diz respeito à dificuldade da tarefa e não ao método. No estudo de ablação, aplicar a aprendizagem contrastiva apenas à componente textual degrada a exatidão nos três conjuntos de referência, ficando abaixo da variante que não usa aprendizagem contrastiva nenhuma; os ganhos vêm da componente quantitativa, e os próprios autores concluem que a informação textual desempenha um papel complementar. Quem pretenda usar texto para antecipar a direção de um movimento tem aqui, publicada, uma indicação de que o sinal é fraco; a Secção 5.3 chega, por via inteiramente independente, a uma conclusão do mesmo sinal.

É sobre essas duas diferenças que a quarta questão de investigação se constrói. Se a direção é o sinal fraco que aquele estudo de ablação mostra, e se ali o espaço de comparação permanece inalterado, então ficam em aberto duas perguntas distintas: se a *magnitude* do movimento — que não é uma direção e não constitui previsão — é aprendível do texto, e se o ganho aparece quando se ajusta o próprio codificador em vez de uma rede colocada por cima dele. A Secção 3.5.1 descreve como ambas são postas à prova, com um braço treinado sobre a magnitude e um braço de replicação treinado sobre a direção, e a Secção 5.4 reporta o que se obteve.

A representação de cada notícia por um vetor converte a identificação de casos comparáveis num problema de recuperação de informação. A medida de proximidade adotada é a semelhança do cosseno, cuja mecânica é descrita na Secção 3.5. A operação é exata, uma vez que se percorre a totalidade da base de casos e se ordena o resultado, pelo que este não depende de qualquer aproximação. A escalas substancialmente superiores, a procura exaustiva pode ser substituída por um índice aproximado (Johnson, Douze e Jégou 2021) sem alteração da representação, o que constitui caminho de crescimento e não necessidade presente.

Uma vez que a recuperação devolve uma lista ordenada, a sua avaliação recorre a medidas sensíveis à ordem (Manning, Raghavan e Schütze 2008). A adotada neste trabalho é a precisão nos k primeiros resultados, ou seja a fração desses k resultados que são relevantes. A definição de relevância, que é onde uma avaliação desta natureza se decide, é estabelecida na Secção 3.5 juntamente com as linhas de base contra as quais o resultado é comparado.

2.4.1 Recuperação com geração, e por que razão o sistema para antes dela

A arquitetura hoje corrente para responder a uma pergunta a partir de um corpo de documentos é a geração aumentada por recuperação, na qual um recuperador seleciona passagens e um modelo de linguagem redige a resposta a partir delas (Lewis et al. 2020). A literatura sobre a família é extensa e encontra-se sistematizada (Y. Huang e J. X. Huang 2026).

O sistema aqui descrito executa a primeira metade dessa arquitetura e detêm-se antes da segunda, e a razão é a mesma que atravessa o trabalho. A recuperação devolve objetos verificáveis: um título, uma data, uma semelhança medida e um movimento de preço observado. A geração converte esses objetos numa afirmação em prosa, cuja fidelidade ao que foi recuperado é ela própria uma propriedade a avaliar, e que o destinatário deste sistema não tem meios para confrontar. A opção não decorre de limitação técnica, e a distinção deve ser feita com clareza: acrescentar a geração é possível e barato; o que não é barato é a avaliação de que ela não desloca o significado da evidência. Nenhuma comparação com uma arquitetura completa foi realizada neste trabalho, pelo que o que aqui se afirma é uma razão de desenho e não um resultado. A Secção 4.7 descreve a camada de geração ancorada que chegou a ser construída e avaliada, e a razão pela qual não é exposta.

2.4.2 Corpora de notícias financeiras e rótulos de setor

A avaliação de recuperação sobre notícias financeiras exige um corpo de texto alinhado com preços, e esse alinhamento é o que distingue um corpus utilizável de uma coleção de títulos. O conjunto utilizado neste trabalho é o FNSPID (Dong, Fan e Peng 2024), que reúne notícias e séries de preços correspondentes e cuja construção está documentada.

A relevância entre duas notícias é aproximada, neste trabalho, pela pertença ao mesmo setor. A opção substitui uma anotação humana inexistente por um critério objetivo, e transporta a limitação correspondente. A validade de um agrupamento é mensurável, pela separação entre grupos (Rousseeuw 1987) ou pela concordância entre agrupamentos alternativos corrigida para o acaso (Vinh, Epps e Bailey 2010). Nenhuma dessas medidas foi aplicada ao mapa setorial adotado. O que o rótulo garante é objetividade e reprodutibilidade, e não que o setor seja a partição mais informativa do corpus.

2.5 Estudos de evento e decomposição de retornos

Esta secção apresenta o instrumento com que se mede o efeito de um acontecimento sobre o preço, bem como a correção estatística de que depende a separação entre a componente de empresa e a componente de mercado.

O instrumento adotado é o estudo de evento, cuja formulação remonta a Fama et al. (1969). O comportamento do método sobre retornos diários foi examinado por Brown e Warner (1985), que confrontam formas alternativas de estimar o retorno esperado e concluem que os procedimentos correntes, assentes na estimação do modelo de mercado por mínimos

quadrados, permanecem bem especificados em janelas curtas em torno do acontecimento. O alcance desta conclusão é delimitado pelos próprios autores: a variante mais simples, que subtrai apenas a média histórica da ação, perde potência estatística e pode tornar-se mal especificada quando as datas dos acontecimentos coincidem. É este resultado que motiva a ordem de grandeza das janelas de um, três e cinco dias adotadas neste trabalho. A transposição não é direta, e a diferença está declarada na Secção 3.5, segundo a qual o valor apresentado ao utilizador é o retorno bruto e não o retorno anormal que aqueles autores estudam.

A existência de uma relação estatística entre o texto publicado e os movimentos do mercado é observação antiga (Tetlock 2007). O verbo adequado é o da evidência de uma relação estatística, e não o da demonstração de causalidade.

Um ponto metodológico condiciona a segunda pergunta do trabalho, a da separação entre a empresa e o mercado. Essa separação exige estimar a sensibilidade de cada ação ao mercado, e a estimativa é ruidosa, sobretudo em empresas voláteis ou com histórico curto. Blume (1971) estabelece que os coeficientes assim estimados tendem a regredir para a média entre períodos sucessivos, ou seja que uma estimativa extrema num período tende a sê-lo menos no seguinte; daí decorreu a prática, corrente mas posterior ao próprio artigo, de encolher a estimativa com um peso fixo. Essa prática aplica a mesma correção a estimativas precisas e imprecisas. A alternativa adotada neste trabalho pondera o encolhimento pela imprecisão da própria estimativa (Vasicek 1973), de modo que uma estimativa fiável é praticamente preservada e uma estimativa frágil é aproximada do valor de referência. A formulação é apresentada na Secção 3.4.

O enquadramento teórico que justifica a recusa de prever pertence igualmente a esta área. A hipótese dos mercados eficientes, na sua forma semiforte, sustenta que os preços refletem já a informação publicamente disponível (Fama 1970), do que decorre que movimentos futuros não deveriam ser sistematicamente previsíveis a partir dessa informação. Constitui uma das razões pelas quais o sistema mede o que já ocorreu em vez de projetar o que virá; a segunda, de natureza prática, é que apenas o passado é verificável por quem lê.

2.6 Raciocínio baseado em casos

Esta secção enquadra a terceira técnica do sistema numa linha estabelecida de inteligência artificial e delimita a parte dessa linha que o trabalho implementa.

O raciocínio baseado em casos (Aamodt e Plaza 1994) aborda um problema novo através da recuperação de problemas anteriores semelhantes e do aproveitamento do que sobre eles é conhecido, dispensando o recurso exclusivo a conhecimento geral do domínio. A fonte organiza o método num ciclo de quatro processos, a saber recuperar, reutilizar, rever e reter, e considera os quatro necessários à resolução completa de um problema.

A Figura 2.2 representa o ciclo e assinala onde o sistema se detém.

A técnica descrita na Secção 3.5 implementa os dois primeiros e interrompe-se deliberadamente antes dos restantes: recupera casos semelhantes e apresenta o que neles foi medido, sem adaptar esse desfecho ao caso presente. A adaptação produziria uma expectativa sobre o que virá a acontecer, ou seja precisamente a previsão que o trabalho recusa. A implementação parcial de um ciclo estabelecido é, neste caso, uma consequência da restrição fundadora e não uma insuficiência.

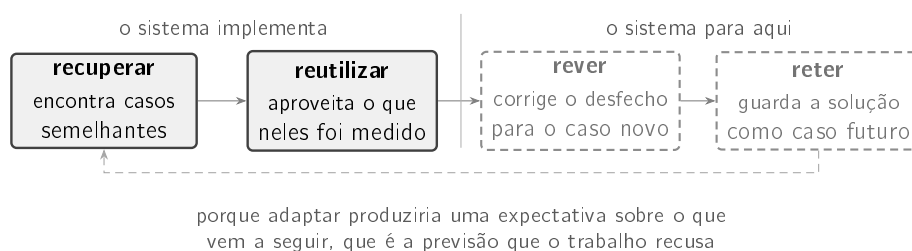


Figura 2.2: Os quatro processos que Aamodt e Plaza (1994) consideram necessários à resolução completa de um problema. O sistema executa os dois primeiros a cheio e detém-se antes dos dois seguintes. A interrupção não é uma insuficiência de implementação: *rever* adapta o desfecho de um caso passado ao caso presente, e essa adaptação é uma expectativa sobre o futuro, ou seja exatamente a previsão que a restrição fundadora recusa. O que o sistema apresenta é o desfecho medido de cada caso, tal como ocorreu. Os dois primeiros processos, executados por inteiro e com a decisão entregue à pessoa, correspondem ao que Kolodner (1991) designa por apoio à decisão baseado em casos.

Esta paragem tem, além disso, nome próprio na literatura, e reconhecê-lo altera-lhe o estatuto. Kolodner (1991) descreve o *apoio à decisão baseado em casos* como uma metodologia em que o sistema aumenta a memória da pessoa fornecendo-lhe casos análogos, e em que é a pessoa, e não a máquina, quem decide, servindo-se desses casos como orientação. O ponto de partida é uma observação de psicologia: as pessoas raciocinam bem por analogia mas recordam mal os casos certos, ao passo que os computadores recordam bem. Enunciado assim, o que este sistema faz deixa de ser a execução de metade de um ciclo e passa a ser a execução completa de uma metodologia distinta, proposta em 1991 por quem definiu a área. A diferença não é de amor-próprio: uma implementação parcial explica o que lhe falta, ao passo que uma metodologia declara o que entrega e a quem cabe decidir.

Convém, em sentido contrário, registar o que o raciocínio baseado em casos tem efetivamente feito neste domínio, para que a originalidade reivindicada não seja maior do que é. Oh e T. Y. Kim (2007) constroem um indicador diário da condição do mercado financeiro coreano que classifica cada dia como período estável, instável ou de crise, recuperando casos de uma base construída sobre a crise de 1997. É raciocínio baseado em casos aplicado a finanças, e é instrutivo por dois motivos. O primeiro é o objeto: a unidade classificada é o mercado inteiro, num juízo sobre risco sistémico, e não o movimento de uma empresa na sequência de uma notícia. O segundo é o destino dos casos recuperados, que servem para produzir automaticamente uma etiqueta; o artigo não descreve a sua apresentação a quem quer que seja. Mostrar os casos, que é o que aqui se faz com eles, é precisamente o que ali fica por fazer.

A opção encontra apoio adicional do lado de quem lê. A investigação sobre explicação em ciências sociais estabelece que as pessoas procuram razões contrastivas e seletivas, e não uma enumeração exhaustiva de tudo o que contribuiu para um resultado (Miller 2019). Um conjunto reduzido de casos concretos, com data e desfecho, corresponde melhor a essa expectativa do que um coeficiente. É por essa razão que cada alerta apresenta alguns precedentes e as quantidades exatas que sustentam a decisão, em vez da totalidade dos valores calculados.

Há um segundo requisito, do mesmo lado, que condiciona não o conteúdo da explicação mas

a frequência com que ela é entregue. Um destinatário exposto a avisos em excesso deixa de os processar, fenómeno documentado em domínios onde o custo de o ignorar é elevado (Ancker et al. 2017), e cuja transposição para este domínio deixou de ser necessária desde que existe medição feita sobre investidores particulares (C.-W. Liu, Chen e Wen 2023), discutida na Secção 2.1. A consequência é que a política de decisão constitui parte do desenho. Um alerta que não é lido vale o mesmo que um alerta que não foi enviado, e é por isso que o Capítulo 4 trata os critérios de supressão com o cuidado que dedica aos métodos.

2.7 Explicabilidade e confiança em sistemas automáticos

Esta secção situa o requisito de explicabilidade que atravessa o trabalho e apresenta as cautelas que a literatura associa à apresentação de explicações.

A exigência de que um sistema demonstre como chegou a uma conclusão constitui uma área própria, com revisões consolidadas (Adadi e Berrada 2018; Barredo Arrieta et al. 2020). A área divide-se em duas vias, representadas na Figura 2.3: os modelos transparentes, interpretáveis em si mesmos, e os métodos *a posteriori*, que explicam um modelo opaco já treinado e que podem ser organizados pelo tipo de objeto que explicam (Guidotti et al. 2018).




Figura 2.3: As duas vias distinguidas pela literatura (Barredo Arrieta et al. 2020; Guidotti et al. 2018): construir modelos transparentes por desenho, ou explicar um modelo opaco depois de treinado. Este trabalho segue a primeira.

Os dois métodos *a posteriori* de utilização mais generalizada operam de formas distintas. O LIME ajusta um modelo simples na vizinhança de uma previsão individual, aproximando localmente o comportamento do modelo opaco (Ribeiro, Singh e Guestrin 2016). O SHAP atribui uma previsão às variáveis que a produziram recorrendo a valores de Shapley (Lundberg e S.-I. Lee 2017). Ambos são genéricos e ambos são úteis.

Ambos partilham, contudo, uma propriedade determinante neste contexto. Perante decisões de consequência séria, Rudin (2019) defende o abandono dos modelos opacos em favor de modelos interpretáveis por construção, com o argumento de que toda a explicação *a posteriori* constitui ela própria uma aproximação, e uma aproximação pode conduzir a leituras erradas. O utilizador recebe nesse caso dois objetos cuja relação não está em condições de avaliar, que são uma decisão e uma explicação que pode não lhe corresponder.

Este trabalho segue a via conservadora. Em lugar de explicar *a posteriori* um modelo opaco, recorre a componentes em que a explicação e o cálculo coincidem. Um afastamento face a uma norma recente, uma repartição aditiva cuja soma reproduz o movimento observado e um conjunto de casos anteriores com os desfechos medidos constituem objetos apresentáveis por inteiro. A explicação não constitui um segundo objeto produzido sobre a decisão: é a decisão, enunciada por extenso.

Duas cautelas da literatura fecham esta secção, e ambas condicionam a organização do Capítulo 5.

A primeira é que interpretabilidade não designa uma propriedade única (Lipton 2018), pelo que um sistema deve declarar o tipo de interpretabilidade que oferece em vez de reclamar o termo sem qualificação. Este trabalho oferece transparência de mecanismo, ou seja o utilizador pode seguir o cálculo que conduziu à decisão, e não oferece uma explicação causal do acontecimento no mundo.

A segunda respeita ao efeito da própria explicação sobre quem a recebe. A confiança em sistemas automáticos falha em dois sentidos simétricos, com o utilizador a ignorar um aviso correto ou a aceitar um aviso incorreto, pelo que o objetivo não é maximizar a confiança mas torná-la ajustada à capacidade real do sistema (J. D. Lee e See 2004). Bansal et al. (2021) acrescentam que a presença de uma explicação aumenta a probabilidade de aceitação da resposta do sistema quer esta esteja certa quer esteja errada, ou seja que o ganho observado não decorre de a pessoa passar a distinguir melhor os dois casos. As consequências de desenho que daqui decorrem estão descritas na Secção 3.8.3.

Estas cautelas são gerais. Sobre a opção concreta desta dissertação — explicar por casos — existe evidência empírica recolhida com pessoas que aponta em sentido contrário, e remetê-la para uma nota de rodapé seria a forma mais barata de a neutralizar.

Waa et al. (2021) compararam explicações por regras, explicações por exemplos e ausência de explicação, em duas experiências com quarenta e cinco participantes cada, num apoio à decisão para dosagem de insulina. As explicações por regras melhoraram significativamente a identificação do fator decisivo; as explicações por exemplos não se distinguiram da ausência de explicação, nem na identificação do fator ($p = 0,796$) nem na compreensão auto-reportada ($p = 0,283$). A explicação que os autores dão para o resultado é a parte que mais interessa a este trabalho: ambos os estilos, escrevem, fornecem apenas os pormenores relevantes para uma decisão isolada, e não o raciocínio ou a causalidade que lhe estão por baixo.

No próprio domínio financeiro, e com não-especialistas, existem dois estudos recentes. Cau et al. (2023) comparam três estilos de explicação numa tarefa de negociação de ações e concluem que os estilos abduutivo e dedutivo melhoram o desempenho quando o modelo está confiante, por comparação com o estilo indutivo — que é o estilo baseado em exemplos, ou seja o mais próximo daquilo que este sistema entrega. Bertrand, Eagan e Maxwell (2023) testam um consultor automático de seguros de vida com explicações por atributos e concluem que estas não melhoram nem a compreensão nem a adequação da confiança, por comparação com não dar explicação nenhuma, e que o formato mais conversacional aumenta a confiança do utilizador por vezes em prejuízo dele.

Daqui decorrem três consequências para esta dissertação. A primeira é que a opção por explicação baseada em casos, justificada na Secção 2.6 pela literatura de explicação em ciências sociais (Miller 2019), não tem apoio nas medições com pessoas que existem, e num

caso tem contra si evidência do próprio domínio. A segunda é que o diagnóstico de Waa et al. (2021) nomeia exatamente aquilo que este sistema acrescenta aos casos: uma repartição aditiva cuja soma reproduz o movimento observado, que é o cálculo subjacente cuja ausência os autores responsabilizam pelo resultado. O sistema não entrega apenas casos; entrega casos e a conta que os acompanha. Se isso é suficiente é uma pergunta empírica em aberto, e o trabalho não a responde. A terceira, e a mais consequente, é que estes resultados tornam o estudo com utilizadores mais necessário e não menos: existe literatura publicada a apontar contra a hipótese fundadora, e é nesses termos que a Secção 6.4 enuncia a sua ausência.

O segundo estudo apoia, em contrapartida, uma decisão já tomada. Se o formato conversacional é o que produz confiança excessiva, então não expor a camada conversacional descrita na Secção 4.8 deixa de ser apenas prudência de engenharia e passa a ter apoio empírico no domínio.

Acresce que afirmações de interpretabilidade exigem avaliação rigorosa e não se estabelecem por declaração (Doshi-Velez e B. Kim 2018). É por essa razão que o Capítulo 5 mede o que é mensurável por procedimento automático e identifica explicitamente a parte que permanece por avaliar por ausência de um estudo controlado com utilizadores.

2.8 Aprendizagem automática em ambiente de produção

Esta secção reúne a literatura relativa ao componente aprendido do sistema, organizada segundo as três questões que a sua implantação levanta.

A primeira questão é a de determinar contra que referência superior comparar um modelo simples. Conjuntos de árvores treinados por reforço do gradiente (Friedman 2001) captam interações e efeitos não lineares que uma regressão logística não capta, e desempenham por isso essa função no Capítulo 5. Não se afirma que constituam o melhor método existente, uma vez que tal seria uma afirmação sobre um campo inteiro.

A segunda questão respeita à honestidade do valor apresentado. Uma pontuação só é interpretável como probabilidade se estiver calibrada, e as pontuações em bruto de muitos classificadores não o estão; a calibração *a posteriori* sobre um bloco de validação reservado corrige essa distorção (Niculescu-Mizil e Caruana 2005). A mesma fonte não favorece, contudo, a opção tomada neste trabalho: identifica a regressão logística como já bem calibrada à partida e conclui que, acima de cerca de mil casos de calibração, a regressão isotónica iguala ou supera a sigmoide. O modelo implantado é uma regressão logística com um bloco de validação muito acima desse limiar, pelo que ambas as afirmações se lhe aplicam. A opção justifica-se por medição e não por autoridade: a comparação das duas variantes sobre a mesma validação está reportada na Tabela 5.6, na página 92.

Uma via alternativa foi considerada e não adotada. A predição conformal devolve um conjunto de rótulos com uma garantia livre de distribuição, válida em amostras finitas (Angelopoulos e Bates 2023; Vovk, Gammerman e Shafer 2005). Duas precisões determinam que não é aplicável nas condições deste trabalho. A cobertura da variante corrente é marginal: vale em média sobre os casos, e não caso a caso. E a garantia exige permutabilidade entre o bloco de calibração e o de teste, hipótese que a divisão cronológica com embargo da Secção 3.6 recusa por construção. A Secção 6.5 retoma o método como caminho a explorar.

A terceira questão é a da permanência do desempenho ao longo do tempo. Um modelo implantado enfrenta alteração da distribuição dos dados que observa, e a literatura de deriva de conceito estabelece a taxonomia dessa mudança e as estratégias de detecção e adaptação (Gama et al. 2014). Este trabalho mede a deriva sobre os seus próprios dados em vez de assumir ausente.

Existe, por fim, um custo que não é captado por nenhuma métrica de qualidade. D. Sculley et al. (2015) estabelecem que os componentes de aprendizagem automática acumulam manutenção oculta, em particular através do emaranhamento entre peças e de dependências de dados instáveis e não declaradas. O Capítulo 6 regressa a este ponto com um exemplo medido no presente sistema, em que parte do ciclo de aprendizagem se interrompeu sem que qualquer erro fosse registado.

2.9 Síntese e posicionamento do trabalho

Esta secção localiza o trabalho relativamente à revisão apresentada e enuncia as decisões de âmbito que dela decorrem.

A revisão permite delimitar com precisão o espaço em que o trabalho se inscreve, e esse espaço não constitui um vazio técnico. Cada componente utilizado existe, está publicado e está avaliado, como a Tabela 2.3 torna explícito.

Tabela 2.3: Cada componente do sistema existe na literatura de forma isolada. O que não existe é a sua combinação sob a restrição de custo nulo, com a evidência entregue ao utilizador no momento em que a afirmação lhe é apresentada.

Pergunta	O que a literatura oferece	O que falta ao público-alvo
É invulgar?	Deteção de anomalias, estatística e aprendida (Chandola, Banerjee e Kumar 2009; F. T. Liu, Ting e Zhou 2008)	Uma medida relativa à norma da própria empresa, comunicada em linguagem acessível
É a empresa ou o mercado?	Estudo de evento e estimação de sensibilidade (Brown e Warner 1985; Vasicek 1973)	Disponibilidade fora de um terminal profissional
Já aconteceu antes?	Representação de frases e recuperação (Manning, Raghavan e Schütze 2008; Reimers e Gurevych 2019)	Uma base de casos com desfechos medidos, e não recordados
Por que razão acreditar?	Explicabilidade e literatura de confiança (J. D. Lee e See 2004; Rudin 2019); medições com pessoas que não confirmam o ganho (Bertrand, Eagan e Maxwell 2023; Cau et al. 2023; Waa et al. 2021)	A evidência entregue junto da afirmação e verificável no momento da leitura — por demonstrar com utilizadores

A lacuna não é, portanto, de método, mas de integração sob restrição. Os produtos que respondem às três perguntas são terminais profissionais, indisponíveis em regime gratuito ou acessível ao investidor particular. O seu preço não é publicado de forma citável, e é a indisponibilidade, e não um valor concreto, que sustenta o argumento. Os produtos gratuitos que declaram responder à terceira entregam uma afirmação sem a evidência que a sustenta. E os componentes académicos que resolveriam cada parte foram avaliados isoladamente, sobre corpora de referência, nunca como um sistema em funcionamento contínuo contra fontes reais.

Esta última afirmação precisa de uma ressalva, e a Secção 2.2 deu-lhe o nome. Sistemas integrados para este público existem e estão publicados, sendo o mais desenvolvido o de Muntermann (2009). A diferença face a esse trabalho não é de integração, que ele também fez, mas de duas outras coisas. A primeira é a postura epistémica: aquele sistema estima o efeito de preço que se seguirá ao comunicado, e este mede o efeito que já se produziu e explica-o. A segunda é o objeto da avaliação: aquele mede a oportunidade económica por simulação, e este mede a qualidade daquilo que entrega, contra dados reais e ao longo de um período de funcionamento. Enunciada assim, a lacuna é mais estreita do que uma afirmação de ausência, e é defensável.

Esta observação determina a distinção que atravessa o trabalho e que o Capítulo 4 retoma ao justificar a ausência de um modelo de linguagem na composição das mensagens. Uma frase gerada é uma afirmação: apresenta-se ao leitor num registo fluente e não lhe fornece meios para a confrontar com aquilo que a sustenta. Uma frase composta a partir de objetos calculados é uma afirmação acompanhada da evidência, na qual cada valor apresentado remete para a medição que o produziu e o leitor pode confirmar cada elemento no momento em que o lê. É esta a propriedade que o sistema procura preservar, e é ela que fixa a natureza da contribuição. Não é a formulação de um método novo. É a seleção, integração e avaliação crítica de métodos existentes num sistema funcional, sob restrições declaradas, e com os resultados que não favorecem as opções tomadas incluídos na avaliação.

Quatro decisões de âmbito decorrem deste posicionamento, e cada uma exclui deliberadamente uma classe de funcionalidade.

Responder às três perguntas, e apenas a essas. Não são incorporadas funcionalidades que não sirvam uma delas, o que mantém o sistema com dimensão compatível com a sua explicação integral.

Não produzir previsões de preço. Nem direção, nem alvo, nem recomendação. Além da razão de verificabilidade enunciada no Capítulo 1, aplica-se o enquadramento teórico da Secção 2.5 (Fama 1970).

Não gerir carteiras nem prestar aconselhamento. O sistema não conhece as posições do utilizador e não lhe indica que ação tomar, o que evita a recolha de dados pessoais e mantém o trabalho fora da fronteira do aconselhamento financeiro regulado.

Utilizar exclusivamente fontes gratuitas. A restrição torna o sistema acessível ao público a que se destina e converte as limitações resultantes em quantidades medidas e reportadas.

A última decisão tem um custo real que importa enunciar sem atenuação. As notícias chegam com atraso e a cobertura dos acontecimentos é incompleta. O Capítulo 4 quantifica ambas as limitações e o Capítulo 6 avalia as suas consequências.

Capítulo 3

Métodos e materiais

O Capítulo 2 estabeleceu que as três perguntas do investidor particular têm resposta na literatura mas não em nenhuma ferramenta gratuita. Este capítulo descreve as opções tomadas para lhes responder. Apresenta-se primeiro a metodologia de investigação e os conjuntos de dados. Descrevem-se em seguida os quatro métodos seleccionados, um para cada decisão que o sistema tem de tomar. Indicam-se as ferramentas empregues. E enunciam-se, por fim, os desafios tecnológicos e sociais do domínio. Quem o leia fica a saber como cada uma das quatro decisões é tomada, e que garantia impede cada uma de utilizar informação que ainda não existia.

3.1 Metodologia de investigação

Esta dissertação enquadra-se na investigação por desenho (Hevner et al. 2004), na qual o objeto de estudo é um artefacto construído para resolver uma classe de problema e o conhecimento produzido reside tanto no artefacto como no processo da sua avaliação. Trata-se do enquadramento adequado quando a contribuição é um sistema, e distingue-se de um estudo puramente empírico pelo facto de o objeto avaliado não existir antes da sua construção.

A literatura de investigação por desenho estabelece que a avaliação do artefacto deve ser rigorosa e constituir uma atividade central do processo, e não um passo final de confirmação (Hevner et al. 2004; Peffers et al. 2007). Este requisito é cumprido através de três compromissos assumidos antes da execução das experiências.

O primeiro consiste em comparar deteção, recuperação e triagem com alternativas mais simples, seleccionadas antes da medição, de modo que o resultado possa ser negativo. A decomposição recebe apenas uma verificação descritiva da repartição e do ajuste. O segundo consiste em fixar o critério de sucesso de cada comparação juntamente com a métrica, e não após a observação dos valores obtidos. O terceiro consiste em avaliar o artefacto duas vezes: sobre dados históricos retidos e, posteriormente, em funcionamento, sobre as decisões que o sistema toma autonomamente em produção. Esta segunda avaliação produz o resultado descrito na Secção 5.7.

A exigência não é cumprida na totalidade, e a lacuna é declarada. Utilidade, no sentido em que a literatura de investigação por desenho emprega o termo, é utilidade para quem usa o artefacto, e essa propriedade determina-se com utilizadores. O que nesta dissertação foi medido é a fidelidade das explicações produzidas, propriedade que pertence ao sistema; a utilidade, que depende da relação entre o sistema e quem o lê, permanece por medir.

O sistema toma quatro decisões distintas, representadas na Figura 3.1. As três primeiras correspondem às três perguntas do investidor enunciadas no Capítulo 1; a quarta não é uma questão do investidor, mas do próprio sistema, e existe porque responder às três primeiras não implica interromper o utilizador.

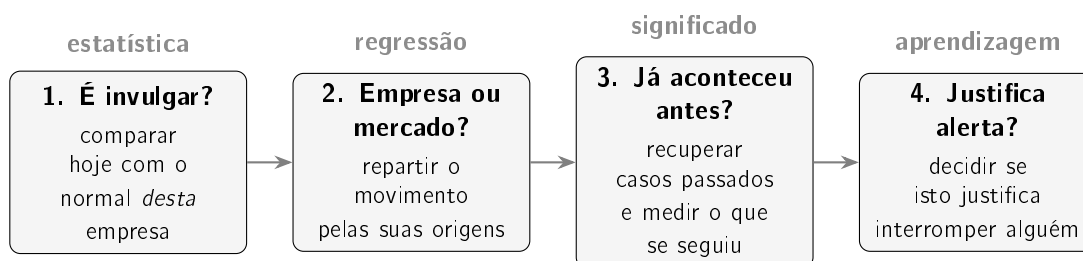


Figura 3.1: As quatro decisões do sistema e a família de técnicas associada a cada uma. As três primeiras correspondem às perguntas enunciadas no Capítulo 1. A cada coluna corresponde uma secção deste capítulo, entre a Secção 3.3 e a Secção 3.6.

3.2 Conjuntos de dados

Esta secção descreve os conjuntos de dados utilizados no treino e na avaliação do sistema, bem como os registos produzidos pelo sistema em funcionamento.

A camada histórica utiliza a componente de notícias do FNSPID (Dong, Fan e Peng 2024), que associa a cada título uma data e uma empresa. Embora o conjunto publicado também inclua preços, neste trabalho os retornos e os rótulos são construídos alinhando os títulos com séries de preços obtidas separadamente. Do alinhamento resulta o conjunto de treino do modelo de triagem, com 79 753 exemplos.

O ficheiro de origem é identificado pela revisão, e não pelo nome. O FNSPID é distribuído num repositório cujo endereço por omissão aponta para o ramo principal, e um ramo é um ponteiro que se move: um conjunto de dados assim referido não é reproduzível por construção. O corpus deste trabalho parte do ficheiro `Stock_news/nasdaq_external_data.csv` numa revisão fixa, com 23,2 GB e soma de controlo SHA-256 de prefixo `1a7a3eb8`; a filtragem é local e determinística, e o corpus que dela resulta tem prefixo `af61708c`. As somas completas, a contagem por empresa e a auditoria do procedimento constam de um manifesto versionado no repositório, e um teste automático recusa qualquer corpus que não seja este.

Duas decisões de construção ficam declaradas por afetarem a leitura dos resultados. A primeira é que os títulos são conservados tal como o FNSPID os entrega: o corpus contém 1 704 títulos exatamente repetidos, 2,1% do total, que não foram removidos. A segunda é que a filtragem percorre o ficheiro inteiro, em vez de parar quando julga ter passado os símbolos procurados; o ficheiro não está globalmente ordenado por símbolo, e uma paragem antecipada truncaria o corpus em silêncio.

O conjunto cobre catorze das quinze empresas do mapa canónico. A ausente é a Meta, e a razão está no conjunto de dados e não no procedimento: o FNSPID indexa a empresa pelo símbolo antigo FB, pelo que a seleção pelo símbolo atual não devolve registo nenhum. Os registos sob o símbolo antigo existem, mas resumem-se a 432 títulos distribuídos por 87 dias entre fevereiro e junho de 2020 — quatro meses num intervalo de seis anos. A empresa

consta, por isso, da avaliação da deteção, que assenta em preços, e não do conjunto de notícias.

A avaliação do detetor de anomalias utiliza um conjunto distinto, composto por três anos de cotações diárias. A escolha de um conjunto próprio é deliberada: a avaliação exige variedade de volatilidade entre empresas, ao passo que a lista monitorizada em produção é uma decisão de produto. Avaliar o detetor exatamente sobre o conjunto que ele foi construído para servir produziria uma medição sem valor informativo.

Todos os preços utilizados são fechos ajustados para desdobramentos e distribuição de dividendos. O ajuste não é um pormenor no período considerado, que contém um desdobramento de quatro para um da Apple e dois da Tesla: sobre séries não ajustadas, o detetor assinalaria quedas de trinta a oitenta por cento em dias sem qualquer acontecimento.

A Tabela 3.1 reúne os conjuntos utilizados, e a Tabela 3.2 os conjuntos de empresas, cujas contagens diferem por razões descritas na coluna respetiva.

Tabela 3.1: Conjuntos de dados utilizados no trabalho. O intervalo do conjunto de treino da triagem refere-se a dias de negociação, depois do alinhamento: os títulos vão de 2018-01-01 a 2023-12-16, e as duas datas extremas — um feriado e um sábado — são remetidas para a sessão seguinte. As três últimas linhas correspondem ao sistema em funcionamento.

Conjunto	Intervalo	Dimensão
<i>Histórico</i>		
Conjunto de treino da triagem	2018-01-02 a 2023-12-18	79 753 exemplos, 14 empresas
Preços para avaliação da deteção	2023-06-01 a 2026-06-01	15 empresas, $\approx$ 750 dias cada
<i>Operação</i>		
Base de precedentes reconstruída	um ano de recolha própria	38 214 casos com impacto medido
Alertas entregues	2026-07-09 a 2026-08-13	367 mensagens
Registo de decisões de triagem	2026-07-22 a 2026-08-20	36 925 decisões

3.3 Deteção de movimentos invulgares

A primeira decisão do sistema consiste em determinar se o movimento observado num dia é invulgar para a empresa em causa. Uma regra de limiar fixo, do tipo assinalar variações superiores a três por cento, é inadequada para este fim, porque a mesma percentagem corresponde a acontecimentos de raridade muito distinta consoante a volatilidade da empresa.

O método adotado pertence à família estatística da taxonomia de deteção de anomalias (Chandola, Banerjee e Kumar 2009), que define normalidade a partir da distribuição recente dos próprios dados. O movimento do dia é comparado com o comportamento recente da mesma ação e expresso em desvios-padrão:

$$z_t = \frac{r_t - \mu}{\sigma} \quad (3.1)$$

3.3. Detecção de movimentos invulgares

Tabela 3.2: Conjuntos de empresas utilizados. As contagens diferem porque cada conjunto serve um propósito distinto. Os conjuntos não são encaixados: a lista monitorizada em produção contém duas empresas ausentes de todos os conjuntos históricos, e o mapa canónico contém uma terceira — a Meta — que não chega ao conjunto de dados da triagem, pela razão dada acima.

Conjunto	Empresas	Propósito
Mapa de setores alargado	17	Universo percorrido pela decomposição do movimento
Mapa canónico do histórico	15	Rótulo de relevância na avaliação da recuperação
Preços para a deteção	15	Variedade de volatilidade na avaliação do detetor
Conjunto de dados da triagem	14	Resultado do alinhamento entre notícias e preços
coberto pelo bloco de treino	13	Empresas efetivamente presentes no treino
coberto pelo bloco de teste	9	Empresas presentes na avaliação
Lista monitorizada em produção	12	Decisão de produto

onde r_t é o retorno logarítmico do dia, $r_t = \ln(P_t/P_{t-1})$, e μ e σ são a média e o desvio-padrão dos retornos dos vinte dias anteriores. A utilização de retornos logarítmicos segue a convenção corrente em séries financeiras, por tornar os retornos aditivos ao longo do tempo e simétricos entre subidas e descidas. Os valores apresentados diferem, por essa razão, dos exibidos por uma aplicação de bolsa: um retorno logarítmico de +19,82% corresponde a uma variação de preço de +21,92%.

A janela desliza a cada dia, e o dia avaliado é excluído da janela que define a sua própria norma, como representado na Figura 3.2. Sem esta exclusão, o dia contribuiria para a média e para o desvio-padrão contra os quais é comparado, atenuando a sua própria anomalia. A mesma disciplina impede a utilização de qualquer informação posterior ao dia avaliado.




Figura 3.2: A janela que estabelece o comportamento habitual da ação. O dia avaliado **fica de fora** do cálculo da norma contra a qual é comparado, separação que impede a utilização de informação indisponível no momento da decisão.

A separação não é apenas uma convenção de escrita: é uma fatia. O Excerto 3.1 reproduz o cálculo tal como é executado. A linha que a garante é a que estabelece a janela **recent**, cujo intervalo termina no penúltimo elemento e exclui, por construção, o dia que está a ser avaliado.

Quando o desvio-padrão da janela é nulo, a Equação 3.1 não está definida. O sistema distingue dois casos: a manutenção do valor constante não constitui anomalia, ao passo

```

1 r = pd.Series(list(returns), dtype="float64").dropna().reset_index(drop=
  ↳ True)
2 if len(r) < window + 1:
3     raise ValueError(f"São precisos pelo menos {window + 1} retornos (
  ↳ recebidos {len(r)}).")
4
5 recent = r.iloc[-window - 1 : -1] # janela ANTES do último (sem
  ↳ lookahead)
6 last = float(r.iloc[-1])
7 mu = float(recent.mean())
8 sigma = float(recent.std(ddof=1))

```

Excerto 3.1: A janela que exclui o dia avaliado. O intervalo $[-window-1:-1]$ termina antes do último elemento, pelo que o retorno do dia em avaliação não entra na média nem no desvio-padrão contra os quais é comparado. Reproduz-se o corpo da função de detecção, sem a indentação que ela tem no ficheiro de origem.

que um afastamento dessa norma plana é assinalado sem lhe ser atribuído um valor de z , indicando-se que a variância anterior era nula. Esta distinção evita que a proteção contra a divisão por zero silencie precisamente o primeiro movimento após um período constante.

A aplicação do método ao maior movimento do período estudado, registado pela Tesla a 24 de outubro de 2024, produz um retorno diário de $+19,82\%$ contra uma média de $-0,92\%$ e um desvio-padrão de $2,725\%$ nos vinte dias anteriores, o que corresponde a $z = +7,61$. O valor não decorre da dimensão absoluta do movimento, mas do facto de este exceder em sete vezes e meia a oscilação habitual da ação naquelas semanas.

3.4 Decomposição do movimento observado

A técnica anterior quantifica a dimensão do movimento, mas não identifica a sua origem. A segunda decisão do sistema consiste em repartir o retorno observado nas suas componentes de mercado, de setor e específica da empresa:

$$r = \underbrace{\beta_m r_m}_{\text{mercado}} + \underbrace{\beta_s \tilde{r}_s}_{\text{setor}} + \underbrace{\varepsilon}_{\text{empresa}} \quad (3.2)$$

As variáveis r_m e $\tilde{r}_s$ designam, respetivamente, o retorno diário do índice de mercado e o do setor, ao passo que β_m e β_s quantificam a sensibilidade histórica da ação a cada uma dessas fontes. A componente específica da empresa é definida como o resíduo, pelo que a soma das três parcelas reproduz sempre o movimento observado. O mercado é representado pelo fundo cotado que segue o índice largo norte-americano, e o setor pelo fundo setorial correspondente, escolhidos por serem os mais líquidos da sua classe e por disporem de histórico longo em fontes gratuitas.

Três aspetos determinam a validade da repartição.

O primeiro é a ortogonalização do fator setorial. Um fundo setorial e o índice de mercado apresentam movimentos fortemente correlacionados, e a sua introdução conjunta na regressão produz coeficientes instáveis por colinearidade. O fator utilizado não é, por isso, o retorno do setor, mas o resíduo de uma primeira regressão do setor sobre o mercado.

3.4. Decomposição do movimento observado

O segundo é a restrição temporal da estimação. A janela termina no dia anterior ao dia explicado, pela mesma disciplina aplicada à detecção.

O terceiro é o tratamento do ruído. Uma sensibilidade estimada sobre vinte observações é imprecisa, e estimativas extremas em janelas agitadas produzem repartições sem significado. A literatura de finanças documenta que os betas estimados regredem para a média entre períodos sucessivos (Blume 1971), do que decorreu a prática de encolher a estimativa com um peso fixo. Essa prática aplica a mesma correção a estimativas precisas e imprecisas. A alternativa adotada pondera o encolhimento pela imprecisão da própria estimativa (Vasicek 1973):

$$\beta = w\hat{\beta} + (1 - w)\beta_{\text{ref}}, \quad w = \frac{\sigma_{\text{ref}}^2}{\sigma_{\text{ref}}^2 + \text{SE}^2(\hat{\beta})} \quad (3.3)$$

Quando o ajuste é preciso, o erro-padrão é reduzido, w aproxima-se da unidade e a estimativa é praticamente preservada; quando a janela é ruidosa, o erro-padrão cresce e a estimativa recai sobre o valor de referência. O ajuste é gradual e não dicotômico. A formulação original estima β_{ref} e σ_{ref}^2 a partir da distribuição transversal dos betas; neste trabalho são fixados, e cada um tem justificação própria. Para o mercado adota-se $\beta_{\text{ref}} = 1,0$, que corresponde à hipótese de a ação acompanhar o índice na ausência de informação local fiável, e é o valor para o qual a média transversal dos betas tende por construção do próprio índice. Para o fator setorial, já ortogonalizado face ao mercado, adota-se $\beta_{\text{ref}} = 0,0$, como escolha de regularização para ausência de exposição setorial adicional quando a estimativa é imprecisa. A média nula do fator ortogonalizado não implica um coeficiente nulo. O desvio-padrão comum de 0,5 determina a rapidez da transição entre a estimativa amostral e o valor de referência: fixa-o de modo que uma janela com erro-padrão dessa mesma ordem receba peso aproximadamente igual das duas origens, o que situa o ponto de equilíbrio dentro da gama de erros-padrão efetivamente observada em janelas de vinte dias. A estimação destes valores a partir da amostra não foi realizada, e a razão é declarada: doze a dezassete empresas não constituem um corte transversal representativo, pelo que um prior estimado sobre elas teria aparência empírica sem o ser.

Três salvaguardas completam a estimação. Abaixo de dez observações utilizáveis a regressão não é tentada, assumindo-se sensibilidade unitária ao mercado e nula ao setor, situação que é declarada ao utilizador. Uma estimativa cujo módulo exceda dez é tratada como falha numérica da janela e não como sensibilidade económica, recaindo no mesmo recuo; a guarda destina-se a janelas degeneradas e não substitui o encolhimento, que é o mecanismo que trata o ruído. Por fim, o termo constante é recalculado sobre os coeficientes já encolhidos, uma vez que o valor devolvido pela regressão está centrado nos coeficientes brutos e a sua reutilização descentraria o modelo efetivamente reportado.

A Figura 3.3 apresenta a repartição de um movimento real, em que as componentes de mercado e de setor atuam em sentido contrário ao movimento observado.

Neste caso da AMD, o retorno logarítmico de +6,2944%, correspondente a uma variação simples do preço de +6,50%, reparte-se em -0,3992% de mercado, -0,0362% de setor e +6,7298% específicos da empresa, com $\beta_m = 2,0143$ e $\beta_s = 1,5888$ estimados sobre os vinte dias anteriores. A informação transmitida excede a percentagem isolada: a ação subiu apesar de o contexto ter atuado em sentido contrário, e o beta de mercado indica uma ação que historicamente amplifica os movimentos do índice.




Figura 3.3: Repartição de um movimento da AMD em retornos logarítmicos. A data das barras não ficou preservada no registo desta avaliação. As componentes de mercado e de setor atuaram em sentido descendente, pelo que a subida é integralmente atribuída à empresa. A igualdade entre a soma das parcelas e o movimento observado verifica-se por construção e, por essa razão, nada estabelece quanto à qualidade do ajuste, ponto retomado na Secção 5.6.

A soma exata das três parcelas não constitui validação do método. A igualdade verifica-se por construção, uma vez que a componente específica é definida como resíduo, e uma repartição sem significado somaria igualmente. A medida informativa sobre a qualidade do ajuste é o coeficiente de determinação na janela de estimação, cujo valor é reportado no Capítulo 5.

3.5 Recuperação de precedentes

A terceira decisão consiste em identificar notícias passadas comparáveis com a notícia em análise e medir o comportamento subsequente do preço. A procura por correspondência de palavras é inadequada por duas razões simétricas: notícias com o mesmo significado podem não partilhar vocabulário, e notícias com vocabulário comum podem tratar de assuntos distintos.

A representação adotada é um modelo de embeddings de frase (Reimers e Gurevych 2019), que converte cada título num vetor de 384 dimensões cuja posição no espaço reflete o significado da frase. A contribuição relevante deste modelo não é a arquitetura, mas o objetivo de treino: os vetores são aprendidos de modo que a distância entre dois deles corresponda a semelhança de sentido. Um codificador da mesma família treinado para outra tarefa não herda esta propriedade, observação que o Capítulo 5 confirma experimentalmente.

A proximidade entre duas frases é medida pela semelhança do cosseno, ou seja pelo ângulo entre os vetores e não pela distância entre as suas extremidades, o que torna a medida independente do comprimento do texto. Os vetores são devolvidos com norma unitária, pelo que o cosseno se reduz ao produto interno, propriedade que permite percorrer a base de casos completa sem aproximação. Sobre dois pares reais da base de casos, dois títulos sobre a descida de empresas de tecnologia e semicondutores obtêm $\cos = +0,956$, e um título sobre a Peloton comparado com outro sobre o impacto da pandemia na indústria automóvel obtêm $\cos = -0,086$. O limiar de semelhança utilizado em produção é de 0,45.

A ordenação dos candidatos não é, contudo, o cosseno isolado. Casos próximos no tema mas distantes no tempo descrevem um regime de mercado que já não é o vigente, pelo que a ordenação aplica um decaimento exponencial sobre a idade do caso, na forma $\cos \times 2^{-\text{idade}/h}$, com meia-vida h de cento e vinte dias. Um caso com um ano entra assim com peso aproximado de 0,12 e prevalece apenas na ausência de material mais recente sobre o mesmo tema.

O decaimento ordena e não é apresentado: o valor exibido junto de cada precedente é sempre o cosseno, uma vez que apresentar uma pontuação composta sob o nome de semelhança produziria um número que o utilizador não pode verificar. As duas decisões compõem-se em série, pelo que o limiar de 0,45 incide sobre um conjunto já selecionado pela ordenação, e não sobre os vizinhos de maior cosseno. A Figura 3.4 representa a propriedade que esta medida explora: títulos com o mesmo significado ocupam posições próximas ainda que não partilhem vocabulário, ao passo que títulos que partilham vocabulário e tratam de assuntos distintos ficam afastados.




Figura 3.4: Cada frase corresponde a um ponto do espaço. Frases de significado próximo ocupam posições vizinhas ainda que não partilhem vocabulário, ao passo que frases com vocabulário comum (“record”) e assunto distinto ficam afastadas. A representação é bidimensional para permitir a leitura; o modelo utiliza 384 dimensões.

A medição do desfecho adapta o estudo de evento (Brown e Warner 1985): fixado o dia da notícia, mede-se a variação do preço a um, três e cinco dias. Duas decisões de detalhe condicionam o resultado. Notícias publicadas fora de dias de negociação são alinhadas com o primeiro dia de negociação seguinte. A medição inicia-se no fecho do dia da notícia, e não na abertura, opção conservadora que evita atribuir à notícia a parte do movimento anterior à sua publicação. A Figura 3.5 representa as duas decisões.

O valor apresentado ao utilizador é o retorno bruto e não o retorno anormal que a fonte normaliza. A opção é deliberada e tem um custo declarado. O retorno bruto é verificável




Figura 3.5: As duas decisões de detalhe que condicionam todos os desfechos medidos neste trabalho. Uma notícia publicada fora de um dia de negociação é alinhada com o primeiro dia seguinte em que o mercado abre, e a medição inicia-se no fecho desse dia, assinalado a cheio. A segunda decisão é conservadora por construção: começar na abertura atribuiria à notícia a parte do movimento que a antecedeu.

pelo utilizador na sua própria aplicação, mas incorpora o movimento do mercado no período. Em períodos de queda generalizada, os precedentes aparentam desfechos piores do que os atribuíveis à notícia. O desconto do mercado é aplicado onde é indispensável, na construção do rótulo descrito na secção seguinte.

3.5.1 Ajuste do codificador por materialidade comparável

A recuperação descrita acima organiza a base de casos por *tema*. Um precedente do mesmo tema pode, no entanto, ter-se movido por uma magnitude muito diferente daquela que está em causa, e o alerta apresenta-o ao lado dela como se fossem comparáveis. A quarta questão de investigação pergunta se o codificador pode ser ajustado de forma que a proximidade passe a refletir também materialidade comparável, e a Secção 1.3 justifica por que razão essa pergunta não contraria a restrição de não previsão.

Os pares de treino

O alvo de um par de títulos é $1 - |p(a) - p(b)|$, onde p é o percentil do movimento subsequente na distribuição dos movimentos do bloco de treino. Duas razões sustentam o percentil em vez da diferença bruta. A primeira é que os retornos têm cauda pesada: meio ponto percentual não significa o mesmo no centro da distribuição e na cauda, e um alvo construído sobre a diferença bruta gastaria quase todo o seu domínio a distinguir extremos entre si. O percentil é invariante a transformações monótonas e trata as duas regiões pelo mesmo padrão. A segunda é que o alvo fica em $[0, 1]$ por construção, que é o domínio esperado pelas funções de perda utilizadas, sem escala arbitrária a justificar.

O mapa de percentis é ajustado *apenas* sobre o bloco de treino e reutilizado nos restantes. Ajustá-lo sobre o conjunto completo constituiria fuga de informação, e uma fuga de um tipo que nenhuma verificação de fronteiras apanharia: a distribuição do bloco de teste entraria no treino sem que um único par cruzasse a fronteira. O bloco de embargo fica sempre de fora, uma vez que existe precisamente para separar treino de teste.

A amostragem, e a razão pela qual não pode ser ao acaso

A primeira construção sorteava dois índices ao acaso. A diferença de percentis entre dois pontos uniformes é *triangular*, com média $1/3$ e densidade quase nula nos extremos, pelo que o alvo fica concentrado em torno de um valor único: medido sobre os dados, média 0,665 e desvio 0,237. Com um alvo assim, o mínimo da perda obtém-se prevendo a média para todos os pares — e prever a média para tudo é, na prática, colapsar a representação. A Secção 5.4 reporta que foi exactamente isso que aconteceu.

A construção adoptada sorteia primeiro a distância desejada d e só depois o ponto de partida dentro da margem que d admite, $p_a \sim U(0, 1 - d)$, de modo que $|p(a) - p(b)| = d$ por construção. Sobre os dados reais o alvo passa a ter média 0,499 e desvio 0,289, ou seja a distribuição uniforme pretendida.

Os dois braços, e o que a comparação entre eles estabelece

O braço principal treina sobre a *magnitude* do movimento, tomada em valor absoluto. O braço de replicação treina sobre o retorno *com sinal*, reproduzindo neste mesmo arnês o objetivo de direção de Du et al. (2024). A comparação entre os dois é o que torna verificável a distinção entre magnitude e direção: se a direção fosse tão aprendível do texto como a magnitude, os dois braços seriam indistinguíveis.

A extensão face a esse trabalho está no que é ajustado. Du et al. (2024) treinam uma rede de tripletos sobre texto e séries de preço, tomando como positivo o par que partilha o rótulo de *direção*, e mantêm o codificador de frases *congelado*. Aqui o codificador é ajustado, e o objetivo do braço principal é a magnitude e não a direção.

Configuração e reprodutibilidade

Os dois braços partem do mesmo all-MiniLM-L6-v2 utilizado na Secção 3.5, para que a comparação com a recuperação sem ajuste seja de igual para igual. A perda é a *CoSENT*, que ordena pares por similaridade graduada sem impor uma escala à saída do cosseno. O treino corre sobre quarenta mil pares, uma época, lotes de trinta e dois exemplos e taxa de aprendizagem 5×10^{-6} , com semente fixada em quarenta e dois para o gerador do *random*, do *numpy* e do *torch*. A configuração completa é guardada ao lado dos pesos.

As duas medidas, e o diagnóstico que as precede

A medida do objetivo é a **comparabilidade de materialidade**: a diferença média absoluta, em pontos percentuais, entre a magnitude do movimento da consulta e a dos precedentes devolvidos. Valores menores são melhores. A segunda medida é a **precisão@5 por setor** da Secção 5.3, e está presente para mostrar o que o ajuste custa, ou não custa, em relevância temática. Medir apenas por setor seria avaliar o braço principal pela métrica do braço que ele não é.

Antes de qualquer das duas ser interpretada corre um diagnóstico de degeneração, que mede o cosseno médio entre títulos *diferentes*, a norma do vetor médio e o desvio por dimensão, e ainda quanto o espaço se deslocou face ao modelo de partida e se a geometria das semelhanças foi preservada. A razão é que um codificador colapsado produz uma tabela de métricas plausível e sem significado nenhum: todas as consultas devolvem os mesmos vizinhos, e nada na tabela o denuncia.

3.6 Triagem de notícias

A quarta decisão determina que notícias justificam a interrupção do utilizador. Ao contrário das anteriores, não dispõe de uma formulação analítica evidente, constituindo o ponto natural para aprendizagem a partir dos dados.

O rótulo formaliza a pergunta como a ocorrência de um movimento anormalmente grande após a notícia. Mede-se o retorno da ação nos três dias seguintes, subtrai-se o movimento do mercado no mesmo período e classifica-se o exemplo como positivo quando o valor absoluto do resíduo excede dois por cento. O uso do valor absoluto é deliberado: o modelo aprende sobre materialidade e nunca sobre direção, o que preserva a restrição fundadora do trabalho.

A subtração do movimento do mercado assume uma sensibilidade unitária, o que constitui uma incoerência com a técnica descrita na Secção 3.4, que recusa precisamente essa suposição. Numa ação de beta elevado, o resíduo retém parte do movimento do mercado, e o rótulo pode classificar como material um dia em que apenas o mercado se moveu. Todas as famílias de modelos avaliadas no Capítulo 5 são treinadas e avaliadas contra o mesmo rótulo, pelo que a comparação entre elas é internamente consistente sob esta definição de alvo. Tal não garante, porém, que a ordenação resista a uma definição alternativa, uma vez que o erro introduzido pode estar correlacionado com a empresa e com a volatilidade.

O modelo recebe nove entradas: a volatilidade dos vinte dias anteriores, o momento dos cinco dias anteriores, o retorno do próprio dia, o comprimento do título e cinco indicadores de setor. Uma variante adicional incorpora o vetor de 384 dimensões do título. A Figura 3.6 agrupa as entradas pelo nível de informação que cada uma descreve, distinção que o Capítulo 5 demonstra ser determinante.




Figura 3.6: As nove entradas do modelo implantado, agrupadas segundo o que cada uma permite distinguir. Sete caracterizam a **empresa** e variam lentamente ou permanecem constantes; uma caracteriza o **dia** e assume o mesmo valor para todas as notícias desse dia; **apenas uma** varia entre títulos consecutivos. A ablação da Secção 5.5.5 mede a dependência dominante da empresa; o rótulo partilhado não permite avaliar a distinção entre títulos do mesmo dia.

Sete entradas descrevem a empresa e variam lentamente ou são constantes; uma descreve o dia e é idêntica para todas as notícias desse dia; e apenas uma, o comprimento do título, distingue dois títulos da mesma empresa no mesmo dia.

A divisão dos dados é cronológica e não aleatória, como representado na Figura 3.7. Uma

divisão aleatória permitiria treinar sobre notícias posteriores às utilizadas na avaliação, invertendo a ordem temporal que o sistema enfrenta em funcionamento. Entre blocos consecutivos existe um embargo de cinco dias, necessário porque o rótulo de uma notícia depende dos três dias seguintes: sem o embargo, o rótulo das notícias no final de um bloco seria determinado por dias pertencentes ao bloco seguinte. O embargo descarta 820 das 79 753 linhas, ou seja 1,03%, ficando 28 574 exemplos para treino, 17 710 para validação e 32 649 para teste.




Figura 3.7: A divisão dos dados obedece à **ordem cronológica** e não a um sorteio. Entre blocos consecutivos intercala-se um *embargo* de cinco dias, uma vez que o rótulo de cada notícia depende dos três dias seguintes: sem ele, o final do bloco de treino seria determinado por dias pertencentes ao bloco seguinte.

A disciplina cronológica é uma afirmação sobre o que o conjunto de dados contém, e uma afirmação dessa natureza não se estabelece por declaração. É por isso imposta por um procedimento executável, reproduzido no Excerto 3.2, que constrói duas séries idênticas até ao dia da notícia e divergentes depois dele, e exige as duas propriedades que distinguem uma entrada legítima de uma fuga: as entradas do modelo têm de permanecer iguais, e o rótulo tem de mudar. Uma entrada que passasse a depender do futuro faria falhar a primeira propriedade; um rótulo que não dependesse dele faria falhar a segunda.

```

1 def test_anti_lookahead_mutar_o_futuro_muda_o_rotulo_mas_nao_as_features
2     ↪():
3         base = [100.0] * 25
4         sobe = _serie(base + [100, 110, 120, 130]) # movimento anormal
5         ↪enorme
6         plano = _serie(base + [100, 100, 100, 100]) # nada acontece
7         mercado = _serie([100.0] * 29)
8         d = 25
9         assert event_features(sobe, d) == event_features(plano, d)
10        ↪# features iguais
11        assert abnormal_label(sobe, mercado, d, 0.02, 3) == 1
12        ↪# rótulos diferentes
13        assert abnormal_label(plano, mercado, d, 0.02, 3) == 0

```

Excerto 3.2: O procedimento que impõe a separação temporal. As duas séries coincidem até ao dia do acontecimento e divergem a seguir. As entradas têm de sair idênticas, porque nenhuma delas pode observar as sessões seguintes; os rótulos têm de sair diferentes, porque é precisamente o futuro que eles medem. O teste corre a cada execução da verificação automática.

O bloco de teste contém mais exemplos do que o de treino. O corte é feito em dias de negociação, segundo a proporção de setenta, quinze e quinze por cento, e a assimetria resulta da densidade de notícias, que cresce acentuadamente ao longo do período coberto

pelo corpus. A divisão por dias, e não por número de exemplos, é necessária para que notícias do mesmo dia não sejam repartidas por blocos distintos.

A pontuação produzida pelo modelo não constitui, por si, uma probabilidade. Uma vez que o valor é apresentado ao utilizador, é convertido através de calibração *a posteriori*, ajustando uma sigmoide de dois parâmetros sobre o bloco de validação reservado (Niculescu-Mizil e Caruana 2005):

$$p_{\text{calibrada}} = \frac{1}{1 + e^{-(a p_{\text{bruta}} + b)}} \quad (3.4)$$

Os valores aprendidos são $a = 3,700$ e $b = -2,313$. O sinal negativo de b indica que o modelo, sem calibração, produz valores sistematicamente superiores à frequência observada. Parte deste comportamento decorre da reponderação das classes durante o treino, que desloca as pontuações para cima por construção.

A calibração é ajustada num bloco cuja prevalência de casos positivos difere da do bloco de teste, consequência da divisão cronológica. O efeito é mensurável e está reportado no Capítulo 5. A transformação é monótona e preserva a ordenação entre notícias, que é o que a política de decisão utiliza; o valor absoluto apresentado é o que fica afetado.

3.7 Ferramentas e infraestrutura

O sistema está escrito em Python 3.12. As dependências que produzem os resultados desta dissertação estão fixadas em versões exatas, e não em intervalos, de modo que o ambiente possa ser recriado noutra máquina: `numpy` 2.1.3, `pandas` 2.2.3, `scikit-learn` 1.9.0, `matplotlib` 3.11.0, `sentence-transformers` 5.6.0 e `torch` 2.12.1 na variante para CPU. Nenhum resultado exige unidade de processamento gráfico, consequência das opções descritas neste capítulo.

O treino da triagem, a calibração e a reamostragem por empresa e dia usam a semente 42. As cinco repetições da recuperação, incluindo a avaliação com anterioridade, usam as sementes 42 a 46. A linha de base aleatória da análise do orçamento usa 40 sementes, de 0 a 39. Estas escolhas fixam as operações aleatórias de cada protocolo; não tornam iguais conjuntos de dados recolhidos em momentos diferentes.

Todas as fontes de dados são gratuitas. Os preços provêm de uma cadeia de fornecedores alternativos consultados por ordem fixa, uma vez que nenhuma fonte gratuita apresenta fiabilidade suficiente isoladamente; o sistema regista sempre qual delas respondeu. As notícias provêm de três fornecedores complementares, cuja comparação é apresentada no Capítulo 4. A entrega utiliza a interface de robô do Telegram.

3.8 Desafios tecnológicos e sociais

Esta secção enuncia os riscos que um sistema com estas características levanta e as decisões de desenho que respondem a cada um.

3.8.1 Privacidade e proteção de dados

Uma carteira de investimentos revela rendimento, aversão ao risco e projetos de vida, informação que o Regulamento Geral sobre a Proteção de Dados trata como merecedora de proteção reforçada quando permite traçar o perfil de uma pessoa.

A decisão de desenho que responde a este risco é a minimização: o sistema não conhece as posições dos utilizadores e não as solicita. Não existe carteira, não existem posições nem montantes, e o canal público não identifica destinatários. Um alerta sobre uma empresa é idêntico para todos os leitores. O custo desta opção é a impossibilidade de personalização, uma vez que o sistema alerta sobre uma lista fixa de empresas e não sobre as posições de quem lê.

Existe uma exceção que importa nomear. Os utilizadores que optem por receber alertas personalizados através do robô do Telegram ficam associados a dois elementos: o identificador de conversa atribuído pela plataforma e a lista de empresas selecionadas. Não são armazenados nome, contacto nem montantes. O tratamento assenta no pedido expresso do próprio utilizador, que o inicia ao subscrever e o termina através de um comando que elimina o registo.

3.8.2 Segurança

Um sistema autónomo que consome serviços externos detém credenciais. As chaves residem em variáveis de ambiente e no cofre de segredos da plataforma, nunca no repositório, e o texto enviado para os registos passa por uma função que mascara parâmetros com nome de credencial. Esta segunda salvaguarda responde ao facto de as mensagens de erro de bibliotecas de comunicação reproduzirem o endereço do pedido, e de algumas interfaces transportarem a chave nesse endereço.

O codificador de frases é obtido sob pedido e confrontado com uma soma de controlo fixada no código. Na ausência dessa verificação, um ficheiro corrompido ou substituído modificaria sem aviso o critério de semelhança utilizado pelo sistema.

3.8.3 Questões éticas e sociais

A restrição fundadora do trabalho é também a sua principal salvaguarda ética. Um sistema que anunciasse o comportamento futuro do preço emitiria uma previsão não verificável no momento da leitura; um sistema que indicasse instrumentos a adquirir entraria numa atividade regulada. Esta fronteira é de desenho, traçada por prudência e não a partir de uma análise do direito aplicável: não houve parecer jurídico, e a operação do sistema como serviço exigiria obtê-lo previamente.

A garantia aplica-se ao que o sistema escreve e não ao que reproduz. Os títulos de terceiros são citados na íntegra, uma vez que constituem o facto que desencadeia o alerta e permitem a verificação na fonte, e alguns são eles próprios especulativos. Daqui decorre uma limitação sem solução no âmbito assumido: o filtro de relevância determina se um título é sobre a empresa, e não se é factual. A distinção entre notícia e opinião exigiria um classificador que o sistema não possui.

A interrupção repetida constitui o segundo risco. O efeito está documentado em sistemas de apoio à decisão clínica, onde Ancker et al. (2017) medem que a probabilidade de aceitação de um alerta decresce à medida que o volume de alertas recebidos aumenta, e que o efeito

se acentua com a repetição do mesmo alerta. O domínio é distinto e o que se transfere é o mecanismo: quem é interrompido com frequência deixa de distinguir as interrupções, momento a partir do qual um aviso correto e um aviso incorreto passam a ter o mesmo efeito. O sistema responde com um orçamento diário de alertas, um limiar crescente para alertas repetidos da mesma empresa e supressão de notícias que reproduzem uma história já comunicada.

O terceiro risco decorre da própria explicação. A confiança em sistemas automáticos falha nos dois sentidos, com o utilizador a ignorar um aviso correto ou a aceitar um aviso incorreto (J. D. Lee e See 2004), e a presença de uma explicação aumenta a aceitação de respostas erradas (Bansal et al. 2021). O sistema apresenta, por essa razão, os casos passados individualmente, com data e desfecho. A média que acompanha os casos no alerta é descritiva e não permite antecipar o desfecho da notícia atual. Que esta opção produza confiança apropriada constitui uma hipótese e não um resultado, uma vez que o estudo controlado necessário para a verificar não foi realizado.

3.8.4 Utilização de ferramentas de inteligência artificial

Esta subsecção declara, conforme a Declaração de Integridade remete, como foram utilizadas ferramentas de inteligência artificial generativa neste trabalho e com que finalidade.

A conceção é do autor: o problema, as questões de investigação, as restrições que definem o sistema (apenas fontes gratuitas, explicabilidade primeiro, e a recusa de prever preços), o desenho de cada experiência, o critério de sucesso fixado antes de a correr, e todas as decisões sobre o que construir, manter ou descartar. Nenhuma conclusão deste documento foi delegada.

A execução foi assistida, e em extensão substancial. Essas ferramentas escreveram e reestruturaram parte considerável do código do sistema e dos seus testes, implementaram os procedimentos de avaliação, redigiram e editaram prosa neste documento, e conduziram revisões que encontraram defeitos no software e no texto. Onde uma medição contrariou uma afirmação do autor, a afirmação foi retirada em vez de defendida, e o Apêndice A regista as que foram retiradas.

O conteúdo deste documento foi revisto pelo autor. Ele, os erros que nele restem, e a sua defesa são da sua responsabilidade.

Capítulo 4

Implementação: InvestiGator

Este capítulo descreve a realização do sistema: a sua arquitetura, a forma como cada método do Capítulo 3 é concretizado, a política que decide o que é comunicado ao utilizador, a construção da mensagem entregue, e o ciclo de vida do componente aprendido. Quem o leia fica a saber o percurso de uma notícia desde a recolha até à mensagem, e por que razão nove em cada dez candidatas não chegam a ser comunicadas.

O Capítulo 3 apresentou quatro métodos de forma isolada. A sua composição num sistema em funcionamento introduz problemas que nenhum deles apresenta isoladamente: a indisponibilidade das fontes, o volume de candidatos por ciclo, a coerência entre os valores calculados e o texto apresentado, e a degradação silenciosa dos componentes ao longo do tempo. A descrição que se segue organiza-se em torno desses problemas.

O sistema desenvolvido designa-se por InvestiGator e encontra-se em funcionamento contínuo, entregando alertas a um canal de mensagens e disponibilizando o registo das suas decisões numa aplicação web. Os valores apresentados neste capítulo foram lidos do registo do sistema em operação, e as datas em que cada medição foi efetuada são indicadas junto de cada uma.

4.1 Arquitetura do sistema

A arquitetura do InvestiGator foi definida de acordo com os seguintes requisitos, relativos a custo, modularidade, verificabilidade e resiliência:

- operar exclusivamente sobre fontes de dados gratuitas, sem subscrições nem custos por pedido;
- isolar cada método num componente com responsabilidade única, substituível sem alteração dos restantes;
- garantir que qualquer valor apresentado ao utilizador tem origem no componente que o calculou, e não numa segunda derivação independente;
- tolerar a indisponibilidade de qualquer fonte externa sem interrupção do serviço;
- registar cada decisão tomada, incluindo as decisões de não comunicar.

O sistema organiza-se em cinco componentes, representados na Figura 4.1: deteção, recuperação, triagem, explicação e entrega. A decomposição do movimento constitui um sexto componente, ativado apenas no percurso iniciado por movimento de preço, uma vez que a repartição incide sobre o retorno do dia e não existe objeto a repartir quando o acontecimento que desencadeia a avaliação é uma notícia.




Figura 4.1: Componentes do sistema e respectivas ligações. À esquerda, as fontes de dados; ao centro, os métodos do Capítulo 3 e o componente que compõe o texto; à direita, os dois canais de entrega. A decomposição encontra-se a tracejado por ser o único componente que não intervém em todas as avaliações.

Uma regra de construção atravessa a totalidade da implementação: o texto entregue ao utilizador é composto a partir dos objetos que os componentes produziram, e não redigido de forma independente. Quando o detetor calcula um valor de z igual a $+7,61$, é esse valor que a mensagem apresenta. A alternativa, que consistiria em manter um local onde o texto é escrito e outro onde a quantidade é calculada, admite divergência entre os dois sem que essa divergência seja observável. A restrição elimina essa possibilidade por construção.

4.1.1 Comunicação entre componentes

Os componentes comunicam por passagem direta de objetos dentro de um processo único, e não por protocolo de rede. A decisão decorre do perfil de utilização: o sistema serve uma lista reduzida de empresas, com um ciclo de avaliação de sessenta segundos, e o volume não justifica o custo de coordenação de uma arquitetura distribuída. A separação entre componentes é assegurada por interfaces explícitas, o que preserva a substituíbilidade sem introduzir latência de comunicação.

Duas exceções operam sobre fronteiras de processo. A entrega utiliza a interface de robô do canal de mensagens, por pedido HyperText Transfer Protocol (HTTP). A aplicação web que expõe o registo de decisões corre como processo separado e lê o mesmo armazenamento de dados, sem escrever nele. Esta segunda separação garante que a consulta do registo não interfere com o ciclo de avaliação.

4.2 Aquisição de dados

A restrição de custo nulo determina as decisões de aquisição. Um investidor particular que considere elevados os custos de corretagem não subscreve um terminal de informação

financeira, e a utilidade do sistema para o destinatário definido no Capítulo 1 depende de o sistema operar sem esse custo. As fontes gratuitas apresentam, contudo, três limitações sistemáticas: bloqueiam o acesso por excesso de pedidos, respondem com erro sem aviso, e publicam com atraso. As decisões descritas nesta seção respondem a essas limitações.

4.2.1 Cotações

Os preços são obtidos através de uma cadeia de cinco fontes, consultadas por ordem fixa, adotando-se a primeira que responde com dados válidos. O identificador da fonte que serviu cada valor é registado juntamente com o valor, uma vez que a proveniência de uma quantidade integra a sua explicação.

A ordem da cadeia não é arbitrária nem definitiva. Uma das fontes foi despromovida ao passar a responder com uma verificação anti-robô, que a torna inutilizável de forma fiável em operação automática; permanece na cadeia, em posição inferior, como tentativa oportunista. A decisão resultou da observação do que a fonte devolvia, e não de preferência declarada.

A redundância da cadeia tem uma consequência que ultrapassa a disponibilidade. Sem ela, um dia em que a fonte única bloqueia o acesso é indistinguível de um dia em que o mercado não abriu, e o sistema não dispõe de forma de separar as duas situações.

4.2.2 Notícias

As notícias são obtidas por empresa, a partir de três interfaces gratuitas. O material recebido inclui um volume elevado de conteúdo não aproveitável: listas automáticas de maiores variações do dia, textos que mencionam a empresa apenas de passagem, e comunicados de escritórios de advocacia. Um filtro de relevância, aplicado à entrada, exige que o título nomeie explicitamente a empresa e rejeita os padrões conhecidos de texto gerado automaticamente.

A utilização de três fontes em vez de uma foi avaliada por medição, sobre doze empresas e três dias. O critério adotado não é o número de títulos devolvidos por cada fonte, mas o número de títulos que sobrevive ao filtro de relevância, dado que o material rejeitado à entrada não chega a existir para o sistema. A Tabela 4.1 apresenta o resultado.

Tabela 4.1: Material entregue por cada fonte gratuita após aplicação do filtro de relevância. A coluna *exclusivos* indica os títulos que uma fonte traz e nenhuma das outras traz. Esse valor constitui um limite superior, uma vez que a comparação entre títulos é efetuada por correspondência textual após normalização, e duas fontes que descrevam o mesmo acontecimento por outras palavras produzem dois títulos contabilizados como distintos.

Fonte	Relevantes	Precisão	Frescura	Cobertura	Exclusivos
Finnhub	432	35%	15,8 h	12/12	401
Alpha Vantage	141	24%	9,3 h	12/12	119
Polygon	429	27%	52,6 h	8/12	418

As três fontes apresentam perfis complementares, e é essa complementaridade, e não o volume agregado, que justifica a sua utilização conjunta. O Finnhub apresenta a maior precisão de etiquetagem e cobre a totalidade das empresas. A Alpha Vantage apresenta a menor mediana de idade das notícias, com 9,3 horas contra 15,8, o que a torna a fonte

relevante para a redução do atraso dos alertas. O Polygon contribui com o maior número de títulos exclusivos, com uma mediana de idade de 52,6 horas, o que o torna adequado à alimentação da base de casos e inadequado ao alerta em tempo útil. É essa a utilização que lhe está atribuída.

O conjunto das três fontes produz 970 títulos relevantes distintos, contra os 432 obtidos apenas com o Finnhub. O ganho concentra-se nas empresas com menor cobertura individual, que correspondem precisamente aos casos em que o sistema anteriormente não dispunha de material para comentar.

A agregação não garante, contudo, redução da latência em geral. As três fontes publicam com atrasos próprios, e o ganho num caso concreto depende de qual delas observou o acontecimento em primeiro lugar. A mediana de frescura melhora, e essa melhoria encontra-se medida; a afirmação de que os alertas passam a chegar mais cedo exigiria nova medição da latência de extremo a extremo sobre um período alargado, que não foi realizada.

4.2.3 Base histórica e base implantada

A recuperação de precedentes requer um corpo de casos passados com desfecho conhecido. O sistema utiliza dois conjuntos distintos, com finalidades distintas, e a sua separação é relevante para a leitura dos resultados do Capítulo 5.

O primeiro é o FNSPID (Dong, Fan e Peng 2024), um conjunto público de notícias financeiras alinhado com os preços correspondentes. Do alinhamento descrito na Secção 3.2 resultam 79 753 exemplos entre 2018 e 2023, cada um com o movimento de preço subsequente. É sobre este conjunto que os métodos são avaliados.

O segundo é a base de casos que o sistema implantado consulta, e resulta da fusão de duas origens que importa não confundir. A primeira é uma reconstrução de um ano de história, obtida executando os componentes de recolha e de maturação sobre o passado, com 38 214 casos; a separação face ao registo do sistema em funcionamento é deliberada, uma vez que um caso reproduzido não é um caso observado. A segunda é a base viva, alimentada pela varredura, com 11 445 casos à data de 20 de agosto de 2026, e que cresce com a operação. A recuperação percorre as duas em conjunto. Os vetores são armazenados como matriz de precisão simples mapeada em disco. O formato não é indiferente: as mesmas representações em estruturas nativas da linguagem excediam a memória disponível no contentor de execução, e a alteração de formato foi a condição que tornou a sua utilização possível.

4.3 Percurso de um acontecimento

O sistema admite dois percursos distintos, consoante o acontecimento que desencadeia a avaliação seja uma notícia ou um movimento de preço. Os dois convergem no componente de explicação e utilizam a mesma política de decisão, descrita na Secção 4.4.

4.3.1 Percurso iniciado por notícia

O percurso iniciado por notícia compreende nove etapas, representadas na Figura 4.2. Cinco dessas etapas são pontos de decisão em que a candidata pode ser descartada, situação em que o sistema não comunica.




Figura 4.2: As nove etapas do percurso. As caixas a tracejado correspondem a pontos de decisão em que a candidata pode ser descartada. A Secção 4.4 quantifica a proporção de candidatas eliminada em cada um.

O funcionamento do percurso é ilustrado por um alerta entregue a 12 de julho de 2026, relativo à Meta, com o título *“Mark Zuckerberg Said Meta’s AI Bets ‘Haven’t Come to Fruition Yet’ as Shares Fell 5%”*. O título nomeia a empresa e não corresponde a nenhum dos padrões de texto automático. A data situa-se dentro do intervalo de dois dias exigido. Os três precedentes mais próximos são Microsoft de 2023-11-07, com semelhança 0,46, Nvidia de 2023-08-02, com 0,51, e Nvidia de 2023-09-21, com 0,46; a melhor delas fica acima do limiar de 0,45. O modelo de triagem atribui uma probabilidade de 54%. E o alerta é o primeiro relativo à empresa nesse dia. A mensagem é então composta e registada.

Os precedentes recuperados neste caso pertencem a empresas distintas daquela sobre a qual o alerta incide, e são apresentados na mesma. A opção é deliberada e decorre da formulação da segunda questão de investigação: a comparabilidade é estabelecida pelo tema da notícia e não pela identidade da empresa. Notícias relativas a investimento em inteligência artificial em empresas tecnológicas de grande dimensão constituem casos comparáveis entre si.

Os desfechos dos três precedentes são divergentes, com movimentos de +2,70%, −3,87% e +5,05%. O sistema apresenta os três individualmente, acompanhados da amplitude e da média. A média resume apenas os casos exibidos; isolada, ocultaria a inexistência de um desfecho comum a casos semelhantes e não sustentaria uma previsão para a notícia atual.

4.3.2 Percurso iniciado por movimento de preço

O segundo percurso é substancialmente mais curto. O z-score é calculado por dois caminhos. Após o fecho de cada sessão, o sistema avalia o retorno do dia fechado de cada empresa da lista vigiada contra a norma dos vinte dias anteriores, conforme descrito na Secção 3.3. Durante a sessão, avalia o retorno em curso, obtido da cotação corrente contra o fecho anterior, contra a mesma norma diária, formada nesse caso pelos vinte dias completos mais recentes, uma vez que o dia em curso ainda não pertence à série. O segundo caminho antecipa a deteção sem alterar a definição de normalidade, e é o que permite comunicar um movimento enquanto a sessão decorre; é também o que não depende da fonte de séries históricas, cuja barra do dia pode chegar com atraso. Em qualquer dos caminhos, a ultrapassagem do limiar constitui condição suficiente para avaliação.

É neste percurso, e apenas neste, que intervém a decomposição do movimento. Ao alerta é acrescentada uma linha com a repartição calculada segundo a Secção 3.4, com a forma “NFLX -2,11% hoje = -0,08% mercado · -0,32% setor · -1,71% da própria empresa”, seguida de uma frase que nomeia em linguagem corrente a parcela dominante. Quando a estimação da sensibilidade ao mercado não é possível, a linha é apresentada na mesma, declarando que foi assumida sensibilidade unitária e que a repartição tem carácter indicativo.

Duas capacidades foram acrescentadas ao percurso após a entrada do sistema em funcionamento, ambas por observação do comportamento em operação. A primeira consiste na atribuição de níveis de severidade: um valor de z de 1,6 e um valor de 3,2 passaram a ser descritos por termos distintos, em lugar de gerarem a mesma formulação. A segunda consiste na comparação com as restantes empresas do mesmo setor na mesma sessão, dado que um alerta que reporta uma descida sem indicar que o setor inteiro desceu transmite informação incompleta.

A segunda correção resultou da leitura dos trinta primeiros alertas entregues. Em nove deles o texto era internamente contraditório: uma linha indicava que o movimento parecia comum ao setor, e a repartição apresentada duas linhas abaixo atribuía a maior parcela à empresa. As duas linhas estavam corretas isoladamente, e a contradição resultava de a comparação com os pares considerar apenas a direção do movimento das empresas vizinhas, e não a sua magnitude. A comparação passou a considerar ambas.

4.4 Política de decisão

A comunicação de todas as candidatas avaliadas é equivalente à ausência de comunicação. Um canal que entregue quinze mensagens diárias deixa de ser lido, e o sistema perde a utilidade que justifica a sua existência. Os pontos de decisão da Figura 4.2 respondem a esta restrição.

4.4.1 Seletividade observada

O efeito conjunto dos pontos de decisão é considerável. Sobre as notícias datadas entre 1 e 3 de setembro de 2026, o sistema avaliou 743 títulos distintos de doze empresas e entregou 15 alertas, o que corresponde a uma razão aproximada de um para cinquenta. A janela é curta, e o registo de decisões que a sustenta conserva três dias, o que fixa o seu limite. A Figura 4.3 apresenta a distribuição por empresa.

O orçamento é, na configuração em operação, a restrição que efetivamente atua. Sobre o registo de decisões de produção, e em cada um dos seis dias medidos, entre 77,7% e 99,8% das avaliações terminam nele, contra um máximo de 4,6% no limiar de semelhança e de 14,0% na verificação de repetição no mesmo dia. A leitura não é a de que as restantes portas sejam inúteis: é a de que a redução de volume que importa já ocorreu antes delas, no filtro de relevância e na seleção de um título por empresa por ciclo, e que a partir daí a quantidade governada é o total diário. É também a consequência direta da alteração de política descrita na Secção 5.7: o modelo deixou de exercer veto e passou a ordenar dentro do orçamento, pelo que o orçamento ser a restrição ativa é a política a comportar-se como foi desenhada, e não um desvio dela.

Dois esclarecimentos condicionam a leitura destes números, e o segundo é o mais importante. O primeiro é o de que a unidade é o título distinto: o sistema reavalia os mesmos títulos a cada ciclo, pelo que o registo contém 1 321 linhas para os 743 títulos, e contar avaliações

inflacionaria o funil. O segundo é o de que o total de quinze alertas não mede a matéria-prima disponível, mas a política: o orçamento diário de cinco foi integralmente utilizado nos três dias, pelo que quinze é o teto que a política impõe e não uma quantidade observada. O que a repartição por empresa mede é a ordenação dentro desse teto, e essa não é imposta: nenhuma empresa dispõe de quota própria.





Figura 4.3: Títulos distintos avaliados e alertas efetivamente entregues, por empresa, entre 1 e 3 de setembro de 2026. O total é de 743 títulos e 15 alertas, e as duas quantidades são contadas sobre a mesma janela. O total de alertas é o teto que o orçamento diário impõe, e não uma medição; o que a figura mostra é a repartição desse teto, que a política não fixa. Oito das doze empresas recebem pelo menos um alerta, e a empresa com mais títulos avaliados não é a mais alertada. A Seção 5.7 examina o efeito desta política sobre uma janela muito maior.

O comportamento num único dia permite localizar a eliminação de candidatas. A Figura 4.4 distribui as 5 060 avaliações registradas a 15 de agosto de 2026 pelo ponto de decisão em que cada uma terminou. O registo lido corresponde a parte do dia e não ao dia completo, pelo que os valores devem ser lidos como proporções.

A leitura destes valores expõe um defeito de instrumentação. As 333 avaliações que atravessaram todos os pontos de decisão não correspondem a 333 candidatas distintas aprovadas para entrega. O sistema reavalia os mesmos títulos em cada ciclo de sessenta segundos, e um título já entregue nesse dia voltava a atravessar todos os pontos de decisão em cada ciclo. A entrega era impedida no final, por uma verificação de duplicação que, ao contrário de todas as restantes, não estava registada como etapa.

A consequência é relevante para a finalidade do registo. A vista construída para tornar as decisões do sistema inspecionáveis indicava 333 aprovações num dia em que foram entregues cinco mensagens. A verificação de duplicação passou a constituir uma etapa com identificação própria, como as restantes, e existe um teste automático que falha caso volte a ser omitida. Os valores da Figura 4.4 são anteriores a essa correção.



5 mensagens entregues $\neq$ 333 passagens pelas portas
 Uma avaliação não é um título distinto; os mesmos títulos foram reavaliados.

Figura 4.4: As 5060 avaliações registadas em parte de 15 de agosto de 2026. Cada banda representa o que resta depois da porta indicada, e o valor à direita o que essa porta eliminou; as eliminações somam 4727 e deixam 333 das 5060 avaliações. As cinco mensagens entregues são uma contagem separada, não uma categoria de avaliações. O orçamento diário foi integralmente utilizado. A data é também a do dia em que o piso de triagem deixou de exercer veto e passou a ordenar, pelo que a banda de 1194 avaliações eliminadas nesse ponto pertence à configuração anterior à descrita na Tabela 4.2; nos dias seguintes esse ponto deixa de eliminar candidatas. O mesmo se aplica à banda do piso escalonado, que a Figura 4.5 regista a zero nos seis dias posteriores.

4.4.2 Limiares e a sua proveniência

Cada ponto de decisão utiliza uma constante, e a origem dessas constantes é heterogênea. A Tabela 4.2 distingue os valores derivados de uma análise dos valores escolhidos, distinção que é pertinente porque os dois casos admitem defesas de natureza diferente.

O limiar de semelhança requer tratamento separado, por ser o menos fundamentado dos sete. Numa varredura medida em julho de 2026, quando a lista vigiada tinha dez empresas e o orçamento diário ainda não existia, sete candidatas foram eliminadas neste ponto, quatro delas por diferenças de 0,04 ou inferiores, e era então o ponto que mais eliminava. Deixou de o ser: sob a política em operação, a ordem de grandeza do que cada ponto elimina é a da Figura 4.5. Foi testada a hipótese de valores mais elevados de semelhança corresponderem a precedentes mais informativos, e a hipótese não se confirma: a concordância de direção entre o caso passado e o caso em avaliação situa-se ao nível do acaso em ambos os lados do limiar. O limiar controla o volume de alertas e assegura coerência temática, e não seleciona casos com maior valor preditivo.

4.5 Construção da explicação

A mensagem entregue não é uma frase única, mas uma estrutura com quatro partes, sempre presentes e sempre pela mesma ordem:

1. o facto observado, expresso em valores, com indicação da fonte;
2. os casos passados recuperados, apresentados individualmente, com data, semelhança e movimento subsequente;

Tabela 4.2: Constante associada a cada ponto de decisão e origem do respectivo valor. O ponto que verifica se o título nomeia a empresa não utiliza constante, por corresponder a uma regra de correspondência textual. O orçamento diário atua depois dos pontos de decisão representados na Figura 4.2 e constitui, na configuração em operação, o mecanismo que efetivamente limita o volume.

Ponto de decisão	Valor	Proveniência
Movimento invulgar	$ z \geq 1,5$	Escolhido, e distinto do valor de 3,0 sob o qual o detetor é avaliado no Capítulo 5. A avaliação fixa um valor exigente para caracterizar o método; a implantação adota um valor mais permissivo por decisão de produto, compensado pelos níveis de severidade que distinguem 1,5, 2,0 e 3,0 na formulação apresentada. Os dois valores respondem a perguntas diferentes.
Nomeia a empresa	—	Regra textual, definida após inspeção do material que atravessava o filtro inicial.
É recente	2 dias	Escolhido, por cobrir um fim de semana.
Evidência suficiente	0,45	Escolhido. Eliminava mais candidatas na configuração anterior; na atual predomina o orçamento diário.
Triagem acima do piso	50%	Derivado de uma análise de custos, que produz 0,49 na condição de custo simétrico entre movimento não comunicado e falso alarme; o valor implantado corresponde ao arredondamento desse resultado. Na configuração em operação não exerce veto: ordena as candidatas do mesmo ciclo.
Orçamento diário	5 por dia	Escolhido. Os cinco lugares são atribuídos por ordem de chegada e não às cinco candidatas com maior pontuação do dia, uma vez que a decisão é tomada ciclo a ciclo, sem conhecimento das candidatas posteriores. Acresce a um limite de duas mensagens por empresa por dia, que se mantém em vigor e é verificado depois deste. Os dois respondem a problemas distintos: o limite por empresa impede a saturação por um único nome, e o orçamento global impede que doze empresas a duas mensagens cada produzam vinte e quatro interrupções num dia.
Piso escalonado	segundo alerta: 0,64	A configuração conserva os valores derivados 0,49 e 0,64, e o primeiro é explicitamente ignorado quando o orçamento global está ativo: o primeiro alerta diário de cada empresa não tem piso de triagem. O mecanismo atua assim apenas como limitador de repetição dentro da mesma empresa.

PONTO DE DECISÃO	VALOR	ORIGEM	DO QUE ELIMINA
Nomeia a empresa	regra	☐ escolhido	antes do registo
Não havia notícia	--	☐ escolhido	0 a 3,9%
É recente	2 dias	☐ escolhido	0 a 3,5%
Evidência suficiente	0,45	☐ escolhido	0 a 4,6%
Triagem acima do piso	50%	☒ derivado	deixou de vetar
Mesma história	--	☐ escolhido	0 a 1,8%
Já enviada hoje	--	☐ escolhido	0 a 14,0%
Piso escalonado	0,64	☒ derivado	0% nos seis dias
Orçamento diário	5 por dia	☐ escolhido	77,7 a 99,8%

O ponto que elimina quase tudo é um dos escolhidos, e é-o em todos os dias medidos. Dos dois cujo valor foi derivado de uma análise de custos, o piso da triagem deixou de vetar em 15 de agosto de 2026 e o piso escalonado continua armado e nada eliminou em nenhum dos seis dias medidos, por o orçamento se esgotar antes de uma empresa alcançar um segundo alerta. O filtro de relevância atua antes de existir registo de etapa, pelo que a fração que elimina não é observável aqui.

Figura 4.5: Cada ponto de decisão, a origem do valor que utiliza e a fração das avaliações que nele termina, medida sobre o registo de decisões de produção em seis dias, entre 19 e 21 de agosto e entre 3 e 5 de setembro de 2026. A coluna apresenta a amplitude entre esses dias e não um valor único, uma vez que o registo conserva apenas três dias de cada vez e as frações variam com o dia. A unidade é a avaliação e não a notícia: o sistema repontua os mesmos títulos a cada ciclo de sessenta segundos, pelo que estes valores medem onde o tempo do sistema é gasto e não quantas histórias distintas cada ponto eliminou. A distinção entre valor derivado e valor escolhido é a mesma da Tabela 4.2. Os nove incluem os cinco representados na Figura 4.2 e mais quatro que atuam fora dela: a ausência de notícia, a supressão de histórias repetidas, o piso escalonado e o orçamento diário. A leitura que a figura permite, e que a tabela sozinha não dá, é a de que a redução de volume não é feita pelos pontos cujo valor foi derivado: é feita pelo orçamento, cujo valor foi escolhido, e assim é em cada um dos seis dias. Os valores provêm do registo de decisões publicado com o sistema.

3. a ressalva de que os casos apresentados constituem história observada e não previsão;
4. a estimativa de probabilidade de reação do mercado, sem indicação de direção.

A ordem responde a duas restrições. O facto precede a estatística porque um alerta iniciado por um valor de z perde o leitor na primeira linha, e o destinatário definido no Capítulo 1 não dispõe da formação que tornaria esse valor imediatamente interpretável. A estimativa ocupa a última posição por ser a única quantidade da mensagem que se refere ao futuro, o que assegura que a leitura interrompida antes do fim retém factos e histórico.

No percurso iniciado por movimento de preço, a primeira parte integra também a caracterização estatística em linguagem corrente, dado que nesse caso o facto observado é o próprio movimento. No percurso iniciado por notícia, essa posição é ocupada pelo título e pela ligação para o artigo.

O número de precedentes apresentados é igualmente uma decisão de desenho. O sistema exhibe três dos casos recuperados em vez da totalidade, e a razão não é de espaço disponível. A investigação sobre explicação estabelece que as pessoas procuram razões seletivas e contrastivas, e não enumerações exaustivas dos fatores que contribuíram para um resultado (Miller 2019). Uma lista de trinta casos seria mais completa e menos utilizável. O mesmo princípio determina que a mensagem exhiba as quantidades que sustentam a decisão e não o cálculo integral que as produziu.

A Figura 4.6 reproduz um alerta tal como foi entregue, copiado do registo do canal sem edição. A mensagem, tal como a interface, é redigida em inglês. A opção decorre do domínio: as empresas monitorizadas são norte-americanas e as notícias recolhidas das três fontes gratuitas são publicadas em inglês, pelo que traduzir o título citado quebraria a verificabilidade, que é a propriedade que o sistema existe para preservar. As figuras que reproduzem o sistema em funcionamento conservam por isso a língua original.

A probabilidade apresentada na última linha não corresponde à pontuação bruta do modelo. Resulta da sua conversão em probabilidade, por ajuste de uma sigmoide sobre um bloco de validação reservado (Niculescu-Mizil e Caruana 2005). A distinção é operacionalmente relevante: uma pontuação bruta ordena as candidatas sem admitir interpretação isolada, ao passo que uma probabilidade calibrada estabelece que, entre os títulos aos quais o sistema atribui 57%, aproximadamente essa fração apresenta efetivamente movimento invulgar. É a diferença entre uma quantidade utilizável apenas internamente e uma quantidade que pode ser apresentada.

A garantia tem limites declarados. A Secção 5.5 reporta o erro médio desta probabilidade e regista que a calibração é ajustada num bloco cuja prevalência não coincide com a do bloco a que é aplicada, o que desloca a escala em cerca de cinco pontos percentuais no sentido otimista. A ordenação entre candidatas não é afetada, uma vez que a transformação preserva a ordem; o valor absoluto anunciado é.

A última linha do alerta não se limita a apresentar a probabilidade: nomeia as entradas que a elevam e as que a reduzem. Essa enumeração não é redigida, é lida do próprio cálculo. O Excerto 4.1 mostra a operação que a produz. Numa regressão logística com normalização, o logit é a soma do termo constante com o produto de cada coeficiente pelo valor normalizado da respetiva entrada, pelo que cada parcela dessa soma é a contribuição exata de uma entrada, e não uma aproximação obtida sobre o modelo depois de treinado. As centenas de dimensões do vetor do título são somadas numa só parcela, para que a mensagem permaneça legível; as entradas de contexto aparecem uma a uma. É desta

```

[1] News alert for AMZN (Amazon) (2026-08-13)
    "Prediction: Amazon Will Join Apple in the $4 Trillion Club Before 2030"

[2] 3 similar past headlines. Their 5-day move ranged -2.73% to -2.73%
    (average -2.73%):
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "If You Invested $100 In Apple
      Stock 10 Years Ago, You Would Have This Much Today" (sim 0.56)
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "Apple's Selloff Is Overdone"
      (sim 0.51)
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "Apple's Buyback Is Retiring
      Less Stock Just As The Memory Bill Grows" (sim 0.47)

[3] 3 of 3 shown cases moved down - topic-similar past cases, not a
    prediction for this news (an observed pattern, not a forecast).
    Observed past outcomes after similar news, not a price prediction and
    not advice.

[4] Materiality estimate (learned triage): 57% chance of an unusually
    large move over the next few days, in EITHER direction - raised by
    recent volatility (20d) and sector; lowered by today's own move and
    recent momentum (5d). This estimates whether the market reacts, never
    which way: it is not a price forecast and not advice.

```

Figura 4.6: Alerta entregue a 13 de agosto de 2026, reproduzido do registo do canal, com a supressão dos marcadores tipográficos e a numeração das quatro partes acrescentada; nenhum número, palavra ou sinal de pontuação foi alterado. Os números entre parênteses retos identificam as quatro partes da estrutura. Todos os valores provêm dos componentes que os calcularam: a semelhança, do motor de recuperação; o movimento a cinco dias, da medição de impacto; e a probabilidade de 57%, do modelo calibrado. A parte [1] contém um título que é ele próprio uma previsão, com alvo e prazo; trata-se de conteúdo de terceiros reproduzido literalmente, e a Secção 3.8.3 discute o alcance da garantia de não previsão nesse contexto. A parte [2] exhibe a semelhança em valor bruto, fiel ao que o motor calculou e não interpretável por quem a lê.

ordenação que saem as palavras *“raised by recent volatility (20d) and sector; lowered by today's own move”* da Figura 4.6.

4.5.1 Discordância entre a afirmação e a evidência

O alerta da Figura 4.6 apresenta três precedentes com impacto idêntico, de $-2,73\%$, e data idêntica. A coincidência não é fortuita: o impacto é medido por par constituído por empresa e dia, pelo que três títulos da mesma empresa no mesmo dia partilham o mesmo valor por construção. A formulação *“3 of 3 shown cases moved down”* apresenta como concordância entre três casos aquilo que constitui um dia observado três vezes.

A extensão do problema foi medida sobre os 247 alertas de notícia com precedentes entregues entre 11 de julho e 13 de agosto de 2026. Em 36,8% deles os casos exibidos assentam num número de dias distintos inferior ao número de casos apresentados, e em 11,3% os três casos correspondem ao mesmo dia. Dos 120 alertas que afirmam unanimidade de direção, 23,3% apoiam-se num único dia.

O efeito é circunscrito. Nenhuma métrica reportada no Capítulo 5 é afetada, uma vez que a precisão em k contabiliza títulos e a concordância de direção é medida par a par sobre o corpus histórico. O que é afetado é a força que o alerta reivindica perante o utilizador, e o Capítulo 6 regista o facto como limitação.

```

1 scaler = pipeline.named_steps["scale"]
2 lr = pipeline.named_steps["lr"]
3 x_scaled = scaler.transform(np.asarray(x_row, dtype="float64").reshape
    ↪(1, -1))[0]
4 contribs = lr.coef_[0] * x_scaled
5
6 grouped: dict[str, float] = {}
7 for name, c in zip(feature_names, contribs, strict=True):
8     if name.startswith("emb_"):
9         key = "headline content"
10    elif name.startswith("sector_"):
11        key = "sector"
12    else:
13        key = _FRIENDLY.get(name, name)
14    grouped[key] = grouped.get(key, 0.0) + float(c)
15 return sorted(grouped.items(), key=lambda kv: -abs(kv[1]))

```

Excerto 4.1: A repartição que a última linha do alerta enuncia. O produto do vetor de coeficientes pelo vetor normalizado dá a contribuição de cada entrada para o logit; as parcelas são agrupadas e ordenadas por módulo decrescente. A explicação apresentada ao utilizador é esta soma, e não um segundo modelo ajustado sobre o primeiro. Omite-se a documentação interna da função.

4.5.2 Aplicação web

A mesma informação é disponibilizada numa aplicação web, que permite consultar o que foi entregue e, sobretudo, o que não foi. É nessa aplicação que reside o registo de decisões descrito na Secção 4.4. O desenho da interface não constitui contribuição desta dissertação, pelo que não é descrito; a sua apresentação justifica-se por ser o único local em que a ausência de comunicação por parte do sistema é observável. As Figuras 4.7, 4.8 e 4.9 apresentam, por essa ordem, o estado do dia, a evidência de uma empresa e o registo de uma decisão de não comunicar.

A empresa da Figura 4.8 constitui um caso ilustrativo da segunda pergunta do investidor, pela discordância entre a variação percentual e a repartição. A ação registava uma subida de 0,99%, e o mercado e o setor puxavam ambos em sentido contrário, com $-0,47\%$ e $-0,54\%$; a parcela específica da empresa era $+2,00\%$, ou seja mais do dobro do movimento observado. A subida é atribuída pelo modelo inteiramente à empresa, e não ao ambiente em que ela negocia. Esta repartição estatística não exclui a existência de causas externas não modeladas. O veredicto classifica o dia como comum: 141 dos últimos 250 dias de negociação registaram variação igual ou superior.

A contagem de raridade que o cartão apresenta corre sobre um ano de sessões, ao passo que a do alerta corre sobre os seis meses que o varrimento carrega no momento em que o compõe. O denominador difere por essa razão entre a Figura 1.1 e esta, para a mesma empresa no mesmo dia, e a fração que ambos exprimem é próxima.

A mesma figura mostra a ressalva que a acompanha. O coeficiente de determinação desta empresa é de 0,26, abaixo da mediana de 0,46 da lista vigiada, e a interface declara-o por baixo da repartição, com a instrução de a ler como indicativa. As duas afirmações convivem de propósito: a repartição é a melhor estimativa disponível e, nesta empresa, o mercado e o setor explicam apenas um quarto da variação diária. Omitir a segunda tornaria a primeira mais persuasiva do que o ajuste que a sustenta, que é o defeito que a Secção 6.4 nomeia.




Figura 4.7: Aplicação web a 2 de setembro de 2026, com a sessão norte-americana fechada. Os cinco indicadores repartem as doze empresas vigiadas em cinco alertas entregues e sete decisões de não comunicar; a contagem de movimentos fora do comum mede outra coisa, o preço, e por isso é apresentada como contagem separada. Cada empresa declara o seu estado à superfície, e toda a cor utilizada tem legenda, incluindo a da mascote, que acompanha a variação diária do índice de mercado utilizado na decomposição. As capturas são geradas a partir de um instantâneo da própria aplicação, e não recolhidas à mão, com a largura de captura fixada no gerador de cada uma, por ser dela que depende o texto da interface permanecer legível depois de reduzido à caixa de texto deste documento.

4.5. Construção da explicação




Figura 4.8: Vista de uma empresa: o veredicto em palavras antes de qualquer número, a repartição do movimento nas três parcelas, e a série de preço. As marcas separam as duas coisas que este trabalho distingue: o ponto assinala um dia em que um alerta foi entregue, e a seta um dia que o detetor assinalou e que nenhuma mensagem acompanhou. A faixa inferior mostra o valor de z desses dias contra o limiar de $\pm 1,5$, em eixo próprio por não partilhar unidade com o preço. A direção da seta é a do fecho e nada mais; a data e o valor de z de cada dia estão nas fichas por baixo, e não sobre a linha, para não se sobreporem. A interface abre no dia corrente; a figura mostra o intervalo de seis meses, por ser aquele em que a distinção entre assinalar e comunicar se torna observável. A linha em itálico por baixo da repartição declara a qualidade do ajuste que a produziu, comparada com a mediana da lista vigiada, e é o que permite ao leitor saber quando a repartição é de fiar.




Figura 4.9: As portas que uma empresa atravessou, pela ordem da política da Seção 4.4. As portas transpostas são enunciadas pelo que a empresa cumpriu; apenas aquela em que parou é enunciada pela rejeição, com o motivo concreto. O silêncio é aqui uma decisão registrada, e não ausência de informação.

A Figura 4.9 mostra a mesma exigência do lado do silêncio, no dia da Figura 4.7: as sete empresas que não geraram alerta pararam todas na mesma porta, a do orçamento diário de cinco alertas, esgotado às 14h02 UTC. A leitura importante não é o número, mas a forma: a empresa transpôs oito portas, cada uma enunciada pelo critério que cumpriu, e parou numa restrição de desenho declarada à partida. Nenhuma das portas transpostas é apresentada como falha, o que evita a leitura inversa que a versão anterior da interface permitia.

4.6 Implantação e operação

O sistema corre como processo permanente, com ciclo de varredura de sessenta segundos, sobre créditos de alojamento incluídos num plano académico. A primeira versão utilizava um agendador gratuito de melhor esforço, cuja periodicidade efetiva era de aproximadamente hora e meia. A alteração para processo permanente foi motivada pela redução do atraso dos alertas.

A latência foi medida sobre os 278 alertas de notícia entregues entre 29 de julho e 30 de agosto de 2026 que registam hora de publicação e hora de envio. A mediana do percurso completo é de 353 minutos, com percentil noventa de 964 minutos. A repartição localiza esse tempo sem ambiguidade: a mediana entre a publicação e a deteção é de 353 minutos, e a mediana entre a deteção e a chegada da mensagem é de 5 segundos, com percentil noventa de 16 segundos. O sistema entrega em segundos aquilo que a fonte lhe dá.

A separação por configuração não confirma a expectativa que motivou a alteração. Sobre os 28 alertas entregues pelo agendador a mediana é de 196 minutos; sobre os 250 entregues

pelo processo permanente é de 402 minutos. O ciclo mais curto não reduziu a latência observada. A comparação não é interpretável como efeito do ciclo, uma vez que as duas configurações não operaram em paralelo, entre elas alteraram-se as fontes de notícias e o período de calendário, e as amostras são de dimensão muito desigual. O que a medição estabelece é que encurtar o ciclo só compensaria se o tempo estivesse na cadência com que o sistema consulta a fonte, e não está.

Três causas concorrem para o atraso da descoberta, e este histórico não as separa. A primeira é a fonte listar a notícia horas depois da hora que ela própria declara. A segunda é a notícia mais recente do fluxo não ser a mais recente *relevante*: numa amostra recolhida a 7 de agosto de 2026, o fluxo de uma das empresas trazia 250 títulos com o mais recente publicado às 11:39, mas o mais recente entre os 30 relevantes era das 08:14. O alerta sai sobre o título correto, e é esse título que é antigo. A terceira é o orçamento diário já estar gasto, que não aparece nesta medição porque um alerta que não é entregue não regista hora de envio. Apenas a primeira seria atenuada por um serviço pago de notícias, e a sua contribuição não está medida.

Todos estes valores constituem um limite inferior da latência sentida pelo utilizador, uma vez que a hora de publicação é a declarada pela fonte e não o instante do acontecimento.

4.6.1 Crescimento da base de casos

Todo o título relevante observado pela varredura é conservado como candidato a precedente. Oito dias depois, quando o impacto no preço se torna observável, o candidato é medido pela mesma regra de alinhamento da Secção 3.5 e integra a base de casos. O intervalo de espera não constitui ineficiência: é a condição que impede um caso de conhecer o seu próprio desfecho. A Figura 4.10 representa o ciclo.




Figura 4.10: Percurso de um título entre a sua observação e a sua disponibilidade como precedente. O intervalo de oito dias decorre de o impacto de um caso só ser observável após o movimento do preço. O ciclo mantém atualizada a evidência apresentada pelo sistema, e não os parâmetros do modelo: nenhum componente é retreinado.

O mecanismo atualiza a evidência exibida, sem tocar nos parâmetros do modelo. Na taxonomia de deriva de conceito de Gama et al. (2014), o sistema dispõe da deteção da mudança e não da adaptação a ela.

Verificou-se, com o sistema já em funcionamento, que este ciclo estivera interrompido durante dezanove dias sem registo de qualquer erro. Os dois processos correm em máquinas separadas cujo sistema de ficheiros é reinicializado a cada arranque, e os ficheiros intermédios de maturação não estavam a ser publicados no armazenamento de dados partilhado. Corresponde à classe de custo que D. Sculley et al. (2015) designam por dependência de dados não declarada: cada componente cumpre o seu contrato, e a suposição que os liga não está expressa em parte alguma. O Capítulo 6 retoma o caso como limitação.

4.7 Ciclo de vida do componente aprendido

O sistema treina um único modelo, que é a regressão logística de nove entradas descrita na Secção 3.6. Medido contra uma linha de base de uma só variável, esse modelo apresenta desempenho inferior, resultado reportado na Secção 5.5.

A contribuição de engenharia não reside na dimensão do modelo, mas na infraestrutura que torna esse resultado, e a conclusão negativa que ele sustenta, defensáveis. Essa infraestrutura tem sete componentes, cada um dos quais existe porque a sua ausência produziria um resultado favorável e não verificável. A Figura 4.11 representa as duas metades do ciclo.




Figura 4.11: As duas metades do ciclo. Na metade superior, a construção: os dados são rotulados, a divisão é cronológica, a calibração é ajustada no bloco de validação e as comparações são realizadas no bloco de teste reservado. A reutilização desse bloco limita a independência das comparações, como discutido na Secção 5.5. Na metade inferior, a observação: o modelo em produção é o modelo avaliado, cada decisão é registrada, e dias mais tarde é confrontada com o movimento efetivamente observado. A ligação a tracejado fecharia o ciclo e não existe: a deriva é medida e não é corrigida.

Construção do conjunto de dados. O FNSPID fornece títulos datados, e os preços provêm de fonte distinta. O alinhamento das duas séries, a atribuição de uma notícia de sábado ao dia de negociação correspondente, e a derivação do rótulo a partir do movimento futuro constituem o trabalho que produz os 79 753 exemplos da Secção 3.2.

Declaração do rótulo como decisão. A existência de movimento anormal nos três dias seguintes não é um facto presente nos dados: é uma definição, com limiar e horizonte escolhidos. A Secção 5.5 mede nove definições alternativas em lugar de assumir a adotada.

Verificação da separação temporal. Aos blocos cronológicos e ao embargo junta-se um teste executável, reproduzido no Excerto 3.2: perturbado o futuro de um exemplo, as suas entradas têm de permanecer inalteradas e o seu rótulo tem de mudar. A ausência de fuga passa assim de afirmação a propriedade verificada a cada execução.

Calibração com enviesamento medido. A saída do classificador é um valor no intervalo unitário, que serve simultaneamente para ordenar candidatas e para as excluir. O ajuste de Platt corre sobre um bloco que nunca participou no treino, e a discrepância de prevalência entre esse bloco e o de teste é declarada no Capítulo 5 em vez de ficar implícita.

Versionamento dos artefactos. O modelo treinado, o calibrador e um descritor da execução, contendo dimensão de cada bloco, prevalência, semente e métricas, são conservados com a dissertação. Uma métrica desacompanhada do artefacto que a produziu não é reproduzível.

Identidade entre modelo avaliado e modelo implantado. O codificador de frases utilizado na avaliação depende de uma biblioteca cujo volume excede o contendor de produção. Em vez da substituição por outro modelo, que faria a dissertação descrever um sistema distinto do que se encontra em funcionamento, o mesmo modelo foi exportado para formato de execução leve e a fidelidade da conversão foi medida.

Observação do sistema implantado. Cada decisão de triagem é registada. Decorridos os dias necessários, um segundo procedimento rotula essas decisões pela mesma regra utilizada no treino e mede o contributo do modelo. Foi por esta via que se estabeleceu a ausência de contributo reportada na Secção 5.5. A deriva das entradas é medida pelo mesmo mecanismo.

4.7.1 Componentes desenvolvidos e componentes consumidos

O único modelo consumido do exterior é um codificador de frases pré-treinado, utilizado sem qualquer ajuste. O trabalho não reivindica contribuição sobre esse componente além da sua seleção por medição, efetuada contra quatro alternativas, entre as quais um modelo de maior dimensão, dois codificadores mais recentes e um modelo específico do domínio financeiro, que apresentou o pior desempenho do conjunto. A dependência é essencial, uma vez que não existe recuperação semântica sem representação de frases, e é simultaneamente substituível: a interface que o isola dispõe de uma implementação alternativa que degrada para sobreposição lexical quando o modelo não está disponível.

Foi desenvolvido no âmbito deste trabalho tudo o resto. O conjunto de dados rotulado e o procedimento de alinhamento que o protege de fuga temporal. O detetor, com a janela de estimação que exclui o dia explicado. A repartição do movimento com encolhimento dos coeficientes. A base de precedentes com impacto medido. O classificador de triagem e a sua calibração. A política de decisão e as constantes da Tabela 4.2. A camada que compõe o texto a partir dos objetos calculados. E o mecanismo que observa o sistema depois de implantado.

O sistema não integra um modelo de linguagem na produção do texto entregue ao utilizador. A ausência é deliberada e decorre do argumento desenvolvido na Secção 2.7: uma frase gerada constitui uma afirmação, ao passo que o sistema descrito entrega afirmações acompanhadas da evidência que as sustenta.

Uma camada de geração ancorada encontra-se, ainda assim, implementada e avaliada, e não é exposta ao utilizador. A Secção 4.8 descreve-a, com a garantia que oferece e a razão pela qual permanece fechada.

4.7.2 O elo em falta: arquitetura de retreino

O ciclo não inclui retreino. Os parâmetros correspondem ao período de 2018 a 2023 e não foram reajustados, apesar de a deriva se encontrar medida e de o índice de estabilidade populacional situar a entrada principal na banda de deslocamento significativo. A operação seria tecnicamente possível, dado que os rótulos novos derivam dos preços observados; o impedimento é que o retreino com o registo de produção alteraria os valores reportados

neste documento, e a avaliação dessa alteração exige tempo de observação que, à data em que este capítulo foi escrito, não existia.

A instrumentação que o tornaria possível foi construída e implantada em 4 de setembro de 2026, e o registo passou a guardar, por decisão, o valor de cada entrada, a data da última barra de preço utilizada e a identidade do modelo. Duas restrições limitam o que dela se poderá retirar, e ambas foram fixadas antes de existir qualquer candidato. A primeira é que apenas são utilizáveis as decisões cuja barra de preço seja anterior ou igual à data da notícia, uma vez que uma barra posterior descreveria um mercado que já observou o desfecho que o rótulo mede. A segunda é que a unidade de análise é o par constituído pela empresa e pelo dia, e não o título, o que reduz substancialmente o número de observações independentes disponíveis numa janela curta. Nada se afirma neste documento sobre o resultado dessa comparação.

A ausência de execução não dispensa, contudo, a definição da arquitetura. A Figura 4.12 apresenta o ciclo de treino contínuo desenhado para este sistema, com os mecanismos que o tornariam seguro. Três decisões o caracterizam.

A primeira é o **gatilho**, condicional e não temporal. O retreino desencadeia-se quando o Population Stability Index (PSI) de qualquer entrada ultrapassa 0,25, o limiar convencional de deslocamento significativo, ou ao fim de três meses sem revisão. A segunda é a **janela deslizante**: o treino cobre os vinte e quatro meses anteriores ao gatilho, e a validação e o teste os períodos seguintes, com o embargo de cinco dias da Secção 3.6. A divisão permanece cronológica, porque o problema não deixa de ser temporal por o modelo ser novo.

A terceira, e a que distingue um ciclo de treino contínuo de uma automatização perigosa, é a **porta de promoção**. Um modelo recém-treinado não substitui o modelo em vigor por ser mais recente: substitui-o apenas se o superar sobre o mesmo bloco de teste reservado, e se a sobreposição do intervalo de confiança da diferença excluir zero. Um modelo que não passe essa porta é registado e descartado, e o modelo em vigor permanece com a deriva declarada. É a diferença entre adaptar-se à mudança e perseguir ruído.




Figura 4.12: Ciclo de treino contínuo definido para este sistema e não executado no âmbito deste trabalho. O gatilho é condicional e não temporal; a janela é deslizante e a divisão permanece cronológica com embargo; e a porta de promoção impede que um modelo novo substitua o modelo em vigor sem o superar sobre um bloco reservado. A ligação a tracejado é o caminho de rejeição, e a sua existência é o que distingue o ciclo de uma automatização que persegue ruído.

O ciclo não inclui igualmente qualquer forma de verdade humana. Os três rótulos utilizados neste trabalho, correspondentes a movimento anormal, pertença ao mesmo setor e percentil de movimento, constituem aproximações verificáveis que nunca foram confrontadas com o julgamento de um avaliador humano. É a limitação de que as restantes mais dependem, e o Capítulo 6 retoma-a.

4.8 A camada de inteligência

As secções anteriores descreveram um sistema que compõe texto a partir de objetos calculados, com um vocabulário fechado. Esta secção descreve a camada que faz o mesmo com um modelo de linguagem, sob uma garantia diferente, e a razão pela qual não está exposta ao utilizador.

A arquitetura corrente para responder a uma pergunta sobre um corpo de documentos é a geração aumentada por recuperação (Lewis et al. 2020), discutida na Secção 2.4.1. O sistema em produção executa a primeira metade e detêm-se antes da segunda. A camada aqui descrita executa as duas, e existe para determinar o que custaria fazê-lo com a mesma disciplina de evidência.

4.8.1 O contrato: a linguagem não produz factos

O objeto que atravessa esta camada é um *pacote de evidência*. Cada facto que dele consta traz um identificador citável e a origem declarada, que é uma de três: medido a partir de preços, calculado por um dos motores do Capítulo 3, ou produzido pelo modelo de triagem. Nenhum facto tem origem *gerada*. A separação é a regra que estrutura a camada: o modelo de linguagem escreve a língua e nunca os números.

A Figura 4.13 representa a travessia. Duas chamadas ao modelo, e a divisão entre elas é deliberada. A primeira não escreve texto: traduz a pergunta num plano que o sistema sabe executar. A segunda não decide nada: redige sobre factos que já existem. Entre as duas, são os componentes descritos neste capítulo que produzem a evidência, e nenhuma das chamadas tem acesso ao mercado.

Um encaminhador determinístico cobre a primeira chamada quando não existe chave de interface disponível. Não é um recuo de conveniência: a restrição de utilizar apenas fontes gratuitas implica que a camada tem de continuar a responder quando o limite de utilização acabar, e uma interface conversacional que emudece nessa altura não serviria o público que o Capítulo 1 define.

4.8.2 Dois níveis de garantia, e o mais fraco é este

A verificação de ancoragem recusa a frase cujo número não pertença ao facto que ela cita. A formulação importa: a ligação é por frase e não pelo pacote inteiro, porque de outro modo qualquer número do pacote poderia ser colado a qualquer afirmação.

A garantia não é, contudo, da mesma natureza da que o alerta oferece, e a Tabela 4.3 separa as duas.

A assimetria justifica-se pelo risco e não pelo desempenho. O alerta interrompe o utilizador sem que ele o tenha pedido, e o texto desta camada é consultado por quem já está a olhar para a evidência que o acompanha.

Tabela 4.3: As duas formas de garantir que o texto não afirma mais do que os componentes calcularam. A diferença não é de eficácia medida, mas de natureza: uma enumeração do que é permitido é fechada, e uma enumeração do que é proibido é uma lista que pode não estar completa.

	Alerta entregue	Texto desta camada
Como chega ao leitor	empurrado, sem ser pedido	puxado, com a evidência ao lado
Como se compõe	vocabulário fechado	modelo de linguagem
O que a verificação enumera	o que é permitido	o que é proibido
Força da garantia	fechada por construção	limitada pela lista

4.8.3 O que foi medido, e o que não se afirma

A verificação foi confrontada com um conjunto de tentativas de a contornar. Sobre vinte e três ataques, todos foram recusados; sobre oito textos fiéis, nenhum o foi; e nas secções efetivamente compostas não se registou uma única violação entregue.

Estes números delimitam-se a si próprios. Os dois primeiros são determinísticos e reproduzem-se sobre o mesmo corpo de ataques; o terceiro é uma contagem sobre uma execução concreta. A força medida é um limite inferior, uma vez que o corpo de ataques foi construído pelo próprio autor e nada garante que esgote as formas de contornar a verificação.

A camada não está exposta, e a razão não é o desempenho da verificação. É a natureza da garantia que a Tabela 4.3 descreve: expor ao utilizador um texto sob a garantia mais fraca, quando o resto do sistema opera sob a mais forte, tornaria a promessa do produto desigual conforme o ecrã. Nenhuma comparação com uma arquitetura completa de geração aumentada por recuperação foi realizada, pelo que nada se afirma sobre o que ela acrescentaria.




Figura 4.13: As duas chamadas ao modelo de linguagem estão separadas de propósito. A primeira traduz uma frase humana num plano que o sistema sabe executar e não escreve texto. A segunda redige sobre factos que já existem e não decide nada. Entre as duas, os motores descritos neste capítulo produzem a evidência, e cada facto chega com a origem declarada. A verificação final recusa a frase cujo número não pertença ao facto que ela cita, e é o que permite ao leitor abrir a âncora e confrontar a afirmação com aquilo que a sustenta.

Capítulo 5


Casos de estudo

Os dois capítulos anteriores descreveram os métodos escolhidos e o sistema que os põe a funcionar. Este determina o que cada um deles vale. Descreve-se primeiro o desenho experimental e as métricas utilizadas. Seguem-se quatro casos de estudo: três correspondem às questões de investigação, e o quarto ao comportamento do sistema em operação, onde as escolhas dos capítulos anteriores encontram dados que não estavam disponíveis quando foram tomadas. Quem o leia fica a saber quanto vale cada técnica contra uma alternativa mais simples, e onde a medição não confirmou a escolha implantada.

5.1 Desenho experimental e métricas

Esta secção fixa a forma comum a todos os casos de estudo e define as medidas empregues, com especial atenção ao valor que cada uma assume na ausência de informação.

Cada caso de estudo segue quatro passos, representados na Figura 5.1: a pergunta, o procedimento de medição e a alternativa contra a qual a comparação é feita, o resultado obtido, e o que esse resultado não permite concluir. O quarto passo é o que distingue uma avaliação de uma demonstração. Os valores medidos sobre conjuntos históricos congelados são produzidos por procedimentos automáticos com semente fixa e reproduzem-se exatamente. Duas classes de valor não têm essa propriedade, e são identificadas onde aparecem. Os valores lidos do sistema em operação são instantâneos datados, que crescem com o canal. Os que dependem de cotações reajustadas pela fonte podem variar na terceira casa decimal.



os dois erros custam coisas diferentes, e nenhuma medida deste capítulo os trata por igual

Figura 5.1: A forma seguida por todos os casos de estudo. O quarto passo delimita o alcance de cada resultado. Em baixo, os dois tipos de erro que as medidas desta secção equilibram, e o custo distinto de cada um no domínio de aplicação.

Todas as medidas assentam nas quatro combinações entre o que o sistema afirma e o que se verifica. A precisão é a fração de acertos entre as ocasiões em que o sistema falou,

$VP/(VP + FP)$; a cobertura, também chamada *recall*, é a fração dos casos relevantes que foram assinalados, $VP/(VP + FN)$. As duas variam em sentidos opostos, e uma regra que assinale quase tudo atinge cobertura elevada com precisão baixa.

O F_1 é a média harmónica das duas, $2PC/(P + C)$, e aproxima-se do pior dos dois valores, o que impede que um extremo seja premiado. Para o z-score, com precisão 0,381 e cobertura 0,800, resulta 0,516; para a regra de limiar fixo, com precisão 0,122 e cobertura 0,992, resulta 0,218. As duas parcelas estão arredondadas à terceira casa, pelo que a conta refeita sobre os valores impressos pode diferir na última.

A precisão@ k aplica-se à recuperação, que devolve uma lista ordenada de que o utilizador lê apenas o início. Mede a fração dos k primeiros resultados que são relevantes (Manning, Raghavan e Schütze 2008), com $k = 5$, valor que corresponde ao que cabe num alerta.

A Precision-Recall Area Under the Curve (PR-AUC) aplica-se à triagem, que devolve uma probabilidade e não uma decisão. Cada limiar possível produz um par de precisão e cobertura, e o conjunto desses pares desenha a curva de precisão e cobertura; a área sob essa curva resume o modelo em todos os limiares simultaneamente, em vez de o julgar num limiar escolhido manualmente. É preferível à percentagem de acertos porque, com classes desequilibradas, responder invariavelmente que a notícia não é material acerta 62,2% das vezes sem qualquer aprendizagem.

O índice de Brier observa o valor da probabilidade e não a ordenação, sendo a média do quadrado do erro entre a probabilidade anunciada e o resultado observado, com valores menores a corresponder a melhor desempenho. O quadrado penaliza de forma mais do que proporcional os enganos confiantes, que é a propriedade adequada num sistema que exhibe percentagens a um destinatário sem meios para as questionar.

Uma medida lida sem o valor que lhe corresponde na ausência de informação conduz à conclusão errada, e este capítulo documenta três ocasiões em que isso sucedeu. A Tabela 5.1 fixa esse valor para cada medida.

Tabela 5.1: Cada medida, a pergunta a que responde, o valor que um método sem informação obtém, e o caso de estudo em que é utilizada. A coluna central é a que impede a leitura otimista de uma percentagem isolada.

Medida	Responde a	Valor sem informação	Utilizada em
Amplitude de disparo	O detetor comporta-se do mesmo modo em empresas distintas?	zero é o ótimo, e é atingível sem informação	Q 1
F_1	Acerta quando fala, e fala quando devia?	depende dos dados	Q 1
Precisão@5	Das cinco apresentadas, quantas são relevantes?	0,240, medido por escolha aleatória	Q 2
PR-AUC	Ordena bem, qualquer que seja o limiar?	0,378, a prevalência do bloco de teste	Q 3
Índice de Brier	A percentagem anunciada corresponde à frequência observada?	cerca de 0,235, anunciando a prevalência de treino	Q 3

A primeira linha da Tabela 5.1 é a única medida do capítulo que não utiliza rótulos. A amplitude de disparo é a diferença entre a taxa a que o detetor assinala na empresa em que mais fala e a taxa na empresa em que menos fala. Assenta num único princípio: um detetor universal deve comportar-se de forma semelhante em empresas distintas. A sua propriedade menos evidente, e que a Secção 5.2 desenvolve, é a de que o ótimo é atingível sem qualquer informação.

5.2 Deteção consistente entre empresas

O primeiro caso de estudo responde à Q11: um z-score deslizante deteta movimentos invulgares de forma mais consistente entre empresas do que uma regra de limiar fixo. A resposta é afirmativa, com uma margem de mais de vinte vezes na medida principal.

5.2.1 Procedimento

A avaliação utiliza três anos de cotações diárias de quinze empresas de grande capitalização, entre junho de 2023 e junho de 2026, o que corresponde a aproximadamente setecentos e cinquenta dias por empresa. O conjunto é distinto da lista de doze empresas monitorizadas em produção, pela razão enunciada na Secção 3.2: a avaliação exige variedade de volatilidade, e a lista implantada é uma decisão de produto.

O argumento principal não recorre a rótulos. Um detetor destinado a assinalar dias raros deve disparar a uma taxa semelhante em empresas distintas; se dispara com frequência elevada numa e raramente noutra, o que está a medir é a volatilidade da empresa e não a raridade do dia. Como argumento de apoio utiliza-se um rótulo aproximado, que classifica como extremo um dia situado no percentil noventa e nove dos retornos da própria empresa. O rótulo é imperfeito, por ser ele próprio relativo à volatilidade, e ocupa por isso a posição secundária.

5.2.2 Resultado

A Figura 5.2 resume as duas medidas. É a primeira que sustenta a conclusão: o que distingue os métodos não é o nível a que disparam, mas o facto de o limiar fixo acompanhar a volatilidade de cada ação enquanto o z-score se mantém quase constante entre elas.

A amplitude da taxa de disparo é de 0,015 para o z-score e de 0,344 para o limiar fixo, uma diferença superior a vinte vezes. Contra o rótulo aproximado, o z-score obtém $F_1 = 0,516$ e o limiar fixo 0,218.

A comparação envolve uma assimetria de tratamento. A janela do z-score é variada mais adiante nesta secção, ao passo que o limiar de três por cento da regra fixa é o valor convencional e não foi otimizado. O que a comparação estabelece com segurança não é que nenhum limiar fixo obteria melhor resultado, mas que um limiar fixo mede uma quantidade diferente da pretendida, porque a mesma percentagem corresponde a raridades distintas em empresas distintas. Este argumento não depende do valor escolhido.

5.2.3 O que a medida principal não exclui

A amplitude da taxa de disparo tem o zero como ótimo, e esse ótimo é atingível por um método sem qualquer informação. Um detetor que assinalasse em cada empresa uma fração




Figura 5.2: As duas medidas, lado a lado. Em A, a diferença entre a taxa máxima e a taxa mínima entre as quinze empresas; o limiar fixo assinala 0,9% dos dias na empresa mais calma e 35,3% na mais volátil, enquanto o z-score se mantém entre 1,6% e 3,1% em todas. Em B, o desempenho contra o rótulo aproximado.

fixa de dias escolhidos ao acaso apresentaria amplitude praticamente nula, superando o z-score precisamente na medida que esta secção elege como principal. A afirmação decorre da construção do método e não exige execução.

A medida não fica invalidada; o que daí resulta é a obrigação de a ler em conjunto com a segunda, e é essa a razão de existirem duas. A amplitude exclui o limiar fixo, que dispara em função da volatilidade da empresa e não da raridade do dia. O F_1 exclui o disparo aleatório, que se situa ao nível do acaso contra qualquer rótulo. Nenhuma das duas medidas é suficiente isoladamente, e apenas a regra deslizante satisfaz ambas.

Regista-se ainda uma assimetria no padrão de evidência aplicado ao longo do capítulo. Os valores desta secção e da seguinte são pontos, sem intervalo de confiança, ao passo que os da Secção 5.5, onde reside o resultado que contraria a hipótese inicial, são acompanhados de reamostragem por grupos. A justificação parcial reside na ordem de grandeza das diferenças aqui observadas, que nenhuma reamostragem plausível inverteria. A justificação não é completa, uma vez que dias da mesma empresa também não constituem observações independentes neste caso, pela mesma razão de agrupamento de volatilidade invocada mais adiante.

5.2.4 Comparação com detetores aprendidos

A comparação mais exigente confronta a regra estatística com métodos de aprendizagem automática concebidos para detetar anomalias. Foram avaliados dois, sobre a mesma informação e sob a mesma disciplina de não utilizar informação posterior ao dia avaliado: o *Isolation Forest* (F. T. Liu, Ting e Zhou 2008) e o *Local Outlier Factor* (Breunig et al. 2000). Ambos correram numa única configuração, sem procura de hiperparâmetros, o que limita o alcance da sua derrota pela mesma razão invocada adiante para o modelo de árvores. Fica estabelecido que estes detetores, assim parametrizados e sobre estas entradas, não superam a regra; não que nenhuma parametrização o faria. A Figura 5.3 apresenta o resultado.

A regra transparente supera os dois métodos, com quase o dobro do F_1 e com consistência entre empresas substancialmente melhor. Este é o primeiro de três casos, ao longo do capítulo, em que uma técnica mais sofisticada é comparada em condições equivalentes com




Figura 5.3: Os três detetores sobre os mesmos dados e sob o mesmo protocolo, restrito à região que os três conseguem pontuar. Os dois métodos aprendidos ocupam a região de cobertura quase total e precisão baixa; a regra troca alguma cobertura por precisão. O F_1 junto de cada ponto resume esse compromisso. A amplitude da taxa de disparo acompanha o mesmo padrão, com 0,017 para a regra contra 0,140 e 0,183 para os detetores aprendidos.

uma técnica mais simples e não obtém melhor resultado. A escolha do método simples passa assim a estar justificada por medição e não por preferência.

A explicação não reside na qualidade dos métodos. Ambos determinam o que é invulgar a partir da geometria dos dados, por vias opostas. O *Isolation Forest* identifica o ponto raro pela facilidade com que sucessivos cortes aleatórios o separam dos restantes (F. T. Liu, Ting e Zhou 2008). O *Local Outlier Factor* confronta a densidade na vizinhança de cada ponto com a dos pontos que o rodeiam (Breunig et al. 2000).

Trata-se de métodos não paramétricos, exteriores à família estatística que Chandola, Banerjee e Kumar (2009) caracteriza pela modelação da distribuição dos dados normais, e foram concebidos para conjuntos com muitas variáveis em interação. O problema aqui tratado apresenta outra forma: uma série de retornos por empresa, cuja estrutura pertinente é temporal. O agrupamento da volatilidade, formalizado pelos modelos Autoregressive Conditional Heteroscedasticity (ARCH) e Generalized Autoregressive Conditional Heteroscedasticity (GARCH) (Bollerslev 1986; Engle 1982), desloca ao longo do tempo o limiar do que constitui um dia invulgar; uma janela deslizante acompanha essa deslocação por construção, enquanto um detetor ajustado ao conjunto completo tem de a inferir.

Uma nota sobre a compatibilidade entre os valores: o z-score aparece com $F_1 = 0,530$ nesta comparação e com 0,516 na anterior. Os dois valores medem o mesmo detetor sob protocolos distintos. O segundo abrange todos os dias avaliados, enquanto o primeiro se restringe à região que os três detetores conseguem pontuar, única em que a comparação entre eles é equitativa. A amplitude segue a mesma regra, sendo 0,017 neste protocolo e 0,015 no anterior.

5.2.5 Duas comparações que não confirmam as escolhas implantadas

Duas experiências adicionais foram concebidas para justificar opções tomadas, e nenhuma delas as confirmou. Ambas ficam reportadas tal como resultaram.

A primeira incide sobre o estimador de volatilidade. A alternativa a atribuir o mesmo peso aos vinte dias da janela consiste em atribuir maior peso aos dias recentes, através de uma média com decaimento exponencial. A Figura 5.4 apresenta o resultado.




Figura 5.4: Os dois estimadores, com a mesma cobertura; cada segmento liga o resultado implantado à alternativa na mesma medida. A alternativa com decaimento exponencial elimina quase metade dos falsos alarmes, elevando a precisão de 0,381 para 0,568, e é ainda mais consistente entre empresas, com amplitude de 0,012 contra 0,015. O sistema mantém o estimador que obteve o resultado inferior, pela razão exposta no texto.

Com cobertura idêntica, a alternativa obtém $F_1 = 0,664$ contra 0,516 do estimador implantado. O mecanismo é compreensível. Movimentos grandes ocorrem em grupo. Uma média de vinte dias com pesos iguais dilui um choque por vinte observações e continua a assinalar os dias seguintes durante semanas; uma média que privilegia o passado recente absorve-o de imediato.

O sistema mantém o estimador que obteve o resultado inferior. A razão é a que atravessa o trabalho: a média e o desvio-padrão dos últimos vinte dias são explicáveis em duas frases a qualquer leitor, e pesos com decaimento exponencial não o são. Numa ferramenta cujo argumento central é a explicabilidade, um ganho de precisão obtido à custa da explicação não constitui inequivocamente um ganho. Fica, porém, registado como escolha e não como resultado: a alternativa está medida, o ganho está quantificado, e a sua adoção constitui uma alteração de pequena dimensão caso a explicabilidade deixe de ser a restrição dominante.

A segunda experiência incide sobre a dimensão da janela, e a Figura 5.5 apresenta-a.

Uma janela de sessenta dias obtém $F_1 = 0,678$ contra os 0,516 da janela de vinte. Duas razões justificam a manutenção da janela mais curta. A primeira é de responsividade: uma janela de sessenta dias demora três meses a reagir a uma mudança de regime, e uma empresa que transite de calma a volátil continuaria a ser julgada pela norma anterior.

A segunda respeita à validade desta medição concreta. O rótulo é construído a partir do percentil de movimento da própria empresa, sendo por isso relativo à volatilidade; uma janela mais longa produz uma norma menos adaptativa, que assinala com maior frequência a cauda extrema, que é precisamente o que este rótulo premeia. Existe circularidade, e ela favorece a janela longa por construção. Esta é a razão pela qual o argumento principal desta secção é a consistência da taxa de disparo, que não recorre a rótulos. A formulação que subsiste é que a janela de vinte dias foi escolhida por responsividade, e que a única medição existente sobre este ponto não a sustenta.




Figura 5.5: Desempenho contra o rótulo aproximado para três dimensões da janela. O valor cresce de forma monótona com a dimensão da janela, e a janela implantada não é a que obtém o melhor resultado. O texto expõe as duas razões pelas quais a janela mais longa não foi adotada, sendo a segunda uma reserva sobre a validade desta própria medição.

5.2.6 Limites da conclusão

O rótulo é aproximado e relativo à volatilidade, razão pela qual o argumento de peso é o da consistência, que dele não depende. As quinze empresas são todas de grande capitalização e foram selecionadas em 2026, com a avaliação a percorrer o passado: sobreviveram por construção, e nenhuma delas saiu de bolsa, foi absorvida ou desapareceu da lista. O que se mede é o comportamento do método em empresas que subsistiram, e não na população de que foram extraídas. A comparação incide ainda sobre este conjunto e este período, e nada nela permite antecipar o resultado noutro mercado ou noutra década.

5.3 Recuperação de precedentes

O segundo caso de estudo responde à Q12: a recuperação por significado encontra notícias de outra empresa do mesmo setor melhor do que as alternativas textuais e de ordenação avaliadas. A resposta é afirmativa perante esses comparadores; a vantagem sobre o acaso verifica-se nos cinco setores. A anterioridade é avaliada em separado, em agregado sobre o corpus histórico.

5.3.1 Procedimento

A avaliação de sistemas de recuperação enfrenta a ausência de uma lista de respostas corretas, dado que nenhum conjunto de pares de notícias se encontra anotado como relacionado. Utiliza-se por isso uma aproximação verificável: considera-se relevante a notícia recuperada que pertença ao mesmo setor da notícia de consulta. A aproximação é imperfeita, porque duas notícias do mesmo setor podem tratar de assuntos distintos, mas é objetiva e foi fixada antes de os resultados serem observados.

Impõe-se ainda uma restrição que torna a tarefa mais difícil: a notícia recuperada tem de pertencer a uma empresa diferente. Sem ela, o sistema obteria bom desempenho devolvendo notícias da própria empresa, que pertencem quase sempre ao mesmo setor por construção. O corpus contém 3714 notícias distribuídas por cinco setores, recolhidas ao longo de vinte e sete dias, e a medição utiliza quinhentas consultas por repetição em cinco repetições com

sementes distintas. A amplitude do corpus delimita o que a medição estabelece: vinte e sete dias não sustentam afirmações sobre generalização temporal. O protocolo não exige que o candidato seja anterior à consulta, e apenas 31,1% dos vizinhos o são. A verificação sob restrição de anterioridade foi feita em agregado sobre o corpus histórico, onde a margem sobre o acaso se conserva, e não por setor.

5.3.2 Resultado

A Figura 5.6 apresenta o método utilizado, uma variante de maior dimensão e as alternativas triviais.




Figura 5.6: Precisão@5 do MiniLM implantado, em verde cheio, contra sete alternativas. O contorno verde identifica a variante MPNet de maior dimensão; as barras cinzentas reúnem duas linhas de base, uma linha lexical e um codificador específico do domínio financeiro. As duas barras tracejadas dispensam qualquer modelo: devolver sempre notícias do setor maior obtém 0,467, valor discutido no texto e que obriga a ler o agregado com reserva, e filtrar os candidatos pelo setor conhecido da consulta satisfaz o rótulo em todos os lugares da lista sempre que existam cinco candidatos elegíveis. O 1,000 não é uma medição: é uma consequência aritmética da definição de relevância, e consta aqui por ser o valor de referência mais alto que esta tarefa admite. Não constitui alternativa de produto, uma vez que devolveria casos do mesmo setor sem observar o tema da notícia.

A escolha aleatória acerta em 24,0% dos casos, e é esse o valor de referência, e não zero, uma vez que os setores existem em número finito e têm dimensões distintas. A procura por palavras em comum eleva o resultado para 34,6%, e a comparação de significado para 51,4%.

A linha lexical corresponde à forma mais simples dessa família: contagem de palavras projetada por dispersão e comparada pelo cosseno, sem ponderação pela raridade dos termos, sem saturação da frequência e sem normalização pelo comprimento do texto. Pertence à tradição que vai do modelo de espaço vetorial (Salton, Wong e C. S. Yang 1975) às funções de ordenação probabilísticas como o BM25 (Robertson e Zaragoza 2009), situando-se no degrau inicial dessa família. Os dezassete pontos percentuais que a representação de frases (Reimers e Gurevych 2019) acrescenta medem, por conseguinte, a distância a um ponto de

partida elementar e não a distância a um sistema lexical afinado. A comparação com uma função de ordenação bem parametrizada constitui trabalho por realizar, e é a que tornaria esta conclusão mais forte.

O codificador específico do domínio financeiro obtém 0,420, o valor mais baixo de todos os modelos avaliados. O modelo avaliado é o ponto de controlo público *ProsusAI/finbert*, identificado desta forma por ser o artefacto exato sobre o qual a medição incide; pertence à família de codificadores financeiros de que Zhuang Liu et al. (2020) e A. H. Huang, Wang e Y. Yang (2023) são as versões documentadas em publicações revistas por pares. Foi utilizado com a média dos seus vetores como representação da frase, que é a forma de o aplicar sem novo treino. Trata-se de um codificador ajustado para classificação de sentimento e não para posicionar frases num espaço onde a distância signifique semelhança, e é precisamente esse objetivo de treino que o Sentence-BERT acrescenta (Reimers e Gurevych 2019). A medição estabelece que este modelo de domínio, utilizado desta forma, obtém resultado inferior a um modelo genérico treinado para semelhança; não estabelece que conhecimento de domínio seja irrelevante para a tarefa.

5.3.3 A alternativa trivial que o valor agregado esconde

O corpus não está equilibrado: 1736 das 3714 notícias, quase metade, pertencem ao setor da tecnologia. Existe por isso uma estratégia que dispensa qualquer modelo e não observa sequer a consulta, consistindo em devolver invariavelmente cinco notícias de tecnologia. Acerta em todas as consultas de tecnologia e em nenhuma das restantes, pelo que a sua precisão iguala exatamente a fração de consultas que são de tecnologia, 0,467. Medida contra esta alternativa, e não contra o acaso uniforme, a margem do método reduz-se de +0,274 para +0,047, e a linha lexical de 0,346 passa a situar-se abaixo do valor de referência.

O elemento enganador é, contudo, o valor agregado. A estratégia trivial obtém 1,000 nas consultas de tecnologia e 0,000 em todas as outras, devolvendo notícias de semicondutores a quem consulta sobre uma petrolífera. O que ela explora não é uma propriedade do problema, mas a composição deste corpus.

A comparação dentro de cada setor verifica se a vantagem sobre o acaso também existe fora da tecnologia. O painel A da Figura 5.7 apresenta-a.

O valor de acaso é de 0,429 na tecnologia e situa-se em torno de 0,072 em cada um dos quatro setores restantes. O método obtém 0,712 na tecnologia, 0,448 na energia, 0,419 na saúde, 0,272 na banca e 0,171 no consumo. Onde o valor agregado é dominado, o método acrescenta 0,283; onde o corpus é escasso, obtém várias vezes o valor de referência. O agregado subestima o método e sobrestima a alternativa trivial pela mesma razão, que é a de quase metade das consultas provir do único setor onde o valor de referência já era elevado. A afirmação que o trabalho sustenta é por isso a mais estreita: a recuperação semântica supera a taxa-base dentro de cada um dos cinco setores, perante os comparadores avaliados.

Esta comparação não mede a vantagem sobre uma regra que conheça o setor da consulta. Esse setor está disponível no mapa de empresas: filtrar candidatos de outra empresa pelo mesmo setor acertaria em todos os lugares da lista, desde que existissem cinco candidatos elegíveis. É uma consequência do rótulo, não uma experiência adicional. A avaliação mede a recuperação dessa aproximação a partir do texto; não demonstra superioridade sobre o filtro por setor nem mede a relevância semântica adicional que o produto pretende oferecer.




Figura 5.7: Em A, a precisão@5 e o valor de acaso correspondente dentro de cada setor: o método situa-se acima do respetivo valor de referência nos cinco. Em B, o protocolo simétrico do teste de escala e o protocolo que exige anterioridade, sem reproduzir a maturação de oito dias da produção, cada um ao lado do seu valor de referência. A precisão desce de 0,595 para 0,513 e o valor de acaso de 0,333 para 0,259, pelo que a margem varia apenas de +0,262 para +0,254.

A variante de maior dimensão obtém $0,538 \pm 0,011$ contra $0,514 \pm 0,015$ da utilizada, sobre cinco sementes; a diferença é pequena face à dispersão e nenhum teste de significância foi realizado. Dois codificadores mais recentes obtém 0,504 e 0,513, indistinguíveis do implantado. A adoção do modelo mais pequeno em produção decorreu do custo computacional e não de uma vantagem de qualidade, constituindo uma troca explícita cujo preço em precisão está quantificado. A alternativa aparentemente mais razoável, que consiste em apresentar as notícias mais recentes, obtém 0,126, o valor mais baixo de todos, o que é coerente com a ausência de qualquer razão para a notícia mais recente sobre outra empresa estar relacionada com a notícia em análise.

5.3.4 Comportamento à escala e sob restrição de anterioridade

A avaliação anterior incide sobre um corpus recente e de dimensão limitada. Para verificar que o resultado não depende desse corpus, a mesma medição foi repetida sobre o conjunto histórico completo, com aproximadamente oitenta mil notícias de seis anos. Neste protocolo simétrico, que ainda admite candidatos posteriores à consulta, a precisão@5 sobe para 0,595. A subida não deve, porém, ser lida na íntegra como ganho: o valor de acaso sobe igualmente, de 0,240 para 0,333, porque a composição por setores é distinta. Medida contra o valor de referência respetivo, a margem é de +0,274 no primeiro caso e de +0,262 no segundo. O resultado estabelece que o método não se degrada quando o corpus passa de recente e curto para seis anos, e não que melhore com mais dados.

A escala permite ainda a comparação que o corpus preliminar não sustentava, e que é a primeira que um resultado de recuperação convida a fazer. A linha lexical da Figura 5.6 é a sobreposição de palavras, que não pondera termos raros nem corrige o comprimento do título. Sobre o conjunto histórico, e no mesmo protocolo emparelhado, mediu-se em seu lugar o BM25 (Robertson e Zaragoza 2009), que é o método de referência da recuperação lexical: obtém 0,521, contra 0,595 do modelo semântico, com o acaso em 0,333. A diferença

emparelhada é de +0,073, positiva nas cinco repetições, e nenhuma consulta ficou com candidatos de pontuação nula.

O número obriga a moderar a leitura. Medidas contra o acaso, a margem do BM25 é de +0,188 e a do modelo semântico de +0,261: a correspondência lexical, quando bem feita, capta cerca de três quartos da distância que separa o método do acaso. O ganho da representação semântica é real, consistente e mensurável, mas é o menor dos dois efeitos. Este resultado não estava na avaliação preliminar porque o comparador lexical aí usado é mais fraco, e a sua ausência deixava a vantagem semântica parecer maior do que é.

O protocolo anterior concede uma liberdade que o sistema em produção não possui. A única restrição imposta é a de o candidato pertencer a outra empresa, o que permite que seja posterior à consulta, e esse caso é comum: no corpus recente, 38,7% dos vizinhos devolvidos têm data posterior à da consulta e outros 30,2% são do mesmo dia. O sistema implantado não dispõe dessa liberdade, uma vez que a base de precedentes só recebe um caso oito dias após a sua observação, conforme a Secção 4.6.1 descreve.

O critério de acerto é a pertença ao mesmo setor, que não utiliza o desfecho futuro do preço. Ainda assim, permitir candidatos posteriores altera a tarefa de recuperação. Está em causa a correspondência entre o valor reportado e a tarefa que a questão de investigação descreve, que fala em notícias passadas. A medição repete o protocolo acrescentando à máscara a condição de o candidato ser estritamente anterior à consulta, e reproduz o valor simétrico na mesma execução para que a comparação seja emparelhada. Nenhuma das 2 500 consultas ficou sem passado suficiente. O resultado consta do painel B da Figura 5.7: a precisão desce 0,082, o valor de referência desce quase outro tanto, e a margem varia 0,008. O método conserva praticamente toda a vantagem quando se exige anterioridade. A máscara não impõe os oito dias de maturação nem verifica a disponibilidade dos desfechos a três e cinco sessões. O resultado não equivale, por isso, a uma avaliação da base efetivamente disponível no instante da decisão em produção.

Esta é a terceira ocasião no capítulo em que a leitura de uma precisão sem o valor de referência correspondente conduziria à conclusão errada. Sucedeu na passagem do corpus recente para o completo, sucede na precisão dentro do orçamento tratada na Secção 5.5, e sucede aqui. A precisão é uma quantidade sem significado próprio, que apenas o adquire ao lado da alternativa sem informação.

5.3.5 Limites da conclusão

A pertença ao mesmo setor não equivale a relação entre notícias, sendo uma aproximação construída por ser verificável e não por corresponder exatamente à propriedade pretendida.

A segunda observação tem consequências para o produto: a recuperação capta tema e não direção. Duas notícias podem tratar do mesmo assunto e o preço evoluir em sentidos opostos, que foi o que sucedeu no exemplo apresentado no Capítulo 4. A Figura 5.8 quantifica-o.

A concordância de direção entre a notícia de consulta e os casos recuperados situa-se em 0,708 contra um valor de acaso de 0,688. É por esta razão que o sistema apresenta os casos um a um e acompanha a amplitude e a média com esses casos individuais. A média descreve os casos recuperados, não antecipa o próximo retorno; o texto do alerta declara tratar-se de semelhança de tema.




Figura 5.8: Fração de casos recuperados cujo preço evoluiu no mesmo sentido que o da notícia de consulta, contra o valor obtido por emparelhamento aleatório sob as mesmas restrições, numa escala completa entre zero e um. A diferença é de 0,020. O sistema apresenta por isso os casos individualmente, e o texto do alerta declara que a semelhança é de tema.

5.4 Ajuste do codificador por materialidade comparável

5.4.1 A medição que motiva a pergunta

A recuperação avaliada na secção anterior é medida por pertença ao setor, e nada nessa métrica diz respeito à magnitude do movimento. A primeira medição desta secção é, por isso, a que justifica fazer a pergunta: sobre o bloco de teste, o codificador sem ajuste obtém uma comparabilidade de materialidade de 2,173 pontos percentuais, contra 2,259 de um emparelhamento ao acaso sob as mesmas restrições. Os desvios entre repetições são 0,062 e 0,107, pelo que os dois valores não se distinguem. **Na quantidade que a Secção 3.5.1 se propõe melhorar, a representação utilizada pelo sistema é indistinguível do acaso.** Há, portanto, espaço para melhorar, e é esse espaço que a experiência tenta ocupar.

5.4.2 A primeira tentativa colapsou o codificador

A primeira execução usou pares sorteados ao acaso, e o resultado foi o que a Secção 3.5.1 antecipa como consequência do alvo concentrado: o codificador deixou de distinguir títulos. A Tabela 5.2 reúne o diagnóstico.

Tabela 5.2: Diagnóstico de degeneração, corrido antes de qualquer métrica de recuperação ser interpretada. A primeira coluna é o modelo de partida; a segunda é a primeira tentativa, com pares ao acaso; as duas últimas são os dois braços com amostragem estratificada. Um cosseno próximo da unidade entre títulos *diferentes* significa que todas as consultas devolvem os mesmos vizinhos, e nenhuma tabela de precisão o denunciaria.

	sem ajuste	ao acaso	magnitude	direção
Cosseno entre títulos diferentes	0,205	0,994	0,271	0,277
Norma do vetor médio	0,454	0,997	0,521	0,527
Desvio por dimensão	0,045	0,004	0,043	0,043
Deslocamento face ao inicial	—	0,269	0,782	0,775
Correlação das semelhanças	—	0,234	0,607	0,630

O cosseno médio entre títulos diferentes subiu de 0,205 para 0,994 e o desvio por dimensão caiu de 0,045 para 0,004: o modelo passou a mapear todos os títulos praticamente para o mesmo vetor. **As métricas de recuperação dessa execução foram descartadas sem serem**

lidas, porque uma representação colapsada produz uma tabela plausível cujo significado é nulo.

Com a amostragem estratificada os dois braços passam o diagnóstico, e passam-no de forma semelhante entre si. As duas últimas linhas da tabela são as que distinguem *não ter degenerado* de *ter aprendido*: os dois braços deslocaram substancialmente o espaço face ao modelo de partida — cosseno médio de 0,782 e 0,775 entre a representação inicial e a ajustada — e preservaram a geometria das semelhanças, com correlação de 0,607 e 0,630. O treino, portanto, funcionou.

5.4.3 Resultado

A medição corre sobre as 32 649 manchetes do bloco de teste, com quinhentas consultas por repetição em cinco repetições, cinco vizinhos por consulta e horizonte de três dias. As consultas são sorteadas antes de qualquer modelo ser aplicado, pelo que são idênticas nos três braços e as comparações são emparelhadas. A Tabela 5.3 apresenta os resultados.

Tabela 5.3: Comparabilidade de materialidade e precisão@5 por setor, sobre o bloco de teste. A comparabilidade é a diferença média absoluta, em pontos percentuais, entre a magnitude do movimento da consulta e a dos precedentes devolvidos, e *valores menores são melhores*. A precisão@5 é a métrica da secção anterior e está aqui para mostrar o que o ajuste custa em relevância temática.

Braço	Comparabilidade (pp) ↓	Precisão@5 ↑
Sem ajuste	2,173 ± 0,062	0,771 ± 0,011
Ajustado pela magnitude	2,185 ± 0,065	0,746 ± 0,009
Ajustado pela direção	2,157 ± 0,071	0,744 ± 0,006
Emparelhamento ao acaso	2,259 ± 0,107	0,629 ± 0,007

Na quantidade que o ajuste existe para melhorar, nada acontece. O braço da magnitude fica 0,012 pontos *acima* do modelo sem ajuste, isto é pior, e o da direção fica 0,016 abaixo. As duas diferenças são cerca de um quinto do desvio entre repetições do próprio braço, pelo que não são efeitos.

E o ajuste tem um custo que se mede. A precisão@5 por setor desce de 0,771 para 0,746 e 0,744, uma perda de cerca de 0,026 com o mesmo sinal nos dois braços e maior do que a dispersão entre repetições. O que o ajuste alterou na representação foi suficiente para degradar a relevância temática e insuficiente para melhorar a comparabilidade de materialidade.

Uma vez que o diagnóstico da subsecção anterior estabelece que os dois braços treinaram e moveram o espaço, **a leitura é que a hipótese não se confirma, e não que a montagem falhou**. A comparação entre os dois braços acrescenta a segunda parte: sendo praticamente indistinguíveis entre si, a experiência não encontra a assimetria entre magnitude e direção que motivou a pergunta.

5.4.4 Sob restrição de anterioridade

O protocolo anterior não exige que o precedente seja anterior à consulta. Repetida a medição com essa exigência, que é a que a produção cumpre, as conclusões mantêm-se: a

comparabilidade passa a 2,287 sem ajuste, 2,309 com o braço da magnitude e 2,289 com o da direção, contra 2,336 do acaso, e a precisão@5 desce de 0,747 para 0,722 e 0,720.

Há neste protocolo uma observação que o anterior não permite. A margem do modelo sem ajuste sobre o acaso *encolhe* de 0,086 para 0,049 pontos percentuais quando se exige anterioridade. **No protocolo que a produção realmente cumpre, a representação está ainda mais próxima do acaso nesta quantidade do que a primeira medição desta secção indicava**, o que reforça a motivação da pergunta ao mesmo tempo que torna a resposta negativa mais nítida: o espaço para melhorar era maior do que se supunha, e o ajuste não o ocupou.

Duas das duas mil e quinhentas consultas foram excluídas, por não existir um único candidato anterior a elas dentro do bloco. A exclusão é declarada aqui e no relatório gerado, e o filtro é aplicado antes de qualquer modelo ser aplicado, pelo que é idêntico nos três braços.

5.4.5 Limites da conclusão

O resultado é negativo sobre um objetivo de treino, um alvo e uma configuração, e não sobre a ideia de ajustar codificadores. Três limites delimitam-no. O primeiro é o alvo: a magnitude entra como percentil do movimento subsequente, e um alvo construído de outra forma poderia comportar-se de outro modo. O segundo é a configuração: correu uma época sobre quarenta mil pares com uma taxa de aprendizagem baixa, escolhida por ser a que evita o colapso, e não se procuraram hiperparâmetros. O terceiro é a função de perda: a alternativa clássica, que minimiza o erro quadrático entre o cosseno e o alvo, ficou declarada na Secção 3.5.1 e não foi corrida.

O que o resultado estabelece, e que não depende desses limites, é o valor da porta: uma representação colapsada produz métricas de aparência normal, e sem o diagnóstico da Tabela 5.2 a primeira execução teria produzido uma tabela completa e sem significado.

5.5 Triagem de notícias

O terceiro caso de estudo responde à Q13: um modelo treinado prioriza notícias melhor do que uma linha de base baseada apenas em volatilidade. A resposta é negativa, e é o resultado com maior valor informativo do trabalho.

5.5.1 Procedimento

O conjunto de dados contém 79 753 exemplos entre 2018 e 2023, cada um correspondente a uma notícia com o contexto de mercado do dia e o rótulo definido na Secção 3.6. A divisão é cronológica com embargo, e a prevalência de casos positivos no bloco de teste é de 0,378. A métrica principal é a PR-AUC, adequada quando as duas classes estão desequilibradas.

Para efeitos práticos, uma diferença de PR-AUC inferior a 0,02 é tratada como indistinguível, mesmo quando o intervalo emparelhado exclui zero. O limite é uma escolha do autor, declarada antes dos resultados, o que obriga à sua aplicação nos dois sentidos.

Dois cuidados de montagem asseguram que a comparação não favorece a conclusão obtida. O primeiro é a inclusão de um conjunto de árvores treinado por reforço do gradiente (Friedman 2001), o mais expressivo dos modelos comparados, por captar interações e efeitos não lineares que a regressão logística não capta por construção. Este modelo foi executado

com os parâmetros por defeito da biblioteca, sem procura de hiperparâmetros, o que limita o alcance da sua derrota: estabelece que o texto não produz vantagem nesta montagem, e não que a não produziria num modelo não linear afinado. O segundo cuidado é a conversão de todas as pontuações em probabilidades por calibração *a posteriori* sobre um bloco de validação reservado (Niculescu-Mizil e Caruana 2005), sem a qual a comparação pelo índice de Brier não seria válida entre modelos.

Uma entrada não está disponível no mesmo referencial em produção. O retorno do próprio dia corresponde, no conjunto histórico, ao movimento completo do dia da notícia, ao passo que em produção a notícia é pontuada antes de esse dia encerrar. O resultado apresentado avalia por isso o modelo com a variável diária completa e não demonstra paridade com a pontuação intradiária. A entrada em causa pertence ao bloco de contexto; a linha de base vencedora usa apenas a volatilidade dos vinte dias anteriores, fechada na véspera. Corrigir o referencial pode alterar o ajuste e a ordenação dos modelos de contexto em qualquer sentido. O efeito permanece por medir mediante novo treino e avaliação; o resultado negativo vale para o protocolo aqui executado.

5.5.2 Resultado

A Figura 5.9 apresenta os cinco modelos e a referência sem informação comparados. As curvas completas, de que estes valores são a área, constam dos artefactos identificados no Apêndice A. Nelas a curva da volatilidade situa-se acima das restantes em quase toda a extensão do eixo, o que estabelece que a diferença não é artefacto do valor agregado.




Figura 5.9: Área sob a curva de precisão e cobertura de cinco modelos, com intervalos marginais a noventa e cinco por cento obtidos por reamostragem dos 1951 grupos. A linha tracejada assinala a prevalência do bloco de teste, que é o valor obtido por um modelo que atribua a mesma probabilidade a todos os exemplos. Os valores são pontos, e os intervalos são amplos e sobrepõem-se: [0,492; 0,597] para a volatilidade, [0,487; 0,592] para o contexto e [0,453; 0,540] para o contexto com texto. A comparação que a subsecção seguinte sustenta é a diferença emparelhada entre modelos sobre as mesmas reamostragens, e não a distância entre dois pontos.

O valor mais elevado pertence ao modelo mais simples de todos, o que utiliza apenas a volatilidade recente. Acrescentar-lhe o restante contexto não altera o resultado de forma distinguível, com 0,538 contra 0,542; acrescentar o texto do título deteriora-o de forma distinguível, com 0,496. O índice de Brier acompanha a mesma ordenação, com 0,218

para o modelo de volatilidade contra 0,229 para o modelo com texto. Anunciar sempre a unidade produz 0,622, mas é uma referência fraca. A constante igual à prevalência de treino, $q = 0,3854$, produz cerca de 0,235 no teste: $\pi(1-q)^2 + (1-\pi)q^2$, com $\pi = 0,3781$. Este é um cálculo descritivo com as prevalências arredondadas da Figura 5.17, na página 88, e não uma nova execução. A hipótese inicial, segundo a qual o texto da notícia traria informação ausente dos preços, não é confirmada sobre este corpus.

5.5.3 Três verificações à montagem experimental

O resultado negativo foi submetido a três verificações destinadas a determinar se decorre da montagem experimental.

A primeira respeita ao ajuste do modelo de texto. A comparação foi repetida concedendo ao texto as melhores condições disponíveis, com regularização afinada, redução do bloco de texto a trinta e duas dimensões e um modelo de linguagem especializado em finanças. O melhor resultado do texto sobe para 0,533 e permanece abaixo dos 0,542 da volatilidade.

A segunda respeita ao ruído de amostragem. O bloco de teste foi reamostrado mil vezes por grupos constituídos pela empresa e pelo dia, uma vez que notícias do mesmo dia sobre a mesma empresa partilham o rótulo e não constituem observações independentes. A diferença entre a volatilidade e a variante com texto é de +0,048, com intervalo entre +0,032 e +0,066, que exclui zero e supera o limite prático de 0,02. O valor é a média sobre as reamostragens e não coincide exatamente com a diferença entre os dois pontos, de +0,046. Das comparações desta secção com a linha de base de volatilidade, é a única que o supera.

O alcance deste intervalo é, contudo, limitado: a reamostragem realiza-se dentro de um único bloco de teste, com duzentos e vinte e um dias de negociação, pelo que mede o ruído de amostragem nesse período e nada estabelece sobre a estabilidade entre períodos. A distinção não é teórica neste trabalho, dado que a Secção 5.7 reporta um deslocamento significativo na distribuição da entrada principal. Uma origem rolante com três ou quatro cortes sucessivos responderia à pergunta mais larga, e não foi realizada.

A terceira respeita à definição do rótulo, que utiliza um limiar de dois por cento e um horizonte de três dias, ambos escolhidos pelo autor. A comparação foi repetida para nove combinações de limiar e horizonte, e a Figura 5.10 apresenta o resultado.

O resultado negativo resiste às três verificações. A volatilidade iguala ou supera o modelo com texto nas nove definições de rótulo, com prevalências entre 0,082 e 0,597, o que retira à escolha concreta de limiar e horizonte o estatuto de ponto de ataque.

Uma quarta verificação incide sobre a composição dos blocos e conduz a uma conclusão que atua nos dois sentidos. A composição por empresa muda entre os blocos, com sobreposição substancial. O bloco de treino decorre entre 2 de janeiro de 2018 e 3 de março de 2022 e contém treze empresas; o bloco de teste decorre entre 2 de fevereiro e 18 de dezembro de 2023 e contém nove. Cinco empresas do treino não figuram uma única vez no teste, e uma empresa do teste, responsável por 17,1% das suas linhas, nunca figura no treino. Assim, oito das nove empresas de teste já aparecem no treino e representam 82,9% das linhas de teste. Para as empresas presentes em ambos os lados, a taxa de positivos desloca-se de forma acentuada, e a Apple passa de 0,448 no treino para 0,183 no teste. Estes valores leem-se diretamente das colunas de identificação e de bloco do conjunto congelado e não exigem qualquer execução adicional.




Figura 5.10: Desempenho das duas famílias sob os três horizontes, em três painéis correspondentes aos limiares, com a prevalência de cada célula como referência. A faixa verde identifica a definição utilizada no restante capítulo. A volatilidade iguala ou supera o modelo com texto nas nove combinações, com prevalências entre 0,082 e 0,597.

Não se trata de utilização de informação futura nem de erro de divisão: o corte é realizado por dia, e a proporção respeita a definida na Secção 3.6. É a composição do corpus que varia com o tempo, pela mesma razão que torna o bloco de teste maior do que o de treino, uma vez que as empresas e o peso de cada uma no corpus variam entre 2018 e 2023.

O sinal do modelo é essencialmente a identidade da empresa, conforme a Secção 5.5.5 estabelece. A sobreposição permite avaliá-lo em empresas conhecidas, mas as suas taxas de positivos mudam entre períodos. A comparação não separa a qualidade do modelo da transferência dessas taxas e da mudança de composição; exigiria uma análise de composição constante. A diferença entre 47,0% de positivos na validação e 37,8% no teste pode combinar esses dois efeitos, cuja contribuição individual não foi medida.

5.5.4 Utilidade sob a restrição de orçamento

O produto apresenta no máximo cinco alertas por dia, pelo que a pergunta com significado operacional é a de qual a fração de acertos entre as cinco notícias escolhidas em cada dia. A Figura 5.11 isola duas referências que parecem equivalentes, mas não são. O modelo e a alternativa baseada em volatilidade são comparados na Figura 5.18, na página 89.




Figura 5.11: Duas formas de escolher as cinco notícias do dia, sobre o mesmo bloco de teste. O desempate alfabético não mede escolha às cegas; a escolha aleatória obtém $0,379 \pm 0,017$ sobre quarenta sementes. As duas políticas escolhem conhecendo o dia completo; estes valores descrevem seleção diferida e não estabelecem um limite para a precisão em linha.

A referência alfabética exige uma explicação: a designação original, «alertar sempre», induz em erro. O modelo que alerta sempre atribui a mesma pontuação a todas as notícias, e quando todas empatam a métrica seleciona pela ordem em que as linhas surgem no ficheiro, que está ordenado por data e por nome da empresa. Esse valor de 0,163 mede a escolha por ordem alfabética e não a escolha aleatória, e todas as linhas que seleciona pertencem à empresa que ocupa a primeira posição no alfabeto. Comparado com o valor de referência correto, o ganho do modelo é de 1,67 vezes e não das quase quatro vezes que a primeira leitura sugeriria. A lição é geral e aplica-se ao restante capítulo: verificar o que a linha de base mede é tão necessário quanto verificar o que o modelo faz.

A comparação com a volatilidade, na Figura 5.18 da página 89, contém o resultado incómodo. Uma tabela de treze constantes, correspondentes à volatilidade média de cada empresa, calculada exclusivamente sobre o bloco de treino e sem leitura de um único título, obtém 0,662 e supera o modelo treinado. O valor não é o da linha *só volatilidade* da Figura 5.12, que é uma regressão sobre a volatilidade diária e obtém 0,632 nesta métrica: aqui a volatilidade entra como uma constante por empresa, e a Secção 5.7 reconcilia as duas. A comparação tem uma reserva que a torna menos limpa do que parece: 17,1% das linhas do bloco de teste pertencem a uma empresa ausente do treino e recebem o valor global de recuo em vez de uma constante própria. É, ainda assim, o terceiro caso do capítulo em que o método mais simples obtém melhor resultado. O que a evidência sustenta é que ordenar por volatilidade compensa, e não que aprender compense.

5.5.5 Ablação das entradas do modelo

O resultado anterior sugere que o modelo implantado reconhece a empresa e não a notícia. A verificação dessa hipótese consiste em tentar reproduzi-lo com uma tabela de consulta que atribua a cada empresa um único número fixado no bloco de treino, correspondente à fração das suas notícias que se revelaram materiais. Essa tabela não observa o título, não observa o dia e devolve invariavelmente o mesmo valor para a mesma empresa. A Figura 5.12 compara-a com o modelo implantado e desmonta o modelo entrada a entrada, sob o protocolo congelado.

Três leituras resultam da figura.

A tabela de consulta iguala o modelo e supera-o numa das medidas. Na PR-AUC obtém 0,534 contra 0,538; na precisão dentro do orçamento, que é a medida mais próxima da utilização real, obtém 0,662 contra 0,632. Esta segunda diferença não foi acompanhada de reamostragem por grupos, ao contrário das diferenças de PR-AUC desta secção, pelo que se reporta como observação e não como superioridade estabelecida. Um número por empresa, fixado meses antes e nunca atualizado, produz o mesmo efeito que o modelo treinado.

Sem as entradas de nível de empresa não subsiste sinal. Retirando-as, a PR-AUC desce para 0,378, que é precisamente a prevalência do bloco de teste e o valor definido na Secção 5.1 como correspondente à ausência de informação.

A única entrada que descreve a notícia nada acrescenta. O comprimento do título, isoladamente, produz o mesmo valor, o que torna a única informação por título recebida pelo modelo implantado indistinguível da ausência de informação.

Estas leituras obrigam a separar duas afirmações. A conclusão científica da QI3 mantém-se: a variante com texto dispõe de trezentos e oitenta e quatro números por título, possuindo por isso informação real sobre a notícia, e ainda assim obteve 0,496 contra os 0,542 da




Figura 5.12: Cada linha corresponde a uma variante com um subconjunto das entradas ou a uma referência alternativa; as linhas não formam uma sequência de remoções cumulativas. A linha decisiva é a da tabela de consulta, que não observa a notícia e iguala o modelo implantado na primeira medida e o supera na segunda. As duas linhas inferiores, que não dispõem de qualquer entrada de nível de empresa, situam-se na PR-AUC exatamente na prevalência do bloco de teste.

volatilidade, sendo essa a comparação que responde à questão. A decisão de produto, por seu turno, estava errada por razão distinta: o que foi implantado como porta de decisão foi a variante sem texto, escolhida por uma métrica que não formulava a pergunta de que o produto necessitava.

A manutenção da variante de nove entradas não decorre de esta apresentar o melhor valor entre as que cabiam no contentor de execução. Pelo critério fixado antes dos resultados, quatro valores são indistinguíveis entre si: os 0,542 da volatilidade, os 0,543 da variante sem indicadores de setor, os 0,538 da variante implantada e os 0,534 da tabela de consulta. Nenhuma das diferenças entre elas excede 0,009, muito abaixo do limite de 0,02. Aplicar esse limite apenas quando desfavorece uma conclusão seria não o ter fixado. A única diferença que o critério separa nesta comparação é a que distingue estas quatro variantes do bloco com texto; medida sobre a linha de base de volatilidade, é de +0,048, com intervalo entre +0,032 e +0,066. A escolha entre as quatro é, por isso, inteiramente de explicabilidade e não tem preço mensurável em PR-AUC: apenas a variante de nove entradas permite ao alerta apresentar as contribuições que elevam e reduzem a pontuação, conforme a Figura 4.6 exhibe.

A lição de método permanece: a PR-AUC sobre o conjunto completo pode assumir valor elevado quando a variação entre empresas domina, mesmo na ausência de qualquer capacidade de distinguir notícias dentro da mesma empresa. O rótulo empresa-dia não permite avaliar diferenças entre títulos do mesmo grupo; essa capacidade requer um alvo por notícia.

5.5.6 O texto como acréscimo e não como substituto

Comparar a volatilidade, o contexto e o texto isoladamente responde a qual das representações é melhor, e não a se o texto acrescenta informação. A resposta a esta segunda pergunta exige somá-lo a uma base que conheça a empresa sem conhecer a notícia.

A variante que combina contexto e texto não constitui essa base, por somar o texto a um bloco que contém informação da notícia através da entrada de retorno do próprio dia. A base adequada é a tabela de consulta por empresa, e a razão é metodológica e não de desempenho: ela contém tudo o que o modelo conhece sobre a empresa e nada sobre a notícia, pelo que somar-lhe o título isola a contribuição do texto. A tabela de consulta não é o melhor preditor conhecido, dado que na PR-AUC a volatilidade isolada se situa acima dela, com 0,542 contra 0,534.

O critério foi fixado antes da medição: um acréscimo apenas conta se o intervalo de confiança a noventa e cinco por cento da diferença, obtido por reamostragem por grupos constituídos pela empresa e pelo dia, excluir zero. A representação de texto não foi afinada para esta experiência, utilizando a mesma redução a trinta e duas dimensões da verificação anterior, de modo que o resultado não decorra da procura da configuração conveniente. A reamostragem utiliza mil repetições sobre 1951 grupos. A Figura 5.13 apresenta os três intervalos.




Figura 5.13: Diferenças de desempenho e respetivos intervalos de confiança a noventa e cinco por cento, obtidos por reamostragem por grupos. As duas primeiras linhas são diferenças de PR-AUC e a terceira é uma diferença de capacidade de ordenação dentro de cada empresa. Apenas a primeira exclui zero, e fá-lo abaixo do critério prático fixado antes da medição.

O título acrescenta a essa base +0,012 de PR-AUC, com intervalo entre +0,004 e +0,020, que exclui zero. É a primeira ocasião em que uma representação de texto apresenta um acréscimo detetável nesta tarefa, e o valor situa-se abaixo do critério prático de 0,02 fixado antes dos resultados. O acréscimo e a base estão arredondados à terceira casa, pelo que somá-los pode diferir na última do valor que a reserva seguinte reporta.

Três reservas delimitam o alcance deste acréscimo, e todas são medições. Os intervalos da primeira e da terceira são os que a Figura 5.13 desenha, e nenhum deles exclui zero.

1. **A soma não supera a volatilidade isolada.** A variante que junta o título à tabela de consulta obtém 0,547 contra os 0,542 da volatilidade, e o intervalo dessa diferença contém zero.
2. **O acréscimo não chega ao produto.** A precisão dentro do orçamento de cinco alertas por dia é de 0,662 com e sem o texto, sem uma casa decimal de diferença. O acréscimo existe na ordenação do conjunto completo e desaparece quando apenas cinco notícias por dia são selecionadas.
3. **Não se demonstra ganho de ordenação dentro da empresa.** A capacidade de ordenação dentro de cada empresa vale 0,500 por construção para a tabela de consulta e sobe para 0,512 quando se lhe soma o título. Para o modelo implantado é de 0,502, com intervalo entre 0,462 e 0,542, e sobe para 0,508 com o texto, num acréscimo cujo intervalo contém zero. Nenhum dos dois se distingue do acaso.

A resposta à Q13 mantém-se negativa e torna-se mais precisa. Nenhum modelo com texto supera a volatilidade. O pequeno acréscimo agregado não se traduz em ganho no orçamento nem demonstra melhor ordenação dentro da empresa. O rótulo partilhado não permite identificar informação específica de cada título no mesmo dia; essa avaliação requer um rótulo por notícia.

Uma reserva final aplica-se ao próprio método. Este é mais um modelo avaliado sobre o mesmo bloco de teste, que já serviu várias comparações do capítulo, e quanto mais vezes um conjunto de teste é observado, mais provável se torna encontrar nele uma diferença pequena. As duas defesas utilizadas, que consistem em não afinar a configuração e em declarar o critério antes da medição, reduzem esse risco sem o eliminarem. A formulação que subsiste é a mais fraca das possíveis: não é possível rejeitar que o título acrescente informação, e o acréscimo, a existir, é inferior ao critério prático fixado antes da medição. O valor observado não estabelece um limite garantido para o efeito do texto.

5.5.7 Limites da conclusão

O resultado não estabelece que o texto de notícias seja inútil. Foi avaliada uma única representação, constituída por títulos sem o corpo do artigo, sobre um único corpus. Com textos completos e maior volume de dados a resposta poderia ser distinta, o que constitui trabalho futuro.

Existe ainda uma hipótese alternativa que estas medições não excluem. O rótulo desconta o movimento do mercado assumindo sensibilidade unitária, pela incoerência declarada na Secção 3.6. Numa ação de sensibilidade elevada, o resíduo da subtração retém movimento do mercado, pelo que o erro do rótulo não é aleatório: é maior nas ações mais sensíveis ao mercado, que são tipicamente também as mais voláteis. Ora a linha de base vencedora é exatamente a volatilidade. Com o que está medido não é possível separar a hipótese de a volatilidade prever melhor a materialidade da hipótese de a volatilidade prever melhor o erro introduzido pelo rótulo. A experiência que resolveria a questão consiste em reconstruir o alvo com sensibilidades estimadas e encolhidas, como faz a Secção 3.4, e repetir as seis famílias. Não foi realizada. O nível e a ordenação das métricas ficam condicionados ao rótulo utilizado.

5.6 O que permanece mensurável na decomposição

A decomposição do movimento não dá origem a uma questão de investigação. Esta secção estabelece a razão dessa ausência e o que, apesar dela, permanece falsificável na técnica.

A diferença face às três técnicas anteriores é a existência de um alvo externo. Para a deteção existe um critério de movimento extremo, o que permite contar acertos e falhas; para a recuperação existe uma noção verificável de relevância, de que decorre a precisão@k; para a triagem existe um rótulo construído a partir de preços posteriores. Em todos estes casos a técnica pode revelar-se errada contra um alvo que lhe é exterior.

Na decomposição esse alvo não existe. Nenhuma fonte de dados publica qual foi a parcela verdadeira do mercado no movimento de uma ação num dado dia, uma vez que essa quantidade não é observável e apenas existe relativamente a um modelo. Fixadas as sensibilidades, a repartição é uma identidade contabilística e não uma previsão suscetível de sair certa ou errada. A construção de uma medida de exatidão neste ponto produziria um valor sem referente.

A técnica não fica por avaliar, mas por avaliar dessa forma, o que obriga a determinar o que nela permanece falsificável. São duas propriedades, e ambas se medem sobre as dezassete empresas do mapa de setores, que é o conjunto percorrido pelo procedimento de avaliação, distinto da lista monitorizada em produção. A Figura 5.14 apresenta as duas.




Figura 5.14: As dezassete empresas do mapa de setores, decompostas no mesmo dia. Em A, a componente identificada como maior parcela do mesmo sinal que o movimento observado. Em B, a dispersão da quota atribuída à empresa. A repartição produz respostas distintas para empresas distintas no mesmo dia, que é a condição mínima para a sua utilidade.

A primeira propriedade é a capacidade de discriminar. Uma decomposição que atribuísse a totalidade do movimento à empresa em todos os dias seria inútil ainda que aritmeticamente correta. No dia medido, o motor identificado foi a própria empresa em oito casos, o mercado em cinco e o setor em quatro, e a quota do movimento atribuída à empresa apresentou mediana de 0,487, com extremos em 0,064 e 0,939.

A segunda propriedade é a qualidade da estimação das sensibilidades, e é a que pode efetivamente estar errada. A medida apropriada é o coeficiente de determinação na janela de estimação, cuja mediana foi de 0,460. Não se trata do coeficiente do ajuste por mínimos quadrados, que, calculado dentro da amostra e com termo constante, nunca poderia ser negativo, mas do coeficiente do modelo efetivamente utilizado, com as sensibilidades já recolhidas e o termo constante recentrado. É esta a medida adequada, por corresponder ao

modelo cuja repartição é apresentada ao utilizador, e é por essa razão que pode assumir valor negativo. Numa das dezassete empresas assumiu, o que significa que, naquela janela, o mercado e o setor não explicavam a variação daquela ação melhor do que a sua própria média, e que a repartição desse dia assenta num ajuste que não descreve os dados.

O resultado não estabelece que a repartição esteja correta pelo facto de as parcelas somarem. Elas somam sempre, com diferença nula até à precisão da máquina, porque a parcela da empresa é definida como resíduo, e uma repartição sem qualquer significado somaria igualmente. A soma exata constitui uma verificação de implementação e não uma validação de método. O resultado também não estabelece que o valor apresentado ao utilizador seja fiável em todos os dias, o que no caso de coeficiente negativo não sucede, e é por essa razão que a limitação consta do Capítulo 6.

5.7 O sistema em operação

O quarto caso de estudo incide sobre o comportamento do sistema depois de implantado, sobre as decisões que toma autonomamente. É a avaliação menos comum das duas descritas na Secção 3.1, e a que produz o diagnóstico que alterou o sistema.

5.7.1 O que a porta de decisão estava a separar

A porta implantada era um limiar fixo sobre a probabilidade calibrada, que deixava passar as candidatas acima de 0,50. A pergunta com significado é a de saber se esse limiar separava títulos ou separava empresas, e a medição foi realizada sobre as 36 925 decisões efetivamente tomadas em produção entre 22 de julho e 20 de agosto de 2026. A Figura 5.15 apresenta o resultado.




Figura 5.15: Intervalo de todas as pontuações atribuídas pelo modelo a cada empresa em produção, sobre as 36 925 decisões registadas entre 22 de julho e 20 de agosto de 2026, com a mediana assinalada. As barras claras nunca alcançam o limiar, as escuras atravessam-no e as alaranjadas situam-se sempre acima. Sete das doze empresas encontram-se inteiramente de um dos lados, o que significa que para essas a decisão estava tomada antes de o título ser lido.

Os valores confirmam a leitura da figura, e reproduzem-se em duas janelas de observação distintas, como mostra a Tabela 5.4.

Tabela 5.4: Indicadores de seletividade da porta de decisão em duas janelas de observação. A amplitude entre empresas é, nas duas, várias vezes a amplitude dentro de cada uma: a conclusão de que a pontuação separa empresas, e não notícias, não depende da janela escolhida. As duas amplitudes estão arredondadas à terceira casa e a razão é calculada sobre os valores não arredondados, pelo que a divisão refeita sobre os números impressos pode diferir na casa apresentada.

Indicador	36 925 decisões 22/07 a 20/08	4 366 decisões até 15/08
Amplitude média dentro de cada empresa	0,072	0,064
Amplitude entre as medianas das empresas	0,392	0,385
Razão entre as duas	5,4×	6,1×
Empresas sempre acima do limiar	2 de 12	3 de 12
Empresas em que o limiar chega a decidir	5 de 12	4 de 12

O que a pontuação separa são empresas, e não notícias. Em nenhuma das avaliações registadas a Apple alcançou o limiar, com um máximo observado de 0,472, ao passo que a AMD o ultrapassou em todas. É a mesma empresa cujo movimento a Secção 3.4 reparte.

A fração de casos em que o resultado estava determinado antes de o título ser lido admite duas contagens, e ambas se reportam. Contada uma vez por título distinto é de 48%; contada por decisão registada sobe para 60%. Cita-se a primeira, e a razão é que o sistema repontua os mesmos títulos a cada ciclo de sessenta segundos: essa duplicação é maior nas empresas com menos notícias, que são precisamente as que nunca ultrapassam o limiar, pelo que contar decisões desloca a fração para cima, e na direção que convém à conclusão.

O defeito tem a mesma forma que o identificado na Secção 5.2, uma camada acima. Naquele caso, um limiar fixo sobre o retorno mede a volatilidade da empresa em vez da raridade do dia; neste, um limiar fixo sobre uma pontuação quase constante por empresa ordena empresas em vez de notícias.

Nenhum dos testes automáticos existentes o cobria. O modelo foi avaliado sobre a distribuição do conjunto de treino e implantado atrás de dois filtros que a alteram, e cada componente cumpria o seu contrato. O teste que o teria apanhado é o que este trabalho passou a executar: comparar a amplitude das pontuações dentro de cada empresa com a amplitude entre empresas. O que estava errado era uma suposição sobre a ligação entre eles, não enunciada em nenhum ponto. Corresponde à classe de custo que D. Sculley et al. (2015) arrumam sob dependências de dados e emaranhamento entre componentes, com o sintoma que os autores descrevem: o sistema continua a produzir valores de aparência normal.

Existe uma segunda causa possível, que os registos não permitem separar da primeira. Uma das nove entradas é o retorno do próprio dia. No treino corresponde ao movimento completo do dia da notícia. Em produção é calculado sobre a última barra diária disponível, que durante

a sessão é o fecho da véspera ou uma barra incompleta. As duas causas produzem o mesmo sintoma, e o registo, à data desta medição, guardava a probabilidade e o resultado mas não o valor das entradas no momento da pontuação, pelo que a sua separação exigiria registar essas entradas e voltar a observar durante semanas.

Essa instrumentação foi construída e implantada em 4 de setembro de 2026, e o registo passou a guardar, por decisão, o valor de cada uma das nove entradas, a data da última barra de preço utilizada e a identidade do modelo que pontuou. Duas consequências decorrem dela e nenhuma é um resultado. A primeira é que as decisões anteriores a essa data permanecem não reproduzíveis a partir do registo, uma vez que recalculer hoje as entradas de um dia passado utilizaria uma série de preços que já contém o que veio a seguir; as medições deste capítulo assentam nessas decisões e não são afetadas pela alteração. A segunda é que a janela de observação necessária para separar as duas causas começou nessa data, e o critério de aceitação de qualquer comparação futura foi fixado antes de existir candidato, pela mesma razão que o Capítulo 3 invoca para as restantes experiências. Nada se afirma aqui sobre o seu desfecho.

A correção aparente consistiria em substituir o limiar fixo por um limiar relativo a cada empresa. A simulação dessa alternativa sobre as mesmas decisões resolve metade do problema, uma vez que as doze empresas passam a estar representadas, e introduz outro. Nas empresas cuja pontuação quase não varia, o percentil recai sobre a constante e quase todas as decisões empatam acima dele; uma delas passa a gerar 874 alertas. O limiar relativo deixa de escolher por materialidade e passa a escolher por desempate, que é precisamente o artefacto documentado na Secção 5.5. Dentro de uma empresa a pontuação do modelo quase não varia com o título, e nenhuma regra de decisão aplicada a essa pontuação a pode tornar sensível à notícia, porque a informação que distinguiria um título do seguinte não está presente.

Em consequência, o modelo deixou de constituir porta e passou a constituir critério de ordenação, que é a utilização que a medição sustenta, e o controlo de volume passou para um orçamento diário de cinco alertas. Esta alteração aproxima duas políticas que divergiam: a dissertação avaliava uma política de orçamento e o sistema implantava uma política de limiar, pelo que o valor reportado descrevia um sistema distinto do que estava em funcionamento. As duas políticas passaram a pertencer à mesma família sem se tornarem idênticas. A Tabela 5.5 reúne as três políticas e o que cada uma produz.

A alteração foi medida sobre os alertas efetivamente entregues, e o efeito pretendido verificase. A quantidade observada é a concentração, definida como a fração dos alertas que pertence às três empresas mais alertadas, e a sua vantagem é ser adimensional, o que permite comparar janelas de dimensões distintas. Nos alertas de notícia, que são os que o orçamento governa, a concentração desce de 0,713 para 0,480, com intervalo de confiança da diferença a excluir zero, e o número de empresas que chegam a produzir um alerta passa de sete para nove das doze monitorizadas.

O que sustenta a leitura não é, porém, a descida isolada, mas a comparação com uma série que a alteração não governa. Os alertas de movimento de preço atravessam o mesmo período, as mesmas empresas e as mesmas condições de mercado, e o orçamento diário não os conta. Nessa série a concentração passa de 0,449 para 0,485, com o intervalo a conter zero. A quantidade governada deslocou-se e a quantidade não governada não, o que afasta a explicação alternativa de que o mercado se teria distribuído de forma mais uniforme no segundo período.

Tabela 5.5: As três políticas de decisão consideradas para a porta, e o que cada uma produz sobre as mesmas doze empresas. A segunda não chegou a ser implantada: foi simulada sobre as decisões registradas, e é essa simulação que a exclui. Os valores de concentração referem-se aos alertas de notícia efetivamente entregues; o valor de 874 é o número de alertas que a simulação atribui a uma única empresa.

Política	O que faz	O que produz
Limiar fixo (a que estava)	O modelo veta: a notícia passa se a pontuação exceder um valor único	7 das 12 empresas chegam a alertar; concentração 0,713
Limiar por empresa (simulada, rejeitada)	O valor deixa de ser único e passa a um percentil dentro de cada empresa	Nas empresas de pontuação quase constante o percentil recai sobre a constante: uma delas geraria 874 alertas
Ordenação com orçamento (a implantada)	O modelo deixa de vetar e passa a ordenar; o volume é cortado por um orçamento de cinco alertas por dia	9 das 12 empresas chegam a alertar; concentração 0,480

Cinco dias são excluídos da janela posterior, e a razão é registrada por ser ela própria um resultado. Entre 25 e 29 de agosto de 2026 o contador diário residia em disco efêmero e regressava ao valor inicial a cada arranque do processo, o que produziu séries de exatamente cinco alertas nos instantes dos arranques e um dia com vinte. Nesses dias o orçamento não estava em vigor, e a sua inclusão elevaria a concentração posterior para 0,514. A reamostragem é efetuada por dia, que é a unidade sobre a qual o orçamento atua.

A comparação não constitui um ensaio aleatorizado. A série de controlo partilha o período mas não foi atribuída ao acaso, e as duas janelas diferem em duração e em condições de mercado. O que se estabelece é que a quantidade governada se deslocou e a não governada não, e não que nenhuma outra causa exista.

A métrica avaliada ordena todas as candidatas do bloco de teste e apenas depois preenche cinco lugares em cada dia, o que exige conhecer o dia completo antes de decidir e constitui por isso uma política diferida. O sistema implantado decide em linha, de sessenta em sessenta segundos, e gasta o primeiro lugar na primeira notícia que atravessasse as portas, porque no momento da decisão a notícia da tarde ainda não existe. A precisão dentro do orçamento reportada neste capítulo descreve essa seleção diferida. Conhecer mais candidatas não garante maior precisão quando as pontuações podem errar; a relação com a precisão da política em linha permanece por medir.

5.7.2 O desempenho do modelo sobre as decisões que tomou

O sistema regista todas as decisões de triagem e, decorridos os dias necessários para o preço responder, confronta-as com o resultado efetivo. Duas medições resultam desse registo: a fração de casos que se revelaram materiais de cada lado da porta, e a capacidade de ordenação do modelo, medida pela Receiver Operating Characteristic Area Under the Curve (ROC-AUC). A Figura 5.16 apresenta ambas, sobre 825 decisões já maturadas.




Figura 5.16: Em A, a fração de casos que se revelaram materiais entre as decisões que o modelo deixou passar e entre as que travou, com intervalos de confiança a noventa e cinco por cento e a taxa-base do conjunto. As suprimidas apresentam fração superior às mantidas, mas os dois intervalos sobrepõem-se em quase toda a extensão e não as separam. Em B, a capacidade de ordenação medida sobre as 239 unidades independentes, com o intervalo a conter confortavelmente o valor de acaso.

Sobre a população que efetivamente observa, esta amostra não distingue o modelo do acaso em nenhuma das duas medidas. As notícias que deixou passar revelaram-se materiais em 58,9% dos casos, contra 61,7% das que travou, sobre uma taxa-base de 60,2%; os intervalos das duas frações sobrepõem-se, pelo que a ordenação aparente não é estabelecida. O que fica medido é a ausência de benefício detetável com esta dimensão de amostra, e não a ausência de benefício.

Estes valores exigem uma reserva de precisão considerável: as 825 decisões não constituem 825 observações independentes, dado que o rótulo é atribuído por par formado pela empresa e pelo dia, e as linhas repartem-se por apenas 239 pares distintos. Medida sobre essas unidades, a capacidade de ordenação situa-se em 0,486 com intervalo de confiança entre 0,403 e 0,571, num intervalo em que o acaso vale exatamente 0,500. A leitura correta não é a de que o modelo seja pior do que a ausência de modelo, mas a de que esta amostra não o distingue do acaso.

A medição foi repetida quando o registo dispunha de 825 decisões maturadas contra as 530 da primeira leitura, e quase nada se alterou: a diferença entre mantidas e suprimidas estreitou-se, a capacidade de ordenação passou de 0,494 para 0,486 e o intervalo encolheu. Com metade mais evidência, o veredicto mantém-se e torna-se mais firme.

A explicação mais provável não é a de que o modelo esteja avariado, mas a de que esteja em excesso. Quando é invocado, as notícias já atravessaram o filtro de relevância e o filtro de frescura, e esses filtros elementares removeram grande parte daquilo que o modelo foi treinado para remover, restando pouco para separar. Um modelo avaliado isoladamente e implantado atrás de filtros nunca foi avaliado na distribuição que efetivamente observa, e esta é a constatação com maior capacidade de transferência do trabalho.

A observação dessa distribuição foi instrumentada. Em 4 de setembro de 2026 o registo de decisões passou a conservar, para cada candidata avaliada e não apenas para a sobrevivente de cada ciclo, o valor de cada entrada e a data da última barra de preço utilizada, conforme descrito na Secção 4.7. É essa alteração que torna observável, pela primeira vez, a população que o modelo teria de ordenar se fosse ele a triar, e não apenas a fração que os filtros elementares lhe entregam. O protocolo de análise foi fixado antes de existir qualquer medição: a unidade é o par formado pela empresa e pelo dia, só são utilizáveis as decisões cuja barra de preço seja anterior ou igual à data da notícia, e abaixo de um número mínimo de pares maturados nenhuma métrica é publicada. Nada se afirma neste documento sobre o resultado dessa observação, que à data de escrita não existia.

Três das doze empresas monitorizadas, a AMD, a Netflix e a Meta, não figuram no corpus de treino, e uma quarta, a Microsoft, figura apenas no bloco de teste. O modelo pontua-as na mesma, porque o que recebe são valores numéricos e não a identidade da empresa, mas fá-lo sobre uma combinação de entradas que não observou. Uma das ausentes, a AMD, é uma das duas empresas que se situam sempre acima do limiar, e outra, a Meta, apresenta mediana imediatamente acima dele, pelo que a determinação por empresa descrita acima incide também sobre nomes que o modelo nunca observou. Constitui um segundo sentido, mais literal, em que o modelo implantado opera fora da distribuição em que foi avaliado, e as decisões dessas empresas entram nas 825 acima como quaisquer outras.

5.7.3 Deriva das distribuições

Uma segunda razão, independente da anterior, pode fazer com que um modelo implantado deixe de servir: os dados alteram-se. O modelo foi treinado sobre o período de 2018 a 2023 e opera em 2026. A medida utilizada é o PSI, ou índice de estabilidade populacional, que confronta aqui a distribuição de cada entrada no bloco de treino, compreendido entre 2018 e 2022, com a do bloco de teste, de 2023. Não é, portanto, a distância entre o treino e o presente, que a subsecção seguinte discute em separado: é a deriva interna ao próprio protocolo. As bandas são as convencionadas em risco de crédito, segundo as quais valores abaixo de 0,10 indicam estabilidade, valores entre 0,10 e 0,25 deslocamento moderado e valores acima de 0,25 deslocamento significativo. A Figura 5.17 apresenta o resultado.




Figura 5.17: Índice de estabilidade populacional de cada entrada entre o bloco de treino, de 2018 a 2022, e o bloco de teste, de 2023, com as bandas convencionadas assinaladas. A entrada de que o modelo mais depende é a que mais se deslocou. A prevalência do rótulo passa de 0,3854 para 0,3781 entre as duas pontas, mas não é estável pelo meio: no bloco de validação, temporalmente entre ambas, chega a 0,4704.

O resultado tem duas metades. A entrada que mais se deslocou é a volatilidade dos vinte dias anteriores, situada na banda significativa, ao passo que as restantes permanecem estáveis ou moderadas. O rótulo desloca-se pouco entre as pontas, com a prevalência de positivos a passar de 0,3854 para 0,3781, mas não é estável: o bloco de validação, temporalmente entre os dois, chega a 0,4704. A prevalência oscila com o regime de volatilidade em vez de derivar numa direção, o que é coerente com a volatilidade ser a entrada que mais se desloca.

A leitura correta desta medição é a de que a deriva não é externa aos valores deste capítulo: é a que o próprio protocolo atravessa, uma vez que treina em 2018–2022 e avalia em 2023. A PR-AUC reportada é já uma medida sob esta deriva, e a combinação é desfavorável porque a entrada de que o modelo mais depende é precisamente a que mais se deslocou.

O que esta medição não estabelece é a distância entre o treino e 2026, que é o período em que o sistema opera. Um instantâneo sobre cotações atuais aponta na mesma direção, com a volatilidade a ser de novo a entrada que mais se desloca. Assenta, porém, em janelas deslizantes consecutivas que partilham a quase totalidade das observações, o que inflaciona o índice e torna a sua magnitude não comparável com a da figura. O valor permanece por medir, e não é estimado por analogia. A deriva é, em qualquer dos casos, medida e não corrigida, e a Secção 6.5 enuncia o que seria necessário para a corrigir.

5.7.4 O sistema completo contra as alternativas existentes

As secções anteriores comparam componente a componente. Falta a comparação ao nível do sistema: dadas as notícias de um dia, a política escolhe as cinco a apresentar melhor do que uma regra disponível sem custo. A Figura 5.18 responde. Todas as políticas escolhem cinco por dia, sobre o mesmo bloco de teste e com o mesmo rótulo, e o desempate é aleatório e explícito em todas.




Figura 5.18: Cinco políticas de seleção sobre o mesmo bloco de teste. A escolha aleatória serve de referência, e obtém aqui 0,375 contra os 0,379 da Figura 5.11: são duas execuções do mesmo sorteio por procedimentos distintos, e a diferença situa-se dentro da dispersão entre sementes de qualquer uma delas. O oráculo é um máximo teórico não utilizável, obtido com conhecimento das respostas. Todas escolhem conhecendo o dia completo. Os valores das políticas utilizáveis descrevem seleção diferida; apenas o oráculo estabelece o máximo possível neste conjunto.

Três leituras resultam da figura. A primeira é que o sistema supera a alternativa realista: apresentar notícias das empresas com maior movimento do dia é o que qualquer aplicação de bolsa já faz sem custo, e obtém 0,489, contra 0,632 do sistema, um ganho de 0,143

sob o mesmo protocolo. Este valor mede a capacidade de ordenar o rótulo aproximado no bloco histórico, e não a utilidade percebida por uma pessoa nem o valor causal dos alertas em funcionamento.

A segunda é que o sistema continua a não superar a volatilidade. Treze constantes calculadas exclusivamente sobre o bloco de treino obtêm 0,662, o que é coerente com a ablação da Secção 5.5.5: o modelo é, na prática, uma tabela por empresa, e a volatilidade é outra tabela por empresa, mais simples, sendo esta a que dispensa treino. Não é a mesma quantidade que a Figura 5.12 designa por *só volatilidade*, que é uma regressão sobre a volatilidade diária e obtém 0,632 nesta métrica; aqui a volatilidade entra como uma constante por empresa.

Duas constantes por empresa distintas obtêm, nesta métrica, o mesmo valor de 0,662: a volatilidade média de cada empresa, aqui, e a fração das suas notícias que se revelaram materiais, na Secção 5.5.5. A coincidência não é fortuita e decorre da forma da própria medida. A precisão dentro do orçamento depende apenas de quais as cinco notícias escolhidas em cada dia; e uma pontuação constante por empresa reduz essa escolha a uma ordenação das empresas que têm notícia nesse dia. Dois preditores que ordenem as empresas da mesma maneira selecionam, por isso, exatamente as mesmas notícias, e obtêm o mesmo valor, ainda que a quantidade que atribuem a cada empresa seja diferente. Que duas quantidades tão distintas produzam a mesma ordenação é a observação desta secção sob outra forma: o que separa as empresas neste conjunto é, em larga medida, a sua volatilidade.

A terceira, e mais útil, é a localização da limitação pelo máximo teórico. O melhor resultado possível, escolhendo com conhecimento das respostas, seria de 0,968, o que significa que em quase todos os dias existem efetivamente cinco notícias materiais no conjunto disponível. O sistema não está limitado por escassez de linhas com rótulo positivo, mas pela seleção que realiza. A margem entre 0,632 e 0,968 é de 0,336. Como todos os títulos de uma empresa no mesmo dia partilham o rótulo, trocar títulos dentro desse grupo não altera a precisão. Esta margem mede uma distância à seleção ideal de grupos empresa-dia; não localiza uma incapacidade de distinguir títulos dentro de cada grupo nem constitui uma verificação independente dessa capacidade.

Todas as políticas desta comparação escolhem de entre o que a fonte entregou, o que deixa de fora a pergunta anterior a todas, relativa aos dias em que nada foi entregue. Sobre um ano de notícias captadas, existia pelo menos uma notícia relevante em 88,5% dos dias que o detetor considerou invulgares, num total de 417, e em 47 dos 52 dias mais extremos, dimensão que não permite distinguir as duas frações. Nos restantes, nenhuma alteração ao sistema produz efeito, uma vez que uma notícia não associada à empresa pela fonte gratuita não chega a entrar no percurso. A cobertura é ainda muito desigual, com a empresa pior coberta a situar-se nos 50%. Este valor é um limite superior, e a distinção determina o que ele vale: estabelece que existia uma notícia, e não que tenha chegado a notícia correta. A Secção 6.4 retoma-o como limitação.

Uma linha de base não foi medida, e a razão fica registada. A alternativa mais natural consistiria em apresentar as primeiras cinco notícias a chegar. Não é mensurável neste protocolo, uma vez que o conjunto de dados histórico não conserva a hora de publicação e está ordenado por data e por empresa, pelo que utilizar a ordem do ficheiro mediria a ordem alfabética das empresas. Seria o mesmo artefacto documentado na Secção 5.5, desta vez introduzido deliberadamente. Uma linha de base errada é pior do que uma linha de base em falta.

5.7.5 Utilidade percebida dos alertas entregues

O canal passou a acompanhar cada alerta entregue com dois botões, *útil* e *não ajudou*, e a registar o voto de quem carrega. As regras de análise foram fixadas antes de existir um único voto e não foram alteradas depois: mínimo de vinte votos efetivos para reportar qualquer proporção, um voto por pessoa e por alerta com o último a substituir o anterior, salvaguarda que repete o cálculo sem o votante dominante quando este representa mais de quarenta por cento dos votos, sempre sujeita ao mesmo mínimo, e intervalos de confiança de Wilson, calculados sem correção por agrupamento. Contaram apenas votos sobre alertas presentes no registo partilhado.

Foram registados 81 votos válidos entre 2026-09-02 e 2026-09-04, que correspondem a 42 votos efetivos de 3 pessoas distintas, sobre 29 alertas. 10 votos foram posteriormente alterados pela mesma pessoa, e apenas o último de cada par conta. Outros 29 repetem um voto anterior sem o alterar e contam uma só vez. 5 votos foram excluídos por não corresponderem a nenhum alerta do registo partilhado.

Dos 42 votos efetivos, 41 classificaram o alerta como útil, ou seja 98%, com intervalo de confiança de Wilson a 95% entre 88% e 100%. Este cálculo binomial não corrige a dependência entre votos da mesma pessoa ou sobre o mesmo alerta; a sua largura não representa toda a incerteza desta amostra.

Uma única pessoa representa 67% dos votos efetivos, acima do limite de 40% fixado no protocolo. Excluindo-a, restam 14 votos, dos quais 14 classificam o alerta como útil. Este recorte também fica abaixo do mínimo de 20; nenhuma segunda proporção é reportada e a amostra não sustenta uma leitura independente do votante dominante.

A independência entre quem constrói o sistema e quem o classifica é condição desta amostra: o autor não figura entre os votantes contabilizados. Os votos provêm de leitores do canal público, e o registo conserva de cada um apenas o identificador de conversa atribuído pela plataforma.

Estes votos constituem retorno observacional em contexto real e não substituem o estudo controlado que a Secção 6.4 identifica como a lacuna de maior peso deste trabalho, e que permanece por realizar.

Quatro limitações acompanham este resultado e nenhuma delas se resolve com mais votos. A primeira é a autosselecção: vota quem quer, e quem considera um alerta indiferente tende a não carregar em nada, o que empurra a amostra para os extremos. A segunda é a ausência de contrafactual, uma vez que nenhum grupo recebeu a variação de preço sem a explicação que a acompanha; nada aqui atribui a utilidade à explicação em si. A terceira é a distância entre utilidade percebida e decisão melhor, que é a hipótese fundadora deste trabalho e permanece por testar. A quarta é o desconhecimento de quem vota: o canal é público e não se sabe se quem responde pertence ao público que a dissertação assume.

5.8 Síntese dos resultados

Esta secção reúne as comparações realizadas ao longo do trabalho, incluindo aquelas em que o sistema mantém a opção que a medição não favorece.

Duas das três respostas são afirmativas e uma é negativa. A resposta negativa é a que exigiu maior esforço de verificação, e é também a que estabelece que a avaliação foi construída de

modo a poder produzir uma resposta negativa. A Tabela 5.6 apresenta cada escolha técnica ao lado da alternativa medida contra ela.

Tabela 5.6: As decisões técnicas do trabalho, cada uma com a alternativa medida contra ela. Três linhas registam que a opção implantada não obteve o melhor resultado, e a razão da sua manutenção consta da coluna respetiva. As três últimas linhas são restrições fixadas antes de qualquer medição, e não resultados: apresentá-las como comparação atribuir-lhes-ia uma autoridade que não possuem.

Opção implantada	Alternativa medida	Leitura
z-score deslizante	Limiar fixo de três por cento: amplitude 0,344 contra 0,015	Um limiar fixo mede a volatilidade da empresa e não a raridade do dia.
z-score deslizante	<i>Isolation Forest</i> com F_1 de 0,269 e <i>Local Outlier Factor</i> com 0,280, contra 0,530	Os detetores aprendidos assinalam quase tudo e acertam pouco.
Janela de vinte dias	Não obteve o melhor resultado: dez dias produzem F_1 de 0,385, vinte dias 0,516 e sessenta dias 0,678	A medição favorece a janela mais longa. Mantida por responsividade, com a reserva de circularidade do rótulo declarada.
Desvio-padrão de pesos iguais	Não obteve o melhor resultado: o decaimento exponencial produz F_1 de 0,664 contra 0,516	Mantido por ser explicável a um leitor não especializado, e registado como escolha e não como resultado.
Embeddings de frase	Sobreposição de palavras: precisão@5 de 0,346 contra 0,514	Vocabulário comum não implica assunto comum, e assunto comum não exige vocabulário comum.
MiniLM em vez de MPNet	Não obteve o melhor resultado: o MPNet produz 0,538 contra 0,514; um codificador de domínio financeiro produz 0,420	O modelo mais pesado é melhor e foi substituído por custo. O codificador de domínio obteve o pior resultado de todos, por medição e não por suposição.
Regressão logística	Árvores com reforço do gradiente: PR-AUC de 0,469 contra 0,538	O modelo mais expressivo não obteve melhor resultado, e o modelo simples é explicável.
Calibração de Platt	Regressão isotónica, comparada sobre a mesma validação	A calibração de Platt iguala ou supera no índice de Brier nas cinco famílias avaliadas: 0,218 contra 0,223 na de volatilidade e 0,224 contra 0,226 na implantada.
Semelhança do cosseno	Distância euclidiana	Com vetores normalizados as duas produzem a mesma ordenação, e a primeira dispõe de leitura mais direta.
Dois gatilhos, notícia e preço	Fusão com o volume e a intensidade de notícia, na linha dos painéis que combinam sinais de origens distintas (<i>World Monitor</i> 2026): perde em dois dos três orçamentos, com $-0,050$ e $-0,032$, e ganha no terceiro por $+0,004$	Um ganho que depende do orçamento escolhido, e uma ordem de grandeza menor do que as perdas, não sustenta a adoção. O volume continua a ser calculado e apresentado como contexto, sem originar alertas.
Apenas fontes gratuitas	—	Restrição fundadora: define o público que o sistema pode servir.
Ausência de previsão de preços	—	Restrição de desenho: é o que torna verificável tudo o restante.
Mercado dos Estados Unidos	—	Restrição de âmbito: é onde as fontes gratuitas apresentam cobertura.

Três linhas da tabela merecem desenvolvimento. A primeira respeita ao codificador de domínio financeiro, cuja derrota tem explicação no objetivo de treino e não no conhecimento do domínio, conforme a Secção 5.3 estabelece. A segunda respeita à janela de vinte dias, que

é a opção mais difícil de justificar, uma vez que a única medição existente sobre este ponto não a sustenta e a justificação de responsividade não é quantitativa. A terceira respeita ao estimador de volatilidade, mantido por explicabilidade contra uma alternativa medida como superior.

O capítulo documenta três ocasiões em que uma técnica mais simples superou uma técnica mais sofisticada em condições equivalentes, e três ocasiões em que sucedeu o inverso e o sistema conservou mesmo assim a opção implantada. Nestas últimas a razão difere em cada caso, e nenhuma delas é o resultado da medição: o estimador de pesos iguais foi mantido por explicabilidade, a janela de vinte dias por responsividade, e o codificador de frases mais pequeno por custo computacional. A distinção entre os dois conjuntos é a distinção entre resultado e escolha, e o Capítulo 6 retoma-a ao estabelecer o que este trabalho demonstra e o que apenas decide.

Capítulo 6

Conclusões

O Capítulo 5 avaliou os quatro componentes. Este reúne o que dessas medições se retira. Sintetiza o trabalho realizado, apresenta a resposta obtida para cada questão de investigação, identifica as limitações do estudo e enuncia as linhas de desenvolvimento futuro. Quem o leia fica a saber o que o trabalho estabelece, o que decide sem estabelecer, e o que fica por testar.

6.1 Conclusões principais

O trabalho produziu um sistema em funcionamento e uma avaliação de cada uma das técnicas que o compõem. O InvestiGator monitoriza doze empresas em ciclo contínuo, entrega alertas explicados a um canal público e disponibiliza uma página onde ficam registadas tanto as mensagens enviadas como as decisões que conduziram ao silêncio. Entre 9 de julho e 13 de agosto de 2026 foram entregues 367 mensagens, entre 22 de julho e 20 de agosto registaram-se 36 925 decisões de triagem, e a reconstrução da base de precedentes reuniu 38 214 casos com impacto medido. Estes números descrevem um sistema implantado e não uma demonstração construída para o efeito.

A componente que confere ao trabalho o carácter de dissertação não é, contudo, o sistema, mas a avaliação a que foi submetido. Três das quatro técnicas foram comparadas com alternativas mais simples, escolhidas e declaradas antes de a medição ser realizada, o que é a condição para que o resultado possa ser negativo. Numa delas o resultado foi efetivamente negativo. A quarta técnica, a decomposição do movimento, não admite comparação da mesma natureza, uma vez que a repartição de um retorno não possui referente externo observável. Dela mediu-se o que permanece falsificável: a qualidade do ajuste que a sustenta, e a capacidade de produzir respostas distintas para empresas distintas.

A contribuição de engenharia não reside na dimensão do modelo aprendido. O sistema treina um único modelo, com nove entradas, e esse modelo perde para uma linha de base de uma só variável. A confiança nesse valor, e na conclusão negativa que ele sustenta, depende do que foi preciso construir em volta dele. A Secção 4.7 descreve as sete peças. O conjunto de dados é rotulado a partir de duas fontes independentes. O rótulo é declarado como decisão, e nove definições alternativas são medidas em vez de a adotada ser assumida. A separação temporal é verificada por um procedimento automático. A calibração vem acompanhada da medição e da declaração do enviesamento que a afeta. Os artefactos ficam sob controlo de versões. O modelo implantado é comprovadamente o modelo avaliado. E o sistema em funcionamento continua a ser observado. É nesse conjunto, e não no modelo, que reside o trabalho.

Uma segunda conclusão atravessa os quatro casos de estudo e não pertence a nenhum deles em particular. Em quatro ocasiões distintas, uma técnica mais simples obteve melhor resultado do que uma mais sofisticada em condições equivalentes; em três outras sucedeu o inverso, e o sistema conservou mesmo assim a opção implantada, por uma razão distinta em cada caso. A Figura 6.1 reúne as sete.

a técnica simples obteve melhor resultado	a alternativa obteve mais, e o sistema manteve a sua
z-score deslizante contra dois detetores aprendidos F_1 de 0,530 contra 0,269 e 0,280	decaimento exponencial obtém mais, e não foi adotado F_1 de 0,664 contra 0,516 · explicabilidade
volatilidade recente contra as representações de texto PR-AUC de 0,542 contra 0,496	janela de sessenta dias obtém mais, e não foi adotada F_1 de 0,678 contra 0,516 · responsividade
treze constantes por empresa contra o modelo treinado precisão@5 de 0,662 contra 0,632	MPNet obtém mais, e não foi adotado precisão@5 de 0,538 contra 0,514 · custo
codificador sem ajuste contra o ajustado por materialidade precisão@5 de 0,771 contra 0,746	

Figura 6.1: À esquerda, as quatro ocasiões em que uma técnica mais simples obteve melhor resultado do que uma mais sofisticada em condições equivalentes; a última é a mais recente, e nela a técnica mais simples é a ausência de ajuste. À direita, as três em que sucedeu o inverso e o sistema conservou mesmo assim a opção implantada, com a razão de cada uma. A distinção entre as duas colunas é a distinção entre resultado e escolha, e a Tabela 5.6 reúne-as com as restantes.

A distinção entre estes dois casos é a distinção entre resultado e escolha, e o presente capítulo mantém-na explícita: o que a medição estabelece é reportado como resultado, e o que o autor decidiu apesar da medição é reportado como decisão, acompanhada do que essa decisão custa quando a medição separa as alternativas, e da declaração de que nada custa em PR-AUC quando não as separa.

6.2 As respostas às questões de investigação

Esta secção responde às quatro questões enunciadas na Secção 1.3 e delimita, em cada caso, o que a resposta permite e não permite afirmar. A Figura 6.2 reúne as quatro.

6.2.1 Detecção de movimentos invulgares

A resposta à Q11 é afirmativa. Um z-score sobre uma janela deslizante de vinte dias assinala dias raros a uma taxa praticamente idêntica em empresas de volatilidades muito distintas. A amplitude entre a empresa mais e a menos assinalada é de 0,015, contra 0,344 de uma regra de limiar fixo em três por cento. Contra um rótulo aproximado, o método obtém $F_1 = 0,516$ e a regra fixa 0,218. Sujeito a um protocolo causal equivalente, o mesmo método supera ainda dois detetores concebidos para esta tarefa, com F_1 de 0,530 contra 0,269 do *Isolation Forest* (F. T. Liu, Ting e Zhou 2008) e 0,280 do *Local Outlier Factor* (Breunig et al. 2000).

Q11 · detecção Detetar movimentos invulgares de forma consistente entre empresas?	SIM	amplitude da taxa de disparo de 0,015 contra 0,344 da regra de limiar fixo, e F_1 acima de dois detetores aprendidos
Q12 · precedentes Recuperar notícias passadas de outra empresa do mesmo setor?	SIM	supera o acaso nos cinco setores; com notícias anteriores à consulta, precisão@5 de 0,513 contra acaso de 0,259
Q13 · triagem Um modelo treinado prioriza notícias melhor do que uma linha de base simples?	NÃO	PR-AUC de 0,496 com texto contra 0,542 só com volatilidade, resultado que resiste a três verificações à montagem experimental
Q14 · comparabilidade O ajuste do codificador aproxima notícias de materialidade comparável?	NÃO	2,185 pontos com ajuste contra 2,173 sem ajuste, diferença de um quinto do desvio entre repetições, e precisão@5 a descer 0,026

Figura 6.2: As quatro respostas, com as duas respostas negativas apresentadas com o mesmo destaque das duas afirmativas. A resposta à segunda questão limita-se às alternativas avaliadas e ao critério aproximado de relevância setorial.

A configuração implantada não é, porém, a melhor medida dentro da própria família. Com a mesma cobertura, um estimador com decaimento exponencial obtém $F_1 = 0,664$ e uma janela de sessenta dias obtém 0,678, contra os 0,516 da configuração em produção. O que a Q11 estabelece é que a família deslizante supera o limiar fixo e os dois detetores aprendidos, e não que a parametrização escolhida seja a melhor dessa família.

Este resultado é menos surpreendente do que a diferença de valores sugere, e a literatura permite situá-lo. Os dois detetores aprendidos definem raridade a partir da geometria dos dados, um por isolamento do ponto e outro por comparação de densidades, e foram concebidos para espaços com múltiplas variáveis em interação. O problema tratado apresenta uma única série de retornos por empresa, na qual a estrutura relevante é temporal e não geométrica: períodos de agitação sucedem-se a períodos calmos. É a propriedade que os modelos ARCH e GARCH formalizam (Bollerslev 1986; Engle 1982). A janela deslizante capta-a diretamente; um detetor treinado sobre o conjunto completo teria de a aprender. Quando a suposição embutida num método simples coincide com a estrutura efetiva do problema, a margem para a superar é reduzida.

O alcance da resposta é delimitado por três condições. A comparação incide sobre quinze empresas de grande capitalização, selecionadas em 2026 e avaliadas sobre o passado, que sobreviveram por construção; sobre três anos de cotações e sobre um único mercado. O rótulo utilizado como argumento secundário é ele próprio relativo à volatilidade de cada empresa, razão pela qual o argumento principal é a consistência da taxa de disparo, que não depende de rótulos. O limiar de três por cento da regra alternativa não foi otimizado, pelo que o que a comparação estabelece não é que nenhum limiar fixo obtivesse melhor resultado, mas que uma regra de limiar fixo mede uma quantidade distinta da pretendida.

6.2. As respostas às questões de investigação




Figura 6.3: Para cada questão, o percurso da pergunta até ao resultado, e a linha que delimita o alcance desse resultado. As três primeiras colunas são o protocolo, fixado antes da medição; a quarta é o valor obtido contra a alternativa. A linha inferior de cada bloco é a que distingue uma avaliação de uma demonstração, e é desenvolvida nas subsecções que se seguem.

6.2.2 Recuperação de precedentes

A resposta à Q12 é afirmativa face às alternativas avaliadas. Sobre o corpus recente, a recuperação por semelhança de frase (Reimers e Gurevych 2019) obtém precisão@5 de 0,514, contra 0,346 da sobreposição de vocabulário, 0,240 da escolha aleatória e 0,126 da apresentação das notícias mais recentes. Também aqui o modelo implantado não é o melhor medido: uma variante de maior dimensão obtém 0,538 sobre o mesmo protocolo, e foi preterida por custo computacional.

O valor agregado não constitui, porém, a forma adequada de enunciar o resultado. Quase metade das notícias do corpus pertence ao setor da tecnologia, o que torna disponível uma estratégia que dispensa qualquer modelo e sequer observa a consulta, consistindo em devolver invariavelmente notícias desse setor; a sua precisão iguala a fração de consultas de tecnologia, 0,467. Essa estratégia é inútil enquanto produto, dado que acerta em todas as consultas de um setor e em nenhuma dos quatro restantes, mas a sua existência demonstra que o agregado mede em parte a composição do corpus.

A comparação que controla esta composição realiza-se dentro de cada setor, onde o método supera o respetivo valor de referência nos cinco. A margem absoluta é maior no setor mais abundante, com +0,283 na tecnologia; nos setores escassos, onde o valor de referência ronda 0,072, o método obtém várias vezes esse valor com margem absoluta menor. O alcance é o das alternativas avaliadas: se a seleção pudesse usar o setor conhecido da consulta, bastaria filtrar por esse setor para satisfazer o rótulo, desde que existissem candidatos suficientes. A análise por setor não mede vantagem semântica sobre esse filtro.

Duas verificações adicionais delimitam a resposta. Sobre o corpus histórico completo, com aproximadamente oitenta mil notícias de seis anos, a precisão sobe para 0,595. O valor de

referência sobe também, e mais depressa, pelo que a margem desce de $+0,274$ para $+0,262$. O método não se degrada com a escala, nem melhora com ela. Exigir que o precedente seja anterior à consulta reduz a precisão para 0,513 e o valor de referência para 0,259, com a margem a variar 0,008. O método conserva a vantagem sob esta restrição de anterioridade. O teste não impõe a maturação de oito dias usada em produção e, por isso, não valida integralmente a disponibilidade dos desfechos.

A segunda ressalva tem consequências diretas sobre o produto. A recuperação identifica tema e não direção: a concordância entre o sentido do movimento da notícia de consulta e o dos precedentes situa-se em 0,708 contra um valor de acaso de 0,688, uma diferença de 0,020. Duas notícias podem tratar do mesmo assunto e o preço evoluir em sentidos opostos. O resultado é coerente com o que a forma semiforte da hipótese dos mercados eficientes conduziria a esperar (Fama 1970), segundo a qual a informação pública se encontra já refletida no preço, sem que o trabalho a teste ou nela se apoie para estabelecer qualquer conclusão. A consequência prática é apresentar os precedentes individualmente, com data e desfecho. O alerta histórico reproduzido na Figura 4.6 inclui também uma média, que resume aqueles casos e não constitui previsão para a notícia recebida.

Uma delimitação final respeita ao rótulo. A pertença ao mesmo setor aproxima a relevância de forma verificável, sem coincidir com a propriedade que se pretendia medir. A linha de base lexical é a forma mais elementar da sua família, sem ponderação pela raridade dos termos nem normalização pelo comprimento. Os dezassete pontos percentuais de vantagem medem a distância a um ponto de partida, e não a uma função de ordenação afinada (Robertson e Zaragoza 2009).

6.2.3 Triagem de notícias

A resposta à QI3 é negativa. Nenhuma variante que incorpora o texto do título supera uma linha de base construída apenas com a volatilidade dos vinte dias anteriores, com 0,496 de PR-AUC contra 0,542, e o índice de Brier acompanha a mesma ordenação. O resultado resiste a três verificações. A primeira repete a comparação concedendo ao texto as melhores condições disponíveis, e eleva o seu melhor valor para 0,533, sem alcançar a linha de base. A segunda reamostra por grupos constituídos pela empresa e pelo dia, e mantém o intervalo a excluir zero. A terceira repete a medição para nove combinações alternativas de limiar e horizonte do rótulo, e a volatilidade iguala ou supera o modelo com texto nas nove.

A resposta ganhou precisão no decurso do trabalho e essa precisão altera o que dela se retira. As comparações anteriores colocam as representações lado a lado e respondem, por conseguinte, à pergunta sobre qual delas é melhor. A pergunta com maior utilidade para quem constrói um sistema é distinta e consiste em determinar se o texto acrescenta ao que já é conhecido. Medida sobre a tabela de consulta por empresa, que contém tudo o que o modelo conhece da empresa e nada da notícia, a resposta é afirmativa: o título acrescenta $+0,012$ de PR-AUC, com intervalo entre $+0,004$ e $+0,020$, que exclui zero. É a única ocasião em que uma representação de texto apresenta um acréscimo detetável nesta tarefa.

O valor situa-se abaixo do limite de 0,02 que o Capítulo 5 fixou antes das medições. O acréscimo observado fica abaixo desse critério prático; não estabelece um limite garantido para o efeito do texto.

Três medições impedem que este acréscimo reabra o veredicto. A soma não supera a volatilidade isolada, e o intervalo da diferença contém zero. O acréscimo não sobrevive à métrica que descreve o produto: a precisão dentro do orçamento de cinco alertas por dia

permanece em 0,662 com e sem texto. A ordenação dentro de cada empresa mantém-se ao nível do acaso. Estas medições não demonstram ganho operacional do texto: o rótulo é comum a todas as notícias de uma empresa no mesmo dia, pelo que a métrica avalia a seleção de dias de empresa e não a distinção entre títulos desse dia.

Existe uma linha de investigação estabelecida que utiliza texto para antecipar movimentos de preço (Ding et al. 2015; Xing, Cambria e Welsch 2018), e este resultado não a contradiz. A diferença não reside na dimensão do texto, uma vez que Ding et al. (2015) operam igualmente sobre títulos, mas no tratamento que lhe é dado. Aqueles autores extraem estruturas de acontecimento e treinam uma rede para prever a direção do movimento. Aqui os títulos são comparados por semelhança, e a direção nunca é objeto de previsão. Os corpora e os horizontes de avaliação diferem igualmente. A afirmação que este trabalho sustenta é mais estreita do que uma refutação: sob esta restrição de dados e com esta família de métodos, o sinal textual nada acrescenta ao que a volatilidade recente já indicava. O alcance do resultado limita-se, por isso, a um regime de recursos e a uma escolha de representação, e não se estende à linguagem.

Existe, ainda assim, uma leitura teórica que o enquadra e que se enuncia com a mesma cautela. A forma semiforte da hipótese dos mercados eficientes (Fama 1970) sustenta que a informação publicamente disponível se encontra já refletida no preço. Se assim for, um título público não tem, no momento em que é lido, informação que os preços recentes não contenham, e o resultado obtido é o que essa hipótese conduziria a esperar. A condição de recursos deste trabalho agrava a expectativa em vez de a atenuar: entre a publicação de uma notícia e a sua deteção por fontes gratuitas decorrem 353 minutos de mediana, intervalo durante o qual qualquer reação do mercado já ocorreu. O sistema observa, por construção, informação que deixou de ser nova.

Esta leitura é um enquadramento, sem estatuto de conclusão. O trabalho não testa a hipótese dos mercados eficientes, e um resultado negativo obtido com uma família de métodos sobre um corpus concreto não a confirma; confirmá-la exigiria um desenho que este não tem. O que a leitura acrescenta é a razão pela qual o resultado é menos surpreendente do que a hipótese inicial supunha, e por que motivo a sua correção mais provável não está na representação do texto mas no atraso com que ele chega.

6.2.4 Comparabilidade de materialidade

A resposta é **não**, e é negativa nas duas metades da pergunta. O ajuste contrastivo do codificador não melhora a comparabilidade de materialidade dos precedentes recuperados: o braço treinado sobre a magnitude obtém 2,185 pontos percentuais contra 2,173 do modelo sem ajuste, ou seja um valor pior, e o treinado sobre a direção obtém 2,157. As duas diferenças são cerca de um quinto do desvio entre repetições do próprio braço. E o ajuste tem um custo que a medição separa: a precisão@5 por setor desce cerca de 0,026 nos dois braços, com o mesmo sinal e acima da dispersão.

O que distingue este resultado de uma montagem que falhou é o diagnóstico que o precede. A primeira tentativa colapsou o codificador, e foi descartada sem que as suas métricas fossem lidas; os dois braços que produziram os valores acima deslocaram substancialmente o espaço face ao modelo de partida e preservaram a geometria das semelhanças. Treinaram, portanto, e o que não se confirma é a hipótese.

A comparação entre os dois braços era a parte da experiência destinada a separar magnitude de direção, e não encontrou a assimetria que a motivou: os dois são praticamente

indistinguíveis entre si, tanto no diagnóstico como nas duas medidas. A conjectura de que a magnitude seria parcialmente aprendível do texto onde a direção não o é permanece, por conseguinte, sem apoio nesta montagem.

A consequência para o sistema é a de manter o que já fazia. A base de casos organiza-se por tema, e o alerta declara que a semelhança é de tema; este resultado estabelece que, por esta via, não é possível acrescentar-lhe a garantia de que a magnitude do precedente é comparável. Fica assim reforçada a decisão descrita na Secção 6.2.2 de apresentar os casos um a um em vez de os resumir por uma média.

6.3 Objetivos alcançados

Dos quatro objetivos enunciados na Secção 1.3, três encontram-se integralmente cumpridos e um cumprido com a ressalva descrita adiante.

O primeiro objetivo, construir o sistema completo desde a aquisição de dados até à entrega do alerta, está cumprido. Os dois gatilhos funcionam de ponta a ponta em produção, sobre fontes gratuitas, e o percurso de um acontecimento está documentado no Capítulo 4 com os valores de um caso real.

O segundo objetivo, avaliar os componentes com linhas de base transparentes, está cumprido para as três técnicas em que existe um referente externo. Num dos casos foi além do previsto: o detetor foi comparado não apenas com uma regra de limiar fixo, mas também com dois métodos aprendidos. A decomposição do movimento constitui a ressalva: não existe verdade de terreno contra a qual medir a exatidão de uma repartição, pelo que se mediu o que nela permanece falsificável, correspondente à qualidade do ajuste e à capacidade de discriminar. Ficaram por realizar comparações internas que seriam possíveis, como a do modelo de um fator contra o de dois fatores ou a das sensibilidades brutas contra as encolhidas.

O terceiro objetivo, garantir que as explicações apresentadas são fiéis ao que o sistema calculou, está cumprido por construção, sem depender de verificação posterior. Cada valor exibido provém do objeto que o calculou, e o texto é composto a partir dessas peças, pelo que não é possível ao alerta enunciar um valor distinto do que o sistema obteve. A fidelidade é, contudo, uma propriedade do sistema, e não da relação entre o sistema e quem o lê; a utilidade das explicações para um investidor particular não foi medida, e a Secção 6.4 trata essa ausência.

O quarto objetivo, reportar os resultados obtidos incluindo os que não confirmem as expectativas iniciais, está cumprido. A resposta negativa à Q13 aparece na Figura 6.2 e no corpo deste capítulo com o mesmo destaque das restantes, acompanhada das três verificações a que foi submetida e das três ocasiões em que uma técnica mais simples superou uma mais sofisticada.

6.4 Limitações

Esta secção enumera as limitações do trabalho por ordem de importância. A Tabela 6.1 apresenta-as em conjunto, com o trabalho que encerraria cada uma e a natureza do respetivo custo; o texto que se segue desenvolve as quatro de maior consequência e resume as restantes. A maioria está quantificada. Duas não o estão por natureza: a ausência de estudo controlado é uma ausência e não uma medida, e a distância entre cada rótulo e a propriedade que aproxima só seria mensurável contra uma anotação humana que não existe.

Tabela 6.1: As onze limitações, por ordem de importância, com o trabalho que encerraria cada uma e a natureza do custo desse trabalho. As duas que dependem de tempo de calendário são as que exigem julgamento humano, e são também as duas de que as restantes mais dependem: enquanto não existir uma amostra anotada por pessoas, nem a utilidade das explicações nem a qualidade dos rótulos deixam de ser aproximações.

Limitação	O que a encerra	Custo
Nenhum estudo controlado com pessoas	Executar o protocolo desenhado, com seis a dez participantes	tempo de calendário
A pontuação é quase constante dentro de cada empresa	Entradas que variem de um título para o seguinte	reduzido; re-treina
O rótulo pode favorecer a linha de base vencedora	Reconstruir o alvo com sensibilidades estimadas	reduzido; re-treina
Os rótulos são aproximações verificáveis	Anotar uma amostra com julgamento humano	tempo de calendário
O alerta afirma mais evidência do que a que possui	Medir o impacto por notícia e não por dia	dados intradiários
A composição por empresa varia entre os três blocos	Uma divisão de composição constante	reduzido; reavalia
Apenas o título é lido, e não o corpo do artigo	Recolher e representar o texto integral	dados novos
A repartição nem sempre está bem estimada	Comparar um fator com dois; o ajuste já é exibido	reduzido; reavalia
A deriva é medida e não corrigida	Re-treinar com o registo de produção	reduzido; re-treina
A cobertura das fontes é incompleta e desigual	Acrescentar fontes, ou declarar o limite	fora de controlo
As três causas do atraso não estão separadas	Registar quando cada item surge no fluxo	instrumentação

Não foi realizado um estudo controlado com utilizadores. Esta é a lacuna de maior peso. O sistema assenta na hipótese de que uma explicação acompanhada da respetiva evidência conduz um não especialista a uma decisão melhor, e essa hipótese não foi submetida a um desenho experimental. O protocolo existe, com participantes, tarefas e critérios definidos, e não foi executado. O que existe, e está reportado na Secção 5.7.5, é retorno recolhido em contexto real: leitores do canal público classificam os alertas que recebem, sob regras de análise fixadas antes do primeiro voto, e a recolha prossegue. A literatura é explícita quanto ao peso desta ausência: afirmações de interpretabilidade exigem avaliação e não se estabelecem por declaração (Doshi-Velez e B. Kim 2018). A razão não é formal. O efeito de uma explicação sobre uma pessoa não é dedutível da sua construção: sabe-se que a confiança em sistemas automáticos falha nos dois sentidos, com o utilizador a ignorar um aviso correto ou a aceitar um aviso incorreto (J. D. Lee e See 2004), e que a mera presença de uma explicação aumenta a aceitação de respostas erradas (Bansal et al. 2021). O sistema foi construído para produzir confiança apropriada, apresentando evidência em vez de emitir um veredicto, mas que o consiga permanece uma hipótese. Na ausência do estudo, os dois modos de falha são indistinguíveis nos registos: um alerta ignorado e um alerta indevidamente acreditado produzem a mesma ausência de dados.

A distinção entre as duas coisas determina o que cada uma permite afirmar. O retorno do canal é observacional: vota quem quer, o que desloca a amostra para os extremos; nenhum grupo recebeu a variação de preço sem a explicação que a acompanha, pelo que nada atribui a utilidade à explicação em si; e o canal é público, pelo que se desconhece se quem responde pertence ao público que este trabalho assume. O que esses votos medem é utilidade percebida por quem se dispôs a responder. A hipótese fundadora diz respeito a decisão melhor, que é outra quantidade, e é essa que permanece por testar.

Duas observações da literatura alteram o peso desta ausência, em sentidos opostos, e ambas devem constar. A primeira agrava-o. A hipótese fundadora não é apenas indemonstrada neste trabalho: tem contra si medições publicadas. Waa et al. (2021) não encontraram diferença entre a explicação por exemplos e a ausência de explicação, e Cau et al. (2023) encontraram, numa tarefa de negociação de ações com não-especialistas, desempenho inferior do estilo indutivo face aos estilos abductivo e dedutivo quando o modelo está confiante. Enquanto o estudo não se fizer, a posição honesta não é «por demonstrar», é «por demonstrar, e com evidência publicada a apontar em sentido contrário». A Secção 2.7 enuncia a razão pela qual este trabalho pode ainda assim esperar desfecho diferente — entrega o cálculo subjacente, e é a falta dele que aqueles autores responsabilizam pelo resultado — mas uma expectativa fundamentada continua a ser uma expectativa.

A segunda situa-o. O trabalho publicado mais próximo desta classe de sistema (Muntermann 2009) avaliou o artefacto por simulação e remeteu igualmente o estudo com utilizadores para investigação futura, quinze anos antes deste. Na revisão que sustenta o Capítulo 2 não se encontrou, nesta classe de sistema, nenhum estudo que estabeleça por via causal que alertas acompanhados de evidência melhoram a decisão de um não especialista. Isto não desculpa a ausência nem a torna menos limitação, mas altera o que ela significa: não é uma etapa que este trabalho tenha saltado, é uma etapa que a área ainda não deu.

O modelo implantado não podia executar a função que lhe foi atribuída. A variante colocada em produção como porta de decisão recebe sete entradas de nível de empresa, uma de nível do dia e uma única que varia de um título para o seguinte, correspondente ao comprimento do título. A sua pontuação é, por aritmética e não por acidente, quase

constante dentro de cada empresa: a amplitude média dentro de cada empresa é de 0,072 e a amplitude entre as medianas das empresas é de 0,392. Em 48% dos títulos distintos, o resultado estava determinado antes de o título ser lido.

Duas afirmações têm de ser separadas, uma vez que apenas uma corresponde a erro. O resultado da QI3 mantém-se, porque a variante com texto dispunha de trezentos e oitenta e quatro números por título e ainda assim perdeu. A decisão de produto estava errada, e a razão é de método: a escolha foi tomada por uma métrica que interroga a ordenação do conjunto completo, quando o produto necessitava de selecionar oportunidades sob um orçamento diário. O rótulo por empresa e dia não permite avaliar a distinção entre dois títulos publicados nessa mesma unidade.

O sistema foi alterado e o modelo deixou de constituir porta para passar a critério de ordenação. Essa alteração não está validada. Sobre as 825 decisões maturadas em produção, agrupadas nas 239 unidades independentes que o rótulo admite, a capacidade de ordenação é de 0,486, com intervalo entre 0,403 e 0,571, que contém o acaso. A ordenação é a utilização menos indefensável do modelo, e não uma utilização demonstrada.

Esta falha pertence a uma classe descrita na literatura de sistemas de aprendizagem em produção. D. Sculley et al. (2015) identificam um custo que não figura em nenhuma métrica de qualidade, e que vem de dependências de dados e do emaranhamento entre componentes: a validade de uma peça depende de suposições sobre outra que nunca foram enunciadas. O modelo foi avaliado isoladamente, sobre a distribuição do conjunto de treino, e implantado atrás de dois filtros que a alteram. Nenhum teste falhou e nenhum registo assinalou anomalia. Um componente aprendido é avaliado onde é treinado e é útil onde é colocado, e quando esses dois lugares diferem a diferença não se anuncia.

O rótulo pode favorecer a linha de base vencedora. O rótulo desconta o movimento do mercado assumindo sensibilidade unitária, pelo que o seu erro não é aleatório: é maior nas ações mais sensíveis ao mercado, que são tipicamente as mais voláteis. A linha de base vencedora é exatamente a volatilidade. Com o que está medido não é possível separar a hipótese de a volatilidade prever melhor a materialidade da hipótese de a volatilidade prever melhor o erro do rótulo. Tanto o nível como a ordenação das métricas da QI3 ficam por isso condicionados ao rótulo utilizado.

O alerta afirma mais evidência do que a que possui. Quando exibe três precedentes concordantes quanto ao sentido do movimento, o alerta apresenta essa concordância como resultante de três observações. O impacto é, porém, medido por par constituído pela empresa e pelo dia, pelo que três títulos da mesma empresa no mesmo dia partilham o valor por construção. Sobre os 247 alertas com precedentes entregues, em 36,8% os casos exibidos assentam em menos dias distintos do que o número de casos apresentados, e em 11,3% correspondem todos ao mesmo dia; dos 120 alertas que afirmam unanimidade, 23,3% apoiam-se num único dia. A formulação do texto foi corrigida para contar dias e não títulos, o que torna a afirmação verdadeira. A causa subsiste: enquanto o impacto for medido por dia, duas notícias do mesmo dia não constituem duas observações independentes.

As restantes sete, em síntese. Os rótulos são aproximações: relevância é aproximada pela pertença ao mesmo setor, materialidade pela ocorrência de um movimento acima de um limiar, e raridade por um percentil dos retornos da própria empresa. As três são objetivas e verificáveis, e nenhuma corresponde exatamente à propriedade que se pretendia medir. A

dependência de aproximações não é particularidade deste trabalho: em domínios financeiros vizinhos, como a deteção de fraude, os métodos não supervisionados ocupam posição central pela escassez de anomalias rotuladas (Ahmed, Mahmood e Islam 2016).

A composição por empresa varia entre os três blocos. O treino contém treze empresas e o teste nove: oito são comuns, cinco só aparecem no treino e uma só no teste. Esta última representa 17,1% das linhas de teste; as empresas conhecidas representam os restantes 82,9%. Existe sobreposição substancial, mas as frequências mudam. A comparação não isola o efeito dessa mudança do desempenho do modelo, nem demonstra generalização uniforme a empresas novas.

As notícias são lidas apenas ao nível do título. O sistema representa o título e não o corpo do artigo, o que limita o que a representação de texto pode captar e constitui explicação plausível, ainda que não confirmada, para o resultado negativo da QI3. As revisões de análise textual em finanças descrevem trabalhos que operam sobre documentos completos (Kearney e S. Liu 2014), e um título é a parte do documento onde mais informação foi descartada.

A repartição de um movimento nem sempre está bem estimada. A soma das três parcelas verifica-se por construção e não valida coisa alguma. A medida informativa é o coeficiente de determinação na janela de estimação, cuja mediana foi de 0,460 e que numa das dezassete empresas assumiu valor negativo, o que significa que naquela janela o ajuste não descrevia os dados. A interface passou a exibir esse coeficiente ao lado das três parcelas, comparado com a mediana da lista vigiada, e a nomear em palavras o caso em que o ajuste não descreve os dados. A estimativa não melhora por ser exibida, e a limitação subsiste; o que deixa de suceder é o leitor receber uma repartição sem meio de saber quando ela é fraca. O encolhimento ponderado pela precisão (Vasicek 1973) limita o dano de uma estimativa má sem a transformar numa estimativa boa.

A deriva é medida e não corrigida. Os parâmetros foram estimados entre 2018 e 2023 e não voltaram a ser ajustados. Entre o bloco de treino e o de teste, o índice de estabilidade populacional situa a volatilidade dos vinte dias na banda de deslocamento significativo, com 0,281, que é a entrada de que o modelo mais depende. A literatura de deriva de conceito trata deste problema, com uma taxonomia da mudança e estratégias de deteção e adaptação (Gama et al. 2014); aqui existe a deteção, sem a adaptação. A arquitetura que a forneceria está definida na Secção 4.7, com gatilho condicional, janela deslizante e porta de promoção, e não foi executada: a limitação é de execução e não de desenho.

A cobertura das fontes é incompleta e desigual. Existia pelo menos uma notícia relevante em 88,5% dos 417 dias considerados invulgares pelo detetor, e a empresa pior coberta situa-se nos 50%. Nos dias restantes nenhuma alteração ao sistema produz efeito, uma vez que uma notícia não associada à empresa pela fonte não chega a entrar no percurso. O valor é um limite superior: estabelece que existia uma notícia, e não que tenha chegado a notícia adequada.

O atraso está na descoberta, e as suas três causas não estão separadas. Sobre os 278 alertas com hora de publicação e de envio, a mediana entre a publicação e a deteção é de 353 minutos, e a mediana entre a deteção e a entrega é de 5 segundos. A passagem de um agendador de melhor esforço para um ciclo de sessenta segundos não reduziu o atraso, o que exclui a cadência de consulta como explicação. Restam três causas que o histórico não separa, e apenas uma delas, a de a fonte listar tarde, seria atenuada por um serviço pago; as outras duas subsistem com qualquer fonte.

6.5 Trabalho futuro

As linhas enunciadas nesta secção derivam das limitações da secção anterior, segundo a correspondência apresentada na Tabela 6.1, e estão ordenadas pela relação entre o efeito esperado e o custo. Uma lista de trabalho futuro que não derive de limitações medidas constitui uma justificação sob outra forma. A Figura 6.4 agrupa-as pelo que cada uma exige antes de poder ser executada.

1. **Executar o estudo com utilizadores.** Seis a dez participantes, com sessões de aproximadamente quinze minutos, comparando a leitura de um facto isolado com a leitura do alerta completo. Encerra a afirmação central do trabalho, que é a de que a evidência apresentada junto do alerta conduz a uma decisão melhor. Partilha com a construção de um alvo anotado, terceiro item desta lista, a propriedade de nenhum meio computacional o acelerar, uma vez que ambos dependem de julgamento humano. Outras afirmações permanecem por verificar independentemente dele, entre as quais a qualidade dos três rótulos, a utilidade do modelo sobre a população que efetivamente observa e a estabilidade do resultado entre períodos.
2. **Dotar o modelo de decisão de entradas que variem com a notícia.** É a correção direta da limitação de maior consequência técnica, e o seu custo é reduzido, dado que as duas quantidades mais evidentes já são calculadas pelo sistema: a semelhança do melhor precedente recuperado e a concordância de direção entre os precedentes. Ao contrário da volatilidade e do setor, ambas variam de um título para o seguinte.
3. **Construir um alvo com julgamento humano.** A anotação de uma amostra de dias, identificando quais das notícias hoje suprimidas deveriam passar e quais das que passam nada acrescentam, forneceria pela primeira vez um alvo real para otimizar, em substituição do ajuste de constantes contra uma aproximação. A mesma amostra permitiria estimar a qualidade dos três rótulos utilizados.
4. **Reconstruir o rótulo com sensibilidades estimadas.** O rótulo da triagem desconta o movimento do mercado assumindo sensibilidade unitária, o que introduz um erro correlacionado com a volatilidade da empresa, que é precisamente a linha de base vencedora. Refazer o alvo com as sensibilidades encolhidas descritas na Secção 3.4 e repetir as seis famílias de modelos determinaria se a ordenação obtida resiste a uma definição alternativa de materialidade.
5. **Ler o corpo dos artigos e não apenas o título.** É a hipótese mais direta para explicar o resultado negativo da QI3 e é verificável com o protocolo já construído, exigindo apenas a recolha do texto integral.
6. **Detetar histórias repetidas por significado.** A supressão de repetições assenta hoje em sobreposição de vocabulário, e a sua realização por semelhança utilizaria a técnica de que o sistema já dispõe. O ponto é mais relevante do que a sua dimensão técnica sugere: se o investidor particular adquire os ativos que lhe captam a atenção (Barber e Odean 2008), um sistema que comunica a mesma história três vezes não está a informar, mas a amplificar o mesmo estímulo.
7. **Eliminar a assimetria de referencial do retorno do próprio dia.** A entrada corresponde, no treino, ao movimento completo do dia da notícia, e em produção à última barra disponível no momento da pontuação. Substituí-la pelo retorno acumulado até à publicação, ou, de forma mais conservadora, pelo retorno da véspera, elimina a diferença e permite reportar o desempenho sob um referencial único. O efeito na

comparação entre modelos permanece por medir: exige reconstruir as entradas e repetir o treino e a avaliação.

8. **Agrupar os precedentes por par de empresa e dia antes da seleção.** A correção aplicada ao texto do alerta tornou a afirmação verdadeira sem remover a causa. Seleccionar os candidatos depois de agrupar por dia, exibindo de cada dia apenas o título mais próximo, elimina na origem a possibilidade de um dia observado três vezes ser apresentado como três casos concordantes.
9. **Expor a qualidade do ajuste na própria mensagem.** A repartição de um movimento é exibida com a mesma confiança quando o coeficiente de determinação da janela é elevado e quando é negativo. Apresentá-lo junto da repartição, e acrescentar uma nota explícita abaixo de um limiar mínimo, converte uma limitação hoje declarada apenas no documento numa propriedade observável por quem lê o alerta.
10. **Re-treinar o modelo com o registo de produção.** A deriva está medida e os rótulos novos derivam dos preços, pelo que a execução é possível. O impedimento não é técnico, uma vez que um re-treino alteraria os valores reportados neste documento e exigiria tempo de avaliação próprio.




Figura 6.4: As dez linhas de trabalho futuro, agrupadas pelo que cada uma exige antes de poder ser executada. Sete operam sobre componentes que o sistema já possui e dependem apenas de trabalho técnico. Uma aguarda tempo de observação, que começou a decorrer em setembro de 2026. Duas exigem julgamento humano e são as únicas que nenhum meio computacional acelera, o que as coloca no caminho crítico apesar de não serem as de maior custo técnico. A numeração é a da lista desta secção, que está ordenada pela relação entre o efeito esperado e o custo.

Um caminho foi considerado e não seguido, e as razões ficam registadas por serem necessárias a quem retome o trabalho. A predição conformal permite devolver conjuntos de

respostas com uma garantia livre de distribuição (Angelopoulos e Bates 2023; Vovk, Gammernan e Shafer 2005), o que se ajusta a uma ferramenta que recusa afirmar mais do que aquilo que sabe. Duas razões afastaram-na. A primeira é que a garantia é marginal, valendo em média sobre os casos e não caso a caso, que é precisamente a leitura que um utilizador não especializado faria.

A segunda é mais determinante: a garantia exige permutabilidade entre calibração e teste, e estes dados constituem uma série temporal, na qual os títulos chegam por ordem. É a mesma suposição que este trabalho recusa ao dividir o conjunto por data e com embargo. A aplicação do método sem tratamento desse ponto produziria intervalos com uma garantia que os dados não sustentam, substituindo um valor honesto por um valor com aparência de rigor.

Três direções técnicas ficam igualmente registadas, e são de outra natureza. Não derivam de limitações medidas, pelo que não integram a lista anterior; decorrem de decisões de implementação que a Secção 2.4 enuncia e que o trabalho não teve razão para revisitar.

A primeira é a reordenação por codificador cruzado. A recuperação compara cada par de frases através de vetores calculados uma única vez, opção que a escala da base de casos impõe. Um codificador que processe as duas frases em conjunto produz uma comparação mais fina e é impraticável sobre dezenas de milhares de casos, mas praticável sobre os vinte primeiros resultados de uma consulta. O protocolo de avaliação já construído mede exatamente essa lista.

A segunda é a aprendizagem de ordenação sob restrição de orçamento. O problema que o produto resolve não é classificar cada notícia isoladamente, mas escolher cinco por dia, e a métrica principal do Capítulo 5 interroga a primeira formulação. Existe uma família de métodos dedicada à segunda, e a diferença entre as duas está medida neste trabalho sem ser nomeada: é a distância entre a PR-AUC sobre o conjunto completo e a precisão dentro do orçamento.

A terceira é a substituição da procura exaustiva por um índice aproximado (Johnson, Douze e Jégou 2021), referida na Secção 2.4 como caminho de crescimento. Com a dimensão atual da base a procura exata é praticável e exata, pelo que a substituição não se justifica hoje; justificar-se-ia a partir de uma ordem de grandeza acima.

6.6 Considerações finais

O trabalho partiu de três perguntas que um investidor particular formula perante um movimento de preço, e a que as ferramentas gratuitas não respondem. Se o movimento é invulgar. Se a origem é a empresa ou o mercado. E se existem precedentes com desfecho conhecido. Construiu-se um sistema que responde às três com evidência verificável e sem emitir previsões. Três técnicas foram comparadas com alternativas mais simples; na decomposição mediu-se a qualidade do ajuste.

O resultado com maior valor informativo é negativo. A hipótese de que o texto das notícias transportaria informação ausente dos preços não foi confirmada sobre este corpus. A sua investigação produziu um diagnóstico de alcance superior ao da questão que a originou. O componente aprendido foi avaliado sobre uma distribuição e implantado sobre outra, e a métrica pela qual foi selecionado formulava uma pergunta distinta da que o produto necessitava. Nenhum teste automático assinalou a discrepância, porque cada componente cumpria o seu contrato e o que estava errado era uma suposição sobre a ligação entre eles.

A restrição fundadora do trabalho, segundo a qual o sistema não produz previsões de preço, revelou-se a decisão de maior alcance. Determina o que pode ser afirmado: toda a afirmação do sistema é confirmável contra o registo no momento em que é lida. Determina a forma da explicação, que permite inspecionar os casos individuais e os seus desfechos. E determina o critério de avaliação, que incide sobre a capacidade de identificar o que é invulgar e não sobre a de antecipar. Um sistema que apresente evidência em lugar de veredictos entrega menos do que um sistema que anuncie direções, e entrega apenas o que consegue sustentar.




Figura 6.5: O limite exato da afirmação. À esquerda, as três propriedades que o sistema demonstra e que se verificam por inspeção do que ele produz. À direita, a proposição que o trabalho não testou: que apresentar a evidência junto do alerta conduza a uma decisão melhor. A separação não é uma reserva de cortesia, uma vez que a segunda é a hipótese que motivou o trabalho, e distingui-la do que ficou demonstrado é o que impede que a primeira seja lida como se a segunda estivesse provada.

A contribuição enuncia-se, por isso, no seu nível exato. O que este trabalho estabelece é que o sistema está tecnicamente preparado para sustentar explicações assentes em evidência histórica verificável: cada quantidade apresentada provém do componente que a calculou, é confrontável com o registo no momento em que é lida, e a política que decide o silêncio está documentada e medida. O que este trabalho não estabelece é que essa forma de explicação conduza o investidor particular a uma decisão melhor. Essa é a hipótese fundadora, permanece por testar, e o seu teste é o primeiro item da secção anterior. A Figura 6.5 apresenta a separação.

Bibliografia

- Aamodt, Agnar e Enric Plaza (1994). «Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches». Em: *AI Communications* 7.1, pp. 39–59. doi: 10.3233/AIC-1994-7104.
- Adadi, Amina e Mohammed Berrada (2018). «Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)». Em: *IEEE Access* 6, pp. 52138–52160. doi: 10.1109/ACCESS.2018.2870052.
- Ahmed, Mohiuddin, Abdun Naser Mahmood e Md. Rafiqul Islam (2016). «A Survey of Anomaly Detection Techniques in Financial Domain». Em: *Future Generation Computer Systems* 55, pp. 278–288. doi: 10.1016/j.future.2015.01.001.
- Ancker, Jessica S. et al. (2017). «Effects of Workload, Work Complexity, and Repeated Alerts on Alert Fatigue in a Clinical Decision Support System». Em: *BMC Medical Informatics and Decision Making* 17.1, p. 36. doi: 10.1186/s12911-017-0430-8.
- Angelopoulos, Anastasios N. e Stephen Bates (2023). «Conformal Prediction: A Gentle Introduction». Em: *Foundations and Trends in Machine Learning* 16.4, pp. 494–591. doi: 10.1561/2200000101.
- Bansal, Gagan et al. (2021). «Does the Whole Exceed its Parts? The Effect of AI Explanations on Complementary Team Performance». Em: *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. doi: 10.1145/3411764.3445717.
- Barber, Brad M. e Terrance Odean (2008). «All That Glitters: The Effect of Attention and News on the Buying Behavior of Individual and Institutional Investors». Em: *The Review of Financial Studies* 21.2, pp. 785–818. doi: 10.1093/rfs/hhm079.
- Barberis, Nicholas e Richard Thaler (2003). «A Survey of Behavioral Finance». Em: *Handbook of the Economics of Finance*. Ed. por George M. Constantinides, Milton Harris e René M. Stulz. Vol. 1. Elsevier. Cap. 18, pp. 1053–1128. doi: 10.1016/S1574-0102(03)01027-6.
- Barredo Arrieta, Alejandro et al. (2020). «Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI». Em: *Information Fusion* 58, pp. 82–115. doi: 10.1016/j.inffus.2019.12.012.
- Bertrand, Astrid, James R. Eagan e Winston Maxwell (2023). «Questioning the Ability of Feature-Based Explanations to Empower Non-Experts in Robo-Advised Financial Decision-Making». Em: *Proceedings of the 2023 ACM Conference on Fairness, Accountability, and Transparency (FAccT '23)*. Association for Computing Machinery, pp. 943–958. doi: 10.1145/3593013.3594053.
- Blume, Marshall E. (1971). «On the Assessment of Risk». Em: *The Journal of Finance* 26.1, pp. 1–10. doi: 10.1111/j.1540-6261.1971.tb00584.x.
- Bollerslev, Tim (1986). «Generalized Autoregressive Conditional Heteroskedasticity». Em: *Journal of Econometrics* 31.3, pp. 307–327. doi: 10.1016/0304-4076(86)90063-1.
- Breunig, Markus M. et al. (2000). «LOF: Identifying Density-Based Local Outliers». Em: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104. doi: 10.1145/342009.335388.

- Brown, Stephen J. e Jerold B. Warner (1985). «Using Daily Stock Returns: The Case of Event Studies». Em: *Journal of Financial Economics* 14.1, pp. 3–31. doi: 10.1016/0304-405X(85)90042-X.
- Cahill, Daniel, Zhangxin Liu e Lee A. Smales (2025). «Investigating proxies for retail investor attention in financial markets». Em: *Accounting & Finance* 65.1, pp. 521–550. doi: 10.1111/acfi.13338.
- Cambridge Centre for Alternative Finance (2026). *Global AI in Financial Services Report: Adoption, Impact and Risks*. Cambridge Judge Business School, University of Cambridge. url: <https://www.jbs.cam.ac.uk/faculty-research/centres/alternative-finance/publications/2026-global-ai-in-financial-services-report/> (acedido em 21/06/2026).
- Cardillo, Giovanni e Helen Chiappini (2024). «Robo-advisors: A Systematic Literature Review». Em: *Finance Research Letters* 62, p. 105119. doi: 10.1016/j.fr1.2024.105119.
- Cau, Federico Maria et al. (2023). «Supporting High-Uncertainty Decisions through AI and Logic-Style Explanations». Em: *Proceedings of the 28th International Conference on Intelligent User Interfaces (IUI '23)*. Association for Computing Machinery, pp. 251–263. doi: 10.1145/3581641.3584080.
- Chandola, Varun, Arindam Banerjee e Vipin Kumar (2009). «Anomaly Detection: A Survey». Em: *ACM Computing Surveys* 41.3, 15:1–15:58. doi: 10.1145/1541880.1541882.
- D. Sculley et al. (2015). «Hidden Technical Debt in Machine Learning Systems». Em: *Advances in Neural Information Processing Systems 28 (NIPS 2015)*. Curran Associates, Inc., pp. 2503–2511. url: https://papers.nips.cc/paper_files/paper/2015/hash/86df7dcfd896fcdf2674f757a2463eba-Abstract.html.
- D'Acunto, Francesco, Nagpurnanand Prabhala e Alberto G. Rossi (2019). «The Promises and Pitfalls of Robo-Advising». Em: *The Review of Financial Studies* 32.5, pp. 1983–2020. doi: 10.1093/rfs/hhz014.
- Da, Zhi, Joseph Engelberg e Pengjie Gao (2011). «In Search of Attention». Em: *The Journal of Finance* 66.5, pp. 1461–1499. doi: 10.1111/j.1540-6261.2011.01679.x.
- Devlin, Jacob et al. (2019). «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». Em: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, pp. 4171–4186. doi: 10.18653/v1/N19-1423.
- Ding, Xiao et al. (2015). «Deep Learning for Event-Driven Stock Prediction». Em: *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 2327–2333. url: <https://www.ijcai.org/Abstract/15/329>.
- Dong, Zihan, Xinyu Fan e Zhiyuan Peng (2024). «FNSPID: A Comprehensive Financial News Dataset in Time Series». Em: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '24)*. Association for Computing Machinery, pp. 4918–4927. doi: 10.1145/3637528.3671629.
- Doshi-Velez, Finale e Been Kim (2018). «Considerations for Evaluation and Generalization in Interpretable Machine Learning». Em: *Explainable and Interpretable Models in Computer Vision and Machine Learning*. Ed. por Hugo Jair Escalante et al. The Springer Series on Challenges in Machine Learning. Cham: Springer, pp. 3–17. isbn: 978-3-319-98130-7. doi: 10.1007/978-3-319-98131-4_1.
- Du, Kelvin et al. (2024). «Explainable Stock Price Movement Prediction using Contrastive Learning». Em: *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management (CIKM '24)*. Association for Computing Machinery, pp. 529–537. doi: 10.1145/3627673.3679544.

- Engle, Robert F. (1982). «Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation». Em: *Econometrica* 50.4, pp. 987–1007. doi: 10.2307/1912773.
- Ernst, Thomas H. e Chester S. Spatt (2026). «Retail Investors and Trading Execution». Em: *Annual Review of Financial Economics*. doi: 10.1146/annurev-financial-111424-124712.
- Fama, Eugene F. (1970). «Efficient Capital Markets: A Review of Theory and Empirical Work». Em: *The Journal of Finance* 25.2, pp. 383–417. doi: 10.2307/2325486.
- Fama, Eugene F. et al. (1969). «The Adjustment of Stock Prices to New Information». Em: *International Economic Review* 10.1, pp. 1–21. doi: 10.2307/2525569.
- Friedman, Jerome H. (2001). «Greedy Function Approximation: A Gradient Boosting Machine». Em: *The Annals of Statistics* 29.5, pp. 1189–1232. doi: 10.1214/aos/1013203451.
- Gallup (2025). *What Percentage of Americans Own Stock?* url: <https://news.gallup.com/poll/266807/percentage-americans-owns-stock.aspx> (acedido em 21/06/2026).
- Gama, João et al. (2014). «A Survey on Concept Drift Adaptation». Em: *ACM Computing Surveys* 46.4, pp. 1–37. doi: 10.1145/2523813.
- Google (jun. de 2026). *Our latest Google Finance upgrades, including a new app*. url: <https://blog.google/products-and-platforms/products/search/google-finance-updates-june-2026/> (acedido em 07/08/2026).
- Guidotti, Riccardo et al. (2018). «A Survey of Methods for Explaining Black Box Models». Em: *ACM Computing Surveys* 51.5, 93:1–93:42. doi: 10.1145/3236009.
- Hevner, Alan R. et al. (2004). «Design Science in Information Systems Research». Em: *MIS Quarterly* 28.1, pp. 75–106. doi: 10.2307/25148625.
- Huang, Allen H., Hui Wang e Yi Yang (2023). «FinBERT: A Large Language Model for Extracting Information from Financial Text». Em: *Contemporary Accounting Research* 40.2, pp. 806–841. doi: 10.1111/1911-3846.12832.
- Huang, Yizheng e Jimmy Xiangji Huang (2026). «A Survey on Retrieval-Augmented Text Generation for Large Language Models». Em: *ACM Computing Surveys* 58, pp. 1–38. doi: 10.1145/3805774.
- Johnson, Jeff, Matthijs Douze e Hervé Jégou (2021). «Billion-Scale Similarity Search with GPUs». Em: *IEEE Transactions on Big Data* 7.3, pp. 535–547. doi: 10.1109/TBDATA.2019.2921572.
- Kahneman, Daniel e Amos Tversky (1979). «Prospect Theory: An Analysis of Decision under Risk». Em: *Econometrica* 47.2, pp. 263–291. doi: 10.2307/1914185.
- Kearney, Colm e Sha Liu (2014). «Textual Sentiment in Finance: A Survey of Methods and Models». Em: *International Review of Financial Analysis* 33, pp. 171–185. doi: 10.1016/j.irfa.2014.02.006.
- Kolodner, Janet L. (1991). «Improving Human Decision Making through Case-Based Decision Aiding». Em: *AI Magazine* 12.2, p. 52. doi: 10.1609/aimag.v12i2.895.
- Lee, John D. e Katrina A. See (2004). «Trust in Automation: Designing for Appropriate Reliance». Em: *Human Factors* 46.1, pp. 50–80. doi: 10.1518/hfes.46.1.50.30392.
- Lewis, Patrick et al. (2020). «Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks». Em: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. Curran Associates, pp. 9459–9474. url: <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.

- Li, Yinheng et al. (2023). «Large Language Models in Finance: A Survey». Em: *Proceedings of the Fourth ACM International Conference on AI in Finance (ICAIF '23)*. Association for Computing Machinery, pp. 374–382. doi: 10.1145/3604237.3626869.
- Lipton, Zachary C. (2018). «The Mythos of Model Interpretability». Em: *Communications of the ACM* 61.10, pp. 36–43. doi: 10.1145/3233231.
- Liu, Che-Wei, Yanzhen Chen e Ming-Hui Wen (2023). *Alert for Alerts: How Investment Price Tracking Alerts Affect Retail Investors*. SSRN Working Paper. doi: 10.2139/ssrn.4466498.
- Liu, Fei Tony, Kai Ming Ting e Zhi-Hua Zhou (2008). «Isolation Forest». Em: *2008 Eighth IEEE International Conference on Data Mining (ICDM)*, pp. 413–422. doi: 10.1109/ICDM.2008.17.
- Liu, Zhuang et al. (2020). «FinBERT: A Pre-trained Financial Language Representation Model for Financial Text Mining». Em: *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence (IJCAI-20)*. International Joint Conferences on Artificial Intelligence Organization, pp. 4513–4519. doi: 10.24963/ijcai.2020/622.
- Loughran, Tim e Bill McDonald (2011). «When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks». Em: *The Journal of Finance* 66.1, pp. 35–65. doi: 10.1111/j.1540-6261.2010.01625.x.
- Lundberg, Scott M. e Su-In Lee (2017). «A Unified Approach to Interpreting Model Predictions». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 4765–4774. url: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html.
- Manning, Christopher D., Prabhakar Raghavan e Hinrich Schütze (2008). *Introduction to Information Retrieval*. Cambridge, England: Cambridge University Press. isbn: 978-0-521-86571-5.
- Mikolov, Tomas et al. (2013). «Distributed Representations of Words and Phrases and their Compositionality». Em: *Advances in Neural Information Processing Systems 26 (NIPS 2013)*. Vol. 26. Curran Associates, Inc., pp. 3111–3119. url: https://papers.nips.cc/paper_files/paper/2013/hash/9aa42b31882ec039965f3c4923ce901b-Abstract.html.
- Miller, Tim (2019). «Explanation in Artificial Intelligence: Insights from the Social Sciences». Em: *Artificial Intelligence* 267, pp. 1–38. doi: 10.1016/j.artint.2018.07.007.
- Muntermann, Jan (2009). «Towards Ubiquitous Information Supply for Individual Investors: A Decision Support System Design». Em: *Decision Support Systems* 47.2, pp. 82–92. doi: 10.1016/j.dss.2009.01.003.
- Niculescu-Mizil, Alexandru e Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». Em: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, pp. 625–632. doi: 10.1145/1102351.1102430.
- Oh, Kyong Joo e Tae Yoon Kim (2007). «Financial Market Monitoring by Case-Based Reasoning». Em: *Expert Systems with Applications* 32.3, pp. 789–800. doi: 10.1016/j.eswa.2006.01.044.
- Pang, Guansong et al. (2021). «Deep Learning for Anomaly Detection: A Review». Em: *ACM Computing Surveys* 54.2, 38:1–38:38. doi: 10.1145/3439950.
- Peppers, Ken et al. (2007). «A Design Science Research Methodology for Information Systems Research». Em: *Journal of Management Information Systems* 24.3, pp. 45–77. doi: 10.2753/MIS0742-1222240302.
- Pennington, Jeffrey, Richard Socher e Christopher D. Manning (2014). «GloVe: Global Vectors for Word Representation». Em: *Proceedings of the 2014 Conference on Empirical*

- Methods in Natural Language Processing (EMNLP)*, pp. 1532–1543. doi: 10.3115/v1/D14-1162.
- Reimers, Nils e Iryna Gurevych (2019). «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». Em: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. doi: 10.18653/v1/D19-1410.
- Ribeiro, Marco Tulio, Sameer Singh e Carlos Guestrin (2016). «“Why Should I Trust You?”: Explaining the Predictions of Any Classifier». Em: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135–1144. doi: 10.1145/2939672.2939778.
- Robertson, Stephen e Hugo Zaragoza (2009). «The Probabilistic Relevance Framework: BM25 and Beyond». Em: *Foundations and Trends in Information Retrieval* 4.1-2, pp. 1–174. doi: 10.1561/15000000019.
- Robinhood Markets (mar. de 2025). *Introducing Robinhood Strategies, Robinhood Banking, and Robinhood Cortex*. url: <https://robinhood.com/us/en/newsroom/introducing-strategies-banking-and-cortex/> (acedido em 07/08/2026).
- Rousseeuw, Peter J. (1987). «Silhouettes: a graphical aid to the interpretation and validation of cluster analysis». Em: *Journal of Computational and Applied Mathematics* 20, pp. 53–65. doi: 10.1016/0377-0427(87)90125-7.
- Rudin, Cynthia (2019). «Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead». Em: *Nature Machine Intelligence* 1.5, pp. 206–215. doi: 10.1038/s42256-019-0048-x.
- Salton, Gerard, A. Wong e C. S. Yang (1975). «A Vector Space Model for Automatic Indexing». Em: *Communications of the ACM* 18.11, pp. 613–620. doi: 10.1145/361219.361220.
- Securities Industry and Financial Markets Association (2025). *2025 Capital Markets Fact Book*. url: <https://www.sifma.org/resources/research/fact-book/> (acedido em 21/06/2026).
- Tetlock, Paul C. (2007). «Giving Content to Investor Sentiment: The Role of Media in the Stock Market». Em: *The Journal of Finance* 62.3, pp. 1139–1168. doi: 10.1111/j.1540-6261.2007.01232.x.
- Vasicek, Oldrich A. (1973). «A Note on Using Cross-Sectional Information in Bayesian Estimation of Security Betas». Em: *The Journal of Finance* 28.5, pp. 1233–1239. doi: 10.1111/j.1540-6261.1973.tb01452.x.
- Vaswani, Ashish et al. (2017). «Attention Is All You Need». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 5998–6008. url: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fb053c1c4a845aa-Abstract.html.
- Vinh, Nguyen Xuan, Julien Epps e James Bailey (2010). «Information Theoretic Measures for Clusterings Comparison: Variants, Properties, Normalization and Correction for Chance». Em: *Journal of Machine Learning Research* 11.95, pp. 2837–2854. url: <https://www.jmlr.org/papers/v11/vinh10a.html>.
- Vovk, Vladimir, Alexander Gammerman e Glenn Shafer (2005). *Algorithmic Learning in a Random World*. New York: Springer. isbn: 978-0-387-00152-4. doi: 10.1007/b106715.
- Waa, Jasper van der et al. (2021). «Evaluating XAI: A Comparison of Rule-Based and Example-Based Explanations». Em: *Artificial Intelligence* 291, p. 103404. doi: 10.1016/j.artint.2020.103404.
- Welch, Ivo (2022). «The Wisdom of the Robinhood Crowd». Em: *The Journal of Finance* 77.3, pp. 1489–1527. doi: 10.1111/jofi.13128.

- World Monitor* (2026). *Real-time global intelligence dashboard*. url: <https://worldmonitor.app> (acedido em 31/07/2026).
- Xing, Frank Z., Erik Cambria e Roy E. Welsch (2018). «Natural Language Based Financial Forecasting: A Survey». Em: *Artificial Intelligence Review* 50.1, pp. 49–73. doi: 10.1007/s10462-017-9588-9.

Apêndice A

Reprodutibilidade

Este apêndice documenta a proveniência dos resultados apresentados no corpo da dissertação. Enumera os artefactos conservados, estabelece a correspondência entre cada resultado reportado e o procedimento que o produz, apresenta o estado em que ficou cada afirmação substantiva depois de medida, e regista as condições de licenciamento dos dados utilizados.

A.1 Artefactos conservados

Esta secção enumera o que é conservado com o trabalho e o que não é, com a razão de cada caso. O conjunto do código, dos ficheiros de resultados e dos artefactos do modelo aqui descritos acompanha a dissertação e pode ser disponibilizado ao júri; o presente apêndice existe para que a proveniência de cada valor seja verificável a partir deste documento, sem depender desse acesso.

O ambiente de execução está descrito na Secção 3.7, com as versões exatas das bibliotecas que produziram os valores deste documento. As versões estão fixadas, e não expressas em intervalos, porque uma biblioteca que se atualize sozinha altera resultados sem emitir aviso. Nenhum dos procedimentos exige unidade de processamento gráfico.

São conservadas três classes de artefacto. A primeira é o componente aprendido, que compreende o modelo treinado, o calibrador ajustado sobre o bloco de validação e um ficheiro descritivo da execução que os produziu, com a dimensão de cada bloco, a prevalência de casos positivos, a semente utilizada e as métricas obtidas. A segunda é o conjunto de ficheiros de resultados, um por procedimento de avaliação, que o texto cita. A terceira é a componente reconstruída da base de precedentes, com cinquenta e seis megabytes de vetores e oito de metadados; a base que a aplicação implantada consulta é a fusão desta com a base viva, conforme a Secção 4.2.3 descreve. Esta última não constitui uma amostra: é o artefacto de que o sistema necessita para arrancar, e sem ele não existiriam precedentes para apresentar.

Os corpora de origem não são conservados. O conjunto histórico ocupa várias centenas de megabytes e é reconstruído pelos procedimentos de preparação descritos na Secção 3.2. No seu lugar são conservadas amostras reduzidas, cuja finalidade é permitir que a verificação automática decorra sem acesso à rede, incluindo o teste que impõe a separação temporal descrita na Secção 3.6 e que o Excerto 3.2 reproduz.

A.2 Origem de cada resultado

Esta secção estabelece a correspondência entre cada resultado reportado no corpo do documento e o procedimento que o gera.

Nenhum resultado desta dissertação foi introduzido manualmente no texto. Cada um é produzido por um procedimento automático de semente fixa, que escreve o seu próprio ficheiro de resultados, e é esse ficheiro que o texto cita. Uma segunda execução sobre os mesmos dados devolve os mesmos valores. A Tabela A.1 reúne os resultados reportados e identifica a secção em que cada um aparece.

A verificação que esta cadeia permite é possível a partir deste documento, e é essa a razão de o apêndice a descrever em vez de a delegar. A secção indicada na terceira coluna enuncia, para cada resultado, o protocolo, a linha de base contra a qual foi comparado e a população sobre que incidiu; e a Secção 3.7 fixa as versões exatas das bibliotecas e a semente. Um leitor que disponha dos dados de origem, cuja proveniência e licenciamento constam da Secção A.4, dispõe do necessário para reconstruir qualquer uma das medições sem recorrer a este trabalho.

A garantia de determinismo aplica-se ao bloco superior da tabela. As linhas do bloco inferior são de outra natureza, e por isso estão separadas: constituem medições sobre a operação do sistema, cujo valor depende do momento em que o registo foi lido e não de uma semente. A secção em que cada uma é apresentada declara o período e o conjunto sobre que foi realizada.

Uma dessas medições não é regenerável, e a distinção fica registada em vez de omitida. A repartição do funil por porta, apresentada na Secção 4.4, foi lida do registo de decisões num dia concreto, e esse registo conserva apenas três dias, pela razão indicada na Secção 3.2: é republicado a cada ciclo, pelo que o custo é de publicação e não de armazenamento. A execução do mesmo procedimento numa data posterior produz um dia diferente. O valor foi conservado com a data da leitura e a identificação do procedimento que a produziu, de modo que qualquer leitura futura tenha origem declarada ainda que aquele dia não se repita.

Os restantes valores numéricos do documento pertencem a três categorias. Os valores extraídos da literatura estão citados no local em que aparecem. As constantes de configuração constam da Tabela 4.2, com a distinção entre as que foram derivadas de uma medição e as que foram escolhidas. A terceira categoria reúne medições que servem uma passagem e não um resultado, como as linhas descartadas pelo embargo, o desvio-padrão do caso trabalhado da Secção 3.3 ou as contagens por fonte de notícias; cada uma declara, no local em que aparece, o conjunto sobre que foi realizada.

A.3 Matriz de evidência

Esta secção submete cada afirmação substantiva do trabalho à evidência que a sustenta e regista o estado em que ficou.

A tabela da secção anterior enumera resultados. A Tabela A.2 enumera afirmações, exame mais exigente, uma vez que uma afirmação pode não sobreviver à evidência que a suportava. As afirmações retiradas permanecem na tabela, dado que uma matriz que enumere apenas as sobreviventes não constitui uma auditoria.

Duas observações incidem sobre a tabela no seu conjunto e não sobre qualquer linha isolada.

Tabela A.1: Os resultados reportados no corpo do documento e a secção em que aparecem. O bloco superior é determinístico e reproduz-se exatamente sobre os mesmos dados; o bloco inferior reúne medições sobre a operação, cujo valor depende da data de leitura do registo.

Resultado	Valor	Onde aparece
Amplitude da taxa de disparo, desvio relativo contra limiar fixo	0,015 contra 0,344	§5.2
F_1 contra o rótulo aproximado	0,516 contra 0,218	§5.2
Comparação com dois detetores aprendidos	0,530 / 0,269 / 0,280	§5.2
Ablação à janela e ao peso do desvio	0,678 e 0,664 contra 0,516	§5.2
Precisão@5 da recuperação, quatro métodos	0,514 / 0,346 / 0,240 / 0,126	§5.3
Valor de referência do setor mais representado	0,467	§5.3
Precisão@5 no protocolo simétrico à escala	0,595 com acaso 0,333	§5.3
Precisão@5 apenas com precedentes anteriores	0,513 com acaso 0,259	§5.3
Concordância de direção contra o valor de acaso	0,708 contra 0,688	§5.3
Triagem, PR-AUC das seis famílias	de 0,378 a 0,542	§5.5
Precisão dentro do orçamento, quatro políticas	0,163 / 0,379 / 0,662 / 0,632	§5.5
Grelha de nove definições de rótulo	9 de 9	§5.5
Ablação da identidade, tabela de consulta contra modelo	0,534 contra 0,538	§5.5.5
Acréscimo do texto sobre a tabela de consulta	0,547 contra 0,534	§5.5.6
Qualidade do ajuste da decomposição, mediana e casos negativos	0,460, 1 em 17	§5.6
Seletividade da porta, dentro e entre empresas	0,072 contra 0,392	§5.7
Deriva de distribuição, PSI da volatilidade	0,281	§5.7
Sistema completo contra as alternativas	0,489 / 0,632 / 0,662 / 0,968	§5.7
Verificação da geração ancorada, ataques e controlos	23 de 23 e 8 de 8	§4.8
<i>Medições sobre a operação: o valor depende da data de leitura do registo</i>		
Decisões maturadas, mantidas contra suprimidas	58,9% contra 61,7%	§5.7
Capacidade de ordenação sobre as decisões tomadas	0,486	§5.7
Cobertura de notícias em dias invulgares	88,5%	§5.7
Latência, descoberta e entrega	353 min e 5 s	§4.6
Funil de seletividade, títulos distintos até entregues	743 → 15	§4.4
Funil de um dia, repartido por porta	5 060 avaliações	§4.4

Tabela A.2: Cada afirmação substantiva, a evidência que a sustenta e o estado em que ficou. O estado *retirada* indica que o trabalho a abandonou depois de a medir; o estado *estreitada* indica que subsiste numa formulação mais restrita do que a inicial.

Afirmação	Evidência	Estado
Deteção de movimentos invulgares		
Dispara a ritmo comparável entre empresas de volatilidade muito distinta	Amplitude de 0,015 contra 0,344, sem recurso a rótulos	Mantida
Supera um limiar fixo no rótulo aproximado	F_1 de 0,516 contra 0,218	Mantida, com o rótulo declarado como aproximação
Supera dois detetores aprendidos com a mesma informação	F_1 de 0,530 contra 0,269 e 0,280	Mantida
Não utiliza informação posterior ao dia avaliado	A janela exclui esse dia, e um teste automático impõe a exclusão	Mantida
A janela de vinte dias e o desvio de pesos iguais são as melhores opções	Variantes alternativas obtêm 0,678 e 0,664 contra 0,516	Retirada: mantidas por explicabilidade, não por desempenho
Recuperação de precedentes		
Supera as alternativas lexical e triviais avaliadas	Precisão@5 de 0,514 contra 0,346, 0,240 e 0,126	Mantida
Supera por larga margem o melhor valor de referência trivial	A escolha do setor mais representado obtém 0,467, o que reduz a margem de +0,274 para +0,047	Estreitada: por setor, face ao acaso; não avalia um filtro pelo setor da consulta
Resiste ao aumento de escala do corpus	Precisão@5 de 0,595 com acaso de 0,333	Mantida como teste de escala
Resiste à restrição de anterioridade da consulta	Precisão@5 de 0,513 com acaso de 0,259; a margem varia 0,008	Estreitada: não testa a maturação de oito dias da produção
Capta tema e não direção	Concordância de 0,708 contra acaso de 0,688	Mantida, e reportada como limitação
A pertença ao mesmo setor equivale a relação entre notícias	—	Não afirmado: é uma aproximação declarada
Triagem de notícias		
Nenhuma variante com texto supera a volatilidade	PR-AUC de 0,496 contra 0,542, com nove definições de rótulo e reamostragem por grupos	Mantida
O texto acrescenta informação sobre a tabela de consulta	PR-AUC de 0,547 contra 0,534, com acréscimo emparelhado de +0,012 e intervalo entre +0,004 e +0,020	Nova, positiva, e sem efeito na precisão dentro do orçamento
As entradas não incorporam retornos posteriores ao dia da notícia	Alterar as sessões posteriores deixa as entradas iguais e altera o rótulo	Mantida
A triagem quadruplica a precisão dentro do orçamento	O valor de referência de 0,163 resulta de ordenação alfabética; a escolha aleatória obtém 0,379	Retirada: o ganho é de 1,67 vezes
O ganho dentro do orçamento provém da aprendizagem	Treze constantes por empresa obtêm 0,662 contra 0,632 do modelo	Retirada
O modelo implantado seleciona melhor do que o acaso	58,9% de casos materiais entre as mantidas contra 61,7% entre as suprimidas	Retirada
Sistema		
O texto do alerta não pode divergir do cálculo	É composto a partir dos objetos calculados, sem geração de linguagem	Mantida
A restrição de gratuidade limita a cobertura	Pelo menos uma notícia relevante em 88,5% dos dias invulgares	Mantida como limite superior
As explicações são úteis a uma pessoa	Retorno observacional do canal, sem contrafactual	Não afirmado

A primeira é que as afirmações retiradas são confrontadas com medições do próprio trabalho. A possibilidade de obter respostas negativas faz parte da avaliação; a revisão do seu alcance também exige conferir se a interpretação corresponde ao protocolo medido.

A segunda é que as duas linhas assinaladas como não afirmadas têm o mesmo peso das restantes. Uma delas é a utilidade das explicações para o utilizador, que não fica estabelecida por ausência de estudo controlado, apesar do retorno observacional reportado na Secção 5.7.5. Onde a evidência disponível não sustenta a afirmação, ela não é formulada.

A.4 Dados, licenças e atribuição

Esta secção regista a origem dos dados utilizados e as obrigações que o seu licenciamento impõe.

O conjunto histórico que sustenta a base de precedentes é o FNSPID (Dong, Fan e Peng 2024), utilizado ao abrigo da licença Creative Commons BY-SA 4.0, cuja atribuição é aqui cumprida. Do corpus constam no documento apenas excertos mínimos de títulos, a título ilustrativo.

Essa licença comporta uma segunda obrigação, que é acionada neste caso. Uma vez que são distribuídos ficheiros derivados do FNSPID, a cláusula de partilha nos mesmos termos aplica-se a esses ficheiros. A licença do código constitui uma decisão que permanece em aberto neste documento, e é esta a restrição que a condiciona.

Os preços provêm de serviços gratuitos de dados de mercado, através da cadeia de alternativas descrita na Secção 4.2; as notícias em tempo real provêm de três interfaces gratuitas, dentro dos respetivos limites de utilização, comparadas na Secção 4.2.2.

Quanto a dados pessoais, a formulação exata consta da Secção 3.8.1: o sistema não conhece as posições dos utilizadores e não as solicita, e o canal público não identifica destinatários. A exceção é a subscrição opcional de alertas personalizados, em que ficam associados o identificador de conversa atribuído pela plataforma e a lista de empresas escolhida, e esses são os únicos elementos armazenados.

A.5 Infraestrutura: o que entra no sistema, e a que custo

A Figura A.1 reúne as peças externas de que o sistema depende, pelo ponto do percurso em que cada uma entra, e o texto que se lhe segue apresenta o custo efetivo da operação. O codificador de frases é executado no formato Open Neural Network Exchange (ONNX), que permite corrê-lo sem a biblioteca de treino. Nenhuma peça foi escolhida por preferência: todas decorrem da restrição fundadora de utilizar apenas fontes gratuitas, e as duas exceções a essa restrição, que são o alojamento e o canal de mensagens, são custos de operação e não fontes de dados.

Custo da operação, e a razão do escalão escolhido

O sistema correu durante a maior parte do período documentado em contentores do escalão mais baixo, ao custo de sete dólares mensais por processo. Em 4 de setembro de 2026 o processo de recolha passou a exceder de forma persistente a quota de memória de 512 MB, com avisos de excesso a uma frequência de aproximadamente dois por minuto e leituras entre 518 e 970 MB.




Figura A.1: As peças externas de que o sistema depende, pela ordem em que entram. As marcas pertencem aos respectivos titulares e a sua utilização aqui é nominativa, destinando-se a identificar a ferramenta empregue. A proveniência de cada ficheiro, com o resumo criptográfico correspondente, consta do manifesto conservado com o trabalho.

Quatro causas foram medidas e corrigidas: a base de casos viva era carregada em listas de *float* de Python, ao custo de 136,7 MB para 10 968 registos, contra 21,7 MB da mesma informação numa matriz de precisão simples; as bases e o codificador eram reconstruídos a cada ciclo de sessenta segundos; o ficheiro de casos pendentes era lido uma vez por empresa; e a publicação de um ficheiro de 40 MB produzia cinco cópias dele em memória. O conjunto reduziu o pico de 970 para 663 MB.

O conjunto de trabalho da aplicação excede genuinamente um contentor de 512 MB: as bibliotecas numéricas e o motor de inferência ocupam, por si, 158 MB, e a matriz de precedentes torna-se residente assim que a primeira consulta lhe percorre as páginas. O processo assentava em 536 MB mesmo entre picos.

A alternativa técnica seria retirar do processo a base de 38 214 precedentes, o que degradaria a qualidade da recuperação, isto é, trocava uma limitação de infraestrutura por uma limitação de resultado. A opção tomada foi a inversa, e o custo consta da Tabela A.3.

Tabela A.3: Escalões de contentor antes e depois de 4 de setembro de 2026. O fornecedor não permite misturar escalões na mesma aplicação, pelo que o processo web, que nunca excedeu a quota, subiu por arrasto. É a razão de o acréscimo ser de sessenta e um dólares e não dos quarenta e três que a alteração de um só processo custaria.

Processo	Escalão	Memória	Custo	Razão
Até 4 de setembro de 2026				
web	Basic	0,5 GB	\$7	nunca excedeu a quota excedia de forma persistente
recolha	Basic	0,5 GB	\$7	
A partir de 4 de setembro de 2026				
web	Standard-1X	0,5 GB	\$25	subiu por não ser possível misturar escalões
recolha	Standard-2X	1,0 GB	\$50	é o primeiro escalão acima de 0,5 GB

Após a alteração, e sobre a mesma carga, não se registou um único aviso de excesso de memória. O saldo de crédito disponível cobre aproximadamente quatro meses de operação neste escalão, o que excede a duração prevista do trabalho. A restrição de utilizar apenas

A.5. Infraestrutura: o que entra no sistema, e a que custo

fontes gratuitas mantém-se para os *dados*, que são a matéria da dissertação; o alojamento e o canal de mensagens são custos de operação e estão declarados como tal.