

# Explicar sem prever

Deteção de anomalias e recuperação de precedentes em alertas financeiros verificáveis

Henrique José da Silva Santos

Orientador: Prof. Luís Gomes    Coorientador: Rafael Silva


MEIA, Instituto Superior de Engenharia do Porto

Defesa



InvestiGator

Uma pessoa abre a aplicação, vê isto, e fica com três perguntas



**1. Isto é invulgar?**

4% numa empresa calma é muito. Noutra, é terça-feira.

**2. Foi a empresa, ou foi o mercado?**

Se caiu tudo, a história é outra.

**3. Já aconteceu antes, e o que se seguiu?**

Houve dias parecidos? O que fez o preço depois?

**As aplicações gratuitas correntes não respondem a nenhuma delas.**

Há produtos recentes que declaram ir além disso. Nenhum mostra os casos passados, um a um, com o desfecho medido.


## O que existe hoje

|                               | invulgar?                                          | empresa ou mercado? | já aconteceu? | custo         |
|-------------------------------|----------------------------------------------------|---------------------|---------------|---------------|
| Aplicação da corretora        | —                                                  | —                   | —             | incluído      |
| Agregador de notícias         | —                                                  | —                   | —             | grátis        |
| Gestor automático de carteira | —                                                  | —                   | —             | % da carteira |
| Terminal profissional         | ✓                                                  | ✓                   | ✓             | não publicado |
| Resumo gerado (2025–26)       | <i>declaram responder; não mostram a evidência</i> |                     |               | grátis        |
| <b>Este trabalho</b>          | ✓                                                  | ✓                   | ✓             | <b>grátis</b> |

Dois produtos recentes declaram responder à mesma pergunta. Nenhum declara **mostrar a evidência**  
— os casos passados, um a um, com data e desfecho medido.

**A diferença que reivindico não é de fluência: é de verificabilidade.**

# O que o sistema faz



E há uma coisa que ele **recusa** fazer.

Nunca diz que vai subir.

Nunca diz para comprar.

Nunca mostra um alvo de preço.

Parece uma limitação. É o contrário:  
**é o que torna tudo o resto verificável.**

Uma afirmação sobre o que já aconteceu confere-se contra o registo.

Uma previsão não se confere.

# Técnica 1: é invulgar?

Comparar o dia de hoje com os **20 dias anteriores da mesma ação**.




$$z = \frac{\text{movimento de hoje} - \text{média}}{\text{desvio-padrão}}$$

$z = +7$  quer dizer o mesmo numa empresa calma e numa volátil.

**O dia julgado não entra no cálculo da sua própria norma.** Sem isto, seria falsear.

## Técnica 2: foi a empresa, ou foi o mercado?

Um +6,29% pode ser a empresa ou pode ser o mercado. A aplicação da corretora mostra o **mesmo número** nos dois casos.



A AMD subiu **apesar** de o mercado e o setor terem puxado ao contrário. Os *betas* são estimados **só com dias anteriores**.

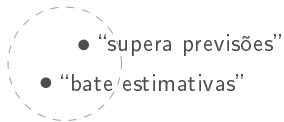
**Ressalva:** as parcelas somam sempre, porque a da empresa é o resto, e isso não prova que estejam bem estimadas.  $R^2$  mediano 0,460, e num dos casos negativo.

**É a única das quatro sem questão de investigação:** não há resposta certa contra a qual comparar, e por isso o que se mede nela é o ajuste, e não o acerto.

## Técnica 3: já aconteceu antes?

Procurar por palavras falha nos **dois** sentidos:

*mesmo sentido, palavras diferentes*



*palavra igual, sentido diferente*



Cada título passa a **384 números**: uma coordenada de significado.

Compara-se pelo **ângulo** entre elas.

Depois, para cada caso passado, mede-se o que o preço fez a +1, +3 e +5 dias.

É uma **medição do passado, não uma previsão**.



## Técnica 4: merece avisar?

Aqui não há fórmula óbvia. É o sítio para **aprender dos dados**.

- **79 753** exemplos que construí a partir de notícias e preços (2018–2023)
- Pergunta: *depois desta notícia houve um movimento anormalmente grande?* **Em valor absoluto**, nunca em que direção



Divisão por **dias inteiros** com embargo de **cinco**, nunca por linhas: duas notícias do mesmo dia não podem cair uma de cada lado. E a garantia não é prometida, é **imposta por um teste**: dois futuros absurdos (+300% e –99%) sobre o mesmo passado têm de dar entradas **idênticas** e rótulos **diferentes**. Se o futuro vazasse, as entradas mudavam.

# Um alerta real, do princípio ao fim

Meta, 12 de julho de 2026. *“Mark Zuckerberg Said Meta's AI Bets ‘Haven't Come to Fruition Yet’ as Shares*

|          | etapa               | o que aconteceu                   |
|----------|---------------------|-----------------------------------|
| Fell 5%” | 2 nomeia a empresa? | “Meta”, “Zuckerberg” ✓            |
|          | 3 é recente?        | menos de 2 dias ✓                 |
|          | 4 casos parecidos   | MSFT 0,46 · NVDA 0,51 · NVDA 0,46 |
|          | 5 evidência forte?  | melhor $0,51 \geq 0,45$ ✓         |
|          | 6 merece avisar?    | $54\% \geq 50\%$ ✓                |
|          | 9 enviado           | ao canal, e guardado              |

Os desfechos foram **em sentidos opostos**:  $+2,70\% \cdot -3,87\% \cdot +5,05\%$

Por isso mostram-se **um a um**: uma média esconderia isso.

## Resultado 1: deteção **sim**

Um bom detetor deve disparar a um ritmo **parecido** em empresas diferentes.

|                   | mín   | máx   | amplitude |
|-------------------|-------|-------|-----------|
| z-score           | 0,016 | 0,031 | 0,015     |
| Limiar fixo de 3% | 0,009 | 0,353 | 0,344     |

Mais de **20 vezes** mais consistente.

E ganha também a dois métodos aprendidos:  $F_1$  0,530 contra 0,269 e 0,280.

## Resultado 2: precedentes **sim**

| método                     | precisão@5 |
|----------------------------|------------|
| Por significado (o método) | 0,514      |
| Sempre o setor maior       | 0,467      |
| Por palavras em comum      | 0,346      |
| Ao acaso (o chão)          | 0,240      |
| As mais recentes           | 0,126      |

- Metade do corpus é tecnologia: **devolver sempre tecnologia** vale 0,467 sem modelo nenhum. A margem real é +0,047, e não +0,274.
- O método supera o acaso nos **cinco setores**: 0,448 na energia, com chão 0,072. Não se mediu vantagem sobre um **filtro pelo setor conhecido** da consulta.
- Exigindo candidatos anteriores: **0,513**, chão **0,259**, margem +0,254. O teste não impõe a maturação de oito dias da produção.
- **Semelhança de tema não garante direção**. Os casos são apresentados um a um.

## Resultado 3: triagem **não**

| modelo           | PR-AUC |
|------------------|--------|
| Só volatilidade  | 0,542  |
| Só contexto      | 0,538  |
| Contexto + texto | 0,496  |
| Só texto         | 0,439  |

**Nenhum modelo que lê o texto bate a volatilidade.**

Era o contrário do que eu esperava. Verifiquei por três caminhos: re-teste em condições favoráveis ao texto (0,533, ainda abaixo), reamostragem por grupos, e **nove** definições diferentes do rótulo: a volatilidade ganha nas nove.

## O erro que encontrei em mim próprio

Eu tinha escrito que a triagem “*quase quadruplica*” a precisão: de 0,163 para 0,632.

O 0,163 vinha do modelo “alertar sempre”, que dá a mesma pontuação a tudo.

**Com tudo empatado, a métrica desempata pela ordem do ficheiro**, que está ordenado por data e por nome da empresa.


Esse número não media escolher às cegas.  
**Media escolher por ordem alfabética.**

Ao acaso a sério dá 0,379  $\Rightarrow$  o ganho é de **1,67** $\times$ , não de quase quatro.

E uma tabela de **13 constantes** dá 0,662: bate o modelo treinado.

## E encontrei-o outra vez, um nível acima

O sistema decidia se avisava com um **limiar fixo** sobre a pontuação do modelo: passa quem estiver acima de 0,50.



Em **48%** dos títulos distintos, o resultado estava determinado pela **empresa** antes de o título ser lido.

Em nenhuma avaliação registrada a Apple alcançou o piso, com um máximo de 0,472; a AMD ultrapassou-o em todas. Contada por decisão a fração sobe a 60%, e é a repontuação de minuto a minuto que a inflaciona.

## E a correção óbvia também estava errada

**A tentação:** se um limiar fixo mede a empresa e não a notícia, torna-se *relativo a cada empresa*, que foi exatamente o que o z-score fez para os preços.

Simulei-o **antes** de escrever código. Metade resolve-se: as doze passam a estar representadas.

**Mas** nas empresas de pontuação quase constante o percentil cai *em cima* da constante e quase tudo empata acima. A JNJ passaria **874** vezes.

Não se corrige um defeito introduzindo o defeito vizinho.

**O que se fez:** o modelo deixou de decidir e passou a **ordenar**, com um orçamento de 5 alertas por dia. E isso fechou uma divergência: a dissertação *avaliava* uma política de orçamento e o sistema *implantava* uma de limiar.



# Então quanto vale o modelo? Duas medições que respondem

## 1. Tirei-lhe a notícia.

Uma *tabela de consulta*: um número fixo por empresa, zero informação sobre o título.

| o que vê                    | PR-AUC |
|-----------------------------|--------|
| o implantado, nove entradas | 0,538  |
| <b>só a empresa</b>         | 0,534  |
| sem nada da empresa         | 0,378  |
| só o comprimento do título  | 0,378  |

Diferença de 0,004, e 0,378 é o chão. **O modelo implantado é uma tabela de consulta.**

## 2. Comparei o sistema inteiro.

Precisão nas cinco notícias que o produto mostra por dia.

| política                       | prec.@5 |
|--------------------------------|---------|
| ao acaso                       | 0,375   |
| quem mais se mexeu hoje        | 0,489   |
| <b>o sistema</b>               | 0,632   |
| volatilidade, treze constantes | 0,662   |
| oráculo                        | 0,968   |

Bate a alternativa realista. **Mas o oráculo é a informação nova:** as notícias importantes *estão* no lote.

A margem que falta não está em melhores dados. Está em **separar duas notícias da mesma empresa no mesmo dia.**

# “E onde está a engenharia de inteligência artificial?”

Começo pela parte incômoda: este trabalho treina **um** modelo, e é uma regressão logística com nove entradas que **perdeu** para uma linha de base de uma só variável.

## A engenharia não está no tamanho do modelo.

Está no que foi preciso construir para que aquele número, e a conclusão negativa que ele sustenta, sejam *de confiança*.

1. O conjunto de dados é **construído**, não encontrado: 79 753 linhas que não existiam.
2. O rótulo é uma **decisão**, e por isso mediram-se **nove** definições alternativas.
3. A separação temporal é imposta por um **teste** que muta o futuro, não prometida.
4. As probabilidades são calibradas, e o seu enviesamento está **medido**.
5. O modelo, o calibrador e a corrida estão **versionados**.
6. O modelo implantado é o modelo avaliado: exportado para um formato leve, com a fidelidade da conversão medida em vez de assumida.
7. O que corre é **observado**: cada decisão é registada e confrontada dias depois com o que o preço fez. Foi assim que se soube que *não* estava a ajudar.

A parte difícil não foi escolher a técnica. Foi montar a avaliação que **consegue dizer que não**, e depois acreditar nela.


# Limitações, ditas antes de me perguntarem, e o que as fecha

**Cada limitação foi medida, e a coluna da direita é o trabalho que ela pede.**

| limitação medida                                           |   | o que a fecha                       | custo       |
|------------------------------------------------------------|---|-------------------------------------|-------------|
| Nenhuma avaliação com pessoas                              | → | Correr o estudo: 6 a 10 pessoas     | calendário  |
| O modelo implantado é uma tabela de consulta               | → | Entradas que variem com o título    | baixo       |
| Cobertura de 88,5%, e 50% na pior                          | → | Julgamento humano sobre uma amostra | calendário  |
| Lê o título e não o corpo                                  | → | Ler o corpo dos artigos             | dados novos |
| Deriva: a entrada de que mais depende é a que mais derivou | → | Re-treinar com o que se observa     | baixo       |

**Mais duas:** o atraso é da *fonte* e não da infraestrutura ( $\approx 353$  min até detetar, 5 s até entregar); e **nada volta a ser treinado**, porque a base de casos cresce sozinha, os pesos não.

# As três perguntas, respondidas no ecrã



## 1. É invulgar?

Em palavras, antes do número: 204 dos últimos 250 dias moveram-se tanto ou mais. O veredicto é “*Quiet*”, e é dito antes de qualquer valor.

## 2. Foi a empresa?


Não. A ação desce 0,30%, mas a contribuição da própria empresa é **positiva** (+0,53%): quem a puxa para baixo é o **mercado** (-0,61%). A percentagem sozinha mandava procurar na empresa uma razão que estava fora dela.

## 3. Já aconteceu?

Os dias assinalados na curva, e os precedentes dentro do texto do alerta.

## O sistema está no ar. [gravação]

uma notícia real, do momento em que chega até ao alerta que sai



O percurso de uma candidata pelas portas, até onde parou. **É a parte que uma demonstração ao vivo não mostra:** nove em cada dez varreduras não enviam nada, e o silêncio fica escrito como um alerta.

# O que aprendi

## ❶ A linha de base é tão importante como o modelo.

O resultado mais útil do trabalho veio de olhar para aquilo contra o qual eu estava a comparar.

## ❷ O sítio onde se põe um modelo importa tanto como o modelo.

O meu funcionava sozinho e deixou de servir atrás de dois filtros simples, que já faziam o trabalho.

## ❸ A técnica mais simples ganhou três vezes.

Ao Isolation Forest e ao modelo que lê o texto, que são *simples contra complexo*. E uma tabela de constantes ganhou ao modelo implantado, que é um caso diferente: ali o modelo até era interpretável, e perdeu por **falta de informação**.

A parte difícil não foi escolher a técnica mais avançada.  
Foi montar a avaliação **capaz de dizer que ela não era precisa**.

**Obrigado.** Perguntas?