

Explicar sem prever

Deteção de anomalias e recuperação de precedentes em alertas financeiros verificáveis

Henrique José da Silva Santos

Orientador: Prof. Luís Gomes Coorientador: Rafael Silva

MEIA, Instituto Superior de Engenharia do Porto

Defesa



InvestiGator

Serviu a alguém? A única evidência recolhida em aberto


Cada alerta leva dois botões. **As regras foram fixadas antes de existir o primeiro voto** e nenhuma foi alterada depois.

Votos, um por pessoa e alerta, sobre 62 alertas	91
Pessoas	3
Classificaram o alerta como útil	86 de 91 = 95% [88; 98]
O mesmo, sem o leitor que deu 58% deles	34 de 38 = 89% [76; 96]

entre parênteses, o intervalo de Wilson a 95%

E o que isto não é. Três pessoas são um piloto, não um estudo. Vota quem quer, o que empurra a amostra para os extremos; ninguém recebeu o movimento *sem* explicação, logo nada aqui atribui a utilidade à explicação em si; e utilidade percebida não é decisão melhor. **O estudo controlado está desenhado e não foi corrido** — é a primeira limitação das conclusões.

Uma pessoa abre a aplicação, vê isto, e fica com três perguntas



1. Isto é invulgar?

4% numa empresa calma é muito. Noutra, é terça-feira.

2. Foi a empresa, ou foi o mercado?

Se caiu tudo, a história é outra.

3. Já aconteceu antes, e o que se seguiu?

Houve dias parecidos? O que fez o preço depois?

As aplicações gratuitas correntes não respondem a nenhuma delas.

Há produtos recentes que declaram ir além disso. Nenhum mostra os casos passados, um a um, com o desfecho medido.


O que existe hoje

	invulgar?	empresa ou mercado?	já aconteceu?	custo
Aplicação da corretora	—	—	—	incluído
Agregador de notícias	—	—	—	grátis
Gestor automático de carteira	—	—	—	% da carteira
Terminal profissional	✓	✓	✓	não publicado
Resumo gerado (2025–26)	<i>declaram responder; não mostram a evidência</i>			grátis
Este trabalho	✓	✓	✓	grátis

Dois produtos recentes declaram responder à mesma pergunta. Nenhum declara **mostrar a evidência**
— os casos passados, um a um, com data e desfecho medido.

A diferença que reivindico não é de fluência: é de verificabilidade.

O que o sistema faz



E há uma coisa que ele **recusa** fazer.

Nunca diz que vai subir.

Nunca diz para comprar.

Nunca mostra um alvo de preço.

Parece uma limitação. É o contrário:
é o que torna tudo o resto verificável.

Uma afirmação sobre o que já aconteceu confere-se contra o registo.

Uma previsão não se confere.

Técnica 1: é invulgar?

Comparar o dia de hoje com os **20 dias anteriores da mesma ação**.




$$z = \frac{\text{movimento de hoje} - \text{média}}{\text{desvio-padrão}}$$

$z = +7$ quer dizer o mesmo numa empresa calma e numa volátil.

O dia julgado não entra no cálculo da sua própria norma. Sem isto, seria falsear.

Técnica 2: foi a empresa, ou foi o mercado?

Um +6,29% pode ser a empresa ou pode ser o mercado. A aplicação da corretora mostra o **mesmo número** nos dois casos.



A AMD subiu **apesar** de o mercado e o setor terem puxado ao contrário. Os *betas* são estimados **só com dias anteriores**.


Ressalva: as parcelas somam sempre, porque a da empresa é o resto, e isso não prova que estejam bem estimadas. R^2 mediano 0,460, e num dos casos negativo.

É a única das quatro sem questão de investigação: não há resposta certa contra a qual comparar, e por isso o que se mede nela é o ajuste, e não o acerto.

Técnica 3: já aconteceu antes?

Procurar por palavras falha nos **dois** sentidos:

mesmo sentido, palavras diferentes



palavra igual, sentido diferente



Cada título passa a **384 números**: uma coordenada de significado.

Compara-se pelo **ângulo** entre elas.

Depois, para cada caso passado, mede-se o que o preço fez a +1, +3 e +5 dias.

É uma medição do passado, não uma previsão.

Técnica 4: merece avisar?

Aqui não há fórmula óbvia. É o sítio para **aprender dos dados**.

- **79 753** exemplos que construí a partir de notícias e preços (2018–2023)
- Pergunta: *depois desta notícia houve um movimento anormalmente grande?* **Em valor absoluto**, nunca em que direção



Divisão por **dias inteiros** com embargo de **cinco**, nunca por linhas: duas notícias do mesmo dia não podem cair uma de cada lado. E a garantia não é prometida, é **imposta por um teste**: dois futuros absurdos (+300% e –99%) sobre o mesmo passado têm de dar entradas **idênticas** e rótulos **diferentes**. Se o futuro vazasse, as entradas mudavam.

Um alerta real, do princípio ao fim

Meta, 12 de julho de 2026. *“Mark Zuckerberg Said Meta's AI Bets ‘Haven't Come to Fruition Yet’ as Shares*

	etapa	o que aconteceu
Fell 5%”	2 nomeia a empresa?	“Meta”, “Zuckerberg” ✓
	3 é recente?	menos de 2 dias ✓
	4 casos parecidos	MSFT 0,46 · NVDA 0,51 · NVDA 0,46
	5 evidência forte?	melhor $0,51 \geq 0,45$ ✓
	6 merece avisar?	$54\% \geq 50\%$ ✓
	9 enviado	ao canal, e guardado

Os desfechos foram **em sentidos opostos**: $+2,70\% \cdot -3,87\% \cdot +5,05\%$

Por isso mostram-se **um a um**: uma média esconderia isso.

Resultado 1: deteção **sim**

Um bom detetor deve disparar a um ritmo **parecido** em empresas diferentes.

	mín	máx	amplitude
z-score	0,016	0,031	0,015
Limiar fixo de 3%	0,009	0,353	0,344

Mais de **20 vezes** mais consistente.

E ganha também a dois métodos aprendidos: F_1 0,530 contra 0,269 e 0,280.

Resultado 2: precedentes **sim**

método	precisão@5
Por significado (o método)	0,395
As mais recentes	0,204
Sempre o setor maior	0,200
Por palavras em comum	0,196
Ao acaso (o chão)	0,117

- O corpus completo é 84% tecnologia, e ali **devolver sempre tecnologia** vale 0,840 sem modelo nenhum, acima de qualquer método. É por isso que a medição principal usa o subconjunto **equilibrado**, onde essa estratégia vale 0,200 o método a supera com folga, e a margem sobre o acaso é +0,278.
- O método supera o acaso nos **cinco setores**: 0,589 na energia, com chão 0,110. Não se mediu vantagem sobre um **filtro pelo setor conhecido** da consulta.
- Exigindo candidatos anteriores: **0,513**, chão **0,259**, margem +0,254. O teste não impõe a maturação de oito dias da produção.
- **Semelhança de tema não garante direção**. Os casos são apresentados um a um.

Resultado 3: triagem **não**

modelo	PR-AUC
Só volatilidade	0,542
Só contexto	0,538
Contexto + texto	0,496
Só texto	0,439

Nenhum modelo que lê o texto bate a volatilidade.

Era o contrário do que eu esperava. Verifiquei por três caminhos: re-teste em condições favoráveis ao texto (0,533, ainda abaixo), reamostragem por grupos, e **nove** definições diferentes do rótulo: a volatilidade ganha nas nove.

O erro que encontrei em mim próprio

Eu tinha escrito que a triagem “*quase quadruplica*” a precisão: de 0,163 para 0,632.

O 0,163 vinha do modelo “alertar sempre”, que dá a mesma pontuação a tudo.

Com tudo empatado, a métrica desempata pela ordem do ficheiro, que está ordenado por data e por nome da empresa.


Esse número não media escolher às cegas.
Media escolher por ordem alfabética.

Ao acaso a sério dá 0,379 $\Rightarrow$ o ganho é de **1,67** $\times$, não de quase quatro.

E uma tabela de **13 constantes** dá 0,662: bate o modelo treinado.

E encontrei-o outra vez, um nível acima

O sistema decidia se avisava com um **limiar fixo** sobre a pontuação do modelo: passa quem estiver acima de 0,50.



Em **48%** dos títulos distintos, o resultado estava determinado pela **empresa** antes de o título ser lido.

Em nenhuma avaliação registrada a Apple alcançou o piso, com um máximo de 0,472; a AMD ultrapassou-o em todas. Contada por decisão a fração sobe a 60%, e é a repontuação de minuto a minuto que a inflaciona.

E a correção óbvia também estava errada

A tentação: se um limiar fixo mede a empresa e não a notícia, torna-se *relativo a cada empresa*, que foi exatamente o que o z-score fez para os preços.

Simulei-o **antes** de escrever código. Metade resolve-se: as doze passam a estar representadas.

Mas nas empresas de pontuação quase constante o percentil cai *em cima* da constante e quase tudo empata acima. A JNJ passaria **874** vezes.

Não se corrige um defeito introduzindo o defeito vizinho.

O que se fez: o modelo deixou de decidir e passou a **ordenar**, com um orçamento de 5 alertas por dia. E isso fechou uma divergência: a dissertação *avaliava* uma política de orçamento e o sistema *implantava* uma de limiar.

Então quanto vale o modelo? Duas medições que respondem

1. Tirei-lhe a notícia.

Uma *tabela de consulta*: um número fixo por empresa, zero informação sobre o título.

o que vê	PR-AUC
o implantado, nove entradas	0,538
só a empresa	0,534
sem nada da empresa	0,378
só o comprimento do título	0,378

Diferença de 0,004, e 0,378 é o chão. **O modelo implantado é uma tabela de consulta.**

2. Comparei o sistema inteiro.

Precisão nas cinco notícias que o produto mostra por dia.

política	prec.@5
ao acaso	0,375
quem mais se mexeu hoje	0,489
o sistema	0,632
volatilidade, treze constantes	0,662
oráculo	0,968

Bate a alternativa realista. **Mas o oráculo é a informação nova:** as notícias importantes *estão* no lote.

A margem que falta não está em melhores dados. Está em **separar duas notícias da mesma empresa no mesmo dia.**

“E onde está a engenharia de inteligência artificial?”

Começo pela parte incômoda: este trabalho treina **um** modelo, e é uma regressão logística com nove entradas que **perdeu** para uma linha de base de uma só variável.

A engenharia não está no tamanho do modelo.

Está no que foi preciso construir para que aquele número, e a conclusão negativa que ele sustenta, sejam *de confiança*.

1. O conjunto de dados é **construído**, não encontrado: 79 753 linhas que não existiam.
2. O rótulo é uma **decisão**, e por isso mediram-se **nove** definições alternativas.
3. A separação temporal é imposta por um **teste** que muta o futuro, não prometida.
4. As probabilidades são calibradas, e o seu enviesamento está **medido**.
5. O modelo, o calibrador e a corrida estão **versionados**.
6. O modelo implantado é o modelo avaliado: exportado para um formato leve, com a fidelidade da conversão medida em vez de assumida.
7. O que corre é **observado**: cada decisão é registada e confrontada dias depois com o que o preço fez. Foi assim que se soube que *não* estava a ajudar.

A parte difícil não foi escolher a técnica. Foi montar a avaliação que **consegue dizer que não**, e depois acreditar nela.


Limitações, ditas antes de me perguntarem, e o que as fecha

Cada limitação foi medida, e a coluna da direita é o trabalho que ela pede.

limitação medida		o que a fecha	custo
Nenhuma estudo <i>controlado</i> com pessoas	→	Correr o estudo: 6 a 10 pessoas	calendário
O modelo implantado é uma tabela de consulta	→	Entradas que variem com o título	baixo
Cobertura de 88,5%, e 50% na pior	→	Julgamento humano sobre uma amostra	calendário
Lê o título e não o corpo	→	Ler o corpo dos artigos	dados novos
Deriva: a entrada de que mais depende é a que mais derivou	→	Re-treinar com o que se observa	baixo

Mais duas: o atraso é da *fonte* e não da infraestrutura (≈ 353 min até detetar, 5 s até entregar); e **nada volta a ser treinado**, porque a base de casos cresce sozinha, os pesos não.

As três perguntas, respondidas no ecrã



1. É invulgar?

Em palavras, antes do número: 128 dos últimos 248 dias moveram-se tanto ou mais. O veredicto é “*Quiet*”, e é dito antes de qualquer valor.

2. Foi a empresa?


Não, não foi. A ação caiu 0,97% e a parcela da própria empresa é *positiva*, +0,11%: puxaram-na para baixo o mercado (-0,53%) e o setor (-0,55%). E o ajuste desta empresa fica **abaixo** da mediana.

3. Já aconteceu?

Os dias assinalados na curva, e os precedentes dentro do texto do alerta.

O sistema está no ar. [gravação]

uma notícia real, do momento em que chega até ao alerta que sai



As decisões registadas para uma empresa, cada uma nomeando o título e, quando a mensagem foi retida, o motivo. **É a parte que uma demonstração ao vivo não mostra:** nove em cada dez varreduras não enviam nada, e o silêncio fica escrito como um alerta.

O que aprendi

❶ A linha de base é tão importante como o modelo.

O resultado mais útil do trabalho veio de olhar para aquilo contra o qual eu estava a comparar.

❷ O sítio onde se põe um modelo importa tanto como o modelo.

O meu funcionava sozinho e deixou de servir atrás de dois filtros simples, que já faziam o trabalho.

❸ A técnica mais simples ganhou três vezes.

Ao Isolation Forest e ao modelo que lê o texto, que são *simples contra complexo*. E uma tabela de constantes ganhou ao modelo implantado, que é um caso diferente: ali o modelo até era interpretável, e perdeu por **falta de informação**.

A parte difícil não foi escolher a técnica mais avançada.
Foi montar a avaliação **capaz de dizer que ela não era precisa**.

Obrigado. Perguntas?