

InvestiGator: alertas financeiros explicáveis para o investidor particular

**Deteção de anomalias e recuperação de
precedentes sobre fontes de dados gratuitas**

Henrique José da Silva Santos

Aluno nº: 1180934

**Dissertação para obtenção do Grau de
Mestre em Engenharia de Inteligência Artificial**

Orientador: Luís Gomes
Co-Orientador: Rafael Silva

Júri:

Presidente:

[Nome do Presidente, Categoria, Escola]

Vogais:

[Nome do Vogal 1, Categoria, Escola]

[Nome do Vogal 2, Categoria, Escola]

Declaração de Integridade

Declaro que realizei este trabalho acadêmico com integridade.

Não recorri a plágio nem a qualquer forma de utilização indevida ou falsificação de informações ou resultados ao longo do processo que conduziu à sua elaboração.

Declaro, por isso, que este documento é original e da minha autoria, não tendo sido utilizado anteriormente para qualquer outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

Uso de Inteligência Artificial. Em conformidade com as orientações do P.PORTO/ISEP, declaro o uso de ferramentas de inteligência artificial generativa neste trabalho, e descrevo-o com precisão.

A concepção é minha: o problema, as questões de investigação, as restrições que definem o sistema (apenas fontes gratuitas, explicabilidade primeiro, e a recusa de prever preços), o desenho de cada experiência e o critério de sucesso fixado antes de a correr, e todas as decisões sobre o que construir, manter ou descartar. Nenhuma conclusão deste documento foi delegada.

A execução foi assistida, e em extensão substancial. Essas ferramentas escreveram e reestruturaram parte considerável do código do sistema e dos seus testes, implementaram os procedimentos de avaliação, redigiram e editaram prosa neste documento, e conduziram revisões que encontraram defeitos no software e no texto. Onde uma medição contrariou uma afirmação minha, retirei a afirmação em vez de a defender, e o Apêndice A regista as que foram retiradas.

Revi o conteúdo deste documento. Ele, os erros que nele restem, e a sua defesa são da minha responsabilidade.

ISEP, Porto, setembro de 2026

Dedicatória

À minha família.

Resumo

Quando o preço de uma ação se move de forma abrupta, o investidor particular necessita de determinar se o movimento é invulgar, se a sua origem é a empresa ou o mercado, e se existem precedentes. As aplicações gratuitas apresentam a variação percentual e não respondem a estas questões; os terminais profissionais respondem, a um custo incompatível com este investidor.

Esta dissertação apresenta o InvestiGator, um sistema de alertas financeiros assente exclusivamente em fontes de dados gratuitas, que responde às três questões e expõe a evidência que sustenta cada resposta. O sistema integra quatro técnicas: deteção de anomalias por z-score deslizando, decomposição do retorno em mercado, setor e empresa com encolhimento do beta, recuperação de precedentes por semelhança semântica com medição do desfecho observado, e um modelo supervisionado de triagem treinado sobre um conjunto de dados construído para o efeito.

Cada componente foi avaliado contra linhas de base transparentes. A deteção normalizada pela volatilidade revela-se consistente entre empresas; a recuperação semântica supera a taxa-base em todos os setores avaliados; o modelo de triagem não supera uma linha de base baseada apenas em volatilidade, resultado negativo que é reportado e analisado.

Por desenho, o sistema não produz previsões de preço.

Palavras-chave: Inteligência Artificial Explicável, Alertas Financeiros, Deteção de Anomalias, Recuperação Semântica, Investidor Particular

Abstract

When a stock price moves abruptly, retail investors need to determine whether the movement is unusual, whether its origin lies with the company or the market, and whether comparable precedents exist. Free applications display the percentage change and answer none of these questions; professional terminals do answer them, at a cost incompatible with this investor profile.

This dissertation presents InvestiGator, a financial alerting system built exclusively on free data sources, which answers the three questions and exposes the evidence supporting each answer. The system integrates four techniques: anomaly detection through a rolling z-score, decomposition of returns into market, sector and company components with beta shrinkage, precedent retrieval by semantic similarity with measurement of the observed outcome, and a supervised triage model trained on a purpose-built dataset.

Each component was evaluated against transparent baselines. Volatility-normalised detection proves consistent across companies; semantic retrieval outperforms the base rate in every sector assessed; the triage model does not outperform a volatility-only baseline, a negative result that is reported and analysed.

By design, the system does not produce price forecasts.

Keywords: Explainable Artificial Intelligence, Financial Alerts, Anomaly Detection, Semantic Retrieval, Retail Investor

Agradecimentos

Ao meu orientador, Prof. Luís Gomes, e ao meu coorientador, Rafael Silva, por todo o apoio ao longo desta tese. Por trocarem ideias comigo e me ajudarem a decidir a direção do tema; por me mostrarem exemplos de aplicações que já existem e me manterem a par do que se vai fazendo na área; e por me guiarem na elaboração deste documento. Muito do que aqui está tomou a forma que tem porque houve antes uma conversa com eles.

À minha família, por todo o apoio e por acreditarem em mim. Por me incentivarem sempre, e pela alegria com que foram acompanhando a construção disto. É, para mim, a melhor parte de o ter feito.

Aos meus colegas da Sistrade, e à Sistrade, pela flexibilidade que me permitiu seguir este mestrado a par do trabalho, pelas conversas informais sobre a aplicação ao longo destes meses, e por serem boa companhia todos os dias.

Índice

Lista de Acrónimos	xxi
1 Introdução	1
1.1 Contextualização	1
1.2 Descrição do problema	2
1.3 Objetivos e questões de investigação	2
1.4 Contribuições científicas	3
1.5 Estrutura do documento	4
2 Estado da arte	5
2.1 O investidor particular e o problema da atenção	5
2.2 Ferramentas de informação financeira para o retalho	6
2.3 Detecção de anomalias em séries temporais financeiras	8
2.4 Representação de texto e recuperação semântica	9
2.4.1 Recuperação com geração, e por que razão o sistema para antes dela	12
2.4.2 Corpora de notícias financeiras e rótulos de setor	12
2.5 Estudos de evento e decomposição de retornos	12
2.6 Raciocínio baseado em casos	13
2.7 Explicabilidade e confiança em sistemas automáticos	14
2.8 Aprendizagem automática em ambiente de produção	15
2.9 Síntese e posicionamento do trabalho	16
3 Métodos e materiais	19
3.1 Metodologia de investigação	19
3.2 Conjuntos de dados	20
3.3 Detecção de movimentos invulgares	20
3.4 Decomposição do movimento observado	22
3.5 Recuperação de precedentes	24
3.6 Triagem de notícias	26
3.7 Ferramentas e infraestrutura	27
3.8 Desafios tecnológicos e sociais	28
3.8.1 Privacidade e proteção de dados	28
3.8.2 Segurança	28
3.8.3 Questões éticas e sociais	29
4 Implementação: InvestiGator	31
4.1 Arquitetura do sistema	31
4.1.1 Comunicação entre componentes	32
4.2 Aquisição de dados	32
4.2.1 Preços	33
4.2.2 Notícias	33

4.2.3	Base histórica e base implantada	34
4.3	Percurso de um acontecimento	34
4.3.1	Percurso iniciado por notícia	34
4.3.2	Percurso iniciado por movimento de preço	35
4.4	Política de decisão	36
4.4.1	Seletividade observada	36
4.4.2	Limiares e sua proveniência	37
4.5	Construção da explicação	37
4.5.1	Discordância entre a afirmação e a evidência	40
4.5.2	Aplicação web	41
4.6	Implantação e operação	41
4.6.1	Crescimento da base de casos	43
4.7	Ciclo de vida do componente aprendido	44
4.7.1	Componentes desenvolvidos e componentes consumidos	45
4.7.2	Limitações do ciclo	45
5	Casos de estudo	47
5.1	Desenho experimental e métricas	47
5.2	Deteção consistente entre empresas	49
5.2.1	Procedimento	49
5.2.2	Resultado	49
5.2.3	O que a medida principal não exclui	50
5.2.4	Comparação com detetores aprendidos	50
5.2.5	Duas comparações que não confirmam as escolhas implantadas	51
5.2.6	Limites da conclusão	53
5.3	Recuperação de precedentes	53
5.3.1	Procedimento	53
5.3.2	Resultado	54
5.3.3	A alternativa trivial que o valor agregado esconde	55
5.3.4	Comportamento à escala e sob a restrição da produção	56
5.3.5	Limites da conclusão	56
5.4	Triagem de notícias	57
5.4.1	Procedimento	57
5.4.2	Resultado	58
5.4.3	Três verificações à montagem experimental	59
5.4.4	Utilidade sob a restrição de orçamento	60
5.4.5	Ablação das entradas do modelo	61
5.4.6	O texto como acréscimo e não como substituto	62
5.4.7	Limites da conclusão	64
5.5	O que permanece mensurável na decomposição	64
5.6	O sistema em operação	65
5.6.1	O que a porta de decisão estava a separar	66
5.6.2	O desempenho do modelo sobre as decisões que tomou	68
5.6.3	Deriva das distribuições	69
5.6.4	O sistema completo contra as alternativas existentes	70
5.7	Síntese dos resultados	71
6	Conclusões	75
6.1	Conclusões principais	75

6.2	As respostas às questões de investigação	76
6.2.1	Deteção de movimentos invulgares	76
6.2.2	Recuperação de precedentes	77
6.2.3	Triagem de notícias	78
6.3	Objetivos alcançados	79
6.4	Limitações	80
6.5	Trabalho futuro	83
6.6	Considerações finais	84
Bibliografia		85
A Reprodutibilidade		91
A.1	Artefactos conservados	91
A.2	Origem de cada resultado	91
A.3	Matriz de evidência	92
A.4	Dados, licenças e atribuição	95
A.5	Desenho do estudo com utilizadores	95
B Correspondência com o plano curricular		97

Lista de Figuras

1.1	Capitalização do mercado acionista dos EUA	2
1.2	Os dois gatilhos do sistema	3
2.1	Três gerações de representação de texto	9
2.2	As duas vias para a explicabilidade	14
3.1	As quatro decisões do sistema	20
3.2	A janela deslizante do z-score	22
3.3	Um movimento repartido em três parcelas	24
3.4	Frases como pontos num espaço	25
3.5	As nove entradas, por nível	26
3.6	Divisão temporal com embargo	27
4.1	Arquitetura do InvestiGator	32
4.2	Etapas do percurso iniciado por notícia	35
4.3	Seletividade do sistema por empresa	37
4.4	Distribuição das avaliações de um dia pelos pontos de decisão	39
4.5	Alerta entregue ao canal	40
4.6	Vistas da aplicação web	42
4.7	Ciclo de crescimento da base de casos	43
4.8	Ciclo de vida do componente aprendido	44
5.1	A forma comum aos quatro casos de estudo	47
5.2	As duas medidas da primeira questão	49
5.3	A regra transparente contra dois detetores aprendidos	51
5.4	Dois estimadores de volatilidade sobre o mesmo protocolo	52
5.5	Ablação à dimensão da janela	52
5.6	Recuperação: o método contra cinco alternativas	54
5.7	Recuperação por setor e sob a restrição temporal	55
5.8	Tema e direção não são a mesma propriedade	57
5.9	Seis modelos de triagem sobre o mesmo bloco de teste	58
5.10	O resultado sob nove definições alternativas de rótulo	59
5.11	Precisão dentro de um orçamento de cinco alertas por dia	60
5.12	O modelo desmontado entrada a entrada	61
5.13	Os três acréscimos, com intervalo de confiança	63
5.14	A decomposição discrimina entre empresas no mesmo dia	65
5.15	O que a porta de decisão separava	66
5.16	O modelo sobre as decisões que tomou em produção	68
5.17	Deslocamento das distribuições de entrada	69
5.18	O sistema contra as alternativas já disponíveis	70
6.1	As três questões de investigação e as respostas obtidas	76

Lista de Tabelas

2.1	As ferramentas existentes contra as três perguntas	6
2.2	Abordagens de representação de texto	11
2.3	Posicionamento do trabalho face à literatura	17
3.1	Conjuntos de dados utilizados	21
3.2	Conjuntos de empresas	21
4.1	Caracterização das três fontes de notícias	33
4.2	Limiares da política de decisão e sua proveniência	38
5.1	As medidas utilizadas e o valor que cada uma tem sem informação	48
5.2	Cada escolha, contra a alternativa que não ficou	72
6.1	As limitações e o trabalho que as encerraria	80
A.1	Cada resultado e o procedimento que o produz	93
A.2	Matriz de evidência	94
B.1	Correspondência com o plano curricular	98

Lista de Acrônimos

ARCH Autoregressive Conditional Heteroscedasticity.

BERT Bidirectional Encoder Representations from Transformers.

FNSPID Financial News and Stock Price Integration Dataset.

GARCH Generalized Autoregressive Conditional Heteroscedasticity.

IA Inteligência Artificial.

LIME Local Interpretable Model-agnostic Explanations.

PR-AUC Precision-Recall Area Under the Curve.

PSI Population Stability Index.

QI Questão de Investigação.

ROC-AUC Receiver Operating Characteristic Area Under the Curve.

SBERT Sentence-BERT.

SHAP SHapley Additive exPlanations.

Capítulo 1

Introdução

Este capítulo apresenta a contextualização do trabalho descrito nesta dissertação, o problema que motiva a sua realização, as questões de investigação e os objetivos definidos, as contribuições científicas e a organização do documento.

1.1 Contextualização

A aquisição de ações tornou-se uma operação de baixa fricção, acessível através de aplicações móveis e sem custos de corretagem significativos. A maioria dos adultos norte-americanos detém hoje ações, diretamente ou através de fundos e planos de reforma (Gallup 2025), num mercado cuja capitalização excede os 62 biliões de dólares (Securities Industry and Financial Markets Association (SIFMA) 2025), conforme representado na Figura 1.1.

A facilidade de acesso não se estendeu, contudo, à interpretação da informação. Quando o preço de um ativo se move, o investidor particular dispõe de instrumentos limitados para determinar o significado desse movimento.

O comportamento deste segmento é objeto de investigação corrente, e dois resultados recentes delimitam o problema tratado nesta dissertação. O primeiro é o de que a atenção do investidor particular constitui hoje uma quantidade medida, cujos indicadores são discutidos e comparados na literatura (Cahill, Zhangxin Liu e Smales 2025): aquilo que determina o que o investidor observa é estudado como variável, e não como acaso. O segundo é o de que a participação do investidor particular no mercado, e as condições em que negocia, permanecem tema de revisão ativa (Ernst e Spatt 2026). O Capítulo 2 desenvolve os mecanismos comportamentais que esta literatura documenta, e que explicam por que razão a ausência de contexto é mais onerosa para este público do que para um profissional.

Interessa reter deste conjunto o que delimita o problema. Os sinais que captam a atenção do investidor chegam-lhe sem contexto, e a decisão que se lhes segue é tomada sob condições que a literatura documenta como desfavoráveis. Três questões concretas permanecem por responder no momento em que o investidor observa um movimento de preço:

1. **o movimento é invulgar?** Uma variação de quatro por cento representa um acontecimento raro numa empresa de baixa volatilidade e um dia comum numa empresa volátil;
2. **a origem do movimento é a empresa ou o mercado?** Uma descida que acompanha o mercado e uma descida isolada correspondem a situações distintas;
3. **existem precedentes, e qual foi o seu desfecho?** A existência de dias comparáveis no passado, e do que se lhes seguiu, permite situar o movimento observado.

As aplicações gratuitas correntes apresentam a variação percentual e não respondem a nenhuma das três. Os terminais de informação financeira profissional respondem às três, com custos de subscrição incompatíveis com o perfil de investidor em causa. A lacuna não decorre da indisponibilidade de dados, que existem em quantidade e são gratuitos, mas da ausência de contexto verificável construído sobre eles.




Figura 1.1: Capitalização do mercado acionista dos Estados Unidos, 2015–2024, em bilhões de dólares. Elaborado a partir dos dados do SIFMA Capital Markets Fact Book (Securities Industry and Financial Markets Association (SIFMA) 2025).

1.2 Descrição do problema

Esta dissertação apresenta o InvestiGator, um sistema de alertas financeiros construído exclusivamente sobre fontes de dados gratuitas, que monitoriza um conjunto de empresas, deteta acontecimentos que se afastam do comportamento habitual de cada uma e emite alertas acompanhados da explicação e da evidência que os sustentam.

O sistema dispõe de dois gatilhos, representados na Figura 1.2: um movimento de preço invulgar para a empresa em causa, ou a chegada de uma notícia relevante sobre ela. Em ambos os casos, a mensagem entregue identifica o acontecimento, o critério pelo qual foi considerado invulgar, a proveniência dos dados utilizados e os casos passados semanticamente próximos, com o comportamento observado do preço após cada um deles.

Uma decisão de desenho atravessa o sistema e condiciona todas as restantes: **o sistema não produz previsões de preço**. Não indica direção futura, não emite recomendações de compra ou venda e não apresenta alvos de preço. Esta restrição tem duas justificações. A primeira é de verificabilidade: uma afirmação sobre um acontecimento passado pode ser confirmada contra o registo no momento em que é lida, ao passo que uma previsão só é avaliável depois de a decisão do investidor já ter sido tomada. A segunda é teórica: a hipótese dos mercados eficientes, na sua forma semiforte, torna improvável a antecipação sistemática de movimentos a partir de informação publicamente disponível. O Capítulo 2 desenvolve-a e identifica a literatura correspondente. Esta dissertação não testa essa hipótese nem se apoia nela para estabelecer qualquer conclusão.

1.3 Objetivos e questões de investigação

O objetivo geral desta dissertação é desenhar, construir e avaliar um sistema de alertas financeiros explicável para investidores particulares, utilizando exclusivamente fontes de dados




Figura 1.2: Os dois gatilhos do sistema e a saída que produzem. O investidor recebe um alerta acompanhado da evidência que permite verificá-lo, e não apenas a notificação de que o preço se moveu.

gratuitas.

Deste objetivo decorrem três questões de investigação, cada uma associada a uma medição e a um critério de sucesso definidos antes da execução das experiências:

- **Questão de Investigação (QI)1, detecção.** Consegue um método estatístico simples e transparente detetar movimentos invulgares de forma consistente entre empresas com volatilidades distintas, e fazê-lo melhor do que uma regra de limiar fixo?
- **QI2, precedentes.** Consegue o sistema recuperar notícias passadas de outra empresa do mesmo setor melhor do que alternativas triviais, e medir o comportamento subsequente do preço sem recorrer a informação posterior ao momento da consulta?
- **QI3, triagem.** Consegue um modelo treinado decidir que notícias justificam um alerta melhor do que uma linha de base baseada apenas em volatilidade?

A segunda questão do investidor, relativa à separação entre a componente de mercado e a componente específica da empresa, é tratada por uma técnica descrita no Capítulo 3 mas não dá origem a uma questão de investigação. A razão é metodológica: a repartição de um movimento não possui um valor de referência observável contra o qual possa ser comparada, uma vez que essa quantidade existe apenas relativamente a um modelo. A Secção 5.5 estabelece o que, apesar disso, permanece mensurável nessa técnica.

Estas questões concretizam-se em quatro objetivos:

1. construir o sistema completo, desde a aquisição de dados até à entrega do alerta;
2. avaliar cada componente contra linhas de base transparentes;
3. garantir que as explicações apresentadas são fiéis ao que o sistema calculou;
4. reportar os resultados obtidos, incluindo os que não confirmem as expectativas iniciais.

1.4 Contribuições científicas

Tratando-se de uma dissertação em Engenharia de Inteligência Artificial (IA), a contribuição não reside na formulação de um algoritmo novo, mas na seleção, integração e avaliação crítica de técnicas estabelecidas até constituírem um sistema funcional, explicável e reproduzível. Identificam-se quatro contribuições:

1. **Um sistema completo em funcionamento**, com os dois gatilhos, assente em fontes gratuitas e efetivamente implantado, e não uma demonstração laboratorial.

2. **Um método reprodutível para medir o comportamento do preço na sequência de notícias semanticamente próximas**, combinando recuperação por semelhança de frases com janelas de estudo de evento, sem utilização de informação posterior ao momento da decisão. O Capítulo 2 identifica as duas linhas de trabalho de que provêm.
3. **Um conjunto de dados próprio e um modelo treinado sobre ele**, com 79 753 exemplos construídos a partir do corpus público Financial News and Stock Price Integration Dataset (FNSPID) (Dong, Fan e Peng 2024) e de séries de preços, com o modelo, a calibração e as métricas conservados como artefactos versionados.
4. **Uma avaliação de cada componente contra linhas de base transparentes**, incluindo o resultado que contraria a hipótese inicial, reportado como tal.

1.5 Estrutura do documento

O Capítulo 2 apresenta o estado da arte, caracterizando o público-alvo, as ferramentas atualmente disponíveis e as áreas técnicas de onde provêm os componentes utilizados. O Capítulo 3 descreve os dados e as quatro técnicas que constituem o sistema. O Capítulo 4 descreve a arquitetura do InvestiGator e o percurso de uma notícia desde a recolha até à entrega. O Capítulo 5 apresenta o desenho experimental e os resultados obtidos para cada questão de investigação. O Capítulo 6 sintetiza as respostas, identifica as limitações do trabalho e enuncia as linhas de desenvolvimento futuro.

Cada mecanismo descrito é ilustrado sobre um caso real, com os valores efetivamente calculados pelo sistema, e não sobre exemplos construídos para o efeito.

Capítulo 2

Estado da arte

Este capítulo apresenta o enquadramento científico e tecnológico do trabalho. Caracteriza-se primeiro o público a que o sistema se dirige e as limitações que definem o problema; examinam-se depois as soluções atualmente disponíveis; percorrem-se por fim as áreas técnicas de onde provêm os componentes utilizados, situando a contribuição desta dissertação em relação a cada uma.

2.1 O investidor particular e o problema da atenção

Esta secção caracteriza o comportamento documentado do público a que o sistema se dirige, uma vez que são as limitações desse comportamento, e não a dimensão do mercado, que delimitam o problema tratado.

O Capítulo 1 estabeleceu a escala do universo em causa. A caracterização que falta é de comportamento, e começa por uma observação que contraria a representação corrente do investidor particular como agente que apenas reage em pânico. Durante a queda de março de 2020, os investidores particulares de uma plataforma sem comissões aumentaram as suas posições agregadas em vez de reduzirem a exposição (Welch 2022). Trata-se de um público que decide com regularidade, e que por isso beneficia de melhor informação no momento da decisão.

A literatura de finanças comportamentais estabelece que essas decisões se afastam de forma sistemática do ideal racional (Barberis e Thaler 2003). Duas regularidades condicionam diretamente o desenho de um sistema de alertas. A primeira é a aversão à perda (Kahneman e Tversky 1979), já enunciada no capítulo anterior, e cuja consequência para este trabalho é que o custo da ausência de contexto é assimétrico: é maior precisamente quando a informação é desfavorável.

A segunda é o efeito da atenção, e é a que fundamenta o problema. Barber e Odean (2008) estabelecem que os investidores particulares são compradores líquidos das ações que lhes captam a atenção, identificadas por três indicadores observáveis, que são a presença em notícias, o volume de transação anormal e o retorno extremo num único dia. O mecanismo proposto pelos autores é o do problema de procura: perante um número muito elevado de alternativas, o investidor não avalia todas e a sua escolha recai sobre o subconjunto que lhe foi tornado visível.

Os autores delimitam o alcance da afirmação, que respeita a um desequilíbrio agregado entre compras e vendas e não a um comportamento universal, e reportam a conclusão que justifica este trabalho: o padrão de aquisição assim formado não gera retornos superiores. A base empírica são registos de corretoras norte-americanas entre 1991 e 1999, anteriores à

negociação por telemóvel e à ausência de comissões, pelo que o que se assume transferível é o mecanismo e não os valores medidos. A centralidade da atenção neste processo é de tal ordem que se tornou mensurável através do volume de pesquisas na internet (Da, Engelberg e Gao 2011).

Os três indicadores identificados pela literatura são calculados por este sistema, mas o estatuto de cada um difere. A notícia e o movimento extremo constituem os dois gatilhos descritos no Capítulo 1 e podem, por si, originar um alerta. O volume é calculado e apresentado como contexto, e não interrompe o utilizador. A razão desta assimetria é empírica e está reportada na Secção 5.7: a combinação do volume com os restantes sinais melhorou a triagem em apenas um de três orçamentos considerados, resultado que não sustenta a introdução de uma terceira via de interrupção. A ideia de fundir sinais de origens distintas num indicador único provém de um painel de informação em tempo real com essa arquitetura (*World Monitor* 2026), sugerido pelo coorientador deste trabalho, e entra na dissertação na condição em que foi avaliada, ou seja como alternativa medida e não adotada.

Do lado das instituições financeiras, a adoção de inteligência artificial deixou de ser experimental, como documenta o inquérito a empresas do setor conduzido pelo Cambridge Centre for Alternative Finance (2026). Esse inquérito não mede a população dos produtos destinados ao investidor particular, pelo que não sustenta afirmações sobre ela; a caracterização dessa população assenta no que os próprios fornecedores declaram, e é objeto da secção seguinte.

2.2 Ferramentas de informação financeira para o retalho

Esta secção examina as soluções atualmente disponíveis, avaliando cada uma contra um critério fixo, que são as três perguntas enunciadas no Capítulo 1. A Tabela 2.1 apresenta o resultado dessa avaliação.

Tabela 2.1: As categorias de ferramenta existentes avaliadas contra as três perguntas do Capítulo 1. A classificação *parcial* indica que a ferramenta fornece matéria-prima para a resposta e deixa a interpretação ao utilizador.

Ferramenta	É invulgar?	Empresa ou mercado?	Já aconteceu?	Custo
Aplicação da corretora	não	não	não	incluído
Agregador de notícias	não	não	não	gratuito
Aplicação de sentimento	parcial	não	não	gratuito ou baixo
Gestor automático de carteira	não	não	não	percentagem da carteira
Terminal profissional	sim	sim	sim	milhares por ano
Este trabalho	sim	sim	sim	gratuito

A tabela evidencia o essencial. A linha que responde às três perguntas existe e é a mais dispendiosa de todas. O problema não é, portanto, de natureza científica, mas de acesso: as respostas são conhecidas e estão condicionadas a uma subscrição incompatível com o perfil de investidor em causa.

Três categorias merecem exame individual, uma vez que cada uma falha por uma razão distinta e essas razões informam decisões tomadas nos capítulos seguintes.

A aplicação da corretora é o instrumento de acesso mais imediato ao preço, e é aquele cuja documentação pública descreve o menor conjunto de indicadores. Apresenta a variação percentual do dia e um gráfico de preço. Não indica se essa variação é elevada para aquela ação em particular, não separa a componente de empresa da componente de mercado e não dispõe de memória de acontecimentos comparáveis.

Os alertas de preço oferecidos por estas aplicações partilham a mesma limitação de forma mais acentuada: disparam quando um limiar fixo é atravessado, critério que ignora a volatilidade própria de cada ação e que por isso produz alertas frequentes nas empresas agitadas e raros nas empresas calmas. Comunicam ainda que um nível foi ultrapassado, e nunca porquê. Esta observação determina a opção metodológica descrita na Secção 3.3, que substitui o limiar absoluto por uma medida relativa à norma recente de cada empresa, e cuja diferença é quantificada na Secção 5.2.

As aplicações de sentimento classificam notícias como positivas ou negativas e apresentam o resultado dessa classificação. Fornecem matéria-prima para a primeira pergunta e não avançam além dela. A Secção 5.3 apresenta ainda uma medição própria segundo a qual o tema de uma notícia e a direção do movimento que se lhe segue coincidem com menos frequência do que a intuição sugere, o que limita o alcance de uma pontuação de sentimento como indicador de impacto.

Os gestores automáticos de carteira respondem sobretudo a uma pergunta distinta, a da distribuição de capital por um conjunto de ativos. A literatura reconhece-lhes benefícios genuínos, embora não uniformes: D'Acunto, Prabhala e Rossi (2019) medem uma melhoria da diversificação e uma redução da volatilidade nos investidores que detinham menos de cinco ações antes da adesão, ao passo que para os que já detinham mais de dez o efeito sobre a diversificação é próximo de nulo. A contenção de enviesamentos comportamentais é o benefício mais consistentemente reportado (Cardillo e Chiappini 2024; D'Acunto, Prabhala e Rossi 2019). A diferença face a este trabalho é de objeto e não de transparência: um gestor automático recomenda uma carteira e executa-a, ao passo que este sistema não formula recomendações e entrega evidência sobre um acontecimento concreto. Acresce que a prestação de aconselhamento sobre investimentos constitui atividade regulada, fronteira que o presente trabalho evita por desenho, conforme discutido na Secção 3.8.3.

Existem, por fim, produtos recentes que declaram responder exatamente à pergunta tratada nesta dissertação. O Robinhood Cortex, anunciado em março de 2025, declara na página do próprio fornecedor destinar-se a responder à questão de saber por que razão uma ação está a subir ou a descer num dado dia (Robinhood Markets 2025). Os momentos-chave do Google Finance, apresentados em junho de 2026, propõem-se explicar por que razão uma ação se moveu (Google 2026). Trata-se da mesma pergunta, formulada por organizações com recursos e base de utilizadores incomparavelmente maiores.

A diferença situa-se no que as respetivas páginas declaram ser entregue. Ambas descrevem um resumo em linguagem natural, e nenhuma descreve a apresentação dos casos passados individualizados, com datas, semelhanças medidas e comportamento observado do preço após cada um, que é o que este trabalho entrega. A distinção reivindicada não é de fluência, mas de verificabilidade, e respeita ao que as páginas declaram: os produtos não foram testados, pelo que nada se afirma sobre o que efetivamente entregam.

A objeção mais razoável ao trabalho consiste em perguntar por que razão um assistente de inteligência artificial genérico não resolveria o mesmo problema. Não foi realizada uma comparação com nenhum desses assistentes, pelo que o que se segue é um argumento de desenho e não um resultado. Um assistente que não disponha de acesso externo a dados de mercado não dispõe de três elementos. O primeiro é a volatilidade recente da ação, que permite determinar se uma variação é elevada. O segundo é a separação entre a componente de mercado e a componente específica da empresa. O terceiro é uma base de casos passados sobre a qual efetuar uma recuperação.

Quanto a este último ponto, um modelo de linguagem recorda casos vistos durante o treino, o que não constitui recuperação e não é verificável pelo leitor. Existem modelos de grande dimensão especializados em texto financeiro, cuja capacidade está documentada (Li et al. 2023). A saída de qualquer deles permanece uma afirmação que se lê com facilidade e não se confere.

A literatura de explicabilidade dá razões para desconfiar dela. Lipton (2018) argumenta que a interpretabilidade não designa uma propriedade única e que um sistema deve declarar qual delas oferece. Rudin (2019) argumenta que uma explicação produzida sobre um modelo opaco é uma aproximação que pode induzir em erro. Nenhum dos dois trata de texto gerado por modelos de linguagem, pelo que a transposição é do autor e o que dela se retira é uma razão de desenho e não um resultado da literatura. É esta a razão pela qual a linguagem nunca produz factos neste sistema: os números provêm dos componentes que os calcularam, e o texto é composto a partir deles, conforme descrito na Secção 4.5.

2.3 Detecção de anomalias em séries temporais financeiras

Esta secção situa a primeira decisão do sistema no campo da deteção de anomalias e enuncia as famílias de método consideradas.

A deteção de anomalias constitui uma área estabelecida, com uma taxonomia consolidada que separa os métodos pela forma como definem normalidade (Chandola, Banerjee e Kumar 2009; Pang et al. 2021). Três famílias são relevantes para séries temporais financeiras.

A família estatística define normalidade a partir da distribuição local dos próprios dados, estimada numa janela deslizante, e assinala como anómalas as observações que dela se afastam além de um limiar. A explicação de uma deteção coincide com o cálculo que a produziu, o que a torna integralmente comunicável ao utilizador. Em contrapartida, supõe que a distribuição dos retornos é localmente estável.

A família aprendida não supervisionada define normalidade a partir da estrutura geométrica dos dados. O Isolation Forest (F. T. Liu, Ting e Zhou 2008) identifica como anómalos os pontos que uma partição aleatória isola com poucos cortes; o Local Outlier Factor (Breunig et al. 2000) identifica-os pela densidade reduzida face à dos seus vizinhos. Ambos dispensam rótulos e captam padrões multivariados que uma regra sobre uma única série não capta, ao custo de a decisão deixar de ser enunciável numa frase.

A família profunda aprende um modelo de normalidade através de uma rede (Pang et al. 2021). Oferece maior capacidade de representação, exige volumes de dados superiores e afasta-se do requisito de explicabilidade que estrutura este trabalho.

Uma restrição prática condiciona toda esta escolha. Em domínios financeiros vizinhos, como a deteção de fraude, os métodos não supervisionados ocupam posição central precisamente

porque anomalias rotuladas são escassas e os padrões se alteram ao longo do tempo (Ahmed, Mahmood e Islam 2016). A mesma condição verifica-se aqui: não existe um conjunto de dados em que tenha sido registado, dia a dia, que movimentos justificariam um alerta. Esta ausência determina a forma como o Capítulo 5 pode avaliar o componente, e é a razão pela qual a avaliação assenta num critério derivado dos próprios dados em vez de um julgamento humano.

A suposição de estabilidade local em que a família estatística assenta é confrontada e não escondida. Os modelos de volatilidade condicional, introduzidos por Engle (1982) e generalizados por Bollerslev (1986), formalizam o agrupamento de volatilidade, ou seja a tendência de os períodos calmos e os períodos agitados ocorrerem em séries. Ambos os artigos formalizam o fenómeno sobre séries de inflação, pelo que a sua transposição para retornos de ações não é assumida: a Secção 5.2 mede-a nos dados deste trabalho, comparando a janela de pesos iguais com uma variante que atribui maior peso às observações recentes. Uma janela deslizante acompanha parcialmente o fenómeno, uma vez que a norma contra a qual cada dia é comparado é reestimada diariamente a partir do passado próximo. A escolha não elimina o problema, e a medição referida quantifica o que custa mantê-la.

A comparação entre a família estatística e a família aprendida não permanece no plano do argumento. O Capítulo 5 executa ambas sobre os mesmos dados e reporta o resultado obtido.

2.4 Representação de texto e recuperação semântica

Esta secção percorre as formas de representar texto que tornam possível comparar notícias por significado, e enuncia o critério de avaliação da recuperação que delas decorre.

A comparação de notícias por significado depende inteiramente da representação adotada, e essa representação atravessou três gerações, esquematizadas na Figura 2.1 e detalhadas na Tabela 2.2.




Figura 2.1: As três gerações de representação de texto. Cada uma resolve uma limitação identificada na anterior, e a terceira é a que permite comparar duas frases diretamente pela posição dos respetivos vetores.

A primeira geração representa um documento pela frequência dos termos que contém. O modelo de espaço vetorial (Salton, Wong e C. S. Yang 1975) é transparente e computacionalmente barato, e é cego a sinónimos: os termos “subiu” e “valorizou” constituem, para esta representação, símbolos sem relação. Dentro da mesma geração existe uma segunda linha, oriunda de um quadro probabilístico distinto, a das funções de ordenação de que o BM25 (Robertson e Zaragoza 2009) é o representante corrente; ambas permanecem linhas de base fortes em recuperação de informação e partilham aquela cegueira. Em texto financeiro existe ainda uma variante especializada, os léxicos de domínio, que corrigem o facto

de os dicionários de sentimento genéricos interpretarem incorretamente palavras correntes na linguagem financeira (Loughran e McDonald 2011). São integralmente transparentes, e ficam limitados ao vocabulário que foi compilado.

A segunda geração representa cada palavra como um vetor num espaço onde a proximidade traduz uso semelhante, aprendido a partir do contexto local (Mikolov et al. 2013) ou da coocorrência global (Pennington, Socher e Manning 2014). Esta representação aproxima sinónimos, resolvendo a limitação anterior, e introduz uma nova: cada palavra recebe um vetor único, independentemente da frase em que ocorre.

A terceira geração remove essa limitação. O Transformer (Vaswani et al. 2017) tornou viável o processamento da frase completa com dependências de longo alcance, e o Bidirectional Encoder Representations from Transformers (BERT) (Devlin et al. 2019) produziu representações contextuais, nas quais o vetor de uma palavra depende das que a rodeiam. Um passo adicional é necessário para o problema aqui tratado: comparar duas frases com um modelo dessa natureza exigiria processá-las conjuntamente, uma vez por par, o que não é praticável sobre uma base com dezenas de milhares de casos. O Sentence-BERT (SBERT) (Reimers e Gurevych 2019) resolve esta questão produzindo um vetor por frase, calculado uma única vez, de modo que a comparação passa a ser uma operação aritmética entre vetores já existentes.

A contribuição do SBERT que importa a este trabalho não reside na arquitetura mas no objetivo de treino: os vetores são aprendidos de forma que a distância entre dois deles traduza semelhança de sentido. Os autores reportam que um codificador da família BERT utilizado diretamente para comparar frases produz representações fracas para esse fim, ficando por vezes atrás da média simples de vetores de palavra (Reimers e Gurevych 2019). Daqui decorre que um codificador ajustado a outra tarefa não herda esta propriedade pelo facto de ter sido treinado no domínio adequado.

Para texto financeiro existem modelos treinados especificamente para o domínio (A. H. Huang, Wang e Y. Yang 2023; Zhuang Liu et al. 2020). A suposição natural é a de que sejam superiores nesta tarefa por essa razão. A suposição não é automaticamente verdadeira, e a Secção 5.3 mede-a em vez de a assumir.

O trabalho inscreve-se na literatura mais vasta de processamento de linguagem natural aplicado a finanças. A revisão de Kearney e S. Liu (2014) cobre o estado dessa área até 2014, dominado pelos léxicos de domínio e por classificadores supervisionados sobre contagens de palavras; as representações contextuais de frase utilizadas neste trabalho são posteriores e não constam dessa revisão. Existe ainda uma linha de investigação substancial que utiliza texto para antecipar movimentos de preço (Ding et al. 2015; Xing, Cambria e Welsch 2018). O presente trabalho situa-se fora dessa linha por opção de desenho: o texto é aqui empregue para localizar casos anteriores comparáveis, cujo desfecho já ocorreu e já foi medido, e não para gerar uma previsão.

A representação de cada notícia por um vetor converte a identificação de casos comparáveis num problema de recuperação de informação. A medida de proximidade adotada é a semelhança do cosseno, cuja mecânica é descrita na Secção 3.5. A operação é exata, uma vez que se percorre a totalidade da base de casos e se ordena o resultado, pelo que este não depende de qualquer aproximação. A escalas substancialmente superiores, a procura exaustiva pode ser substituída por um índice aproximado (Johnson, Douze e Jégou 2021) sem alteração da representação, o que constitui caminho de crescimento e não necessidade presente.

Tabela 2.2: As abordagens consideradas para representar notícias financeiras, com a representação que cada uma produz e as implicações da sua adoção.

Abordagem	Representação	Forças e limitações
Contagem de termos (Robertson e Zaragoza 2009; Salton, Wong e C. S. Yang 1975)	Frequência ponderada de palavras	Transparente e rápida; cega a sinónimos
Léxicos financeiros (Loughran e McDonald 2011)	Listas de palavras com polaridade atribuída	Totalmente transparente; limitada ao vocabulário compilado
Vetores de palavra (Mikolov et al. 2013; Pennington, Socher e Manning 2014)	Um vetor fixo por palavra	Aproxima sinónimos; um só sentido por palavra
Vetores de frase (Devlin et al. 2019; Reimers e Gurevych 2019)	Um vetor por frase, sensível ao contexto	Compara frases diretamente; modelo maior e menos legível internamente
Modelos de domínio (A. H. Huang, Wang e Y. Yang 2023; Zhuang Liu et al. 2020)	Como acima, ajustada a texto financeiro	Vocabulário do domínio; superioridade nesta tarefa não é automática
Modelos de grande dimensão (Li et al. 2023)	Geração de texto sobre conhecimento amplo	Capacidade elevada; dispendiosos, opacos e fora da restrição de gratuidade

Uma vez que a recuperação devolve uma lista ordenada, a sua avaliação recorre a medidas sensíveis à ordem (Manning, Raghavan e Schütze 2008). A adotada neste trabalho é a precisão nos k primeiros resultados, ou seja a fração desses k resultados que são relevantes. A definição de relevância, que é onde uma avaliação desta natureza se decide, é estabelecida na Secção 3.5 juntamente com as linhas de base contra as quais o resultado é comparado.

2.4.1 Recuperação com geração, e por que razão o sistema para antes dela

A arquitetura hoje corrente para responder a uma pergunta a partir de um corpo de documentos é a geração aumentada por recuperação, na qual um recuperador seleciona passagens e um modelo de linguagem redige a resposta a partir delas (Lewis et al. 2020). A literatura sobre a família é extensa e encontra-se sistematizada (Y. Huang e J. X. Huang 2026).

O sistema aqui descrito executa a primeira metade dessa arquitetura e detém-se antes da segunda, e a razão é a mesma que atravessa o trabalho. A recuperação devolve objetos verificáveis: um título, uma data, uma semelhança medida e um movimento de preço observado. A geração converte esses objetos numa afirmação em prosa, cuja fidelidade ao que foi recuperado é ela própria uma propriedade a avaliar, e que o destinatário deste sistema não tem meios para confrontar. A opção não decorre de limitação técnica, e a distinção deve ser feita com clareza: acrescentar a geração é possível e barato; o que não é barato é a avaliação de que ela não desloca o significado da evidência. Nenhuma comparação com uma arquitetura completa foi realizada neste trabalho, pelo que o que aqui se afirma é uma razão de desenho e não um resultado.

2.4.2 Corpora de notícias financeiras e rótulos de setor

A avaliação de recuperação sobre notícias financeiras exige um corpo de texto alinhado com preços, e esse alinhamento é o que distingue um corpus utilizável de uma coleção de títulos. O conjunto utilizado neste trabalho é o FNSPID (Dong, Fan e Peng 2024), que reúne notícias e séries de preços correspondentes e cuja construção está documentada.

A relevância entre duas notícias é aproximada, neste trabalho, pela pertença ao mesmo setor. A opção substitui uma anotação humana inexistente por um critério objetivo, e transporta a limitação correspondente: a validade de um agrupamento é uma propriedade mensurável, seja pela separação entre grupos (Rousseuw 1987), seja pela concordância entre agrupamentos alternativos corrigida para o acaso (Vinh, Epps e Bailey 2010), e nenhuma dessas medidas foi aplicada ao mapa setorial adotado. O que o rótulo garante é objetividade e reprodutibilidade, e não que o setor seja a partição mais informativa do corpus.

2.5 Estudos de evento e decomposição de retornos

Esta secção apresenta o instrumento com que se mede o efeito de um acontecimento sobre o preço, bem como a correção estatística de que depende a separação entre a componente de empresa e a componente de mercado.

O instrumento adotado é o estudo de evento, cuja formulação remonta a Fama et al. (1969). O comportamento do método sobre retornos diários foi examinado por Brown e Warner (1985), que confrontam formas alternativas de estimar o retorno esperado e concluem que os procedimentos correntes, assentes na estimação do modelo de mercado por mínimos quadrados, permanecem bem especificados em janelas curtas em torno do acontecimento.

O alcance desta conclusão é delimitado pelos próprios autores: a variante mais simples, que subtrai apenas a média histórica da ação, perde potência estatística e pode tornar-se mal especificada quando as datas dos acontecimentos coincidem. É este resultado que motiva a ordem de grandeza das janelas de um, três e cinco dias adotadas neste trabalho. A transposição não é direta, e a diferença está declarada na Secção 3.5, segundo a qual o valor apresentado ao utilizador é o retorno bruto e não o retorno anormal que aqueles autores estudam.

A existência de uma relação estatística entre o texto publicado e os movimentos do mercado é observação antiga (Tetlock 2007). O verbo adequado é o da evidência de uma relação estatística, e não o da demonstração de causalidade.

Um ponto metodológico condiciona a segunda pergunta do trabalho, a da separação entre a empresa e o mercado. Essa separação exige estimar a sensibilidade de cada ação ao mercado, e a estimativa é ruidosa, sobretudo em empresas voláteis ou com histórico curto. Blume (1971) estabelece que os coeficientes assim estimados tendem a regredir para a média entre períodos sucessivos, ou seja que uma estimativa extrema num período tende a sê-lo menos no seguinte; daí decorreu a prática, corrente mas posterior ao próprio artigo, de encolher a estimativa com um peso fixo. Essa prática aplica a mesma correção a estimativas precisas e imprecisas. A alternativa adotada neste trabalho pondera o encolhimento pela imprecisão da própria estimativa (Vasicek 1973), de modo que uma estimativa fiável é praticamente preservada e uma estimativa frágil é aproximada do valor de referência. A formulação é apresentada na Secção 3.4.

O enquadramento teórico que justifica a recusa de prever pertence igualmente a esta área. A hipótese dos mercados eficientes, na sua forma semiforte, sustenta que os preços refletem já a informação publicamente disponível (Fama 1970), do que decorre que movimentos futuros não deveriam ser sistematicamente previsíveis a partir dessa informação. Constitui uma das razões pelas quais o sistema mede o que já ocorreu em vez de projetar o que virá; a segunda, de natureza prática, é que apenas o passado é verificável por quem lê.

2.6 Raciocínio baseado em casos

Esta secção enquadra a terceira técnica do sistema numa linha estabelecida de inteligência artificial e delimita a parte dessa linha que o trabalho implementa.

O raciocínio baseado em casos (Aamodt e Plaza 1994) aborda um problema novo através da recuperação de problemas anteriores semelhantes e do aproveitamento do que sobre eles é conhecido, dispensando o recurso exclusivo a conhecimento geral do domínio. A fonte organiza o método num ciclo de quatro processos, a saber recuperar, reutilizar, rever e reter, e considera os quatro necessários à resolução completa de um problema.

A técnica descrita na Secção 3.5 implementa os dois primeiros e interrompe-se deliberadamente antes dos restantes: recupera casos semelhantes e apresenta o que neles foi medido, sem adaptar esse desfecho ao caso presente. A adaptação produziria uma expectativa sobre o que virá a acontecer, ou seja precisamente a previsão que o trabalho recusa. A implementação parcial de um ciclo estabelecido é, neste caso, uma consequência da restrição fundadora e não uma insuficiência.

A opção encontra apoio adicional do lado de quem lê. A investigação sobre explicação em ciências sociais estabelece que as pessoas procuram razões contrastivas e seletivas, e não

uma enumeração exaustiva de tudo o que contribuiu para um resultado (Miller 2019). Um conjunto reduzido de casos concretos, com data e desfecho, corresponde melhor a essa expectativa do que um coeficiente. É por essa razão que cada alerta apresenta alguns precedentes e as quantidades exatas que sustentam a decisão, em vez da totalidade dos valores calculados.

Há um segundo requisito, do mesmo lado, que condiciona não o conteúdo da explicação mas a frequência com que ela é entregue. Um destinatário exposto a avisos em excesso deixa de os processar, fenómeno documentado em domínios onde o custo de o ignorar é elevado (Ancker et al. 2017). A consequência para este trabalho é que a política de decisão não é um acessório do sistema mas parte do seu desenho: um alerta que não é lido tem o mesmo valor de um alerta que não foi enviado, e é por isso que o Capítulo 4 trata os critérios de supressão com o mesmo cuidado com que trata os métodos que produzem o alerta.

2.7 Explicabilidade e confiança em sistemas automáticos

Esta secção situa o requisito de explicabilidade que atravessa o trabalho e apresenta as cautelas que a literatura associa à apresentação de explicações.

A exigência de que um sistema demonstre como chegou a uma conclusão constitui uma área própria, com revisões consolidadas (Adadi e Berrada 2018; Barredo Arrieta et al. 2020). A área divide-se em duas vias, representadas na Figura 2.2: os modelos transparentes, interpretáveis em si mesmos, e os métodos *a posteriori*, que explicam um modelo opaco já treinado e que podem ser organizados pelo tipo de objeto que explicam (Guidotti et al. 2018).




Figura 2.2: As duas vias distinguidas pela literatura (Barredo Arrieta et al. 2020; Guidotti et al. 2018): construir modelos transparentes por desenho, ou explicar um modelo opaco depois de treinado. Este trabalho segue a primeira.

Os dois métodos *a posteriori* de utilização mais generalizada operam de formas distintas. O LIME ajusta um modelo simples na vizinhança de uma previsão individual, aproximando localmente o comportamento do modelo opaco (Ribeiro, Singh e Guestrin 2016). O SHAP atribui uma previsão às variáveis que a produziram recorrendo a valores de Shapley (Lundberg e S.-I. Lee 2017). Ambos são genéricos e ambos são úteis.

Ambos partilham, contudo, uma propriedade determinante neste contexto. Perante decisões de consequência séria, Rudin (2019) defende o abandono dos modelos opacos em favor de modelos interpretáveis por construção, com o argumento de que toda a explicação *a posteriori* constitui ela própria uma aproximação, e uma aproximação pode conduzir a leituras erradas. O utilizador recebe nesse caso dois objetos cuja relação não está em condições de avaliar, que são uma decisão e uma explicação que pode não lhe corresponder.

Este trabalho segue a via conservadora. Em lugar de explicar *a posteriori* um modelo opaco, recorre a componentes em que a explicação e o cálculo coincidem. Um afastamento face a uma norma recente, uma repartição aditiva cuja soma reproduz o movimento observado e um conjunto de casos anteriores com os desfechos medidos constituem objetos apresentáveis por inteiro. A explicação não constitui um segundo objeto produzido sobre a decisão: é a decisão, enunciada por extenso.

Duas cautelas da literatura fecham esta secção, e ambas condicionam a organização do Capítulo 5.

A primeira é que interpretabilidade não designa uma propriedade única (Lipton 2018), pelo que um sistema deve declarar o tipo de interpretabilidade que oferece em vez de reclamar o termo sem qualificação. Este trabalho oferece transparência de mecanismo, ou seja o utilizador pode seguir o cálculo que conduziu à decisão, e não oferece uma explicação causal do acontecimento no mundo.

A segunda respeita ao efeito da própria explicação sobre quem a recebe. A confiança em sistemas automáticos falha em dois sentidos simétricos, com o utilizador a ignorar um aviso correto ou a aceitar um aviso incorreto, pelo que o objetivo não é maximizar a confiança mas torná-la ajustada à capacidade real do sistema (J. D. Lee e See 2004). Bansal et al. (2021) acrescentam que a presença de uma explicação aumenta a probabilidade de aceitação da resposta do sistema quer esta esteja certa quer esteja errada, ou seja que o ganho observado não decorre de a pessoa passar a distinguir melhor os dois casos. As consequências de desenho que daqui decorrem estão descritas na Secção 3.8.3.

Acresce que afirmações de interpretabilidade exigem avaliação rigorosa e não se estabelecem por declaração (Doshi-Velez e Kim 2018). É por essa razão que o Capítulo 5 mede o que é mensurável por procedimento automático e identifica explicitamente a parte que permanece por avaliar por ausência de um estudo com utilizadores.

2.8 Aprendizagem automática em ambiente de produção

Esta secção reúne a literatura relativa ao componente aprendido do sistema, organizada segundo as três questões que a sua implantação levanta.

A primeira questão é a de determinar contra que referência superior comparar um modelo simples. Conjuntos de árvores treinados por reforço do gradiente (Friedman 2001) captam interações e efeitos não lineares que uma regressão logística não capta, e desempenham por isso essa função no Capítulo 5. Não se afirma que constituam o melhor método existente, uma vez que tal seria uma afirmação sobre um campo inteiro.

A segunda questão respeita à honestidade do valor apresentado. Uma pontuação só é interpretável como probabilidade se estiver calibrada, e as pontuações em bruto de muitos classificadores não o estão; a calibração *a posteriori* sobre um bloco de validação reservado corrige essa distorção (Niculescu-Mizil e Caruana 2005). A mesma fonte não favorece,

contudo, a opção tomada neste trabalho: identifica a regressão logística como já bem calibrada à partida e conclui que, acima de cerca de mil casos de calibração, a regressão isotónica iguala ou supera a sigmoide. O modelo implantado é uma regressão logística com um bloco de validação muito acima desse limiar, pelo que ambas as afirmações se lhe aplicam. A opção justifica-se por medição e não por autoridade: a comparação das duas variantes sobre a mesma validação está reportada na Tabela 5.2.

Uma via alternativa foi considerada e não adotada. A predição conformal devolve um conjunto de rótulos com uma garantia livre de distribuição, válida em amostras finitas (Angelopoulos e Bates 2023; Vovk, Gammerman e Shafer 2005). Duas precisões determinam que não é aplicável nas condições deste trabalho. A cobertura da variante corrente é marginal: vale em média sobre os casos, e não caso a caso. E a garantia exige permutabilidade entre o bloco de calibração e o de teste, hipótese que a divisão cronológica com embargo da Secção 3.6 recusa por construção. A Secção 6.5 retoma o método como caminho a explorar.

A terceira questão é a da permanência do desempenho ao longo do tempo. Um modelo implantado enfrenta alteração da distribuição dos dados que observa, e a literatura de deriva de conceito estabelece a taxonomia dessa mudança e as estratégias de deteção e adaptação (Gama et al. 2014). Este trabalho mede a deriva sobre os seus próprios dados em vez de assumir ausente.

Existe, por fim, um custo que não é captado por nenhuma métrica de qualidade. D. Sculley et al. (2015) estabelecem que os componentes de aprendizagem automática acumulam manutenção oculta, em particular através do emaranhamento entre peças e de dependências de dados instáveis e não declaradas. O Capítulo 6 regressa a este ponto com um exemplo medido no presente sistema, em que parte do ciclo de aprendizagem se interrompeu sem que qualquer erro fosse registado.

2.9 Síntese e posicionamento do trabalho

Esta secção localiza o trabalho relativamente à revisão apresentada e enuncia as decisões de âmbito que dela decorrem.

A revisão permite delimitar com precisão o espaço em que o trabalho se inscreve, e esse espaço não constitui um vazio técnico. Cada componente utilizado existe, está publicado e está avaliado, como a Tabela 2.3 torna explícito.

A lacuna não é, portanto, de método, mas de integração sob restrição. Os produtos que respondem às três perguntas são terminais profissionais, que não são disponibilizados em regime gratuito nem em regime acessível ao investidor particular; o seu preço não é publicado de forma que permita citá-lo aqui, e é a indisponibilidade, e não um valor concreto, que sustenta o argumento. Os produtos gratuitos que declaram responder à terceira entregam uma afirmação sem a evidência que a sustenta. E os componentes académicos que resolveriam cada parte foram avaliados isoladamente, sobre corpora de referência, e não como um sistema em funcionamento contínuo contra fontes reais.

Esta observação determina a distinção que atravessa o trabalho e que o Capítulo 4 retoma ao justificar a ausência de um modelo de linguagem na composição das mensagens. Uma frase gerada é uma afirmação: apresenta-se ao leitor num registo fluente e não lhe fornece meios para a confrontar com aquilo que a sustenta. Uma frase composta a partir de objetos

2.9. Síntese e posicionamento do trabalho

Tabela 2.3: Cada componente do sistema existe na literatura de forma isolada. O que não existe é a sua combinação sob a restrição de custo nulo, com a evidência entregue ao utilizador no momento em que a afirmação lhe é apresentada.

Pergunta	O que a literatura oferece	O que falta ao público-alvo
É invulgar?	Deteção de anomalias, estatística e aprendida (Chandola, Banerjee e Kumar 2009; F. T. Liu, Ting e Zhou 2008)	Uma medida relativa à norma da própria empresa, comunicada em linguagem acessível
É a empresa ou o mercado?	Estudo de evento e estimação de sensibilidade (Brown e Warner 1985; Vasicek 1973)	Disponibilidade fora de um terminal profissional
Já aconteceu antes?	Representação de frases e recuperação (Manning, Raghavan e Schütze 2008; Reimers e Gurevych 2019)	Uma base de casos com desfechos medidos, e não recordados
Por que razão acreditar?	Explicabilidade e literatura de confiança (J. D. Lee e See 2004; Rudin 2019)	A evidência entregue junto da afirmação e verificável no momento da leitura

calculados é uma afirmação acompanhada da evidência, na qual cada valor apresentado remete para a medição que o produziu e o leitor pode confirmar cada elemento no momento em que o lê. É esta a propriedade que o sistema procura preservar, e é ela que fixa a natureza da contribuição. Não é a formulação de um método novo. É a seleção, integração e avaliação crítica de métodos existentes num sistema funcional, sob restrições declaradas, e com os resultados que não favorecem as opções tomadas incluídos na avaliação.

Quatro decisões de âmbito decorrem deste posicionamento, e cada uma exclui deliberadamente uma classe de funcionalidade.

Responder às três perguntas, e apenas a essas. Não são incorporadas funcionalidades que não sirvam uma delas, o que mantém o sistema com dimensão compatível com a sua explicação integral.

Não produzir previsões de preço. Nem direção, nem alvo, nem recomendação. Além da razão de verificabilidade enunciada no Capítulo 1, aplica-se o enquadramento teórico da Secção 2.5 (Fama 1970).

Não gerir carteiras nem prestar aconselhamento. O sistema não conhece as posições do utilizador e não lhe indica que ação tomar, o que evita a recolha de dados pessoais e mantém o trabalho fora da fronteira do aconselhamento financeiro regulado.

Utilizar exclusivamente fontes gratuitas. A restrição torna o sistema acessível ao público a que se destina e converte as limitações resultantes em quantidades medidas e reportadas.

A última decisão tem um custo real que importa enunciar sem atenuação. As notícias chegam com atraso e a cobertura dos acontecimentos é incompleta. O Capítulo 4 quantifica ambas as limitações e o Capítulo 6 avalia as suas consequências.

Capítulo 3

Métodos e materiais

O Capítulo 2 estabeleceu que as três perguntas do investidor particular têm resposta na literatura mas não em nenhuma ferramenta gratuita. Este capítulo descreve as opções tomadas para lhes responder. Apresenta-se primeiro a metodologia de investigação e os conjuntos de dados. Descrevem-se em seguida os quatro métodos selecionados, um para cada decisão que o sistema tem de tomar. Indicam-se as ferramentas empregues. E enunciam-se, por fim, os desafios tecnológicos e sociais do domínio.

3.1 Metodologia de investigação

Esta dissertação enquadra-se na investigação por desenho (Hevner et al. 2004), na qual o objeto de estudo é um artefacto construído para resolver uma classe de problema e o conhecimento produzido reside tanto no artefacto como no processo da sua avaliação. Trata-se do enquadramento adequado quando a contribuição é um sistema, e distingue-se de um estudo puramente empírico pelo facto de o objeto avaliado não existir antes da sua construção.

A literatura de investigação por desenho estabelece que a avaliação do artefacto deve ser rigorosa e constituir uma atividade central do processo, e não um passo final de confirmação (Hevner et al. 2004; Peffers et al. 2007). Este requisito é cumprido através de três compromissos assumidos antes da execução das experiências.

O primeiro consiste em comparar cada componente com uma alternativa mais simples, selecionada e declarada antes de a medição ser realizada, de modo que o resultado possa ser negativo. O segundo consiste em fixar o critério de sucesso de cada comparação juntamente com a métrica, e não após a observação dos valores obtidos. O terceiro consiste em avaliar o artefacto duas vezes: sobre dados históricos retidos e, posteriormente, em funcionamento, sobre as decisões que o sistema toma autonomamente em produção. A terceira avaliação é a menos comum das três e é a que produz o resultado descrito na Secção 5.6.

A exigência não é cumprida na totalidade, e a lacuna é declarada. Utilidade, no sentido em que a literatura de investigação por desenho emprega o termo, é utilidade para quem usa o artefacto, e essa propriedade determina-se com utilizadores. O que nesta dissertação foi medido é a fidelidade das explicações produzidas, propriedade que pertence ao sistema; a utilidade, que depende da relação entre o sistema e quem o lê, permanece por medir.

O sistema toma quatro decisões distintas, representadas na Figura 3.1. As três primeiras correspondem às questões enunciadas no Capítulo 1; a quarta não é uma questão do investidor, mas do próprio sistema, e existe porque responder às três primeiras não implica interromper o utilizador.




Figura 3.1: As quatro decisões do sistema e a família de técnicas associada a cada uma. As três primeiras correspondem às perguntas enunciadas no Capítulo 1. A cada coluna corresponde uma secção deste capítulo, entre a Secção 3.3 e a Secção 3.6.

3.2 Conjuntos de dados

Esta secção descreve os conjuntos de dados utilizados no treino e na avaliação do sistema, bem como os registos produzidos pelo sistema em funcionamento.

A camada histórica assenta no FNSPID (Dong, Fan e Peng 2024), um corpus público de notícias financeiras que associa a cada título uma data e uma empresa. O corpus não contém preços, reação de mercado nem qualquer indicação de relevância: essa informação é construída neste trabalho, alinhando cada título com as séries de preços correspondentes. Do alinhamento resulta o conjunto de treino do modelo de triagem, com 79 753 exemplos.

A avaliação do detetor de anomalias utiliza um conjunto distinto, composto por três anos de cotações diárias. A escolha de um conjunto próprio é deliberada: a avaliação exige variedade de volatilidade entre empresas, ao passo que a lista monitorizada em produção é uma decisão de produto. Avaliar o detetor exatamente sobre o conjunto que ele foi construído para servir produziria uma medição sem valor informativo.

Todos os preços utilizados são fechos ajustados para desdobramentos e distribuição de dividendos. O ajuste não é um pormenor no período considerado, que contém um desdobramento de quatro para um da Apple e dois da Tesla: sobre séries não ajustadas, o detetor assinalaria quedas de trinta a oitenta por cento em dias sem qualquer acontecimento.

A Tabela 3.1 reúne os conjuntos utilizados, e a Tabela 3.2 os conjuntos de empresas, cujas contagens diferem por razões descritas na coluna respetiva.

3.3 Detecção de movimentos invulgares

A primeira decisão do sistema consiste em determinar se o movimento observado num dia é invulgar para a empresa em causa. Uma regra de limiar fixo, do tipo assinalar variações superiores a três por cento, é inadequada para este fim, porque a mesma percentagem corresponde a acontecimentos de raridade muito distinta consoante a volatilidade da empresa.

O método adotado pertence à família estatística da taxonomia de deteção de anomalias (Chandola, Banerjee e Kumar 2009), que define normalidade a partir da distribuição recente dos próprios dados. O movimento do dia é comparado com o comportamento recente da mesma ação e expresso em desvios-padrão:

$$z_t = \frac{r_t - \mu}{\sigma} \quad (3.1)$$

3.3. Detecção de movimentos invulgares

Tabela 3.1: Conjuntos de dados utilizados no trabalho, com o intervalo temporal e a dimensão lidos dos ficheiros. As três últimas linhas correspondem ao sistema em funcionamento.

Conjunto	Intervalo	Dimensão
<i>Histórico</i>		
Conjunto de treino da triagem	2018-01-02 a 2023-12-18	79 753 exemplos, 14 empresas
Preços para avaliação da deteção	2023-06-01 a 2026-06-01	15 empresas, $\approx$ 750 dias cada
<i>Operação</i>		
Base de precedentes implantada	um ano de recolha própria	38 214 casos com impacto medido
Alertas entregues	2026-07-09 a 2026-08-13	367 mensagens
Registo de decisões de triagem	2026-07-22 a 2026-08-15	4 366 decisões

Tabela 3.2: Conjuntos de empresas utilizados. As contagens diferem porque cada conjunto serve um propósito distinto. Os conjuntos não são encaixados: a lista monitorizada em produção contém duas empresas ausentes de todos os conjuntos históricos.

Conjunto	Empresas	Propósito
Mapa de setores alargado	17	Universo percorrido pela decomposição do movimento
Mapa canónico do histórico	15	Rótulo de relevância na avaliação da recuperação
Preços para a deteção	15	Variedade de volatilidade na avaliação do detetor
Conjunto de dados da triagem	14	Resultado do alinhamento entre notícias e preços
coberto pelo bloco de treino	13	Empresas efetivamente presentes no treino
coberto pelo bloco de teste	9	Empresas presentes na avaliação
Lista monitorizada em produção	12	Decisão de produto

onde r_t é o retorno logarítmico do dia, $r_t = \ln(P_t/P_{t-1})$, e μ e σ são a média e o desvio-padrão dos retornos dos vinte dias anteriores. A utilização de retornos logarítmicos segue a convenção corrente em séries financeiras, por tornar os retornos aditivos ao longo do tempo e simétricos entre subidas e descidas. Os valores apresentados diferem, por essa razão, dos exibidos por uma aplicação de bolsa: um retorno logarítmico de +19,82% corresponde a uma variação de preço de +21,92%.

A janela desliza a cada dia, e o dia avaliado é excluído da janela que define a sua própria norma, como representado na Figura 3.2. Sem esta exclusão, o dia contribuiria para a média e para o desvio-padrão contra os quais é comparado, atenuando a sua própria anomalia. A mesma disciplina impede a utilização de qualquer informação posterior ao dia avaliado.




Figura 3.2: A janela que estabelece o comportamento habitual da ação. O dia avaliado **fica de fora** do cálculo da norma contra a qual é comparado, separação que impede a utilização de informação indisponível no momento da decisão.

Quando o desvio-padrão da janela é nulo, a Equação 3.1 não está definida. O sistema distingue dois casos: a manutenção do valor constante não constitui anomalia, ao passo que um afastamento dessa norma plana é assinalado sem lhe ser atribuído um valor de z , indicando-se que a variância anterior era nula. Esta distinção evita que a proteção contra a divisão por zero silencie precisamente o primeiro movimento após um período constante.

A aplicação do método ao maior movimento do período estudado, registado pela Tesla a 24 de outubro de 2024, produz um retorno diário de +19,82% contra uma média de -0,92% e um desvio-padrão de 2,72% nos vinte dias anteriores, o que corresponde a $z = +7,61$. O valor não decorre da dimensão absoluta do movimento, mas do facto de este exceder em sete vezes e meia a oscilação habitual da ação naquelas semanas.

3.4 Decomposição do movimento observado

A técnica anterior quantifica a dimensão do movimento, mas não identifica a sua origem. A segunda decisão do sistema consiste em repartir o retorno observado nas suas componentes de mercado, de setor e específica da empresa:

$$r = \underbrace{\beta_m r_m}_{\text{mercado}} + \underbrace{\beta_s \tilde{r}_s}_{\text{setor}} + \underbrace{\varepsilon}_{\text{empresa}} \quad (3.2)$$

As variáveis r_m e $\tilde{r}_s$ designam, respetivamente, o retorno diário do índice de mercado e o do setor, ao passo que β_m e β_s quantificam a sensibilidade histórica da ação a cada uma dessas fontes. A componente específica da empresa é definida como o resíduo, pelo que a soma das três parcelas reproduz sempre o movimento observado. O mercado é representado pelo fundo cotado que segue o índice largo norte-americano, e o setor pelo fundo setorial

3.4. Decomposição do movimento observado

correspondente, escolhidos por serem os mais líquidos da sua classe e por disporem de histórico longo em fontes gratuitas.

Três aspetos determinam a validade da repartição.

O primeiro é a ortogonalização do fator setorial. Um fundo setorial e o índice de mercado apresentam movimentos fortemente correlacionados, e a sua introdução conjunta na regressão produz coeficientes instáveis por colinearidade. O fator utilizado não é, por isso, o retorno do setor, mas o resíduo de uma primeira regressão do setor sobre o mercado.

O segundo é a restrição temporal da estimação. A janela termina no dia anterior ao dia explicado, pela mesma disciplina aplicada à deteção.

O terceiro é o tratamento do ruído. Uma sensibilidade estimada sobre vinte observações é imprecisa, e estimativas extremas em janelas agitadas produzem repartições sem significado. A literatura de finanças documenta que os betas estimados regredem para a média entre períodos sucessivos (Blume 1971), do que decorreu a prática de encolher a estimativa com um peso fixo. Essa prática aplica a mesma correção a estimativas precisas e imprecisas. A alternativa adotada pondera o encolhimento pela imprecisão da própria estimativa (Vasicek 1973):

$$\beta = w\hat{\beta} + (1 - w)\beta_{\text{ref}}, \quad w = \frac{\sigma_{\text{ref}}^2}{\sigma_{\text{ref}}^2 + \text{SE}^2(\hat{\beta})} \quad (3.3)$$

Quando o ajuste é preciso, o erro-padrão é reduzido, w aproxima-se da unidade e a estimativa é praticamente preservada; quando a janela é ruidosa, o erro-padrão cresce e a estimativa recai sobre o valor de referência. O ajuste é gradual e não dicotómico. A formulação original estima β_{ref} e σ_{ref}^2 a partir da distribuição transversal dos betas; neste trabalho são escolhas do autor, com $\beta_{\text{ref}} = 1,0$ para o mercado, $\beta_{\text{ref}} = 0,0$ para o fator setorial já ortogonalizado, e um desvio-padrão comum de 0,5. A amostra de empresas não constitui um corte transversal representativo, pelo que a estimação de um prior sobre ela produziria um valor com aparência empírica sem o ser.

Três salvaguardas completam a estimação. Abaixo de dez observações utilizáveis a regressão não é tentada, assumindo-se sensibilidade unitária ao mercado e nula ao setor, situação que é declarada ao utilizador. Uma estimativa cujo módulo exceda dez é tratada como falha numérica da janela e não como sensibilidade económica, recaindo no mesmo recuo; a guarda destina-se a janelas degeneradas e não substitui o encolhimento, que é o mecanismo que trata o ruído. Por fim, o termo constante é recalculado sobre os coeficientes já encolhidos, uma vez que o valor devolvido pela regressão está centrado nos coeficientes brutos e a sua reutilização descentraria o modelo efetivamente reportado.

A Figura 3.3 apresenta a repartição de um movimento real, em que as componentes de mercado e de setor atuam em sentido contrário ao movimento observado.

Neste caso, registado pela AMD a 15 de agosto de 2026, o retorno logarítmico de +6,2944%, correspondente a uma variação simples do preço de +6,50%, reparte-se em -0,3992% de mercado, -0,0362% de setor e +6,7298% específicos da empresa, com $\beta_m = 2,0143$ e $\beta_s = 1,5888$ estimados sobre os vinte dias anteriores. A informação transmitida excede a percentagem isolada: a ação subiu apesar de o contexto ter atuado em sentido contrário, e o beta de mercado indica uma ação que historicamente amplifica os movimentos do índice.




Figura 3.3: Repartição de um dia da AMD, o de 15 de agosto de 2026, em retornos logarítmicos. As componentes de mercado e de setor atuaram em sentido descendente, pelo que a subida é integralmente atribuída à empresa. A igualdade entre a soma das parcelas e o movimento observado verifica-se por construção e, por essa razão, nada estabelece quanto à qualidade do ajuste, ponto retomado na Secção 5.5.

A soma exata das três parcelas não constitui validação do método. A igualdade verifica-se por construção, uma vez que a componente específica é definida como resíduo, e uma repartição sem significado somaria igualmente. A medida informativa sobre a qualidade do ajuste é o coeficiente de determinação na janela de estimação, cujo valor é reportado no Capítulo 5.

3.5 Recuperação de precedentes

A terceira decisão consiste em identificar notícias passadas comparáveis com a notícia em análise e medir o comportamento subsequente do preço. A procura por correspondência de palavras é inadequada por duas razões simétricas: notícias com o mesmo significado podem não partilhar vocabulário, e notícias com vocabulário comum podem tratar de assuntos distintos.

A representação adotada é um modelo de embeddings de frase (Reimers e Gurevych 2019), que converte cada título num vetor de 384 dimensões cuja posição no espaço reflete o significado da frase. A contribuição relevante deste modelo não é a arquitetura, mas o objetivo de treino: os vetores são aprendidos de modo que a distância entre dois deles corresponda a semelhança de sentido. Um codificador da mesma família treinado para outra tarefa não herda esta propriedade, observação que o Capítulo 5 confirma experimentalmente.

A proximidade entre duas frases é medida pela semelhança do cosseno, ou seja pelo ângulo entre os vetores e não pela distância entre as suas extremidades, o que torna a medida

independente do comprimento do texto. Os vetores são devolvidos com norma unitária, pelo que o cosseno se reduz ao produto interno, propriedade que permite percorrer a base de casos completa sem aproximação. Sobre dois pares reais da base de casos, dois títulos sobre a descida de empresas de tecnologia e semicondutores obtêm $\cos = +0,956$, e um título sobre a Peloton comparado com outro sobre o impacto da pandemia na indústria automóvel obtêm $\cos = -0,086$. O limiar de semelhança utilizado em produção é de 0,45.

A ordenação dos candidatos não é, contudo, o cosseno isolado. Casos próximos no tema mas distantes no tempo descrevem um regime de mercado que já não é o vigente, pelo que a ordenação aplica um decaimento exponencial sobre a idade do caso, na forma $\cos \times 2^{-\text{idade}/h}$, com meia-vida h de cento e vinte dias. Um caso com um ano entra assim com peso aproximado de 0,12 e prevalece apenas na ausência de material mais recente sobre o mesmo tema.

O decaimento ordena e não é apresentado: o valor exibido junto de cada precedente é sempre o cosseno, uma vez que apresentar uma pontuação composta sob o nome de semelhança produziria um número que o utilizador não pode verificar. As duas decisões compõem-se em série, pelo que o limiar de 0,45 incide sobre um conjunto já selecionado pela ordenação, e não sobre os vizinhos de maior cosseno. A Figura 3.4 representa a propriedade que esta medida explora: títulos com o mesmo significado ocupam posições próximas ainda que não partilhem vocabulário, ao passo que títulos que partilham vocabulário e tratam de assuntos distintos ficam afastados.




Figura 3.4: Cada frase corresponde a um ponto do espaço. Frases de significado próximo ocupam posições vizinhas ainda que não partilhem vocabulário, ao passo que frases com vocabulário comum ("bate") e assunto distinto ficam afastadas. A representação é bidimensional para permitir a leitura; o modelo utiliza 384 dimensões.

A medição do desfecho adapta o estudo de evento (Brown e Warner 1985): fixado o dia da notícia, mede-se a variação do preço a um, três e cinco dias. Duas decisões de detalhe condicionam o resultado. Notícias publicadas fora de dias de negociação são alinhadas com o primeiro dia de negociação seguinte. A medição inicia-se no fecho do dia da notícia, e não na abertura, opção conservadora que evita atribuir à notícia a parte do movimento anterior à sua publicação.

O valor apresentado ao utilizador é o retorno bruto e não o retorno anormal que a fonte normaliza. A opção é deliberada e tem um custo declarado. O retorno bruto é verificável pelo utilizador na sua própria aplicação, mas incorpora o movimento do mercado no período. Em períodos de queda generalizada, os precedentes aparentam desfechos piores do que os

atribuíveis à notícia. O desconto do mercado é aplicado onde é indispensável, na construção do rótulo descrito na secção seguinte.

3.6 Triagem de notícias

A quarta decisão determina que notícias justificam a interrupção do utilizador. Ao contrário das anteriores, não dispõe de uma formulação analítica evidente, constituindo o ponto natural para aprendizagem a partir dos dados.

O rótulo formaliza a pergunta como a ocorrência de um movimento anormalmente grande após a notícia. Mede-se o retorno da ação nos três dias seguintes, subtrai-se o movimento do mercado no mesmo período e classifica-se o exemplo como positivo quando o valor absoluto do resíduo excede dois por cento. O uso do valor absoluto é deliberado: o modelo aprende sobre materialidade e nunca sobre direção, o que preserva a restrição fundadora do trabalho.

A subtração do movimento do mercado assume uma sensibilidade unitária, o que constitui uma incoerência com a técnica descrita na Secção 3.4, que recusa precisamente essa suposição. Numa ação de beta elevado, o resíduo retém parte do movimento do mercado, e o rótulo pode classificar como material um dia em que apenas o mercado se moveu. Todas as famílias de modelos avaliadas no Capítulo 5 são treinadas e avaliadas contra o mesmo rótulo, pelo que a comparação entre elas é internamente consistente sob esta definição de alvo. Tal não garante, porém, que a ordenação resista a uma definição alternativa, uma vez que o erro introduzido pode estar correlacionado com a empresa e com a volatilidade.

O modelo recebe nove entradas: a volatilidade dos vinte dias anteriores, o momento dos cinco dias anteriores, o retorno do próprio dia, o comprimento do título e cinco indicadores de setor. Uma variante adicional incorpora o vetor de 384 dimensões do título. A Figura 3.5 agrupa as entradas pelo nível de informação que cada uma descreve, distinção que o Capítulo 5 demonstra ser determinante.




Figura 3.5: As nove entradas do modelo implantado, agrupadas segundo o que cada uma permite distinguir. Sete caracterizam a **empresa** e variam lentamente ou permanecem constantes; uma caracteriza o **dia** e assume o mesmo valor para todas as notícias desse dia; **apenas uma** varia entre títulos consecutivos. Desta composição decorre a expectativa de que o modelo não separe duas notícias da mesma empresa no mesmo dia, expectativa que a ablação da Secção 5.4.5 confirma.

Sete entradas descrevem a empresa e variam lentamente ou são constantes; uma descreve o dia e é idêntica para todas as notícias desse dia; e apenas uma, o comprimento do título, distingue dois títulos da mesma empresa no mesmo dia.

A divisão dos dados é cronológica e não aleatória, como representado na Figura 3.6. Uma divisão aleatória permitiria treinar sobre notícias posteriores às utilizadas na avaliação, invertendo a ordem temporal que o sistema enfrenta em funcionamento. Entre blocos consecutivos existe um embargo de cinco dias, necessário porque o rótulo de uma notícia depende dos três dias seguintes: sem o embargo, o rótulo das notícias no final de um bloco seria determinado por dias pertencentes ao bloco seguinte. O embargo descarta 820 das 79 753 linhas, ou seja, 1,03%, ficando 28 574 exemplos para treino, 17 710 para validação e 32 649 para teste.




Figura 3.6: A divisão dos dados obedece à **ordem cronológica** e não a um sorteio. Entre blocos consecutivos intercala-se um *embargo* de cinco dias, uma vez que o rótulo de cada notícia depende dos três dias seguintes: sem ele, o final do bloco de treino seria determinado por dias pertencentes ao bloco seguinte.

O bloco de teste contém mais exemplos do que o de treino. O corte é feito em dias de negociação, segundo a proporção de setenta, quinze e quinze por cento, e a assimetria resulta da densidade de notícias, que cresce acentuadamente ao longo do período coberto pelo corpus. A divisão por dias, e não por número de exemplos, é necessária para que notícias do mesmo dia não sejam repartidas por blocos distintos.

A pontuação produzida pelo modelo não constitui, por si, uma probabilidade. Uma vez que o valor é apresentado ao utilizador, é convertido através de calibração *a posteriori*, ajustando uma sigmoide de dois parâmetros sobre o bloco de validação reservado (Niculescu-Mizil e Caruana 2005):

$$p_{\text{calibrada}} = \frac{1}{1 + e^{-(a p_{\text{bruta}} + b)}} \quad (3.4)$$

Os valores aprendidos são $a = 3,700$ e $b = -2,313$. O sinal negativo de b indica que o modelo, sem calibração, produz valores sistematicamente superiores à frequência observada. Parte deste comportamento decorre da reponderação das classes durante o treino, que desloca as pontuações para cima por construção.

A calibração é ajustada num bloco cuja prevalência de casos positivos difere da do bloco de teste, consequência da divisão cronológica. O efeito é mensurável e está reportado no Capítulo 5. A transformação é monótona e preserva a ordenação entre notícias, que é o que a política de decisão utiliza; o valor absoluto apresentado é o que fica afetado.

3.7 Ferramentas e infraestrutura

O sistema está escrito em Python 3.12. As dependências que produzem os resultados desta dissertação estão fixadas em versões exatas, e não em intervalos, de modo que o ambiente possa ser recriado noutra máquina: `numpy` 2.1.3, `pandas` 2.2.3, `scikit-learn` 1.9.0,

`matplotlib` 3.11.0, `sentence-transformers` 5.6.0 e `torch` 2.12.1 na variante para CPU. Nenhum resultado exige unidade de processamento gráfico, consequência das opções descritas neste capítulo.

Todas as fontes de dados são gratuitas. Os preços provêm de uma cadeia de fornecedores alternativos consultados por ordem fixa, uma vez que nenhuma fonte gratuita apresenta fiabilidade suficiente isoladamente; o sistema regista sempre qual delas respondeu. As notícias provêm de três fornecedores complementares, cuja comparação é apresentada no Capítulo 4. A entrega utiliza a interface de robô do Telegram.

3.8 Desafios tecnológicos e sociais

Esta secção enuncia os riscos que um sistema com estas características levanta e as decisões de desenho que respondem a cada um.

3.8.1 Privacidade e proteção de dados

Uma carteira de investimentos revela rendimento, aversão ao risco e projetos de vida, informação que o Regulamento Geral sobre a Proteção de Dados trata como merecedora de proteção reforçada quando permite traçar o perfil de uma pessoa.

A decisão de desenho que responde a este risco é a minimização: o sistema não conhece as posições dos utilizadores e não as solicita. Não existe carteira, não existem posições nem montantes, e o canal público não identifica destinatários. Um alerta sobre uma empresa é idêntico para todos os leitores. O custo desta opção é a impossibilidade de personalização, uma vez que o sistema alerta sobre uma lista fixa de empresas e não sobre as posições de quem lê.

Existe uma exceção que importa nomear. Os utilizadores que optem por receber alertas personalizados através do robô do Telegram ficam associados a dois elementos: o identificador de conversa atribuído pela plataforma e a lista de empresas selecionadas. Não são armazenados nome, contacto nem montantes. O tratamento assenta no pedido expresso do próprio utilizador, que o inicia ao subscrever e o termina através de um comando que elimina o registo.

3.8.2 Segurança

Um sistema autónomo que consome serviços externos detém credenciais. As chaves residem em variáveis de ambiente e no cofre de segredos da plataforma, nunca no repositório, e o texto enviado para os registos passa por uma função que mascara parâmetros com nome de credencial. Esta segunda salvaguarda responde ao facto de as mensagens de erro de bibliotecas de comunicação reproduzirem o endereço do pedido, e de algumas interfaces transportarem a chave nesse endereço.

O codificador de frases é obtido sob pedido e confrontado com uma soma de controlo fixada no código. Na ausência dessa verificação, um ficheiro corrompido ou substituído modificaria sem aviso o critério de semelhança utilizado pelo sistema.

3.8.3 Questões éticas e sociais

A restrição fundadora do trabalho é também a sua principal salvaguarda ética. Um sistema que anunciasse o comportamento futuro do preço emitiria uma previsão não verificável no momento da leitura; um sistema que indicasse instrumentos a adquirir entraria numa atividade regulada. Esta fronteira é de desenho, traçada por prudência e não a partir de uma análise do direito aplicável: não houve parecer jurídico, e a operação do sistema como serviço exigiria obtê-lo previamente.

A garantia aplica-se ao que o sistema escreve e não ao que reproduz. Os títulos de terceiros são citados na íntegra, uma vez que constituem o facto que desencadeia o alerta e permitem a verificação na fonte, e alguns são eles próprios especulativos. Daqui decorre uma limitação sem solução no âmbito assumido: o filtro de relevância determina se um título é sobre a empresa, e não se é factual. A distinção entre notícia e opinião exigiria um classificador que o sistema não possui.

A interrupção repetida constitui o segundo risco. O efeito está documentado em sistemas de apoio à decisão clínica, onde Ancker et al. (2017) medem que a probabilidade de aceitação de um alerta decresce à medida que o volume de alertas recebidos aumenta, e que o efeito se acentua com a repetição do mesmo alerta. O domínio é distinto e o que se transfere é o mecanismo: quem é interrompido com frequência deixa de distinguir as interrupções, momento a partir do qual um aviso correto e um aviso incorreto passam a ter o mesmo efeito. O sistema responde com um orçamento diário de alertas, um limiar crescente para alertas repetidos da mesma empresa e supressão de notícias que reproduzem uma história já comunicada.

O terceiro risco decorre da própria explicação. A confiança em sistemas automáticos falha nos dois sentidos, com o utilizador a ignorar um aviso correto ou a aceitar um aviso incorreto (J. D. Lee e See 2004), e a presença de uma explicação aumenta a aceitação de respostas erradas (Bansal et al. 2021). O sistema apresenta, por essa razão, os casos passados individualmente, com data e desfecho, em vez de os resumir a uma média suscetível de ser lida como previsão. Que esta opção produza confiança apropriada constitui uma hipótese e não um resultado, uma vez que o estudo com utilizadores necessário para a verificar não foi realizado.

Capítulo 4

Implementação: InvestiGator

Este capítulo descreve a realização do sistema: a sua arquitetura, a forma como cada método do Capítulo 3 é concretizado, a política que decide o que é comunicado ao utilizador, a construção da mensagem entregue, e o ciclo de vida do componente aprendido.

O Capítulo 3 apresentou quatro métodos de forma isolada. A sua composição num sistema em funcionamento introduz problemas que nenhum deles apresenta isoladamente: a indisponibilidade das fontes, o volume de candidatos por ciclo, a coerência entre os valores calculados e o texto apresentado, e a degradação silenciosa dos componentes ao longo do tempo. A descrição que se segue organiza-se em torno desses problemas.

O sistema desenvolvido designa-se por InvestiGator e encontra-se em funcionamento contínuo, entregando alertas a um canal de mensagens e disponibilizando o registo das suas decisões numa aplicação web. Os valores apresentados neste capítulo foram lidos do registo do sistema em operação, e as datas em que cada medição foi efetuada são indicadas junto de cada uma.

4.1 Arquitetura do sistema

A arquitetura do InvestiGator foi definida de acordo com os seguintes requisitos, relativos a custo, modularidade, verificabilidade e resiliência:

- operar exclusivamente sobre fontes de dados gratuitas, sem subscrições nem custos por pedido;
- isolar cada método num componente com responsabilidade única, substituível sem alteração dos restantes;
- garantir que qualquer valor apresentado ao utilizador tem origem no componente que o calculou, e não numa segunda derivação independente;
- tolerar a indisponibilidade de qualquer fonte externa sem interrupção do serviço;
- registar cada decisão tomada, incluindo as decisões de não comunicar.

O sistema organiza-se em cinco componentes, representados na Figura 4.1: deteção, recuperação, triagem, explicação e entrega. A decomposição do movimento constitui um sexto componente, ativado apenas no percurso iniciado por movimento de preço, uma vez que a repartição incide sobre o retorno do dia e não existe objeto a repartir quando o acontecimento que desencadeia a avaliação é uma notícia.




Figura 4.1: Componentes do sistema e respetivas ligações. À esquerda, as fontes de dados; ao centro, os métodos do Capítulo 3 e o componente que compõe o texto; à direita, os dois canais de entrega. A decomposição encontra-se a tracejado por ser o único componente que não intervém em todas as avaliações.

Uma regra de construção atravessa a totalidade da implementação: o texto entregue ao utilizador é composto a partir dos objetos que os componentes produziram, e não redigido de forma independente. Quando o detetor calcula um valor de z igual a $+7,61$, é esse valor que a mensagem apresenta. A alternativa, que consistiria em manter um local onde o texto é escrito e outro onde a quantidade é calculada, admite divergência entre os dois sem que essa divergência seja observável. A restrição elimina essa possibilidade por construção.

4.1.1 Comunicação entre componentes

Os componentes comunicam por passagem direta de objetos dentro de um processo único, e não por protocolo de rede. A decisão decorre do perfil de utilização: o sistema serve uma lista reduzida de empresas, com um ciclo de avaliação de sessenta segundos, e o volume não justifica o custo de coordenação de uma arquitetura distribuída. A separação entre componentes é assegurada por interfaces explícitas, o que preserva a substituibilidade sem introduzir latência de comunicação.

Duas exceções operam sobre fronteiras de processo. A entrega utiliza a interface de robô do canal de mensagens, por pedido HTTP. A aplicação web que expõe o registo de decisões corre como processo separado e lê o mesmo repositório de dados, sem escrever nele. Esta segunda separação garante que a consulta do registo não interfere com o ciclo de avaliação.

4.2 Aquisição de dados

A restrição de custo nulo determina as decisões de aquisição. Um investidor particular que considere elevados os custos de corretagem não subscreve um terminal de informação financeira, e a utilidade do sistema para o destinatário definido no Capítulo 1 depende de

o sistema operar sem esse custo. As fontes gratuitas apresentam, contudo, três limitações sistemáticas: bloqueiam o acesso por excesso de pedidos, respondem com erro sem aviso, e publicam com atraso. As decisões descritas nesta seção respondem a essas limitações.

4.2.1 Preços

Os preços são obtidos através de uma cadeia de quatro alternativas, consultadas por ordem fixa, adotando-se a primeira que responde com dados válidos. O identificador da fonte que serviu cada valor é registrado juntamente com o valor, uma vez que a proveniência de uma quantidade integra a sua explicação.

A ordem da cadeia não é arbitrária nem definitiva. Uma das fontes foi despromovida na sequência da observação do conteúdo que devolvia, e uma candidata adicional foi rejeitada por responder com verificação anti-robô, o que a torna inutilizável em operação automática. Estas duas decisões resultaram de medição e não de preferência declarada.

A redundância da cadeia tem uma consequência que ultrapassa a disponibilidade. Sem ela, um dia em que a fonte única bloqueia o acesso é indistinguível de um dia em que o mercado não abriu, e o sistema não dispõe de forma de separar as duas situações.

4.2.2 Notícias

As notícias são obtidas por empresa, a partir de três interfaces gratuitas. O material recebido inclui um volume elevado de conteúdo não aproveitável: listas automáticas de maiores variações do dia, textos que mencionam a empresa apenas de passagem, e comunicados de escritórios de advocacia. Um filtro de relevância, aplicado à entrada, exige que o título nomeie explicitamente a empresa e rejeita os padrões conhecidos de texto gerado automaticamente.

A utilização de três fontes em vez de uma foi avaliada por medição, sobre doze empresas e três dias. O critério adotado não é o número de títulos devolvidos por cada fonte, mas o número de títulos que sobrevive ao filtro de relevância, dado que o material rejeitado à entrada não chega a existir para o sistema. A Tabela 4.1 apresenta o resultado.

Tabela 4.1: Material entregue por cada fonte gratuita após aplicação do filtro de relevância. A coluna *exclusivos* indica os títulos que uma fonte traz e nenhuma das outras traz. Esse valor constitui um limite superior, uma vez que a comparação entre títulos é efetuada por correspondência textual após normalização, e duas fontes que descrevam o mesmo acontecimento por outras palavras produzem dois títulos contabilizados como distintos.

Fonte	Relevantes	Precisão	Frescura	Cobertura	Exclusivos
Finnhub	432	35%	15,8 h	12/12	401
Alpha Vantage	141	24%	9,3 h	12/12	119
Polygon	429	27%	52,6 h	8/12	418

As três fontes apresentam perfis complementares, e é essa complementaridade, e não o volume agregado, que justifica a sua utilização conjunta. O Finnhub apresenta a maior precisão de etiquetagem e cobre a totalidade das empresas. A Alpha Vantage apresenta a menor mediana de idade das notícias, com 9,3 horas contra 15,8, o que a torna a fonte relevante para a redução do atraso dos alertas. O Polygon contribui com o maior número

de títulos exclusivos, com uma mediana de idade de 52,6 horas, o que o torna adequado à alimentação da base de casos e inadequado ao alerta em tempo útil. É essa a utilização que lhe está atribuída.

O conjunto das três fontes produz 970 títulos relevantes distintos, contra os 432 obtidos apenas com o Finnhub. O ganho concentra-se nas empresas com menor cobertura individual, que correspondem precisamente aos casos em que o sistema anteriormente não dispunha de material para comentar.

A agregação não garante, contudo, redução da latência em geral. As três fontes publicam com atrasos próprios, e o ganho num caso concreto depende de qual delas observou o acontecimento em primeiro lugar. A mediana de frescura melhora, e essa melhoria encontra-se medida; a afirmação de que os alertas passam a chegar mais cedo exigiria nova medição da latência de extremo a extremo sobre um período alargado, que não foi realizada.

4.2.3 Base histórica e base implantada

A recuperação de precedentes requer um corpo de casos passados com desfecho conhecido. O sistema utiliza dois conjuntos distintos, com finalidades distintas, e a sua separação é relevante para a leitura dos resultados do Capítulo 5.

O primeiro é o FNSPID (Dong, Fan e Peng 2024), um conjunto público de notícias financeiras alinhado com os preços correspondentes. Do alinhamento descrito na Secção 3.2 resultam 79 753 exemplos entre 2018 e 2023, cada um com o movimento de preço subsequente. É sobre este conjunto que os métodos são avaliados.

O segundo é a base de casos que o sistema implantado consulta, e resulta da fusão de duas origens que importa não confundir. A primeira é uma reconstrução de um ano de história, obtida executando os componentes de recolha e de maturação sobre o passado, com 38 214 casos; a separação face ao registo do sistema em funcionamento é deliberada, uma vez que um caso reproduzido não é um caso observado. A segunda é a base viva, alimentada pela varredura, com 11 445 casos. A recuperação percorre as duas em conjunto. Os vetores são armazenados como matriz de precisão simples mapeada em disco. O formato não é indiferente: as mesmas representações em estruturas nativas da linguagem excediam a memória disponível no contentor de execução, e a alteração de formato foi a condição que tornou a sua utilização possível.

4.3 Percurso de um acontecimento

O sistema admite dois percursos distintos, consoante o acontecimento que desencadeia a avaliação seja uma notícia ou um movimento de preço. Os dois convergem no componente de explicação e utilizam a mesma política de decisão, descrita na Secção 4.4.

4.3.1 Percurso iniciado por notícia

O percurso iniciado por notícia compreende nove etapas, representadas na Figura 4.2. Quatro dessas etapas são pontos de decisão em que a candidata pode ser descartada, situação em que o sistema não comunica.

O funcionamento do percurso é ilustrado por um alerta entregue a 12 de julho de 2026, relativo à Meta, com o título *“Mark Zuckerberg Said Meta’s AI Bets ‘Haven’t Come to*




Figura 4.2: As nove etapas do percurso. As caixas a tracejado correspondem a pontos de decisão em que a candidata pode ser descartada. A Secção 4.4 quantifica a proporção de candidatas eliminada em cada um.

Fruition Yet' as Shares Fell 5%". O título nomeia a empresa e não corresponde a nenhum dos padrões de texto automático. A data situa-se dentro do intervalo de dois dias exigido. Os três precedentes mais próximos são Microsoft de 2023-11-07, com semelhança 0,46, Nvidia de 2023-08-02, com 0,51, e Nvidia de 2023-09-21, com 0,46; a melhor delas fica acima do limiar de 0,45. O modelo de triagem atribui uma probabilidade de 54%. E o alerta é o primeiro relativo à empresa nesse dia. A mensagem é então composta e registada.

Os precedentes recuperados neste caso pertencem a empresas distintas daquela sobre a qual o alerta incide, e são apresentados na mesma. A opção é deliberada e decorre da formulação da terceira questão de investigação: a comparabilidade é estabelecida pelo tema da notícia e não pela identidade da empresa. Notícias relativas a investimento em inteligência artificial em empresas tecnológicas de grande dimensão constituem casos comparáveis entre si.

Os desfechos dos três precedentes são divergentes, com movimentos de +2,70%, −3,87% e +5,05%. O sistema apresenta os três individualmente, e não a sua média, precisamente por essa razão. A média oculta a informação mais relevante do conjunto, que é a inexistência de um desfecho comum a casos semelhantes.

4.3.2 Percurso iniciado por movimento de preço

O segundo percurso é substancialmente mais curto. O z-score é calculado por dois caminhos. Após o fecho de cada sessão, o sistema avalia o retorno do dia fechado de cada empresa da lista vigiada contra a norma dos vinte dias anteriores, conforme descrito na Secção 3.3. Durante a sessão, avalia o retorno em curso, obtido da cotação corrente contra o fecho anterior, contra a mesma norma diária, formada nesse caso pelos vinte dias completos mais recentes, uma vez que o dia em curso ainda não pertence à série. O segundo caminho antecipa a deteção sem alterar a definição de normalidade, e é o que permite comunicar um movimento enquanto a sessão decorre; é também o que não depende da fonte de séries históricas, cuja barra do dia pode chegar com atraso. Em qualquer dos caminhos, a ultrapassagem do limiar constitui condição suficiente para avaliação.

É neste percurso, e apenas neste, que intervém a decomposição do movimento. Ao alerta é acrescentada uma linha com a repartição calculada segundo a Secção 3.4, com a forma *"NFLX −2,11% hoje = −0,08% mercado · −0,32% setor · −1,71% da própria empresa"*,

seguida de uma frase que nomeia em linguagem corrente a parcela dominante. Quando a estimação da sensibilidade ao mercado não é possível, a linha é apresentada na mesma, declarando que foi assumida sensibilidade unitária e que a repartição tem carácter indicativo.

Duas capacidades foram acrescentadas ao percurso após a entrada do sistema em funcionamento, ambas por observação do comportamento em operação. A primeira consiste na atribuição de níveis de severidade: um valor de z de 1,6 e um valor de 3,2 passaram a ser descritos por termos distintos, em lugar de gerarem a mesma formulação. A segunda consiste na comparação com as restantes empresas do mesmo setor na mesma sessão, dado que um alerta que reporta uma descida sem indicar que o setor inteiro desceu transmite informação incompleta.

A segunda correção resultou da leitura dos trinta primeiros alertas entregues. Em nove deles o texto era internamente contraditório: uma linha indicava que o movimento parecia comum ao setor, e a repartição apresentada duas linhas abaixo atribuía a maior parcela à empresa. As duas linhas estavam corretas isoladamente, e a contradição resultava de a comparação com os pares considerar apenas a direção do movimento das empresas vizinhas, e não a sua magnitude. A comparação passou a considerar ambas.

4.4 Política de decisão

A comunicação de todas as candidatas avaliadas é equivalente à ausência de comunicação. Um canal que entregue quinze mensagens diárias deixa de ser lido, e o sistema perde a utilidade que justifica a sua existência. Os pontos de decisão da Figura 4.2 respondem a esta restrição.

4.4.1 Seletividade observada

O efeito conjunto dos pontos de decisão é considerável. Sobre as notícias datadas entre 4 e 13 de julho de 2026, das 944 notícias relevantes que entraram no sistema resultaram 42 alertas, o que corresponde a uma razão aproximada de um para vinte e dois. O valor é um limite superior da seletividade da política atual, uma vez que o limite de duas mensagens por empresa entrou em vigor a 11 de julho, a meio da janela observada. A Figura 4.3 apresenta a distribuição por empresa.

O comportamento num único dia permite localizar a eliminação de candidatas. A Figura 4.4 distribui as 5 060 avaliações registadas a 15 de agosto de 2026 pelo ponto de decisão em que cada uma terminou. O registo lido corresponde a parte do dia e não ao dia completo, pelo que os valores devem ser lidos como proporções.

A leitura destes valores expõe um defeito de instrumentação. As 333 avaliações que atravessaram todos os pontos de decisão não correspondem a 333 candidatas distintas aprovadas para entrega. O sistema reavalia os mesmos títulos em cada ciclo de sessenta segundos, e um título já entregue nesse dia voltava a atravessar todos os pontos de decisão em cada ciclo. A entrega era impedida no final, por uma verificação de duplicação que, ao contrário de todas as restantes, não estava registada como etapa.

A consequência é relevante para a finalidade do registo. A vista construída para tornar as decisões do sistema inspecionáveis indicava 333 aprovações num dia em que foram entregues

4.5. Construção da explicação




Figura 4.3: Títulos relevantes captados e alertas efetivamente entregues, por empresa, na janela observada. O total é de 944 títulos e 42 alertas. A concentração dos alertas em três empresas não resulta de qualquer regra que privilegie essas empresas: decorre da interação entre o limiar de semelhança e a composição da base de casos, cuja cobertura por empresa é desigual.

cinco mensagens. A verificação de duplicação passou a constituir uma etapa com identificação própria, como as restantes, e existe um teste automático que falha caso volte a ser omitida. Os valores da figura são anteriores a essa correção.

4.4.2 Limiares e sua proveniência

Cada ponto de decisão utiliza uma constante, e a origem dessas constantes é heterogênea. A Tabela 4.2 distingue os valores derivados de uma análise dos valores escolhidos, distinção que é pertinente porque os dois casos admitem defesas de natureza diferente.

O limiar de semelhança requer tratamento separado, por ser simultaneamente o mais restritivo e o menos fundamentado. Numa varredura medida, com dez empresas na lista vigiada, sete candidatas foram eliminadas neste ponto, quatro delas por diferenças de 0,04 ou inferiores. Foi testada a hipótese de valores mais elevados de semelhança corresponderem a precedentes mais informativos, e a hipótese não se confirma: a concordância de direção entre o caso passado e o caso em avaliação situa-se ao nível do acaso em ambos os lados do limiar. O limiar controla o volume de alertas e assegura coerência temática, e não seleciona casos com maior valor preditivo.

4.5 Construção da explicação

A mensagem entregue não é uma frase única, mas uma estrutura com quatro partes, sempre presentes e sempre pela mesma ordem:

1. o facto observado, expresso em valores, com indicação da fonte;

Tabela 4.2: Constante associada a cada ponto de decisão e origem do respectivo valor. O primeiro ponto não utiliza constante, por corresponder a uma regra de correspondência textual. O orçamento diário atua depois dos pontos de decisão representados na Figura 4.2 e constitui, na configuração em operação, o mecanismo que efetivamente limita o volume.

Ponto de decisão	Valor	Proveniência
Movimento invulgar	$ z \geq 1,5$	Escolhido, e distinto do valor de 3,0 sob o qual o detetor é avaliado no Capítulo 5. A avaliação fixa um valor exigente para caracterizar o método; a implantação adota um valor mais permissivo por decisão de produto, compensado pelos níveis de severidade que distinguem 1,5, 2,0 e 3,0 na formulação apresentada. Os dois valores respondem a perguntas diferentes.
Nomeia a empresa	—	Regra textual, definida após inspeção do material que atravessava o filtro inicial.
É recente	2 dias	Escolhido, por cobrir um fim de semana.
Evidência suficiente	0,45	Escolhido. É o ponto que elimina o maior número de candidatas.
Triagem acima do piso	50%	Derivado de uma análise de custos, que produz 0,49 na condição de custo simétrico entre movimento não comunicado e falso alarme; o valor implantado corresponde ao arredondamento desse resultado. Na configuração em operação não exerce veto: ordena as candidatas do mesmo ciclo.
Orçamento diário	5 por dia	Escolhido. Os cinco lugares são atribuídos por ordem de chegada e não às cinco candidatas com maior pontuação do dia, uma vez que a decisão é tomada ciclo a ciclo, sem conhecimento das candidatas posteriores. Acresce a um limite de duas mensagens por empresa por dia, que se mantém em vigor e é verificado depois deste. Os dois respondem a problemas distintos: o limite por empresa impede a saturação por um único nome, e o orçamento global impede que doze empresas a duas mensagens cada produzam vinte e quatro interrupções num dia.
Piso escalonado	segundo alerta: 0,64	A configuração conserva os valores derivados 0,49 e 0,64, e o primeiro é explicitamente ignorado quando o orçamento global está ativo: o primeiro alerta diário de cada empresa não tem piso de triagem. O mecanismo atua assim apenas como limitador de repetição dentro da mesma empresa.

4.5. Construção da explicação




Figura 4.4: As 5 060 avaliações registradas a 15 de agosto de 2026, distribuídas pelo ponto em que cada uma terminou. As 333 avaliações que atravessaram todos os pontos de decisão não figuram no gráfico, pela razão apresentada no texto. O orçamento diário de cinco mensagens foi integralmente utilizado. A data é também a do dia em que o piso de triagem deixou de exercer veto e passou a ordenar, pelo que a barra de 1 194 avaliações eliminadas nesse ponto pertence à configuração anterior à descrita na Tabela 4.2; nos dias seguintes esse ponto deixa de eliminar candidatas.

2. os casos passados recuperados, apresentados individualmente, com data, semelhança e movimento subsequente;
3. a ressalva de que os casos apresentados constituem história observada e não previsão;
4. a estimativa de probabilidade de reação do mercado, sem indicação de direção.

A ordem responde a duas restrições. O facto precede a estatística porque um alerta iniciado por um valor de z perde o leitor na primeira linha, e o destinatário definido no Capítulo 1 não dispõe da formação que tornaria esse valor imediatamente interpretável. A estimativa ocupa a última posição por ser a única quantidade da mensagem que se refere ao futuro, o que assegura que a leitura interrompida antes do fim retém factos e histórico.

No percurso iniciado por movimento de preço, a primeira parte integra também a caracterização estatística em linguagem corrente, dado que nesse caso o facto observado é o próprio movimento. No percurso iniciado por notícia, essa posição é ocupada pelo título e pela ligação para o artigo.

O número de precedentes apresentados é igualmente uma decisão de desenho. O sistema exhibe três dos casos recuperados e não a totalidade, e a razão não é de espaço disponível. A investigação sobre explicação estabelece que as pessoas procuram razões seletivas e contrastivas, e não enumerações exaustivas dos fatores que contribuíram para um resultado (Miller 2019). Uma lista de trinta casos seria mais completa e menos utilizável. O mesmo princípio determina que a mensagem exhiba as quantidades que sustentam a decisão e não o cálculo integral que as produziu.

A Figura 4.5 reproduz um alerta tal como foi entregue, copiado do registo do canal sem edição. A mensagem, tal como a interface, é redigida em inglês. A opção decorre do domínio: as empresas monitorizadas são norte-americanas e as notícias recolhidas das três fontes gratuitas são publicadas em inglês, pelo que traduzir o título citado quebraria a

verificabilidade, que é a propriedade que o sistema existe para preservar. As figuras que reproduzem o sistema em funcionamento conservam por isso a língua original.

```
[1] News alert for AMZN (Amazon) (2026-08-13)
    "Prediction: Amazon Will Join Apple in the $4 Trillion Club Before 2030"

[2] 3 similar past headlines. Their 5-day move ranged -2.73% to -2.73%
    (average -2.73%):
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "If You Invested $100 In Apple
      Stock 10 Years Ago, You Would Have This Much Today" (sim 0.56)
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "Apple's Selloff Is Overdone"
      (sim 0.51)
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "Apple's Buyback Is Retiring
      Less Stock Just As The Memory Bill Grows" (sim 0.47)

[3] 3 of 3 shown cases moved down - topic-similar past cases, not a
    prediction for this news (an observed pattern, not a forecast).
    Observed past outcomes after similar news, not a price prediction and
    not advice.

[4] Materiality estimate (learned triage): 57% chance of an unusually
    large move over the next few days, in EITHER direction - raised by
    recent volatility (20d) and sector; lowered by today's own move and
    recent momentum (5d). This estimates whether the market reacts, never
    which way: it is not a price forecast and not advice.
```

Figura 4.5: Alerta entregue a 13 de agosto de 2026, reproduzido do registo sem edição. Os números entre parênteses retos identificam as quatro partes da estrutura. Todos os valores provêm dos componentes que os calcularam: a semelhança, do motor de recuperação; o movimento a cinco dias, da medição de impacto; e a probabilidade de 57%, do modelo calibrado. A parte [1] contém um título que é ele próprio uma previsão, com alvo e prazo; trata-se de conteúdo de terceiros reproduzido literalmente, e a Secção 3.8.3 discute o alcance da garantia de não previsão nesse contexto. A parte [2] exhibe a semelhança em valor bruto, fiel ao que o motor calculou e não interpretável por quem a lê.

A probabilidade apresentada na última linha não corresponde à pontuação bruta do modelo. Resulta da sua conversão em probabilidade, por ajuste de uma sigmoide sobre um bloco de validação reservado (Niculescu-Mizil e Caruana 2005). A distinção é operacionalmente relevante: uma pontuação bruta ordena as candidatas sem admitir interpretação isolada, ao passo que uma probabilidade calibrada estabelece que, entre os títulos aos quais o sistema atribui 57%, aproximadamente essa fração apresenta efetivamente movimento invulgar. É a diferença entre uma quantidade utilizável apenas internamente e uma quantidade que pode ser apresentada.

A garantia tem limites declarados. A Secção 5.4 reporta o erro médio desta probabilidade e regista que a calibração é ajustada num bloco cuja prevalência não coincide com a do bloco a que é aplicada, o que desloca a escala em cerca de cinco pontos percentuais no sentido otimista. A ordenação entre candidatas não é afetada, uma vez que a transformação preserva a ordem; o valor absoluto anunciado é.

4.5.1 Discordância entre a afirmação e a evidência

O alerta da Figura 4.5 apresenta três precedentes com impacto idêntico, de $-2,73\%$, e data idêntica. A coincidência não é fortuita: o impacto é medido por par constituído por empresa e dia, pelo que três títulos da mesma empresa no mesmo dia partilham o mesmo valor por

construção. A formulação “3 of 3 shown cases moved down” apresenta como concordância entre três casos aquilo que constitui um dia observado três vezes.

A extensão do problema foi medida sobre os 247 alertas de notícia com precedentes entregues entre 11 de julho e 13 de agosto de 2026. Em 36,8% deles os casos exibidos assentam num número de dias distintos inferior ao número de casos apresentados, e em 11,3% os três casos correspondem ao mesmo dia. Dos 120 alertas que afirmam unanimidade de direção, 23,3% apoiam-se num único dia.

O efeito é circunscrito. Nenhuma métrica reportada no Capítulo 5 é afetada, uma vez que a precisão em k contabiliza títulos e a concordância de direção é medida par a par sobre o corpus histórico. O que é afetado é a força que o alerta reivindica perante o utilizador, e o Capítulo 6 regista o facto como limitação.

4.5.2 Aplicação web

A mesma informação é disponibilizada numa aplicação web, que permite consultar o que foi entregue e, sobretudo, o que não foi. É nessa aplicação que reside o registo de decisões descrito na Secção 4.4. A Figura 4.6 apresenta as duas vistas principais. O desenho da interface não constitui contribuição desta dissertação, pelo que não é descrito; a sua apresentação justifica-se por ser o único local em que a ausência de comunicação por parte do sistema é observável.


A empresa apresentada na vista superior constitui um caso ilustrativo da segunda questão de investigação, pela discordância entre a variação percentual e a repartição. A ação registava uma descida de 0,41%; o mercado e a componente específica da empresa apresentavam valores positivos, de +0,08% e +0,07%; e a parcela que puxava o preço para baixo era a do setor, com -0,56%. A variação percentual isolada indica uma descida da empresa e conduz à procura de uma causa interna que não existe. O veredicto termina na expressão “so far today”, uma vez que a captura corresponde a meio da sessão e não a um fecho.

4.6 Implantação e operação

O sistema corre como processo permanente, com ciclo de varredura de sessenta segundos, sobre créditos de alojamento incluídos num plano académico. A primeira versão utilizava um agendador gratuito de melhor esforço, cuja periodicidade efetiva era de aproximadamente hora e meia. A alteração para processo permanente foi motivada pela redução do atraso dos alertas.

A latência foi medida sobre os 278 alertas de notícia entregues entre 29 de julho e 30 de agosto de 2026 que registam hora de publicação e hora de envio. A mediana do percurso completo é de 353 minutos, com percentil noventa de 964 minutos. A repartição localiza esse tempo sem ambiguidade: a mediana entre a publicação e a deteção é de 353 minutos, e a mediana entre a deteção e a chegada da mensagem é de 5 segundos, com percentil noventa de 16 segundos. O sistema entrega em segundos aquilo que a fonte lhe dá.

A separação por configuração não confirma a expectativa que motivou a alteração. Sobre os 28 alertas entregues pelo agendador a mediana é de 196 minutos; sobre os 250 entregues pelo processo permanente é de 402 minutos. O ciclo mais curto não reduziu a latência observada. A comparação não é interpretável como efeito do ciclo, uma vez que as duas configurações não operaram em paralelo, entre elas alteraram-se as fontes de notícias e o



período de calendário, e as amostras são de dimensão muito desigual. O que a medição estabelece é que encurtar o ciclo só compensaria se o tempo estivesse na cadência com que o sistema consulta a fonte, e não está.

Três causas concorrem para o atraso da descoberta, e este histórico não as separa. A primeira é a fonte listar a notícia horas depois da hora que ela própria declara. A segunda é a notícia mais recente do fluxo não ser a mais recente *relevante*: numa amostra recolhida a 7 de agosto de 2026, o fluxo de uma das empresas trazia 250 títulos com o mais recente publicado às 11:39, mas o mais recente entre os 30 relevantes era das 08:14. O alerta sai sobre o título correto, e é esse título que é antigo. A terceira é o orçamento diário já estar gasto, que não aparece nesta medição porque um alerta que não é entregue não regista hora de envio. Apenas a primeira seria atenuada por um serviço pago de notícias, e a sua contribuição não está medida.

Todos estes valores constituem um limite inferior da latência sentida pelo utilizador, uma vez que a hora de publicação é a declarada pela fonte e não o instante do acontecimento.

4.6.1 Crescimento da base de casos

Todo o título relevante observado pela varredura é conservado como candidato a precedente. Oito dias depois, quando o impacto no preço se torna observável, o candidato é medido pela mesma regra de alinhamento da Secção 3.5 e integra a base de casos. O intervalo de espera não constitui ineficiência: é a condição que impede um caso de conhecer o seu próprio desfecho. A Figura 4.7 representa o ciclo.




Figura 4.7: Percurso de um título entre a sua observação e a sua disponibilidade como precedente. O intervalo de oito dias decorre de o impacto de um caso só ser observável após o movimento do preço. O ciclo mantém atualizada a evidência apresentada pelo sistema, e não os parâmetros do modelo: nenhum componente é retreinado.

O mecanismo atualiza a evidência exibida e não os parâmetros do modelo. Na taxonomia de deriva de conceito de Gama et al. (2014), o sistema dispõe da deteção da mudança e não da adaptação a ela.

Verificou-se, com o sistema já em funcionamento, que este ciclo estivera interrompido durante dezanove dias sem registo de qualquer erro. Os dois processos correm em máquinas separadas cujo sistema de ficheiros é reinicializado a cada arranque, e os ficheiros intermédios de maturação não estavam a ser publicados no repositório de dados. Corresponde à classe de custo que D. Sculley et al. (2015) designam por dependência de dados não declarada: cada componente cumpre o seu contrato, e a suposição que os liga não está expressa em parte alguma. O Capítulo 6 retoma o caso como limitação.

4.7 Ciclo de vida do componente aprendido

O sistema treina um único modelo, que é a regressão logística de nove entradas descrita na Secção 3.6. Medido contra uma linha de base de uma só variável, esse modelo apresenta desempenho inferior, resultado reportado na Secção 5.4.

A contribuição de engenharia não reside na dimensão do modelo, mas na infraestrutura que torna esse resultado, e a conclusão negativa que ele sustenta, defensáveis. Essa infraestrutura tem sete componentes, cada um dos quais existe porque a sua ausência produziria um resultado favorável e não verificável. A Figura 4.8 representa as duas metades do ciclo.




Figura 4.8: As duas metades do ciclo. Na metade superior, a construção: os dados são rotulados, a divisão é cronológica, a calibração é ajustada no bloco de validação e o bloco de teste é utilizado uma única vez. Na metade inferior, a observação: o modelo em produção é o modelo avaliado, cada decisão é registada, e dias mais tarde é confrontada com o movimento efetivamente observado. A ligação a tracejado fecharia o ciclo e não existe: a deriva é medida e não é corrigida.

Construção do conjunto de dados. O FNSPID fornece títulos datados, e os preços provêm de fonte distinta. O alinhamento das duas séries, a atribuição de uma notícia de sábado ao dia de negociação correspondente, e a derivação do rótulo a partir do movimento futuro constituem o trabalho que produz os 79 753 exemplos da Secção 3.2.

Declaração do rótulo como decisão. A existência de movimento anormal nos três dias seguintes não é um facto presente nos dados: é uma definição, com limiar e horizonte escolhidos. A Secção 5.4 mede nove definições alternativas em lugar de assumir a adotada.

Verificação da separação temporal. Aos blocos cronológicos e ao embargo junta-se um teste executável: perturbado o futuro de um exemplo, as suas entradas têm de permanecer inalteradas e o seu rótulo tem de mudar. A ausência de fuga passa assim de afirmação a propriedade verificada a cada execução.

Calibração com enviesamento medido. A saída do classificador é um valor no intervalo unitário, que serve simultaneamente para ordenar candidatas e para as excluir. O ajuste de Platt corre sobre um bloco que nunca participou no treino, e a discrepância de prevalência entre esse bloco e o de teste é declarada no Capítulo 5 em vez de ficar implícita.

Versionamento dos artefactos. O modelo treinado, o calibrador e um descritor da execução, contendo dimensão de cada bloco, prevalência, semente e métricas, residem no repositório. Uma métrica desacompanhada do artefacto que a produziu não é reproduzível.

Identidade entre modelo avaliado e modelo implantado. O codificador de frases utilizado na avaliação depende de uma biblioteca cujo volume excede o contendor de produção. Em vez da substituição por outro modelo, que faria a dissertação descrever um sistema distinto do que se encontra em funcionamento, o mesmo modelo foi exportado para formato de execução leve e a fidelidade da conversão foi medida.

Observação do sistema implantado. Cada decisão de triagem é registada. Decorridos os dias necessários, um segundo procedimento rotula essas decisões pela mesma regra utilizada no treino e mede o contributo do modelo. Foi por esta via que se estabeleceu a ausência de contributo reportada na Secção 5.4. A deriva das entradas é medida pelo mesmo mecanismo.

4.7.1 Componentes desenvolvidos e componentes consumidos

O único modelo consumido do exterior é um codificador de frases pré-treinado, utilizado sem qualquer ajuste. O trabalho não reivindica contribuição sobre esse componente além da sua seleção por medição, efetuada contra quatro alternativas, entre as quais um modelo de maior dimensão, dois codificadores mais recentes e um modelo específico do domínio financeiro, que apresentou o pior desempenho do conjunto. A dependência é essencial, uma vez que não existe recuperação semântica sem representação de frases, e é simultaneamente substituível: a interface que o isola dispõe de uma implementação alternativa que degrada para sobreposição lexical quando o modelo não está disponível.

Foi desenvolvido no âmbito deste trabalho tudo o resto. O conjunto de dados rotulado e o procedimento de alinhamento que o protege de fuga temporal. O detetor, com a janela de estimação que exclui o dia explicado. A repartição do movimento com encolhimento dos coeficientes. A base de precedentes com impacto medido. O classificador de triagem e a sua calibração. A política de decisão e as constantes da Tabela 4.2. A camada que compõe o texto a partir dos objetos calculados. E o mecanismo que observa o sistema depois de implantado.

O sistema não integra um modelo de linguagem na produção do texto entregue ao utilizador. A ausência é deliberada e decorre do argumento desenvolvido na Secção 2.7: uma frase gerada constitui uma afirmação, ao passo que o sistema descrito entrega afirmações acompanhadas da evidência que as sustenta.

4.7.2 Limitações do ciclo

O ciclo não inclui retreino. Os parâmetros correspondem ao período de 2018 a 2023 e não foram reajustados, apesar de a deriva se encontrar medida. A operação seria tecnicamente possível, dado que os rótulos novos derivam dos preços observados; o impedimento é que o retreino com o registo de produção alteraria os valores reportados neste documento, e a avaliação dessa alteração exige tempo de observação que não estava disponível. A Secção 6.5 enuncia-o como trabalho futuro.

O ciclo não inclui igualmente qualquer forma de verdade humana. Os três rótulos utilizados neste trabalho, correspondentes a movimento anormal, pertença ao mesmo setor e percentil de movimento, constituem aproximações verificáveis que nunca foram confrontadas com o julgamento de um avaliador humano. É a limitação de que as restantes mais dependem, e o Capítulo 6 retoma-a.

Capítulo 5


Casos de estudo

Os dois capítulos anteriores descreveram os métodos escolhidos e o sistema que os põe a funcionar. Este determina o que cada um deles vale. Descreve-se primeiro o desenho experimental e as métricas utilizadas. Seguem-se quatro casos de estudo: três correspondem às questões de investigação, e o quarto ao comportamento do sistema em operação, onde as escolhas dos capítulos anteriores encontram dados que não estavam disponíveis quando foram tomadas.

5.1 Desenho experimental e métricas

Esta secção fixa a forma comum a todos os casos de estudo e define as medidas empregues, com especial atenção ao valor que cada uma assume na ausência de informação.

Cada caso de estudo segue quatro passos, representados na Figura 5.1: a pergunta, o procedimento de medição e a alternativa contra a qual a comparação é feita, o resultado obtido, e o que esse resultado não permite concluir. O quarto passo é o que distingue uma avaliação de uma demonstração. Os valores medidos sobre conjuntos históricos congelados são produzidos por procedimentos automáticos com semente fixa e reproduzem-se exatamente. Duas classes de valor não têm essa propriedade, e são identificadas onde aparecem. Os valores lidos do sistema em operação são instantâneos datados, que crescem com o canal. Os que dependem de cotações reajustadas pela fonte podem variar na terceira casa decimal.



os dois erros custam coisas diferentes, e nenhuma medida deste capítulo os trata como iguais

Figura 5.1: A forma seguida por todos os casos de estudo. O quarto passo delimita o alcance de cada resultado. Em baixo, os dois tipos de erro que as medidas desta secção equilibram, e o custo distinto de cada um no domínio de aplicação.

Todas as medidas assentam nas quatro combinações entre o que o sistema afirma e o que se verifica. A precisão é a fração de acertos entre as ocasiões em que o sistema falou, $VP/(VP + FP)$; a cobertura, também chamada *recall*, é a fração dos casos relevantes que

foram assinalados, $VP/(VP + FN)$. As duas variam em sentidos opostos, e uma regra que assinale quase tudo atinge cobertura elevada com precisão baixa.

O F_1 é a média harmónica das duas, $2PC/(P + C)$, e aproxima-se do pior dos dois valores, o que impede que um extremo seja premiado. Para o z-score, com precisão 0,381 e cobertura 0,800, resulta 0,516; para a regra de limiar fixo, com precisão 0,122 e cobertura 0,992, resulta 0,218.

A precisão@ k aplica-se à recuperação, que devolve uma lista ordenada de que o utilizador lê apenas o início. Mede a fração dos k primeiros resultados que são relevantes (Manning, Raghavan e Schütze 2008), com $k = 5$, valor que corresponde ao que cabe num alerta.

A Precision-Recall Area Under the Curve (PR-AUC) aplica-se à triagem, que devolve uma probabilidade e não uma decisão. Cada limiar possível produz um par de precisão e cobertura, e o conjunto desses pares desenha a curva de precisão e cobertura; a área sob essa curva resume o modelo em todos os limiares simultaneamente, em vez de o julgar num limiar escolhido manualmente. É preferível à percentagem de acertos porque, com classes desequilibradas, responder invariavelmente que a notícia não é material acerta 62,2% das vezes sem qualquer aprendizagem.

O índice de Brier observa o valor da probabilidade e não a ordenação, sendo a média do quadrado do erro entre a probabilidade anunciada e o resultado observado, com valores menores a corresponder a melhor desempenho. O quadrado penaliza de forma mais do que proporcional os enganos confiantes, que é a propriedade adequada num sistema que exhibe percentagens a um destinatário sem meios para as questionar.

Uma medida lida sem o valor que lhe corresponde na ausência de informação conduz à conclusão errada, e este capítulo documenta três ocasiões em que isso sucedeu. A Tabela 5.1 fixa esse valor para cada medida.

Tabela 5.1: Cada medida, a pergunta a que responde, o valor que um método sem informação obtém, e o caso de estudo em que é utilizada. A coluna central é a que impede a leitura otimista de uma percentagem isolada.

Medida	Responde a	Valor sem informação	Utilizada em
Amplitude de disparo	O detetor comporta-se do mesmo modo em empresas distintas?	zero é o ótimo, e é atingível sem informação	QI1
F_1	Acerta quando fala, e fala quando devia?	depende dos dados	QI1
Precisão@5	Das cinco apresentadas, quantas são relevantes?	0,240, medido por escolha aleatória	QI2
PR-AUC	Ordena bem, qualquer que seja o limiar?	0,378, a prevalência do bloco de teste	QI3
Índice de Brier	A percentagem anunciada corresponde à frequência observada?	0,622, obtido por anunciar sempre a unidade	QI3

A primeira linha da Tabela 5.1 é a única medida do capítulo que não utiliza rótulos. A amplitude de disparo é a diferença entre a taxa a que o detetor assinala na empresa em que

mais fala e a taxa na empresa em que menos fala. Assenta num único princípio: um detetor universal deve comportar-se de forma semelhante em empresas distintas. A sua propriedade menos evidente, e que a Secção 5.2 desenvolve, é a de que o ótmo é atingível sem qualquer informação.

5.2 Detecção consistente entre empresas

O primeiro caso de estudo responde à Q11: um z-score deslizando deteta movimentos invulgares de forma mais consistente entre empresas do que uma regra de limiar fixo. A resposta é afirmativa, com uma margem de mais de vinte vezes na medida principal.

5.2.1 Procedimento

A avaliação utiliza três anos de cotações diárias de quinze empresas de grande capitalização, entre junho de 2023 e junho de 2026, o que corresponde a aproximadamente setecentos e cinquenta dias por empresa. O conjunto é distinto da lista de doze empresas monitorizadas em produção, pela razão enunciada na Secção 3.2: a avaliação exige variedade de volatilidade, e a lista implantada é uma decisão de produto.

O argumento principal não recorre a rótulos. Um detetor destinado a assinalar dias raros deve disparar a uma taxa semelhante em empresas distintas; se dispara com frequência elevada numa e raramente noutra, o que está a medir é a volatilidade da empresa e não a raridade do dia. Como argumento de apoio utiliza-se um rótulo aproximado, que classifica como extremo um dia situado no percentil noventa e nove dos retornos da própria empresa. O rótulo é imperfeito, por ser ele próprio relativo à volatilidade, e ocupa por isso a posição secundária.

5.2.2 Resultado

A Figura 5.2 resume as duas medidas, e a primeira delas é a que sustenta a conclusão desta secção: o que distingue os dois métodos não é o nível a que disparam, mas o facto de o limiar fixo acompanhar a volatilidade de cada ação enquanto o z-score se mantém quase constante entre elas.




Figura 5.2: As duas medidas, lado a lado. Em A, a diferença entre a taxa máxima e a taxa mínima entre as quinze empresas; o limiar fixo assinala 0,9% dos dias na empresa mais calma e 35,3% na mais volátil, enquanto o z-score se mantém entre 1,6% e 3,1% em todas. Em B, o desempenho contra o rótulo aproximado.

A amplitude da taxa de disparo é de 0,015 para o z-score e de 0,344 para o limiar fixo, uma diferença superior a vinte vezes. Contra o rótulo aproximado, o z-score obtém $F_1 = 0,516$ e o limiar fixo 0,218.

A comparação envolve uma assimetria de tratamento. A janela do z-score é variada mais adiante nesta secção, ao passo que o limiar de três por cento da regra fixa é o valor convencional e não foi otimizado. O que a comparação estabelece com segurança não é que nenhum limiar fixo obteria melhor resultado, mas que um limiar fixo mede uma quantidade diferente da pretendida, porque a mesma percentagem corresponde a raridades distintas em empresas distintas. Este argumento não depende do valor escolhido.

5.2.3 O que a medida principal não exclui

A amplitude da taxa de disparo tem o zero como ótimo, e esse ótimo é atingível por um método sem qualquer informação. Um detetor que assinalasse em cada empresa uma fração fixa de dias escolhidos ao acaso apresentaria amplitude praticamente nula, superando o z-score precisamente na medida que esta secção elege como principal. A afirmação decorre da construção do método e não exige execução.

A consequência não é a invalidação da medida, mas a obrigação de a ler em conjunto com a segunda, e é essa a razão de existirem duas. A amplitude exclui o limiar fixo, que dispara em função da volatilidade da empresa e não da raridade do dia. O F_1 exclui o disparo aleatório, que se situa ao nível do acaso contra qualquer rótulo. Nenhuma das duas medidas é suficiente isoladamente, e apenas a regra deslizante satisfaz ambas.

Regista-se ainda uma assimetria no padrão de evidência aplicado ao longo do capítulo. Os valores desta secção e da seguinte são pontos, sem intervalo de confiança, ao passo que os da Secção 5.4, onde reside o resultado que contraria a hipótese inicial, são acompanhados de reamostragem por grupos. A justificação parcial reside na ordem de grandeza das diferenças aqui observadas, que nenhuma reamostragem plausível inverteria. A justificação não é completa, uma vez que dias da mesma empresa também não constituem observações independentes neste caso, pela mesma razão de agrupamento de volatilidade invocada mais adiante.

5.2.4 Comparação com detetores aprendidos

A comparação mais exigente confronta a regra estatística com métodos de aprendizagem automática concebidos para detetar anomalias. Foram avaliados dois, sobre a mesma informação e sob a mesma disciplina de não utilizar informação posterior ao dia avaliado: o *Isolation Forest* (F. T. Liu, Ting e Zhou 2008) e o *Local Outlier Factor* (Breunig et al. 2000). Ambos correram numa única configuração, sem procura de hiperparâmetros, o que limita o alcance da sua derrota pela mesma razão invocada adiante para o modelo de árvores. Fica estabelecido que estes detetores, assim parametrizados e sobre estas entradas, não superam a regra; não que nenhuma parametrização o faria. A Figura 5.3 apresenta o resultado.

A regra transparente supera os dois métodos, com quase o dobro do F_1 e com consistência entre empresas substancialmente melhor. Este é o primeiro de três casos, ao longo do capítulo, em que uma técnica mais sofisticada é comparada em condições equivalentes com uma técnica mais simples e não obtém melhor resultado. A escolha do método simples passa assim a estar justificada por medição e não por preferência.




Figura 5.3: Os três detetores sobre os mesmos dados e sob o mesmo protocolo, restrito à região que os três conseguem pontuar. Os dois métodos aprendidos assinalam quase tudo, com cobertura de 0,913 e 0,989, e acertam pouco, com precisão em torno de 0,16. A amplitude da taxa de disparo acompanha o mesmo padrão, com 0,017 para a regra contra 0,140 e 0,183 para os detetores aprendidos.

A explicação não reside na qualidade dos métodos. Ambos determinam o que é invulgar a partir da geometria dos dados, por vias opostas. O *Isolation Forest* identifica o ponto raro pela facilidade com que sucessivos cortes aleatórios o separam dos restantes (F. T. Liu, Ting e Zhou 2008). O *Local Outlier Factor* confronta a densidade na vizinhança de cada ponto com a dos pontos que o rodeiam (Breunig et al. 2000).

Trata-se de métodos não paramétricos, exteriores à família estatística que Chandola, Banerjee e Kumar (2009) caracteriza pela modelação da distribuição dos dados normais, e foram concebidos para conjuntos com muitas variáveis em interação. O problema aqui tratado apresenta outra forma: uma série de retornos por empresa, cuja estrutura pertinente é temporal. O agrupamento da volatilidade, formalizado pelos modelos Autoregressive Conditional Heteroscedasticity (ARCH) e Generalized Autoregressive Conditional Heteroscedasticity (GARCH) (Bollerslev 1986; Engle 1982), desloca ao longo do tempo o limiar do que constitui um dia invulgar; uma janela deslizante acompanha essa deslocação por construção, enquanto um detetor ajustado ao conjunto completo tem de a inferir.

Uma nota sobre a compatibilidade entre os valores: o z-score aparece com $F_1 = 0,530$ nesta comparação e com 0,516 na anterior. Os dois valores medem o mesmo detetor sob protocolos distintos. O segundo abrange todos os dias avaliados, enquanto o primeiro se restringe à região que os três detetores conseguem pontuar, única em que a comparação entre eles é equitativa. A amplitude segue a mesma regra, sendo 0,017 neste protocolo e 0,015 no anterior.

5.2.5 Duas comparações que não confirmam as escolhas implantadas

Duas experiências adicionais foram concebidas para justificar opções tomadas, e nenhuma delas as confirmou. Ambas ficam reportadas tal como resultaram.

A primeira incide sobre o estimador de volatilidade. A alternativa a atribuir o mesmo peso aos vinte dias da janela consiste em atribuir maior peso aos dias recentes, através de uma média com decaimento exponencial. A Figura 5.4 apresenta o resultado.




Figura 5.4: Os dois estimadores, com a mesma cobertura. A alternativa com decaimento exponencial elimina quase metade dos falsos alarmes, elevando a precisão de 0,381 para 0,568, e é ainda mais consistente entre empresas, com amplitude de 0,012 contra 0,015. O sistema mantém o estimador que obteve o resultado inferior, pela razão exposta no texto.

Com cobertura idêntica, a alternativa obtém $F_1 = 0,664$ contra 0,516 do estimador implantado. O mecanismo é compreensível. Movimentos grandes ocorrem em grupo. Uma média de vinte dias com pesos iguais dilui um choque por vinte observações e continua a assinalar os dias seguintes durante semanas; uma média que privilegia o passado recente absorve-o de imediato.

O sistema mantém o estimador que obteve o resultado inferior. A razão é a que atravessa o trabalho: a média e o desvio-padrão dos últimos vinte dias são explicáveis em duas frases a qualquer leitor, e pesos com decaimento exponencial não o são. Numa ferramenta cujo argumento central é a explicabilidade, um ganho de precisão obtido à custa da explicação não constitui inequivocamente um ganho. Fica, porém, registado como escolha e não como resultado: a alternativa está medida, o ganho está quantificado, e a sua adoção constitui uma alteração de pequena dimensão caso a explicabilidade deixe de ser a restrição dominante.

A segunda experiência incide sobre a dimensão da janela, e a Figura 5.5 apresenta-a.




Figura 5.5: Desempenho contra o rótulo aproximado para três dimensões da janela. O valor cresce de forma monótona com a dimensão da janela, e a janela implantada não é a que obtém o melhor resultado. O texto expõe as duas razões pelas quais a janela mais longa não foi adotada, sendo a segunda uma reserva sobre a validade desta própria medição.

Uma janela de sessenta dias obtém $F_1 = 0,678$ contra os 0,516 da janela de vinte. Duas razões justificam a manutenção da janela mais curta. A primeira é de responsividade: uma janela de sessenta dias demora três meses a reagir a uma mudança de regime, e uma empresa que transite de calma a volátil continuaria a ser julgada pela norma anterior.

A segunda respeita à validade desta medição concreta. O rótulo é construído a partir do percentil de movimento da própria empresa, sendo por isso relativo à volatilidade; uma janela mais longa produz uma norma menos adaptativa, que assinala com maior frequência a cauda extrema, que é precisamente o que este rótulo premeia. Existe circularidade, e ela favorece a janela longa por construção. Esta é a razão pela qual o argumento principal desta secção é a consistência da taxa de disparo, que não recorre a rótulos. A formulação que subsiste é que a janela de vinte dias foi escolhida por responsividade, e que a única medição existente sobre este ponto não a sustenta.

5.2.6 Limites da conclusão

O rótulo é aproximado e relativo à volatilidade, razão pela qual o argumento de peso é o da consistência, que dele não depende. As quinze empresas são todas de grande capitalização e foram selecionadas em 2026, com a avaliação a percorrer o passado: sobreviveram por construção, e nenhuma delas saiu de bolsa, foi absorvida ou desapareceu da lista. O que se mede é o comportamento do método em empresas que subsistiram, e não na população de que foram extraídas. A comparação incide ainda sobre este conjunto e este período, e nada nela permite antecipar o resultado noutro mercado ou noutra década.

5.3 Recuperação de precedentes

O segundo caso de estudo responde à Q12: a recuperação por significado encontra notícias passadas de outra empresa do mesmo setor melhor do que alternativas triviais. A resposta é afirmativa nos cinco setores avaliados, e a formulação por setor é necessária, uma vez que o valor agregado é enganador nos dois sentidos.

5.3.1 Procedimento

A avaliação de sistemas de recuperação enfrenta a ausência de uma lista de respostas corretas, dado que nenhum conjunto de pares de notícias se encontra anotado como relacionado. Utiliza-se por isso uma aproximação verificável: considera-se relevante a notícia recuperada que pertença ao mesmo setor da notícia de consulta. A aproximação é imperfeita, porque duas notícias do mesmo setor podem tratar de assuntos distintos, mas é objetiva e foi fixada antes de os resultados serem observados.

Impõe-se ainda uma restrição que torna a tarefa mais difícil: a notícia recuperada tem de pertencer a uma empresa diferente. Sem ela, o sistema obteria bom desempenho devolvendo notícias da própria empresa, que pertencem quase sempre ao mesmo setor por construção. O corpus contém 3 714 notícias distribuídas por cinco setores, recolhidas ao longo de vinte e sete dias, e a medição utiliza quinhentas consultas por repetição em cinco repetições com sementes distintas. A amplitude do corpus delimita o que a medição estabelece: vinte e sete dias não sustentam afirmações sobre generalização temporal. O protocolo não exige que o candidato seja anterior à consulta, e apenas 31,1% dos vizinhos o são. A verificação sob restrição causal foi feita em agregado sobre o corpus histórico, onde a margem sobre o acaso se conserva, e não por setor.

5.3.2 Resultado

A Figura 5.6 apresenta o método utilizado, uma variante de maior dimensão e as alternativas triviais.




Figura 5.6: Precisão@5 do método utilizado, a escuro, contra cinco alternativas. As barras claras incluem duas linhas de base triviais, uma linha lexical e um codificador específico do domínio financeiro. A alternativa de devolver sempre notícias do setor maior obtém 0,467 sem qualquer modelo, valor discutido no texto e que obriga a ler o agregado com reserva.

A escolha aleatória acerta em 24,0% dos casos, e é esse o valor de referência, e não zero, uma vez que os setores existem em número finito e têm dimensões distintas. A procura por palavras em comum eleva o resultado para 34,6%, e a comparação de significado para 51,4%.

A linha lexical corresponde à forma mais simples dessa família: contagem de palavras projetada por dispersão e comparada pelo cosseno, sem ponderação pela raridade dos termos, sem saturação da frequência e sem normalização pelo comprimento do texto. Pertence à tradição que vai do modelo de espaço vetorial (Salton, Wong e C. S. Yang 1975) às funções de ordenação probabilísticas como o BM25 (Robertson e Zaragoza 2009), situando-se no degrau inicial dessa família. Os dezassete pontos percentuais que a representação de frases (Reimers e Gurevych 2019) acrescenta medem, por conseguinte, a distância a um ponto de partida elementar e não a distância a um sistema lexical afinado. A comparação com uma função de ordenação bem parametrizada constitui trabalho por realizar, e é a que tornaria esta conclusão mais forte.

O codificador específico do domínio financeiro obtém 0,420, o valor mais baixo de todos os modelos avaliados. O modelo avaliado é o ponto de controlo público *ProsusAI/finbert*, identificado desta forma por ser o artefacto exato sobre o qual a medição incide; pertence à família de codificadores financeiros de que Zhuang Liu et al. (2020) e A. H. Huang, Wang e Y. Yang (2023) são as versões documentadas em publicações revistas por pares. Foi utilizado com a média dos seus vetores como representação da frase, que é a forma de o aplicar sem novo treino. Trata-se de um codificador ajustado para classificação de sentimento e não para posicionar frases num espaço onde a distância signifique semelhança, e é precisamente esse objetivo de treino que o Sentence-BERT acrescenta (Reimers e Gurevych 2019). A medição estabelece que este modelo de domínio, utilizado desta forma, obtém resultado

inferior a um modelo genérico treinado para semelhança; não estabelece que conhecimento de domínio seja irrelevante para a tarefa.

5.3.3 A alternativa trivial que o valor agregado esconde

O corpus não está equilibrado: 1 736 das 3 714 notícias, quase metade, pertencem ao setor da tecnologia. Existe por isso uma estratégia que dispensa qualquer modelo e não observa sequer a consulta, consistindo em devolver invariavelmente cinco notícias de tecnologia. Acerta em todas as consultas de tecnologia e em nenhuma das restantes, pelo que a sua precisão iguala exatamente a fração de consultas que são de tecnologia, 0,467. Medida contra esta alternativa, e não contra o acaso uniforme, a margem do método reduz-se de +0,274 para +0,047, e a linha lexical de 0,346 passa a situar-se abaixo do valor de referência.

O valor agregado é, contudo, o elemento enganador, e não o método. A estratégia trivial obtém 1,000 nas consultas de tecnologia e 0,000 em todas as outras, devolvendo notícias de semicondutores a quem consulta sobre uma petrolífera. O que ela explora não é uma propriedade do problema, mas a composição deste corpus.

A comparação que resiste a esta objeção é a que se realiza dentro de cada setor, onde a estratégia trivial não tem por onde se apoiar. O painel A da Figura 5.7 apresenta-a.




Figura 5.7: Em A, a precisão@5 e o valor de acaso correspondente dentro de cada setor: o método situa-se acima do respetivo valor de referência nos cinco. Em B, o protocolo simétrico do teste de escala e o protocolo causal que reproduz a restrição da produção, cada um ao lado do seu valor de referência. A precisão desce de 0,595 para 0,513, mas a margem sobre o acaso varia apenas de +0,262 para +0,254.

O valor de acaso é de 0,429 na tecnologia e situa-se em torno de 0,072 em cada um dos quatro setores restantes. O método obtém 0,712 na tecnologia, 0,448 na energia, 0,419 na saúde, 0,272 na banca e 0,171 no consumo. Onde o valor agregado é dominado, o método acrescenta 0,283; onde o corpus é escasso, obtém várias vezes o valor de referência. O agregado subestima o método e sobrestima a alternativa trivial pela mesma razão, que é a de quase metade das consultas provir do único setor onde o valor de referência já era elevado. A afirmação que o trabalho sustenta é por isso a mais estreita: a recuperação semântica supera a taxa-base dentro de cada um dos cinco setores, e o valor agregado não é a forma adequada de o enunciar.

A variante de maior dimensão obtém $0,538 \pm 0,011$ contra $0,514 \pm 0,015$ da utilizada, sobre cinco sementes; a diferença é pequena face à dispersão e nenhum teste de significância foi

realizado. Dois codificadores mais recentes obtêm 0,504 e 0,513, indistinguíveis do implantado. A adoção do modelo mais pequeno em produção decorreu do custo computacional e não de uma vantagem de qualidade, constituindo uma troca explícita cujo preço em precisão está quantificado. A alternativa aparentemente mais razoável, que consiste em apresentar as notícias mais recentes, obtém 0,126, o valor mais baixo de todos, o que é coerente com a ausência de qualquer razão para a notícia mais recente sobre outra empresa estar relacionada com a notícia em análise.

5.3.4 Comportamento à escala e sob a restrição da produção

A avaliação anterior incide sobre um corpus recente e de dimensão limitada. Para verificar que o resultado não depende desse corpus, a mesma medição foi repetida sobre o conjunto histórico completo, com aproximadamente oitenta mil notícias de seis anos. Neste protocolo simétrico, que ainda admite candidatos posteriores à consulta, a precisão@5 sobe para 0,595. A subida não deve, porém, ser lida na íntegra como ganho: o valor de acaso sobe igualmente, de 0,240 para 0,333, porque a composição por setores é distinta. Medida contra o valor de referência respetivo, a margem é de +0,274 no primeiro caso e de +0,262 no segundo. O resultado estabelece que o método não se degrada quando o corpus passa de recente e curto para seis anos, e não que melhore com mais dados.

O protocolo anterior concede uma liberdade que o sistema em produção não possui. A única restrição imposta é a de o candidato pertencer a outra empresa, o que permite que seja posterior à consulta, e esse caso é comum: no corpus recente, 38,7% dos vizinhos devolvidos têm data posterior à da consulta e outros 30,2% são do mesmo dia. O sistema implantado não dispõe dessa liberdade, uma vez que a base de precedentes só recebe um caso oito dias após a sua observação, conforme a Secção 4.6.1 descreve.

Não é utilização de informação futura no sentido corrente. O critério de acerto é a pertença ao mesmo setor, e o setor de uma notícia não varia com o tempo, pelo que a direção temporal não pode inflacionar a precisão. O que está em causa é a correspondência entre o valor reportado e a tarefa que a questão de investigação descreve, que fala em notícias passadas. A medição repete o protocolo acrescentando à máscara a condição de o candidato ser estritamente anterior à consulta, e reproduz o valor simétrico na mesma execução para que a comparação seja emparelhada. Nenhuma das 2 500 consultas ficou sem passado suficiente. O resultado consta do painel B da Figura 5.7: a precisão desce 0,082, o valor de referência desce quase outro tanto, e a margem varia 0,008. O método conserva praticamente toda a vantagem quando obrigado a operar como opera em produção.

Esta é a terceira ocasião no capítulo em que a leitura de uma precisão sem o valor de referência correspondente conduziria à conclusão errada. Sucedeu na passagem do corpus recente para o completo, sucede na precisão dentro do orçamento tratada na Secção 5.4, e sucede aqui. A precisão é uma quantidade sem significado próprio, que apenas o adquire ao lado da alternativa sem informação.

5.3.5 Limites da conclusão

A pertença ao mesmo setor não equivale a relação entre notícias, sendo uma aproximação construída por ser verificável e não por corresponder exatamente à propriedade pretendida.

A segunda observação tem consequências para o produto: a recuperação capta tema e não direção. Duas notícias podem tratar do mesmo assunto e o preço evoluir em sentidos opostos, que foi o que sucedeu no exemplo apresentado no Capítulo 4. A Figura 5.8 quantifica-o.



Figura 5.8: Fração de casos recuperados cujo preço evoluiu no mesmo sentido que o da notícia de consulta, contra o valor obtido por emparelhamento aleatório sob as mesmas restrições. A diferença é de 0,020. O sistema apresenta por isso os casos individualmente, e o texto do alerta declara que a semelhança é de tema.

A concordância de direção entre a notícia de consulta e os casos recuperados situa-se em 0,708 contra um valor de acaso de 0,688. É por esta razão que o sistema apresenta os casos um a um e nunca os resume a uma média, que seria lida como previsão, e que o texto do alerta declara explicitamente tratar-se de casos semelhantes quanto ao tema.

5.4 Triagem de notícias

O terceiro caso de estudo responde à Q13: um modelo treinado prioriza notícias melhor do que uma linha de base baseada apenas em volatilidade. A resposta é negativa, e é o resultado com maior valor informativo do trabalho.

5.4.1 Procedimento

O conjunto de dados contém 79 753 exemplos entre 2018 e 2023, cada um correspondente a uma notícia com o contexto de mercado do dia e o rótulo definido na Secção 3.6. A divisão é cronológica com embargo, e a prevalência de casos positivos no bloco de teste é de 0,378. A métrica principal é a PR-AUC, adequada quando as duas classes estão desequilibradas.

Para efeitos práticos, uma diferença de PR-AUC inferior a 0,02 é tratada como indistinguível, mesmo quando o intervalo emparelhado exclui zero. O limite é uma escolha do autor, declarada antes dos resultados, o que obriga à sua aplicação nos dois sentidos.

Dois cuidados de montagem asseguram que a comparação não favorece a conclusão obtida. O primeiro é a inclusão de um conjunto de árvores treinado por reforço do gradiente (Friedman 2001), o mais expressivo dos modelos comparados, por captar interações e efeitos não lineares que a regressão logística não capta por construção. Este modelo foi executado com os parâmetros por defeito da biblioteca, sem procura de hiperparâmetros, o que limita o alcance da sua derrota: estabelece que o texto não produz vantagem nesta montagem, e não que a não produziria num modelo não linear afinado. O segundo cuidado é a conversão de todas as pontuações em probabilidades por calibração *a posteriori* sobre um bloco de validação reservado (Niculescu-Mizil e Caruana 2005), sem a qual a comparação pelo índice de Brier não seria válida entre modelos.

Uma entrada não está disponível no mesmo referencial em produção. O retorno do próprio dia corresponde, no conjunto histórico, ao movimento completo do dia da notícia, ao passo que em produção a notícia é pontuada antes de esse dia encerrar. O resultado apresentado avalia por isso o modelo com a variável diária completa e não demonstra paridade com a pontuação intradiária. A direção da assimetria é conhecida. A entrada em causa pertence ao bloco de contexto, presente nos modelos de resultado inferior. A linha de base vencedora usa uma só entrada: a volatilidade dos vinte dias anteriores, fechada na véspera. O referencial mais generoso encontra-se do lado dos modelos que a comparação não favorece, e a sua correção só poderia tornar o resultado negativo mais forte.

5.4.2 Resultado

A Figura 5.9 apresenta os seis modelos comparados. As curvas completas de precisão e cobertura, de que estes valores agregados são a área, constam dos artefactos de avaliação identificados no Apêndice A; nelas a curva do modelo de volatilidade situa-se acima das restantes em quase toda a extensão do eixo, o que estabelece que a diferença não é um artefacto do valor agregado.




Figura 5.9: Área sob a curva de precisão e cobertura dos seis modelos. A linha tracejada assinala a prevalência do bloco de teste, que é o valor obtido por um modelo que atribua a mesma probabilidade a todos os exemplos. Os valores são pontos, e os intervalos marginais a noventa e cinco por cento, obtidos por reamostragem dos 1 951 grupos, são amplos e sobrepõem-se: [0,492; 0,597] para a volatilidade, [0,487; 0,592] para o contexto e [0,453; 0,540] para o contexto com texto. A comparação que a subsecção seguinte sustenta é a diferença emparelhada entre modelos sobre as mesmas reamostragens, e não a distância entre dois pontos.

O valor mais elevado pertence ao modelo mais simples de todos, o que utiliza apenas a volatilidade recente. Acrescentar-lhe o restante contexto não altera o resultado de forma distinguível, com 0,538 contra 0,542; acrescentar o texto do título deteriora-o de forma distinguível, com 0,496. O índice de Brier acompanha a mesma ordenação, com 0,218 para o modelo de volatilidade contra 0,229 para o modelo com texto e 0,622 para o modelo que anuncia sempre a unidade. A hipótese inicial, segundo a qual o texto da notícia traria informação ausente dos preços, não é confirmada sobre este corpus.

5.4.3 Três verificações à montagem experimental

O resultado negativo foi submetido a três verificações destinadas a determinar se decorre da montagem experimental.

A primeira respeita ao ajuste do modelo de texto. A comparação foi repetida concedendo ao texto as melhores condições disponíveis, com regularização afinada, redução do bloco de texto a trinta e duas dimensões e um modelo de linguagem especializado em finanças. O melhor resultado do texto sobe para 0,533 e permanece abaixo dos 0,542 da volatilidade.

A segunda respeita ao ruído de amostragem. O bloco de teste foi reamostrado mil vezes por grupos constituídos pela empresa e pelo dia, uma vez que notícias do mesmo dia sobre a mesma empresa partilham o rótulo e não constituem observações independentes. A diferença entre a volatilidade e a variante com texto é de +0,048, com intervalo entre +0,032 e +0,066, que exclui zero e supera o limite prático de 0,02. É a única comparação desta secção que o supera.

O alcance deste intervalo é, contudo, limitado: a reamostragem realiza-se dentro de um único bloco de teste, com duzentos e vinte e um dias de negociação, pelo que mede o ruído de amostragem nesse período e nada estabelece sobre a estabilidade entre períodos. A distinção não é teórica neste trabalho, dado que a Secção 5.6 reporta um deslocamento significativo na distribuição da entrada principal. Uma origem rolante com três ou quatro cortes sucessivos responderia à pergunta mais larga, e não foi realizada.

A terceira respeita à definição do rótulo, que utiliza um limiar de dois por cento e um horizonte de três dias, ambos escolhidos pelo autor. A comparação foi repetida para nove combinações de limiar e horizonte, e a Figura 5.10 apresenta o resultado.




Figura 5.10: Desempenho das duas famílias sob nove combinações de limiar e horizonte, com a prevalência de cada célula como referência. A volatilidade iguala ou supera o modelo com texto nas nove combinações, com prevalências entre 0,082 e 0,597. A célula correspondente ao rótulo utilizado no restante capítulo é a quinta, com limiar de dois por cento e horizonte de três dias.

O resultado negativo resiste às três verificações. A volatilidade iguala ou supera o modelo com texto nas nove definições de rótulo, com prevalências entre 0,082 e 0,597, o que retira à escolha concreta de limiar e horizonte o estatuto de ponto de ataque.

Uma quarta verificação incide sobre a composição dos blocos e conduz a uma conclusão que atua nos dois sentidos. Os três blocos quase não partilham empresas. O bloco de treino decorre entre 2 de janeiro de 2018 e 3 de março de 2022 e contém treze empresas; o bloco de teste decorre entre 2 de fevereiro e 18 de dezembro de 2023 e contém nove. Cinco empresas do treino não figuram uma única vez no teste, e uma empresa do teste, responsável por 17,1% das suas linhas, nunca figura no treino. Para as empresas presentes em ambos os lados, a taxa de positivos desloca-se de forma acentuada, e a Apple passa de 0,448 no treino para 0,183 no teste. Estes valores leem-se diretamente das colunas de identificação e de bloco do conjunto congelado e não exigem qualquer execução adicional.

Não se trata de utilização de informação futura nem de erro de divisão: o corte é realizado por dia, e a proporção respeita a definida na Secção 3.6. É a composição do corpus que varia com o tempo, pela mesma razão que torna o bloco de teste maior do que o de treino, uma vez que as empresas sobre as quais se escreve em 2018 não são as mesmas de 2023.

A favor do resultado negativo pesa o seguinte. O sinal do modelo é essencialmente a identidade da empresa, conforme a Secção 5.4.5 estabelece, e essa identidade é estimada sobre um conjunto de empresas quase ausente do bloco onde é avaliada. A volatilidade dos vinte dias anteriores, fechada na véspera, é comparável entre empresas e não depende da identidade de nenhuma. Contra o resultado, a comparação não separa a hipótese de o modelo ser pior da hipótese de a identidade não transferir entre estes dois períodos, separação que exigiria uma divisão de composição constante. A mesma constatação explica, sem recurso ao acaso, a prevalência de 47,0% da validação contra 37,8% do teste, que correspondem a conjuntos de empresas distintos e não apenas a períodos distintos.

5.4.4 Utilidade sob a restrição de orçamento

O produto apresenta no máximo cinco alertas por dia, pelo que a pergunta com significado operacional é a de qual a fração de acertos entre as cinco notícias escolhidas em cada dia. A Figura 5.11 apresenta quatro formas de as escolher.




Figura 5.11: Quatro formas de escolher as cinco notícias do dia, sobre o mesmo bloco de teste. A primeira barra não mede escolha às cegas, pela razão exposta no texto; o valor que corresponde à escolha às cegas é o segundo, $0,379 \pm 0,017$ sobre quarenta sementes. As quatro políticas escolhem conhecendo o dia completo, pelo que os valores são limites superiores do que uma política em linha consegue obter.

A primeira barra exige uma explicação, uma vez que a sua designação induz em erro. O modelo que alerta sempre atribui a mesma pontuação a todas as notícias, e quando todas empatam a métrica seleciona pela ordem em que as linhas surgem no ficheiro, que está ordenado por data e por nome da empresa. Esse valor de 0,163 mede a escolha por ordem

alfabética e não a escolha aleatória, e todas as linhas que seleciona pertencem à empresa que ocupa a primeira posição no alfabeto. Comparado com o valor de referência correto, o ganho do modelo é de 1,67 vezes e não das quase quatro vezes que a primeira leitura sugeriria. A lição é geral e aplica-se ao restante capítulo: verificar o que a linha de base mede é tão necessário quanto verificar o que o modelo faz.

A terceira e a quarta barras contêm o resultado incómodo. Uma tabela de treze constantes, correspondentes à volatilidade média de cada empresa, calculada exclusivamente sobre o bloco de treino e sem leitura de um único título, obtém 0,662 e supera o modelo treinado. A comparação tem uma reserva que a torna menos limpa do que parece: 17,1% das linhas do bloco de teste pertencem a uma empresa ausente do treino e recebem a mediana global em vez de uma constante própria. É, ainda assim, o terceiro caso do capítulo em que o método mais simples obtém melhor resultado. O que a evidência sustenta é que ordenar por volatilidade compensa, e não que aprender compense.

5.4.5 Ablação das entradas do modelo

O resultado anterior sugere que o modelo implantado reconhece a empresa e não a notícia. A verificação dessa hipótese consiste em tentar reproduzi-lo com uma tabela de consulta que atribua a cada empresa um único número fixado no bloco de treino, correspondente à fração das suas notícias que se revelaram materiais. Essa tabela não observa o título, não observa o dia e devolve invariavelmente o mesmo valor para a mesma empresa. A Figura 5.12 compara-a com o modelo implantado e desmonta o modelo entrada a entrada, sob o protocolo congelado.




Figura 5.12: Cada linha corresponde a um modelo treinado com menos informação do que o anterior. A linha decisiva é a da tabela de consulta, que não observa a notícia e iguala o modelo implantado na primeira medida e o supera na segunda. As duas linhas inferiores, que não dispõem de qualquer entrada de nível de empresa, situam-se exatamente na prevalência do bloco de teste.

Três leituras resultam da figura, e nenhuma depende de interpretação.

A tabela de consulta iguala o modelo e supera-o numa das medidas. Na PR-AUC obtém 0,534 contra 0,538, uma diferença de 0,004; na precisão dentro do orçamento, que é a medida mais próxima da utilização real, obtém 0,662 contra 0,632. Esta segunda diferença não foi acompanhada de reamostragem por grupos, ao contrário das diferenças de PR-AUC desta secção, pelo que se reporta como observação e não como superioridade estabelecida. Um número por empresa, fixado meses antes e nunca atualizado, produz o mesmo efeito que o modelo treinado.

Sem as entradas de nível de empresa não subsiste sinal. Retirando-as, a PR-AUC desce para 0,378, que é precisamente a prevalência do bloco de teste e o valor definido na Secção 5.1 como correspondente à ausência de informação.

A única entrada que descreve a notícia nada acrescenta. O comprimento do título, isoladamente, produz igualmente 0,378, o que torna a única informação por título recebida pelo modelo implantado indistinguível da ausência de informação.

Estas leituras obrigam a separar duas afirmações. A conclusão científica da QI3 mantém-se: a variante com texto dispõe de trezentos e oitenta e quatro números por título, possuindo por isso informação real sobre a notícia, e ainda assim obteve 0,496 contra os 0,542 da volatilidade, sendo essa a comparação que responde à questão. A decisão de produto, por seu turno, estava errada por razão distinta: o que foi implantado como porta de decisão foi a variante sem texto, escolhida por uma métrica que não formulava a pergunta de que o produto necessitava.

A manutenção da variante de nove entradas não decorre de esta apresentar o melhor valor entre as que cabiam no contentor de execução. Pelo critério fixado antes dos resultados, quatro valores são indistinguíveis entre si: os 0,542 da volatilidade, os 0,543 da variante sem indicadores de setor, os 0,538 da variante implantada e os 0,534 da tabela de consulta. As diferenças situam-se entre 0,004 e 0,009, muito abaixo do limite de 0,02. Aplicar esse limite apenas quando desfavorece uma conclusão seria não o ter fixado. A única diferença que o critério separa nesta comparação é a que distingue estas quatro variantes do bloco com texto, de +0,048 com intervalo entre +0,032 e +0,066. A escolha entre as quatro é, por isso, inteiramente de explicabilidade e não tem preço mensurável em PR-AUC: apenas a variante de nove entradas permite ao alerta apresentar as contribuições que elevam e reduzem a pontuação, conforme a Figura 4.5 exhibe.

A lição de método permanece: a PR-AUC sobre o conjunto completo pode assumir valor elevado quando a variação entre empresas domina, mesmo na ausência de qualquer capacidade de distinguir notícias dentro da mesma empresa. A métrica respondia à pergunta sobre a ordenação do conjunto, enquanto o produto necessitava da pergunta sobre a distinção entre duas notícias da mesma empresa.

5.4.6 O texto como acréscimo e não como substituto

Comparar a volatilidade, o contexto e o texto isoladamente responde a qual das representações é melhor, e não a se o texto acrescenta informação. A resposta a esta segunda pergunta exige somá-lo a uma base que conheça a empresa sem conhecer a notícia.

A variante que combina contexto e texto não constitui essa base, por somar o texto a um bloco que contém informação da notícia através da entrada de retorno do próprio dia. A base adequada é a tabela de consulta por empresa, e a razão é metodológica e não de desempenho: ela contém tudo o que o modelo conhece sobre a empresa e nada sobre a

notícia, pelo que somar-lhe o título isola a contribuição do texto. A tabela de consulta não é o melhor preditor conhecido, dado que na PR-AUC a volatilidade isolada se situa acima dela, com 0,542 contra 0,534.

O critério foi fixado antes da medição: um acréscimo apenas conta se o intervalo de confiança a noventa e cinco por cento da diferença, obtido por reamostragem por grupos constituídos pela empresa e pelo dia, excluir zero. A representação de texto não foi afinada para esta experiência, utilizando a mesma redução a trinta e duas dimensões da verificação anterior, de modo que o resultado não decorra da procura da configuração conveniente. A reamostragem utiliza mil repetições sobre 1951 grupos. A Figura 5.13 apresenta os três intervalos.




Figura 5.13: Diferenças de desempenho e respetivos intervalos de confiança a noventa e cinco por cento, obtidos por reamostragem por grupos. As duas primeiras linhas são diferenças de PR-AUC e a terceira é uma diferença de capacidade de ordenação dentro de cada empresa. Apenas a primeira exclui zero, e fá-lo abaixo do critério prático fixado antes da medição.

O título acrescenta a essa base +0,012 de PR-AUC, com intervalo entre +0,004 e +0,020, que exclui zero. É a primeira ocasião em que uma representação de texto apresenta um acréscimo detetável nesta tarefa, e o valor situa-se abaixo do critério prático de 0,02 fixado antes dos resultados.

Três reservas delimitam o alcance deste acréscimo, e todas são medições. A primeira é que a soma não supera a volatilidade isolada: o valor obtido é de 0,547 contra 0,542, e a diferença tem intervalo entre -0,032 e +0,037, que contém zero. A segunda é que o acréscimo não chega ao produto. A precisão dentro do orçamento de cinco alertas por dia é de 0,662 com e sem o texto, sem uma casa decimal de diferença. O acréscimo existe na ordenação do conjunto completo e desaparece quando apenas cinco notícias por dia são selecionadas.

A terceira é que o texto continua a não separar notícias da mesma empresa. A capacidade de ordenação dentro de cada empresa vale 0,500 por construção para a tabela de consulta e sobe para 0,512 quando se lhe soma o título. Para o modelo implantado é de 0,502, com intervalo entre 0,462 e 0,542, e sobe para 0,508 com o texto, num acréscimo de +0,006 cujo intervalo, entre -0,014 e +0,025, contém zero. Nenhum dos dois se distingue do acaso. A informação que o texto traz distingue empresas e períodos, e não notícias.

A resposta à Q13 mantém-se negativa e torna-se mais precisa. Nenhum modelo com texto supera a volatilidade, e o texto não é inútil: acrescenta ao que o modelo já conhece sobre

a empresa, de forma pequena e mensurável. O que impede esse acréscimo de alterar o sistema não é a ausência de informação, mas a natureza da informação, que distingue empresas quando o produto necessita de distinguir notícias. O trabalho seguinte requer um rótulo por notícia, e não apenas um modelo de maior dimensão.

Uma reserva final aplica-se ao próprio método. Este é mais um modelo avaliado sobre o mesmo bloco de teste, que já serviu várias comparações do capítulo, e quanto mais vezes um conjunto de teste é observado, mais provável se torna encontrar nele uma diferença pequena. As duas defesas utilizadas, que consistem em não afinar a configuração e em declarar o critério antes da medição, reduzem esse risco sem o eliminarem. A formulação que subsiste é a mais fraca das possíveis: não é possível rejeitar que o título acrescente informação, e o acréscimo, a existir, é inferior ao critério prático fixado antes da medição. Trata-se de um limite superior de um efeito e não de uma descoberta.

5.4.7 Limites da conclusão

O resultado não estabelece que o texto de notícias seja inútil. Foi avaliada uma única representação, constituída por títulos sem o corpo do artigo, sobre um único corpus. Com textos completos e maior volume de dados a resposta poderia ser distinta, o que constitui trabalho futuro.

Existe ainda uma hipótese alternativa que estas medições não excluem. O rótulo desconta o movimento do mercado assumindo sensibilidade unitária, pela incoerência declarada na Secção 3.6. Numa ação de sensibilidade elevada, o resíduo da subtração retém movimento do mercado, pelo que o erro do rótulo não é aleatório: é maior nas ações mais sensíveis ao mercado, que são tipicamente também as mais voláteis. Ora a linha de base vencedora é exatamente a volatilidade. Com o que está medido não é possível separar a hipótese de a volatilidade prever melhor a materialidade da hipótese de a volatilidade prever melhor o erro introduzido pelo rótulo. A experiência que resolveria a questão consiste em reconstruir o alvo com sensibilidades estimadas e encolhidas, como faz a Secção 3.4, e repetir as seis famílias. Não foi realizada. O nível e a ordenação das métricas ficam condicionados ao rótulo utilizado.

5.5 O que permanece mensurável na decomposição

A decomposição do movimento não dá origem a uma questão de investigação. Esta secção estabelece a razão dessa ausência e o que, apesar dela, permanece falsificável na técnica.

A diferença face às três técnicas anteriores é a existência de um alvo externo. Para a deteção existe um critério de movimento extremo, o que permite contar acertos e falhas; para a recuperação existe uma noção verificável de relevância, de que decorre a precisão@ k ; para a triagem existe um rótulo construído a partir de preços posteriores. Em todos estes casos a técnica pode revelar-se errada contra um alvo que lhe é exterior.

Na decomposição esse alvo não existe. Nenhuma fonte de dados publica qual foi a parcela verdadeira do mercado no movimento de uma ação num dado dia, uma vez que essa quantidade não é observável e apenas existe relativamente a um modelo. Fixadas as sensibilidades, a repartição é uma identidade contabilística e não uma previsão suscetível de sair certa ou errada. A construção de uma medida de exatidão neste ponto produziria um valor sem referente.

A técnica não fica por avaliar, mas por avaliar dessa forma, o que obriga a determinar o que nela permanece falsificável. São duas propriedades, e ambas se medem sobre as dezassete empresas do mapa de setores, que é o conjunto percorrido pelo procedimento de avaliação e não a lista monitorizada em produção. A Figura 5.14 apresenta as duas.




Figura 5.14: As dezassete empresas do mapa de setores, decompostas no mesmo dia. Em A, a componente identificada como maior parcela do mesmo sinal que o movimento observado. Em B, a dispersão da quota atribuída à empresa. A repartição produz respostas distintas para empresas distintas no mesmo dia, que é a condição mínima para a sua utilidade.

A primeira propriedade é a capacidade de discriminar. Uma decomposição que atribuísse a totalidade do movimento à empresa em todos os dias seria inútil ainda que aritmeticamente correta. No dia medido, o motor identificado foi a própria empresa em oito casos, o mercado em cinco e o setor em quatro, e a quota do movimento atribuída à empresa apresentou mediana de 0,487, com extremos em 0,064 e 0,939.

A segunda propriedade é a qualidade da estimação das sensibilidades, e é a que pode efetivamente estar errada. A medida apropriada é o coeficiente de determinação na janela de estimação, cuja mediana foi de 0,460. Não se trata do coeficiente do ajuste por mínimos quadrados, que, calculado dentro da amostra e com termo constante, nunca poderia ser negativo, mas do coeficiente do modelo efetivamente utilizado, com as sensibilidades já encolhidas e o termo constante recentrado. É esta a medida adequada, por corresponder ao modelo cuja repartição é apresentada ao utilizador, e é por essa razão que pode assumir valor negativo. Numa das dezassete empresas assumiu, o que significa que, naquela janela, o mercado e o setor não explicavam a variação daquela ação melhor do que a sua própria média, e que a repartição desse dia assenta num ajuste que não descreve os dados.

O resultado não estabelece que a repartição esteja correta pelo facto de as parcelas somarem. Elas somam sempre, com diferença nula até à precisão da máquina, porque a parcela da empresa é definida como resíduo, e uma repartição sem qualquer significado somaria igualmente. A soma exata constitui uma verificação de implementação e não uma validação de método. O resultado também não estabelece que o valor apresentado ao utilizador seja fiável em todos os dias, o que no caso de coeficiente negativo não sucede, e é por essa razão que a limitação consta do Capítulo 6.

5.6 O sistema em operação

O quarto caso de estudo incide sobre o comportamento do sistema depois de implantado, sobre as decisões que toma autonomamente. É a avaliação menos comum das três descritas

na Secção 3.1, e a que produz o diagnóstico que alterou o sistema.

5.6.1 O que a porta de decisão estava a separar

A porta implantada era um limiar fixo sobre a probabilidade calibrada, que deixava passar as candidatas acima de 0,50. A pergunta com significado é a de saber se esse limiar separava títulos ou separava empresas, e a medição foi realizada sobre as 4 366 decisões efetivamente tomadas em produção. A Figura 5.15 apresenta o resultado.




Figura 5.15: Intervalo de todas as pontuações atribuídas pelo modelo a cada empresa em produção, com a mediana assinalada. As barras claras nunca alcançam o limiar, as escuras atravessam-no e as alaranjadas situam-se sempre acima. Oito das doze empresas encontram-se inteiramente de um dos lados, o que significa que para essas a decisão estava tomada antes de o título ser lido.

Os valores confirmam a leitura da figura. Sobre as 36 925 decisões registadas, a amplitude média das pontuações dentro de cada empresa é de 0,072, ao passo que a amplitude entre as medianas das empresas é de 0,392, isto é, 5,4 vezes superior. Duas empresas situavam-se sempre acima do limiar e cinco nunca o alcançavam, pelo que apenas em cinco das doze o limiar chegava a decidir. Em 48% dos títulos distintos o resultado estava determinado pela empresa antes de o título ser lido. Contada por decisão registada, a fração sobe para 60%. Cita-se a primeira: a repontuação dos mesmos títulos a cada ciclo de sessenta segundos inflaciona a segunda, e de forma desigual entre empresas.

Numa janela anterior e mais curta, de 4 366 decisões, os mesmos indicadores valiam 0,064, 0,385 e 6,1 vezes, com três empresas sempre acima e quatro em que o limiar decidia. A conclusão estrutural não depende da janela. Em nenhuma das avaliações registadas a Apple alcançou o limiar, com um máximo observado de 0,472, ao passo que a AMD o ultrapassou em todas.

As duas contagens medem quantidades distintas e ambas são reportadas. O sistema repontua os mesmos títulos a cada ciclo de sessenta segundos, e a duplicação é maior nas empresas com menos notícias, que são as que nunca ultrapassam o limiar, pelo que contar decisões desloca a fração para cima. Contada uma vez por título distinto, sobre uma janela mais ampla de 36 925 decisões, a fração é de 48%. A conclusão estrutural não depende da

contagem escolhida: continuam a existir empresas inteiramente de um dos lados do limiar, e a amplitude entre empresas continua a ser várias vezes a amplitude dentro de cada uma.

O defeito tem a mesma forma que o identificado na Secção 5.2, uma camada acima. Naquele caso, um limiar fixo sobre o retorno mede a volatilidade da empresa em vez da raridade do dia; neste, um limiar fixo sobre uma pontuação quase constante por empresa ordena empresas em vez de notícias.

Nenhum dos testes automáticos existentes o cobria. O modelo foi avaliado sobre a distribuição do conjunto de treino e implantado atrás de dois filtros que a alteram, e cada componente cumpria o seu contrato. O teste que o teria apanhado é o que este trabalho passou a executar: comparar a amplitude das pontuações dentro de cada empresa com a amplitude entre empresas. O que estava errado era uma suposição sobre a ligação entre eles, não enunciada em nenhum ponto. Corresponde à classe de custo que D. Sculley et al. (2015) arrumam sob dependências de dados e emaranhamento entre componentes, com o sintoma que os autores descrevem: o sistema continua a produzir valores de aparência normal.

Existe uma segunda causa possível, que os registos não permitem separar da primeira. Uma das nove entradas é o retorno do próprio dia. No treino corresponde ao movimento completo do dia da notícia. Em produção é calculado sobre a última barra diária disponível, que durante a sessão é o fecho da véspera ou uma barra incompleta. As duas causas produzem o mesmo sintoma, e o registo guarda a probabilidade e o resultado mas não o valor das entradas no momento da pontuação. A sua separação exigiria registar essas entradas e voltar a observar durante semanas.

A correção aparente consistiria em substituir o limiar fixo por um limiar relativo a cada empresa. A simulação dessa alternativa sobre as mesmas decisões resolve metade do problema, uma vez que as doze empresas passam a estar representadas, e introduz outro. Nas empresas cuja pontuação quase não varia, o percentil recai sobre a constante e quase todas as decisões empatam acima dele; uma delas passa a gerar 874 alertas. O limiar relativo deixa de escolher por materialidade e passa a escolher por desempate, que é precisamente o artefacto documentado na Secção 5.4. Dentro de uma empresa a pontuação do modelo quase não varia com o título, e nenhuma regra de decisão aplicada a essa pontuação a pode tornar sensível à notícia, porque a informação que distinguiria um título do seguinte não está presente.

Em consequência, o modelo deixou de constituir porta e passou a constituir critério de ordenação, que é a utilização que a medição sustenta, e o controlo de volume passou para um orçamento diário de cinco alertas. Esta alteração aproxima duas políticas que divergiam: a dissertação avaliava uma política de orçamento e o sistema implantava uma política de limiar, pelo que o valor reportado descrevia um sistema distinto do que estava em funcionamento. As duas políticas passaram a pertencer à mesma família sem se tornarem idênticas.

A métrica avaliada ordena todas as candidatas do bloco de teste e apenas depois preenche cinco lugares em cada dia, o que exige conhecer o dia completo antes de decidir e constitui por isso uma política diferida. O sistema implantado decide em linha, de sessenta em sessenta segundos, e gasta o primeiro lugar na primeira notícia que atravessa as portas, porque no momento da decisão a notícia da tarde ainda não existe. A precisão dentro do orçamento reportada neste capítulo é, por conseguinte, um limite superior do que a política implantada obtém.

5.6.2 O desempenho do modelo sobre as decisões que tomou

O sistema regista todas as decisões de triagem e, decorridos os dias necessários para o preço responder, confronta-as com o resultado efetivo. Duas medições resultam desse registo: a fração de casos que se revelaram materiais de cada lado da porta, e a capacidade de ordenação do modelo, medida pela Receiver Operating Characteristic Area Under the Curve (ROC-AUC). A Figura 5.16 apresenta ambas, sobre 825 decisões já maturadas.




Figura 5.16: Em A, a fração de casos que se revelaram materiais entre as decisões que o modelo deixou passar e entre as que travou, com intervalos de confiança a noventa e cinco por cento e a taxa-base do conjunto. As suprimidas apresentam fração superior às mantidas, mas os dois intervalos sobrepõem-se em quase toda a extensão e não as separam. Em B, a capacidade de ordenação medida sobre as 239 unidades independentes, com o intervalo a conter confortavelmente o valor de acaso.

Sobre a população que efetivamente observa, esta amostra não distingue o modelo do acaso em nenhuma das duas medidas. As notícias que deixou passar revelaram-se materiais em 58,9% dos casos, contra 61,7% das que travou, sobre uma taxa-base de 60,2%; os intervalos das duas frações sobrepõem-se, pelo que a ordenação aparente não é estabelecida. O que fica medido é a ausência de benefício detetável com esta dimensão de amostra, e não a ausência de benefício.

Estes valores exigem uma reserva de precisão considerável: as 825 decisões não constituem 825 observações independentes, dado que o rótulo é atribuído por par formado pela empresa e pelo dia, e as linhas repartem-se por apenas 239 pares distintos. Medida sobre essas unidades, a capacidade de ordenação situa-se em 0,486 com intervalo de confiança entre 0,403 e 0,571, num intervalo em que o acaso vale exatamente 0,500. A leitura correta não é a de que o modelo seja pior do que a ausência de modelo, mas a de que esta amostra não o distingue do acaso.

A medição foi repetida quando o registo dispunha de 825 decisões maturadas contra as 530 da primeira leitura, e quase nada se alterou: a diferença entre mantidas e suprimidas estreitou-se, a capacidade de ordenação passou de 0,494 para 0,486 e o intervalo encolheu. Com metade mais evidência, o veredicto mantém-se e torna-se mais firme.

A explicação mais provável não é a de que o modelo esteja avariado, mas a de que esteja em excesso. Quando é invocado, as notícias já atravessaram o filtro de relevância e o filtro de frescura, e esses filtros elementares removeram grande parte daquilo que o modelo foi treinado para remover, restando pouco para separar. Um modelo avaliado isoladamente e implantado atrás de filtros nunca foi avaliado na distribuição que efetivamente observa, e esta é a constatação com maior capacidade de transferência do trabalho.

Três das doze empresas monitorizadas, a AMD, a Netflix e a Meta, não figuram no corpus de treino, e uma quarta, a Microsoft, figura apenas no bloco de teste. O modelo pontua-as na mesma, porque o que recebe são valores numéricos e não a identidade da empresa, mas fá-lo sobre uma combinação de entradas que não observou. Duas das ausentes, a AMD e a Meta, estão entre as que se situam sempre acima do limiar, pelo que a determinação por empresa descrita acima se concentra precisamente em nomes que o modelo nunca observou. Constitui um segundo sentido, mais literal, em que o modelo implantado opera fora da distribuição em que foi avaliado, e as decisões dessas empresas entram nas 825 acima como quaisquer outras.

5.6.3 Deriva das distribuições

Uma segunda razão, independente da anterior, pode fazer com que um modelo implantado deixe de servir: os dados alteram-se. O modelo foi treinado sobre o período de 2018 a 2023 e opera em 2026. A medida utilizada é o Population Stability Index (PSI), que confronta aqui a distribuição de cada entrada no bloco de treino, compreendido entre 2018 e 2022, com a do bloco de teste, de 2023. Não é, portanto, a distância entre o treino e o presente, que a subsecção seguinte discute em separado: é a deriva interna ao próprio protocolo. As bandas são as convencionadas em risco de crédito, segundo as quais valores abaixo de 0,10 indicam estabilidade, valores entre 0,10 e 0,25 deslocamento moderado e valores acima de 0,25 deslocamento significativo. A Figura 5.17 apresenta o resultado.




Figura 5.17: Índice de estabilidade populacional de cada entrada entre o bloco de treino, de 2018 a 2022, e o bloco de teste, de 2023, com as bandas convencionadas assinaladas. A entrada de que o modelo mais depende é a que mais se deslocou. A prevalência do rótulo passa de 0,3854 para 0,3781 entre as duas pontas, mas não é estável pelo meio: no bloco de validação, temporalmente entre ambas, chega a 0,4704.

O resultado tem duas metades. A entrada que mais se deslocou é a volatilidade dos vinte dias anteriores, situada na banda significativa, ao passo que as restantes permanecem estáveis ou moderadas. O rótulo desloca-se pouco entre as pontas, com a prevalência de positivos a passar de 0,3854 para 0,3781, mas não é estável: o bloco de validação, temporalmente

entre os dois, chega a 0,4704. A prevalência oscila com o regime de volatilidade em vez de derivar numa direção, o que é coerente com a volatilidade ser a entrada que mais se desloca.

A leitura correta desta medição é a de que a deriva não é externa aos valores deste capítulo: é a que o próprio protocolo atravessa, uma vez que treina em 2018–2022 e avalia em 2023. A PR-AUC reportada é já uma medida sob esta deriva, e a combinação é desfavorável porque a entrada de que o modelo mais depende é precisamente a que mais se deslocou.

O que esta medição não estabelece é a distância entre o treino e 2026, que é o período em que o sistema opera. Um instantâneo sobre cotações atuais aponta na mesma direção, com a volatilidade a ser de novo a entrada que mais se desloca. Assenta, porém, em janelas deslizantes consecutivas que partilham a quase totalidade das observações, o que inflaciona o índice e torna a sua magnitude não comparável com a da figura. Fica registado como não medido, em vez de estimado por analogia. A deriva é, em qualquer dos casos, medida e não corrigida, e a Secção 6.5 enuncia o que seria necessário para a corrigir.

5.6.4 O sistema completo contra as alternativas existentes

As secções anteriores comparam componente a componente. Falta a comparação ao nível do sistema: dadas as notícias de um dia, a política escolhe as cinco a apresentar melhor do que uma regra disponível sem custo. A Figura 5.18 responde. Todas as políticas escolhem cinco por dia, sobre o mesmo bloco de teste e com o mesmo rótulo, e o desempate é aleatório e explícito em todas.




Figura 5.18: Cinco políticas de seleção sobre o mesmo bloco de teste. A primeira e a última não são políticas utilizáveis: uma é o valor de referência e a outra é o máximo teórico, obtido com conhecimento das respostas. Todas escolhem conhecendo o dia completo, pelo que cada valor é um limite superior do que a mesma regra obteria decidindo ao minuto.

Três leituras resultam da figura. A primeira é que o sistema supera a alternativa realista: apresentar notícias das empresas com maior movimento do dia é o que qualquer aplicação de bolsa já faz sem custo, e obtém 0,489, contra 0,632 do sistema, um ganho de 0,143 sob o mesmo protocolo. Este valor mede a capacidade de ordenar o rótulo aproximado no bloco histórico, e não a utilidade percebida por uma pessoa nem o valor causal dos alertas em funcionamento.

A segunda é que o sistema continua a não superar a volatilidade. Treze constantes calculadas exclusivamente sobre o bloco de treino obtêm 0,662, o que é coerente com a ablação da Secção 5.4.5: o modelo é, na prática, uma tabela por empresa, e a volatilidade é outra tabela por empresa, mais simples, sendo esta a que dispensa treino.

A terceira, e mais útil, é a localização da limitação pelo máximo teórico. O melhor resultado possível, escolhendo com conhecimento das respostas, seria de 0,968, o que significa que em quase todos os dias existem efetivamente cinco notícias materiais no conjunto disponível. O sistema não está limitado por escassez de matéria-prima, mas pela incapacidade de identificar quais são. A margem entre 0,632 e 0,968 é de 0,336 e reside quase integralmente na separação de notícias dentro de cada empresa, que é precisamente o que o modelo implantado não consegue realizar. É a mesma conclusão obtida por um terceiro caminho independente.

Todas as políticas desta comparação escolhem de entre o que a fonte entregou, o que deixa de fora a pergunta anterior a todas, relativa aos dias em que nada foi entregue. Sobre um ano de notícias captadas, existia pelo menos uma notícia relevante em 88,5% dos dias que o detetor considerou invulgares, num total de 417, e em 47 dos 52 dias mais extremos, dimensão que não permite distinguir as duas frações. Nos restantes, nenhuma alteração ao sistema produz efeito, uma vez que uma notícia não associada à empresa pela fonte gratuita não chega a entrar no percurso. A cobertura é ainda muito desigual, com a empresa pior coberta a situar-se nos 50%. Este valor é um limite superior, e a distinção determina o que ele vale: estabelece que existia uma notícia, e não que tenha chegado a notícia correta. A Secção 6.4 retoma-o como limitação.

Uma linha de base não foi medida, e a razão fica registada. A alternativa mais natural consistiria em apresentar as primeiras cinco notícias a chegar. Não é mensurável neste protocolo, uma vez que o conjunto de dados histórico não conserva a hora de publicação e está ordenado por data e por empresa, pelo que utilizar a ordem do ficheiro mediria a ordem alfabética das empresas. Seria o mesmo artefacto documentado na Secção 5.4, desta vez introduzido deliberadamente. Uma linha de base errada é pior do que uma linha de base em falta.

5.7 Síntese dos resultados

Esta secção reúne as comparações realizadas ao longo do trabalho, incluindo aquelas em que o sistema mantém a opção que a medição não favorece.

Duas das três respostas são afirmativas e uma é negativa. A resposta negativa é a que exigiu maior esforço de verificação, e é também a que estabelece que a avaliação foi construída de modo a poder produzir uma resposta negativa. A Tabela 5.2 apresenta cada escolha técnica ao lado da alternativa medida contra ela.

Três linhas da tabela merecem desenvolvimento. A primeira respeita ao codificador de domínio financeiro, cuja derrota tem explicação no objetivo de treino e não no conhecimento do domínio, conforme a Secção 5.3 estabelece. A segunda respeita à janela de vinte dias, que é a opção mais difícil de justificar, uma vez que a única medição existente sobre este ponto não a sustenta e a justificação de responsividade não é quantitativa. A terceira respeita ao estimador de volatilidade, mantido por explicabilidade contra uma alternativa medida como superior.

As três últimas linhas não apresentam valores deliberadamente. São restrições e não resultados, tendo sido fixadas antes de qualquer medição, e a sua apresentação sob a forma de comparação atribuir-lhes-ia uma autoridade que não possuem.

O capítulo documenta três ocasiões em que uma técnica mais simples superou uma técnica mais sofisticada em condições equivalentes, e duas ocasiões em que a técnica mais sofisticada

Tabela 5.2: As decisões técnicas do trabalho, cada uma com a alternativa medida contra ela. Três linhas registam que a opção implantada não obteve o melhor resultado, e a razão da sua manutenção consta da coluna respetiva. As três últimas linhas não apresentam valores por corresponderem a restrições fixadas antes de qualquer medição.

Opção implantada	Alternativa medida	Leitura
z-score deslizando	Limiar fixo de três por cento: amplitude 0,344 contra 0,015	Um limiar fixo mede a volatilidade da empresa e não a raridade do dia.
z-score deslizando	<i>Isolation Forest</i> com F_1 de 0,269 e <i>Local Outlier Factor</i> com 0,280, contra 0,530	Os detetores aprendidos assinalam quase tudo e acertam pouco.
Janela de vinte dias	Não obteve o melhor resultado: dez dias produzem F_1 de 0,385, vinte dias 0,516 e sessenta dias 0,678	A medição favorece a janela mais longa. Mantida por responsividade, com a reserva de circularidade do rótulo declarada.
Desvio-padrão de pesos iguais	Não obteve o melhor resultado: o decaimento exponencial produz F_1 de 0,664 contra 0,516	Mantido por ser explicável a um leitor não especializado, e registado como escolha e não como resultado.
Embeddings de frase	Sobreposição de palavras: precisão@5 de 0,346 contra 0,514	Vocabulário comum não implica assunto comum, e assunto comum não exige vocabulário comum.
MiniLM em vez de MPNet	Não obteve o melhor resultado: o MPNet produz 0,538 contra 0,514; um codificador de domínio financeiro produz 0,420	O modelo mais pesado é melhor e foi substituído por custo. O codificador de domínio obteve o pior resultado de todos, por medição e não por suposição.
Regressão logística	Árvores com reforço do gradiente: PR-AUC de 0,469 contra 0,538	O modelo mais expressivo não obteve melhor resultado, e o modelo simples é explicável.
Calibração de Platt	Regressão isotónica, comparada sobre a mesma validação	A calibração de Platt iguala ou supera no índice de Brier em todas as famílias avaliadas.
Semelhança do cosseno	Distância euclidiana	Com vetores normalizados as duas produzem a mesma ordenação, e a primeira dispõe de leitura mais direta.
Dois gatilhos, notícia e preço	Fusão com o volume e a intensidade de notícia, na linha dos painéis que combinam sinais de origens distintas (<i>World Monitor</i> 2026): perde em dois dos três orçamentos, com $-0,050$ e $-0,032$, e ganha no terceiro por $+0,004$	Um ganho que depende do orçamento escolhido, e uma ordem de grandeza menor do que as perdas, não sustenta a adoção. O volume continua a ser calculado e apresentado como contexto, sem originar alertas.
Apenas fontes gratuitas	—	Restrição fundadora: define o público que o sistema pode servir.
Ausência de previsão de preços	—	Restrição de desenho: é o que torna verificável tudo o restante.
Mercado dos Estados Unidos	—	Restrição de âmbito: é onde as fontes gratuitas apresentam cobertura.

5.7. *Síntese dos resultados*

obteve melhor resultado e o sistema manteve a mais simples por explicabilidade. A distinção entre estes dois casos é a distinção entre resultado e escolha, e o Capítulo 6 retoma-a ao estabelecer o que este trabalho demonstra e o que apenas decide.

Capítulo 6

Conclusões

O Capítulo 5 mediu cada componente isoladamente. Este reúne o que dessas medições se retira. Sintetiza o trabalho realizado, apresenta a resposta obtida para cada questão de investigação, identifica as limitações do estudo e enuncia as linhas de desenvolvimento futuro.

6.1 Conclusões principais

O trabalho produziu um sistema em funcionamento e uma avaliação de cada uma das técnicas que o compõem. O InvestiGator monitoriza doze empresas em ciclo contínuo, entrega alertas explicados a um canal público e disponibiliza uma página onde ficam registadas tanto as mensagens enviadas como as decisões que conduziram ao silêncio. Ao longo do período documentado no Capítulo 5 foram entregues 367 mensagens e registadas 4 366 decisões de triagem, e a base de precedentes acumulou 38 214 casos com impacto medido. Estes números descrevem um sistema implantado e não uma demonstração construída para o efeito.

A componente que confere ao trabalho o carácter de dissertação não é, contudo, o sistema, mas a avaliação a que foi submetido. Três das quatro técnicas foram comparadas com alternativas mais simples, escolhidas e declaradas antes de a medição ser realizada, o que é a condição para que o resultado possa ser negativo. Numa delas o resultado foi efetivamente negativo. A quarta técnica, a decomposição do movimento, não admite comparação da mesma natureza, uma vez que a repartição de um retorno não possui referente externo observável. Dela mediu-se o que permanece falsificável: a qualidade do ajuste que a sustenta, e a capacidade de produzir respostas distintas para empresas distintas.

A contribuição de engenharia não reside na dimensão do modelo aprendido. O sistema treina um único modelo, com nove entradas, e esse modelo perde para uma linha de base de uma só variável. A confiança nesse valor, e na conclusão negativa que ele sustenta, depende do que foi preciso construir em volta dele. A Secção 4.7 descreve as seis peças. O conjunto de dados é rotulado a partir de duas fontes independentes. A separação temporal é verificada por um procedimento automático. A calibração vem acompanhada da medição e da declaração do enviesamento que a afeta. Os artefactos ficam sob controlo de versões. O modelo implantado é comprovadamente o modelo avaliado. E o sistema em funcionamento continua a ser observado. É nesse conjunto, e não no modelo, que reside o trabalho.

Uma segunda conclusão atravessa os quatro casos de estudo e não pertence a nenhum deles em particular. Em três ocasiões distintas, uma técnica mais simples obteve melhor resultado do que uma técnica mais sofisticada em condições equivalentes: o z-score deslizante contra

dois detetores aprendidos, a volatilidade recente contra as representações de texto, e uma tabela de treze constantes contra o modelo treinado. Em três outras ocasiões sucedeu o inverso, com a alternativa medida a obter melhor resultado. O sistema conservou a opção implantada por razões distintas em cada caso: o estimador de pesos iguais por explicabilidade, a janela de vinte dias por responsividade, e o codificador de frases mais pequeno por custo computacional.

A distinção entre estes dois casos é a distinção entre resultado e escolha, e o presente capítulo mantém-na explícita: o que a medição estabelece é reportado como resultado, e o que o autor decidiu apesar da medição é reportado como decisão, acompanhada do que essa decisão custa quando a medição separa as alternativas, e da declaração de que nada custa em PR-AUC quando não as separa.

6.2 As respostas às questões de investigação

Esta secção responde às três questões enunciadas na Secção 1.3 e delimita, em cada caso, o que a resposta permite e não permite afirmar. A Figura 6.1 reúne as três.

Q11 · deteção Detetar movimentos invulgares de forma consistente entre empresas?	SIM	amplitude da taxa de disparo de 0,015 contra 0,344 da regra de limiar fixo, e F_1 superior ao de dois detetores aprendidos
Q12 · precedentes Recuperar notícias passadas de outra empresa do mesmo setor?	SIM	supera o valor de referência nos cinco setores; sob a restrição temporal da produção, precisão@5 de 0,513 contra um acaso de 0,259
Q13 · triagem Um modelo treinado prioriza notícias melhor do que uma linha de base simples?	NÃO	PR-AUC de 0,496 com texto contra 0,542 apenas com volatilidade, resultado que resiste a três verificações da montagem experimental

Figura 6.1: As três respostas, com a resposta negativa apresentada com o mesmo destaque das duas restantes. A terceira linha é a que atribui crédito às outras: um trabalho que reporte apenas os resultados favoráveis não permite determinar se as respostas afirmativas foram medidas ou pressupostas.

6.2.1 Deteção de movimentos invulgares

A resposta à Q11 é afirmativa. Um z-score sobre uma janela deslizante de vinte dias assinala dias raros a uma taxa praticamente idêntica em empresas de volatilidades muito distintas. A amplitude entre a empresa mais e a menos assinalada é de 0,015, contra 0,344 de uma regra de limiar fixo em três por cento. Contra um rótulo aproximado, o método obtém $F_1 = 0,516$ e a regra fixa 0,218. Sujeito a um protocolo causal equivalente, o mesmo método supera ainda dois detetores concebidos para esta tarefa, com F_1 de 0,530 contra 0,269 do *Isolation Forest* (F. T. Liu, Ting e Zhou 2008) e 0,280 do *Local Outlier Factor* (Breunig et al. 2000).

A configuração implantada não é, porém, a melhor medida dentro da própria família. Com a mesma cobertura, um estimador com decaimento exponencial obtém $F_1 = 0,664$ e uma

janela de sessenta dias obtém 0,678, contra os 0,516 da configuração em produção. O que a QI1 estabelece é que a família deslizante supera o limiar fixo e os dois detetores aprendidos, e não que a parametrização escolhida seja a melhor dessa família.

Este resultado é menos surpreendente do que a diferença de valores sugere, e a literatura permite situá-lo. Os dois detetores aprendidos definem raridade a partir da geometria dos dados, um por isolamento do ponto e outro por comparação de densidades, e foram concebidos para espaços com múltiplas variáveis em interação. O problema tratado apresenta uma única série de retornos por empresa, na qual a estrutura relevante é temporal e não geométrica: períodos de agitação sucedem-se a períodos calmos. É a propriedade que os modelos ARCH e GARCH formalizam (Bollerslev 1986; Engle 1982). A janela deslizante capta-a diretamente; um detetor treinado sobre o conjunto completo teria de a aprender. Quando a suposição embutida num método simples coincide com a estrutura efetiva do problema, a margem para a superar é reduzida.

O alcance da resposta é delimitado por três condições. A comparação incide sobre quinze empresas de grande capitalização, selecionadas em 2026 e avaliadas sobre o passado, que sobreviveram por construção; sobre três anos de cotações e sobre um único mercado. O rótulo utilizado como argumento secundário é ele próprio relativo à volatilidade de cada empresa, razão pela qual o argumento principal é a consistência da taxa de disparo, que não depende de rótulos. O limiar de três por cento da regra alternativa não foi otimizado, pelo que o que a comparação estabelece não é que nenhum limiar fixo obtivesse melhor resultado, mas que uma regra de limiar fixo mede uma quantidade distinta da pretendida.

6.2.2 Recuperação de precedentes

A resposta à QI2 é afirmativa, e a sua formulação exige o nível do setor. Sobre o corpus recente, a recuperação por semelhança de frase (Reimers e Gurevych 2019) obtém precisão@5 de 0,514, contra 0,346 da sobreposição de vocabulário, 0,240 da escolha aleatória e 0,126 da apresentação das notícias mais recentes. Também aqui o modelo implantado não é o melhor medido: uma variante de maior dimensão obtém 0,538 sobre o mesmo protocolo, e foi preterida por custo computacional.

O valor agregado não constitui, porém, a forma adequada de enunciar o resultado. Quase metade das notícias do corpus pertence ao setor da tecnologia, o que torna disponível uma estratégia que dispensa qualquer modelo e sequer observa a consulta, consistindo em devolver invariavelmente notícias desse setor; a sua precisão iguala a fração de consultas de tecnologia, 0,467. Essa estratégia é inútil enquanto produto, dado que acerta em todas as consultas de um setor e em nenhuma dos quatro restantes, mas a sua existência demonstra que o agregado mede em parte a composição do corpus.

A comparação que resiste à objeção realiza-se dentro de cada setor, onde o método supera o respetivo valor de referência nos cinco. A margem absoluta é maior no setor mais abundante, com +0,283 na tecnologia; nos setores escassos, onde o valor de referência ronda 0,072, o método obtém várias vezes esse valor com margem absoluta menor. É esta a afirmação que o trabalho sustenta.

Duas verificações adicionais delimitam a resposta. Sobre o corpus histórico completo, com aproximadamente oitenta mil notícias de seis anos, a precisão sobe para 0,595. O valor de referência sobe na mesma proporção, e a margem mantém-se. O método não se degrada com a escala, nem melhora com ela. A imposição da restrição que o sistema efetivamente enfrenta, segundo a qual o precedente tem de ser anterior à consulta, reduz a precisão para

0,513 e o valor de referência para 0,259, com a margem a variar 0,008. O método conserva a vantagem quando obrigado a operar como opera em produção.

A segunda ressalva tem consequências diretas sobre o produto. A recuperação identifica tema e não direção: a concordância entre o sentido do movimento da notícia de consulta e o dos precedentes situa-se em 0,708 contra um valor de acaso de 0,688, uma diferença de 0,020. Duas notícias podem tratar do mesmo assunto e o preço evoluir em sentidos opostos. O resultado é coerente com o que a forma semiforte da hipótese dos mercados eficientes conduziria a esperar (Fama 1970), segundo a qual a informação pública se encontra já refletida no preço, sem que o trabalho a teste ou nela se apoie para estabelecer qualquer conclusão. A consequência prática é a decisão de apresentar os precedentes individualmente, com data e desfecho, em vez de os resumir a uma média suscetível de ser lida como previsão.

Uma delimitação final respeita ao rótulo. A pertença ao mesmo setor é uma aproximação verificável de relevância, e não a propriedade que se pretendia medir. A linha de base lexical é a forma mais elementar da sua família, sem ponderação pela raridade dos termos nem normalização pelo comprimento. Os dezassete pontos percentuais de vantagem medem a distância a um ponto de partida, e não a uma função de ordenação afinada (Robertson e Zaragoza 2009).

6.2.3 Triagem de notícias

A resposta à Q13 é negativa. Nenhuma variante que incorpora o texto do título supera uma linha de base construída apenas com a volatilidade dos vinte dias anteriores, com 0,496 de PR-AUC contra 0,542, e o índice de Brier acompanha a mesma ordenação. O resultado resiste a três verificações. A primeira repete a comparação concedendo ao texto as melhores condições disponíveis, e eleva o seu melhor valor para 0,533, sem alcançar a linha de base. A segunda reamostra por grupos constituídos pela empresa e pelo dia, e mantém o intervalo a excluir zero. A terceira repete a medição para nove combinações alternativas de limiar e horizonte do rótulo, e a volatilidade iguala ou supera o modelo com texto nas nove.

A resposta ganhou precisão no decurso do trabalho e essa precisão altera o que dela se retira. As comparações anteriores colocam as representações lado a lado e respondem, por conseguinte, à pergunta sobre qual delas é melhor. A pergunta com maior utilidade para quem constrói um sistema é distinta e consiste em determinar se o texto acrescenta ao que já é conhecido. Medida sobre a tabela de consulta por empresa, que contém tudo o que o modelo conhece da empresa e nada da notícia, a resposta é afirmativa: o título acrescenta +0,012 de PR-AUC, com intervalo entre +0,004 e +0,020, que exclui zero. É a única ocasião em que uma representação de texto apresenta um acréscimo detetável nesta tarefa.

O valor situa-se abaixo do limite de 0,02 que o Capítulo 5 fixou antes das medições, e esse limite aplica-se nos dois sentidos. Fica estabelecido um limite superior para o efeito do texto, e não uma quantidade de que o sistema possa dispor.

Três medições impedem que este acréscimo reabra o veredicto. A soma não supera a volatilidade isolada, e o intervalo da diferença contém zero. O acréscimo não sobrevive à métrica que descreve o produto: a precisão dentro do orçamento de cinco alertas por dia permanece em 0,662 com e sem texto. E a capacidade de separar notícias da mesma empresa mantém-se ao nível do acaso. O que estas medições acrescentam à resposta negativa não é uma ressalva mas uma localização: a informação que o texto transporta distingue empresas e períodos, quando o produto necessitava de distinguir notícias. A formulação que subsiste

é a mais fraca das possíveis, correspondendo a um limite superior de um efeito e não a uma descoberta.

Existe uma linha de investigação estabelecida que utiliza texto para antecipar movimentos de preço (Ding et al. 2015; Xing, Cambria e Welsch 2018), e este resultado não a contradiz. A diferença não reside na dimensão do texto, uma vez que Ding et al. (2015) operam igualmente sobre títulos, mas no tratamento que lhe é dado. Aqueles autores extraem estruturas de acontecimento e treinam uma rede para prever a direção do movimento. Aqui os títulos são comparados por semelhança, e a direção nunca é objeto de previsão. Os corpora e os horizontes de avaliação diferem igualmente. A afirmação que este trabalho sustenta é mais estreita do que uma refutação: sob esta restrição de dados e com esta família de métodos, o sinal textual nada acrescenta ao que a volatilidade recente já indicava. O alcance do resultado limita-se, por isso, a um regime de recursos e a uma escolha de representação, e não se estende à linguagem.

6.3 Objetivos alcançados

Dos quatro objetivos enunciados na Secção 1.3, três encontram-se integralmente cumpridos e um cumprido com a ressalva descrita adiante.

O primeiro objetivo, construir o sistema completo desde a aquisição de dados até à entrega do alerta, está cumprido. Os dois gatilhos funcionam de ponta a ponta em produção, sobre fontes gratuitas, e o percurso de um acontecimento está documentado no Capítulo 4 com os valores de um caso real.

O segundo objetivo, avaliar cada componente contra linhas de base transparentes, está cumprido para as três técnicas em que existe um referente externo. Num dos casos foi além do previsto: o detetor foi comparado não apenas com uma regra de limiar fixo, mas também com dois métodos aprendidos. A decomposição do movimento constitui a ressalva: não existe verdade de terreno contra a qual medir a exatidão de uma repartição, pelo que se mediu o que nela permanece falsificável, correspondente à qualidade do ajuste e à capacidade de discriminar. Ficaram por realizar comparações internas que seriam possíveis, como a do modelo de um fator contra o de dois fatores ou a das sensibilidades brutas contra as encolhidas.

O terceiro objetivo, garantir que as explicações apresentadas são fiéis ao que o sistema calculou, está cumprido por construção e não por verificação posterior. Cada valor exibido provém do objeto que o calculou, e o texto é composto a partir dessas peças, pelo que não é possível ao alerta enunciar um valor distinto do que o sistema obteve. A fidelidade é, contudo, uma propriedade do sistema, e não da relação entre o sistema e quem o lê; a utilidade das explicações para um investidor particular não foi medida, e a Secção 6.4 trata essa ausência.

O quarto objetivo, reportar os resultados obtidos incluindo os que não confirmem as expectativas iniciais, está cumprido. A resposta negativa à Q13 aparece na Figura 6.1 e no corpo deste capítulo com o mesmo destaque das restantes, acompanhada das três verificações a que foi submetida e das três ocasiões em que uma técnica mais simples superou uma mais sofisticada.

6.4 Limitações

Esta secção enumera as limitações do trabalho por ordem de importância. A Tabela 6.1 apresenta-as em conjunto, com o trabalho que encerraria cada uma e a natureza do respetivo custo; o texto que se segue desenvolve as quatro de maior consequência e resume as restantes. A maioria está quantificada. Duas não o estão por natureza: a ausência de avaliação com utilizadores é uma ausência e não uma medida, e a distância entre cada rótulo e a propriedade que aproxima só seria mensurável contra uma anotação humana que não existe.

Tabela 6.1: As onze limitações, por ordem de importância, com o trabalho que encerraria cada uma e a natureza do custo desse trabalho. As duas que dependem de tempo de calendário são as que exigem julgamento humano, e são também as duas de que as restantes mais dependem: enquanto não existir uma amostra anotada por pessoas, nem a utilidade das explicações nem a qualidade dos rótulos deixam de ser aproximações.

Limitação	O que a encerra	Custo
Nenhuma avaliação com pessoas	Executar o estudo desenhado, com seis a dez participantes	tempo de calendário
A pontuação é quase constante dentro de cada empresa	Entradas que variem de um título para o seguinte	reduzido
O rótulo pode favorecer a linha de base vencedora	Reconstruir o alvo com sensibilidades estimadas	reduzido
Os rótulos são aproximações verificáveis	Anotar uma amostra com julgamento humano	tempo de calendário
O alerta afirma mais evidência do que a que possui	Medir o impacto por notícia e não por dia	dados intradiários
Os três blocos quase não partilham empresas	Uma divisão de composição constante	reduzido
Apenas o título é lido, e não o corpo do artigo	Recolher e representar o texto integral	dados novos
A repartição nem sempre está bem estimada	Exibir o ajuste junto de cada repartição	reduzido
A deriva é medida e não corrigida	Re-treinar com o registo de produção	reduzido
A cobertura das fontes é incompleta e desigual	Acrescentar fontes, ou declarar o limite	fora de controlo
A causa do atraso não está identificada	Registrar quando cada item surge no fluxo	instrumentação

Não foi realizada qualquer avaliação com utilizadores. Esta é a lacuna de maior peso. O sistema assenta na hipótese de que uma explicação acompanhada da respetiva evidência conduz um não especialista a uma decisão melhor, e essa hipótese não foi confrontada com pessoas. O desenho do estudo existe, com participantes, tarefas e critérios definidos, e não foi executado. A literatura é explícita quanto ao peso desta ausência: afirmações de interpretabilidade exigem avaliação e não se estabelecem por declaração (Doshi-Velez e Kim 2018). A razão não é formal. O efeito de uma explicação sobre uma pessoa não é dedutível da sua construção: sabe-se que a confiança em sistemas automáticos falha nos dois sentidos, com o utilizador a ignorar um aviso correto ou a aceitar um aviso incorreto (J. D. Lee e See 2004), e que a mera presença de uma explicação aumenta a aceitação de respostas erradas (Bansal et al. 2021). O sistema foi construído para produzir confiança apropriada, apresentando evidência em vez de emitir um veredicto, mas que o consiga permanece uma

hipótese. Na ausência do estudo, os dois modos de falha são indistinguíveis nos registros: um alerta ignorado e um alerta indevidamente acreditado produzem a mesma ausência de dados.

O modelo implantado não podia executar a função que lhe foi atribuída. A variante colocada em produção como porta de decisão recebe sete entradas de nível de empresa, uma de nível do dia e uma única que varia de um título para o seguinte, correspondente ao comprimento do título. A sua pontuação é, por aritmética e não por acidente, quase constante dentro de cada empresa: a amplitude média dentro de cada empresa é de 0,072 e a amplitude entre as medianas das empresas é de 0,392. Em 48% dos títulos distintos, o resultado estava determinado antes de o título ser lido.

Duas afirmações têm de ser separadas, uma vez que apenas uma corresponde a erro. O resultado da QI3 mantém-se, porque a variante com texto dispunha de trezentos e oitenta e quatro números por título e ainda assim perdeu. A decisão de produto estava errada, e a razão é de método: a escolha foi tomada por uma métrica que interroga a ordenação do conjunto completo, quando o produto necessitava da distinção entre dois títulos da mesma empresa.

O sistema foi alterado e o modelo deixou de constituir porta para passar a critério de ordenação. Essa alteração não está validada. Sobre as 825 decisões maturadas em produção, agrupadas nas 239 unidades independentes que o rótulo admite, a capacidade de ordenação é de 0,486, com intervalo entre 0,403 e 0,571, que contém o acaso. A ordenação é a utilização menos indefensável do modelo, e não uma utilização demonstrada.

Esta falha pertence a uma classe descrita na literatura de sistemas de aprendizagem em produção. D. Sculley et al. (2015) identificam um custo que não figura em nenhuma métrica de qualidade, e que vem de dependências de dados e do emaranhamento entre componentes: a validade de uma peça depende de suposições sobre outra que nunca foram enunciadas. O modelo foi avaliado isoladamente, sobre a distribuição do conjunto de treino, e implantado atrás de dois filtros que a alteram. Nenhum teste falhou e nenhum registo assinalou anomalia. Um componente aprendido é avaliado onde é treinado e é útil onde é colocado, e quando esses dois lugares diferem a diferença não se anuncia.

O rótulo pode favorecer a linha de base vencedora. O rótulo desconta o movimento do mercado assumindo sensibilidade unitária, pelo que o seu erro não é aleatório: é maior nas ações mais sensíveis ao mercado, que são tipicamente as mais voláteis. A linha de base vencedora é exatamente a volatilidade. Com o que está medido não é possível separar a hipótese de a volatilidade prever melhor a materialidade da hipótese de a volatilidade prever melhor o erro do rótulo. Tanto o nível como a ordenação das métricas da QI3 ficam por isso condicionados ao rótulo utilizado.

O alerta afirma mais evidência do que a que possui. Quando exhibe três precedentes concordantes quanto ao sentido do movimento, o alerta apresenta essa concordância como resultante de três observações. O impacto é, porém, medido por par constituído pela empresa e pelo dia, pelo que três títulos da mesma empresa no mesmo dia partilham o valor por construção. Sobre os 247 alertas com precedentes entregues, em 36,8% os casos exibidos assentam em menos dias distintos do que casos exibidos, e em 11,3% correspondem todos ao mesmo dia; dos 120 alertas que afirmam unanimidade, 23,3% apoiam-se num único dia. A formulação do texto foi corrigida para contar dias e não títulos, o que torna a afirmação

verdadeira. A causa subsiste: enquanto o impacto for medido por dia, duas notícias do mesmo dia não constituem duas observações independentes.

As restantes sete, em síntese. Os **rótulos são aproximações**: relevância é aproximada pela pertença ao mesmo setor, materialidade pela ocorrência de um movimento acima de um limiar, e raridade por um percentil dos retornos da própria empresa. As três são objetivas e verificáveis, e nenhuma corresponde exatamente à propriedade que se pretendia medir. A dependência de aproximações não é particularidade deste trabalho: em domínios financeiros vizinhos, como a deteção de fraude, os métodos não supervisionados ocupam posição central pela escassez de anomalias rotuladas (Ahmed, Mahmood e Islam 2016).

Os **três blocos de dados quase não partilham empresas**. O bloco de treino contém treze empresas e o de teste nove, cinco empresas do treino não figuram uma única vez no teste, e uma empresa responsável por 17,1% das linhas de teste nunca figura no treino. A constatação atua nos dois sentidos: reforça o resultado negativo, porque um modelo cujo sinal é essencialmente a identidade da empresa estima-a sobre um conjunto quase ausente do bloco onde é avaliado; e limita-o, porque não permite separar a hipótese de o modelo ser pior da hipótese de a identidade não transferir entre estes dois períodos.

As **notícias são lidas apenas ao nível do título**. O sistema representa o título e não o corpo do artigo, o que limita o que a representação de texto pode captar e constitui explicação plausível, ainda que não confirmada, para o resultado negativo da QI3. As revisões de análise textual em finanças descrevem trabalhos que operam sobre documentos completos (Kearney e S. Liu 2014), e um título é a parte do documento onde mais informação foi descartada.

A **repartição de um movimento nem sempre está bem estimada**. A soma das três parcelas verifica-se por construção e não valida coisa alguma. A medida informativa é o coeficiente de determinação na janela de estimação, cuja mediana foi de 0,460 e que numa das dezassete empresas assumiu valor negativo; nesses casos a repartição continua a ser exibida e deve ser lida como indicativa. O encolhimento ponderado pela precisão (Vasicek 1973) limita o dano de uma estimativa má sem a transformar numa estimativa boa.

A **deriva é medida e não corrigida**. Os parâmetros foram estimados entre 2018 e 2023 e não voltaram a ser ajustados. Entre o bloco de treino e o de teste, o índice de estabilidade populacional situa a volatilidade dos vinte dias na banda de deslocamento significativo, com 0,281, que é a entrada de que o modelo mais depende. A literatura de deriva de conceito trata deste problema, com uma taxonomia da mudança e estratégias de deteção e adaptação (Gama et al. 2014); aqui existe a deteção e não a adaptação.

A **cobertura das fontes é incompleta e desigual**. Existia pelo menos uma notícia relevante em 88,5% dos 417 dias considerados invulgares pelo detetor, e a empresa pior coberta situa-se nos 50%. Nos dias restantes nenhuma alteração ao sistema produz efeito, uma vez que uma notícia não associada à empresa pela fonte não chega a entrar no percurso. O valor é um limite superior: estabelece que existia uma notícia, e não que tenha chegado a notícia adequada.

O **atraso está na descoberta, e a sua causa não está identificada**. Sobre os 278 alertas com hora de publicação e de envio, a mediana entre a publicação e a deteção é de 353 minutos, e a mediana entre a deteção e a entrega é de 5 segundos. A passagem de um agendador de melhor esforço para um ciclo de sessenta segundos não reduziu o atraso, o que exclui a cadência de consulta como explicação. Restam três causas que o histórico não

separa, e apenas uma delas, a de a fonte listar tarde, seria atenuada por um serviço pago; as outras duas subsistem com qualquer fonte.

6.5 Trabalho futuro

As linhas enunciadas nesta secção derivam das limitações da secção anterior, segundo a correspondência apresentada na Tabela 6.1, e estão ordenadas pela relação entre o efeito esperado e o custo. Uma lista de trabalho futuro que não derive de limitações medidas constitui uma justificação sob outra forma.

1. **Executar o estudo com utilizadores.** Seis a dez participantes, com sessões de aproximadamente quinze minutos, comparando a leitura de um facto isolado com a leitura do alerta completo. Encerra a afirmação central do trabalho, que é a de que a evidência apresentada junto do alerta conduz a uma decisão melhor, e é o único item desta lista que não pode ser acelerado por meios computacionais. Outras afirmações permanecem por verificar independentemente dele, entre as quais a qualidade dos três rótulos, a utilidade do modelo sobre a população que efetivamente observa e a estabilidade do resultado entre períodos.
2. **Dotar o modelo de decisão de entradas que variem com a notícia.** É a correção direta da limitação de maior consequência técnica, e o seu custo é reduzido, dado que as duas quantidades mais evidentes já são calculadas pelo sistema: a semelhança do melhor precedente recuperado e a concordância de direção entre os precedentes. Ao contrário da volatilidade e do setor, ambas variam de um título para o seguinte.
3. **Construir um alvo com julgamento humano.** A anotação de uma amostra de dias, identificando quais das notícias hoje suprimidas deveriam passar e quais das que passam nada acrescentam, forneceria pela primeira vez um alvo real para otimizar, em substituição do ajuste de constantes contra uma aproximação. A mesma amostra permitiria estimar a qualidade dos três rótulos utilizados.
4. **Reconstruir o rótulo com sensibilidades estimadas.** O rótulo da triagem desconta o movimento do mercado assumindo sensibilidade unitária, o que introduz um erro correlacionado com a volatilidade da empresa, que é precisamente a linha de base vencedora. Refazer o alvo com as sensibilidades encolhidas descritas na Secção 3.4 e repetir as seis famílias de modelos determinaria se a ordenação obtida resiste a uma definição alternativa de materialidade.
5. **Ler o corpo dos artigos e não apenas o título.** É a hipótese mais direta para explicar o resultado negativo da QI3 e é verificável com o protocolo já construído, exigindo apenas a recolha do texto integral.
6. **Detetar histórias repetidas por significado.** A supressão de repetições assenta hoje em sobreposição de vocabulário, e a sua realização por semelhança utilizaria a técnica de que o sistema já dispõe. O ponto é mais relevante do que a sua dimensão técnica sugere: se o investidor particular adquire os ativos que lhe captam a atenção (Barber e Odean 2008), um sistema que comunica a mesma história três vezes não está a informar, mas a amplificar o mesmo estímulo.
7. **Re-treinar o modelo com o registo de produção.** A deriva está medida e os rótulos novos derivam dos preços, pelo que a execução é possível. O impedimento não é

técnico, uma vez que um re-treino alteraria os valores reportados neste documento e exigiria tempo de avaliação próprio.

Um caminho foi considerado e não seguido, e as razões ficam registradas por serem necessárias a quem retome o trabalho. A predição conformal permite devolver conjuntos de respostas com uma garantia livre de distribuição (Angelopoulos e Bates 2023; Vovk, Gammerman e Shafer 2005), o que se ajusta a uma ferramenta que recusa afirmar mais do que aquilo que sabe. Duas razões afastaram-na. A primeira é que a garantia é marginal, valendo em média sobre os casos e não caso a caso, que é precisamente a leitura que um utilizador não especializado faria.

A segunda é mais determinante: a garantia exige permutabilidade entre calibração e teste, e estes dados constituem uma série temporal, na qual os títulos chegam por ordem. É a mesma suposição que este trabalho recusa ao dividir o conjunto por data e com embargo. A aplicação do método sem tratamento desse ponto produziria intervalos com uma garantia que os dados não sustentam, substituindo um valor honesto por um valor com aparência de rigor.

6.6 Considerações finais

O trabalho partiu de três perguntas que um investidor particular formula perante um movimento de preço, e a que as ferramentas gratuitas não respondem. Se o movimento é invulgar. Se a origem é a empresa ou o mercado. E se existem precedentes com desfecho conhecido. Construiu-se um sistema que responde às três com evidência verificável e sem emitir previsões, e avaliou-se cada componente contra alternativas mais simples declaradas antes da medição.

O resultado com maior valor informativo é negativo. A hipótese de que o texto das notícias transportaria informação ausente dos preços não foi confirmada sobre este corpus. A sua investigação produziu um diagnóstico de alcance superior ao da questão que a originou. O componente aprendido foi avaliado sobre uma distribuição e implantado sobre outra, e a métrica pela qual foi selecionado formulava uma pergunta distinta da que o produto necessitava. Nenhum teste automático assinalou a discrepância, porque cada componente cumpria o seu contrato e o que estava errado era uma suposição sobre a ligação entre eles.

A restrição fundadora do trabalho, segundo a qual o sistema não produz previsões de preço, revelou-se a decisão de maior alcance. Determina o que pode ser afirmado: toda a afirmação do sistema é confirmável contra o registo no momento em que é lida. Determina a forma da explicação, que apresenta casos individuais em vez de médias. E determina o critério de avaliação, que incide sobre a capacidade de identificar o que é invulgar e não sobre a de antecipar. Um sistema que apresente evidência em lugar de veredictos entrega menos do que um sistema que anuncie direções, e entrega apenas o que consegue sustentar.

Bibliografia

- Aamodt, Agnar e Enric Plaza (1994). «Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches». Em: *AI Communications* 7.1, pp. 39–59. doi: 10.3233/AIC-1994-7104.
- Adadi, Amina e Mohammed Berrada (2018). «Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)». Em: *IEEE Access* 6, pp. 52138–52160. doi: 10.1109/ACCESS.2018.2870052.
- Ahmed, Mohiuddin, Abdun Naser Mahmood e Md. Rafiqul Islam (2016). «A Survey of Anomaly Detection Techniques in Financial Domain». Em: *Future Generation Computer Systems* 55, pp. 278–288. doi: 10.1016/j.future.2015.01.001.
- Ancker, Jessica S. et al. (2017). «Effects of Workload, Work Complexity, and Repeated Alerts on Alert Fatigue in a Clinical Decision Support System». Em: *BMC Medical Informatics and Decision Making* 17.1, p. 36. doi: 10.1186/s12911-017-0430-8.
- Angelopoulos, Anastasios N. e Stephen Bates (2023). «Conformal Prediction: A Gentle Introduction». Em: *Foundations and Trends in Machine Learning* 16.4, pp. 494–591. doi: 10.1561/22000000101.
- Bansal, Gagan et al. (2021). «Does the Whole Exceed its Parts? The Effect of AI Explanations on Complementary Team Performance». Em: *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. doi: 10.1145/3411764.3445717.
- Barber, Brad M. e Terrance Odean (2008). «All That Glitters: The Effect of Attention and News on the Buying Behavior of Individual and Institutional Investors». Em: *The Review of Financial Studies* 21.2, pp. 785–818. doi: 10.1093/rfs/hhm079.
- Barberis, Nicholas e Richard Thaler (2003). «A Survey of Behavioral Finance». Em: *Handbook of the Economics of Finance*. Ed. por George M. Constantinides, Milton Harris e René M. Stulz. Vol. 1. Elsevier. Cap. 18, pp. 1053–1128. doi: 10.1016/S1574-0102(03)01027-6.
- Barredo Arrieta, Alejandro et al. (2020). «Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI». Em: *Information Fusion* 58, pp. 82–115. doi: 10.1016/j.inffus.2019.12.012.
- Blume, Marshall E. (1971). «On the Assessment of Risk». Em: *The Journal of Finance* 26.1, pp. 1–10. doi: 10.1111/j.1540-6261.1971.tb00584.x.
- Bollerslev, Tim (1986). «Generalized Autoregressive Conditional Heteroskedasticity». Em: *Journal of Econometrics* 31.3, pp. 307–327. doi: 10.1016/0304-4076(86)90063-1.
- Breunig, Markus M. et al. (2000). «LOF: Identifying Density-Based Local Outliers». Em: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104. doi: 10.1145/342009.335388.
- Brown, Stephen J. e Jerold B. Warner (1985). «Using Daily Stock Returns: The Case of Event Studies». Em: *Journal of Financial Economics* 14.1, pp. 3–31. doi: 10.1016/0304-405X(85)90042-X.
- Cahill, Daniel, Zhangxin Liu e Lee A. Smales (2025). «Investigating proxies for retail investor attention in financial markets». Em: *Accounting & Finance* 65.1, pp. 521–550. doi: 10.1111/acfi.13338.

- Cambridge Centre for Alternative Finance (2026). *Global AI in Financial Services Report: Adoption, Impact and Risks*. Cambridge Judge Business School, University of Cambridge. url: <https://www.jbs.cam.ac.uk/faculty-research/centres/alternative-finance/publications/2026-global-ai-in-financial-services-report/> (acedido em 21/06/2026).
- Cardillo, Giovanni e Helen Chiappini (2024). «Robo-advisors: A Systematic Literature Review». Em: *Finance Research Letters* 62, p. 105119. doi: 10.1016/j.fr1.2024.105119.
- Chandola, Varun, Arindam Banerjee e Vipin Kumar (2009). «Anomaly Detection: A Survey». Em: *ACM Computing Surveys* 41.3, 15:1–15:58. doi: 10.1145/1541880.1541882.
- D. Sculley et al. (2015). «Hidden Technical Debt in Machine Learning Systems». Em: *Advances in Neural Information Processing Systems 28 (NIPS 2015)*. Curran Associates, Inc., pp. 2503–2511. url: https://papers.nips.cc/paper_files/paper/2015/hash/86df7dcfd896fcdf2674f757a2463eba-Abstract.html.
- D'Acunto, Francesco, Nagpurnanand Prabhala e Alberto G. Rossi (2019). «The Promises and Pitfalls of Robo-Advising». Em: *The Review of Financial Studies* 32.5, pp. 1983–2020. doi: 10.1093/rfs/hhz014.
- Da, Zhi, Joseph Engelberg e Pengjie Gao (2011). «In Search of Attention». Em: *The Journal of Finance* 66.5, pp. 1461–1499. doi: 10.1111/j.1540-6261.2011.01679.x.
- Devlin, Jacob et al. (2019). «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». Em: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, pp. 4171–4186. doi: 10.18653/v1/N19-1423.
- Ding, Xiao et al. (2015). «Deep Learning for Event-Driven Stock Prediction». Em: *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 2327–2333. url: <https://www.ijcai.org/Abstract/15/329>.
- Dong, Zihan, Xinyu Fan e Zhiyuan Peng (2024). «FNSPID: A Comprehensive Financial News Dataset in Time Series». Em: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '24)*. Association for Computing Machinery, pp. 4918–4927. doi: 10.1145/3637528.3671629.
- Doshi-Velez, Finale e Been Kim (2018). «Considerations for Evaluation and Generalization in Interpretable Machine Learning». Em: *Explainable and Interpretable Models in Computer Vision and Machine Learning*. Ed. por Hugo Jair Escalante et al. The Springer Series on Challenges in Machine Learning. Cham: Springer, pp. 3–17. isbn: 978-3-319-98130-7. doi: 10.1007/978-3-319-98131-4_1.
- Engle, Robert F. (1982). «Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation». Em: *Econometrica* 50.4, pp. 987–1007. doi: 10.2307/1912773.
- Ernst, Thomas H. e Chester S. Spatt (2026). «Retail Investors and Trading Execution». Em: *Annual Review of Financial Economics*. doi: 10.1146/annurev-financial-111424-124712.
- Fama, Eugene F. (1970). «Efficient Capital Markets: A Review of Theory and Empirical Work». Em: *The Journal of Finance* 25.2, pp. 383–417. doi: 10.2307/2325486.
- Fama, Eugene F. et al. (1969). «The Adjustment of Stock Prices to New Information». Em: *International Economic Review* 10.1, pp. 1–21. doi: 10.2307/2525569.
- Friedman, Jerome H. (2001). «Greedy Function Approximation: A Gradient Boosting Machine». Em: *The Annals of Statistics* 29.5, pp. 1189–1232. doi: 10.1214/aos/1013203451.

- Gallup (2025). *What Percentage of Americans Own Stock?* url: <https://news.gallup.com/poll/266807/percentage-americans-owns-stock.aspx> (acedido em 21/06/2026).
- Gama, João et al. (2014). «A Survey on Concept Drift Adaptation». Em: *ACM Computing Surveys* 46.4, pp. 1–37. doi: 10.1145/2523813.
- Google (jun. de 2026). *Our latest Google Finance upgrades, including a new app.* url: <https://blog.google/products-and-platforms/products/search/google-finance-updates-june-2026/> (acedido em 07/08/2026).
- Guidotti, Riccardo et al. (2018). «A Survey of Methods for Explaining Black Box Models». Em: *ACM Computing Surveys* 51.5, 93:1–93:42. doi: 10.1145/3236009.
- Hevner, Alan R. et al. (2004). «Design Science in Information Systems Research». Em: *MIS Quarterly* 28.1, pp. 75–106. doi: 10.2307/25148625.
- Huang, Allen H., Hui Wang e Yi Yang (2023). «FinBERT: A Large Language Model for Extracting Information from Financial Text». Em: *Contemporary Accounting Research* 40.2, pp. 806–841. doi: 10.1111/1911-3846.12832.
- Huang, Yizheng e Jimmy Xiangji Huang (2026). «A Survey on Retrieval-Augmented Text Generation for Large Language Models». Em: *ACM Computing Surveys* 58, pp. 1–38. doi: 10.1145/3805774.
- Johnson, Jeff, Matthijs Douze e Hervé Jégou (2021). «Billion-Scale Similarity Search with GPUs». Em: *IEEE Transactions on Big Data* 7.3, pp. 535–547. doi: 10.1109/TBDATA.2019.2921572.
- Kahneman, Daniel e Amos Tversky (1979). «Prospect Theory: An Analysis of Decision under Risk». Em: *Econometrica* 47.2, pp. 263–291. doi: 10.2307/1914185.
- Kearney, Colm e Sha Liu (2014). «Textual Sentiment in Finance: A Survey of Methods and Models». Em: *International Review of Financial Analysis* 33, pp. 171–185. doi: 10.1016/j.irfa.2014.02.006.
- Lee, John D. e Katrina A. See (2004). «Trust in Automation: Designing for Appropriate Reliance». Em: *Human Factors* 46.1, pp. 50–80. doi: 10.1518/hfes.46.1.50_30392.
- Lewis, Patrick et al. (2020). «Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks». Em: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. Curran Associates, pp. 9459–9474. url: <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- Li, Yinheng et al. (2023). «Large Language Models in Finance: A Survey». Em: *Proceedings of the Fourth ACM International Conference on AI in Finance (ICAIF '23)*. Association for Computing Machinery, pp. 374–382. doi: 10.1145/3604237.3626869.
- Lipton, Zachary C. (2018). «The Mythos of Model Interpretability». Em: *Communications of the ACM* 61.10, pp. 36–43. doi: 10.1145/3233231.
- Liu, Fei Tony, Kai Ming Ting e Zhi-Hua Zhou (2008). «Isolation Forest». Em: *2008 Eighth IEEE International Conference on Data Mining (ICDM)*, pp. 413–422. doi: 10.1109/ICDM.2008.17.
- Liu, Zhuang et al. (2020). «FinBERT: A Pre-trained Financial Language Representation Model for Financial Text Mining». Em: *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence (IJCAI-20)*. International Joint Conferences on Artificial Intelligence Organization, pp. 4513–4519. doi: 10.24963/ijcai.2020/622.
- Loughran, Tim e Bill McDonald (2011). «When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks». Em: *The Journal of Finance* 66.1, pp. 35–65. doi: 10.1111/j.1540-6261.2010.01625.x.
- Lundberg, Scott M. e Su-In Lee (2017). «A Unified Approach to Interpreting Model Predictions». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*,

- pp. 4765–4774. url: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html.
- Manning, Christopher D., Prabhakar Raghavan e Hinrich Schütze (2008). *Introduction to Information Retrieval*. Cambridge, England: Cambridge University Press. isbn: 978-0-521-86571-5.
- Mikolov, Tomas et al. (2013). «Distributed Representations of Words and Phrases and their Compositionality». Em: *Advances in Neural Information Processing Systems 26 (NIPS 2013)*. Vol. 26. Curran Associates, Inc., pp. 3111–3119. url: https://papers.nips.cc/paper_files/paper/2013/hash/9aa42b31882ec039965f3c4923ce901b-Abstract.html.
- Miller, Tim (2019). «Explanation in Artificial Intelligence: Insights from the Social Sciences». Em: *Artificial Intelligence* 267, pp. 1–38. doi: 10.1016/j.artint.2018.07.007.
- Niculescu-Mizil, Alexandru e Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». Em: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, pp. 625–632. doi: 10.1145/1102351.1102430.
- Pang, Guansong et al. (2021). «Deep Learning for Anomaly Detection: A Review». Em: *ACM Computing Surveys* 54.2, 38:1–38:38. doi: 10.1145/3439950.
- Peppers, Ken et al. (2007). «A Design Science Research Methodology for Information Systems Research». Em: *Journal of Management Information Systems* 24.3, pp. 45–77. doi: 10.2753/MIS0742-1222240302.
- Pennington, Jeffrey, Richard Socher e Christopher D. Manning (2014). «GloVe: Global Vectors for Word Representation». Em: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1532–1543. doi: 10.3115/v1/D14-1162.
- Reimers, Nils e Iryna Gurevych (2019). «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». Em: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. doi: 10.18653/v1/D19-1410.
- Ribeiro, Marco Tulio, Sameer Singh e Carlos Guestrin (2016). «“Why Should I Trust You?”: Explaining the Predictions of Any Classifier». Em: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135–1144. doi: 10.1145/2939672.2939778.
- Robertson, Stephen e Hugo Zaragoza (2009). «The Probabilistic Relevance Framework: BM25 and Beyond». Em: *Foundations and Trends in Information Retrieval* 4.1–2, pp. 1–174. doi: 10.1561/15000000019.
- Robinhood Markets (mar. de 2025). *Introducing Robinhood Strategies, Robinhood Banking, and Robinhood Cortex*. url: <https://robinhood.com/us/en/newsroom/introducing-strategies-banking-and-cortex/> (acedido em 07/08/2026).
- Rousseeuw, Peter J. (1987). «Silhouettes: a graphical aid to the interpretation and validation of cluster analysis». Em: *Journal of Computational and Applied Mathematics* 20, pp. 53–65. doi: 10.1016/0377-0427(87)90125-7.
- Rudin, Cynthia (2019). «Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead». Em: *Nature Machine Intelligence* 1.5, pp. 206–215. doi: 10.1038/s42256-019-0048-x.
- Salton, Gerard, A. Wong e C. S. Yang (1975). «A Vector Space Model for Automatic Indexing». Em: *Communications of the ACM* 18.11, pp. 613–620. doi: 10.1145/361219.361220.

- Securities Industry and Financial Markets Association (SIFMA) (2025). *2025 Capital Markets Fact Book*. url: <https://www.sifma.org/resources/research/fact-book/> (acedido em 21/06/2026).
- Tetlock, Paul C. (2007). «Giving Content to Investor Sentiment: The Role of Media in the Stock Market». Em: *The Journal of Finance* 62.3, pp. 1139–1168. doi: 10.1111/j.1540-6261.2007.01232.x.
- Vasicek, Oldrich A. (1973). «A Note on Using Cross-Sectional Information in Bayesian Estimation of Security Betas». Em: *The Journal of Finance* 28.5, pp. 1233–1239. doi: 10.1111/j.1540-6261.1973.tb01452.x.
- Vaswani, Ashish et al. (2017). «Attention Is All You Need». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 5998–6008. url: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fb053c1c4a845aa-Abstract.html.
- Vinh, Nguyen Xuan, Julien Epps e James Bailey (2010). «Information Theoretic Measures for Clusterings Comparison: Variants, Properties, Normalization and Correction for Chance». Em: *Journal of Machine Learning Research* 11.95, pp. 2837–2854. url: <https://www.jmlr.org/papers/v11/vinh10a.html>.
- Vovk, Vladimir, Alexander Gammerman e Glenn Shafer (2005). *Algorithmic Learning in a Random World*. New York: Springer. isbn: 978-0-387-00152-4. doi: 10.1007/b106715.
- Welch, Ivo (2022). «The Wisdom of the Robinhood Crowd». Em: *The Journal of Finance* 77.3, pp. 1489–1527. doi: 10.1111/jofi.13128.
- World Monitor (2026). *Real-time global intelligence dashboard*. url: <https://worldmonitor.app> (acedido em 31/07/2026).
- Xing, Frank Z., Erik Cambria e Roy E. Welsch (2018). «Natural Language Based Financial Forecasting: A Survey». Em: *Artificial Intelligence Review* 50.1, pp. 49–73. doi: 10.1007/s10462-017-9588-9.

Apêndice A

Reprodutibilidade

Este apêndice documenta a proveniência dos resultados apresentados no corpo da dissertação. Enumera os artefactos conservados, estabelece a correspondência entre cada resultado reportado e o procedimento que o produz, apresenta o estado em que ficou cada afirmação substantiva depois de medida, e regista as condições de licenciamento dos dados utilizados. Encerra com o desenho do estudo com utilizadores que a Secção 6.4 identifica como a lacuna de maior peso do trabalho.

A.1 Artefactos conservados

Esta secção enumera o que é conservado no repositório de código e o que não é, com a razão de cada caso.

O ambiente de execução está descrito na Secção 3.7, com as versões exatas das bibliotecas que produziram os valores deste documento. As versões estão fixadas, e não expressas em intervalos, porque uma biblioteca que se atualize sozinha altera resultados sem emitir aviso. Nenhum dos procedimentos exige unidade de processamento gráfico.

São conservadas três classes de artefacto. A primeira é o componente aprendido, que compreende o modelo treinado, o calibrador ajustado sobre o bloco de validação e um ficheiro descritivo da execução que os produziu, com a dimensão de cada bloco, a prevalência de casos positivos, a semente utilizada e as métricas obtidas. A segunda é o conjunto de ficheiros de resultados, um por procedimento de avaliação, que o texto cita. A terceira é a base de precedentes que a aplicação implantada consulta, com cinquenta e seis megabytes de vetores e oito de metadados. Esta última não constitui uma amostra: é o artefacto de que o sistema necessita para arrancar, e sem ele não existiriam precedentes para apresentar.

Os corpora de origem não são conservados no repositório. O conjunto histórico ocupa várias centenas de megabytes e é reconstruído pelos procedimentos de preparação descritos na Secção 3.2. Acompanham o código amostras reduzidas, cuja finalidade é permitir que a verificação automática decorra sem acesso à rede, incluindo o teste que impõe a separação temporal descrita na Secção 3.6.

A.2 Origem de cada resultado

Esta secção estabelece a correspondência entre cada resultado reportado no corpo do documento e o procedimento que o gera.

Nenhum resultado desta dissertação foi introduzido manualmente no texto. Cada um é produzido por um procedimento automático de semente fixa, que escreve o seu próprio ficheiro de resultados, e é esse ficheiro que o texto cita. Uma segunda execução sobre os mesmos dados devolve os mesmos valores. A Tabela A.1 reúne os resultados reportados e identifica a secção em que cada um aparece; o repositório de código nomeia, para cada resultado, o ficheiro que o contém e o procedimento que o produz.

A garantia de determinismo aplica-se ao bloco superior da tabela. As linhas do bloco inferior são de outra natureza, e por isso estão separadas: constituem medições sobre a operação do sistema, cujo valor depende do momento em que o registo foi lido e não de uma semente. A secção em que cada uma é apresentada declara o período e o conjunto sobre que foi realizada.

Uma dessas medições não é regenerável, e a distinção fica registada em vez de omitida. A repartição do funil por porta, apresentada na Secção 4.4, foi lida do registo de decisões num dia concreto, e esse registo conserva apenas três dias, pela razão indicada na Secção 3.2: é republicado a cada ciclo, pelo que o custo é de publicação e não de armazenamento. A execução do mesmo procedimento numa data posterior produz outro dia, e não o mesmo. O valor consta de um ficheiro de resultados, com a data da leitura e o procedimento que a produziu, de modo que qualquer leitura futura tenha origem declarada ainda que aquele dia não se repita.

Os restantes valores numéricos do documento pertencem a três categorias. Os valores extraídos da literatura estão citados no local em que aparecem. As constantes de configuração constam da Tabela 4.2, com a distinção entre as que foram derivadas de uma medição e as que foram escolhidas. A terceira categoria reúne medições que servem uma passagem e não um resultado, como as linhas descartadas pelo embargo, o desvio-padrão do caso trabalhado da Secção 3.3 ou as contagens por fonte de notícias; cada uma declara, no local em que aparece, o conjunto sobre que foi realizada.

A.3 Matriz de evidência

Esta secção submete cada afirmação substantiva do trabalho à evidência que a sustenta e regista o estado em que ficou.

A tabela da secção anterior enumera resultados. A Tabela A.2 enumera afirmações, exame mais exigente, uma vez que uma afirmação pode não sobreviver à evidência que a suportava. As afirmações retiradas permanecem na tabela, dado que uma matriz que enumere apenas as sobreviventes não constitui uma auditoria.

Duas observações incidem sobre a tabela no seu conjunto e não sobre qualquer linha isolada.

A primeira é que as afirmações retiradas o foram por medições do próprio trabalho, e nenhuma por revisão externa. Constitui o comportamento pretendido de um plano de avaliação fixado antes das experiências, cuja utilidade reside precisamente na capacidade de produzir uma resposta negativa.

A segunda é que as duas linhas assinaladas como não afirmadas têm o mesmo peso das restantes. Uma delas é a utilidade das explicações para o utilizador, que não foi medida por ausência de estudo com pessoas. Onde não existe evidência, não é formulada afirmação.

Tabela A.1: Os resultados reportados no corpo do documento e a secção em que aparecem. O bloco superior é determinístico e reproduz-se exatamente sobre os mesmos dados; o bloco inferior reúne medições sobre a operação, cujo valor depende da data de leitura do registo.

Resultado	Valor	Onde aparece
Amplitude da taxa de disparo, desvio relativo contra limiar fixo	0,015 contra 0,344	§5.2
F_1 contra o critério aproximado	0,516 contra 0,218	§5.2
Comparação com dois detetores aprendidos	0,530 / 0,269 / 0,280	§5.2
Ablação à janela e ao peso do desvio	0,678 e 0,664 contra 0,516	§5.2
Precisão@5 da recuperação, quatro métodos	0,514 / 0,346 / 0,240 / 0,126	§5.3
Valor de referência do setor mais representado	0,467	§5.3
Precisão@5 no protocolo simétrico à escala	0,595 com acaso 0,333	§5.3
Precisão@5 apenas com precedentes anteriores	0,513 com acaso 0,259	§5.3
Concordância de direção contra o valor de acaso	0,708 contra 0,688	§5.3
Triagem, PR-AUC das seis famílias	de 0,378 a 0,542	§5.4
Precisão dentro do orçamento, quatro políticas	0,163 / 0,379 / 0,662 / 0,632	§5.4
Grelha de nove definições de critério	9 de 9	§5.4
Ablação da identidade, tabela de consulta contra modelo	0,534 contra 0,538	§5.4.5
Acréscimo do texto sobre a tabela de consulta	0,547 contra 0,534	§5.4.5
Qualidade do ajuste da decomposição, mediana e casos negativos	0,460, 1 em 17	§5.5
Seletividade da porta, dentro e entre empresas	0,072 contra 0,392	§5.6
Deriva de distribuição, PSI da volatilidade	0,281	§5.6
Sistema completo contra as alternativas	0,489 / 0,632 / 0,662 / 0,968	§5.6
<i>Medições sobre a operação: o valor depende da data de leitura do registo</i>		
Decisões maturadas, mantidas contra suprimidas	58,9% contra 61,7%	§5.6
Capacidade de ordenação sobre as decisões tomadas	0,486	§5.6
Cobertura de notícias em dias invulgares	88,5%	§5.6
Latência, descoberta e entrega	353 min e 5 s	§4.6
Funil de produção, relevantes até entregues	944 → 42	§4.4
Funil de um dia, repartido por porta	5 060 avaliações	§4.4

Tabela A.2: Cada afirmação substantiva, a evidência que a sustenta e o estado em que ficou. O estado *retirada* indica que o trabalho a abandonou depois de a medir; o estado *estreitada* indica que subsiste numa formulação mais restrita do que a inicial.

Afirmação	Evidência	Estado
Deteção de movimentos invulgares		
Dispara a ritmo comparável entre empresas de volatilidade muito distinta	Amplitude de 0,015 contra 0,344, sem recurso a rótulos	Mantida
Supera um limiar fixo no critério aproximado	F_1 de 0,516 contra 0,218	Mantida, com o critério declarado como aproximação
Supera dois detetores aprendidos com a mesma informação	F_1 de 0,530 contra 0,269 e 0,280	Mantida
Não utiliza informação posterior ao dia avaliado	A janela exclui esse dia, e um teste automático impõe a exclusão	Mantida
A janela de vinte dias e o desvio de pesos iguais são as melhores opções	Variantes alternativas obtêm 0,678 e 0,664 contra 0,516	Retirada: mantidas por explicabilidade, não por desempenho
Recuperação de precedentes		
Supera as alternativas lexical e triviais	Precisão@5 de 0,514 contra 0,346, 0,240 e 0,126	Mantida
Supera por larga margem o melhor valor de referência trivial	A escolha do setor mais representado obtém 0,467, o que reduz a margem de +0,274 para +0,047	Estreitada: a afirmação passa a ser por setor, onde se mantém nos cinco
Resiste ao aumento de escala do corpus	Precisão@5 de 0,595 com acaso de 0,333	Mantida como teste de escala
Resiste à restrição temporal da produção	Precisão@5 de 0,513 com acaso de 0,259: a margem varia 0,008	Estreitada: o valor simétrico descreve tarefa menos exigente
Capta tema e não direção	Concordância de 0,708 contra acaso de 0,688	Mantida, e reportada como limitação
A pertença ao mesmo setor equivale a relação entre notícias	—	Não afirmado: é uma aproximação declarada
Triagem de notícias		
Nenhuma variante com texto supera a volatilidade	PR-AUC de 0,496 contra 0,542, com nove definições de critério e reamostragem por grupos	Mantida
O texto acrescenta informação sobre a tabela de consulta	PR-AUC de 0,547 contra 0,534, com intervalo entre +0,004 e +0,020	Nova, positiva, e sem efeito na precisão dentro do orçamento
As entradas não incorporam informação futura	Alterar o futuro de um exemplo deixa as entradas iguais e altera o critério	Mantida
A triagem quadruplica a precisão dentro do orçamento	O valor de referência de 0,163 resulta de ordenação alfabética; a escolha aleatória obtém 0,379	Retirada: o ganho é de 1,67 vezes
O ganho dentro do orçamento provém da aprendizagem	Treze constantes por empresa obtêm 0,662 contra 0,632 do modelo	Retirada
O modelo implantado seleciona melhor do que o acaso	58,9% de casos materiais entre as mantidas contra 61,7% entre as suprimidas	Retirada
Sistema		
O texto do alerta não pode divergir do cálculo	É composto a partir dos objetos calculados, sem geração de linguagem	Mantida
A restrição de gratuidade limita a cobertura	Pelo menos uma notícia relevante em 88,5% dos dias invulgares	Mantida como limite superior
As explicações são úteis a uma pessoa	—	Não afirmado

A.4 Dados, licenças e atribuição

Esta secção regista a origem dos dados utilizados e as obrigações que o seu licenciamento impõe.

O conjunto histórico que sustenta a base de precedentes é o FNSPID (Dong, Fan e Peng 2024), utilizado ao abrigo da licença Creative Commons BY-SA 4.0, cuja atribuição é aqui cumprida. Do corpus constam no documento apenas excertos mínimos de títulos, a título ilustrativo.

Essa licença comporta uma segunda obrigação, que é acionada neste caso. Uma vez que o repositório distribui ficheiros derivados do FNSPID, a cláusula de partilha nos mesmos termos aplica-se a esses ficheiros. A licença do código constitui uma decisão que permanece em aberto neste documento, e é esta a restrição que a condiciona.

Os preços provêm de serviços gratuitos de dados de mercado, através da cadeia de alternativas descrita na Secção 4.2; as notícias em tempo real provêm de três interfaces gratuitas, dentro dos respetivos limites de utilização, comparadas na Secção 4.2.2.

Quanto a dados pessoais, a formulação exata consta da Secção 3.8.1: o sistema não conhece as posições dos utilizadores e não as solicita, e o canal público não identifica destinatários. A exceção é a subscrição opcional de alertas personalizados, em que ficam associados o identificador de conversa atribuído pela plataforma e a lista de empresas escolhida, e esses são os únicos elementos armazenados.

A.5 Desenho do estudo com utilizadores

Esta secção apresenta o desenho do estudo referido na Secção 6.5.

O estudo compara duas condições sobre seis alertas reais extraídos do canal. A condição A apresenta o facto sem explicação e a condição B apresenta o alerta completo. Dois dos seis casos são situações em que o tema da notícia e a direção do movimento discordam, configuração em que a Secção 5.3 mostra o sistema ser mais suscetível de interpretação incorreta.

O contrabalanço cruza dois fatores, que são a ordem das condições e a metade dos estímulos que serve de condição A. O segundo fator é necessário porque as duas condições recorrem a alertas distintos, sob pena de a segunda medir memória em vez de compreensão; sem o cruzamento, qualquer diferença entre condições ficaria confundida com a maior acessibilidade de uma das metades.

A pergunta central é a que a verificação automática não alcança. A correspondência entre cada frase do alerta e o facto que a sustenta está garantida por construção, mas a afirmação do produto descreve um percurso realizado por um leitor: dada uma frase com remissão, aceder ao facto correspondente e julgar autonomamente se este a sustenta. A questão é qualitativa e não exige amostra de grande dimensão.

Duas salvaguardas metodológicas estão fixadas no código antes de existirem dados: o limiar de oito participantes para o teste estatístico, cuja alteração ficaria registada no histórico de versões, e o procedimento de análise, que sobre a folha por preencher não produz resultado algum. Um terceiro bloco do desenho original, relativo a texto gerado, não é executável, uma vez que as vias que o serviam foram retiradas do sistema.

Apêndice B

Correspondência com o plano curricular

Este apêndice estabelece a correspondência entre as unidades curriculares do mestrado e os pontos do trabalho em que a respetiva matéria foi aplicada. A Tabela B.1 apresenta essa correspondência e identifica igualmente as unidades cuja matéria não teve aplicação, uma vez que uma correspondência que encontre aplicação para todas as unidades em todos os pontos não transmite informação.

Duas entradas da tabela declaram ausência de aplicação: a matéria de Ambientes Inteligentes e a componente de programação lógica e por restrições. O seu registo é mais informativo do que a construção de uma ligação artificial.

Tabela B.1: Aplicação da matéria de cada unidade curricular do plano de estudos do mestrado no trabalho descrito nesta dissertação. A última coluna indica a secção em que essa aplicação é visível.

Unidade	Onde é aplicada	Secção
<i>Fundamentos de sistemas inteligentes</i>		
Aprendizagem Automática 1	Construção de um conjunto de treino rotulado a partir de duas fontes desalinhas no tempo; regressão logística com normalização e reponderação de classes; conjuntos de árvores por reforço do gradiente como referência superior; calibração <i>a posteriori</i>	§3.6, §5.4
Engenharia do Conhecimento	Raciocínio baseado em casos: recuperação e reutilização de precedentes em substituição de uma regra geral, com a interrupção deliberada do ciclo antes da adaptação	§2.6, §3.5
Paradigmas de Programação em IA	Separação entre lógica pura e efeitos externos, que é a propriedade que permite verificar o núcleo do sistema sem acesso à rede e sem carregar modelos. A matéria de programação lógica e por restrições não teve aplicação	§3.1
Planeamento e Tomada de Decisão	Política de decisão sob orçamento: portas em cascata, limiar derivado de uma análise de custos de erro, e distinção entre uma política que dispõe do dia completo e uma política que decide a cada ciclo	§4.4, §5.4
<i>Inteligência artificial avançada e aplicações especializadas</i>		
Aprendizagem Automática 2	Representações contextuais de frase produzidas por uma arquitetura <i>Transformer</i> ; exportação do codificador para um formato leve, com medição da fidelidade da conversão, imposta pela restrição de memória do ambiente de execução	§2.4, §3.5
Linguagem Natural e Sistemas Conversacionais	Semelhança semântica entre frases e avaliação de recuperação sensível à ordem. O sistema constitui uma arquitetura de recuperação sem geração: recupera evidência e recusa produzir texto sobre ela, com a justificação apresentada no estado da arte	§2.4, §5.3
Ambientes Inteligentes	Sem aplicação. O trabalho não comporta componente física, robótica nem de Internet das Coisas	—
<i>Profissionalismo, segurança e inovação</i>		
Aspectos Sociais e Éticos em IA	Confiança apropriada em sistemas automáticos e risco de a explicação aumentar a aceitação de respostas incorretas; recusa de aconselhamento; fadiga de alertas como requisito de desenho	§2.7, §3.8
Privacidade e Segurança em Sistemas Inteligentes	Minimização de dados por desenho, com a exceção declarada; gestão de credenciais e mascaramento de segredos em registos; verificação de integridade do modelo transferido	§3.8.1, §3.8.2
Investigação e Inovação em IA	Enquadramento em investigação por desenho; critérios de sucesso fixados antes das medições; linhas de comparação declaradas com o respetivo valor de referência; matriz de evidência com as afirmações retiradas	§3.1, Apêndice A