

Guia de estudo do InvestiGator

Do zero até conseguir defender

Henrique J. S. Santos



Como usar este guia

- **Nível 0:** as bases de IA. Só o que esta tese usa, nada mais.
- **Nível 1:** o problema e o sistema.
- **Níveis 2 a 4:** uma técnica de cada vez, com contas feitas.
- **Nível 5:** os números que tens de saber de cor.
- **Nível 6:** as perguntas do júri, com resposta.

Se só tiveres uma hora: **Nível 5** e **Nível 6**.

Se tiveres uma tarde: tudo, por ordem.

Nível 0: IA, aprendizagem automática, e o que tu usas

- **Inteligência artificial** é o guarda-chuva: qualquer sistema que faça algo que associamos a inteligência.
- **Aprendizagem automática (ML)** é um pedaço desse guarda-chuva: em vez de escreveres a regra, dás **exemplos** e o programa encontra a regra.
- **Aprendizagem profunda** é um pedaço do ML: redes neuronais com muitas camadas.

Na tua tese

Usas **estatística** nas técnicas 1 e 2 (o z-score e a decomposição do movimento), **aprendizagem profunda já treinada por outros** na técnica 3 (os *embeddings* de frase) e **aprendizagem automática treinada por ti** na técnica 4 (a triagem).

Não treinas redes neuronais. **Não** usas visão computacional. **Não** usas aprendizagem por reforço. Diz isso sem hesitar.

Nível 0: as palavras que vais ouvir

Features	As colunas que o modelo vê. Na tua: volatilidade, momento, movimento do dia, comprimento do título, setor.
Rótulo	A resposta certa, conhecida. Na tua: houve movimento anormal a seguir? Sim/não.
Treino / teste	Ensinas com uns dados, avalias com <i>outros</i> . Se avaliasse com os mesmos, media memória e não aprendizagem.
Linha de base	O método simples contra o qual comparas. Sem ele, um número não quer dizer nada.
Sobreajuste	O modelo decora o treino e falha no resto. É o que a divisão treino/teste deteta.
Calibração	Fazer com que “70%” queira mesmo dizer 70% das vezes.

Nível 0: a pergunta que te vão fazer e a resposta

“Isto aprende sozinho? Melhora com o tempo?”

Resposta

Não. O modelo foi treinado uma vez, sobre dados de 2018–2023, e está **congelado**. Quando corre em produção faz **inferência**, ou seja, aplica o que aprendeu, e **não** volta a aprender.

Três coisas diferentes que é fácil confundir:

treino (aprender dos exemplos, uma vez) $\neq$ **inferência** (aplicar, todos os dias) $\neq$ **re-treino** (voltar a treinar com dados novos, o que não é feito).

Nível 1: as três perguntas

- ❶ Isto é **invulgar?** estatística
- ❷ Foi a **empresa ou o mercado?** decomposição
- ❸ Já **aconteceu, e o que se seguiu?** recuperação e medição

Guarda esta frase

“As aplicações gratuitas mostram a percentagem, que é o *princípio* da primeira pergunta e não a resposta. Os terminais profissionais respondem às três e custam milhares por ano. **O problema não é científico, é de acesso.**”

Nível 1: o que o sistema recusa fazer

Não prevê preços. Não aconselha. Não gere carteiras.


Porque é que isto é uma força

Uma afirmação sobre o que **já aconteceu** confere-se contra o registo.

Uma previsão só se confere depois de já ter sido preciso decidir.

E há uma razão teórica: se o futuro fosse previsível a partir de informação *pública*, essa informação já estaria no preço.

Nível 1: e é isto que está no ar




Captura real da produção, com a sessão a decorrer.

- A **frase** vem antes do número: é a regra de apresentação.
- A **repartição** responde à segunda pergunta. Aqui a ação desce 0.30%, mas a contribuição da própria empresa é **positiva**: quem a puxa é o **mercado**.
- Os **marcadores** na curva separam os dias que deram alerta dos que o detetor assinalou e não deram. A distância entre uns e outros é o custo das portas.

Nível 1: e o que nenhum produto mostra

A mesma página abre, para cada candidata, **o percurso pelas portas** e onde parou.



Se te perguntarem “*e quando não envia nada?*”, é para aqui que apontas: nove em cada dez varreduras não enviam, e cada etapa diz a porta que a deteve (aqui, o orçamento de cinco alertas do dia, já gasto).

Nível 2, técnica 1: o z-score, com contas

$$z = \frac{\text{movimento de hoje} - \text{média dos 20 dias}}{\text{desvio-padrão dos 20 dias}}$$

Exemplo real (Tesla, 24 out 2024):

Média dos 20 dias anteriores	-0,92%
Desvio-padrão desses 20 dias	2,72%
Movimento do dia	+19,82%
$z = (19,82 - (-0,92))/2,72$	+7,61

Faz esta conta à mão uma vez. Se te pedirem para a explicar no quadro, tens de a saber fazer.

Nível 2: a parte que te vão testar

“Porque é que o dia de hoje não entra no cálculo da sua própria norma?”

Resposta

Porque se entrasse, um dia extremo puxava a média e aumentava o desvio-padrão, e ficaria a parecer **menos** invulgar do que foi.

Isso seria usar informação que, no momento da decisão, ainda não devia contar. Chama-se **lookahead**, e é o erro mais comum em modelos financeiros.

Na tese isto é garantido por **um teste automático**, não por uma promessa: o teste altera o futuro e exige que as *features* fiquem iguais e o rótulo mude.

Caso limite: se os vinte dias forem constantes, manter o mesmo valor não dispara; um salto dispara com a explicação *“norma plana; z indefinido”*. Nunca digas que esse salto tem $z = 0$.

Nível 2, técnica 2: foi a empresa, ou foi o mercado?

Responde à **segunda** das três perguntas, e é a que um arguente com finanças conhece.

- **A conta:** o movimento do dia parte-se em três parcelas que **somam ao total**: *mercado* (o beta vezes o índice), *setor* (o fundo do setor, já descontado do mercado) e *empresa* (o que sobra).
- **Os betas** são estimados só com dias **anteriores** ao dia explicado, e **encolhidos** pela sua precisão: mercado para 1, setor ortogonalizado para 0 (Vasicek, 1973). O desvio-padrão comum do prior é 0.5.
- **Porquê encolher:** sem isso, um beta mal estimado atribuía o movimento inteiro à empresa.

O que dizes se te perguntarem se estás certa

“As parcelas somam sempre, por construção, portanto isso não prova nada. Medi as duas coisas que podiam falhar: se a repartição **discrimina** (num mesmo dia o motor foi a empresa em 8 casos, o mercado em 5 e o setor em 4, logo não diz sempre o mesmo) e se os **betas** estão bem estimados (R^2 mediano 0.460, e **numa das dezassete foi negativo**). E não há verdade humana para comparar: é por isso que esta técnica não dá origem a uma pergunta de investigação.”

Nível 3, técnica 3: frases como pontos

- Um **embedding** é uma lista de números que representa uma frase: aqui, **384**.
- Funciona como uma **coordenada de significado**: frases parecidas ficam perto.
- Compara-se pelo **cosseno**: o **ângulo** entre duas direções, entre -1 e 1 .

Porquê o ângulo e não a distância?

Porque interessa *sobre o que* a frase fala, não o comprimento do texto. Um título curto e um parágrafo longo sobre o mesmo assunto devem ficar próximos.

O modelo não é teu: é pré-treinado (Sentence-BERT). Diz isso; está declarado na tese.

Nível 3: tema não é direção

É a ressalva mais importante desta técnica.

Duas notícias podem ser sobre **o mesmo assunto** e o preço ter ido para **lados opostos**.

Medido

Concordância de direção entre a notícia e os casos recuperados: **0.708**

Chão de acaso: **0.688**

Ou seja: **quase nada**.

É por isso que o sistema mostra os casos **um a um** e nunca só a média. Uma média esconderia que foram em sentidos opostos.

Nível 4, técnica 4: o teu modelo

- **79 753** exemplos que construístes (notícias 2018–2023 + preços).
- **Rótulo:** houve movimento anormal $\geq 2\%$ nos 3 dias seguintes? **Em valor absoluto**, nunca a direção.
- **Divisão cronológica** 70/15/15, com **embargo** de 5 dias entre blocos.
- **Calibração** de Platt, ajustada na validação.

Porquê o embargo?

O rótulo olha 3 dias para a frente. Uma notícia no último dia de treino tem o rótulo determinado por dias que já são do bloco seguinte. Deitam-se fora os dias de fronteira.

Nível 4: o resultado, e como o defendes

Nenhum modelo que lê o texto bate a volatilidade sozinha.
0,496 contra 0,542

Se te disserem “então o vosso modelo falhou”

“O modelo não falhou: a hipótese foi testada e a resposta foi não. Escrevi o critério **antes** de correr a experiência, e verifiquei por três caminhos: re-teste em condições favoráveis ao texto, reamostragem por grupos, e **nove** definições diferentes do rótulo. A volatilidade ganha nas nove. Um trabalho que só reporta o que corre bem não é uma avaliação.”

Nível 4: e a metade da resposta que quase ficou por medir

Todas as comparações acima põem as variantes **lado a lado**: respondem a *qual é melhor*. Falta a outra pergunta, e é a mais útil para quem constrói:

o texto acrescenta ao que já se sabe da empresa?

Medido **por cima** da tabela de consulta, que sabe tudo da empresa e nada da notícia:

+0,012 de PR-AUC, IC [+0,004, +0,020] — **exclui zero**

É a única vez neste trabalho em que uma representação de texto mostra um acréscimo detetável; fica abaixo do critério prático de 0,02 e não muda a métrica de produto.

Mas o veredicto não muda, e dizes tu porquê antes que perguntem

1. 0,547 vs 0,542, e o intervalo da diferença **contém zero** — não digas que ganha;
2. a precisão no orçamento é 0,662 com e sem texto;
3. continua a não separar dois dias da mesma empresa.

*Não é uma ressalva, é uma **localização***: o texto distingue **empresas**, e o produto precisava que distinguísse **notícias**.

Nível 5: os números de cor

0.015 vs 0.344	amplitude de disparo: z-score vs limiar fixo	Q11
0.530 / 0.269 / 0.280	F_1 : z-score vs Isolation Forest vs LOF	Q11
0.514 vs 0.467	precisão@5: significado vs <i>sempre tecnologia</i>	Q12
0.346 / 0.240	idem: palavras em comum / acaso uniforme	Q12
0.513 / 0.259 / +0.254	P@5 causal / chão / margem; 0.595 é o teste simétrico	Q12
0.708 vs 0.688	concordância de direção vs acaso (tema $\neq$ direção)	Q12
0.542 vs 0.496	PR-AUC: só volatilidade vs contexto+texto	Q13
+0.012 IC [+0.004, +0.020]	o texto por cima da tabela de consulta : acrescenta	Q13
9 de 9	células da grelha em que a volatilidade ganha	Q13
0.379 → 0.632	precisão no orçamento: acaso → modelo (1,67×)	Q13
0.662	o prior de 13 constantes, que bate o modelo	Q13
84%	decisões determinadas pela empresa , não pela notícia	Q13
0.064 vs 0.385	variação do score dentro vs entre empresas (6,1×)	Q13
79 753	exemplos do teu conjunto de dados	—
88,5%	dias invulgares com notícia captada (limite superior)	limitação
944 → 42	funil de produção: captadas → enviadas	sistema

Nível 5: o número que NÃO debes dizer

Não digas “quadruplica”.

O 0,163 do “alertar sempre” **não media escolher às cegas**: com todas as pontuações empatadas, a métrica desempata pela ordem do ficheiro, que está ordenado por data e nome da empresa. Media **escolher por ordem alfabética**.

O que dizes

“Contra um chão que escolhe mesmo ao acaso (0,379), o ganho é de **1.67 vezes**. Encontrei o erro a verificar o que a minha própria linha de base media, e corriji-o. Está na matriz de evidência.”

Nível 5: mais dois enganos fáceis de cometer

Não digas “a precisão ao vivo foi de 0.667 contra 0.455”

Esse par existiu, e foi **retirado**: eram **12 decisões**, com intervalo de confiança a 95% de $[0.391, 0.862]$, que **contém** a taxa-base. Refeito sobre o registo inteiro, hoje com **825** decisões maturadas, o sinal **inverte-se**: mantidas 0.589 contra suprimidas 0.617.

O que dizes: “uma percentagem sobre uma amostra pequena não é um resultado, e retirei-a”. A lição vale mais do que o número valia.

Não digas “RQ”

A tese longa tinha **quatro RQ**. Esta tem **três QI**, e a correspondência não é um para um: a antiga RQ3, sobre a utilidade das explicações, **não existe** aqui, porque não foi feito estudo com pessoas. $RQ1 \rightarrow QI1$, $RQ2 \rightarrow QI2$, $RQ4 \rightarrow QI3$.

Os documentos de defesa antigos ainda dizem RQ. Traduz antes de responder.

Nível 6: perguntas do júri (1/3)

“Onde está a engenharia de IA? Isto são bibliotecas.”

“Está no que foi **medido para decidir**. Construí três alternativas e não implantei duas delas porque a medição não as sustentou. A engenharia está em ter um critério capaz de dizer não.”

“Qual é a contribuição, se os modelos já existiam?”

“A integração avaliada. Nenhum algoritmo é novo. O que é novo é um sistema que responde às três perguntas a custo zero, com cada afirmação rastreável ao procedimento que a produziu, e com os resultados negativos reportados tal como caíram.”

Nível 6: perguntas do júri (2/3)

“Não bastava perguntar a um ChatGPT?”

“Um assistente genérico não tem a volatilidade daquela ação, não separa a empresa do mercado, e não *recupera* casos passados. No melhor dos casos *recorda* do treino, o que não é verificável. E a saída dele é uma afirmação; a minha vem com a evidência ao lado.”

“Como sabe que não há informação do futuro nas features?”

“Não sei por promessa: sei por teste. Há um teste que altera o futuro e exige duas condições ao mesmo tempo: que as features fiquem **iguais** e que o rótulo **mude**. Se alguma informação futura se tivesse infiltrado, o teste falha.”

Nível 6: perguntas do júri (3/3)

“Fez estudo com utilizadores?”

“**Não.** O desenho está feito (participantes, tarefas, critérios), mas não foi corrido a tempo. Por isso não afirmo nada sobre utilidade: a fidelidade está garantida por construção, a utilidade fica em aberto e está escrito assim na tese.”

Nunca inventes participantes nem opiniões. É a única resposta que te pode custar o grau.

“Os alertas parecem falhar notícias importantes.”

“Parte disso está medido: havia notícia captada em 88,5% dos dias invulgares, e a empresa pior coberta fica-se pelos 50%. E é um **limite superior**: pergunta se existia *uma* notícia, não se chegou *a certa*. Saber isso exige julgamento humano dia a dia, e é o primeiro trabalho futuro que aponto.”

Nível 6: a pergunta mais dura, e a tua melhor resposta

“O vosso modelo não serve para nada, então?”

“Serve para o que a medição sustenta: **ordenar** empresas. Não serve para o que eu lhe estava a pedir. Medi o que ele fazia quando decidia e a pontuação varia **0.064** dentro de cada empresa e **0.385** entre empresas: o limiar estava a separar empresas, não títulos. Em **84%** das decisões o resultado estava determinado antes de a notícia ser lida.”

“E porque não puseram o limiar relativo a cada empresa?”

“Simulei isso **antes** de mexer no código. Resolve metade, e cria outro problema: nas empresas de pontuação quase constante o percentil cai em cima da constante e quase tudo empata acima. Uma delas passaria **874** vezes. Não se corrige um defeito introduzindo o defeito vizinho.”

Se te perguntarem só uma coisa sobre a QI3, é esta. Diz sempre a segunda parte: mostra que testaste a correcção óbvia em vez de a assumir.

Se te esqueceres de tudo, guarda isto

Duas respostas de sim, uma de não.

E um erro meu, encontrado por mim e corrigido.

“A parte difícil não foi escolher a técnica mais avançada.
Foi montar a avaliação capaz de dizer que ela não era precisa.”