

Guia de estudo do InvestiGator

Do zero até conseguir defender

Henrique J. S. Santos



Como usar este guia

- **Nível 0:** as bases de IA. Só o que esta tese usa, nada mais.
- **Nível 1:** o problema e o sistema.
- **Níveis 2 a 4:** uma técnica de cada vez, com contas feitas.
- **Nível 5:** os números que tens de saber de cor.
- **Nível 6:** as perguntas do júri, com resposta.

Se só tiveres uma hora: **Nível 5** e **Nível 6**.

Se tiveres uma tarde: tudo, por ordem.

Nível 0: IA, aprendizagem automática, e o que tu usas

- **Inteligência artificial** é o guarda-chuva: qualquer sistema que faça algo que associamos a inteligência.
- **Aprendizagem automática (ML)** é um pedaço desse guarda-chuva: em vez de escreveres a regra, dás **exemplos** e o programa encontra a regra.
- **Aprendizagem profunda** é um pedaço do ML: redes neuronais com muitas camadas.

Na tua tese

Usas **estatística** nas técnicas 1 e 2 (o z-score e a decomposição do movimento), **aprendizagem profunda já treinada por outros** na técnica 3 (os *embeddings* de frase) e **aprendizagem automática treinada por ti** na técnica 4 (a triagem).

Não treinas redes neuronais. **Não** usas visão computacional. **Não** usas aprendizagem por reforço. Diz isso sem hesitar.

Nível 0: as palavras que vais ouvir

Features	As colunas que o modelo vê. Na tua: volatilidade, momento, movimento do dia, comprimento do título, setor.
Rótulo	A resposta certa, conhecida. Na tua: houve movimento anormal a seguir? Sim/não.
Treino / teste	Ensinas com uns dados, avalias com <i>outros</i> . Se avaliasse com os mesmos, media memória e não aprendizagem.
Linha de base	O método simples contra o qual comparas. Sem ele, um número não quer dizer nada.
Sobreajuste	O modelo decora o treino e falha no resto. É o que a divisão treino/teste deteta.
Calibração	Fazer com que “70%” queira mesmo dizer 70% das vezes.

Nível 0: a pergunta que te vão fazer e a resposta

“Isto aprende sozinho? Melhora com o tempo?”

Resposta

Não. O modelo foi treinado uma vez, sobre dados de 2018–2023, e está **congelado**. Quando corre em produção faz **inferência**, ou seja, aplica o que aprendeu, e **não** volta a aprender.

Três coisas diferentes que é fácil confundir:

treino (aprender dos exemplos, uma vez) $\neq$ **inferência** (aplicar, todos os dias) $\neq$ **re-treino** (voltar a treinar com dados novos, o que não é feito).

Nível 1: as três perguntas

- ❶ Isto é **invulgar?** estatística
- ❷ Foi a **empresa ou o mercado?** decomposição
- ❸ Já **aconteceu, e o que se seguiu?** recuperação e medição

Guarda esta frase

“As aplicações gratuitas mostram a percentagem, que é o *princípio* da primeira pergunta e não a resposta. Os terminais profissionais respondem às três e custam milhares por ano. **O problema não é científico, é de acesso.**”

Nível 1: o que o sistema recusa fazer

Não prevê preços. Não aconselha. Não gere carteiras.


Porque é que isto é uma força

Uma afirmação sobre o que **já aconteceu** confere-se contra o registo.

Uma previsão só se confere depois de já ter sido preciso decidir.

E há uma razão teórica: se o futuro fosse previsível a partir de informação *pública*, essa informação já estaria no preço.

Nível 1: e é isto que está no ar



Captura real, de 20 de agosto, com a sessão a decorrer.

- A **frase** vem antes do número: é a regra de apresentação.
- A **repartição** responde à segunda pergunta. Aqui a ação desce, mas o mercado e a empresa estavam em alta: quem a puxa é o **setor**.
- Os **pontos** na curva são dias que o detetor assinalou; as **setas**, os que deram alerta. A distância entre uns e outros é o custo das portas.

Nível 1: e o que nenhum produto mostra

A mesma página mostra, por baixo, **onde cada empresa parou** nesse dia.

Too old ¹ the newest relevant headline is past the freshness window	JPM newest is 2026-06-17, past 2 days
No strong past case ¹ no past headline was similar enough to be worth showing	AMD best match 0.42, floor 0.45
Same story, other words ¹ already sent today under a different headline	META sent under another headline
Already sent ⁵ this exact headline had already gone out today	AMZN same headline already delivered today GOOGL same headline already delivered today META same headline already delivered today MSFT same headline already delivered today TSLA same headline already delivered today
Daily budget spent ⁷ the five slots for the day were already used	AAPL all 5 slots used JNJ all 5 slots used JPM all 5 slots used MSFT all 5 slots used NFLX all 5 slots used NVDA all 5 slots used XOM all 5 slots used
Alert sent ⁵ cleared every gate and was delivered	AMZN Amazon Stock Moves Higher Wednesday: What's Going On? GOOGL Alphabet Stock: A Berkshire Hathaway-Style Compounder Hiding In Plain Sight META Meta Stock Climbs as Landmark Trial Threatens \$1.4 Trillion Penalties MSFT Comparative Study: Microsoft And Industry Competitors in Software Industry TSLA Elon Musk Is No Longer a Trillionaire, but He Could Still Give Every Person on E

Se te perguntarem “*e quando não envia nada?*”, é para aqui que apontas: nove em cada dez varreduras não enviam, e cada etapa diz a porta e a margem que faltou (a AMD parou em 0.42 contra um piso de 0.45).

Nível 2, técnica 1: o z-score, com contas

$$z = \frac{\text{movimento de hoje} - \text{média dos 20 dias}}{\text{desvio-padrão dos 20 dias}}$$

Exemplo real (Tesla, 24 out 2024):

Média dos 20 dias anteriores	-0,92%
Desvio-padrão desses 20 dias	2,72%
Movimento do dia	+19,82%
$z = (19,82 - (-0,92))/2,72$	+7,61

Faz esta conta à mão uma vez. Se te pedirem para a explicar no quadro, tens de a saber fazer.

Nível 2: a parte que te vão testar

“Porque é que o dia de hoje não entra no cálculo da sua própria norma?”

Resposta

Porque se entrasse, um dia extremo puxava a média e aumentava o desvio-padrão, e ficaria a parecer **menos** invulgar do que foi.

Isso seria usar informação que, no momento da decisão, ainda não devia contar. Chama-se **lookahead**, e é o erro mais comum em modelos financeiros.

Na tese isto é garantido por **um teste automático**, não por uma promessa: o teste altera o futuro e exige que as *features* fiquem iguais e o rótulo mude.

Nível 2, técnica 2: foi a empresa, ou foi o mercado?

Responde à **segunda** das três perguntas, e é a que um arguente com finanças conhece.

- **A conta:** o movimento do dia parte-se em três parcelas que **somam ao total**: *mercado* (o beta vezes o índice), *setor* (o fundo do setor, já descontado do mercado) e *empresa* (o que sobra).
- **Os betas** são estimados só com dias **anteriores** ao dia explicado, e **encolhidos** para 1 na proporção da sua própria precisão (Vasicek, 1973).
- **Porquê encolher:** sem isso, um beta mal estimado atribuía o movimento inteiro à empresa.

O que dizes se te perguntarem se estás certa

“As parcelas somam sempre, por construção, portanto isso não prova nada. Medi as duas coisas que podiam falhar: se a repartição **discrimina** (num mesmo dia o motor foi a empresa em 8 casos, o mercado em 5 e o setor em 4, logo não diz sempre o mesmo) e se os **betas** estão bem estimados (R^2 mediano 0.460, e **numa das dezassete foi negativo**). E não há verdade humana para comparar: é por isso que esta técnica não dá origem a uma pergunta de investigação.”

Nível 3, técnica 3: frases como pontos

- Um **embedding** é uma lista de números que representa uma frase: aqui, **384**.
- Funciona como uma **coordenada de significado**: frases parecidas ficam perto.
- Compara-se pelo **cosseno**: o **ângulo** entre duas direções, entre -1 e 1 .

Porquê o ângulo e não a distância?

Porque interessa *sobre o que* a frase fala, não o comprimento do texto. Um título curto e um parágrafo longo sobre o mesmo assunto devem ficar próximos.

O modelo não é teu: é pré-treinado (Sentence-BERT). Diz isso; está declarado na tese.

Nível 3: tema não é direção

É a ressalva mais importante desta técnica.

Duas notícias podem ser sobre **o mesmo assunto** e o preço ter ido para **lados opostos**.

Medido

Concordância de direção entre a notícia e os casos recuperados: **0.708**

Chão de acaso: **0.688**

Ou seja: **quase nada**.

É por isso que o sistema mostra os casos **um a um** e nunca só a média. Uma média esconderia que foram em sentidos opostos.

Nível 4, técnica 4: o teu modelo

- **79 753** exemplos que construístes (notícias 2018–2023 + preços).
- **Rótulo:** houve movimento anormal $\geq 2\%$ nos 3 dias seguintes? **Em valor absoluto**, nunca a direção.
- **Divisão cronológica** 70/15/15, com **embargo** de 5 dias entre blocos.
- **Calibração** de Platt, ajustada na validação.

Porquê o embargo?

O rótulo olha 3 dias para a frente. Uma notícia no último dia de treino tem o rótulo determinado por dias que já são do bloco seguinte. Deitam-se fora os dias de fronteira.

Nível 4: o resultado, e como o defendes

Nenhum modelo que lê o texto bate a volatilidade sozinha.
0,496 contra 0,542

Se te disserem “então o vosso modelo falhou”

“O modelo não falhou: a hipótese foi testada e a resposta foi não. Escrevi o critério **antes** de correr a experiência, e verifiquei por três caminhos: re-teste em condições favoráveis ao texto, reamostragem por grupos, e **nove** definições diferentes do rótulo. A volatilidade ganha nas nove. Um trabalho que só reporta o que corre bem não é uma avaliação.”

Nível 4: e a metade da resposta que quase ficou por medir

Todas as comparações acima põem as variantes **lado a lado**: respondem a *qual é melhor*.
Falta a outra pergunta, e é a mais útil para quem constrói:

o texto acrescenta ao que já se sabe da empresa?

Medido **por cima** da tabela de consulta, que sabe tudo da empresa e nada da notícia:

+0,012 de PR-AUC, IC [+0,004, +0,020] — **exclui zero**

É a única vez neste trabalho em que uma representação de texto mostra valor mensurável.

Mas o veredicto não muda, e dizes tu porquê antes que perguntem

1. 0,547 vs 0,542, e o intervalo da diferença **contém zero** — não digas que ganha;
2. a precisão no orçamento é 0,662 com e sem texto;
3. continua a não separar dois dias da mesma empresa.

*Não é uma ressalva, é uma **localização**: o texto distingue **empresas**, e o produto precisava que distinguísse **notícias**.*

Nível 5: os números de cor

0.015 vs 0.344	amplitude de disparo: z-score vs limiar fixo	QI1
0.530 / 0.269 / 0.280	F_1 : z-score vs Isolation Forest vs LOF	QI1
0.514 vs 0.467	precisão@5: significado vs <i>sempre tecnologia</i>	QI2
0.346 / 0.240	idem: palavras em comum / acaso uniforme	QI2
0.595	precisão@5 no corpus completo (80 mil)	QI2
0.708 vs 0.688	concordância de direção vs acaso (tema $\neq$ direção)	QI2
0.542 vs 0.496	PR-AUC: só volatilidade vs contexto+texto	QI3
+0.012 IC [+0.004, +0.020]	o texto por cima da tabela de consulta : acrescenta	QI3
9 de 9	células da grelha em que a volatilidade ganha	QI3
0.379 → 0.632	precisão no orçamento: acaso → modelo ($1,67\times$)	QI3
0.662	o prior de 13 constantes, que bate o modelo	QI3
84%	decisões determinadas pela empresa , não pela notícia	QI3
0.064 vs 0.385	variação do score dentro vs entre empresas ($6,1\times$)	QI3
79 753	exemplos do teu conjunto de dados	—
88,5%	dias invulgares com notícia captada (limite superior)	limitação
944 → 42	funil de produção: captadas → enviadas	sistema

Nível 5: o número que NÃO debes dizer

Não digas “quadruplica”.

O 0,163 do “alertar sempre” **não media escolher às cegas**: com todas as pontuações empatadas, a métrica desempata pela ordem do ficheiro, que está ordenado por data e nome da empresa. Media **escolher por ordem alfabética**.

O que dizes

“Contra um chão que escolhe mesmo ao acaso (0,379), o ganho é de **1.67 vezes**. Encontrei o erro a verificar o que a minha própria linha de base media, e corriji-o. Está na matriz de evidência.”

Nível 5: mais dois enganos fáceis de cometer

Não digas “a precisão ao vivo foi de 0.667 contra 0.455”

Esse par existiu, e foi **retirado**: eram **12 decisões**, com intervalo de confiança a 95% de $[0.391, 0.862]$, que **contém** a taxa-base. Refeito sobre o registo inteiro, hoje com **825** decisões maturadas, o sinal **inverte-se**: mantidas 0.589 contra suprimidas 0.617.

O que dizes: “uma percentagem sobre uma amostra pequena não é um resultado, e retirei-a”. A lição vale mais do que o número valia.

Não digas “RQ”

A tese longa tinha **quatro RQ**. Esta tem **três QI**, e a correspondência não é um para um: a antiga RQ3, sobre a utilidade das explicações, **não existe** aqui, porque não foi feito estudo com pessoas. $RQ1 \rightarrow QI1$, $RQ2 \rightarrow QI2$, $RQ4 \rightarrow QI3$.

Os documentos de defesa antigos ainda dizem RQ. Traduz antes de responder.

Nível 6: perguntas do júri (1/3)

“Onde está a engenharia de IA? Isto são bibliotecas.”

“Está no que foi **medido para decidir**. Construí três alternativas e não implantei duas delas porque a medição não as sustentou. A engenharia está em ter um critério capaz de dizer não.”

“Qual é a contribuição, se os modelos já existiam?”

“A integração avaliada. Nenhum algoritmo é novo. O que é novo é um sistema que responde às três perguntas a custo zero, com cada afirmação rastreável ao procedimento que a produziu, e com os resultados negativos reportados tal como caíram.”

Nível 6: perguntas do júri (2/3)

“Não bastava perguntar a um ChatGPT?”

“Um assistente genérico não tem a volatilidade daquela ação, não separa a empresa do mercado, e não *recupera* casos passados. No melhor dos casos *recorda* do treino, o que não é verificável. E a saída dele é uma afirmação; a minha vem com a evidência ao lado.”

“Como sabe que não há informação do futuro nas features?”

“Não sei por promessa: sei por teste. Há um teste que altera o futuro e exige duas condições ao mesmo tempo: que as features fiquem **iguais** e que o rótulo **mude**. Se alguma informação futura se tivesse infiltrado, o teste falha.”

Nível 6: perguntas do júri (3/3)

“Fez estudo com utilizadores?”

“**Não.** O desenho está feito (participantes, tarefas, critérios), mas não foi corrido a tempo. Por isso não afirmo nada sobre utilidade: a fidelidade está garantida por construção, a utilidade fica em aberto e está escrito assim na tese.”

Nunca inventes participantes nem opiniões. É a única resposta que te pode custar o grau.

“Os alertas parecem falhar notícias importantes.”

“Parte disso está medido: havia notícia captada em 88,5% dos dias invulgares, e a empresa pior coberta fica-se pelos 50%. E é um **limite superior**: pergunta se existia *uma* notícia, não se chegou *a certa*. Saber isso exige julgamento humano dia a dia, e é o primeiro trabalho futuro que aponto.”

Nível 6: a pergunta mais dura, e a tua melhor resposta

“O vosso modelo não serve para nada, então?”

“Serve para o que a medição sustenta: **ordenar** empresas. Não serve para o que eu lhe estava a pedir. Medi o que ele fazia quando decidia e a pontuação varia **0.064** dentro de cada empresa e **0.385** entre empresas: o limiar estava a separar empresas, não títulos. Em **84%** das decisões o resultado estava determinado antes de a notícia ser lida.”

“E porque não puseram o limiar relativo a cada empresa?”

“Simulei isso **antes** de mexer no código. Resolve metade, e cria outro problema: nas empresas de pontuação quase constante o percentil cai em cima da constante e quase tudo empata acima. Uma delas passaria **874** vezes. Não se corrige um defeito introduzindo o defeito vizinho.”

Se te perguntarem só uma coisa sobre a QI3, é esta. Diz sempre a segunda parte: mostra que testaste a correcção óbvia em vez de a assumir.

Se te esqueceres de tudo, guarda isto

Duas respostas de sim, uma de não.

E um erro meu, encontrado por mim e corrigido.

“A parte difícil não foi escolher a técnica mais avançada.
Foi montar a avaliação capaz de dizer que ela não era precisa.”