



Instituto Superior de
Engenharia do Porto



DEPARTAMENTO DE ENGENHARIA
INFORMÁTICA

Alertas Financeiros Explicáveis para Investidores de Retalho: Detecção de Anomalias, Recuperação de Precedentes e Triagem Aprendida

Henrique José da Silva Santos

Aluno nº: 1180934

**Dissertação para obtenção do Grau de
Mestre em Engenharia de Inteligência Artificial**

Orientador: Luís Gomes
Co-Orientador: Rafael Silva

Júri:

Presidente:
[A definir]

Vogais:
[A definir]

Porto, 15 de agosto de 2026

Declaração de Integridade

Declaro que realizei este trabalho acadêmico com integridade.

Não recorri a plágio nem a qualquer forma de utilização indevida ou falsificação de informações ou resultados ao longo do processo que conduziu à sua elaboração.

Declaro, por isso, que este documento é original e da minha autoria, não tendo sido utilizado anteriormente para qualquer outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

Uso de Inteligência Artificial. Em conformidade com as orientações do P.PORTO/ISEP, declaro que foram utilizadas ferramentas de inteligência artificial generativa ao longo do desenvolvimento deste trabalho, e declaro-o na sua extensão real. Foram usadas para escrever e reestruturar parte substancial do código do sistema e dos seus testes, para implementar os procedimentos de avaliação, para redigir e editar prosa neste documento, e para conduzir revisões que encontraram defeitos no software e no texto.

O que é meu é o trabalho para onde essas ferramentas foram apontadas: a escolha do problema, as questões de investigação, as restrições que definem o sistema (apenas fontes gratuitas, explicabilidade primeiro, e a recusa de prever preços), e todas as decisões sobre o que construir, manter ou descartar. Sempre que uma medição contrariou uma afirmação minha, retirei a afirmação em vez de a defender. Revi o conteúdo deste documento, e ele, os erros que nele restem, e a sua defesa são da minha responsabilidade.

ISEP, Porto, 15 de agosto de 2026

Dedicatória

À minha família.

Resumo

Quando uma ação se move de forma abrupta, um investidor não profissional faz sempre as mesmas três perguntas: *isto é invulgar?*, *foi a empresa ou foi o mercado?*, e *já aconteceu antes, e o que se seguiu?* As ferramentas gratuitas mostram a percentagem e ficam-se por aí; os terminais profissionais respondem, mas a um custo fora do alcance de quem investe as suas poupanças.

Esta dissertação apresenta o **InvestiGator**, um sistema de alertas financeiros construído sobre fontes de dados gratuitas, que responde às três perguntas e mostra sempre como chegou à resposta. O trabalho assenta em três técnicas: deteção de anomalias por z-score deslizante, recuperação de precedentes por semelhança semântica com medição do desfeito observado, e um modelo supervisionado de triagem, treinado sobre um conjunto de dados próprio, para decidir que notícias merecem interromper alguém.

Cada componente foi avaliado contra linhas de base transparentes, e os resultados são reportados tal como se revelaram. A deteção normalizada pela volatilidade dispara de forma muito mais consistente entre empresas do que um limiar fixo. A recuperação semântica supera as linhas de base lexical e triviais. O modelo de triagem, treinado em 79 753 exemplos, **não** superou uma linha de base que usa apenas volatilidade — um resultado negativo que se reporta, e que valida por medição a opção pela simplicidade que atravessa todo o trabalho.

O sistema recusa, por desenho, prever preços: explica o que já aconteceu, com a evidência ao lado. **Palavras-chave:** IA Explicável, Alertas Financeiros, Deteção de Anomalias,

Recuperação Semântica, Investidores de Retalho

Abstract

When a stock moves abruptly, a non-professional investor always asks the same three questions: *is this unusual?*, *was it the company or the market?*, and *has this happened before, and what followed?* Free tools show the percentage and stop there; professional terminals do answer, at a subscription cost beyond someone investing their savings.

This dissertation presents **InvestiGator**, a financial alerting system built on free data sources that answers those three questions and always shows how it reached the answer. The work rests on three techniques: anomaly detection with a rolling z-score, precedent retrieval by semantic similarity with measurement of the observed outcome, and a supervised triage model, trained on a purpose-built dataset, to decide which news deserves interrupting someone.

Each component was evaluated against transparent baselines, and the results are reported exactly as they fell. Volatility-normalised detection fires far more consistently across companies than a fixed threshold. Semantic retrieval beats lexical and trivial baselines. The triage model, trained on 79 753 examples, did **not** beat a volatility-only baseline — a negative result that is reported, and that validates by measurement the simplicity-first stance running through the work.

By design, the system refuses to predict prices: it explains what already happened, with the evidence beside it. **Keywords:** IA Explicável, Alertas Financeiros, Detecção de Anomalias,

Recuperação Semântica, Investidores de Retalho

Agradecimentos

Ao meu orientador, Prof. Luís Gomes, e ao meu coorientador, Rafael Silva, por todo o apoio ao longo desta tese. Por trocarem ideias comigo e me ajudarem a decidir a direção do tema; por me mostrarem exemplos de aplicações que já existem e me manterem a par do que se vai fazendo na área; e por me guiarem na elaboração deste documento. Muito do que aqui está tomou a forma que tem porque houve antes uma conversa com eles.

À minha família, por todo o apoio e por acreditarem em mim. Por me incentivarem sempre, e pela alegria com que foram acompanhando a construção disto — que é, para mim, a melhor parte de o ter feito.

Aos meus colegas da Sistrade, e à Sistrade, pela flexibilidade que me permitiu seguir este mestrado a par do trabalho, pelas opiniões e pelo feedback que foram dando sobre a aplicação, e por serem boa companhia todos os dias.

Índice

Lista de Acrónimos	xix
1 Introdução	1
1.1 De onde veio este trabalho	1
1.2 O que o sistema faz, numa página	1
1.3 Objetivos e perguntas de investigação	3
1.4 Contribuições	3
1.5 Como ler este documento	4
2 Contexto	5
3 Metodologia	7
3.1 As três decisões	7
3.2 Técnica 1: detetar o que é invulgar	7
3.2.1 O problema, em palavras	7
3.2.2 A ideia: medir em desvios-padrão	8
3.2.3 A janela que anda, e a regra que a protege	8
3.2.4 Um caso real	9
3.3 Técnica 2: encontrar casos parecidos	9
3.3.1 O problema, em palavras	9
3.3.2 A ideia: transformar frases em pontos	10
3.3.3 Medir a distância: o cosseno	10
3.3.4 Medir o que se seguiu	10
3.4 Técnica 3: decidir o que merece um alerta	11
3.4.1 O problema, em palavras	11
3.4.2 A tarefa e o rótulo	12
3.4.3 O que o modelo vê	12
3.4.4 Treinar sem fazer batota com o tempo	12
3.4.5 Da pontuação à probabilidade: calibração	13
3.5 Como é que se sabe que isto funciona	13
4 O Sistema	15
5 Avaliação	17
6 Conclusões	19
Bibliografia	21
A Reprodutibilidade	23

Lista de Figuras

1.1	Capitalização do mercado acionista dos EUA	2
1.2	O que o sistema faz	2
3.1	As três decisões do sistema	7
3.2	A janela deslizando do z-score	8
3.3	Frases como pontos num espaço	10
3.4	Como se mede o impacto de uma notícia	11
3.5	Divisão temporal com embargo	12

Lista de Tabelas

3.1	O z-score de um dia real, passo a passo (Tesla, 24 de outubro de 2024).	9
-----	---	---

Lista de Acrónimos

QI Questão de Investigação.

Capítulo 1

Introdução

1.1 De onde veio este trabalho

Que problema é este, e porque é que vale a pena resolvê-lo?

Hoje é fácil comprar ações. Basta uma aplicação no telemóvel e alguns minutos. A maior parte das famílias americanas já tem ações, diretamente ou através de fundos e planos de reforma (Gallup 2025), e o mercado onde investem vale mais de 62 biliões de dólares (Securities Industry and Financial Markets Association (SIFMA) 2025).

Difícil é a parte seguinte: perceber o que aconteceu quando o preço se mexe.

Imagine-se uma pessoa que tem cinco ou seis ações e olha para elas de vez em quando. Um dia abre a aplicação e vê uma delas a cair 4%. A aplicação diz-lhe exatamente isso: menos 4%. E mais nada.

A partir daí a pessoa fica sozinha com três perguntas, e faz sempre estas três, por esta ordem:

1. **Isto é invulgar?** Quatro por cento numa empresa calma é muito. Na mesma semana, e noutra empresa, pode ser um dia perfeitamente normal.
2. **Foi a empresa, ou foi o mercado?** Se caiu tudo, a história é uma. Se caiu só esta, é outra completamente diferente.
3. **Já aconteceu antes, e o que se seguiu?** Se já houve dias parecidos, o que fez o preço a seguir?

As aplicações gratuitas não respondem a nenhuma das três. Mostram a percentagem, que é o princípio da primeira pergunta e não a resposta. Os terminais profissionais respondem às três, mas custam mais por mês do que muita gente investe por ano.

É essa distância que este trabalho tenta encurtar. Não por falta de dados — há dados a mais, e gratuitos. Por falta de **contexto**, e de um contexto que a pessoa possa *verificar*.

1.2 O que o sistema faz, numa página

Se tivesse de explicar o InvestiGator numa frase, qual seria?

Esta: **o sistema vigia um conjunto de empresas, deteta quando algo sai fora do normal, e avisa — mas só avisa com a explicação e a evidência ao lado.**




Figura 1.1: Capitalização do mercado acionista dos EUA, 2015–2024, em biliões de dólares. É neste mercado que investem as pessoas de quem este trabalho fala. Elaborado a partir dos dados do SIFMA Capital Markets Fact Book (Securities Industry and Financial Markets Association (SIFMA) 2025).

Há duas maneiras de o sistema começar a prestar atenção, e estão na Figura 1.2. Ou o **preço** se mexe de forma invulgar, ou chega uma **notícia** relevante sobre uma das empresas. Em qualquer dos casos, o que sai do outro lado não é uma notificação seca. É um alerta que diz o que aconteceu, porque é que foi considerado invulgar, de onde vieram os dados, e que casos parecidos já existiram no passado — com o que o preço fez depois deles.




Figura 1.2: Os dois gatilhos e o que sai deles. O que o investidor recebe é um alerta que ele consegue seguir e conferir, e não apenas um aviso de que o preço mexeu.

E o que o sistema recusa fazer

Há uma coisa que este sistema não faz, e não é por não ter dado jeito: **não prevê preços**.

Nunca diz que uma ação vai subir. Nunca diz para comprar ou para vender. Nunca mostra um alvo de preço.

Isto pode parecer uma limitação. É o contrário: é o que torna tudo o resto verificável. Uma afirmação sobre o que *já* aconteceu pode ser conferida contra o registo. Uma previsão não pode ser conferida por ninguém, nem no momento em que é feita nem depois. Ao recusar prever, o sistema obriga-se a dizer só coisas que consegue mostrar.

1.3 Objetivos e perguntas de investigação

O que é que este trabalho se propõe descobrir?

O objetivo geral é **desenhar, construir e avaliar** um sistema de alertas financeiros explicável para investidores de retalho, usando apenas fontes de dados gratuitas.

Para lá chegar, o trabalho responde a três perguntas de investigação. Cada uma tem uma medição associada, porque uma pergunta a que não se sabe responder com um número não é uma pergunta de investigação — é uma opinião.

- **Questão de Investigação (QI)1 — deteção.** Consegue um método estatístico simples e transparente detetar movimentos invulgares de forma consistente entre empresas com volatilidades muito diferentes, e fazê-lo melhor do que uma regra fixa?
- **QI2 — precedentes.** Consegue o sistema encontrar notícias passadas genuinamente parecidas com a atual, melhor do que alternativas triviais, e medir o que aconteceu ao preço a seguir a elas sem usar informação do futuro?
- **QI3 — triagem.** Consegue um modelo treinado decidir que notícias merecem um alerta melhor do que uma linha de base simples baseada apenas em volatilidade?

Estas três perguntas dão origem a quatro objetivos concretos:

1. construir o sistema completo, dos dados até ao alerta entregue;
2. avaliar cada componente contra linhas de base transparentes;
3. garantir que as explicações são fiéis ao que o sistema realmente calculou;
4. reportar os resultados tal como se revelarem, incluindo os que forem negativos.

O quarto objetivo é o mais importante e é o mais fácil de trair. Voltarei a ele no Capítulo 6.

1.4 Contribuições

O que é que fica feito no fim?

Esta é uma dissertação de **Engenharia de Inteligência Artificial**. A contribuição não é inventar um algoritmo novo. É escolher, integrar e avaliar criticamente técnicas que já existem, até formarem um sistema que funciona, que se explica, e que outra pessoa consegue reproduzir. Escolher bem é o trabalho de engenharia.

Ficam quatro coisas:

1. **Um sistema completo e a funcionar**, com os dois gatilhos, sobre fontes gratuitas, e implantado — não uma demonstração de laboratório.
2. **Um método reprodutível para ligar notícias a impacto de mercado**, que combina recuperação por semelhança semântica com janelas de estudo de evento, sem deixar entrar informação do futuro.
3. **Um conjunto de dados próprio e um modelo treinado sobre ele**: 79 753 exemplos construídos a partir de notícias e preços históricos, com o modelo, a calibração e as métricas guardados como artefactos versionados.

4. **Uma avaliação honesta de cada componente** contra linhas de base transparentes — incluindo o resultado que me correu ao contrário, que está reportado como tal.

1.5 Como ler este documento

Por onde é que isto vai?

O documento foi escrito para ser lido de fio a pavio, e cada capítulo responde a uma pergunta:

- **Capítulo 2 — Contexto:** o que já existe, e porque é que não chega para o problema desta tese.
- **Capítulo 3 — Metodologia:** as três técnicas, explicadas devagar e com desenhos.
- **Capítulo 4 — O sistema:** como as peças se ligam, e uma notícia real seguida do princípio ao fim.
- **Capítulo 5 — Avaliação:** o que foi medido, contra o quê, e com que resultado.
- **Capítulo 6 — Conclusões:** o que ficou provado, o que ficou por fazer, e o que eu faria a seguir.

Há um fio que atravessa os capítulos 3 a 5: **a mesma notícia real**, seguida desde o momento em que chega até ao alerta que sai. Sempre que aparecer, é a mesma. Serve para que nada aqui fique abstrato.

Capítulo 2

Contexto

Por escrever.

Capítulo 3

Metodologia

3.1 As três decisões

O que é que o sistema tem mesmo de decidir?

Tudo o que este trabalho faz cabe em três decisões. Estão na Figura 3.1 e são sempre as mesmas, por esta ordem.




Figura 3.1: As três decisões, e a família de técnicas que responde a cada uma. Cada secção deste capítulo trata de uma coluna.

Cada decisão é tratada com a técnica mais simples que consegue resolvê-la. Isto não é preguiça: é uma escolha de desenho que se paga no Capítulo 5, onde cada técnica é comparada com alternativas mais complicadas. Quando a simples ganha, fica a simples — e diz-se porquê.

3.2 Técnica 1: detetar o que é invulgar

Como é que um computador decide que 4% é muito?

3.2.1 O problema, em palavras

Não é possível responder com um número fixo.

Uma regra do género “avisar sempre que uma ação se mexer mais de 3%” parece razoável e é má. Para uma empresa calma, como uma cadeia de supermercados, 3% é um acontecimento raro. Para uma empresa volátil, como uma tecnológica em crescimento, 3% acontece muitas vezes por mês. A mesma regra dá quase nenhum alerta na primeira e alertas quase todos os dias na segunda.

O que interessa não é o tamanho do movimento. É o tamanho do movimento **comparado com o que é normal para aquela empresa**.

3.2.2 A ideia: medir em desvios-padrão

A solução é velha e boa, e é a forma mais comum de detetar anomalias em séries temporais (Chandola, Banerjee e Kumar 2009): em vez de comparar com um número fixo, comparo com o comportamento recente da própria ação.

Olho para os últimos vinte dias e pergunto duas coisas: *quanto é que esta ação costuma mexer?* e *quão longe do costume ficou hoje?* A resposta chama-se **z-score**:

$$z_t = \frac{r_t - \mu}{\sigma} \quad (3.1)$$

Termo a termo:

- r_t é o retorno de hoje — quanto a ação subiu ou desceu;
- μ (mu) é a **média** dos retornos dos vinte dias anteriores: o “centro” do que é normal;
- σ (sigma) é o **desvio-padrão** desses vinte dias: uma medida de quanto a ação costuma oscilar à volta desse centro;
- z_t é o resultado: *a quantos desvios-padrão do normal ficou o dia de hoje*.

Um z de +1 quer dizer “um bocadinho acima do costume”. Um z de +7 quer dizer “isto quase nunca acontece”. E — o ponto todo — $z = +7$ significa a mesma coisa na empresa calma e na empresa volátil, porque cada uma é comparada consigo própria.

3.2.3 A janela que anda, e a regra que a protege

A Figura 3.2 mostra como isto funciona ao longo do tempo. A janela dos vinte dias desliza: para julgar o dia de hoje, usa os vinte dias *anteriores*; amanhã, desliza um dia.




Figura 3.2: A janela que define “o normal”. O dia que está a ser julgado **não entra** no cálculo da sua própria norma — e é esta separação que garante que o sistema nunca usa informação que ainda não teria.

Repare-se num pormenor da figura que parece pequeno e não é: **o dia que está a ser julgado não entra no cálculo da sua própria norma**. Se entrasse, um dia muito extremo puxaria a média e inflacionaria o desvio-padrão, e o próprio dia pareceria menos invulgar do que foi. O sistema estaria a usar informação que, no momento da decisão, ainda não devia contar.

Esta regra tem um nome — **evitar lookahead** — e atravessa todo o trabalho. Volto a ela na Secção 3.5, onde mostro como é imposta por um teste automático em vez de ser apenas prometida.

3.2.4 Um caso real

A Tabela 3.1 mostra o cálculo completo para o maior movimento do período estudado: a Tesla, a 24 de outubro de 2024, no dia a seguir aos resultados trimestrais.

Tabela 3.1: O z-score de um dia real, passo a passo (Tesla, 24 de outubro de 2024).

Quantidade	Valor
Média dos retornos dos 20 dias anteriores, μ	-0.92%
Desvio-padrão desses 20 dias, σ	2.73%
Retorno do dia, r_t	+19.82%
z-score, $(r_t - \mu)/\sigma$	+7.61
Sinalizado?	sim

Um movimento de quase 20% num dia é evidente para qualquer pessoa. O que a tabela mostra é *porquê*: não porque 20% seja um número grande em abstrato, mas porque é sete vezes e meia o que aquela ação costumava mexer naquelas semanas. É essa frase que o sistema consegue mostrar ao utilizador, e é a diferença entre avisar e explicar.

Há ainda um caso pequeno que vale a pena resolver bem: se uma ação não se mexeu *nada* durante vinte dias, o desvio-padrão é zero e a divisão da Equação 3.1 não existe. Nesse caso o sistema devolve $z = 0$ em vez de rebentar. Uma ação parada é descrita como não tendo nada de especial, que é exatamente o que se passa.

Em três frases. Comparo o dia de hoje com os vinte dias anteriores da mesma ação e conto a distância em desvios-padrão. Assim, o mesmo número significa a mesma coisa numa empresa calma e numa volátil. O dia julgado nunca entra no cálculo da sua própria norma.

3.3 Técnica 2: encontrar casos parecidos

Como é que o computador percebe que duas notícias falam da mesma coisa?

3.3.1 O problema, em palavras

Chega uma notícia: “Nvidia bate estimativas com procura de centros de dados”.

A pergunta útil é: *já houve notícias parecidas com esta, e o que fez o preço a seguir?*

A maneira ingénua de procurar é por palavras. Procurar notícias antigas que contenham “Nvidia”, “bate” e “estimativas”. Funciona mal, por duas razões simétricas:

- duas notícias podem dizer a **mesma coisa com palavras diferentes** — “supera previsões” e “bate estimativas” não partilham uma única palavra importante;
- duas notícias podem **partilhar palavras e falar de coisas diferentes** — “bate estimativas” e “bate recorde de despedimentos” partilham “bate”.

O que é preciso é comparar **significado**, não letras.

3.3.2 A ideia: transformar frases em pontos

É aqui que entra a única peça de aprendizagem profunda deste trabalho, e vale a pena explicá-la com calma porque é a que soa mais complicada e não é.

Um **modelo de embeddings de frase** (Reimers e Gurevych 2019) é um modelo já treinado que recebe uma frase e devolve uma lista de números — neste caso, 384 números. Essa lista chama-se *embedding*, e funciona como uma **coordenada**: é a posição daquela frase num espaço.

A propriedade que interessa é esta: o modelo foi treinado de forma a que frases com significado parecido fiquem **perto** umas das outras nesse espaço, mesmo que usem palavras diferentes. A Figura 3.3 mostra a ideia em duas dimensões (as verdadeiras são 384, que não se conseguem desenhar).




Figura 3.3: Cada frase vira um ponto. Frases com o mesmo significado ficam próximas, mesmo sem partilharem palavras; frases que partilham palavras (“bate”) mas falam de coisas diferentes ficam longe. O desenho tem duas dimensões para se poder ver — o modelo usa 384.

3.3.3 Medir a distância: o cosseno

Tendo duas frases como pontos, falta medir se estão perto.

A medida usada é a **semelhança do cosseno**. Em vez de medir a distância em linha reta, mede o **ângulo** entre as duas direções. Dá um valor entre -1 e 1 :

- perto de 1: as duas frases apontam na mesma direção — significado muito parecido;
- perto de 0: não têm relação;
- negativo: apontam em direções opostas.

Usa-se o ângulo e não a distância porque o que interessa é *sobre o que* a frase fala, e não o comprimento do texto. Uma manchete curta e um parágrafo longo sobre o mesmo assunto devem ficar próximos, e o ângulo dá isso.

3.3.4 Medir o que se seguiu

Encontrar notícias parecidas é metade. A outra metade é dizer o que aconteceu ao preço depois de cada uma delas.

3.4. Técnica 3: decidir o que merece um alerta

Para isso usa-se uma técnica clássica de finanças, o **estudo de evento** (Brown e Warner 1985): fixa-se o dia da notícia e mede-se a variação do preço 1, 3 e 5 dias depois. A Figura 3.4 mostra o alinhamento.




Figura 3.4: O impacto é medido a partir do *fecho* do dia da notícia. Se a notícia sai num sábado, o dia d é o primeiro dia de bolsa seguinte. É uma **medição do que aconteceu**, não uma previsão.

Duas decisões de detalhe, ambas com consequência:

1. **Se a notícia sai fora de dias de bolsa**, o dia d é o primeiro dia de negociação igual ou posterior. Sem esta regra, uma notícia de sábado não teria a que se agarrar.
2. **A medição começa no fecho de d** , não na abertura. É a opção conservadora: não atribui à notícia a parte do movimento que já tinha acontecido antes de ela ser lida.

E vale a pena dizer aquilo que isto **não** é. Medir o que aconteceu a seguir a notícias passadas não é prever o que vai acontecer agora. É por isso que o sistema mostra sempre os casos *um a um*, com a data e o valor de cada um, em vez de resumir tudo a uma média — uma média esconde que os casos podem ter ido em sentidos opostos.

Em três frases. Um modelo já treinado transforma cada manchete numa lista de 384 números que funciona como uma coordenada de significado. Comparo manchetes pelo ângulo entre essas coordenadas, o que apanha frases parecidas mesmo com palavras diferentes. Para cada caso passado, meço o que o preço fez 1, 3 e 5 dias depois — uma medição, não uma previsão.

3.4 Técnica 3: decidir o que merece um alerta

Já sei que algo é invulgar. Devo mesmo interromper alguém?

3.4.1 O problema, em palavras

Chegam muitas notícias. A maioria não interessa: repetições, listas automáticas, textos que mencionam a empresa de passagem.

Um sistema que avisa de tudo é tão inútil como um que não avisa de nada — pior, até, porque ensina a pessoa a ignorar o canal. Este problema tem nome, **fadiga de alertas**, e é a razão pela qual esta terceira decisão existe.

Aqui, ao contrário das duas anteriores, não há uma fórmula óbvia. É o sítio natural para **aprender a partir dos dados**.

3.4.2 A tarefa e o rótulo

Para treinar um modelo é preciso, antes de tudo, uma pergunta com resposta conhecida.

A pergunta escolhida foi: *depois desta notícia, houve um movimento anormalmente grande no preço?* A resposta — o **rótulo** — constrói-se assim:

1. mede-se o retorno da ação nos três dias seguintes à notícia;
2. subtrai-se o movimento do mercado no mesmo período, para não confundir “a empresa mexeu-se” com “mexeu-se tudo”;
3. se o que sobra for maior do que 2% em valor absoluto, o rótulo é 1; caso contrário, 0.

Repare-se em **valor absoluto**. O rótulo diz se houve movimento *grande*, e nunca em que **direção**. Isto é deliberado e é a fronteira que o trabalho não atravessa: o modelo aprende sobre *materialidade*, não sobre subir ou descer.

3.4.3 O que o modelo vê

O modelo recebe cinco tipos de informação sobre o momento da notícia:

- **volatilidade recente** — quanto a ação tem oscilado nos últimos 20 dias;
- **momento** — como se comportou nos últimos 5 dias;
- **o movimento do próprio dia**;
- **o comprimento da manchete**;
- **o setor** da empresa.

E, numa das variantes testadas, também o *embedding* da manchete — os mesmos 384 números da Secção 3.3. Comparar a variante com texto e a variante sem texto é precisamente o que a Q13 pergunta, e a resposta está no Capítulo 5.

3.4.4 Treinar sem fazer batota com o tempo

Esta é a parte onde é mais fácil enganar-se a si próprio, por isso vale a pena o desenho da Figura 3.5.




Figura 3.5: Os dados são divididos **por ordem cronológica**, nunca ao acaso. Entre blocos há um *embargo* de cinco dias, porque o rótulo de uma notícia olha até três dias para a frente e sem o embargo o fim do treino tocava no princípio do teste.

Duas regras, e as duas existem para impedir que o modelo pareça melhor do que é:

Dividir pelo tempo, não ao acaso. Se os dados fossem baralhados, o modelo treinaria com notícias de 2023 e seria testado com notícias de 2019 — estaria a ser avaliado sobre

3.5. Como é que se sabe que isto funciona

um passado que já conhece. Aqui, treina-se no início do período e testa-se no fim, como acontece na realidade.

Embargo entre blocos. O rótulo de uma notícia depende dos três dias seguintes. Uma notícia no último dia de treino tem o seu rótulo determinado por dias que já pertencem ao bloco seguinte. Deitam-se fora os cinco dias de fronteira, e diz-se quantas linhas isso custou.

3.4.5 Da pontuação à probabilidade: calibração

O modelo devolve uma pontuação. Uma pontuação alta não é, por si só, uma probabilidade: dizer 0.8 não garante que aconteça em 8 de cada 10 casos.

Como o número vai ser mostrado a uma pessoa, isso tem de ser corrigido. O passo chama-se **calibração** (Niculescu-Mizil e Caruana 2005): ajusta-se uma função simples que transforma pontuações em probabilidades *honestas*, de modo a que, entre todos os casos a que o modelo dá 70%, cerca de 70% tenham mesmo acontecido. A calibração é ajustada no bloco de validação — nunca no de teste.

Em três frases. Treinei um modelo para estimar se uma notícia é seguida de um movimento anormalmente grande, em qualquer direção. Os dados são divididos pelo tempo, com um embargo entre blocos, para o modelo nunca ser avaliado sobre um futuro que já viu. A pontuação é calibrada, para o número mostrado ao utilizador querer dizer o que parece querer dizer.

3.5 Como é que se sabe que isto funciona

O que impede um resultado bonito de ser um resultado enganador?

Três compromissos, assumidos *antes* de correr as experiências.

Primeiro: comparar sempre com o mais simples. Um número sozinho não diz nada. Dizer que a recuperação acerta em metade dos casos só significa alguma coisa quando se sabe o que acertaria uma alternativa trivial. Por isso cada técnica é comparada com **linhas de base** — uma regra fixa, uma escolha ao acaso, a notícia mais recente. Se a técnica sofisticada não ganhar, isso é o resultado, e é o que fica escrito.

Segundo: o não-lookahead é imposto por um teste, não prometido. É fácil escrever “não usámos informação do futuro”. É difícil garanti-lo. Aqui existe um teste automático que faz o seguinte: pega num exemplo, **altera artificialmente o futuro** e volta a calcular. Depois exige duas coisas ao mesmo tempo — que as *features* fiquem exatamente iguais (porque descrevem o passado) e que o *rótulo* mude (porque descreve o futuro). Se alguma informação do futuro se tivesse infiltrado nas features, o teste falha.

Terceiro: reportar o que sair. O critério de sucesso de cada experiência foi escrito antes de a correr. Onde o resultado contrariou o que se esperava, fica reportado como se revelou. O Capítulo 5 tem um caso desses, e é o mais interessante dos três.

Capítulo 4

O Sistema

Por escrever.

Capítulo 5

Avaliação

Por escrever.

Capítulo 6

Conclusões

Por escrever.

Bibliografia

- Brown, Stephen J. e Jerold B. Warner (1985). «Using Daily Stock Returns: The Case of Event Studies». Em: *Journal of Financial Economics* 14.1, pp. 3–31. doi: 10.1016/0304-405X(85)90042-X.
- Chandola, Varun, Arindam Banerjee e Vipin Kumar (2009). «Anomaly Detection: A Survey». Em: *ACM Computing Surveys* 41.3, 15:1–15:58. doi: 10.1145/1541880.1541882.
- Gallup (2025). *What Percentage of Americans Own Stock?* url: <https://news.gallup.com/poll/266807/percentage-americans-owns-stock.aspx> (acedido em 21/06/2026).
- Niculescu-Mizil, Alexandru e Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». Em: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, pp. 625–632. doi: 10.1145/1102351.1102430.
- Reimers, Nils e Iryna Gurevych (2019). «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». Em: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. doi: 10.18653/v1/D19-1410.
- Securities Industry and Financial Markets Association (SIFMA) (2025). *2025 Capital Markets Fact Book*. url: <https://www.sifma.org/resources/research/fact-book/> (acedido em 21/06/2026).

Apêndice A

Reprodutibilidade

Por escrever.