



Instituto Superior de
Engenharia do Porto



DEPARTAMENTO DE ENGENHARIA
INFORMÁTICA

Alertas Financeiros Explicáveis para Investidores de Retalho: Detecção de Anomalias, Recuperação de Precedentes e Triagem Aprendida

Henrique José da Silva Santos

Aluno nº: 1180934

**Dissertação para obtenção do Grau de
Mestre em Engenharia de Inteligência Artificial**

Orientador: Luís Gomes
Co-Orientador: Rafael Silva

Júri:

Presidente:
[A definir]

Vogais:
[A definir]

Porto, 15 de agosto de 2026

Declaração de Integridade

Declaro que realizei este trabalho acadêmico com integridade.

Não recorri a plágio nem a qualquer forma de utilização indevida ou falsificação de informações ou resultados ao longo do processo que conduziu à sua elaboração.

Declaro, por isso, que este documento é original e da minha autoria, não tendo sido utilizado anteriormente para qualquer outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

Uso de Inteligência Artificial. Em conformidade com as orientações do P.PORTO/ISEP, declaro que foram utilizadas ferramentas de inteligência artificial generativa ao longo do desenvolvimento deste trabalho, e declaro-o na sua extensão real. Foram usadas para escrever e reestruturar parte substancial do código do sistema e dos seus testes, para implementar os procedimentos de avaliação, para redigir e editar prosa neste documento, e para conduzir revisões que encontraram defeitos no software e no texto.

O que é meu é o trabalho para onde essas ferramentas foram apontadas: a escolha do problema, as questões de investigação, as restrições que definem o sistema (apenas fontes gratuitas, explicabilidade primeiro, e a recusa de prever preços), e todas as decisões sobre o que construir, manter ou descartar. Sempre que uma medição contrariou uma afirmação minha, retirei a afirmação em vez de a defender. Revi o conteúdo deste documento, e ele, os erros que nele restem, e a sua defesa são da minha responsabilidade.

ISEP, Porto, 15 de agosto de 2026

Dedicatória

À minha família.

Resumo

Quando uma ação se move de forma abrupta, um investidor não profissional faz sempre as mesmas três perguntas: *isto é invulgar?*, *foi a empresa ou foi o mercado?*, e *já aconteceu antes, e o que se seguiu?* As ferramentas gratuitas mostram a percentagem e ficam-se por aí; os terminais profissionais respondem, mas a um custo fora do alcance de quem investe as suas poupanças.

Esta dissertação apresenta o **InvestiGator**, um sistema de alertas financeiros construído sobre fontes de dados gratuitas, que responde às três perguntas e mostra sempre como chegou à resposta. O trabalho assenta em três técnicas: deteção de anomalias por z-score deslizante, recuperação de precedentes por semelhança semântica com medição do desfeito observado, e um modelo supervisionado de triagem, treinado sobre um conjunto de dados próprio, para decidir que notícias merecem interromper alguém.

Cada componente foi avaliado contra linhas de base transparentes, e os resultados são reportados tal como se revelaram. A deteção normalizada pela volatilidade dispara de forma muito mais consistente entre empresas do que um limiar fixo. A recuperação semântica supera as linhas de base lexical e triviais. O modelo de triagem, treinado em 79 753 exemplos, **não** superou uma linha de base que usa apenas volatilidade, um resultado negativo que se reporta, e que valida por medição a opção pela simplicidade que atravessa todo o trabalho.

O sistema recusa, por desenho, prever preços: explica o que já aconteceu, com a evidência ao lado. **Palavras-chave:** IA Explicável, Alertas Financeiros, Deteção de Anomalias,

Recuperação Semântica, Investidores de Retalho

Abstract

When a stock moves abruptly, a non-professional investor always asks the same three questions: *is this unusual?*, *was it the company or the market?*, and *has this happened before, and what followed?* Free tools show the percentage and stop there; professional terminals do answer, at a subscription cost beyond someone investing their savings.

This dissertation presents **InvestiGator**, a financial alerting system built on free data sources that answers those three questions and always shows how it reached the answer. The work rests on three techniques: anomaly detection with a rolling z-score, precedent retrieval by semantic similarity with measurement of the observed outcome, and a supervised triage model, trained on a purpose-built dataset, to decide which news deserves interrupting someone.

Each component was evaluated against transparent baselines, and the results are reported exactly as they fell. Volatility-normalised detection fires far more consistently across companies than a fixed threshold. Semantic retrieval beats lexical and trivial baselines. The triage model, trained on 79 753 examples, did **not** beat a volatility-only baseline, a negative result that is reported, and that validates by measurement the simplicity-first stance running through the work.

By design, the system refuses to predict prices: it explains what already happened, with the evidence beside it. **Keywords:** IA Explicável, Alertas Financeiros, Detecção de Anomalias,

Recuperação Semântica, Investidores de Retalho

Agradecimentos

Ao meu orientador, Prof. Luís Gomes, e ao meu coorientador, Rafael Silva, por todo o apoio ao longo desta tese. Por trocarem ideias comigo e me ajudarem a decidir a direção do tema; por me mostrarem exemplos de aplicações que já existem e me manterem a par do que se vai fazendo na área; e por me guiarem na elaboração deste documento. Muito do que aqui está tomou a forma que tem porque houve antes uma conversa com eles.

À minha família, por todo o apoio e por acreditarem em mim. Por me incentivarem sempre, e pela alegria com que foram acompanhando a construção disto. É, para mim, a melhor parte de o ter feito.

Aos meus colegas da Sistrade, e à Sistrade, pela flexibilidade que me permitiu seguir este mestrado a par do trabalho, pelas opiniões e pelo feedback que foram dando sobre a aplicação, e por serem boa companhia todos os dias.

Índice

Lista de Acrónimos	xix
1 Introdução	1
1.1 De onde veio este trabalho	1
1.2 O que o sistema faz, numa página	1
1.3 Objetivos e perguntas de investigação	3
1.4 Contribuições	3
1.5 Como ler este documento	4
2 Contexto	5
2.1 O que existe hoje para quem investe pouco	5
2.2 Os produtos que fazem exatamente esta pergunta	6
2.3 E um assistente de IA genérico?	6
2.4 As peças técnicas que este trabalho usa	6
2.5 As escolhas que este trabalho faz	8
3 Metodologia	9
3.1 As três decisões	9
3.2 Técnica 1: detetar o que é invulgar	9
3.2.1 O problema, em palavras	9
3.2.2 A ideia: medir em desvios-padrão	10
3.2.3 A janela que anda, e a regra que a protege	10
3.2.4 Um caso real	11
3.3 Técnica 2: encontrar casos parecidos	11
3.3.1 O problema, em palavras	11
3.3.2 A ideia: transformar frases em pontos	12
3.3.3 Medir a distância: o cosseno	12
3.3.4 Medir o que se seguiu	12
3.4 Técnica 3: decidir o que merece um alerta	13
3.4.1 O problema, em palavras	13
3.4.2 A tarefa e o rótulo	14
3.4.3 O que o modelo vê	14
3.4.4 Treinar sem fazer batota com o tempo	14
3.4.5 Da pontuação à probabilidade: calibração	15
3.5 Como é que se sabe que isto funciona	15
4 O Sistema	17
4.1 Vista de conjunto	17
4.2 De onde vêm os dados	17
4.3 O caminho de uma notícia, do princípio ao fim	18
4.4 O caminho de um movimento de preço	19

4.5	As portas: quando o sistema decide calar-se	20
4.6	Como o alerta é explicado	20
4.7	Onde isto corre, e o que isso custou	21
5	Avaliação	23
5.1	Como está montado este capítulo	23
5.2	QI1: detetar o que é invulgar	23
5.2.1	Como foi medido	23
5.2.2	Resultado	24
5.2.3	E contra métodos aprendidos?	24
5.2.4	O que isto não permite concluir	25
5.3	QI2: encontrar casos parecidos	25
5.3.1	Como foi medido	25
5.3.2	Resultado	25
5.3.3	Aguenta à escala?	26
5.3.4	O que isto não permite concluir	26
5.4	QI3: decidir o que merece um alerta	26
5.4.1	Como foi medido	26
5.4.2	Resultado	27
5.4.3	Não será um acidente do meu setup?	27
5.4.4	Mas serve para alguma coisa?	27
5.4.5	E em produção?	28
5.4.6	O que isto não permite concluir	28
5.5	Resumo dos três resultados	28
6	Conclusões	31
6.1	O que ficou feito	31
6.2	As respostas às perguntas de investigação	31
6.3	Os objetivos, um a um	32
6.4	Limitações	32
6.5	O que eu faria a seguir	33
6.6	O que eu aprendi	33
	Bibliografia	35
A	Reprodutibilidade	37
A.1	Ambiente	37
A.2	Como cada número é reproduzido	37
A.3	Matriz de evidência	38
A.4	Dados e atribuição	38

Lista de Figuras

1.1	Capitalização do mercado acionista dos EUA	2
1.2	O que o sistema faz	2
2.1	Três gerações de representação de texto	7
3.1	As três decisões do sistema	9
3.2	A janela deslizante do z-score	10
3.3	Frases como pontos num espaço	12
3.4	Como se mede o impacto de uma notícia	13
3.5	Divisão temporal com embargo	14
4.1	Arquitetura do sistema	17
4.2	As nove etapas de um alerta	18
4.3	A página inicial do sistema	21
5.1	Taxa de disparo por empresa	24

Lista de Tabelas

2.1	As ferramentas existentes contra as três perguntas	5
3.1	O z-score de um dia real, passo a passo (Tesla, 24 de outubro de 2024). .	11
4.1	Uma notícia real, etapa a etapa	19
4.2	As portas e as suas constantes	20
4.3	O que o ciclo de 60 segundos comprou	22
5.1	Consistência da taxa de disparo	24
5.2	A regra transparente contra dois métodos aprendidos	25
5.3	Recuperação: o método contra três alternativas triviais	26
5.4	Triagem: seis modelos sobre o mesmo bloco de teste	27
5.5	Precisão dentro de um orçamento de cinco alertas por dia	28
5.6	As três perguntas e as suas respostas	29
A.1	Versões fixadas das dependências principais.	37
A.2	Cada resultado e o procedimento que o produz	38
A.3	Matriz de evidência	39

Lista de Acrónimos

FNSPID Financial News and Stock Price Integration Dataset.

QI Questão de Investigação.

Capítulo 1

Introdução

1.1 De onde veio este trabalho

Que problema é este, e porque é que vale a pena resolvê-lo?

Hoje é fácil comprar ações. Basta uma aplicação no telemóvel e alguns minutos. A maior parte das famílias americanas já tem ações, diretamente ou através de fundos e planos de reforma (Gallup 2025), e o mercado onde investem vale mais de 62 biliões de dólares (Securities Industry and Financial Markets Association (SIFMA) 2025) (Figura 1.1).

Difícil é a parte seguinte: perceber o que aconteceu quando o preço se mexe.

Imagine-se uma pessoa que tem cinco ou seis ações e olha para elas de vez em quando. Um dia abre a aplicação e vê uma delas a cair 4%. A aplicação diz-lhe exatamente isso: menos 4%. E mais nada.

A partir daí a pessoa fica sozinha com três perguntas, e faz sempre estas três, por esta ordem:

1. **Isto é invulgar?** Quatro por cento numa empresa calma é muito. Na mesma semana, e noutra empresa, pode ser um dia perfeitamente normal.
2. **Foi a empresa, ou foi o mercado?** Se caiu tudo, a história é uma. Se caiu só esta, é outra completamente diferente.
3. **Já aconteceu antes, e o que se seguiu?** Se já houve dias parecidos, o que fez o preço a seguir?

As aplicações gratuitas não respondem a nenhuma das três. Mostram a percentagem, que é o princípio da primeira pergunta e não a resposta. Os terminais profissionais respondem às três, mas custam mais por mês do que muita gente investe por ano.

É essa distância que este trabalho tenta encurtar. Não por falta de dados: há dados a mais, e gratuitos. O que falta é **contexto**, e um contexto que a pessoa possa *verificar*.

1.2 O que o sistema faz, numa página

Se tivesse de explicar o InvestiGator numa frase, qual seria?

Esta: **o sistema vigia um conjunto de empresas, deteta quando algo sai fora do normal, e avisa, mas só avisa com a explicação e a evidência ao lado.**




Figura 1.1: Capitalização do mercado acionista dos EUA, 2015–2024, em biliões de dólares. É neste mercado que investem as pessoas de quem este trabalho fala. Elaborado a partir dos dados do SIFMA Capital Markets Fact Book (Securities Industry and Financial Markets Association (SIFMA) 2025).

Há duas maneiras de o sistema começar a prestar atenção, e estão na Figura 1.2. Ou o **preço** se mexe de forma invulgar, ou chega uma **notícia** relevante sobre uma das empresas. Em qualquer dos casos, o que sai do outro lado não é uma notificação seca. É um alerta que diz o que aconteceu, porque é que foi considerado invulgar, de onde vieram os dados, e que casos parecidos já existiram no passado, com o que o preço fez depois deles.




Figura 1.2: Os dois gatilhos e o que sai deles. O que o investidor recebe é um alerta que ele consegue seguir e conferir, e não apenas um aviso de que o preço mexeu.

E o que o sistema recusa fazer

Há uma coisa que este sistema não faz, e não é por não ter dado jeito: **não prevê preços**.

Nunca diz que uma ação vai subir. Nunca diz para comprar ou para vender. Nunca mostra um alvo de preço.

Isto pode parecer uma limitação. É o contrário: é o que torna tudo o resto verificável. Uma afirmação sobre o que *já* aconteceu pode ser confirmada contra o registo no momento em que é lida. Uma previsão não pode: só se saberá se estava certa depois de o investidor já ter tido de decidir. Ao recusar prever, o sistema obriga-se a dizer apenas aquilo que consegue mostrar.

1.3 Objetivos e perguntas de investigação

O que é que este trabalho se propõe descobrir?

O objetivo geral é **desenhar, construir e avaliar** um sistema de alertas financeiros explicável para investidores de retalho, usando apenas fontes de dados gratuitas.

Para lá chegar, o trabalho responde a três perguntas de investigação. Cada uma tem uma medição associada, porque uma pergunta a que não se sabe responder com um número não é uma pergunta de investigação: é uma opinião.

- **Questão de Investigação (QI)1, deteção.** Consegue um método estatístico simples e transparente detetar movimentos invulgares de forma consistente entre empresas com volatilidades muito diferentes, e fazê-lo melhor do que uma regra fixa?
- **QI2, precedentes.** Consegue o sistema encontrar notícias passadas genuinamente parecidas com a atual, melhor do que alternativas triviais, e medir o que aconteceu ao preço a seguir a elas sem usar informação do futuro?
- **QI3, triagem.** Consegue um modelo treinado decidir que notícias merecem um alerta melhor do que uma linha de base simples baseada apenas em volatilidade?

Estas três perguntas dão origem a quatro objetivos concretos:

1. construir o sistema completo, dos dados até ao alerta entregue;
2. avaliar cada componente contra linhas de base transparentes;
3. garantir que as explicações são fiéis ao que o sistema realmente calculou;
4. reportar os resultados tal como se revelarem, incluindo os que forem negativos.

O quarto objetivo é o mais importante e é o mais fácil de trair. Voltarei a ele no Capítulo 6.

1.4 Contribuições

O que é que fica feito no fim?

Esta é uma dissertação de **Engenharia de Inteligência Artificial**. A contribuição não é inventar um algoritmo novo. É escolher, integrar e avaliar criticamente técnicas que já existem, até formarem um sistema que funciona, que se explica, e que outra pessoa consegue reproduzir. Escolher bem é o trabalho de engenharia.

Ficam quatro contribuições:

1. **Um sistema completo e a funcionar**, com os dois gatilhos, sobre fontes gratuitas, e implantado, e não uma demonstração de laboratório.
2. **Um método reprodutível para ligar notícias a impacto de mercado**, que combina recuperação por semelhança semântica com janelas de estudo de evento, sem deixar entrar informação do futuro.
3. **Um conjunto de dados próprio e um modelo treinado sobre ele**: 79 753 exemplos construídos a partir de notícias e preços históricos, com o modelo, a calibração e as métricas guardados como artefactos versionados.

4. **Uma avaliação honesta de cada componente** contra linhas de base transparentes, incluindo o resultado que me correu ao contrário, que está reportado como tal.

1.5 Como ler este documento

Por onde é que isto vai?

O documento foi escrito para ser lido do princípio ao fim, e cada capítulo responde a uma pergunta:

- **Contexto** (Capítulo 2): o que já existe, e porque é que não chega para o problema desta tese.
- **Metodologia** (Capítulo 3): as três técnicas, explicadas devagar e com desenhos.
- **O sistema** (Capítulo 4): como as peças se ligam, e uma notícia real seguida do princípio ao fim.
- **Avaliação** (Capítulo 5): o que foi medido, contra o quê, e com que resultado.
- **Conclusões** (Capítulo 6): o que ficou provado, o que ficou por fazer, e o que eu faria a seguir.

Há um fio que atravessa os capítulos 3 a 5: **a mesma notícia real**, seguida desde o momento em que chega até ao alerta que sai. Sempre que aparecer, é a mesma. Serve para que nada aqui fique abstrato.

Capítulo 2

Contexto

2.1 O que existe hoje para quem investe pouco

Ninguém resolveu isto antes?

Resolveram, em parte, e de maneiras diferentes. Vale a pena olhar para o que existe com um critério fixo, em vez de o descrever em geral. O critério deste trabalho são as três perguntas do Capítulo 1, e a Tabela 2.1 usa-as para pontuar as alternativas.

Tabela 2.1: O que cada tipo de ferramenta responde. “Parcial” significa que dá matéria-prima para a resposta, mas deixa o trabalho ao utilizador.

Ferramenta	É invulgar?	Empresa ou mercado?	Já aconteceu?	Custo
App da corretora	não	não	não	incluído
Agregador de notícias	não	não	não	grátis
App de sentimento	parcial	não	não	grátis/baixo
Robo-advisor	não	não	não	% da carteira
Terminal profissional	sim	sim	sim	milhares/ano
Este trabalho	sim	sim	sim	grátis

A tabela mostra o essencial: **a linha que responde às três perguntas existe, e é a mais cara de todas**. Não há aqui um problema científico por resolver: há um problema de acesso. As respostas são conhecidas; estão atrás de uma subscrição que a pessoa de quem este trabalho fala não vai pagar.

Vale a pena olhar para duas linhas em particular.

A **app da corretora** é onde a maioria das pessoas realmente olha. Mostra a percentagem do dia e um gráfico. Não diz se aquilo é muito para aquela ação, não separa a empresa do mercado, e não tem memória. A pergunta “isto é normal?” fica sem resposta precisamente no sítio onde é feita.

Os *robo-advisors* (D’Acunto, Prabhala e Rossi 2019) respondem a outra pergunta: como distribuir dinheiro por uma carteira. É uma pergunta legítima e não é esta. Além disso, aconselhar sobre investimentos tem obrigações regulatórias que este trabalho evita por desenho (ver Secção 2.5).

2.2 Os produtos que fazem exatamente esta pergunta

E os produtos recentes que prometem explicar porque é que uma ação subiu?

Existem, são recentes, e seria desonesto não os nomear.

O **Robinhood Cortex**, anunciado em março de 2025, declara na página do próprio fornecedor que serve para “responder à velha questão de porque é que esta ação está a subir ou a descer hoje” (Robinhood Markets 2025). Os **momentos-chave** do Google Finance, de junho de 2026, propõem-se “explicar porque é que uma ação se moveu” (Google 2026).

É a mesma pergunta deste trabalho, feita por empresas com muito mais recursos e muito mais utilizadores. Convém dizê-lo com clareza em vez de fingir que este território estava vazio.

A diferença está no que é entregue. Um resumo gerado é uma **afirmação**: o utilizador lê e acredita, ou não. O que este trabalho entrega é uma afirmação **com a evidência anexada**: os casos passados, um a um, com as datas, as semelhanças e o que o preço fez a seguir a cada um. A diferença não é de fluência: é de *verificabilidade*.

Uma ressalva de método, porque é fácil escorregar aqui: destes produtos só se afirma o que está escrito nas páginas dos próprios fornecedores, consultadas em data registada. Não se testaram, e por isso não se diz o que fazem por dentro; diz-se apenas o que declaram fazer.

2.3 E um assistente de IA genérico?

Não bastava perguntar a um modelo de linguagem?

É a objecção mais razoável de todas, e merece resposta séria.

Um assistente genérico responde bem à pergunta, no sentido em que produz um texto fluente e plausível. O problema é o que está por trás desse texto. Ele não tem:

- a **volatilidade recente** daquela ação, que é o que permite dizer se 4% é muito;
- a **separação** entre o que foi o mercado e o que foi a empresa;
- uma **base de casos passados** para *recuperar*. No melhor dos casos *recorda* casos do treino, o que não é a mesma coisa e não é verificável.

E há uma diferença mais funda, que é a razão pela qual este trabalho não é um invólucro à volta de um modelo de linguagem. Modelos grandes especializados em finanças existem (Wu et al. 2023) e são impressionantes. Mas a saída deles é uma afirmação, e a literatura sobre confiança em sistemas automáticos mostra que o problema não é as pessoas confiarem de menos: é confiarem *na medida errada*, o que exige que o sistema mostre em que se apoia (Lee e See 2004).

Por isso, neste trabalho, a linguagem nunca produz factos. Os números vêm dos motores que os calcularam, e o texto é montado a partir deles, como se descreveu na Secção 4.6.

2.4 As peças técnicas que este trabalho usa

De onde vêm as três técnicas do capítulo seguinte?

Nenhuma delas é invenção minha. Todas têm uma literatura, e a contribuição está em escolhê-las, integrá-las e avaliá-las, e não em inventá-las.

Detetar o que é invulgar. A detecção de anomalias é uma área grande (Chandola, Banerjee e Kumar 2009). Para séries temporais financeiras há duas famílias: as **estatísticas**, que comparam o presente com uma norma recente, e as **aprendidas**, que tentam descobrir sozinhas o que é raro, como o *Isolation Forest* (Liu, Ting e Zhou 2008) ou o *Local Outlier Factor* (Breunig et al. 2000). Este trabalho usa a primeira família e compara-a com a segunda no Capítulo 5.

Representar texto: três gerações. Comparar notícias por significado depende de como se representa o texto, e essa representação passou por três gerações, na Figura 2.1.




Figura 2.1: Como se passou de contar palavras a representar o sentido de uma frase inteira. Cada geração resolve uma limitação da anterior.

A primeira geração conta palavras (Salton, Wong e Yang 1975): simples, e cega a sinónimos. A segunda representa cada *palavra* como um vetor (Mikolov et al. 2013), o que aproxima sinónimos, mas cada palavra fica com um sentido fixo, independentemente da frase. A terceira usa modelos que leem a frase toda (Devlin et al. 2019), e permite comparar *frases* diretamente (Reimers e Gurevych 2019). É esta que este trabalho usa.

Existem modelos treinados especificamente para texto financeiro (Araci 2019). Não são automaticamente melhores para esta tarefa, e no Capítulo 5 isso é medido em vez de assumido.

Medir o efeito de um acontecimento. Ligar uma notícia ao que o preço fez a seguir é um problema clássico em finanças, com metodologia estabelecida há décadas: o estudo de evento (Brown e Warner 1985). E que o texto publicado tem relação estatística com os movimentos do mercado é observação antiga (Tetlock 2007).

Raciocinar por casos passados. Mostrar casos anteriores parecidos, em vez de uma regra abstrata, tem nome próprio em inteligência artificial: *raciocínio baseado em casos* (Aamodt e Plaza 1994). É exatamente o que a segunda técnica deste trabalho faz.

Explicar decisões automáticas. Por fim, a exigência de que um sistema mostre *como* chegou a uma conclusão é uma área em si (Adadi e Berrada 2018; Barredo Arrieta et al. 2020). Este trabalho segue a via mais conservadora: em vez de explicar *a posteriori* um modelo opaco, usa componentes cuja explicação é o próprio cálculo.

2.5 As escolhas que este trabalho faz

Face a tudo isto, o que é que fica decidido?

Quatro decisões, e cada uma fecha uma porta de propósito.

Responder às três perguntas, e só a essas. Não se acrescentam funcionalidades que não sirvam uma delas. É o que mantém o sistema pequeno o suficiente para ser explicado por inteiro.

Não prever preços. Nem direção, nem alvo, nem recomendação. Além da razão já dada, que é o que torna tudo verificável, há uma razão teórica: se movimentos futuros fossem previsíveis a partir de informação pública, essa informação já estaria refletida no preço (Fama 1970).

Não gerir carteiras nem aconselhar. O sistema não sabe o que o utilizador tem, e não lhe diz o que fazer. Isto evita recolher dados pessoais e mantém o trabalho fora da fronteira do aconselhamento financeiro regulado.

Só fontes gratuitas. Torna o sistema utilizável por quem ele serve, e transforma as limitações resultantes em algo que se *mede* e reporta, em vez de algo que se compra.

A última merece uma nota honesta. Usar apenas fontes gratuitas limita o sistema de forma real: as notícias chegam com atraso, e nem tudo o que acontece é coberto. O Capítulo 4 quantifica esse atraso e o Capítulo 6 volta a ele. A opção foi ter uma limitação medida em vez de uma capacidade comprada. Mas é uma limitação, e não uma virtude.

Capítulo 3

Metodologia

3.1 As três decisões

O que é que o sistema tem mesmo de decidir?

Tudo o que este trabalho faz cabe em três decisões. Estão na Figura 3.1 e são sempre as mesmas, por esta ordem.




Figura 3.1: As três decisões, e a família de técnicas que responde a cada uma. Cada secção deste capítulo trata de uma coluna.

Cada decisão é tratada com a técnica mais simples que consegue resolvê-la. Isto não é preguiça: é uma escolha de desenho que se paga no Capítulo 5, onde cada técnica é comparada com alternativas mais complicadas. Quando a simples ganha, fica a simples, e diz-se porquê.

3.2 Técnica 1: detetar o que é invulgar

Como é que um computador decide que 4% é muito?

3.2.1 O problema, em palavras

Não é possível responder com um número fixo.

Uma regra do género “avisar sempre que uma ação se mexer mais de 3%” parece razoável e é má. Para uma empresa calma, como uma cadeia de supermercados, 3% é um acontecimento raro. Para uma empresa volátil, como uma tecnológica em crescimento, 3% acontece muitas vezes por mês. A mesma regra dá quase nenhum alerta na primeira e alertas quase todos os dias na segunda.

O que interessa não é o tamanho do movimento. É o tamanho do movimento **comparado com o que é normal para aquela empresa**.

3.2.2 A ideia: medir em desvios-padrão

A solução é velha e boa, e é a forma mais comum de detetar anomalias em séries temporais (Chandola, Banerjee e Kumar 2009): em vez de comparar com um número fixo, comparo com o comportamento recente da própria ação.

Olho para os últimos vinte dias e pergunto duas coisas: *quanto é que esta ação costuma oscilar?* e *quão longe do costume ficou hoje?* A resposta chama-se **z-score**:

$$z_t = \frac{r_t - \mu}{\sigma} \quad (3.1)$$

Termo a termo:

- r_t é o retorno de hoje, ou seja, quanto a ação subiu ou desceu;
- μ (mu) é a **média** dos retornos dos vinte dias anteriores: o “centro” do que é normal;
- σ (sigma) é o **desvio-padrão** desses vinte dias: uma medida de quanto a ação costuma oscilar à volta desse centro;
- z_t é o resultado: *a quantos desvios-padrão do normal ficou o dia de hoje.*

Um z de $+1$ quer dizer “ligeiramente acima do costume”. Um z de $+7$ quer dizer “isto quase nunca acontece”. E é aqui que está o essencial: $z = +7$ significa a mesma coisa na empresa calma e na empresa volátil, porque cada uma é comparada consigo própria.

3.2.3 A janela que anda, e a regra que a protege

A Figura 3.2 mostra como isto funciona ao longo do tempo. A janela dos vinte dias desliza: para julgar o dia de hoje, usa os vinte dias *anteriores*; amanhã, desliza um dia.




Figura 3.2: A janela que define “o normal”. O dia que está a ser julgado **não entra** no cálculo da sua própria norma, e é esta separação que garante que o sistema nunca usa informação que ainda não teria.

Repare-se num pormenor da figura que parece pequeno e não é: **o dia que está a ser julgado não entra no cálculo da sua própria norma**. Se entrasse, um dia muito extremo puxaria a média e inflacionaria o desvio-padrão, e o próprio dia pareceria menos invulgar do que foi. O sistema estaria a usar informação que, no momento da decisão, ainda não devia contar.

Esta regra tem um nome, **evitar lookahead**, e atravessa todo o trabalho. Volto a ela na Secção 3.5, onde mostro como é imposta por um teste automático em vez de ser apenas prometida.

3.2.4 Um caso real

A Tabela 3.1 mostra o cálculo completo para o maior movimento do período estudado: a Tesla, a 24 de outubro de 2024, no dia a seguir aos resultados trimestrais.

Tabela 3.1: O z-score de um dia real, passo a passo (Tesla, 24 de outubro de 2024).

Quantidade	Valor
Média dos retornos dos 20 dias anteriores, μ	-0.92%
Desvio-padrão desses 20 dias, σ	2.73%
Retorno do dia, r_t	+19.82%
z-score, $(r_t - \mu)/\sigma$	+7.61
Sinalizado?	sim

Um movimento de quase 20% num dia é evidente para qualquer pessoa. O que a tabela mostra é *porquê*: não porque 20% seja um número grande em abstrato, mas porque é sete vezes e meia o que aquela ação costumava mexer naquelas semanas. É essa frase que o sistema consegue mostrar ao utilizador, e é a diferença entre avisar e explicar.

Há ainda um caso pequeno que vale a pena resolver bem: se uma ação não se mexeu *nada* durante vinte dias, o desvio-padrão é zero e a divisão da Equação 3.1 não existe. Nesse caso o sistema devolve $z = 0$ em vez de rebentar. Uma ação parada é descrita como não tendo nada de especial, que é exatamente o que se passa.

Em três frases. Comparo o dia de hoje com os vinte dias anteriores da mesma ação e conto a distância em desvios-padrão. Assim, o mesmo número significa a mesma coisa numa empresa calma e numa volátil. O dia julgado nunca entra no cálculo da sua própria norma.

3.3 Técnica 2: encontrar casos parecidos

Como é que o computador percebe que duas notícias falam da mesma coisa?

3.3.1 O problema, em palavras

Chega uma notícia: “Nvidia bate estimativas com procura de centros de dados”.

A pergunta útil é: *já houve notícias parecidas com esta, e o que fez o preço a seguir?*

A maneira ingénua de procurar é por palavras. Procurar notícias antigas que contenham “Nvidia”, “bate” e “estimativas”. Funciona mal, por duas razões simétricas:

- duas notícias podem dizer a **mesma coisa com palavras diferentes**: “supera previsões” e “bate estimativas” não partilham uma única palavra importante;
- duas notícias podem **partilhar palavras e falar de assuntos diferentes**: “bate estimativas” e “bate recorde de despedimentos” partilham “bate”.

O que é preciso é comparar **significado**, não letras.

3.3.2 A ideia: transformar frases em pontos

É aqui que entra a única peça de aprendizagem profunda que o sistema usa, e vale a pena explicá-la com calma porque é a que soa mais complicada e não é.

Um **modelo de embeddings de frase** (Reimers e Gurevych 2019) é um modelo já treinado que recebe uma frase e devolve uma lista de números, neste caso 384. Essa lista chama-se *embedding* e funciona como uma **coordenada**: é a posição daquela frase num espaço.

A propriedade que interessa é esta: o modelo foi treinado de forma a que frases com significado parecido fiquem **perto** umas das outras nesse espaço, mesmo que usem palavras diferentes. A Figura 3.3 mostra a ideia em duas dimensões (as verdadeiras são 384, que não se conseguem desenhar).




Figura 3.3: Cada frase vira um ponto. Frases com o mesmo significado ficam próximas, mesmo sem partilharem palavras; frases que partilham palavras (“bate”) mas falam de assuntos diferentes ficam longe. O desenho tem duas dimensões para se poder ver; o modelo usa 384.

3.3.3 Medir a distância: o cosseno

Tendo duas frases como pontos, falta medir se estão perto.

A medida usada é a **semelhança do cosseno**. Em vez de medir a distância em linha reta, mede o **ângulo** entre as duas direções. Dá um valor entre -1 e 1 :

- perto de 1: as duas frases apontam na mesma direção, ou seja, significado muito parecido;
- perto de 0: não têm relação;
- negativo: apontam em direções opostas.

Usa-se o ângulo e não a distância porque o que interessa é *sobre o que* a frase fala, e não o comprimento do texto. Uma manchete curta e um parágrafo longo sobre o mesmo assunto devem ficar próximos, e o ângulo dá isso.

3.3.4 Medir o que se seguiu

Encontrar notícias parecidas é metade. A outra metade é dizer o que aconteceu ao preço depois de cada uma delas.

3.4. Técnica 3: decidir o que merece um alerta

Para isso usa-se uma técnica clássica de finanças, o **estudo de evento** (Brown e Warner 1985): fixa-se o dia da notícia e mede-se a variação do preço 1, 3 e 5 dias depois. A Figura 3.4 mostra o alinhamento.




Figura 3.4: O impacto é medido a partir do *fecho* do dia da notícia. Se a notícia sai num sábado, o dia d é o primeiro dia de bolsa seguinte. É uma **medição do que aconteceu**, não uma previsão.

Duas decisões de detalhe, ambas com consequência:

1. **Se a notícia sai fora de dias de bolsa**, o dia d é o primeiro dia de negociação igual ou posterior. Sem esta regra, uma notícia de sábado não teria a que se agarrar.
2. **A medição começa no fecho de d** , não na abertura. É a opção conservadora: não atribui à notícia a parte do movimento que já tinha acontecido antes de ela ser lida.

E vale a pena dizer aquilo que isto **não** é. Medir o que aconteceu a seguir a notícias passadas não é prever o que vai acontecer agora. É por isso que o sistema mostra sempre os casos *um a um*, com a data e o valor de cada um, em vez de resumir tudo a uma média. Uma média esconde que os casos podem ter ido em sentidos opostos.

Em três frases. Um modelo já treinado transforma cada manchete numa lista de 384 números que funciona como uma coordenada de significado. Comparo manchetes pelo ângulo entre essas coordenadas, o que aproxima frases parecidas mesmo com palavras diferentes. Para cada caso passado, meço o que o preço fez 1, 3 e 5 dias depois: uma medição, não uma previsão.

3.4 Técnica 3: decidir o que merece um alerta

Já sei que algo é invulgar. Devo mesmo interromper alguém?

3.4.1 O problema, em palavras

Chegam muitas notícias. A maioria não interessa: repetições, listas automáticas, textos que mencionam a empresa de passagem.

Um sistema que avisa de tudo é tão inútil como um que não avisa de nada. Pior, até, porque ensina a pessoa a ignorar o canal. Este problema tem nome, **fadiga de alertas**, e é a razão pela qual esta terceira decisão existe.

Aqui, ao contrário das duas anteriores, não há uma fórmula óbvia. É o sítio natural para **aprender a partir dos dados**.

3.4.2 A tarefa e o rótulo

Para treinar um modelo é preciso, antes de tudo, uma pergunta com resposta conhecida.

A pergunta escolhida foi: *depois desta notícia, houve um movimento anormalmente grande no preço?* A resposta, o **rótulo**, constrói-se assim:

1. mede-se o retorno da ação nos três dias seguintes à notícia;
2. subtrai-se o movimento do mercado no mesmo período, para não confundir “a empresa mexeu-se” com “mexeu-se tudo”;
3. se o que sobra for maior do que 2% em valor absoluto, o rótulo é 1; caso contrário, 0.

Repare-se em **valor absoluto**. O rótulo diz se houve movimento *grande*, e nunca em que **direção**. Isto é deliberado e é a fronteira que o trabalho não atravessa: o modelo aprende sobre *materialidade*, não sobre subir ou descer.

3.4.3 O que o modelo vê

O modelo recebe cinco tipos de informação sobre o momento da notícia:

- **volatilidade recente**: quanto a ação tem oscilado nos últimos 20 dias;
- **momento**: como se comportou nos últimos 5 dias;
- **o movimento do próprio dia**;
- **o comprimento da manchete**;
- **o setor** da empresa.

E, numa das variantes testadas, também o *embedding* da manchete, os mesmos 384 números da Secção 3.3. Comparar a variante com texto e a variante sem texto é precisamente o que a Q13 pergunta, e a resposta está no Capítulo 5.

3.4.4 Treinar sem fazer batota com o tempo

Esta é a parte onde é mais fácil enganar-se a si próprio, por isso vale a pena o desenho da Figura 3.5.




Figura 3.5: Os dados são divididos **por ordem cronológica**, nunca ao acaso. Entre blocos há um *embargo* de cinco dias, porque o rótulo de uma notícia olha até três dias para a frente e sem o embargo o fim do treino tocava no princípio do teste.

Duas regras, e as duas existem para impedir que o modelo pareça melhor do que é:

Dividir pelo tempo, não ao acaso. Se os dados fossem baralhados, o modelo treinaria com notícias de 2023 e seria testado com notícias de 2019, ou seja, estaria a ser avaliado

sobre um passado que já conhece. Aqui, treina-se no início do período e testa-se no fim, como acontece na realidade.

Embargo entre blocos. O rótulo de uma notícia depende dos três dias seguintes. Uma notícia no último dia de treino tem o seu rótulo determinado por dias que já pertencem ao bloco seguinte. Deitam-se fora os cinco dias de fronteira, e diz-se quantas linhas isso custou.

3.4.5 Da pontuação à probabilidade: calibração

O modelo devolve uma pontuação. Uma pontuação alta não é, por si só, uma probabilidade: dizer 0.8 não garante que aconteça em 8 de cada 10 casos.

Como o número vai ser mostrado a uma pessoa, isso tem de ser corrigido. O passo chama-se **calibração** (Niculescu-Mizil e Caruana 2005): ajusta-se uma função simples que transforma pontuações em probabilidades *honestas*, de modo a que, entre todos os casos a que o modelo dá 70%, cerca de 70% tenham mesmo acontecido. A calibração é ajustada no bloco de validação, nunca no de teste.

Em três frases. Treinei um modelo para estimar se uma notícia é seguida de um movimento anormalmente grande, em qualquer direção. Os dados são divididos pelo tempo, com um embargo entre blocos, para o modelo nunca ser avaliado sobre um futuro que já viu. A pontuação é calibrada, para o número mostrado ao utilizador querer dizer o que parece querer dizer.

3.5 Como é que se sabe que isto funciona

O que impede um resultado bonito de ser um resultado enganador?

Três compromissos, assumidos *antes* de correr as experiências.

Primeiro: comparar sempre com o mais simples. Um número sozinho não diz nada. Dizer que a recuperação acerta em metade dos casos só significa alguma coisa quando se sabe o que acertaria uma alternativa trivial. Por isso cada técnica é comparada com **linhas de base**: uma regra fixa, uma escolha ao acaso, a notícia mais recente. Se a técnica sofisticada não ganhar, isso é o resultado, e é o que fica escrito.

Segundo: o não-lookahead é imposto por um teste, não prometido. É fácil escrever “não usámos informação do futuro”. É difícil garanti-lo. Aqui existe um teste automático que faz o seguinte: pega num exemplo, **altera artificialmente o futuro** e volta a calcular. Depois exige duas condições ao mesmo tempo: que as *features* fiquem exatamente iguais (porque descrevem o passado) e que o *rótulo* mude (porque descreve o futuro). Se alguma informação do futuro se tivesse infiltrado nas features, o teste falha.

Terceiro: reportar o que sair. O critério de sucesso de cada experiência foi escrito antes de a correr. Onde o resultado contrariou o que se esperava, fica reportado como se revelou. O Capítulo 5 tem um caso desses, e é o mais interessante dos três.

Capítulo 4

O Sistema

4.1 Vista de conjunto

Como é que as peças se ligam?

O Capítulo 3 explicou três técnicas isoladas. Este mostra-as a trabalhar juntas.

O sistema chama-se **InvestiGator** e tem cinco partes, na Figura 4.1: **deteção**, **recuperação**, **triagem**, **explicação** e **entrega**. Cada uma faz uma coisa só, e passa o resultado à seguinte.




Figura 4.1: As cinco partes do InvestiGator. À esquerda, de onde vêm os dados; ao centro, as três técnicas do capítulo anterior; à direita, as duas formas de o utilizador receber o resultado.

Há uma regra de desenho que atravessa tudo isto e que vale a pena dizer já: **a explicação é montada a partir dos objetos que foram calculados**, e nunca escrita à parte. Se o detetor calculou um z de $+7.61$, é esse número que aparece no texto. Não há um sítio onde alguém escreva a frase e outro sítio onde alguém calcule o valor, porque, se houvesse, os dois podiam divergir sem ninguém dar por isso.

4.2 De onde vêm os dados

Com que matéria-prima é que isto funciona?

Uma restrição fundadora deste trabalho é usar **apenas fontes gratuitas**. Não foi por comodidade: é o que torna o sistema utilizável por quem ele serve. Um investidor que já acha caro pagar comissões não vai subscrever um terminal financeiro.

Isso obriga a três decisões de engenharia.

Preços: uma cadeia, não uma fonte. As fontes gratuitas de preços falham. Bloqueiam por excesso de pedidos, respondem com erro, ou simplesmente não têm o dia de hoje. Em vez de depender de uma, o sistema tenta várias por ordem e fica pela primeira que responde. Regista sempre qual serviu, porque saber de onde veio um número faz parte de o poder explicar.

Notícias: por empresa, e filtradas à entrada. As notícias vêm de uma API gratuita, empresa a empresa. O que chega é muito e é sujo: listas automáticas de “os dez maiores movimentos do dia”, textos que mencionam a empresa de passagem, comunicados de escritórios de advogados. Antes de qualquer coisa, um filtro exige que a notícia **nomeie mesmo a empresa** e rejeita padrões conhecidos de texto automático.

Histórico: um conjunto de dados público, alinhado com preços. Para responder à pergunta “já aconteceu antes?” é preciso um passado. Usa-se o Financial News and Stock Price Integration Dataset (FNSPID) (Dong, Fan e Peng 2024), um conjunto público de notícias financeiras, alinhado com os preços correspondentes. Desse alinhamento nasce a base de casos: cerca de 80 mil notícias entre 2018 e 2023, cada uma com o que o preço fez a seguir.

4.3 O caminho de uma notícia, do princípio ao fim

O que acontece, exatamente, entre uma notícia sair e um alerta chegar ao telemóvel?

Esta é a secção central do capítulo, e segue **uma notícia real**: um alerta que o canal enviou a 12 de julho de 2026 sobre a Meta.

“Mark Zuckerberg Said Meta’s AI Bets ‘Haven’t Come to Fruition Yet’ as Shares Fell 5%”

A Figura 4.2 mostra as etapas. A Tabela 4.1 mostra o que aconteceu em cada uma, com os valores que o sistema realmente calculou.




Figura 4.2: As nove etapas. As caixas a tracejado são **portas**: em qualquer uma delas a notícia pode ser descartada e o sistema fica calado. Nove em cada dez varreduras acabam assim.

4.4. O caminho de um movimento de preço

Tabela 4.1: O que aconteceu em cada etapa para o alerta da Meta de 12 de julho de 2026. Todos os valores são os que o sistema calculou nesse dia.

Etapa	O que aconteceu
1. Recolher	A varredura foi buscar as notícias da semana para cada empresa da lista.
2. Nomeia a empresa?	A manchete diz “Meta” e “Mark Zuckerberg”, que estão na lista de nomes da empresa, e não corresponde a nenhum padrão de texto automático. Passa.
3. É recente?	Tem menos de dois dias. Passa: sem esta porta, a mesma notícia alertava dias seguidos.
4. Procurar parecidas	A manchete é transformada em 384 números e comparada com a base de casos. As três mais parecidas: Microsoft 2023-11-07 (0.46), Nvidia 2023-08-02 (0.51), Nvidia 2023-09-21 (0.46).
5. Evidência forte?	A melhor semelhança é 0.51, acima do mínimo de 0.45. Passa.
6. Merece avisar?	O modelo de triagem dá 54%, acima do mínimo de 50%. Passa.
7. Já avisei hoje?	É o primeiro alerta desta empresa hoje, e nenhum outro produtor o enviou. Passa.
8. Montar a explicação	O texto é composto a partir dos objetos calculados: o movimento, os três casos passados com o que se seguiu a cada um, e a nota de que isto não é uma previsão.
9. Enviar e registar	Enviado ao canal e guardado no registo partilhado, de onde a página web o vai buscar depois.

Vale a pena olhar para a etapa 4 com atenção, porque é onde o trabalho fica interessante. Os três casos recuperados são de **outras empresas** (duas da Nvidia e uma da Microsoft), e o sistema mostra-os na mesma. É deliberado: se a pergunta é “já houve notícias como esta?”, a resposta não tem de vir da mesma empresa. Notícias sobre investimento em inteligência artificial numa tecnológica grande são comparáveis entre si.

E os desfechos foram **em sentidos opostos**: +2.70%, -3.87% e +5.05%. O sistema mostra os três, um a um, exatamente por isso. Se mostrasse só a média, esconderia a coisa mais importante que há para saber: que casos parecidos deram resultados diferentes.

4.4 O caminho de um movimento de preço

E quando não há notícia nenhuma?

O segundo gatilho é mais curto. Todos os dias, depois do fecho, o sistema calcula o z-score de cada empresa da lista, como na Secção 3.2. Se algum passar o limiar, há alerta.

Duas coisas foram acrescentadas depois de o sistema estar a funcionar, e ambas por observação:

Níveis de severidade. Um z de 1.6 e um z de 3.2 não são a mesma coisa, e o texto do alerta passou a distingui-los em palavras (“assinalável”, “forte”, “extremo”) em vez de dar o mesmo aviso aos dois.

Comparação com os pares. Um alerta que diz “a empresa caiu 8%” sem dizer que o setor inteiro caiu é enganador. O sistema passou a olhar para as outras empresas do mesmo setor no mesmo dia, e a dizê-lo.

Esta segunda correção veio de ler os primeiros trinta alertas enviados. Em nove deles o texto **contradizia-se**: uma linha dizia que o movimento parecia ser do setor inteiro, e duas linhas abaixo a repartição dizia que a maior parte pertencia à empresa. As duas linhas estavam certas isoladamente: a comparação com os pares olhava apenas para a *direção* do movimento dos vizinhos, nunca para a sua *dimensão*. Passou a olhar para as duas.

4.5 As portas: quando o sistema decide calar-se

Porque é que o sistema não avisa de quase nada?

Porque avisar de tudo é o mesmo que não avisar de nada. Se o canal enviar quinze mensagens por dia, a pessoa deixa de as ler, e o sistema perde a única coisa que tinha para dar.

As cinco portas da Figura 4.2 existem para isso. O efeito conjunto é grande: numa janela medida em produção, das **944** notícias relevantes que entraram, saíram **42** alertas. Cerca de uma em cada vinte e duas.

Cada porta tem uma constante associada, e é justo perguntar de onde vêm esses números. A Tabela 4.2 responde, incluindo quando a resposta é “foi escolhido”.

Tabela 4.2: As cinco portas, o valor usado, e de onde vem. Distinguir “derivado” de “escolhido” é uma questão de honestidade: as duas coisas defendem-se de maneiras diferentes.

Porta	Valor	De onde vem
Nomeia a empresa	—	Regra escrita depois de ler os primeiros alertas e ver o que passava.
É recente	2 dias	Escolhido: cobre um fim de semana.
Evidência forte	0.45	Escolhido , e é a porta mais agressiva de todas (ver abaixo).
Merece avisar	50%	Derivado de uma análise de custos: quando falhar um movimento e dar um falso alarme custam o mesmo, o limiar ótimo é 0.49.
Teto diário	2/dia	Escolhido, com um piso que sobe: o segundo alerta do dia sobre a mesma empresa exige uma pontuação mais alta.

O chão de semelhança merece um parágrafo próprio, porque é a porta que mais mata e a que tem a justificação mais fraca. Numa varredura medida, sete das dez empresas foram travadas exatamente ali, e quatro delas por menos de 0.04 de diferença. Testei depois se um valor mais alto de semelhança correspondia a precedentes mais informativos, e **não corresponde**: a concordância de direção entre o caso passado e o caso atual fica ao nível do acaso dos dois lados do limiar. A conclusão honesta é que este número serve para *controlar o volume* de alertas e para garantir coerência de tema, e não para escolher casos que preveem melhor. Fica dito assim.

4.6 Como o alerta é explicado

O que é que a pessoa recebe, e porque é que se pode fiar?

4.7. Onde isto corre, e o que isso custou

O alerta não é uma frase. É uma pequena estrutura, sempre com as mesmas partes e sempre pela mesma ordem:

1. **o facto**: o que aconteceu, em números;
2. **porquê foi assinalado**: a razão estatística, em linguagem simples;
3. **os casos passados**: um a um, com data, semelhança e o que se seguiu a cada um;
4. **a ressalva**: que isto é história observada e não uma previsão.

A Figura 4.3 mostra como isto chega ao ecrã.

A ordem importa. A pessoa lê primeiro o que aconteceu e só depois a estatística, porque é assim que uma pessoa pensa; um alerta que abre com “ $z = 2.65$ ” perde o leitor na primeira linha.

E a garantia que sustenta tudo isto é de construção, não de boa vontade: **cada número do texto vem do objeto que o calculou**. O texto é montado a partir dessas peças. Não é possível o alerta dizer +4.47% e o sistema ter calculado outra coisa, porque só existe um sítio onde esse valor existe.




Figura 4.3: A página que o utilizador vê. Cada empresa tem um cartão com o veredicto *em palavras* antes de qualquer número, o movimento do dia, e a raridade expressa em dias (“6 dos últimos 249 dias mexeram-se pelo menos isto”) em vez de um valor estatístico que a maioria das pessoas não sabe ler.

4.7 Onde isto corre, e o que isso custou

Como é que um sistema destes se mantém a funcionar sem servidor pago?

A primeira versão corria no agendador gratuito de um serviço de alojamento de código. Funcionava, e tinha um problema que só se vê a usar: **os alertas chegavam tarde**. O

agendador gratuito é de melhor esforço: na prática corria de hora e meia em hora e meia, e não de meia em meia hora como estava configurado.

A solução veio do plano do ISEP: o *GitHub Student Developer Pack* dá créditos que permitiram alojar o sistema num serviço com processo permanente. O ciclo passou a correr de **60 em 60 segundos**.

E aqui está o resultado, na Tabela 4.3, que é mais interessante do que a decisão:

Tabela 4.3: Latência medida sobre os alertas entregues, separando as duas eras. O tempo está quase todo na *descoberta*, não na entrega.

Medição	Valor
Mediana, com o agendador gratuito	196 min
Mediana, com o ciclo de 60 segundos	143 min
Da publicação até o sistema detetar	≈ 158 min
Da deteção até a mensagem chegar	≈ 1 s

O ciclo comprou **53 minutos**, e não as duas horas que eu esperava. A razão está nas duas últimas linhas: quase todo o tempo é gasto *até a notícia aparecer na fonte gratuita*, e nada do lado da infraestrutura muda isso. Depois de o sistema ver a notícia, a mensagem chega em cerca de um segundo.

Isto é uma limitação real e fica escrita como tal. Comprar um serviço de notícias em tempo real resolveria, e violaria a restrição fundadora do trabalho. Preferi ter uma limitação medida a ter uma capacidade comprada.

Capítulo 5

Avaliação

5.1 Como está montado este capítulo

O que é que vale como prova?

Cada uma das três perguntas de investigação tem aqui a sua secção. Todas seguem a mesma forma, de propósito:

1. a pergunta;
2. como foi medida, e contra que alternativa;
3. o resultado;
4. **o que este resultado não permite concluir.**

O quarto ponto é o que separa uma avaliação de uma demonstração. Todos os números deste capítulo são produzidos por procedimentos automáticos com semente fixa: correr outra vez sobre os mesmos dados dá exatamente os mesmos valores.

5.2 QI1: detetar o que é invulgar

*Um z-score deslizante deteta movimentos invulgares de forma mais consistente do que uma regra fixa? **Sim, e com uma margem grande.***

5.2.1 Como foi medido

Foram usados três anos de cotações diárias de quinze empresas grandes, entre junho de 2023 e junho de 2026, ou seja, cerca de 750 dias por empresa.

São quinze, e não as doze que o sistema vigia em produção. A diferença é de propósito: a avaliação quer *variedade* de volatilidade, para o argumento da consistência ter sobre o que incidir; a lista de produção é uma escolha de produto e não uma amostra. Confundir as duas seria avaliar o detetor exatamente no conjunto que ele foi montado para servir.

O argumento principal não precisa de rótulos nenhuns, e é por isso que é o principal. Um bom detetor universal deve disparar a um ritmo **parecido** em empresas diferentes. Se dispara muito numa e quase nada noutra, o que está a medir é a volatilidade da empresa e não a raridade do dia.

Como argumento de apoio, usou-se também um rótulo aproximado: considera-se “dia extremo” um dia no percentil 99 dos retornos *daquela* empresa. É um rótulo imperfeito, porque é ele próprio relativo à volatilidade, e por isso vem em segundo lugar.

5.2.2 Resultado

A Tabela 5.1 mostra o argumento principal.

Tabela 5.1: Com que frequência cada método dispara, entre as quinze empresas. O que interessa é a **amplitude**: quanto menor, mais consistente é o detetor.

Método	Taxa mínima	Taxa máxima	Amplitude
z-score (janela 20)	0.016	0.031	0.015
Limiar fixo ($ r \geq 3\%$)	0.009	0.353	0.344

A Figura 5.1 mostra a mesma informação empresa a empresa.

A diferença é de mais de vinte vezes. O limiar fixo dispara em 0.9% dos dias na empresa mais calma e em 35.3% dos dias na mais volátil: para uma delas quase nunca diz nada e para a outra fala um dia em cada três. O z-score fica entre 1.6% e 3.1% em todas.




Figura 5.1: A mesma informação, empresa a empresa. As barras do limiar fixo acompanham a volatilidade de cada ação; as do z-score mantêm-se quase constantes.

Contra o rótulo aproximado, o z-score obtém $F_1 = 0.516$ contra 0.218 do limiar fixo.

5.2.3 E contra métodos aprendidos?

Faltava a comparação mais exigente: e se em vez de uma regra estatística se usasse um método de aprendizagem automática desenhado para detetar anomalias?

Foram testados dois, sobre exatamente a mesma informação e com o mesmo cuidado de não usar o futuro: *Isolation Forest* (Liu, Ting e Zhou 2008) e *Local Outlier Factor* (Breunig et al. 2000). O resultado está na Tabela 5.2.

5.3. QI2: encontrar casos parecidos

Tabela 5.2: Os três detetores, sobre os mesmos dados e sob o mesmo protocolo.

Detetor	Precisão	Recall	F_1	Amplitude
z-score (a regra)	0.407	0.761	0.530	0.017
Isolation Forest	0.158	0.913	0.269	0.140
Local Outlier Factor	0.163	0.989	0.280	0.183

A regra transparente ganha aos dois. Não por pouco: quase o dobro do F_1 , e com uma consistência entre empresas muito melhor. Os dois métodos aprendidos assinalam quase tudo (*recall* altíssimo) e acertam pouco (precisão baixa).

Este é o primeiro de três casos, neste capítulo, em que uma técnica mais sofisticada foi comparada de forma justa com uma mais simples e perdeu. É um resultado que vale por si: justifica por medição a escolha do método simples, em vez de a justificar por preferência.

5.2.4 O que isto não permite concluir

O rótulo é aproximado e relativo à volatilidade, e por isso o argumento de peso é o da consistência, que não usa rótulo nenhum. E a comparação foi feita sobre estas quinze empresas e este período; nada aqui diz o que aconteceria noutro mercado ou noutra década.

5.3 QI2: encontrar casos parecidos

A recuperação por significado encontra notícias passadas genuinamente relacionadas, melhor do que alternativas triviais? Sim, com folga sobre todas elas.

5.3.1 Como foi medido

O problema de avaliar recuperação é que não existe uma lista de “respostas certas”. Ninguém etiquetou pares de notícias como relacionados ou não.

Usou-se então uma aproximação verificável: considera-se que uma notícia recuperada é **relevante** se pertencer ao *mesmo setor* da notícia de consulta. É imperfeito, porque duas notícias do mesmo setor podem não ter nada a ver, mas tem duas virtudes: é objetivo, e não foi escolhido depois de ver os resultados.

Além disso, impôs-se uma restrição que torna a tarefa *mais difícil*: a notícia recuperada tem de ser de uma **empresa diferente**. Sem isso, o sistema podia parecer bom limitando-se a devolver notícias da mesma empresa, que estão quase sempre no mesmo setor por construção.

A métrica é a **precisão@5**: das cinco notícias que o sistema devolve, quantas são relevantes.

5.3.2 Resultado

A Tabela 5.3 tem o método usado, uma variante maior, e as três alternativas triviais. A leitura é direta: escolher ao acaso acerta em 24% dos casos. É esse o chão, e não zero, porque há cinco setores e alguns são maiores do que outros. Procurar por palavras em comum sobe para 34.6%. Comparar significado sobe para 51.4%, mais do dobro do acaso.

Tabela 5.3: Precisão@5, média de cinco repetições com sementes diferentes.
Quanto maior, melhor.

Método	Precisão@5	O que é
Embeddings (MiniLM)	0.514	o método usado
Embeddings (MPNet)	0.538	um modelo maior, mais lento
Palavras em comum	0.346	procurar por sobreposição de palavras
Escolha ao acaso	0.240	o chão: a proporção natural
Mais recente	0.126	devolver simplesmente as últimas notícias

E a alternativa que parece mais razoável de todas, “mostra-me apenas as notícias mais recentes”, é a **pior** de todas, com 12.6%. Faz sentido: a notícia mais recente sobre outra empresa não tem razão nenhuma para estar relacionada com esta.

5.3.3 Aguenta à escala?

A avaliação acima corre sobre um corpus recente e curto. Para confirmar que o resultado não é um acidente desse corpus, a mesma medição foi repetida sobre o conjunto histórico completo, com cerca de 80 mil notícias de seis anos: a precisão@5 sobe para **0.595**.

5.3.4 O que isto não permite concluir

Duas coisas, e a segunda é importante para o produto.

Primeiro, “mesmo setor” não é o mesmo que “relacionado”. É uma aproximação, e o número deve ser lido como tal.

Segundo, e mais interessante: a recuperação capta **tema**, não **direção**. Duas notícias podem ser sobre o mesmo assunto e o preço ter ido para lados opostos, que foi exatamente o que aconteceu no exemplo do Capítulo 4. Medindo a concordância de direção entre a notícia de consulta e os casos recuperados, obtém-se 0.708 contra um chão de acaso de 0.688: quase nada. Por isso o sistema mostra os casos um a um e nunca resume a uma média, e por isso o texto do alerta diz explicitamente que se trata de casos semelhantes no *tema*.

5.4 Q13: decidir o que merece um alerta

Um modelo treinado prioriza notícias melhor do que uma linha de base simples baseada só em volatilidade? Não. E é o resultado mais interessante deste trabalho.

5.4.1 Como foi medido

O conjunto de dados foi construído a partir do histórico: **79 753** exemplos entre 2018 e 2023, cada um uma notícia com o contexto de mercado do dia e o rótulo descrito na Secção 3.4. A divisão é cronológica com embargo, como na Figura 3.5.

Compararam-se seis modelos, do mais simples ao mais completo. A métrica principal é a **PR-AUC**, apropriada quando as duas classes são desequilibradas.

Tabela 5.4: Quanto maior a PR-AUC, melhor; quanto menor o Brier, melhor calibradas estão as probabilidades.

Modelo	PR-AUC	Brier
Alertar sempre (chão)	0.378	0.622
Só volatilidade	0.542	0.218
Só contexto de mercado	0.538	0.224
Só texto da manchete	0.439	0.240
Contexto + texto	0.496	0.229
Gradient boosting (contexto + texto)	0.469	0.228

5.4.2 Resultado

O melhor modelo da Tabela 5.4 é o mais simples de todos: o que usa **apenas a volatilidade recente**. Acrescentar o resto do contexto não melhora. Acrescentar o texto da manchete *piora*, de 0.542 para 0.496.

Isto era o contrário do que eu esperava quando comecei. A hipótese era que o texto da notícia trouxesse informação que os preços não tinham. Sobre este corpus, não traz.

5.4.3 Não será um acidente do meu setup?

Foi a primeira coisa que fui verificar, por três caminhos.

Será que o modelo de texto estava mal afinado? Repetiu-se a comparação dando ao texto as melhores condições possíveis: regularização afinada, redução de dimensionalidade do bloco de texto, e um modelo de linguagem especializado em finanças. O melhor resultado do texto sobe para 0.533, e continua abaixo dos 0.542 da volatilidade.

Será que a diferença é ruído? Reamostrou-se o bloco de teste mil vezes, por grupos (empresa, dia), porque notícias do mesmo dia sobre a mesma empresa partilham o rótulo e não são observações independentes. A diferença mantém-se com o intervalo a excluir zero.

Será que depende de como defini o rótulo? O rótulo usa um limiar de 2% e um horizonte de três dias, ambos escolhidos por mim. Repetiu-se toda a comparação para nove combinações diferentes de limiar e horizonte. A volatilidade iguala ou bate o modelo com texto nas **nove**.

O resultado negativo aguenta os três testes. Não é um acidente do meu setup: é o que os dados dizem.

5.4.4 Mas serve para alguma coisa?

Serve, mas aqui é preciso muito cuidado com a comparação, porque é fácil enganar-se.

O produto não mostra tudo: mostra no máximo cinco alertas por dia. A pergunta útil passa a ser *das cinco notícias que escolho mostrar, quantas eram mesmo importantes?* A Tabela 5.5 responde.

Tabela 5.5: Quatro formas de escolher as cinco notícias do dia, sobre o mesmo bloco de teste.

Como escolher	Precisão@5	O que é
"Alertar sempre"	0.163	<i>não é escolher às cegas</i> ; ver o aviso abaixo
Ao acaso (40 sementes)	0.379 ± 0.017	o que "às cegas" quer mesmo dizer
Volatilidade média da empresa	0.662	treze constantes, sem ler manchete nenhuma
O modelo treinado	0.632	o que está implantado

Um aviso sobre a primeira linha, que eu próprio quase publiquei errado. O modelo "alertar sempre" dá a mesma pontuação a todas as notícias. Quando todas empatam, a métrica escolhe pela ordem em que as linhas aparecem no ficheiro, e o ficheiro está ordenado por data e por nome da empresa. Ou seja, esse 0.163 **não mede escolher ao acaso: mede escolher por ordem alfabética**, e todas as linhas que ele seleciona pertencem à empresa que vem primeiro no alfabeto. Comparado com o chão certo, o ganho do modelo é de 1.67 vezes, e não das quase quatro vezes que a primeira leitura sugeria. Deixo isto escrito porque foi um erro meu, e porque a lição é geral: *verificar o que a linha de base mede é tão importante como verificar o que o modelo faz.*

Há ainda a terceira linha, que é desconfortável e fica. Uma tabela de **treze constantes**, a volatilidade média de cada empresa, calculada só sobre o bloco de treino e sem ler uma única manchete, obtém 0.662 e **bate o modelo treinado**. É o terceiro caso deste capítulo em que o método mais simples ganha. O que a evidência sustenta, portanto, é que *ordenar por volatilidade* compensa; não que *aprender* compense.

5.4.5 E em produção?

O sistema regista todas as decisões de triagem e, dias depois, verifica o que realmente aconteceu. Sobre 530 decisões já maturadas, o modelo não mostra benefício: as notícias que ele deixou passar eram importantes 59.2% das vezes, contra 64.7% das que ele travou.

A explicação mais provável não é que o modelo esteja avariado, mas que esteja a **mais**. Quando ele é chamado, as notícias já passaram pelo filtro de relevância e pelo de frescura. Esses filtros baratos já removeram grande parte do que o modelo foi treinado para remover, e sobra-lhe pouco para separar. **Um modelo avaliado isolado e implantado atrás de filtros nunca foi avaliado na distribuição que vai ver.** É a lição mais transferível deste trabalho.

5.4.6 O que isto não permite concluir

Que o texto de notícias não sirva para nada. Só se testou uma representação (manchetes, sem o corpo do artigo) sobre um corpus. Com textos completos e mais dados, a resposta podia ser outra, e isso fica como trabalho futuro, não como desculpa.

5.5 Resumo dos três resultados

A Tabela 5.6 junta as três. Duas das respostas são afirmativas e uma é negativa. A negativa é a que eu mais aprendi a defender: mostra que a avaliação foi montada para poder dizer

5.5. Resumo dos três resultados

Tabela 5.6: O veredicto de cada questão de investigação.

Pergunta	Resposta	Com base em quê
QI1 detecção	Sim	Amplitude de disparo 0.015 contra 0.344; e ganha a dois métodos aprendidos (F_1 0.530 contra 0.269 e 0.280)
QI2 preceden-tes	Sim	Precisão@5 de 0.514 contra 0.346 (palavras), 0.240 (acaso) e 0.126 (recência); 0.595 à escala
QI3 triagem	Não	Nenhum modelo com texto bate a volatilidade (0.496 contra 0.542), e o resultado aguenta três testes de robustez

que não, e uma avaliação que só sabe dizer que sim não avalia nada.

Capítulo 6

Conclusões

6.1 O que ficou feito

No fim, o que é que existe?

Existe um sistema a funcionar, e não uma demonstração. O InvestiGator vigia doze empresas, corre de forma contínua, e envia alertas explicados a um canal público, com uma página web onde tudo o que foi enviado pode ser consultado depois.

E existe uma avaliação de cada uma das três técnicas, contra alternativas mais simples, com os resultados reportados como se revelaram. É essa a parte que dá a este trabalho o carácter de dissertação e não o de projeto.

6.2 As respostas às perguntas de investigação

QI1, deteção. Sim. Um z-score deslizante deteta movimentos invulgares de forma muito mais consistente entre empresas do que uma regra fixa: uma amplitude de disparo de 0.015 contra 0.344, mais de vinte vezes melhor. E, sujeito a uma comparação justa, ganha também a dois métodos de aprendizagem desenhados para esta tarefa.

QI2, precedentes. Sim. A recuperação por significado encontra notícias passadas relacionadas melhor do que procurar por palavras, do que escolher ao acaso e do que devolver as mais recentes (0.514 contra 0.346, 0.240 e 0.126), e o resultado aguenta à escala do corpus completo (0.595). Com uma ressalva que ficou clara ao medir: a semelhança capta o **tema**, não a **direção**.

QI3, triagem. Não. Nenhum modelo que lê o texto da manchete bateu uma linha de base que usa apenas volatilidade (0.496 contra 0.542). O resultado sobreviveu a um re-teste em condições favoráveis ao texto, a uma reamostragem por grupos, e a nove definições diferentes do rótulo.

Esta última resposta é negativa e é a que eu levo mais a sério. Escrevi o critério de sucesso antes de correr a experiência, e o resultado foi ao contrário do que eu esperava. Reportá-lo tal como caiu era a única opção compatível com o resto do trabalho.

6.3 Os objetivos, um a um

Dos quatro objetivos da Secção 1.3, **três estão cumpridos e um está cumprido por metade**.

1. *Construir o sistema completo.* Cumprido. Os dois gatilhos funcionam de ponta a ponta, em produção.
2. *Avaliar cada componente contra linhas de base transparentes.* Cumprido, e mais do que o prometido: o detetor foi comparado não só com uma regra fixa mas também com dois métodos aprendidos.
3. *Garantir que as explicações são fiéis.* **Cumprido por metade.** A fidelidade está garantida por construção: o texto é montado a partir dos objetos calculados, e não pode divergir deles. Mas a *utilidade* para uma pessoa real não foi medida, porque não se chegou a fazer um estudo com utilizadores. Não se afirma nada sobre ela.
4. *Reportar os resultados tal como se revelarem.* Cumprido, e a prova é o resultado negativo da QI3 estar no documento com o mesmo destaque dos outros dois.

6.4 Limitações

Onde é que este trabalho é fraco?

Ditas em voz alta, por ordem de importância.

Não há estudo com utilizadores. É a lacuna maior e a mais fácil de nomear. Todo o sistema é construído à volta da ideia de que uma explicação ajuda um não-especialista a decidir melhor, e essa ideia **não foi testada com pessoas**. O desenho do estudo existe, com participantes, tarefas e critérios definidos, mas não foi corrido a tempo. Enquanto isso não acontecer, a metade “útil” do terceiro objetivo fica sem resposta, e é assim que está escrito.

Os alertas ainda não estão bem calibrados, e sei disso a usar. Esta é a limitação que mais me incomoda, precisamente porque a noto como utilizador e não nos números. Recebo no telemóvel, por outras vias, notícias sobre estas empresas que o sistema não assinalou. E há dias em que uma ação sobe bastante e não gera alerta nenhum.

Parte disto está medido: sobre um ano de notícias captadas, existia pelo menos uma notícia relevante em 88.5% dos dias que o detetor considerou invulgares. Os restantes 11.5% são dias em que **nenhuma alteração ao código ajuda**: se a fonte gratuita não associou nenhuma notícia à empresa, ela nunca entra no funil. E a cobertura é muito desigual: a empresa pior coberta fica-se pelos 50%.

Mas esse número é um **limite superior**, e a distinção importa: ele pergunta se existia *uma* notícia, não se chegou a *certa*. Saber isso exigiria julgamento humano dia a dia, e é trabalho por fazer.

As notícias são só manchetes. O sistema lê o título e não o corpo do artigo. Isso limita o que a representação de texto consegue captar, e é uma explicação plausível, embora não confirmada, para o resultado negativo da QI3.

Os rótulos são aproximações. “Relevante” é aproximado por “mesmo setor”, e “importante” é aproximado por “houve movimento grande”. As duas são objetivas e verificáveis, mas nenhuma é a coisa que realmente se queria medir.

O modelo treinado não mostra benefício em produção. Medido sobre as decisões já verificadas, o modelo não separa melhor do que o acaso na população que realmente vê. A explicação mais provável é que ele esteja a mais: quando é chamado, os filtros mais baratos já removeram quase tudo o que ele foi treinado para remover.

O atraso é real e não se resolve com engenharia. Entre a notícia ser publicada e o sistema a ver passam, em mediana, cerca de duas horas e meia. A entrega, depois disso, demora um segundo. Comprar um serviço de notícias em tempo real resolveria e violaria a restrição fundadora deste trabalho.

6.5 O que eu faria a seguir

Se houvesse mais três meses, por onde começava?

Por esta ordem, e as três primeiras respondem diretamente às limitações acima.

1. **Correr o estudo com utilizadores.** Seis a dez pessoas, quinze minutos cada. Fecha a metade em aberto do terceiro objetivo e é a única coisa desta lista que não se pode acelerar com mais computação: precisa de calendário.
2. **Estudar a sério os critérios de alerta.** É o trabalho que a limitação anterior pede. Não basta ajustar limiares: é preciso perceber, com julgamento humano sobre uma amostra de dias, quais das notícias que hoje não passam *deviam* passar, e quais das que passam não acrescentam nada. Isso daria pela primeira vez um alvo real para otimizar, em vez de se estar a afinar constantes contra um proxy.
3. **Ler o corpo dos artigos, e não só o título.** É a hipótese mais direta para explicar o negativo da Q13, e é testável com o mesmo protocolo já montado.
4. **Detetar histórias repetidas por significado.** Hoje a repetição é apanhada por palavras em comum. Fazê-lo por significado usaria a técnica que o sistema já tem, e atacaria de frente a fadiga de alertas.

6.6 O que eu aprendi

Termino com aquilo que mudou na minha cabeça ao longo destes meses, porque é a parte que não estava no plano.

A primeira coisa foi perceber que **a linha de base é tão importante como o modelo**. Passei semanas a melhorar modelos e o resultado mais útil de todo o trabalho veio de olhar com atenção para aquilo contra o qual os estava a comparar. Numa das medições, o valor que eu usava como “escolher às cegas” não escolhia às cegas de todo: escolhia por ordem alfabética. Corrigir isso reduziu para menos de metade um ganho que eu já tinha escrito.

A segunda foi perceber que **o sítio onde se põe um modelo importa tanto como o modelo**. O meu funcionava razoavelmente quando avaliado sozinho e deixou de servir para nada quando colocado atrás de dois filtros simples, que já faziam grande parte do trabalho.

Isso não estava em nenhum sítio do plano inicial, e é provavelmente a lição mais transferível que levo daqui.

E a terceira foi mais simples do que as outras: **a técnica mais simples ganhou três vezes**. Ganhou ao Isolation Forest, ganhou ao modelo que lê o texto, e uma tabela de treze constantes ganhou ao modelo que está implantado. Comecei este trabalho a assumir que o caminho para um bom resultado era acrescentar sofisticação. Acabo-o com três medições a dizer o contrário, e com a convicção de que a parte difícil da engenharia de inteligência artificial não é escolher a técnica mais avançada, é montar a avaliação que consegue dizer que ela não era precisa.

Bibliografia

- Aamodt, Agnar e Enric Plaza (1994). «Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches». Em: *AI Communications* 7.1, pp. 39–59. doi: 10.3233/AIC-1994-7104.
- Adadi, Amina e Mohammed Berrada (2018). «Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)». Em: *IEEE Access* 6, pp. 52138–52160. doi: 10.1109/ACCESS.2018.2870052.
- Araci, Dogu (2019). «FinBERT: Financial Sentiment Analysis with Pre-trained Language Models». Em: *arXiv preprint*. arXiv: 1908.10063 [cs.CL].
- Barredo Arrieta, Alejandro et al. (2020). «Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI». Em: *Information Fusion* 58, pp. 82–115. doi: 10.1016/j.inffus.2019.12.012.
- Breunig, Markus M. et al. (2000). «LOF: Identifying Density-Based Local Outliers». Em: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104. doi: 10.1145/342009.335388.
- Brown, Stephen J. e Jerold B. Warner (1985). «Using Daily Stock Returns: The Case of Event Studies». Em: *Journal of Financial Economics* 14.1, pp. 3–31. doi: 10.1016/0304-405X(85)90042-X.
- Chandola, Varun, Arindam Banerjee e Vipin Kumar (2009). «Anomaly Detection: A Survey». Em: *ACM Computing Surveys* 41.3, 15:1–15:58. doi: 10.1145/1541880.1541882.
- D’Acunto, Francesco, Nagpurnanand Prabhala e Alberto G. Rossi (2019). «The Promises and Pitfalls of Robo-Advising». Em: *The Review of Financial Studies* 32.5, pp. 1983–2020. doi: 10.1093/rfs/hhz014.
- Devlin, Jacob et al. (2019). «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». Em: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, pp. 4171–4186. doi: 10.18653/v1/N19-1423. arXiv: 1810.04805.
- Dong, Zihan, Xinyu Fan e Zhiyuan Peng (2024). «FNSPID: A Comprehensive Financial News Dataset in Time Series». Em: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD ’24)*. Association for Computing Machinery, pp. 4918–4927. doi: 10.1145/3637528.3671629. arXiv: 2402.06698 [q-fin.ST].
- Fama, Eugene F. (1970). «Efficient Capital Markets: A Review of Theory and Empirical Work». Em: *The Journal of Finance* 25.2, pp. 383–417. doi: 10.2307/2325486.
- Gallup (2025). *What Percentage of Americans Own Stock?* url: <https://news.gallup.com/poll/266807/percentage-americans-owns-stock.aspx> (acedido em 21/06/2026).
- Google (jun. de 2026). *Our latest Google Finance upgrades, including a new app*. url: <https://blog.google/products-and-platforms/products/search/google-finance-updates-june-2026/> (acedido em 07/08/2026).
- Lee, John D. e Katrina A. See (2004). «Trust in Automation: Designing for Appropriate Reliance». Em: *Human Factors* 46.1, pp. 50–80. doi: 10.1518/hfes.46.1.50_30392.

- Liu, Fei Tony, Kai Ming Ting e Zhi-Hua Zhou (2008). «Isolation Forest». Em: *2008 Eighth IEEE International Conference on Data Mining (ICDM)*, pp. 413–422. doi: 10.1109/ICDM.2008.17.
- Mikolov, Tomas et al. (2013). «Efficient Estimation of Word Representations in Vector Space». Em: *arXiv preprint*. arXiv: 1301.3781.
- Niculescu-Mizil, Alexandru e Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». Em: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, pp. 625–632. doi: 10.1145/1102351.1102430.
- Reimers, Nils e Iryna Gurevych (2019). «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». Em: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. doi: 10.18653/v1/D19-1410.
- Robinhood Markets (mar. de 2025). *Introducing Robinhood Strategies, Robinhood Banking, and Robinhood Cortex*. url: <https://robinhood.com/us/en/newsroom/introducing-strategies-banking-and-cortex/> (acedido em 07/08/2026).
- Salton, Gerard, A. Wong e C. S. Yang (1975). «A Vector Space Model for Automatic Indexing». Em: *Communications of the ACM* 18.11, pp. 613–620. doi: 10.1145/361219.361220.
- Securities Industry and Financial Markets Association (SIFMA) (2025). *2025 Capital Markets Fact Book*. url: <https://www.sifma.org/resources/research/fact-book/> (acedido em 21/06/2026).
- Tetlock, Paul C. (2007). «Giving Content to Investor Sentiment: The Role of Media in the Stock Market». Em: *The Journal of Finance* 62.3, pp. 1139–1168. doi: 10.1111/j.1540-6261.2007.01232.x.
- Wu, Shijie et al. (2023). «BloombergGPT: A Large Language Model for Finance». Em: *arXiv preprint*. arXiv: 2303.17564 [cs.LG].

Apêndice A

Reprodutibilidade

A.1 Ambiente

O sistema está escrito em Python 3.12. As dependências estão fixadas num ficheiro de bloqueio, para que o ambiente possa ser recriado noutra máquina. A Tabela A.1 lista as principais.

Tabela A.1: Versões fixadas das dependências principais.

Biblioteca	Versão	Biblioteca	Versão
numpy	2.1.3	sentence-transformers	5.6.0
pandas	2.2.3	transformers	5.12.1
scikit-learn	1.9.0	torch (versão CPU)	2.12.1
matplotlib	3.11.0	pytest	8.3.4
yfinance	1.4.1	ruff	0.8.6

Não é preciso GPU. Tudo o que esta dissertação reporta corre num computador portátil comum, o que é uma consequência deliberada das escolhas do Capítulo 3.

O código está organizado por componente, a espelhar a Figura 4.1: dados de mercado, recolha de notícias, deteção, motor de correlação, base de casos, motor de explicação e entrega. A lógica pura está separada da entrada e saída, e as dependências pesadas são carregadas só quando precisas, e por isso o núcleo é testado sem rede e sem carregar modelos. A suite tem **726 testes** automáticos.

Os segredos (chaves de API, credenciais) são lidos de um ficheiro local que nunca é versionado.

A.2 Como cada número é reproduzido

Nenhum *resultado* desta dissertação foi escrito à mão. Cada um é produzido por um procedimento automático com semente fixa, que escreve o seu próprio ficheiro de resultados; o texto cita esse ficheiro. A Tabela A.2 liga cada resultado ao procedimento que o gera. Os restantes números do documento são de dois tipos, e nenhum deles é uma medição minha: valores retirados das fontes citadas, e constantes de configuração do sistema.

Tabela A.2: Todos os resultados reportados, e onde são gerados. Correr outra vez sobre os mesmos dados devolve exatamente os mesmos valores.

Resultado	Valor	Onde aparece
Amplitude da taxa de disparo (z-score vs limiar fixo)	0.015 vs 0.344	§5.2
F_1 contra o rótulo aproximado	0.516 vs 0.218	§5.2
z-score contra dois detetores aprendidos	0.530 / 0.269 / 0.280	§5.2
Precisão@5 da recuperação (4 métodos)	0.514 / 0.346 / 0.240 / 0.126	§5.3
Precisão@5 sobre o corpus completo	0.595	§5.3
Concordância de direção vs chão de acaso	0.708 vs 0.688	§5.3
Triagem, PR-AUC das seis famílias	0.378 a 0.542	§5.4
Precisão dentro do orçamento (4 formas de escolher)	0.163 / 0.379 / 0.662 / 0.632	§5.4
Grelha de nove definições de rótulo	9 de 9	§5.4
Decisões maturadas em produção	0.592 vs 0.647	§5.4
Cobertura das notícias em dias invulgares	88.5%	§6.4
Latência, por era e decomposta	196 / 143 / 158 min	§4.7
Funil de produção (captadas → enviadas)	944 → 42	§4.5

A.3 Matriz de evidência

A tabela anterior lista *resultados*. Esta lista *afirmações*, que é um teste mais duro, porque uma afirmação pode sobreviver à evidência que a sustentava.

A Tabela A.3 põe cada afirmação substantiva desta dissertação frente à evidência que a suporta e ao estado em que ficou. **As afirmações retiradas ficam na tabela em vez de serem apagadas**, porque uma matriz que só lista as sobreviventes não é uma auditoria.

Duas observações sobre a tabela no seu conjunto, e não sobre nenhuma linha.

Primeiro: **quatro afirmações foram retiradas, e todas o foram pelas medições deste próprio trabalho**, nenhuma por revisão externa. É o comportamento pretendido de uma avaliação desenhada antes das experiências: tem de ser capaz de dizer que não.

Segundo: as duas linhas marcadas “não afirmado” são tão importantes como as outras. Uma delas é a utilidade para o utilizador, que não foi medida porque não houve estudo com pessoas. Onde não há evidência, não há afirmação.

A.4 Dados e atribuição

Os ficheiros de dados grandes não são versionados: são regenerados pelos procedimentos de preparação, e apenas pequenas amostras acompanham o código para que os testes corram sem rede.

O conjunto histórico usado para construir a base de casos é o FNSPID (Dong, Fan e Peng 2024), utilizado ao abrigo da sua licença Creative Commons BY-SA 4.0, cuja atribuição é aqui cumprida. Apenas excertos mínimos de manchetes aparecem no documento, a título ilustrativo.

A.4. Dados e atribuição

Tabela A.3: Cada afirmação, a evidência, e o que lhe aconteceu. “Retirada” significa que este trabalho a abandonou depois de a medir.

Afirmação	Evidência	Estado
QI1, deteção		
Dispara a um ritmo comparável entre empresas muito diferentes	Amplitude 0.015 vs 0.344, sem usar rótulos	Mantida
Bate um limiar fixo no rótulo aproximado	F_1 0.516 vs 0.218	Mantida (o rótulo é um proxy)
Bate dois detetores aprendidos com a mesma informação	F_1 0.530 vs 0.269 e 0.280	Mantida
Não usa informação do futuro	A janela exclui o dia julgado; imposto por teste	Mantida
QI2, precedentes		
Bate as alternativas lexical e triviais	P@5 0.514 vs 0.346 / 0.240 / 0.126	Mantida
Aguenta à escala do corpus completo	P@5 0.595	Mantida
Capta tema, não direção	Concordância 0.708 contra um chão de 0.688	Mantida (é uma limitação)
“Relevante” é o mesmo que “mesmo setor”	—	Não afirmado (é um proxy)
O chão de semelhança escolhe precedentes que preveem melhor	Acima do chão 0.504, abaixo 0.506, acaso 0.507	Retirada
QI3, triagem		
Nenhum modelo com texto bate a volatilidade	PR-AUC 0.496 vs 0.542; aguenta re-teste justo, reamostragem por grupos e nove rótulos	Mantida
Sem uso de informação futura nas features	Mutar o futuro deixa as features iguais e muda o rótulo	Mantida
A triagem quase quadruplica a precisão no orçamento	O chão de 0.163 ordena alfabeticamente; ao acaso dá 0.379	Retirada (o ganho é 1.67×)
É a aprendizagem que produz o ganho no orçamento	Um prior de 13 constantes dá 0.662 contra 0.632 do modelo	Retirada
O modelo implantado seleciona melhor do que o acaso	0.592 mantidas contra 0.647 suprimidas	Retirada
Sistema		
O texto do alerta não pode divergir do cálculo	É montado a partir dos objetos calculados	Mantida
A fonte gratuita limita a cobertura	Pelo menos uma notícia em 88.5% dos dias invulgares	Mantida (limite superior)
As explicações são <i>úteis</i> a uma pessoa	—	Não afirmado

Os preços vêm de serviços gratuitos de dados de mercado, através de uma cadeia de alternativas descrita na Secção 4.2; as notícias em tempo real vêm de uma API gratuita, dentro dos seus limites de utilização. Não é recolhido nem armazenado qualquer dado pessoal: o sistema não sabe o que os utilizadores possuem, e não lhes pergunta.