



Instituto Superior de
Engenharia do Porto



DEPARTAMENTO DE ENGENHARIA
INFORMÁTICA

Alertas Financeiros Explicáveis para Investidores de Retalho: Detecção de Anomalias, Recuperação de Precedentes e Triagem Aprendida

Henrique José da Silva Santos

Aluno nº: 1180934

**Dissertação para obtenção do Grau de
Mestre em Engenharia de Inteligência Artificial**

Orientador: Luís Gomes
Co-Orientador: Rafael Silva

Júri:

Presidente:
[A definir]

Vogais:
[A definir]

Porto, 17 de agosto de 2026

Declaração de Integridade

Declaro que realizei este trabalho acadêmico com integridade.

Não recorri a plágio nem a qualquer forma de utilização indevida ou falsificação de informações ou resultados ao longo do processo que conduziu à sua elaboração.

Declaro, por isso, que este documento é original e da minha autoria, não tendo sido utilizado anteriormente para qualquer outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

Uso de Inteligência Artificial. Em conformidade com as orientações do P.PORTO/ISEP, declaro que foram utilizadas ferramentas de inteligência artificial generativa ao longo do desenvolvimento deste trabalho, e declaro-o na sua extensão real. Foram usadas para escrever e reestruturar parte substancial do código do sistema e dos seus testes, para implementar os procedimentos de avaliação, para redigir e editar prosa neste documento, e para conduzir revisões que encontraram defeitos no software e no texto.

O que é meu é o trabalho para onde essas ferramentas foram apontadas: a escolha do problema, as questões de investigação, as restrições que definem o sistema (apenas fontes gratuitas, explicabilidade primeiro, e a recusa de prever preços), e todas as decisões sobre o que construir, manter ou descartar. Sempre que uma medição contrariou uma afirmação minha, retirei a afirmação em vez de a defender. Revi o conteúdo deste documento, e ele, os erros que nele restem, e a sua defesa são da minha responsabilidade.

ISEP, Porto, 17 de agosto de 2026

Dedicatória

À minha família.

Resumo

Quando uma ação se move de forma abrupta, um investidor não profissional faz sempre as mesmas três perguntas: *isto é invulgar?*, *foi a empresa ou foi o mercado?*, e *já aconteceu antes, e o que se seguiu?* As ferramentas gratuitas mostram a percentagem e ficam-se por aí; os terminais profissionais respondem, mas a um custo fora do alcance de quem investe as suas poupanças.

Esta dissertação apresenta o **InvestiGator**, um sistema de alertas financeiros construído sobre fontes de dados gratuitas, que responde às três perguntas e mostra sempre como chegou à resposta. O trabalho assenta em três técnicas: deteção de anomalias por z-score deslizante, recuperação de precedentes por semelhança semântica com medição do desfeito observado, e um modelo supervisionado de triagem, treinado sobre um conjunto de dados próprio, para decidir que notícias merecem interromper alguém.

Cada componente foi avaliado contra linhas de base transparentes, e os resultados são reportados tal como se revelaram. A deteção normalizada pela volatilidade dispara de forma muito mais consistente entre empresas do que um limiar fixo. A recuperação semântica supera as linhas de base lexical e triviais. O modelo de triagem, treinado em 79 753 exemplos, **não** superou uma linha de base que usa apenas volatilidade, um resultado negativo que se reporta, e que valida por medição a opção pela simplicidade que atravessa todo o trabalho.

O sistema recusa, por desenho, prever preços: explica o que já aconteceu, com a evidência ao lado. **Palavras-chave:** IA Explicável, Alertas Financeiros, Deteção de Anomalias,

Recuperação Semântica, Investidores de Retalho

Abstract

When a stock moves abruptly, a non-professional investor always asks the same three questions: *is this unusual?*, *was it the company or the market?*, and *has this happened before, and what followed?* Free tools show the percentage and stop there; professional terminals do answer, at a subscription cost beyond someone investing their savings.

This dissertation presents **InvestiGator**, a financial alerting system built on free data sources that answers those three questions and always shows how it reached the answer. The work rests on three techniques: anomaly detection with a rolling z-score, precedent retrieval by semantic similarity with measurement of the observed outcome, and a supervised triage model, trained on a purpose-built dataset, to decide which news deserves interrupting someone.

Each component was evaluated against transparent baselines, and the results are reported exactly as they fell. Volatility-normalised detection fires far more consistently across companies than a fixed threshold. Semantic retrieval beats lexical and trivial baselines. The triage model, trained on 79 753 examples, did **not** beat a volatility-only baseline, a negative result that is reported, and that validates by measurement the simplicity-first stance running through the work.

By design, the system refuses to predict prices: it explains what already happened, with the evidence beside it. **Keywords:** IA Explicável, Alertas Financeiros, Detecção de Anomalias,

Recuperação Semântica, Investidores de Retalho

Agradecimentos

Ao meu orientador, Prof. Luís Gomes, e ao meu coorientador, Rafael Silva, por todo o apoio ao longo desta tese. Por trocarem ideias comigo e me ajudarem a decidir a direção do tema; por me mostrarem exemplos de aplicações que já existem e me manterem a par do que se vai fazendo na área; e por me guiarem na elaboração deste documento. Muito do que aqui está tomou a forma que tem porque houve antes uma conversa com eles.

À minha família, por todo o apoio e por acreditarem em mim. Por me incentivarem sempre, e pela alegria com que foram acompanhando a construção disto. É, para mim, a melhor parte de o ter feito.

Aos meus colegas da Sistrade, e à Sistrade, pela flexibilidade que me permitiu seguir este mestrado a par do trabalho, pelas opiniões e pelo feedback que foram dando sobre a aplicação, e por serem boa companhia todos os dias.

Índice

Lista de Acrónimos	xxi
1 Introdução	1
1.1 De onde veio este trabalho	1
1.2 O que o sistema faz, numa página	1
1.3 Objetivos e perguntas de investigação	3
1.4 Contribuições	3
1.5 Como ler este documento	4
2 Contexto	5
2.1 O que existe hoje para quem investe pouco	5
2.2 Os produtos que fazem exatamente esta pergunta	6
2.3 E um assistente de IA genérico?	6
2.4 As peças técnicas que este trabalho usa	6
2.5 As escolhas que este trabalho faz	8
3 Metodologia	9
3.1 As três decisões	9
3.2 Os dados, tal como são	9
3.2.1 O que entra: uma notícia histórica	9
3.2.2 O que é construído: uma linha do conjunto de treino	10
3.2.3 O que é guardado: um caso na base de precedentes	10
3.2.4 Que períodos, exatamente	11
3.3 Técnica 1: detetar o que é invulgar	12
3.3.1 O problema, em palavras	12
3.3.2 A ideia: medir em desvios-padrão	12
3.3.3 A janela que anda, e a regra que a protege	13
3.3.4 Um caso real	13
3.4 Técnica 2: encontrar casos parecidos	14
3.4.1 O problema, em palavras	14
3.4.2 A ideia: transformar frases em pontos	14
3.4.3 Medir a distância: o cosseno	15
3.4.4 O cosseno em dois casos reais	16
3.4.5 Medir o que se seguiu	16
3.5 Técnica 3: decidir o que merece um alerta	17
3.5.1 O problema, em palavras	17
3.5.2 A tarefa e o rótulo	17
3.5.3 O que o modelo vê	18
3.5.4 Treinar sem fazer batota com o tempo	18
3.5.5 Da pontuação à probabilidade: calibração	19
3.5.6 Da linha de dados aos 39%: a conta toda	19

3.6	Como é que se sabe que isto funciona	20
4	O Sistema	21
4.1	Vista de conjunto	21
4.2	De onde vêm os dados	21
4.3	As peças que não são minhas	22
4.4	O caminho de uma notícia, do princípio ao fim	22
4.5	O caminho de um movimento de preço	23
4.6	As portas: quando o sistema decide calar-se	24
4.7	Como o alerta é explicado	24
4.8	Onde isto corre, e o que isso custou	26
5	Avaliação	31
5.1	Como está montado este capítulo	31
5.2	Como se lê cada número deste capítulo	31
5.2.1	As quatro maneiras de acertar e de errar	31
5.2.2	Precisão e cobertura	32
5.2.3	O F_1 : obrigar as duas a andarem juntas	32
5.2.4	A precisão@ k : avaliar uma lista curta	33
5.2.5	A PR-AUC: a lista toda, em todos os pontos de corte	34
5.2.6	O Brier: a probabilidade tem de ser honesta	35
5.2.7	Qual medida responde a que pergunta	35
5.3	QI1: detetar o que é invulgar	35
5.3.1	Como foi medido	36
5.3.2	Resultado	36
5.3.3	E contra métodos aprendidos?	37
5.3.4	E uma segunda comparação, que também não me deu razão	38
5.3.5	O que isto não permite concluir	38
5.4	QI2: encontrar casos parecidos	39
5.4.1	Como foi medido	39
5.4.2	Resultado	39
5.4.3	Aguenta à escala?	39
5.4.4	O que isto não permite concluir	40
5.5	QI3: decidir o que merece um alerta	40
5.5.1	Como foi medido	40
5.5.2	Resultado	40
5.5.3	Não será um acidente do meu setup?	41
5.5.4	Mas serve para alguma coisa?	42
5.5.5	E em produção?	43
5.5.6	E o que é que o portão estava a escolher, afinal?	43
5.5.7	A correção óbvia, e porque é que não servia	44
5.5.8	O que isto não permite concluir	45
5.6	Todas as alternativas que foram testadas e não ficaram	45
5.7	Resumo dos três resultados	46
6	Conclusões	47
6.1	O que ficou feito	47
6.2	As respostas às perguntas de investigação	47
6.3	Os objetivos, um a um	48

6.4	Limitações	48
6.5	O que eu faria a seguir	49
6.6	O que eu aprendi	49
Bibliografia		51
A	Reprodutibilidade	53
A.1	Ambiente	53
A.2	Como cada número é reproduzido	53
A.3	Matriz de evidência	54
A.4	Dados e atribuição	54

Lista de Figuras

1.1	Capitalização do mercado acionista dos EUA	2
1.2	O que o sistema faz	2
2.1	Três gerações de representação de texto	7
3.1	As três decisões do sistema	9
3.2	Uma linha do conjunto de dados histórico	10
3.3	Uma linha do conjunto de treino, inteira	10
3.4	Um caso guardado na base de precedentes	11
3.5	A janela deslizante do z-score	13
3.6	Frases como pontos num espaço	15
3.7	Como se mede o impacto de uma notícia	17
3.8	Divisão temporal com embargo	18
4.1	Arquitetura do sistema	21
4.2	As nove etapas de um alerta	23
4.3	Um alerta real, tal como foi entregue	25
4.4	Onde cada peça corre	26
5.1	As quatro combinações possíveis	32
5.2	A precisão@5 numa consulta	33
5.3	Como se lê uma curva de precisão–cobertura	34
5.4	Taxa de disparo por empresa	37
5.5	A regra contra os métodos aprendidos	38
5.6	Recuperação, por setor e por tamanho de lista	40
5.7	As curvas de precisão e cobertura da triagem	41
5.8	O que o portão separava	43

Lista de Tabelas

2.1	As ferramentas existentes contra as três perguntas	5
3.1	O dicionário de colunas	11
3.2	O intervalo real de cada conjunto de dados	12
3.3	O z-score de um dia real, passo a passo (Tesla, 24 de outubro de 2024).	14
3.4	O cosseno entre duas manchetes reais	16
3.5	Uma linha, do início ao fim	20
4.1	Tudo o que o sistema usa de fora	28
4.2	Uma notícia real, etapa a etapa	29
4.3	O funil de um dia real	29
4.4	As portas e as suas constantes	30
4.5	O que o ciclo de 60 segundos comprou	30
5.1	As medidas usadas e o que cada uma responde	36
5.2	Consistência da taxa de disparo	36
5.3	A regra transparente contra dois métodos aprendidos	37
5.4	Recuperação: o método contra três alternativas triviais	39
5.5	Triagem: seis modelos sobre o mesmo bloco de teste	41
5.6	Precisão dentro de um orçamento de cinco alertas por dia	42
5.7	Cada escolha, contra a alternativa que perdeu	45
5.8	As três perguntas e as suas respostas	46
A.1	Versões fixadas das dependências principais.	53
A.2	Cada resultado e o procedimento que o produz	54
A.3	Matriz de evidência	55

Lista de Acrónimos

API Interface de Programação de Aplicações.

CI Integração Contínua.

CSV Comma-Separated Values.

FNSPID Financial News and Stock Price Integration Dataset.

JSON JavaScript Object Notation.

QI Questão de Investigação.

RSS Really Simple Syndication.

Capítulo 1

Introdução

1.1 De onde veio este trabalho

Que problema é este, e porque é que vale a pena resolvê-lo?

Hoje é fácil comprar ações. Basta uma aplicação no telemóvel e alguns minutos. A maior parte das famílias americanas já tem ações, diretamente ou através de fundos e planos de reforma (Gallup 2025), e o mercado onde investem vale mais de 62 biliões de dólares (Securities Industry and Financial Markets Association (SIFMA) 2025) (Figura 1.1).

Difícil é a parte seguinte: perceber o que aconteceu quando o preço se mexe.

Imagine-se uma pessoa que tem cinco ou seis ações e olha para elas de vez em quando. Um dia abre a aplicação e vê uma delas a cair 4%. A aplicação diz-lhe exatamente isso: menos 4%. E mais nada.

A partir daí a pessoa fica sozinha com três perguntas, e faz sempre estas três, por esta ordem:

1. **Isto é invulgar?** Quatro por cento numa empresa calma é muito. Na mesma semana, e noutra empresa, pode ser um dia perfeitamente normal.
2. **Foi a empresa, ou foi o mercado?** Se caiu tudo, a história é uma. Se caiu só esta, é outra completamente diferente.
3. **Já aconteceu antes, e o que se seguiu?** Se já houve dias parecidos, o que fez o preço a seguir?

As aplicações gratuitas não respondem a nenhuma das três. Mostram a percentagem, que é o princípio da primeira pergunta e não a resposta. Os terminais profissionais respondem às três, mas custam mais por mês do que muita gente investe por ano.

É essa distância que este trabalho tenta encurtar. Não por falta de dados: há dados a mais, e gratuitos. O que falta é **contexto**, e um contexto que a pessoa possa *verificar*.

1.2 O que o sistema faz, numa página

Se tivesse de explicar o InvestiGator numa frase, qual seria?

Esta: **o sistema vigia um conjunto de empresas, deteta quando algo sai fora do normal, e avisa, mas só avisa com a explicação e a evidência ao lado.**




Figura 1.1: Capitalização do mercado acionista dos EUA, 2015–2024, em biliões de dólares. É neste mercado que investem as pessoas de quem este trabalho fala. Elaborado a partir dos dados do SIFMA Capital Markets Fact Book (Securities Industry and Financial Markets Association (SIFMA) 2025).

Há duas maneiras de o sistema começar a prestar atenção, e estão na Figura 1.2. Ou o **preço** se mexe de forma invulgar, ou chega uma **notícia** relevante sobre uma das empresas. Em qualquer dos casos, o que sai do outro lado não é uma notificação seca. É um alerta que diz o que aconteceu, porque é que foi considerado invulgar, de onde vieram os dados, e que casos parecidos já existiram no passado, com o que o preço fez depois deles.




Figura 1.2: Os dois gatilhos e o que sai deles. O que o investidor recebe é um alerta que ele consegue seguir e conferir, e não apenas um aviso de que o preço mexeu.

E o que o sistema recusa fazer

Há uma coisa que este sistema não faz, e não é por não ter dado jeito: **não prevê preços**.

Nunca diz que uma ação vai subir. Nunca diz para comprar ou para vender. Nunca mostra um alvo de preço.

Isto pode parecer uma limitação. É o contrário: é o que torna tudo o resto verificável. Uma afirmação sobre o que *já* aconteceu pode ser confirmada contra o registo no momento em que é lida. Uma previsão não pode: só se saberá se estava certa depois de o investidor já ter tido de decidir. Ao recusar prever, o sistema obriga-se a dizer apenas aquilo que consegue mostrar.

1.3 Objetivos e perguntas de investigação

O que é que este trabalho se propõe descobrir?

O objetivo geral é **desenhar, construir e avaliar** um sistema de alertas financeiros explicável para investidores de retalho, usando apenas fontes de dados gratuitas.

Para lá chegar, o trabalho responde a três perguntas de investigação. Cada uma tem uma medição associada, porque uma pergunta a que não se sabe responder com um número não é uma pergunta de investigação: é uma opinião.

- **Questão de Investigação (QI)1, deteção.** Consegue um método estatístico simples e transparente detetar movimentos invulgares de forma consistente entre empresas com volatilidades muito diferentes, e fazê-lo melhor do que uma regra fixa?
- **QI2, precedentes.** Consegue o sistema encontrar notícias passadas genuinamente parecidas com a atual, melhor do que alternativas triviais, e medir o que aconteceu ao preço a seguir a elas sem usar informação do futuro?
- **QI3, triagem.** Consegue um modelo treinado decidir que notícias merecem um alerta melhor do que uma linha de base simples baseada apenas em volatilidade?

Estas três perguntas dão origem a quatro objetivos concretos:

1. construir o sistema completo, dos dados até ao alerta entregue;
2. avaliar cada componente contra linhas de base transparentes;
3. garantir que as explicações são fiéis ao que o sistema realmente calculou;
4. reportar os resultados tal como se revelarem, incluindo os que forem negativos.

O quarto objetivo é o mais importante e é o mais fácil de trair. Voltarei a ele no Capítulo 6.

1.4 Contribuições

O que é que fica feito no fim?

Esta é uma dissertação de **Engenharia de Inteligência Artificial**. A contribuição não é inventar um algoritmo novo. É escolher, integrar e avaliar criticamente técnicas que já existem, até formarem um sistema que funciona, que se explica, e que outra pessoa consegue reproduzir. Escolher bem é o trabalho de engenharia.

Ficam quatro contribuições:

1. **Um sistema completo e a funcionar**, com os dois gatilhos, sobre fontes gratuitas, e implantado, e não uma demonstração de laboratório.
2. **Um método reprodutível para ligar notícias a impacto de mercado**, que combina recuperação por semelhança semântica com janelas de estudo de evento, sem deixar entrar informação do futuro.
3. **Um conjunto de dados próprio e um modelo treinado sobre ele**: 79 753 exemplos construídos a partir de notícias e preços históricos, com o modelo, a calibração e as métricas guardados como artefactos versionados.

4. **Uma avaliação honesta de cada componente** contra linhas de base transparentes, incluindo o resultado que me correu ao contrário, que está reportado como tal.

1.5 Como ler este documento

Por onde é que isto vai?

O documento foi escrito para ser lido do princípio ao fim, e cada capítulo responde a uma pergunta:

- **Contexto** (Capítulo 2): o que já existe, e porque é que não chega para o problema desta tese.
- **Metodologia** (Capítulo 3): as três técnicas, explicadas devagar e com desenhos.
- **O sistema** (Capítulo 4): como as peças se ligam, e uma notícia real seguida do princípio ao fim.
- **Avaliação** (Capítulo 5): o que foi medido, contra o quê, e com que resultado.
- **Conclusões** (Capítulo 6): o que ficou provado, o que ficou por fazer, e o que eu faria a seguir.

Há um fio que atravessa os capítulos 3 a 5: **a mesma notícia real**, seguida desde o momento em que chega até ao alerta que sai. Sempre que aparecer, é a mesma. Serve para que nada aqui fique abstrato.

Capítulo 2

Contexto

2.1 O que existe hoje para quem investe pouco

Ninguém resolveu isto antes?

Resolveram, em parte, e de maneiras diferentes. Vale a pena olhar para o que existe com um critério fixo, em vez de o descrever em geral. O critério deste trabalho são as três perguntas do Capítulo 1, e a Tabela 2.1 usa-as para pontuar as alternativas.

Tabela 2.1: O que cada tipo de ferramenta responde. “Parcial” significa que dá matéria-prima para a resposta, mas deixa o trabalho ao utilizador.

Ferramenta	É invulgar?	Empresa ou mercado?	Já aconteceu?	Custo
App da corretora	não	não	não	incluído
Agregador de notícias	não	não	não	grátis
App de sentimento	parcial	não	não	grátis/baixo
Robo-advisor	não	não	não	% da carteira
Terminal profissional	sim	sim	sim	milhares/ano
Este trabalho	sim	sim	sim	grátis

A tabela mostra o essencial: **a linha que responde às três perguntas existe, e é a mais cara de todas**. Não há aqui um problema científico por resolver: há um problema de acesso. As respostas são conhecidas; estão atrás de uma subscrição que a pessoa de quem este trabalho fala não vai pagar.

Vale a pena olhar para duas linhas em particular.

A **app da corretora** é onde a maioria das pessoas realmente olha. Mostra a percentagem do dia e um gráfico. Não diz se aquilo é muito para aquela ação, não separa a empresa do mercado, e não tem memória. A pergunta “isto é normal?” fica sem resposta precisamente no sítio onde é feita.

Os *robo-advisors* (D’Acunto, Prabhala e Rossi 2019) respondem a outra pergunta: como distribuir dinheiro por uma carteira. É uma pergunta legítima e não é esta. Além disso, aconselhar sobre investimentos tem obrigações regulatórias que este trabalho evita por desenho (ver Secção 2.5).

2.2 Os produtos que fazem exatamente esta pergunta

E os produtos recentes que prometem explicar porque é que uma ação subiu?

Existem, são recentes, e seria desonesto não os nomear.

O **Robinhood Cortex**, anunciado em março de 2025, declara na página do próprio fornecedor que serve para “responder à velha questão de porque é que esta ação está a subir ou a descer hoje” (Robinhood Markets 2025). Os **momentos-chave** do Google Finance, de junho de 2026, propõem-se “explicar porque é que uma ação se moveu” (Google 2026).

É a mesma pergunta deste trabalho, feita por empresas com muito mais recursos e muito mais utilizadores. Convém dizê-lo com clareza em vez de fingir que este território estava vazio.

A diferença está no que é entregue. Um resumo gerado é uma **afirmação**: o utilizador lê e acredita, ou não. O que este trabalho entrega é uma afirmação **com a evidência anexada**: os casos passados, um a um, com as datas, as semelhanças e o que o preço fez a seguir a cada um. A diferença não é de fluência: é de *verificabilidade*.

Uma ressalva de método, porque é fácil escorregar aqui: destes produtos só se afirma o que está escrito nas páginas dos próprios fornecedores, consultadas em data registada. Não se testaram, e por isso não se diz o que fazem por dentro; diz-se apenas o que declaram fazer.

2.3 E um assistente de IA genérico?

Não bastava perguntar a um modelo de linguagem?

É a objecção mais razoável de todas, e merece resposta séria.

Um assistente genérico responde bem à pergunta, no sentido em que produz um texto fluente e plausível. O problema é o que está por trás desse texto. Ele não tem:

- a **volatilidade recente** daquela ação, que é o que permite dizer se 4% é muito;
- a **separação** entre o que foi o mercado e o que foi a empresa;
- uma **base de casos passados** para *recuperar*. No melhor dos casos *recorda* casos do treino, o que não é a mesma coisa e não é verificável.

E há uma diferença mais funda, que é a razão pela qual este trabalho não é um invólucro à volta de um modelo de linguagem. Modelos grandes especializados em finanças existem (Wu et al. 2023) e são impressionantes. Mas a saída deles é uma afirmação, e a literatura sobre confiança em sistemas automáticos mostra que o problema não é as pessoas confiarem de menos: é confiarem *na medida errada*, o que exige que o sistema mostre em que se apoia (Lee e See 2004).

Por isso, neste trabalho, a linguagem nunca produz factos. Os números vêm dos motores que os calcularam, e o texto é montado a partir deles, como se descreveu na Secção 4.7.

2.4 As peças técnicas que este trabalho usa

De onde vêm as três técnicas do capítulo seguinte?

Nenhuma delas é invenção minha. Todas têm uma literatura, e a contribuição está em escolhê-las, integrá-las e avaliá-las, e não em inventá-las.

Detetar o que é invulgar. A detecção de anomalias é uma área grande (Chandola, Banerjee e Kumar 2009). Para séries temporais financeiras há duas famílias: as **estatísticas**, que comparam o presente com uma norma recente, e as **aprendidas**, que tentam descobrir sozinhas o que é raro, como o *Isolation Forest* (Liu, Ting e Zhou 2008) ou o *Local Outlier Factor* (Breunig et al. 2000). Este trabalho usa a primeira família e compara-a com a segunda no Capítulo 5.

Representar texto: três gerações. Comparar notícias por significado depende de como se representa o texto, e essa representação passou por três gerações, na Figura 2.1.




Figura 2.1: Como se passou de contar palavras a representar o sentido de uma frase inteira. Cada geração resolve uma limitação da anterior.

A primeira geração conta palavras (Salton, Wong e Yang 1975): simples, e cega a sinónimos. A segunda representa cada *palavra* como um vetor (Mikolov et al. 2013), o que aproxima sinónimos, mas cada palavra fica com um sentido fixo, independentemente da frase. A terceira usa modelos que leem a frase toda (Devlin et al. 2019), e permite comparar *frases* diretamente (Reimers e Gurevych 2019). É esta que este trabalho usa.

Existem modelos treinados especificamente para texto financeiro (Araci 2019). Não são automaticamente melhores para esta tarefa, e no Capítulo 5 isso é medido em vez de assumido.

Medir o efeito de um acontecimento. Ligar uma notícia ao que o preço fez a seguir é um problema clássico em finanças, com metodologia estabelecida há décadas: o estudo de evento (Brown e Warner 1985). E que o texto publicado tem relação estatística com os movimentos do mercado é observação antiga (Tetlock 2007).

Raciocinar por casos passados. Mostrar casos anteriores parecidos, em vez de uma regra abstrata, tem nome próprio em inteligência artificial: *raciocínio baseado em casos* (Aamodt e Plaza 1994). É exatamente o que a segunda técnica deste trabalho faz.

Explicar decisões automáticas. Por fim, a exigência de que um sistema mostre *como* chegou a uma conclusão é uma área em si (Adadi e Berrada 2018; Barredo Arrieta et al. 2020). Este trabalho segue a via mais conservadora: em vez de explicar *a posteriori* um modelo opaco, usa componentes cuja explicação é o próprio cálculo.

2.5 As escolhas que este trabalho faz

Face a tudo isto, o que é que fica decidido?

Quatro decisões, e cada uma fecha uma porta de propósito.

Responder às três perguntas, e só a essas. Não se acrescentam funcionalidades que não sirvam uma delas. É o que mantém o sistema pequeno o suficiente para ser explicado por inteiro.

Não prever preços. Nem direção, nem alvo, nem recomendação. Além da razão já dada, que é o que torna tudo verificável, há uma razão teórica: se movimentos futuros fossem previsíveis a partir de informação pública, essa informação já estaria refletida no preço (Fama 1970).

Não gerir carteiras nem aconselhar. O sistema não sabe o que o utilizador tem, e não lhe diz o que fazer. Isto evita recolher dados pessoais e mantém o trabalho fora da fronteira do aconselhamento financeiro regulado.

Só fontes gratuitas. Torna o sistema utilizável por quem ele serve, e transforma as limitações resultantes em algo que se *mede* e reporta, em vez de algo que se compra.

A última merece uma nota honesta. Usar apenas fontes gratuitas limita o sistema de forma real: as notícias chegam com atraso, e nem tudo o que acontece é coberto. O Capítulo 4 quantifica esse atraso e o Capítulo 6 volta a ele. A opção foi ter uma limitação medida em vez de uma capacidade comprada. Mas é uma limitação, e não uma virtude.

Capítulo 3

Metodologia

3.1 As três decisões

O que é que o sistema tem mesmo de decidir?

Tudo o que este trabalho faz cabe em três decisões. Estão na Figura 3.1 e são sempre as mesmas, por esta ordem.




Figura 3.1: As três decisões, e a família de técnicas que responde a cada uma. Cada secção deste capítulo trata de uma coluna.

Cada decisão é tratada com a técnica mais simples que consegue resolvê-la. Isto não é preguiça: é uma escolha de desenho que se paga no Capítulo 5, onde cada técnica é comparada com alternativas mais complicadas. Quando a simples ganha, fica a simples, e diz-se porquê.

3.2 Os dados, tal como são

Antes de explicar o que se faz com os dados: com que é que eles se parecem, exatamente?

Uma dissertação pode descrever dados durante páginas sem que o leitor consiga imaginar uma única linha deles. Esta secção resolve isso da forma mais direta possível: mostra as linhas verdadeiras, copiadas dos ficheiros que o sistema usa.

3.2.1 O que entra: uma notícia histórica

A camada histórica vem do Financial News and Stock Price Integration Dataset (FNSPID) (Dong, Fan e Peng 2024), um conjunto público de notícias financeiras. O ficheiro é um Comma-Separated Values (CSV) com três colunas, e a Figura 3.2 mostra como uma linha se parece:

Repare-se no que *não* está ali. Não há preço, não há reação do mercado, não há indicação de que a notícia seja importante. Uma manchete sobre petróleo aparece etiquetada como

```
date,ticker,headline
2020-03-09,AAPL,"Crude Awakening: Energy Sector Takes A 20% Spill As
Crude Price War Sends Oil To 4-Year Lows"
```

Figura 3.2: Uma linha real do FNSPID, copiada do ficheiro. Três colunas e mais nada: data, empresa, título. Não traz preço, não traz corpo do artigo, e não traz rótulo nenhum. Tudo o resto é construído.

AAPL, o que ilustra bem a qualidade da etiquetagem à entrada e justifica o filtro de relevância descrito no Capítulo 4.

3.2.2 O que é construído: uma linha do conjunto de treino

Do lado de lá do processamento está o conjunto de dados com que o modelo de triagem é treinado. Tem 79 753 linhas. A Figura 3.3 mostra uma delas, inteira, sem cortes.

```
date = 2023-02-02
news_date = 2023-02-02
ticker = AAPL
sector = tech
headline = "Apple (AAPL) Misses Q1 Earnings and Revenue Estimates"
headline_len = 53
vol20 = 0.01266203305026954
mom5 = 0.024854333506149767
ret_event = 0.036392215960942983
label = 1
label_t0.015_h1 = 1   label_t0.015_h3 = 1   label_t0.015_h5 = 1
label_t0.02_h1 = 1   label_t0.02_h3 = 1   label_t0.02_h5 = 1
label_t0.03_h1 = 1   label_t0.03_h3 = 0   label_t0.03_h5 = 0
split = test
```

Figura 3.3: Uma linha real do conjunto de dados de triagem. As nove colunas `label_*` são as nove definições alternativas de rótulo usadas na Secção 5.5: repare-se que a mesma notícia é “importante” com um limiar de 1.5% ou 2% e deixa de o ser a 3% ao fim de três dias.

A Tabela 3.1 diz o que cada coluna é, de onde vem, e a pergunta que mais importa: **consegue esta coluna ver o futuro?** É a pergunta que separa uma avaliação honesta de uma avaliação impossível de acreditar.

As colunas de rótulo **têm** de ver o futuro: é isso que um rótulo é. O que não pode acontecer é uma coluna de *entrada* ver o futuro, e é exatamente isso que o teste descrito na Secção 3.6 verifica automaticamente.

3.2.3 O que é guardado: um caso na base de precedentes

A base de casos é um ficheiro onde cada linha é um objeto JavaScript Object Notation (JSON). A Figura 3.4 mostra um registo real, com o vetor abreviado por ser demasiado longo para caber na página.

Estes três objetos são todo o material do trabalho. Tudo o resto neste capítulo é o que se faz com eles.

3.2. Os dados, tal como são

Tabela 3.1: Cada coluna do conjunto de treino, a sua origem, e se pode ou não conter informação posterior ao momento da decisão.

Coluna	O que é	Vê o futuro?	Origem
date	dia de negociação a que a notícia foi alinhada	não	calculado
news_date	data que a fonte declara para a notícia	não	FNSPID
ticker	empresa	não	FNSPID
sector	setor, de um mapa fixo escrito à mão	não	mapa do autor
headline	o título, tal como veio	não	FNSPID
headline_len	número de caracteres do título	não	calculado
vol120	desvio-padrão dos retornos dos 20 dias anteriores	não	preços
mom5	retorno acumulado dos 5 dias anteriores	não	preços
ret_event	retorno do próprio dia da notícia	não	preços
label	houve movimento anormal em $(d, d+3]$?	sim	preços
label_t*_h*	o mesmo, com nove limiares e horizontes	sim	preços
split	treino, validação ou teste	não	divisão temporal

```
{ "date": "2020-03-09",  
  "ticker": "AAPL",  
  "headline": "Crude Awakening: Energy Sector Takes A 20% Spill ...",  
  "impacts": { "1": 0.0720, "3": -0.0674, "5": -0.0900 },  
  "embedding": [-0.0112, +0.0243, +0.1301, ..., +0.0662] }
```

Figura 3.4: Um registo real da base de casos. O campo `impacts` é o que o preço fez 1, 3 e 5 dias depois, **medido** e não estimado. O campo `embedding` tem 384 números, dos quais se mostram quatro. É este vetor que permite comparar esta notícia com uma de hoje.

3.2.4 Que períodos, exatamente

Uma dissertação que diz “dados de 2018 a 2023” obriga o leitor a acreditar. A Tabela 3.2 diz o intervalo **lido dos próprios ficheiros**, e distingue as duas coisas que é fácil confundir: o material *histórico*, com que se treina e avalia, e o registo do sistema *a funcionar*, que é muito mais recente e muito mais curto.

Os 367 alertas dividem-se em 278 de notícia, 48 de movimento de preço, 24 resumos de fecho e 17 notas de abertura. O primeiro alerta de notícia é de 9 de julho de 2026; o primeiro de movimento, de 13 de julho.

A ressalva da última linha, porque é um defeito que encontrei a escrever esta tabela. O registo do funil guarda apenas os últimos dias, e isso quase passou despercebido. O limite estava escrito em **número de linhas** (5000) e foi dimensionado quando o sistema corria de meia em meia hora, o que dava cerca de oito dias de história. Com o ciclo de 60 segundos passaram a existir trinta vezes mais registos, e o mesmo limite guarda **menos de um dia**: quando fui ler o ficheiro publicado, as 5000 linhas eram todas do próprio dia.

Tabela 3.2: Cada conjunto usado, com o intervalo e a dimensão medidos no ficheiro. As três últimas linhas são o sistema em operação, e a diferença de escala em relação às primeiras é ela própria uma informação.

Conjunto	Intervalo	Dimensão
Histórico: com que se treina e avalia		
Conjunto de treino da triagem	2018-01-02 a 2023-12-18	79 753 exemplos
Preços para a deteção	2023-06-01 a 2026-06-01	15 empresas, $\approx$ 750 dias cada
Operação: o sistema a funcionar		
Alertas entregues ao canal	2026-07-09 a 2026-08-13	367 mensagens
Registo de decisões de triagem	2026-07-22 a 2026-08-15	4 366 decisões
Registo do funil de portas	últimos 3 dias (por desenho)	ver a ressalva abaixo

Uma retenção contada em linhas muda de significado sempre que a cadência muda; contada em dias, não muda. Passou a ser contada em dias. Fica em três, e não numa semana, porque o ficheiro é republicado a cada ciclo e o custo é de publicação, não de armazenamento. A restrição que fixa o número está escrita em vez de parecer arbitrária.

3.3 Técnica 1: detetar o que é invulgar

Como é que um computador decide que 4% é muito?

3.3.1 O problema, em palavras

Não é possível responder com um número fixo.

Uma regra do género “avisar sempre que uma ação se mexer mais de 3%” parece razoável e é má. Para uma empresa calma, como uma cadeia de supermercados, 3% é um acontecimento raro. Para uma empresa volátil, como uma tecnológica em crescimento, 3% acontece muitas vezes por mês. A mesma regra dá quase nenhum alerta na primeira e alertas quase todos os dias na segunda.

O que interessa não é o tamanho do movimento. É o tamanho do movimento **comparado com o que é normal para aquela empresa**.

3.3.2 A ideia: medir em desvios-padrão

A solução é velha e boa, e é a forma mais comum de detetar anomalias em séries temporais (Chandola, Banerjee e Kumar 2009): em vez de comparar com um número fixo, comparo com o comportamento recente da própria ação.

Olho para os últimos vinte dias e pergunto duas coisas: *quanto é que esta ação costuma oscilar?* e *quão longe do costume ficou hoje?* A resposta chama-se **z-score**:

$$z_t = \frac{r_t - \mu}{\sigma} \quad (3.1)$$

3.3. Técnica 1: detetar o que é invulgar

Termo a termo:

- r_t é o retorno de hoje, ou seja, quanto a ação subiu ou desceu;
- μ (mu) é a **média** dos retornos dos vinte dias anteriores: o “centro” do que é normal;
- σ (sigma) é o **desvio-padrão** desses vinte dias: uma medida de quanto a ação costuma oscilar à volta desse centro;
- z_t é o resultado: *a quantos desvios-padrão do normal ficou o dia de hoje.*

Um z de $+1$ quer dizer “ligeiramente acima do costume”. Um z de $+7$ quer dizer “isto quase nunca acontece”. E é aqui que está o essencial: $z = +7$ significa a mesma coisa na empresa calma e na empresa volátil, porque cada uma é comparada consigo própria.

3.3.3 A janela que anda, e a regra que a protege

A Figura 3.5 mostra como isto funciona ao longo do tempo. A janela dos vinte dias desliza: para julgar o dia de hoje, usa os vinte dias *anteriores*; amanhã, desliza um dia.




Figura 3.5: A janela que define “o normal”. O dia que está a ser julgado **não entra** no cálculo da sua própria norma, e é esta separação que garante que o sistema nunca usa informação que ainda não teria.

Repare-se num pormenor da figura que parece pequeno e não é: **o dia que está a ser julgado não entra no cálculo da sua própria norma**. Se entrasse, um dia muito extremo puxaria a média e inflacionaria o desvio-padrão, e o próprio dia pareceria menos invulgar do que foi. O sistema estaria a usar informação que, no momento da decisão, ainda não devia contar.

Esta regra tem um nome, **evitar lookahead**, e atravessa todo o trabalho. Volto a ela na Secção 3.6, onde mostro como é imposta por um teste automático em vez de ser apenas prometida.

3.3.4 Um caso real

A Tabela 3.3 mostra o cálculo completo para o maior movimento do período estudado: a Tesla, a 24 de outubro de 2024, no dia a seguir aos resultados trimestrais.

Um movimento de quase 20% num dia é evidente para qualquer pessoa. O que a tabela mostra é *porque*: não porque 20% seja um número grande em abstrato, mas porque é sete vezes e meia o que aquela ação costumava mexer naquelas semanas. É essa frase que o sistema consegue mostrar ao utilizador, e é a diferença entre avisar e explicar.

Há ainda um caso pequeno que vale a pena resolver bem: se uma ação não se mexeu *nada* durante vinte dias, o desvio-padrão é zero e a divisão da Equação 3.1 não existe. Nesse caso o sistema devolve $z = 0$ em vez de rebentar. Uma ação parada é descrita como não tendo nada de especial, que é exatamente o que se passa.

Tabela 3.3: O z-score de um dia real, passo a passo (Tesla, 24 de outubro de 2024).

Quantidade	Valor
Média dos retornos dos 20 dias anteriores, μ	-0.92%
Desvio-padrão desses 20 dias, σ	2.73%
Retorno do dia, r_t	+19.82%
z-score, $(r_t - \mu)/\sigma$	+7.61
Sinalizado?	sim

Em três frases. Comparo o dia de hoje com os vinte dias anteriores da mesma ação e conto a distância em desvios-padrão. Assim, o mesmo número significa a mesma coisa numa empresa calma e numa volátil. O dia julgado nunca entra no cálculo da sua própria norma.

3.4 Técnica 2: encontrar casos parecidos

Como é que o computador percebe que duas notícias falam da mesma coisa?

3.4.1 O problema, em palavras

Chega uma notícia: “Nvidia bate estimativas com procura de centros de dados”.

A pergunta útil é: *já houve notícias parecidas com esta, e o que fez o preço a seguir?*

A maneira ingênua de procurar é por palavras. Procurar notícias antigas que contenham “Nvidia”, “bate” e “estimativas”. Funciona mal, por duas razões simétricas:

- duas notícias podem dizer a **mesma coisa com palavras diferentes**: “supera previsões” e “bate estimativas” não partilham uma única palavra importante;
- duas notícias podem **partilhar palavras e falar de assuntos diferentes**: “bate estimativas” e “bate recorde de despedimentos” partilham “bate”.

O que é preciso é comparar **significado**, não letras.

3.4.2 A ideia: transformar frases em pontos

É aqui que entra a única peça de aprendizagem profunda que o sistema usa, e vale a pena explicá-la com calma porque é a que soa mais complicada e não é.

Um **modelo de embeddings de frase** (Reimers e Gurevych 2019) é um modelo já treinado que recebe uma frase e devolve uma lista de números, neste caso 384. Essa lista chama-se *embedding* e funciona como uma **coordenada**: é a posição daquela frase num espaço.

A propriedade que interessa é esta: o modelo foi treinado de forma a que frases com significado parecido fiquem **perto** umas das outras nesse espaço, mesmo que usem palavras diferentes. A Figura 3.6 mostra a ideia em duas dimensões (as verdadeiras são 384, que não se conseguem desenhar).




Figura 3.6: Cada frase vira um ponto. Frases com o mesmo significado ficam próximas, mesmo sem partilharem palavras; frases que partilham palavras ("bate") mas falam de assuntos diferentes ficam longe. O desenho tem duas dimensões para se poder ver; o modelo usa 384.

3.4.3 Medir a distância: o cosseno

Tendo duas frases como pontos, falta medir se estão perto.

A medida usada é a **semelhança do cosseno**. Em vez de medir a distância em linha reta, mede o **ângulo** entre as duas direções. Dá um valor entre -1 e 1 :

- perto de 1: as duas frases apontam na mesma direção, ou seja, significado muito parecido;
- perto de 0: não têm relação;
- negativo: apontam em direções opostas.

Usa-se o ângulo e não a distância porque o que interessa é *sobre o que* a frase fala, e não o comprimento do texto. Uma manchete curta e um parágrafo longo sobre o mesmo assunto devem ficar próximos, e o ângulo dá isso.

A fórmula geral do cosseno entre dois vetores **u** e **v** é:

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\sum_{i=1}^{384} u_i v_i}{\sqrt{\sum_{i=1}^{384} u_i^2} \cdot \sqrt{\sum_{i=1}^{384} v_i^2}} \quad (3.2)$$

Em cima multiplicam-se as duas listas número a número e soma-se tudo. Em baixo dividem-se pelos comprimentos dos dois vetores, e é essa divisão que faz o resultado depender só da direção.

E há aqui uma simplificação que vale a pena conhecer. O modelo devolve os vetores já com comprimento 1. Isso não é um detalhe de arrumação: quando os dois comprimentos valem 1, o denominador da Equação 3.2 vale $1 \times 1 = 1$ e a fórmula reduz-se à soma de cima. Comparar duas manchetes passa a ser **multiplicar e somar**, sem mais nada, o que é a razão de o sistema conseguir percorrer 80 mil casos depressa.

3.4.4 O cosseno em dois casos reais

A Tabela 3.4 segue a conta para dois pares de manchetes retirados da base de casos. São reais, e os valores são os que o sistema calcula.

Tabela 3.4: Dois pares do lado oposto da escala. Repare-se na linha do comprimento: vale exatamente 1 nos quatro vetores, o que confirma a normalização e faz o cosseno coincidir com a soma dos produtos.

	Par A: mesmo assunto	Par B: assuntos diferentes
Primeira manchete	"Shares of several companies in the technology, software and semiconductor space are trading lower..."	"Peloton Shares Tick To Session Low As Hearing Report Apple Working On 'Guided Workout'..."
Segunda manchete	"Shares of several technology, software and semiconductor companies are trading lower..."	"Coronavirus: Another Severe Hit To The Automotive Industry"
Comprimento do 1.º vetor	1.000000	1.000000
Comprimento do 2.º vetor	1.000000	1.000000
Soma dos 384 produtos	+0.955626	-0.085901
Cosseno	+0.956	-0.086
Leitura	praticamente a mesma notícia	sem relação nenhuma

Para tornar a soma concreta, eis as quatro primeiras das 384 parcelas do par A:

$$\begin{aligned}
 & \underbrace{(+0.0609)(+0.0418)}_{+0.002546} + \underbrace{(-0.0524)(-0.0312)}_{+0.001638} + \\
 & \underbrace{(+0.0584)(+0.0648)}_{+0.003779} + \underbrace{(+0.0142)(+0.0004)}_{+0.000006} + \dots = +0.955626
 \end{aligned}$$

Note-se a segunda parcela: dois números *negativos* contribuem *positivamente*, porque o que conta é os dois vetores concordarem naquela dimensão, e não o sinal em si. E note-se, no par B, que a soma final é ligeiramente negativa: as manchetes não são opostas em sentido nenhum, apenas não têm nada em comum, e o valor anda à volta de zero.

O limiar usado em produção é 0.45. O par A passaria com folga; o par B nem se aproxima.

3.4.5 Medir o que se seguiu

Encontrar notícias parecidas é metade. A outra metade é dizer o que aconteceu ao preço depois de cada uma delas.

Para isso usa-se uma técnica clássica de finanças, o **estudo de evento** (Brown e Warner 1985): fixa-se o dia da notícia e mede-se a variação do preço 1, 3 e 5 dias depois. A Figura 3.7 mostra o alinhamento.

Duas decisões de detalhe, ambas com consequência:

3.5. Técnica 3: decidir o que merece um alerta




Figura 3.7: O impacto é medido a partir do *fecho* do dia da notícia. Se a notícia sai num sábado, o dia d é o primeiro dia de bolsa seguinte. É uma **medição do que aconteceu**, não uma previsão.

1. **Se a notícia sai fora de dias de bolsa**, o dia d é o primeiro dia de negociação igual ou posterior. Sem esta regra, uma notícia de sábado não teria a que se agarrar.
2. **A medição começa no fecho de d** , não na abertura. É a opção conservadora: não atribui à notícia a parte do movimento que já tinha acontecido antes de ela ser lida.

E vale a pena dizer aquilo que isto **não** é. Medir o que aconteceu a seguir a notícias passadas não é prever o que vai acontecer agora. É por isso que o sistema mostra sempre os casos *um a um*, com a data e o valor de cada um, em vez de resumir tudo a uma média. Uma média esconde que os casos podem ter ido em sentidos opostos.

Em três frases. Um modelo já treinado transforma cada manchete numa lista de 384 números que funciona como uma coordenada de significado. Comparo manchetes pelo ângulo entre essas coordenadas, o que aproxima frases parecidas mesmo com palavras diferentes. Para cada caso passado, meço o que o preço fez 1, 3 e 5 dias depois: uma medição, não uma previsão.

3.5 Técnica 3: decidir o que merece um alerta

Já sei que algo é invulgar. Devo mesmo interromper alguém?

3.5.1 O problema, em palavras

Chegam muitas notícias. A maioria não interessa: repetições, listas automáticas, textos que mencionam a empresa de passagem.

Um sistema que avisa de tudo é tão inútil como um que não avisa de nada. Pior, até, porque ensina a pessoa a ignorar o canal. Este problema tem nome, **fadiga de alertas**, e é a razão pela qual esta terceira decisão existe.

Aqui, ao contrário das duas anteriores, não há uma fórmula óbvia. É o sítio natural para **aprender a partir dos dados**.

3.5.2 A tarefa e o rótulo

Para treinar um modelo é preciso, antes de tudo, uma pergunta com resposta conhecida.

A pergunta escolhida foi: *depois desta notícia, houve um movimento anormalmente grande no preço?* A resposta, o **rótulo**, constrói-se assim:

1. mede-se o retorno da ação nos três dias seguintes à notícia;
2. subtrai-se o movimento do mercado no mesmo período, para não confundir “a empresa mexeu-se” com “mexeu-se tudo”;
3. se o que sobra for maior do que 2% em valor absoluto, o rótulo é 1; caso contrário, 0.

Repare-se em **valor absoluto**. O rótulo diz se houve movimento *grande*, e nunca em que **direção**. Isto é deliberado e é a fronteira que o trabalho não atravessa: o modelo aprende sobre *materialidade*, não sobre subir ou descer.

3.5.3 O que o modelo vê

O modelo recebe cinco tipos de informação sobre o momento da notícia:

- **volatilidade recente**: quanto a ação tem oscilado nos últimos 20 dias;
- **momento**: como se comportou nos últimos 5 dias;
- **o movimento do próprio dia**;
- **o comprimento da manchete**;
- **o setor** da empresa.

E, numa das variantes testadas, também o *embedding* da manchete, os mesmos 384 números da Secção 3.4. Comparar a variante com texto e a variante sem texto é precisamente o que a Q13 pergunta, e a resposta está no Capítulo 5.

3.5.4 Treinar sem fazer batota com o tempo

Esta é a parte onde é mais fácil enganar-se a si próprio, por isso vale a pena o desenho da Figura 3.8.




Figura 3.8: Os dados são divididos **por ordem cronológica**, nunca ao acaso. Entre blocos há um *embargo* de cinco dias, porque o rótulo de uma notícia olha até três dias para a frente e sem o embargo o fim do treino tocava no princípio do teste.

Duas regras, e as duas existem para impedir que o modelo pareça melhor do que é:

Dividir pelo tempo, não ao acaso. Se os dados fossem baralhados, o modelo treinaria com notícias de 2023 e seria testado com notícias de 2019, ou seja, estaria a ser avaliado sobre um passado que já conhece. Aqui, treina-se no início do período e testa-se no fim, como acontece na realidade.

Embargo entre blocos. O rótulo de uma notícia depende dos três dias seguintes. Uma notícia no último dia de treino tem o seu rótulo determinado por dias que já pertencem

ao bloco seguinte. Deitam-se fora os cinco dias de fronteira, e diz-se quantas linhas isso custou.

3.5.5 Da pontuação à probabilidade: calibração

O modelo devolve uma pontuação. Uma pontuação alta não é, por si só, uma probabilidade: dizer 0.8 não garante que aconteça em 8 de cada 10 casos.

Como o número vai ser mostrado a uma pessoa, isso tem de ser corrigido. O passo chama-se **calibração** (Niculescu-Mizil e Caruana 2005): ajusta-se uma função simples que transforma pontuações em probabilidades *honestas*, de modo a que, entre todos os casos a que o modelo dá 70%, cerca de 70% tenham mesmo acontecido. A calibração é ajustada no bloco de validação, nunca no de teste.

A função usada tem apenas dois números a aprender, a e b :

$$p_{\text{calibrada}} = \frac{1}{1 + e^{-(a p_{\text{bruta}} + b)}} \quad (3.3)$$

Neste trabalho os dois valores aprendidos foram $a = 3.700$ e $b = -2.313$. O sinal negativo de b diz o essencial: o modelo, deixado por sua conta, era **demasiado otimista**, e a calibração existe para o puxar para baixo.

3.5.6 Da linha de dados aos 39%: a conta toda

Falta ligar as pontas. A Tabela 3.5 segue **a mesma linha** que a Figura 3.3 mostrou no início deste capítulo, desde os valores em bruto até à percentagem final, sem saltar nenhuma etapa.

Há duas coisas neste percurso que merecem atenção, e são as que tornam o exemplo útil.

A calibração não é uma formalidade. A pontuação bruta era 0.507, praticamente um lançamento de moeda. Depois de calibrada passa a 0.392. São leituras diferentes: a primeira diria a um utilizador que a coisa está em aberto, e a segunda diz que é mais provável não acontecer nada de especial. **A ordenação entre notícias não muda** com esta transformação, porque ela é sempre crescente; o que muda é o *significado* do número mostrado, e é esse número que a pessoa lê.

E a maior contribuição foi negativa. A parcela de maior peso, -0.253 , veio da volatilidade, e puxou a probabilidade *para baixo*. A razão é que a Apple vinha de vinte dias mais calmos do que o habitual, e o modelo aprendeu que notícias em períodos calmos são menos frequentemente seguidas de movimentos grandes. É a mesma lógica do detetor do início do capítulo, aprendida em vez de escrita, e é a razão pela qual o alerta consegue dizer ao utilizador *o que levantou* e *o que baixou* a estimativa.

Em três frases. Treinei um modelo para estimar se uma notícia é seguida de um movimento anormalmente grande, em qualquer direção. Os dados são divididos pelo tempo, com um embargo entre blocos, para o modelo nunca ser avaliado sobre um futuro que já viu. A pontuação é calibrada, para o número mostrado ao utilizador querer dizer o que parece querer dizer.

Tabela 3.5: As cinco etapas para a notícia da Apple de 2 de fevereiro de 2023. Os valores são os que o modelo implantado produz; a soma da terceira etapa reproduz o modelo até à sexta casa decimal.

	Etapas	O que acontece
1	Entrada	As nove entradas da linha: volatilidade 0.0127, momento 0.0249, movimento do dia 0.0364, comprimento do título 53, e o setor em nove casas das quais só uma está a 1.
2	Normalização	Cada valor é comparado com a média e a dispersão do conjunto de treino, para que grandezas diferentes possam ser somadas. A volatilidade deste dia fica em -0.49 , ou seja, <i>abaixo</i> do habitual; o movimento do dia fica em $+1.10$.
3	Soma pesada	Cada valor normalizado é multiplicado pelo seu peso e somam-se todos: -0.253 da volatilidade, $+0.236$ do setor, $+0.006$ do movimento do dia, mais os restantes e o termo constante. Total: $+0.029$.
4	Sigmoide	O total é convertido em algo entre 0 e 1: $1/(1 + e^{-0.029}) = \mathbf{0.507}$.
5	Calibração	$3.700 \times 0.507 - 2.313 = -0.437$, e a sigmoide disso dá 0.392 . É este o número que chega ao ecrã, arredondado: 39% .

3.6 Como é que se sabe que isto funciona

O que impede um resultado bonito de ser um resultado enganador?

Três compromissos, assumidos *antes* de correr as experiências.

Primeiro: comparar sempre com o mais simples. Um número sozinho não diz nada. Dizer que a recuperação acerta em metade dos casos só significa alguma coisa quando se sabe o que acertaria uma alternativa trivial. Por isso cada técnica é comparada com **linhas de base**: uma regra fixa, uma escolha ao acaso, a notícia mais recente. Se a técnica sofisticada não ganhar, isso é o resultado, e é o que fica escrito.

Segundo: o não-lookahead é imposto por um teste, não prometido. É fácil escrever “não usámos informação do futuro”. É difícil garanti-lo. Aqui existe um teste automático que faz o seguinte: pega num exemplo, **altera artificialmente o futuro** e volta a calcular. Depois exige duas condições ao mesmo tempo: que as *features* fiquem exatamente iguais (porque descrevem o passado) e que o *rótulo* mude (porque descreve o futuro). Se alguma informação do futuro se tivesse infiltrado nas features, o teste falha.

Terceiro: reportar o que sair. O critério de sucesso de cada experiência foi escrito antes de a correr. Onde o resultado contrariou o que se esperava, fica reportado como se revelou. O Capítulo 5 tem um caso desses, e é o mais interessante dos três.

Capítulo 4

O Sistema

4.1 Vista de conjunto

Como é que as peças se ligam?

O Capítulo 3 explicou três técnicas isoladas. Este mostra-as a trabalhar juntas.

O sistema chama-se **InvestiGator** e tem cinco partes, na Figura 4.1: **deteção**, **recuperação**, **triagem**, **explicação** e **entrega**. Cada uma faz uma coisa só, e passa o resultado à seguinte.




Figura 4.1: As cinco partes do InvestiGator. À esquerda, de onde vêm os dados; ao centro, as três técnicas do capítulo anterior; à direita, as duas formas de o utilizador receber o resultado.

Há uma regra de desenho que atravessa tudo isto e que vale a pena dizer já: **a explicação é montada a partir dos objetos que foram calculados**, e nunca escrita à parte. Se o detetor calculou um z de $+7.61$, é esse número que aparece no texto. Não há um sítio onde alguém escreva a frase e outro sítio onde alguém calcule o valor, porque, se houvesse, os dois podiam divergir sem ninguém dar por isso.

4.2 De onde vêm os dados

Com que matéria-prima é que isto funciona?

Uma restrição fundadora deste trabalho é usar **apenas fontes gratuitas**. Não foi por comodidade: é o que torna o sistema utilizável por quem ele serve. Um investidor que já acha caro pagar comissões não vai subscrever um terminal financeiro.

Isso obriga a três decisões de engenharia.

Preços: uma cadeia, não uma fonte. As fontes gratuitas de preços falham. Bloqueiam por excesso de pedidos, respondem com erro, ou simplesmente não têm o dia de hoje. Em vez de depender de uma, o sistema tenta várias por ordem e fica pela primeira que responde. Regista sempre qual serviu, porque saber de onde veio um número faz parte de o poder explicar.

Notícias: por empresa, e filtradas à entrada. As notícias vêm de uma API gratuita, empresa a empresa. O que chega é muito e é sujo: listas automáticas de “os dez maiores movimentos do dia”, textos que mencionam a empresa de passagem, comunicados de escritórios de advogados. Antes de qualquer coisa, um filtro exige que a notícia **nomeie mesmo a empresa** e rejeita padrões conhecidos de texto automático.

Histórico: um conjunto de dados público, alinhado com preços. Para responder à pergunta “já aconteceu antes?” é preciso um passado. Usa-se o FNSPID (Dong, Fan e Peng 2024), um conjunto público de notícias financeiras, alinhado com os preços correspondentes. Desse alinhamento nasce a base de casos: cerca de 80 mil notícias entre 2018 e 2023, cada uma com o que o preço fez a seguir.

4.3 As peças que não são minhas

O que é que este sistema usa de fora, e porquê essas e não outras?

Um sistema construído sobre serviços de terceiros deve dizer quais são. Não por formalidade: porque cada um deles é uma dependência, um limite, e uma decisão que podia ter sido tomada ao contrário. A Tabela 4.1 lista todas, com o que cada uma faz, o que custa, e o que foi *rejeitado* em favor dela.

Duas observações que valem mais do que a tabela.

A cadeia de preços é a peça de engenharia mais aborrecida e mais necessária. Nenhuma fonte gratuita de preços é fiável sozinha. O sistema tenta-as por ordem fixa e fica pela primeira que responde, registando sempre qual serviu. Sem isto, um dia em que o Yahoo bloqueia seria indistinguível de um dia sem mercado.

Nada disto é escolhido por gosto sem prova. Duas destas linhas mudaram por *medição* e não por opinião: o Stooq foi despromovido depois de se ver o que devolve, e o modelo de vetores foi comparado com três alternativas antes de ficar. As restantes são escolhas de restrição: são as que cabem em “apenas fontes gratuitas”.

4.4 O caminho de uma notícia, do princípio ao fim

O que acontece, exatamente, entre uma notícia sair e um alerta chegar ao telemóvel?

Esta é a secção central do capítulo, e segue **uma notícia real**: um alerta que o canal enviou a 12 de julho de 2026 sobre a Meta.

4.5. O caminho de um movimento de preço

“Mark Zuckerberg Said Meta’s AI Bets ‘Haven’t Come to Fruition Yet’ as Shares Fell 5%”

A Figura 4.2 mostra as etapas. A Tabela 4.2 mostra o que aconteceu em cada uma, com os valores que o sistema realmente calculou.




Figura 4.2: As nove etapas. As caixas a tracejado são **portas**: em qualquer uma delas a notícia pode ser descartada e o sistema fica calado. Nove em cada dez varreduras acabam assim.

Vale a pena olhar para a etapa 4 com atenção, porque é onde o trabalho fica interessante. Os três casos recuperados são de **outras empresas** (duas da Nvidia e uma da Microsoft), e o sistema mostra-os na mesma. É deliberado: se a pergunta é “já houve notícias como esta?”, a resposta não tem de vir da mesma empresa. Notícias sobre investimento em inteligência artificial numa tecnológica grande são comparáveis entre si.

E os desfechos foram **em sentidos opostos**: +2.70%, −3.87% e +5.05%. O sistema mostra os três, um a um, exatamente por isso. Se mostrasse só a média, esconderia a coisa mais importante que há para saber: que casos parecidos deram resultados diferentes.

4.5 O caminho de um movimento de preço

E quando não há notícia nenhuma?

O segundo gatilho é mais curto. Todos os dias, depois do fecho, o sistema calcula o z-score de cada empresa da lista, como na Secção 3.3. Se algum passar o limiar, há alerta.

Duas coisas foram acrescentadas depois de o sistema estar a funcionar, e ambas por observação:

Níveis de severidade. Um z de 1.6 e um z de 3.2 não são a mesma coisa, e o texto do alerta passou a distingui-los em palavras (“assinalável”, “forte”, “extremo”) em vez de dar o mesmo aviso aos dois.

Comparação com os pares. Um alerta que diz “a empresa caiu 8%” sem dizer que o setor inteiro caiu é enganador. O sistema passou a olhar para as outras empresas do mesmo setor no mesmo dia, e a dizê-lo.

Esta segunda correção veio de ler os primeiros trinta alertas enviados. Em nove deles o texto **contradizia-se**: uma linha dizia que o movimento parecia ser do setor inteiro, e duas

linhas abaixo a repartição dizia que a maior parte pertencia à empresa. As duas linhas estavam certas isoladamente: a comparação com os pares olhava apenas para a *direção* do movimento dos vizinhos, nunca para a sua *dimensão*. Passou a olhar para as duas.

4.6 As portas: quando o sistema decide calar-se

Porque é que o sistema não avisa de quase nada?

Porque avisar de tudo é o mesmo que não avisar de nada. Se o canal enviar quinze mensagens por dia, a pessoa deixa de as ler, e o sistema perde a única coisa que tinha para dar.

As cinco portas da Figura 4.2 existem para isso. O efeito conjunto é grande: numa janela medida em produção, das **944** notícias relevantes que entraram, saíram **42** alertas. Cerca de uma em cada vinte e duas.

Vale a pena ver isto num dia concreto, com os números lidos do registo do próprio sistema. A Tabela 4.3 mostra o dia 15 de agosto de 2026.

E a ressalva é um defeito que encontrei ao construir esta tabela. Cinco mil avaliações e quatro mensagens: a proporção está certa e é o comportamento pretendido. Mas a linha dos 330 não queria dizer o que parecia. O sistema reavalia as mesmas manchetes de 60 em 60 segundos, e uma manchete que já tinha sido entregue nesse dia voltava a passar todas as portas a cada minuto. Era travada no fim, por uma verificação de “isto já foi enviado” que **não estava registada como uma etapa**, ao contrário das três acima dela.

Resultado: a vista que existe para tornar as decisões do sistema inspecionáveis dizia “alerta enviado” 330 vezes num dia em que enviou 4 mensagens. Não é um erro de contagem inofensivo: é a mesma classe de defeito que a tabela abaixo documenta para as outras portas, sobrevivendo na única que ficou por instrumentar.

Está corrigido: a supressão passou a ser uma etapa com nome próprio, como as outras, e existe um teste que falha se voltar a desaparecer. Os números da tabela são os de *antes* da correção, porque é esse o estado em que os medi.

Cada porta tem uma constante associada, e é justo perguntar de onde vêm esses números. A Tabela 4.4 responde, incluindo quando a resposta é “foi escolhido”.

O chão de semelhança merece um parágrafo próprio, porque é a porta que mais mata e a que tem a justificação mais fraca. Numa varredura medida, sete das dez empresas foram travadas exatamente ali, e quatro delas por menos de 0.04 de diferença. Testei depois se um valor mais alto de semelhança correspondia a precedentes mais informativos, e **não corresponde**: a concordância de direção entre o caso passado e o caso atual fica ao nível do acaso dos dois lados do limiar. A conclusão honesta é que este número serve para *controlar o volume* de alertas e para garantir coerência de tema, e não para escolher casos que preveem melhor. Fica dito assim.

4.7 Como o alerta é explicado

O que é que a pessoa recebe, e porque é que se pode fiar?

O alerta não é uma frase. É uma pequena estrutura, sempre com as mesmas partes e sempre pela mesma ordem:

4.7. Como o alerta é explicado

1. **o facto:** o que aconteceu, em números;
2. **porquê foi assinalado:** a razão estatística, em linguagem simples;
3. **os casos passados:** um a um, com data, semelhança e o que se seguiu a cada um;
4. **a ressalva:** que isto é história observada e não uma previsão.

A ordem importa. A pessoa lê primeiro o que aconteceu e só depois a estatística, porque é assim que uma pessoa pensa; um alerta que abre com “ $z = 2.65$ ” perde o leitor na primeira linha.

A Figura 4.3 mostra um alerta **tal como foi entregue**, copiado do registo do canal. A mesma informação fica disponível numa página web, que serve para consultar o que foi enviado e, sobretudo, o que *não* foi: é aí que vive o registo das decisões descrito na Secção 4.6. A interface em si não é uma contribuição deste trabalho e não se descreve aqui.

```
[1] News alert for AMZN (Amazon) (2026-08-13)
    "Prediction: Amazon Will Join Apple in the $4 Trillion Club Before 2030"

[3] 3 similar past headlines. Their 5-day move ranged -2.73% to -2.73%
    (average -2.73%):
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "If You Invested $100 In Apple
      Stock 10 Years Ago, You Would Have This Much Today" (sim 0.56)
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "Apple's Selloff Is Overdone"
      (sim 0.51)
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "Apple's Buyback Is Retiring
      Less Stock Just As The Memory Bill Grows" (sim 0.47)

[4] 3 of 3 shown cases moved down - topic-similar past cases, not a
    prediction for this news (an observed pattern, not a forecast).
    Observed past outcomes after similar news, not a price prediction and
    not advice.

[2] Materiality estimate (learned triage): 57% chance of an unusually
    large move over the next few days, in EITHER direction - raised by
    recent volatility (20d) and sector; lowered by today's own move and
    recent momentum (5d). This estimates whether the market reacts, never
    which way: it is not a price forecast and not advice.
```

Figura 4.3: Um alerta enviado ao canal a 13 de agosto de 2026, copiado do registo sem edição. Os números entre parênteses marcam as quatro partes da lista acima. Todos os valores vêm dos objetos que os calcularam: a semelhança do motor de recuperação, o movimento a cinco dias da medição de impacto, e os 57% do modelo calibrado.

E este exemplo mostra um defeito que eu não tinha visto até o pôr aqui. Os três precedentes têm o *mesmo* impacto, -2.73% , e a mesma data. Não é coincidência: o impacto é medido por **(empresa, dia)**, logo três manchetes da mesma empresa no mesmo dia partilham o mesmo valor por construção. A frase “*3 of 3 shown cases moved down*” apresenta como concordância entre três casos aquilo que é **um dia observado três vezes**.

Medido sobre os 247 alertas de notícia com precedentes já entregues: em 36.8% deles os casos mostrados assentam em menos dias distintos do que casos exibidos, e em 11.3% os três são o mesmo dia. Dos 120 alertas que afirmam unanimidade, 23.3% apoiam-se num único dia.

Isto **não afeta** nenhum número reportado no Capítulo 5: a precisão@5 conta manchetes e a concordância de direção é medida par a par sobre o corpus histórico. Afeta a força que o *alerta* reivindica quando fala ao utilizador, e fica registado como limitação por isso.

E a garantia que sustenta tudo isto é de construção, não de boa vontade: **cada número do texto vem do objeto que o calculou**. O texto é montado a partir dessas peças. Não é possível o alerta dizer +4.47% e o sistema ter calculado outra coisa, porque só existe um sítio onde esse valor existe.

4.8 Onde isto corre, e o que isso custou

Como é que um sistema destes se mantém a funcionar sem servidor pago?

A primeira versão corria no agendador do **GitHub Actions**, configurado para disparar de meia em meia hora nos dias úteis. Funcionava, e tinha um problema que só se vê a usar: **os alertas chegavam tarde**. Esse agendador é de *melhor esforço* para repositórios gratuitos: quando os executores partilhados enchem, a corrida é saltada. Na prática corria de hora e meia em hora e meia.

A solução veio do plano do ISEP: o *GitHub Student Developer Pack* dá créditos de **Heroku**, que permitiram passar de um agendador para um **processo permanente**. O ciclo passou a correr de **60 em 60 segundos**.

A Figura 4.4 mostra onde cada peça corre depois dessa mudança, porque a arquitetura de execução não é óbvia e tem uma consequência que me custou tempo real.




Figura 4.4: Os dois processos do Heroku não partilham disco. Tudo o que tem de sobreviver a um reinício, ou de ser visto pelo outro processo, passa pela **branch de dados** no GitHub.

A consequência, e é um defeito que encontrei e corrigi. Os dois processos correm em máquinas separadas e o disco de cada uma é apagado a cada reinício. Isso está escrito na documentação do serviço e eu sabia-o. Mesmo assim, dois dos ficheiros de registo, o do funil e o das decisões de triagem, estavam a ser escritos **apenas em disco local**. Resultado: o processo que serve a página mostrava uma semana atrasada, e o registo que alimenta a validação posterior tinha deixado de crescer. Ambos passaram a ser publicados na branch de dados a cada ciclo.

E o GitHub Actions não desapareceu. Continua a fazer três coisas: corre os testes a cada alteração de código (Integração Contínua (CI)), compila esta dissertação, e mantém

um agendador de reserva que dispara nos mesmos horários. Se o processo permanente parar, o sistema degrada para o comportamento da primeira versão em vez de ficar mudo, e o mecanismo que evita alertas repetidos garante que os dois não enviam a mesma coisa duas vezes.

E aqui está o resultado, na Tabela 4.5, que é mais interessante do que a decisão:

O ciclo comprou **53 minutos**, e não as duas horas que eu esperava. A razão está nas duas últimas linhas: quase todo o tempo é gasto *até a notícia aparecer na fonte gratuita*, e nada do lado da infraestrutura muda isso. Depois de o sistema ver a notícia, a mensagem chega em cerca de um segundo.

Isto é uma limitação real e fica escrita como tal. Comprar um serviço de notícias em tempo real resolveria, e violaria a restrição fundadora do trabalho. Prefiro ter uma limitação medida a ter uma capacidade comprada.

Tabela 4.1: As dependências externas, nomeadas. A coluna da direita é a que interessa: uma escolha só se defende contra a alternativa que não foi tomada.

Peça	Para quê	Custo/limite	Porquê esta, e não a outra
Finnhub	notícias por empresa, em tempo quase real	grátis, 60 pedidos/min	Dá notícias <i>por empresa</i> , que é o que o sistema precisa. Alternativas de Really Simple Syndication (RSS) genérico obrigariam a descobrir a empresa a partir do texto, acrescentando um erro que não é preciso ter.
yfinance	preços diários e intradiários	grátis, sem garantia	É a fonte mais completa sem chave. Falha com frequência, e por isso não é usada sozinha: ver a cadeia abaixo.
Tiingo, Polygon, Alpha Vantage	preços, quando a primeira falha	grátis com chave; Alpha Vantage 25 pedidos/dia	São <i>alternativas de recurso</i> , não fontes principais. A ordem é fixa e o sistema regista qual delas serviu, porque saber a origem de um número faz parte de o poder explicar.
Stooq	era candidato a fonte de preços	grátis	Rejeitada por medição. Foi testada ao vivo e responde com uma verificação anti-robô, o que a torna inutilizável dentro de um processo automático. Fica registada porque parecia servir.
FNSPID (Dong, Fan e Peng 2024)	o passado: notícias antigas alinhadas com preços	grátis, licença CC BY-SA	É público, é grande, e já vem alinhado com preços. Construir uma base equivalente exigiria comprar histórico de notícias.
Sentence-BERT (Reimers e Gurevych 2019)	transformar manchetes em vetores	grátis, corre localmente	Modelo já treinado, pequeno o suficiente para caber num contentor de memória limitada. Alternativas maiores e um modelo específico de finanças foram testados e estão medidos no Capítulo 5.
Telegram	entregar o alerta ao telemóvel	grátis, sem limite prático	Tem Interface de Programação de Aplicações (API) de <i>bot</i> sem custo e sem processo de aprovação, e o utilizador subscreve com um clique. Notificações nativas de telemóvel obrigariam a publicar aplicações em duas lojas.
Heroku	manter o sistema a correr sem parar	créditos do <i>GitHub Student Pack</i>	Dá um processo permanente , que é o que o ciclo de 60 segundos exige. É a decisão explicada na Secção 4.8.
GitHub Actions	correr os testes, compilar a dissertação, e guardar o histórico	grátis para repositórios públicos	Serve hoje de rede de segurança do processo permanente, e serviu de <i>motor</i> na primeira versão.

4.8. Onde isto corre, e o que isso custou

Tabela 4.2: O que aconteceu em cada etapa para o alerta da Meta de 12 de julho de 2026. Todos os valores são os que o sistema calculou nesse dia.

Etapa	O que aconteceu
1. Recolher	A varredura foi buscar as notícias da semana para cada empresa da lista.
2. Nomeia a empresa?	A manchete diz “Meta” e “Mark Zuckerberg”, que estão na lista de nomes da empresa, e não corresponde a nenhum padrão de texto automático. Passa.
3. É recente?	Tem menos de dois dias. Passa: sem esta porta, a mesma notícia alertava dias seguidos.
4. Procurar parecidas	A manchete é transformada em 384 números e comparada com a base de casos. As três mais parecidas: Microsoft 2023-11-07 (0.46), Nvidia 2023-08-02 (0.51), Nvidia 2023-09-21 (0.46).
5. Evidência forte?	A melhor semelhança é 0.51, acima do mínimo de 0.45. Passa.
6. Merece avisar?	O modelo de triagem dá 54%, acima do mínimo de 50%. Passa.
7. Já avisei hoje?	É o primeiro alerta desta empresa hoje, e nenhum outro produtor o enviou. Passa.
8. Montar a explicação	O texto é composto a partir dos objetos calculados: o movimento, os três casos passados com o que se seguiu a cada um, e a nota de que isto não é uma previsão.
9. Enviar e registar	Enviado ao canal e guardado no registo partilhado, de onde a página web o vai buscar depois.

Tabela 4.3: Onde morreram as avaliações do dia 15 de agosto de 2026, lidas do registo do sistema. A leitura da coluna da direita é a parte que interessa.

Onde morreu	Avaliações	O que é
Sem precedente forte	3 086	nenhum caso passado acima do mínimo de semelhança
Abaixo do piso da triagem	1 136	o modelo pontuou abaixo de 50%
A mesma história	307	já contada por outras palavras
Piso escalonado	141	o segundo alerta do dia exigia pontuação mais alta
Sobreviveu às portas	330	ver a ressalva
Mensagens entregues	4	o que a pessoa recebeu de facto

Tabela 4.4: As cinco portas, o valor usado, e de onde vem. Distinguir “derivado” de “escolhido” é uma questão de honestidade: as duas coisas defendem-se de maneiras diferentes.

Porta	Valor	De onde vem
Nomeia a empresa	—	Regra escrita depois de ler os primeiros alertas e ver o que passava.
É recente	2 dias	Escolhido: cobre um fim de semana.
Evidência forte	0.45	Escolhido , e é a porta mais agressiva de todas (ver abaixo).
Merece avisar	50%	Derivado de uma análise de custos: quando falhar um movimento e dar um falso alarme custam o mesmo, o limiar ótimo é 0.49.
Teto diário	2/dia	Escolhido, com um piso que sobe: o segundo alerta do dia sobre a mesma empresa exige uma pontuação mais alta.

Tabela 4.5: Latência medida sobre os alertas entregues, separando as duas eras. O tempo está quase todo na *descoberta*, não na entrega.

Medição	Valor
Mediana, com o agendador gratuito	196 min
Mediana, com o ciclo de 60 segundos	143 min
Da publicação até o sistema detetar	≈ 158 min
Da detecção até a mensagem chegar	≈ 1 s

Capítulo 5

Avaliação

5.1 Como está montado este capítulo

O que é que vale como prova?

Cada uma das três perguntas de investigação tem aqui a sua secção. Todas seguem a mesma forma, de propósito:

1. a pergunta;
2. como foi medida, e contra que alternativa;
3. o resultado;
4. **o que este resultado não permite concluir.**

O quarto ponto é o que separa uma avaliação de uma demonstração. Todos os números deste capítulo são produzidos por procedimentos automáticos com semente fixa: correr outra vez sobre os mesmos dados dá exatamente os mesmos valores.

5.2 Como se lê cada número deste capítulo

Antes de ver os resultados: o que é que cada medida quer dizer, e como é calculada?

Esta secção existe porque um resultado só vale o que vale a medida que o produziu. Um número como " $F_1 = 0.530$ " não diz nada a quem não sabe o que é o F_1 , e um leitor que aceite esse número sem o compreender não está a avaliar o trabalho: está a confiar nele. Percorro por isso cada medida usada, com a fórmula, com o que ela premeia, e com a conta feita até ao valor que aparece mais à frente.

5.2.1 As quatro maneiras de acertar e de errar

Todas as medidas deste capítulo, à exceção de uma, assentam na mesma ideia de partida. O sistema faz uma afirmação sobre um dia, a realidade tem uma resposta, e há quatro combinações possíveis. Estão na Figura 5.1 e o nome habitual deste quadro é **matriz de confusão**.

A distinção que importa é a última. Os dois erros não são simétricos, e nenhuma medida única os resume sem escolher uma prioridade. É por isso que se usam duas medidas em vez de uma.

	a realidade: invulgar	a realidade: banal
o sistema assinala	Verdadeiro positivo assinalou, e o dia era mesmo invulgar	Falso positivo assinalou, e o dia era banal <i>(alarme falso)</i>
o sistema cala-se	Falso negativo calou-se, e o dia era invulgar <i>(escapou)</i>	Verdadeiro negativo calou-se, e o dia era mesmo banal

Figura 5.1: A matriz de confusão. As duas células cinzentas são acertos; as duas alaranjadas são os dois erros possíveis, e **custam coisas diferentes**. Um falso positivo gasta a atenção de quem lê; um falso negativo deixa passar o dia que interessava.

5.2.2 Precisão e cobertura

A **precisão** responde a: *das vezes que o sistema falou, quantas tinha razão?*

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (5.1)$$

A **cobertura**, também chamada *recall*, responde a uma pergunta diferente: *dos dias que eram mesmo invulgares, quantos é que o sistema apanhou?*

$$\text{Cobertura} = \frac{VP}{VP + FN} \quad (5.2)$$

Repare-se em que o denominador muda. A precisão divide pelo que o sistema *disse*; a cobertura divide pelo que *existia*. São perguntas diferentes e podem dar respostas opostas.

E é exatamente isso que acontece neste trabalho, o que torna o exemplo particularmente útil. A regra do limiar fixo, aquela que assinala qualquer movimento acima de 3%, obtém uma cobertura de 0.992: apanha praticamente todos os dias invulgares que existiam. Vista só por esse número parece excelente. Mas a sua precisão é de 0.122, ou seja, **de cada cem vezes que fala, tem razão doze**. Apanha tudo porque fala quase sempre, e uma regra que fala quase sempre não está a detetar coisa nenhuma.

Este par de números é a razão de ser da secção seguinte: é preciso uma medida que não se deixe enganar por nenhum dos dois extremos.

5.2.3 O F_1 : obrigar as duas a andarem juntas

O F_1 combina precisão e cobertura numa só medida através da **média harmónica**:

$$F_1 = 2 \cdot \frac{\text{Precisão} \times \text{Cobertura}}{\text{Precisão} + \text{Cobertura}} \quad (5.3)$$

A escolha da média harmónica, e não da média habitual, é deliberada e vale a pena perceber porquê. A média aritmética de 0.122 e 0.992 é 0.557, um valor que faria a regra do limiar fixo parecer razoável. A média harmónica **puxa para baixo em direção ao pior dos dois**, e

por isso só dá um valor alto quando *ambos* são altos. É uma medida que não deixa comprar cobertura à custa de precisão.

Vejamos a conta completa, com os dois detetores, exatamente como os valores aparecem mais à frente.

Para o limiar fixo , com precisão 0.122 e cobertura 0.992:

$$F_1 = 2 \cdot \frac{0.122 \times 0.992}{0.122 + 0.992} = 2 \cdot \frac{0.1210}{1.114} = \frac{0.2421}{1.114} = 0.218$$

Para o z-score , com precisão 0.381 e cobertura 0.800:

$$F_1 = 2 \cdot \frac{0.381 \times 0.800}{0.381 + 0.800} = 2 \cdot \frac{0.3048}{1.181} = \frac{0.6096}{1.181} = 0.516$$

São estes os dois valores que a Secção 5.3 reporta. O z-score tem *menos* cobertura do que o limiar fixo, e ainda assim ganha com folga, porque triplica a precisão. É a média harmónica a fazer o seu trabalho.

5.2.4 A precisão@k: avaliar uma lista curta

A recuperação de precedentes não devolve uma decisão de sim ou não: devolve uma **lista ordenada**. E o utilizador não lê a lista toda, lê as primeiras. Faz portanto sentido medir apenas o topo dessa lista, que é o que a **precisão@k** faz:

$$\text{Precisão@k} = \frac{\text{número de casos relevantes entre os } k \text{ primeiros}}{k} \quad (5.4)$$

Neste trabalho $k = 5$, porque cinco é a ordem de grandeza do que cabe num alerta sem o tornar ilegível. Um caso recuperado conta como relevante se pertencer ao mesmo setor da notícia de consulta, com a restrição adicional de ter de ser de **outra empresa**, pelas razões dadas na Secção 5.4.

A Figura 5.2 mostra a conta para uma consulta.

consulta: notícia de tecnologia			
1.	tecnologia	relevante	} Precisão@5 = $\frac{3}{5} = 0.600$
2.	tecnologia	relevante	
3.	energia	não	
4.	tecnologia	relevante	
5.	banca	não	

Figura 5.2: Uma consulta devolve cinco casos; três são do mesmo setor. A medida é a fração, e faz-se a média sobre muitas consultas. Note-se que **a ordem dentro dos cinco não conta**: esta medida pergunta quantos acertou, não se pôs os melhores à frente.

Falta um número sem o qual a medida não se interpreta: **qual é o valor de quem escolhe ao acaso?** Não é zero. Como há cinco setores e alguns são maiores do que outros, uma escolha aleatória acerta uma fração apreciável das vezes só por sorte. Esse chão foi medido, e vale 0.240. Qualquer método tem de ser lido contra ele, e não contra zero.

5.2.5 A PR-AUC: a lista toda, em todos os pontos de corte

O modelo de triagem não devolve uma decisão: devolve uma **probabilidade** para cada notícia. Para transformar isso numa decisão é preciso escolher um limiar, e o valor da precisão e da cobertura muda conforme o limiar escolhido.

Se o limiar for muito baixo, o sistema alerta quase sempre: a cobertura sobe e a precisão desce. Se for muito alto, alerta quase nunca: a precisão sobe e a cobertura desce. Cada limiar possível dá, portanto, um par (cobertura, precisão), e o conjunto de todos esses pares desenha uma curva. É a **curva de precisão–cobertura**, e a Figura 5.3 explica como se lê.




Figura 5.3: Cada ponto da curva é um limiar de decisão diferente. Um modelo melhor mantém a curva alta durante mais tempo antes de cair. A área debaixo da curva resume esse comportamento num só número, sem obrigar a escolher um limiar.

A **PR-AUC** é a área debaixo dessa curva. O seu valor está entre 0 e 1, e a grande vantagem é resumir o modelo em *todos* os limiares de uma vez, em vez de o julgar num limiar escolhido à mão, que seria uma decisão arbitrária a contaminar a comparação.

Há aqui uma propriedade que convém conhecer, porque é o que torna esta medida interpretável. **O chão da PR-AUC não é zero: é a proporção de casos positivos que existem nos dados.** Um modelo que ignore por completo o que lhe dão e atribua a mesma probabilidade a tudo obtém uma PR-AUC igual a essa proporção.

No bloco de teste deste trabalho a proporção de casos positivos é de 37.8%, e o modelo “alertar sempre” obtém exatamente $PR-AUC = 0.378$. Não é coincidência: é a propriedade acima, e serve de verificação de que a medição está bem montada. Todos os valores de PR-AUC deste capítulo devem ser lidos contra esse chão de 0.378.

E porquê esta medida, e não a percentagem de acertos? Porque a percentagem de acertos engana quando as duas classes têm tamanhos diferentes. Se apenas 37.8% dos casos são positivos, um modelo que responda sempre “não é importante” acerta em 62.2%

das vezes sem ter aprendido nada. Um número que premeia esse comportamento não serve para escolher entre modelos.

5.2.6 O Brier: a probabilidade tem de ser honesta

As medidas anteriores olham para a *ordenação*: se o modelo põe os casos importantes à frente. Falta uma que olhe para o *valor* da probabilidade. Isso importa porque o sistema mostra ao utilizador uma frase do género “57% de probabilidade”, e essa percentagem tem de querer dizer alguma coisa.

O **Brier** é a média do quadrado do erro entre a probabilidade anunciada e o que aconteceu:

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2 \quad (5.5)$$

onde p_i é a probabilidade que o modelo deu ao caso i e y_i vale 1 se o caso se revelou importante e 0 se não. Ao contrário das anteriores, aqui **quanto menor, melhor**: zero seria a perfeição.

O quadrado não está ali por acaso. Penaliza mais do que proporcionalmente os enganos confiantes: um modelo que diz 90% e erra paga $(0.9 - 0)^2 = 0.81$, enquanto um que diz 60% e erra paga apenas 0.16. Prometer muito e falhar sai caro, que é a propriedade desejada num sistema que mostra percentagens a quem não as sabe questionar.

Vale a pena fazer a conta para o caso mais simples de todos, porque fecha exatamente. O modelo “alertar sempre” anuncia $p_i = 1$ para todas as notícias. Para os casos que se revelaram importantes ($y_i = 1$) o erro é $(1 - 1)^2 = 0$; para os restantes ($y_i = 0$) é $(1 - 0)^2 = 1$. O Brier passa a ser, simplesmente, a fração de casos não importantes:

$$\text{Brier} = 1 - 0.378 = 0.622$$

E 0.622 é precisamente o valor que a tabela da Secção 5.5 reporta para esse modelo. O modelo de volatilidade obtém 0.218, ou seja, menos de metade do erro.

5.2.7 Qual medida responde a que pergunta

A Tabela 5.1 resume o que cada uma faz e onde é usada, porque usar a medida errada para a pergunta certa é uma forma silenciosa de chegar a uma conclusão falsa.

Uma nota final sobre a primeira linha, que é a única medida deste capítulo que não usa rótulos. A amplitude de disparo mede a diferença entre a empresa em que o detetor mais fala e aquela em que menos fala. Não precisa de saber quais dias eram mesmo invulgares: parte apenas do princípio de que um bom detetor universal deve comportar-se de forma parecida em empresas diferentes. É por não depender de rótulo nenhum que ela serve de argumento principal da secção seguinte, e as restantes de argumento de apoio.

5.3 QI1: detetar o que é invulgar

Um z-score deslizante deteta movimentos invulgares de forma mais consistente do que uma regra fixa? **Sim, e com uma margem grande.**

Tabela 5.1: Cada medida, a pergunta a que responde, o seu chão de referência, e onde aparece neste capítulo.

Medida	Responde a	Chão	Usada em
Amplitude de disparo	O detetor comporta-se do mesmo modo em empresas diferentes?	zero seria o ideal	Q 1
F_1	Acerta quando fala, e fala quando devia?	depende dos dados	Q 1
Precisão@5	Das cinco que mostro, quantas prestam?	0.240 (acaso medido)	Q 2
PR-AUC	Ordena bem, seja qual for o limiar?	0.378 (a prevalência)	Q 3
Brier	A percentagem anunciada é honesta?	0.622 (alertar sempre)	Q 3

5.3.1 Como foi medido

Foram usados três anos de cotações diárias de quinze empresas grandes, entre junho de 2023 e junho de 2026, ou seja, cerca de 750 dias por empresa.

São quinze, e não as doze que o sistema vigia em produção. A diferença é de propósito: a avaliação quer *variedade* de volatilidade, para o argumento da consistência ter sobre o que incidir; a lista de produção é uma escolha de produto e não uma amostra. Confundir as duas seria avaliar o detetor exatamente no conjunto que ele foi montado para servir.

O argumento principal não precisa de rótulos nenhuns, e é por isso que é o principal. Um bom detetor universal deve disparar a um ritmo **parecido** em empresas diferentes. Se disparar muito numa e quase nada noutra, o que está a medir é a volatilidade da empresa e não a raridade do dia.

Como argumento de apoio, usou-se também um rótulo aproximado: considera-se “dia extremo” um dia no percentil 99 dos retornos *daquela* empresa. É um rótulo imperfeito, porque é ele próprio relativo à volatilidade, e por isso vem em segundo lugar.

5.3.2 Resultado

A Tabela 5.2 mostra o argumento principal.

Tabela 5.2: Com que frequência cada método dispara, entre as quinze empresas. O que interessa é a **amplitude**: quanto menor, mais consistente é o detetor.

Método	Taxa mínima	Taxa máxima	Amplitude
z-score (janela 20)	0.016	0.031	0.015
Limiar fixo ($ r \geq 3\%$)	0.009	0.353	0.344

A Figura 5.4 mostra a mesma informação empresa a empresa.

A diferença é de mais de vinte vezes. O limiar fixo dispara em 0.9% dos dias na empresa mais calma e em 35.3% dos dias na mais volátil: para uma delas quase nunca diz nada e para a outra fala um dia em cada três. O z-score fica entre 1.6% e 3.1% em todas.




Figura 5.4: A mesma informação, empresa a empresa. As barras do limiar fixo acompanham a volatilidade de cada ação; as do z-score mantêm-se quase constantes.

Contra o rótulo aproximado, o z-score obtém $F_1 = 0.516$ contra 0.218 do limiar fixo.

5.3.3 E contra métodos aprendidos?

Faltava a comparação mais exigente: e se em vez de uma regra estatística se usasse um método de aprendizagem automática desenhado para detetar anomalias?

Foram testados dois, sobre exatamente a mesma informação e com o mesmo cuidado de não usar o futuro: *Isolation Forest* (Liu, Ting e Zhou 2008) e *Local Outlier Factor* (Breunig et al. 2000). O resultado está na Tabela 5.3.

Tabela 5.3: Os três detetores, sobre os mesmos dados e sob o mesmo protocolo.

Detetor	Precisão	Recall	F_1	Amplitude
z-score (a regra)	0.407	0.761	0.530	0.017
Isolation Forest	0.158	0.913	0.269	0.140
Local Outlier Factor	0.163	0.989	0.280	0.183

A regra transparente ganha aos dois. Não por pouco: quase o dobro do F_1 , e com uma consistência entre empresas muito melhor. Os dois métodos aprendidos assinalam quase tudo (*recall* altíssimo) e acertam pouco (precisão baixa).

Este é o primeiro de três casos, neste capítulo, em que uma técnica mais sofisticada foi comparada de forma justa com uma mais simples e perdeu. É um resultado que vale por si: justifica por medição a escolha do método simples, em vez de a justificar por preferência.

A Figura 5.5 mostra esta comparação em gráfico, e ao lado uma segunda que ainda não foi discutida.




Figura 5.5: À esquerda, os três detetores sobre a mesma região pontuada e com o mesmo cuidado de não usar o futuro. À direita, uma segunda comparação, entre duas maneiras de estimar a volatilidade: a que o sistema usa e uma alternativa. Está discutida a seguir, porque o resultado não foi o esperado.

5.3.4 E uma segunda comparação, que também não me deu razão

O painel direito da Figura 5.5 responde a outra pergunta: e se, em vez de calcular o desvio-padrão dando *o mesmo peso* aos vinte dias, se desse mais peso aos dias recentes?

É uma ideia antiga em finanças, e a experiência foi desenhada para justificar por que razão o sistema *não* precisava dela. Deu o contrário. Com o mesmo *recall*, a alternativa obtém $F_1 = 0.664$ contra os 0.516 da regra usada, e consegue-o eliminando quase metade dos falsos alarmes (precisão 0.568 contra 0.381).

O mecanismo é compreensível depois de visto. Movimentos grandes andam em grupo: depois de um dia agitado costumam vir mais. Uma média de vinte dias com pesos iguais dilui o choque por vinte dias e continua a achar tudo invulgar durante semanas; uma média que dá mais peso ao que é recente absorve o choque de imediato e volta a calar-se.

O sistema continua a usar a versão que perdeu, e a razão é a mesma que atravessa o trabalho: “a média e o desvio dos últimos vinte dias” explica-se a qualquer pessoa em duas frases, e “pesos que decaem exponencialmente” não. Numa ferramenta cujo argumento central é a explicabilidade, um ganho de precisão que custa a explicação não é obviamente um ganho.

Mas é uma escolha, não um resultado, e é assim que fica escrita. A alternativa está medida, o ganho está registado, e adotá-la é uma alteração pequena se algum dia a explicabilidade deixar de ser a restrição dominante.

5.3.5 O que isto não permite concluir

O rótulo é aproximado e relativo à volatilidade, e por isso o argumento de peso é o da consistência, que não usa rótulo nenhum. E a comparação foi feita sobre estas quinze empresas e este período; nada aqui diz o que aconteceria noutro mercado ou noutra década.

5.4 QI2: encontrar casos parecidos

A recuperação por significado encontra notícias passadas genuinamente relacionadas, melhor do que alternativas triviais? **Sim, com folga sobre todas elas.**

5.4.1 Como foi medido

O problema de avaliar recuperação é que não existe uma lista de “respostas certas”. Ninguém etiquetou pares de notícias como relacionados ou não.

Usou-se então uma aproximação verificável: considera-se que uma notícia recuperada é **relevante** se pertencer ao *mesmo setor* da notícia de consulta. É imperfeito, porque duas notícias do mesmo setor podem não ter nada a ver, mas tem duas virtudes: é objetivo, e não foi escolhido depois de ver os resultados.

Além disso, impôs-se uma restrição que torna a tarefa *mais difícil*: a notícia recuperada tem de ser de uma **empresa diferente**. Sem isso, o sistema podia parecer bom limitando-se a devolver notícias da mesma empresa, que estão quase sempre no mesmo setor por construção.

A métrica é a **precisão@5**: das cinco notícias que o sistema devolve, quantas são relevantes.

5.4.2 Resultado

Tabela 5.4: Precisão@5, média de cinco repetições com sementes diferentes.
Quanto maior, melhor.

Método	Precisão@5	O que é
Embeddings (MiniLM)	0.514	o método usado
Embeddings (MPNet)	0.538	um modelo maior, mais lento
Palavras em comum	0.346	procurar por sobreposição de palavras
Escolha ao acaso	0.240	o chão: a proporção natural
Mais recente	0.126	devolver simplesmente as últimas notícias

A Tabela 5.4 tem o método usado, uma variante maior, e as três alternativas triviais. A leitura é direta: escolher ao acaso acerta em 24% dos casos. É esse o chão, e não zero, porque há cinco setores e alguns são maiores do que outros. Procurar por palavras em comum sobe para 34.6%. Comparar significado sobe para 51.4%, mais do dobro do acaso.

A Figura 5.6 mostra o mesmo por setor e para vários tamanhos de lista.

E a alternativa que parece mais razoável de todas, “mostra-me apenas as notícias mais recentes”, é a **pior** de todas, com 12.6%. Faz sentido: a notícia mais recente sobre outra empresa não tem razão nenhuma para estar relacionada com esta.

5.4.3 Aguenta à escala?

A avaliação acima corre sobre um corpus recente e curto. Para confirmar que o resultado não é um acidente desse corpus, a mesma medição foi repetida sobre o conjunto histórico completo, com cerca de 80 mil notícias de seis anos: a precisão@5 sobe para **0.595**.




Figura 5.6: Precisão@ k para cada método, com a restrição de a notícia recuperada ter de ser de outra empresa. A separação entre a linha do método usado e as alternativas mantém-se para todos os k testados, e não apenas para $k = 5$.

5.4.4 O que isto não permite concluir

Duas coisas, e a segunda é importante para o produto.

Primeiro, “mesmo setor” não é o mesmo que “relacionado”. É uma aproximação, e o número deve ser lido como tal.

Segundo, e mais interessante: a recuperação capta **tema**, não **direção**. Duas notícias podem ser sobre o mesmo assunto e o preço ter ido para lados opostos, que foi exatamente o que aconteceu no exemplo do Capítulo 4. Medindo a concordância de direção entre a notícia de consulta e os casos recuperados, obtém-se 0.708 contra um chão de acaso de 0.688: quase nada. Por isso o sistema mostra os casos um a um e nunca resume a uma média, e por isso o texto do alerta diz explicitamente que se trata de casos semelhantes no *tema*.

5.5 Q13: decidir o que merece um alerta

Um modelo treinado prioriza notícias melhor do que uma linha de base simples baseada só em volatilidade? Não. E é o resultado mais interessante deste trabalho.

5.5.1 Como foi medido

O conjunto de dados foi construído a partir do histórico: **79 753** exemplos entre 2018 e 2023, cada um uma notícia com o contexto de mercado do dia e o rótulo descrito na Secção 3.5. A divisão é cronológica com embargo, como na Figura 3.8.

Compararam-se seis modelos, do mais simples ao mais completo. A métrica principal é a **PR-AUC**, apropriada quando as duas classes são desequilibradas.

5.5.2 Resultado

A Figura 5.7 mostra as curvas completas, e não apenas o número resumo.

Tabela 5.5: Quanto maior a PR-AUC, melhor; quanto menor o Brier, melhor calibradas estão as probabilidades.

Modelo	PR-AUC	Brier
Alertar sempre (chão)	0.378	0.622
Só volatilidade	0.542	0.218
Só contexto de mercado	0.538	0.224
Só texto da manchete	0.439	0.240
Contexto + texto	0.496	0.229
Gradient boosting (contexto + texto)	0.469	0.228




Figura 5.7: As curvas sobre o bloco de teste. A área debaixo de cada curva é o valor da tabela. A curva do modelo que usa apenas volatilidade está por cima das outras em quase toda a extensão, e não só no valor agregado.

O melhor modelo da Tabela 5.5 é o mais simples de todos: o que usa **apenas a volatilidade recente**. Acrescentar o resto do contexto não melhora. Acrescentar o texto da manchete *piora*, de 0.542 para 0.496.

Isto era o contrário do que eu esperava quando comecei. A hipótese era que o texto da notícia trouxesse informação que os preços não tinham. Sobre este corpus, não traz.

5.5.3 Não será um acidente do meu setup?

Foi a primeira coisa que fui verificar, por três caminhos.

Será que o modelo de texto estava mal afinado? Repetiu-se a comparação dando ao texto as melhores condições possíveis: regularização afinada, redução de dimensionalidade do bloco de texto, e um modelo de linguagem especializado em finanças. O melhor resultado do texto sobe para 0.533, e continua abaixo dos 0.542 da volatilidade.

Será que a diferença é ruído? Reamostrou-se o bloco de teste mil vezes, por grupos (empresa, dia), porque notícias do mesmo dia sobre a mesma empresa partilham o rótulo e não são observações independentes. A diferença mantém-se com o intervalo a excluir zero.

Será que depende de como defini o rótulo? O rótulo usa um limiar de 2% e um horizonte de três dias, ambos escolhidos por mim. Repetiu-se toda a comparação para nove combinações diferentes de limiar e horizonte. A volatilidade iguala ou bate o modelo com texto nas **nove**.

O resultado negativo aguenta os três testes. Não é um acidente do meu setup: é o que os dados dizem.

5.5.4 Mas serve para alguma coisa?

Serve, mas aqui é preciso muito cuidado com a comparação, porque é fácil enganar-se.

O produto não mostra tudo: mostra no máximo cinco alertas por dia. A pergunta útil passa a ser *das cinco notícias que escolho mostrar, quantas eram mesmo importantes?* A Tabela 5.6 responde.

Tabela 5.6: Quatro formas de escolher as cinco notícias do dia, sobre o mesmo bloco de teste.

Como escolher	Precisão@5	O que é
"Alertar sempre"	0.163	<i>não é escolher às cegas</i> ; ver o aviso abaixo
Ao acaso (40 sementes)	0.379 ± 0.017	o que "às cegas" quer mesmo dizer
Volatilidade média da empresa	0.662	treze constantes, sem ler manchete nenhuma
O modelo treinado	0.632	o que está implantado

Um aviso sobre a primeira linha, que eu próprio quase publiquei errado. O modelo "alertar sempre" dá a mesma pontuação a todas as notícias. Quando todas empatam, a métrica escolhe pela ordem em que as linhas aparecem no ficheiro, e o ficheiro está ordenado por data e por nome da empresa. Ou seja, esse 0.163 **não mede escolher ao acaso: mede escolher por ordem alfabética**, e todas as linhas que ele seleciona pertencem à empresa que vem primeiro no alfabeto.

Comparado com o chão certo, o ganho do modelo é de 1.67 vezes, e não das quase quatro vezes que a primeira leitura sugeria. Deixo isto escrito porque foi um erro meu, e porque a lição é geral: *verificar o que a linha de base mede é tão importante como verificar o que o modelo faz.*

Há ainda a terceira linha, que é desconfortável e fica. Uma tabela de **treze constantes**, a volatilidade média de cada empresa, calculada só sobre o bloco de treino e sem ler uma única manchete, obtém 0.662 e **bate o modelo treinado**. É o terceiro caso deste capítulo em que o método mais simples ganha. O que a evidência sustenta, portanto, é que *ordenar por volatilidade* compensa; não que *aprender* compense.

5.5.5 E em produção?

O sistema regista todas as decisões de triagem e, dias depois, verifica o que realmente aconteceu. Sobre 530 decisões já maturadas, o modelo não mostra benefício: as notícias que ele deixou passar eram importantes 59.2% das vezes, contra 64.7% das que ele travou.

A explicação mais provável não é que o modelo esteja avariado, mas que esteja a **mais**. Quando ele é chamado, as notícias já passaram pelo filtro de relevância e pelo de frescura. Esses filtros baratos já removeram grande parte do que o modelo foi treinado para remover, e sobra-lhe pouco para separar. **Um modelo avaliado isolado e implantado atrás de filtros nunca foi avaliado na distribuição que vai ver.** É a lição mais transferível deste trabalho.

5.5.6 E o que é que o portão estava a escolher, afinal?

A subsecção anterior diz que o modelo está a *mais*. Fica bem como explicação e é vaga: não diz **o que** ele estava a fazer quando era chamado. Vale a pena responder a isso, porque a resposta é medível e porque foi ela que mudou o sistema.

A pergunta é simples. O portão implantado era um limiar fixo sobre a probabilidade calibrada: passa quem estiver acima de 0.50. *Esse limiar separava manchetes, ou separava empresas?*

Mediu-se sobre as 4 366 decisões **realmente tomadas em produção**, e a Figura 5.8 mostra o resultado de uma só vez.




Figura 5.8: Para cada empresa, o intervalo de todas as pontuações que o modelo lhe deu em produção, com a mediana marcada a preto. A linha tracejada é o piso de decisão. As barras claras nunca o alcançam, as escuras atravessam-no, e as alaranjadas estão sempre acima. Repare-se em que oito das doze estão **inteiramente** de um dos lados: para essas, a decisão estava tomada antes de se ler a manchete.

A leitura da figura é imediata e os números confirmam-na:

- a amplitude média das pontuações **dentro** de cada empresa é 0.064;
- a amplitude **entre** as medianas das empresas é 0.385, ou seja, 6.1 vezes maior;
- três empresas ficavam **sempre** acima do piso e cinco **nunca** lá chegavam;

- só em quatro das doze o piso decidia alguma coisa.

Em 84% das decisões, o resultado estava determinado pela **empresa** antes de a manchete ser lida. A Apple não conseguia gerar um alerta de notícia, acontecesse o que acontecesse; a AMD passava em 963 de 963.

E este é o mesmo defeito que este trabalho já tinha identificado, um nível acima. A Secção 5.3 mostra que um limiar fixo sobre o *retorno* mede a volatilidade da empresa e não a raridade do dia, e é essa a razão de ser do z-score. O limiar fixo sobre a *pontuação do modelo* tem exatamente a mesma forma: como a pontuação é quase uma constante por empresa, cortá-la num valor fixo ordena empresas, não notícias. Encontrei o meu próprio erro repetido numa camada diferente.

5.5.7 A correção óbvia, e porque é que não servia

Se o remédio funcionou para os preços, a tentação é aplicá-lo aqui: em vez de um piso fixo, um piso *relativo a cada empresa*, alertando quando a pontuação é invulgar *para aquela empresa*.

Simulei-o sobre as mesmas decisões antes de escrever uma linha de código. Metade do problema resolve-se: as doze empresas passam a estar representadas, que é o efeito pretendido. Mas aparece outro, e é o mais instrutivo desta secção.

Nas empresas cuja pontuação quase não varia, o percentil cai **em cima** da constante e quase todas as decisões empatam acima dele. A JNJ, cuja pontuação vive entre 0.298 e 0.324, passaria 874 vezes. O piso relativo deixa de escolher por materialidade e passa a escolher por desempate, que é precisamente o artefacto documentado na Secção 5.5 a propósito do chão de comparação.

Não se corrige um defeito introduzindo o defeito vizinho. A conclusão honesta é mais funda do que “falta afinar o piso”:

Dentro de uma empresa, a pontuação do modelo quase não varia com a manchete. Nenhuma regra de decisão aplicada a essa pontuação a pode tornar sensível à notícia, porque a informação que distinguiria uma manchete da seguinte não está lá.

O que se fez em consequência, e porquê. O modelo deixou de ser porta e passou a ser critério de **ordenação**. É o uso que a medição sustenta: entre empresas ele tem informação, e é exatamente isso que a precisão dentro de um orçamento mede. O controlo de volume passou para um **orçamento diário** de cinco alertas, servido por ordem de materialidade.

E isto fecha uma divergência que só se viu ao olhar para as duas coisas ao mesmo tempo: **esta dissertação avaliava uma política de orçamento e o sistema implantava uma política de limiar**. Eram políticas diferentes, portanto o número reportado descrevia um sistema que não era o que estava no ar. Passaram a ser a mesma.

5.5.8 O que isto não permite concluir

Que o texto de notícias não sirva para nada. Só se testou uma representação (manchetes, sem o corpo do artigo) sobre um corpus. Com textos completos e mais dados, a resposta podia ser outra, e isso fica como trabalho futuro, não como desculpa.

E, sobre a secção anterior, que o modelo seja inútil. Ele ordena empresas melhor do que o acaso, e é com esse papel que ficou. O que a medição desmente é o uso que lhe estava a ser dado.

5.6 Todas as alternativas que foram testadas e não ficaram

Como é que sei que estas escolhas são boas, e não apenas as primeiras que me ocorreram?

Ao longo dos três capítulos anteriores cada técnica foi apresentada com uma justificação. Falta juntá-las num sítio só, porque é assim que se vê o padrão: **a maior parte das escolhas deste sistema foi decidida por medição contra uma alternativa concreta**, e várias delas contrariaram o que eu esperava.

A Tabela 5.7 lista todas. A coluna do meio é a que interessa: não o que ficou, mas o que foi *posto de lado* e com que número.

Tabela 5.7: As decisões técnicas do trabalho, cada uma com a alternativa medida contra ela. Duas linhas dizem *não ganhou*: são os pontos em que o sistema usa a opção que a medição não favorece, e a razão está escrita. As três últimas não têm número porque são decisões de restrição.

Ficou	Perdeu, e com que número	O que isso quer dizer
z-score deslizante	Limiar fixo de 3%: amplitude 0.344 contra 0.015	Um limiar fixo mede a volatilidade da empresa, não a raridade do dia.
z-score deslizante	<i>Isolation Forest</i> (F_1 0.269) e <i>Local Outlier Factor</i> (0.280) contra 0.530	Os métodos aprendidos assinalam quase tudo e acertam pouco.
Janela de 20 dias	Não ganhou : 10d dá F_1 0.385, 20d dá 0.516, e 60d dá 0.678	A medição favorece uma janela mais longa. Ver a discussão abaixo.
Desvio-padrão de pesos iguais	Não ganhou : pesos que decaem dão F_1 0.664 contra 0.516	Mantido por ser explicável a um leigo, e dito como escolha e não como resultado.
Embeddings de frase	Sobreposição de palavras: P@5 0.346 contra 0.514	Palavras iguais não são assunto igual, e assunto igual não precisa de palavras iguais.
MiniLM	MPNet (0.538, maior e mais lento) e um modelo de finanças (0.420)	O modelo específico do domínio foi o pior. Não se assumiu: mediu-se.
Regressão logística	Árvores com <i>boosting</i> : PR-AUC 0.469 contra 0.538	O modelo mais expressivo não ganhou, e o simples explica-se.
Calibração de Platt	Regressão isotónica, comparada na mesma validação	Platt iguala ou ganha no Brier em todas as famílias testadas.
Cosseno	Distância euclidiana	Com vetores normalizados as duas dão a mesma ordenação, e o cosseno lê-se melhor.
Apenas fontes gratuitas	—	Restrição fundadora: define quem o sistema pode servir.
Não prever preços	—	Restrição de desenho: é o que torna tudo o resto verificável.
Mercado dos EUA	—	Restrição de âmbito: é onde as fontes gratuitas têm cobertura.

Vale a pena olhar para três linhas com atenção.

O **modelo de finanças perdeu**. Era a escolha que parecia mais óbvia de todas: um modelo treinado especificamente em texto financeiro devia ser melhor a comparar notícias financeiras. Obteve 0.420 contra os 0.514 de um modelo genérico e pequeno. Se eu o tivesse adotado por ser o óbvio, o sistema ficava pior e eu nunca saberia.

A janela de 20 dias é a única linha desta tabela em que o sistema não usa o vencedor. E é a que mais me custou deixar escrita. A ablação diz que uma janela de 60 dias obtém $F_1 = 0.678$ contra os 0.516 da janela de 20. Se o critério fosse este número, o sistema devia usar 60.

Não usa, por duas razões, e a segunda é a que importa.

A primeira é que uma janela de 60 dias demora três meses a reagir a uma mudança de regime. Uma empresa que passa de calma a volátil continuaria a ser julgada pela sua norma antiga, e o detetor dispararia a torto e a direito durante semanas.

A segunda é que **este número não é de confiança para esta comparação**. O rótulo é um *proxy* construído a partir do percentil de movimento *da própria empresa*, portanto é ele próprio relativo à volatilidade. Uma janela mais longa produz uma norma menos adaptativa, que assinala mais vezes a cauda extrema, que é precisamente o que este rótulo premeia. Há circularidade, e ela favorece a janela longa por construção.

É por isso que o argumento principal da Secção 5.3 é a **consistência da taxa de disparo**, que não usa rótulo nenhum. Mas nada disto transforma 0.678 em 0.516. A afirmação honesta é: *a janela de 20 dias foi escolhida por responsividade, e a única medição que existe sobre este ponto não a sustenta*. Fica assim.

E as **três últimas linhas não têm número de propósito**. São restrições, não resultados: foram escolhidas antes de haver qualquer medição e não se defendem com uma tabela. Apresentá-las como se tivessem sido testadas seria dar-lhes uma autoridade que não têm.

5.7 Resumo dos três resultados

Tabela 5.8: O veredicto de cada questão de investigação.

Pergunta	Resposta	Com base em quê
Q11 deteção	Sim	Amplitude de disparo 0.015 contra 0.344; e ganha a dois métodos aprendidos (F_1 0.530 contra 0.269 e 0.280)
Q12 precedentes	Sim	Precisão@5 de 0.514 contra 0.346 (palavras), 0.240 (acaso) e 0.126 (recência); 0.595 à escala
Q13 triagem	Não	Nenhum modelo com texto bate a volatilidade (0.496 contra 0.542), e o resultado aguenta três testes de robustez

A Tabela 5.8 junta as três. Duas das respostas são afirmativas e uma é negativa. A negativa é a que eu mais aprendi a defender: mostra que a avaliação foi montada para poder dizer que não, e uma avaliação que só sabe dizer que sim não avalia nada.

Capítulo 6

Conclusões

6.1 O que ficou feito

No fim, o que é que existe?

Existe um sistema a funcionar, e não uma demonstração. O InvestiGator vigia doze empresas, corre de forma contínua, e envia alertas explicados a um canal público, com uma página web onde tudo o que foi enviado pode ser consultado depois.

E existe uma avaliação de cada uma das três técnicas, contra alternativas mais simples, com os resultados reportados como se revelaram. É essa a parte que dá a este trabalho o carácter de dissertação e não o de projeto.

6.2 As respostas às perguntas de investigação

QI1, deteção. Sim. Um z-score deslizante deteta movimentos invulgares de forma muito mais consistente entre empresas do que uma regra fixa: uma amplitude de disparo de 0.015 contra 0.344, mais de vinte vezes melhor. E, sujeito a uma comparação justa, ganha também a dois métodos de aprendizagem desenhados para esta tarefa.

QI2, precedentes. Sim. A recuperação por significado encontra notícias passadas relacionadas melhor do que procurar por palavras, do que escolher ao acaso e do que devolver as mais recentes (0.514 contra 0.346, 0.240 e 0.126), e o resultado aguenta à escala do corpus completo (0.595). Com uma ressalva que ficou clara ao medir: a semelhança capta o **tema**, não a **direção**.

QI3, triagem. Não. Nenhum modelo que lê o texto da manchete bateu uma linha de base que usa apenas volatilidade (0.496 contra 0.542). O resultado sobreviveu a um re-teste em condições favoráveis ao texto, a uma reamostragem por grupos, e a nove definições diferentes do rótulo.

Esta última resposta é negativa e é a que eu levo mais a sério. Escrevi o critério de sucesso antes de correr a experiência, e o resultado foi ao contrário do que eu esperava. Reportá-lo tal como caiu era a única opção compatível com o resto do trabalho.

6.3 Os objetivos, um a um

Dos quatro objetivos da Secção 1.3, **três estão cumpridos e um está cumprido por metade**.

1. *Construir o sistema completo.* Cumprido. Os dois gatilhos funcionam de ponta a ponta, em produção.
2. *Avaliar cada componente contra linhas de base transparentes.* Cumprido, e mais do que o prometido: o detetor foi comparado não só com uma regra fixa mas também com dois métodos aprendidos.
3. *Garantir que as explicações são fiéis.* **Cumprido por metade.** A fidelidade está garantida por construção: o texto é montado a partir dos objetos calculados, e não pode divergir deles. Mas a *utilidade* para uma pessoa real não foi medida, porque não se chegou a fazer um estudo com utilizadores. Não se afirma nada sobre ela.
4. *Reportar os resultados tal como se revelarem.* Cumprido, e a prova é o resultado negativo da QI3 estar no documento com o mesmo destaque dos outros dois.

6.4 Limitações

Onde é que este trabalho é fraco?

Ditas em voz alta, por ordem de importância.

Não há estudo com utilizadores. É a lacuna maior e a mais fácil de nomear. Todo o sistema é construído à volta da ideia de que uma explicação ajuda um não-especialista a decidir melhor, e essa ideia **não foi testada com pessoas**. O desenho do estudo existe, com participantes, tarefas e critérios definidos, mas não foi corrido a tempo. Enquanto isso não acontecer, a metade “útil” do terceiro objetivo fica sem resposta, e é assim que está escrito.

Os alertas ainda não estão bem calibrados, e sei disso a usar. Esta é a limitação que mais me incomoda, precisamente porque a noto como utilizador e não nos números. Recebo no telemóvel, por outras vias, notícias sobre estas empresas que o sistema não assinalou. E há dias em que uma ação sobe bastante e não gera alerta nenhum.

Parte disto está medido: sobre um ano de notícias captadas, existia pelo menos uma notícia relevante em 88.5% dos dias que o detetor considerou invulgares. Os restantes 11.5% são dias em que **nenhuma alteração ao código ajuda**: se a fonte gratuita não associou nenhuma notícia à empresa, ela nunca entra no funil. E a cobertura é muito desigual: a empresa pior coberta fica-se pelos 50%.

Mas esse número é um **limite superior**, e a distinção importa: ele pergunta se existia *uma* notícia, não se chegou *a certa*. Saber isso exigiria julgamento humano dia a dia, e é trabalho por fazer.

O alerta afirma mais evidência do que tem. Quando mostra três precedentes e diz que os três se moveram na mesma direção, está a apresentar isso como concordância entre três casos. Só que o impacto é medido por (*empresa, dia*): três manchetes da mesma empresa no mesmo dia partilham o mesmo valor por construção. Medido sobre os 247 alertas já

entregues com precedentes, em 36.8% deles os casos assentam em menos dias distintos do que casos mostrados, e em 11.3% são todos do mesmo dia. Não afeta nenhum número do Capítulo 5; afeta o que o produto diz ao utilizador, e a correção é contar dias e não manchetes.

As notícias são só manchetes. O sistema lê o título e não o corpo do artigo. Isso limita o que a representação de texto consegue captar, e é uma explicação plausível, embora não confirmada, para o resultado negativo da Q13.

Os rótulos são aproximações. “Relevante” é aproximado por “mesmo setor”, e “importante” é aproximado por “houve movimento grande”. As duas são objetivas e verificáveis, mas nenhuma é a coisa que realmente se queria medir.

O modelo treinado não mostra benefício em produção. Medido sobre as decisões já verificadas, o modelo não separa melhor do que o acaso na população que realmente vê. A explicação mais provável é que ele esteja a mais: quando é chamado, os filtros mais baratos já removeram quase tudo o que ele foi treinado para remover.

O atraso é real e não se resolve com engenharia. Entre a notícia ser publicada e o sistema a ver passam, em mediana, cerca de duas horas e meia. A entrega, depois disso, demora um segundo. Comprar um serviço de notícias em tempo real resolveria e violaria a restrição fundadora deste trabalho.

6.5 O que eu faria a seguir

Se houvesse mais três meses, por onde começava?

Por esta ordem, e as três primeiras respondem diretamente às limitações acima.

1. **Correr o estudo com utilizadores.** Seis a dez pessoas, quinze minutos cada. Fecha a metade em aberto do terceiro objetivo e é a única coisa desta lista que não se pode acelerar com mais computação: precisa de calendário.
2. **Estudar a sério os critérios de alerta.** É o trabalho que a limitação anterior pede. Não basta ajustar limiares: é preciso perceber, com julgamento humano sobre uma amostra de dias, quais das notícias que hoje não passam *deviam* passar, e quais das que passam não acrescentam nada. Isso daria pela primeira vez um alvo real para otimizar, em vez de se estar a afinar constantes contra um proxy.
3. **Ler o corpo dos artigos, e não só o título.** É a hipótese mais direta para explicar o negativo da Q13, e é testável com o mesmo protocolo já montado.
4. **Detetar histórias repetidas por significado.** Hoje a repetição é apanhada por palavras em comum. Fazê-lo por significado usaria a técnica que o sistema já tem, e atacaria de frente a fadiga de alertas.

6.6 O que eu aprendi

Termino com aquilo que mudou na minha cabeça ao longo destes meses, porque é a parte que não estava no plano.

A primeira coisa foi perceber que **a linha de base é tão importante como o modelo**. Passei semanas a melhorar modelos e o resultado mais útil de todo o trabalho veio de olhar com atenção para aquilo contra o qual os estava a comparar. Numa das medições, o valor que eu usava como “escolher às cegas” não escolhia às cegas de todo: escolhia por ordem alfabética. Corrigir isso reduziu para menos de metade um ganho que eu já tinha escrito.

A segunda foi perceber que **o sítio onde se põe um modelo importa tanto como o modelo**. O meu funcionava razoavelmente quando avaliado sozinho e deixou de servir para nada quando colocado atrás de dois filtros simples, que já faziam grande parte do trabalho. Isso não estava em nenhum sítio do plano inicial, e é provavelmente a lição mais transferível que levo daqui.

E a terceira foi mais simples do que as outras: **a técnica mais simples ganhou três vezes**. Ganhou ao Isolation Forest, ganhou ao modelo que lê o texto, e uma tabela de treze constantes ganhou ao modelo que está implantado. Comecei este trabalho a assumir que o caminho para um bom resultado era acrescentar sofisticação. Acabo-o com três medições a dizer o contrário, e com a convicção de que a parte difícil da engenharia de inteligência artificial não é escolher a técnica mais avançada, é montar a avaliação que consegue dizer que ela não era precisa.

Bibliografia

- Aamodt, Agnar e Enric Plaza (1994). «Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches». Em: *AI Communications* 7.1, pp. 39–59. doi: 10.3233/AIC-1994-7104.
- Adadi, Amina e Mohammed Berrada (2018). «Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)». Em: *IEEE Access* 6, pp. 52138–52160. doi: 10.1109/ACCESS.2018.2870052.
- Araci, Dogu (2019). «FinBERT: Financial Sentiment Analysis with Pre-trained Language Models». Em: *arXiv preprint*. arXiv: 1908.10063 [cs.CL].
- Barredo Arrieta, Alejandro et al. (2020). «Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI». Em: *Information Fusion* 58, pp. 82–115. doi: 10.1016/j.inffus.2019.12.012.
- Breunig, Markus M. et al. (2000). «LOF: Identifying Density-Based Local Outliers». Em: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104. doi: 10.1145/342009.335388.
- Brown, Stephen J. e Jerold B. Warner (1985). «Using Daily Stock Returns: The Case of Event Studies». Em: *Journal of Financial Economics* 14.1, pp. 3–31. doi: 10.1016/0304-405X(85)90042-X.
- Chandola, Varun, Arindam Banerjee e Vipin Kumar (2009). «Anomaly Detection: A Survey». Em: *ACM Computing Surveys* 41.3, 15:1–15:58. doi: 10.1145/1541880.1541882.
- D’Acunto, Francesco, Nagpurnanand Prabhala e Alberto G. Rossi (2019). «The Promises and Pitfalls of Robo-Advising». Em: *The Review of Financial Studies* 32.5, pp. 1983–2020. doi: 10.1093/rfs/hhz014.
- Devlin, Jacob et al. (2019). «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». Em: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, pp. 4171–4186. doi: 10.18653/v1/N19-1423. arXiv: 1810.04805.
- Dong, Zihan, Xinyu Fan e Zhiyuan Peng (2024). «FNSPID: A Comprehensive Financial News Dataset in Time Series». Em: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD ’24)*. Association for Computing Machinery, pp. 4918–4927. doi: 10.1145/3637528.3671629. arXiv: 2402.06698 [q-fin.ST].
- Fama, Eugene F. (1970). «Efficient Capital Markets: A Review of Theory and Empirical Work». Em: *The Journal of Finance* 25.2, pp. 383–417. doi: 10.2307/2325486.
- Gallup (2025). *What Percentage of Americans Own Stock?* url: <https://news.gallup.com/poll/266807/percentage-americans-owns-stock.aspx> (acedido em 21/06/2026).
- Google (jun. de 2026). *Our latest Google Finance upgrades, including a new app*. url: <https://blog.google/products-and-platforms/products/search/google-finance-updates-june-2026/> (acedido em 07/08/2026).
- Lee, John D. e Katrina A. See (2004). «Trust in Automation: Designing for Appropriate Reliance». Em: *Human Factors* 46.1, pp. 50–80. doi: 10.1518/hfes.46.1.50_30392.

- Liu, Fei Tony, Kai Ming Ting e Zhi-Hua Zhou (2008). «Isolation Forest». Em: *2008 Eighth IEEE International Conference on Data Mining (ICDM)*, pp. 413–422. doi: 10.1109/ICDM.2008.17.
- Mikolov, Tomas et al. (2013). «Efficient Estimation of Word Representations in Vector Space». Em: *arXiv preprint*. arXiv: 1301.3781.
- Niculescu-Mizil, Alexandru e Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». Em: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, pp. 625–632. doi: 10.1145/1102351.1102430.
- Reimers, Nils e Iryna Gurevych (2019). «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». Em: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. doi: 10.18653/v1/D19-1410.
- Robinhood Markets (mar. de 2025). *Introducing Robinhood Strategies, Robinhood Banking, and Robinhood Cortex*. url: <https://robinhood.com/us/en/newsroom/introducing-strategies-banking-and-cortex/> (acedido em 07/08/2026).
- Salton, Gerard, A. Wong e C. S. Yang (1975). «A Vector Space Model for Automatic Indexing». Em: *Communications of the ACM* 18.11, pp. 613–620. doi: 10.1145/361219.361220.
- Securities Industry and Financial Markets Association (SIFMA) (2025). *2025 Capital Markets Fact Book*. url: <https://www.sifma.org/resources/research/fact-book/> (acedido em 21/06/2026).
- Tetlock, Paul C. (2007). «Giving Content to Investor Sentiment: The Role of Media in the Stock Market». Em: *The Journal of Finance* 62.3, pp. 1139–1168. doi: 10.1111/j.1540-6261.2007.01232.x.
- Wu, Shijie et al. (2023). «BloombergGPT: A Large Language Model for Finance». Em: *arXiv preprint*. arXiv: 2303.17564 [cs.LG].

Apêndice A

Reprodutibilidade

A.1 Ambiente

O sistema está escrito em Python 3.12. As dependências estão fixadas num ficheiro de bloqueio, para que o ambiente possa ser recriado noutra máquina. A Tabela A.1 lista as principais.

Tabela A.1: Versões fixadas das dependências principais.

Biblioteca	Versão	Biblioteca	Versão
numpy	2.1.3	sentence-transformers	5.6.0
pandas	2.2.3	transformers	5.12.1
scikit-learn	1.9.0	torch (versão CPU)	2.12.1
matplotlib	3.11.0	pytest	8.3.4
yfinance	1.4.1	ruff	0.8.6

Não é preciso GPU. Tudo o que esta dissertação reporta corre num computador portátil comum, o que é uma consequência deliberada das escolhas do Capítulo 3.

O código está organizado por componente, a espelhar a Figura 4.1: dados de mercado, recolha de notícias, deteção, motor de correlação, base de casos, motor de explicação e entrega. A lógica pura está separada da entrada e saída, e as dependências pesadas são carregadas só quando precisas, e por isso o núcleo é testado sem rede e sem carregar modelos. A suite tem **726 testes** automáticos.

Os segredos (chaves de API, credenciais) são lidos de um ficheiro local que nunca é versionado.

A.2 Como cada número é reproduzido

Nenhum *resultado* desta dissertação foi escrito à mão. Cada um é produzido por um procedimento automático com semente fixa, que escreve o seu próprio ficheiro de resultados; o texto cita esse ficheiro. A Tabela A.2 liga cada resultado ao procedimento que o gera. Os restantes números do documento são de dois tipos, e nenhum deles é uma medição minha: valores retirados das fontes citadas, e constantes de configuração do sistema.

Tabela A.2: Todos os resultados reportados, e onde são gerados. Correr outra vez sobre os mesmos dados devolve exatamente os mesmos valores.

Resultado	Valor	Onde aparece
Amplitude da taxa de disparo (z-score vs limiar fixo)	0.015 vs 0.344	§5.3
F_1 contra o rótulo aproximado	0.516 vs 0.218	§5.3
z-score contra dois detetores aprendidos	0.530 / 0.269 / 0.280	§5.3
Precisão@5 da recuperação (4 métodos)	0.514 / 0.346 / 0.240 / 0.126	§5.4
Precisão@5 sobre o corpus completo	0.595	§5.4
Concordância de direção vs chão de acaso	0.708 vs 0.688	§5.4
Triagem, PR-AUC das seis famílias	0.378 a 0.542	§5.5
Precisão dentro do orçamento (4 formas de escolher)	0.163 / 0.379 / 0.662 / 0.632	§5.5
Grelha de nove definições de rótulo	9 de 9	§5.5
Decisões maturadas em produção	0.592 vs 0.647	§5.5
Cobertura das notícias em dias invulgares	88.5%	§6.4
Latência, por era e decomposta	196 / 143 / 158 min	§4.8
Funil de produção (captadas → enviadas)	944 → 42	§4.6

A.3 Matriz de evidência

A tabela anterior lista *resultados*. Esta lista *afirmações*, que é um teste mais duro, porque uma afirmação pode sobreviver à evidência que a sustentava.

A Tabela A.3 põe cada afirmação substantiva desta dissertação frente à evidência que a suporta e ao estado em que ficou. **As afirmações retiradas ficam na tabela em vez de serem apagadas**, porque uma matriz que só lista as sobreviventes não é uma auditoria.

Duas observações sobre a tabela no seu conjunto, e não sobre nenhuma linha.

Primeiro: **quatro afirmações foram retiradas, e todas o foram pelas medições deste próprio trabalho**, nenhuma por revisão externa. É o comportamento pretendido de uma avaliação desenhada antes das experiências: tem de ser capaz de dizer que não.

Segundo: as duas linhas marcadas “não afirmado” são tão importantes como as outras. Uma delas é a utilidade para o utilizador, que não foi medida porque não houve estudo com pessoas. Onde não há evidência, não há afirmação.

A.4 Dados e atribuição

Os ficheiros de dados grandes não são versionados: são regenerados pelos procedimentos de preparação, e apenas pequenas amostras acompanham o código para que os testes corram sem rede.

O conjunto histórico usado para construir a base de casos é o FNSPID (Dong, Fan e Peng 2024), utilizado ao abrigo da sua licença Creative Commons BY-SA 4.0, cuja atribuição é aqui cumprida. Apenas excertos mínimos de manchetes aparecem no documento, a título ilustrativo.

A.4. Dados e atribuição

Tabela A.3: Cada afirmação, a evidência, e o que lhe aconteceu. “Retirada” significa que este trabalho a abandonou depois de a medir.

Afirmação	Evidência	Estado
QI1, deteção		
Dispara a um ritmo comparável entre empresas muito diferentes	Amplitude 0.015 vs 0.344, sem usar rótulos	Mantida
Bate um limiar fixo no rótulo aproximado	F_1 0.516 vs 0.218	Mantida (o rótulo é um proxy)
Bate dois detetores aprendidos com a mesma informação	F_1 0.530 vs 0.269 e 0.280	Mantida
Não usa informação do futuro	A janela exclui o dia julgado; imposto por teste	Mantida
QI2, precedentes		
Bate as alternativas lexical e triviais	P@5 0.514 vs 0.346 / 0.240 / 0.126	Mantida
Aguenta à escala do corpus completo	P@5 0.595	Mantida
Capta tema, não direção	Concordância 0.708 contra um chão de 0.688	Mantida (é uma limitação)
“Relevante” é o mesmo que “mesmo setor”	—	Não afirmado (é um proxy)
O chão de semelhança escolhe precedentes que preveem melhor	Acima do chão 0.504, abaixo 0.506, acaso 0.507	Retirada
QI3, triagem		
Nenhum modelo com texto bate a volatilidade	PR-AUC 0.496 vs 0.542; aguenta re-teste justo, reamostragem por grupos e nove rótulos	Mantida
Sem uso de informação futura nas features	Mutar o futuro deixa as features iguais e muda o rótulo	Mantida
A triagem quase quadruplica a precisão no orçamento	O chão de 0.163 ordena alfabeticamente; ao acaso dá 0.379	Retirada (o ganho é 1.67×)
É a aprendizagem que produz o ganho no orçamento	Um prior de 13 constantes dá 0.662 contra 0.632 do modelo	Retirada
O modelo implantado seleciona melhor do que o acaso	0.592 mantidas contra 0.647 suprimidas	Retirada
Sistema		
O texto do alerta não pode divergir do cálculo	É montado a partir dos objetos calculados	Mantida
A fonte gratuita limita a cobertura	Pelo menos uma notícia em 88.5% dos dias invulgares	Mantida (limite superior)
As explicações são <i>úteis</i> a uma pessoa	—	Não afirmado

Os preços vêm de serviços gratuitos de dados de mercado, através de uma cadeia de alternativas descrita na Secção 4.2; as notícias em tempo real vêm de uma API gratuita, dentro dos seus limites de utilização. Não é recolhido nem armazenado qualquer dado pessoal: o sistema não sabe o que os utilizadores possuem, e não lhes pergunta.