

Explicar sem prever: deteção de anomalias e recuperação de precedentes em alertas verificáveis para o investidor particular

Henrique José da Silva Santos

Aluno nº: 1180934

**Dissertação para obtenção do Grau de
Mestre em Engenharia de Inteligência Artificial**

Orientador: Luís Gomes
Co-Orientador: Rafael Silva

Júri:

Presidente:

[Nome do Presidente, Categoria, Escola]

Vogais:

[Nome do Vogal 1, Categoria, Escola]

[Nome do Vogal 2, Categoria, Escola]

Declaração de Integridade

Declaro que realizei este trabalho acadêmico com integridade.

Não recorri a plágio nem a qualquer forma de utilização indevida ou falsificação de informações ou resultados ao longo do processo que conduziu à sua elaboração.

Declaro, por isso, que este documento é original e da minha autoria, não tendo sido utilizado anteriormente para qualquer outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

Uso de Inteligência Artificial. Em conformidade com as orientações do P.PORTO/ISEP, declaro o uso de ferramentas de inteligência artificial generativa neste trabalho, e descrevo-o com precisão.

A concepção é minha: o problema, as questões de investigação, as restrições que definem o sistema (apenas fontes gratuitas, explicabilidade primeiro, e a recusa de prever preços), o desenho de cada experiência e o critério de sucesso fixado antes de a correr, e todas as decisões sobre o que construir, manter ou descartar. Nenhuma conclusão deste documento foi delegada.

A execução foi assistida, e em extensão substancial. Essas ferramentas escreveram e reestruturaram parte considerável do código do sistema e dos seus testes, implementaram os procedimentos de avaliação, redigiram e editaram prosa neste documento, e conduziram revisões que encontraram defeitos no software e no texto. Onde uma medição contrariou uma afirmação minha, retirei a afirmação em vez de a defender, e o Apêndice A regista as que foram retiradas.

Revi o conteúdo deste documento. Ele, os erros que nele restem, e a sua defesa são da minha responsabilidade.

ISEP, Porto, setembro de 2026

Dedicatória

À minha família.

Resumo

Quando uma ação se move de forma abrupta, um investidor particular faz quase sempre as mesmas três perguntas: *isto é invulgar?*, *foi a empresa ou foi o mercado?*, e *já aconteceu antes, e o que se seguiu?* As ferramentas gratuitas mostram a percentagem e ficam-se por aí; os terminais profissionais respondem, mas a um custo fora do alcance de quem investe as suas poupanças.

Esta dissertação apresenta o **InvestiGator**, um sistema de alertas financeiros construído sobre fontes de dados gratuitas, que responde às três perguntas e mostra sempre como chegou à resposta. O trabalho assenta em quatro técnicas: deteção de anomalias por z-score deslizante; decomposição do movimento em mercado, setor e empresa, com encolhimento do beta pela precisão da estimativa; recuperação de precedentes por semelhança semântica, com medição do desfecho observado; e um modelo supervisionado de triagem, treinado sobre um conjunto de dados próprio, para decidir que notícias merecem interromper alguém.

Cada componente foi avaliado contra linhas de base transparentes, e os resultados são reportados tal como se revelaram. A deteção normalizada pela volatilidade dispara de forma muito mais consistente entre empresas do que um limiar fixo. A recuperação semântica supera as linhas de base lexical e triviais. O modelo de triagem, construído sobre um conjunto de 79 753 exemplos, **não** superou uma linha de base que usa apenas volatilidade, um resultado negativo que se reporta, e que valida por medição a opção pela simplicidade que atravessa todo o trabalho. Medido, porém, *por cima* de uma base que sabe tudo da empresa e nada da notícia, em vez de contra ela, o título acrescenta uma quantidade pequena e mensurável, o que situa o limite: a informação que ele traz distingue empresas, e não notícias.

O sistema esteve em funcionamento contínuo durante a escrita desta dissertação, e as suas próprias decisões foram avaliadas uma segunda vez contra o que o mercado fez a seguir, sobre 825 decisões já maturadas.

O sistema recusa, por desenho, prever preços: explica o que já aconteceu, com a evidência ao lado. A única exceção é declarada como tal e vai no fim de cada alerta: uma probabilidade de o mercado reagir de forma invulgar, *em qualquer direção*, que é uma afirmação sobre a materialidade e nunca sobre o sentido do movimento.

Palavras-chave: IA Explicável, Alertas Financeiros, Deteção de Anomalias, Recuperação Semântica, Investidor Particular

Abstract

When a stock moves abruptly, a retail investor tends to ask the same three questions: *is this unusual?*, *was it the company or the market?*, and *has this happened before, and what followed?* Free tools show the percentage and stop there; professional terminals do answer, at a subscription cost beyond someone investing their savings.

This dissertation presents **InvestiGator**, a financial alerting system built on free data sources that answers those three questions and always shows how it reached the answer. The work rests on four techniques: anomaly detection with a rolling z-score; decomposition of a move into market, sector and company, with the beta shrunk by the precision of its estimate; precedent retrieval by semantic similarity, with measurement of the observed outcome; and a supervised triage model, trained on a purpose-built dataset, to decide which news deserves interrupting someone.

Each component was evaluated against transparent baselines, and the results are reported exactly as they fell. Volatility-normalised detection fires far more consistently across companies than a fixed threshold. Semantic retrieval beats lexical and trivial baselines. The triage model, trained on a purpose-built dataset of 79 753 examples, did **not** beat a volatility-only baseline, a negative result that is reported, and that validates by measurement the simplicity-first stance running through the work. Measured *on top of* a baseline that knows everything about the company and nothing about the news item, rather than against it, the headline does add a small and measurable amount, which locates the limit: the information it carries separates companies, not news items.

The system ran continuously while this dissertation was being written, and its own decisions were evaluated a second time against what the market did next, over 825 matured decisions.

By design, the system refuses to predict prices: it explains what already happened, with the evidence beside it. The one exception is declared as such and comes last in every alert: a probability that the market reacts unusually, *in either direction*, which is a claim about materiality and never about which way the price goes.

Keywords: Explainable AI, Financial Alerts, Anomaly Detection, Semantic Retrieval, Retail Investor

Agradecimentos

Ao meu orientador, Prof. Luís Gomes, e ao meu coorientador, Rafael Silva, por todo o apoio ao longo desta tese. Por trocarem ideias comigo e me ajudarem a decidir a direção do tema; por me mostrarem exemplos de aplicações que já existem e me manterem a par do que se vai fazendo na área; e por me guiarem na elaboração deste documento. Muito do que aqui está tomou a forma que tem porque houve antes uma conversa com eles.

À minha família, por todo o apoio e por acreditarem em mim. Por me incentivarem sempre, e pela alegria com que foram acompanhando a construção disto. É, para mim, a melhor parte de o ter feito.

Aos meus colegas da Sistrade, e à Sistrade, pela flexibilidade que me permitiu seguir este mestrado a par do trabalho, pelas conversas informais sobre a aplicação ao longo destes meses, e por serem boa companhia todos os dias.

Índice

Lista de Acrónimos

xxiii

1	Introdução	1
1.1	Contextualização	1
1.2	O problema, e o que o sistema faz	2
1.3	Objetivos e perguntas de investigação	3
1.4	Contribuições científicas	4
1.5	Estrutura do documento	4
2	Estado da arte	7
2.1	Quem investe, e porque é que a atenção é o problema	7
2.2	O que existe hoje para quem investe pouco	9
2.3	Os produtos que fazem exatamente esta pergunta	10
2.4	E um assistente de IA genérico?	10
2.5	Detetar o que é invulgar	11
2.6	Representar texto por significado	12
2.7	Recuperar casos parecidos, e saber se a recuperação é boa	14
2.8	Medir o efeito de um acontecimento	14
2.9	Raciocinar por casos passados	15
2.10	Explicar decisões automáticas	15
2.11	Um modelo que continua a funcionar depois de implantado	17
2.12	Síntese: a lacuna que este trabalho ocupa	18
2.13	As escolhas que este trabalho faz	19
3	Métodos e materiais	21
3.1	Que tipo de investigação é esta	21
3.2	As quatro decisões	22
3.3	Os dados, tal como são	22
3.3.1	O que entra: uma notícia histórica	22
3.3.2	O que é construído: uma linha do conjunto de treino	23
3.3.3	O que é guardado: um caso na base de precedentes	23
3.3.4	Que períodos, exatamente	24
3.4	Técnica 1: detetar o que é invulgar	25
3.4.1	O problema, em palavras	25
3.4.2	A ideia: medir em desvios-padrão	25
3.4.3	A janela que anda, e a regra que a protege	26
3.4.4	Um caso real	27
3.5	Técnica 2: separar a empresa do mercado	27
3.5.1	O problema, em palavras	27
3.5.2	A ideia: um movimento tem parcelas	28
3.5.3	Um caso real, com todos os passos	30

3.5.4	O que esta técnica não garante	31
3.6	Técnica 3: encontrar casos parecidos	31
3.6.1	O problema, em palavras	31
3.6.2	A ideia: transformar frases em pontos	31
3.6.3	Medir a distância: o cosseno	32
3.6.4	O cosseno em dois casos reais	33
3.6.5	Medir o que se seguiu	34
3.7	Técnica 4: decidir o que merece um alerta	35
3.7.1	O problema, em palavras	35
3.7.2	A tarefa e o rótulo	35
3.7.3	O que o modelo vê	36
3.7.4	Treinar sem deixar o futuro entrar no treino	37
3.7.5	Da pontuação à probabilidade: calibração	38
3.7.6	Da linha de dados aos 39%: a conta toda	39
3.8	Como é que se sabe que isto funciona	41
3.9	Desafios tecnológicos e sociais	42
3.9.1	Privacidade e proteção de dados	42
3.9.2	Segurança	42
3.9.3	Questões éticas e sociais	43
4	InvestiGator: o sistema	45
4.1	Vista de conjunto	45
4.2	De onde vêm os dados	46
4.3	As peças que não são minhas	46
4.3.1	Porquê três fontes de notícias, e não a melhor	48
4.4	O caminho de uma notícia, do princípio ao fim	49
4.5	O caminho de um movimento de preço	49
4.6	As portas: quando o sistema decide calar-se	51
4.7	Como o alerta é explicado	53
4.8	Onde isto corre, e o que isso custou	56
4.8.1	O sistema aprende com o que vai vendo, e quase não aprendia	57
4.8.2	Trinta e oito mil casos que não cabiam na memória	58
4.9	O ciclo de vida do modelo, e o que nele é meu	60
4.9.1	O que é meu, e o que é consumido	61
4.9.2	O que este ciclo não tem	61
5	Avaliação	63
5.1	Como está montado este capítulo	63
5.2	Como se lê cada número deste capítulo	63
5.2.1	As quatro maneiras de acertar e de errar	63
5.2.2	Precisão e cobertura	64
5.2.3	O F_1 : obrigar as duas a andarem juntas	64
5.2.4	A precisão@ k : avaliar uma lista curta	65
5.2.5	A PR-AUC: a lista toda, em todos os pontos de corte	66
5.2.6	O Brier: a probabilidade tem de ser honesta	67
5.2.7	Qual medida responde a que pergunta	68
5.3	QI1: detetar o que é invulgar	68
5.3.1	Como foi medido	68
5.3.2	Resultado	69

5.3.3	E contra métodos aprendidos?	70
5.3.4	E uma segunda comparação, que também não confirmou a escolha	71
5.3.5	O que isto não permite concluir	72
5.4	A técnica sem pergunta: porque é que a decomposição não tem QI	72
5.5	QI2: encontrar casos parecidos	73
5.5.1	Como foi medido	73
5.5.2	Resultado	73
5.5.3	Aguenta à escala?	75
5.5.4	E se o sistema só puder olhar para trás?	76
5.5.5	O que isto não permite concluir	76
5.6	QI3: decidir o que merece um alerta	77
5.6.1	Como foi medido	77
5.6.2	Resultado	77
5.6.3	Não será um acidente da minha montagem?	78
5.6.4	Mas tem utilidade prática?	79
5.6.5	E em produção?	80
5.6.6	E os dados de hoje ainda se parecem com os do treino?	80
5.6.7	E o que é que a porta estava a escolher, afinal?	81
5.6.8	E a medição acima não é uma surpresa: é aritmética	83
5.6.9	A prova: uma tabela que não vê a notícia	83
5.6.10	E se o texto não for para substituir, mas para acrescentar?	85
5.6.11	A correção óbvia, e porque é que não servia	86
5.6.12	O que isto não permite concluir	87
5.7	Todas as alternativas que foram testadas e não ficaram	87
5.8	E o sistema inteiro vale mais do que o que a pessoa já tem?	89
5.9	Resumo dos três resultados	90
6	Conclusões	93
6.1	Síntese do trabalho	93
6.2	As respostas às perguntas de investigação	93
6.3	Objetivos alcançados	95
6.4	Limitações	96
6.5	Trabalho futuro	99
6.6	O que eu aprendi	100
	Bibliografia	103
A	Reprodutibilidade	107
A.1	Ambiente	107
A.2	Como cada número é reproduzido	107
A.3	Matriz de evidência	108
A.4	Dados e atribuição	108

Lista de Figuras

1.1	Capitalização do mercado acionista dos EUA	2
1.2	O que o sistema faz	3
2.1	Da atenção à decisão	8
2.2	Três gerações de representação de texto	12
2.3	As duas vias para a explicabilidade	16
3.1	As quatro decisões do sistema	22
3.2	Uma linha do conjunto de dados histórico	22
3.3	Uma linha do conjunto de treino, inteira	23
3.4	Um caso guardado na base de precedentes	23
3.5	A janela deslizante do z-score	26
3.6	Um movimento repartido em três parcelas	29
3.7	Frases como pontos num espaço	32
3.8	O cosseno, e porque é o ângulo e não a distância	33
3.9	Como se mede o impacto de uma notícia	35
3.10	As nove entradas, por nível	37
3.11	Divisão temporal com embargo	37
3.12	A calibração, desenhada	39
4.1	Arquitetura do sistema	45
4.2	As nove etapas de um alerta	49
4.3	Um alerta real, tal como foi entregue	54
4.4	A página, capturada em funcionamento	55
4.5	Onde cada peça corre	56
4.6	O ciclo que faz a base de casos crescer	57
4.7	O ciclo de vida do modelo	60
5.1	As quatro combinações possíveis	64
5.2	A precisão@5 numa consulta	66
5.3	Como se lê uma curva de precisão–cobertura	66
5.4	Taxa de disparo por empresa	69
5.5	A regra contra os métodos aprendidos	71
5.6	Recuperação, por setor e por tamanho de lista	75
5.7	As curvas de precisão e cobertura da triagem	78
5.8	O que a porta separava	81
6.1	As três perguntas e as suas respostas	94
6.2	As limitações e o que as fecha	96
6.3	Das limitações ao trabalho futuro	99

Lista de Tabelas

2.1	As ferramentas existentes contra as três perguntas	9
2.2	Famílias de detecção de anomalias	11
2.3	Abordagens de representação de texto	13
2.4	Abordagens de explicabilidade consideradas	16
2.5	Onde fica este trabalho	19
3.1	O dicionário de colunas	24
3.2	O intervalo real de cada conjunto de dados	24
3.3	O z-score de um dia real	27
3.4	A decomposição de um movimento real	30
3.5	O cosseno entre dois títulos reais	34
3.6	Uma linha, do início ao fim	40
4.1	Tudo o que o sistema usa de fora	47
4.2	As três fontes, medidas	48
4.3	Uma notícia real, etapa a etapa	50
4.4	O funil de um dia real	51
4.5	As portas e as suas constantes	52
4.6	O mesmo conteúdo, três formatos	58
4.7	O que o ciclo de 60 segundos comprou	59
5.1	As medidas usadas e o que cada uma responde	68
5.2	Consistência da taxa de disparo	69
5.3	A regra transparente contra dois métodos aprendidos	70
5.4	Recuperação: o método contra quatro alternativas triviais	74
5.5	A recuperação sob a restrição da produção	76
5.6	Triagem: seis modelos sobre o mesmo bloco de teste	78
5.7	Precisão dentro de um orçamento de cinco alertas por dia	79
5.8	O modelo, desmontado entrada a entrada	84
5.9	O texto por cima da tabela de consulta	85
5.10	Cada escolha, contra a alternativa que perdeu	88
5.11	O sistema contra as alternativas que já existem	89
5.12	As três perguntas e as suas respostas	91
A.1	Versões fixadas das dependências	107
A.2	Cada resultado e o procedimento que o produz	110
A.3	Matriz de evidência	111

Lista de Excertos de Código

3.1	O cálculo do z-score. A fatia [-window-1:-1] exclui o próprio dia da janela que define a sua norma.	26
3.2	Os dois testes que impedem o futuro de entrar nas entradas. O primeiro exige que duas séries com futuros diferentes dêem entradas iguais; o segundo, que é o que fecha o argumento, exige ao mesmo tempo que o <i>rótulo</i> mude.	41

Lista de Acrónimos

API Interface de Programação de Aplicações.

ARCH Autoregressive Conditional Heteroscedasticity.

CI Integração Contínua.

CSV Comma-Separated Values.

FNSPID Financial News and Stock Price Integration Dataset.

GARCH Generalized Autoregressive Conditional Heteroscedasticity.

IA Inteligência Artificial.

JSON JavaScript Object Notation.

LIME Local Interpretable Model-agnostic Explanations.

PR-AUC Precision-Recall Area Under the Curve.

PSI Population Stability Index.

QI Questão de Investigação.

ROC-AUC Receiver Operating Characteristic Area Under the Curve.

SHAP SHapley Additive exPlanations.

Capítulo 1

Introdução

1.1 Contextualização

Que problema é este, e porque é que vale a pena resolvê-lo?

Comprar ações tornou-se uma operação trivial, que exige pouco mais do que uma aplicação no telemóvel e alguns minutos de atenção. Talvez por isso a maior parte dos adultos americanos detenha hoje ações, diretamente ou através de fundos e planos de reforma (Gallup 2025), num mercado que vale mais de 62 biliões de dólares (Securities Industry and Financial Markets Association (SIFMA) 2025) (Figura 1.1).

Difícil é a parte seguinte: perceber o que aconteceu quando o preço se mexe.

E não é uma dificuldade sem consequências. A investigação em finanças comportamentais mostra que os investidores particulares se afastam de forma sistemática do ideal racional (Barberis e Thaler 2003), e um desses desvios diz respeito diretamente a este trabalho: perante milhares de escolhas possíveis, a pessoa acaba por comprar aquilo que lhe *chamou a atenção*. Os autores usam três indicadores observáveis dessa atenção, que são a notícia, o volume invulgar e o retorno extremo de um único dia, e advertem que nenhum deles é um substituto perfeito (Barber e Odean 2008). Dois desses três são exatamente os momentos em que este sistema fala; o volume é calculado e mostrado como contexto, e nunca levanta um alerta sozinho. A isso acresce que as perdas se sentem com mais intensidade do que os ganhos equivalentes (Kahneman e Tversky 1979), o que torna a falta de contexto mais cara justamente quando as notícias são más.

Imagine-se uma pessoa que tem cinco ou seis ações e olha para elas de vez em quando. Num dia qualquer abre a aplicação, vê uma delas a cair 4%, e o que a aplicação lhe diz é exatamente isso, menos 4%. E mais nada.

A partir daí a pessoa fica sozinha com três perguntas. São estas, e são as três à volta das quais este trabalho foi construído:

1. **Isto é invulgar?** Quatro por cento numa empresa habitualmente calma é um movimento grande, ao passo que na mesma semana, e noutra empresa, pode ser um dia perfeitamente normal.
2. **Foi a empresa, ou foi o mercado?** Se caiu tudo, a história é uma; se caiu apenas esta, é outra completamente diferente, e as duas pedem reações opostas.
3. **Já aconteceu antes, e o que se seguiu?** Havendo dias parecidos no passado, saber o que o preço fez a seguir a cada um deles é a única forma de situar o de hoje.

Nenhuma das três obtém resposta nas aplicações gratuitas correntes, que se limitam a mostrar a percentagem, ou seja o princípio da primeira pergunta e não a sua resposta. Há produtos recentes que prometem mais do que isso, e a Secção 2.3 nomeia-os em vez de fingir que este território estava vazio. Os terminais profissionais respondem às três, mas custam por mês mais do que muita gente investe por ano.

É essa distância que este trabalho tenta encurtar, e não por falta de dados, porque dados há de sobra e gratuitos. O que falta é **contexto**, e um contexto que a pessoa possa *verificar*.




Figura 1.1: Capitalização do mercado acionista dos EUA, 2015–2024, em biliões de dólares. É neste mercado que investem as pessoas de quem este trabalho fala. Elaborado a partir dos dados do SIFMA Capital Markets Fact Book (Securities Industry and Financial Markets Association (SIFMA) 2025).

1.2 O problema, e o que o sistema faz

Se tivesse de explicar o InvestiGator numa frase, qual seria?

Esta: **o sistema vigia um conjunto de empresas, deteta quando algo sai fora do normal, e avisa, mas só avisa com a explicação e a evidência ao lado.**

Há duas maneiras de o sistema começar a prestar atenção, representadas na Figura 1.2: ou o **preço** se mexe de forma invulgar para aquela empresa, ou chega uma **notícia** relevante sobre ela. Em qualquer dos dois casos, o que sai do outro lado não é uma notificação seca, mas um alerta que diz o que aconteceu, porque é que foi considerado invulgar, de onde vieram os dados, e que casos parecidos já existiram no passado, com o que o preço fez depois de cada um deles.

E o que o sistema recusa fazer

Há uma decisão de desenho que atravessa este sistema, e não foi tomada por comodidade: **não prevê preços.**

Nunca diz que uma ação vai subir. Nunca diz para comprar ou para vender. Nunca mostra um alvo de preço.

1.3. Objetivos e perguntas de investigação




Figura 1.2: Os dois gatilhos e o que sai deles. O que o investidor recebe é um alerta que ele consegue seguir e conferir, e não apenas um aviso de que o preço mexeu.

Isto pode parecer uma limitação. É o contrário: é o que torna tudo o resto verificável. Uma afirmação sobre o que *já* aconteceu pode ser confirmada contra o registo no momento em que é lida. Uma previsão não pode: só se saberá se estava certa depois de o investidor já ter tido de decidir. Ao recusar prever, o sistema obriga-se a dizer apenas aquilo que consegue mostrar.

Há ainda uma segunda razão, esta teórica, e que a Secção 2.8 desenvolve. A hipótese dos mercados eficientes, na sua forma semiforte, sustenta que os preços já refletem a informação publicamente disponível (Fama 1970); se assim for, movimentos futuros não deveriam ser sistematicamente antecipáveis a partir dessa informação. Este trabalho não a testa nem se apoia nela para concluir seja o que for; serve apenas para dizer que prometer previsão a partir de notícias públicas gratuitas seria prometer aquilo que a teoria dominante considera improvável.

1.3 Objetivos e perguntas de investigação

O objetivo geral é **desenhar, construir e avaliar** um sistema de alertas financeiros explicável para investidores particulares, usando apenas fontes de dados gratuitas.

Para lá chegar, o trabalho responde a três perguntas de investigação. Cada uma tem uma medição associada, porque uma pergunta a que não se sabe responder com um número não é uma pergunta de investigação: é uma opinião.

- **Questão de Investigação (QI)1, deteção.** Consegue um método estatístico simples e transparente detetar movimentos invulgares de forma consistente entre empresas com volatilidades muito diferentes, e fazê-lo melhor do que uma regra fixa?
- **QI2, precedentes.** Consegue o sistema encontrar notícias passadas genuinamente parecidas com a atual, melhor do que alternativas triviais, e medir o que aconteceu ao preço a seguir a elas sem usar informação do futuro?
- **QI3, triagem.** Consegue um modelo treinado decidir que notícias merecem um alerta melhor do que uma linha de base simples baseada apenas em volatilidade?

Convém desfazer já uma ambiguidade de numeração, porque de outro modo acompanha o leitor até ao fim. As três perguntas que abrem este capítulo são as do *investidor*; as três perguntas de investigação são as do *trabalho*, e não são as mesmas. A correspondência é esta: a QI1 responde à primeira pergunta do investidor, a QI2 responde à terceira, e a QI3 não corresponde a nenhuma, porque é uma pergunta que o sistema tem de fazer a si próprio antes de interromper alguém.

Falta então a segunda pergunta do investidor, a de separar a empresa do mercado. É respondida por uma técnica descrita no Capítulo 3 e demonstrada com um caso real, mas não dá origem a uma pergunta de investigação, e a razão é metodológica: não existe uma resposta certa contra a qual comparar a repartição de um movimento, porque essa quantidade só existe relativamente a um modelo. Inventar aí uma métrica de exatidão seria produzir um número sem referente. A Secção 5.4 explica o que, apesar disso, se pode medir nela, e mede-o.

Estas perguntas dão origem a quatro objetivos concretos:

1. construir o sistema completo, dos dados até ao alerta entregue;
2. avaliar cada componente contra linhas de base transparentes;
3. garantir que as explicações são fiéis ao que o sistema realmente calculou;
4. reportar os resultados tal como se revelarem, incluindo os que forem negativos.

O quarto objetivo é o mais importante e é o mais fácil de trair. Voltarei a ele no Capítulo 6.

1.4 Contribuições científicas

Sendo esta uma dissertação de **Engenharia de Inteligência Artificial (IA)**, a contribuição não está em inventar um algoritmo novo, mas em escolher, integrar e avaliar criticamente técnicas que já existem, até formarem um sistema que funciona, que se explica, e que outra pessoa consegue reproduzir. Escolher bem é o trabalho de engenharia.

Ficam quatro contribuições:

1. **Um sistema completo e a funcionar**, com os dois gatilhos, sobre fontes gratuitas, e implantado, e não uma demonstração de laboratório.
2. **Um método reprodutível para ligar notícias a impacto de mercado**, que combina recuperação por semelhança semântica de frases (Reimers e Gurevych 2019) com janelas de estudo de evento na tradição de Brown e Warner (1985), sem deixar entrar informação do futuro.
3. **Um conjunto de dados próprio e um modelo treinado sobre ele**: 79 753 exemplos construídos a partir do corpus público Financial News and Stock Price Integration Dataset (FNSPID) (Dong, Fan e Peng 2024) e de preços históricos, com o modelo, a calibração e as métricas guardados como artefactos versionados.
4. **Uma avaliação honesta de cada componente** contra linhas de base transparentes, incluindo o resultado que me correu ao contrário, que está reportado como tal.

1.5 Estrutura do documento

O documento foi escrito para ser lido do princípio ao fim, e cada capítulo responde a uma pergunta:

- **Estado da arte** (Capítulo 2): o que já existe, e porque é que não chega para o problema desta tese.
- **Métodos e materiais** (Capítulo 3): as quatro técnicas, explicadas devagar e com desenhos.

- **InvestiGator: o sistema** (Capítulo 4): como as peças se ligam, e uma notícia real seguida do princípio ao fim.
- **Avaliação** (Capítulo 5): o que foi medido, contra o quê, e com que resultado.
- **Conclusões** (Capítulo 6): o que ficou provado, o que ficou por fazer, e o que eu faria a seguir.

Uma opção de escrita atravessa o documento: **cada mecanismo é mostrado sobre um caso real**, com os valores que o sistema calculou nesse dia, e nunca sobre um exemplo inventado. O Capítulo 3 mostra as três formas que uma notícia toma dentro do sistema e segue depois uma linha de treino real até à percentagem final; o Capítulo 4 segue outra notícia desde a recolha até à mensagem entregue. Os casos são diferentes, e de propósito: a primeira vem do histórico, onde se pode ver o que o preço fez a seguir, e a segunda vem da operação real, onde se pode ver o que a pessoa recebeu.

Uma nota sobre a arrumação, para quem procurar os estudos de caso. Uma dissertação desta natureza costuma reunir num capítulo próprio os casos que demonstram o artefacto. Aqui eles existem e estão **distribuídos**, cada um junto da técnica que ilustra, porque a decisão de escrita foi explicar cada mecanismo sobre um caso e não guardar todos para o fim. Para quem os procurar em conjunto, estão nestes sítios: o dia invulgar da Tesla, com a conta do z-score feita à mão, na Secção 3.4; a repartição de um movimento real da AMD, na Secção 3.5; dois títulos comparados pelo cosseno, na Secção 3.6.3; uma notícia seguida da recolha até à mensagem entregue, na Secção 4.4; o funil das decisões registadas num dia, na Secção 4.6; e a página em funcionamento sobre uma empresa cuja descida veio toda do setor, enquanto o mercado e a própria empresa subiam, na Figura 4.4.

Capítulo 2

Estado da arte

Este capítulo responde a uma pergunta simples de enunciar e difícil de responder com honestidade: *o que é que já existe, e porque é que não chega?* A resposta organiza-se em três movimentos. Primeiro caracteriza-se a pessoa a quem o sistema se dirige, porque as limitações dela são o que define o problema. Depois examinam-se as ferramentas que hoje ocupam este espaço, com um critério fixo em vez de uma descrição geral. Por fim percorrem-se, uma a uma, as áreas técnicas de onde vêm as peças que o Capítulo 3 vai usar, para que fique claro que nenhuma delas é invenção deste trabalho e que a contribuição está na escolha, na integração e na avaliação crítica.

2.1 Quem investe, e porque é que a atenção é o problema

Quem é esta pessoa, e o que é que a literatura já sabe sobre a forma como ela decide?

A escala foi dada no Capítulo 1: a maior parte dos adultos americanos detém ações (Gallup 2025), num mercado que vale mais de 62 biliões de dólares (Securities Industry and Financial Markets Association (SIFMA) 2025). Interessa agora a segunda metade da caracterização, que não é de dimensão mas de comportamento, e que explica porque é que o problema deste trabalho existe.

Este público é numeroso e é ativo. Mesmo durante a queda de março de 2020, os investidores particulares de uma plataforma sem comissões aumentaram as suas posições agregadas em vez de fugirem (Welch 2022), o que contraria a caricatura do investidor particular que só reage em pânico. São pessoas que decidem, com regularidade, e que por isso beneficiam de melhor informação.

O que a literatura de finanças comportamentais estabelece é que essas decisões se afastam de forma sistemática, e não aleatória, do ideal racional (Barberis e Thaler 2003). Duas dessas regularidades importam diretamente para o desenho de um sistema de alertas.

A primeira é a **aversão à perda**: sentimos as perdas com mais intensidade do que os ganhos equivalentes (Kahneman e Tversky 1979). Daí que uma pessoa fique particularmente sensível a más notícias, e daí que um alerta que chegue a tempo e venha explicado tenha valor real em vez de valor decorativo.

A segunda é mais desconfortável, e é a que fundamenta este trabalho inteiro. Barber e Odean (2008) mostram que os investidores particulares são compradores líquidos de ações que *chamam a atenção*, entendendo-se por isso as que aparecem nas notícias, as que apresentam volume invulgar e as que registam retornos extremos num único dia. O mecanismo que os autores propõem é o do problema de procura: perante milhares de escolhas possíveis, a

pessoa não avalia todas, e recai sobre aquilo que lhe saltou à vista. A base empírica desta afirmação é concreta: são registos de corretoras dos Estados Unidos entre 1991 e 1999, anteriores à negociação por telemóvel e sem comissões, e o mecanismo que descrevem é o que aqui se assume transferível, não os valores concretos. A atenção é de tal modo central neste processo que chega a ser mensurável através do volume de pesquisas na internet (Da, Engelberg e Gao 2011).

Repare-se no que isto significa quando se junta às três perguntas do Capítulo 1. Os três sinais que capturam a atenção do investidor são a notícia, o volume invulgar e o movimento extremo do dia, e este sistema calcula os três. Convém, no entanto, ser exato quanto ao estatuto de cada um, porque não é o mesmo: a notícia e o movimento extremo são os dois *gatilhos*, ou seja podem por si levantar um alerta, ao passo que o volume é calculado e mostrado como contexto e nunca levanta nada. A razão está medida e é dita na Secção 5.7: a combinação do volume com os outros sinais só melhorou a triagem em um de três orçamentos, e uma capacidade que ganha uma vez em três não justifica mais uma via de interrupção. A diferença é o que acontece a seguir. Hoje, esses sinais chegam à pessoa em bruto, e o que a literatura documenta é que, em agregado, estes investidores comprem mais do que vendem aquilo que lhes chamou a atenção. Os autores são explícitos quanto ao alcance da afirmação: nem toda a gente compra tudo o que lhe salta à vista, e o que se mede é um desequilíbrio entre compras e vendas. São também explícitos quanto ao que daí resulta, e é essa a metade que justifica este trabalho: esse padrão de compra *não* gera retornos superiores. O que este trabalho tenta é interpor, entre o sinal e a decisão, o contexto que permite julgá-lo: se aquilo é invulgar para aquela empresa, se foi a empresa ou o mercado, e o que se seguiu em casos parecidos. A Figura 2.1 resume esta cadeia.

Uma nota de atribuição sobre essa combinação, porque a ideia não é minha. Veio de um painel de informação em tempo real que reúne sinais de origens diferentes num só indicador (*World Monitor* 2026), sugerido pelo coorientador deste trabalho. Era plausível o suficiente para ser *medida* em vez de descartada por argumento, e é assim que entra nesta dissertação: como uma alternativa que foi testada e não ficou.




Figura 2.1: Os três indicadores de atenção que a literatura usa (Barber e Odean 2008) são calculados por este sistema, mas apenas dois levantam alertas: a caixa do volume está a tracejado porque o sinal é mostrado como contexto e não interrompe ninguém. A seta a tracejado é o caminho que existe hoje, em que o sinal chega em bruto. A caixa central é o que este trabalho acrescenta.

Uma última nota de enquadramento. Do lado das *instituições*, a adoção de inteligência

artificial em serviços financeiros deixou de ser experimental e passou a ser generalizada, como documenta o inquérito a empresas do setor conduzido pelo Cambridge Centre for Alternative Finance (2026). Do lado dos *produtos de retalho* não cito esse inquérito, porque ele não mede essa população; o que se sabe é o que os próprios fornecedores anunciam, e disso trata a Secção 2.3. Com essa ressalva, a pergunta relevante já não é se estas técnicas vão chegar ao investidor particular, mas em que condições de transparência é que chegam.

2.2 O que existe hoje para quem investe pouco

Ninguém resolveu isto antes?

Resolveram, em parte, e de maneiras diferentes. O que existe merece ser olhado com um critério fixo, em vez de o descrever em geral. O critério deste trabalho são as três perguntas do Capítulo 1, e a Tabela 2.1 usa-as para pontuar as alternativas.

Tabela 2.1: O que cada tipo de ferramenta responde. “Parcial” significa que dá matéria-prima para a resposta, mas deixa o trabalho ao utilizador.

Ferramenta	É invulgar?	Empresa ou mercado?	Já aconteceu?	Custo
Aplicação da corretora	não	não	não	incluído
Agregador de notícias	não	não	não	grátis
Aplicação de sentimento	parcial	não	não	grátis/baixo
Robo-advisor	não	não	não	% da carteira
Terminal profissional	sim	sim	sim	milhares/ano
Este trabalho	sim	sim	sim	grátis

A tabela mostra o essencial: **a linha que responde às três perguntas existe, e é a mais cara de todas**. Não há aqui um problema científico por resolver: há um problema de acesso. As respostas são conhecidas; estão atrás de uma subscrição que a pessoa de quem este trabalho fala não vai pagar.

Três linhas merecem atenção em particular, porque cada uma falha por uma razão diferente e essas razões informam decisões de desenho tomadas mais à frente.

A **aplicação da corretora** é onde a maioria das pessoas realmente olha. Mostra a percentagem do dia e um gráfico. Não diz se aquilo é muito para aquela ação, não separa a empresa do mercado, e não tem memória. A pergunta “isto é normal?” fica sem resposta precisamente no sítio onde é feita. Os alertas de preço que estas aplicações oferecem partilham a mesma limitação de forma mais aguda: disparam quando um limiar fixo é atravessado, o que ignora a volatilidade própria de cada ação, e por isso disparam constantemente nas empresas agitadas e quase nunca nas calmas. Além disso dizem apenas *que* um nível foi ultrapassado, nunca *porquê*. Esta observação não é acessória: é a razão pela qual o Capítulo 3 usa uma medida relativa à norma de cada empresa em vez de um limiar absoluto, e o Capítulo 5 mede a diferença que isso faz.

As **aplicações de sentimento** pontuam notícias como positivas ou negativas e mostram o resultado. Dão matéria-prima para a primeira pergunta, mas param aí, e o Capítulo 5

mostra, com medição própria, que o tema de uma notícia e a direção do movimento que se lhe segue são coisas distintas com mais frequência do que a intuição sugere.

Os *robo-advisors* (D’Acunto, Prabhala e Rossi 2019) respondem sobretudo a outra pergunta: como distribuir dinheiro por uma carteira. É uma pergunta legítima e não é esta. A literatura reconhece-lhes benefícios genuínos, embora não uniformes: D’Acunto, Prabhala e Rossi (2019) medem uma melhoria da diversificação e uma redução da volatilidade *para quem tinha menos de cinco ações* antes da adesão, ao passo que para quem já detinha mais de dez o efeito sobre a diversificação é quase nulo. A contenção de enviesamentos comportamentais é o benefício mais consistente (Cardillo e Chiappini 2024; D’Acunto, Prabhala e Rossi 2019).

A diferença face a este trabalho é de *objeto* e não de transparência. Um *robo-advisor* recomenda uma carteira e executa-a, ainda que a decisão final continue a ser autorizada pelo investidor; aqui não se recomenda nada, e o que se entrega é a evidência sobre um acontecimento concreto. Acresce que aconselhar sobre investimentos tem obrigações regulatórias que este trabalho evita por desenho, como se detalha na Secção 2.13.

2.3 Os produtos que fazem exatamente esta pergunta

E os produtos recentes que prometem explicar porque é que uma ação subiu?

Existem, são recentes, e seria desonesto não os nomear.

O **Robinhood Cortex**, anunciado em março de 2025, declara na página do próprio fornecedor que serve para “responder à velha questão de porque é que esta ação está a subir ou a descer hoje” (Robinhood Markets 2025). Os **momentos-chave** do Google Finance, de junho de 2026, propõem-se “explicar porque é que uma ação se moveu” (Google 2026).

É a mesma pergunta deste trabalho, feita por empresas com muito mais recursos e muito mais utilizadores. Vale a pena dizê-lo com clareza, em vez de fingir que este território estava vazio.

A diferença está no que é entregue. Um resumo gerado é uma **afirmação**: o utilizador lê e acredita, ou não. O que este trabalho entrega é uma afirmação **com a evidência anexada**: os casos passados, um a um, com as datas, as semelhanças e o que o preço fez a seguir a cada um. A diferença não é de fluência: é de *verificabilidade*.

Uma ressalva de método, porque é fácil escorregar aqui: destes produtos só se afirma o que está escrito nas páginas dos próprios fornecedores, consultadas em data registada. Não se testaram, e por isso não se diz o que fazem por dentro; diz-se apenas o que declaram fazer.

2.4 E um assistente de IA genérico?

É a objeção mais razoável de todas, e merece resposta séria.

Um assistente genérico responde bem à pergunta, no sentido em que produz um texto fluente e plausível. O problema é o que está por trás desse texto. Ele não tem:

- a **volatilidade recente** daquela ação, que é o que permite dizer se 4% é muito;
- a **separação** entre o que foi o mercado e o que foi a empresa;
- uma **base de casos passados** para *recuperar*. No melhor dos casos *recorda* casos do treino, o que não é a mesma coisa e não é verificável.

E há uma diferença mais funda, que é a razão pela qual este trabalho não é um invólucro à volta de um modelo de linguagem. Modelos grandes especializados em finanças existem (Wu et al. 2023) e são impressionantes. Mas a saída deles é uma afirmação que se lê bem e não se consegue conferir, e a literatura da área avisa que uma explicação que não se pode verificar não resolve o problema que diz resolver (Lipton 2018; Rudin 2019). A literatura sobre confiança em sistemas automáticos acrescenta a razão pela qual isso importa. J. D. Lee e See (2004) descrevem *dois* modos de falha simétricos: confiar de menos, e por isso ignorar um aviso correto, e confiar de mais, e por isso aceitar um errado. O objetivo não é maximizar a confiança nem minimizá-la, mas torná-la *apropriada*, ou seja ajustada à capacidade real do sistema. E uma pessoa só pode ajustar a sua confiança se lhe for mostrado em que é que o sistema se apoia.

Por isso, neste trabalho, a linguagem nunca produz factos. Os números vêm dos motores que os calcularam, e o texto é montado a partir deles, como se descreve na Secção 4.7.

2.5 Detetar o que é invulgar

Como é que se decide, de forma defensável, que um dia foi diferente dos outros?

A deteção de anomalias é uma área estabelecida, com uma taxonomia consolidada que separa os métodos pela forma como definem normalidade (Chandola, Banerjee e Kumar 2009; Pang et al. 2021). Para o problema deste trabalho interessam três famílias, resumidas na Tabela 2.2.

Tabela 2.2: As três famílias relevantes para séries temporais financeiras, e o que cada uma exige em troca do que oferece.

Família	Como define normalidade	Custo e benefício
Estatística (limiar sobre a norma recente)	Distribuição local dos retornos, estimada numa janela deslizante	A explicação é o próprio cálculo; supõe uma distribuição localmente estável
Aprendida, não supervisionada (Breunig et al. 2000; F. T. Liu, Ting e Zhou 2008)	Estrutura geométrica dos dados: pontos fáceis de isolar ou pouco densos face aos vizinhos	Não precisa de rótulos e capta padrões multivariados; a decisão deixa de ser legível em uma frase
Profunda (Pang et al. 2021)	Um modelo de normalidade aprendido por uma rede	Maior capacidade; exige mais dados e afasta-se do requisito de explicabilidade

Há uma restrição prática que condiciona toda esta escolha e que convém enunciar cedo. Em domínios financeiros vizinhos, como a deteção de fraude, os métodos *não supervisionados* ocupam um lugar central, precisamente porque anomalias rotuladas são escassas e os padrões mudam com o tempo (Ahmed, Mahmood e Islam 2016). O mesmo se aplica ao problema deste trabalho. Não existe um conjunto de dados em que alguém tenha marcado, dia a dia, quais os movimentos que mereciam um alerta. Essa ausência não é um detalhe de implementação: molda a forma como o Capítulo 5 pode avaliar este componente, e é a razão pela qual a avaliação se apoia num critério definido a partir dos próprios dados em vez de um julgamento humano.

A família estatística assenta numa suposição, a de que a distribuição dos retornos é localmente estável, e essa suposição merece ser confrontada em vez de escondida. Os modelos de volatilidade condicional, introduzidos por Engle (1982) sobre séries de inflação e generalizados por Bollerslev (1986), formalizam o *agrupamento de volatilidade*, ou seja a tendência de os períodos calmos e os agitados chegarem em séries. Os dois artigos formalizam-na sobre séries de inflação, e este trabalho não a toma emprestada para os retornos de ações: mede-a nos próprios dados, na Secção 5.3, ao comparar a janela de pesos iguais com uma que pondera as observações recentes com mais peso. Uma janela deslizante é precisamente o que acompanha esse agrupamento, porque a norma contra a qual o dia de hoje é comparado é reestimada a cada dia a partir do passado recente. A escolha não elimina o problema, mas trata-o, e a medição referida acima diz quanto custa mantê-la.

A comparação entre a família estatística e a aprendida não fica em argumento. O Capítulo 5 corre as duas sobre os mesmos dados e reporta o resultado tal como sai.

2.6 Representar texto por significado

Como é que um computador decide que duas notícias falam do mesmo?

Comparar notícias por significado depende inteiramente de como se representa o texto, e essa representação passou por três gerações, esquematizadas na Figura 2.2 e detalhadas na Tabela 2.3.




Figura 2.2: Como se passou de contar palavras a representar o sentido de uma frase inteira. Cada geração resolve uma limitação da anterior.

A primeira geração conta palavras. O modelo de espaço vetorial (Salton, Wong e C. S. Yang 1975) representa um documento pela frequência dos termos que contém. Dentro desta geração há ainda uma segunda linha, nascida de um quadro diferente e não deste, a das funções de ordenação probabilísticas, de que o BM25 (Robertson e Zaragoza 2009) é o representante corrente; as duas continuam a ser linhas de base fortes em recuperação de informação. É transparente e é rápido, mas é cego a sinónimos: para este tipo de representação, “subiu” e “valorizou” são símbolos sem relação nenhuma. Em texto financeiro há ainda uma variante especializada, os léxicos de domínio, que corrigem o facto de dicionários de sentimento genéricos lerem mal palavras financeiras correntes como “passivo” ou “imposto” (Loughran e McDonald 2011). São inteiramente transparentes, e estão limitados pelo vocabulário que alguém teve o cuidado de compilar.

A segunda geração representa cada *palavra* como um vetor num espaço onde a proximidade significa uso semelhante, aprendido a partir do contexto local (Mikolov et al. 2013) ou da coocorrência global (Pennington, Socher e Manning 2014). Isto aproxima sinónimos, que

2.6. Representar texto por significado

era o problema da geração anterior, mas mantém uma limitação própria: cada palavra fica com um único vetor, independentemente da frase em que aparece.

A terceira geração remove essa limitação. O *Transformer* (Vaswani et al. 2017) tornou viável processar a frase inteira com dependências de longo alcance, e o BERT (Devlin et al. 2019) produziu representações profundamente *contextuais*, em que o vetor de uma palavra depende das que a rodeiam. Falta ainda um passo para o problema deste trabalho, porque comparar duas frases com um modelo desses exigiria processá-las em conjunto, uma vez por par, o que não escala para uma base com dezenas de milhares de casos. O Sentence-BERT (Reimers e Gurevych 2019) resolve isso ao produzir um vetor por frase, calculado uma única vez, de modo que a comparação passa a ser uma operação aritmética entre vetores já existentes. É esta a representação que este trabalho usa, e a razão da escolha é tanto de qualidade como de arquitetura.

Tabela 2.3: As opções consideradas para representar notícias financeiras, e o que cada uma implica.

Abordagem	Representação	Forças e limitações
Contagem de termos (Robertson e Zaragoza 2009; Salton, Wong e C. S. Yang 1975)	Frequência ponderada de palavras	Transparente e rápida; cega a sinónimos
Léxicos financeiros (Loughran e McDonald 2011)	Listas de palavras com polaridade	Totalmente transparente; limitada ao vocabulário compilado
Vetores de palavras (Mikolov et al. 2013; Pennington, Socher e Manning 2014)	Um vetor fixo por palavra	Aproxima sinónimos; um só sentido por palavra
Frases contextuais (Devlin et al. 2019; Reimers e Gurevych 2019)	Um vetor por frase, sensível ao contexto	Compara frases diretamente; modelo maior, menos legível por dentro
Modelos de domínio (Huang, Wang e Y. Yang 2023; Z. Liu et al. 2020)	Como acima, ajustado a texto financeiro	Vocabulário do domínio; não é automaticamente melhor nesta tarefa
Modelos grandes (Wu et al. 2023)	Geração de texto sobre conhecimento amplo	Muito capaz; caro, opaco e fora da restrição de gratuidade

Para texto financeiro existem modelos treinados de propósito para o domínio (Huang, Wang e Y. Yang 2023; Z. Liu et al. 2020). A suposição natural é que sejam melhores nesta tarefa por isso mesmo. Essa suposição não é automaticamente verdadeira, e o Capítulo 5 mede-a em vez de a assumir.

Este trabalho situa-se dentro da literatura mais vasta de processamento de linguagem natural aplicado a finanças. A revisão de Kearney e S. Liu (2014) cobre o estado dessa área até 2014: os léxicos de domínio e os classificadores supervisionados sobre contagens de palavras, que eram então os instrumentos correntes. As representações contextuais de frase, que este

trabalho usa, chegariam anos depois e não constam da revisão. Existe ainda uma linha de investigação substancial que usa texto para *prever* movimentos de preço (Ding et al. 2015; Xing, Cambria e Welsch 2018). Este trabalho não pertence a essa linha, e a distinção é deliberada: aqui o texto serve para encontrar casos passados comparáveis, cujo desfecho já é conhecido e já foi medido, e não para produzir uma previsão sobre o futuro.

2.7 Recuperar casos parecidos, e saber se a recuperação é boa

Encontrada uma representação, como se recupera o que interessa, e como se avalia isso?

Representar cada notícia por um vetor transforma a pergunta “que casos passados se parecem com este?” num problema de recuperação de informação. A medida de proximidade usada é o cosseno do ângulo entre os vetores, cuja mecânica se detalha na Secção 3.6.3. A operação é exata, e portanto o resultado não depende de nenhuma aproximação: percorrem-se todos os casos da base e ordenam-se. A escalas muito superiores, essa procura exaustiva pode ser trocada por um índice aproximado (Johnson, Douze e Jégou 2021) sem alterar a representação, o que fica registado como caminho de crescimento e não como necessidade atual.

Como a recuperação devolve uma lista ordenada, avalia-se com medidas sensíveis à ordem (Manning, Raghavan e Schütze 2008). A mais direta, e a que este trabalho usa, é a *precisão@k*, ou seja a fração dos k primeiros resultados que são relevantes. A definição de relevância, que é onde uma avaliação destas se ganha ou se perde, é estabelecida no Capítulo 3 juntamente com as linhas de base contra as quais o resultado é comparado.

2.8 Medir o efeito de um acontecimento

Encontrados casos análogos, como se mede honestamente o que aconteceu ao preço a seguir?

O instrumento é o *estudo de evento*, introduzido por Fama et al. (1969). Brown e Warner (1985) estudam em detalhe o seu comportamento com retornos *diários*, comparando várias formas de estimar o retorno esperado, e concluem que os procedimentos correntes, assentes no modelo de mercado estimado por mínimos quadrados, se mantêm bem especificados em janelas curtas em torno do acontecimento. Os próprios autores delimitam o alcance dessa conclusão: a variante mais simples de todas, que desconta apenas a média histórica da própria ação, perde potência e chega a ficar mal especificada quando as datas dos acontecimentos se concentram no mesmo dia.

É esse resultado que dá conforto às janelas de mais um, mais três e mais cinco dias usadas neste trabalho, com uma diferença que a Secção 3.6 declara: o que aqui se mostra ao utilizador é o retorno bruto e não o retorno anormal que aqueles autores estudam.

Que o texto publicado tem relação estatística com os movimentos do mercado é observação antiga (Tetlock 2007). Convém enunciá-la com o verbo certo: trata-se de evidência de uma relação estatística, e não de uma prova de causalidade.

Há um ponto metodológico que interessa antecipar aqui, porque afeta a segunda pergunta do trabalho, a de separar a empresa do mercado. Fazer essa separação exige estimar a sensibilidade de cada ação ao mercado, e essa estimativa é ruidosa, sobretudo em empresas voláteis ou com histórico curto. A literatura de finanças documentou o fenómeno e propôs a

correção. Blume (1971) estabelece que os betas estimados tendem a regredir para a média entre períodos sucessivos, ou seja que uma estimativa extrema hoje tende a sê-lo menos amanhã; daí decorreu a prática, corrente mas posterior ao próprio artigo, de encolher a estimativa com um peso fixo. Essa prática encolhe com a mesma força uma estimativa boa e uma má. A alternativa que este trabalho adota pondera o encolhimento pela *imprecisão* da própria estimativa (Vasicek 1973), de modo que uma estimativa fiável é praticamente preservada e uma frágil é puxada para o valor de referência. O detalhe está na Secção 3.5.

Por fim, o enquadramento teórico que justifica a recusa de prever. A hipótese dos mercados eficientes, na sua forma semiforte, sustenta que os preços já refletem a informação publicamente disponível (Fama 1970); daí decorre que movimentos futuros não deveriam ser sistematicamente previsíveis a partir dessa informação. Esta é uma das razões pelas quais o sistema mede o que já aconteceu em vez de projetar o que virá, e a outra, mais prática, é que apenas o passado é verificável por quem lê.

2.9 Raciocinar por casos passados

Mostrar casos anteriores em vez de uma regra: isso tem nome?

Tem, e é uma linha estabelecida em inteligência artificial. O *raciocínio baseado em casos* (Aamodt e Plaza 1994) resolve um problema novo recuperando problemas passados semelhantes e reutilizando o que se sabe sobre eles, em vez de se apoiar *apenas* em conhecimento geral do domínio. A fonte descreve um ciclo de quatro processos, que são recuperar, reutilizar, rever e reter, e afirma que os quatro são necessários para resolver um problema por completo.

A terceira técnica deste trabalho implementa os dois primeiros e **para deliberadamente** antes dos outros dois: recupera casos semelhantes e mostra o que neles foi medido, mas não adapta esse desfecho ao caso presente. Adaptar seria produzir uma expectativa sobre o que vai acontecer, ou seja exatamente a previsão que este trabalho recusa.

A escolha tem uma justificação adicional, que vem do lado de quem lê. A investigação sobre explicação em ciências sociais mostra que as pessoas procuram razões *contrastivas* e seletivas, e não uma enumeração exaustiva de tudo o que contribuiu (Miller 2019). Um punhado de casos concretos, com datas e desfechos, corresponde a essa expectativa muito melhor do que um coeficiente. Daí que cada alerta mostre alguns precedentes relevantes e as quantidades exatas por detrás da decisão, em vez de despejar tudo o que o sistema calculou.

2.10 Explicar decisões automáticas

Se o sistema decide, como é que mostra em que se baseou?

A exigência de que um sistema mostre *como* chegou a uma conclusão constitui uma área própria, com revisões consolidadas (Adadi e Berrada 2018; Barredo Arrieta et al. 2020). Essa área divide-se em duas vias, ilustradas na Figura 2.3 e comparadas na Tabela 2.4: modelos *transparentes*, interpretáveis em si mesmos, e métodos *a posteriori*, que explicam um modelo opaco já treinado e que podem ser organizados pelo que explicam (Guidotti et al. 2018).




Figura 2.3: As duas vias que a literatura distingue (Barredo Arrieta et al. 2020; Guidotti et al. 2018): construir modelos transparentes por desenho, ou explicar um modelo opaco depois de treinado. Este trabalho segue a via da esquerda.

Os dois métodos *a posteriori* mais usados operam de formas distintas. O Local Interpretable Model-agnostic Explanations (LIME) ajusta um modelo simples em torno de uma previsão individual, aproximando localmente o comportamento do modelo opaco (Ribeiro, Singh e Guestrin 2016). O SHapley Additive exPlanations (SHAP) atribui uma previsão às suas variáveis usando valores de Shapley (Lundberg e S.-I. Lee 2017). Ambos são genéricos e ambos são úteis.

Ambos partilham, contudo, uma propriedade que pesa muito neste contexto. Para decisões de consequência séria, Rudin (2019) argumenta que se deve abandonar o compromisso com modelos opacos e usar antes modelos interpretáveis à partida, precisamente porque uma explicação *a posteriori* é ela própria uma aproximação, e uma aproximação pode induzir em erro. O utilizador recebe então duas coisas cuja relação não consegue avaliar: uma decisão e uma explicação que talvez não corresponda a ela.

Tabela 2.4: As opções ponderadas, e a razão da escolha feita neste trabalho.

Método	Tipo	Forças e limitações
LIME (Ribeiro, Singh e Guestrin 2016)	Substituto local, a posteriori	Intuitivo e agnóstico ao modelo; as explicações podem ser instáveis e só valem localmente
SHAP (Lundberg e S.-I. Lee 2017)	Atribuição por valores de Shapley	Fundamentação teórica sólida; custo computacional e leitura exigente para um leigo
Modelo transparente (Rudin 2019)	Interpretável por construção	A explicação é o próprio cálculo, logo não pode divergir da decisão; limita a família de modelos disponível

Este trabalho segue a via conservadora: em vez de explicar *a posteriori* um modelo opaco, usa componentes cuja explicação é o próprio cálculo. Um desvio relativo a uma norma recente, uma decomposição aditiva que soma exatamente ao movimento observado e uma lista de casos passados com os respetivos desfechos são todos objetos que se podem mostrar por inteiro. A explicação não é uma segunda coisa produzida sobre a decisão: é a decisão, escrita por extenso.

Duas cautelas da literatura fecham esta secção, e as duas condicionam o modo como o Capítulo 5 está organizado.

A primeira é que “interpretabilidade” não designa uma coisa só (Lipton 2018), pelo que um sistema deve declarar que tipo de interpretabilidade oferece em vez de reclamar a palavra sem qualificação. Este trabalho oferece transparência de mecanismo, ou seja o utilizador pode seguir o cálculo, e não oferece uma explicação causal do acontecimento no mundo.

A segunda é mais incómoda e é frequentemente ignorada. Explicações podem induzir *confiança excessiva*: Bansal et al. (2021) mostram que acrescentar uma explicação aumenta a probabilidade de a pessoa aceitar a resposta do sistema **quer ela esteja certa quer esteja errada**, ou seja que o ganho não vem de a pessoa passar a distinguir melhor os dois casos. É a presença da explicação que produz o efeito, e não o tom com que é apresentada. Daqui decorre uma consequência de desenho concreta neste sistema. A média dos desfechos dos casos recuperados é mostrada como aquilo que é, uma medição sobre o passado, e nunca como uma expectativa sobre o futuro, porque tratá-la como previsão seria exatamente a confiança excessiva contra a qual a literatura de confiança avisa (Bansal et al. 2021; J. D. Lee e See 2004).

Acresce que afirmações de interpretabilidade exigem avaliação rigorosa e não basta declará-las (Doshi-Velez e Kim 2017). É por isso que o Capítulo 5 mede o que pode ser medido por máquina e diz, de forma explícita, qual a parte que continua por avaliar por faltar um estudo com pessoas.

2.11 Um modelo que continua a funcionar depois de implantado

Treinar um modelo é uma coisa. Mantê-lo a funcionar é outra. O que diz a literatura?

Este trabalho inclui um componente aprendido, cuja função é ordenar notícias por materialidade esperada, e esse componente levanta três questões que a literatura trata separadamente.

A primeira é a de saber contra que teto comparar um modelo simples. Conjuntos de árvores treinados por reforço do gradiente (Friedman 2001) são uma família de modelos não lineares forte e amplamente usada em dados tabulares, capaz de captar interações e efeitos não lineares que uma regressão logística não capta, e servem por isso de referência superior contra a qual o modelo interpretável é medido no Capítulo 5. Não se afirma que sejam o melhor método existente, porque essa é uma afirmação sobre um campo inteiro e não foi medida aqui.

A segunda é a da honestidade do número produzido. Para quem lê, uma pontuação só é honesta se for uma *probabilidade*. As pontuações em bruto de muitos classificadores estão mal calibradas, e a calibração *a posteriori*, ajustando uma sigmoide sobre um bloco de validação reservado, corrige essa distorção (Niculescu-Mizil e Caruana 2005).

Convém, no entanto, registar o que a mesma fonte conclui, porque não favorece a escolha feita aqui. Niculescu-Mizil e Caruana (2005) apontam a regressão logística como já *bem calibrada à partida*, e concluem que nessas famílias a calibração posterior não traz melhoria e chega a prejudicar quando o bloco de calibração é pequeno. Acrescentam que, acima de cerca de mil casos de calibração, a regressão isotónica iguala ou supera sempre a sigmoide. O modelo implantado neste trabalho é precisamente uma regressão logística, e o seu bloco de validação está muito acima desse limiar, pelo que as duas afirmações se aplicam ao caso.

A calibração não se justifica aqui, portanto, por autoridade, e sim por medição: a Secção 5.7 compara as duas variantes na mesma validação, e a sigmoide iguala ou ganha no Brier em todas as famílias testadas. É um caso em que a teoria apontava para a alternativa e a medição sobre estes dados não a confirmou, e fica registado como tal.

Uma terceira via, considerada e não adotada, merece registo porque a decisão foi tomada com conhecimento dela. A predição conformal permite envolver um preditor de modo que devolva um *conjunto* de rótulos com uma garantia livre de distribuição e válida em amostras finitas (Vovk, Gammerman e Shafer 2005), e a variante que calibra sobre um bloco reservado, com a respetiva correção de quantil para amostras finitas, está estabelecida (Angelopoulos e Bates 2023).

Duas precisões, porque são as que decidem se o método serve aqui. A primeira é o alcance da garantia, e é o mal-entendido mais comum a respeito deste método: a cobertura é *marginal*, ou seja vale em média sobre os casos, e não caso a caso. Registe-se que Vovk, Gammerman e Shafer (2005) não tratam isto como limite intransponível, e dedicam uma secção a mostrar que a *validade condicional* se pode obter modificando a definição de preditor conformal. Convém dizer o que essa expressão ali significa, porque não é o que o nome sugere: é validade *dentro de categorias* fixadas à partida, e não caso a caso, portanto estreita a média sem a eliminar. O que se afirma aqui é que a variante corrente, e a que seria adotada sem trabalho adicional, dá a garantia marginal. A segunda precisão é a condição sob a qual essa garantia vale, que é a **permutabilidade** entre os dados de calibração e os de teste. Não é um pormenor técnico neste trabalho: os dados são uma série temporal financeira, os títulos chegam por ordem cronológica, e a Secção 3.7 divide o conjunto por data e com embargo precisamente porque tratar estas observações como permutáveis produziria uma avaliação otimista. A hipótese que a garantia conformal exige é a mesma que este trabalho recusa noutro sítio, e por isso o método entra no Capítulo 6 como caminho a explorar e não como omissão.

A terceira questão é a de continuar a funcionar com o tempo. Um modelo implantado enfrenta alteração da distribuição dos dados que vê, e o tratamento habitual disso em aprendizagem automática é a literatura de *deriva de conceito*, cuja revisão de referência estabelece a taxonomia da mudança, sendo esta súbita, gradual, incremental ou recorrente, bem como as estratégias de deteção e os métodos de adaptação (Gama et al. 2014). Este trabalho mede a deriva sobre os seus próprios dados no Capítulo 5, em vez de a assumir ausente.

Há por fim um custo que não aparece em nenhuma métrica de qualidade e que a experiência com sistemas em produção documenta bem. D. Sculley et al. (2015) argumentam que os componentes de aprendizagem automática acumulam um custo de manutenção distintivo e em grande medida oculto, nomeadamente o emaranhamento, em que mudar qualquer coisa muda tudo, as dependências de dados instáveis e não declaradas, e a dívida de configuração. O Capítulo 6 regressa a este ponto com um exemplo concreto e medido deste próprio sistema, em que uma parte do ciclo de aprendizagem parou sem que nenhum erro fosse registado.

2.12 Síntese: a lacuna que este trabalho ocupa

A revisão feita neste capítulo permite localizar com precisão o espaço em que este trabalho se inscreve, e esse espaço não é um vazio técnico. Cada peça individual existe, está publicada e está avaliada. A Tabela 2.5 torna isso explícito.

2.13. As escolhas que este trabalho faz

Tabela 2.5: Cada componente existe na literatura. O que não existe é a combinação, sob a restrição de custo nulo, com a evidência entregue ao utilizador.

Pergunta	O que a literatura oferece	O que falta para esta pessoa
É invulgar?	Deteção de anomalias, estatística e aprendida (Chandola, Banerjee e Kumar 2009; F. T. Liu, Ting e Zhou 2008)	Chegar-lhe em linguagem que ela leia, relativa à norma daquela empresa
Empresa ou mercado?	Estudo de evento e estimação de sensibilidade (Brown e Warner 1985; Vasicek 1973)	Estar disponível fora de um terminal profissional
Já aconteceu antes?	Representação de frases e recuperação (Manning, Raghavan e Schütze 2008; Reimers e Gurevych 2019)	Uma base de casos com desfechos já medidos, e não recordados
Porque é que acredito?	Explicabilidade e literatura de confiança (J. D. Lee e See 2004; Rudin 2019)	A evidência entregue junto da afirmação, verificável no momento da leitura

A lacuna, portanto, não é de método: é de *integração sob restrição*. Os produtos que respondem às três perguntas cobram milhares por ano. Os produtos gratuitos que prometem responder à terceira entregam uma afirmação sem a evidência. E os componentes académicos que resolveriam cada pedaço foram avaliados isoladamente, sobre corpora de referência, e não como um sistema que funciona todos os dias contra fontes reais e que reporta o que falha.

É esse o espaço que este trabalho ocupa, e é também o que determina a natureza da sua contribuição: não está em inventar um método novo, mas em escolher, integrar e avaliar criticamente métodos existentes num sistema que funciona, sob restrições declaradas, e cuja avaliação inclui os resultados que não favorecem o próprio sistema.

2.13 As escolhas que este trabalho faz

Quatro decisões, e cada uma fecha uma porta de propósito.

Responder às três perguntas, e só a essas. Não se acrescentam funcionalidades que não sirvam uma delas. É o que mantém o sistema pequeno o suficiente para ser explicado por inteiro.

Não prever preços. Nem direcção, nem alvo, nem recomendação. Além da razão já dada, que é o que torna tudo verificável, há a razão teórica da Secção 2.8: os preços já refletem a informação publicamente disponível (Fama 1970), e se assim for, movimentos futuros não deveriam ser sistematicamente previsíveis a partir dela.

Não gerir carteiras nem aconselhar. O sistema não sabe o que o utilizador tem, e não lhe diz o que fazer. Isto evita recolher dados pessoais e mantém o trabalho fora da fronteira do aconselhamento financeiro regulado.

Só fontes gratuitas. Torna o sistema utilizável por quem ele serve, e transforma as limitações resultantes em algo que se *mede* e reporta, em vez de algo que se compra.

A última merece uma nota honesta. A restrição limita o sistema de forma real: as notícias chegam com atraso, e nem tudo o que acontece é coberto. O Capítulo 4 quantifica esse atraso e o Capítulo 6 volta a ele. É uma limitação, e não uma virtude.

Capítulo 3

Métodos e materiais

3.1 Que tipo de investigação é esta

Convém dizê-lo antes de qualquer detalhe técnico, porque determina o que conta como resultado neste documento.

Este trabalho pertence à família da **investigação por desenho**: o objeto de estudo não é uma hipótese sobre o mundo, é um *artefacto* construído para resolver uma classe de problema, e o conhecimento produzido está tanto no artefacto como no que se aprende ao avaliá-lo (Hevner et al. 2004). É o enquadramento habitual quando a contribuição é um sistema, e distingue-se de um estudo puramente empírico por uma razão simples: aqui o objeto avaliado não existia antes de ser construída.

Esse enquadramento traz uma exigência que interessa cumprir e não apenas invocar. A avaliação de um artefacto tem de ser **rigorosa e demonstrar utilidade**, e é uma atividade central do processo, não um passo final de confirmação (Hevner et al. 2004; Peffers et al. 2007). Este trabalho leva essa exigência a sério de três maneiras:

- cada componente é comparado com uma **alternativa mais simples**, escolhida e declarada *antes* de a medição correr, para que o resultado possa ser negativo;
- o critério de sucesso de cada comparação é fixado com a métrica, e não escolhido depois de ver os números;
- o artefacto é avaliado **duas vezes**: sobre dados históricos retidos, e outra vez em funcionamento, sobre as decisões que tomou sozinho em produção.

A terceira é a menos comum e é a que dá o resultado mais desconfortável deste documento, na Secção 5.6: um componente que se comporta bem no primeiro exercício e não transfere para o segundo. Sem a segunda avaliação, essa conclusão não existiria e a dissertação afirmaria uma falsidade com números verdadeiros.

E onde é que este trabalho fica a dever. Na mesma exigência, e vale mais dizê-lo aqui do que esperar que alguém repare. Utilidade, no sentido em que a literatura de investigação por desenho a usa, é utilidade **para quem usa** o artefacto, e isso mede-se com pessoas. Aqui mediu-se a fidelidade das explicações, que é uma propriedade do sistema, e não a sua utilidade, que é uma propriedade da relação entre o sistema e quem o lê. O Capítulo 6 volta a esta falta, e ela é a razão pela qual o terceiro objetivo do trabalho é dado como cumprido por metade.

3.2 As quatro decisões

Tudo o que este trabalho faz cabe em quatro decisões, na Figura 3.1. As três primeiras são, uma a uma, as três perguntas do Capítulo 1; a quarta não é uma pergunta do investidor, mas do sistema, e existe porque responder às três não obriga a interromper ninguém.




Figura 3.1: As quatro decisões, e a família de técnicas que responde a cada uma. As três primeiras são as três perguntas do Capítulo 1. Cada coluna tem a sua secção neste capítulo, da Secção 3.4 à Secção 3.7.

Cada decisão é tratada com a técnica mais simples que consegue resolvê-la. Isto não é preguiça: é uma escolha de desenho que se paga no Capítulo 5, onde cada técnica é comparada com alternativas mais complicadas. Quando a simples ganha, fica a simples, e diz-se porquê.

3.3 Os dados, tal como são

Antes de explicar o que se faz com os dados: com que é que eles se parecem, exatamente?

Uma dissertação pode descrever dados durante páginas sem que o leitor consiga imaginar uma única linha deles. Esta secção resolve isso da forma mais direta possível: mostra as linhas verdadeiras, copiadas dos ficheiros que o sistema usa.

3.3.1 O que entra: uma notícia histórica

A camada histórica vem do FNSPID (Dong, Fan e Peng 2024), um conjunto público de notícias financeiras. O ficheiro é um Comma-Separated Values (CSV) com três colunas, e a Figura 3.2 mostra como uma linha se parece:

```
date,ticker,headline
2020-03-09,AAPL,"Crude Awakening: Energy Sector Takes A 20% Spill As
Crude Price War Sends Oil To 4-Year Low"
```

Figura 3.2: Uma linha real do FNSPID, copiada do ficheiro. Três colunas e mais nada: data, empresa, título. Não traz preço, não traz corpo do artigo, e não traz rótulo nenhum. Tudo o resto é construído.

Repare-se no que *não* está ali. Não há preço, não há reação do mercado, não há indicação de que a notícia seja importante. Um título sobre petróleo aparece etiquetado como AAPL, o que ilustra bem a qualidade da etiquetagem à entrada e justifica o filtro de relevância descrito no Capítulo 4.

3.3.2 O que é construído: uma linha do conjunto de treino

Do lado de lá do processamento está o conjunto de dados com que o modelo de triagem é treinado. Tem 79 753 linhas. A Figura 3.3 mostra uma delas, inteira, sem cortes.

```
date = 2023-02-02
news_date = 2023-02-02
ticker = AAPL
sector = tech
headline = "Apple (AAPL) Misses Q1 Earnings and Revenue Estimates"
headline_len = 53
vol120 = 0.01266203305026954
mom5 = 0.024854333506149767
ret_event = 0.036392215960942983
label = 1
label_t0.015_h1 = 1   label_t0.015_h3 = 1   label_t0.015_h5 = 1
label_t0.02_h1 = 1   label_t0.02_h3 = 1   label_t0.02_h5 = 1
label_t0.03_h1 = 1   label_t0.03_h3 = 0   label_t0.03_h5 = 0
split = test
```

Figura 3.3: Uma linha real do conjunto de dados de triagem. As nove colunas `label_*` são as nove definições alternativas de rótulo usadas na Secção 5.6: repare-se que a mesma notícia é “importante” com um limiar de 1.5% ou 2% e deixa de o ser a 3% ao fim de três dias.

A Tabela 3.1 diz o que cada coluna é, de onde vem, e a pergunta que mais importa: **consegue esta coluna ver o futuro?** É a pergunta que separa uma avaliação honesta de uma avaliação impossível de acreditar.

As colunas de rótulo **têm** de ver o futuro: é isso que um rótulo é. O que não pode acontecer é uma coluna de *entrada* ver o futuro, e é exatamente isso que o teste descrito na Secção 3.8 verifica automaticamente.

3.3.3 O que é guardado: um caso na base de precedentes

A base de casos é um ficheiro onde cada linha é um objeto JavaScript Object Notation (JSON). A Figura 3.4 mostra um registo real, com o vetor abreviado por ser demasiado longo para caber na página.

```
{"date": "2020-03-09",
 "ticker": "AAPL",
 "headline": "Crude Awakening: Energy Sector Takes A 20% Spill ...",
 "impacts": {"1": 0.0720, "3": -0.0674, "5": -0.0900},
 "embedding": [-0.0112, +0.0243, +0.1301, ..., +0.0662]}
```

Figura 3.4: Um registo real da base de casos. O campo `impacts` é o que o preço fez 1, 3 e 5 dias depois, **medido** e não estimado. O campo `embedding` tem 384 números, dos quais se mostram quatro. É este vetor que permite comparar esta notícia com uma de hoje.

Estes três objetos são todo o material de que este trabalho dispõe, e tudo o resto que se segue neste capítulo é o que se faz com eles.

Tabela 3.1: Cada coluna do conjunto de treino, a sua origem, e se pode ou não conter informação posterior ao momento da decisão.

Coluna	O que é	Vê o futuro?	Origem
date	dia de negociação a que a notícia foi alinhada	não	calculado
news_date	data que a fonte declara para a notícia	não	FNSPID
ticker	empresa	não	FNSPID
sector	setor, de um mapa fixo escrito à mão	não	mapa do autor
headline	o título, tal como veio	não	FNSPID
headline_len	número de caracteres do título	não	calculado
vol20	desvio-padrão dos retornos dos 20 dias anteriores	não	preços
mom5	retorno acumulado dos 5 dias anteriores	não	preços
ret_event	retorno do próprio dia da notícia	não	preços
label	houve movimento anormal em $(d, d+3]$?	sim	preços
label_t*_h*	o mesmo, com nove limiares e horizontes	sim	preços
split	treino, validação ou teste	não	divisão temporal

3.3.4 Que períodos, exatamente

Uma dissertação que diz “dados de 2018 a 2023” obriga o leitor a acreditar. A Tabela 3.2 diz o intervalo **lido dos próprios ficheiros**, e distingue os dois conjuntos que é fácil confundir: o material *histórico*, com que se treina e avalia, e o registo do sistema *a funcionar*, que é muito mais recente e muito mais curto.

Uma nota que parece técnica e não é: todos os preços usados são **fechos ajustados** para desdobramentos e dividendos. Não é um pormenor nesta janela, que contém o desdobramento de quatro para um da Apple e dois da Tesla: sem ajuste, a série mostraria quedas de trinta a oitenta por cento em dias em que não aconteceu nada, e o detetor assinalaria todas com convicção.

Tabela 3.2: Cada conjunto usado, com o intervalo e a dimensão medidos no ficheiro. As três últimas linhas são o sistema em operação, e a diferença de escala em relação às primeiras é ela própria uma informação.

Conjunto	Intervalo	Dimensão
Histórico: com que se treina e avalia		
Conjunto de treino da triagem	2018-01-02 a 2023-12-18	79 753 exemplos, 14 empresas
Preços para a deteção	2023-06-01 a 2026-06-01	15 empresas, $\approx$ 750 dias cada
Operação: o sistema a funcionar		
Alertas entregues ao canal	2026-07-09 a 2026-08-13	367 mensagens
Registo de decisões de triagem	2026-07-22 a 2026-08-15	4 366 decisões
Registo do funil de portas	últimos 3 dias (por desenho)	ver a ressalva abaixo

Os 367 alertas dividem-se em 278 de notícia, 48 de movimento de preço, 24 resumos de fecho e 17 notas de abertura. O primeiro alerta de notícia é de 9 de julho de 2026; o primeiro de movimento, de 13 de julho.

A ressalva da última linha, porque é um defeito que encontrei a escrever esta tabela. O registo do funil guarda apenas os últimos dias, e isso quase passou despercebido. O limite estava escrito em **número de linhas** (5000) e foi dimensionado quando o sistema corria de meia em meia hora, o que dava cerca de oito dias de história. Com o ciclo de 60 segundos passaram a existir trinta vezes mais registos, e o mesmo limite guarda **menos de um dia**: quando fui ler o ficheiro publicado, as 5000 linhas eram todas do próprio dia.

Uma retenção contada em linhas muda de significado sempre que a cadência muda; contada em dias, não muda. Passou a ser contada em dias. Fica em três, e não numa semana, porque o ficheiro é republicado a cada ciclo e o custo é de publicação, não de armazenamento. A restrição que fixa o número está escrita em vez de parecer arbitrária.

3.4 Técnica 1: detetar o que é invulgar

Como é que um computador decide que 4% é muito?

3.4.1 O problema, em palavras

Não é possível responder com um número fixo.

Uma regra do género “avisar sempre que uma ação se mexer mais de 3%” parece razoável e é má. Para uma empresa calma, como uma cadeia de supermercados, 3% é um acontecimento raro. Para uma empresa volátil, como uma tecnológica em crescimento, 3% acontece muitas vezes por mês. A mesma regra sinaliza menos de um por cento dos dias na primeira e mais de um terço na segunda, e os números são medidos: a Secção 5.3 reporta-os.

O que interessa, portanto, não é o tamanho do movimento em si, mas o tamanho do movimento **comparado com o que é normal para aquela empresa**.

3.4.2 A ideia: medir em desvios-padrão

A solução é velha e boa, e pertence à família *estatística* da taxonomia de deteção de anomalias (Chandola, Banerjee e Kumar 2009), ou seja àquela que define o que é normal a partir da distribuição recente dos próprios dados: em vez de comparar com um número fixo, comparo com o comportamento recente da própria ação.

Olho para os últimos vinte dias e faço duas perguntas: *quanto é que esta ação costuma oscilar?* e *quão longe do costume ficou hoje?* A resposta chama-se **z-score**:

$$z_t = \frac{r_t - \mu}{\sigma} \quad (3.1)$$

Termo a termo:

- r_t é o retorno de hoje, ou seja, quanto a ação subiu ou desceu. Interessa dizer já como é calculado, porque afeta a leitura de todos os números deste capítulo: é um **retorno logarítmico**, $r_t = \ln(P_t/P_{t-1})$, e não a variação percentual simples. A escolha é a

convenção corrente em séries financeiras, porque torna os retornos aditivos ao longo do tempo e simétricos entre subidas e descidas. A consequência prática é que os valores aqui apresentados diferem ligeiramente dos que uma aplicação de bolsa mostra: um retorno logarítmico de +19.82% corresponde a uma variação de preço de +21.92%. A diferença é desprezável para movimentos pequenos e cresce com a dimensão do movimento;

- μ (mu) é a **média** dos retornos dos vinte dias anteriores: o “centro” do que é normal;
- σ (sigma) é o **desvio-padrão** desses vinte dias: uma medida de quanto a ação costuma oscilar à volta desse centro;
- z_t é o resultado: *a quantos desvios-padrão do normal ficou o dia de hoje.*

Um z de +1 quer dizer “ligeiramente acima do costume”. Um z de +7 quer dizer “isto quase nunca acontece”. E é aqui que está o essencial: $z = +7$ significa a mesma coisa na empresa calma e na empresa volátil, porque cada uma é comparada consigo própria.

3.4.3 A janela que anda, e a regra que a protege

A Figura 3.5 mostra como isto funciona ao longo do tempo. A janela dos vinte dias desliza: para julgar o dia de hoje, usa os vinte dias *anteriores*; amanhã, desliza um dia.




Figura 3.5: A janela que define “o normal”. O dia que está a ser julgado **não entra** no cálculo da sua própria norma, e é esta separação que garante que o sistema nunca usa informação que ainda não teria.

Repare-se num pormenor da figura que parece pequeno e não é: **o dia que está a ser julgado não entra no cálculo da sua própria norma**. Se entrasse, um dia muito extremo puxaria a média e inflacionaria o desvio-padrão, e o próprio dia pareceria menos invulgar do que foi. O sistema estaria a usar informação que, no momento da decisão, ainda não devia contar.

No código, esta separação é uma única fatia, e é ela que a garante. O Excerto 3.1 mostra o cálculo completo:

```
1 r = pd.Series(list(returns), dtype="float64").dropna().reset_index(drop=True)
2
3 recent = r.iloc[-window - 1 : -1] # a janela ANTES do ultimo (sem lookahead)
4 last = float(r.iloc[-1])
5
6 mu = float(recent.mean())
7 sigma = float(recent.std(ddof=1))
8 z = (last - mu) / sigma if sigma > 0 else 0.0
```

Excerto 3.1: O cálculo do z -score. A fatia `[-window-1:-1]` exclui o próprio dia da janela que define a sua norma.

3.5. Técnica 2: separar a empresa do mercado

O -1 final é a garantia inteira. Sem ele, o dia entraria no cálculo da sua própria média e do seu próprio desvio-padrão, e um dia extremo diluir-se-ia a si mesmo. A última linha é o caso da ação parada, discutido acima: quando o desvio-padrão é zero, devolve-se zero em vez de dividir.

Esta regra tem um nome, **evitar lookahead**, e atravessa todo o trabalho. Volto a ela na Secção 3.8, onde mostro como é imposta por um teste automático em vez de ser apenas prometida.

3.4.4 Um caso real

A Tabela 3.3 mostra o cálculo completo para o maior movimento do período estudado: a Tesla, a 24 de outubro de 2024, no dia a seguir aos resultados trimestrais.

Tabela 3.3: O z-score de um dia real, passo a passo (Tesla, 24 de outubro de 2024). Todos os retornos são logarítmicos; o movimento de preço correspondente nesse dia foi de +21.92%.

Quantidade	Valor
Média dos retornos dos 20 dias anteriores, μ	-0.92%
Desvio-padrão desses 20 dias, σ	2.72%
Retorno do dia, r_t	+19.82%
z-score, $(r_t - \mu)/\sigma$	+7.61
Sinalizado?	sim

Os valores da tabela estão arredondados a duas casas e o z foi calculado com todas, portanto quem refizer a divisão com os números impressos chega a 7.63 e não a 7.61. A diferença é só o arredondamento, e fica dita para não parecer um erro.

Um movimento de quase 20% num dia é evidente para qualquer pessoa. O que a tabela mostra é *porque*: não porque 20% seja um número grande em abstrato, mas porque é sete vezes e meia o que aquela ação costumava mexer naquelas semanas. É essa frase que o sistema consegue mostrar ao utilizador, e é a diferença entre avisar e explicar.

Há ainda um caso limite que convém resolver bem: se uma ação não se moveu *nada* durante vinte dias, o desvio-padrão é zero e a divisão da Equação 3.1 não existe. Nesse caso o sistema devolve $z = 0$ em vez de falhar. Uma ação parada é descrita como não tendo nada de especial, que é exatamente o que se passa.

Em três frases. Comparo o dia de hoje com os vinte dias anteriores da mesma ação e conto a distância em desvios-padrão. Assim, o mesmo número significa a mesma coisa numa empresa calma e numa volátil. O dia julgado nunca entra no cálculo da sua própria norma.

3.5 Técnica 2: separar a empresa do mercado

3.5.1 O problema, em palavras

A técnica anterior responde a *quanto*. Não responde a *de quem*. E essa é, de longe, a pergunta que uma pessoa faz a seguir: se a minha ação caiu 4%, caiu porque alguma coisa

aconteceu a esta empresa, ou porque caiu tudo?

As duas situações pedem reações opostas e são indistinguíveis no ecrã de qualquer aplicação gratuita, que mostra apenas o número final. Uma queda que acompanhou o mercado inteiro não é uma história sobre a empresa; uma queda de 4% num dia em que o mercado subiu é uma história muito específica. O número mostrado é o mesmo nos dois casos.

3.5.2 A ideia: um movimento tem parcelas

A ideia é repartir o movimento observado em três parcelas que somam ao total:

$$r_{\text{empresa}} = \underbrace{\beta_m r_m}_{\text{mercado}} + \underbrace{\beta_s \tilde{r}_s}_{\text{setor}} + \underbrace{\varepsilon}_{\text{específico da empresa}} \quad (3.2)$$

onde r_m é o retorno do índice de mercado do dia, $\tilde{r}_s$ o do setor, e β_m e β_s medem a sensibilidade histórica desta ação a cada um. A terceira parcela é definida como o resto, ou seja tudo o que mercado e setor não explicam, e é por isso que a soma fecha sempre.

Duas precisões sobre o que estes dois fatores realmente são. Convém primeiro nomeá-los, porque a equação não o faz e sem isso um β_s impresso não se pode julgar. O mercado é o **SPY**, o fundo cotado que segue o índice largo americano, e o setor é o **SPDR Select Sector** correspondente ao mapa desta secção: XLK na tecnologia, XLF na banca, XLE na energia, XLV na saúde e XLP no consumo. Foram escolhidos por serem os mais líquidos da sua classe e por terem histórico longo em qualquer fonte gratuita, que é a restrição em que este trabalho vive. Daí decorrem duas ressalvas que a equação não deixa ver, e nenhuma delas é neutra.

A primeira é que **a empresa explicada faz parte dos índices contra os quais é regredida**. Nas maiores da amostra isto não é um pormenor: elas estão entre as maiores posições dos dois fundos. Parte do que a repartição atribui ao mercado ou ao setor é, por isso, o próprio movimento da empresa a ser-lhe devolvido, e o enviesamento tem direção conhecida, empurra a parcela específica para baixo. Corrigi-lo exigiria índices construídos sem a ação em causa, que nenhuma fonte gratuita publica; o efeito é maior precisamente nas empresas de que o sistema mais fala.

A segunda é que **o mapa de setores é grosseiro, e é meu**. Cinco das nove empresas que ele arruma como tecnologia não pertencem ao XLK: a classificação padrão da indústria põe duas em consumo discricionário e três em serviços de comunicação, um setor que foi criado em 2018 precisamente para as separar da tecnologia. Nesses casos a regressão mede a sensibilidade a um agregado *vizinho* e não ao setor de pertença. O mapa fica como está por uma razão que vale a pena escrever: é o mesmo que a Secção 3.6 usa como rótulo de relevância, e trocá-lo agora mudaria dois resultados ao mesmo tempo, um de método e outro de avaliação. Declara-se em vez de se corrigir. Este ponto volta a ser importante mais abaixo, porque é a origem da limitação principal da técnica. A Figura 3.6 mostra a repartição de um dia real, e a primeira coisa que se vê nela é que duas das parcelas podem puxar ao contrário do movimento final.

Há três detalhes que decidem se isto funciona ou se produz números com boa aparência e sem significado.




Figura 3.6: O mesmo dia da AMD da Tabela 3.4, desenhado. O mercado e o setor puxaram *para baixo*, e a subida foi toda da empresa. As três parcelas somam ao movimento observado por construção, e é precisamente por somarem sempre que essa soma não prova nada sobre a qualidade da repartição, como a Secção 5.4 discute.

Primeiro: o setor tem de ser ortogonalizado. Um fundo de índice setorial e o índice de mercado movem-se quase juntos. Se as duas variáveis entrarem na regressão como estão, os coeficientes ficam instáveis e a repartição perde sentido, um efeito conhecido de colinearidade. Por isso o fator de setor usado não é o retorno do setor, mas o que dele *sobra* depois de descontado o mercado, ou seja o resíduo de uma primeira regressão do setor sobre o mercado. É esse resíduo que $\tilde{r}_s$ representa na Equação 3.2.

Segundo: os betas só podem ver o passado. A janela de estimação termina no dia anterior ao dia que se está a explicar. Esta é a mesma disciplina anti-antecipação da Secção 3.4, e aqui é ainda mais fácil de violar sem dar por isso, porque a tentação de incluir o próprio dia na regressão é grande e melhoraria o ajuste.

Terceiro: um beta estimado em vinte dias é ruidoso, e isso trata-se. Este foi o ponto onde a primeira versão desta técnica estava errada, e vale a pena registar porquê. A estimativa bruta de β_m pode sair absurda numa janela agitada. A correção inicial foi cortar a régua num limite fixo, e recair sobre $\beta_m = 1$ acima dele. Isso é exatamente o tipo de constante por justificar que este trabalho corrige noutros sítios, e tem uma consequência pior do que parece: num dia em que a estimativa dispara, o sistema deixava silenciosamente de descontar o mercado e atribuía o movimento *inteiro* à empresa, que é a conclusão mais forte que sabe tirar.

A solução vem da literatura de finanças e está descrita na Secção 2.8: encolher a estimativa na direção de um valor de referência, com um peso determinado pela *imprecisão* da própria estimativa (Vasicek 1973),

$$\beta = w \hat{\beta} + (1 - w) \beta_{\text{ref}}, \quad w = \frac{\sigma_{\text{ref}}^2}{\sigma_{\text{ref}}^2 + \text{SE}^2(\hat{\beta})}. \quad (3.3)$$

Quando o ajuste é limpo, o erro-padrão é pequeno, w aproxima-se de 1 e a estimativa fica praticamente intacta. Quando a janela é ruidosa, o erro-padrão cresce, w aproxima-se de 0 e o beta recai sobre a referência. O ajuste é gradual e não tudo ou nada. A alternativa mais simples, um peso fixo na tradição decorrente de Blume (1971), foi testada e rejeitada por uma razão concreta: encolhe com a mesma força uma estimativa boa e uma má, e num caso construído em que uma ação se move exatamente ao dobro do mercado, um peso fixo de dois terços devolve 1.67 onde a verdade é 2.0.

Falta declarar um desvio face à formulação original, porque ele existe e um leitor que conheça o artigo iria procurá-lo. Em Vasicek (1973), o valor de referência β_{ref} e a sua dispersão σ_{ref}^2 **não** são constantes escolhidas: são a média e a variância da distribuição dos betas no conjunto dos títulos, estimadas do corte transversal, e é precisamente aí que reside a natureza bayesiana do método. Aqui são fixos, 1.0 e 0.5, e a razão é de âmbito: a lista de empresas vigiadas tem doze empresas, e estimar uma distribuição de betas a partir de doze observações produziria uma referência mais ruidosa do que a constante que ela substituiria. O mecanismo de ponderação pela precisão mantém-se exatamente o de Vasicek; o que se simplifica é a origem do valor para o qual se encolhe.

3.5.3 Um caso real, com todos os passos

A Tabela 3.4 mostra a decomposição de um dia real da AMD, o de 15 de agosto de 2026. O procedimento que a gera vive no repositório de código, como todos os outros (Apêndice A), e decompõe sempre a última sessão fechada à data em que corre, pelo que reproduzir estes valores exatos exige fixar essa data.

Tabela 3.4: Um dia da AMD, repartido. Os betas foram estimados sobre os 20 dias anteriores e encolhidos pela Equação 3.3. A soma das três parcelas reproduz o movimento observado exatamente.

Passo	Valor
Movimento observado no dia	+6.2944%
β_m estimado e encolhido	2.0143
β_s estimado e encolhido	1.5888
R^2 do ajuste na janela	0.6577
Dias usados na estimação	20
Componente de mercado, $\beta_m r_m$	−0.3992%
Componente de setor, $\beta_s \tilde{r}_s$	−0.0362%
Componente específica da empresa, ε	+6.7298%
Soma das três parcelas	+6.2944%

Este caso foi escolhido por ser instrutivo, e não por ser favorável. A AMD subiu 6.29% num dia em que **tanto o mercado como o setor puxaram para baixo**. O sistema não diz apenas “foi específico da empresa”; diz também que subiu *apesar* de o contexto ter empurrado no sentido contrário, o que é uma afirmação mais forte e mais informativa do que a percentagem sozinha. O beta de mercado de 2.01 diz ainda que esta é uma ação

que historicamente amplifica o mercado, e é por isso que uma queda de 2% no índice não significa a mesma coisa para a AMD e para uma ação defensiva.

No mesmo dia, e sobre as dezassete empresas do mapa de setores que o procedimento de avaliação percorre, a resposta variou: em 8 casos o motor foi a própria empresa, em 5 foi o mercado e em 4 foi o setor. A quota do movimento atribuída à empresa teve mediana 0.487, com extremos em 0.064 e 0.939. Isto é um único dia e não é uma estimativa estável, mas estabelece o mínimo necessário para a pergunta valer a pena: a resposta não é a mesma para todas as empresas.

3.5.4 O que esta técnica não garante

Há uma armadilha nesta técnica que é fácil não ver, e convém dizê-la antes que alguém a encontre.

As três parcelas somam sempre o movimento observado, com diferença nula até à precisão da máquina. Isso é tentador de apresentar como validação, e não é: a soma fecha *por construção*, porque a parcela da empresa é definida como o resto. Uma repartição inteiramente sem sentido também somaria.

A medida que diz alguma coisa sobre a qualidade da repartição é o R^2 do ajuste na janela de estimação. Sobre essas dezassete empresas, o R^2 mediano foi 0.460, e **numa delas foi negativo**, o que significa que naquela janela o mercado e o setor não explicavam a variação daquela ação melhor do que a simples média. Nesses casos a repartição continua a somar, continua a ser exibida, e deve ler-se como indicativa.

Esta é uma limitação real e fica registada como tal, em vez de ser escondida atrás de uma soma que fecha. O Capítulo 6 regressa a ela.

3.6 Técnica 3: encontrar casos parecidos

Como é que o computador percebe que duas notícias falam da mesma coisa?

3.6.1 O problema, em palavras

Chega uma notícia: “Nvidia bate estimativas com procura de centros de dados”.

A pergunta útil é: *já houve notícias parecidas com esta, e o que fez o preço a seguir?*

A maneira ingênua de procurar é por palavras. Procurar notícias antigas que contenham “Nvidia”, “bate” e “estimativas”. Funciona mal, por duas razões simétricas:

- duas notícias podem dizer a **mesma coisa com palavras diferentes**: “supera previsões” e “bate estimativas” não partilham uma única palavra importante;
- duas notícias podem **partilhar palavras e falar de assuntos diferentes**: “bate estimativas” e “bate recorde de despedimentos” partilham “bate”.

O que é preciso é comparar **significado**, não letras.

3.6.2 A ideia: transformar frases em pontos

É aqui que entra a única peça de aprendizagem profunda que o sistema usa, e merece ser explicada com calma porque é a que soa mais complicada e não é.

Um **modelo de embeddings de frase** (Reimers e Gurevych 2019) é um modelo já treinado que recebe uma frase e devolve uma lista de números, neste caso 384. Essa lista chama-se *embedding* e funciona como uma **coordenada**: é a posição daquela frase num espaço.

A propriedade que interessa é esta: o modelo foi treinado de forma a que frases com significado parecido fiquem **perto** umas das outras nesse espaço, mesmo que usem palavras diferentes. A Figura 3.7 mostra a ideia em duas dimensões (as verdadeiras são 384, que não se conseguem desenhar).




Figura 3.7: Cada frase vira um ponto. Frases com o mesmo significado ficam próximas, mesmo sem partilharem palavras; frases que partilham palavras (“bate”) mas falam de assuntos diferentes ficam longe. O desenho tem duas dimensões para se poder ver; o modelo usa 384.

3.6.3 Medir a distância: o cosseno

Tendo duas frases como pontos, falta medir se estão perto.

A medida usada é a **semelhança do cosseno**. Em vez de medir a distância em linha reta, mede o **ângulo** entre as duas direções. Dá um valor entre -1 e 1 :

- perto de 1: as duas frases apontam na mesma direção, ou seja, significado muito parecido;
- perto de 0: não têm relação;
- negativo: apontam em direções opostas.

Usa-se o ângulo e não a distância porque o que interessa é *sobre o que* a frase fala, e não o comprimento do texto. Um título curto e um parágrafo longo sobre o mesmo assunto devem ficar próximos, e o ângulo dá isso. A Figura 3.8 mostra as duas situações.

A fórmula geral do cosseno entre dois vetores $\mathbf{u}$ e $\mathbf{v}$ é:

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\sum_{i=1}^{384} u_i v_i}{\sqrt{\sum_{i=1}^{384} u_i^2} \cdot \sqrt{\sum_{i=1}^{384} v_i^2}} \quad (3.4)$$




Figura 3.8: Cada título é uma seta com 384 coordenadas, aqui desenhada em duas para se poder ver. O que se compara é o **ângulo** entre elas, e não o sítio onde as pontas caem: um título curto e um parágrafo longo sobre o mesmo assunto apontam na mesma direção, e o comprimento da seta, que é o que a distância mediria, diz respeito ao tamanho do texto e não ao seu tema. Os dois valores são os do par real da Tabela 3.5.

Em cima multiplicam-se as duas listas número a número e soma-se tudo. Em baixo dividem-se pelos comprimentos dos dois vetores, e é essa divisão que faz o resultado depender só da direção.

E há aqui uma simplificação de consequências práticas. O modelo devolve os vetores já com comprimento 1. Isso não é um detalhe de arrumação: quando os dois comprimentos valem 1, o denominador da Equação 3.4 vale $1 \times 1 = 1$ e a fórmula reduz-se à soma de cima. Comparar dois títulos passa a ser **multiplicar e somar**, sem mais nada, o que é a razão de o sistema conseguir percorrer 80 mil casos depressa.

3.6.4 O cosseno em dois casos reais

A Tabela 3.5 segue a conta para dois pares de títulos retirados da base de casos. São reais, e os valores são os que o sistema calcula.

Para tornar a soma concreta, eis as quatro primeiras das 384 parcelas do par A:

$$\begin{aligned} & \underbrace{(+0.0609)(+0.0418)}_{+0.002546} + \underbrace{(-0.0524)(-0.0312)}_{+0.001638} + \\ & \underbrace{(+0.0584)(+0.0648)}_{+0.003779} + \underbrace{(+0.0142)(+0.0004)}_{+0.000006} + \dots = +0.955626 \end{aligned}$$

Note-se a segunda parcela: dois números *negativos* contribuem *positivamente*, porque o que conta é os dois vetores concordarem naquela dimensão, e não o sinal em si. E note-se, no par B, que a soma final é ligeiramente negativa: os títulos não são opostos em sentido nenhum, apenas não têm nada em comum, e o valor anda à volta de zero.

O chão de semelhança usado em produção é 0.45. O par A passaria com folga; o par B nem se aproxima.

Tabela 3.5: Dois pares do lado oposto da escala. Repare-se na linha do comprimento: vale exatamente 1 nos quatro vetores, o que confirma a normalização e faz o cosseno coincidir com a soma dos produtos.

	Par A: mesmo assunto	Par B: assuntos diferentes
Primeiro título	“Shares of several companies in the technology, software and semiconductor space are trading lower...”	“Peloton Shares Tick To Session Low As Hearing Report Apple Working On ‘Guided Workout’...”
Segundo título	“Shares of several technology, software and semiconductor companies are trading lower...”	“Coronavirus – Another Severe Hit To The Automotive Industry”
Comprimento do 1.º vetor	1.000000	1.000000
Comprimento do 2.º vetor	1.000000	1.000000
Soma dos 384 produtos	+0.955626	−0.085901
Cosseno	+0.956	−0.086
Leitura	praticamente a mesma notícia	sem relação nenhuma

3.6.5 Medir o que se seguiu

Encontrar notícias parecidas é metade. A outra metade é dizer o que aconteceu ao preço depois de cada uma delas.

Para isso adapta-se uma técnica clássica de finanças, o **estudo de evento** (Brown e Warner 1985): fixa-se o dia da notícia e mede-se o que o preço fez 1, 3 e 5 dias depois. A Figura 3.9 mostra o alinhamento.

O verbo “adapta-se” está ali de propósito, e a diferença tem de ficar dita porque é uma simplificação face à fonte. O que Brown e Warner (1985) normalizam é a medição do retorno *anormal*, ou seja o retorno já descontado de uma referência, tipicamente o movimento do mercado no mesmo período. O que este trabalho mostra ao utilizador é o retorno **bruto**, sem desconto nenhum.

A escolha é deliberada e tem um custo. A favor: o valor exibido é o que a pessoa veria na sua aplicação, e um número que ela pode conferir vale mais, num produto que se propõe ser verificável, do que um número mais correto que ela não sabe reproduzir. Contra, e é real: um retorno bruto mistura a reação à notícia com o que o mercado inteiro fez nesses dias, pelo que num período de queda generalizada os precedentes parecerão piores do que foram. O sistema *sabe* fazer o desconto, e fá-lo onde ele é indispensável, que é na construção do rótulo da Secção 3.7; aqui não o faz, e isso fica registado como escolha e não como descuido.

Duas decisões de detalhe, ambas com consequência:

1. **Se a notícia sai fora de dias de bolsa**, o dia d é o primeiro dia de negociação igual ou posterior. Sem esta regra, uma notícia de sábado não teria a que se agarrar.
2. **A medição começa no fecho de d** , não na abertura. É a opção conservadora: não atribui à notícia a parte do movimento que já tinha acontecido antes de ela ser lida.

3.7. Técnica 4: decidir o que merece um alerta




Figura 3.9: O impacto é medido a partir do *fecho* do dia da notícia. Se a notícia sai num sábado, o dia d é o primeiro dia de bolsa seguinte. É uma **medição do que aconteceu**, não uma previsão.

Convém dizer também aquilo que isto **não** é. Medir o que aconteceu a seguir a notícias passadas não é prever o que vai acontecer agora. É por isso que o sistema mostra sempre os casos *um a um*, com a data e o valor de cada um, em vez de resumir tudo a uma média. Uma média esconde que os casos podem ter ido em sentidos opostos.

Em três frases. Um modelo já treinado transforma cada título numa lista de 384 números que funciona como uma coordenada de significado. Comparo títulos pelo ângulo entre essas coordenadas, o que aproxima frases parecidas mesmo com palavras diferentes. Para cada caso passado, meço o que o preço fez 1, 3 e 5 dias depois: uma medição, não uma previsão.

3.7 Técnica 4: decidir o que merece um alerta

Já sei que algo é invulgar. Devo mesmo interromper alguém?

3.7.1 O problema, em palavras

Chegam muitas notícias. A maioria não interessa: repetições, listas automáticas, textos que mencionam a empresa de passagem.

Um sistema que avisa de tudo é tão inútil como um que não avisa de nada. Pior, até, porque ensina a pessoa a ignorar o canal. Este problema tem nome, **fadiga de alertas**, e é a razão pela qual esta terceira decisão existe.

Aqui, ao contrário das duas anteriores, não há uma fórmula óbvia. É o sítio natural para **aprender a partir dos dados**.

3.7.2 A tarefa e o rótulo

Para treinar um modelo é preciso, antes de tudo, uma pergunta com resposta conhecida.

A pergunta escolhida foi: *depois desta notícia, houve um movimento anormalmente grande no preço?* A resposta, o **rótulo**, constrói-se assim:

1. mede-se o retorno da ação nos três dias seguintes à notícia;
2. subtrai-se o movimento do mercado no mesmo período, para não confundir “a empresa mexeu-se” com “mexeu-se tudo”;

3. se o que sobra for maior do que 2% em valor absoluto, o rótulo é 1; caso contrário, 0.

Repare-se em **valor absoluto**. O rótulo diz se houve movimento *grande*, e nunca em que **direção**. Isto é deliberado e é a fronteira que o trabalho não atravessa: o modelo aprende sobre *materialidade*, não sobre subir ou descer.

E o passo 2 usa um beta de um, o que é uma incoerência com a técnica anterior.

Subtrair o movimento do mercado *tal e qual* equivale a supor que esta ação acompanha o mercado ponto por ponto. É exatamente a suposição que a Secção 3.5 recusa uma página antes, com o argumento de que recair sobre $\beta = 1$ é a classe de constante por justificar que este trabalho corrige noutros sítios, e ali mostra-se uma ação cujo beta bruto estimado foi 4.43. Numa ação de beta alto, o que sobra depois da subtração ainda contém parte do movimento do mercado, e o rótulo passa a marcar como material um dia em que só o mercado se mexeu.

A incoerência é real e fica declarada. O que a atenua é que o efeito é *simétrico entre os modelos comparados*: todas as seis famílias da Secção 5.6 são treinadas e avaliadas contra o mesmo rótulo, portanto um rótulo mais ruidoso torna a tarefa mais difícil para todas por igual e não favorece nenhuma. O que ele afeta é o *nível* das métricas, não a ordenação, que é o que a pergunta compara. Refazer o rótulo com betas encolhidos obrigaria a retreinar as seis e a re-correr tudo o que delas depende, e o benefício seria um número diferente para a mesma conclusão.

3.7.3 O que o modelo vê

O modelo recebe cinco tipos de informação sobre o momento da notícia:

- **volatilidade recente**: quanto a ação tem oscilado nos últimos 20 dias;
- **momento**: como se comportou nos últimos 5 dias;
- **o movimento do próprio dia**;
- **o comprimento do título**;
- **o setor** da empresa.

E, numa das variantes testadas, também o *embedding* do título, os mesmos 384 números da Secção 3.6. Comparar a variante com texto e a variante sem texto é precisamente o que a Q13 pergunta, e a resposta está no Capítulo 5.

Vale a pena olhar para esta lista com atenção, porque ela decide mais do que parece.

A que *nível* vive cada uma destas informações? A volatilidade e o momento descrevem a empresa e movem-se devagar. O setor é literalmente constante. O movimento do dia é igual para todas as notícias do mesmo dia. Sobra uma única entrada que distingue dois títulos da mesma empresa no mesmo dia: **o comprimento do título**. A Figura 3.10 arruma as nove entradas por esse critério.

Na variante *sem texto*, duas notícias diferentes da mesma empresa, no mesmo dia, diferem para o modelo apenas no número de caracteres do título. Essa entrada tem um peso pequeno, e por isso a pontuação dessa variante é **quase constante dentro de cada empresa** por construção, e não por acidente do treino.

3.7. Técnica 4: decidir o que merece um alerta




Figura 3.10: As nove entradas do modelo implantado, agrupadas pelo que cada uma consegue distinguir. Sete descrevem a **empresa** e mudam devagar ou nada; uma descreve o **dia** e é igual para todas as notícias desse dia; e **uma só** muda de um título para o seguinte. A figura antecipa, sem a demonstrar, a medição da Seção 5.6.9: um modelo com esta composição de entradas dificilmente poderia separar duas notícias, e a ablação mostra que não separa.

Isto não invalida a comparação que a QI3 faz: a variante *com* texto tem 384 números por título e é essa que responde à pergunta. Mas fixa desde já o que a variante sem texto pode e não pode fazer, e é uma distinção a que o Capítulo 5 volta, porque foi ela que me escapou quando escolhi o que implantar.

3.7.4 Treinar sem deixar o futuro entrar no treino

Esta é a parte onde é mais fácil enganar-se a si próprio, e daí o desenho da Figura 3.11.




Figura 3.11: Os dados são divididos **por ordem cronológica**, nunca ao acaso. Entre blocos há um *embargo* de cinco dias, porque o rótulo de uma notícia olha até três dias para a frente e sem o embargo o fim do treino tocaria no princípio do teste.

Duas regras, e as duas existem para impedir que o modelo pareça melhor do que é:

Dividir pelo tempo, não ao acaso. Se os dados fossem baralhados, o modelo treinaria com notícias de 2023 e seria testado com notícias de 2019, ou seja, estaria a ser avaliado sobre um passado que já conhece. Aqui, treina-se no início do período e testa-se no fim, como acontece na realidade.

Embargo entre blocos. O rótulo de uma notícia depende dos três dias seguintes. Uma notícia no último dia de treino tem o seu rótulo determinado por dias que já pertencem ao bloco seguinte. Deitam-se fora os cinco dias de fronteira, e o preço disso é conhecido: **820 das 79 753 linhas**, ou seja 1.03%. Ficam 28 574 para treino, 17 710 para validação e 32 649 para teste.

E há aqui um número que surpreende, por isso convém explicá-lo antes que espante.

O bloco de teste tem *mais* exemplos do que o de treino, 32 649 contra 28 574. Não é um erro de divisão: o corte é de 70, 15 e 15 por cento **em dias de negociação**, e por dias a proporção é exatamente essa, com 1 050 dias de treino contra 221 de teste. O que desequilibra as contagens é a densidade de notícias, que cresce muito ao longo do período: 2018 vale 5.1% das linhas e 2023 vale 43.8%. Mil e cinquenta dias antigos produzem menos exemplos do que duzentos e vinte e um dias recentes.

A divisão é por dias, e não por linhas, porque é o dia que separa o passado do futuro: cortar por número de exemplos partiria dias ao meio e deixaria entrar no treino notícias do mesmo dia que está a ser testado. O efeito colateral não é mau, e vale a pena dizê-lo: um bloco de teste grande torna a estimativa mais precisa. O que ele custa é do outro lado, e fica registado como limitação: o modelo é treinado sobre a metade menos densa do período.

3.7.5 Da pontuação à probabilidade: calibração

O modelo devolve uma pontuação. Uma pontuação alta não é, por si só, uma probabilidade: dizer 0.8 não garante que aconteça em 8 de cada 10 casos.

Como o número vai ser mostrado a uma pessoa, isso tem de ser corrigido. O passo chama-se **calibração**, e a função usada aqui é a sigmoide de dois parâmetros proposta por Platt em 1999, cuja avaliação empírica comparativa é feita por Niculescu-Mizil e Caruana (2005). Transforma pontuações em probabilidades *honestas*, de modo a que, entre todos os casos a que o modelo dá 70%, cerca de 70% tenham mesmo acontecido. A calibração é ajustada no bloco de validação, nunca no de teste.

A função usada tem apenas dois números a aprender, a e b :

$$p_{\text{calibrada}} = \frac{1}{1 + e^{-(a p_{\text{bruta}} + b)}} \quad (3.5)$$

Neste trabalho os dois valores aprendidos foram $a = 3.700$ e $b = -2.313$. O sinal negativo de b diz o essencial: o modelo, deixado por sua conta, era **demasiado otimista**, e a calibração existe para o puxar para baixo. A Figura 3.12 desenha a curva.

Convém acrescentar de onde vem parte desse otimismo, porque não é uma propriedade do modelo, é uma escolha minha. O treino **repondera as classes** para compensar o desequilíbrio entre elas, e numa tarefa em que os positivos são pouco mais de um terço isso empurra as pontuações para cima por construção. A calibração está portanto, em parte, a desfazer uma decisão tomada um passo antes. Não invalida nada, porque o que sai é ajustado contra o que realmente aconteceu num bloco reservado, mas explica a magnitude do b melhor do que dizer que o modelo era otimista.

E a calibração fica enviesada, por uma razão que convém dizer. A sigmoide é ajustada no bloco de validação e aplicada ao de teste, e os dois blocos não têm a mesma proporção de casos importantes: a validação tem 47.0% e o teste 37.8%. Como a divisão é cronológica, essa diferença não é um defeito de amostragem, é o mundo a mudar entre dois períodos.

A consequência é mensurável e vai no sentido desfavorável. No bloco de validação a probabilidade média prevista iguala a observada, 0.470 contra 0.470, como não podia deixar de ser, porque é ali que a sigmoide é ajustada. No bloco de teste a média prevista é 0.428




Figura 3.12: A curva que converte a pontuação do modelo numa probabilidade, com os dois valores aprendidos neste trabalho, $a = 3.700$ e $b = -2.313$. A curva corre **abaixo** da diagonal em quase toda a extensão, e é isso que quer dizer o sinal negativo de b : o modelo, deixado por sua conta, anunciava mais do que acontecia, e a calibração puxa-o para baixo. O ponto marcado é o caso real seguido na Tabela 3.6, onde uma pontuação de 0.507, praticamente um lançamento de moeda, se torna 0.392.

contra 0.378 observado, ou seja o sistema anuncia cerca de **cinco pontos percentuais a mais** do que acontece.

Isto não altera a *ordenação* entre notícias, porque a sigmoide é monótona e preserva a ordem, e é a ordenação que o produto usa para escolher o que enviar. Altera o valor absoluto que aparece no alerta. Fica registado porque é o único número que o utilizador vê, e porque o corrigir exigiria recalibrar sobre a distribuição que o sistema encontra em produção, que é trabalho por fazer.

3.7.6 Da linha de dados aos 39%: a conta toda

Falta ligar as pontas. A Tabela 3.6 segue **a mesma linha** que a Figura 3.3 mostrou no início deste capítulo, desde os valores em bruto até à percentagem final, sem saltar nenhuma etapa.

Há dois pormenores neste percurso que merecem atenção, e são eles que tornam o exemplo útil.

A calibração não é uma formalidade. A pontuação bruta era 0.507, praticamente um lançamento de moeda. Depois de calibrada passa a 0.392. São leituras diferentes: a primeira diria a um utilizador que o desfecho está em aberto, e a segunda diz que é mais provável não acontecer nada de especial. **A ordenação entre notícias não muda** com esta transformação, porque ela é sempre crescente; o que muda é o *significado* do número mostrado, e é esse número que a pessoa lê.

E a maior contribuição foi negativa. A parcela de maior peso, -0.252 , veio da volatilidade, e puxou a probabilidade *para baixo*. A razão é que a Apple vinha de vinte dias mais calmos do que o habitual, e o modelo aprendeu que notícias em períodos calmos são menos frequentemente seguidas de movimentos grandes. É a mesma lógica do detetor do início

Tabela 3.6: As cinco etapas para a notícia da Apple de 2 de fevereiro de 2023. Os valores são os que o modelo implantado produz. As parcelas estão arredondadas a três casas, e a etapa 3 diz o que a sua soma impressa dá e o que o total não arredondado dá; contra o modelo, a soma sem arredondar reproduz até à sexta casa decimal.

	Etapa	O que acontece
1	Entrada	As nove entradas da linha: quatro números, que são volatilidade 0.0127, momento 0.0249, movimento do dia 0.0364 e comprimento do título 53, mais o setor codificado em cinco casas, uma por setor, das quais só a da tecnologia está a 1.
2	Normalização	Cada valor é comparado com a média e a dispersão do conjunto de treino, para que grandezas diferentes possam ser somadas. A volatilidade deste dia fica em -0.49 , ou seja, <i>abaixo</i> do habitual; o movimento do dia fica em $+1.10$.
3	Soma pesada	Cada valor normalizado é multiplicado pelo seu peso e somam-se todos: -0.252 da volatilidade, $+0.236$ da casa do setor tecnológico, $+0.067$ das restantes casas de setor, $+0.006$ do movimento do dia, -0.003 do comprimento do título, $+0.000$ do momento, e o termo constante -0.025 . Total: $+0.030$. As parcelas estão arredondadas a três casas e a sua soma impressa dá 0.029; o total é o valor não arredondado.
4	Sigmoide	O total é convertido em algo entre 0 e 1: $1/(1 + e^{-0.030}) = \mathbf{0.507}$.
5	Calibração	$3.700 \times 0.507 - 2.313 = -0.437$, e a sigmoide disso dá 0.392 . É este o número que chega ao ecrã, arredondado: 39% .

do capítulo, aprendida em vez de escrita, e é a razão pela qual o alerta consegue dizer ao utilizador *o que* levantou e *o que* baixou a estimativa.

Repare-se também no outro extremo da lista. O **momento** entrou com $+0.000$, e não por arredondamento infeliz: o peso que o modelo lhe aprendeu é de facto quase nulo. Das nove entradas, uma não está a fazer nada, e isso só se vê desmontando um caso.

Em três frases. Treinei um modelo para estimar se uma notícia é seguida de um movimento anormalmente grande, em qualquer direção. Os dados são divididos pelo tempo, com um embargo entre blocos, para o modelo nunca ser avaliado sobre um futuro que já viu. A pontuação é calibrada, para o número mostrado ao utilizador querer dizer o que parece querer dizer.

3.8 Como é que se sabe que isto funciona

O que impede um resultado bonito de ser um resultado enganador?

Três compromissos, assumidos *antes* de correr as experiências.

Primeiro: comparar sempre com o mais simples. Um número sozinho não diz nada. Dizer que a recuperação acerta em metade dos casos só significa alguma coisa quando se sabe o que acertaria uma alternativa trivial. Cada técnica é, portanto, comparada com **linhas de base**: uma regra fixa, uma escolha ao acaso, a notícia mais recente. Se a técnica sofisticada não ganhar, isso é o resultado, e é o que fica escrito.

Segundo: o não-lookahead é imposto por um teste, não prometido. É fácil escrever “não usámos informação do futuro”. É difícil garanti-lo. Aqui existe um teste automático que faz o seguinte: pega num exemplo, **altera artificialmente o futuro** e volta a calcular. Depois exige duas condições ao mesmo tempo: que as entradas fiquem exatamente iguais (porque descrevem o passado) e que o *rótulo* mude (porque descreve o futuro). Se alguma informação do futuro se tivesse infiltrado nas entradas, o teste falha.

Esta é a garantia mais importante de todo o trabalho e a mais fácil de prometer sem cumprir, por isso o Excerto 3.2 mostra-a tal como está escrita.

```

1 def test_anti_lookahead_mutar_o_futuro_nao_muda_features():
2     base = [100.0 + i * 0.1 for i in range(30)]
3     futuro_a = base + [200.0, 300.0, 400.0] # futuros absurdos A
4     futuro_b = base + [50.0, 10.0, 1.0]    # futuros absurdos B
5     d = len(base) - 1                      # o evento e o ultimo dia comum
6
7     fa = event_features(_serie(futuro_a), event_idx=d)
8     fb = event_features(_serie(futuro_b), event_idx=d)
9
10    assert fa == fb # features identicas => o futuro nao vaza
11
12 def test_mutar_o_futuro_muda_o_ROTULO_mas_nao_as_features():
13     sobe = _serie([100.0] * 25 + [100, 110, 120, 130]) # movimento enorme
14     plano = _serie([100.0] * 25 + [100, 100, 100, 100]) # nada acontece
15
16     assert event_features(sobe, 25) == event_features(plano, 25)
17     assert abnormal_label(sobe, mercado, 25, 0.02, 3) == 1
18     assert abnormal_label(plano, mercado, 25, 0.02, 3) == 0

```

Excerto 3.2: Os **dois** testes que impedem o futuro de entrar nas entradas. O primeiro exige que duas séries com futuros diferentes dêem entradas iguais; o segundo, que é o que fecha o argumento, exige ao mesmo tempo que o *rótulo* mude.

O segundo teste é o que fecha o argumento, e é o que distingue esta verificação de uma verificação inútil. Exigir apenas que as entradas não mudem seria satisfeito por um sistema que ignorasse os dados por completo. Exigir, ao mesmo tempo, que o **rótulo mude** obriga a que a diferença entre as duas séries seja real e detetável, e é essa combinação que prova que a fronteira está no sítio certo.

Terceiro: reportar o que sair. O critério de sucesso de cada experiência foi escrito antes de a correr. Onde o resultado contrariou o que se esperava, fica reportado como se revelou. O Capítulo 5 tem um caso desses, e é o mais interessante dos três.

3.9 Desafios tecnológicos e sociais

Que riscos é que um sistema destes cria, e o que é que este faz em relação a eles?

Um sistema que recolhe informação sobre empresas, guarda decisões, e interrompe pessoas no telemóvel levanta questões que não são técnicas. Convém tratá-las com o mesmo cuidado que se dá às medições, e no mesmo sítio: aqui, e não numa nota no fim.

3.9.1 Privacidade e proteção de dados

O risco mais óbvio de uma aplicação financeira é saber demasiado sobre quem a usa. Uma carteira revela rendimento, aversão ao risco e projetos de vida, e é informação que o Regulamento Geral sobre a Proteção de Dados trata como merecendo proteção reforçada quando permite traçar o perfil de alguém.

A decisão de desenho que responde a isto foi tomada no início e é a mais simples possível: **o sistema não sabe o que cada pessoa possui, e não pergunta.** Não há carteira, não há posições, não há montantes, e o canal público não identifica ninguém. Um alerta sobre a Apple é o mesmo alerta para toda a gente, e por isso não há nada a proteger que possa identificar um leitor.

Isto tem um custo que convém dizer: sem saber o que a pessoa tem, o sistema não pode personalizar. Alerta sobre uma lista fixa de empresas, e não sobre as de quem lê. É uma troca deliberada, e a alternativa está registada como trabalho futuro na Secção 6.5, onde também se diz o que ela obrigaria a recolher.

Há uma exceção, e é preciso nomeá-la em vez de a arredondar. Quem quiser receber alertas personalizados pode falar com um robô do Telegram, e nesse caso ficam guardados **duas coisas**: o identificador de conversa que a plataforma atribui, e a lista de empresas que a pessoa escolheu seguir. Não há nome, não há contacto, não há montante. É pouco, e é a totalidade. Escrever “não são guardados dados pessoais” seria mais arrumado e seria falso, porque um identificador de conversa é um identificador.

3.9.2 Segurança

Um sistema que corre sozinho e fala com serviços externos tem credenciais, e credenciais fogem.

As chaves nunca estão no repositório: vivem em variáveis de ambiente e no cofre de segredos da plataforma. Isso é o mínimo e não chega, e a razão pela qual sei que não chega é que **falhou**. As mensagens de erro de uma biblioteca de HTTP incluem o endereço do pedido, e o endereço de algumas destas Interface de Programação de Aplicações (APIs) leva a chave lá dentro. Bastou um dia em que uma fonte respondeu com erro a todos os pedidos para a chave ficar escrita centenas de vezes no registo do serviço. O código nunca imprimiu a chave: imprimiu a exceção.

A correção tem duas partes, e só a primeira é técnica. A primeira é uma função que mascara qualquer parâmetro com nome de credencial em todo o texto que vai para o registo, e um

teste que usa a cadeia real que apareceu. A segunda é que **uma máscara não desfaz uma fuga**: a chave exposta tem de ser substituída, e isso é uma operação humana que fica na lista de tarefas por fazer.

Há ainda uma decisão de segurança do lado dos modelos. O codificador de frases é descarregado sob pedido e verificado contra uma soma de controlo fixada no código. Sem essa verificação, um descarregamento corrompido ou substituído mudaria em silêncio aquilo que o sistema entende por “semelhante”; com ela, falha fechado.

3.9.3 Questões éticas e sociais

Quatro, por ordem de importância. As três primeiras são decisões de desenho; a última é uma restrição que se descobriu tarde e que não se escolheu.

Não aconselhar, e não prever. A restrição fundadora deste trabalho é também a sua principal salvaguarda ética. Um sistema que dissesse a alguém o que vai acontecer ao preço estaria a emitir uma previsão que ninguém pode conferir no momento em que é lida; um que dissesse o que comprar estaria dentro de uma atividade regulada. Este descreve o que já aconteceu e mostra a evidência ao lado, e a Secção 2.13 explica porque é que essa fronteira é de desenho e não de modéstia.

Há aqui uma distinção que é preciso fazer em voz alta, porque a Figura 4.3 a torna impossível de ignorar: o alerta que serve de exemplo, e que é um alerta real copiado do registo, cita um título que diz *“Prediction: Amazon Will Join Apple in the \$4 Trillion Club Before 2030”*. Isso é uma previsão, com um alvo e com uma data, entregue no telemóvel de uma pessoa por este sistema.

A garantia que este trabalho dá aplica-se ao que o sistema **escreve**, e não ao que ele **cita**. O título é conteúdo de terceiros, reproduzido *verbatim* porque é o facto que desencadeou o alerta, e reproduzi-lo é o que torna o resto verificável: sem ele o leitor não pode ir à fonte confirmar do que se trata. Tudo o que é do sistema, nesse mesmo alerta, respeita a restrição, e vê-se nas três partes seguintes, que falam de casos passados observados, de *“not a prediction for this news”* e de probabilidade **em qualquer direção**.

Fica no entanto uma limitação que decorre disto e que não tem solução dentro das restrições assumidas: **o filtro de relevância decide se o título é sobre a empresa, e não se ele é factual**. Um título especulativo passa como qualquer outro. Distinguir notícia de opinião exigiria um classificador que este trabalho não tem, e é uma das linhas que o Capítulo 6 deixa em aberto.

Fadiga de alertas, e o direito a não ser interrompido. Um sistema que avisa de tudo não é atento, é ruidoso, e ensina quem o recebe a ignorá-lo. Isto trata-se como um requisito e não como um detalhe: existe um orçamento de cinco alertas por dia entre todas as empresas, um piso que sobe a cada alerta repetido da mesma empresa, e supressão de histórias repetidas. Ao contrário dos pisos, que saem de um varrimento de custos, **o cinco não foi derivado de medição nenhuma**: é uma escolha, feita para que uma pessoa consiga ler tudo o que recebe, e a Secção 5.6 avalia a política *dado* esse orçamento em vez de o justificar. O Capítulo 4 mostra o funil completo, e nove em cada dez varreduras não enviam nada. O silêncio é uma decisão do sistema, e é por isso que a página web o torna inspecionável.

Confiança a mais, e confiança a menos. Uma explicação não torna automaticamente uma decisão melhor. A literatura mostra que a confiança falha nos dois sentidos, com o utilizador a ignorar um aviso correto ou a aceitar um errado (J. D. Lee e See 2004), e que a simples presença de uma explicação aumenta a aceitação de respostas erradas (Bansal et al. 2021). É por isso que este sistema mostra os casos passados um a um, com as datas e o desfecho de cada um, em vez de os resumir a uma média que se lê como uma previsão. **Que isso consiga produzir confiança apropriada é uma hipótese, e não um resultado:** sem o estudo com pessoas descrito na Secção 6.4, não é possível distinguir um alerta ignorado de um alerta indevidamente acreditado, porque ambos deixam o mesmo registo, que é nenhum.

E uma restrição legal que se descobriu a meio. Três dos ficheiros que o repositório distribui derivam de um conjunto de dados publicado sob uma licença que exige partilha nos mesmos termos, e o modelo de documento usado nesta dissertação tem uma licença que exige o mesmo e ainda proíbe uso comercial. Isso condiciona a licença do próprio código, que deixa de ser uma escolha livre. Fica registado porque é o tipo de restrição que se descobre tarde e obriga a decidir com pressa.

Capítulo 4

InvestiGator: o sistema

4.1 Vista de conjunto

Como é que as peças se ligam?

O Capítulo 3 explicou quatro técnicas isoladas; este mostra-as a trabalhar juntas, que é onde aparecem os problemas que nenhuma delas tem sozinha.

O sistema chama-se **InvestiGator** e tem cinco partes, na Figura 4.1: **deteção**, **recuperação**, **triagem**, **explicação** e **entrega**. Cada uma tem uma responsabilidade única e passa o resultado à seguinte, o que permite substituir qualquer delas sem tocar nas outras.




Figura 4.1: As cinco partes do InvestiGator. À esquerda, de onde vêm os dados; ao centro, as quatro técnicas do capítulo anterior mais o motor que compõe o texto; à direita, as duas formas de o utilizador receber o resultado. A **decomposição** está a tracejado porque é a única que não corre em todos os alertas: só entra no de preço, já que sem movimento do dia não há nada para repartir.

Há uma regra de desenho que atravessa tudo isto e que convém enunciar já: **a explicação é montada a partir dos objetos que foram calculados**, e nunca escrita à parte. Se o detetor calculou um z de $+7.61$, é esse número que aparece no texto. Não há um sítio onde

alguém escreva a frase e outro sítio onde alguém calcule o valor, porque, se houvesse, os dois podiam divergir sem ninguém dar por isso.

4.2 De onde vêm os dados

Uma restrição fundadora deste trabalho é usar **apenas fontes gratuitas**. Não foi por comodidade: é o que torna o sistema utilizável por quem ele serve. Um investidor que já acha caro pagar comissões não vai subscrever um terminal financeiro.

Isso obriga a três decisões de engenharia.

Preços: uma cadeia, não uma fonte. As fontes gratuitas de preços falham com regularidade, seja bloqueando por excesso de pedidos, seja respondendo com erro, seja simplesmente não tendo ainda o dia de hoje. Em vez de depender de uma, o sistema tenta várias por ordem e fica pela primeira que responde, registrando sempre qual delas serviu, porque saber de onde veio um número faz parte de o poder explicar.

Notícias: por empresa, e filtradas à entrada. As notícias vêm de uma API gratuita, empresa a empresa, e o que chega é muito e é sujo: listas automáticas de “os dez maiores movimentos do dia”, textos que mencionam a empresa apenas de passagem, comunicados de escritórios de advogados. Antes de tudo o resto, portanto, um filtro exige que a notícia **nomeie mesmo a empresa** e rejeita os padrões conhecidos de texto automático.

Histórico: um conjunto de dados público, alinhado com preços. Para responder à pergunta “já aconteceu antes?” é preciso um passado. Usa-se o FNSPID (Dong, Fan e Peng 2024), um conjunto público de notícias financeiras, alinhado com os preços correspondentes. Desse alinhamento nascem cerca de 80 mil casos entre 2018 e 2023, cada um com o que o preço fez a seguir, e é sobre eles que a recuperação é *avaliada* no Capítulo 5.

Convém separar isso do que o sistema *implantado* consulta, porque não é o mesmo ficheiro. Em produção a base de casos é um ano de notícias reais recolhidas pelo próprio sistema, com o impacto medido da mesma maneira: são 38 214 casos, e a Secção 4.8.2 conta o que foi preciso fazer para caberem na memória. Um serve para medir se o método funciona, o outro é o que está a correr.

4.3 As peças que não são minhas

O que é que este sistema usa de fora, e porquê essas e não outras?

Um sistema construído sobre serviços de terceiros deve dizer quais são. Não por formalidade: porque cada um deles é uma dependência, um limite, e uma decisão que podia ter sido tomada ao contrário. A Tabela 4.1 lista todas, com o que cada uma faz, o que custa, e o que foi *rejeitado* em favor dela.

Duas observações que valem mais do que a tabela.

A cadeia de preços é a peça de engenharia mais aborrecida e mais necessária. Nenhuma fonte gratuita de preços é fiável sozinha, e por isso o sistema tenta-as por ordem

4.3. As peças que não são minhas

Tabela 4.1: As dependências externas, nomeadas. A coluna da direita é a que interessa: uma escolha só se defende contra a alternativa que não foi tomada.

Peça	Para quê	Custo/limite	Porquê esta, e não a outra
Finnhub	notícias por empresa	grátis, 60 pedidos/min	Dá notícias <i>por empresa</i> , que é o de que o sistema precisa, e é a que etiqueta melhor (Secção 4.3.1).
Alpha Vantage	notícias, segunda fonte	grátis com chave	É a mais fresca das três, e a frescura é o que ataca a queixa de os alertas chegarem tarde.
Polygon	notícias, terceira fonte	grátis com chave	Traz mais títulos exclusivos do que qualquer outra fonte, mas antigos: serve para encher a base de casos, não para alertar.
yfinance	preços diários e intradiários	grátis, sem garantia	É a fonte mais completa sem chave. Falha com frequência, e por isso não é usada sozinha: ver a cadeia abaixo.
Tiingo, Polygon, Alpha Vantage	preços, quando a primeira falha	grátis com chave; Alpha Vantage 25 pedidos/dia	São <i>alternativas de recurso</i> , não fontes principais. A ordem é fixa e o sistema regista qual delas serviu, porque saber a origem de um número faz parte de o poder explicar.
Stooq	era candidato a fonte de preços	grátis	Rejeitado por medição. Foi testado ao vivo e responde com uma verificação anti-robô, o que o torna inutilizável dentro de um processo automático. Fica registado porque parecia servir.
Tiingo, GNews	eram candidatos a fontes de notícias	grátis com chave	Rejeitados por medição. O Tiingo devolve erro de autorização no endpoint de notícias (exige plano pago) e o GNews não é por empresa: é pesquisa por palavras, e usá-lo obrigaria a inferir a empresa a partir do texto.
FNSPID (Dong, Fan e Peng 2024)	o passado: notícias antigas alinhadas com preços	grátis, licença CC BY-SA	É público, é grande, e traz título, data e empresa. O alinhamento com preços que este trabalho usa é construído aqui; comprar histórico de notícias equivalente não era opção.
Sentence-BERT (Reimers e Gurevych 2019)	transformar títulos em vetores	grátis, corre localmente	Modelo já treinado, pequeno o suficiente para caber num contentor de memória limitada. Alternativas maiores e um modelo específico de finanças foram testados e estão medidos no Capítulo 5.
Telegram	entregar o alerta ao telemóvel	grátis, sem limite prático	Tem API de <i>bot</i> sem custo e sem processo de aprovação, e o utilizador subscreve com um clique. Notificações nativas de telemóvel obrigariam a publicar aplicações em duas lojas.
Heroku	manter o sistema a correr sem parar	créditos do <i>GitHub Student Pack</i>	Dá um processo permanente , que é o que o ciclo de 60 segundos exige. É a decisão explicada na Secção 4.8.
GitHub Actions	correr os testes, compilar a dissertação, e guardar o histórico	grátis para repositórios públicos	Serve hoje de rede de segurança do processo permanente, e serviu de <i>motor</i> na primeira versão.

fixa, fica pela primeira que responde e registra sempre qual delas serviu. Sem esta cadeia, um dia em que o Yahoo bloqueia seria indistinguível de um dia em que o mercado não abriu.

4.3.1 Porquê três fontes de notícias, e não a melhor

O sistema começou com uma fonte só, e a pergunta natural é se acrescentar mais compensa. A resposta não é “mais é melhor”: é preciso medir, porque cada fonte custa pedidos e uma fonte generosa mas mal etiquetada não acrescenta nada de aproveitável.

O critério também não pode ser quantas notícias cada uma devolve, mas quantas **sobrevivem ao filtro de relevância** que já está em produção, porque tudo o que é rejeitado à entrada não chega a existir para o sistema. A Tabela 4.2 mede exatamente isso, sobre as doze empresas e três dias.

Tabela 4.2: O que cada fonte gratuita entrega depois do filtro de relevância. A última coluna é a que decide se compensa somar: quantos títulos cada uma traz que *nenhuma* das outras traz.

Fonte	Relevantes	Precisão	Frescura	Cobertura	Exclusivas
Finnhub	432	35%	15.8 h	12/12	401
Alpha Vantage	141	24%	9.3 h	12/12	119
Polygon	429	27%	52.6 h	8/12	418

Três fontes gratuitas com **três forças diferentes**, e é isso, e não o volume, que justifica somá-las:

- o **Finnhub** etiqueta melhor e cobre todas as empresas;
- a **Alpha Vantage** é a mais fresca, com 9.3 horas de mediana contra 15.8, e a frescura é exatamente o que ataca a queixa de os alertas chegarem tarde;
- o **Polygon** traz mais títulos exclusivos do que qualquer outra fonte, incluindo o Finnhub, mas com 52.6 horas de mediana. Serve para *encher a base de casos*, não para alertar, e é assim que está a ser usado.

Juntas dão 970 títulos relevantes distintos, contra os 432 do Finnhub sozinho: mais 125%. Para as empresas menos cobertas a diferença é maior ainda, e são precisamente essas as que o sistema quase nunca conseguia comentar.

Há ainda um segundo motivo, que não é de volume: quando uma fonte falha ou bloqueia, as outras respondem. É a mesma razão pela qual os preços já vinham de uma cadeia e não de uma fonte só.

O que isto não compra. Latência garantida. As três publicam com atrasos próprios, e o ganho num caso concreto depende de qual delas viu a história primeiro. A frescura mediana melhora, e isso está medido; afirmar que os alertas passam a chegar mais cedo em geral exigiria voltar a medir a latência ponta a ponta ao fim de algumas semanas, e isso ainda não foi feito.

Nada disto é escolhido por gosto sem prova. Duas destas linhas mudaram por *medição* e não por opinião: o Stooq foi despromovido depois de se ver o que devolve, e o modelo

4.4. O caminho de uma notícia, do princípio ao fim

de vetores foi comparado com três alternativas antes de ficar. As restantes são escolhas de restrição: são as que cabem em “apenas fontes gratuitas”.

4.4 O caminho de uma notícia, do princípio ao fim

O que acontece, exatamente, entre uma notícia sair e um alerta chegar ao telemóvel?

Esta é a secção central do capítulo, e segue **uma notícia real**: um alerta que o canal enviou a 12 de julho de 2026 sobre a Meta.

“Mark Zuckerberg Said Meta’s AI Bets ‘Haven’t Come to Fruition Yet’ as Shares Fell 5%”

A Figura 4.2 mostra as etapas. A Tabela 4.3 mostra o que aconteceu em cada uma, com os valores que o sistema realmente calculou.




Figura 4.2: As nove etapas. As caixas a tracejado são **portas**: em qualquer uma delas a notícia pode ser descartada e o sistema fica calado. Nove em cada dez varreduras acabam assim.

A etapa 4 merece atenção, e a razão está no que ela devolve. Os três casos recuperados são de **outras empresas** (duas da Nvidia e uma da Microsoft), e o sistema mostra-os na mesma. É deliberado: se a pergunta é “já houve notícias como esta?”, a resposta não tem de vir da mesma empresa. Notícias sobre investimento em inteligência artificial numa tecnológica grande são comparáveis entre si.

E os desfechos foram **em sentidos opostos**: +2.70%, −3.87% e +5.05%. O sistema mostra os três, um a um, exatamente por isso. Se mostrasse só a média, esconderia o que mais importante que há para saber: que casos parecidos deram resultados diferentes.

4.5 O caminho de um movimento de preço

E quando não há notícia nenhuma?

O segundo gatilho é bastante mais curto: todos os dias, depois do fecho, o sistema calcula o z-score de cada empresa da lista, como na Secção 3.4, e basta que um deles ultrapasse o limiar para haver alerta.

É também aqui, e só aqui, que entra a segunda técnica do Capítulo 3. Ao alerta de preço é acrescentada uma linha com a **repartição do movimento**, calculada como a Secção 3.5

Tabela 4.3: O que aconteceu em cada etapa para o alerta da Meta de 12 de julho de 2026. Todos os valores são os que o sistema calculou nesse dia.

Etapa	O que aconteceu
1. Recolher	A varredura foi buscar as notícias da semana para cada empresa da lista.
2. Nomeia a empresa?	O título diz “Meta” e “Mark Zuckerberg”, que estão na lista de nomes da empresa, e não corresponde a nenhum padrão de texto automático. Passa.
3. É recente?	Tem menos de dois dias. Passa: sem esta porta, a mesma notícia alertava dias seguidos.
4. Procurar parecidas	O título é transformado em 384 números e comparado com a base de casos. As três mais parecidas: Microsoft 2023-11-07 (0.46), Nvidia 2023-08-02 (0.51), Nvidia 2023-09-21 (0.46).
5. Evidência forte?	A melhor semelhança é 0.51, acima do chão de 0.45. Passa.
6. Merece avisar?	O modelo de triagem dá 54%. À data deste alerta esse valor era um limiar de corte; hoje serve para ordenar, e quem corta é o orçamento diário. Passa.
7. Já avisei hoje?	É o primeiro alerta desta empresa hoje, e nenhum outro produtor o enviou. Passa.
8. Montar a explicação	O texto é composto a partir dos objetos calculados: o movimento, os três casos passados com o que se seguiu a cada um, e a nota de que isto não é uma previsão.
9. Enviar e registrar	Enviado ao canal e guardado no registo partilhado, de onde a página web o vai buscar depois.

descreve, do género “*NFLX -2.11% hoje = -0.08% mercado · -0.32% setor · -1.71% da própria empresa*”, seguida de uma frase em palavras que nomeia a maior parcela. É a resposta à segunda das três perguntas fundadoras, entregue em números dentro da mensagem.

Não aparece no alerta de notícia, e a razão é que a repartição é do *movimento do dia*: sem movimento não há o que repartir. Quando a estimação da sensibilidade ao mercado falha, a linha sai na mesma mas diz que assumiu sensibilidade 1.0 e que a repartição é indicativa, em vez de calar a incerteza.

Duas capacidades foram acrescentadas depois de o sistema estar a funcionar, e ambas por observação:

Níveis de severidade. Um *z* de 1.6 e um *z* de 3.2 não são a mesma coisa, e o texto do alerta passou a distingui-los em palavras (“assinalável”, “forte”, “extremo”) em vez de dar o mesmo aviso aos dois.

Comparação com os pares. Um alerta que diz “a empresa caiu 8%” sem dizer que o setor inteiro caiu é enganador. O sistema passou a olhar para as outras empresas do mesmo setor no mesmo dia, e a dizê-lo.

Esta segunda correção veio de ler os primeiros trinta alertas enviados. Em nove deles o texto **contradizia-se**: uma linha dizia que o movimento parecia ser do setor inteiro, e duas linhas abaixo a repartição dizia que a maior parte pertencia à empresa. As duas linhas estavam certas isoladamente: a comparação com os pares olhava apenas para a *direção* do movimento dos vizinhos, nunca para a sua *dimensão*. Passou a olhar para as duas.

4.6 As portas: quando o sistema decide calar-se

Porque é que o sistema não avisa de quase nada?

Porque avisar de tudo é o mesmo que não avisar de nada. Se o canal enviar quinze mensagens por dia, a pessoa deixa de as ler, e o sistema perde o único valor que tinha para dar.

As cinco portas da Figura 4.2 existem precisamente para isso, e o efeito conjunto delas é grande: numa janela medida em produção, das **944** notícias relevantes que entraram saíram **42** alertas, ou seja cerca de uma em cada vinte e duas.

Vale a pena ver isto num dia concreto, com os números lidos do registo do próprio sistema. A Tabela 4.4 mostra as avaliações registadas a 15 de agosto de 2026.

Tabela 4.4: Onde morreram as avaliações registadas a 15 de agosto de 2026. São as 5060 que o registo continha no momento em que foi lido, o que é parte de um dia e não o dia inteiro. O que se lê aqui são proporções, não totais. A coluna da direita é a parte que interessa.

Onde morreu	Avaliações	O que é
Sem precedente forte	2 994	nenhum caso passado acima do chão de semelhança
Abaixo do piso da triagem	1 194	o modelo pontuou abaixo do mínimo
Piso escalonado	269	o segundo alerta do dia exigia pontuação mais alta
A mesma história	249	já contada por outras palavras
Orçamento esgotado	21	o dia já tinha gasto os cinco alertas
Sobreviveu às portas	333	ver a ressalva
Mensagens entregues	5	o orçamento do dia, gasto por inteiro

E a ressalva é um defeito que encontrei ao construir esta tabela. Cinco mil avaliações e cinco mensagens: a proporção está certa e é o comportamento pretendido. Mas a linha dos 333 não queria dizer o que parecia. O sistema reavalia os mesmos títulos de 60 em 60 segundos, e um título que já tinha sido entregue nesse dia voltava a passar todas as portas a cada minuto. Era travado no fim, por uma verificação de “isto já foi enviado” que **não estava registada como uma etapa**, ao contrário de todas as outras.

Resultado: a vista que existe para tornar as decisões do sistema inspecionáveis dizia “alerta enviado” 333 vezes num dia em que enviou 5 mensagens. Não é um erro de contagem inofensivo: é a mesma classe de defeito que a tabela abaixo documenta para as outras portas, sobrevivendo na única que ficou por instrumentar.

Está corrigido: a supressão passou a ser uma etapa com nome próprio, como as outras, e existe um teste que falha se voltar a desaparecer. Os números da tabela são os de *antes* da correção, e sabe-se que são: o registo não contém uma única linha da etapa nova, quando 333 sobreviveram às portas e apenas 5 foram enviadas.

Cada porta tem uma constante associada, e é justo perguntar de onde vêm esses números. A Tabela 4.5 responde, incluindo quando a resposta é “foi escolhido”.

O chão de semelhança merece um parágrafo próprio, porque é a porta que trava mais casos e a que tem a justificação mais fraca. Numa varredura medida, quando a lista vigiada ainda

Tabela 4.5: Cada porta, e de onde vem o valor que usa. A primeira não tem valor nenhum, porque é uma regra de texto e não um limiar. A porta “já avisei hoje” não aparece porque não tem constante nenhuma, e o orçamento diário aparece porque, apesar de atuar depois das portas da figura, é hoje quem verdadeiramente corta. Distinguir “derivado” de “escolhido” é uma questão de honestidade: os dois casos defendem-se de maneiras diferentes.

Porta	Valor	De onde vem
Nomeia a empresa	—	Regra escrita depois de ler os primeiros alertas e ver o que passava.
É recente	2 dias	Escolhido: cobre um fim de semana.
Evidência forte	0.45	Escolhido , e é a porta mais agressiva de todas (ver abaixo).
Merece avisar	50%	Derivado de uma análise de custos, que dá 0.49 quando falhar um movimento e dar um falso alarme custam o mesmo; o valor implantado foi arredondado à mão para 0.50. Hoje já não veta : serve para <i>ordenar</i> as candidatas, e quem corta é o orçamento diário.
Orçamento diário	5/dia	Escolhido, e é hoje o verdadeiro controlo de volume. Mas os cinco lugares são gastos por ordem de chegada , e não pelas cinco melhores do dia: a decisão é tomada de ciclo em ciclo, sem saber o que a tarde ainda traz. A pontuação ordena as candidatas <i>do mesmo ciclo</i> , e é o piso escalonado que encarece cada lugar seguinte. Veio corrigir um teto de duas por empresa, que limitava cada nome e não o total.
Piso escalonado	0.49 e 0.64	Derivados da mesma análise de custos, para dois rácios diferentes: o primeiro alerta do dia de uma empresa exige 0.49 e o segundo exige 0.64. A ideia é que o segundo aviso do mesmo nome no mesmo dia tem de valer mais do que o primeiro, porque o custo dominante deixa de ser falhar um movimento e passa a ser cansar quem lê.

tinha dez nomes, sete deles foram travados exatamente ali, e quatro por 0.04 ou menos de diferença. Testei depois se um valor mais alto de semelhança correspondia a precedentes mais informativos, e **não corresponde**: a concordância de direção entre o caso passado e o caso atual fica ao nível do acaso dos dois lados do limiar. A conclusão honesta é que este número serve para *controlar o volume* de alertas e para garantir coerência de tema, e não para escolher casos que preveem melhor. Fica dito assim.

4.7 Como o alerta é explicado

O que é que a pessoa recebe, e porque é que se pode fiar?

O alerta não é uma frase. É uma pequena estrutura, sempre com as mesmas partes e sempre pela mesma ordem:

1. **o facto**: o que aconteceu, em números, e a fonte;
2. **os casos passados**: um a um, com data, semelhança e o que se seguiu a cada um;
3. **a ressalva**: que isto é história observada e não uma previsão;
4. **a estimativa**: a probabilidade de o mercado reagir, e nunca em que direção.

A ordem importa, e cada extremo foi escolhido. A pessoa lê primeiro o que aconteceu e só depois a estatística, porque é assim que uma pessoa pensa; um alerta que abre com “ $z = 2.65$ ” perde o leitor na primeira linha. E a estimativa fica em **último**, porque é o único número da mensagem que olha para a frente: quem parar de ler antes dela fica com factos e com histórico, que é exatamente o que este trabalho quer entregar.

No alerta de movimento de preço a primeira parte traz também a razão estatística, em linguagem simples, porque aí o que aconteceu é o movimento; no alerta de notícia esse lugar é ocupado pelo título e pela ligação para o artigo.

Importa também a *quantidade*. O sistema mostra três precedentes e não os trinta que encontrou, e essa não é uma decisão de espaço no ecrã: a investigação sobre explicação estabelece que as pessoas procuram razões seletivas e contrastivas, e não uma enumeração exaustiva de tudo o que contribuiu (Miller 2019). Uma lista com trinta casos seria mais completa e menos útil, porque a pessoa não a leria. Pela mesma razão o alerta exhibe as quantidades exatas por detrás da decisão e não o cálculo inteiro que as produziu.

A Figura 4.3 mostra um alerta **tal como foi entregue**, copiado do registo do canal. A mesma informação fica disponível numa página web, que serve para consultar o que foi enviado e, sobretudo, o que *não* foi: é aí que vive o registo das decisões descrito na Secção 4.6. A Figura 4.4 mostra as duas metades, capturadas da aplicação em funcionamento. A interface em si não é uma contribuição deste trabalho, e por isso não se descreve aqui o seu desenho; mostra-se porque é o único sítio onde o *silêncio* do sistema é visível.

A empresa da figura é um caso instrutivo, e o que o torna instrutivo é a discordância entre a percentagem e a repartição. A ação estava a descer 0.41%; o mercado e a própria empresa estavam ligeiramente em alta, +0.08% e +0.07%; e o que a puxava para baixo era o **setor**, com -0.56%. A percentagem sozinha diz a *Johnson & Johnson desceu* e convida a procurar uma razão na empresa, onde não há nenhuma. É esta a diferença que a segunda pergunta do trabalho existe para tornar visível.

Repare-se ainda que o veredicto termina em “*so far today*”: a captura é de meio da sessão americana, não de um fecho, e o sistema di-lo em vez de apresentar um número em curso como se fosse definitivo.

```
[1] News alert for AMZN (Amazon) (2026-08-13)
    "Prediction: Amazon Will Join Apple in the $4 Trillion Club Before 2030"

[2] 3 similar past headlines. Their 5-day move ranged -2.73% to -2.73%
    (average -2.73%):
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "If You Invested $100 In Apple
      Stock 10 Years Ago, You Would Have This Much Today" (sim 0.56)
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "Apple's Selloff Is Overdone"
      (sim 0.51)
    -2.73% in 5d · AAPL 2026-08-05 (8d ago) · "Apple's Buyback Is Retiring
      Less Stock Just As The Memory Bill Grows" (sim 0.47)

[3] 3 of 3 shown cases moved down - topic-similar past cases, not a
    prediction for this news (an observed pattern, not a forecast).
    Observed past outcomes after similar news, not a price prediction and
    not advice.

[4] Materiality estimate (learned triage): 57% chance of an unusually
    large move over the next few days, in EITHER direction - raised by
    recent volatility (20d) and sector; lowered by today's own move and
    recent momentum (5d). This estimates whether the market reacts, never
    which way: it is not a price forecast and not advice.
```

Figura 4.3: Um alerta enviado ao canal a 13 de agosto de 2026, copiado do registo sem edição. Os números entre parênteses rectos marcam as quatro partes da lista acima, pela ordem em que saem. Todos os valores vêm dos objetos que os calcularam: a semelhança do motor de recuperação, o movimento a cinco dias da medição de impacto, e os 57% do modelo calibrado. **Repare-se em [1]:** o título citado é ele próprio uma previsão, com alvo e data. É conteúdo de terceiros reproduzido *verbatim*, e não uma frase do sistema; a Secção 3.9.3 explica porque é que a garantia de não previsão se aplica ao que o sistema escreve e não ao que ele cita, e que limitação isso deixa em aberto.

Uma nota sobre o número que aparece na última linha do alerta. Os 57% não são a pontuação em bruto do modelo: são o resultado de a converter numa *probabilidade*, ajustando uma sigmoide sobre um bloco de validação reservado (Niculescu-Mizil e Caruana 2005). A distinção não é decorativa neste contexto. Uma pontuação em bruto ordena bem e não significa nada por si, ao passo que uma probabilidade calibrada pretende que, entre os títulos a que o sistema atribui 57%, aproximadamente essa fração tenha mesmo um movimento invulgar. É a diferença entre um número que se pode mostrar a alguém e um número que só serve por dentro.

Convém, porém, não prometer mais do que se cumpre. A Secção 5.6 reporta o erro médio desta probabilidade, mas a Secção 3.7.6 regista uma limitação que esse erro médio não revela: a calibração é ajustada num bloco com mais casos importantes do que aquele a que é aplicada, e por isso o valor anunciado é cerca de cinco pontos percentuais otimista. A ordenação entre notícias não é afetada, porque a transformação preserva a ordem; o número absoluto é.

E este exemplo mostra um defeito que eu não tinha visto até o pôr aqui. Os três precedentes têm o *mesmo* impacto, -2.73% , e a mesma data. Não é coincidência: o impacto é medido por **(empresa, dia)**, logo três títulos da mesma empresa no mesmo

4.7. Como o alerta é explicado




Figura 4.4: A página, capturada da aplicação em funcionamento a 20 de agosto de 2026, com a sessão americana a decorrer. **Em cima**, uma empresa. **Em baixo**, as decisões do dia inteiro, pela ordem por que são tomadas, com a margem que faltou quando existe.

dia partilham o mesmo valor por construção. A frase “3 of 3 shown cases moved down” apresenta como concordância entre três casos aquilo que é **um dia observado três vezes**.

Medido sobre os 247 alertas de notícia com precedentes já entregues: em 36.8% deles os casos mostrados assentam em menos dias distintos do que casos exibidos, e em 11.3% os três são o mesmo dia. Dos 120 alertas que afirmam unanimidade, 23.3% apoiam-se num único dia.

Isto **não afeta** nenhum número reportado no Capítulo 5: a precisão@5 conta títulos e a concordância de direção é medida par a par sobre o corpus histórico. Afeta a força que o *alerta* reivindica quando fala ao utilizador, e fica registado como limitação por isso.

E a garantia que sustenta tudo isto é de construção, não de boa vontade: **cada número do texto vem do objeto que o calculou**. O texto é montado a partir dessas peças. Não é possível o alerta dizer +4.47% e o sistema ter calculado outro valor, porque só existe um sítio onde esse valor existe.

4.8 Onde isto corre, e o que isso custou

Como é que um sistema destes se mantém a funcionar sem servidor pago?

A primeira versão corria no agendador do **GitHub Actions**, configurado para disparar de meia em meia hora nos dias úteis. Funcionava, e tinha um problema que só se vê a usar: **os alertas chegavam tarde**. Esse agendador é de *melhor esforço* para repositórios gratuitos: quando os executores partilhados enchem, a corrida é saltada. Na prática corria de hora e meia em hora e meia.

A solução veio do plano do ISEP: o *GitHub Student Developer Pack* dá créditos de **Heroku**, que permitiram passar de um agendador para um **processo permanente**. O ciclo passou a correr de **60 em 60 segundos**.

A Figura 4.5 mostra onde cada peça corre depois dessa mudança, porque a arquitetura de execução não é óbvia e tem uma consequência que descobri à minha custa.




Figura 4.5: Os dois processos do Heroku não partilham disco. Tudo o que tem de sobreviver a um reinício, ou de ser visto pelo outro processo, passa pela **branch de dados** no GitHub.

A consequência, e é um defeito que encontrei e corrigi. Os dois processos correm em máquinas separadas e o disco de cada uma é apagado a cada reinício. Isso está escrito na documentação do serviço e eu sabia-o. Mesmo assim, dois dos ficheiros de registo, o do funil e o das decisões de triagem, estavam a ser escritos **apenas em disco local**. Resultado:

o processo que serve a página mostrava uma semana atrasada, e o registo que alimenta a validação posterior tinha deixado de crescer. Ambos passaram a ser publicados na branch de dados a cada ciclo.

4.8.1 O sistema aprende com o que vai vendo, e quase não aprendia

Há uma parte do desenho que só faz sentido com o tempo a passar. Todo o título relevante que a varredura vê é guardado como **candidato a precedente futuro**. Passados oito dias, quando o impacto no preço já é observável, esse candidato é medido com a mesma regra de alinhamento do Capítulo 3 e entra na base de casos. A base cresce sozinha, e os alertas de amanhã comparam-se contra o que o sistema viu ontem. A Figura 4.6 mostra o ciclo.




Figura 4.6: O que acontece a um título entre ser visto e poder servir de precedente. A espera de oito dias existe porque o impacto de um caso só é observável depois de o preço se mover, e medi-lo antes seria deixar o caso conhecer o seu próprio desfecho. Este ciclo mantém atualizada a **evidência** que o sistema mostra, e não os pesos do modelo: nada aqui re-treina nada.

Convém situar o que este mecanismo é e o que não é. Ele mantém atualizada a *base de casos*, ou seja a evidência que o sistema mostra, mas não re-treina modelo nenhum: os pesos da triagem são os que foram aprendidos uma vez. A literatura de deriva de conceito trata precisamente do problema de um modelo implantado deixar de corresponder aos dados que passa a ver, e organiza as respostas em deteção da mudança e adaptação a ela (Gama et al. 2014). Deste par, este sistema tem a primeira metade, porque mede a deriva, e não tem a segunda.

Isso é o desenho. Fui verificar se estava a acontecer, e não estava.

A base de casos viva estava congelada havia **dezanove dias**, e havia 1 785 candidatas de julho ainda por maturar, quando a maturação precisa de oito. O sistema captava centenas de casos por ciclo e **nenhum** chegava a ser convertido em precedente utilizável.

A causa é a mesma que já tinha atingido dois ficheiros de registo: no serviço de alojamento, o processo que serve a página e o que faz as varreduras são *máquinas separadas*, e o disco de cada uma é apagado quando ela reinicia. Tudo o que tem de sobreviver a um reinício passa pelo repositório de dados, e estes dois ficheiros não passavam.

Convém dar nome a esta classe de falha, porque ela não é uma distração minha e repete-se em sistemas muito maiores do que este. D. Sculley et al. (2015) descrevem, a partir de experiência com sistemas de aprendizagem em produção, um custo de manutenção que

não aparece em nenhuma métrica de qualidade, e cujos sintomas incluem exatamente este. Entre os factores de risco que enumeram estão as *dependências de dados* instáveis e o emaranhamento entre componentes; o caso aqui é uma variante deles, em que a correção de uma peça depende de uma suposição sobre outra que ninguém escreveu em lado nenhum. Aqui a suposição era “o ficheiro que escrevi continua lá amanhã”, e ela é verdadeira na máquina de quem desenvolve e falsa no contentor. Nenhum teste podia apanhá-la, porque cada peça cumpria o seu contrato, e nenhum erro foi registado, porque escrever no disco local nunca falhou.

Mas a correção não podia ser a mesma, e é isso que torna o caso interessante. Os registos que já eram publicados a cada ciclo pesam menos de um megabyte. Estes pesam 16.6 e 11.9 megabytes. Publicá-los de sessenta em sessenta segundos seriam dezenas de *gigabytes* por dia de tráfego, o que é insustentável e é, muito provavelmente, a razão pela qual ninguém os tinha publicado.

A solução separa os dois problemas que estavam a ser confundidos: **semear** no arranque, para o contentor não começar do zero, e **publicar com um intervalo mínimo** de trinta minutos, em vez de a cada ciclo. O que se perde fica dito: até trinta minutos de capturas, se o contentor reiniciar nesse intervalo. É uma perda pequena e recuperável, porque o mesmo título volta a ser captado na varredura seguinte enquanto estiver dentro da janela de frescura.

4.8.2 Trinta e oito mil casos que não cabiam na memória

O sistema tinha, guardado, um ano inteiro de notícias reais com o impacto já medido: 38 214 casos. Não os usava, por duas razões que se descobriram uma de cada vez.

A primeira era simples: faltavam-lhes os vetores. Foram calculados com o mesmo modelo do produto, e o procedimento **recusa-se a escrever** se esse modelo não estiver disponível, porque vetores de outro modelo seriam incomparáveis com a base de produção e isso é pior do que não os ter.

A segunda apareceu ao medir, e é uma lição de engenharia que vale por si. Está na Tabela 4.6.

Tabela 4.6: Custo de memória para os mesmos 38 214 vetores de 384 dimensões. O contentor de produção tem 512 MB.

Como está guardado	Memória	Carregar
Listas de números em Python (o que o formato de texto produz)	655 MB	9.0 s
Matriz de precisão dupla	112 MB	—
Matriz de precisão simples, mapeada do disco	25 MB	0.44 s

Em formato de texto a base **não arrancava**: pedia mais memória do que o contentor tem. E o problema não era o volume dos dados. As mesmas $38\,214 \times 384$ posições valem 56 MB de números de precisão simples, mas ocupavam 655 MB porque cada número era um objeto individual de Python dentro de uma lista, e cada objeto desses carrega o seu próprio cabeçalho: são 11.7 vezes o tamanho do conteúdo, gastas em contabilidade.

Guardando-os como uma matriz mapeada do disco, o processo passa a pagar 25 MB, ou seja 26 **vezes menos** do que a versão em texto, e menos ainda do que os 56 MB do conteúdo em

bruto, porque o sistema operativo carrega apenas as páginas que forem lidas. A diferença está toda na forma de guardar.

A mesma medição revelou um desperdício que ninguém tinha notado: a comparação com os casos passados reconstruía a matriz *inteira* a cada consulta. Passou a ser carregada uma vez.

Uma nota sobre até onde isto escala, porque é a pergunta seguinte. A procura continua a ser **exaustiva**, ou seja compara a consulta com os 38 214 casos todos, e a esta dimensão isso custa menos de um segundo e tem a vantagem de o resultado ser exato. Se a base crescesse uma ou duas ordens de grandeza, a substituição conhecida é um índice aproximado (Johnson, Douze e Jégou 2021), que troca uma garantia de exatidão por tempo de resposta sem alterar a representação. Não foi feito porque ainda não é preciso, e trocar exatidão por velocidade que não faz falta seria pagar um custo sem comprar nada.

O efeito no produto é o que se esperaria de multiplicar a base por vinte: os precedentes que o alerta mostra passaram a ser da própria empresa e sobre o mesmo assunto, com semelhanças acima de 0.7 onde antes apareciam casos de outra empresa a 0.46.

E o GitHub Actions não desapareceu. Continua a desempenhar três funções: corre os testes a cada alteração de código (Integração Contínua (CI)), compila esta dissertação, e mantém um agendador de reserva que dispara nos mesmos horários. Se o processo permanentemente parar, o sistema degrada para o comportamento da primeira versão em vez de ficar mudo, e o mecanismo que evita alertas repetidos garante que os dois não enviam a mesma coisa duas vezes.

O resultado está na Tabela 4.7, e é mais informativo do que a decisão:

Tabela 4.7: Latência medida sobre os alertas entregues. As duas primeiras linhas separam as duas eras; as duas últimas repartem o percurso e são medidas sobre o conjunto *inteiro*, as duas eras juntas, e por isso não se subtraem às de cima. O tempo está quase todo na *descoberta*, não na entrega.

Medição	Valor	Casos
<i>Por era, sobre o percurso completo</i>		
Mediana, com o agendador gratuito	196 min	28
Mediana, com o ciclo de 60 segundos	143 min	73
<i>As duas eras juntas, repartindo o percurso</i>		
Da publicação até o sistema detetar	≈ 158 min	101
Da deteção até a mensagem chegar	≈ 1 s	101

O ciclo comprou **53 minutos**, e não as duas horas que eu esperava. A razão está nas duas últimas linhas: quase todo o tempo é gasto *até a notícia aparecer na fonte gratuita*, e nada do lado da infraestrutura muda isso. Depois de o sistema ver a notícia, a mensagem chega em cerca de um segundo.

Isto é uma limitação real e fica escrita como tal. Comprar um serviço de notícias em tempo real resolveria, e violaria a restrição fundadora do trabalho. Preferi ter uma limitação medida a ter uma capacidade comprada.

4.9 O ciclo de vida do modelo, e o que nele é meu

Onde é que está, concretamente, a engenharia de inteligência artificial deste trabalho?

É uma pergunta justa, e merece uma resposta reunida num sítio só, porque as peças estão espalhadas por três capítulos e obrigar quem lê a juntá-las é uma forma de não responder.

Começo pela parte incómoda. Este sistema treina **um** modelo, e esse modelo é uma regressão logística com nove entradas que, medida contra uma linha de base de uma só variável, **perdeu**. Se a pergunta for *quantos modelos treinou?*, a resposta é um, e é pequeno.

A engenharia não está no tamanho do modelo. Está no que foi preciso construir para que aquele número, e a conclusão negativa que ele sustenta, sejam de confiança. Essa construção tem sete peças, e cada uma existe porque a sua ausência produziria um resultado bonito e falso. A Figura 4.7 mostra as duas metades do ciclo.




Figura 4.7: As duas metades do ciclo. Em cima, construir: os dados são rotulados, a divisão é cronológica, a calibração é ajustada na validação, e o bloco de teste é usado no fim. Em baixo, observar: o modelo que corre é o mesmo que foi avaliado, cada decisão fica registada, e dias depois é confrontada com o que o preço realmente fez. O elo a tracejado é o que fecharia o ciclo e **não existe**: a deriva é medida e não corrigida, e a Secção 6.5 diz o que faria falta para a corrigir.

- 1. O conjunto de dados é construído, não encontrado.** O FNSPID dá títulos com data; os preços vêm de outro lado. Alinhar as duas coisas, decidir a que dia de negociação pertence uma notícia de sábado, e derivar o rótulo a partir do movimento futuro, é o trabalho que produz as 79 753 linhas da Secção 3.3. Nenhuma delas existia antes.
- 2. O rótulo é uma decisão, e é declarado como tal.** “Houve movimento anormal nos três dias seguintes” não é um facto que estivesse nos dados: é uma definição, com um limiar e um horizonte escolhidos por quem constrói. Por isso a Secção 5.6 não se fica por essa escolha e mede **nove** definições alternativas.
- 3. A separação temporal é imposta por um teste, não prometida.** A divisão é cronológica com embargo, e existe um teste automático que altera o futuro de um exemplo e exige que as entradas fiquem iguais e o rótulo mude. É a diferença entre afirmar que não há fuga e ter onde a ir buscar se houver.
- 4. As probabilidades são calibradas, e o seu enviesamento está medido.** O modelo devolve um número entre zero e um, e esse número é usado para ordenar e para cortar. A calibração de Platt é ajustada num bloco reservado, e o Capítulo 5 declara que a prevalência da validação não é a do teste, o que desloca a escala.

5. **Os artefactos existem e estão versionados.** O modelo treinado, o calibrador e um ficheiro que descreve a corrida (dimensão de cada bloco, prevalência, semente, métricas) vivem no repositório. Uma métrica sem o artefacto que a produziu não é reproduzível; é uma afirmação.
6. **O modelo implantado é o modelo avaliado.** Isto parece trivial e não é. O codificador de frases usado na avaliação corre sobre uma biblioteca pesada que não cabe no contentor de produção. Em vez de trocar por outro modelo, o que faria a dissertação descrever um sistema que ninguém usa, exportou-se o *mesmo* modelo para um formato leve, e mediu-se a fidelidade da conversão. A alternativa fácil era mais rápida e teria invalidado o Capítulo 5.
7. **O que corre é observado.** Cada decisão de triagem é registada. Dias depois, quando o preço já disse o que fez, um segundo procedimento rotula essas decisões com a mesma regra do treino e mede se o modelo está a ajudar. Foi assim que se soube que *não* está, e é a Secção 5.6 que o reporta. A deriva das entradas é medida pelo mesmo espírito.

4.9.1 O que é meu, e o que é consumido

A distinção interessa, e escondê-la seria fácil.

Consumido de fora: um codificador de frases pré-treinado, e mais nada em matéria de modelos. Não foi ajustado, não foi treinado, e o trabalho não reivindica nada sobre ele além de o ter escolhido *por medição*, contra quatro alternativas: um modelo maior, dois codificadores mais recentes, e um modelo específico de finanças, que foi o pior de todos. É uma dependência **essencial**: sem representação de frases não há recuperação semântica. É também **substituível**: a interface que o isola tem uma implementação de reserva que degrada para sobreposição de palavras quando o modelo não está disponível.

Construído aqui: o conjunto de dados rotulado, o alinhamento anti-fuga, o detetor e a sua janela protegida, a decomposição com encolhimento, a base de casos com impacto medido, o modelo de triagem e a sua calibração, as portas de decisão com as constantes derivadas, a camada de explicação amarrada aos objetos calculados, e o ciclo de observação que mede o sistema depois de implantado.

Deliberadamente ausente: não há aqui um modelo de linguagem a escrever texto para o utilizador, pela razão que a Secção 2.4 desenvolve e que atravessa o trabalho: uma frase gerada é uma afirmação, e este sistema entrega afirmações com a evidência ao lado.

4.9.2 O que este ciclo não tem

Duas coisas, e as causas são diferentes.

Não há re-treino. Os pesos são de 2018–2023 e não voltaram a ser ajustados, apesar de a deriva estar medida. Seria possível, porque os rótulos novos vêm dos preços: o que impede não é a técnica, é que re-treinar com o registo de produção mudaria os números que este documento reporta, e isso precisa de tempo para ser avaliado. Fica como trabalho declarado.

Não há verdade humana. Os três rótulos deste trabalho, ou seja movimento anormal, mesmo setor e percentil de movimento, são aproximações verificáveis que nunca foram confrontadas com o julgamento de uma pessoa. É a limitação de que mais dependem as outras, e o Capítulo 6 volta a ela.

Capítulo 5

Avaliação

5.1 Como está montado este capítulo

O que é que vale como prova?

Cada uma das três perguntas de investigação tem aqui a sua secção. Todas seguem a mesma forma, de propósito:

1. a pergunta;
2. como foi medida, e contra que alternativa;
3. o resultado;
4. **o que este resultado não permite concluir.**

O quarto ponto é o que separa uma avaliação de uma demonstração. Todos os números deste capítulo são produzidos por procedimentos automáticos com semente fixa: correr outra vez sobre os mesmos dados dá exatamente os mesmos valores.

Falta explicar uma assimetria, antes que ela pareça um esquecimento. O Capítulo 3 descreve *quatro* técnicas e este capítulo tem *três* perguntas de investigação. A técnica que fica de fora é a decomposição de um movimento, e a razão por que fica é metodológica e não de conveniência: não existe resposta certa contra a qual a comparar. A Secção 5.4 trata-a à parte e explica o que, nela, ainda assim se pode medir.

5.2 Como se lê cada número deste capítulo

Antes de ver os resultados: o que é que cada medida quer dizer, e como é calculada?

Esta secção existe porque um resultado só vale o que vale a medida que o produziu. Um número como " $F_1 = 0.530$ " não diz nada a quem não sabe o que é o F_1 , e um leitor que aceite esse número sem o compreender não está a avaliar o trabalho: está a confiar nele. Percorro por isso cada medida usada, com a fórmula, com o que ela premeia, e com a conta feita até ao valor que aparece mais à frente.

5.2.1 As quatro maneiras de acertar e de errar

Todas as medidas deste capítulo, à exceção de uma, assentam na mesma ideia de partida. O sistema faz uma afirmação sobre um dia, a realidade tem uma resposta, e há quatro combinações possíveis. Estão na Figura 5.1 e o nome habitual deste quadro é **matriz de confusão**.

	a realidade: invulgar	a realidade: banal
o sistema assinala	Verdadeiro positivo (VP) assinalou, e o dia era mesmo invulgar	Falso positivo (FP) assinalou, e o dia era banal <i>(alarme falso)</i>
o sistema cala-se	Falso negativo (FN) calou-se, e o dia era invulgar <i>(escapou)</i>	Verdadeiro negativo (VN) calou-se, e o dia era mesmo banal

Figura 5.1: A matriz de confusão. As duas células cinzentas são acertos; as duas alaranjadas são os dois erros possíveis, e **custam coisas diferentes**. Um falso positivo gasta a atenção de quem lê; um falso negativo deixa passar o dia que interessava.

A distinção que importa é a última. Os dois erros não são simétricos, e nenhuma medida única os resume sem escolher uma prioridade. É por isso que se usam duas medidas em vez de uma.

5.2.2 Precisão e cobertura

A **precisão** responde a: *das vezes que o sistema falou, quantas tinha razão?*

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (5.1)$$

A **cobertura**, também chamada *recall*, responde a uma pergunta diferente: *dos dias que eram mesmo invulgares, quantos é que o sistema apanhou?*

$$\text{Cobertura} = \frac{VP}{VP + FN} \quad (5.2)$$

Repare-se em que o denominador muda: a precisão divide pelo que o sistema *disse*, ao passo que a cobertura divide pelo que *existia*. São por isso perguntas diferentes, e nada impede que deem respostas opostas sobre o mesmo detetor.

E é exatamente isso que acontece neste trabalho, o que torna o exemplo particularmente útil. A regra do limiar fixo, aquela que assinala qualquer movimento acima de 3%, obtém uma cobertura de 0.992: apanha praticamente todos os dias invulgares que existiam. Vista só por esse número parece excelente. Mas a sua precisão é de 0.122, ou seja, **de cada cem vezes que fala, tem razão doze**. Apanha tudo porque fala quase sempre, e uma regra que fala quase sempre não está a detetar nada.

Este par de números é a razão de ser da secção seguinte: é preciso uma medida que não se deixe enganar por nenhum dos dois extremos.

5.2.3 O F_1 : obrigar as duas a andarem juntas

O F_1 combina precisão e cobertura numa só medida através da **média harmónica**:

$$F_1 = 2 \cdot \frac{\text{Precisão} \times \text{Cobertura}}{\text{Precisão} + \text{Cobertura}} \quad (5.3)$$

A escolha da média harmónica, e não da média habitual, é deliberada, e a razão é instrutiva. A média aritmética de 0.122 e 0.992 é 0.557, um valor que faria a regra do limiar fixo parecer razoável. A média harmónica **puxa para baixo em direção ao pior dos dois**, e por isso só dá um valor alto quando *ambos* são altos. É uma medida que não deixa comprar cobertura à custa de precisão.

Vejamos a conta completa, com os dois detetores, exatamente como os valores aparecem mais à frente.

Para o limiar fixo, com precisão 0.122 e cobertura 0.992:

$$F_1 = 2 \cdot \frac{0.122 \times 0.992}{0.122 + 0.992} = 2 \cdot \frac{0.1210}{1.114} = \frac{0.2420}{1.114} = 0.217$$

Com estas duas casas a conta dá 0.217, e a tabela do resultado reporta 0.218. A diferença é o arredondamento: a precisão e a cobertura são mostradas com três casas mas o valor foi calculado com todas. Fica dito porque um leitor que refaça a conta chega ao meu 0.217, e um número que não fecha sem explicação é pior do que um número com uma casa a mais.

Para o z-score, com precisão 0.381 e cobertura 0.800:

$$F_1 = 2 \cdot \frac{0.381 \times 0.800}{0.381 + 0.800} = 2 \cdot \frac{0.3048}{1.181} = \frac{0.6096}{1.181} = 0.516$$

São estes os dois valores que a Secção 5.3 reporta, e a comparação entre eles mostra a média harmónica a fazer exatamente o seu trabalho: o z-score tem *menos* cobertura do que o limiar fixo e ainda assim ganha com folga, porque triplica a precisão e o F_1 recusa-se a deixar comprar uma à custa da outra.

5.2.4 A precisão@k: avaliar uma lista curta

A recuperação de precedentes não devolve uma decisão de sim ou não: devolve uma **lista ordenada**. E o utilizador não lê a lista toda, lê as primeiras. Por isso se usa uma medida sensível à ordem, como é prática estabelecida em recuperação de informação (Manning, Raghavan e Schütze 2008), e a mais direta dessas medidas olha apenas para o topo da lista. É o que a **precisão@k** faz:

$$\text{Precisão@k} = \frac{\text{número de casos relevantes entre os } k \text{ primeiros}}{k} \quad (5.4)$$

Neste trabalho $k = 5$, porque cinco é a ordem de grandeza do que cabe num alerta sem o tornar ilegível. Um caso recuperado conta como relevante se pertencer ao mesmo setor da notícia de consulta, com a restrição adicional de ter de ser de **outra empresa**, pelas razões dadas na Secção 5.5.

A Figura 5.2 mostra a conta para uma consulta.




Figura 5.2: Uma consulta devolve cinco casos; três são do mesmo setor. A medida é a fração, e faz-se a média sobre muitas consultas. Note-se que **a ordem dentro dos cinco não conta**: esta medida pergunta quantos acertou, não se pôs os melhores à frente.

Falta um número sem o qual a medida não se interpreta: **qual é o valor de quem escolhe ao acaso?** Não é zero. Como há cinco setores e alguns são maiores do que outros, uma escolha aleatória acerta uma fração apreciável das vezes apenas por sorte, e esse chão, uma vez medido, vale 0.240. É contra ele, e não contra zero, que qualquer método tem de ser lido.

5.2.5 A PR-AUC: a lista toda, em todos os pontos de corte

O modelo de triagem não devolve uma decisão: devolve uma **probabilidade** para cada notícia. Para transformar isso numa decisão é preciso escolher um limiar, e o valor da precisão e da cobertura muda conforme o limiar escolhido.

Se o limiar for muito baixo, o sistema alerta quase sempre: a cobertura sobe e a precisão desce. Se for muito alto, alerta quase nunca: a precisão sobe e a cobertura desce. Cada limiar possível dá, portanto, um par (cobertura, precisão), e o conjunto de todos esses pares desenha uma curva. É a **curva de precisão–cobertura**, e a Figura 5.3 explica como se lê.




Figura 5.3: Cada ponto da curva é um limiar de decisão diferente. Um modelo melhor mantém a curva alta durante mais tempo antes de cair. A área debaixo da curva resume esse comportamento num só número, sem obrigar a escolher um limiar.

A **Precision-Recall Area Under the Curve (PR-AUC)** é a área debaixo dessa curva. O seu valor está entre 0 e 1, e a grande vantagem é resumir o modelo em *todos* os limiares de uma vez, em vez de o julgar num limiar escolhido à mão, que seria uma decisão arbitrária a contaminar a comparação.

Há aqui uma propriedade que convém conhecer, porque é o que torna esta medida interpretável. **O chão da PR-AUC não é zero: é a proporção de casos positivos que existem nos dados.** Um modelo que ignore por completo o que lhe dão e atribua a mesma probabilidade a tudo obtém uma PR-AUC igual a essa proporção.

No bloco de teste deste trabalho a proporção de casos positivos é de 37.8%, e o modelo “alertar sempre” obtém exatamente $\text{PR-AUC} = 0.378$. Não é coincidência: é a propriedade acima, e serve de verificação de que a medição está bem montada. Todos os valores de PR-AUC deste capítulo devem ser lidos contra esse chão de 0.378.

E porquê esta medida, e não a percentagem de acertos? Porque a percentagem de acertos engana quando as duas classes têm tamanhos diferentes. Se apenas 37.8% dos casos são positivos, um modelo que responda sempre “não é importante” acerta em 62.2% das vezes sem ter aprendido nada. Um número que premeia esse comportamento não serve para escolher entre modelos.

5.2.6 O Brier: a probabilidade tem de ser honesta

As medidas anteriores olham para a *ordenação*: se o modelo põe os casos importantes à frente. Falta uma que olhe para o *valor* da probabilidade. Isso importa porque o sistema mostra ao utilizador uma frase do género “57% de probabilidade”, e essa percentagem tem de querer dizer alguma coisa.

O **Brier** é a média do quadrado do erro entre a probabilidade anunciada e o que aconteceu:

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2 \quad (5.5)$$

onde p_i é a probabilidade que o modelo deu ao caso i e y_i vale 1 se o caso se revelou importante e 0 se não. Ao contrário das anteriores, aqui **quanto menor, melhor**: zero seria a perfeição.

O quadrado não está ali por acaso. Penaliza mais do que proporcionalmente os enganos confiantes: um modelo que diz 90% e erra paga $(0.9 - 0)^2 = 0.81$, enquanto um que diz 60% e erra paga $(0.6 - 0)^2 = 0.36$. A confiança é uma vez e meia maior e o castigo é mais do dobro, e é isso que “mais do que proporcionalmente” quer dizer. Prometer muito e falhar sai caro, que é a propriedade desejada num sistema que mostra percentagens a quem não as sabe questionar.

Vale a pena fazer a conta para o caso mais simples de todos, porque fecha exatamente. O modelo “alertar sempre” anuncia $p_i = 1$ para todas as notícias. Para os casos que se revelaram importantes ($y_i = 1$) o erro é $(1 - 1)^2 = 0$; para os restantes ($y_i = 0$) é $(1 - 0)^2 = 1$. O Brier passa a ser, simplesmente, a fração de casos não importantes:

$$\text{Brier} = 1 - 0.378 = 0.622$$

E 0.622 é precisamente o valor que a tabela da Secção 5.6 reporta para esse modelo. O modelo de volatilidade obtém 0.218, ou seja, menos de metade do erro.

5.2.7 Qual medida responde a que pergunta

A Tabela 5.1 resume o que cada uma faz e onde é usada, porque usar a medida errada para a pergunta certa é uma forma silenciosa de chegar a uma conclusão falsa.

Tabela 5.1: Cada medida, a pergunta a que responde, o seu chão de referência, e onde aparece neste capítulo.

Medida	Responde a	Chão	Usada em
Amplitude de disparo	O detetor comporta-se do mesmo modo em empresas diferentes?	zero seria o ideal	Q 1
F_1	Acerta quando fala, e fala quando devia?	depende dos dados	Q 1
Precisão@5	Das cinco que mostro, quantas são relevantes?	0.240 (acaso medido)	Q 2
PR-AUC	Ordena bem, seja qual for o limiar?	0.378 (a prevalência)	Q 3
Brier	A percentagem anunciada é honesta?	0.622 (alertar sempre)	Q 3

Uma nota final sobre a primeira linha, que é a única medida deste capítulo que não usa rótulos. A amplitude de disparo mede a diferença entre a empresa em que o detetor mais fala e aquela em que menos fala. Não precisa de saber quais dias eram mesmo invulgares: parte apenas do princípio de que um bom detetor universal deve comportar-se de forma parecida em empresas diferentes. É por não depender de rótulo nenhum que ela serve de argumento principal da secção seguinte, e as restantes de argumento de apoio.

5.3 QI1: detetar o que é invulgar

Um z-score deslizando deteta movimentos invulgares de forma mais consistente do que uma regra fixa? **Sim, e com uma margem grande.**

5.3.1 Como foi medido

Foram usados três anos de cotações diárias de quinze empresas grandes, entre junho de 2023 e junho de 2026, ou seja, cerca de 750 dias por empresa.

São quinze, e não as doze que o sistema vigia em produção. A diferença é de propósito: a avaliação quer *variedade* de volatilidade, para o argumento da consistência ter sobre o que incidir; a lista de produção é uma escolha de produto e não uma amostra. Confundir as duas seria avaliar o detetor exatamente no conjunto que ele foi montado para servir.

O argumento principal não precisa de rótulos nenhuns, e é por isso que é o principal. Um bom detetor universal deve disparar a um ritmo **parecido** em empresas diferentes. Se disparar muito numa e quase nada noutra, o que está a medir é a volatilidade da empresa e não a raridade do dia.

Como argumento de apoio, usou-se também um rótulo aproximado: considera-se “dia extremo” um dia no percentil 99 dos retornos *daquela* empresa. É um rótulo imperfeito, porque é ele próprio relativo à volatilidade, e por isso vem em segundo lugar.

5.3.2 Resultado

A Tabela 5.2 mostra o argumento principal.

Tabela 5.2: Com que frequência cada método dispara, entre as quinze empresas. O que interessa é a **amplitude**: quanto menor, mais consistente é o detetor.

Método	Taxa mínima	Taxa máxima	Amplitude
z-score (janela 20)	0.016	0.031	0.015
Limiar fixo ($ r \geq 3\%$)	0.009	0.353	0.344

A Figura 5.4 mostra a mesma informação empresa a empresa.

A diferença é de mais de vinte vezes. O limiar fixo dispara em 0.9% dos dias na empresa mais calma e em 35.3% dos dias na mais volátil, ou seja para uma delas quase nunca diz nada e para a outra fala um dia em cada três, ao passo que o z-score se mantém entre 1.6% e 3.1% em todas elas.




Figura 5.4: A mesma informação, empresa a empresa. As barras do limiar fixo acompanham a volatilidade de cada ação; as do z-score mantêm-se quase constantes.

Contra o rótulo aproximado, o z-score obtém $F_1 = 0.516$ contra 0.218 do limiar fixo.

Uma ressalva sobre esta comparação: a janela do z-score é variada mais abaixo, e o limiar de 3% da regra fixa **não é**. É o valor convencional e não foi otimizado. Um limiar mais alto subir-lhe-ia a precisão à custa da cobertura, e não é evidente em que ponto o F_1 ficaria; o que a comparação mostra com segurança não é que nenhum limiar fixo consegue melhor, é que um limiar fixo mede a coisa errada, porque a mesma percentagem significa coisas diferentes em empresas diferentes. Esse argumento não depende do valor escolhido.

Uma nota sobre o padrão de evidência desta secção, e é uma nota contra mim. Os números desta pergunta e da seguinte são pontos, sem intervalo. Os da Secção 5.6, que

é onde está o resultado que me contraria, levam reamostragem por grupos e intervalos de confiança. É uma assimetria: os resultados que me favorecem estão a ser julgados por um padrão mais fraco do que o que me desfavorece. A justificação parcial é que as diferenças aqui são de outra ordem de grandeza — 0.516 contra 0.218, ou uma amplitude de 0.015 contra 0.344, não são 0.005 — e por isso nenhuma reamostragem plausível as inverteria. Mas a justificação não é completa, porque dias da mesma empresa também não são independentes aqui, e pela razão que este mesmo capítulo invoca a propósito do desvio ponderado: os movimentos grandes andam em grupo. A comparação de recuperação, essa, passou a mostrar o desvio sobre as cinco repetições, que já existia e não estava impresso.

5.3.3 E contra métodos aprendidos?

Faltava a comparação mais exigente: e se em vez de uma regra estatística se usasse um método de aprendizagem automática desenhado para detetar anomalias?

Foram testados dois, sobre exatamente a mesma informação e com o mesmo cuidado de não usar o futuro: *Isolation Forest* (F. T. Liu, Ting e Zhou 2008) e *Local Outlier Factor* (Breunig et al. 2000). O resultado está na Tabela 5.3.

Tabela 5.3: Os três detetores, sobre os mesmos dados e sob o mesmo protocolo.

Detetor	Precisão	Cobertura	F_1	Amplitude
z-score (a regra)	0.407	0.761	0.530	0.017
Isolation Forest	0.158	0.913	0.269	0.140
Local Outlier Factor	0.163	0.989	0.280	0.183

A regra transparente ganha aos dois. Não por pouco: quase o dobro do F_1 , e com uma consistência entre empresas muito melhor. Os dois métodos aprendidos assinalam quase tudo (cobertura altíssima) e acertam pouco (precisão baixa).

Uma nota para quem comparar esta tabela com a conta feita na Secção 5.2.3, onde o mesmo z-score aparece com $F_1 = 0.516$. Os dois valores são reais e medem o mesmo detetor sob protocolos diferentes: o 0.516 é sobre todos os dias avaliados, ao passo que o 0.530 desta tabela é sobre a região que os **três** detetores conseguem pontuar, que é a única em que a comparação entre eles é justa. Comparar cada método fora da região comum daria vantagem a quem pontua mais dias.

Este é o primeiro de três casos, neste capítulo, em que uma técnica mais sofisticada foi comparada de forma justa com uma mais simples e perdeu. É um resultado que vale por si: justifica por medição a escolha do método simples, em vez de a justificar por preferência.

Interessa perceber *porquê*, porque a explicação não é que os métodos sejam maus. Ambos decidem o que é invulgar pela geometria dos dados, ainda que por vias opostas: o *Isolation Forest* recusa modelar o normal e isola diretamente o ponto raro, pela facilidade com que ele se separa por cortes aleatórios (F. T. Liu, Ting e Zhou 2008), enquanto o *Local Outlier Factor* compara a densidade em torno de cada ponto com a dos seus vizinhos (Breunig et al. 2000). São ambos métodos não paramétricos, distintos da família *estatística* que Chandola, Banerjee e Kumar (2009) define como aquela que modela a distribuição dos dados normais, e foram construídos para dados com muitas variáveis a interagir. Aqui não é esse o caso: há uma série de retornos por empresa, cuja estrutura relevante é *temporal*. O

agrupamento de volatilidade, que os modelos Autoregressive Conditional Heteroscedasticity (ARCH) e Generalized Autoregressive Conditional Heteroscedasticity (GARCH) formalizam (Bollerslev 1986; Engle 1982), faz com que o que conta como invulgar mude ao longo do tempo, e uma janela deslizante acompanha isso por construção, enquanto um detetor ajustado ao conjunto todo tem de o inferir. O padrão de resultados confirma-o: os dois métodos aprendidos assinalam demasiado, que é o que sucede quando se aplica uma noção global de raridade a séries cuja escala varia.

A Figura 5.5 mostra esta comparação em gráfico, e ao lado uma segunda que ainda não foi discutida.




Figura 5.5: À esquerda, os três detetores sobre a mesma região pontuada e com o mesmo cuidado de não usar o futuro. À direita, uma segunda comparação, entre duas maneiras de estimar a volatilidade: a que o sistema usa e uma alternativa. Está discutida a seguir, porque o resultado não foi o esperado.

5.3.4 E uma segunda comparação, que também não confirmou a escolha

O painel direito da Figura 5.5 responde a outra pergunta: e se, em vez de calcular o desvio-padrão dando *o mesmo peso* aos vinte dias, se desse mais peso aos dias recentes?

É uma ideia antiga em finanças, e a experiência foi desenhada para justificar por que razão o sistema *não* precisava dela. Deu o contrário. Com a mesma cobertura, a alternativa obtém $F_1 = 0.664$ contra os 0.516 da regra usada, e consegue-o eliminando quase metade dos falsos alarmes (precisão 0.568 contra 0.381).

O mecanismo é compreensível depois de visto. Movimentos grandes andam em grupo: depois de um dia agitado costumam vir mais. Uma média de vinte dias com pesos iguais dilui o choque por vinte dias e continua a achar tudo invulgar durante semanas; uma média que dá mais peso ao que é recente absorve o choque de imediato e volta a calar-se.

O sistema continua a usar a versão que perdeu, e a razão é a mesma que atravessa o trabalho: “a média e o desvio dos últimos vinte dias” explica-se a qualquer pessoa em duas frases, e “pesos que decaem exponencialmente” não. Numa ferramenta cujo argumento central é a explicabilidade, um ganho de precisão que custa a explicação não é obviamente um ganho.

Mas é uma escolha, não um resultado, e é assim que fica escrita. A alternativa está medida, o ganho está registado, e adotá-la é uma alteração pequena se algum dia a explicabilidade deixar de ser a restrição dominante.

5.3.5 O que isto não permite concluir

O rótulo é aproximado e relativo à volatilidade, e por isso o argumento de peso é o da consistência, que não usa rótulo nenhum. E as quinze são todas de grande capitalização e foram escolhidas em 2026, com a avaliação a correr para trás até 2018: sobreviveram por construção, e nenhuma delas saiu de bolsa, foi absorvida ou desapareceu da lista. O que se mede é portanto o comportamento do método em empresas que duraram, e não na população de que elas foram tiradas. E a comparação foi feita sobre estas quinze empresas e este período; nada aqui diz o que aconteceria noutro mercado ou noutra década.

5.4 A técnica sem pergunta: porque é que a decomposição não tem QI

Se a decomposição responde à segunda pergunta do investidor, porque é que não tem uma pergunta de investigação?

Porque não há nada contra o que a comparar, e é melhor dizê-lo do que fabricar uma métrica.

Repare-se na diferença face às outras três técnicas. Para a deteção existe um critério objetivo de “movimento extremo”, pelo que é possível contar acertos e falhas; para a recuperação existe uma noção verificável de relevância, e daí a precisão@k; para a triagem existe um rótulo construído a partir de preços futuros. Em todos estes casos há um alvo externo contra o qual a técnica pode sair errada.

Na decomposição não há. Nenhuma fonte de dados publica qual foi a parcela “verdadeira” de mercado no movimento da AMD num dado dia, porque essa quantidade não é observável: ela só existe *relativamente a um modelo*. Dados os betas, a repartição é uma identidade contabilística, e não uma previsão que possa sair certa ou errada. Inventar aqui um número de exatidão seria produzir uma métrica com boa aparência e sem referente, que é precisamente o contrário do que este capítulo faz.

Isto não deixa a técnica por avaliar: deixa-a por avaliar *daquela* maneira, e obriga a perguntar o que, dentro dela, continua a ser falsificável. São duas coisas, e ambas se medem.

Primeira: a repartição discrimina, ou diz sempre o mesmo? Uma decomposição que atribuisse tudo à empresa todos os dias seria inútil mesmo estando aritmeticamente correta. Medido num mesmo dia sobre as dezassete empresas do mapa de setores, que é o conjunto que o procedimento de avaliação percorre e não a lista de empresas vigiadas implantada: o motor identificado foi a própria empresa em 8 casos, o mercado em 5 e o setor em 4. A quota do movimento atribuída à empresa teve mediana 0.487, com extremos em 0.064 e 0.939. A repartição responde coisas diferentes para empresas diferentes no mesmo dia, que é a condição mínima para valer a pena calculá-la.

Segunda: os betas estão bem estimados? Esta é a parte que pode mesmo estar errada, e a medida apropriada é o R^2 na janela de estimação, cuja mediana foi 0.460. Convém dizer de que R^2 se trata, porque não é o do ajuste por mínimos quadrados: esse, calculado dentro

da amostra e com termo constante, nunca poderia ser negativo. O que se reporta é o R^2 do **modelo efetivamente usado**, ou seja com os betas já encolhidos e o termo constante recentrado para eles. É exatamente por isso que ele pode ser negativo, e é a medida certa a olhar, porque é esse o modelo cuja repartição aparece no ecrã. **Numa dessas dezassete empresas foi negativo**, o que significa que, naquela janela, mercado e setor não explicavam a variação daquela ação melhor do que a sua própria média, e portanto que a repartição desse dia se apoia num ajuste que não descreve os dados.

O que este resultado não permite concluir. Que a repartição está certa porque as parcelas somam. Elas somam sempre, com diferença nula até à precisão da máquina, porque a parcela da empresa é *definida* como o resto. Uma repartição inteiramente sem sentido somaria igualmente bem. A soma que fecha é uma verificação de implementação e não uma validação de método, e apresentá-la como validação seria o tipo de afirmação que este trabalho recusa noutros sítios.

Também não permite concluir que o valor exibido ao utilizador é fiável em todos os dias. No caso de R^2 negativo não é, e é por isso que a limitação fica registada no Capítulo 6 em vez de ficar escondida atrás de uma soma exata.

5.5 QI2: encontrar casos parecidos

A recuperação por significado encontra notícias passadas genuinamente relacionadas, melhor do que alternativas triviais? **Sim, com folga sobre todas elas.**

5.5.1 Como foi medido

O problema de avaliar recuperação é que não existe uma lista de “respostas certas”. Ninguém etiquetou pares de notícias como relacionados ou não.

Usou-se então uma aproximação verificável: considera-se que uma notícia recuperada é **relevante** se pertencer ao *mesmo setor* da notícia de consulta. É imperfeito, porque duas notícias do mesmo setor podem ser sobre assuntos distintos, mas tem duas virtudes: é objetivo, e não foi escolhido depois de ver os resultados.

Além disso, impôs-se uma restrição que torna a tarefa *mais difícil*: a notícia recuperada tem de ser de uma **empresa diferente**. Sem isso, o sistema podia parecer bom limitando-se a devolver notícias da mesma empresa, que estão quase sempre no mesmo setor por construção.

A métrica é a **precisão@5**: das cinco notícias que o sistema devolve, quantas são relevantes.

5.5.2 Resultado

A Tabela 5.4 tem o método usado, uma variante maior, e as três alternativas triviais. A leitura é direta: escolher ao acaso acerta em 24% dos casos. É esse o chão, e não zero, porque há cinco setores e alguns são maiores do que outros. Procurar por palavras em comum sobe para 34.6%. Comparar significado sobe para 51.4%, mais do dobro do acaso. A linha “sempre o setor maior” é discutida a seguir, e é a que obriga a ler tudo isto com cuidado.

Tabela 5.4: Precisão@5, média $\pm$ desvio-padrão sobre cinco repetições com sementes diferentes. Quanto maior, melhor. A linha “sempre o setor maior” não tem desvio porque não é uma medição: é a fração de consultas que são do setor maior, e sai igual em qualquer repetição.

Método	Precisão@5	O que é
Embeddings (MiniLM)	0.514 ± 0.015	o método usado
Embeddings (MPNet)	0.538 ± 0.011	um modelo maior, mais lento
Palavras em comum	0.346 ± 0.011	procurar por sobreposição de palavras
Sempre o setor maior	0.467	devolver sempre notícias de tecnologia
Escolha ao acaso	0.240 ± 0.004	o chão: a proporção natural
Mais recente	0.126 ± 0.006	devolver simplesmente as últimas notícias

Convém dizer com precisão o que a linha “palavras em comum” é, porque o nome admite leituras muito diferentes. É a forma mais simples da família lexical: contagem de palavras projetada por dispersão e comparada por cosseno. Não tem ponderação pela raridade dos termos, não tem saturação da frequência, e não tem normalização pelo comprimento do texto. Pertence portanto à tradição que vai do modelo de espaço vetorial (Salton, Wong e C. S. Yang 1975) às funções de ordenação probabilísticas como o BM25 (Robertson e Zaragoza 2009), mas fica no degrau de entrada dessa família, e não no topo.

Isso obriga a ler o resultado pelo que ele é. Os 17 pontos percentuais que a representação de frases (Reimers e Gurevych 2019) acrescenta medem a distância a um ponto de partida honesto, e **não** a distância a um sistema lexical afinado. Comparar contra um BM25 bem parametrizado é trabalho por fazer, e é a comparação que tornaria esta conclusão mais forte.

E há uma alternativa trivial que faltava a esta tabela, que é a que mais incomoda. O corpus tem 3 714 notícias e não está equilibrado: 1 736 delas, ou seja quase metade, são de tecnologia. Existe por isso uma estratégia que não precisa de modelo nenhum e não olha sequer para a consulta: *devolver sempre cinco notícias de tecnologia*. Ela acerta em todas as consultas de tecnologia e em nenhuma das outras, portanto a sua precisão é exatamente a fração de consultas que são de tecnologia, 0.467. Medida contra ela, e não contra o acaso uniforme, a margem do método cai de +0.274 para +0.047, e a linha lexical de 0.346 passa a estar *abaixo* do chão.

Isto é a mesma classe de defeito que a Secção 5.6 apanha na precisão dentro do orçamento, e que este capítulo diz três vezes: uma precisão sem o seu chão dá a conclusão errada. Aqui o chão que estava na tabela era o mais generoso dos disponíveis.

E, dito isto, é o número agregado que está a enganar, e não o método. A estratégia trivial obtém 1.000 nas consultas de tecnologia e 0.000 em todas as outras. Como produto não serve para nada: devolveria notícias de semicondutores a quem perguntasse por uma petrolífera. O que ela explora não é uma propriedade do problema, é a composição deste corpus.

A comparação que sobrevive a isso é a que se faz *dentro* de cada setor, onde a estratégia trivial não tem por onde se agarrar. Aí o chão de acaso é 0.429 na tecnologia e cerca de 0.072 em cada um dos outros quatro, e o método obtém 0.712 na tecnologia, 0.448 na energia e 0.419 na saúde. Ou seja: onde o agregado é dominado, o método ganha

0.283; onde o corpus é fino, ganha seis vezes o chão. **O agregado subestima o método e sobrestima a alternativa trivial, e pela mesma razão** — quase metade das consultas vem do único setor onde o chão já era alto.

A afirmação que este trabalho passa a fazer é portanto a mais estreita e a mais defensável: a recuperação semântica supera a taxa-base **em todos os cinco setores**, e o número agregado não é a forma certa de o dizer.

A variante MPNet fica acima da MiniLM (0.538 contra 0.514), e a escolha do modelo mais pequeno para produção foi tomada por custo e não por qualidade. Fica registada como o que é: uma troca declarada, cujo preço em precisão está medido nesta tabela.

A Figura 5.6 mostra o mesmo por setor e para vários tamanhos de lista.




Figura 5.6: Precisão@ k para cada método, com a restrição de a notícia recuperada ter de ser de outra empresa. A separação entre a linha do método usado e as alternativas mantém-se para todos os k testados, e não apenas para $k = 5$.

E a alternativa que parece mais razoável de todas, “mostra-me apenas as notícias mais recentes”, é a **pior** de todas, com 12.6%. Faz sentido: a notícia mais recente sobre outra empresa não tem razão nenhuma para estar relacionada com esta.

5.5.3 Aguenta à escala?

A avaliação acima corre sobre um corpus recente e curto, pelo que, para confirmar que o resultado não é um acidente desse corpus, a mesma medição foi repetida sobre o conjunto histórico completo, com cerca de 80 mil notícias de seis anos. A precisão@5 não só se mantém como sobe, para **0.595**.

Convém, no entanto, não ler essa subida como se fosse toda ganho. O chão de acaso também sobe, de 0.240 no corpus recente para 0.333 no completo, porque a mistura de setores é diferente e acertar por sorte fica mais fácil. Medida contra o respectivo chão, a margem é de +0.274 no primeiro caso e +0.262 no segundo, ou seja praticamente a mesma. O que este resultado mostra, lido com rigor, não é que o método melhora com mais dados: é que **não se degrada** quando o corpus passa de recente e curto para seis anos, e era isso que estava em causa.

5.5.4 E se o sistema só puder olhar para trás?

Há uma liberdade que o protocolo acima permite e que o sistema em produção não tem, e é preciso dizê-la. A restrição imposta é que a notícia recuperada seja de *outra empresa*, e mais nada: em particular, ela pode ser **posterior** à consulta. E não é raro, é o caso comum: no corpus recente, 38.7% dos vizinhos devolvidos têm data posterior à da consulta e outros 30.2% são do mesmo dia.

O sistema implantado não tem essa liberdade. A base de precedentes só recebe um caso oito dias depois, quando o impacto no preço já é observável, portanto tudo o que ele consegue devolver é passado. O número acima descreve, então, uma tarefa ligeiramente mais fácil do que aquela que o produto executa, e a pergunta de investigação fala em encontrar notícias *passadas*.

Convém separar duas coisas antes de medir. Isto **não** é uma fuga de informação no sentido habitual: o critério de acerto é *pertencer ao mesmo setor*, e o setor de uma notícia não muda com o tempo, pelo que a direção temporal não tem por onde inflacionar a precisão. O que está em causa é mais simples: se o número reportado corresponde à tarefa que a pergunta descreve.

A medição repete o protocolo exatamente, acrescentando à máscara a condição de o candidato ser **estritamente anterior** à consulta, e reproduz o número simétrico na mesma corrida para a comparação ser emparelhada. Nenhuma das 2500 consultas ficou sem passado suficiente. A Tabela 5.5 põe as duas leituras lado a lado.

Tabela 5.5: A mesma tarefa, com e sem a restrição de o precedente ter de ser anterior à consulta. A coluna que interessa é a última.

O que o sistema pode ver	Precisão@5	Chão	Margem
Tudo menos a própria empresa	0.595	0.333	+0.262
Só o que é anterior	0.513	0.259	+0.254

A precisão desce 0.082, o que parece muito. Mas o chão desce quase outro tanto, porque restringir os candidatos aos anteriores muda a composição do conjunto de onde se escolhe e acertar por sorte deixa de ser tão provável. Medida contra o respectivo chão, **a margem muda** 0.008: o método mantém praticamente toda a vantagem quando é obrigado a trabalhar como trabalha em produção.

Repare-se que esta é a *terceira* vez neste capítulo em que ler uma precisão sem o seu chão daria a conclusão errada. Foi assim na passagem do corpus recente para o completo, foi assim na precisão dentro do orçamento, onde custou uma afirmação retirada, e é assim aqui. Não é coincidência: uma precisão é uma quantidade sem significado próprio, e só o adquire ao lado da alternativa que não sabe nada.

5.5.5 O que isto não permite concluir

Duas observações, e a segunda tem consequências para o produto.

Primeiro, “mesmo setor” não é o mesmo que “relacionado”: é uma aproximação construída porque era verificável, e não porque fosse exatamente aquilo que se queria medir, e o número deve ser lido com essa reserva.

Segundo, e mais interessante: a recuperação capta **tema**, não **direção**. Duas notícias podem ser sobre o mesmo assunto e o preço ter ido para lados opostos, que foi exatamente o que aconteceu no exemplo do Capítulo 4. Medindo a concordância de direção entre a notícia de consulta e os casos recuperados, obtém-se 0.708 contra um chão de acaso de 0.688: quase nada. Daí que o sistema mostre os casos um a um e nunca os resuma a uma média, e daí também que o texto do alerta diz explicitamente que se trata de casos semelhantes no *tema*.

5.6 QI3: decidir o que merece um alerta

Um modelo treinado prioriza notícias melhor do que uma linha de base simples baseada só em volatilidade? **Não. E é o resultado mais interessante deste trabalho.**

5.6.1 Como foi medido

O conjunto de dados foi construído a partir do histórico: **79 753** exemplos entre 2018 e 2023, cada um uma notícia com o contexto de mercado do dia e o rótulo descrito na Secção 3.7. A divisão é cronológica com embargo, como na Figura 3.11.

Compararam-se seis modelos, do mais simples ao mais completo. A métrica principal é a **PR-AUC**, apropriada quando as duas classes são desequilibradas.

Dois cuidados de montagem, ambos para que a comparação não favoreça a conclusão que se acabou por obter. Primeiro, um dos seis modelos é um conjunto de árvores treinado por reforço do gradiente (Friedman 2001), incluído por ser o mais expressivo dos seis: capta interações e efeitos não lineares entre as variáveis que a regressão logística, por construção, não capta. Com uma ressalva que enfraquece a palavra *teto* e que é preciso dar: correu com os parâmetros por defeito da biblioteca, sem qualquer procura de hiperparâmetros. Um modelo de árvores por afinar não é o melhor que essa família consegue, portanto a sua derrota limita o que se pode concluir: mostra que o texto não aparece *nesta* montagem, e não que não apareceria num modelo não linear bem afinado. Serve de teto, e se o texto tivesse sinal a extrair era ali que teria mais hipóteses de aparecer. Convém enunciar o alcance exato desta garantia: mostra que *nenhum dos seis* modelos comparados extraiu sinal do texto, e não que nenhum modelo o conseguiria. Um método mais recente, ou o corpo dos artigos em vez do título, continuam por testar. Segundo, todas as pontuações são convertidas em probabilidades por calibração *a posteriori* sobre um bloco de validação reservado (Niculescu-Mizil e Caruana 2005), sem o que a coluna do Brier não seria comparável entre modelos.

5.6.2 Resultado

A Figura 5.7 mostra as curvas completas, e não apenas o número resumo.

O melhor modelo da Tabela 5.6 é o mais simples de todos: o que usa **apenas a volatilidade recente**. Acrescentar o resto do contexto não melhora. Acrescentar o texto do título *piora*, de 0.542 para 0.496.

Isto era o contrário do que eu esperava quando comecei. A hipótese era que o texto da notícia trouxesse informação que os preços não tinham. Sobre este corpus, não traz.

Tabela 5.6: Quanto maior a PR-AUC, melhor; quanto menor o Brier, melhor calibradas estão as probabilidades.

Modelo	PR-AUC	Brier
Alertar sempre (chão)	0.378	0.622
Só volatilidade	0.542	0.218
Só contexto de mercado	0.538	0.224
Só texto do título	0.439	0.240
Contexto + texto	0.496	0.229
Árvores com reforço do gradiente (contexto + texto)	0.469	0.228




Figura 5.7: As curvas sobre o bloco de teste. A área debaixo de cada curva é o valor da tabela. A curva do modelo que usa apenas volatilidade está por cima das outras em quase toda a extensão, e não só no valor agregado.

5.6.3 Não será um acidente da minha montagem?

Foi a primeira hipótese que fui verificar, por três caminhos.

Será que o modelo de texto estava mal afinado? Repetiu-se a comparação dando ao texto as melhores condições possíveis: regularização afinada, redução do bloco de texto a 32 dimensões, e um modelo de linguagem especializado em finanças. O melhor resultado do texto sobe para 0.533, e continua abaixo dos 0.542 da volatilidade.

Será que a diferença é ruído? Reamostrou-se o bloco de teste mil vezes, por grupos (empresa, dia), porque notícias do mesmo dia sobre a mesma empresa partilham o rótulo e não são observações independentes. A diferença mantém-se com o intervalo a excluir zero.

E convém dizer a que pergunta este intervalo responde, porque não é a mais larga. A reamostragem é feita *dentro* de um único bloco de teste, que são 221 dias de negociação; mede portanto o ruído de amostragem nesse período e não diz nada sobre a estabilidade

entre períodos. A distinção não é teórica neste trabalho: a Secção 5.6.6 mede um Population Stability Index (PSI) de 0.281 na volatilidade, e a prevalência do rótulo passa de 47.0% na validação para 37.8% no teste. Se a variação de um período para outro é dessa ordem, é plausível que a variância *entre* janelas seja maior do que os efeitos que aqui se declaram distinguíveis de zero, e todas as comparações deste capítulo, incluindo as nove definições de rótulo e as ablações, correm sobre o mesmo bloco. Uma origem rolante com três ou quatro cortes sucessivos responderia à pergunta larga, e não foi feita; fica declarado, e não contornado.

Será que depende de como defini o rótulo? O rótulo usa um limiar de 2% e um horizonte de três dias, ambos escolhidos por mim. Repetiu-se toda a comparação para nove combinações diferentes de limiar e horizonte. A volatilidade iguala ou bate o modelo com texto nas **nove**.

O resultado negativo aguenta os três testes. Não é um acidente da minha montagem: é o que os dados dizem.

5.6.4 Mas tem utilidade prática?

Serve, mas aqui é preciso muito cuidado com a comparação, porque é fácil enganar-se.

O produto não mostra tudo: mostra no máximo cinco alertas por dia. A pergunta útil passa a ser *das cinco notícias que escolho mostrar, quantas eram mesmo importantes?* A Tabela 5.7 responde.

Tabela 5.7: Quatro formas de escolher as cinco notícias do dia, sobre o mesmo bloco de teste. As quatro escolhem *sabendo o dia inteiro*, e por isso os valores são limites superiores do que uma política online consegue: ver a ressalva na Secção 5.6.

Como escolher	Precisão@5	O que é
“Alertar sempre”	0.163	<i>não é escolher às cegas</i> ; ver o aviso abaixo
Ao acaso (40 sementes)	0.379 ± 0.017	o que “às cegas” quer mesmo dizer
Volatilidade média da empresa	0.662	treze constantes, sem ler título nenhum
O modelo treinado	0.632	o que está implantado

Um aviso sobre a primeira linha, que eu próprio quase publiquei errado. O modelo “alertar sempre” dá a mesma pontuação a todas as notícias. Quando todas empatam, a métrica escolhe pela ordem em que as linhas aparecem no ficheiro, e o ficheiro está ordenado por data e por nome da empresa. Ou seja, esse 0.163 **não mede escolher ao acaso: mede escolher por ordem alfabética**, e todas as linhas que ele seleciona pertencem à empresa que vem primeiro no alfabeto. Comparado com o chão certo, o ganho do modelo é de 1.67 vezes, e não das quase quatro vezes que a primeira leitura sugeria. Deixo isto escrito porque foi um erro meu, e porque a lição é geral: *verificar o que a linha de base mede é tão importante como verificar o que o modelo faz*.

Há ainda a terceira linha, que é desconfortável e fica. Uma tabela de **treze constantes**, a volatilidade média de cada empresa, calculada só sobre o bloco de treino e sem ler um único título, obtém 0.662 e **bate o modelo treinado**. É o terceiro caso deste capítulo em

que o método mais simples ganha. O que a evidência sustenta, portanto, é que *ordenar por volatilidade* compensa; não que *aprender* compense.

5.6.5 E em produção?

O sistema registra todas as decisões de triagem e, dias depois, verifica o que realmente aconteceu. Sobre 825 decisões já maturadas, o modelo não mostra benefício: as notícias que ele deixou passar eram importantes 58.9% das vezes, contra 61.7% das que ele travou.

Estes dois números pedem uma ressalva sobre a sua precisão, e ela é grande. As 825 decisões não são 825 observações independentes: o rótulo é atribuído por (*empresa, dia*), e as 825 linhas repartem-se por apenas 239 pares distintos. Medida sobre essas 239 unidades, a capacidade de ordenação do modelo, a **Receiver Operating Characteristic Area Under the Curve (ROC-AUC)**, fica em 0.486 com um intervalo de confiança a 95% de [0.403, 0.571]. Nesta medida o acaso vale exatamente 0.5, portanto o intervalo contém-no confortavelmente. A leitura correta não é que o modelo seja pior do que nada, mas que **esta amostra não distingue o modelo do acaso**.

E duas das doze empresas vigiadas não estão no corpus de treino. O mapa canônico do material histórico tem quinze nomes e o treino cobre catorze; a lista que o produto vigia tem doze, e duas delas nunca apareceram em nenhum exemplo de treino. O modelo pontua-as na mesma, porque o que ele recebe são valores numéricos e não a identidade da empresa, mas fá-lo sobre uma combinação de entradas que não viu. É um segundo sentido, mais literal, em que o modelo implantado corre fora da distribuição em que foi avaliado, e as decisões dessas duas empresas entram nas 825 acima como quaisquer outras.

Esta medição foi refeita a 20 de agosto de 2026, quando o registo já tinha 825 decisões maturadas contra as 530 de que dispunha a primeira leitura. Vale a pena dizer o que mudou, porque quase nada mudou: a diferença entre mantidas e suprimidas estreitou-se (era 59.2% contra 64.7%), a **ROC-AUC** passou de 0.494 para 0.486, e o intervalo encolheu. Com metade mais evidência o veredicto é o mesmo, e é mais firme.

A explicação mais provável não é que o modelo esteja avariado, mas que esteja a **mais**. Quando ele é chamado, as notícias já passaram pelo filtro de relevância e pelo de frescura. Esses filtros baratos já removeram grande parte do que o modelo foi treinado para remover, e sobra-lhe pouco para separar. **Um modelo avaliado isolado e implantado atrás de filtros nunca foi avaliado na distribuição que vai ver.** É a lição mais transferível deste trabalho.

5.6.6 E os dados de hoje ainda se parecem com os do treino?

Há uma segunda razão pela qual um modelo implantado pode deixar de servir, e é independente da anterior: os dados mudam. Este foi treinado sobre 2018–2023 e corre em 2026. A distância está afirmada em vários sítios deste documento, e afirmar é barato, portanto foi medida.

A medida usada é o PSI, que compara a distribuição de cada entrada entre o período de treino e o atual, com as bandas convencionadas em risco de crédito: abaixo de 0.10 estável, entre 0.10 e 0.25 moderada, acima de 0.25 significativa.

O resultado tem duas metades e as duas interessam. A entrada que mais se deslocou é a **volatilidade dos vinte dias anteriores**, com PSI de 0.281, ou seja na banda significativa;

as restantes ficam estáveis. Mas o **rótulo quase não se move**: a prevalência de positivos passa de 0.3854 para 0.3781.

É uma combinação incómoda de ler e vale a pena dizer o que significa. A entrada de que o modelo mais depende é precisamente a que mais derivou, e o que ele tenta prever manteve-se onde estava. Não invalida nenhum número deste capítulo, porque todos foram medidos dentro do mesmo período, mas diz que o modelo implantado está a ver uma distribuição que já não é a do treino. Aqui a deriva é **medida e não corrigida**: nada se re-treina, e a Secção 6.5 diz o que faria falta para isso.

5.6.7 E o que é que a porta estava a escolher, afinal?

A subsecção anterior diz que o modelo está *a mais*. Serve de explicação e é vaga: não diz **o que** ele estava a fazer quando era chamado. Vale a pena responder a isso, porque a resposta é medível e porque foi ela que mudou o sistema.

A pergunta é simples. A porta implantada era um limiar fixo sobre a probabilidade calibrada: passa quem estiver acima de 0.50. *Esse limiar separava títulos, ou separava empresas?*

Mediu-se sobre as 4 366 decisões **realmente tomadas em produção**, e a Figura 5.8 mostra o resultado de uma só vez.




Figura 5.8: Para cada empresa, o intervalo de todas as pontuações que o modelo lhe deu em produção, com a mediana marcada a preto. A linha tracejada é o piso de decisão. As barras claras nunca o alcançam, as escuras atravessam-no, e as alaranjadas estão sempre acima. Repare-se em que oito das doze estão **inteiramente** de um dos lados: para essas, a decisão estava tomada antes de se ler o título.

A leitura da figura é imediata e os números confirmam-na:

- a amplitude média das pontuações **dentro** de cada empresa é 0.064;
- a amplitude **entre** as medianas das empresas é 0.385, ou seja, 6.1 vezes maior;
- três empresas ficavam **sempre** acima do piso e cinco **nunca** lá chegavam;
- só em quatro das doze o piso decidia alguma coisa.

Em 84% das decisões registadas, o resultado estava determinado pela **empresa** antes de o título ser lido. A Apple não conseguia gerar um alerta de notícia, acontecesse o que acontecesse; a AMD passava em 963 de 963.

E esse 84% precisa de uma ressalva, que aponta contra o próprio argumento. O número conta **decisões registadas**, e o sistema repontua os mesmos títulos a cada ciclo de sessenta segundos: o mesmo título entra dezenas de vezes. Pior, a duplicação não é uniforme. É maior nas empresas com *menos* notícias, que são precisamente as que nunca passam o piso, pelo que contar decisões empurra a fração para cima, ou seja na direção que favorece a conclusão que estou a defender.

Contado uma vez por título distinto, sobre uma janela posterior e maior (36 925 decisões até 20 de agosto de 2026), a fração cai para 48%. A conclusão estrutural não muda, e é ela que sustenta a decisão que se seguiu: continua a haver empresas inteiramente de um dos lados do piso, e a amplitude entre empresas continua a ser várias vezes a amplitude dentro de cada uma. O que muda é a força do número isolado, e fica assim escrito.

E este é o mesmo defeito que este trabalho já tinha identificado, um nível acima. A Secção 5.3 mostra que um limiar fixo sobre o *retorno* mede a volatilidade da empresa e não a raridade do dia, e é essa a razão de ser do z-score. O limiar fixo sobre a *pontuação do modelo* tem exatamente a mesma forma: como a pontuação é quase uma constante por empresa, cortá-la num valor fixo ordena empresas, não notícias. Encontrei o meu próprio erro repetido numa camada diferente.

Porque é que nada disto disparou um alarme. Convém explicar como um defeito desta dimensão sobrevive meses num sistema com centenas de testes, porque a resposta é genérica e não específica deste trabalho. O modelo foi avaliado sobre a distribuição do conjunto de treino e implantado atrás de dois filtros que a alteram: só chegam à sua entrada títulos que já passaram relevância e frescura. Nenhum teste podia detetar isto, porque cada peça cumpria o seu contrato; o que estava errado era uma suposição sobre a ligação entre elas, que ninguém tinha escrito em lado nenhum. É a classe de custo que D. Sculley et al. (2015) arrumam sob dependências de dados e emaranhamento entre componentes, e o sintoma que eles apontam verificou-se aqui por inteiro: o sistema continuou a produzir números de aparência perfeitamente normal.

E há uma segunda causa possível, que não consigo separar da primeira. Uma das nove entradas do modelo é a **reação do próprio dia**, e no treino ela é o retorno do fecho de $d - 1$ para o fecho de d , ou seja o movimento completo do dia da notícia, que só se conhece quando esse dia fecha. Em produção o sistema pontua a notícia no minuto em que a apanha, com uma latência mediana de 158 minutos desde a publicação e exemplos captados às 08:14: a essa hora o dia da notícia ainda não fechou. A entrada é então calculada sobre a última barra diária que a fonte tem, que durante a sessão é o fecho da véspera ou uma barra incompleta do próprio dia. Em nenhum dos casos é a quantidade sobre a qual o modelo foi treinado.

Não é a mesma coisa que a redundância descrita acima, e as duas produzem o mesmo sintoma. Com o que ficou registado não consigo atribuir peso a cada uma: o registo de decisões guarda a probabilidade e o resultado, e não guarda o valor das entradas no momento

em que a pontuação foi feita. Separá-las exigiria registrar as entradas, que é uma linha de código e uma corrida de semanas. Fica dito porque a explicação que eu tinha dado era completa de mais.

5.6.8 E a medição acima não é uma surpresa: é aritmética

Apresentei o resultado anterior como uma descoberta empírica. Ao verificá-lo percebi que é pior do que isso, e é preciso dizê-lo com clareza porque muda a leitura.

O modelo implantado é a variante **sem texto**. Como a Secção 3.7.3 já mostrou, das suas entradas apenas uma distingue dois títulos da mesma empresa no mesmo dia: o comprimento do título. Com o peso que essa entrada tem, oitenta caracteres a mais deslocam a pontuação interna do modelo em 0.0128, e depois de passar pela calibração isso são poucos milésimos na probabilidade que o sistema mostra. A amplitude entre empresas, medida nessa mesma probabilidade, é de 0.385. As duas grandezas separam-se por duas ordens de magnitude.

O cuidado com as escalas é deliberado e vale a pena explicá-lo, porque é fácil enganar-se aqui: o 0.0128 vive na escala interna do modelo, antes da calibração, e o 0.385 vive na probabilidade calibrada. Pô-los lado a lado sem os converter compararia coisas diferentes, e a conversão só torna o argumento mais forte, não mais fraco.

A pontuação quase constante dentro de cada empresa não é um acidente do treino nem um defeito dos dados. É uma **consequência aritmética do conjunto de entradas**. O modelo implantado nunca foi capaz de ordenar notícias, e nenhum treino o tornaria capaz.

Isto podia ficar-se por um raciocínio sobre a lista de entradas, e um raciocínio não é uma prova. Vale a pena testá-lo, e o teste é o mais simples possível.

5.6.9 A prova: uma tabela que não vê a notícia

Se o modelo aprendeu sobretudo a reconhecer a empresa, então deve ser possível reproduzi-lo com uma **tabela de consulta**: para cada empresa, um único número fixado no bloco de treino, que é a fração das suas notícias que se revelaram importantes. Essa tabela não vê o título, não vê o dia, não vê nada. Devolve sempre o mesmo valor para a mesma empresa.

A Tabela 5.8 compara-a com o modelo implantado e desmonta o modelo entrada a entrada, tudo sob o protocolo congelado.

Três leituras, e nenhuma delas depende de interpretação.

A tabela de consulta iguala o modelo, e numa das métricas bate-o. Na PR-AUC obtém 0.534 contra 0.538, uma diferença de 0.004. Na precisão dentro do orçamento, que é a métrica mais próxima do uso real, obtém 0.662 contra 0.632, ou seja **fica à frente**. Um número por empresa, fixado meses antes e nunca atualizado, faz o mesmo que o modelo treinado e, no critério que mais se parece com o produto, faz melhor. **O modelo implantado é uma tabela de consulta.**

Sem a empresa, não sobra nada. Retirando todas as entradas de nível de empresa, a PR-AUC cai para 0.378, que é precisamente a prevalência do bloco de teste, ou seja, o chão definido na Secção 5.2.5. Um modelo que obtém exatamente o chão não aprendeu nada.

Tabela 5.8: Cada linha é um modelo treinado com menos informação do que o anterior. A terceira linha é a decisiva: não vê a notícia e iguala o modelo implantado.

Modelo	O que vê	PR-AUC	Precisão@5
Contexto completo (o implantado)	as nove entradas	0.538	0.632
Só volatilidade	uma entrada, de empresa	0.542	0.632
Tabela de consulta por empresa	nada da notícia	0.534	0.662
Sem os indicadores de setor	tira 5 entradas de empresa	0.543	0.629
Sem volatilidade nem momento	tira as 2 que restam	0.389	0.390
Sem nada de nível de empresa	fica o dia e a notícia	0.378	0.368
Só o comprimento do título	a única de nível de notícia	0.378	0.352

E a única entrada que descreve a notícia não acrescenta nada. O comprimento do título, sozinho, também dá 0.378 de PR-AUC. É o mesmo chão. A única informação por título que o modelo implantado recebia é indistinguível de não receber informação nenhuma.

Isto obriga a separar duas afirmações que eu tinha juntado, e a separação é a parte honesta:

- **A conclusão científica da Q13 mantém-se.** A variante *com* texto tem 384 números por título, portanto tem mesma informação sobre a notícia, e ainda assim obteve 0.496 contra os 0.542 da volatilidade. É essa comparação que responde à pergunta, e o resultado negativo é dela.
- **A decisão de produto estava errada por outra razão.** O que foi implantado como porta de decisão foi a variante *sem* texto, e escolhi-a sem reparar que a métrica que usei para o fazer não fazia a pergunta de que o produto precisava.

E a frase que eu tinha escrito aqui também não era exata. Durante várias versões deste capítulo esta lista dizia que a variante implantada foi escolhida *por ter a melhor PR-AUC entre as que cabiam no contentor*. A tabela desta secção desmente-o quatro linhas acima: a variante só-volatilidade obtém 0.542 e a variante sem os indicadores de setor obtém 0.543, contra os 0.538 da implantada, e nenhuma delas precisa do codificador de frases, portanto ambas cabiam. A justificação que eu dava a uma escolha errada estava ela própria errada, dentro do parágrafo que existe para a corrigir.

A razão defensável que a escolha tem, e que só reconheço agora, é outra e não é de exatidão: a variante de nove entradas é a única das três cujas contribuições o alerta consegue *mostrar*. A linha da Figura 4.3 que diz “*raised by recent volatility (20d) and sector; lowered by today’s own move and recent momentum (5d)*” precisa de mais do que uma entrada para existir, e com um modelo de uma variável reduzir-se-ia a repetir o nome dessa variável. Num trabalho cuja restrição fundadora é a explicabilidade, isso é uma razão; mas é uma razão que encontrei depois, e o preço em PR-AUC dela são os 0.005 que a tabela mostra.

E é aqui que está a lição de método, que vale mais do que o resultado. A PR-AUC é calculada sobre o conjunto de teste inteiro, onde a variação *entre* empresas domina. Uma pontuação que ordene bem as empresas e não distinga nada dentro de cada uma obtém uma PR-AUC alta. A métrica estava correta e a resposta que ela dá também: só que a pergunta

que ela faz (*ordena bem no conjunto todo?*) não é a pergunta de que o produto precisava (*distingue duas notícias da mesma empresa?*).

Nenhum dos números deste capítulo muda por causa disto. O que muda é o que se pode afirmar com eles, e é essa a correção.

5.6.10 E se o texto não for para substituir, mas para acrescentar?

Há uma pergunta que a comparação de famílias não faz, e que só me ocorreu depois de a ablação da identidade explicar o que o modelo é.

Toda a avaliação da QI3 põe as variantes **lado a lado**: só volatilidade contra só contexto contra só texto. Uma comparação dessas responde a *qual é melhor*. Não responde a *o texto acrescenta ao melhor que existe*, que é uma pergunta diferente e, para um sistema, mais útil: ninguém é obrigado a escolher entre as duas fontes de informação.

A variante *contexto + texto* parece já fazer isso, e não faz, por uma razão que a Secção 5.6.9 tornou visível: soma o texto ao bloco de contexto, que **não é** a base certa para esta pergunta. A base certa é a **tabela de consulta por empresa**, e a razão é metodológica e não de desempenho: ela contém tudo o que o modelo sabe sobre a *empresa* e absolutamente nada sobre a *notícia*, portanto somar-lhe o título isola a contribuição do texto. Convém dizer o que ela não é: na PR-AUC a volatilidade sozinha fica **acima** dela, 0.542 contra 0.534, e é por isso que a tabela dos intervalos tem uma segunda linha. Nunca se tinha testado o texto por cima desta base.

O critério, fixado antes de medir. Um acréscimo só conta se o intervalo de confiança a 95% da diferença, obtido por reamostragem **por grupos** (empresa, dia), excluir zero. E a representação de texto não foi afinada aqui: usa-se a mesma redução a 32 dimensões do reteste da Secção 5.6, para que a comparação não seja o resultado de procurar a configuração que convém.

Tabela 5.9: Somar o título à tabela de consulta. A coluna da direita é a capacidade de ordenar *dentro* de cada empresa, onde a tabela vale 0.5 por construção e não por estimativa.

Modelo	PR-AUC	Prec.@5	AUC dentro
Tabela de consulta por empresa	0.534	0.662	0.500
Tabela + texto	0.547	0.662	0.512
Contexto (o implantado)	0.538	0.632	0.502
Contexto + texto	0.533	0.627	0.508
Só texto	0.457	0.616	0.495

O resultado, e é positivo. O título **acrescenta** a essa base: +0.012 de PR-AUC, com intervalo [+0.004, +0.020], que exclui zero. É o valor mais alto medido em qualquer variante deste trabalho, e é a primeira vez que uma representação de texto mostra valor mensurável nesta tarefa.

Três ressalvas impedem que isto seja mais do que é, e todas são medições e não modéstia.

Não bate a volatilidade sozinha. O 0.547 é maior do que o 0.542, mas a diferença entre os dois tem intervalo [-0.032, +0.037], que contém zero. São dois pontos dentro do

ruído um do outro, e afirmar que o modelo com texto *ganha* seria ler uma diferença que esta amostra não sustenta. O veredicto da QI3 não muda.

Não chega ao produto. A precisão dentro do orçamento de cinco alertas por dia é 0.662 com e sem o texto, sem uma casa decimal de diferença. O acréscimo existe na ordenação do conjunto todo e desaparece quando só se escolhem cinco por dia, que é exatamente o que o sistema faz. Um ganho que não sobrevive à métrica de produto não muda o produto.

E continua a não separar dias da mesma empresa. A última coluna da Tabela 5.9 mede a capacidade de ordenar *dentro* de cada empresa, onde a tabela de consulta vale 0.500 por construção, por devolver sempre o mesmo valor. O modelo implantado obtém 0.502 com intervalo [0.462, 0.542], que contém 0.5; com texto sobe para 0.512, e o acréscimo tem intervalo que também contém zero. Ou seja: a informação que o texto traz distingue **empresas e períodos**, e não notícias. O diagnóstico da secção anterior sai confirmado, não desmentido.

O que isto muda na resposta à QI3. A resposta continua a ser não, e passa a ser mais precisa. Antes dizia-se: *nenhum modelo com texto bate a volatilidade*. Continua verdade. Acrescenta-se agora: *mas o texto não é inútil*, acrescenta ao que o modelo já sabe sobre a empresa, de forma pequena e mensurável, e o que o impede de mudar o sistema não é a ausência de informação, é a informação ser do tipo errado. Distingue empresas quando o produto precisa de distinguir notícias.

É uma resposta melhor do que a anterior porque diz *onde* está o limite. E aponta o trabalho seguinte sem ambiguidade: não é procurar um modelo maior, é arranjar um rótulo por notícia.

Uma ressalva sobre o próprio método. Este é mais um modelo avaliado sobre o mesmo bloco de teste, que já serviu várias comparações deste capítulo. Quanto mais vezes se olha para um conjunto de teste, mais fácil é encontrar nele uma diferença pequena. As duas defesas usadas não afinar a configuração aqui, e escrever o critério antes de medir, reduzem esse risco sem o eliminarem, e um efeito de +0.012 deve ser lido com essa reserva.

5.6.11 A correção óbvia, e porque é que não servia

Se o remédio funcionou para os preços, a tentação é aplicá-lo aqui: em vez de um piso fixo, um piso *relativo a cada empresa*, alertando quando a pontuação é invulgar *para aquela empresa*.

Simulei-o sobre as mesmas decisões antes de escrever uma linha de código. Metade do problema resolve-se: as doze empresas passam a estar representadas, que é o efeito pretendido. Mas aparece outro, e é o mais instrutivo desta secção.

Nas empresas cuja pontuação quase não varia, o percentil cai **em cima** da constante e quase todas as decisões empatam acima dele. A JNJ, cuja pontuação vive entre 0.298 e 0.324, passaria 874 vezes. O piso relativo deixa de escolher por materialidade e passa a escolher por desempate, que é precisamente o artefacto documentado na Secção 5.6 a propósito do chão de comparação.

Não se corrige um defeito introduzindo o defeito vizinho. A conclusão honesta é mais funda do que “falta afinar o piso”:

Dentro de uma empresa, a pontuação do modelo quase não varia com o título. Nenhuma regra de decisão aplicada a essa pontuação a pode tornar sensível à notícia, porque a informação que distinguiria um título do seguinte não está lá.

O que se fez em consequência, e porquê. O modelo deixou de ser porta e passou a ser critério de **ordenação**. É o uso que a medição sustenta: entre empresas ele tem informação, e é exatamente isso que a precisão dentro de um orçamento mede. O controlo de volume passou para um **orçamento diário** de cinco alertas, servido por ordem de materialidade.

E isto aproxima uma divergência que só se torna visível ao confrontar as duas: **esta dissertação avaliava uma política de orçamento e o sistema implantava uma política de limiar**. Eram políticas diferentes, portanto o número reportado descrevia um sistema que não era o que estava no ar. Passaram a ser da mesma família.

Mas não passaram a ser a mesma, e a diferença que resta tem de ficar dita. A métrica avaliada ordena *todas* as candidatas do bloco de teste e só depois enche cinco lugares em cada dia. Isso exige conhecer o dia inteiro antes de decidir, ou seja é uma política **offline**. O sistema implantado decide **online**, de sessenta em sessenta segundos: gasta o primeiro lugar na primeira notícia que passe as portas, porque no momento da decisão a notícia da tarde ainda não existe. Não se pode reservar quota para uma história que ainda não se viu, nem retirar um alerta já entregue.

A consequência é precisa e vale a pena enunciá-la assim: **a precisão dentro do orçamento que este capítulo reporta é um limite superior** do que a política implantada consegue. Nenhuma regra online bate uma que escolhe as cinco melhores de um dia inteiro. O que a ordenação do modelo compra em produção é mais modesto e é real: decide quem vai à frente *dentro de cada ciclo*, e o piso escalonado da Secção 4.6 encarece cada lugar seguinte, para que uma notícia menor da manhã não gaste a quota que a da tarde ia precisar. É o que se consegue fazer sem ver o futuro, e é por isso que fica escrito como limite e não como equivalência.

5.6.12 O que isto não permite concluir

Que o texto de notícias não sirva para nada. Só se testou uma representação (títulos, sem o corpo do artigo) sobre um corpus. Com textos completos e mais dados, a resposta podia ser outra, e isso fica como trabalho futuro, não como desculpa.

E, sobre a secção anterior, que o modelo seja inútil. Ele ordena empresas melhor do que o acaso, e é com esse papel que ficou. O que a medição desmente é o uso que lhe estava a ser dado.

5.7 Todas as alternativas que foram testadas e não ficaram

Como é que sei que estas escolhas são boas, e não apenas as primeiras que me ocorreram?

Ao longo dos três capítulos anteriores cada técnica foi apresentada com uma justificação. Falta juntá-las num sítio só, porque é assim que se vê o padrão: **a maior parte das escolhas deste sistema foi decidida por medição contra uma alternativa concreta**, e várias delas contrariaram o que eu esperava.

A Tabela 5.10 lista todas. A coluna do meio é a que interessa: não o que ficou, mas o que foi *posto de lado* e com que número.

Tabela 5.10: As decisões técnicas do trabalho, cada uma com a alternativa medida contra ela. Três linhas dizem *não ganhou*: são os pontos em que o sistema usa a opção que a medição não favorece, e a razão está escrita. As três últimas não têm número porque são decisões de restrição.

Ficou	Perdeu, e com que número	O que isso quer dizer
z-score deslizando	Limiar fixo de 3%: amplitude 0.344 contra 0.015	Um limiar fixo mede a volatilidade da empresa, não a raridade do dia.
z-score deslizando	<i>Isolation Forest</i> (F_1 0.269) e <i>Local Outlier Factor</i> (0.280) contra 0.530	Os métodos aprendidos assinalam quase tudo e acertam pouco.
Janela de 20 dias	Não ganhou : 10d dá F_1 0.385, 20d dá 0.516, e 60d dá 0.678	A medição favorece uma janela mais longa. Ver a discussão abaixo.
Desvio-padrão de pesos iguais	Não ganhou : pesos que decaem dão F_1 0.664 contra 0.516	Mantido por ser explicável a um leigo, e dito como escolha e não como resultado.
Embeddings de frase	Sobreposição de palavras: P@5 0.346 contra 0.514	Palavras iguais não são assunto igual, e assunto igual não precisa de palavras iguais.
MiniLM, e não MPNet	Não ganhou : MPNet dá P@5 0.538 contra 0.514; um modelo de finanças dá 0.420	O modelo mais pesado é melhor, e foi trocado por custo, não por qualidade. O modelo específico do domínio foi o pior de todos. Não se assumiu: mediu-se.
Regressão logística	Árvores com reforço do gradiente: PR-AUC 0.469 contra 0.538	O modelo mais expressivo não ganhou, e o simples explica-se.
Calibração de Platt	Regressão isotônica, comparada na mesma validação	Platt iguala ou ganha no Brier em todas as famílias testadas.
Cosseno	Distância euclidiana	Com vetores normalizados as duas dão a mesma ordenação, e o cosseno lê-se melhor.
Dois gatilhos (notícia e preço)	Juntar-lhes o volume e a intensidade de notícia numa fusão, na linha dos painéis que combinam sinais de origens diferentes (<i>World Monitor</i> 2026): ganha em 1 de 3 orçamentos (+0.0045 em top-5, -0.0498 em top-1, -0.0317 em top-3)	O volume continua a ser calculado e mostrado como contexto, mas não levanta alertas: uma capacidade que ganha uma vez em três não justifica mais uma via de interrupção.
Apenas fontes gratuitas	—	Restrição fundadora: define quem o sistema pode servir.
Não prever preços	—	Restrição de desenho: é o que torna tudo o resto verificável.
Mercado dos EUA	—	Restrição de âmbito: é onde as fontes gratuitas têm cobertura.

Três linhas merecem atenção.

O **modelo de finanças perdeu**. Era a escolha que parecia mais óbvia de todas: um modelo treinado especificamente em texto financeiro devia ser melhor a comparar notícias financeiras. O modelo medido foi o FinBERT de Araci (2019), e obteve 0.420 contra os 0.514 de um modelo genérico e pequeno. Se eu o tivesse adotado por ser o óbvio, o sistema ficava pior e eu nunca saberia.

A janela de 20 dias é a linha desta tabela que mais me custou deixar escrita. É uma das três em que o sistema não usa o que a medição favorece, e a mais difícil de justificar. A

5.8. E o sistema inteiro vale mais do que o que a pessoa já tem?

ablação diz que uma janela de 60 dias obtém $F_1 = 0.678$ contra os 0.516 da janela de 20. Se o critério fosse este número, o sistema devia usar 60.

Não usa, por duas razões, e a segunda é a que importa.

A primeira é que uma janela de 60 dias demora três meses a reagir a uma mudança de regime. Uma empresa que passa de calma a volátil continuaria a ser julgada pela sua norma antiga, e o detetor dispararia sem critério durante semanas.

A segunda é que **este número não é de confiança para esta comparação**. O rótulo é um *proxy* construído a partir do percentil de movimento *da própria empresa*, portanto é ele próprio relativo à volatilidade. Uma janela mais longa produz uma norma menos adaptativa, que assinala mais vezes a cauda extrema, que é precisamente o que este rótulo premeia. Há circularidade, e ela favorece a janela longa por construção.

É por isso que o argumento principal da Secção 5.3 é a **consistência da taxa de disparo**, que não usa rótulo nenhum. Mas nada disto transforma 0.678 em 0.516. A afirmação honesta é: *a janela de 20 dias foi escolhida por responsividade, e a única medição que existe sobre este ponto não a sustenta*. Fica assim.

E as **três últimas linhas não têm número de propósito**. São restrições, não resultados: foram escolhidas antes de haver qualquer medição e não se defendem com uma tabela. Apresentá-las como se tivessem sido testadas seria dar-lhes uma autoridade que não têm.

5.8 E o sistema inteiro vale mais do que o que a pessoa já tem?

Cada componente foi comparado com a sua alternativa. E o conjunto?

As secções anteriores comparam peça a peça: o detetor contra um limiar fixo, a recuperação contra escolher ao acaso, a triagem contra a volatilidade. Falta a comparação de que o utilizador precisa, que é ao nível do **sistema**: dadas as notícias de um dia, quais são as cinco que valia a pena mostrar, e o sistema escolhe-as melhor do que aquilo que já existe sem custo?

A Tabela 5.11 responde. Todas as políticas escolhem cinco por dia, sobre o mesmo bloco de teste e com o mesmo rótulo. O desempate é **aleatório e explícito** em todas, pela razão dada na Secção 5.6.

Tabela 5.11: Todas as políticas escolhem cinco notícias por dia, e todas o fazem *sabendo o dia inteiro*: a comparação entre elas é justa, e cada valor é um limite superior do que a mesma regra daria a decidir ao minuto. A primeira e a última não são políticas: uma é o chão e a outra é o teto.

Política	O que faz	Precisão@5
Ao acaso	escolhe cinco à sorte	0.375 ¹
Quem mais se mexeu hoje	notícias das empresas com maior movimento do dia	0.489
O modelo implantado	a triagem aprendida	0.632
Volatilidade da empresa	treze constantes, sem ler título	0.662
Oráculo	sabe as respostas: o melhor possível	0.968

Três leituras saem daqui, e a última é a mais útil.

O sistema bate a alternativa realista. Mostrar notícias de quem mais se mexeu hoje é o que qualquer aplicação de bolsa já faz, sem custo nenhum, e obtém 0.489. O sistema obtém 0.632. O trabalho acrescenta, portanto, valor mensurável sobre o que a pessoa já tinha, e é a primeira vez neste documento que isso é medido ao nível do conjunto e não de uma peça.

E continua a não bater a volatilidade. Treze constantes calculadas só sobre o bloco de treino obtém 0.662, uma por cada empresa que aparece no treino. Já se sabia da Secção 5.6, e agora sabe-se porquê: a Secção 5.6.9 mostrou que o modelo é, na prática, uma tabela por empresa, e a volatilidade é outra tabela por empresa, mais simples. Duas tabelas a fazer a mesma coisa, e ganha a que não precisa de ser treinada.

O oráculo diz onde está o problema, e não é onde eu julgava. O melhor resultado possível, escolhendo com as respostas na mão, seria 0.968. Isso quer dizer que **em quase todos os dias existem mesmo cinco notícias importantes no lote**. O sistema não está limitado por falta de matéria-prima: está limitado por não conseguir distinguir quais são.

A margem entre 0.632 e 0.968 é de 0.336, e está quase toda em separar notícias *dentro* de cada empresa, que é exatamente o que o modelo implantado não consegue fazer. É a mesma conclusão a chegar por um terceiro caminho independente.

E tudo isto conta com a notícia ter chegado. Todas as políticas desta tabela escolhem de dentro do que a fonte entregou, o que deixa de fora a pergunta anterior a todas: e quando não entregou nada? Está medido. Sobre um ano de notícias captadas, existia pelo menos uma notícia relevante em 88.5% dos dias que o detetor considerou invulgares, e 90.4% nos mais extremos. Nos restantes, nenhuma alteração ao código ajuda: se a fonte gratuita não associou notícia nenhuma à empresa, ela nunca entra no funil. E a cobertura é muito desigual, com a empresa pior coberta a ficar-se pelos 50%.

Este número é um **limite superior** e a distinção decide o que ele vale: pergunta se existia uma notícia, não se chegou a certa. A Secção 6.4 retoma-o como limitação.

Uma linha de base que não foi medida, e porquê. A alternativa mais natural de todas seria “ler as primeiras cinco notícias que chegam”. Não é medível aqui: o conjunto de dados histórico não guarda a hora de publicação e está ordenado por data e por empresa, portanto usar a ordem do ficheiro mediria a ordem **alfabética** das empresas. Seria o mesmo artefacto que a Secção 5.6 documenta, desta vez introduzido de propósito. Uma linha de base errada é pior do que uma linha de base em falta.

5.9 Resumo dos três resultados

E um critério que este capítulo usa e nunca tinha enunciado. Vão aparecer diferenças pequenas lidas de maneiras diferentes, e convém dizer a regra antes de elas surgirem em

¹Este chão de acaso (0.375 ± 0.012) difere ligeiramente do que a Tabela 5.7 reporta (0.379 ± 0.017). Não é discrepância: são dois protocolos, um sobre o conjunto de candidatas do sistema completo e outro sobre o bloco de teste da triagem, e os dois intervalos sobrepõem-se largamente.

Tabela 5.12: O veredicto de cada questão de investigação.

Pergunta	Resposta	Com base em quê
QI1 detecção	Sim	Amplitude de disparo 0.015 contra 0.344; e ganha a dois métodos aprendidos (F_1 0.530 contra 0.269 e 0.280)
QI2 precedentes	Sim	Precisão@5 de 0.514 contra 0.346 (palavras), 0.240 (acaso) e 0.126 (recência); 0.595 à escala
QI3 triagem	Não	Nenhum modelo com texto bate a volatilidade de forma sustentada (0.496 contra 0.542; a melhor variante com texto chega a 0.547, mas a diferença tem intervalo que contém zero), e o resultado aguenta os três testes de robustez. Mas o texto acrescenta ao que o modelo já sabe da empresa: +0.012, IC [+0.004, +0.020]

vez de a deixar adivinhar. Uma diferença de PR-AUC **abaixo de** 0.02 é tratada aqui como indistinguível para efeitos práticos, mesmo quando o intervalo emparelhado exclui zero. É por isso que o +0.012 do texto sobre a tabela de consulta é reportado como real e ao mesmo tempo como incapaz de reabrir o veredicto, e que o 0.004 entre a tabela de consulta e o modelo implantado não sustenta escolher um em vez do outro. O limite é meu e é arbitrário; o que não pode ser arbitrário é aplicá-lo nos dois sentidos, e é para isso que fica escrito.

A Tabela 5.12 junta as três. Duas das respostas são afirmativas e uma é negativa. A negativa é a que eu mais aprendi a defender: mostra que a avaliação foi montada para poder dizer que não, e uma avaliação que só sabe dizer que sim não avalia nada.

Capítulo 6

Conclusões

6.1 Síntese do trabalho

Existe um sistema a funcionar, e não uma demonstração. O InvestiGator vigia doze empresas, corre de forma contínua, e envia alertas explicados a um canal público, com uma página web onde o que foi enviado pode ser consultado depois.

E existe uma avaliação de cada uma das quatro técnicas, com os resultados reportados como se revelaram. Três foram medidas *contra alternativas mais simples*, que é o desenho que permite dizer que não. A quarta, a decomposição, não podia sê-lo, porque não existe uma resposta certa contra a qual comparar uma repartição: dela mede-se o que é mensurável, que é a qualidade do ajuste, e a Secção 5.4 explica porquê. É esta parte que dá ao trabalho o carácter de dissertação e não o de projeto.

Vale a pena dizer também onde está a engenharia, porque a resposta não é o tamanho do modelo. Este trabalho treina um só, e é pequeno. O que foi preciso construir para que o número dele, e a conclusão negativa que ele sustenta, sejam de confiança está reunido na Secção 4.9: o conjunto de dados rotulado, a separação temporal imposta por um teste, a calibração com o seu enviesamento declarado, os artefactos versionados, a garantia de que o modelo implantado é o modelo avaliado, e o ciclo que observa o sistema depois de estar a correr. É aí, e não no modelo, que está o trabalho.

6.2 As respostas às perguntas de investigação

A Figura 6.1 responde às três de uma vez, e o resto desta secção diz o que cada resposta permite e não permite afirmar.

Q11, deteção. Sim. Um z-score deslizante deteta movimentos invulgares de forma muito mais consistente entre empresas do que uma regra fixa: uma amplitude de disparo de 0.015 contra 0.344, mais de vinte vezes melhor. E, sujeito a uma comparação justa, ganha também a dois métodos de aprendizagem desenhados para esta tarefa (Breunig et al. 2000; F. T. Liu, Ting e Zhou 2008).

Este resultado é menos surpreendente do que parece à primeira vista, e a literatura ajuda a perceber porquê. Os dois métodos aprendidos decidem o que é invulgar pela geometria dos dados (Breunig et al. 2000; F. T. Liu, Ting e Zhou 2008), um isolando o ponto raro e o outro comparando densidades, e foram desenhados para situações com muitas variáveis a interagir; aqui há uma série de retornos por empresa, e a estrutura que interessa é temporal, não geométrica. A janela deslizante capta diretamente o *agrupamento de volatilidade*, a

QI1 Detetar o que é invulgar de forma consistente entre empresas?	SIM	amplitude de disparo 0.015 contra 0.344 de uma regra fixa; e bate dois detetores aprendidos
QI2 Encontrar notícias passadas genuinamente parecidas?	SIM	precisão@5 de 0.514 contra 0.346, 0.240 e 0.126; aguenta à escala, com 0.595
QI3 Um modelo treinado decide melhor do que uma linha de base simples?	NÃO	PR-AUC 0.496 com texto contra 0.542 só com volatilidade; aguenta três testes de robustez. Mas somado à tabela de consulta o texto <i>acrescenta</i> : +0.012, IC [+0.004, +0.020]

Figura 6.1: O resultado do trabalho numa figura, com a resposta negativa apresentada com o mesmo destaque das outras duas. A terceira linha é a que mais custou a escrever e é a que dá crédito às outras: um trabalho que só reporta o que correu bem não permite saber se as duas primeiras respostas foram medidas ou desejadas.

propriedade que os modelos ARCH e GARCH formalizam (Bollerslev 1986; Engle 1982) sobre séries de inflação e que a Secção 5.3 mede nos retornos analisados aqui, ao passo que um detetor treinado sobre o conjunto todo tem de aprender essa estrutura a partir dos dados. Quando a suposição de um método simples coincide com a estrutura real do problema, é difícil batê-lo.

QI2, precedentes. Sim. A recuperação por significado encontra notícias passadas relacionadas melhor do que procurar por sobreposição de palavras, do que escolher ao acaso e do que devolver as mais recentes (0.514 contra 0.346, 0.240 e 0.126), e o resultado aguenta à escala do corpus completo (0.595). A linha de base lexical medida é a mais simples da sua família, e não uma função de ordenação afinada, o que delimita o alcance da afirmação.

E o número agregado não é a forma certa de dizer isto, pela razão que a Secção 5.5 desmonta: quase metade das consultas vem de um só setor, e existe uma estratégia sem modelo nenhum, *devolver sempre notícias desse setor*, que obtém 0.467 sem olhar para a pergunta. Contra ela a margem do método é de +0.047, e não de +0.274. Essa estratégia é inútil como produto, porque acerta em tudo num setor e em nada nos outros quatro, mas a sua existência mostra que o agregado mede em parte a composição do corpus. A afirmação que fica é a de dentro de cada setor, onde ela não se aplica: a recuperação semântica supera a taxa-base **nos cinco**, e o ganho é maior onde o corpus é mais fino.

Com uma segunda ressalva, que ficou clara ao medir: a semelhança capta o **tema**, não a **direção**.

Essa ressalva é coerente com o que se esperaria, e não é apenas um defeito da implementação. A hipótese dos mercados eficientes na sua forma semiforte (Fama 1970) diz que a informação pública já está refletida no preço; se assim for, a direção de um movimento futuro não deveria ser recuperável a partir do tema de uma notícia pública. Convém ser cuidadoso com o estatuto disto: trata-se de uma hipótese e não de uma lei, e o próprio autor sublinha que os seus testes são sempre conjuntos, da eficiência e de um modelo de formação de preços ao mesmo tempo. Este trabalho não a testa nem se apoia nela para

concluir seja o que for. Serve apenas para dizer que o resultado medido não é anômalo, e é uma das razões pelas quais o produto apresenta os precedentes como observações do passado e nunca como indicação do que vem a seguir.

Q13, triagem. Não. Nenhum modelo que lê o texto do título bateu uma linha de base que usa apenas volatilidade (0.496 contra 0.542). O resultado sobreviveu a um re-teste em condições favoráveis ao texto, a uma reamostragem por grupos, e a nove definições diferentes do rótulo.

A resposta é negativa e é preciso dizê-la com a precisão que ela ganhou no fim do trabalho. Todas essas comparações põem as variantes *lado a lado*, e respondem por isso a *qual é melhor*. A pergunta que faltava era outra, e mais útil para quem constrói um sistema: *o texto acrescenta ao que já se sabe?* Medida por cima da tabela de consulta por empresa, que a Secção 5.6.9 mostra conter tudo o que o modelo sabe da empresa e nada da notícia, a resposta é **sim**, com +0.012 de PR-AUC e um intervalo [+0.004, +0.020] que exclui zero. É pequeno, é real, e é a única vez neste trabalho em que uma representação de texto mostra valor mensurável.

Três medições impedem que isso reabra o veredicto, e estão na Secção 5.6.10: a diferença para a volatilidade sozinha continua a ter um intervalo que contém zero; a precisão dentro do orçamento não muda uma casa decimal, ou seja o ganho não sobrevive à métrica que descreve o produto; e a capacidade de separar dois dias da mesma empresa continua ao nível do acaso. O que isto acrescenta ao “não” não é uma ressalva, é uma **localização**: a informação que o texto traz distingue empresas e períodos, e o produto precisava que distinguísse notícias. É essa a diferença entre um resultado negativo e um resultado negativo compreendido, e é ela que aponta o trabalho seguinte na Secção 6.5.

Esta última resposta é negativa e é a que eu levo mais a sério. Escrevi o critério de sucesso antes de correr a experiência, e o resultado foi ao contrário do que eu esperava. Reportá-lo tal como caiu era a única opção compatível com o resto do trabalho.

Existe uma linha de investigação considerável que usa texto para antecipar movimentos de preço (Ding et al. 2015; Xing, Cambria e Welsch 2018), e seria cómodo apresentar este resultado como se a contradissesse. Não a contradiz, e convém ser preciso sobre porquê, incluindo num ponto em que a diferença é menor do que eu gostaria. Ding et al. (2015) trabalham também sobre *títulos*, e não sobre o corpo dos artigos, pelo que a diferença não está aí. Está no que se faz com eles: extraem estruturas de acontecimento, do tipo ator, ação e objeto, e treinam uma rede para prever a direção do movimento, ao passo que aqui se compara o título inteiro por semelhança e se recusa prever direção. Os corpora e os horizontes de avaliação também diferem.

O que aqui se mostra é, portanto, mais estreito do que uma refutação, e é essa a afirmação que faço: **sob esta restrição de dados e com esta família de métodos**, ou seja títulos de fontes gratuitas comparados por semelhança de frase, o sinal textual não acrescenta ao que a volatilidade recente já dizia. É um resultado sobre um regime de recursos e uma escolha de representação, e não sobre a linguagem.

6.3 Objetivos alcançados

Dos quatro objetivos da Secção 1.3, **três estão cumpridos e um está cumprido por metade**.

1. *Construir o sistema completo.* Cumprido. Os dois gatilhos funcionam de ponta a ponta, em produção.
2. *Avaliar cada componente contra linhas de base transparentes.* Cumprido para os três componentes em que uma linha de base existe, e num deles mais do que o prometido: o detetor foi comparado não só com uma regra fixa mas também com dois métodos aprendidos. Para a decomposição não há linha de base possível, e o que se fez em vez disso está dito na Secção 5.4.
3. *Garantir que as explicações são fiéis.* **Cumprido por metade.** A fidelidade está garantida por construção: o texto é montado a partir dos objetos calculados, e não pode divergir deles. Mas a *utilidade* para uma pessoa real não foi medida, porque não se chegou a fazer um estudo com utilizadores. Não se afirma nada sobre ela.
4. *Reportar os resultados tal como se revelarem.* Cumprido, e a prova é o resultado negativo da QI3 estar no documento com o mesmo destaque dos outros dois.

6.4 Limitações

Onde é que este trabalho é fraco?

Ditas em voz alta, por ordem de importância. A Figura 6.2 resume as cinco principais e o que cada uma pediria para ser fechada.

limitação, e está medida	o que a fecha	o que custa
Nenhuma avaliação com pessoas	Correr o estudo desenhado: 6 a 10 participantes	tempo de calendário
Os rótulos são aproximações	Anotar uma amostra com julgamento humano	tempo de calendário
O alerta afirma mais evidência do que tem	Medir o impacto por notícia, e não por dia	preços ao minuto
Só se lê o título, e não o corpo	Recolher e representar o texto integral	dados novos
A deriva é medida e não corrigida	Re-treinar com o que se observa em produção	baixo

Figura 6.2: Cada limitação desta secção foi **medida**, e não apenas afirmada. A coluna do meio é o trabalho que cada uma pede, e a da direita é a razão pela qual ainda não foi feito. As duas primeiras partilham o mesmo obstáculo, que é o único deste trabalho com relógio de calendário: sem julgamento humano sobre uma amostra, nem a utilidade das explicações nem a qualidade dos rótulos podem deixar de ser aproximações.

Não há estudo com utilizadores. É a lacuna maior e a mais fácil de nomear. Todo o sistema é construído à volta da ideia de que uma explicação ajuda um não-especialista a decidir melhor, e essa ideia **não foi testada com pessoas**. O desenho do estudo existe, com participantes, tarefas e critérios definidos, mas não foi corrido a tempo. Enquanto isso não acontecer, a metade “útil” do terceiro objetivo fica sem resposta, e é assim que está escrito.

A literatura é explícita quanto ao peso desta falta. Afirmarções de interpretabilidade exigem avaliação e não basta declará-las (Doshi-Velez e Kim 2017), e o motivo não é formalismo: o efeito de uma explicação sobre uma pessoa não é dedutível da sua construção. O que se sabe é que a confiança pode falhar nos *dois* sentidos, ignorando um aviso correto ou aceitando um errado (J. D. Lee e See 2004), e que a simples presença de uma explicação chega para aumentar a aceitação de respostas erradas (Bansal et al. 2021). Este sistema é construído para tornar a confiança apropriada, mostrando a evidência em vez de emitir um veredicto, mas *que o consiga* é uma hipótese por verificar e não um resultado. Note-se, aliás, que sem estudo com pessoas eu não consigo distinguir os dois modos de falha: um alerta ignorado e um alerta indevidamente acreditado são, para os meus registos, exatamente a mesma ausência de dados.

Os alertas ainda não estão bem calibrados, e sei disso a usar. Esta é a limitação que mais me incomoda, precisamente porque a noto como utilizador e não nos números. Recebo no telemóvel, por outras vias, notícias sobre estas empresas que o sistema não assinalou. E há dias em que uma ação sobe bastante e não gera alerta nenhum.

Parte disto está medido, e o número está na Secção 5.8: sobre um ano de notícias captadas, existia pelo menos uma notícia relevante em 88.5% dos dias que o detetor considerou invulgares. Os restantes 11.5% são dias em que **nenhuma alteração ao código ajuda**: se a fonte gratuita não associou nenhuma notícia à empresa, ela nunca entra no funil. E a cobertura é muito desigual: a empresa pior coberta fica-se pelos 50%.

Mas esse número é um **limite superior**, e a distinção importa: ele pergunta se existia *uma* notícia, não se chegou *a certa*. Saber isso exigiria julgamento humano dia a dia, e é trabalho por fazer.

O alerta afirma mais evidência do que tem. Quando mostra três precedentes e diz que os três se moveram na mesma direção, está a apresentar isso como concordância entre três casos. Só que o impacto é medido por (*empresa, dia*): três títulos da mesma empresa no mesmo dia partilham o mesmo valor por construção. Medido sobre os 247 alertas já entregues com precedentes, em 36.8% deles os casos assentam em menos dias distintos do que casos mostrados, e em 11.3% são todos do mesmo dia. Não afeta nenhum número do Capítulo 5; afeta o que o produto diz ao utilizador.

O alerta passou a contar dias e não títulos, o que torna a afirmação verdadeira. Mas a causa de fundo continua lá: o impacto é medido por dia, portanto duas notícias do mesmo dia nunca poderão ser duas observações independentes, por mais que se conte bem. Medir impacto por notícia exigiria dados de preço ao minuto, que as fontes gratuitas não dão.

As notícias são só títulos. O sistema lê o título e não o corpo do artigo. Isso limita o que a representação de texto consegue captar, e é uma explicação plausível, embora não confirmada, para o resultado negativo da Q13. As revisões de análise textual em finanças descrevem trabalhos que operam sobre documentos inteiros (Kearney e S. Liu 2014), e um título é, por construção, a parte do documento onde mais informação foi deitada fora.

Os rótulos são aproximações. “Relevante” é aproximado por “mesmo setor”, e “importante” é aproximado por “houve movimento grande”. As duas são objetivas e verificáveis, mas nenhuma é aquilo que realmente se queria medir. Esta dependência de aproximações não é uma particularidade deste trabalho: em domínios financeiros vizinhos, como a deteção

de fraude, os métodos não supervisionados ocupam um lugar central precisamente porque anomalias rotuladas são escassas (Ahmed, Mahmood e Islam 2016). Quem quiser um alvo melhor tem de o construir com julgamento humano, que é o que a segunda linha do trabalho futuro propõe.

A repartição de um movimento nem sempre está bem estimada. A decomposição em mercado, setor e empresa soma sempre exatamente ao movimento observado, mas essa soma fecha por construção e não valida nada, como a Secção 5.4 explica. A medida que diz alguma coisa é o R^2 da janela de estimação, cuja mediana foi 0.460 e que numa das dezassete empresas foi negativo. Nesses casos a repartição continua a ser exibida e deve ler-se como indicativa. O encolhimento do beta (Vasicek 1973) limita o dano de uma estimativa má, mas não a transforma numa boa.

Nada volta a ser treinado. O modelo implantado é o que foi treinado uma vez, e o sistema não se re-treina. A literatura de deriva de conceito trata exatamente deste problema, com uma taxonomia da mudança e estratégias de deteção e adaptação (Gama et al. 2014). Aqui a deriva é medida mas não é corrigida, e há um episódio concreto que mostra que o custo é real: o ciclo que faz maturar os casos observados esteve parado dezanove dias sem que um único erro fosse registado, porque o processo que os escrevia e o processo que os servia corriam em máquinas diferentes com discos diferentes. É a mesma classe de dependência de dados descrita atrás (D. Sculley et al. 2015), e foi encontrada a olhar, não por um alarme.

Escolhi para o produto um modelo que não podia fazer o que eu lhe estava a pedir. Esta é a limitação que mais me custa escrever, e é a que aprendi mais tarde.

O que foi implantado como porta de decisão foi a variante *sem texto*, escolhida por ter a melhor PR-AUC entre as que cabiam no contentor. Só que essa variante recebe informação de nível de *empresa*, e a única entrada que distingue dois títulos da mesma empresa no mesmo dia é o comprimento do título. A sua pontuação é quase constante dentro de cada empresa **por aritmética**, e não por acidente: na maioria das decisões o resultado estava determinado antes de a notícia ser lida (Secção 5.6.8).

Convém separar bem as duas afirmações, porque só uma delas é um erro:

- o **resultado da Q13 mantém-se**. A variante com texto tinha mesmo 384 números por título e perdeu à volatilidade. A pergunta de investigação foi respondida;
- a **escolha de produto estava errada**, e a razão é de método: escolhi por uma métrica que faz a pergunta “ordena bem no conjunto todo?” quando o produto precisava de “distingue duas notícias da mesma empresa?”. Uma pontuação constante por empresa responde bem à primeira e não responde de todo à segunda.

O sistema foi mudado: o modelo deixou de decidir e passou a ordenar entre empresas, que é o uso para o qual tem informação. Mas a limitação de fundo mantém-se, e não se resolve com nenhuma regra de decisão nem com mais treino. Resolve-se com entradas que variem com a notícia, e é a primeira linha do trabalho futuro.

Esta falha tem nome na literatura de sistemas de aprendizagem em produção, e reconhecê-la ajuda a generalizá-la. D. Sculley et al. (2015) descrevem, a partir de experiência com sistemas reais, uma classe de custo que não aparece em nenhuma métrica de qualidade: dependências de dados instáveis e emaranhamento entre componentes, em que a validade

de uma peça depende de suposições sobre outra que ninguém escreveu. Foi exatamente isso que aconteceu aqui. O modelo foi avaliado isoladamente, sobre a distribuição do conjunto de treino, e implantado atrás de dois filtros que alteram essa distribuição. Nenhum teste falhou, nenhum registo acusou nada, e o modelo continuou a produzir números com boa aparência durante meses. Um componente aprendido é avaliado onde é treinado e é útil onde é colocado, e quando esses dois sítios diferem a diferença não se anuncia sozinha.

O atraso é real e não se resolve com engenharia. Entre a notícia ser publicada e o sistema vê-la passar, em mediana, 158 minutos, perto de duas horas e quarenta minutos. A entrega, depois disso, demora um segundo. Comprar um serviço de notícias em tempo real resolveria e violaria a restrição fundadora deste trabalho.

6.5 Trabalho futuro

Se houvesse mais três meses, por onde começava?

Nada nesta lista é uma ideia solta. Os cinco primeiros itens fecham cada um uma limitação da secção anterior, e a Figura 6.3 mostra essa correspondência linha a linha, porque uma lista de trabalho futuro que não derive das limitações medidas é um pedido de desculpas com outra forma. O sexto é de outra natureza e por isso não está na figura: regista um caminho que foi considerado e *não* seguido, com as razões, que é informação de que precisa quem retomar isto.

Limitação medida	O que a fecha	Custo
Nenhuma avaliação com pessoas	Correr o estudo: 6 a 10 pessoas, 15 min cada	calendário
O modelo implantado é uma tabela de consulta: a maioria das decisões fecha antes de ler a notícia	Entradas que variem com o título	baixo: já existem no sistema
Cobertura de 88.5%, e 50% na pior empresa	Julgamento humano sobre uma amostra de dias	calendário
Lê o título e não o corpo do artigo	Ler o corpo dos artigos	dados novos
Repetição apanhada por palavras em comum	Detetar repetição por significado	baixo: técnica já existe

Figura 6.3: Cada linha do trabalho futuro responde a uma limitação que foi medida, e não a uma intuição. As duas que custam calendário e não computação são as que só se resolvem com pessoas, e são por isso as duas primeiras da lista numerada abaixo.

Por esta ordem, e as três primeiras respondem diretamente às limitações acima.

1. **Correr o estudo com utilizadores.** Seis a dez pessoas, quinze minutos cada. Fecha a metade em aberto do terceiro objetivo e é o único item desta lista que não se pode acelerar com mais computação: precisa de calendário.

2. **Estudar a sério os critérios de alerta.** É o trabalho que a limitação anterior pede. Não basta ajustar limiares: é preciso perceber, com julgamento humano sobre uma amostra de dias, quais das notícias que hoje não passam *deviam* passar, e quais das que passam não acrescentam nada. Isso daria pela primeira vez um alvo real para otimizar, em vez de se estar a afinar constantes contra um *proxy*.
3. **Dar ao modelo de decisão entradas que variem com a notícia.** É a correção direta da limitação anterior, e é barata: as duas quantidades óbvias já existem no sistema, que são a semelhança do melhor precedente e a concordância de direção entre eles. Ao contrário da volatilidade e do setor, mudam de título para título.
4. **Ler o corpo dos artigos, e não só o título.** É a hipótese mais direta para explicar o negativo da QI3, e é testável com o mesmo protocolo já montado.
5. **Detetar histórias repetidas por significado.** Hoje a repetição é apanhada por palavras em comum. Fazê-lo por significado usaria a técnica que o sistema já tem, e atacaria de frente a fadiga de alertas. Este ponto é mais importante do que parece: se os particulares compram aquilo que lhes chama a atenção (Barber e Odean 2008), um sistema que repete a mesma história três vezes não está a informar, está a amplificar o mesmo estímulo.
6. **Dar ao utilizador um conjunto em vez de um número.** A predição conformal permite devolver um conjunto de respostas com uma garantia livre de distribuição (Angelopoulos e Bates 2023; Vovk, Gammerman e Shafer 2005), o que encaixa bem numa ferramenta que recusa afirmar mais do que sabe. Foi considerada e não adotada, e ficam registadas as *duas* razões, porque quem retomar isto precisa das duas. A primeira é que a garantia é *marginal*, vale em média sobre os casos e não caso a caso, que é precisamente a leitura errada que um utilizador faria. A segunda é mais dura: a garantia exige **permutabilidade** entre calibração e teste, e estes dados são uma série temporal, com os títulos a chegarem por ordem. É a mesma hipótese que este trabalho recusa quando divide o conjunto por data e com embargo. Aplicar o método sem tratar isso daria intervalos com uma garantia que os dados não sustentam, e seria trocar um número honesto por um número com aparência de rigor.

6.6 O que eu aprendi

Termino com aquilo que mudou na minha cabeça ao longo destes meses, porque é a parte que não estava no plano.

A primeira foi perceber que **a linha de base é tão importante como o modelo**. Passei semanas a melhorar modelos e o resultado mais útil de todo o trabalho veio de olhar com atenção para aquilo contra o qual os estava a comparar. Numa das medições, o valor que eu usava como “escolher às cegas” não escolhia às cegas de todo: escolhia por ordem alfabética. Corrigir isso reduziu para menos de metade um ganho que eu já tinha escrito.

A segunda foi perceber que **o sítio onde se põe um modelo importa tanto como o modelo**. O meu funcionava razoavelmente quando avaliado sozinho e deixou de servir para nada quando colocado atrás de dois filtros simples, que já faziam grande parte do trabalho. Isso não estava em nenhum sítio do plano inicial, e é provavelmente a lição mais transferível que levo daqui.

E a terceira foi mais simples do que as outras: **a técnica mais simples ganhou três vezes**. Ganhou ao Isolation Forest, ganhou ao modelo que lê o texto, e uma tabela de treze constantes ganhou ao modelo que está implantado. Convém dizer também as duas vezes em que foi ao contrário: uma janela mais longa e um desvio-padrão com pesos que decaem obtêm ambos um F_1 melhor do que o que o sistema usa, e manteve o simples por ser explicável. Essas duas são uma *escolha*, e não um resultado, e é assim que estão escritas no Capítulo 5. Comecei este trabalho a assumir que o caminho para um bom resultado era acrescentar sofisticação. Acabo-o com medições a dizer o contrário, e com a convicção de que a parte difícil da engenharia de inteligência artificial não é escolher a técnica mais avançada, é montar a avaliação que consegue dizer que ela não era precisa.

Esta conclusão não é minha nem é original, e é por isso que me deixa mais descansado do que se fosse. Rudin (2019) defende que, em decisões de consequência séria, se deve usar modelos interpretáveis à partida em vez de explicar modelos opacos depois, e um dos argumentos é que a diferença de desempenho que justificaria a opacidade muitas vezes não existe quando se verifica. A primeira das minhas três comparações é uma instância disso, o z-score contra dois detetores cuja decisão não se lê, e há ainda uma quarta comparação, fora dessa lista e com a mesma lição, que é a regressão logística contra as árvores com reforço do gradiente.

A das treze constantes não é, e convém não a arrumar na mesma prateleira só porque a conclusão rima. A tabela de treze constantes não venceu um modelo opaco: venceu uma regressão logística calibrada, que é interpretável e cujas contribuições esta tese exhibe uma a uma. Aquilo não é um argumento sobre opacidade, é um argumento sobre *informação*: o modelo perdeu para uma tabela porque as suas entradas quase não variavam dentro de cada empresa, e não porque fosse complexo demais. São lições diferentes, e juntá-las tornaria a mais interessante das duas invisível.

Bibliografia

- Aamodt, Agnar e Enric Plaza (1994). «Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches». Em: *AI Communications* 7.1, pp. 39–59. doi: 10.3233/AIC-1994-7104.
- Adadi, Amina e Mohammed Berrada (2018). «Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)». Em: *IEEE Access* 6, pp. 52138–52160. doi: 10.1109/ACCESS.2018.2870052.
- Ahmed, Mohiuddin, Abdun Naser Mahmood e Md. Rafiqul Islam (2016). «A Survey of Anomaly Detection Techniques in Financial Domain». Em: *Future Generation Computer Systems* 55, pp. 278–288. doi: 10.1016/j.future.2015.01.001.
- Angelopoulos, Anastasios N. e Stephen Bates (2023). «Conformal Prediction: A Gentle Introduction». Em: *Foundations and Trends in Machine Learning* 16.4, pp. 494–591. doi: 10.1561/22000000101.
- Araci, Dogu (2019). «FinBERT: Financial Sentiment Analysis with Pre-trained Language Models». Em: *arXiv preprint*. arXiv: 1908.10063 [cs.CL].
- Bansal, Gagan et al. (2021). «Does the Whole Exceed its Parts? The Effect of AI Explanations on Complementary Team Performance». Em: *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. doi: 10.1145/3411764.3445717.
- Barber, Brad M. e Terrance Odean (2008). «All That Glitters: The Effect of Attention and News on the Buying Behavior of Individual and Institutional Investors». Em: *The Review of Financial Studies* 21.2, pp. 785–818. doi: 10.1093/rfs/hhm079.
- Barberis, Nicholas e Richard Thaler (2003). «A Survey of Behavioral Finance». Em: *Handbook of the Economics of Finance*. Ed. por George M. Constantinides, Milton Harris e René M. Stulz. Vol. 1. Elsevier. Cap. 18, pp. 1053–1128. doi: 10.1016/S1574-0102(03)01027-6.
- Barredo Arrieta, Alejandro et al. (2020). «Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI». Em: *Information Fusion* 58, pp. 82–115. doi: 10.1016/j.inffus.2019.12.012.
- Blume, Marshall E. (1971). «On the Assessment of Risk». Em: *The Journal of Finance* 26.1, pp. 1–10. doi: 10.1111/j.1540-6261.1971.tb00584.x.
- Bollerslev, Tim (1986). «Generalized Autoregressive Conditional Heteroskedasticity». Em: *Journal of Econometrics* 31.3, pp. 307–327. doi: 10.1016/0304-4076(86)90063-1.
- Breunig, Markus M. et al. (2000). «LOF: Identifying Density-Based Local Outliers». Em: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104. doi: 10.1145/342009.335388.
- Brown, Stephen J. e Jerold B. Warner (1985). «Using Daily Stock Returns: The Case of Event Studies». Em: *Journal of Financial Economics* 14.1, pp. 3–31. doi: 10.1016/0304-405X(85)90042-X.
- Cambridge Centre for Alternative Finance (2026). *Global AI in Financial Services Report: Adoption, Impact and Risks*. Cambridge Judge Business School, University of Cambridge. url: <https://www.jbs.cam.ac.uk/faculty-research/centres/alternative-finance>

- ce/publications/2026-global-ai-in-financial-services-report/ (acedido em 21/06/2026).
- Cardillo, Giovanni e Helen Chiappini (2024). «Robo-advisors: A Systematic Literature Review». Em: *Finance Research Letters* 62, p. 105119. doi: 10.1016/j.fr1.2024.105119.
- Chandola, Varun, Arindam Banerjee e Vipin Kumar (2009). «Anomaly Detection: A Survey». Em: *ACM Computing Surveys* 41.3, 15:1–15:58. doi: 10.1145/1541880.1541882.
- D. Sculley et al. (2015). «Hidden Technical Debt in Machine Learning Systems». Em: *Advances in Neural Information Processing Systems 28 (NIPS 2015)*. Curran Associates, Inc., pp. 2503–2511. url: https://papers.nips.cc/paper_files/paper/2015/hash/86df7dcfd896fcdf2674f757a2463eba-Abstract.html.
- D'Acunto, Francesco, Nagpurnanand Prabhala e Alberto G. Rossi (2019). «The Promises and Pitfalls of Robo-Advising». Em: *The Review of Financial Studies* 32.5, pp. 1983–2020. doi: 10.1093/rfs/hhz014.
- Da, Zhi, Joseph Engelberg e Pengjie Gao (2011). «In Search of Attention». Em: *The Journal of Finance* 66.5, pp. 1461–1499. doi: 10.1111/j.1540-6261.2011.01679.x.
- Devlin, Jacob et al. (2019). «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». Em: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, pp. 4171–4186. doi: 10.18653/v1/N19-1423.
- Ding, Xiao et al. (2015). «Deep Learning for Event-Driven Stock Prediction». Em: *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 2327–2333. url: <https://www.ijcai.org/Abstract/15/329>.
- Dong, Zihan, Xinyu Fan e Zhiyuan Peng (2024). «FNSPID: A Comprehensive Financial News Dataset in Time Series». Em: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '24)*. Association for Computing Machinery, pp. 4918–4927. doi: 10.1145/3637528.3671629.
- Doshi-Velez, Finale e Been Kim (2017). «Towards a Rigorous Science of Interpretable Machine Learning». Em: *arXiv preprint*. arXiv: 1702.08608 [stat.ML].
- Engle, Robert F. (1982). «Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation». Em: *Econometrica* 50.4, pp. 987–1007. doi: 10.2307/1912773.
- Fama, Eugene F. (1970). «Efficient Capital Markets: A Review of Theory and Empirical Work». Em: *The Journal of Finance* 25.2, pp. 383–417. doi: 10.2307/2325486.
- Fama, Eugene F. et al. (1969). «The Adjustment of Stock Prices to New Information». Em: *International Economic Review* 10.1, pp. 1–21. doi: 10.2307/2525569.
- Friedman, Jerome H. (2001). «Greedy Function Approximation: A Gradient Boosting Machine». Em: *The Annals of Statistics* 29.5, pp. 1189–1232. doi: 10.1214/aos/1013203451.
- Gallup (2025). *What Percentage of Americans Own Stock?* url: <https://news.gallup.com/poll/266807/percentage-americans-owns-stock.aspx> (acedido em 21/06/2026).
- Gama, João et al. (2014). «A Survey on Concept Drift Adaptation». Em: *ACM Computing Surveys* 46.4, pp. 1–37. doi: 10.1145/2523813.
- Google (jun. de 2026). *Our latest Google Finance upgrades, including a new app*. url: <https://blog.google/products-and-platforms/products/search/google-finance-updates-june-2026/> (acedido em 07/08/2026).
- Guidotti, Riccardo et al. (2018). «A Survey of Methods for Explaining Black Box Models». Em: *ACM Computing Surveys* 51.5, 93:1–93:42. doi: 10.1145/3236009.

- Hevner, Alan R. et al. (2004). «Design Science in Information Systems Research». Em: *MIS Quarterly* 28.1, pp. 75–106. doi: 10.2307/25148625.
- Huang, Allen H., Hui Wang e Yi Yang (2023). «FinBERT: A Large Language Model for Extracting Information from Financial Text». Em: *Contemporary Accounting Research* 40.2, pp. 806–841. doi: 10.1111/1911-3846.12832.
- Johnson, Jeff, Matthijs Douze e Hervé Jégou (2021). «Billion-Scale Similarity Search with GPUs». Em: *IEEE Transactions on Big Data* 7.3, pp. 535–547. doi: 10.1109/TBDATA.2019.2921572.
- Kahneman, Daniel e Amos Tversky (1979). «Prospect Theory: An Analysis of Decision under Risk». Em: *Econometrica* 47.2, pp. 263–291. doi: 10.2307/1914185.
- Kearney, Colm e Sha Liu (2014). «Textual Sentiment in Finance: A Survey of Methods and Models». Em: *International Review of Financial Analysis* 33, pp. 171–185. doi: 10.1016/j.irfa.2014.02.006.
- Lee, John D. e Katrina A. See (2004). «Trust in Automation: Designing for Appropriate Reliance». Em: *Human Factors* 46.1, pp. 50–80. doi: 10.1518/hfes.46.1.50_30392.
- Lipton, Zachary C. (2018). «The Mythos of Model Interpretability». Em: *Communications of the ACM* 61.10, pp. 36–43. doi: 10.1145/3233231.
- Liu, Fei Tony, Kai Ming Ting e Zhi-Hua Zhou (2008). «Isolation Forest». Em: *2008 Eighth IEEE International Conference on Data Mining (ICDM)*, pp. 413–422. doi: 10.1109/ICDM.2008.17.
- Liu, Zhuang et al. (2020). «FinBERT: A Pre-trained Financial Language Representation Model for Financial Text Mining». Em: *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence (IJCAI-20)*. International Joint Conferences on Artificial Intelligence Organization, pp. 4513–4519. doi: 10.24963/ijcai.2020/622.
- Loughran, Tim e Bill McDonald (2011). «When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks». Em: *The Journal of Finance* 66.1, pp. 35–65. doi: 10.1111/j.1540-6261.2010.01625.x.
- Lundberg, Scott M. e Su-In Lee (2017). «A Unified Approach to Interpreting Model Predictions». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 4765–4774. url: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html.
- Manning, Christopher D., Prabhakar Raghavan e Hinrich Schütze (2008). *Introduction to Information Retrieval*. Cambridge, England: Cambridge University Press. isbn: 978-0-521-86571-5.
- Mikolov, Tomas et al. (2013). «Distributed Representations of Words and Phrases and their Compositionality». Em: *Advances in Neural Information Processing Systems 26 (NIPS 2013)*. Vol. 26. Curran Associates, Inc., pp. 3111–3119. url: https://papers.nips.cc/paper_files/paper/2013/hash/9aa42b31882ec039965f3c4923ce901b-Abstract.html.
- Miller, Tim (2019). «Explanation in Artificial Intelligence: Insights from the Social Sciences». Em: *Artificial Intelligence* 267, pp. 1–38. doi: 10.1016/j.artint.2018.07.007.
- Niculescu-Mizil, Alexandru e Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». Em: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, pp. 625–632. doi: 10.1145/1102351.1102430.
- Pang, Guansong et al. (2021). «Deep Learning for Anomaly Detection: A Review». Em: *ACM Computing Surveys* 54.2, 38:1–38:38. doi: 10.1145/3439950.
- Peppers, Ken et al. (2007). «A Design Science Research Methodology for Information Systems Research». Em: *Journal of Management Information Systems* 24.3, pp. 45–77. doi: 10.2753/MIS0742-1222240302.

- Pennington, Jeffrey, Richard Socher e Christopher D. Manning (2014). «GloVe: Global Vectors for Word Representation». Em: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1532–1543. doi: 10.3115/v1/D14-1162.
- Reimers, Nils e Iryna Gurevych (2019). «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». Em: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. doi: 10.18653/v1/D19-1410.
- Ribeiro, Marco Tulio, Sameer Singh e Carlos Guestrin (2016). «“Why Should I Trust You?”: Explaining the Predictions of Any Classifier». Em: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135–1144. doi: 10.1145/2939672.2939778.
- Robertson, Stephen e Hugo Zaragoza (2009). «The Probabilistic Relevance Framework: BM25 and Beyond». Em: *Foundations and Trends in Information Retrieval* 4.1–2, pp. 1–174. doi: 10.1561/15000000019.
- Robinhood Markets (mar. de 2025). *Introducing Robinhood Strategies, Robinhood Banking, and Robinhood Cortex*. url: <https://robinhood.com/us/en/newsroom/introducing-strategies-banking-and-cortex/> (acedido em 07/08/2026).
- Rudin, Cynthia (2019). «Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead». Em: *Nature Machine Intelligence* 1.5, pp. 206–215. doi: 10.1038/s42256-019-0048-x.
- Salton, Gerard, A. Wong e C. S. Yang (1975). «A Vector Space Model for Automatic Indexing». Em: *Communications of the ACM* 18.11, pp. 613–620. doi: 10.1145/361219.361220.
- Securities Industry and Financial Markets Association (SIFMA) (2025). *2025 Capital Markets Fact Book*. url: <https://www.sifma.org/resources/research/fact-book/> (acedido em 21/06/2026).
- Tetlock, Paul C. (2007). «Giving Content to Investor Sentiment: The Role of Media in the Stock Market». Em: *The Journal of Finance* 62.3, pp. 1139–1168. doi: 10.1111/j.1540-6261.2007.01232.x.
- Vasicek, Oldrich A. (1973). «A Note on Using Cross-Sectional Information in Bayesian Estimation of Security Betas». Em: *The Journal of Finance* 28.5, pp. 1233–1239. doi: 10.1111/j.1540-6261.1973.tb01452.x.
- Vaswani, Ashish et al. (2017). «Attention Is All You Need». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 5998–6008. url: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fb053c1c4a845aa-Abstract.html.
- Vovk, Vladimir, Alexander Gammerman e Glenn Shafer (2005). *Algorithmic Learning in a Random World*. New York: Springer. isbn: 978-0-387-00152-4. doi: 10.1007/b106715.
- Welch, Ivo (2022). «The Wisdom of the Robinhood Crowd». Em: *The Journal of Finance* 77.3, pp. 1489–1527. doi: 10.1111/jofi.13128.
- World Monitor (2026). *Real-time global intelligence dashboard*. url: <https://worldmonitor.app> (acedido em 31/07/2026).
- Wu, Shijie et al. (2023). «BloombergGPT: A Large Language Model for Finance». Em: *arXiv preprint*. arXiv: 2303.17564 [cs.LG].
- Xing, Frank Z., Erik Cambria e Roy E. Welsch (2018). «Natural Language Based Financial Forecasting: A Survey». Em: *Artificial Intelligence Review* 50.1, pp. 49–73. doi: 10.1007/s10462-017-9588-9.

Apêndice A

Reprodutibilidade

A.1 Ambiente

O sistema está escrito em Python 3.12. As dependências do ambiente que produz os números desta dissertação estão fixadas num ficheiro de bloqueio, para que esse ambiente possa ser recriado noutra máquina. O serviço implantado tem o seu próprio conjunto, mais pequeno, porque não precisa de treinar nada. A Tabela A.1 lista as principais.

Tabela A.1: As versões com que todos os números deste documento foram produzidos, lidas do ficheiro de dependências do repositório. Estão fixadas, e não em intervalos, porque uma biblioteca que muda sozinha muda os resultados sem aviso.

Biblioteca	Versão	Biblioteca	Versão
numpy	2.1.3	sentence-transformers	5.6.0
pandas	2.2.3	transformers	5.12.1
scikit-learn	1.9.0	torch (versão CPU)	2.12.1
matplotlib	3.11.0	pytest	8.3.4
yfinance	1.4.1	ruff	0.8.6

Não é preciso GPU. Tudo o que esta dissertação reporta corre num computador portátil comum, o que é uma consequência deliberada das escolhas do Capítulo 3.

O código está organizado por componente, com um pacote para cada peça da Figura 4.1: dados de mercado, recolha de notícias, deteção, motor de correlação, base de casos, triagem, motor de explicação e entrega. A lógica pura está separada da entrada e saída, e as dependências pesadas são carregadas só quando precisas, e por isso o núcleo é testado sem rede e sem carregar modelos. A suite tem **754 testes** automáticos.

Os segredos (chaves de API, credenciais) são lidos de um ficheiro local que nunca é versionado.

A.2 Como cada número é reproduzido

Nenhum *resultado* desta dissertação foi escrito à mão. Cada um é produzido por um procedimento automático com semente fixa, que escreve o seu próprio ficheiro de resultados; o texto cita esse ficheiro. A Tabela A.2 reúne todos os resultados reportados e indica onde cada um aparece no corpo do documento; o ficheiro de resultados correspondente, e o procedimento que o escreve, estão nomeados no repositório de código.

A garantia de determinismo vale para tudo o que está acima da linha divisória da tabela. As três linhas de baixo são de outra natureza e por isso estão separadas: são medições sobre a *operação*, e o seu valor depende de quando o registo foi lido, não de uma semente. O capítulo onde aparecem diz sempre sobre que período e que conjunto foram feitas.

Os restantes números do documento são de três tipos. Os **valores retirados das fontes citadas** estão citados no sítio onde aparecem. As **constantes de configuração** estão na Tabela 4.5, com a distinção entre as que foram derivadas e as que foram escolhidas. E há um terceiro tipo, que convém não esconder: **medições minhas que ficam fora desta tabela** porque servem uma passagem e não um resultado, como as 820 linhas que o embargo descarta, o σ do caso trabalhado da Tesla, o custo de memória dos três formatos, ou as contagens por fonte de notícias. Cada uma diz, no sítio onde aparece, sobre que dados foi feita.

Uma delas merece nota própria, porque é a única que não se pode regenerar. A repartição do funil por porta, na Tabela 4.4, foi lida do registo de decisões num dia concreto, e esse registo guarda apenas três dias: a razão está na Secção 3.3, e é que ele é republicado a cada ciclo, portanto o custo é de publicação e não de armazenamento. Correr o mesmo procedimento hoje daria outro dia, não o mesmo. Fica dito assim, em vez de se apresentar como reproduzível uma medição que o não é.

Declarar que um número não se regenera não é, porém, o mesmo que mostrar de onde ele veio, e essa segunda parte faltava: a repartição estava escrita apenas nesta dissertação. Passou a estar também num ficheiro de evidência, ao lado dos outros, com a data da leitura e com o procedimento que a produziu, de forma a que qualquer dia futuro tenha origem mesmo que aquele já não volte.

A.3 Matriz de evidência

A tabela anterior lista *resultados*. Esta lista *afirmações*, que é um teste mais duro, porque uma afirmação pode sobreviver à evidência que a sustentava.

A Tabela A.3 põe cada afirmação substantiva desta dissertação frente à evidência que a suporta e ao estado em que ficou. **As afirmações retiradas ficam na tabela em vez de serem apagadas**, porque uma matriz que só lista as sobreviventes não é uma auditoria.

Duas observações sobre a tabela no seu conjunto, e não sobre nenhuma linha.

Primeiro: **quatro afirmações foram retiradas, e todas o foram pelas medições deste próprio trabalho**, nenhuma por revisão externa. É o comportamento pretendido de uma avaliação desenhada antes das experiências: tem de ser capaz de dizer que não.

Segundo: as duas linhas marcadas “não afirmado” são tão importantes como as outras. Uma delas é a utilidade para o utilizador, que não foi medida porque não houve estudo com pessoas. Onde não há evidência, não há afirmação.

A.4 Dados e atribuição

Os corpora de origem não são versionados: o conjunto histórico completo ocupa centenas de megabytes e é regenerado pelos procedimentos de preparação. Acompanham o código pequenas amostras, para que os testes corram sem rede, e uma excepção que convém declarar: a **base de casos que o sistema consulta** está versionada, com 56 megabytes de

vetores e 8 de metadados. Não é uma amostra, é o artefacto de que a aplicação implantada precisa para arrancar, e sem ele o sistema não teria precedentes para mostrar.

O conjunto histórico usado para construir a base de casos é o FNSPID (Dong, Fan e Peng 2024), utilizado ao abrigo da sua licença Creative Commons BY-SA 4.0, cuja atribuição é aqui cumprida. Apenas excertos mínimos de títulos aparecem no documento, a título ilustrativo.

Essa licença tem uma segunda obrigação que convém não calar, porque é acionada: como o repositório distribui ficheiros *derivados* do FNSPID, a cláusula de partilha nos mesmos termos aplica-se a eles. A licença do código é uma decisão que fica em aberto neste documento, e é esta a restrição que a condiciona.

Os preços vêm de serviços gratuitos de dados de mercado, através de uma cadeia de alternativas descrita na Secção 4.2; as notícias em tempo real vêm de uma API gratuita, dentro dos seus limites de utilização. Sobre dados pessoais convém ser exato em vez de generoso. O sistema **não sabe o que os utilizadores possuem e não lhes pergunta**, que é a decisão de desenho que interessa: não há carteira, não há posições, não há montantes. O canal público não identifica ninguém. Há, no entanto, uma funcionalidade opcional em que quem quiser receber alertas personalizados fala com o robô, e aí ficam guardados o identificador de conversa do Telegram e a lista de empresas que essa pessoa escolheu seguir. É pouco, e é a totalidade: fica dito, porque “nenhum dado pessoal” seria mais simples de escrever e não seria verdade.

Tabela A.2: Todos os resultados reportados, e onde são gerados. Correr outra vez sobre os mesmos dados devolve exatamente os mesmos valores.

Resultado	Valor	Onde aparece
Amplitude da taxa de disparo (z-score vs limiar fixo)	0.015 vs 0.344	§5.3
F_1 contra o rótulo aproximado	0.516 vs 0.218	§5.3
z-score contra dois detetores aprendidos	0.530 / 0.269 / 0.280	§5.3
Precisão@5 da recuperação (4 métodos)	0.514 / 0.346 / 0.240 / 0.126	§5.5
Precisão@5 sobre o corpus completo	0.595	§5.5
Precisão@5 só com precedentes anteriores	0.513 com chão 0.259	§5.5.4
Concordância de direção vs chão de acaso	0.708 vs 0.688	§5.5
Triagem, PR-AUC das seis famílias	0.378 a 0.542	§5.6
Precisão dentro do orçamento (4 formas de escolher)	0.163 / 0.379 / 0.662 / 0.632	§5.6
Grelha de nove definições de rótulo	9 de 9	§5.6
Decomposição de um movimento, caso trabalhado	-0.3992 / -0.0362 / +6.7298 %	§3.5
R^2 da decomposição, mediana e casos negativos	0.460, 1 de 17	§5.4
Ablação da identidade: tabela de consulta vs modelo	0.534 vs 0.538	§5.6.9
O texto por cima da tabela de consulta	0.547 contra 0.534	§5.6.10
Selectividade da porta, dentro vs entre empresas	0.064 vs 0.385	§5.6.7
Deriva de distribuição, PSI da volatilidade	0.281	§5.6.6
Sistema inteiro contra as alternativas	0.489 / 0.632 / 0.662 / 0.968	§5.8
Ablação à janela e ao peso do desvio	0.678 e 0.664 contra 0.516	§5.7
<i>Medições sobre a operação, sem semente: dependem de quando o registo foi lido</i>		
Decisões maturadas em produção, mantidas vs suprimidas	0.589 vs 0.617	§5.6
Cobertura das notícias em dias invulgares	88.5%	§6.4
Latência, por era e decomposta	196 / 143 / 158 min	§4.8
Funil de produção (captadas → enviadas)	944 → 42	§4.6
Funil de um dia, repartido por porta	5 060 → 5	§4.6

Tabela A.3: Cada afirmação, a evidência, e o que lhe aconteceu. “Retirada” significa que este trabalho a abandonou depois de a medir.

Afirmação	Evidência	Estado
QI1, deteção		
Dispara a um ritmo comparável entre empresas muito diferentes	Amplitude 0.015 vs 0.344, sem usar rótulos	Mantida
Bate um limiar fixo no rótulo aproximado	F_1 0.516 vs 0.218	Mantida (o rótulo é um proxy)
Bate dois detetores aprendidos com a mesma informação	F_1 0.530 vs 0.269 e 0.280	Mantida
Não usa informação do futuro	A janela exclui o dia julgado; imposto por teste	Mantida
QI2, precedentes		
Bate as alternativas lexical e triviais	P@5 0.514 vs 0.346 / 0.240 / 0.126	Mantida
Bate por larga margem o melhor chão trivial	“Sempre o setor maior” dá 0.467: a margem é +0.047 e não +0.274	Estreitada (o agregado media a composição do corpus; a afirmação passa a ser por setor, onde ela se mantém nos cinco)
Aguenta à escala do corpus completo	P@5 0.595	Mantida
Aguenta a restrição da produção (só o passado)	P@5 0.513 com chão 0.259: a margem sobre o acaso muda 0.008	Estreitada (o número simétrico descrevia uma tarefa mais fácil)
Capta tema, não direção	Concordância 0.708 contra um chão de 0.688	Mantida (é uma limitação)
“Relevante” é o mesmo que “mesmo setor”	—	Não afirmado (é um proxy)
O chão de semelhança escolhe precedentes que preveem melhor	Acima do chão 0.504, abaixo 0.506, acaso 0.507	Retirada
QI3, triagem		
Nenhum modelo com texto bate a volatilidade	PR-AUC 0.496 vs 0.542; aguenta re-teste justo, reamostragem por grupos e nove rótulos	Mantida
O texto acrescenta por cima da tabela de consulta	PR-AUC 0.547 contra 0.534: +0.012, IC [+0.004, +0.020] por grupos	Nova (positiva, e não muda a precisão no orçamento)
Sem uso de informação futura nas entradas	Mutar o futuro deixa as entradas iguais e muda o rótulo	Mantida
A triagem quase quadruplica a precisão no orçamento	O chão de 0.163 ordena alfabeticamente; ao acaso dá 0.379	Retirada (o ganho é 1.67×)
É a aprendizagem que produz o ganho no orçamento	Um prior de 13 constantes dá 0.662 contra 0.632 do modelo	Retirada
O modelo implantado seleciona melhor do que o acaso	0.589 mantidas contra 0.617 suprimidas	Retirada
Sistema		
O texto do alerta não pode divergir do cálculo	É montado a partir dos objetos calculados	Mantida
A fonte gratuita limita a cobertura	Pelo menos uma notícia em 88.5% dos dias invulgares	Mantida (limite superior)
As explicações são úteis a uma pessoa	—	Não afirmado