

Explicar sem prever

Alertas financeiros com evidência verificável para o investidor particular


Henrique José da Silva Santos

Orientador: Prof. Luís Gomes Coorientador: Rafael Silva

MEIA, Instituto Superior de Engenharia do Porto

Defesa

Uma pessoa abre a aplicação, vê isto, e fica com três perguntas



1. Isto é invulgar?

4% numa empresa calma é muito. Noutra, é terça-feira.

2. Foi a empresa, ou foi o mercado?

Se caiu tudo, a história é outra.

3. Já aconteceu antes, e o que se seguiu?

Houve dias parecidos? O que fez o preço depois?

As aplicações gratuitas não respondem a nenhuma delas.


O que existe hoje

	invulgar?	empresa ou mercado?	já aconteceu?	custo
Aplicação da corretora	—	—	—	incluído
Agregador de notícias	—	—	—	grátis
<i>Robo-advisor</i>	—	—	—	% da carteira
Terminal profissional	✓	✓	✓	milhares/ano
Este trabalho	✓	✓	✓	grátis

A linha que responde às três **já existe**. É a mais cara de todas.

O problema não é científico: é de acesso.

O que o sistema faz



E há uma coisa que ele **recusa** fazer.

Nunca diz que vai subir.

Nunca diz para comprar.

Nunca mostra um alvo de preço.

Parece uma limitação. É o contrário:
é o que torna tudo o resto verificável.

Uma afirmação sobre o que já aconteceu confere-se contra o registo.

Uma previsão não se confere.

Técnica 1: é invulgar?

Comparar o dia de hoje com os **20 dias anteriores da mesma ação**.




$$z = \frac{\text{movimento de hoje} - \text{média}}{\text{desvio-padrão}}$$

$z = +7$ quer dizer o mesmo numa empresa calma e numa volátil.

O dia julgado não entra no cálculo da sua própria norma. Sem isto, seria falsear.

Técnica 2: foi a empresa, ou foi o mercado?

Um +6.29% pode ser a empresa ou pode ser o mercado. A aplicação da corretora mostra o **mesmo número** nos dois casos.



A AMD subiu **apesar** de o mercado e o setor terem puxado ao contrário. Os *betas* são estimados **só com dias anteriores**.


Ressalva: as parcelas somam sempre, porque a da empresa é o resto, e isso não prova que estejam bem estimadas. R^2 mediano 0.460, e num dos casos negativo.

É a única das quatro sem questão de investigação: não há resposta certa contra a qual comparar, e por isso o que se mede nela é o ajuste, e não o acerto.

Técnica 3: já aconteceu antes?

Procurar por palavras falha nos **dois** sentidos:

mesmo sentido, palavras diferentes



palavra igual, sentido diferente



Cada título passa a **384 números**: uma coordenada de significado.

Compara-se pelo **ângulo** entre elas.

Depois, para cada caso passado, mede-se o que o preço fez a +1, +3 e +5 dias.

É uma medição do passado, não uma previsão.

Técnica 4: merece avisar?

Aqui não há fórmula óbvia. É o sítio para **aprender dos dados**.

- **79 753** exemplos que construí a partir de notícias e preços (2018–2023)
- Pergunta: *depois desta notícia houve um movimento anormalmente grande?*
- **Em valor absoluto**, nunca em que direção
- Divisão **cronológica** com embargo; probabilidades calibradas

O modelo, o seu treino e as suas métricas ficam guardados como artefactos.

É o meu modelo, treinado nos meus dados.

Um alerta real, do princípio ao fim

Meta, 12 de julho de 2026. *“Mark Zuckerberg Said Meta's AI Bets ‘Haven't Come to Fruition Yet’ as Shares*

	etapa	o que aconteceu
Fell 5%”	2 nomeia a empresa?	“Meta”, “Zuckerberg” ✓
	3 é recente?	menos de 2 dias ✓
	4 casos parecidos	MSFT 0.46 · NVDA 0.51 · NVDA 0.46
	5 evidência forte?	melhor $0.51 \geq 0.45$ ✓
	6 merece avisar?	$54\% \geq 50\%$ ✓
	9 enviado	ao canal, e guardado

Os desfechos foram **em sentidos opostos**: $+2.70\% \cdot -3.87\% \cdot +5.05\%$

Por isso mostram-se **um a um**: uma média esconderia isso.

Resultado 1: deteção **sim**

Um bom detetor deve disparar a um ritmo **parecido** em empresas diferentes.

	mín	máx	amplitude
z-score	0.016	0.031	0.015
Limiar fixo de 3%	0.009	0.353	0.344

Mais de **20 vezes** mais consistente.

E ganha também a dois métodos aprendidos: F_1 0.530 contra 0.269 e 0.280.

Resultado 2: precedentes **sim**

método	precisão@5
Por significado (o método)	0.514
Por palavras em comum	0.346
Ao acaso (o chão)	0.240
As mais recentes	0.126

- Sobre o corpus completo (80 mil notícias): **0.595**
- **Capta tema, não direção**, e é por isso que os casos aparecem um a um

Resultado 3: triagem **não**

modelo	PR-AUC
Só volatilidade	0.542
Só contexto	0.538
Contexto + texto	0.496
Só texto	0.439

Nenhum modelo que lê o texto bate a volatilidade.

Era o contrário do que eu esperava. Verifiquei por três caminhos: re-teste em condições favoráveis ao texto (0.533, ainda abaixo), reamostragem por grupos, e **nove** definições diferentes do rótulo: a volatilidade ganha nas nove.

O erro que encontrei em mim próprio

Eu tinha escrito que a triagem “*quase quadruplica*” a precisão: de 0.163 para 0.632.

O 0.163 vinha do modelo “alertar sempre”, que dá a mesma pontuação a tudo.

Com tudo empatado, a métrica desempata pela ordem do ficheiro, que está ordenado por data e por nome da empresa.


Esse número não media escolher às cegas.
Media escolher por ordem alfabética.

Ao acaso a sério dá 0.379 $\Rightarrow$ o ganho é de **1.67** $\times$, não de quase quatro.

E uma tabela de **13 constantes** dá 0.662: bate o modelo treinado.

E encontrei-o outra vez, um nível acima

O sistema decidia se avisava com um **limiar fixo** sobre a pontuação do modelo: passa quem estiver acima de 0.50.



Em **84%** das decisões, o resultado estava determinado pela **empresa** antes de o título ser lido.

A Apple não conseguia gerar um alerta de notícia. A AMD passava em 963 de 963.

E a correção óbvia também estava errada

A tentação: se um limiar fixo mede a empresa e não a notícia, torna-se *relativo a cada empresa*, que foi exatamente o que o z-score fez para os preços.

Simulei-o **antes** de escrever código. Metade resolve-se: as doze passam a estar representadas.

Mas nas empresas de pontuação quase constante o percentil cai *em cima* da constante e quase tudo empata acima. A JNJ passaria **874** vezes.

Não se corrige um defeito introduzindo o defeito vizinho.

O que se fez: o modelo deixou de decidir e passou a **ordenar**, com um orçamento de 5 alertas por dia. E isso fechou uma divergência: a dissertação *avaliava* uma política de orçamento e o sistema *implantava* uma de limiar.

Então quanto vale o modelo? Duas medições que respondem

1. Tirei-lhe a notícia.

Uma *tabela de consulta*: um número fixo por empresa, zero informação sobre o título.

o que vê	PR-AUC
o implantado, nove entradas	0.538
só a empresa	0.534
sem nada da empresa	0.378
só o comprimento do título	0.378

Diferença de 0.004, e 0.378 é o chão. **O modelo implantado é uma tabela de consulta.**

2. Comparei o sistema inteiro.

Precisão nas cinco notícias que o produto mostra por dia.

política	prec.@5
ao acaso	0.375
quem mais se mexeu hoje	0.489
o sistema	0.632
volatilidade, treze constantes	0.662
oráculo	0.968

Bate a alternativa realista. **Mas o oráculo é a informação nova:** as notícias importantes *estão* no lote.

A margem que falta não está em melhores dados. Está em **separar duas notícias da mesma empresa no mesmo dia.**

Limitações, ditas antes de me perguntarem, e o que as fecha

Cada limitação foi medida, e a coluna da direita é o trabalho que ela pede.

limitação medida		o que a fecha	custo
Nenhuma avaliação com pessoas	→	Correr o estudo: 6 a 10 pessoas	calendário
O modelo implantado é uma tabela de consulta	→	Entradas que variem com o título	baixo
Cobertura de 88.5%, e 50% na pior	→	Julgamento humano sobre uma amostra	calendário
Lê o título e não o corpo	→	Ler o corpo dos artigos	dados novos
Deriva: a entrada de que mais depende é a que mais derivou	→	Re-treinar com o que se observa	baixo

Mais duas: o atraso é da *fonte* e não da infraestrutura (≈ 2.5 h até detetar, 1 s até entregar); e **nada volta a ser treinado**, porque a base de casos cresce sozinha, os pesos não.

O sistema está no ar.

[gravação]

uma notícia real, do momento em que chega
até ao alerta que sai

O que aprendi

❶ A linha de base é tão importante como o modelo.

O resultado mais útil do trabalho veio de olhar para aquilo contra o qual eu estava a comparar.

❷ O sítio onde se põe um modelo importa tanto como o modelo.

O meu funcionava sozinho e deixou de servir atrás de dois filtros simples, que já faziam o trabalho.

❸ A técnica mais simples ganhou três vezes.

Ao Isolation Forest e ao modelo que lê o texto, que são *simples contra complexo*. E uma tabela de constantes ganhou ao modelo implantado, que é um caso diferente: ali o modelo até era interpretável, e perdeu por **falta de informação**.

A parte difícil não foi escolher a técnica mais avançada.
Foi montar a avaliação **capaz de dizer que ela não era precisa**.

Obrigado. Perguntas?