

Explicar sem prever

Deteção de anomalias e recuperação de precedentes em alertas verificáveis

Henrique José da Silva Santos


Orientador: Prof. Luís Gomes Coorientador: Rafael Silva

MEIA, Instituto Superior de Engenharia do Porto

Defesa



Uma pessoa abre a aplicação, vê isto, e fica com três perguntas



1. Isto é invulgar?

4% numa empresa calma é muito. Noutra, é terça-feira.

2. Foi a empresa, ou foi o mercado?

Se caiu tudo, a história é outra.

3. Já aconteceu antes, e o que se seguiu?

Houve dias parecidos? O que fez o preço depois?


As aplicações gratuitas não respondem a nenhuma delas.

O que existe hoje

	invulgar?	empresa ou mercado?	já aconteceu?	custo
Aplicação da corretora	—	—	—	incluído
Agregador de notícias	—	—	—	grátis
<i>Robo-advisor</i>	—	—	—	% da carteira
Terminal profissional	✓	✓	✓	milhares/ano
Este trabalho	✓	✓	✓	grátis

A linha que responde às três **já existe**. É a mais cara de todas.
O problema não é científico: é de acesso.

O que o sistema faz



E há uma coisa que ele **recusa** fazer.

Nunca diz que vai subir.

Nunca diz para comprar.

Nunca mostra um alvo de preço.

Parece uma limitação. É o contrário:
é o que torna tudo o resto verificável.

Uma afirmação sobre o que já aconteceu confere-se contra o registo.

Uma previsão não se confere.

Técnica 1: é invulgar?

Comparar o dia de hoje com os **20 dias anteriores da mesma ação**.




$$z = \frac{\text{movimento de hoje} - \text{média}}{\text{desvio-padrão}}$$

$z = +7$ quer dizer o mesmo numa empresa calma e numa volátil.

O dia julgado não entra no cálculo da sua própria norma. Sem isto, seria falsear.

Técnica 2: foi a empresa, ou foi o mercado?

Um +6.29% pode ser a empresa ou pode ser o mercado. A aplicação da corretora mostra o **mesmo número** nos dois casos.



A AMD subiu **apesar** de o mercado e o setor terem puxado ao contrário. Os *betas* são estimados **só com dias anteriores**.

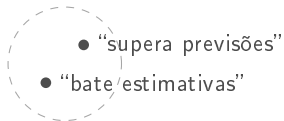
Ressalva: as parcelas somam sempre, porque a da empresa é o resto, e isso não prova que estejam bem estimadas. R^2 mediano 0.460, e num dos casos negativo.

É a única das quatro sem questão de investigação: não há resposta certa contra a qual comparar, e por isso o que se mede nela é o ajuste, e não o acerto.

Técnica 3: já aconteceu antes?

Procurar por palavras falha nos **dois** sentidos:

mesmo sentido, palavras diferentes



palavra igual, sentido diferente



Cada título passa a **384 números**: uma coordenada de significado.

Compara-se pelo **ângulo** entre elas.

Depois, para cada caso passado, mede-se o que o preço fez a +1, +3 e +5 dias.

É uma **medição do passado**, não uma **previsão**.

Técnica 4: merece avisar?

Aqui não há fórmula óbvia. É o sítio para **aprender dos dados**.

- **79 753** exemplos que construí a partir de notícias e preços (2018–2023)
- Pergunta: *depois desta notícia houve um movimento anormalmente grande?* **Em valor absoluto**, nunca em que direção



Divisão por **dias inteiros** com embargo de **cinco**, nunca por linhas: duas notícias do mesmo dia não podem cair uma de cada lado. E a garantia não é prometida, é **imposta por um teste**: dois futuros absurdos (+300% e –99%) sobre o mesmo passado têm de dar entradas **idênticas** e rótulos **diferentes**. Se o futuro vazasse, as entradas mudavam.

Um alerta real, do princípio ao fim

Meta, 12 de julho de 2026. *“Mark Zuckerberg Said Meta's AI Bets ‘Haven't Come to Fruition Yet’ as Shares*

	etapa	o que aconteceu
Fell 5%”	2 nomeia a empresa?	“Meta”, “Zuckerberg” ✓
	3 é recente?	menos de 2 dias ✓
	4 casos parecidos	MSFT 0.46 · NVDA 0.51 · NVDA 0.46
	5 evidência forte?	melhor $0.51 \geq 0.45$ ✓
	6 merece avisar?	$54\% \geq 50\%$ ✓
	9 enviado	ao canal, e guardado

Os desfechos foram **em sentidos opostos**: $+2.70\% \cdot -3.87\% \cdot +5.05\%$

Por isso mostram-se **um a um**: uma média esconderia isso.

Resultado 1: deteção **sim**

Um bom detetor deve disparar a um ritmo **parecido** em empresas diferentes.

	mín	máx	amplitude
z-score	0.016	0.031	0.015
Limiar fixo de 3%	0.009	0.353	0.344

Mais de **20 vezes** mais consistente.

E ganha também a dois métodos aprendidos: F_1 0.530 contra 0.269 e 0.280.

Resultado 2: precedentes **sim**

método	precisão@5
Por significado (o método)	0.514
Sempre o setor maior	0.467
Por palavras em comum	0.346
Ao acaso (o chão)	0.240
As mais recentes	0.126

- Metade do corpus é tecnologia: **devolver sempre tecnologia** vale 0.467 sem modelo nenhum. A margem real é +0.047, e não +0.274.
- **Mas essa alternativa acerta em tudo num setor e em nada nos outros quatro.** Dentro de cada setor o método ganha nos **cinco**: 0.448 na energia, com chão 0.072.
- No corpus completo, sob a restrição causal da produção: **0.513**, com chão **0.259** e margem +0.254. O **0.595** é o teste simétrico de escala.
- E **capta tema, não direção**, que é porque os casos aparecem um a um.

Resultado 3: triagem **não**

modelo	PR-AUC
Só volatilidade	0.542
Só contexto	0.538
Contexto + texto	0.496
Só texto	0.439

Nenhum modelo que lê o texto bate a volatilidade.

Era o contrário do que eu esperava. Verifiquei por três caminhos: re-teste em condições favoráveis ao texto (0.533, ainda abaixo), reamostragem por grupos, e **nove** definições diferentes do rótulo: a volatilidade ganha nas nove.

O erro que encontrei em mim próprio

Eu tinha escrito que a triagem “*quase quadruplica*” a precisão: de 0.163 para 0.632.

O 0.163 vinha do modelo “alertar sempre”, que dá a mesma pontuação a tudo.

Com tudo empatado, a métrica desempata pela ordem do ficheiro, que está ordenado por data e por nome da empresa.


Esse número não media escolher às cegas.
Media escolher por ordem alfabética.

Ao acaso a sério dá 0.379 $\Rightarrow$ o ganho é de **1.67** $\times$, não de quase quatro.

E uma tabela de **13 constantes** dá 0.662: bate o modelo treinado.

E encontrei-o outra vez, um nível acima

O sistema decidia se avisava com um **limiar fixo** sobre a pontuação do modelo: passa quem estiver acima de 0.50.



Em **84%** das decisões, o resultado estava determinado pela **empresa** antes de o título ser lido.

A Apple não conseguia gerar um alerta de notícia. A AMD passava em 963 de 963.

E a correção óbvia também estava errada

A tentação: se um limiar fixo mede a empresa e não a notícia, torna-se *relativo a cada empresa*, que foi exatamente o que o z-score fez para os preços.

Simulei-o **antes** de escrever código. Metade resolve-se: as doze passam a estar representadas.

Mas nas empresas de pontuação quase constante o percentil cai *em cima* da constante e quase tudo empata acima. A JNJ passaria **874** vezes.

Não se corrige um defeito introduzindo o defeito vizinho.

O que se fez: o modelo deixou de decidir e passou a **ordenar**, com um orçamento de 5 alertas por dia. E isso fechou uma divergência: a dissertação *avaliava* uma política de orçamento e o sistema *implantava* uma de limiar.

Então quanto vale o modelo? Duas medições que respondem

1. Tirei-lhe a notícia.

Uma *tabela de consulta*: um número fixo por empresa, zero informação sobre o título.

o que vê	PR-AUC
o implantado, nove entradas	0.538
só a empresa	0.534
sem nada da empresa	0.378
só o comprimento do título	0.378

Diferença de 0.004, e 0.378 é o chão. **O modelo implantado é uma tabela de consulta.**

2. Comparei o sistema inteiro.

Precisão nas cinco notícias que o produto mostra por dia.

política	prec.@5
ao acaso	0.375
quem mais se mexeu hoje	0.489
o sistema	0.632
volatilidade, treze constantes	0.662
oráculo	0.968

Bate a alternativa realista. **Mas o oráculo é a informação nova:** as notícias importantes *estão* no lote.

A margem que falta não está em melhores dados. Está em **separar duas notícias da mesma empresa no mesmo dia.**

“E onde está a engenharia de inteligência artificial?”

Começo pela parte incômoda: este trabalho treina **um** modelo, e é uma regressão logística com nove entradas que **perdeu** para uma linha de base de uma só variável.

A engenharia não está no tamanho do modelo.

Está no que foi preciso construir para que aquele número, e a conclusão negativa que ele sustenta, sejam *de confiança*.

1. O conjunto de dados é **construído**, não encontrado: 79 753 linhas que não existiam.
2. O rótulo é uma **decisão**, e por isso mediram-se **nove** definições alternativas.
3. A separação temporal é imposta por um **teste** que muta o futuro, não prometida.
4. As probabilidades são calibradas, e o seu enviesamento está **medido**.
5. O modelo, o calibrador e a corrida estão **versionados**.
6. O modelo implantado é o modelo avaliado: exportado para um formato leve, com a fidelidade da conversão medida em vez de assumida.
7. O que corre é **observado**: cada decisão é registada e confrontada dias depois com o que o preço fez. Foi assim que se soube que *não* estava a ajudar.

A parte difícil não foi escolher a técnica. Foi montar a avaliação que **consegue dizer que não**, e depois acreditar nela.


Limitações, ditas antes de me perguntarem, e o que as fecha

Cada limitação foi medida, e a coluna da direita é o trabalho que ela pede.

limitação medida		o que a fecha	custo
Nenhuma avaliação com pessoas	→	Correr o estudo: 6 a 10 pessoas	calendário
O modelo implantado é uma tabela de consulta	→	Entradas que variem com o título	baixo
Cobertura de 88.5%, e 50% na pior	→	Julgamento humano sobre uma amostra	calendário
Lê o título e não o corpo	→	Ler o corpo dos artigos	dados novos
Deriva: a entrada de que mais depende é a que mais derivou	→	Re-treinar com o que se observa	baixo

Mais duas: o atraso é da *fonte* e não da infraestrutura (≈ 2.5 h até detetar, 1 s até entregar); e **nada volta a ser treinado**, porque a base de casos cresce sozinha, os pesos não.

As três perguntas, respondidas no ecrã



1. É invulgar?

Em palavras, antes do número: 204 dos últimos 250 dias moveram-se tanto ou mais. O veredicto é “*Quiet*”, e é dito antes de qualquer valor.

2. Foi a empresa?

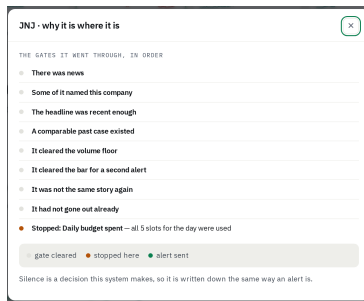
Não. A ação desce 0.30%, mas a contribuição da própria empresa é **positiva** (+0.53%): quem a puxa para baixo é o **mercado** (−0.61%). A percentagem sozinha mandava procurar na empresa uma razão que estava fora dela.

3. Já aconteceu?

Os dias assinalados na curva, e os precedentes dentro do texto do alerta.

O sistema está no ar. [gravação]

uma notícia real, do momento em que chega até ao alerta que sai



O percurso de uma candidata pelas portas, até onde parou. **É a parte que uma demonstração ao vivo não mostra:** nove em cada dez varreduras não enviam nada, e o silêncio fica escrito como um alerta.

O que aprendi

❶ A linha de base é tão importante como o modelo.

O resultado mais útil do trabalho veio de olhar para aquilo contra o qual eu estava a comparar.

❷ O sítio onde se põe um modelo importa tanto como o modelo.

O meu funcionava sozinho e deixou de servir atrás de dois filtros simples, que já faziam o trabalho.

❸ A técnica mais simples ganhou três vezes.

Ao Isolation Forest e ao modelo que lê o texto, que são *simples contra complexo*. E uma tabela de constantes ganhou ao modelo implantado, que é um caso diferente: ali o modelo até era interpretável, e perdeu por **falta de informação**.

A parte difícil não foi escolher a técnica mais avançada.
Foi montar a avaliação **capaz de dizer que ela não era precisa**.

Obrigado. Perguntas?