

Explicar sem prever

Deteção de anomalias e recuperação de precedentes em alertas verificáveis

Henrique José da Silva Santos

Orientador: Prof. Luís Gomes Coorientador: Rafael Silva


MEIA, Instituto Superior de Engenharia do Porto

Defesa



InvestiGator

Uma pessoa abre a aplicação, vê isto, e fica com três perguntas



1. Isto é invulgar?

4% numa empresa calma é muito. Noutra, é terça-feira.

2. Foi a empresa, ou foi o mercado?

Se caiu tudo, a história é outra.

3. Já aconteceu antes, e o que se seguiu?

Houve dias parecidos? O que fez o preço depois?


As aplicações gratuitas não respondem a nenhuma delas.

O que existe hoje

	invulgar?	empresa ou mercado?	já aconteceu?	custo
Aplicação da corretora	—	—	—	incluído
Agregador de notícias	—	—	—	grátis
<i>Robo-advisor</i>	—	—	—	% da carteira
Terminal profissional	✓	✓	✓	milhares/ano
Este trabalho	✓	✓	✓	grátis

A linha que responde às três **já existe**. É a mais cara de todas.
O problema não é científico: é de acesso.

O que o sistema faz



E há uma coisa que ele **recusa** fazer.

Nunca diz que vai subir.

Nunca diz para comprar.

Nunca mostra um alvo de preço.

Parece uma limitação. É o contrário:
é o que torna tudo o resto verificável.

Uma afirmação sobre o que já aconteceu confere-se contra o registo.

Uma previsão não se confere.

Técnica 1: é invulgar?

Comparar o dia de hoje com os **20 dias anteriores da mesma ação**.




$$z = \frac{\text{movimento de hoje} - \text{média}}{\text{desvio-padrão}}$$

$z = +7$ quer dizer o mesmo numa empresa calma e numa volátil.

O dia julgado não entra no cálculo da sua própria norma. Sem isto, seria falsear.

Técnica 2: foi a empresa, ou foi o mercado?

Um +6.29% pode ser a empresa ou pode ser o mercado. A aplicação da corretora mostra o **mesmo número** nos dois casos.



A AMD subiu **apesar** de o mercado e o setor terem puxado ao contrário. Os *betas* são estimados **só com dias anteriores**.


Ressalva: as parcelas somam sempre, porque a da empresa é o resto, e isso não prova que estejam bem estimadas. R^2 mediano 0.460, e num dos casos negativo.

É a única das quatro sem questão de investigação: não há resposta certa contra a qual comparar, e por isso o que se mede nela é o ajuste, e não o acerto.

Técnica 3: já aconteceu antes?

Procurar por palavras falha nos **dois** sentidos:

mesmo sentido, palavras diferentes



palavra igual, sentido diferente



Cada título passa a **384 números**: uma coordenada de significado.

Compara-se pelo **ângulo** entre elas.

Depois, para cada caso passado, mede-se o que o preço fez a +1, +3 e +5 dias.

É uma **medição do passado**, não uma **previsão**.

Técnica 4: merece avisar?

Aqui não há fórmula óbvia. É o sítio para **aprender dos dados**.

- **79 753** exemplos que construí a partir de notícias e preços (2018–2023)
- Pergunta: *depois desta notícia houve um movimento anormalmente grande?* **Em valor absoluto**, nunca em que direção



Divisão por **dias inteiros** com embargo de **cinco**, nunca por linhas: duas notícias do mesmo dia não podem cair uma de cada lado. E a garantia não é prometida, é **imposta por um teste**: dois futuros absurdos (+300% e –99%) sobre o mesmo passado têm de dar entradas **idênticas** e rótulos **diferentes**. Se o futuro vazasse, as entradas mudavam.

Um alerta real, do princípio ao fim

Meta, 12 de julho de 2026. *“Mark Zuckerberg Said Meta's AI Bets ‘Haven't Come to Fruition Yet’ as Shares*

	etapa	o que aconteceu
Fell 5%”	2 nomeia a empresa?	“Meta”, “Zuckerberg” ✓
	3 é recente?	menos de 2 dias ✓
	4 casos parecidos	MSFT 0.46 · NVDA 0.51 · NVDA 0.46
	5 evidência forte?	melhor $0.51 \geq 0.45$ ✓
	6 merece avisar?	$54\% \geq 50\%$ ✓
	9 enviado	ao canal, e guardado

Os desfechos foram **em sentidos opostos**: $+2.70\% \cdot -3.87\% \cdot +5.05\%$

Por isso mostram-se **um a um**: uma média esconderia isso.

Resultado 1: deteção **sim**

Um bom detetor deve disparar a um ritmo **parecido** em empresas diferentes.

	mín	máx	amplitude
z-score	0.016	0.031	0.015
Limiar fixo de 3%	0.009	0.353	0.344

Mais de **20 vezes** mais consistente.

E ganha também a dois métodos aprendidos: F_1 0.530 contra 0.269 e 0.280.

Resultado 2: precedentes **sim**

método	precisão@5
Por significado (o método)	0.514
Sempre o setor maior	0.467
Por palavras em comum	0.346
Ao acaso (o chão)	0.240
As mais recentes	0.126

- Metade do corpus é tecnologia: **devolver sempre tecnologia** vale 0.467 sem modelo nenhum. A margem real é +0.047, e não +0.274.
- **Mas essa alternativa acerta em tudo num setor e em nada nos outros quatro.** Dentro de cada setor o método ganha nos **cinco**: 0.448 na energia, com chão 0.072.
- No corpus completo, sob a restrição causal da produção: **0.513**, com chão **0.259** e margem +0.254. O **0.595** é o teste simétrico de escala.
- E **capta tema, não direção**, que é porque os casos aparecem um a um.

Resultado 3: triagem **não**

modelo	PR-AUC
Só volatilidade	0.542
Só contexto	0.538
Contexto + texto	0.496
Só texto	0.439

Nenhum modelo que lê o texto bate a volatilidade.

Era o contrário do que eu esperava. Verifiquei por três caminhos: re-teste em condições favoráveis ao texto (0.533, ainda abaixo), reamostragem por grupos, e **nove** definições diferentes do rótulo: a volatilidade ganha nas nove.

O erro que encontrei em mim próprio

Eu tinha escrito que a triagem “*quase quadruplica*” a precisão: de 0.163 para 0.632.

O 0.163 vinha do modelo “alertar sempre”, que dá a mesma pontuação a tudo.

Com tudo empatado, a métrica desempata pela ordem do ficheiro, que está ordenado por data e por nome da empresa.


Esse número não media escolher às cegas.
Media escolher por ordem alfabética.

Ao acaso a sério dá 0.379 $\Rightarrow$ o ganho é de **1.67** $\times$, não de quase quatro.

E uma tabela de **13 constantes** dá 0.662: bate o modelo treinado.

E encontrei-o outra vez, um nível acima

O sistema decidia se avisava com um **limiar fixo** sobre a pontuação do modelo: passa quem estiver acima de 0.50.



Em **84%** das decisões, o resultado estava determinado pela **empresa** antes de o título ser lido.

A Apple não conseguia gerar um alerta de notícia. A AMD passava em 963 de 963.

E a correção óbvia também estava errada

A tentação: se um limiar fixo mede a empresa e não a notícia, torna-se *relativo a cada empresa*, que foi exatamente o que o z-score fez para os preços.

Simulei-o **antes** de escrever código. Metade resolve-se: as doze passam a estar representadas.

Mas nas empresas de pontuação quase constante o percentil cai *em cima* da constante e quase tudo empata acima. A JNJ passaria **874** vezes.

Não se corrige um defeito introduzindo o defeito vizinho.

O que se fez: o modelo deixou de decidir e passou a **ordenar**, com um orçamento de 5 alertas por dia. E isso fechou uma divergência: a dissertação *avaliava* uma política de orçamento e o sistema *implantava* uma de limiar.

Então quanto vale o modelo? Duas medições que respondem

1. Tirei-lhe a notícia.

Uma *tabela de consulta*: um número fixo por empresa, zero informação sobre o título.

o que vê	PR-AUC
o implantado, nove entradas	0.538
só a empresa	0.534
sem nada da empresa	0.378
só o comprimento do título	0.378

Diferença de 0.004, e 0.378 é o chão. **O modelo implantado é uma tabela de consulta.**

2. Comparei o sistema inteiro.

Precisão nas cinco notícias que o produto mostra por dia.

política	prec.@5
ao acaso	0.375
quem mais se mexeu hoje	0.489
o sistema	0.632
volatilidade, treze constantes	0.662
oráculo	0.968

Bate a alternativa realista. **Mas o oráculo é a informação nova:** as notícias importantes *estão* no lote.

A margem que falta não está em melhores dados. Está em **separar duas notícias da mesma empresa no mesmo dia.**

“E onde está a engenharia de inteligência artificial?”

Começo pela parte incômoda: este trabalho treina **um** modelo, e é uma regressão logística com nove entradas que **perdeu** para uma linha de base de uma só variável.

A engenharia não está no tamanho do modelo.

Está no que foi preciso construir para que aquele número, e a conclusão negativa que ele sustenta, sejam *de confiança*.

1. O conjunto de dados é **construído**, não encontrado: 79 753 linhas que não existiam.
2. O rótulo é uma **decisão**, e por isso mediram-se **nove** definições alternativas.
3. A separação temporal é imposta por um **teste** que muta o futuro, não prometida.
4. As probabilidades são calibradas, e o seu enviesamento está **medido**.
5. O modelo, o calibrador e a corrida estão **versionados**.
6. O modelo implantado é o modelo avaliado: exportado para um formato leve, com a fidelidade da conversão medida em vez de assumida.
7. O que corre é **observado**: cada decisão é registada e confrontada dias depois com o que o preço fez. Foi assim que se soube que *não* estava a ajudar.

A parte difícil não foi escolher a técnica. Foi montar a avaliação que **consegue dizer que não**, e depois acreditar nela.


Limitações, ditas antes de me perguntarem, e o que as fecha

Cada limitação foi medida, e a coluna da direita é o trabalho que ela pede.

limitação medida		o que a fecha	custo
Nenhuma avaliação com pessoas	→	Correr o estudo: 6 a 10 pessoas	calendário
O modelo implantado é uma tabela de consulta	→	Entradas que variem com o título	baixo
Cobertura de 88.5%, e 50% na pior	→	Julgamento humano sobre uma amostra	calendário
Lê o título e não o corpo	→	Ler o corpo dos artigos	dados novos
Deriva: a entrada de que mais depende é a que mais derivou	→	Re-treinar com o que se observa	baixo

Mais duas: o atraso é da *fonte* e não da infraestrutura (≈ 2.5 h até detetar, 1 s até entregar); e **nada volta a ser treinado**, porque a base de casos cresce sozinha, os pesos não.

As três perguntas, respondidas no ecrã



1. É invulgar?

Em palavras, antes do número: 169 dos últimos 250 dias moveram-se tanto ou mais. E “so far today”: a sessão ainda decorria.

2. Foi a empresa?

Não. A ação desce 0.41%, mas o mercado e a própria empresa estavam em alta. O que a puxa para baixo é o **setor**. A percentagem sozinha mandava procurar uma razão onde não havia nenhuma.

3. Já aconteceu?

Os dias assinalados na curva, e os precedentes dentro do texto do alerta.

O sistema está no ar. [gravação]

uma notícia real, do momento em que chega até ao alerta que sai

Too old 1 the newest relevant headline is past the freshness window	JPM newest is 2026-08-17, past 2 days
No strong past case 1 no past headline was similar enough to be worth showing	AMD best match 0.42, floor 0.45
Same story, other words 1 already sent today under a different headline	META sent under another headline
Already sent 5 this exact headline had already gone out today	AMZN same headline already delivered today GOOGL same headline already delivered today META same headline already delivered today MSFT same headline already delivered today TSLA same headline already delivered today
Daily budget spent 7 the five slots for the day were already used	AAPL all 5 slots used JNU all 5 slots used JPM all 5 slots used MSFT all 5 slots used NFLX all 5 slots used NVDA all 5 slots used XOM all 5 slots used
Alert sent 5 cleared every gate and was delivered	AMZN Amazon Stock Moves Higher Wednesday: What's Going On? GOOGL Alphabet Stock: A Berkshire Hathaway-Style Compounder Hiding In Plain Sight META Meta Stock Climbs as Landmark Trial Threatens \$1.4 Trillion Penalties MSFT Comparative Study: Microsoft And Industry Competitors In Software Industry TSLA Elon Musk Is No Longer a Trillionaire, but He Could Still Give Every Person on E

As decisões de um dia, por ordem. **É a parte que uma demonstração ao vivo não mostra:** nove em cada dez varreduras não enviam nada.

O que aprendi

❶ A linha de base é tão importante como o modelo.

O resultado mais útil do trabalho veio de olhar para aquilo contra o qual eu estava a comparar.

❷ O sítio onde se põe um modelo importa tanto como o modelo.

O meu funcionava sozinho e deixou de servir atrás de dois filtros simples, que já faziam o trabalho.

❸ A técnica mais simples ganhou três vezes.

Ao Isolation Forest e ao modelo que lê o texto, que são *simples contra complexo*. E uma tabela de constantes ganhou ao modelo implantado, que é um caso diferente: ali o modelo até era interpretável, e perdeu por **falta de informação**.

A parte difícil não foi escolher a técnica mais avançada.
Foi montar a avaliação **capaz de dizer que ela não era precisa**.

Obrigado. Perguntas?