

Explicar sem prever

Alertas de mercado com evidência verificável para o investidor de retalho


Henrique José da Silva Santos

Orientador: Prof. Luís Gomes Coorientador: Rafael Silva

MEIA, Instituto Superior de Engenharia do Porto

Defesa

Uma pessoa abre a aplicação e vê isto



E fica com **três perguntas**, sempre estas e sempre por esta ordem.

As três perguntas

1. Isto é invulgar?

4% numa empresa calma é muito. Noutra, é terça-feira.

2. Foi a empresa, ou foi o mercado?

Se caiu tudo, a história é outra.

3. Já aconteceu antes, e o que se seguiu?

Houve dias parecidos? O que fez o preço depois?

As aplicações gratuitas não respondem a nenhuma delas.


O que existe hoje

	invulgar?	empresa ou mercado?	já aconteceu?	custo
App da corretora	—	—	—	incluído
Agregador de notícias	—	—	—	grátis
<i>Robo-advisor</i>	—	—	—	% da carteira
Terminal profissional	✓	✓	✓	milhares/ano
Este trabalho	✓	✓	✓	grátis

A linha que responde às três **já existe**. É a mais cara de todas.

O problema não é científico: é de acesso.

O que o sistema faz



E há uma coisa que ele **recusa** fazer.

Nunca diz que vai subir.

Nunca diz para comprar.

Nunca mostra um alvo de preço.

Parece uma limitação. É o contrário:
é o que torna tudo o resto verificável.

Uma afirmação sobre o que já aconteceu confere-se contra o registo.

Uma previsão não se confere.

Técnica 1: é invulgar?

Comparar o dia de hoje com os **20 dias anteriores da mesma ação**.




$$z = \frac{\text{movimento de hoje} - \text{média}}{\text{desvio-padrão}}$$

$z = +7$ quer dizer o mesmo numa empresa calma e numa volátil.

O dia julgado não entra no cálculo da sua própria norma. Sem isto, seria falsear.

Técnica 2: foi a empresa, ou foi o mercado?

Um +6.29% pode ser a empresa ou pode ser o mercado. A aplicação da corretora mostra o **mesmo número** nos dois casos.



A AMD subiu **apesar** de o mercado e o setor terem puxado ao contrário. Os *betas* são estimados **só com dias anteriores**.

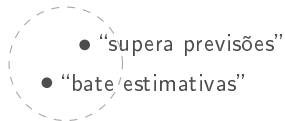
Ressalva: as parcelas somam sempre, porque a da empresa é o resto, e isso não prova que estejam bem estimadas. R^2 mediano 0.460, e num dos casos negativo.

É a única das quatro sem resultado medido: não há resposta certa contra a qual comparar.

Técnica 3: já aconteceu antes?

Procurar por palavras falha nos **dois** sentidos:

mesmo sentido, palavras diferentes



palavra igual, sentido diferente



Cada manchete passa a **384 números**: uma coordenada de significado.
Compara-se pelo **ângulo** entre elas.

Depois, para cada caso passado, mede-se o que o preço fez a +1, +3 e +5 dias.
É uma medição do passado, não uma previsão.

Técnica 4: merece avisar?

Aqui não há fórmula óbvia. É o sítio para **aprender dos dados**.

- **79 753** exemplos que construí a partir de notícias e preços (2018–2023)
- Pergunta: *depois desta notícia houve um movimento anormalmente grande?*
- **Em valor absoluto**, nunca em que direção
- Divisão **cronológica** com embargo; probabilidades calibradas

O modelo, o seu treino e as suas métricas ficam guardados como artefactos.

É o meu modelo, treinado nos meus dados.

Um alerta real, do princípio ao fim

Meta, 12 de julho de 2026. *“Mark Zuckerberg Said Meta's AI Bets ‘Haven't Come to Fruition Yet’ as Shares*

	etapa	o que aconteceu
Fell 5%”	2 nomeia a empresa?	“Meta”, “Zuckerberg” ✓
	3 é recente?	menos de 2 dias ✓
	4 casos parecidos	MSFT 0.46 · NVDA 0.51 · NVDA 0.46
	5 evidência forte?	melhor $0.51 \geq 0.45$ ✓
	6 merece avisar?	$54\% \geq 50\%$ ✓
	9 enviado	ao canal, e guardado

Os desfechos foram **em sentidos opostos**: $+2.70\% \cdot -3.87\% \cdot +5.05\%$

Por isso mostram-se **um a um**: uma média esconderia isso.

Resultado 1: deteção **sim**

Um bom detetor deve disparar a um ritmo **parecido** em empresas diferentes.

	mín	máx	amplitude
z-score	0.016	0.031	0.015
Limiar fixo de 3%	0.009	0.353	0.344

Mais de **20 vezes** mais consistente.

E ganha também a dois métodos aprendidos: F_1 0.530 contra 0.269 e 0.280.

Resultado 2: precedentes **sim**

método	precisão@5
Por significado (o método)	0.514
Por palavras em comum	0.346
Ao acaso (o chão)	0.240
As mais recentes	0.126

- Sobre o corpus completo (80 mil notícias): **0,595**
- **Capta tema, não direção**, e é por isso que os casos aparecem um a um

Resultado 3: triagem **não**

modelo	PR-AUC
Só volatilidade	0.542
Só contexto	0.538
Contexto + texto	0.496
Só texto	0.439

Nenhum modelo que lê o texto bate a volatilidade.

Era o contrário do que eu esperava. Verifiquei por três caminhos: re-teste em condições favoráveis ao texto (0.533, ainda abaixo), reamostragem por grupos, e **nove** definições diferentes do rótulo: a volatilidade ganha nas nove.

O erro que encontrei em mim próprio

Eu tinha escrito que a triagem “*quase quadruplica*” a precisão: de 0.163 para 0.632.

O 0.163 vinha do modelo “alertar sempre”, que dá a mesma pontuação a tudo.

Com tudo empatado, a métrica desempata pela ordem do ficheiro, que está ordenado por data e por nome da empresa.


Esse número não media escolher às cegas.
Media escolher por ordem alfabética.

Ao acaso a sério dá 0.379 $\Rightarrow$ o ganho é de **1,67** $\times$, não de quase quatro.

E uma tabela de **13 constantes** dá 0.662: bate o modelo treinado.

E encontrei-o outra vez, um nível acima

O sistema decidia se avisava com um **limiar fixo** sobre a pontuação do modelo: passa quem estiver acima de 0.50.



Em **84%** das decisões, o resultado estava determinado pela **empresa** antes de a manchete ser lida.

A Apple não conseguia gerar um alerta de notícia. A AMD passava em 963 de 963.

E a correção óbvia também estava errada

A tentação: se um limiar fixo mede a empresa e não a notícia, torna-se *relativo a cada empresa*, que foi exatamente o que o z-score fez para os preços.

Simulei-o **antes** de escrever código. Metade resolve-se: as doze passam a estar representadas.

Mas nas empresas de pontuação quase constante o percentil cai *em cima* da constante e quase tudo empata acima. A JNJ passaria **874** vezes.

Não se corrige um defeito introduzindo o defeito vizinho.

O que se fez: o modelo deixou de decidir e passou a **ordenar**, com um orçamento de 5 alertas por dia. E isso fechou uma divergência: a dissertação *avaliava* uma política de orçamento e o sistema *implantava* uma de limiar.

O que aprendi

❶ A linha de base é tão importante como o modelo.

O resultado mais útil do trabalho veio de olhar para aquilo contra o qual eu estava a comparar.

❷ O sítio onde se põe um modelo importa tanto como o modelo.

O meu funcionava sozinho e deixou de servir atrás de dois filtros simples, que já faziam o trabalho.

❸ A técnica mais simples ganhou três vezes.

Ao Isolation Forest e ao modelo que lê o texto, que são casos de *simples contra complexo*. E uma tabela de constantes ganhou ao modelo implantado, que é um caso diferente: ali o modelo até era interpretável, e perdeu por **falta de informação**, não por excesso de complexidade.


A parte difícil não foi escolher a técnica mais avançada.
Foi montar a avaliação **capaz de dizer que ela não era precisa**.

Limitações, ditas antes de me perguntarem

- **Não fiz estudo com utilizadores.** A fidelidade das explicações está garantida por construção; a *utilidade* não foi medida, e não a afirmo.
- **Os critérios de alerta ainda não estão bem calibrados**, e noto-o a usar. Medido: havia notícia captada em 88.5% dos dias invulgares, e é um *limite superior*, porque pergunta se existia *uma*, não se chegou *a certa*.
- **Só manchetes**, não o corpo dos artigos.
- **O atraso é da fonte, não da infraestrutura**: ≈ 2.5 h até detetar, 1 s até entregar.
- **Nada volta a ser treinado.** A base de casos cresce sozinha, mas os pesos do modelo são os que foram aprendidos uma vez. A deriva é medida e não é corrigida.

O que faria a seguir, e porquê essa ordem

Nenhum destes itens é uma ideia solta: **cada um fecha uma limitação que foi medida.**



As duas que custam **calendário** e não computação são as primeiras da lista.

O sistema está no ar.

[gravação]

uma notícia real, do momento em que chega
até ao alerta que sai

Obrigado

Perguntas?

Duas respostas de “sim”, uma de “não”, e um erro meu encontrado e corrigido.

É isso que uma avaliação honesta produz.