



Instituto Superior de
Engenharia do Porto



DEPARTAMENTO DE ENGENHARIA
INFORMÁTICA

Alertas Financeiros Explicáveis para Investidores de Retalho: Integração de Detecção Estatística de Anomalias e Correlação Notícia–Mercado

Henrique José da Silva Santos

Aluno nº: 1180934

**Dissertação para obtenção do Grau de
Mestre em Engenharia de Inteligência Artificial**

Orientador: Luís Gomes
Co-Orientador: Rafael Silva

Júri:

Presidente:
[A definir]

Vogais:
[A definir]

Porto, 25 de julho de 2026

Declaração de Integridade

Declaro que realizei este trabalho académico com integridade.

Não plagiei nem apliquei qualquer forma de uso indevido de informação ou de falsificação de resultados ao longo do processo que conduziu à sua elaboração.

Assim, o trabalho apresentado neste documento é original e da minha autoria, não tendo sido anteriormente utilizado para qualquer outro fim.

Declaro ainda que tomei pleno conhecimento do Código de Conduta Ética do P.PORTO.

Uso de Inteligência Artificial. Em conformidade com as orientações do P.PORTO/ISEP, declaro que foram utilizadas ferramentas de inteligência artificial (nomeadamente o Claude Code) durante o desenvolvimento deste trabalho, para apoiar a redação e edição do texto e o desenvolvimento de software. Dirigi o trabalho e revi e validei criticamente todos os resultados; as ideias, as decisões e o conteúdo final são meus e da minha responsabilidade.

ISEP, Porto, 25 de julho de 2026

Dedicatória

Resumo

Esta dissertação apresenta o InvestiGator, um sistema de alertas financeiros explicável (XAI-first) para investidores de retalho no mercado acionista dos Estados Unidos (NYSE e NASDAQ). O sistema envia alertas via Telegram a partir de dois gatilhos independentes (movimentos abruptos de mercado, detetados como anomalias estatísticas, e novas notícias financeiras) e, para cada alerta, expõe uma explicação totalmente rastreável: o evento detetado, o raciocínio aplicado, as fontes e os precedentes históricos. O seu núcleo é um motor de correlação notícia–mercado que, dada uma notícia, recupera notícias históricas análogas de uma base de conhecimento e mede o impacto que esses precedentes tiveram nos preços, à maneira de um estudo de evento e sem lookahead. Enquanto contribuição de Engenharia de Inteligência Artificial, o trabalho integra, aplica e avalia criticamente componentes existentes (recuperação por embeddings de frases, deteção estatística de anomalias, triagem supervisionada e explicação transparente) num sistema funcional, explicável e reproduzível. Em dados reais, a recuperação semântica superou claramente as baselines lexical e triviais (precision@5 cross-ticker de 0,51, face a 0,35 de uma baseline lexical e 0,24 do acaso) e o detetor normalizado pela volatilidade disparou de forma muito mais consistente entre ações do que um limiar fixo. Um modelo de triagem de materialidade treinado em 79 753 exemplos notícia–mercado de vários anos quase quadruplicou a precisão dos alertas dentro do orçamento diário, mas nenhum modelo com texto bateu a baseline de só-volatilidade, resultado reportado tal como é. As limitações e o trabalho futuro ficam explícitos.

Palavras-chave: IA Explicável, Alertas Financeiros, Deteção de Anomalias, Impacto de Notícias, Investidores de Retalho, PLN Financeiro

Abstract

This dissertation presents InvestiGator, an explainable (XAI-first) financial-alert system for retail investors in the US equity market (NYSE and NASDAQ). The system raises Telegram alerts from two independent triggers (abrupt market movements, detected as statistical anomalies, and incoming financial news) and, for every alert, exposes a fully traceable explanation: the detected event, the reasoning applied, the sources, and historical precedents. Its core is a news–market correlation engine that, given a news item, retrieves analogous historical news from a knowledge base and measures the impact those precedents had on prices, event-study style and without lookahead. As an Artificial Intelligence Engineering contribution, the work integrates, applies and critically evaluates existing components (sentence-embedding retrieval, statistical anomaly detection, supervised triage and transparent explanation) in a functional, explainable and reproducible system. On real data, semantic retrieval clearly outperformed lexical and trivial baselines (cross-ticker precision@5 of 0.51 against 0.35 lexical and 0.24 random), and the volatility-normalised detector fired far more consistently across stocks than a fixed threshold. A materiality-triage model trained on 79,753 multi-year news–market examples nearly quadrupled within-budget alert precision, yet no text model beat the volatility-only baseline, a finding reported as it stands. Limitations and future work are stated explicitly.

Keywords: IA Explicável, Alertas Financeiros, Detecção de Anomalias, Impacto de Notícias, Investidores de Retalho, PLN Financeiro

Agradecimientos

Índice

Lista de Algoritmos	xvii
Lista de Acrónimos	xxi
1 Introdução	1
1.1 Contextualização	1
1.2 Definição do Problema	2
1.3 Questões de Investigação e Objetivos	2
1.4 Contribuições Científicas	3
1.5 Estrutura do Documento	3
2 Estado da Arte	5
2.1 Investimento de Retalho e Sobrecarga de Informação	5
2.2 Detecção de Anomalias em Mercados Financeiros	6
2.3 Inteligência Artificial Explicável	7
2.4 Confiança e Dependência Apropriada no Apoio à Decisão	8
2.5 PLN Financeiro e Representação de Texto	9
2.6 Recuperação de Informação e Avaliação de Ordenação	10
2.7 Estudos de Evento e Impacto Notícia–Mercado	11
2.8 Raciocínio Baseado em Casos e Recuperação de Precedentes	11
2.9 Triagem Aprendida de Alertas: Classificação Supervisionada de Materialidade	12
2.10 Ferramentas Existentes para o Investidor de Retalho	12
2.11 Análise Comparativa e Posicionamento	13
2.12 Conclusões do Capítulo	13
3 Métodos e Materiais	15
4 InvestiGator: Um Sistema de Alertas Financeiros Explicável para Investidores de Retalho	17
4.1 Visão Geral	17
4.2 O Modelo de Dados	17
4.3 Componentes e Responsabilidades	18
4.4 Fluxo de Dados	19
4.5 Lógica de Decisão	19
4.6 Explicação e Entrega	20
4.7 A Vida de Um Alerta	22
4.8 Uso Prático e Desenho Responsável	22
4.9 Conclusões do Capítulo	24
5 Estudos de Caso	27

6	Conclusões	29
6.1	Conclusões Principais	29
6.2	Questões de Investigação e Objetivos Alcançados	30
6.3	Contribuições Revisitadas	31
6.4	Limitações	31
6.5	Trabalho Futuro	31
	Bibliografia	35
A	Reprodutibilidade	39
A.1	Ambiente	39
A.2	Organização do Repositório	39
A.3	A Pipeline Completa numa Página	40
A.4	Testes e Resultados Reprodutíveis	40
A.5	Prova de Trabalho: Cada Número Rastreado à Sua Fonte	40
A.6	Dados e Atribuição	42

Lista de Figuras

1.1	Capitalização do mercado acionista dos EUA, 2015–2024	1
1.2	O que o InvestiGator faz	2
2.1	Taxonomia dos métodos de detecção de anomalias	6
2.2	Taxonomia das abordagens de explicabilidade	8
2.3	Três gerações de representação de texto	9
4.1	Arquitetura do sistema e fluxo de dados	18
4.2	O modelo de dados do InvestiGator	20
4.3	Fluxo de dados e processamento de ponta a ponta	22
4.4	Alerta Telegram tal como recebido pelo investidor	23
4.5	O dashboard ao vivo, uma captura genuína	24
4.6	Seletividade de produção: manchetes capturadas versus alertas enviados . .	26
6.1	As quatro questões de investigação num relance	29
6.2	As limitações mapeiam em trabalho futuro	32
A.1	A pipeline completa em produção, com cada porta anotada	41

Lista de Tabelas

2.1	Abordagens de detecção de anomalias relevantes para este trabalho.	7
2.2	Abordagens de explicabilidade consideradas.	8
2.3	Abordagens de representação de texto para notícias financeiras.	10
2.4	Ferramentas de retalho existentes versus o sistema proposto neste trabalho.	13
2.5	Escolhas de componentes neste trabalho versus alternativas.	14
4.1	Principais decisões de desenho no InvestiGator e a sua justificação.	19
4.2	Os componentes do InvestiGator, cada um com uma responsabilidade única.	21
4.3	A vida de um alerta real, fase a fase	25
A.1	Versões fixadas das dependências centrais (Python 3.12).	39
A.2	Cada resultado de destaque, o seu valor reportado, e o estudo a que pertence.	42

Lista de Símbolos

r_t	retorno logarítmico de um ativo no dia t	—
μ_t	média móvel dos retornos	—
σ_t	desvio-padrão móvel dos retornos	—
z_t	z-score do retorno no dia t	—
k	limiar de anomalia (em desvios-padrão)	—
w	comprimento da janela móvel	d

Lista de Acrónimos

AI	Inteligência Artificial.
NASDAQ	National Association of Securities Dealers Automated Quotations.
NYSE	New York Stock Exchange.
RQ	Questão de Investigação.

Capítulo 1

Introdução

1.1 Contextualização

A maioria dos norte-americanos possui hoje ações, diretamente ou através de contas de reforma e fundos de investimento (Gallup 2025), e investe no maior mercado acionista do mundo, avaliado em 62,2 bilhões de dólares no final de 2024 (Securities Industry and Financial Markets Association (SIFMA) 2025) (Figura 1.1). A negociação decorre sobretudo na New York Stock Exchange (NYSE) e na National Association of Securities Dealers Automated Quotations (NASDAQ), e uma fração crescente vem agora de pessoas comuns que usam aplicações móveis sem comissões, e não de instituições profissionais.




Figura 1.1: Capitalização do mercado acionista dos EUA, 2015–2024 (bilhões de dólares). Elaborada a partir dos dados reportados no SIFMA 2025 Capital Markets Fact Book (Securities Industry and Financial Markets Association (SIFMA) 2025).

Estes investidores não profissionais, ou “de retalho”, são o público deste trabalho, e a sua posição é difícil. Os mercados movem-se continuamente ao longo de milhares de títulos, e chegam notícias relevantes durante todo o dia de negociação, mas os investidores de retalho não têm nenhuma das ferramentas que os bancos e os fundos tomam como garantidas. A posse também é desigual: chega a 87% dos agregados que ganham acima de 100 000 dólares, mas apenas a 28% dos que ganham abaixo de 50 000 dólares (Gallup 2025).

Entretanto, a inteligência artificial espalhou-se depressa pelas finanças: um inquérito de 2026 encontrou 81% das empresas financeiras a adotar Inteligência Artificial (AI) e 71% já a usar IA generativa (Cambridge Centre for Alternative Finance 2026). Mas grande parte desta tecnologia é opaca, raramente mostrando como chega a uma conclusão (Adadi e Berrada 2018; Barredo Arrieta et al. 2020). Para quem tem de agir sobre um alerta e viver com o resultado, essa opacidade é o obstáculo que esta dissertação remove: permite ao investidor ver *porquê* um alerta foi emitido.

1.2 Definição do Problema

Um investidor de retalho que queira manter-se informado enfrenta dois problemas do dia a dia. O primeiro é distinguir um movimento de preço genuinamente invulgar da volatilidade comum, o que exige juízo estatístico e atenção constante. O segundo é interpretar o que uma notícia pode significar, o que exige saber como eventos semelhantes se desenrolaram no passado. A maioria das pessoas não consegue fazer nenhum dos dois em escala, e as aplicações de consumo que prometem ajudar costumam enviar alertas secos ou esconder o seu raciocínio dentro de um modelo opaco.

Este trabalho assume uma postura deliberadamente diferente: não prevê preços, *explica* eventos. Para cada movimento abrupto ou notícia relevante, o sistema mostra o que detetou, como, de onde veio a informação, e quais os eventos passados que se assemelham ao atual, juntamente com o que aconteceu aos preços depois (Figura 1.2).




Figura 1.2: Os dois gatilhos, um movimento súbito de mercado ou uma notícia relevante, alimentam o InvestiGator, que responde com um alerta explicado que o investidor pode seguir e verificar, e não apenas uma notificação seca.

1.3 Questões de Investigação e Objetivos

O objetivo é conceber, construir e avaliar um sistema de alertas financeiros explicável para investidores de retalho dos EUA, movido por dois gatilhos independentes, um movimento súbito de mercado e uma notícia recebida, e entregue por Telegram. Quatro questões de investigação guiam o trabalho:

- **Questão de Investigação (RQ)1.** Conseguem métodos estatísticos transparentes detetar movimentos abruptos de mercado de forma suficientemente consistente para serem úteis a um investidor de retalho, mantendo-se explicáveis?
- **RQ2.** Consegue um motor de correlação notícia–mercado recuperar notícias históricas genuinamente análogas melhor do que baselines triviais, e quantificar o impacto observado nos preços desses precedentes sem lookahead?

- **RQ3.** Podem as explicações resultantes ser fiéis ao que o sistema realmente calcula, e úteis a um investidor de retalho?
- **RQ4.** Consegue um modelo supervisionado, treinado em notícias históricas e contexto de mercado, priorizar utilmente que notícias merecem um alerta, para além de baselines simples de volatilidade, sem nunca prever a direção do preço?

Estas questões traduzem-se em cinco objetivos concretos:

- construir um pipeline de alertas explicável, movido pelos dois gatilhos;
- avaliar o detetor de anomalias face a baselines transparentes;
- avaliar a recuperação de notícias históricas face a baselines triviais;
- aferir se as explicações são fiéis e úteis;
- treinar, calibrar e avaliar honestamente um modelo de triagem de materialidade que ordena os alertas de notícias.

O sistema é construído de forma incremental, primeiro na sua forma mais simples e defendável, uma escolha metodológica explicada no Capítulo 3.

1.4 Contribuições Científicas

Esta é uma dissertação em *Engenharia* de Inteligência Artificial: a contribuição não é um algoritmo novo, mas a montagem disciplinada de algoritmos existentes num sistema que funciona, se explica a si próprio e pode ser reproduzido. Quatro contribuições destacam-se:

- Um método reproduzível para relacionar notícias com o impacto no mercado, que junta recuperação por embeddings de frases com janelas de estudo de evento, com a medida de similaridade e os horizontes temporais declarados de forma explícita e sem deixar entrar qualquer informação sobre o futuro.
- O **InvestiGator**, um sistema de alertas que mostra toda a sua cadeia de raciocínio: o evento detetado, a evidência de apoio, as fontes e os precedentes históricos relevantes. Como cada explicação é construída diretamente a partir das quantidades que o sistema calcula, o texto não pode divergir do cálculo.
- Um modelo de *triagem de materialidade* treinado e calibrado: aprendizagem supervisionada sobre notícias históricas e contexto de mercado que estima com que frequência notícias com um dado perfil foram seguidas de um movimento anormal, rotuladas pelo próprio código de estudo de evento do sistema, avaliadas face a uma baseline de volatilidade, e integradas nos alertas como evidência ordenada e explicada, e não como uma previsão.
- Uma avaliação crítica e honesta de cada componente central em dados reais, face a baselines simples e lexicais, com os resultados, as ablações e as limitações todos reportados com clareza.

1.5 Estrutura do Documento

O resto da dissertação foi escrito para ser lido por ordem, cada capítulo respondendo a uma pergunta:

- **Capítulo 2 (Estado da Arte):** o que já se sabe, e o que escolhe este trabalho?
- **Capítulo 3 (Métodos e Materiais):** como é construído o sistema, e como é avaliado?
- **Capítulo 4 (InvestiGator):** o que é o sistema, e como se encaixam os seus dados, partes, fluxo e decisões?
- **Capítulo 5 (Estudos de Caso):** funciona em dados reais?
- **Capítulo 6 (Conclusões):** o que se aprendeu, e o que vem a seguir?

Capítulo 2

Estado da Arte

Este capítulo tem uma tarefa: justificar cada escolha de desenho do InvestiGator face às alternativas. Cada secção pergunta o que um campo oferece e termina com o que o InvestiGator lhe retira. A ordem é: como se comportam os investidores de retalho; deteção de anomalias; IA explicável; confiança na automação; representação de texto financeiro; recuperação de informação; estudos de evento; e raciocínio baseado em casos. O achado recorrente é simples. Os blocos de construção são maduros, mas um sistema integrado e explicável para o investidor de retalho continua raro.

2.1 Investimento de Retalho e Sobrecarga de Informação

Como se comportam os investidores de retalho, e o que deve um alerta dar-lhes?

As finanças comportamentais mostram que os investidores reais se afastam sistematicamente do ideal racional (Barberis e Thaler 2003). Uma causa de raiz é a *aversão à perda*: sentimos as perdas mais do que ganhos iguais (Kahneman e Tversky 1979), o que torna os investidores especialmente sensíveis a más notícias, e um alerta atempado e bem explicado valioso.

O padrão mais forte é a *atenção*. Barber e Odean (2008) mostram que os indivíduos são compradores líquidos de ações que captam a atenção (as que estão nas notícias, com volume invulgar, ou retornos extremos de um dia): perante milhares de escolhas, recorrem ao que lhes chamou a atenção. A atenção pode até ser medida através do volume de pesquisas (Da, Engelberg e Gao 2011). Isto é decisivo para o desenho, porque um movimento de preço acentuado e uma manchete saliente são exatamente os dois gatilhos do InvestiGator, pelo que um alerta que acrescenta contexto chega onde as decisões movidas pela atenção são tomadas.

As notícias também movem os mercados, e o seu texto pode ser medido. Tetlock (2007) constrói um índice diário de pessimismo a partir de uma coluna de jornal e liga-o à pressão sobre os preços e ao volume de negociação, uma prova precoce de que os sinais textuais se relacionam com os resultados de mercado, que é a premissa do motor de notícias do InvestiGator. Este público também é grande e ativo: mesmo durante o crash de março de 2020, os investidores de retalho de uma plataforma sem comissões reforçaram as suas posições em vez de entrar em pânico (Welch 2022), consistente com a posse alargada e a escala de mercado reportadas no Capítulo 1 (Gallup 2025; Securities Industry and Financial Markets Association (SIFMA) 2025).

Para o InvestiGator: os investidores de retalho são limitados pela atenção e movidos pelas notícias, pelo que o sistema não prevê o mercado; baixa o custo de *interpretar* os eventos que já captam a atenção, com uma explicação transparente e evidência histórica real.

2.2 Detecção de Anomalias em Mercados Financeiros

Como se distingue um movimento de preço anormal do ruído comum?

O primeiro gatilho do InvestiGator é um detetor de anomalias, pelo que assenta no campo maduro da detecção de anomalias. A taxonomia padrão (Chandola, Banerjee e Kumar 2009) separa anomalias de *ponto*, *contextuais* e *coletivas*, e agrupa os métodos em famílias estatística, de distância/densidade e de aprendizagem automática (Figura 2.1). Um retorno acentuado de um só dia é uma anomalia contextual de ponto: anormal face ao comportamento recente do próprio ativo.




Figura 2.1: Famílias de métodos de detecção de anomalias relevantes para este trabalho, seguindo Chandola, Banerjee e Kumar (2009) e Pang et al. (2021). A interpretabilidade diminui, e a capacidade de modelação aumenta, da esquerda para a direita.

O detetor mais simples é um z-score deslizante: assinalar um retorno que se desvia muito da sua média e desvio-padrão recentes. É atrativo por ser transparente e fácil de justificar. O seu único pressuposto, uma distribuição localmente estável, é tratado pela janela deslizante, que acompanha o *agrupamento de volatilidade*, a conhecida tendência de períodos calmos e turbulentos chegarem em séries (Bollerslev 1986; Engle 1982). O desvio-padrão deslizante é, com efeito, uma versão não-paramétrica mais simples dessa ideia: adapta-se ao regime atual sem ajustar um modelo que o utilizador não pudesse escrutinar. Entre os dois situa-se a média móvel ponderada exponencialmente dos retornos ao quadrado (o estimador RiskMetrics), que pondera o passado recente mais do que o distante mas mesmo assim não estima parâmetros por instrumento. Um ajuste GARCH completo é recusado aqui sob a simplicidade defensável, mas a afirmação não fica como opinião: a variante EWMA, o primeiro passo no caminho para o GARCH, é submetida ao mesmo protocolo de avaliação no Capítulo 5, pelo que o compromisso é medido e não afirmado.

Detetores mais expressivos trocam a interpretabilidade por capacidade. A Isolation Forest isola outliers por partição aleatória e escala para dimensões elevadas (F. T. Liu, Ting e Zhou 2008); o Local Outlier Factor pontua o quão isolado está um ponto na sua vizinhança (Breunig et al. 2000); os detetores profundos aprendem um modelo de normalidade (Pang et al. 2021). Todos são poderosos mas mais difíceis de ler, e a sua vantagem mostra-se sobretudo em dados de dimensão elevada, não numa única série de retornos. Em vez de os descartar só por esses motivos, o Capítulo 5 avalia tanto a Isolation Forest como o Local Outlier Factor sob o mesmo protocolo causal da regra estatística, pelo que a comparação é empírica. Nas finanças, a detecção é de qualquer modo dominada por métodos *não supervisionados*, porque as anomalias rotuladas são escassas (Ahmed, Mahmood e Islam 2016),

uma restrição que também molda a forma como o InvestiGator é avaliado (Capítulo 5). A Tabela 2.1 compara as famílias.

Tabela 2.1: Abordagens de detecção de anomalias relevantes para este trabalho.

Abordagem	Como funciona	Vantagens / limitações
z-score estatístico (deslizante) (Chandola, Banerjee e Kumar 2009)	Assinala retornos que se desviam de uma média e desvio-padrão deslizantes	Transparente e fácil de explicar; assume uma distribuição localmente estável
Isolation Forest (F. T. Liu, Ting e Zhou 2008)	Isola pontos por partição aleatória (ensemble)	Escalável, lida com dimensionalidade elevada; a pontuação não é diretamente interpretável
Local Outlier Factor (Breunig et al. 2000)	Pontua o isolamento numa vizinhança de densidade local	Capta estrutura local; sensível ao tamanho da vizinhança, pontuação difícil de ler
Detetores profundos (Pang et al. 2021)	Aprendem um modelo de normalidade (ex. autoencoders)	Alta capacidade para dados complexos; opacos, ávidos de dados, difíceis de justificar

Para o InvestiGator: o sinal é uma única série de retornos de baixa dimensão que tem de ser explicada a um não-especialista, pelo que o z-score transparente vence; as famílias mais expressivas ficam anotadas como alternativas cuja opacidade o problema não justifica.

2.3 Inteligência Artificial Explicável

Que tipo de explicação deve o sistema dar?

A IA Explicável (XAI) existe porque os modelos mais fortes raramente mostram o seu raciocínio. As revisões mapeiam o campo e a sua divisão central (Adadi e Berrada 2018; Barredo Arrieta et al. 2020): modelos *transparentes*, interpretáveis em si mesmos, versus métodos *post-hoc* que explicam uma caixa preta já treinada, que podem ser organizados por aquilo que explicam (Guidotti et al. 2018) (Figura 2.2). Uma cautela útil: “interpretabilidade” não é uma coisa só (Lipton 2018), pelo que um sistema deve dizer qual delas oferece. O InvestiGator oferece transparência da sua lógica de decisão e evidência rastreável, não uma pretensão de interpretabilidade plena.

Duas técnicas post-hoc são amplamente usadas: o LIME ajusta um substituto local simples em torno de uma previsão (Ribeiro, Singh e Guestrin 2016), e o SHAP atribui uma previsão às suas features usando valores de Shapley (Lundberg e S.-I. Lee 2017). Ambas são valiosas quando se está comprometido com uma caixa preta. Mas para decisões de alto risco, Rudin (2019) defende abandonar esse compromisso e usar modelos que sejam interpretáveis à partida, já que uma explicação post-hoc é ela própria uma aproximação que pode enganar. O InvestiGator segue isto: explica sobretudo por desenho transparente (cada quantidade exposta, precedentes reais mostrados como evidência), com atribuição de features como um extra opcional.

Boas explicações são também uma questão humana. As pessoas querem razões *contrastivas* e seletivas, não um despejo exaustivo (Miller 2019), razão pela qual cada alerta mostra alguns




Figura 2.2: Os dois grandes caminhos para a explicabilidade (Barredo Arrieta et al. 2020; Guidotti et al. 2018): construir modelos transparentes por desenho, ou explicar uma caixa preta a posteriori. Este trabalho segue o primeiro.

precedentes relevantes e as quantidades exatas por detrás da decisão. As explicações têm também de ser avaliadas, não assumidas: Doshi-Velez e Kim (2017) fazem da *fidelidade*, o quão bem uma explicação reflete o cálculo real, um critério central, e a fidelidade é a propriedade que o InvestiGator consegue garantir (Capítulo 5). A Tabela 2.2 resume as opções.

Tabela 2.2: Abordagens de explicabilidade consideradas.

Método	Tipo	Vantagens / limitações
LIME (Ribeiro, Singh e Guestrin 2016)	Substituto local, post-hoc	Intuitivo, agnóstico ao modelo; as explicações podem ser instáveis, só localmente fiéis
SHAP (Lundberg e S.-I. Lee 2017)	Atribuição por valores de Shapley, post-hoc	Consistente, teoricamente fundamentado; computacionalmente custoso
Desenho transparente (Barredo Arrieta et al. 2020; Rudin 2019)	Lógica inerentemente interpretável	Sem aproximação, fiel por construção; restringe a escolha do modelo

Para o InvestiGator: procurar a explicabilidade por desenho transparente e julgá-la pela fidelidade; tratar a atribuição post-hoc como um complemento, não a fundação.

2.4 Confiança e Dependência Apropriada no Apoio à Decisão

Quando deve o investidor confiar de facto num alerta?

Uma explicação só ajuda se produzir uma dependência *apropriada*: nem descartar um aviso sólido, nem agir cegamente sobre um falível. A perspetiva dos fatores humanos (J. D. Lee e See 2004) chama ao objetivo confiança *calibrada*, dependência ajustada à competência real do sistema, e nomeia dois modos de falha, a *subutilização* (ignorar um bom auxílio) e o *uso indevido* (confiar em excesso num falho). Com dinheiro real, ambos são custosos.

As explicações são a forma como a confiança se calibra, mas não são mágicas. Bansal et al. (2021) mostram que as explicações podem até causar *dependência excessiva*, com as pessoas a aceitar explicações confiantes de respostas erradas. A resposta do InvestiGator é concreta:

explicar com *evidência verificável* (o próprio z-score e os seus parâmetros; precedentes reais com o seu impacto medido), e recusar a previsão em cada alerta.

Para o InvestiGator: a transparência não é decoração mas o mecanismo para a dependência apropriada, pelo que o sistema mostra evidência verificável em vez de uma história persuasiva.

2.5 PLN Financeiro e Representação de Texto

Como deve o sistema representar o significado de uma manchete?

Para comparar manchetes, o texto tem de se tornar números. A literatura de PLN financeiro atravessa três gerações (Kearney e S. Liu 2014): léxicos, embeddings de palavras e modelos neuronais contextuais.

Os léxicos vieram primeiro. Listas de palavras específicas de finanças corrigem o facto de os dicionários de sentimento gerais lerem mal palavras financeiras comuns como “liability” ou “tax” (Loughran e McDonald 2011); são totalmente transparentes mas limitados pelo seu vocabulário. Os embeddings de palavras colocaram depois as palavras num espaço vetorial onde a proximidade significa uso semelhante: o word2vec a partir do contexto local (Mikolov et al. 2013), o GloVe a partir da co-ocorrência global (Pennington, Socher e Manning 2014). Ambos dão a cada palavra um único vetor, cego ao contexto.

O Transformer (Vaswani et al. 2017) removeu esse limite, e o BERT (Devlin et al. 2019) produziu representações profundamente *contextuais*. Comparar dois textos com o BERT diretamente é, porém, custoso; o Sentence-BERT (Reimers e Gurevych 2019) resolve isto dando a cada frase um único vetor de comprimento fixo, comparável por um cosseno barato, exatamente o que a recuperação de precedentes precisa. A uma escala muito grande, a pesquisa exata pode ser trocada por um índice aproximado (Johnson, Douze e Jégou 2021) sem mudar a representação (trabalho futuro). Existem também duas opções mais pesadas: modelos FinBERT afinados ao domínio (Araci 2019; Y. Yang, Uy e Huang 2020) e grandes LLMs financeiros como o BloombergGPT (Wu et al. 2023), ambos poderosos mas mais custosos, menos transparentes, e fora da restrição gratuita e reproduzível deste trabalho. A Tabela 2.3 compara-os.




Figura 2.3: Três gerações de transformar texto financeiro em números. Os léxicos financeiros são transparentes mas limitados pelo seu vocabulário; os vetores de palavra estáticos acrescentam similaridade de uso mas sem contexto; os modelos contextuais (BERT) captam o significado mas são custosos de comparar par a par; o Sentence-BERT dá a cada manchete um único vetor comparável por um cosseno barato, exatamente o que a recuperação de precedentes precisa, e é a representação escolhida aqui. Detalhes na Tabela 2.3.

Tabela 2.3: Abordagens de representação de texto para notícias financeiras.

Abordagem	Representação	Vantagens / limitações
Léxicos financeiros (Loughran e McDonald 2011)	Listas de palavras / tom curadas	Totalmente transparente; limitado pelo vocabulário
word2vec / GloVe (Mikolov et al. 2013; Pennington, Socher e Manning 2014)	Vetores de palavra estáticos	Eficiente; um vetor por palavra, sem contexto
BERT (Devlin et al. 2019; Vaswani et al. 2017)	Embeddings contextuais de token	Forte compreensão; a similaridade par a par é custosa
Sentence-BERT (Reimers e Gurevych 2019)	Embeddings de frase (sínteses)	Similaridade do cosseno eficiente; a escolha deste trabalho
FinBERT (Araci 2019; Y. Yang, Uy e Huang 2020)	Modelo de língua adaptado ao domínio	Afinado a finanças; orientado a sentimento / comunicações
LLMs financeiros (Wu et al. 2023)	Grande modelo generativo	Muito capaz; custoso, opaco, fora do âmbito da camada gratuita

Para o InvestiGator: o Sentence-BERT é o ponto ideal (Figura 2.3), significado contextual para além dos léxicos e dos vetores estáticos, e ainda barato, comparável e gratuito de correr. Uma nota de honestidade sobre a comparação: a avaliação no Capítulo 5 mede o Sentence-BERT contra uma linha de base *lexical*, o que delimita a questão que interessa (o significado bate as palavras de superfície?); as variantes word2vec e FinBERT não são corridas empiricamente, porque os vetores de palavra estáticos são estritamente dominados pelos embeddings de frase contextuais na comparação de frases, e o FinBERT afinado ao domínio está orientado à classificação de sentimento e não à similaridade de frases, a um custo que a restrição gratuita-e-reprodutível deste trabalho exclui. Onde uma afirmação é barata de testar, este trabalho testa-a; onde compraria pouco, enuncia-se antes a razão.

2.6 Recuperação de Informação e Avaliação de Ordenação

Uma vez que as manchetes são vetores, como se ordenam as notícias passadas, e como se sabe se a ordenação é boa?

Ordenar um corpus por relevância a uma consulta é o problema definidor da recuperação de informação (IR). O modelo de espaço vetorial (Salton, Wong e C. S. Yang 1975) representa documentos e consultas como vetores ordenados por similaridade do cosseno; a recuperação por embeddings do InvestiGator é a mesma ideia com vetores mais ricos. A ordenação *lexical* clássica pondera os termos informativos, do TF-IDF ao BM25 (Robertson e Zaragoza 2009), ainda uma linha de base forte. A sua fraqueza conhecida é o *desencontro de vocabulário*: um documento relevante que usa palavras diferentes pontua como dissemelhante. Os embeddings semânticos ultrapassam exatamente isso, razão pela qual o InvestiGator compara contra uma linha de base lexical (Capítulo 5).

Como a recuperação devolve uma lista ordenada, é julgada com medidas sensíveis à ordem (Manning, Raghavan e Schütze 2008); a mais direta é a *precisão@k*, a fração dos k primeiros resultados que são relevantes. O InvestiGator adota-a porque um alerta só pode mostrar um punhado de precedentes, pelo que o que interessa é se os primeiros são relevantes, reportado contra linhas de base aleatória, de recência e lexical.

Para o InvestiGator: a recuperação reutiliza uma pipeline madura de representar-depois-ordenar e a métrica padrão *precisão@k*; a contribuição é a aplicação e o emparelhamento com o impacto medido, não um novo algoritmo.

2.7 Estudos de Evento e Impacto Notícia–Mercado

Tendo encontrado notícias análogas, como se mede o que fizeram ao preço, honestamente?

A ferramenta é o *estudo de evento*, introduzido por Fama et al. (1969) e padronizado para retornos diários por Brown e Warner (1985), que fixou a prática de medir retornos sobre janelas curtas pós-evento, a base para os horizontes de +1, +3 e +5 dias do InvestiGator. O impacto é medido estritamente *depois* do evento, pelo que descreve um resultado, não uma previsão.

Porquê não prever simplesmente o preço? Porque as notícias públicas são absorvidas nos preços quase de imediato, a hipótese do mercado eficiente (Fama 1970), pelo que prever retornos a partir de notícias públicas é, por construção, muito difícil. O InvestiGator não compete, portanto, com a eficiência do mercado; mede e explica as reações que *já* se seguiram a notícias comparáveis, o que é simultaneamente mais honesto e mais defensável para um não-especialista.

Relacionar o *texto* das notícias com o impacto é uma área ativa: Tetlock (2007) é um exemplo precoce, e uma linha mais recente tenta *prever* movimentos a partir das notícias (Ding et al. 2015; Xing, Cambria e Welsch 2018). O InvestiGator deliberadamente fica aquém da previsão. Fazer isto em escala precisa de notícias alinhadas aos preços, que é a contribuição do conjunto de dados FNSPID (Dong, Fan e Peng 2024), usado para construir a base de conhecimento; os seus limites de cobertura e período são notados no data card do Capítulo 3.

Para o InvestiGator: emparelhar a recuperação semântica com o impacto de estudo de evento sobre o FNSPID é o núcleo metodológico, evidência sobre o passado, nunca uma previsão.

2.8 Raciocínio Baseado em Casos e Recuperação de Precedentes

O que é o motor, numa ideia familiar?

É o *raciocínio baseado em casos* (CBR). Na descrição clássica (Aamodt e Plaza 1994), um sistema CBR *recupera* casos passados semelhantes, *reutiliza* os seus resultados, e opcionalmente *revê* e *retém-nos*. O InvestiGator é o núcleo recuperar-e-reutilizar: cada manchete passada mais o seu impacto medido é um *caso*; uma manchete nova é a consulta; a similaridade do cosseno recupera; o impacto dos precedentes é reutilizado como evidência. Para antes de *rever*, pelo que nunca transforma a evidência numa previsão.

Para o InvestiGator: nomear o motor como CBR mostra que é um paradigma reconhecido, não ad hoc, e as suas explicações “isto assemelha-se a estes casos passados” são naturalmente inteligíveis para um não-especialista.

2.9 Triagem Aprendida de Alertas: Classificação Supervisionada de Materialidade

Quando dezenas de manchetes chegam num dia, quais merecem um alerta?

A recuperação responde a “a que é que isto se assemelha?”, e o estudo de evento responde a “o que se seguiu a notícias semelhantes?”. Nenhum ordena o fluxo de entrada. Isso é um problema de *triagem*, e pode ser posto como classificação supervisionada sem quebrar a regra de não-previsão. O modelo estima a probabilidade de um *movimento anormal de tamanho invulgar, em qualquer direção*, se seguir a uma notícia; o rótulo é produzido pela própria medição de estudo de evento do sistema, o retorno ajustado ao mercado de Brown e Warner (1985) contra um proxy de índice. O alvo é a *materialidade*, se o mercado reagiu de todo. A direção e a magnitude da trajetória do preço nunca são previstas, pelo que a tarefa fica do lado defensável da linha do mercado eficiente traçada antes neste capítulo.

Duas famílias de modelos cobrem o compromisso interpretabilidade–capacidade. A regressão logística é a escolha transparente: com entradas padronizadas, os seus log-odds são uma soma aditiva exata das contribuições por feature. Isso torna-a o tipo de modelo inerentemente interpretável que Rudin (2019) defende dever ser preferido quando as explicações importam. Os ensembles de árvores de decisão com gradient boosting (Friedman 2001) são o aprendiz não-linear mais forte e servem de teto contra o qual o modelo interpretável é comparado. Para um utilizador final, a pontuação só é honesta se for uma *probabilidade*: as pontuações cruas de um classificador estão tipicamente mal calibradas, e a calibração post-hoc, como ajustar uma sigmoide sobre dados de validação retidos (escalonamento de Platt), corrige isto (Niculescu-Mizil e Caruana 2005). Sob desequilíbrio de classes, a avaliação usa a área sob a curva de precisão-recall em vez da exatidão. Uma precisão em forma de orçamento completa o quadro (quantos dos N alertas que um utilizador consegue absorver por dia eram materiais), porque esse orçamento é exatamente o custo de fadiga de alertas que a triagem existe para reduzir.

Para o InvestiGator: a triagem acrescenta uma pontuação de severidade *treinada* por cima da pipeline transparente, ordenada e limitada por dia, explicada pelas suas contribuições aditivas, calibrada sobre dados de validação, e sempre comparada contra uma linha de base só-volatilidade antes de lhe ser permitido pesar.

2.10 Ferramentas Existentes para o Investidor de Retalho

O que pode um investidor de retalho já usar, e o que falta?

Três tipos de ferramenta são comuns hoje, e cada um deixa uma lacuna. Os *alertas de preço*, em todas as aplicações de corretora, disparam quando um limiar de preço ou percentagem é ultrapassado; aproveitam o mesmo comportamento de atenção que o InvestiGator visa (Barber e Odean 2008), mas um limiar fixo ignora a volatilidade própria de cada ação (disparando constantemente em nomes voláteis, raramente em calmos) e diz apenas *que* um nível foi ultrapassado, nunca *porquê*. As *aplicações de notícias e sentimento* agregam manchetes e anexam uma pontuação de sentimento, apoiando-se na ligação entre o tom e

os mercados (Tetlock 2007) e nos léxicos financeiros (Loughran e McDonald 2011); mas uma única polaridade é fina, muitas vezes proprietária, e raramente liga uma manchete a precedentes históricos concretos e aos seus resultados. Os *robo-advisors*, a ferramenta de fintech de retalho mais estudada, ajudam genuinamente ao melhorar a diversificação e refrear os enviesamentos (Cardillo e Chiappini 2024; D’Acunto, Prabhala e Rossi 2019), mas *agem por* o investidor com lógica proprietária, o oposto de uma ferramenta explicação-primeiro que deixa a decisão ao utilizador. A Tabela 2.4 posiciona os três face ao InvestiGator.

Tabela 2.4: Ferramentas de retalho existentes versus o sistema proposto neste trabalho.

Ferramenta	O que faz	Explica por-quê?	Mostra pre-cedentes?	Age pelo utiliza-dor?
Alerta de preço de corretora	Dispara num limiar fixo de preço / %	Não	Não	Não
App de notícias / sentimento (Tetlock 2007)	Agrega notícias, pontua senti-mento	Em parte (pontuação opaca)	Não	Não
Robo-advisor (D’Acunto, Prabhala e Rossi 2019)	Aloca e reequilibra uma carteira	Raramente (proprietário)	Não	Sim
Este trabalho (InvestiGator)	Explica eventos, mostra evidência	Sim, por desenho	Sim (impacto medido)	Não

Para o InvestiGator: cada ferramenta existente cobre um canto, alertar, notícias ou alocação, mas nenhuma combina deteção sensível à volatilidade, explicação transparente e evidência histórica concreta numa só ferramenta que informa em vez de decidir. Essa lacuna é o nicho que este trabalho preenche.

2.11 Análise Comparativa e Posicionamento

Então o que escolhe o InvestiGator, e porquê?

A Tabela 2.5 reúne as escolhas face às suas alternativas. A regra ao longo de todo o trabalho é a *simplicidade defensável* (Rudin 2019): quando duas opções têm desempenho comparável, preferir a mais transparente, porque o sistema tem de ser compreendido e usado por um não-especialista.

2.12 Conclusões do Capítulo

Nenhum destes blocos de construção é novo. O que é escasso, e o que este trabalho constrói, é a sua integração disciplinada num único sistema explicável para o investidor de retalho: um detetor transparente, recuperação semântica emparelhada com o impacto de estudo de evento, e explicações fiéis por construção. O próximo capítulo transforma estas escolhas num método.

Tabela 2.5: Escolhas de componentes neste trabalho versus alternativas.

Componente	Escolhido	Alternativa	Porquê
Deteção de anomalias	z-score (deslizante)	Isolation Forest, detetores profundos	Transparência; sinal de baixa dimensão
Recuperação de notícias	Sentence-BERT + cos-seno	Léxicos, word2vec, LLMs	Contextual mas barato e reproduzível
Medição de impacto	Janelas de estudo de evento	—	Padrão, reproduzível, sem previsão
Explicação	Desenho transparente + precedentes	Só LIME / SHAP	Fiel por construção

Capítulo 3

Métodos e Materiais

[Tradução em curso. O conteúdo deste capítulo espelha ../thesis/ch3/chapter3.tex.]

Capítulo 4

InvestiGator: Um Sistema de Alertas Financeiros Explicável para Investidores de Retalho

Este capítulo responde a cinco perguntas, por ordem: *O que é o sistema, numa imagem? Com que objetos trabalha? Quais são as suas partes, e quem faz o quê? Como flui os dados por ele? E como decide?* O Capítulo 3 argumentou a favor dos métodos individuais; aqui eles encaixam-se num único sistema funcional, o InvestiGator.

4.1 Visão Geral

O que é o sistema, numa imagem?

O InvestiGator vigia o mercado acionista dos EUA por um investidor de retalho e levanta um alerta quando um de dois gatilhos independentes dispara: um movimento de preço abrupto, ou uma notícia relevante que chega. Cada alerta traz uma explicação completa e rastreável, não uma mera notificação. O sistema é uma pipeline de componentes de responsabilidade única ligados por um esquema de dados comum, pelo que as camadas viva e histórica são diretamente comparáveis. A Figura 4.1 é a vista numa imagem: duas fontes de dados e a base de conhecimento alimentam dois motores, cuja evidência converge num só passo de explicação antes da entrega.

Três princípios de engenharia mantêm o sistema testável e defensável. Primeiro, **uma fatia fina foi construída de ponta a ponta antes da largura**: o gatilho de mercado funcionou do preço ao alerta entregue antes de o motor de correlação mais pesado ser acrescentado, o que controlou o risco de integração. Segundo, **a lógica pura é separada da entrada/saída**, pelo que o núcleo numérico corre e é testado offline, sem rede nem a stack de modelos. Terceiro, **os componentes são programados a interfaces**: o passo de embedding tem duas implementações intermutáveis (uma linha de base lexical sem dependências e o Sentence-BERT), que é o que torna a comparação de modelos do Capítulo 5 justa. A Tabela 4.1 reúne as principais decisões de desenho; num trabalho deste tipo, esse juízo de engenharia é a contribuição.

4.2 O Modelo de Dados

Com que objetos trabalha o sistema, e como se relacionam?




Figura 4.1: Arquitetura do InvestiGator. A camada viva (dados de mercado, fonte de notícias) e a base de conhecimento histórica alimentam dois motores (o detetor de anomalias e o motor de correlação) cuja evidência converge no motor de explicação antes de um alerta ser entregue através do Telegram. O gatilho de movimento de mercado segue o caminho da esquerda; o gatilho de notícias o da direita.

O objeto central é um *caso*: uma notícia passada juntamente com o que aconteceu ao seu preço a seguir. Tudo o resto existe para construir casos, guardá-los e recuperá-los. A Figura 4.2 mostra os objetos e as suas relações.

Dois pontos tornam o modelo fácil de reter. Primeiro, o *esquema partilhado*: um **NewsItem** ao vivo e um **NewsRecord** histórico carregam a mesma data, ticker e manchete, pelo que uma manchete fresca pode ser comparada diretamente com os casos guardados. Um **NewsRecord** é simplesmente um **NewsItem** que foi enriquecido com o *embedding* da sua manchete e o seu *impacto* medido a +1, +3 e +5 dias de negociação. Segundo, a *base de conhecimento* é apenas uma coleção de casos; pedir-lhe precedentes devolve os top-*k* casos mais similares com as suas pontuações de similaridade. O lado do mercado é ainda mais simples: o detetor emite um **AnomalyResult** contendo o movimento e cada quantidade por detrás dele (z , μ , σ , janela, limiar). Estes poucos objetos são tudo o que o motor de explicação alguma vez precisa.

4.3 Componentes e Responsabilidades

Quais são as partes, e quem faz o quê?

O InvestiGator é um pacote por componente, cada um com uma responsabilidade única e uma interface pequena, que é o que permite testar o núcleo numérico offline e trocar uma implementação por outra. A Tabela 4.2 lista-os com a sua única função e os dados em que a transformam.

Tabela 4.1: Principais decisões de desenho no InvestiGator e a sua justificação.

Decisão	Escolha	Justificação
Método de deteção	z-score deslizante	Transparente; cada alerta é explicável a um não-especialista
Representação de notícias	Embeddings Sentence-BERT	Significado contextual, mas barato e reprodutível de comparar
Medição de impacto	Janelas de estudo de evento	Padrão, reprodutível; caracteriza um resultado, não uma previsão
Estratégia de explicação	Desenho transparente + precedentes	Fiel por construção, não uma aproximação post-hoc
Arquitetura de dados	Esquema partilhado, duas camadas	A evidência viva e histórica é diretamente comparável
Acoplamento de componentes	Programados a interfaces	Testável offline; permite substituição justa de modelos
Canal de entrega	Bot de Telegram	Gratuito, ubíquo, sem cliente à medida

4.4 Fluxo de Dados

Como se move os dados pelo sistema, de ponta a ponta?

A Figura 4.3 traça toda a pipeline como três faixas que convergem. A faixa *offline* (topo) corre uma vez: as notícias FNSPID são alinhadas aos preços e embebidas na base de conhecimento (Dong, Fan e Peng 2024). Os dois gatilhos vivos correm online. A faixa de *notícias* (meio) embebe uma manchete que chega, encontra os seus casos mais próximos na base de conhecimento, e anexa o seu impacto medido. A faixa de *mercado* (fundo) transforma preços ao vivo num z-score e dispara apenas quando este cruza o limiar. Ambas as faixas entregam a sua evidência ao motor de explicação, que entrega um alerta através do Telegram.

Um detalhe na construção offline importa para a honestidade: cada notícia é alinhada ao primeiro dia de negociação em ou após a sua data, e o impacto é medido apenas a partir do fecho desse dia em diante, pelo que um salto já no preço de abertura nunca é creditado ao sistema. Construir o corpus multi-ano completo é um trabalho pontual longo, pelo que a avaliação do Capítulo 5 usa uma base de conhecimento construída a partir de notícias reais recentes pelo processo idêntico, com a construção completa deixada para trabalho futuro.

4.5 Lógica de Decisão

Como decide o sistema, de facto? Cada gatilho aplica uma regra simples e transparente.

Gatilho de mercado. Assinalar o dia em que o z-score absoluto cruza o limiar, $|z_t| > k$, com z_t calculado a partir da janela anterior como na Equação ???. O detetor devolve não só a decisão sim/não mas cada quantidade por detrás dela (z , μ , σ , janela, limiar), que




Figura 4.2: Os objetos com que o InvestiGator trabalha. Um **NewsItem** ao vivo e um **NewsRecord** histórico partilham o mesmo esquema (data, ticker, manchete); um **NewsRecord** é um *caso*, acrescentando o embedding da manchete e o seu impacto medido pós-evento. O **Embedder** produz esses vetores; a **Base de conhecimento** guarda muitos casos; uma manchete de consulta recupera os top-*k* casos mais similares com as suas pontuações de similaridade. O gatilho de mercado produz um **AnomalyResult** separado.

é exatamente o que torna a explicação fiel. A mesma regra é aplicada a séries de preços inteiras na avaliação, pelo que as experiências usam a lógica de produção.

Gatilho de notícias. Embeber a manchete que chega, ordenar a base de conhecimento por similaridade do cosseno, e tomar os top-*k* casos. Para cada um, reportar o impacto observado a +1, +3 e +5 dias, medido a partir do fecho do dia do evento, e mostrar a sua média como evidência. Nada aqui prevê: os números são o que *de facto* aconteceu depois de notícias passadas comparáveis, e a base de conhecimento é consultada mas nunca decide.

Severidade aprendida (triagem). Por cima das duas regras transparentes assenta o componente treinado opcional da Secção ?? : cada notícia que chega é pontuada com a probabilidade calibrada de se seguir um movimento anormal, e o alerta pode ser *filtrado* (gated), enviado só quando a pontuação ultrapassa um limiar configurado, e *anotado* com a pontuação e as suas principais contribuições aditivas. O gate vem desligado por defeito e falha-aberto: sem ficheiro de modelo, ou com histórico de preços insuficiente para calcular as features de contexto, a pipeline comporta-se exatamente como antes. A variante em produção usa apenas features de contexto, pelo que corre sem a stack pesada de embeddings, e a linha do alerta nomeia sempre a evidência pelo que ela é: triagem sobre casos históricos, não uma previsão.

4.6 Explicação e Entrega

Como é o alerta explicado, e como chega ao investidor?

O motor de explicação compõe cada alerta diretamente a partir dos objetos acima, pelo que o texto não pode divergir do cálculo. Para o gatilho de mercado, enuncia o movimento, o z-score, o limiar e a janela, e a média e desvio-padrão recentes, e põe o z-score em linguagem simples (quantas vezes o movimento de um dia típico representa) para que um não-especialista o consiga ler. Para o gatilho de notícias, lista os precedentes recuperados (data, ticker, similaridade, impacto medido, manchete) e o seu impacto médio, e termina

Tabela 4.2: Os componentes do InvestiGator, cada um com uma responsabilidade única.

Componente	Responsabilidade	Entrada → saída
Dados de mercado	Obter preços, calcular log-retornos	ticker → retornos diários
Fonte de notícias	Obter e normalizar notícias ao vivo	ticker → NewsItem(s)
Embedder	Transformar uma manchete num vetor	manchete → embedding
Base de conhecimento	Guardar casos passados; recuperar o mais próximo	manchete → top- <i>k</i> casos
Detetor de anomalias	Assinalar movimentos relativos à volatilidade	retornos → AnomalyResult
Motor de correlação	Similaridade do cosseno + impacto de estudo de evento	manchete, KB → precedentes + impacto
Modelo de triagem	Severidade aprendida: $P(\text{segue-se movimento anormal})$ calibrada	manchete + contexto → probabilidade + contribuições
Motor de explicação	Compor um alerta fiel a partir dos objetos	objetos → texto do alerta
Entrega de alertas	Enviar o alerta ao investidor	texto do alerta → Telegram
Orquestração	Correr cada gatilho de ponta a ponta	gatilho → alerta entregue

sempre com um aviso explícito de que estes são resultados passados observados, não uma previsão.

A entrega é por Telegram, escolhido pela sua interface de bot gratuita e ubíqua. Um alerta real foi entregue durante os testes; a Figura 4.4 mostra o formato que o investidor recebe, com toda a cadeia de raciocínio numa só mensagem. No sistema em produção o formato da mensagem foi depois compactado para legibilidade (o facto mais forte primeiro, o método numa nota de rodapé curta, e o intervalo dos resultados dos precedentes mostrado a par da sua média); os campos transportados são exactamente os de cima, pelo que o argumento da fidelidade não muda.

O mesmo raciocínio é também publicado como um dashboard ao vivo (Figura 4.5): uma faixa “market now” resume o dia de toda a watchlist num relance (empresas de um mesmo setor movem-se muitas vezes em conjunto, pelo que o contexto importa); por baixo, uma empresa seleccionada de cada vez é mostrada com um grande gráfico de preços no qual cada evento detetado (anomalias de mercado e notícias materiais — exactamente os alertas entregues ao canal Telegram, lidos de um único registo partilhado e versionado e nunca recalculados) é marcado e pode ser sobrevoado para o texto completo do alerta; os mesmos eventos são listados numa tabela em baixo, e uma linha compacta reporta o risco de fundo do modelo de triagem treinado (Secção ??), calculado todos os dias mesmo sem uma manchete fresca. Tudo o resto (método, avaliação, citação) vive numa vista secundária separada, mantendo a superfície principal só de leitura e mínima.




Figura 4.3: O fluxo de ponta a ponta do InvestiGator como uma pipeline conectada. *Offline* (topo), as notícias FNSPID são alinhadas aos preços e embebedas na base de conhecimento. O *gatilho de notícias* (meio) embebe uma manchete que chega, encontra os seus precedentes mais próximos na base de conhecimento e anexa o seu impacto observado; o *gatilho de mercado* (fundo) transforma preços ao vivo num z-score e dispara apenas quando excede o limiar. Ambos os caminhos convergem no motor de explicação, que entrega um alerta explicado através do Telegram. Esta é a vista simplificada; a pipeline completa, com cada porta de decisão e o seu valor de configuração em produção, é a Figura A.1 no Apêndice A.

4.7 A Vida de Um Alerta

O que faz toda a pipeline, concretamente, da fonte bruta ao telemóvel? A resposta mais limpa é seguir um alerta *real* por cada fase. O caso é a mesma decisão de produção decomposta na Tabela ???: a 12 de julho de 2026 o canal público recebeu um alerta para a Meta sobre a manchete “*Mark Zuckerberg Said Meta’s AI Bets ‘Haven’t Come to Fruition Yet’ as Shares Fell 5%*”. A Tabela 4.3 percorre as fases com os valores que o sistema efetivamente calculou; cada linha é verificável no registo de histórico partilhado que o dashboard lê.

As mesmas portas, vistas em agregado, são a resposta do sistema à fadiga de alertas. A Figura 4.6 mostra os primeiros cinco dias de operação ao vivo: a varredura capturou 944 manchetes relevantes distintas em todos os dez nomes da watchlist, e o canal recebeu 42 alertas, uma seletividade de 22:1 concentrada nos três nomes onde a evidência passou todas as portas. As notícias fluíram para todas as empresas; os alertas aconteceram apenas onde um precedente forte e uma pontuação de triagem material coincidiram. (Uma nota honesta: o teto diário por ticker entrou em produção a 11 de julho, pelo que os dois dias mais precoces mostram mais alertas por nome do que o estado estacionário.)

4.8 Uso Prático e Desenho Responsável

O que é preciso para o correr, e o que exige o uso responsável?

O InvestiGator corre como dois pontos de entrada, um por gatilho, cada um a executar um ciclo completo. No uso diário correm num horário: existe uma implantação de referência em que um temporizador de integração contínua gratuito varre repetidamente uma watchlist durante o horário do mercado dos EUA e entrega quaisquer alertas a um canal de Telegram, com um dashboard interativo publicado a par. Correr o sistema precisa apenas de recursos




Figura 4.4: Um alerta de notícias do InvestiGator tal como entregue através do Telegram (a mensagem é a saída real do produto, em inglês). Uma única mensagem carrega a cadeia de raciocínio completa e rastreável: o evento detetado, o impacto médio observado de eventos passados análogos, os precedentes individuais com as suas pontuações de similaridade e impacto medido, e um aviso explícito de não-previsão. Os números mostrados são uma ilustração representativa e arredondada; a saída real completa de ponta a ponta aparece no Capítulo 5 (Estudo de Caso 3).

gratuitos: uma fonte de dados de mercado, uma fonte de notícias de empresa ou RSS (uma chave de API mantida fora do controlo de versões), e a base de conhecimento construída uma vez a partir do corpus. O Apêndice A dá os passos exatos. Os alertas reais entregues durante os testes e pela varredura agendada mostram que o caminho dos dados brutos ao telemóvel do investidor funciona de ponta a ponta. Uma vez ao vivo, as decisões de triagem são também *pós-validadas*: cada decisão registada é rotulada dias depois com o resultado que efetivamente se seguiu, dando monitorização de precisão e calibração ao vivo e dados de treino frescos (Secção ??).

Dois limites práticos merecem ser enunciados com clareza. A camada gratuita de notícias devolve apenas uma janela recente, pelo que a base de conhecimento é mais rasa do que a construção multi-ano para a qual foi desenhada (um limite de cobertura, não de método). E o InvestiGator é um protótipo de apoio à decisão, não um serviço de produção: sem contas de utilizador, sem persistência para além do ficheiro da base de conhecimento. Estes são passos ordinários de protótipo a produto, registados abertamente em vez de escondidos.

A operação ao vivo também ensinou uma lição de engenharia da forma honesta. Durante os primeiros dias de implantação contínua o caminho de mercado ficou em silêncio: a fonte de preços gratuita bloqueia os endereços de rede partilhados dos runners alojados, e com uma única fonte e sem fallback, a varredura simplesmente não recebia dados. A falha foi diagnosticada a partir dos próprios registos do sistema (os alertas de notícias continuavam a fluir enquanto nem um resumo de mercado aparecia, o que isolou a fonte de preços como a causa) e respondida com engenharia e não com uma mudança de parâmetro: os preços diários vêm agora através de uma cadeia de fornecedores gratuitos tentados por ordem, e a verificação de cotação em tempo real, que usa uma fonte autenticada e por isso fiável, foi promovida do vigia opcional para cada varredura agendada. O episódio é reportado porque




Figura 4.5: O dashboard público (uma captura genuína, não um mockup): a faixa “market now” de toda a watchlist, as notas da abertura da manhã e do fecho anterior como notas recolhíveis, uma empresa selecionada de cada vez, um grande gráfico de preços por intervalo com os eventos detetados marcados na curva (sobrevoar mostra o alerta completo; o marcador aqui é um alerta real do canal público), e o risco de fundo do modelo de triagem treinado. Capturado da base de código em produção durante a operação ao vivo.

é instrutivo: uma única fonte de dados gratuita é um ponto único de falha, e um sistema que regista o seu próprio comportamento é o que torna tal falha diagnosticável de todo.

Uma ferramenta destinada a não-especialistas levanta também duas questões de desenho responsável. A primeira é a *fadiga de alertas*: uma ferramenta que dispara demasiadas vezes ensina o utilizador a ignorá-la. O gatilho de mercado trata disto ao disparar apenas em extremos relativos à volatilidade, e o lado das notícias é tratado pelo modelo de triagem, cuja pontuação de severidade existe precisamente para ordenar o fluxo e filtrar os itens menos materiais (Secção 4.5); a avaliação do Capítulo 5 inclui, portanto, uma métrica de precisão-dentro-do-orçamento-diário que mede este custo diretamente. A segunda é a *dependência excessiva*: uma explicação confiante pode ser merecedora de mais confiança do que a sua evidência justifica (Secção 2.4). O desenho atual mitiga isto ao mostrar os precedentes individuais e a sua dispersão em vez de um número solitário, e ao recusar a previsão em cada alerta; extensões naturais são de-duplicar precedentes quase idênticos e sinalizar quando um agrupamento recuperado discorda na direção.

4.9 Conclusões do Capítulo

O InvestiGator é uma pipeline de dois gatilhos e duas camadas construída a partir de alguns objetos claros (um *caso*, a base de conhecimento, um resultado de anomalia) e componentes de responsabilidade única, com a explicabilidade embutida ao compor cada alerta diretamente a partir do próprio cálculo do sistema, e uma pontuação de triagem treinada opcional,

Tabela 4.3: A vida de um alerta real (META, 12 de julho de 2026), fase a fase. Cada valor é real: a mensagem é preservada verbatim no histórico de alertas partilhado, e a pontuação de triagem é decomposta termo a termo na Tabela ??.

Fase (porta)	O que aconteceu para este alerta
1. Obter	A varredura agendada puxa as notícias de empresa da semana para cada ticker da watchlist da API de notícias gratuita.
2. Filtro de relevância	A manchete nomeia a empresa (“Meta”, “Mark Zuckerberg” estão na lista de aliases do ticker) e não corresponde a nenhum padrão de boilerplate de resumo de mercado: mantida.
3. Captura (KB viva)	A manchete é embebida (MiniLM, 384-d) e guardada como um caso <i>pendente</i> ; matura em precedente quando o seu próprio impacto a +5 dias se torna observável.
4. Frescura	Datada dentro da janela de dois dias: elegível (a mesma história não pode voltar a alertar durante dias).
5. Recuperação	As bases de conhecimento são ordenadas por cosseno com decaimento por idade; top três: MSFT 2023-11-07 ($s = 0.46$, +2.70% em 5d), NVDA 2023-08-02 ($s = 0.51$, -3.87%), NVDA 2023-09-21 ($s = 0.46$, +5.05%).
6. Chão de evidência	Melhor cosseno $0.51 \geq 0.45$: forte o suficiente para mostrar. Os precedentes discordam na direção, pelo que a mensagem carrega o aviso explícito “ <i>moved in BOTH directions</i> ”.
7. Triagem aprendida	O modelo só-contexto em produção pontua $p = 0.54 \geq 0.5$ (decomposto na Tabela ??): não filtrado.
8. Tetos e dedup	Dentro do teto de dois alertas por ticker por dia; não enviado antes por nenhum produtor (dedup do histórico partilhado): mantido.
9. Entrega e registo	Enviado ao canal público de Telegram com a cláusula fixa de não-previsão; anexado verbatim ao histórico partilhado, a partir do qual o dashboard o marca no gráfico de preços.

desligada por defeito e honestamente rotulada, sobreposta por cima. O próximo capítulo põe os componentes centrais à prova sobre dados reais.




Figura 4.6: Seletividade de produção sobre os primeiros cinco dias ao vivo: manchetes relevantes capturadas (claro) versus alertas efetivamente enviados (escuro), por ticker da watchlist. Todas as contagens são reais, lidas da branch de dados partilhada; a diferença entre as duas barras é o trabalho das portas de qualidade da Tabela 4.3.

Capítulo 5

Estudos de Caso

[Tradução em curso. O conteúdo deste capítulo espelha ../thesis/ch5/chapter5.tex.]

Capítulo 6

Conclusões

Esta dissertação propôs-se desenhar, implementar e avaliar um sistema de alertas financeiros explicável e reproduzível para investidores de retalho dos EUA, movido por dois gatilhos independentes e entregue através do Telegram. Este capítulo resume o que foi alcançado face às questões de investigação, revisita as contribuições, e enuncia as limitações e as direções que elas abrem.

6.1 Conclusões Principais

O trabalho resume-se melhor voltando às quatro questões de investigação do Capítulo 1, reunidas num relance na Figura 6.1 e depois tomadas uma a uma.

Questão de investigação	Veredicto	Um número
RQ1: detetar movimentos abruptos de forma transparente	Sim	taxa de disparo 0.015 vs 0.344; F_1 0.516
RQ2: precedentes análogos, sem lookahead	Sim (recuperação)	P@5 0.514 vs 0.346 lexical, 0.240 aleatório
RQ3: explicações fiéis e úteis	Fiel; utilidade em aberto	fiel por construção; ainda sem estudo humano
RQ4: triagem para além da volatilidade	Mecanismo sim, texto não	quota 0.163 → 0.632; PR-AUC 0.542 vs 0.496

Figura 6.1: As quatro questões de investigação e os seus veredictos, reportados exatamente como se revelaram. Duas são um sim sem reservas; duas são divisões honestas: as explicações são fiéis por construção mas a sua utilidade aguarda um estudo humano, e a triagem aprendida ajuda como mecanismo de produto embora nenhum modelo de texto de manchetes tenha batido a linha de base da volatilidade neste corpus. Os números são do Capítulo 5.

RQ1: deteção transparente de movimentos abruptos. Sim. Um detetor de z-score deslizante assinala retornos anormais e, mais importante, fá-lo a um ritmo estável *em ações de volatilidade muito diferente*, onde um limiar de percentagem fixa não consegue. Como reportado no Capítulo 5, a taxa de disparo variou apenas 0.015 entre os quinze tickers no z-score, contra 0.344 na linha de base fixa, e o z-score atingiu um F_1 de 0.516 contra um

indicador de movimentos extremos, mais do dobro da linha de base. O método é simples o suficiente para que cada alerta possa ser explicado ao investidor.

RQ2: precedentes análogos sem lookahead. Sim, para a recuperação. A recuperação semântica com Sentence-BERT recuperou muito mais precedentes análogos por setor do que qualquer alternativa trivial: uma precisão@5 cross-ticker de 0.514 ± 0.015 (em cinco corridas), contra 0.346 de uma linha de base lexical, 0.240 do aleatório e 0.126 da recência. Uma decomposição por setor mostrou que o ganho é maior onde o vocabulário do domínio é mais distintivo (energia, saúde). O estudo de caso ponta a ponta mostrou-a a trazer à superfície precedentes genuinamente temáticos a partir de fontes de empresas diferentes. O impacto é medido estritamente após o evento, ao estilo de um estudo de evento, pelo que nenhuma informação futura se infiltra na evidência. A maquinaria de medição está montada e comporta-se de forma coerente; uma validação em larga escala e multi-ano das magnitudes de impacto fica para trabalho futuro.

RQ3: explicações fiéis e úteis. Fiéis, sim; úteis, ainda em aberto. Como cada alerta é composto diretamente a partir dos mesmos objetos que o sistema calcula (o z-score e os seus parâmetros, ou os precedentes recuperados com as suas pontuações e impactos medidos), a explicação não pode divergir da lógica subjacente, e cada alerta termina com um aviso explícito de não-previsão. A utilidade para um investidor de retalho é plausível por desenho mas ainda não foi medida com um estudo humano, sendo por isso reportada como um ponto em aberto e não como um resultado assente.

RQ4: triagem aprendida para além das linhas de base de volatilidade. Não na hipótese do texto; sim no mecanismo. Um modelo de materialidade supervisionado foi treinado, calibrado e testado em 79,753 exemplos do FNSPID (2018–2023) sob um protocolo temporal estrito. Como mecanismo de produto, a triagem aprendida é claramente valiosa: dentro de um orçamento de cinco alertas por dia, elevou a quota de alertas materiais de 0.163 para 0.632, com probabilidades calibradas. Mas a comparação decisiva pré-comprometida foi noutra sentida: nenhum modelo que lê o texto da manchete bateu a linha de base só-volatilidade (PR-AUC 0.542 contra 0.496 do modelo principal contexto+texto), pelo que neste corpus o sinal da triagem vive no contexto de mercado, não na redação da manchete. Juntamente com a comparação com a Isolation Forest do estudo de anomalias, este é o segundo teste justo e causal em que a escolha transparente venceu, e ambos os resultados são reportados exatamente como se revelaram.

6.2 Questões de Investigação e Objetivos Alcançados

O objetivo geral, desenhar, implementar e avaliar um sistema de alertas explicável e reproduzível movido por dois gatilhos, foi cumprido: o InvestiGator é um sistema funcional cujos dois gatilhos foram provados de ponta a ponta e cujos componentes centrais, incluindo o modelo de triagem treinado, foram avaliados sobre dados reais. Os objetivos de apoio também foram cumpridos: uma fatia fina de ponta a ponta foi entregue primeiro; cada componente foi mantido na sua forma mais simples e defensável; a avaliação seguiu um desenho fixado à partida; e todo o sistema é reproduzível a partir de scripts versionados.

6.3 Contribuições Revisitadas

Enquanto dissertação de *Engenharia* de Inteligência Artificial, a contribuição é a integração, aplicação e avaliação crítica de componentes existentes num todo funcional, explicável e reproduzível, e não um novo algoritmo. Destacam-se quatro contribuições concretas. Primeira, uma metodologia documentada e reproduzível para **correlação notícia-mercado** que combina recuperação por embeddings de frase com janelas de impacto de estudo de evento, com escolhas explícitas de métrica de similaridade e horizonte e evitação explícita de lookahead. Segunda, o **InvestiGator**, um **sistema de alertas XAI-first** cuja cadeia de raciocínio inteira (detecção, evidência, fontes e precedentes) é exposta a um utilizador não-especialista e é fiel por construção. Terceira, um **modelo de triagem de materialidade** treinado e calibrado, rotulado pelo próprio código de estudo de evento do sistema sobre o corpus multi-ano, integrado nos alertas desligado por defeito como evidência ordenada e explicada, e continuamente pós-validado em produção contra os resultados que efetivamente se seguiram. Quarta, uma **avaliação crítica e honesta** de cada componente central contra linhas de base triviais, lexicais e de volatilidade sobre dados reais, incluindo duas comparações pré-comprometidas estatística-versus-aprendida que os métodos transparentes venceram; os resultados, ablações e limitações são todos reportados com clareza e regenerados a partir de scripts versionados.

6.4 Limitações

Restam várias limitações, enunciadas com clareza:

- **Corpus.** A avaliação de recuperação usou um corpus de notícias recente, de poucos meses, de um serviço gratuito, o que limita a análise de impacto e torna os números de recuperação, embora reais, preliminares. O estudo de triagem usou de facto o subconjunto multi-ano do FNSPID, mas com catorze dos quinze tickers (a Meta está indexada sob o seu símbolo antigo no corpus) e apenas o texto da manchete.
- **Indicadores aproximados.** A relevância é aproximada por concordância de setor, e o rótulo de anomalia é relativo à volatilidade, razão pela qual o argumento da taxa de disparo sem rótulos tem primazia.
- **Texto curto.** As notícias são representadas apenas por manchetes, o que limita a semântica captada.
- **Tema, não direção.** A similaridade por embeddings capta o tema, não a direção, pelo que um agrupamento recuperado pode misturar movimentos de subida e de descida; o impacto médio é evidência ao nível do tema, não um sinal direcional, razão pela qual os precedentes são sempre mostrados individualmente.
- **Sem estudo humano.** A utilidade para um investidor real ainda não foi medida.
- **Por desenho.** O sistema não faz previsão de preços nem negociação, pelo que as questões baseadas em lucro estão fora de âmbito, não por responder.

6.5 Trabalho Futuro

As limitações mapeiam diretamente em trabalho futuro, resumido na Figura 6.2.




Figura 6.2: Cada limitação enunciada mapeia diretamente num passo concreto seguinte. Várias já viram uma primeira iteração do lado da produção (uma base de conhecimento viva maturada contra preços observados, sinalização explícita de divergência de direção, e uma cotação intradiária durante o horário de mercado), reportadas como seguimento de engenharia cuja avaliação formal fica para trabalho futuro.

- Avaliar a *recuperação* no corpus FNSPID multi-ano. A própria base de conhecimento já foi reconstruída a partir desse corpus (depois de os estudos de caso aqui terem sido congelados), pelo que o trabalho em aberto é a avaliação: uma análise de impacto mais rica, com estatísticas de dispersão e de consistência de direção sobre os precedentes multi-ano.
- Realizar um pequeno estudo humano, aplicando uma rubrica de clareza, completude e acionabilidade a um conjunto de alertas, para resolver a questão em aberto da utilidade (RQ3).
- Atacar a lacuna de texto em aberto da RQ4: texto mais rico do que manchetes (corpo dos artigos, sentimento financeiro como feature), o ticker em falta recuperado sob o seu símbolo antigo, e o ciclo de pós-validação ao vivo a acumular decisões rotuladas frescas para re-treino periódico; um tratamento por contextual-bandit do limiar do alerta é a extensão aprendida natural.
- Como produto, de-duplicar precedentes quase idênticos e sinalizar a divergência de direção dentro de um agrupamento recuperado, complementando a ordenação por severidade que a triagem já fornece contra os riscos de fadiga de alertas e de confiança excessiva do Capítulo 4.

A produção ao vivo, depois de a avaliação ter sido congelada, já motivou uma primeira iteração de vários destes pontos: o sistema em produção faz agora crescer uma base de conhecimento *viva* a partir das manchetes que varre (cada caso maturado contra preços observados dias depois), ordena os precedentes com um fator de decaimento por idade mostrando sempre a similaridade verdadeira e a idade de cada caso, sinaliza explicitamente a divergência de direção, e avalia o movimento do dia em curso a partir de uma cotação em tempo real durante o horário de mercado. A produção também ensinou a sua própria lição, reportada no Capítulo 4: uma única fonte de preços gratuita provou ser um ponto único de falha em infraestrutura alojada, e foi substituída por uma cadeia de fallback multi-fornecedor. Estas iterações do lado da produção reutilizam os componentes validados sem

alterações e são aqui reportadas como seguimento de engenharia; a sua avaliação formal fica para trabalho futuro. Um ponto está já *validado* em vez de especulativo: a comparação estendida do Estudo de Caso 1 mostrou que uma estimativa de volatilidade com ponderação exponencial melhora substancialmente a concordância do detetor com o indicador, pelo que adotá-la é uma mudança medida, de uma linha, à espera apenas de uma decisão de explicabilidade. Em conjunto, estas mudanças transformariam um protótipo sólido num sistema mais exaustivamente validado, sem abdicar da simplicidade e transparência que o tornam defensável.

Bibliografia

- Aamodt, Agnar e Enric Plaza (1994). «Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches». Em: *AI Communications* 7.1, pp. 39–59. doi: 10.3233/AIC-1994-7104.
- Adadi, Amina e Mohammed Berrada (2018). «Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)». Em: *IEEE Access* 6, pp. 52138–52160. doi: 10.1109/ACCESS.2018.2870052.
- Ahmed, Mohiuddin, Abdun Naser Mahmood e Md. Rafiqul Islam (2016). «A Survey of Anomaly Detection Techniques in Financial Domain». Em: *Future Generation Computer Systems* 55, pp. 278–288. doi: 10.1016/j.future.2015.01.001.
- Araci, Dogu (2019). «FinBERT: Financial Sentiment Analysis with Pre-trained Language Models». Em: *arXiv preprint*. arXiv: 1908.10063 [cs.CL].
- Bansal, Gagan et al. (2021). «Does the Whole Exceed its Parts? The Effect of AI Explanations on Complementary Team Performance». Em: *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. doi: 10.1145/3411764.3445717.
- Barber, Brad M. e Terrance Odean (2008). «All That Glitters: The Effect of Attention and News on the Buying Behavior of Individual and Institutional Investors». Em: *The Review of Financial Studies* 21.2, pp. 785–818. doi: 10.1093/rfs/hhm079.
- Barberis, Nicholas e Richard Thaler (2003). «A Survey of Behavioral Finance». Em: *Handbook of the Economics of Finance*. Ed. por George M. Constantinides, Milton Harris e René M. Stulz. Vol. 1. Elsevier. Cap. 18, pp. 1053–1128. doi: 10.1016/S1574-0102(03)01027-6.
- Barredo Arrieta, Alejandro et al. (2020). «Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI». Em: *Information Fusion* 58, pp. 82–115. doi: 10.1016/j.inffus.2019.12.012.
- Bollerslev, Tim (1986). «Generalized Autoregressive Conditional Heteroskedasticity». Em: *Journal of Econometrics* 31.3, pp. 307–327. doi: 10.1016/0304-4076(86)90063-1.
- Breunig, Markus M. et al. (2000). «LOF: Identifying Density-Based Local Outliers». Em: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104. doi: 10.1145/335191.335388.
- Brown, Stephen J. e Jerold B. Warner (1985). «Using Daily Stock Returns: The Case of Event Studies». Em: *Journal of Financial Economics* 14.1, pp. 3–31. doi: 10.1016/0304-405X(85)90042-X.
- Cambridge Centre for Alternative Finance (2026). *Global AI in Financial Services Report: Adoption, Impact and Risks*. Cambridge Judge Business School, University of Cambridge. url: <https://www.jbs.cam.ac.uk/faculty-research/centres/alternative-finance/publications/2026-global-ai-in-financial-services-report/> (accedido em 21/06/2026).
- Cardillo, Giovanni e Helen Chiappini (2024). «Robo-advisors: A Systematic Literature Review». Em: *Finance Research Letters* 62, p. 105119. doi: 10.1016/j.frl.2024.105119.
- Chandola, Varun, Arindam Banerjee e Vipin Kumar (2009). «Anomaly Detection: A Survey». Em: *ACM Computing Surveys* 41.3, 15:1–15:58. doi: 10.1145/1541880.1541882.

- D'Acunto, Francesco, Nagpurnanand Prabhala e Alberto G. Rossi (2019). «The Promises and Pitfalls of Robo-Advising». Em: *The Review of Financial Studies* 32.5, pp. 1983–2020. doi: 10.1093/rfs/hhz014.
- Da, Zhi, Joseph Engelberg e Pengjie Gao (2011). «In Search of Attention». Em: *The Journal of Finance* 66.5, pp. 1461–1499. doi: 10.1111/j.1540-6261.2011.01679.x.
- Devlin, Jacob et al. (2019). «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». Em: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. arXiv: 1810.04805.
- Ding, Xiao et al. (2015). «Deep Learning for Event-Driven Stock Prediction». Em: *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 2327–2333. url: <https://www.ijcai.org/Abstract/15/329>.
- Dong, Zihan, Xinyu Fan e Zhiyuan Peng (2024). «FNSPID: A Comprehensive Financial News Dataset in Time Series». Em: *arXiv preprint*. arXiv: 2402.06698 [q-fin.ST].
- Doshi-Velez, Finale e Been Kim (2017). «Towards a Rigorous Science of Interpretable Machine Learning». Em: *arXiv preprint*. arXiv: 1702.08608 [stat.ML].
- Engle, Robert F. (1982). «Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation». Em: *Econometrica* 50.4, pp. 987–1007. doi: 10.2307/1912773.
- Fama, Eugene F. (1970). «Efficient Capital Markets: A Review of Theory and Empirical Work». Em: *The Journal of Finance* 25.2, pp. 383–417. doi: 10.2307/2325486.
- Fama, Eugene F. et al. (1969). «The Adjustment of Stock Prices to New Information». Em: *International Economic Review* 10.1, pp. 1–21. doi: 10.2307/2525569.
- Friedman, Jerome H. (2001). «Greedy Function Approximation: A Gradient Boosting Machine». Em: *The Annals of Statistics* 29.5, pp. 1189–1232. doi: 10.1214/aos/1013203451.
- Gallup (2025). *What Percentage of Americans Own Stock?* url: <https://news.gallup.com/poll/266807/percentage-americans-owns-stock.aspx> (accedido em 21/06/2026).
- Guidotti, Riccardo et al. (2018). «A Survey of Methods for Explaining Black Box Models». Em: *ACM Computing Surveys* 51.5, 93:1–93:42. doi: 10.1145/3236009.
- Johnson, Jeff, Matthijs Douze e Hervé Jégou (2021). «Billion-Scale Similarity Search with GPUs». Em: *IEEE Transactions on Big Data* 7.3, pp. 535–547. doi: 10.1109/TBDATA.2019.2921572.
- Kahneman, Daniel e Amos Tversky (1979). «Prospect Theory: An Analysis of Decision under Risk». Em: *Econometrica* 47.2, pp. 263–291. doi: 10.2307/1914185.
- Kearney, Colm e Sha Liu (2014). «Textual Sentiment in Finance: A Survey of Methods and Models». Em: *International Review of Financial Analysis* 33, pp. 171–185. doi: 10.1016/j.irfa.2014.02.006.
- Lee, John D. e Katrina A. See (2004). «Trust in Automation: Designing for Appropriate Reliance». Em: *Human Factors* 46.1, pp. 50–80. doi: 10.1518/hfes.46.1.50.30392.
- Lipton, Zachary C. (2018). «The Mythos of Model Interpretability». Em: *Communications of the ACM* 61.10, pp. 36–43. doi: 10.1145/3233231.
- Liu, Fei Tony, Kai Ming Ting e Zhi-Hua Zhou (2008). «Isolation Forest». Em: *2008 Eighth IEEE International Conference on Data Mining (ICDM)*, pp. 413–422. doi: 10.1109/ICDM.2008.17.
- Loughran, Tim e Bill McDonald (2011). «When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks». Em: *The Journal of Finance* 66.1, pp. 35–65. doi: 10.1111/j.1540-6261.2010.01625.x.

- Lundberg, Scott M. e Su-In Lee (2017). «A Unified Approach to Interpreting Model Predictions». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 4765–4774. arXiv: 1705.07874.
- Manning, Christopher D., Prabhakar Raghavan e Hinrich Schütze (2008). *Introduction to Information Retrieval*. Cambridge, England: Cambridge University Press. isbn: 978-0-521-86571-5.
- Mikolov, Tomas et al. (2013). «Efficient Estimation of Word Representations in Vector Space». Em: *arXiv preprint*. arXiv: 1301.3781.
- Miller, Tim (2019). «Explanation in Artificial Intelligence: Insights from the Social Sciences». Em: *Artificial Intelligence* 267, pp. 1–38. doi: 10.1016/j.artint.2018.07.007.
- Niculescu-Mizil, Alexandru e Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». Em: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, pp. 625–632. doi: 10.1145/1102351.1102430.
- Pang, Guansong et al. (2021). «Deep Learning for Anomaly Detection: A Review». Em: *ACM Computing Surveys* 54.2, 38:1–38:38. doi: 10.1145/3439950.
- Pennington, Jeffrey, Richard Socher e Christopher D. Manning (2014). «GloVe: Global Vectors for Word Representation». Em: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1532–1543. doi: 10.3115/v1/D14-1162.
- Reimers, Nils e Iryna Gurevych (2019). «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». Em: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. doi: 10.18653/v1/D19-1410.
- Ribeiro, Marco Tulio, Sameer Singh e Carlos Guestrin (2016). «“Why Should I Trust You?”: Explaining the Predictions of Any Classifier». Em: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135–1144. doi: 10.1145/2939672.2939778.
- Robertson, Stephen e Hugo Zaragoza (2009). «The Probabilistic Relevance Framework: BM25 and Beyond». Em: *Foundations and Trends in Information Retrieval* 4.1–2, pp. 1–174. doi: 10.1561/15000000019.
- Rudin, Cynthia (2019). «Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead». Em: *Nature Machine Intelligence* 1.5, pp. 206–215. doi: 10.1038/s42256-019-0048-x.
- Salton, Gerard, A. Wong e C. S. Yang (1975). «A Vector Space Model for Automatic Indexing». Em: *Communications of the ACM* 18.11, pp. 613–620. doi: 10.1145/361219.361220.
- Securities Industry and Financial Markets Association (SIFMA) (2025). *2025 Capital Markets Fact Book*. url: <https://www.sifma.org/resources/research/fact-book/> (acedido em 21/06/2026).
- Tetlock, Paul C. (2007). «Giving Content to Investor Sentiment: The Role of Media in the Stock Market». Em: *The Journal of Finance* 62.3, pp. 1139–1168. doi: 10.1111/j.1540-6261.2007.01232.x.
- Vaswani, Ashish et al. (2017). «Attention Is All You Need». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 5998–6008. arXiv: 1706.03762.
- Welch, Ivo (2022). «The Wisdom of the Robinhood Crowd». Em: *The Journal of Finance* 77.3, pp. 1489–1527. doi: 10.1111/jofi.13128.
- Wu, Shijie et al. (2023). «BloombergGPT: A Large Language Model for Finance». Em: *arXiv preprint*. arXiv: 2303.17564 [cs.LG].

- Xing, Frank Z., Erik Cambria e Roy E. Welsch (2018). «Natural Language Based Financial Forecasting: A Survey». Em: *Artificial Intelligence Review* 50.1, pp. 49–73. doi: 10.1007/s10462-017-9588-9.
- Yang, Yi, Mark Christopher Siy Uy e Allen Huang (2020). «FinBERT: A Pretrained Language Model for Financial Communications». Em: *arXiv preprint*. arXiv: 2006.08097.

Apêndice A

Reprodutibilidade

Este apêndice reúne o material que permite reproduzir e inspecionar os resultados: o ambiente de software, os dados em cada fase, e as saídas de avaliação por detrás dos números reportados no corpo.

A.1 Ambiente

O sistema é implementado em Python 3.12, escolhido pela maturidade dos seus pacotes para a stack de aprendizagem automática. As dependências são fixadas e congeladas num ficheiro de lock para que o ambiente possa ser recriado entre máquinas. O tratamento numérico e de dados assenta em bibliotecas open-source estabelecidas; os embeddings de frase usam a framework Sentence-BERT sobre uma build CPU da biblioteca de deep learning subjacente, instalada a partir de um índice dedicado para evitar o download de GPU muito maior; as figuras são produzidas com uma biblioteca de plotting padrão. A Tabela A.1 lista as versões fixadas das dependências centrais; o conjunto completo está congelado no ficheiro de lock do repositório.

Tabela A.1: Versões fixadas das dependências centrais (Python 3.12).

Biblioteca	Versão
numpy	2.1.3
pandas	2.2.3
matplotlib	3.11.0
scikit-learn	1.9.0
yfinance	1.4.1
sentence-transformers	5.6.0
transformers	5.12.1
torch (build CPU)	2.12.1
pytest	8.3.4
ruff	0.8.6

A.2 Organização do Repositório

O código está organizado como um pacote por componente, espelhando a arquitetura da Figura 4.1: dados de mercado, recuperação de notícias, deteção de anomalias, o motor de correlação (similaridade e estudo de evento), a base de conhecimento histórica, o motor de explicação e a entrega de alertas, com uma pequena camada de orquestração a ligá-los nos

dois fluxos de ponta a ponta. A lógica pura é separada da entrada/saída, e as dependências pesadas ou de rede são carregadas de forma tardia, pelo que o núcleo numérico é testado unitariamente sem ligação de rede nem a stack de modelos. Os segredos são lidos apenas de um ficheiro de ambiente local e ignorado, e nunca são escritos em ficheiros versionados.

A.3 A Pipeline Completa numa Página

O corpo da dissertação apresenta deliberadamente o sistema através de vários diagramas pequenos e simples (arquitetura, modelo de dados, fluxos por gatilho, a vida de um alerta). A Figura A.1 é a vista oposta, mantida no apêndice precisamente por ser densa: a pipeline *completa* em produção numa única página em paisagem, com cada porta e o seu valor de configuração de produção anotado. Cada valor é um parâmetro de implantação divulgado (a avaliação do Capítulo 5 congela as suas próprias definições, mais estritas, como notado na figura).

A.4 Testes e Resultados Reprodutíveis

O sistema é coberto por uma suíte de testes automáticos que abrange o detetor de anomalias, o estudo de evento, a similaridade, a base de conhecimento, o parser de notícias, o motor de explicação e os módulos de avaliação, juntamente com um smoke test offline de ponta a ponta do gatilho de notícias. Os testes que exigem acesso à rede ou modelos pesados são marcados e excluídos da corrida por defeito para que esta seja rápida, determinística e offline.

Cada resultado experimental do Capítulo 5 é regenerado por um procedimento determinístico de semente fixa que escreve as suas tabelas e figuras diretamente nos diretórios de avaliação e de figuras, pelo que o ciclo entre computação e documento é fechado e auditável. Cada um dos quatro estudos de caso tem um desses procedimentos — a recuperação de precedentes e a sua decomposição por setor, a taxa de disparo de anomalias e a ablação de janela, a comparação de detetores estatístico-versus-aprendido, e a construção e treino do conjunto de dados de triagem de materialidade — e a decomposição de triagem trabalhada, a projeção do espaço de embeddings e o funil de produção são produzidos da mesma forma. Cada número de destaque no corpo é o valor escrito por um destes procedimentos; nenhum é digitado à mão. O passo de obtenção de dados que os precede, e a construção completa da base de conhecimento histórica, seguem a mesma receita determinística.

A.5 Prova de Trabalho: Cada Número Rastreado à Sua Fonte

Nenhum resultado nesta dissertação é digitado à mão. Cada número é escrito pelo seu procedimento determinístico num registo de resultados congelado, e a tese cita esse registo verbatim, pelo que o ciclo entre computação e documento é fechado e auditável. A Tabela A.2 reúne cada resultado de destaque com o valor como reportado e o estudo de caso a que pertence; cada um pode ser regenerado, e verificado, isoladamente.

O sistema correu mesmo. Para além da reprodutibilidade a pedido, o InvestiGator operou ao vivo. Um workflow agendado varreu a watchlist após cada fecho do mercado dos EUA e entregou alertas explicados a um canal público de Telegram; o registo de alertas partilhado e versionado acumulou dezenas de alertas reais, incluindo a primeira anomalia de mercado




Figura A.1: A pipeline completa em produção numa página: as bases de conhecimento offline e viva, o gatilho de notícias com as suas cinco portas de qualidade, os gatilhos de mercado de fecho e intradiário com a cadeia de fallback de preços multi-fonte, e as saídas partilhadas. As caixas tracejadas são portas que descartam itens; os valores anotados (limiares, tetos, half-life de decaimento) são a configuração de produção divulgada, distinta das definições de avaliação congeladas do Capítulo 5. Os capítulos do corpo apresentam o mesmo sistema como várias vistas mais simples; esta figura existe para que nenhuma fase fique implícita.

Tabela A.2: Cada resultado de destaque, o seu valor reportado, e o estudo a que pertence.

Resultado	Valor	Estudo
Recuperação de precedentes, precisão@5 (MiniLM / MPNet / lexical)	0.514 / 0.538 / 0.346	CS2
Deteção de anomalias, F_1 (z-score vs limiar fixo)	0.516 vs 0.218	CS1
Regra estatística vs detetores aprendidos, F_1 (z-score / IF / LOF)	0.530 / 0.269 / 0.280	CS1
Volatilidade EWMA (futuro validado), F_1 vs deslizante	0.664 vs 0.516	CS1
Triagem de materialidade, PR-AUC (volatilidade / contexto / completo)	0.542 / 0.538 / 0.496	CS4
Precisão@5 da triagem por dia vs alertar-sempre	0.632 vs 0.163	CS4
Ablação de features estendida, PR-AUC (contexto + 5 sinais)	0.535 ($\Delta -0.002$)	CS4
Decisão de triagem trabalhada (META, 12 Jul 2026)	$p = 0.539$ (54%)	CS4
Seletividade de produção (manchetes : alertas enviados)	22 : 1	CS2

genuína (NVDA, 13 de julho de 2026). A base de conhecimento viva maturou as suas manchetes capturadas contra os preços reais que se seguiram, e o ciclo de pós-validação rotulou decisões passadas reais com o seu resultado observado, reportando uma precisão de alertas mantidos de 0.667 contra uma taxa-base de 0.455 — evidência fora da amostra de que o mecanismo de triagem se sustenta. Uma grande suíte automática de testes, offline e determinística, corre em cada push através de integração contínua, e o trabalho está registado ao longo de mais de duzentos commits. Números regeneráveis, uma implantação ao vivo e uma suíte de testes verde são, em conjunto, a prova de trabalho da dissertação.

A.6 Dados e Atribuição

Os ficheiros de dados grandes nunca são versionados; são recriados pelos scripts de dados, e apenas pequenas amostras são commitadas. Os modelos de triagem treinados são a exceção por desenho: são pequenos, pelo que os bundles ajustados são versionados no repositório juntamente com metadados JSON (janela de treino, semente, limiar e métricas), o que torna o próprio modelo em produção inspecionável e reprodutível. O conjunto de dados FNSPID (Dong, Fan e Peng 2024) é usado sob a sua licença CC BY-SA 4.0, com atribuição conforme exigido; os serviços de dados de mercado e de notícias ao vivo são usados dentro das suas camadas gratuitas.