



Instituto Superior de
Engenharia do Porto



DEPARTAMENTO DE ENGENHARIA
INFORMÁTICA

Alertas Financeiros Explicáveis para Investidores de Retalho: Integração de Detecção Estatística de Anomalias e Correlação Notícia–Mercado

Henrique José da Silva Santos

Aluno nº: 1180934

**Dissertação para obtenção do Grau de
Mestre em Engenharia de Inteligência Artificial**

Orientador: Luís Gomes

Co-Orientador: Rafael Silva

Júri:

Presidente:

[A definir]

Vogais:

[A definir]

Porto, 13 de agosto de 2026

Declaração de Integridade

Declaro que realizei este trabalho académico com integridade.

Não plagiei nem apliquei qualquer forma de uso indevido de informação ou de falsificação de resultados ao longo do processo que conduziu à sua elaboração.

Assim, o trabalho apresentado neste documento é original e da minha autoria, não tendo sido anteriormente utilizado para qualquer outro fim.

Declaro ainda que tomei pleno conhecimento do Código de Conduta Ética do P.PORTO.

Uso de Inteligência Artificial. Em conformidade com as orientações do P.PORTO/ISEP, declaro que foram utilizadas ferramentas de inteligência artificial generativa ao longo do desenvolvimento deste trabalho, e declaro-o na sua extensão real e não de forma minimizada. Foram usadas para escrever e reestruturar uma parte substancial do código-fonte do sistema e dos seus testes automáticos, para implementar os procedimentos de avaliação, para redigir e editar prosa neste documento e nos materiais de apoio, e para conduzir revisões que encontraram defeitos tanto no software como no texto.

O que é meu é o trabalho para onde essas ferramentas foram apontadas. A escolha do problema e do público, as questões de investigação, as restrições que definem o sistema (apenas fontes de dados gratuitas, explicabilidade primeiro, e a recusa de prever preços), e todas as decisões sobre o que construir, promover, manter, estreitar ou descartar são minhas. Onde uma medição contrariou uma afirmação que eu tinha feito, a afirmação foi retirada ou estreitada em vez de defendida; essas retractações estão registadas no Apêndice A.6. Todos os valores reportados são produzidos por um procedimento versionado que pode ser re-corrido. Revi o conteúdo desta dissertação, e ele, os erros que nele restem, e a sua defesa são da minha responsabilidade.

ISEP, Porto, 13 de agosto de 2026

Dedicatória

Resumo

Esta dissertação apresenta o InvestiGator, um sistema de alertas financeiros explicável (XAI-first) para investidores de retalho no mercado acionista dos Estados Unidos. Envia alertas via Telegram a partir de dois gatilhos independentes, movimentos abruptos de mercado detetados como anomalias estatísticas e novas notícias financeiras, cada um com uma explicação rastreável: o evento, o raciocínio, as fontes e os precedentes históricos. O seu núcleo é um motor de correlação notícia–mercado que recupera notícias passadas análogas e mede o impacto que esses precedentes tiveram, à maneira de um estudo de evento e sem lookahead. Uma camada generativa sintetiza estes resultados em prosa, com cada afirmação ligada à evidência que cita e verificada antes da entrega. Enquanto contribuição de Engenharia de Inteligência Artificial, o trabalho integra e avalia criticamente componentes existentes num sistema funcional, explicável e reproduzível. Em dados reais, a recuperação semântica superou claramente as baselines lexical e triviais (precision@5 cross-ticker de 0,51, face a 0,35 lexical e 0,24 do acaso) e o detetor normalizado pela volatilidade disparou de forma muito mais consistente entre ações do que um limiar fixo. Um modelo de triagem de materialidade treinado em 79 753 exemplos de vários anos melhorou 1.67*times* a precisão dos alertas dentro do orçamento diário em dados retidos, mas nenhum modelo com texto bateu a baseline de só-volatilidade, e em produção o mesmo gate não mostrou benefício significativo sobre a população, distribuída de outra forma, que de facto vê. Ambos os resultados são reportados tal como são, com as limitações explícitas.

Palavras-chave: IA Explicável, Alertas Financeiros, Detecção de Anomalias, Impacto de Notícias, Investidores de Retalho, PLN Financeiro

Abstract

This dissertation presents InvestiGator, an explainable (XAI-first) financial-alert system for retail investors in the US equity market. It raises Telegram alerts from two independent triggers, abrupt market movements detected as statistical anomalies and incoming financial news, each with a traceable explanation: the event, the reasoning, the sources and historical precedents. Its core is a news–market correlation engine that retrieves analogous past news and measures the impact those precedents had, event-study style and without lookahead. A generative layer synthesises these results into prose, each claim bound to the evidence it cites and verified before delivery. As an Artificial Intelligence Engineering contribution, the work integrates and critically evaluates existing components in a functional, explainable, reproducible system. On real data, semantic retrieval clearly outperformed lexical and trivial baselines (cross-ticker precision@5 of 0.51 against 0.35 lexical and 0.24 random), and the volatility-normalised detector fired far more consistently across stocks than a fixed threshold. A materiality-triage model trained on 79,753 multi-year examples raised within-budget alert precision 1.67-fold on held-out data, yet no text model beat the volatility-only baseline, and in deployment the same gate showed no significant benefit on the differently distributed population it sees. Both are reported as they stand, with limitations stated explicitly.

Keywords: IA Explicável, Alertas Financeiros, Detecção de Anomalias, Impacto de Notícias, Investidores de Retalho, PLN Financeiro

Agradecimentos

Devo agradecimentos a mais pessoas do que uma página permite, e a estas em particular.

Ao meu orientador, Prof. Luís Gomes, e ao meu coorientador, Rafael Silva, pela orientação que deu forma a este trabalho: pela direcção do tema, pelas discussões que me mandaram verificar coisas que eu tinha dado por garantidas, por me apontarem exemplos e desenvolvimentos que sozinho não teria encontrado, e por um feedback que foi tanto mais útil quanto foi directo. Várias das decisões que hoje defendo com mais confiança são decisões a que cheguei porque uma pergunta deles fez a resposta fácil parecer mais fina do que parecia antes.

À Sistrade, e aos meus colegas lá, pela oportunidade e pela flexibilidade que tornaram possível fazer este mestrado a par do trabalho: pelo interesse, pelas opiniões e pelo feedback sobre a aplicação à medida que ela foi ganhando forma, e pelo companheirismo pelo caminho.

À minha família, pelo apoio que não dependeu de como o trabalho ia, pela confiança quando eu ainda não tinha nada que valesse a pena mostrar, e por uma fé em mim que mais do que uma vez durou mais do que a minha.

Índice

Lista de Algoritmos	xx
Lista de Excertos de Código	xxi
Lista de Acrónimos	xxv
1 Introdução	1
1.1 Contextualização	1
1.2 Definição do Problema	2
1.3 Questões de Investigação e Objetivos	3
1.4 Contribuições Científicas	4
1.5 Estrutura do Documento	4
2 Estado da Arte	7
2.1 Investimento de Retalho e Sobrecarga de Informação	7
2.2 Detecção de Anomalias em Mercados Financeiros	8
2.3 Inteligência Artificial Explicável	9
2.4 Confiança e Dependência Apropriada no Apoio à Decisão	10
2.5 PLN Financeiro e Representação de Texto	11
2.6 Recuperação de Informação e Avaliação de Ordenação	12
2.7 Estudos de Evento e Impacto Notícia–Mercado	13
2.8 Raciocínio Baseado em Casos e Recuperação de Precedentes	14
2.9 Triagem Apreendida de Alertas: Classificação Supervisionada de Materialidade	14
2.10 Incerteza e Deriva num Modelo Implantado	15
2.11 Ferramentas Existentes para o Investidor de Retalho	16
2.12 Análise Comparativa e Posicionamento	17
2.13 Conclusões do Capítulo	17
3 Métodos e Materiais	21
3.1 Abordagem e Metodologia	21
3.2 Conjuntos de Dados e Fontes de Dados	22
3.2.1 Camada Histórica: o Corpus FNSPID	22
3.2.2 Pré-processamento e Alinhamento ao Evento	22
3.2.3 Camada Viva e Conjunto de Dados de Avaliação	23
3.2.4 Governança de Dados e Atribuição	24
3.3 Modelos e Técnicas	25
3.3.1 Detecção Estatística de Anomalias	25
3.3.2 Recuperação Semântica e Medição de Impacto	27
3.3.3 Atribuir um Movimento: Mercado, Setor e Empresa	30
3.3.4 Triagem de Materialidade: um Modelo de Severidade Treinado	32
3.3.5 Técnicas de Explicação	36

3.3.6	Geração Ancorada e a sua Verificação de Fidelidade	36
3.4	Ferramentas e Frameworks	38
3.5	IA Responsável e Ética	38
3.6	Metodologia de Avaliação	38
3.6.1	Métrica de recuperação e relevância	38
3.6.2	Linhas de base	39
3.6.3	Protocolo de deteção de anomalias	39
3.6.4	Protocolo de triagem	40
3.6.5	Incerteza, deriva e estrutura não supervisionada	40
3.6.6	Explicação, âmbito e garantias de rigor	41
3.7	Conclusões do Capítulo	42
4	InvestiGator: Um Sistema de Alertas Financeiros Explicável para Investidores de Retalho	43
4.1	Visão Geral	43
4.2	Casos de Uso	43
4.3	O Modelo de Dados	44
4.4	Componentes e Responsabilidades	45
4.5	Fluxo de Dados	46
4.6	Lógica de Decisão	50
4.7	Explicação e Entrega	53
4.7.1	Separar o servidor do cliente, e o que isso comprou	54
4.8	A Camada de Inteligência: Geração Ancorada	55
4.8.1	O que o gerador pode e não pode fazer	56
4.8.2	Dois níveis de garantia, e porque diferem	57
4.8.3	Ligar os números aos factos que os autorizam	58
4.8.4	Comportamento medido	59
4.8.5	A linguagem natural como segunda interface	60
4.9	A Vida de Um Alerta	60
4.10	Uso Prático e Desenho Responsável	61
4.11	Conclusões do Capítulo	65
5	Estudos de Caso	67
5.1	Montagem Experimental Comum	67
5.2	Estudo de Caso 1: Deteção Transparente de Anomalias em Ações dos EUA	68
5.3	Estudo de Caso 2: Recuperação de Precedentes Notícia–Mercado	71
5.4	Estudo de Caso 3: Alerta de Ponta a Ponta e Fidelidade da Explicação	75
5.5	Estudo de Caso 4: Triagem de Materialidade Apreendida	77
5.6	Estudo de Caso 5: Estrutura de Tipo de Evento no Espaço de Embeddings	82
5.7	Estudo de Caso 6: Garantias Livres de Distribuição para o Score de Triagem	84
5.8	Estudo de Caso 7: Medir a Distância até à Implantação	86
5.9	Discussão e Ameaças à Validade	88
5.10	Conclusões do Capítulo	90
6	Conclusões	91
6.1	Conclusões Principais	91
6.2	Posições Assumidas por Exclusão	94
6.3	Questões de Investigação e Objetivos Alcançados	96
6.4	Contribuições Revisitadas	96

6.5	Limitações	97
6.6	Trabalho Futuro	100
Bibliografia		103
A	Reprodutibilidade	107
A.1	Ambiente	107
A.2	Organização do Código	107
A.3	A Pipeline Completa numa Página	108
A.4	Testes e Resultados Reprodutíveis	108
A.5	Cada Número Rastreado à Sua Fonte	108
A.6	Matriz de Evidência	110
A.7	Dados e Atribuição	111

Lista de Figuras

1.1	Capitalização do mercado acionista dos EUA, 2015–2024	1
1.2	O que o InvestiGator faz	3
2.1	Taxonomia dos métodos de detecção de anomalias	8
2.2	Taxonomia das abordagens de explicabilidade	10
2.3	Três gerações de representação de texto	13
3.1	As duas camadas de dados	22
3.2	Uma manchete real por todo o sistema	25
3.3	Os objetos de dados, tal como são	26
3.4	O mesmo movimento, duas ações diferentes	28
3.5	Janelas de impacto de estudo de evento	29
3.6	Ilustração conceptual da recuperação semântica	30
4.1	Arquitetura do sistema e fluxo de dados	44
4.2	Casos de uso e os dois perfis de utilizador	46
4.3	O modelo de dados do InvestiGator	47
4.4	Fluxo de dados e processamento de ponta a ponta	49
4.5	Alerta Telegram tal como recebido pelo investidor	53
4.6	A interface ao vivo, uma captura genuína	56
4.7	Texto gerado com a evidência anexada	57
4.8	Seletividade de produção: manchetes capturadas versus alertas enviados	62
5.1	Taxa de disparo por ticker: limiar fixo versus z-score	68
5.2	Exemplo trabalhado: anomalias por z-score numa ação volátil	69
5.3	Ablação do tamanho da janela para o detetor de anomalias	70
5.4	Comparação estendida de anomalias: detetores e estimadores de volatilidade	72
5.5	Recuperação de precedentes: SBERT versus linhas de base	73
5.6	O espaço de embeddings real da base de conhecimento do produto	74
5.7	Recuperação de precedentes por setor	75
5.8	Mesmo tema, direção oposta	76
5.9	Curvas de precisão-recall para a triagem de materialidade	79
5.10	Calibração das probabilidades da triagem	80
5.11	Uma decisão de triagem real, decomposta	81
5.12	Contribuição marginal das features de contexto estendidas	82
5.13	Estrutura de tipo de evento no espaço de embeddings	83
5.14	Cobertura conformal e o seu custo	86
5.15	Deriva das entradas por feature	88
6.1	As quatro questões de investigação num relance	91
6.2	As limitações mapeiam em trabalho futuro	100

A.1	A pipeline completa em produção, com cada porta anotada	109
-----	---	-----

Lista de Tabelas

2.1	Abordagens de detecção de anomalias relevantes para este trabalho.	9
2.2	Abordagens de explicabilidade consideradas.	10
2.3	Abordagens de representação de texto para notícias financeiras.	12
2.4	Ferramentas de retalho existentes versus o sistema proposto neste trabalho.	16
2.5	Ferramentas existentes pontuadas contra as três perguntas que um investidor de retalho faz (Secção 1.2).	18
2.6	Escolhas de componentes neste trabalho versus alternativas.	19
3.1	Data card da camada histórica <i>desenhada</i> (FNSPID).	23
3.2	Exemplo trabalhado: o mesmo movimento de -3.2% numa ação calma e numa volátil.	27
3.3	Exemplo trabalhado de recuperação sobre a base de conhecimento de amostra incluída. Consulta: “ <i>Nvidia demand surges on AI chip orders</i> ”; as similaridades e impactos são reais e reproduzíveis.	31
3.4	As colunas de features da triagem, com valores reais	34
3.5	Exemplo de triagem trabalhado: um alerta de produção real decomposto	36
4.1	Principais decisões de desenho no InvestiGator e a sua justificação.	45
4.2	Casos de uso, a pergunta que cada um responde, e os componentes envolvidos.	46
4.3	Os componentes do InvestiGator, cada um com uma responsabilidade única.	48
4.4	Uma notícia através de cada etapa	50
4.5	Custo da interface antes e depois de separar cliente e servidor	55
4.6	Dois níveis de garantia de geração	58
4.7	Comportamento medido da guarda de ancoragem	59
4.8	A vida de um alerta real, fase a fase	61
5.1	Taxa de disparo entre os quinze tickers (três anos de dados diários).	68
5.2	Anomalia trabalhada: o movimento pós-resultados da Tesla a 24 de outubro de 2024 (janela 20, $k = 3$); números reais e reproduzíveis.	69
5.3	Comparação estendida de detetores e estimadores de volatilidade	71
5.4	Precisão@ k cross-ticker por setor, média $\pm$ dp sobre cinco corridas (3,714 manchetes reais, cinco setores).	72
5.5	Precisão@ k cross-ticker por setor (consultas de toda a população, MiniLM).	75
5.6	Triagem de materialidade sobre o corpus FNSPID (bloco de teste; prevalência 0.378). A PR-AUC é a métrica primária; a precisão@orçamento admite no máximo cinco alertas por dia. A precisão@orçamento da linha alertar-sempre depende da ordem e é discutida abaixo: com uma pontuação constante, a métrica orçamentada desempata pela ordem das linhas, portanto esse valor mede a seleção alfabética e não a seleção cega. As outras três colunas dessa linha não dependem da ordem.	78
5.7	Chãos para a precisão orçamentada	78

5.8	Estrutura de tipo de evento não supervisionada em $k^* = 18$. A pureza e a concordância são medidas nas 11,889 manchetes que a rubrica de referência cobre.	83
5.9	Cobertura conformal split sobre o modelo de triagem congelado (bloco de teste, 32,649 linhas, dividido a meio entre calibração e avaliação). “Não sei” é a fração de itens cujo conjunto contém os dois rótulos.	85
5.10	Deriva das entradas entre os blocos de treino e de teste, por feature, ordenada por severidade.	87
A.1	Versões fixadas das dependências centrais (Python 3.12).	107
A.2	Cada resultado de destaque, o seu valor reportado, e o estudo a que pertence.	112
A.3	Matriz de evidência	113

Lista de Excertos de Código

3.1	O detetor z-score. A janela que define “normal” pára um dia antes do dia a ser julgado.	26
3.2	O teste de não-lookahead. Mutar o futuro tem de deixar cada feature intacta e tem de mudar o rótulo.	32
3.3	Divisão temporal por dia único, com faixa de embargo depois de cada fronteira.	33
3.4	A linha do “porquê”. As contribuições são os próprios termos do modelo, e não uma aproximação deles.	34

Lista de Símbolos

r_t	retorno logarítmico de um ativo no dia t	—
μ_t	média móvel dos retornos	—
σ_t	desvio-padrão móvel dos retornos	—
z_t	z-score do retorno no dia t	—
k	limiar de anomalia (em desvios-padrão)	—
w	comprimento da janela móvel	d

Lista de Acrónimos

AI	Inteligência Artificial.
NASDAQ	National Association of Securities Dealers Automated Quotations.
NYSE	New York Stock Exchange.
RQ	Questão de Investigação.

Capítulo 1

Introdução

1.1 Contextualização

A maioria dos norte-americanos possui hoje ações, diretamente ou através de contas de reforma e fundos de investimento (Gallup 2025), e investe no maior mercado acionista do mundo, avaliado em 62,2 bilhões de dólares no final de 2024 (Securities Industry and Financial Markets Association (SIFMA) 2025) (Figura 1.1). A negociação decorre sobretudo na New York Stock Exchange (NYSE) e na National Association of Securities Dealers Automated Quotations (NASDAQ), e uma fração crescente vem agora de pessoas comuns que usam aplicações móveis sem comissões, e não de instituições profissionais.




Figura 1.1: Capitalização do mercado acionista dos EUA, 2015–2024 (bilhões de dólares). Elaborada a partir dos dados reportados no SIFMA 2025 Capital Markets Fact Book (Securities Industry and Financial Markets Association (SIFMA) 2025).

Estes investidores não profissionais, ou “de retalho”, são o público deste trabalho, e a sua posição é difícil. Os mercados movem-se continuamente ao longo de milhares de títulos, e chegam notícias relevantes durante todo o dia de negociação, mas os investidores de retalho não têm nenhuma das ferramentas que os bancos e os fundos tomam como garantidas. A posse também é desigual: chega a 87% dos agregados que ganham acima de 100 000 dólares, mas apenas a 28% dos que ganham abaixo de 50 000 dólares (Gallup 2025).

Entretanto, a inteligência artificial espalhou-se depressa pelas finanças: um inquérito de 2026 encontrou 81% das empresas financeiras a adotar Inteligência Artificial (AI) e 71% já a usar IA generativa (Cambridge Centre for Alternative Finance 2026). Mas grande parte desta tecnologia é opaca, raramente mostrando como chega a uma conclusão (Adadi e Berrada 2018; Barredo Arrieta et al. 2020). Para quem tem de agir sobre um alerta e viver com o resultado, essa opacidade é o obstáculo que esta dissertação remove: permite ao investidor ver *porquê* um alerta foi emitido.

1.2 Definição do Problema

Quando uma posição se mexe, o investidor de retalho faz sempre as mesmas três perguntas, pela mesma ordem, e elas correspondem a três problemas técnicos distintos:

1. **Isto é realmente invulgar, ou é normal para esta ação?** Um dia de 3% é banal numa empresa e um acontecimento raro noutra, pelo que o juízo é estatístico e tem de ser feito contra o comportamento recente de cada título.
2. **É esta empresa, ou é o mercado todo?** Uma queda que se limita a acompanhar um índice em queda carrega informação diferente de uma queda que a empresa produziu por si, e separar as duas exige estimar com que força o título costuma seguir o mercado e o seu setor.
3. **Já aconteceu algo assim, e o que se seguiu?** Responder a isto implica encontrar eventos passados genuinamente comparáveis, o que é um problema de recuperação sobre significado e não sobre palavras-chave, e depois medir o que os preços fizeram a seguir.

As ferramentas gratuitas de consumo não respondem a nenhuma das três. Reportam a variação percentual, que é o ponto de partida da primeira pergunta e não a sua resposta. Os terminais profissionais respondem às três, a um custo de subscrição muito acima do alcance de um investidor não-profissional. A lacuna que esta dissertação aborda não é, portanto, falta de dados, que são abundantes e em larga medida gratuitos, mas falta de *contexto* que um investidor comum consiga obter e, sobretudo, consiga verificar.

A quem se destina

Dois perfis de utilizador enquadram o desenho, e querem coisas opostas do mesmo sistema.

O primeiro é o **detentor de longo prazo**: alguém com um número reduzido de posições, que as consulta com pouca frequência e sente ansiedade quando o ecrã está vermelho. Para esta pessoa, a saída mais valiosa é muitas vezes a permissão para não fazer nada, entregue como evidência de que o movimento foi generalizado ao mercado e nada teve de notável. O modo de falha a evitar é o alarme sem informação.

O segundo é o **investidor de retalho ativo**: alguém que consulta várias vezes por dia e já recebe alertas que apenas dizem que um preço se mexeu. Para esta pessoa, o valor está no contexto chegar com o alerta em vez de depois de uma pesquisa noutro lado. O modo de falha a evitar é a fadiga de alertas, em que o volume ensina o leitor a ignorar o canal.

Os dois perfis puxam em direções diferentes quanto à cadência, e o sistema resolve essa tensão sendo deliberadamente seletivo e enunciando as suas regras de seleção de forma aberta, decisão retomada no Capítulo 4.

Posição assumida

Este trabalho assume uma postura deliberadamente diferente das ferramentas que o rodeiam: não prevê preços, *explica* eventos. Para cada movimento abrupto ou notícia relevante, o sistema mostra o que detetou, como, de onde veio a informação, e quais os eventos passados que se assemelham ao atual, juntamente com o que aconteceu aos preços depois (Figura 1.2).

Essa recusa é uma restrição de desenho e não uma limitação pela qual pedir desculpa. Exclui importar previsões de terceiros, o que contradiria a afirmação que está no centro do sistema, e torna cada saída verificável, porque uma afirmação sobre o que já aconteceu pode ser confrontada com o registo, ao passo que uma previsão não pode.




Figura 1.2: Os dois gatilhos, um movimento súbito de mercado ou uma notícia relevante, alimentam o InvestiGator, que responde com um alerta explicado que o investidor pode seguir e verificar, e não apenas uma notificação seca.

1.3 Questões de Investigação e Objetivos

O objetivo é conceber, construir e avaliar um sistema de alertas financeiros explicável para investidores de retalho dos EUA, movido por dois gatilhos independentes, um movimento súbito de mercado e uma notícia recebida, e entregue por Telegram. Quatro questões de investigação guiam o trabalho:

- **Questão de Investigação (RQ)1.** Conseguem métodos estatísticos transparentes detetar movimentos abruptos de mercado de forma suficientemente consistente para serem úteis a um investidor de retalho, mantendo-se explicáveis?
- **RQ2.** Consegue um motor de correlação notícia–mercado recuperar notícias históricas genuinamente análogas melhor do que baselines triviais, e quantificar o impacto observado nos preços desses precedentes sem lookahead?
- **RQ3.** Podem as explicações resultantes ser fiéis ao que o sistema realmente calcula, e úteis a um investidor de retalho?
- **RQ4.** Consegue um modelo supervisionado, treinado em notícias históricas e contexto de mercado, priorizar utilmente que notícias merecem um alerta, para além de baselines simples de volatilidade, sem nunca prever a direção do preço?

Estas questões traduzem-se em cinco objetivos concretos:

- construir um pipeline de alertas explicável, movido pelos dois gatilhos;
- avaliar o detetor de anomalias face a baselines transparentes;
- avaliar a recuperação de notícias históricas face a baselines triviais;

- aferir se as explicações são fiéis e úteis;
- treinar, calibrar e avaliar honestamente um modelo de triagem de materialidade que ordena os alertas de notícias.

O sistema é construído de forma incremental, primeiro na sua forma mais simples e defensável, uma escolha metodológica explicada no Capítulo 3.

1.4 Contribuições Científicas

Esta é uma dissertação em *Engenharia* de Inteligência Artificial: a contribuição não é um algoritmo novo, mas a montagem disciplinada de algoritmos existentes num sistema que funciona, se explica a si próprio e pode ser reproduzido. Cinco contribuições destacam-se:

- Um método reprodutível para relacionar notícias com o impacto no mercado, que junta recuperação por embeddings de frases com janelas de estudo de evento, com a medida de similaridade e os horizontes temporais declarados de forma explícita e sem deixar entrar qualquer informação sobre o futuro.
- O **InvestiGator**, um sistema de alertas que mostra toda a sua cadeia de raciocínio: o evento detetado, a evidência de apoio, as fontes e os precedentes históricos relevantes. Como cada explicação é construída diretamente a partir das quantidades que o sistema calcula, o texto não pode divergir do cálculo.
- Um modelo de *triagem de materialidade* treinado e calibrado: aprendizagem supervisionada sobre notícias históricas e contexto de mercado que estima com que frequência notícias com um dado perfil foram seguidas de um movimento anormal, rotuladas pelo próprio código de estudo de evento do sistema, avaliadas face a uma baseline de volatilidade, e integradas nos alertas como evidência ordenada e explicada, e não como uma previsão.
- Uma camada de *geração ancorada* que transforma esses resultados separados em prosa sem deixar que o passo de linguagem se torne um passo factual: o gerador vê apenas um pacote de evidência cujos registos declaram a sua proveniência, cada número que escreve está ligado ao registo que a própria frase cita, e a interface resolve cada citação de volta a esse registo, para que um leitor possa seguir uma frase até ao motor que a produziu.
- Uma avaliação crítica e honesta de cada componente central em dados reais, face a baselines simples e lexicais, com os resultados, as ablações e as limitações todos reportados com clareza.

1.5 Estrutura do Documento

O resto da dissertação foi escrito para ser lido por ordem, cada capítulo respondendo a uma pergunta:

- **Capítulo 2 (Estado da Arte):** o que já se sabe, e o que escolhe este trabalho?
- **Capítulo 3 (Métodos e Materiais):** como é construído o sistema, e como é avaliado?
- **Capítulo 4 (InvestiGator):** o que é o sistema, e como se encaixam os seus dados, partes, fluxo e decisões?

- **Capítulo 5 (Estudos de Caso):** funciona em dados reais?
- **Capítulo 6 (Conclusões):** o que se aprendeu, e o que vem a seguir?

Capítulo 2

Estado da Arte

Este capítulo tem uma tarefa: justificar cada escolha de desenho do InvestiGator face às alternativas. Cada secção pergunta o que um campo oferece e termina com o que o InvestiGator lhe retira. A ordem é: como se comportam os investidores de retalho; deteção de anomalias; IA explicável; confiança na automação; representação de texto financeiro; recuperação de informação; estudos de evento; e raciocínio baseado em casos. O achado recorrente é simples. Os blocos de construção são maduros, mas um sistema integrado e explicável para o investidor de retalho continua raro.

2.1 Investimento de Retalho e Sobrecarga de Informação

Como se comportam os investidores de retalho, e o que deve um alerta dar-lhes?

As finanças comportamentais mostram que os investidores reais se afastam sistematicamente do ideal racional (Barberis e Thaler 2003). Uma causa de raiz é a *aversão à perda*: sentimos as perdas mais do que ganhos iguais (Kahneman e Tversky 1979), o que torna os investidores especialmente sensíveis a más notícias, e um alerta atempado e bem explicado valioso.

O padrão mais forte é a *atenção*. Barber e Odean (2008) mostram que os indivíduos são compradores líquidos de ações que captam a atenção (as que estão nas notícias, com volume invulgar, ou retornos extremos de um dia): perante milhares de escolhas, recorrem ao que lhes chamou a atenção. A atenção pode até ser medida através do volume de pesquisas (Da, Engelberg e Gao 2011). Isto é decisivo para o desenho, porque um movimento de preço acentuado e uma manchete saliente são exatamente os dois gatilhos do InvestiGator, pelo que um alerta que acrescenta contexto chega onde as decisões movidas pela atenção são tomadas.

As notícias também movem os mercados, e o seu texto pode ser medido. Tetlock (2007) constrói um índice diário de pessimismo a partir de uma coluna de jornal e liga-o à pressão sobre os preços e ao volume de negociação, uma das primeiras evidências de que os sinais textuais se relacionam com os resultados de mercado, que é a premissa do motor de notícias do InvestiGator. Este público também é grande e ativo: mesmo durante o crash de março de 2020, os investidores de retalho de uma plataforma sem comissões reforçaram as suas posições em vez de entrar em pânico (Welch 2022), consistente com a posse alargada e a escala de mercado reportadas no Capítulo 1 (Gallup 2025; Securities Industry and Financial Markets Association (SIFMA) 2025).

Para o InvestiGator: os investidores de retalho são limitados pela atenção e movidos pelas notícias, pelo que o sistema não prevê o mercado; baixa o custo de *interpretar* os eventos que já captam a atenção, com uma explicação transparente e evidência histórica real.

2.2 Detecção de Anomalias em Mercados Financeiros

Como se distingue um movimento de preço anormal do ruído comum?

O primeiro gatilho do InvestiGator é um detetor de anomalias, pelo que assenta no campo maduro da detecção de anomalias. A taxonomia padrão (Chandola, Banerjee e Kumar 2009) separa anomalias de *ponto*, *contextuais* e *coletivas*, e agrupa os métodos em famílias estatística, de distância/densidade e de aprendizagem automática (Figura 2.1). Um retorno acentuado de um só dia é uma anomalia contextual de ponto: anormal face ao comportamento recente do próprio ativo.




Figura 2.1: Famílias de métodos de detecção de anomalias relevantes para este trabalho, seguindo Chandola, Banerjee e Kumar (2009) e Pang et al. (2021). A interpretabilidade diminui, e a capacidade de modelação aumenta, da esquerda para a direita.

O detetor mais simples é um z-score deslizante: assinalar um retorno que se desvia muito da sua média e desvio-padrão recentes. É atrativo por ser transparente e fácil de justificar. O seu único pressuposto, uma distribuição localmente estável, é tratado pela janela deslizante, que acompanha o *agrupamento de volatilidade*, a conhecida tendência de períodos calmos e turbulentos chegarem em séries (Bollerslev 1986; Engle 1982). O desvio-padrão deslizante é, com efeito, uma versão não-paramétrica mais simples dessa ideia: adapta-se ao regime atual sem ajustar um modelo que o utilizador não pudesse escrutinar. Entre os dois situa-se a média móvel ponderada exponencialmente dos retornos ao quadrado (o estimador RiskMetrics), que pondera o passado recente mais do que o distante mas mesmo assim não estima parâmetros por instrumento. Um ajuste GARCH completo é recusado aqui sob a simplicidade defensável, mas a afirmação não fica como opinião: a variante EWMA, o primeiro passo no caminho para o GARCH, é submetida ao mesmo protocolo de avaliação no Capítulo 5, pelo que o compromisso é medido e não afirmado.

Detetores mais expressivos trocam a interpretabilidade por capacidade. A Isolation Forest isola outliers por partição aleatória e escala para dimensões elevadas (F. T. Liu, Ting e Zhou 2008); o Local Outlier Factor pontua o quão isolado está um ponto na sua vizinhança (Breunig et al. 2000); os detetores profundos aprendem um modelo de normalidade (Pang et al. 2021). Todos são poderosos mas mais difíceis de ler, e a sua vantagem mostra-se sobretudo em dados de dimensão elevada, não numa única série de retornos. Em vez de os descartar só por esses motivos, o Capítulo 5 avalia tanto a Isolation Forest como o Local Outlier Factor sob o mesmo protocolo causal da regra estatística, pelo que a comparação é empírica. Nas finanças, a detecção é de qualquer modo dominada por métodos *não supervisionados*, porque as anomalias rotuladas são escassas (Ahmed, Mahmood e Islam 2016),

uma restrição que também molda a forma como o InvestiGator é avaliado (Capítulo 5). A Tabela 2.1 compara as famílias.

Tabela 2.1: Abordagens de detecção de anomalias relevantes para este trabalho.

Abordagem	Como funciona	Vantagens / limitações
z-score estatístico (deslizante) (Chandola, Banerjee e Kumar 2009)	Assinala retornos que se desviam de uma média e desvio-padrão deslizantes	Transparente e fácil de explicar; assume uma distribuição localmente estável
Isolation Forest (F. T. Liu, Ting e Zhou 2008)	Isola pontos por partição aleatória (ensemble)	Escalável, lida com dimensionalidade elevada; a pontuação não é diretamente interpretável
Local Outlier Factor (Breunig et al. 2000)	Pontua o isolamento numa vizinhança de densidade local	Capta estrutura local; sensível ao tamanho da vizinhança, pontuação difícil de ler
Detetores profundos (Pang et al. 2021)	Aprendem um modelo de normalidade (ex. autoencoders)	Alta capacidade para dados complexos; opacos, ávidos de dados, difíceis de justificar

Para o InvestiGator: o sinal é uma única série de retornos de baixa dimensão que tem de ser explicada a um não-especialista, pelo que o z-score transparente vence; as famílias mais expressivas ficam anotadas como alternativas cuja opacidade o problema não justifica.

2.3 Inteligência Artificial Explicável

Que tipo de explicação deve o sistema dar?

A IA Explicável (XAI) existe porque os modelos mais fortes raramente mostram o seu raciocínio. As revisões mapeiam o campo e a sua divisão central (Adadi e Berrada 2018; Barredo Arrieta et al. 2020): modelos *transparentes*, interpretáveis em si mesmos, versus métodos *post-hoc* que explicam uma caixa preta já treinada, que podem ser organizados por aquilo que explicam (Guidotti et al. 2018) (Figura 2.2). Uma cautela útil: “interpretabilidade” não é uma coisa só (Lipton 2018), pelo que um sistema deve dizer qual delas oferece. O InvestiGator oferece transparência da sua lógica de decisão e evidência rastreável, não uma pretensão de interpretabilidade plena.

Duas técnicas post-hoc são amplamente usadas: o LIME ajusta um substituto local simples em torno de uma previsão (Ribeiro, Singh e Guestrin 2016), e o SHAP atribui uma previsão às suas features usando valores de Shapley (Lundberg e S.-I. Lee 2017). Ambas são valiosas quando se está comprometido com uma caixa preta. Mas para decisões de alto risco, Rudin (2019) defende abandonar esse compromisso e usar modelos que sejam interpretáveis à partida, já que uma explicação post-hoc é ela própria uma aproximação que pode enganar. O InvestiGator segue isto: explica sobretudo por desenho transparente (cada quantidade exposta, precedentes reais mostrados como evidência), com atribuição de features como um extra opcional.

Boas explicações são também uma questão humana. As pessoas querem razões *contrastivas* e seletivas, não um despejo exaustivo (Miller 2019), razão pela qual cada alerta mostra




Figura 2.2: Os dois grandes caminhos para a explicabilidade (Barredo Arrieta et al. 2020; Guidotti et al. 2018): construir modelos transparentes por desenho, ou explicar uma caixa preta a posteriori. Este trabalho segue o primeiro.

alguns precedentes relevantes e as quantidades exatas por detrás da decisão. As explicações têm também de ser avaliadas, não assumidas: Doshi-Velez e Kim (2017) defendem que as afirmações de interpretabilidade precisam de avaliação rigorosa em vez de asserção, e mostram como essa avaliação pode ser estruturada. O critério que este trabalho adota é a *fidelidade*, o quão bem uma explicação reflete o cálculo real, porque é a propriedade que o InvestiGator consegue garantir (Capítulo 5). A Tabela 2.2 resume as opções.

Tabela 2.2: Abordagens de explicabilidade consideradas.

Método	Tipo	Vantagens / limitações
LIME (Ribeiro, Singh e Guestrin 2016)	Substituto local, post-hoc	Intuitivo, agnóstico ao modelo; as explicações podem ser instáveis, só localmente fiéis
SHAP (Lundberg e S.-I. Lee 2017)	Atribuição por valores de Shapley, post-hoc	Consistente, teoricamente fundamentado; computacionalmente custoso
Desenho transparente (Barredo Arrieta et al. 2020; Rudin 2019)	Lógica inerentemente interpretável	Sem aproximação, fiel por construção; restringe a escolha do modelo

Para o InvestiGator: procurar a explicabilidade por desenho transparente e julgá-la pela fidelidade; tratar a atribuição post-hoc como um complemento, não a fundação.

2.4 Confiança e Dependência Apropriada no Apoio à Decisão

Quando deve o investidor confiar de facto num alerta?

Uma explicação só ajuda se produzir uma dependência *apropriada*: nem descartar um aviso sólido, nem agir cegamente sobre um falível. A perspetiva dos fatores humanos (J. D. Lee e See 2004) chama ao objetivo confiança *calibrada*, dependência ajustada à competência real do sistema, e nomeia dois modos de falha, a *subutilização* (ignorar um bom auxílio) e o *uso indevido* (confiar em excesso num falho). Com dinheiro real, ambos são custosos.

As explicações são a forma como a confiança se calibra, mas não são mágicas. Bansal et al. (2021) mostram que as explicações podem até causar *dependência excessiva*, com as pessoas

a aceitar explicações confiantes de respostas erradas. A resposta do InvestiGator é concreta: explicar com *evidência verificável* (o próprio z-score e os seus parâmetros; precedentes reais com o seu impacto medido), e recusar a previsão em cada alerta.

Para o InvestiGator: a transparência não é decoração mas o mecanismo para a dependência apropriada, pelo que o sistema mostra evidência verificável em vez de uma história persuasiva.

2.5 PLN Financeiro e Representação de Texto

Como deve o sistema representar o significado de uma manchete?

Para comparar manchetes, o texto tem de se tornar números. A literatura de PLN financeiro divide-se em três gerações: léxicos, embeddings de palavras e modelos neuronais contextuais. As revisões de análise textual em finanças até meados da década de 2010 (Kearney e S. Liu 2014) cobrem as duas primeiras; a terceira surgiu depois, e é dela que este trabalho retira a sua representação.

Os léxicos vieram primeiro. Listas de palavras específicas de finanças corrigem o facto de os dicionários de sentimento gerais lerem mal palavras financeiras comuns como “liability” ou “tax” (Loughran e McDonald 2011); são totalmente transparentes mas limitados pelo seu vocabulário. Os embeddings de palavras colocaram depois as palavras num espaço vetorial onde a proximidade significa uso semelhante: o word2vec a partir do contexto local (Mikolov et al. 2013), o GloVe a partir da co-ocorrência global (Pennington, Socher e Manning 2014). Ambos dão a cada palavra um único vetor, cego ao contexto.

O Transformer (Vaswani et al. 2017) removeu esse limite, e o BERT (Devlin et al. 2019) produziu representações profundamente *contextuais*. Comparar dois textos com o BERT diretamente é, porém, custoso; o Sentence-BERT (Reimers e Gurevych 2019) resolve isto dando a cada frase um único vetor de comprimento fixo, comparável por um cosseno barato, exatamente o que a recuperação de precedentes precisa. A uma escala muito grande, a pesquisa exata pode ser trocada por um índice aproximado (Johnson, Douze e Jégou 2021) sem mudar a representação (trabalho futuro). Existem também duas opções mais pesadas: modelos FinBERT afinados ao domínio (Araci 2019; Y. Yang, Uy e Huang 2020) e grandes LLMs financeiros como o BloombergGPT (Wu et al. 2023), ambos poderosos mas mais custosos, menos transparentes, e fora da restrição gratuita e reproduzível deste trabalho. A Tabela 2.3 compara-os.

Para o InvestiGator: o Sentence-BERT é o ponto ideal (Figura 2.3), significado contextual para além dos léxicos e dos vetores estáticos, e ainda barato, comparável e gratuito de correr. Uma nota de honestidade sobre a comparação: a avaliação no Capítulo 5 mede o Sentence-BERT contra uma linha de base *lexical*, o que delimita a questão que interessa (o significado bate as palavras de superfície?); a própria escolha do embedder foi também aferida no mesmo protocolo. Um FinBERT afinado ao domínio, com mean-pooling em embeddings de frase, atinge apenas uma precision@5 de 0.420, abaixo do 0.514 do MiniLM e coerente com a sua orientação a sentimento, ao passo que os encoders gerais atuais (E5-small, BGE-small) empatam com o MiniLM (cerca de 0.51) em vez de o superarem. O encoder geral, pequeno e gratuito é, portanto, o sweet spot por medição e não apenas por argumento; só os vetores de palavra estáticos, estritamente dominados na comparação de frases, ficam por argumento.

Tabela 2.3: Abordagens de representação de texto para notícias financeiras.

Abordagem	Representação	Vantagens / limitações
Léxicos financeiros (Loughran e McDonald 2011)	Listas de palavras / tom curadas	Totalmente transparente; limitado pelo vocabulário
word2vec / GloVe (Mikolov et al. 2013; Pennington, Socher e Manning 2014)	Vetores de palavra estáticos	Eficiente; um vetor por palavra, sem contexto
BERT (Devlin et al. 2019; Vaswani et al. 2017)	Embeddings contextuais de token	Forte compreensão; a similaridade par a par é custosa
Sentence-BERT (Reimers e Gurevych 2019)	Embeddings de frase (sia-mês)	Similaridade do cosseno eficiente; a escolha deste trabalho
FinBERT (Araci 2019; Y. Yang, Uy e Huang 2020)	Modelo de língua adaptado ao domínio	Afinado a finanças; orientado a sentimento / comunicações
LLMs financeiros (Wu et al. 2023)	Grande modelo generativo	Muito capaz; custoso, opaco, fora do âmbito da camada gratuita

2.6 Recuperação de Informação e Avaliação de Ordenação

Uma vez que as manchetes são vetores, como se ordenam as notícias passadas, e como se sabe se a ordenação é boa?

Ordenar um corpus por relevância a uma consulta é o problema definidor da recuperação de informação (IR). O modelo de espaço vetorial (Salton, Wong e C. S. Yang 1975) representa documentos e consultas como vetores ordenados por similaridade do cosseno; a recuperação por embeddings do InvestiGator é a mesma ideia com vetores mais ricos. A ordenação *lexical* clássica pondera os termos informativos, do TF-IDF ao BM25 (Robertson e Zaragoza 2009), ainda uma linha de base forte. A sua fraqueza conhecida é o *desencontro de vocabulário*: um documento relevante que usa palavras diferentes pontua como dissemelhante. Os embeddings semânticos ultrapassam exatamente isso, razão pela qual o InvestiGator compara contra uma linha de base lexical (Capítulo 5).

Como a recuperação devolve uma lista ordenada, é julgada com medidas sensíveis à ordem (Manning, Raghavan e Schütze 2008); a mais direta é a *precisão@k*, a fração dos k primeiros resultados que são relevantes. O InvestiGator adota-a porque um alerta só pode mostrar um punhado de precedentes, pelo que o que interessa é se os primeiros são relevantes, reportado contra linhas de base aleatória, de recência e lexical.

Para o InvestiGator: a recuperação reutiliza uma pipeline madura de representar-depois-ordenar e a métrica padrão *precisão@k*; a contribuição é a aplicação e o emparelhamento com o impacto medido, não um novo algoritmo.




Figura 2.3: Três gerações de transformar texto financeiro em números. Os léxicos financeiros são transparentes mas limitados pelo seu vocabulário; os vetores de palavra estáticos acrescentam similaridade de uso mas sem contexto; os modelos contextuais (BERT) captam o significado mas são custosos de comparar par a par; o Sentence-BERT dá a cada manchete um único vetor comparável por um cosseno barato, exatamente o que a recuperação de precedentes precisa, e é a representação escolhida aqui. Detalhes na Tabela 2.3.

2.7 Estudos de Evento e Impacto Notícia–Mercado

Tendo encontrado notícias análogas, como se mede o que fizeram ao preço, honestamente?

A ferramenta é o *estudo de evento*, introduzido por Fama et al. (1969) e padronizado para retornos diários por Brown e Warner (1985), que fixou a prática de medir retornos sobre janelas curtas pós-evento, a base para os horizontes de +1, +3 e +5 dias do InvestiGator. O impacto é medido estritamente *depois* do evento, pelo que descreve um resultado, não uma previsão.

Porquê não prever simplesmente o preço? Porque as notícias públicas são absorvidas nos preços quase de imediato, a hipótese do mercado eficiente (Fama 1970), pelo que prever retornos a partir de notícias públicas é, por construção, muito difícil. O InvestiGator não compete, portanto, com a eficiência do mercado; mede e explica as reações que *já* se seguiram a notícias comparáveis, o que é simultaneamente mais honesto e mais defensável para um não-especialista.

Relacionar o *texto* das notícias com o impacto é uma área ativa: Tetlock (2007) é um exemplo precoce, e uma linha mais recente tenta *prever* movimentos a partir das notícias (Ding et al. 2015; Xing, Cambria e Welsch 2018). O InvestiGator deliberadamente fica aquém da previsão. Fazer isto em escala precisa de notícias alinhadas aos preços, que é a contribuição do conjunto de dados FNSPID (Dong, Fan e Peng 2024), usado para construir a base de conhecimento; os seus limites de cobertura e período são notados no data card do Capítulo 3.

Para o InvestiGator: emparelhar a recuperação semântica com o impacto de estudo de evento sobre o FNSPID é o núcleo metodológico, evidência sobre o passado, nunca uma previsão.

2.8 Raciocínio Baseado em Casos e Recuperação de Precedentes

O que é o motor, numa ideia familiar?

É o *raciocínio baseado em casos* (CBR). Na descrição clássica (Aamodt e Plaza 1994), um sistema CBR *recupera* casos passados semelhantes, *reutiliza* os seus resultados, e opcionalmente *revê* e *retém-nos*. O InvestiGator é o núcleo recuperar-e-reutilizar: cada manchete passada mais o seu impacto medido é um *caso*; uma manchete nova é a consulta; a similaridade do cosseno recupera; o impacto dos precedentes é reutilizado como evidência. Para antes de *rever*, pelo que nunca transforma a evidência numa previsão.

Para o InvestiGator: nomear o motor como CBR mostra que é um paradigma reconhecido, não ad hoc, e as suas explicações “isto assemelha-se a estes casos passados” são naturalmente inteligíveis para um não-especialista.

2.9 Triagem Aprendida de Alertas: Classificação Supervisionada de Materialidade

Quando dezenas de manchetes chegam num dia, quais merecem um alerta?

A recuperação responde a “a que é que isto se assemelha?”, e o estudo de evento responde a “o que se seguiu a notícias semelhantes?”. Nenhum ordena o fluxo de entrada. Isso é um problema de *triagem*, e pode ser posto como classificação supervisionada sem quebrar a regra de não-previsão. O modelo estima a probabilidade de um *movimento anormal de tamanho invulgar, em qualquer direção*, se seguir a uma notícia; o rótulo é produzido pela própria medição de estudo de evento do sistema, o retorno ajustado ao mercado de Brown e Warner (1985) contra um proxy de índice. O alvo é a *materialidade*, se o mercado reagiu de todo. A direção e a magnitude da trajetória do preço nunca são previstas, pelo que a tarefa fica do lado defensável da linha do mercado eficiente traçada antes neste capítulo.

Duas famílias de modelos cobrem o compromisso interpretabilidade–capacidade. A regressão logística é a escolha transparente: com entradas padronizadas, os seus log-odds são uma soma aditiva exata das contribuições por feature. Isso torna-a o tipo de modelo inerentemente interpretável que Rudin (2019) defende dever ser preferido quando as explicações importam. Os ensembles de árvores de decisão com gradient boosting (Friedman 2001) são o aprendiz não-linear mais forte e servem de teto contra o qual o modelo interpretável é comparado. Para um utilizador final, a pontuação só é honesta se for uma *probabilidade*: as pontuações cruas de um classificador estão tipicamente mal calibradas, e a calibração post-hoc, como ajustar uma sigmoide sobre dados de validação retidos (escalonamento de Platt), corrige isto (Niculescu-Mizil e Caruana 2005). Sob desequilíbrio de classes, a avaliação usa a área sob a curva de precisão-recall em vez da exatidão. Uma precisão em forma de orçamento completa o quadro (quantos dos N alertas que um utilizador consegue absorver por dia eram materiais), porque esse orçamento é exatamente o custo de fadiga de alertas que a triagem existe para reduzir.

Para o InvestiGator: a triagem acrescenta uma pontuação de severidade *treinada* por cima da pipeline transparente, ordenada e limitada por dia, explicada pelas suas contribuições aditivas, calibrada sobre dados de validação, e sempre comparada contra uma linha de base só-volatilidade antes de lhe ser permitido pesar.

2.10 Incerteza e Deriva num Modelo Implantado

Uma pontuação calibrada continua a não ser uma garantia, e um modelo não fica parado. O que oferece a literatura em cada um destes pontos?

A calibração, tal como usada no score de triagem acima, é uma propriedade *agregada*: entre os itens pontuados perto de uma dada probabilidade, aproximadamente essa fração deveria revelar-se positiva. Nada diz sobre um item individual, e não oferece recurso algum assim que o modelo é aplicado fora das condições em que foi ajustado. A *predição conformal* reduz essa lacuna. Devolve um conjunto por item em vez de uma estimativa pontual, embora a sua garantia continue a ser *marginal*, em média sobre os casos, e não condicional em qualquer um deles. O tratamento fundador (Vovk, Gammerman e Shafer 2005) mostra que um preditor pode ser envolvido de modo a devolver um *conjunto* de rótulos com uma garantia livre de distribuição e válida em amostra finita: para uma taxa de erro α escolhida, o conjunto contém o rótulo verdadeiro em pelo menos $1 - \alpha$ dos casos. A garantia não assume normalidade nem um modelo corretamente especificado, e exige apenas que os dados de calibração e de teste sejam permutáveis. A variante split (ou indutiva), que calibra num bloco reservado e custa por isso uma passagem extra em vez de um ciclo de retreino, é exposta com a sua correção de quantil de amostra finita por Angelopoulos e Bates (2023).

O apelo para um sistema construído sobre a recusa de sobre-afirmar é direto. Numa decisão binária o conjunto devolvido pode conter *ambos* os rótulos, o que é um “não sei” explícito e quantificado, em vez de uma probabilidade perto de meio que mesmo assim força uma escolha. Trata-se de um género de honestidade diferente do da calibração, e as duas são complementares e não alternativas.

A suposição de permutabilidade levanta então a segunda questão. Os modelos são treinados sobre um passado e implantados num futuro, e a relação entre entradas e alvo pode mudar por baixo deles. O tratamento padrão disto em aprendizagem automática é a literatura de *concept drift*, cujo levantamento (Gama et al. 2014) expõe a taxonomia (mudança súbita, gradual, incremental e recorrente), as estratégias de deteção e os métodos de adaptação. É um tratamento geral e não financeiro, pelo que fornece o enquadramento e o vocabulário, ao passo que qualquer afirmação sobre o quanto um corpus concreto derivou tem de vir de medir esse corpus.

Ambas as preocupações pertencem a um ponto mais amplo, sobre sistemas e não sobre modelos. D. Sculley et al. (2015) defendem, a partir da experiência com sistemas em produção, que os componentes de aprendizagem automática acumulam um custo de manutenção próprio e em larga medida escondido: emaranhamento, em que mudar seja o que for muda tudo; dependências de dados instáveis e não declaradas; e dívida de configuração. O seu texto é um artigo de posição, extraído da prática e não um estudo empírico, e é aqui citado apenas para essa afirmação qualitativa. A relevância está em que um protótipo de dissertação que corre continuamente, como este corre, herda a mesma categoria de problema em ponto pequeno.

Para o InvestiGator: estas três linhas convertem duas das ressalvas permanentes do sistema em quantidades mensuráveis. A afirmação de que uma probabilidade não é uma promessa torna-se uma experiência de cobertura (Secção 5.7); a afirmação de que o corpus de treino antecede a implantação torna-se uma medição de deriva com bandas de interpretação convencionadas (Secção 5.8). Nenhuma delas altera o que o sistema implantado faz, e nos dois casos essa contenção é ela própria o resultado reportado.

2.11 Ferramentas Existentes para o Investidor de Retalho

O que pode um investidor de retalho já usar, e o que falta?

Três tipos de ferramenta são comuns hoje, e cada um deixa uma lacuna. Os *alertas de preço*, em todas as aplicações de corretora, disparam quando um limiar de preço ou percentagem é ultrapassado; aproveitam o mesmo comportamento de atenção que o InvestiGator visa (Barber e Odean 2008), mas um limiar fixo ignora a volatilidade própria de cada ação (disparando constantemente em nomes voláteis, raramente em calmos) e diz apenas *que* um nível foi ultrapassado, nunca *porquê*. As *aplicações de notícias e sentimento* agregam manchetes e anexam uma pontuação de sentimento, apoiando-se na ligação entre o tom e os mercados (Tetlock 2007) e nos léxicos financeiros (Loughran e McDonald 2011); mas uma única polaridade é fina, muitas vezes proprietária, e raramente liga uma manchete a precedentes históricos concretos e aos seus resultados. Os *robo-advisors*, a ferramenta de fintech de retalho mais estudada, ajudam genuinamente ao melhorar a diversificação e refrear os enviesamentos (Cardillo e Chiappini 2024; D’Acunto, Prabhala e Rossi 2019), mas *agem por* o investidor com lógica proprietária, o oposto de uma ferramenta explicação-primeiro que deixa a decisão ao utilizador. A Tabela 2.4 posiciona os três face ao InvestiGator.

Tabela 2.4: Ferramentas de retalho existentes versus o sistema proposto neste trabalho.

Ferramenta	O que faz	Explica por- quê?	Mostra pre- cedentes?	Age pelo utiliza- dor?
Alerta de preço de corretora	Dispara num limiar fixo de preço / %	Não	Não	Não
App de notícias / sentimento (Tetlock 2007)	Agrega notícias, pontua senti-mento	Em parte (pontuação opaca)	Não	Não
Robo-advisor (D’Acunto, Prabhala e Rossi 2019)	Aloca e reequilibra uma carteira	Raramente (proprietário)	Não	Sim
Este trabalho (InvestiGator)	Explica eventos, mostra evidência	Sim, por desenhado	Sim (impacto medido)	Não

Uma quarta opção tornou-se comum desde que os grandes modelos de linguagem chegaram aos produtos de consumo: perguntar a um assistente genérico porque é que uma ação se mexeu. Estes modelos são comprovadamente capazes sobre texto financeiro, e existem variantes de domínio (Wu et al. 2023). A dificuldade não é a fluência, é a ancoragem. Um assistente genérico não tem acesso à volatilidade recente do próprio título, pelo que não pode dizer se um movimento foi invulgar *para aquela ação*; não estima a sensibilidade do título ao seu mercado e setor, pelo que não pode separar empresa de mercado; e o seu relato de eventos passados comparáveis é recordado, não recuperado de um corpus indexado com desfechos medidos. A resposta lê-se bem e não pode ser verificada, que é precisamente a falha de interpretabilidade contra a qual a literatura de explicabilidade avisa (Lipton 2018; Rudin 2019).

Desde 2025 essa quarta opção deixou de ser um contorno e passou a ser funcionalidade entregue, o que a torna o concorrente mais próximo da afirmação central deste trabalho e merecedora de ser *nomeada* em vez de descrita como categoria. A Robinhood lançou o *Cortex* em março de 2025 com uma funcionalidade cujo propósito declarado é “responder à velha pergunta: ‘Porque é que esta ação está a subir ou a descer hoje?’” gerando resumos a partir de notícias, relatórios de analistas, sinais técnicos e dos dados da própria corretora (Robinhood Markets 2025). A Google reconstruiu o Google Finance em torno de IA e entregou “key moments” que “explicam porque é que uma ação se moveu”, anotados sobre o gráfico de preços (Google 2026). Ambos foram observados a 2026-08-07; a formulação citada é a de cada fornecedor.

A sobreposição com este trabalho é real e deve ser dita sem rodeios: estes produtos respondem à mesma pergunta para um público muito maior do que uma dissertação alguma vez alcançará, e respondem em linguagem simples, que era um dos objetivos aqui. A diferença está no que sustenta a resposta, e é uma diferença de *natureza*. Um resumo gerado é uma afirmação; o resultado deste trabalho é uma afirmação com a evidência anexada. Nenhum dos produtos declara se o movimento foi invulgar *para aquele título* contra a sua própria volatilidade recente, nenhum separa a contribuição da empresa da do mercado e do setor, e nenhum recupera eventos passados comparáveis com desfechos medidos a posteriori. Nem um nem outro é verificável pelo leitor: a divulgação da própria Robinhood é que “não há garantia de que a IA melhore o desempenho do investimento, mitigue o risco ou reduza perdas” (Robinhood Markets 2025), o que é uma afirmação sobre desfechos e não sobre se uma explicação individual está certa. É essa a lacuna que este trabalho ocupa, e é estreita, dita com honestidade: não uma resposta melhor, mas uma resposta que o leitor pode verificar.

A Tabela 2.5 pontua, por isso, as mesmas ferramentas contra as três perguntas colocadas na Secção 1.2, o que é um teste mais exigente do que uma lista de funcionalidades, porque cada pergunta tem uma resposta verificável.

Para o InvestiGator: cada ferramenta gratuita existente cobre um canto, alertar, notícias ou alocação, e nenhuma combina deteção sensível à volatilidade, atribuição mercado-versus-empresa e evidência histórica concreta numa só ferramenta que informa em vez de decidir. Os terminais profissionais combinam-nas, a um preço que o utilizador-alvo não paga. Essa interseção, as três respostas a custo zero e com o raciocínio à vista, é o nicho que este trabalho preenche.

2.12 Análise Comparativa e Posicionamento

Então o que escolhe o InvestiGator, e porquê?

A Tabela 2.6 reúne as escolhas face às suas alternativas. A regra ao longo de todo o trabalho é a *simplicidade defensável* (Rudin 2019): quando duas opções têm desempenho comparável, preferir a mais transparente, porque o sistema tem de ser compreendido e usado por um não-especialista.

2.13 Conclusões do Capítulo

Nenhum destes blocos de construção é novo. O que é escasso, e o que este trabalho constrói, é a sua integração disciplinada num único sistema explicável para o investidor de retalho: um detetor transparente, recuperação semântica emparelhada com o impacto de

Tabela 2.5: Ferramentas existentes pontuadas contra as três perguntas que um investidor de retalho faz (Secção 1.2).

Ferramenta	Q1 Invulgar para esta ação?	Q2 Empresa ou mercado?	Q3 Já aconteceu, com desfechos?
Alerta de preço da corretora	Não (limiar fixo)	Não	Não
App de notícias / sentimento	Não	Não	Não (só polaridade)
Robo-advisor (D'Acunto, Prabhala e Rossi 2019)	Não exposto	Não exposto	Não
Assistente LLM genérico (Wu et al. 2023)	Não (sem base de volatilidade)	Não (sem estimativa de beta)	Recordado, não recuperado
Funcionalidade IA "porque é que se moveu?" (Robinhood Cortex (Robinhood Markets 2025); Google Finance key moments (Google 2026))	Não declarado	Não declarado	Gerado, não recuperado
Terminal profissional	Sim	Sim	Sim (pago)
Este trabalho (Investi-Gator)	Sim (z-score rolante)	Sim (beta rolante)	Sim (recuperado, medido)

estudo de evento, e explicações fiéis por construção. O próximo capítulo transforma estas escolhas num método.

Tabela 2.6: Escolhas de componentes neste trabalho versus alternativas.

Componente	Escolhido	Alternativa	Porquê
Deteção de anomalias	z-score (deslizante)	Isolation Forest, detetores profundos	Transparência; sinal de baixa dimensão
Recuperação de notícias	Sentence-BERT + cos-seno	Léxicos, word2vec, LLMs	Contextual mas barato e reproduzível
Medição de impacto	Janelas de estudo de evento	—	Padrão, reproduzível, sem previsão
Explicação	Desenho transparente + precedentes	Só LIME / SHAP	Fiel por construção

Capítulo 3

Métodos e Materiais

Este capítulo responde a duas perguntas: como é o sistema construído, e como é julgado? Cobre a abordagem, os dados (numa data card reproduzível), as técnicas por detrás de cada componente, os compromissos de IA responsável, e o desenho da avaliação, que foi fixado antes de qualquer experiência ser corrida. Uma ideia percorre tudo isto: manter as coisas tão simples quanto defensavelmente possível, para que, quando duas opções têm desempenho parecido, a mais transparente vença. O próprio InvestiGator é descrito no Capítulo 4; as experiências são reportadas no Capítulo 5.

3.1 Abordagem e Metodologia

Como foi o sistema construído? Incrementalmente, de ponta a ponta. Em vez de terminar cada componente isoladamente, uma fatia fina foi construída e provada primeiro, da aquisição de dados a um alerta entregue, para que o risco de integração surgisse cedo. Cada componente começou então na sua forma mais simples e defensável e cresceu apenas onde a complexidade extra mereceu o seu lugar. É isto que significa aqui *engenharia* de Inteligência Artificial: os blocos de construção já existem na literatura (Capítulo 2), pelo que a contribuição é a sua integração, aplicação e avaliação crítica disciplinadas, não um novo algoritmo.

Seguem-se dois hábitos. Primeiro, cada componente é definido pela sua *responsabilidade* e pela sua *interface*, não por uma implementação particular, o que o mantém testável e substituível (um modelo de embedding por outro, por exemplo). Segundo, as restrições não-negociáveis do projeto, apenas recursos gratuitos e reproduzíveis, o mercado dos EUA, a transparência, e nenhuma previsão nem negociação, filtram o espaço de desenho antes de qualquer questão de desempenho.

Um terceiro hábito foi adotado depois de se ter tornado necessário, e merece ser enunciado em vez de subentendido, porque é um compromisso metodológico e não uma questão de gosto. A camada visível ao utilizador foi reconstruída várias vezes e rejeitada de cada vez por critério estético, que é um critério sem condição de paragem: há sempre outra disposição para experimentar, e nenhuma versão pode alguma vez ser demonstrada como adequada. O remédio foi escrever os critérios de aceitação *antes* do código, num documento versionado, com cada critério expresso de modo a que um teste ou uma medição o decida em vez de uma opinião. A disciplina tem um custo, e o custo é a prova de que funciona: um dos critérios revelou-se errado assim que a interface existiu, e foi corrigido por escrito, com a razão registada, em vez de ser ignorado em silêncio. Um critério contornado às escondidas é indistinguível de um critério que nunca foi escrito, pelo que emendá-lo às claras é a única versão desta prática que significa alguma coisa. A mesma lógica governa o instrumento de

avaliação humana, cujo limiar de análise é fixado antes de se recolher qualquer resposta, para que um limiar movido a posteriori aparecesse no histórico de versões e não no resultado.

3.2 Conjuntos de Dados e Fontes de Dados

Que dados usa o sistema? Duas camadas claramente separadas que partilham um esquema, pelo que são diretamente comparáveis (Figura 3.1): uma camada **histórica**, construída offline, que fornece os precedentes, e uma camada **viva** que fornece preços e notícias em tempo real. A divisão é deliberada: a camada histórica tem de ser rica e estável, a camada viva atempada e barata.




Figura 3.1: As duas camadas de dados. A camada histórica transforma o corpus FNSPID numa base de conhecimento de notícias passadas e do seu impacto observado no preço; a camada viva normaliza preços e notícias em tempo real nos mesmos campos, para que um evento atual possa ser comparado diretamente com os precedentes.

3.2.1 Camada Histórica: o Corpus FNSPID

A fonte primária pretendida para a camada histórica é o conjunto de dados FNSPID (Dong, Fan e Peng 2024), que fornece notícias financeiras alinhadas no tempo com preços diários para milhares de empresas dos EUA. Esse alinhamento é exatamente o que é necessário para relacionar notícias com o impacto de preço subsequente sem scraping à medida. A componente de notícias do conjunto de dados é grande (da ordem das dezenas de gigabytes), o que motiva diretamente a ingestão em streaming e filtrada descrita abaixo. A Tabela 3.1 regista a data card: as escolhas que tornam o subconjunto histórico reproduzível.

Os quinze tickers de grande capitalização abrangem cinco setores, o que torna a avaliação cross-setor do Capítulo 5 significativa mantendo o corpus tratável; a janela 2018–2023 (a extensão do conjunto de dados) é recente mas longa o suficiente para conter precedentes. Estas são escolhas documentadas, não fixas: um conjunto de tickers ou uma janela diferentes podem ser substituídos sem mudar o método.

3.2.2 Pré-processamento e Alinhamento ao Evento

Como se transforma uma notícia num caso histórico? Em três passos. Primeiro, o ficheiro de notícias é lido em stream e filtrado aos tickers e à janela escolhidos, para que apenas o subconjunto relevante seja materializado. Segundo, cada item é normalizado para o esquema comum (data, ticker, manchete). Terceiro, cada item é alinhado ao mercado e o seu impacto medido. A regra de alinhamento importa para a honestidade: o dia do evento é o primeiro dia

3.2. Conjuntos de Dados e Fontes de Dados

Tabela 3.1: Data card da camada histórica *desenhada* (FNSPID).

Item	Valor
Fonte	FNSPID (Dong, Fan e Peng 2024) (notícias financeiras alinhadas no tempo com preços)
Licença	Creative Commons BY-SA 4.0 (atribuição exigida)
Campos usados	data, ticker, manchete (mapeados para um esquema comum)
Tickers (15)	AAPL, MSFT, AMZN, GOOGL, NVDA, TSLA, META, JPM, BAC, XOM, CVX, JNJ, PFE, WMT, KO
Setores (5)	Tecnologia, banca, energia, saúde, consumo de base
Janela temporal	2018–2023 (granularidade diária)
Preços	Preços de fecho diários para os mesmos tickers
Governança	Dados grandes não retidos (regenerados quando precisos); apenas pequenas amostras guardadas

Nota: esta card documenta a camada histórica baseada no FNSPID. O subconjunto multi-ano *foi* construído pela pipeline de streaming e conduz o estudo de triagem de materialidade do Capítulo 5 (79,753 exemplos, 2018–2023; catorze dos quinze tickers, pois o corpus indexa a Meta sob o seu símbolo antigo).

O estudo de recuperação corre sobre o corpus de avaliação de notícias recentes reais descrito na Secção 3.2.3 (3,714 manchetes para os mesmos tickers, construído pelo processo idêntico); a recuperação foi depois re-corrida à escala no corpus multi-ano (Capítulo 6), ficando o estudo das magnitudes de impacto ajustadas ao mercado como trabalho futuro.

de negociação *em ou após* a data da notícia, e o impacto é medido a partir do *fecho* desse dia em diante. Medir a partir do fecho, não da abertura, evita creditar um movimento já no preço de abertura, e medir estritamente para a frente impõe a garantia de sem-lookahead da Secção 3.6. Os itens sem preços alinhados, ou cuja janela ultrapassa os dados, são descartados em vez de imputados. O Algoritmo 3.1 enuncia a construção.

Para tornar o abstrato concreto, a Figura 3.2 segue *uma manchete real* por cada fase do sistema: o registo bruto tal como recuperado, a limpeza e o alinhamento sem-lookahead, o passo de representação onde a “IA” acontece de facto (a manchete torna-se um embedding de 384 dimensões, o evento torna-se um pequeno vetor de features de contexto de mercado, e o resultado torna-se um rótulo binário de materialidade), e as duas coisas para que essas representações são finalmente usadas e medidas. Cada valor mostrado é genuíno, retirado do conjunto de dados para a Nvidia a 10 de maio de 2018.

A Figura 3.2 é deliberadamente esquemática. A Figura 3.3 mostra a mesma jornada como os *objetos reais*, verbatim, para que não haja dúvida sobre o que o sistema guarda e lê em cada passo.

3.2.3 Camada Viva e Conjunto de Dados de Avaliação

A camada viva fornece preços em tempo real de um serviço de dados de mercado gratuito (com um fallback gratuito) e notícias de um serviço de notícias de empresa gratuito e de feeds RSS. As notícias gratuitas são deliberadamente *não* usadas para construir a camada histórica, porque as camadas gratuitas cobrem apenas uma janela curta, recente e atrasada;

Algorithm 3.1 Construção da base de conhecimento com alinhamento ao evento.

Require: notícias $\{(d_i, c_i, h_i)\}$; preços de fecho diários P_c por ticker; horizontes $H = \{1, 3, 5\}$

Ensure: base de conhecimento $\mathcal{K}$ de casos $(d, c, h, \mathbf{e}, \text{impacto})$

```

1:  $\mathcal{K} \leftarrow \emptyset$ 
2: for cada notícia  $(d_i, c_i, h_i)$  do
3:    $e_i \leftarrow$  primeiro dia de negociação  $\geq d_i$  em  $P_{c_i}$  ▷ alinhamento ao evento
4:   if  $e_i$  existe then
5:      $\mathbf{e}_i \leftarrow \text{embed}(h_i)$  ▷ Sentence-BERT
6:     for  $\tau \in H$  do
7:        $\text{impacto}_i[\tau] \leftarrow$  retorno de  $\text{close}(e_i)$  a  $\text{close}(e_i + \tau)$ , ou n/a se indisponível
8:     end for
9:      $\mathcal{K} \leftarrow \mathcal{K} \cup \{(d_i, c_i, h_i, \mathbf{e}_i, \text{impacto}_i)\}$ 
10:  end if
11: end for
12: return  $\mathcal{K}$ 

```

mas servem bem como gatilho vivo e como fonte de notícias *reais* para uma primeira avaliação. Para isso, um conjunto de 3,714 manchetes reais para os quinze tickers foi recolhido do serviço de notícias de empresa gratuito, e é usado no estudo de recuperação do Capítulo 5.

A amplitude desse corpus precisa de ser enunciada com precisão, porque limita o que o estudo pode afirmar. Abrange **27 dias**, de 28 de maio a 24 de junho de 2026 — a janela que a camada gratuita devolve, que é uma janela e não um histórico. Vinte e sete dias não sustentam qualquer afirmação sobre generalização ao longo do tempo, razão pela qual o resultado de recuperação é reportado como preliminar e depois repetido à escala sobre o corpus multi-ano. Essa construção multi-ano *foi* feita, e é ela que sustenta os estudos de triagem, taxonomia, conformal e deriva do Capítulo 5.

Uma consequência de uma janela de 27 dias merece frase própria, porque muda como se chama a experiência de recuperação e não o que ela mede. A avaliação ordena candidatos por semelhança sem os restringir a serem anteriores à consulta; só a linha de base de recência consulta datas. Sobre as consultas amostradas, apenas 31,1% dos vizinhos recuperados são anteriores à sua consulta, 30,2% partilham a data e 38,7% são posteriores. A métrica não é afectada, porque pontua concordância de setor e o setor de uma manchete não muda com o tempo; mas o que se mede é *recuperação semântica de itens do mesmo setor*, e não recuperação de *precedentes*, e esta dissertação usa a primeira descrição para essa experiência. No sistema implantado a distinção não se levanta: a base de conhecimento curada termina em 2023 e as consultas chegam em 2026, pelo que cada caso recuperado precede a sua consulta por construção.

3.2.4 Governança de Dados e Atribuição

Duas regras de governança aplicam-se a ambas as camadas. Primeiro, os dados e modelos grandes nunca são versionados: são recriados pelo processo de ingestão, e apenas pequenas amostras ilustrativas são mantidas sob controlo de versões. Segundo, o texto de notícias de terceiros não é republicado: o conjunto de dados é citado e atribuído como exigido pela




Figura 3.2: Uma manchete real (Nvidia, 10 de maio de 2018) a viajar por cada fase. É recuperada como uma linha simples mais preços (1), limpa e alinhada ao primeiro dia de negociação com o impacto medido estritamente para a frente (2), depois *representada* para os modelos (3): o texto torna-se um embedding Sentence-BERT de 384 dimensões, o contexto de mercado torna-se um punhado de features, e o resultado observado torna-se um rótulo binário de materialidade. Essas representações alimentam as duas coisas que o sistema mede (4): uma probabilidade de triagem calibrada e a recuperação de precedentes. Cada valor é genuíno, lido do conjunto de dados.

sua licença Creative Commons BY-SA 4.0 (Dong, Fan e Peng 2024), e apenas excertos mínimos de manchetes aparecem neste documento.

3.3 Modelos e Técnicas

Três técnicas fazem o trabalho: um detetor, um motor de recuperação-e-impacto, e um passo de explicação. Cada uma é introduzida pelo que serve, depois como funciona.

3.3.1 Detecção Estatística de Anomalias

Para que serve: assinalar um movimento diário que é invulgar *para aquela ação*, não apenas grande em termos absolutos. *Como funciona:* seja r_t o retorno (logarítmico) do dia e μ_t, σ_t a média e o desvio-padrão dos retornos sobre uma janela anterior de w dias que termina estritamente antes de t . O dia é assinalado quando o z-score absoluto excede um limiar k :

$$z_t = \frac{r_t - \mu_t}{\sigma_t}, \quad \text{anomalia} \iff |z_t| > k. \quad (3.1)$$

Esta é a família estatística de detetores (Chandola, Banerjee e Kumar 2009), escolhida pela transparência: pode mostrar-se ao investidor exatamente quantos desvios-padrão o movimento foi. Existem detetores mais expressivos, a Isolation Forest (F. T. Liu, Ting e Zhou 2008) ou modelos profundos (Pang et al. 2021), mas a sua opacidade não se justifica para uma única série de retornos explicada a um não-especialista (Capítulo 2). A janela w e o limiar k são escolhas explícitas, examinadas por ablação no Capítulo 5. O Algoritmo 3.2 enuncia a regra; a janela para o dia t usa apenas dias anteriores, pelo que nenhuma informação futura entra.

Como a propriedade de não-lookahead é afirmada repetidamente nesta dissertação, vale a pena mostrar onde ela é de facto imposta em vez de apenas a descrever. O Excerto 3.1 é




Figura 3.3: O mesmo registro real em três fases, mostrado verbatim. Uma linha de notícia simples (1) torna-se um registro estruturado depois de limpa, alinhada ao seu dia de evento e anotada com o impacto medido para a frente (2), e é finalmente representada como um vetor Sentence-BERT de 384 dimensões (3). Os impactos tornam concreto o ponto tema-versus-direção num só objeto: a mesma manchete de choque petrolífero é seguida de um salto de +7.2% a um dia mas de uma queda de -9.0% aos cinco dias. Os valores são lidos diretamente do conjunto de dados (impactos arredondados a três casas decimais).

Algorithm 3.2 Detecção de anomalias por z-score deslizando (sem lookahead).

Require: série de retornos $r_1, \dots, r_T$; janela w ; limiar k

Ensure: marca a_t para cada dia, com as quantidades por detrás

```

1: for  $t \leftarrow w + 1$  até  $T$  do
2:    $W \leftarrow (r_{t-w}, \dots, r_{t-1})$  ▷ só dias anteriores
3:    $\mu_t \leftarrow \text{mean}(W)$ ;  $\sigma_t \leftarrow \text{std}(W)$ 
4:    $z_t \leftarrow (r_t - \mu_t) / \sigma_t$ 
5:    $a_t \leftarrow (|z_t| > k)$ 
6: end for
7: return para cada  $t$  assinalado, o tuplo  $(z_t, \mu_t, \sigma_t, w, k)$  ▷ exposto ao motor de explicação

```

o detetor tal como está implantado. A garantia é uma fatia: a janela termina em -1 , pelo que o dia a ser julgado está excluído da média e do desvio-padrão contra os quais é julgado. Se essa fatia incluísse o último elemento, todos os alertas deste trabalho seriam circulares, e nenhuma avaliação a jusante o detetaria.

```

1 r = pd.Series(list(returns), dtype="float64").dropna().reset_index(drop=True)
2 if len(r) < window + 1:
3     raise ValueError(f"Need at least {window + 1} returns (got {len(r)}).")
4
5 recent = r.iloc[-window - 1 : -1] # window BEFORE the last day (no lookahead)
6 last = float(r.iloc[-1])
7 mu = float(recent.mean())
8 sigma = float(recent.std(ddof=1))
9 z = (last - mu) / sigma if sigma > 0 else 0.0
10 return AnomalyResult(is_anomaly=abs(z) > threshold, z_score=z,
11                      last_return=last, mean=mu, std=sigma, ...)

```

Listing 3.1: O detetor z-score. A janela que define “normal” pára um dia antes do dia a ser julgado.

Dois detalhes desse excerto pesam para além da fatia. A função devolve as grandezas por trás da decisão (z , μ , σ) e não apenas o veredicto, que é o que permite que a explicação seja renderizada a partir do cálculo em vez de escrita ao lado dele. E uma janela de variância nula produz $z = 0$ em vez de uma divisão por infinito, pelo que uma ação que não se mexeu de todo é reportada como banal em vez de fazer a varredura rebentar.

Um pequeno exemplo mostra porque isto importa. Duas ações caem ambas 3.2% hoje. Uma tem estado calma ($\sigma \approx 0.40\%$), a outra volátil ($\sigma \approx 1.50\%$). O mesmo movimento é uma anomalia clara para a ação calma ($z \approx -8.1$) mas um dia comum para a volátil ($z \approx -2.2$), como a Tabela 3.2 mostra. Um limiar de percentagem fixa assinalaria ambas; o z-score não, que é exatamente o que queremos.

Tabela 3.2: Exemplo trabalhado: o mesmo movimento de -3.2% numa ação calma e numa volátil.

Quantidade	Ação calma	Ação volátil
Média recente μ	0.04%	0.10%
Desvio-padrão recente σ	0.40%	1.50%
Retorno de hoje r	-3.2%	-3.2%
z-score $(r - \mu)/\sigma$	-8.1	-2.2
Assinalado a $k = 3$?	sim	não

Os mesmos números são mais fáceis de sentir como uma imagem. A Figura 3.4 desenha as distribuições de retornos dia-a-dia de ambas as ações com o movimento de -3.2% de hoje marcado em cada uma: o movimento idêntico cai bem na cauda da ação calma mas dentro do intervalo comum da volátil.

3.3.2 Recuperação Semântica e Medição de Impacto

Para que serve: dada uma manchete nova, encontrar as manchetes passadas mais similares e mostrar o que aconteceu aos seus preços. Este motor de correlação notícia–mercado é o coração do trabalho, e combina duas técnicas. *Recuperação:* cada manchete torna-se um embedding de frase com o Sentence-BERT (Reimers e Gurevych 2019), escolhido (Secção 2.5) porque capta o significado mas produz vetores diretamente comparáveis, pelo que os itens passados mais próximos são encontrados de forma barata por similaridade do cosseno. *Impacto:* para cada precedente, o retorno cumulativo é medido sobre janelas pós-evento fixas (+1, +3 e +5 dias de negociação), à maneira de um estudo de evento (Brown e Warner 1985; Fama et al. 1969). Tanto a métrica de similaridade como as janelas são escolhas explícitas e documentadas, e em conjunto são a contribuição metodológica. O impacto é medido estritamente após o evento, pelo que é um resultado, não uma previsão. O Algoritmo 3.3 enuncia o passo recuperar-e-reutilizar (o núcleo de raciocínio baseado em casos da Secção 2.8).

Dois detalhes do passo de embedding merecem ser explícitos, porque cada um responde a uma pergunta que naturalmente se coloca. O primeiro é o que $\text{embed}(h)$ de facto calcula. O Sentence-BERT é um *bi-encoder*: um transformer pré-treinado lê a manchete uma vez e




Figura 3.4: Porque um limiar de percentagem fixa é rejeitado. Ambas as ações caem -3.2% hoje (linha tracejada). Para a ação calma (distribuição estreita) esse movimento fica bem na cauda ($z = -8.1$) e é assinalado; para a ação volátil (distribuição larga) o movimento idêntico fica dentro do seu intervalo comum dia-a-dia ($z = -2.2$) e não é. O z-score deslizante pergunta “invulgar *para esta ação?*”, o que uma percentagem não consegue. Valores da Tabela 3.2.

Algorithm 3.3 Recuperação de precedentes e reporte de impacto (gatilho de notícias).

Require: manchete h ; base de conhecimento $\mathcal{K} = \{(d_j, c_j, h_j, \mathbf{e}_j, \text{impacto}_j)\}$; vizinhos k ; horizonte τ

Ensure: top- k precedentes com similaridade e impacto observado, e o seu impacto médio

- 1: $\mathbf{q} \leftarrow \text{embed}(h)$ ▷ o mesmo modelo Sentence-BERT que a KB
- 2: **for** cada caso $j \in \mathcal{K}$ **do**
- 3: $s_j \leftarrow \cos(\mathbf{q}, \mathbf{e}_j)$ ▷ cosseno sobre vetores L2-normalizados
- 4: **end for**
- 5: $S \leftarrow$ índices dos k maiores s_j
- 6: **return** $\{(d_j, c_j, h_j, s_j, \text{impacto}_j[\tau]) : j \in S\}$ e $\text{mean}_{j \in S} \text{impacto}_j[\tau]$

produz um vetor contextual por token, e o embedding de frase é a média desses vetores de token (mean pooling), escalado para comprimento unitário:

$$\mathbf{e} = \frac{1}{n} \sum_{i=1}^n \mathbf{t}_i, \quad \hat{\mathbf{e}} = \frac{\mathbf{e}}{\|\mathbf{e}\|_2}, \quad (3.2)$$

onde $\mathbf{t}_1, \dots, \mathbf{t}_n$ são os vetores de token da camada final do transformer. O encoder em produção (MiniLM) é um transformer destilado de seis camadas que produz embeddings de 384 dimensões, pequeno o suficiente para infraestrutura gratuita. O desenho bi-encoder é o que torna uma base de conhecimento prática: cada caso guardado é embebido *uma* vez, e uma manchete nova custa uma única passagem para a frente mais comparações de vetores baratas. A alternativa cross-encoder, mais exata, que relê a consulta e o candidato juntos, precisaria de uma passagem completa de transformer por par (consulta, caso), o que à escala do Capítulo 5 significa dezenas de milhares de passagens por cada manchete que

chega. O segundo detalhe é a própria similaridade. Para embeddings $\mathbf{q}$ e $\mathbf{e}$,

$$\cos(\mathbf{q}, \mathbf{e}) = \frac{\mathbf{q} \cdot \mathbf{e}}{\|\mathbf{q}\|_2 \|\mathbf{e}\|_2}, \quad \|\hat{\mathbf{q}} - \hat{\mathbf{e}}\|_2^2 = 2 - 2 \cos(\hat{\mathbf{q}}, \hat{\mathbf{e}}), \quad (3.3)$$

e a identidade da direita resolve a questão do “porquê cosseno?”: em vetores de comprimento unitário o cosseno iguala o produto interno, e a distância euclidiana é uma função monótona dele, pelo que as três medidas de similaridade naturais induzem exatamente a mesma ordenação. A escolha do cosseno é, portanto, canônica e não arbitrária; o que importa é a normalização L2, que impede que textos mais longos pareçam artificialmente “maiores” do que os curtos.

O próprio impacto é lido de uma janela curta após o evento, como a Figura 3.5 mostra. A notícia pode chegar num dia não-negociável, pelo que o *dia do evento* é o primeiro dia de negociação em ou após ela; o retorno é então acumulado do fecho desse dia até ao fecho +1, +3 e +5 dias de negociação depois. Ancorar no fecho, e olhar apenas para a frente, é o que mantém a medida livre de lookahead: regista o que aconteceu *depois* de o evento se tornar acionável, nunca antes.




Figura 3.5: Como o impacto é medido. A data da notícia d_i pode cair num dia não-negociável; o dia do evento e_i é o primeiro dia de negociação em ou após ela. O retorno é então acumulado para a frente a partir do fecho de e_i ao longo de +1, +3 e +5 dias de negociação. Apenas dias pós-evento são usados, pelo que nenhuma informação futura entra.

Três escolhas fixam *como* o impacto é medido, cada uma feita tanto pela transparência como pelo rigor:

- **Horizontes.** Janelas curtas (+1, +3, +5 dias), padrão para estudos de evento diários (Brown e Warner 1985); janelas mais longas deixam entrar movimentos não relacionados de todo o mercado.
- **Linha de base.** O retorno cumulativo *bruto*, não um retorno anormal ajustado ao mercado, porque é diretamente observável e não precisa de um modelo de mercado estimado que um não-especialista não pudesse verificar. O custo, enunciado com clareza, é que um retorno bruto mistura a reação à notícia com qualquer movimento de todo o mercado nos mesmos dias (a ameaça de confundimento examinada no Capítulo 5); o ajuste ao mercado é trabalho futuro.
- **Agregação.** O número de destaque é o impacto *médio* sobre os precedentes recuperados, mas os precedentes individuais são sempre mostrados também, para que o investidor veja a dispersão, não apenas um número.

Vale a pena resolver aqui uma aparente inconsistência, porque duas partes do sistema medem o rescaldo de um evento de forma diferente, e ambas estão certas para o seu trabalho. O impacto *mostrado* de um precedente usa o retorno bruto, como escolhido acima: é o que

o investidor teria de facto experienciado, e pode ser verificado contra qualquer gráfico de preços público. O *rótulo* do modelo de triagem de materialidade (Secção 3.3.4) usa antes a diferença ajustada ao mercado $|r^{\text{tkr}} - r^{\text{mkt}}|$, porque um alvo de treino tem de isolar o movimento específico do ticker das oscilações de todo o mercado; caso contrário o modelo aprenderia a prever o índice em vez das consequências da notícia. É a mesma maquinaria de estudo de evento a responder a duas perguntas diferentes: “o que aconteceu a esta ação?” para a evidência mostrada a uma pessoa, e “moveu-se esta ação por razões próprias?” para um rótulo que um modelo aprende.

Um exemplo trabalhado torna-o concreto. A Figura 3.6 dá a intuição: o embedding coloca cada manchete num espaço onde temas semelhantes ficam próximos, pelo que uma consulta cai perto das suas correspondências e longe de notícias não relacionadas.




Figura 3.6: Ilustração conceptual da recuperação semântica. Cada manchete torna-se um ponto num espaço de embeddings de dimensão elevada (desenhado em duas dimensões apenas para intuição). Textos do mesmo tema ficam próximos, pelo que uma consulta (estrela) cai perto dos seus precedentes semanticamente similares (cheios), que formam a vizinhança top- k , e longe de notícias não relacionadas (ocas). A tabela seguinte torna isto concreto com números reais.

A Tabela 3.3 corre o passo de ponta a ponta sobre a pequena base de conhecimento de amostra que acompanha o sistema. Para a manter reproduzível sem descarregar um modelo, usa um encoder transparente de sobreposição de palavras (o sistema em produção usa o Sentence-BERT, avaliado no Capítulo 5). Para a consulta “*Nvidia demand surges on AI chip orders*”, os três precedentes mais próximos são todos de tema IA e não todos da mesma empresa: um item de IA-na-nuvem da Microsoft é recuperado a par de dois itens da Nvidia, mostrando a generalização *cross-ticker* em que a avaliação assenta. O seu impacto médio a +5 dias é +6.5%, mostrado como evidência, com a ressalva explícita de que regista o que se seguiu a notícias passadas comparáveis, não uma previsão.

3.3.3 Atribuir um Movimento: Mercado, Setor e Empresa

Para que serve: responder à segunda das três perguntas, *é a empresa ou é o mercado?* O estudo de evento acima mede o que se seguiu a um acontecimento; isto mede de onde veio o movimento de hoje. São instrumentos diferentes e a tese mantém-nos separados: o estudo de evento olha para a *frente* a partir do evento com um beta implícito unitário, e fornece o rótulo da tarefa de triagem, ao passo que a decomposição explica um movimento *contemporâneo* com betas estimados apenas sobre dados anteriores.

Tabela 3.3: Exemplo trabalhado de recuperação sobre a base de conhecimento de amostra incluída. Consulta: “Nvidia demand surges on AI chip orders”; as similaridades e impactos são reais e reproduíveis.

Similaridade	Impacto +5 dias	Ticker / data	Manchete recuperada (excerto)
0.60	+3.5%	NVDA, 2023-05-25	Nvidia guidance surges on soaring demand for AI data-centre chips
0.38	+10.9%	MSFT, 2023-04-25	Microsoft cloud growth accelerates on AI demand
0.38	+4.9%	NVDA, 2023-06-13	Nvidia unveils new AI accelerator to extend data-centre lead
Impacto médio a +5 dias sobre os precedentes recuperados: +6.5%			

Nota: a média é calculada a partir dos impactos não arredondados, pelo que não tem de igualar a média dos valores arredondados mostrados.

Um modelo de um só fator atribuiria à empresa tudo o que o índice não explica, o que para uma ação tecnológica num dia puxado pela tecnologia é simplesmente errado. O sistema usa por isso dois fatores, o índice de mercado e um ETF de setor:

$$r_t = \alpha + \beta_m r_t^m + \beta_s \tilde{r}_t^s + \varepsilon_t, \quad (3.4)$$

onde $\tilde{r}_t^s$ é o retorno do setor *ortogonalizado* contra o mercado. A ortogonalização não é cosmética: um ETF de setor e um índice largo são fortemente colineares, e sem ela os dois coeficientes absorvem a variância um do outro e a repartição torna-se arbitrária. As três contribuições reportadas, $\beta_m r_t^m$, $\beta_s \tilde{r}_t^s$ e o resíduo ε_t , somam o retorno observado por construção, que é o que permite ao alerta enunciá-las sem o risco de uma linha que não fecha. Todos os betas são ajustados numa janela estritamente *anterior* ao dia que se explica, pela mesma razão anti-lookahead do detetor.

Encolher o beta em vez de o cortar. Um beta estimado sobre vinte retornos diários é ruidoso, e um beta ruidoso produz uma atribuição confiante e errada. A primeira implementação cortava a estimativa em ± 4 ; medido com dados reais, a AMD deu $\hat{\beta} = 4,43$ numa janela volátil, caiu pelo corte para um recurso silencioso de $\beta = 1$, e atribuiu à empresa a totalidade do movimento de $-8,5\%$. Um limite rígido é exatamente o tipo de constante por justificar que este trabalho remove noutros sítios: não melhora a estimativa, substitui-a. Um peso de encolhimento fixo, na tradição de Blume (1971), também não serve aqui, porque encolhe um beta bem estimado tanto como um mal estimado; num caso sintético com uma ação a mover-se exatamente ao dobro do mercado, um peso fixo de dois terços devolve 1,67 onde a verdade é 2,0. O sistema encolhe antes na direção de um prior, em proporção à *imprecisão* da estimativa (Vasicek 1973),

$$\beta = w \hat{\beta} + (1 - w) \beta_{\text{prior}}, \quad w = \frac{\sigma_{\text{prior}}^2}{\sigma_{\text{prior}}^2 + \text{SE}^2(\hat{\beta})}, \quad (3.5)$$

pelo que um ajuste limpo fica intacto ($\text{SE} \rightarrow 0 \Rightarrow w \rightarrow 1$) e um ruidoso recai sobre o prior. O ajuste é contínuo em vez de tudo-ou-nada, e a dispersão do prior é uma grandeza económica,

a dispersão dos betas entre ações, e não um limiar escolhido para o exemplo dar certo.

Nomear o motor do movimento. Reportar que fator moveu a ação parece trivial e não é. Tomar a maior componente em valor absoluto dá a resposta errada sempre que um fator puxa *contra* o movimento observado: num dia medido a Nvidia subiu +0,25% enquanto o seu setor contribuiu com −1,54%, pelo que a maior componente em módulo era o setor, e dizer “foi o setor” teria sido falso. O que explica um dia positivo são as contribuições positivas. O motor é por isso a maior componente *com o mesmo sinal do total*, e as componentes que puxaram ao contrário são reportadas à parte em vez de descartadas, porque uma ação que subiu enquanto o seu setor caía é precisamente o caso de que o leitor deve ser informado.

3.3.4 Triagem de Materialidade: um Modelo de Severidade Treinado

Para que serve: ordenar o fluxo de notícias que chega, para que a atenção limitada do utilizador vá para as manchetes com maior probabilidade de importar (Secção 2.9), respondendo à RQ4.

A unidade é um triplo (manchete, ticker, dia do evento), onde o dia do evento d é o primeiro dia de negociação em ou após a data da notícia, a mesma regra de alinhamento que a base de conhecimento usa. O rótulo faz uma pergunta livre de direção por construção: seguiu-se um movimento anormal de tamanho invulgar? Formalmente, o exemplo é *material* quando $|r_{(d,d+h)}^{\text{tkr}} - r_{(d,d+h)}^{\text{mkt}}| \geq \tau$. A quantidade dentro do valor absoluto é o retorno do ticker sobre os h dias de negociação após o evento menos o do mercado (um proxy de índice): o resultado ajustado ao mercado da Secção 2.7. A definição primária é $\tau = 2\%$ a $h = 3$; uma grelha de sensibilidade sobre $\tau \in \{1.5\%, 2\%, 3\%\}$ e $h \in \{1, 3, 5\}$ é reportada para que a conclusão não dependa de um só limiar. Os rótulos são produzidos pelo próprio código de estudo de evento do sistema; não há anotação manual envolvida.

As features respeitam uma convenção temporal estrita, todas calculáveis no fecho do dia d , antes de a janela do rótulo abrir: a volatilidade pré-evento (desvio-padrão dos vinte log-retornos diários que terminam no dia *anterior* ao evento), o momentum de cinco dias até ao mesmo ponto, o próprio retorno do dia do evento (conhecido no fecho de d), o comprimento da manchete, um indicador de setor, e o embedding de frase da manchete.

A convenção é imposta e não confiada, e o mecanismo merece ser mostrado porque é a peça de evidência mais forte contra fuga de informação neste trabalho. O Excerto 3.2 constrói duas séries de preços idênticas até ao dia do evento e depois divergentes de forma absurda, calcula as features sobre ambas, e verifica que são iguais. A afirmação complementar é a que dá força ao teste: a mesma mutação tem de *mudar o rótulo*. Um teste que só verificasse as features seria satisfeito por uma função que ignorasse os preços por completo; exigir que o rótulo se mexa prova que o futuro era genuinamente alcançável e genuinamente excluído.

```

1 def test_anti_lookahead_mutating_the_future_does_not_change_features():
2     base = [100.0 + i * 0.1 for i in range(30)]
3     future_a = base + [200.0, 300.0, 400.0] # absurd future A
4     future_b = base + [50.0, 10.0, 1.0] # absurd future B
5     d = len(base) - 1 # event on the last day
6     of 'base'
7     assert event_features(_series(future_a), event_idx=d) == \
8         event_features(_series(future_b), event_idx=d)
9
10 def test_mutating_the_future_changes_the_label_but_not_the_features():
11     base = [100.0] * 25

```

```

11     up      = _series(base + [100, 110, 120, 130])    # large abnormal
        move
12     flat    = _series(base + [100, 100, 100, 100])    # nothing happens
13     market  = _series([100.0] * 29)
14     d = 25
15     assert event_features(up, d) == event_features(flat, d)    #
        features identical
16     assert abnormal_label(up,    market, d, 0.02, 3) == 1    #
        labels differ
17     assert abnormal_label(flat, market, d, 0.02, 3) == 0

```

Listing 3.2: O teste de não-lookahead. Mutar o futuro tem de deixar cada feature intacta e tem de mudar o rótulo.

O protocolo temporal é imposto da mesma forma literal. O Excerto 3.3 atribui blocos por *dia único* e não por linha, pelo que todas as manchetes sobre uma empresa num dado dia caem no mesmo bloco, e descarta uma faixa de dias depois de cada fronteira. Essa faixa é a parte mais vezes omitida na prática: com uma janela de rótulo até cinco dias de negociação, uma manchete nos últimos dias do bloco de treino seria de outro modo rotulada por preços que pertencem ao bloco de validação.

```

1  d = pd.to_datetime(pd.Series(dates).reset_index(drop=True))
2  unique_days = np.array(sorted(d.unique()))
3  n = len(unique_days)
4  i1 = int(n * train_frac)    # 0.70
5  i2 = int(n * (train_frac + val_frac))    # 0.85
6
7  train_days = set(unique_days[:i1])
8  emb1      = set(unique_days[i1 : i1 + embargo_days])    #
        discarded
9  val_days  = set(unique_days[i1 + embargo_days : i2])
10 emb2      = set(unique_days[i2 : i2 + embargo_days])    #
        discarded
11 test_days = set(unique_days[i2 + embargo_days :])

```

Listing 3.3: Divisão temporal por dia único, com faixa de embargo depois de cada fronteira.

No corpus do Capítulo 5 o embargo remove 820 linhas, que é o preço pago pela garantia e é reportado em vez de absorvido em silêncio na divisão.

A Tabela 3.4 torna essas colunas concretas: lista cada feature, o que é, e o seu valor real para o exemplo trabalhado da Figura 3.2 (Nvidia, 10 de maio de 2018), juntamente com o rótulo-alvo. Estes são exatamente os dados sobre os quais as métricas são calculadas.

As famílias de modelos abrangem o compromisso interpretabilidade–capacidade da Secção 2.9: um chão de alertar-sempre, uma regressão logística só-volatilidade (a regra ingénua forte que qualquer revisor perguntaria), regressões logísticas só sobre features de contexto, só sobre features de texto, e sobre ambas em conjunto (o principal modelo interpretável), e um ensemble com gradient boosting (Friedman 2001) como teto de capacidade.

O membro interpretável dessa família merece a sua matemática por inteiro, porque as explicações em produção decompõem-na termo a termo. Com features padronizadas $\tilde{x}_1, \dots, \tilde{x}_m$, a regressão logística pontua um exemplo como

$$u = b_0 + \sum_{j=1}^m w_j \tilde{x}_j, \quad p_{\text{raw}} = \sigma(u) = \frac{1}{1 + e^{-u}}, \quad (3.6)$$

Tabela 3.4: As colunas que o modelo de triagem lê, com os seus valores reais para um exemplo (Nvidia, 10 de maio de 2018). As linhas 1–6 são as features; a última linha é o alvo supervisionado. As colunas de contexto (1–5) alimentam as regressões logísticas e o ensemble com gradient boosting, pontuadas por PR-AUC e precisão@5/dia; o embedding (6) também alimenta a recuperação de precedentes, pontuada por precisão@ k . Cada feature é calculável no fecho do dia d , antes de a janela do rótulo abrir.

Atributo	O que é	Valor de exemplo
Volatilidade pré-evento	desvio-padrão dos 20 log-retornos diários que terminam em $d-1$	0.021
Momentum de cinco dias	log-retorno cumulativo até $d-1$	+0.122
Retorno do dia do evento	log-retorno de d , conhecido no seu fecho	+0.017
Comprimento da manchete	número de caracteres na manchete	55
Setor	indicador de setor one-hot	tech
Embedding da manchete	vetor Sentence-BERT de 384 dimensões	$[-0.005, 0.004, \dots]$
Materialidade (<i>alvo</i>)	$ \text{retorno anormal vs SPY sobre } (d, d+3) \geq 2\%$	1 (material)

pelo que cada produto $w_j \tilde{x}_j$ é uma contribuição aditiva *exata* para os log-odds u : sem modelo substituto e sem aproximação, a propriedade que torna a linha do “porquê” do alerta fiel por construção.

Essa afirmação é fácil de fazer e merece ser mostrada, porque “fiel por construção” é exatamente o tipo de expressão de que um leitor deve desconfiar à primeira vista. O Excerto 3.4 é o cálculo inteiro por trás da linha do “porquê”: o mesmo escalador com que o modelo foi ajustado, um produto elemento a elemento entre coeficientes e entradas escaladas, e um passo de agrupamento para legibilidade. Não há aqui um segundo modelo, e nada é estimado. As contribuições somam exatamente aos log-odds, e é isso que separa isto de uma atribuição post-hoc que aproxima uma caixa preta e pode portanto discordar dela.

```

1 scaler = pipeline.named_steps["scale"]
2 lr      = pipeline.named_steps["lr"]
3 x_scaled = scaler.transform(np.asarray(x_row, dtype="float64").reshape
    (1, -1))[0]
4 contribs = lr.coef_[0] * x_scaled          # exact additive terms of
    the log-odds
5
6 grouped: dict[str, float] = {}
7 for name, c in zip(feature_names, contribs, strict=True):
8     if name.startswith("emb_"):          key = "headline content"    # 384
        dims -> one term
9     elif name.startswith("sector_"):      key = "sector"              # one-
        hot -> one term
10    else:                                key = _FRIENDLY.get(name, name)
11    grouped[key] = grouped.get(key, 0.0) + float(c)
12 return sorted(grouped.items(), key=lambda kv: -abs(kv[1]))

```

Listing 3.4: A linha do “porquê”. As contribuições são os próprios termos do modelo, e não uma aproximação deles.

O agrupamento é uma decisão de apresentação com um custo que deve ser nomeado. Somar as 384 dimensões do embedding num único termo “headline content” torna a linha legível, mas significa também que se diz ao utilizador que o texto contou sem se lhe dizer que

palavras contaram. Isso é um limite honesto da exibição e não do modelo: os termos por dimensão continuam exatos e disponíveis, e nenhuma dimensão de um embedding de frase tem, de qualquer modo, um significado que valha a pena mostrar a um leigo.

Como uma pontuação discriminativa não é automaticamente uma probabilidade honesta, uma calibração de Platt é ajustada apenas sobre o bloco de validação,

$$p = \sigma(a p_{\text{raw}} + c), \quad (3.7)$$

com apenas dois escalares (a, c) . A forma paramétrica é uma escolha deliberada face à alternativa não-paramétrica, a regressão isotónica: uma sigmoide de dois parâmetros não pode sobreajustar um bloco de validação modesto, ao passo que a regressão isotónica precisa de substancialmente mais dados de calibração antes de a sua flexibilidade extra compensar (Niculescu-Mizil e Caruana 2005). Esse argumento foi depois posto à prova em vez de ficar como suposição. Os dois calibradores foram ajustados no mesmo bloco de validação e avaliados no mesmo teste, para as cinco famílias de modelos e sob o protocolo congelado: a de Platt ganha ou empata no Brier em todas as famílias, e no erro de calibração esperado o quadro é misto e por margens pequenas. Isto verifica-se mesmo com um bloco de validação farto, que é o cenário que deveria favorecer o método não-paramétrico, pelo que a escolha feita por parcimónia é também a escolha que a medição sustenta. A comparação é aditiva e deixou os artefactos congelados intactos.

A Tabela 3.5 torna todo o cálculo concreto ao decompor uma decisão de produção *real*: uma manchete da Meta enviada ao canal público de alertas a 12 de julho de 2026, pontuada pelo bundle só-contexto em produção. Ler a tabela de cima a baixo é ler as Equações (3.6) e (3.7) com números no lugar: a volatilidade recente elevada e o indicador de setor empurram os log-odds para cima, os termos quase-zero mal os movem, a soma dá $u = +0.699$, a sigmoide transforma-o em $p_{\text{raw}} = 0.668$, e o mapa de Platt (valores ajustados $a = 3.700$, $c = -2.313$) produz o $p = 0.539$ calibrado, que ultrapassa a porta de implantação de 0.5. A mensagem efetivamente entregue ao canal nesse dia dizia “*Risk estimate (learned triage): 54% . . . raised by recent volatility (20d) and sector*”: a decomposição reproduz o número de produção e os seus fatores dominantes exatamente. Para as explicações, as dimensões do embedding (quando a variante de texto é usada) são agrupadas num único termo “conteúdo da manchete” para que a mensagem se mantenha legível, e cada pontuação é entregue com a cláusula fixa “*triage evidence, not a forecast*”.

A implantação é deliberadamente conservadora. A pontuação fica atrás de uma porta de configuração que está desligada na configuração por defeito e ligada na implantação de referência; a variante em produção usa apenas features de contexto, pelo que corre na stack de software leve, e o texto do alerta nomeia a variante usada.

O que acontece depois da implantação precisa de ser enunciado com precisão, porque o vocabulário à volta convida ao exagero. Cada decisão de triagem é registada no momento em que é tomada. Um passo de pós-validação, corrido dias depois, rotula cada decisão maturada com o que efetivamente aconteceu, usando a mesma regra que produziu o rótulo de treino, e reporta precisão e calibração ao vivo. Isso é *monitorização e recolha de rótulos*. Não é aprendizagem: nenhum modelo é reajustado, nenhum peso muda, e o artefacto que serve a inferência é o mesmo ficheiro que foi ajustado uma vez e congelado. A distinção importa porque quatro coisas são rotineiramente confundidas. *Inferência* é pontuar um item novo com pesos fixos, e é o que corre a cada ciclo. *Treino* é ajustar esses pesos, o que aconteceu uma vez, offline, sobre o corpus histórico. *Re-treino* é repetir esse ajuste sobre

Tabela 3.5: Exemplo de triagem trabalhado: o modelo só-contexto em produção a pontuar um alerta real (META, 12 de julho de 2026, “Mark Zuckerberg Said Meta’s AI Bets ‘Haven’t Come to Fruition Yet’ as Shares Fell 5%”). As contribuições são os termos aditivos exatos $w_j\tilde{x}_j$ da Equação (3.6); a decomposição é regenerada deterministicamente a partir dos inputs congelados.

Termo	Contribuição para os log-odds
Interceção b_0	−0.025
Volatilidade recente (20 d)	+0.409
Indicador de setor	+0.303
Retorno do dia do evento	+0.010
Comprimento da manchete	+0.002
Momentum recente (5 d)	+0.000
Log-odds u (soma)	+0.699
Probabilidade crua $\sigma(u)$	0.668
p calibrado = $\sigma(3.700 p_{\text{raw}} - 2.313)$	0.539
Porta de implantação $p \geq 0.5$	passou (alerta enviado)

dados mais recentes, o que os rótulos recolhidos tornam possível e que não foi executado. *Aprendizagem contínua* é re-treinar automaticamente à medida que os dados chegam, o que este sistema não faz e não reivindica. O que existe é a pré-condição da terceira: um repositório crescente de decisões rotuladas pelo desfecho segundo a regra de treino, com o comando que o consumiria. A Secção 6.5 reporta o que esse repositório diz hoje, e não é lisonjeiro.

3.3.5 Técnicas de Explicação

Para que serve: transformar os objetos calculados numa mensagem que o investidor possa verificar. A explicação é procurada por desenho transparente (Secção 2.3) (Barredo Arrieta et al. 2020; Rudin 2019). Cada alerta é montado a partir de três ingredientes transparentes: a regra que disparou (o z-score com a sua janela e limiar); os precedentes recuperados com o seu impacto observado; e, opcionalmente, a atribuição de features sobre o detetor com o SHAP (Lundberg e S.-I. Lee 2017). O sentimento financeiro de um modelo de domínio (Araci 2019) é um enriquecimento opcional, usado apenas se acrescentar valor defensável. Como cada alerta é composto diretamente a partir destes objetos, a explicação é fiel ao cálculo por construção, uma propriedade testada no Capítulo 5.

3.3.6 Geração Ancorada e a sua Verificação de Fidelidade

Para que serve: combinar vários resultados calculados num único relato legível, sem deixar que o passo da combinação introduza o que os motores não produziram.

Os métodos anteriores respondem cada um a uma pergunta e devolvem um objeto. Nenhum deles funde esses objetos, e é na fusão que um modelo generativo ganha o seu lugar: o número de estados conjuntos que vale a pena resumir — quantos nomes foram sinalizados, que componente dominou em cada um, se houve manchetes captadas, se existem casos análogos e para que lado foram — cresce mais depressa do que uma biblioteca de modelos de frase, e prosa escolhida por regras lê-se como escrita por uma máquina porque é escolha entre cadeias fixas. Escolher que factos abrem, e ligá-los, é uma tarefa de linguagem.

O método é restringido para que o passo de linguagem não se torne um passo factual. As entradas são serializadas num *pacote de evidência*: um conjunto de registos, cada um com um identificador citável, um valor e uma proveniência declarada de *medido*, *calculado* ou *modelo*, correspondendo aos três tipos de objeto que as secções anteriores produzem. O gerador vê apenas este pacote, é instruído a citar identificadores no texto, e a sua saída é verificada antes de ser usada. Nenhum registo tem proveniência *gerado*, e esse invariante é verificado por teste e não por convenção.

A verificação de fidelidade. A verificação é determinística, conservadora, e aplica três condições independentes.

1. **Ligação numérica.** O texto é segmentado em frases. Para cada frase, os identificadores que ela cita determinam o conjunto de números admissíveis; um valor fora desse conjunto é uma violação *mesmo que exista noutro sítio do pacote*. Isto é mais estrito do que verificar contra o pacote como um todo, e a estrutura é o ponto: um conjunto global permite que uma frase cite um registo e use o valor de outro, o que possibilita apresentar um retorno como um z-score, ou inverter uma direção usando o valor de sinal oposto de um registo diferente. Valores com sinal só são admitidos na forma assinada, já que largar um sinal negativo inverte o dígito mais consequente de uma afirmação sobre o mercado.
2. **Registos proibidos.** Previsão, conselho e causa afirmada são rejeitados por padrão. As ressalvas honestas que o sistema tem de conseguir escrever — que um trecho não contém previsão, que a proximidade é apenas temporal — são retiradas do texto por uma allowlist fechada *antes* desta verificação correr. Um desenho anterior tentava em vez disso detetar negação pelo contexto; isso é uma fraqueza e não uma defesa, porque uma negação colocada por perto desliga a verificação.
3. **Atribuição.** Toda a frase que faz uma afirmação verificável tem de citar pelo menos um registo. Frases que não afirmam nada verificável estão isentas, porque exigir-lhes uma citação obrigaria o gerador a agarrar um registo arbitrário só para satisfazer a regra, e citações decorativas ensinam o leitor a deixar de as seguir.

A rejeição é aplicada por secção e não por documento. Um relatório inteiro descartado por uma frase desperdiçaria síntese sã; um relatório aceite por inteiro não teria guarda nenhuma. Uma secção rejeitada é substituída por uma composição determinística montada a partir dos mesmos registos, e essa composição é obrigada a passar a mesma verificação — se o chão não satisfizesse a guarda, uma falha do gerador deixaria o leitor sem nada.

Protocolo de avaliação. Medem-se duas quantidades, e respondem a perguntas diferentes. Um corpus adversário de ataques, cada um dos quais tem de ser rejeitado, mede a *guarda*. Um conjunto de frases de controlo fiéis, cada uma das quais tem de passar, mede se a guarda está apenas a recusar tudo: sem ele, uma guarda que rejeitasse todo o texto pontuaria perfeitamente e pareceria impecável. É a mesma exigência dos dois sentidos aplicada aos detetores na Secção 3.6. Uma terceira contagem regista as secções *entregues* com violação, que tem de ser zero por construção; reporta-se como verificação do caminho de entrega e é explicitamente circular, já que o mesmo verificador decide e avalia. As duas primeiras são determinísticas e reproduzem exactamente; as contagens de secções são uma *amostra* de uma corrida, já que dependem de quantos relatórios se geraram e do que o modelo escreveu, pelo que o que transita é a taxa de conformidade e não as contagens. O

corpus retém todos os exploits reproduzidos contra versões anteriores da guarda, para que uma fraqueza fechada não possa reabrir em silêncio.

Âmbito da garantia. A garantia aqui obtida é mais fraca do que a do caminho de alerta empurrado (Secção 3.3.5), que usa uma allowlist de vocabulário fechado. Essa diferença é deliberada e decorre do risco de entrega e não da conveniência: um alerta chega sem ser pedido e sem evidência ao lado, ao passo que um relatório é pedido por um leitor que está a olhar para a evidência e pode abrir qualquer registo citado. O que a garantia mais fraca *não* cobre está enunciado na Secção 6.5.

3.4 Ferramentas e Frameworks

O sistema é construído sobre o ecossistema científico open-source de Python: bibliotecas maduras e gratuitas para computação numérica, acesso a dados de mercado, embeddings de frase e figuras. Isto encaixa na restrição de recursos gratuitos e na reprodutibilidade, já que dependências fixadas e sementes fixas permitem recriar o ambiente e os resultados noutro lugar. O ambiente de reprodução e as saídas de avaliação estão reunidos no Apêndice A, para que este capítulo se possa focar nos próprios *métodos*.

3.5 IA Responsável e Ética

O trabalho está vinculado a vários compromissos de IA responsável que decorrem diretamente do seu propósito e do seu público. **Sem aconselhamento e sem previsão:** o sistema não faz previsão de preços nem recomendação de negociação; traz à superfície resultados passados observados como evidência e declara-o explicitamente em cada alerta, para que o investidor seja informado e não instruído. **Transparência:** cada alerta expõe a sua cadeia de raciocínio completa, em consonância com os princípios de explicabilidade do Capítulo 2, para que um utilizador possa verificar em vez de meramente confiar na saída. **Evidência honesta:** apenas os resultados que podem ser reproduzidos e explicados são reportados, e nenhum dado, métrica ou citação é fabricado. **Gestão de dados:** todas as fontes são usadas dentro das suas camadas gratuitas e licenças, o conjunto de dados FNSPID é atribuído como a sua licença Creative Commons exige (Dong, Fan e Peng 2024), o texto de notícias de terceiros não é republicado, e nenhum dado pessoal é processado. **Segurança:** as credenciais nunca são guardadas em ficheiros versionados. Por fim, o sistema é posicionado como um auxílio ao apoio à decisão para um investidor não-profissional, não como substituto de aconselhamento profissional, uma limitação enunciada com clareza.

3.6 Metodologia de Avaliação

Como é o sistema julgado? Por um plano fixado antes de qualquer experiência correr, para que a métrica não possa ser escolhida a posteriori para lisonjear o resultado, um pré-registo em pequena escala. Os resultados estão no Capítulo 5; aqui está o protocolo que segue.

3.6.1 Métrica de recuperação e relevância

A recuperação é avaliada como uma tarefa de recuperação de informação (Secção 2.6) com precisão@ k , a fração dos k primeiros precedentes que são relevantes. Escrevendo Q para

o conjunto de manchetes de consulta e $R_k(q)$ para os k primeiros itens devolvidos para a consulta q ,

$$\text{precisão@}k = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{k} \sum_{d \in R_k(q)} \text{rel}(q, d), \quad \text{rel}(q, d) = \mathbf{1}[\text{setor}(d) = \text{setor}(q)]. \quad (3.8)$$

A relevância é aproximada por *concordância de setor*: um precedente conta como relevante se a sua empresa está no setor da consulta. Este é um substituto automático para “análogo”, usado porque não existe conjunto rotulado; os seus limites são enunciados com os resultados. Duas escolhas tornam a métrica exigente, não lisonjeira. Primeiro, uma restrição *cross-ticker* estrita descarta cada precedente que partilha o ticker da consulta, pelo que o sistema não pode vencer ao emparelhar uma empresa com as suas próprias notícias passadas; tem de generalizar *entre* empresas de um setor. Segundo, k é pequeno (o número de destaque usa $k = 5$), refletindo que um alerta mostra apenas alguns precedentes.

3.6.2 Linhas de base

Um único número significa pouco isolado, pelo que a recuperação semântica é comparada contra três linhas de base, cada uma a controlar por uma explicação rival. **Aleatória** tira k precedentes ao acaso; a sua precisão é a taxa-base do setor, o chão sem-perícia. **Recência** devolve os itens mais recentes, testando se simplesmente trazer notícias frescas à superfície faria igualmente bem. **Lexical** ordena por sobreposição de palavras sob o mesmo cosseno, pelo que a diferença para o modelo de embedding isola o valor do *significado* sobre as palavras de superfície. Cada comparação é repetida sobre cinco sementes aleatórias (média com desvio-padrão), e duas variantes do Sentence-BERT são tentadas, para que o resultado reflita a recuperação semântica em geral, não uma tiragem de sorte ou um modelo.

3.6.3 Protocolo de deteção de anomalias

O detetor de anomalias é julgado sobretudo por um argumento que não precisa de *rótulo*: um bom detetor universal deve disparar a uma taxa comparável em instrumentos de volatilidade muito diferente, ao passo que uma regra cega à volatilidade não consegue. A consistência é, portanto, medida como a amplitude (máximo menos mínimo) das taxas de disparo por ticker: quanto menor a amplitude, mais uniforme o detetor. Só secundariamente é o detetor pontuado contra um proxy explícito de *movimentos extremos* (um movimento diário no ou além do percentil 99 dos próprios retornos desse ticker), via precisão, recall e F_1 ; como este proxy é ele próprio relativo à volatilidade, é tratado como evidência de apoio e não primária. Uma ablação sobre o comprimento da janela de estimação completa o quadro ao expor a sensibilidade do detetor ao seu único parâmetro principal. Por fim, a regra transparente é desafiada por um detetor *aprendido* em igualdade de circunstâncias: uma Isolation Forest (F. T. Liu, Ting e Zhou 2008) treinada causalmente sobre a mesma informação (o retorno de cada dia e a volatilidade dos vinte dias anteriores, ajustada apenas sobre um segmento passado inicial) é pontuada sobre a mesma região de avaliação, pelo que a escolha de uma regra estatística em vez de uma aprendida é testada, não assumida. Duas extensões endurecem ainda mais essa comparação. O Local Outlier Factor (Breunig et al. 2000), citado no Capítulo 2 como a alternativa baseada em densidade, é avaliado sob o protocolo causal idêntico, pelo que a regra estatística enfrenta *dois* detetores aprendidos em vez de um. E a estimativa de volatilidade deslizante é desafiada por uma variante ponderada exponencialmente (estilo RiskMetrics, $\lambda = 0.94$), o primeiro passo empírico rumo à família

GARCH da Secção 2.2, para que a pergunta natural “porquê não GARCH?” receba evidência e não opinião.

3.6.4 Protocolo de triagem

O modelo de materialidade da Secção 3.3.4 é avaliado sob um protocolo temporal estrito. Os exemplos são divididos em blocos de treino, validação e teste cronologicamente, por *dia de evento único* (70/15/15), para que todas as manchetes de um dia caiam no mesmo bloco, e um embargo de vários dias de negociação é removido após cada fronteira para que nenhuma janela de rótulo possa cavalgar dois blocos. A calibração é ajustada apenas sobre o bloco de validação; o bloco de teste é tocado uma vez, para reportar. A métrica primária é a área sob a curva de precisão-recall, cujo chão é a prevalência do teste (uma estratégia de alertar-sempre); a área sob a curva ROC e o Brier score completam o quadro, e uma métrica em forma de produto, a precisão dentro de um orçamento de N alertas por dia, mede o que o utilizador de facto experiencia. As métricas em si são padrão mas vale a pena fixá-las com precisão. Varrer um limiar s sobre as pontuações traça ($\text{recall}(s)$, $\text{preciso}(s)$); a PR-AUC é a área sob essa curva, e um scorer sem perícia ganha exatamente a prevalência π , que ancora cada comparação. A ROC-AUC é a probabilidade de um positivo aleatório superar um negativo aleatório; é reportada por completude mas não usada como primária, porque premeia ordenar os abundantes negativos fáceis e por isso lisonjeia um modelo de triagem cujo utilizador só vê o topo da ordenação. A calibração é medida pelo Brier score,

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2, \quad (3.9)$$

a diferença quadrática média entre a probabilidade declarada p_i e o resultado $y_i \in \{0, 1\}$: é baixa apenas quando as probabilidades podem ser tomadas pelo seu valor facial, que é exatamente o que um utilizador a ler “57%” merece. A comparação decisiva é contra a regressão logística só-volatilidade: o modelo aprendido é considerado útil apenas onde bate essa linha de base, e as ablações de features (só contexto, só texto, ambas) atribuem qualquer ganho à sua fonte. A sensibilidade sobre a grelha de rótulos $\tau \times h$ é reportada a par. Duas garantias adicionais são pré-comprometidas. O treino é determinístico dada a semente, e re-corrê-lo reproduz os artefactos guardados exatamente. E o resultado é reportado seja qual for o sentido em que cai: se o modelo treinado não bater a linha de base da volatilidade num dado corpus, esse achado fica tal como enunciado.

3.6.5 Incerteza, deriva e estrutura não supervisionada

Três protocolos adicionais examinam o sistema por fora, perguntando o que ele não sabe. Os três são aditivos: leem os artefactos congelados e nada alteram neles.

Cobertura conformal. O modelo de triagem congelado é envolvido em predição conformal split (Secção 2.10). A pontuação de não-conformidade é $1 - \hat{p}(y)$ para a classe verdadeira y , e o limiar $\hat{q}$ é o quantil empírico $\lceil (n+1)(1-\alpha) \rceil / n$ das pontuações de calibração; é essa correção de amostra finita, e não o quantil empírico simples, que converte uma tendência para cobrir numa garantia. Um rótulo entra no conjunto de predição quando $\hat{p}(y) \geq 1 - \hat{q}$. Reportam-se duas quantidades em cada α : a cobertura empírica, que testa se a garantia se verifica, e o tamanho médio do conjunto, que mede quanto ela custa. Como a garantia depende da permutabilidade, o protocolo corre duas vezes, uma sobre uma divisão aleatória

do bloco de teste, onde a permutabilidade vale por construção e a corrida serve portanto de verificação da implementação, e outra sobre uma divisão temporal, que é o que a implantação de facto faz. Antes de tudo isto, exige-se que o modelo reproduza exatamente a sua PR-AUC de teste congelada; se não reproduzir, a corrida para, porque nada do que se seguisse diria respeito ao modelo que esta dissertação reporta.

Deriva de distribuição. Duas estatísticas complementares comparam o bloco de treino com um posterior. O *Population Stability Index* soma $(p_{\text{atual}} - p_{\text{ref}}) \ln(p_{\text{atual}}/p_{\text{ref}})$ sobre intervalos-quantil da distribuição de referência, e traz bandas de interpretação convencionadas (< 0.10 estável, 0.10 a 0.25 moderada, acima de 0.25 significativa) herdadas da prática de risco de crédito. Usam-se intervalos-quantil e não de largura igual porque as features financeiras são fortemente assimétricas, e intervalos de largura igual colocariam quase toda a massa no primeiro. A estatística de Kolmogorov–Smirnov compara distribuições acumuladas. Fixa-se de antemão uma regra de leitura: com dezenas de milhar de pontos o valor- p associado rejeita quase qualquer hipótese nula, pelo que se reporta a *estatística* como tamanho de efeito e não se usa o valor- p para argumentar severidade. Os intervalos que a amostra atual não visita recebem um piso pequeno em vez de produzirem um índice infinito, já que um intervalo não visitado é evidência de deriva e não uma divisão por zero.

Estrutura de evento não supervisionada. Os embeddings das manchetes são agrupados por k -médias sobre vetores normalizados por L^2 , e k é escolhido pelo coeficiente de silhueta (Rousseeuw 1987), que contrapõe a coesão de cada ponto dentro do seu próprio grupo à sua separação do grupo mais próximo. Como não existe verdade fundamental para tipo de evento, a concordância é medida contra uma rubrica de palavras-chave escrita e registada *antes* de qualquer agrupamento correr, para que não possa ser afinada até concordar. Duas salvaguardas tornam os números resultantes interpretáveis. A pureza dos grupos é comparada com uma atribuição aleatória de tamanhos idênticos, porque a pureza calculada com rotulagem por maioria inflaciona quando a referência é desequilibrada e k é grande. E quando os grupos são comparados contra referências diferentes, para perguntar se se organizam por tipo de evento ou apenas por assunto, a concordância é medida por informação mútua ajustada (Vinh, Epps e Bailey 2010) e não por pureza: a pureza depende do número de classes e do seu equilíbrio, pelo que compará-la entre referências de cardinalidades diferentes é comparar grandezas incomensuráveis, ao passo que a medida ajustada tem uma linha de base ao acaso próxima de zero que não é enviesada por nenhum número particular de classes. Todas estas comparações são calculadas nas mesmas linhas.

3.6.6 Explicação, âmbito e garantias de rigor

O motor de explicação é avaliado pela *fidelidade*: se o texto do alerta reflete o cálculo real do sistema. Isto verifica-se por construção, porque cada alerta é composto diretamente a partir dos objetos calculados. A sua *utilidade* para um investidor real é uma questão separada, que precisaria de um estudo humano ainda não conduzido, e é reportada como uma limitação e não como uma afirmação. Como o sistema não faz previsão de preços nem negociação, as métricas baseadas em lucro estão fora de âmbito por desenho, não omitidas por conveniência. Sustentando cada experiência estão três garantias. Primeira, **sem lookahead**: qualquer feature calculada num instante usa apenas informação disponível nesse instante ou antes, e o impacto histórico usa apenas janelas pós-evento. Segunda, **reprodutibilidade**: as sementes aleatórias são fixas, as dependências são fixadas, e cada figura de dados e de resultados é produzida por um script versionado. Terceira, **honestidade**:

os resultados são reportados com as suas ressalvas, e achados modestos mas genuínos são preferidos a inflacionados.

3.7 Conclusões do Capítulo

Este capítulo fixou o método: simplicidade defensável e entrega incremental; uma arquitetura de dados de duas camadas numa data card reproduzível; as técnicas de detecção, recuperação, impacto e explicação, cada uma introduzida pelo seu propósito; e uma avaliação fixada à partida. O próximo capítulo reúne estas no InvestiGator.

Capítulo 4

InvestiGator: Um Sistema de Alertas Financeiros Explicável para Investidores de Retalho

Este capítulo responde a cinco perguntas, por ordem: *O que é o sistema, numa imagem? Com que objetos trabalha? Quais são as suas partes, e quem faz o quê? Como flui os dados por ele? E como decide?* O Capítulo 3 argumentou a favor dos métodos individuais; aqui eles encaixam-se num único sistema funcional, o InvestiGator.

4.1 Visão Geral

O que é o sistema, numa imagem?

O InvestiGator vigia o mercado acionista dos EUA por um investidor de retalho e levanta um alerta quando um de dois gatilhos independentes dispara: um movimento de preço abrupto, ou uma notícia relevante que chega. Cada alerta traz uma explicação completa e rastreável, não uma mera notificação. O sistema é uma pipeline de componentes de responsabilidade única ligados por um esquema de dados comum, pelo que as camadas viva e histórica são diretamente comparáveis. A Figura 4.1 é a vista numa imagem: duas fontes de dados e a base de conhecimento alimentam dois motores, cuja evidência converge num só passo de explicação antes da entrega.

Três princípios de engenharia mantêm o sistema testável e defensável. Primeiro, **uma fatia fina foi construída de ponta a ponta antes da largura**: o gatilho de mercado funcionou do preço ao alerta entregue antes de o motor de correlação mais pesado ser acrescentado, o que controlou o risco de integração. Segundo, **a lógica pura é separada da entrada/saída**, pelo que o núcleo numérico corre e é testado offline, sem rede nem a stack de modelos. Terceiro, **os componentes são programados a interfaces**: o passo de embedding tem duas implementações intermutáveis (uma linha de base lexical sem dependências e o Sentence-BERT), que é o que torna a comparação de modelos do Capítulo 5 justa. A Tabela 4.1 reúne as principais decisões de desenho; num trabalho deste tipo, esse juízo de engenharia é a contribuição.

4.2 Casos de Uso

O que é que alguém faz, de facto, com este sistema?




Figura 4.1: Arquitetura do InvestiGator. A camada viva (dados de mercado, fonte de notícias) e a base de conhecimento histórica alimentam dois motores (o detetor de anomalias e o motor de correlação) cuja evidência converge no motor de explicação antes de um alerta ser entregue através do Telegram. O gatilho de movimento de mercado segue o caminho da esquerda; o gatilho de notícias o da direita.

A arquitetura acima julga-se melhor contra as situações que foi construída para servir. A Figura 4.2 coloca-as em relação com os dois perfis de utilizador da Secção 1.2, e a Tabela 4.2 enuncia, para cada uma, a pergunta que está a ser feita e os componentes que lhe respondem. O mapeamento é deliberadamente estrito: um componente que nenhum caso de uso exercitasse seria um componente sem justificação.

Dois destes merecem comentário, porque moldaram o desenho em vez de apenas o consumirem.

O UC2 é o caso de uso que motivou a decomposição mercado-versus-empresa. Sem ela, o sistema podia reportar que uma posição caiu com força deixando o leitor incapaz de distinguir alarme de ruído, que é precisamente o modo de falha identificado para o detentor de longo prazo.

O UC4 é o único caso de uso legitimamente *à frente* dos acontecimentos, e vale a pena ser preciso sobre porque é que isso não viola a postura de não-previsão. Um evento agendado é matéria de registo público, não uma previsão, e o perfil histórico de reação reporta a distribuição dos movimentos passados em torno desses eventos, e não uma afirmação sobre o próximo. O sistema diz o que é sabido e o que aconteceu antes; não diz o que vai acontecer.

4.3 O Modelo de Dados

Com que objetos trabalha o sistema, e como se relacionam?

4.4. Componentes e Responsabilidades

Tabela 4.1: Principais decisões de desenho no InvestiGator e a sua justificação.

Decisão	Escolha	Justificação
Método de deteção	z-score deslizante	Transparente; cada alerta é explicável a um não-especialista
Representação de notícias	Embeddings Sentence-BERT	Significado contextual, mas barato e reprodutível de comparar
Medição de impacto	Janelas de estudo de evento	Padrão, reprodutível; caracteriza um resultado, não uma previsão
Estratégia de explicação	Desenho transparente + precedentes	Fiel por construção, não uma aproximação post-hoc
Arquitetura de dados	Esquema partilhado, duas camadas	A evidência viva e histórica é diretamente comparável
Acoplamento de componentes	Programados a interfaces	Testável offline; permite substituição justa de modelos
Canal de entrega	Bot de Telegram	Gratuito, ubíquo, sem cliente à medida

O objeto central é um *caso*: uma notícia passada juntamente com o que aconteceu ao seu preço a seguir. Tudo o resto existe para construir casos, guardá-los e recuperá-los. A Figura 4.3 mostra os objetos e as suas relações.

Dois pontos tornam o modelo fácil de reter. Primeiro, o *esquema partilhado*: uma notícia ao vivo e um caso histórico carregam a mesma data, ticker e manchete, pelo que uma manchete fresca pode ser comparada diretamente com os casos guardados. Um caso é simplesmente uma notícia que foi enriquecida com o *embedding* da sua manchete e o seu *impacto* medido a +1, +3 e +5 dias de negociação. Segundo, a *base de conhecimento* é apenas uma coleção de casos; pedir-lhe precedentes devolve os top-*k* casos mais similares com as suas pontuações de similaridade. O lado do mercado é ainda mais simples: o detetor emite um *resultado de deteção* contendo o movimento e cada quantidade por detrás dele (z , μ , σ , janela, limiar). Estes poucos objetos são tudo o que o motor de explicação alguma vez precisa.

4.4 Componentes e Responsabilidades

Quais são as partes, e quem faz o quê?

O InvestiGator é um pacote por componente, cada um com uma responsabilidade única e uma interface pequena, que é o que permite testar o núcleo numérico offline e trocar uma implementação por outra. A Tabela 4.3 lista-os com a sua única função e os dados em que a transformam.




Figura 4.2: Os cinco casos de uso e os perfis que os exercitam. O detentor de longo prazo chega ao sistema quando algo o preocupa; o investidor ativo usa-o como superfície diária. Ambos convergem na mesma evidência, e é por isso que um único formato de explicação serve os dois.

Tabela 4.2: Casos de uso, a pergunta que cada um responde, e os componentes envolvidos.

ID	Pergunta que o utilizador faz	Componentes exercitados
UC1	O que na minha watchlist merece atenção hoje?	Detetor de anomalias, triagem aprendida, ordenação
UC2	Porque está isto a cair, e é a empresa ou o mercado?	Decomposição, ligação a notícia, explicação
UC3	Chegou esta manchete; já importou antes?	Filtro de relevância, retrieval, event study
UC4	O que aí vem que possa mexer com isto?	Consulta de eventos agendados, perfil histórico de reação
UC5	Posso simplesmente perguntar, por palavras?	Narrador ancorado sobre os componentes acima

4.5 Fluxo de Dados

Como se move os dados pelo sistema, de ponta a ponta?

A Figura 4.4 traça toda a pipeline como três faixas que convergem. A faixa *offline* (topo) corre uma vez: as notícias FNSPID são alinhadas aos preços e embebidas na base de conhecimento (Dong, Fan e Peng 2024). Os dois gatilhos vivos correm online. A faixa de *notícias* (meio) embebe uma manchete que chega, encontra os seus casos mais próximos na base de conhecimento, e anexa o seu impacto medido. A faixa de *mercado* (fundo) transforma preços ao vivo num z-score e dispara apenas quando este cruza o limiar. Ambas as faixas entregam a sua evidência ao motor de explicação, que entrega um alerta através do Telegram.




Figura 4.3: Os objetos com que o InvestiGator trabalha. Uma **notícia ao vivo** e um **caso histórico** partilham o mesmo esquema (data, ticker, manchete); o caso acrescenta o embedding da manchete e o seu impacto medido pós-evento. O **embedder** produz esses vetores; a **base de conhecimento** guarda muitos casos; uma manchete de consulta recupera os top- k casos mais similares com as suas pontuações de similaridade. O gatilho de mercado produz um **resultado de detecção** separado.

Um item, de ponta a ponta

O diagrama mostra a forma da pipeline; o que não consegue mostrar é o que os dados são em cada passo. Como um leitor desta dissertação não pode inspecionar o sistema em funcionamento, esta subsecção segue uma notícia real desde a resposta do fornecedor até à mensagem num telemóvel, nomeando a forma que os dados tomam e onde repousam em cada etapa. O item é a manchete da Microsoft que o canal recebeu a 9 de agosto de 2026; a Tabela 4.4 é a mesma viagem numa vista.

1. Fonte e obtenção. Um processo worker acorda num ciclo de sessenta segundos e pede notícias de empresa para cada ticker da watchlist a uma API gratuita sobre HTTPS, com a chave fornecida pelo ambiente e nunca guardada no código. A resposta é JSON: uma lista de objetos com manchete, resumo, nome da fonte, URL e carimbo de publicação em segundos de época Unix.

2. Normalização e o que se descarta de propósito. Cada objeto passa a uma notícia interna com quatro campos: data, ticker, manchete e instante de publicação. O *resumo* do fornecedor é lido para o filtro de relevância e depois deitado fora em vez de guardado, porque reter texto de artigos de terceiros seria republicar conteúdo licenciado; guarda-se só a manchete, que é o mínimo necessário para calcular uma similaridade. O carimbo é preservado ao segundo, e é isso que mais tarde torna possível a decomposição de latência do Capítulo 6.

3. Relevância. A manchete tem de nomear a empresa, verificada contra uma lista de aliases (“Microsoft”, “MSFT”, e os nomes dos seus responsáveis), e não pode corresponder a boilerplate de resumo de mercado. Este portão existe porque o fornecedor etiqueta de forma larga: um aviso de um escritório de advogados e uma lista de “maiores movimentos do S&P 500” chegam ambos com o ticker. Três coisas sobre esta regra precisam de ser ditas com clareza, porque é a maior redução da pipeline e nenhuma delas é lisonjeira.

Primeiro, *quanto remove*. Aplicada ao corpus de avaliação, restrita aos doze tickers que o produto vigia, mantém 811 de 2,478 manchetes: **descarta dois terços do que chega**. Segundo, *qual das metades da regra faz o trabalho*. Os padrões de boilerplate, que são a parte mais fácil de descrever e de justificar, explicam apenas 3,0% dos descartes; os

Tabela 4.3: Os componentes do InvestiGator, cada um com uma responsabilidade única.

Componente	Responsabilidade	Entrada → saída
Dados de mercado	Obter preços, calcular log-retornos	ticker → retornos diários
Fonte de notícias	Obter e normalizar notícias ao vivo	ticker → notícias
Embedder	Transformar uma manchete num vetor	manchete → embedding
Base de conhecimento	Guardar casos passados; recuperar o mais próximo	manchete → top-k casos
Detetor de anomalias	Assinalar movimentos relativos à volatilidade	retornos → resultado de deteção
Motor de correlação	Similaridade do cosseno + impacto de estudo de evento	manchete, KB → precedentes + impacto
Modelo de triagem	Severidade aprendida: $P(\text{segue-se movimento anormal})$ calibrada	manchete + contexto → probabilidade + contribuições
Motor de explicação	Compor um alerta fiel a partir dos objetos	objetos → texto do alerta
Entrega de alertas	Enviar o alerta ao investidor	texto do alerta → Telegram
Orquestração	Correr cada gatilho de ponta a ponta	gatilho → alerta entregue

restantes 64,3% falham simplesmente porque a manchete nunca nomeia a empresa. A regra é portanto melhor descrita como um teste de menção com uma pequena exclusão de boilerplate do que ao contrário. Terceiro, *de onde veio a regra*. Não foi derivada a priori. Foi escrita depois de ler os primeiros vinte e sete alertas que o canal tinha efectivamente enviado, e os padrões de boilerplate são transcrições das falhas ali observadas. Isso é engenharia comum e é reproduzível no sentido que importa — a regra é código determinístico, pelo que duas pessoas a aplicarem-na às mesmas manchetes obtêm resultados idênticos — mas não é um critério independente, e chamar-lhe isso representaria mal como foi construída.

Uma quarta propriedade é uma limitação genuína e não uma divulgação. O teste de menção depende de uma lista de aliases escrita à mão, e a sua cobertura vale o que vale essa lista: tickers sem entrada caem no fallback de corresponder ao símbolo nu, que quase nenhuma manchete escreve, pelo que a sua retenção desaba. Outro investigador que escolhesse aliases diferentes obteria taxas de retenção diferentes do mesmo corpus.

4. Representação. A manchete sobrevivente é codificada num vetor de 384 dimensões e norma unitária pelo codificador de frases quantizado, em CPU, em poucos milissegundos. Este é o único ponto da pipeline onde uma rede neuronal corre em produção.

5. Armazenamento. Escrevem-se duas coisas. O vetor com os seus metadados é acrescentado a um ficheiro de casos *pendentes*, onde espera até que o seu próprio impacto a cinco dias seja observável e possa maturar em precedente. Em separado, a decisão que está prestes a ser tomada é acrescentada a um registo de decisões. Ambos vivem numa branch de dados versionada e não no disco do próprio dyno, porque esse disco é efémero e não é partilhado com o processo que serve o painel.

6. Recuperação. O vetor é comparado por cosseno contra cada caso guardado, e tomam-se




Figura 4.4: O fluxo de ponta a ponta do InvestiGator como uma pipeline conectada. *Offline* (topo), as notícias FNSPID são alinhadas aos preços e embebedas na base de conhecimento. O *gatilho de notícias* (meio) embebe uma manchete que chega, encontra os seus precedentes mais próximos na base de conhecimento e anexa o seu impacto observado; o *gatilho de mercado* (fundo) transforma preços ao vivo num z-score e dispara apenas quando excede o limiar. Ambos os caminhos convergem no motor de explicação, que entrega um alerta explicado através do Telegram. Esta é a vista simplificada; a pipeline completa, com cada porta de decisão e o seu valor de configuração em produção, é a Figura A.1 no Apêndice A.

os três melhores, ordenados com um fator de decaimento por idade enquanto a similaridade mostrada continua a ser o cosseno verdadeiro. Para este item os vizinhos mais próximos foram três manchetes da Microsoft de 2023, a similaridades 0.70, 0.57 e 0.55.

7. Desfecho medido. Cada precedente recuperado já traz o retorno que se lhe seguiu a +1, +3 e +5 dias de negociação, medido quando o caso maturou e nunca recalculado no momento da consulta. Aqui variaram entre -1.67% e $+4.79\%$ a cinco dias.

8. Features e pontuação. Em paralelo, os preços recentes do ticker produzem as features de contexto da Secção 3.3.4, e o modelo congelado transforma-as numa probabilidade calibrada com as suas contribuições aditivas exatas.

9. Portões. O item passa uma verificação de frescura, um chão de evidência sobre a melhor similaridade, o gate de materialidade, o tecto diário por empresa com o seu piso escalonado, e uma verificação de duplicados entre produtores. Qualquer um destes pode terminar a viagem em silêncio, e é por isso que existe a superfície de screener para reportar qual deles o fez.

Duas dessas constantes foram derivadas de um modelo de custos e uma não foi, e vale a pena ser explícito sobre a diferença. Os pisos escalonados vêm do varrimento de política sob rácios de custo declarados. O *chão de evidência* sobre a similaridade do cosseno, em 0.45, foi escolhido por juízo, e é o gate mais agressivo do funil: numa varredura medida parou sete de dez empresas, quatro delas por margens de 0.04 ou menos. Testar se podia ser derivado produziu uma resposta negativa que se reporta em vez de se esconder. Se um cosseno mais alto indicasse um precedente mais informativo, a concordância entre a direcção subsequente do precedente e a da própria consulta deveria subir com a similaridade. Medido sobre o corpus multi-ano, sob o protocolo de recuperação do Capítulo 5 e contra um chão de acaso obtido por emparelhamento aleatório sob as mesmas restrições em vez de assumido como metade,

não sobe: os pares acima do chão concordam 0.504 das vezes e os pares abaixo 0.506, uma diferença cujo intervalo contém zero, com ambos os lados ao nível do acaso de 0.507. O chão não pode, portanto, ser justificado como seleccionando precedentes que predizem melhor a direcção, e este trabalho não afirma que o faça. O que ele defensavelmente é, e tudo o que se reivindica, é um controlo de volume sobre a coerência temática — coerente com o achado do Capítulo 5 de que a recuperação capta tema e não direcção.

10. Renderização e entrega. O texto do alerta é montado diretamente a partir dos objetos acima e enviado ao canal; o mesmo registo é acrescentado ao histórico partilhado, de onde o painel o vai buscar depois. A entrega demorou menos de um segundo desde a deteção. A mensagem que o utilizador recebeu está reproduzida na Secção 4.9.

Tabela 4.4: Uma notícia real (Microsoft, 9 de agosto de 2026) em cada etapa, com a forma que os dados tomam e onde repousam. Lida de cima a baixo, é o sistema inteiro.

#	Etapa	Forma dos dados	Onde repousa
1	Pedido ao fornecedor	JSON sobre HTTPS	em memória
2	Normalização	data, ticker, manchete, instante	em memória (resumo descartado)
3	Filtro de relevância	o mesmo, ou descartado	—
4	Codificação	vetor de 384 dimensões	em memória
5	Captura	vetor + metadados; registo da decisão	branch de dados (dois ficheiros)
6	Recuperação	top-3 casos + cosseno	em memória
7	Consulta do desfecho	retornos a +1/+3/+5 dias	lido do caso guardado
8	Features + score	9 números → probabilidade + termos	ficheiro do modelo congelado
9	Portões	manter ou largar, com a razão	registo de portões (branch)
10	Entrega	texto da mensagem	Telegram + histórico partilhado

Duas propriedades desse caminho merecem ser nomeadas por serem decisões de desenho e não consequências. Nada entre os passos 4 e 8 precisa da rede, pelo que uma falha do fornecedor degrada o sistema para silêncio e não para erro. E cada passo que descarta um item regista porque o fez, que é o que torna um dia calmo distinguível de um dia avariado.

Um detalhe na construção offline importa para a honestidade: cada notícia é alinhada ao primeiro dia de negociação em ou após a sua data, e o impacto é medido apenas a partir do fecho desse dia em diante, pelo que um salto já no preço de abertura nunca é creditado ao sistema. Construir o corpus multi-ano completo é um trabalho pontual longo; foi feito, e é ele que fornece os 79,753 exemplos por trás do estudo de triagem do Capítulo 5 e a repetição à escala do resultado de recuperação. O próprio estudo de caso da recuperação usa uma base de conhecimento construída a partir de notícias reais recentes pelo processo idêntico, e o que continua em aberto é mais estreito do que a construção: o estudo da magnitude do impacto ajustado ao mercado sobre esses precedentes multi-ano.

4.6 Lógica de Decisão

Como decide o sistema, de facto? Cada gatilho aplica uma regra simples e transparente.

Gatilho de mercado. Assinalar o dia em que o z-score absoluto cruza o limiar, $|z_t| > k$, com z_t calculado a partir da janela anterior como na Equação 3.1. O detetor devolve não só a decisão sim/não mas cada quantidade por detrás dela (z , μ , σ , janela, limiar), que é exatamente o que torna a explicação fiel. A mesma regra é aplicada a séries de preços inteiras na avaliação, pelo que as experiências usam a lógica de produção.

Gatilho de notícias. Embeber a manchete que chega, ordenar a base de conhecimento por similaridade do cosseno, e tomar os top- k casos. Para cada um, reportar o impacto observado a +1, +3 e +5 dias, medido a partir do fecho do dia do evento, e mostrar a sua média como evidência. Nada aqui prevê: os números são o que *de facto* aconteceu depois de notícias passadas comparáveis, e a base de conhecimento é consultada mas nunca decide.

Severidade aprendida (triagem). Por cima das duas regras transparentes assenta o componente treinado opcional da Secção 3.3.4: cada notícia que chega é pontuada com a probabilidade calibrada de se seguir um movimento anormal, e o alerta pode ser *filtrado* (gated), enviado só quando a pontuação ultrapassa um limiar configurado, e *anotado* com a pontuação e as suas principais contribuições aditivas. O gate falha-aberto: sem ficheiro de modelo, ou com histórico de preços insuficiente para calcular as features de contexto, a pipeline comporta-se exatamente como antes. Vem desligado na configuração por defeito e é ligado na implantação de referência, onde actua como o controlo de volume examinado na Secção 4.10. A variante em produção usa apenas features de contexto, pelo que corre sem a stack pesada de embeddings.

A redação dessa linha merece parágrafo próprio, porque uma versão anterior dela era *desonesta* e a correção é o enunciado mais claro de onde cai realmente a regra de não-previsão deste sistema. O alerta terminava em “triagem sobre casos históricos, não uma previsão”. Era falso. Uma probabilidade de que um movimento invulgarmente grande ocorra nos próximos dias é, por definição, uma afirmação sobre o futuro, e os critérios de interface do próprio projeto banem este número de todas as vistas do painel exatamente por isso. Afirmar no alerta que não é previsão, enquanto se bane do ecrã por o ser, é uma contradição que um arguente encontra. A distinção que é verdadeira, e que o rótulo de treino sustenta, é entre *materialidade* e *direção*: o rótulo pergunta se se seguiu um movimento anormal de tamanho invulgar, em qualquer direção, e nunca para que lado foi. A linha passa portanto a enunciar a probabilidade, a nomear as duas features que a puxam, a dizer explicitamente que é sobre se o mercado reage e nunca sobre para que lado, e a recusar previsão de preço e aconselhamento. O sistema prevê uma coisa, de forma estreita e por desenho, e o caminho honesto é dizer qual em vez de negar que prevê.

Orçamento servido por materialidade e não por ordem de chegada. Um tecto diário de dois alertas de notícia por empresa protege o leitor da fadiga, mas um tecto vale o que vale a regra que decide quais dois passam. O runner percorria originalmente as manchetes de cada dia pela ordem em que a fonte as devolvia, pelo que duas histórias irrelevantes de manhã podiam esgotar o orçamento de uma empresa e uma história genuinamente material da parte da tarde era descartada sem deixar rasto. A falha apareceu em operação e não em testes, num dia em que a Nvidia subiu com força na sequência de um anúncio de fornecimento: o canal levou duas histórias menores dessa empresa e nunca levou a que a moveu. O incómodo é que o sistema já tinha o instrumento certo. O componente de triagem da Secção 3.3.4 existe precisamente para ordenar notícias por materialidade, e o Capítulo 5 reporta que, dentro de um orçamento de cinco alertas, eleva a precisão de 0.379 para 0.632 em dados

retidos, contra um chão que ordena ao acaso; o tecto simplesmente nunca o consultava, e a pontuação era medida e depois ignorada.

A primeira reparação foi servir o tecto por ordem decrescente dessa pontuação, e não funcionou. A falha fica registada em vez de ser substituída em silêncio, porque a sua causa é uma propriedade da implantação que nenhum teste de componente conseguiria expor: ordenar só reordena candidatas presentes ao mesmo tempo, e a varredura emite no máximo uma manchete por empresa por ciclo, pelo que duas histórias a disputar a quota da *mesma* empresa nunca coexistem num lote. Ao longo do dia a ordem continuava, portanto, a ser a de chegada, que era o defeito original. O teste escrito ao lado dessa alteração comparava três manchetes da mesma empresa numa única chamada, um cenário que a produção não sabe produzir, e um teste que passa sobre um cenário impossível é indistinguível de uma correcção que funciona.

O que governa o tecto é, em vez disso, um *piso escalonado*: o k -ésimo alerta de uma empresa num dado dia tem de superar uma probabilidade calibrada mais alta do que o anterior. Os pisos são derivados e não escolhidos. Varrer o limiar de decisão sob uma razão de custo explícita R entre um movimento perdido e um falso alarme (Capítulo 6) dá $\tau^* = 0,49$ a $R = 1$, que é o primeiro alerta do dia, onde os dois erros custam aproximadamente o mesmo, e $\tau^* = 0,64$ a $R = 0,5$, que é o segundo, onde interromper um leitor já interrompido torna a fadiga o custo dominante. Não foi acrescentado um terceiro piso, mais exigente: a pontuação máxima que o modelo produz no conjunto de teste congelado situa-se entre 0,65 e 0,66, pelo que um piso acima disso nunca poderia disparar, e código morto com aparência de rigor é pior do que regra nenhuma. O mecanismo vê-se em operação ao vivo, onde o runner regista recusas da forma “o segundo alerta do dia exige $p \geq 0,64$ e este tem 0,58”.

Um limite é estrutural e não uma lacuna de implementação, e enunciá-lo é mais útil do que afirmar que o problema está resolvido. O primeiro lugar continua a ser gasto na primeira manchete que supera o gate normal, porque no momento dessa decisão a história da tarde ainda não existe: não se pode reservar quota para notícias que ainda não se viram, e um alerta entregue não se retira. O que uma regra online pode fazer é tornar cada lugar adicional mais caro, e é isso que esta faz. A ordenação por materialidade mantém-se pelo benefício menor que de facto entrega, decidir que empresa é anunciada primeiro quando várias qualificam dentro do mesmo ciclo.

A mesma história contada duas vezes. A deduplicação usava como chave o texto exacto do alerta, pelo que uma história publicada por dois meios com títulos diferentes produzia dois alertas. Os alertas passam também a ser comparados pelas palavras de conteúdo da *manchete*, acima de um limiar de semelhança. Que a comparação corra sobre a manchete e não sobre o alerta renderizado é deliberado, e foi um erro corrigido pelo caminho: o alerta é quase todo template fixo, portanto duas histórias genuinamente diferentes sobre a mesma empresa partilham a maior parte das palavras, e comparar alertas renderizados teria suprimido em silêncio um segundo alerta legítimo. A verificação também se recusa a julgar manchetes com muito poucas palavras de conteúdo, onde quaisquer duas cadeias concordam; aí falha aberto, porque um alerta repetido custa ao leitor muito menos do que um alerta em falta.

4.7 Explicação e Entrega

Como é o alerta explicado, e como chega ao investidor?

O motor de explicação compõe cada alerta diretamente a partir dos objetos acima, pelo que o texto não pode divergir do cálculo. Para o gatilho de mercado, enuncia o movimento, o z-score, o limiar e a janela, e a média e desvio-padrão recentes, e põe o z-score em linguagem simples (quantas vezes o movimento de um dia típico representa) para que um não-especialista o consiga ler. Para o gatilho de notícias, lista os precedentes recuperados (data, ticker, similaridade, impacto medido, manchete) e o seu impacto médio, e termina sempre com um aviso explícito de que estes são resultados passados observados, não uma previsão.

A entrega é por Telegram, escolhido pela sua interface de bot gratuita e ubíqua. Um alerta real foi entregue durante os testes; a Figura 4.5 mostra o formato que o investidor recebe, com toda a cadeia de raciocínio numa só mensagem. No sistema em produção o formato da mensagem foi depois compactado para legibilidade (o facto mais forte primeiro, o método numa nota de rodapé curta, e o intervalo dos resultados dos precedentes mostrado a par da sua média); os campos transportados são exatamente os de cima, pelo que o argumento da fidelidade não muda.




Figura 4.5: Um alerta de notícias do InvestiGator tal como entregue através do Telegram (a mensagem é a saída real do produto, em inglês). Uma única mensagem carrega a cadeia de raciocínio completa e rastreável: o evento detetado, o impacto médio observado de eventos passados análogos, os precedentes individuais com as suas pontuações de similaridade e impacto medido, e um aviso explícito de não-previsão. Os números mostrados são uma ilustração representativa e arredondada; a saída real completa de ponta a ponta aparece no Capítulo 5 (Estudo de Caso 3).

O mesmo raciocínio é também publicado como um dashboard ao vivo (Figura 4.6), e a sua decisão organizadora merece vir primeiro por ser a ligação mais clara entre este capítulo e o Capítulo 1. As três perguntas que um investidor de retalho faz (Secção 1.2) passam a ser três secções nomeadas em cada cartão, sempre pela mesma ordem: isto é invulgar para esta ação, é a empresa ou é o mercado, e já aconteceu antes. Aparecem mesmo quando a resposta é que nada aconteceu, porque uma pergunta que só está lá às vezes ensina o

leitor a não a procurar. A superfície de abertura é uma grelha com um cartão por empresa vigiada, nenhuma privilegiada, ordenada por quão raro foi o dia e não por ordem alfabética.

Três outras superfícies completam-no. Um detalhe por empresa guarda o gráfico de preços com o detetor *reproduzido* sobre o último ano, para que as marcas sejam a mesma regra que o sistema corre ao vivo e não anotações acrescentadas à mão, a repartição mercado/setor/empresa em barras que somam ao movimento observado, e os alertas exatamente como o canal Telegram os recebeu, lidos do único registo partilhado e versionado em vez de recalculados. Um screener responde à pergunta oposta, porque é que cada empresa esteve *calma*: lista cada nome que a varredura examinou, o gate que o travou, e a margem que faltou. Esta superfície existe porque o silêncio é uma decisão que o sistema toma, e uma decisão que não se pode inspecionar é indistinguível de um sistema que não está a correr. Uma página de método carrega os números congelados da avaliação, incluindo o resultado negativo do Capítulo 5, cada um ao lado do ficheiro de onde vem, para quem quiser verificar o método antes de confiar na saída.

Três escolhas dentro destas superfícies foram feitas contra versões anteriores e não herdadas delas. Primeiro, a raridade é expressa como uma *contagem empírica* — “5 dos últimos 249 dias de negociação moveram-se isto ou mais” — e não como uma probabilidade. Converter um z-score numa probabilidade exigiria assumir normalidade, e os retornos diários de ações têm caudas mais pesadas do que isso, pelo que o valor resultante seria menos fiável precisamente nos dias que o sistema existe para explicar. Uma contagem não assume nada e é verificável por qualquer pessoa que tenha a mesma série de preços. Segundo, o cartão nomeia o *motor* do movimento em palavras, enquanto a repartição com sinal fica a um clique; um desenho anterior colocava as três componentes em cada linha, e com uma watchlist de doze isso são trinta e seis números com sinal a competir pela atenção no primeiro contacto, o que anula o propósito de haver uma ordenação. Terceiro, a promessa e o compromisso de não-previsão aparecem exatamente uma vez por página, no rodapé, e não ao lado de cada cartão: a repetição fazia uma interface anterior ler como defensiva sem acrescentar informação, ao passo que retirar a afirmação por completo, o que uma revisão posterior chegou a fazer, remove o único compromisso ético que o sistema assume em voz alta.

As duas medidas de excecionalidade podem discordar, e a interface di-lo em vez de escolher a leitura mais confortável. O detetor julga um dia contra os vinte anteriores; a contagem julga-o contra o ano. Uma empresa num período calmo pode assim ficar abaixo do limiar de alerta e ainda assim estar perto do topo da sua amplitude anual, e o cartão reporta os dois factos — normal para as semanas recentes, raro para o ano — e deixa a ponderação ao leitor.

A página não faz cálculo nenhum. O worker escreve um instantâneo pré-computado no fim de cada ciclo, onde o custo de ir buscar os preços já foi pago, e a página limita-se a lê-lo. Medido, construir a grelha a partir da rede custa cerca de cinco segundos, contra onze milissegundos para ler o ficheiro. E como um instantâneo que deixasse de ser escrito pareceria, em silêncio, exatamente um mercado calmo, a página mostra a idade do instantâneo: a desatualização vê-se no ecrã em vez de ser inferida.

4.7.1 Separar o servidor do cliente, e o que isso comprou

Uma revisão anterior desta interface renderizava do lado do servidor, re-executando todo o seu script a cada interação. Esse desenho obrigou a retirar uma capacidade do produto: a recuperação de precedentes foi *removida* da página porque carregar o codificador de frases

e a base de casos acrescentava, medido, cerca de sete segundos a uma carga a frio, que é a maior parte do orçamento que a interface tem. Dentro de uma única página renderizada isso é uma escolha genuína entre a capacidade e a velocidade, e ganhou a velocidade.

Separar as duas coisas elimina a escolha em vez de a resolver. O servidor responde a pedidos e o cliente guarda o estado, portanto o que é caro pode ser pedido *depois* da primeira pintura e pode chegar quando chegar. As medições estão na Tabela 4.5: toda a superfície de abertura passa a chegar num único pedido, e as interações que antes custavam uma ida ao servidor — mudar o intervalo do gráfico, ligar ou desligar uma série, paginar uma tabela — passaram a ser operações sobre um vetor já em memória. A recuperação de precedentes, a terceira das três perguntas em torno das quais este trabalho se organiza, voltou à página pela sua própria rota.

Tabela 4.5: Custo medido da interface, antes e depois de separar o cliente do servidor. As duas primeiras linhas são cargas a frio da superfície de abertura; a terceira é a mediana de cinco mudanças de intervalo na vista de detalhe, medida no browser. A última linha não é um número de velocidade mas de capacidade: o desenho anterior teve de retirar a recuperação de precedentes da página para caber no seu orçamento de carga.

	Renderizado no servidor	Estado no cliente
Superfície de abertura, a frio	5,5–6,2 s	1,0 s
Pedidos de dados para essa superfície	12	1
Mudar o intervalo do gráfico	≈750 ms	2,5–7,3 ms
Chamadas de rede para mudar o intervalo	1	0
Recuperação de precedentes na página	removida	presente

Dois detalhes dessa tabela importam mais do que os totais. O zero da quarta linha é a afirmação estrutural: mudar de intervalo é uma fatia de uma série que o browser já tem, portanto não pode falhar, não pode ficar em fila atrás de um pedido lento, e não custa nada repetir. E a vista de abertura passa a ser, por defeito, a sessão em curso e não uma janela histórica, o que obrigou a acrescentar uma série intradiária de cinco minutos ao instantâneo: sem ela o intervalo por defeito não tinha nada para desenhar, e um produto cujo primeiro ecrã está vazio responde à pergunta errada.

4.8 A Camada de Inteligência: Geração Ancorada

Tudo o que foi descrito até aqui calcula. Deteta, decompõe, recupera e pontua, e apresenta cada resultado ao lado da evidência que o produziu. O que não faz é *combinar* esses resultados, e a lacuna é fácil de enunciar: numa dada manhã o sistema sabe que o mercado alargado caiu, que uma das posições subiu contra ele, que duas manchetes foram captadas pouco antes, e que a varredura ficou calada sobre um terceiro nome. Todos esses factos estão no ecrã. Fica ao leitor juntá-los.

Juntá-los é a tarefa desta camada, e é a única tarefa do sistema em que um modelo generativo é o instrumento certo em vez do instrumento da moda. A razão é combinatória. O número de estados que vale a pena resumir — quantos nomes foram sinalizados, que componente dominou, se houve manchetes captadas, se existem casos análogos e para que lado foram, o que fez o mercado alargado — multiplica mais depressa do que se escrevem modelos de frase, e uma regra que escolhe entre frases pré-escritas produz texto que se




Figura 4.6: A interface pública (uma captura genuína, não um mockup), superfície de abertura, capturada a partir do sistema implantado durante operação ao vivo. Um cartão por empresa, ordenados por quão raro foi o dia, nenhum privilegiado. Cada cartão enuncia o seu veredicto em palavras e evidencia-o depois com uma contagem, em vez de o afirmar, inclusive quando a resposta é que não aconteceu nada: a Tesla, a +0,70%, lê-se “201 dos últimos 249 dias moveram-se isto ou mais”. A raridade aparece duas vezes, como essa frase e como uma tira de marcas, para se poderem comparar empresas sem ler um número — a Exxon Mobil, o único nome sinalizado, mostra uma só marca acesa contra a tira quase cheia da Tesla. A linha de atribuição nomeia o motor em palavras, e o cabeçalho traz o estado do mercado e a idade dos dados, ambos obrigatórios porque os números são os da última sessão fechada e o leitor não tem outra maneira de o saber.

lê como escrito por uma máquina porque é uma máquina a escolher entre cadeias fixas. Escolher que factos merecem a primeira frase, e ligá-los em prosa, é o que os modelos de linguagem fazem bem.

4.8.1 O que o gerador pode e não pode fazer

A divisão de trabalho é absoluta e é a razão de a camada ser defensável: **os motores escrevem os factos e o modelo escreve a língua**. O modelo não tem acesso ao mercado, não tem memória do ativo e não faz recuperação nenhuma. Recebe um *pacote de evidência* e a sua saída é verificada contra esse pacote antes de alguma coisa chegar ao ecrã.

Um pacote é um conjunto de factos, cada um com um identificador curto e citável, um valor e — o campo que faz o trabalho ético — uma *origem* declarada, de entre três:

- **medido:** retirado de dados de mercado ou do carimbo temporal da própria fonte;
- **calculado:** derivado deterministicamente de valores medidos, como um z-score ou a atribuição a três componentes;

4.8. A Camada de Inteligência: Geração Ancorada




Figura 4.7: O painel de inteligência, capturado ao vivo. O distintivo declara que o texto foi gerado e por que fornecedor, e o aviso âmbar por cima reporta que a guarda de fidelidade rejeitou parte da saída do modelo e substituiu-a pela composição determinística — o produto diz ao leitor quando corrigiu o seu próprio gerador, em vez de apresentar o resultado como uniforme. Cada identificador entre parênteses retos no texto é um controlo: o que está aberto aqui resolve para o registo por trás da frase, mostrando o valor e a sua proveniência declarada (*medido*). É a afirmação da Secção 4.8 tornada operacional: o texto gerado mantém-se ligado à sua evidência como uma travessia que o leitor faz, e não como uma promessa sobre o prompt.

- **modelo:** produzido por um modelo treinado, como um precedente recuperado ou uma pontuação de triagem calibrada, e portanto carregando a incerteza que o Capítulo 5 reporta para ele.

Nenhum facto tem origem *gerado*. Não é uma convenção de nomes mas um invariante: o gerador contribui prosa e nunca um facto, e um teste verifica a propriedade, para que uma alteração futura que a violasse falhasse em vez de seguir para produção.

O gerador é instruído a citar os identificadores no meio do texto, e a interface desenha cada citação como um controlo que abre o facto correspondente. A afirmação de que o texto gerado se mantém ligado à sua evidência não é, portanto, uma promessa sobre o prompt; é uma travessia que o leitor pode fazer: da frase para o facto, do facto para o motor, do motor para o ficheiro que o produziu. A Figura 4.7 mostra essa travessia aberta no sistema implantado.

4.8.2 Dois níveis de garantia, e porque diferem

Este trabalho já contém uma guarda de geração. O narrador de alertas (Secção 4.7) usa uma *allowlist de vocabulário fechado* de cerca de duzentas e cinquenta palavras neutras, adotada depois de um exercício adversário abrir vinte e nove furos na blocklist que a precedia e

estabelecer a lição estrutural: o espaço de paráfrases é infinito e uma lista de expressões proibidas é finita.

Um relatório de cinco secções e um analista conversacional não cabem em duzentas e cinquenta palavras. Havia duas opções honestas: aplicar a mesma allowlist e aceitar que o produto quase não poderia dizer nada, ou alargá-la até deixar de ser uma allowlist e passar a ser uma blocklist com outro nome. Não se tomou nenhuma. O sistema passa a ter *dois* níveis de garantia e a declarar a diferença em vez de a esbater, e a razão pela qual diferem é o **risco**, não a conveniência. A Tabela 4.6 põe-nos lado a lado.

Tabela 4.6: Os dois caminhos de geração e o que cada um garante. A última linha é a que interessa: a garantia linguística do caminho puxado é mais fraca, e é declarada e medida em vez de afirmada.

	Alerta (empurrado)	Relatório e analista (puxado)
Como chega ao leitor	Sem ser pedido, no telemóvel	A pedido, na página
Evidência ao lado	Não	Sim, a um clique
Números	Conjunto fechado da evidência	Conjunto fechado <i>por frase</i> , ligado ao facto que essa frase cita
Direção	Sinal obrigatório	Sinal obrigatório
Vocabulário	Allowlist fechada	Blocklist, mais uma allowlist fechada de ressalvas honestas
Atribuição	Validada contra a evidência	Toda a frase que afirma tem de citar um facto
Garantia linguística	Absoluta	Mais fraca, declarada e medida

Um alerta chega sem ser pedido a um dispositivo, sem evidência ao lado; aí a garantia tem de ser absoluta, e o custo de uma allowlist — um leque de expressão mais estreito — vale a pena. Um relatório é pedido por um leitor que já está a olhar para a evidência, com cada frase a carregar os identificadores dos factos que a sustentam. Os perfis de risco diferem, logo as garantias diferem, e fingir o contrário seria exatamente o tipo de afirmação que o resto deste trabalho se esforçou por retirar.

4.8.3 Ligar os números aos factos que os autorizam

A primeira versão da guarda verificava os números contra o pacote como um todo. O ensaio adversário mostrou que isso não é uma guarda mas a sua aparência, e os três achados mais graves partilhavam uma só causa: se qualquer número do pacote pode aparecer em qualquer sítio do texto, então uma frase pode citar um facto e usar o número de outro, e a citação empresta autoridade a uma afirmação que não sustenta. A mesma fraqueza permite apresentar um retorno como se fosse um z-score e permite inverter uma direção usando o valor de sinal oposto de um facto diferente.

A correção não é mais uma regra mas uma mudança de âmbito. O texto é dividido em frases; os identificadores citados *nessa frase* determinam o conjunto de números que essa frase pode usar; e qualquer número fora desse conjunto é uma violação, exista ou não noutro sítio do pacote. A diferença é entre “este número existe algures” e “este número é deste facto”, e só a segunda alguma vez foi a promessa.

Fecharam-se ao mesmo tempo mais quatro fraquezas, e uma delas merece registo porque foi auto-infligida de uma maneira que generaliza. Para tolerar diferenças de formatação, a primeira versão admitia cada valor com várias precisões decimais — o que *cunha* números, já que um z-score de 2,65 escrito sem casas decimais introduz o 3 no conjunto permitido como se um motor o tivesse calculado. Tolerar formatação não pode custar inventar quantidades. As outras foram quantidades escritas por extenso em vez de em dígitos, uma heurística de negação que podia ser usada para desligar a blocklist colocando uma negação por perto, e a inversão de pares ordenados, em que uma afirmação de que nove nomes subiram e três desceram pode ser invertida usando dois números ambos legitimamente presentes.

4.8.4 Comportamento medido

Reportam-se duas quantidades na Tabela 4.7, e medem coisas diferentes. A primeira mede a *guarda*: um corpus adversário de vinte e três ataques, cada um dos quais tem de ser rejeitado. A segunda mede se a guarda está apenas a recusar tudo: um conjunto de oito frases fiéis, cada uma das quais tem de passar. Sem a segunda, uma guarda que rejeitasse todo o texto pontuaria perfeitamente na primeira e pareceria impecável — a mesma exigência de controlo nos dois sentidos que este trabalho aplica aos seus detetores.

Tabela 4.7: Comportamento da guarda de ancoragem, regenerado por um script versionado. **Os três grupos não reproduzem da mesma maneira, e a distinção importa mais do que qualquer número isolado.** O primeiro é determinístico: a guarda é uma função pura e o corpus é fixo, portanto o mesmo código dá sempre o mesmo resultado. O segundo é uma *amostra* de uma corrida — a contagem de secções depende de quantos relatórios se geraram e do que o modelo escreveu — pelo que o que se lê é a taxa e não as contagens. O terceiro não é nem uma coisa nem outra: é uma propriedade que tem de valer em *todas* as corridas, e o número verifica-a em vez de a estimar. Os ataques incluem todos os exploits reproduzidos contra a versão anterior, mantidos como regressões permanentes.

Quantidade	Contagem	Taxa
<i>Determinístico — reproduz exactamente</i>		
Ataques adversários bloqueados	23 / 23	1,000
Frases de controlo fiéis aceites	8 / 8	1,000
<i>Amostrado — uma corrida de seis relatórios</i>		
Secções geradas conformes	27 / 27	1,000
<i>Invariante — tem de valer em todas as corridas</i>		
Secções entregues com violação	0	0,000

Dois destes números precisam de uma ressalva que eles próprios não podem dar. A linha amostrada é uma corrida única: outra corrida gera outro número de secções e pode ver o modelo escrever texto que a guarda rejeita, caso em que o que transita é a *taxa* de conformidade e não as contagens. Enunciá-la como constante seria reivindicar uma estabilidade que só o grupo determinístico tem. E a linha invariante é *circular*, porque o mesmo verificador decide e avalia; reporta-se porque um valor diferente de zero indicaria um defeito no caminho de entrega, não porque estabeleça fidelidade de forma independente. O corpus adversário existe para a complementar, e os riscos residuais que o corpus não cobre estão enunciados na Secção 6.5 em vez de ficarem por descobrir.

O que a guarda rejeita é tão informativo como o que aceita, e também isto é uma propriedade da corrida e não uma grandeza fixa. Ao longo das corridas, as rejeições têm sido de linguagem proibida e não de números fabricados: causa afirmada, conselho e previsão. O modelo, por outras palavras, procura exatamente os três registos que este sistema recusa, e fá-lo com frequência suficiente para a guarda estar a trabalhar continuamente em vez de decorar um caminho que teria sido seguro de qualquer maneira. A frequência com que intervém depende também de quão precisamente o gerador é instruído: apertar a instrução para citar cada registo na mesma frase do número que ele autoriza aumentou a proporção de respostas que passam sem alteração, sem mudar a regra que está a ser aplicada — que é a direção esperada, já que a guarda estava a rejeitar texto verdadeiro mas insuficientemente citado.

4.8.5 A linguagem natural como segunda interface

O analista responde a perguntas sobre os mesmos pacotes. A sua primeira etapa não escreve prosa nenhuma: traduz a pergunta num plano pequeno e validado — que âmbito, que ativo, que tipos de evidência — e cada campo desse plano é verificado contra um conjunto fechado antes de ser usado, portanto um modelo não pode inventar navegação. Um router determinístico, que resolve pronomes a partir do que o leitor está a ver, corre como alternativa; existe para que a interface conversacional continue a funcionar sem chave de API nenhuma, o que é uma restrição fundadora deste trabalho e não um detalhe de implantação.

O plano traz também uma ação para a interface executar, portanto pedir o gráfico do último mês de uma empresa move a vista em vez de a descrever. É isto que faz da linguagem natural uma segunda interface sobre os mesmos dados, em vez de uma caixa de texto ao lado do produto. O produto continua utilizável sem nunca se falar com ele, que é a relação pretendida: o analista aprofunda a análise, não é a análise.

4.9 A Vida de Um Alerta

O que faz toda a pipeline, concretamente, da fonte bruta ao telemóvel? A resposta mais limpa é seguir um alerta *real* por cada fase. O caso é a mesma decisão de produção decomposta na Tabela 3.5: a 12 de julho de 2026 o canal público recebeu um alerta para a Meta sobre a manchete “*Mark Zuckerberg Said Meta’s AI Bets ‘Haven’t Come to Fruition Yet’ as Shares Fell 5%*”. A Tabela 4.8 percorre as fases com os valores que o sistema efetivamente calculou; cada linha é verificável no registo de histórico partilhado que o dashboard lê.

As mesmas portas, vistas em agregado, são a resposta do sistema à fadiga de alertas. A Figura 4.8 mostra os primeiros cinco dias de operação ao vivo: a varredura capturou 944 manchetes relevantes distintas nos dez nomes que a watchlist tinha então, e o canal recebeu 42 alertas, uma seletividade de 22:1 concentrada nos três nomes onde a evidência passou todas as portas. As notícias fluíram para todas as empresas; os alertas aconteceram apenas onde um precedente forte e uma pontuação de triagem material coincidiram. (Uma nota honesta: o teto diário por ticker entrou em produção a 11 de julho, pelo que os dois dias mais precoces mostram mais alertas por nome do que o estado estacionário.)

Um alerta que se contradizia a si próprio. Compor uma explicação a partir de vários componentes independentes cria um modo de falha que nenhum componente isolado consegue detetar: cada linha pode estar certa e a mensagem no seu conjunto ser incoerente.

Tabela 4.8: A vida de um alerta real (META, 12 de julho de 2026), fase a fase. Cada valor é real: a mensagem é preservada verbatim no histórico de alertas partilhado, e a pontuação de triagem é decomposta termo a termo na Tabela 3.5.

Fase (porta)	O que aconteceu para este alerta
1. Obter	A varredura agendada puxa as notícias de empresa da semana para cada ticker da watchlist da API de notícias gratuita.
2. Filtro de relevância	A manchete nomeia a empresa (“Meta”, “Mark Zuckerberg” estão na lista de aliases do ticker) e não corresponde a nenhum padrão de boilerplate de resumo de mercado: mantida.
3. Captura (KB viva)	A manchete é embebida (MiniLM, 384-d) e guardada como um caso <i>pendente</i> ; matura em precedente quando o seu próprio impacto a +5 dias se torna observável.
4. Frescura	Datada dentro da janela de dois dias: elegível (a mesma história não pode voltar a alertar durante dias).
5. Recuperação	As bases de conhecimento são ordenadas por cosseno com decaimento por idade; top três: MSFT 2023-11-07 ($s = 0.46$, +2.70% em 5d), NVDA 2023-08-02 ($s = 0.51$, -3.87%), NVDA 2023-09-21 ($s = 0.46$, +5.05%).
6. Chão de evidência	Melhor cosseno $0.51 \geq 0.45$: forte o suficiente para mostrar. Os precedentes discordam na direção, pelo que a mensagem carrega o aviso explícito “ <i>moved in BOTH directions</i> ”.
7. Triagem aprendida	O modelo só-contexto em produção pontua $p = 0.54 \geq 0.5$ (decomposto na Tabela 3.5): não filtrado.
8. Tetos e dedup	Dentro do teto de dois alertas por ticker por dia; não enviado antes por nenhum produtor (dedup do histórico partilhado): mantido.
9. Entrega e registo	Enviado ao canal público de Telegram com a cláusula fixa de não-previsão; anexado verbatim ao histórico partilhado, a partir do qual o dashboard o marca no gráfico de preços.

A leitura dos primeiros trinta alertas que o canal tinha efetivamente enviado encontrou isto em nove deles. Uma linha de comparação com pares reportava que outros nomes do setor se tinham movido no mesmo sentido, e duas linhas abaixo a decomposição de dois fatores reportava que a maior parte do movimento pertencia à empresa. O caso mais gritante tinha a AMD a cair 13,23% enquanto os pares do setor caíam 2,0%, 1,9% e 1,4%. As duas linhas estavam certas. A comparação com pares testava apenas a *direção* dos movimentos vizinhos e nunca a sua *dimensão*, pelo que uma direção partilhada estava a ser reportada como uma explicação partilhada. A comparação passa a ter em conta o movimento mediano dos pares e, quando o sujeito se moveu desproporcionadamente, diz exatamente isso: a direção é partilhada, a dimensão não é. O defeito fica registado aqui porque é invisível a testes de componente por construção, e porque um alerta que se contradiz duas linhas depois destrói precisamente a confiança que todo o resto do sistema foi construído para ganhar.

4.10 Uso Prático e Desenho Responsável

O que é preciso para o correr, e o que exige o uso responsável?




Figura 4.8: Seletividade de produção sobre os primeiros cinco dias ao vivo: manchetes relevantes capturadas (claro) versus alertas efetivamente enviados (escuro), por ticker da watchlist. Todas as contagens são reais, lidas da branch de dados partilhada; a diferença entre as duas barras é o trabalho das portas de qualidade da Tabela 4.8.

O InvestiGator corre como dois pontos de entrada, um por gatilho, cada um a executar um ciclo completo. A implantação de referência corre-os continuamente numa plataforma alojada: um worker repete a varredura num ciclo de sessenta segundos e entrega quaisquer alertas a um canal de Telegram, enquanto um segundo processo serve o dashboard. Uma disposição anterior usava em vez disso um temporizador de integração contínua gratuito, e o afastamento dele é examinado no Capítulo 6, onde medir a latência de entrega mostrou que o agendador nunca foi a restrição vinculativa. Correr o sistema precisa apenas de recursos de dados gratuitos: uma fonte de dados de mercado, uma fonte de notícias de empresa ou RSS (uma chave de API mantida fora do controlo de versões), e a base de conhecimento construída uma vez a partir do corpus. O Apêndice A dá os passos exatos. Os alertas reais entregues durante os testes e pela varredura agendada mostram que o caminho dos dados brutos ao telemóvel do investidor funciona de ponta a ponta. Uma vez ao vivo, as decisões de triagem são também *pós-validadas*: cada decisão registada é rotulada dias depois com o resultado que efetivamente se seguiu, dando monitorização de precisão e calibração ao vivo e dados de treino frescos (Secção 3.3.4).

Dois limites práticos merecem ser enunciados com clareza. A base de conhecimento que o sistema implantado consulta é muito menor do que o corpus multi-ano construído para a avaliação: a base completa não cabe na camada de alojamento gratuita, pelo que a produção corre sobre um subconjunto curado juntamente com os casos que o próprio sistema captura e matura. Isto é um limite de implantação e não de método, e é a razão pela qual os precedentes ao vivo são mais rasos do que os avaliados. E o InvestiGator é um protótipo de apoio à decisão, não um serviço de produção: sem contas de utilizador, sem persistência para além do ficheiro da base de conhecimento. Estes são passos ordinários de protótipo a produto.

Pôr um transformador em produção sob a restrição de free tier

Um problema de implantação merece relato próprio, porque é onde a restrição de free tier mais apertada e onde a solução é um resultado de engenharia genuíno, e não um contorno.

O componente de retrieval avaliado no Capítulo 5 é um sentence transformer, e a forma habitual de o correr é a sua implementação de referência sobre uma framework de deep learning. Essa stack tem várias centenas de megabytes e pressupõe um ambiente que o alojamento gratuito não oferece de forma fiável. As resoluções ingênuas são ambas más: manter a stack pesada e aceitar que a implantação pública não corre, ou substituir em produção por um modelo mais leve mas diferente, avaliando em silêncio uma coisa e entregando outra. A segunda é pior do que a primeira, porque faz a avaliação descrever um sistema que nenhum utilizador toca.

A resolução adotada foi exportar o *mesmo* modelo para ONNX com quantização int8, cerca de 23 MB, a correr em CPU sem qualquer framework de deep learning presente, e depois verificar que a substituição é fiel antes de confiar nela. Correram-se duas verificações contra a implementação de referência, sobre 503 consultas à base de conhecimento curada. A concordância de embeddings deu um cosseno médio de 0.992 com um mínimo de 0.983, sendo o resíduo ruído de quantização e não um espaço semântico diferente. A concordância de *retrieval* importa mais, porque o produto devolve vizinhos e não vetores, e tem de ser medida na configuração em que o produto de facto corre: a base de conhecimento guarda embeddings calculados uma vez pela implementação de referência, e só a consulta que chega passa pelo modelo exportado. Nesse plano, os dois motores devolvem um top-3 idêntico em 76% das consultas e partilham 95% dos vizinhos recuperados. Onde discordam, discordam por um fio: a diferença mediana de similaridade entre o vizinho que um motor escolheu e o que o outro pôs no seu lugar é 0.006, o que é um empate e não um tema diferente.

Dois pontos de método merecem registo, porque cada um foi um erro apanhado a medir. O primeiro é que uma versão anterior desta verificação re-embebia a base inteira com cada motor. Isso duplica o erro de quantização e responde a uma pergunta que a implantação nunca faz, deprimindo a concordância em conformidade. O segundo é que a mesma verificação foi originalmente corrida sobre 23 consultas e reportou 20 como idênticas. Essa estatística não reproduz: outra amostra do mesmo tamanho dá 12. A instabilidade estava no tamanho da amostra e não no motor, razão pela qual os valores acima são calculados sobre uma ordem de grandeza mais de consultas e pela qual a grandeza robusta a citar é a quota de vizinhos partilhados e não a contagem de listas exatamente idênticas.

Seguem-se duas propriedades, e ambas importam para além da conveniência. Primeiro, o modelo avaliado e o modelo implantado são o mesmo modelo, pelo que os números do Capítulo 5 descrevem o que o utilizador recebe de facto. Segundo, o artefacto do modelo é descarregado sob demanda e verificado contra um resumo SHA256 fixado antes de ser usado, o que torna a dependência auditável: um download substituído ou corrompido falha fechado, em vez de mudar silenciosamente o que o sistema entende por “semelhante”. Para um sistema cuja afirmação central é que o seu raciocínio pode ser verificado, a proveniência dos pesos faz parte dessa afirmação.

Um modelo mais pequeno tem ainda assim de caber na máquina onde corre, e vale a pena registar a forma como essa lição chegou, porque não podia ter chegado de outra maneira. Mudado para um contentor com 512 MB de memória, o worker entrou em ciclo de falha por volta de 1,4 GB. Duas explicações plausíveis estavam erradas: nem o conjunto de threads do motor de inferência nem o tamanho do ramo de dados explicavam o valor. Uma sonda a

correr dentro do próprio contentor mostrou que o arranque consumia apenas 281 MB, o que localizou o pico na varredura e não na carga, e a causa ficou então óbvia em retrospectiva: o runner embebia todas as manchetes novas num único lote, e numa máquina sem estado anterior *todas* as manchetes são novas. Na máquina do autor o ficheiro de pendentes já existia, pelo que o pico nunca ocorria e nenhuma quantidade de testes locais o teria produzido. O embedding passa a correr em lotes de tamanho fixo.

A correção convidava a uma suposição que vale a pena reportar porque medi-la a refutou. A frase natural a escrever é que fatiar em lotes não pode alterar resultados, visto que os mesmos textos são codificados de qualquer das formas. É falso para este modelo: com quantização int8 o preenchimento dentro de um lote perturba a aritmética, e as diferenças medidas na fronteira dos lotes chegaram a 0,022 em similaridade do cosseno. A propriedade que de facto importa foi então testada diretamente em vez de assumida, e essa aguenta-se: os três vizinhos recuperados no topo foram idênticos em 8 de 8 sondagens. A distinção é a mesma em que assenta a validação ONNX acima. O que o produto deve ao utilizador são os mesmos *vizinhos*, não vetores idênticos ao bit, e só uma dessas duas afirmações sobrevive à medição.

A operação ao vivo também ensinou uma lição de engenharia da forma honesta. Durante os primeiros dias de implantação continua o caminho de mercado ficou em silêncio: a fonte de preços gratuita bloqueia os endereços de rede partilhados dos runners alojados, e com uma única fonte e sem fallback, a varredura simplesmente não recebia dados. A falha foi diagnosticada a partir dos próprios registos do sistema (os alertas de notícias continuavam a fluir enquanto nem um resumo de mercado aparecia, o que isolou a fonte de preços como a causa) e respondida com engenharia e não com uma mudança de parâmetro: os preços diários vêm agora através de uma cadeia de fornecedores gratuitos tentados por ordem, e a verificação de cotação em tempo real, que usa uma fonte autenticada e por isso fiável, foi promovida do vigia opcional para cada varredura agendada. O episódio é reportado porque é instrutivo: uma única fonte de dados gratuita é um ponto único de falha, e um sistema que regista o seu próprio comportamento é o que torna tal falha diagnosticável de todo.

Uma ferramenta destinada a não-especialistas levanta também duas questões de desenho responsável. A primeira é a *fadiga de alertas*: uma ferramenta que dispara demasiadas vezes ensina o utilizador a ignorá-la. O gatilho de mercado trata disto ao disparar apenas em extremos relativos à volatilidade. O lado das notícias é tratado pelo gate de triagem, e o que esse gate pode honestamente dizer que faz exige cuidado, porque a medição estreitou a afirmação depois da implantação.

Foi introduzido para *ordenar* o fluxo e largar os itens menos materiais, e em dados retidos do corpus de treino é exactamente isso que faz (Capítulo 5). Na população que encontra em produção, não: a sua ordenação é indistinguível do acaso (Secção 6.5). O que sobrevive à medição é mais estreito e continua a ser real. O gate suprime cerca de três quintos das decisões de notícia, pelo que é um controlo de *volume* eficaz, e o volume que remove é limitado por uma regra que o leitor pode inspecionar em vez de por uma quota; e cada item que passa leva a razão aditiva exacta por que passou, que um corte simples por ordem de chegada ou por contagem diária fixa não conseguiria fornecer. A afirmação de que os itens que mantém são os materiais é retirada para o cenário implantado e mantida só onde foi medida.

O componente é mantido em vez de removido por uma razão que merece ser enunciada, já que removê-lo também seria defensável. O gate é a parte instrumentada da pipeline:

cada decisão que toma é registada e mais tarde rotulada pelo desfecho, que é o que tornou o achado negativo acima observável de todo. Desligá-lo terminaria a medição que revelou o problema e removeria o único canal pelo qual uma mudança nos filtros a montante, ou na mistura de notícias, poderia ser detetada como mudança na utilidade do score. Um componente que não está a ganhar o seu lugar mas que o diz vale mais do que silêncio. A avaliação do Capítulo 5 reporta, em conformidade, uma métrica de precisão-dentro-do-orçamento-diário, e o Capítulo 6 reporta o que o mesmo mecanismo consegue ao vivo, que não é o mesmo número. A segunda é a *dependência excessiva*: uma explicação confiante pode ser merecedora de mais confiança do que a sua evidência justifica (Secção 2.4). O desenho atual mitiga isto ao mostrar os precedentes individuais e a sua dispersão em vez de um número solitário, e ao recusar a previsão em cada alerta. Duas mitigações adicionais foram acrescentadas depois de se lerem os alertas que o canal tinha efectivamente enviado, e ambas nasceram de defeitos e não de previdência. Os precedentes passaram a ser duplicados pelo texto da manchete: a chave anterior juntava data, ticker e manchete, o que parece a escolha mais completa das duas e é precisamente por isso que falhava, porque um acontecimento macroeconómico recuperado sob três tickers diferentes produzia três chaves diferentes e era apresentado como três casos independentes. No histórico ao vivo isto afectava 18 dos 165 alertas de notícia com dois ou mais precedentes, ou seja 11%, e o alerta que o denunciou dizia “3 de 3 casos mostrados desceram” quando era um acontecimento visto três vezes. Não é uma imprecisão de apresentação mas uma afirmação falsa sobre o peso da evidência, e o leitor não tem como distinguir as duas coisas a partir do texto. Um agrupamento recuperado que discorde na direcção passou também a ser sinalizado de forma explícita, o que importa porque a semelhança temática quase não carrega informação direccional (Capítulo 5).

4.11 Conclusões do Capítulo

O InvestiGator é uma pipeline de dois gatilhos e duas camadas construída a partir de alguns objetos claros (um caso, a base de conhecimento, um resultado de anomalia) e componentes de responsabilidade única, com a explicabilidade embutida ao compor cada alerta diretamente a partir do próprio cálculo do sistema, e uma pontuação de triagem treinada opcional, desligada por defeito e honestamente rotulada, sobreposta por cima. O próximo capítulo põe os componentes centrais à prova sobre dados reais.

Capítulo 5

Estudos de Caso

Este capítulo avalia o InvestiGator através de sete estudos de caso sobre dados reais, em dois grupos. Os primeiros quatro testam o desenho central: o gatilho de anomalias em ações de volatilidade muito diferente; o motor de correlação e os casos que recupera; um alerta completo, e se a sua explicação é fiel; e o modelo de triagem de materialidade treinado e testado sobre o corpus multi-ano. Os últimos três examinam o mesmo sistema por fora, perguntando o que ele *não* sabe: se o espaço de embeddings codifica que tipo de acontecimento uma manchete relata, quanto custaria uma garantia livre de distribuição sobre o score de triagem, e quão longe o presente implantado se afastou do corpus de treino. Cada um desses três termina numa decisão de *não* mudar a produção, tomada sobre a evidência. Cada número abaixo vem de um script versionado com uma semente fixa, a avaliação seguiu o plano estabelecido no Capítulo 3, e cada estudo enuncia as suas próprias limitações.

5.1 Montagem Experimental Comum

O que partilham os quatro estudos? São usados três conjuntos de dados reais. Para o gatilho de anomalias, os preços de fecho diários dos quinze tickers de grande capitalização listados na data card foram obtidos de um serviço de dados de mercado gratuito sobre uma janela fixa de três anos (junho de 2023 a junho de 2026), produzindo 750 log-retornos diários por ticker. Para o motor de correlação, 3,714 manchetes reais de notícias financeiras para os mesmos tickers foram recolhidas através de um serviço de notícias de empresa gratuito, abrangendo cinco setores (tecnologia, banca, energia, saúde e consumo de base). Esse corpus cobre **27 dias** (28 de maio a 24 de junho de 2026), que é a janela que a camada gratuita devolve; as consequências de uma janela tão curta, tanto para o que o estudo pode afirmar como para o nome que os seus vizinhos recuperados devem ter, estão na Secção 3.2.3. Este é o corpus de avaliação de recuperação, distinto da camada FNSPID desenhada documentada na data card do Capítulo 3. Para o estudo de triagem de materialidade (Estudo de Caso 4), o subconjunto multi-ano do FNSPID da data card *foi* construído, pela pipeline de streaming, e alinhado aos preços: 79,753 exemplos (manchete, ticker, dia do evento) sobre 2018–2023. As manchetes de notícias e os preços são normalizados para um esquema comum para que as camadas viva e histórica sejam diretamente comparáveis. O corpus recente é suficiente para a experiência de recuperação; uma análise de impacto multi-ano sobre a base de conhecimento de recuperação fica para trabalho futuro. As garantias de sem-lookahead, reprodutibilidade e honestidade da Secção 3.6 aplicam-se a cada estudo abaixo.

5.2 Estudo de Caso 1: Detecção Transparente de Anomalias em Ações dos EUA

Será um z-score deslizante um melhor detetor universal de movimentos abruptos do que um simples limiar de percentagem fixa? **Sim, e claramente:** o z-score (Chandola, Banerjee e Kumar 2009) dispara a uma taxa quase-constante em ações de volatilidade muito diferente, onde a regra fixa não.

A montagem é a seguinte. Uma anomalia “verdadeira” é aproximada por um movimento diário no percentil superior dos próprios retornos *daquela ticker* ($|r| \geq$ o percentil 99); a linha de base é um único limiar global ($|r| \geq 3\%$) aplicado a cada ticker. Como esse rótulo é ele próprio relativo à volatilidade, é apenas evidência de apoio; o argumento primário, feito primeiro abaixo, não precisa de rótulo algum.

Consistência da taxa de disparo (argumento principal). A evidência mais forte é independente de qualquer rótulo. Um bom detetor universal deve disparar a uma taxa comparável entre instrumentos; um limiar cego à volatilidade não consegue. A Tabela 5.1 e a Figura 5.1 mostram que o limiar fixo dispara em cerca de 1% dos dias para uma ação calma (KO) mas em cerca de 35% dos dias para uma volátil (TSLA, NVDA), ao passo que o z-score dispara a uma taxa quase-constante ($\approx 2\text{--}3\%$) para todos os tickers. A amplitude das taxas de disparo entre tickers é mais de vinte vezes mais apertada para o z-score (0.015 versus 0.344), confirmando que normalizar pela volatilidade recente torna a detecção comparável em todo o mercado.

Tabela 5.1: Taxa de disparo entre os quinze tickers (três anos de dados diários).

Método	Taxa mín.	Taxa máx.	Amplitude
z-score (janela 20, ± 3)	0.016	0.031	0.015
Limiar fixo ($ r \geq 3\%$)	0.009	0.353	0.344




Figura 5.1: Taxa de disparo por ticker. O limiar de percentagem fixa varia dramaticamente com a volatilidade de cada ação, enquanto o z-score é estável em todos os tickers.

Um exemplo trabalhado. A Figura 5.2 mostra o detetor a trabalhar numa única ação volátil (Tesla) sobre a janela de três anos. Os dias assinalados não são simplesmente os maiores movimentos brutos: são os movimentos que são grandes *relativamente à própria volatilidade recente do ativo*, que é exatamente o comportamento que um limiar de percentagem fixa não consegue reproduzir. Sobre este período o detetor assinala 16 dos 750 dias de negociação (cerca de 2%), consistente com a taxa de disparo quase-constante reportada acima.




Figura 5.2: Log-retornos diários de uma ação volátil (Tesla) sobre a janela de avaliação, com os dias assinalados pelo detetor de z-score (janela 20, $k = 3$) marcados. O detetor responde à surpresa relativa à volatilidade em vez do tamanho absoluto do movimento.

Para o tornar concreto, considere-se a maior surpresa da janela. A 24 de outubro de 2024, na sequência dos seus resultados trimestrais, o log-retorno diário da Tesla foi $+0.198$, um movimento de preço de cerca de $+22\%$. Medido contra os vinte dias anteriores, cujo log-retorno médio foi -0.92% e desvio-padrão 2.73% , isto é um z-score de $+7.6$, muito para além do limiar $k = 3$ (Tabela 5.2). A mesma regra que deixa uma oscilação comum de dois por cento por assinalar identifica esta reação a resultados de imediato, e expõe as quantidades que justificam o alerta: o movimento, a norma recente contra a qual é julgado, e o z-score resultante, que é o que o motor de explicação mostra depois ao investidor.

Tabela 5.2: Anomalia trabalhada: o movimento pós-resultados da Tesla a 24 de outubro de 2024 (janela 20, $k = 3$); números reais e reproduzíveis.

Quantidade	Valor
Média dos log-retornos dos 20 dias anteriores, μ	-0.92%
Desvio-padrão dos 20 dias anteriores, σ	2.73%
Log-retorno do dia, r (um movimento de preço de $\approx +22\%$)	$+19.82\%$
z-score, $(r - \mu)/\sigma$	$+7.61$
Assinalado a $k = 3$?	sim

Concordância com o rótulo-proxy (apoio). Contra o rótulo de movimentos extremos por ticker, o z-score atinge um F_1 de 0.516 (precisão 0.381, recall 0.800) versus 0.218 do limiar

fixo (precisão 0.122, recall 0.992): a regra fixa apanha quase todos os grandes movimentos brutos mas a precisão muito baixa. Uma ablação de janela (Figura 5.3) mostra o F_1 a subir com a janela de estimação (0.385, 0.516 e 0.678 para 10, 20 e 60 dias), indicando que uma estimativa de volatilidade mais longa produz uma linha de base mais estável antes de começar a saturar. Este rótulo é ele próprio relativo à volatilidade, pelo que alguma circularidade é inevitável; é por isso que a consistência da taxa de disparo acima, que não depende de rótulo, é tratada como a evidência primária.




Figura 5.3: Efeito do comprimento da janela de estimação no F_1 do detetor contra o proxy de movimentos extremos. Uma janela mais longa produz uma linha de base de volatilidade mais estável e maior concordância, com retornos decrescentes nas janelas mais longas.

Regra estatística versus detetor aprendido. O protocolo da Secção 3.6.3 fecha com um desafio: será que um detetor *aprendido*, dada exatamente a mesma informação, bateria a regra transparente? Uma Isolation Forest (F. T. Liu, Ting e Zhou 2008) foi treinada causalmente por ticker sobre o retorno de cada dia e a volatilidade dos vinte dias anteriores, ajustada apenas sobre um segmento inicial de 250 dias, e ambos os detetores foram pontuados sobre a região restante idêntica. O modelo aprendido perde claramente: contra o proxy de movimentos extremos atinge um F_1 de 0.271 (precisão 0.159, recall 0.913), enquanto o z-score na mesma região atinge 0.530 (precisão 0.407, recall 0.761); a floresta também dispara a taxas que variam entre tickers por 0.135, duas ordens de grandeza menos uniforme do que os 0.015 do z-score, falhando o requisito de consistência que motiva o desenho. A comparação, e não qualquer pressuposto, é o que justifica manter a regra estatística em produção: dada informação causal idêntica, o detetor interpretável não foi apenas mais simples mas melhor.

Extensão: um segundo detetor aprendido, e uma segunda estimativa de volatilidade. Restam duas objeções naturais: talvez um detetor aprendido *diferente* vencesse, e talvez uma estimativa de volatilidade mais adaptativa vencesse. Ambas foram testadas sob o protocolo causal idêntico (Secção 3.6.3), numa nova corrida cuja linha do z-score reproduz os valores congelados acima exatamente (a floresta desloca-se na terceira casa decimal porque a fonte de preços gratuita reajusta os fechos históricos retroativamente). A Tabela 5.3 e a Figura 5.4 reportam ambas as respostas. O Local Outlier Factor (Breunig et al. 2000), a alternativa

baseada em densidade do Capítulo 2, comporta-se como a floresta: recupera quase tudo (0.989) com precisão muito baixa (0.163), fica num F_1 de 0.280, e dispara a taxas que variam entre tickers por 0.183, o menos consistente dos três. A regra transparente bate ambos os detetores aprendidos sobre a mesma informação.

A questão da volatilidade produziu a resposta mais interessante, e é reportada exatamente como se revelou. Substituir o desvio-padrão deslizante por uma estimativa ponderada exponencialmente (RiskMetrics, $\lambda = 0.94$), o primeiro passo rumo à família GARCH, *melhora* substancialmente a concordância com o proxy de movimentos extremos: com o mesmo recall (0.800), a precisão sobe de 0.381 para 0.568, elevando o F_1 de 0.516 para 0.664, com as taxas de disparo por ticker ligeiramente *mais* uniformes (0.012 versus 0.015). O mecanismo é o próprio agrupamento de volatilidade: depois de um choque, uma janela deslizante dilui o novo regime por vinte pesos iguais, ao passo que a estimativa exponencial absorve-o de imediato e deixa de re-assinalar dias comuns que se seguem. A experiência foi desenhada para licenciar a frase “o GARCH acrescentaria pouco”, e não a licença; o que mostra, em vez disso, é que o primeiro passo adaptativo já ajuda *neste proxy*. O detetor em produção mantém a regra deslizante, porque “a média e a dispersão dos últimos vinte dias” é explicável a um não-especialista numa frase enquanto os pesos exponenciais não o são, mas o ganho é registado como trabalho futuro validado e não especulativo, a uma linha de configuração de distância. A própria circularidade relativa à volatilidade do proxy, assumida ao longo deste estudo de caso, aplica-se aqui igualmente.

Tabela 5.3: Comparação estendida sob o protocolo causal congelado. Topo: detetores sobre a região pontuada e as features idênticas. Fundo: a mesma regra de z-score com duas estimativas de volatilidade, sobre a região de avaliação completa. Regenerada deterministicamente.

Detetor (mesma região)	Precisão	Recall	F_1	Amplitude da taxa
z-score (regra em produção)	0.407	0.761	0.530	0.017
Isolation Forest	0.158	0.913	0.269	0.135
Local Outlier Factor	0.163	0.989	0.280	0.183
Estimativa de volatilidade (z-score)				
σ deslizante, 20 d (em produção)	0.381	0.800	0.516	0.015
σ EWMA ($\lambda = 0.94$)	0.568	0.800	0.664	0.012

5.3 Estudo de Caso 2: Recuperação de Precedentes Notícia–Mercado

Será que a recuperação semântica encontra precedentes genuinamente análogos, melhor do que linhas de base triviais? **Sim:** sobre dados reais os embeddings batem todas as linhas de base por uma margem larga.

A métrica é a precisão@ k com um proxy de setor, num cenário *cross-ticker*: para cada consulta as k manchetes mais similares *de outras empresas* são recuperadas, e a precisão é a fração que corresponde ao setor da consulta. Excluir a própria empresa da consulta descarta a vitória trivial de emparelhar uma empresa com as suas próprias notícias, e testa antes a analogia temática. Mesmo-setor é um substituto automático para “análogo”, pelo




Figura 5.4: A comparação estendida num relance. Esquerda: sobre features causais idênticas, a regra transparente do z-score bate ambos os detetores aprendidos. Direita: a estimativa de volatilidade ponderada exponencialmente supera a deslizante no proxy, um achado reportado como se revelou; a regra deslizante mantém-se em produção pela explicabilidade, com o ganho da EWMA registado como trabalho futuro validado.

que a métrica mostra se as notícias recuperadas são on-theme, não se uma pessoa as chamaria úteis; essa lacuna é real, e um estudo humano é trabalho futuro. Para mostrar que o resultado não está ligado a um só modelo, dois modelos Sentence-BERT (Reimers e Gurevych 2019) (o leve MiniLM e o maior MPNet) são comparados contra uma linha de base lexical (hashing) e duas triviais, aleatória (a taxa-base do setor) e recência. Quinhentas consultas foram amostradas em cada uma de cinco corridas (sementes 42–46); a Tabela 5.4 reporta a média e o desvio-padrão.

Tabela 5.4: Precisão@ k cross-ticker por setor, média $\pm$ dp sobre cinco corridas (3,714 manchetes reais, cinco setores).

Método	P@5	P@10
SBERT (MiniLM, por defeito)	0.514 $\pm$ 0.015	0.478 $\pm$ 0.011
SBERT (MPNet)	0.538 $\pm$ 0.011	0.506 $\pm$ 0.010
Linha de base lexical (hashing)	0.346 $\pm$ 0.011	0.314 $\pm$ 0.008
Recência	0.126 $\pm$ 0.006	0.106 $\pm$ 0.005
Aleatória (taxa-base)	0.240 $\pm$ 0.004	0.240 $\pm$ 0.004

Como a Tabela 5.4 e a Figura 5.5 mostram, o modelo MiniLM por defeito atinge uma precisão@5 de 0.514, cerca de 2.1 vezes a taxa-base aleatória (0.240) e bem acima da linha de base lexical (0.346). O modelo MPNet mais forte faz ligeiramente melhor (0.538), o que sugere que a vantagem pertence aos embeddings semânticos em geral e não a um modelo particular; os pequenos desvios-padrão (cerca de 0.01) mostram que a diferença é robusta e não um artefacto de amostragem. A recência tem o pior desempenho, abaixo até da taxa-base aleatória, pelo que simplesmente trazer as notícias mais recentes à superfície não substitui a correspondência semântica. O ganho sobre as linhas de base aleatória e lexical é a medida honesta do valor acrescentado pelos embeddings.




Figura 5.5: Precisão@ k cross-ticker por setor. O SBERT excede claramente as linhas de base lexical, de recência e aleatória; as barras de erro mostram ± 1 desvio-padrão sobre as cinco corridas.

Ver o espaço. O próprio espaço de embeddings, até aqui apenas esboçado conceptualmente (Figura 3.6), pode ser mostrado a sério. A Figura 5.6 é uma projeção por componentes principais da base de conhecimento em produção, todos os 2,016 casos com os seus genuínos embeddings MiniLM de 384 dimensões, coloridos por setor, com uma consulta ao vivo (o exemplo trabalhado do Capítulo 3) marcada como uma estrela e os seus três vizinhos recuperados circulos. Seguem-se duas leituras honestas. Mesmo esta sombra bidimensional, que preserva apenas 8.6% da variância, coloca a consulta dentro da sua vizinhança temática, e os três casos recuperados (todas histórias de procura de semicondutores, com cossenos 0.58–0.61 no espaço completo) situam-se visivelmente adjacentes a ela. E os setores *não* se separam com nitidez em duas dimensões, que é exatamente por que o sistema ordena por cosseno no espaço completo de 384 dimensões e não em qualquer projeção: a imagem é para intuição, a ordenação não é feita aí.

Medição de impacto. Para cada precedente recuperado o motor reporta o retorno pós-evento observado a +1, +3 e +5 dias de negociação, medido a partir do fecho do dia do evento ao estilo de um estudo de evento (Brown e Warner 1985). Estes números são resultados observados apresentados como evidência, nunca uma previsão. Sobre a base de conhecimento trabalhada os impactos medidos são direcionalmente coerentes (por exemplo, o cluster de notícias de ameaça competitiva no estudo de caso ponta a ponta abaixo é seguido de retornos de um dia uniformemente negativos), o que dá validade aparente à medição; um estudo de impacto multi-ano rigoroso sobre o corpus FNSPID completo é identificado como trabalho futuro.

Recuperação por setor. O número agregado esconde variação útil entre setores. A Tabela 5.5 e a Figura 5.7 decompõem a recuperação pelo setor da consulta, usando toda a população de cada setor como consultas (para que os números sejam exatos e não amostrados). Duas leituras importam. A precisão@5 bruta é mais alta na tecnologia (0.712), mas em grande parte porque a tecnologia domina o corpus (47% das manchetes) e por isso tem uma taxa-base aleatória alta (0.429); a medida cross-setor justa é o *lift* sobre essa taxa-base. Por essa medida o motor acrescenta mais valor na **energia** (+0.377) e na **saúde**




Figura 5.6: A base de conhecimento em produção projetada em duas dimensões (PCA sobre os embeddings MiniLM reais; os eixos mostram a variância que cada componente preserva). As cores são setores; a estrela é a consulta “Nvidia demand surges on AI chip orders”; os círculos marcam os seus 3 vizinhos recuperados de topo. A projeção é uma sombra para intuição: a recuperação ordena por cosseno no espaço completo de 384 dimensões. Regenerada deterministicamente.

(+0.348), setores cujo vocabulário é distintivo (produção, output, barris; ensaio, fármaco, aprovação), e o menos no **consumo** (+0.100), cujas manchetes são mais genéricas e se sobrepõem tematicamente a outros setores. A recuperação é positiva em todos os setores, mas o seu benefício é maior onde a linguagem do domínio é mais específica.

Porque alguns setores recuperam melhor: um olhar qualitativo. A diferença por setor tem uma explicação concreta, visível em consultas individuais. Na tecnologia, empresas diferentes partilham genuinamente temas: uma manchete sobre os aceleradores de data-center da NVIDIA recupera, dos feeds da Microsoft, Meta e Alphabet, artigos sobre a mesma vaga de competição por chips de IA (Estudo de Caso 3), pelo que a precisão cross-ticker é alta. O setor do consumo comporta-se de forma diferente. Olhando para a vizinhança bruta (antes de a restrição cross-ticker ser aplicada), uma consulta sobre o guidance de mercearia da Walmart recupera sobretudo itens da própria Walmart mais uma história macro de “vendas a retalho nos EUA” veiculada em feeds bancários: adjacente no tema, mas não um análogo de consumo de outra empresa de consumo. Uma vez excluído o próprio ticker da consulta, como a métrica exige, resta pouco material genuinamente relevante, que é por que o lift cross-ticker do consumo é baixo. Uma consulta sobre a Coca-Cola recupera quase só outros itens da Coca-Cola, sobre o seu poder de fixação de preços e volumes de bebidas, que simplesmente não se assemelham às notícias de tráfego de loja da Walmart. O rótulo partilhado “consumo” é demasiado amplo: as notícias dos seus membros são idiossincráticas, pelo que os análogos cross-ticker são escassos e o lift sobre a taxa-base é pequeno. Este é o

5.4. Estudo de Caso 3: Alerta de Ponta a Ponta e Fidelidade da Explicação

Tabela 5.5: Precisão@ k cross-ticker por setor (consultas de toda a população, MiniLM).

Sector	N	P@5	P@10	Aleatório	Lift P@5
Tecnologia	1736	0.712	0.675	0.429	+0.283
Energia	497	0.448	0.408	0.072	+0.377
Saúde	494	0.419	0.379	0.071	+0.348
Banca	496	0.272	0.228	0.072	+0.200
Consumo	491	0.171	0.150	0.071	+0.100

Nota: o lift é a precisão@5 menos a taxa-base aleatória, calculado a partir de valores não arredondados; pode diferir das colunas arredondadas por ± 0.001 .




Figura 5.7: Precisão@5 por setor contra a taxa-base aleatória. A recuperação excede a taxa-base em todos os setores; a diferença (lift) é maior na energia e na saúde, cujo vocabulário é mais distintivo, e menor no setor amplo do consumo.

padrão que os números mostram, e aponta para um refinamento claro para trabalho futuro: agrupar por temas mais finos em vez de por setor.

5.4 Estudo de Caso 3: Alerta de Ponta a Ponta e Fidelidade da Explicação

Será que um alerta completo se sustenta, e a sua explicação é fiel? **Sim, fiel por construção.** Para ver o gatilho de notícias de ponta a ponta, tome-se uma manchete nova da NVIDIA, “Nvidia raises guidance on surging demand for AI data-centre accelerators”. O sistema embebe-a, recupera os precedentes mais similares da base de conhecimento construída sobre o corpus de notícias reais, e compõe o alerta abaixo (cinco precedentes de topo, horizonte de um dia):

```
News alert for NVDA
"Nvidia raises guidance on surging demand for AI data-centre
accelerators"
```

Potential impact (from 5 similar past events): average 1-day move:
-1.97%

Historical precedents:

- 2026-06-24 MSFT (sim 0.68) +1d -3.46%: "Qualcomm debuts line of AI data center chips..."
- 2026-06-24 NVDA (sim 0.68) +1d -1.64%: "Qualcomm debuts line of AI data center chips..."
- 2026-06-24 META (sim 0.68) +1d -2.65%: "Qualcomm debuts line of AI data center chips..."
- 2026-06-24 GOOGL (sim 0.64) +1d -0.46%: "This AI Infrastructure Stock Could Be Bigger Than Nvidia..."
- 2026-06-24 NVDA (sim 0.58) +1d -1.64%: "Tecn Accelerates Data-Driven Lab Journey... NVIDIA"

Note: precedents are retrieved by semantic similarity; the impact is the observed past outcome, not a price prediction.

Cada precedente recuperado diz respeito a chips de data-center de IA e à competição pela NVIDIA, mesmo que os artigos tenham sido arquivados sob feeds de empresas diferentes (Microsoft, Meta, Alphabet e a própria NVIDIA). Ao contrário da métrica de recuperação da Secção 5.3, o alerta ao vivo não exclui o próprio ticker da consulta: essa exclusão existe apenas para manter a avaliação não-trivial, ao passo que um utilizador real é bem servido pelos precedentes mais similares, seja qual for a empresa que digam respeito. De forma notável, a mesma história (um rival a entrar no mercado de chips de data-center de IA) surge em três feeds de empresas diferentes, que o motor agrupa corretamente como um só tema. Esta é evidência direta de que a recuperação é movida pelo *significado* e não pelo nome da empresa ou por palavras-chave exatas, o próprio comportamento para que o motor de correlação é desenhado. Nesta instância os precedentes calham ser uniformemente negativos (um cluster de ameaça competitiva), e a sua média é reportada como um resultado passado observado, não uma previsão. O alerta termina com um aviso explícito, mantendo o sistema dentro do seu âmbito de não-previsão.




Figura 5.8: A lição tema-versus-direção num alerta real. A manchete de consulta "Nvidia raises guidance on surging demand for AI data-centre accelerators" lê-se claramente positiva, e no entanto as cinco manchetes passadas mais similares pertencem todas a um tema de ameaça competitiva de chips de IA e todas caíram no dia seguinte (média -1.97%, tracejada). A recuperação corresponde ao *significado*, não ao sentimento ou à direção, pelo que a média reportada é evidência sobre como um tema se moveu, nunca uma previsão para este item. Valores do alerta trabalhado acima.

O que a recuperação capta e não capta. Este exemplo expõe também uma limitação honesta. A manchete de consulta lê-se como positiva (guidance aumentado), e no entanto os precedentes que recupera formam um cluster de ameaça competitiva cujos resultados de um dia são uniformemente negativos (Figura 5.8). Não há contradição uma vez claro o mecanismo: a similaridade por embeddings de frase corresponde ao *tema*, aqui “chips de data-center de IA”, e não ao sentimento ou à direção esperada. O impacto médio que o alerta reporta é, portanto, evidência sobre como um tema tendeu a mover-se, não uma previsão direcional para este item particular, que é exatamente por que o alerta lista sempre os precedentes individuais e termina com um aviso de não-previsão em vez de se apoiar num único número médio. Tratar essa média como uma previsão seria a dependência excessiva de que a literatura da confiança avisa (Bansal et al. 2021; J. D. Lee e See 2004), e o desenho protege-se disso ao mostrar a evidência em vez de emitir um veredicto.

Dois artefactos cosméticos do corpus recente e raso são também visíveis e vale a pena nomear com clareza: os precedentes partilham uma única data de recuperação, porque a camada gratuita de notícias devolve apenas uma janela recente e há pouco histórico genuíno de onde extrair, e o mesmo ticker pode aparecer duas vezes com um impacto idêntico, porque precedentes do mesmo ticker alinhados ao mesmo dia de evento partilham necessariamente o seu retorno para a frente. Ambos decorrem da profundidade do corpus, não do método, e ambos desaparecem uma vez construída a base de conhecimento multi-ano completa. Pela mesma razão, o impacto médio positivo obtido para uma consulta Nvidia semelhante sobre a base de amostra incluída na Secção 3.3.2 (+6.5% a cinco dias) e a média negativa aqui (−1.97% a um dia) não estão em tensão: usam bases de conhecimento, horizontes e encoders diferentes, e nenhuma é uma previsão.

Fidelidade da explicação. A fidelidade é garantida por construção: o texto do alerta é composto diretamente a partir dos mesmos objetos que o sistema calcula (o z-score, a janela e o limiar para o caminho de anomalias, e os precedentes recuperados exatos com as suas pontuações de similaridade e impactos medidos para o caminho de notícias), pelo que a explicação não pode divergir do cálculo subjacente. Isto é verificado programaticamente por um teste automático que assegura que o alerta composto reproduz exatamente a data, ticker e pontuação de similaridade de cada precedente recuperado e não introduz nenhum que não tenha sido recuperado; é o tipo de explicabilidade transparente, em tempo de desenho, defendida na literatura de XAI (Barredo Arrieta et al. 2020). A utilidade para um investidor de retalho é inerentemente subjetiva; uma pequena avaliação humana com rubrica (clareza, completude, acionabilidade) está planeada mas ainda não foi conduzida, sendo por isso reportada como uma limitação e não como um resultado.

5.5 Estudo de Caso 4: Triagem de Materialidade Aprendida

Pergunta: será que o modelo de triagem treinado da Secção 3.3.4 consegue priorizar as notícias melhor do que a simples evidência de volatilidade (RQ4)? Resposta: cada ranker treinado ultrapassa o chão de alertar-sempre por uma margem larga, e dentro de um orçamento de alertas realista a triagem melhora a precisão em $1.67\times$; mas nenhum dos modelos que lê o texto da manchete bate a linha de base só-volatilidade. Com esta evidência, o sinal da triagem vive no contexto de mercado, não na redação da manchete, e a dissertação reporta esse achado tal como está.

Corpus e montagem. O subconjunto FNSPID foi transmitido em stream e alinhado aos preços exatamente como desenhado: 79,753 exemplos sobre 1,501 dias de negociação únicos (janeiro de 2018 a dezembro de 2023), com zero linhas descartadas. Catorze dos quinze tickers estão representados; a Meta está ausente porque o corpus a indexa sob o seu símbolo antigo (FB) durante a maior parte da janela, uma nota de cobertura e não uma mudança de método. A divisão temporal por dias únicos (70/15/15, embargo de cinco dias) produz 28,574 linhas de treino, 17,710 de validação e 32,649 de teste, com exemplos materiais a 38.5%, 47.0% e 37.8% respetivamente. Duas propriedades do corpus importam para a leitura dos resultados. A densidade de notícias cresce ao longo do tempo (só 2023 detém 44% dos exemplos), pelo que os blocos mais tardios detêm mais linhas do que a sua fração de dias. E as manchetes do mesmo par (ticker, dia) partilham um rótulo, pelo que as linhas vêm em clusters; a divisão por dias únicos mantém cada cluster dentro de um só bloco.

Resultados. A Tabela 5.6 reporta o bloco de teste; a Figura 5.9 mostra as curvas de precisão-recall e a Figura 5.10 a calibração do principal modelo interpretável.

Tabela 5.6: Triagem de materialidade sobre o corpus FNSPID (bloco de teste; prevalência 0.378). A PR-AUC é a métrica primária; a precisão@orçamento admite no máximo cinco alertas por dia. A precisão@orçamento da linha alertar-sempre depende da ordem e é discutida abaixo: com uma pontuação constante, a métrica orçamentada desempata pela ordem das linhas, portanto esse valor mede a seleção alfabética e não a seleção cega. As outras três colunas dessa linha não dependem da ordem.

Modelo	PR-AUC	ROC-AUC	Brier	Prec.@orçamento
Alertar sempre (chão)	0.378	0.500	0.622	0.163
LR só-volatilidade (linha de base)	0.542	0.665	0.218	0.632
LR só-contexto	0.538	0.658	0.224	0.632
LR só-texto	0.439	0.564	0.240	0.572
LR contexto+texto (principal)	0.496	0.622	0.229	0.585
Gradient boosting (contexto+texto)	0.469	0.624	0.228	0.551

Tabela 5.7: Quanto vale ordenar *sem* modelo sob o mesmo orçamento de cinco alertas por dia, no mesmo bloco de teste. A última linha reproduz a Tabela 5.6 ao milésimo, e é isso que estabelece que as quatro linhas partilham um só protocolo; o procedimento recusa-se a reportar seja o que for se não reproduzir.

Regra de ordenação	Prec.@orç.	O que é de facto
Alertar sempre (constante)	0.163	ordem alfabética, não uma escolha
Permutação aleatória (40 sementes)	0.379 ± 0.017	o que quer dizer escolher às cegas
Prior de volatilidade por ticker	0.662	treze constantes do bloco de treino; não lê manchete nem corre modelo
Modelo só-contexto implantado	0.632	o resultado congelado

Ler o resultado. Quatro observações, por ordem decrescente de peso prático.

Primeiro, *ordenar sob orçamento funciona, mas menos do que o chão dava a entender*, e a correção vale mais do que a afirmação original. Uma versão anterior deste parágrafo dizia




Figura 5.9: Curvas de precisão-recall no bloco de teste. Todos os modelos treinados situam-se bem acima do chão de alertar-sempre (linha tracejada na prevalência); a linha de base só-volatilidade não é ultrapassada por nenhum modelo que use o texto da manchete.

que a triagem eleva a fração de alertas materiais de 0.163, “escolhendo às cegas”, para 0.632, quase quatro vezes. O 0.163 não mede escolher às cegas. O modelo alertar-sempre dá a mesma pontuação a todas as manchetes, e a métrica orçamentada desempata pela ordem de chegada das linhas; o corpus está ordenado por data e depois por ticker, portanto uma pontuação constante seleciona a empresa alfabeticamente primeira de cada dia. As 1,105 linhas que escolhe são todas da Apple, cuja taxa-base é a mais baixa do bloco de teste. Contra chãos que são ordenações a sério (Tabela 5.7), uma permutação aleatória dá 0.379 — que é a prevalência, como tem de ser, e essa coincidência é a verificação de sanidade da própria métrica. A pontuação treinada eleva portanto a precisão orçamentada por um fator de 1.67, e não de quase quatro. O retorno contra a fadiga de alertas é real e é menor do que foi afirmado.

Segundo, e menos confortável, *uma tabela de constantes bate o modelo treinado nesta métrica*. Ordenar as manchetes de cada dia pela mediana da volatilidade pré-evento da respetiva empresa, calculada apenas sobre o bloco de treino, não lê manchete nenhuma nem corre inferência; dá 0.662 contra os 0.632 do modelo implantado. Isto é consistente com tudo o resto desta secção e não uma surpresa: a pontuação do modelo de contexto é dominada pela volatilidade recente, portanto um resumo por empresa dessa mesma quantidade capta quase tudo o que ele sabe.

Terceiro, *o sinal é o contexto de mercado, não o texto*: a linha de base só-volatilidade atinge a melhor PR-AUC (0.542), o modelo só-contexto iguala-a na precisão orçamentada, e acrescentar o embedding da manchete *baixa* o modelo linear para 0.496; o ensemble com gradient boosting não recupera a diferença (0.469). As manchetes sozinhas estão bem acima do chão da prevalência (0.439) mas bem abaixo da volatilidade.




Figura 5.10: Calibração do principal modelo interpretável após o escalonamento de Platt sobre o bloco de validação: as probabilidades previstas acompanham as frequências observadas, que é o que torna a pontuação honesta de mostrar a um utilizador final.

Quarto, a resposta à RQ4 tal como colocada é *negativa na hipótese do texto, e positiva no mecanismo com uma ressalva que tem de ser dita*. Ordenar sob orçamento entrega mesmo valor de produto sobre o alerta cego. Mas não é o componente aprendido que o entrega: um prior estático por empresa faz o mesmo trabalho ligeiramente melhor, portanto o que a evidência sustenta é que *ordenar por volatilidade* compensa, e não que *aprender* compensa. Neste corpus e com esta representação de texto o modelo não bate a linha de base simples que era obrigado a bater, e também não bate uma trivial. Esta é a segunda vez neste capítulo que um método aprendido recebeu uma comparação justa e causal contra a escolha transparente e perdeu (Estudo de Caso 1). Essas duas comparações foram pré-comprometidas na Secção 3.6. O prior por ticker *não* foi: foi acrescentado depois, ao verificar o que o chão desta tabela media de facto, e é reportado aqui pela mesma razão que os outros dois — porque foi corrido e saiu contra o modelo treinado. A variante em produção (só-contexto, Secção 4.6) continua consistente com o achado: usa exatamente as features que carregam o sinal que existe.

Ressalvas. O rótulo é um proxy: o tamanho do movimento ajustado ao mercado, não o juízo humano de materialidade. As manchetes do mesmo dia partilham um rótulo, pelo que o tamanho efetivo da amostra é menor do que a contagem de linhas, e a densidade de notícias do corpus cresce ao longo da janela. As manchetes são curtas, pelo que uma representação de texto mais rica (corpos de artigos, sentimento financeiro) poderia ainda fechar a lacuna do texto; essa possibilidade é registada como trabalho futuro e não assumida.

O veredicto depende de onde o rótulo foi traçado? O limiar e o horizonte que definem a materialidade ($\tau = 0.02$ sobre $(d, d + 3]$) foram fixados uma vez, e um resultado negativo que só valesse nessa escolha valeria muito pouco. A análise de sensibilidade estava, de facto, já paga e por recolher: o conjunto de dados traz nove colunas de rótulo, cobrindo $\tau \in \{0.015, 0.02, 0.03\}$ e horizontes de um, três e cinco dias. Reajustando as três famílias

que decidem a comparação sob cada uma delas, com a mesma divisão, a mesma calibração e a mesma métrica, a linha de base de volatilidade iguala ou bate o modelo contexto+texto nas nove células, com prevalências de rótulo entre 0.082 e 0.597. A célula de reprodução devolve os valores congelados exactamente. A resposta negativa à RQ4 não assenta, portanto, em onde o rótulo foi traçado.

O modelo em produção numa decisão real. A afirmação do mecanismo torna-se tangível num único caso ao vivo. A Figura 5.11 decompõe uma decisão de produção real, o alerta da Meta de 12 de julho de 2026 cuja aritmética completa é a Tabela 3.5: a volatilidade recente elevada e o indicador de setor carregam essencialmente todos os log-odds, os restantes termos quase-nulos são o que o achado agregado prevê que um caso único deve parecer, e os 54% calibrados que chegaram ao canal público são reproduzidos exactamente pela decomposição. O achado agregado da avaliação (contexto, não texto) e as decisões individuais do produto em produção são um só e o mesmo cálculo, que é a propriedade de fidelidade que o desenho promete.




Figura 5.11: Uma decisão de triagem de produção real (META, 12 de julho de 2026), decomposta nas suas contribuições aditivas exatas para os log-odds. A volatilidade recente e o setor dominam; a soma $+0.699$ mapeia através da sigmoide e da calibração de Platt para os 54% efetivamente enviados ao canal (Tabela 3.5). Regenerada deterministicamente.

Mais features de mercado ajudam? Uma ablação de features. O resultado acima diz que o sinal vive no contexto de mercado e não no texto da manchete, o que convida ao seguimento natural: será que *mais* contexto ajudaria? Cinco sinais adicionais foram engendrados, todos baratos (sem nova fonte de dados) e todos sob a mesma convenção causal que os originais, para que nada após o dia do evento possa fugir para eles: o próprio regime de volatilidade do mercado amplo (sobre o índice de mercado), o momentum de vinte dias da ação, o rácio de volatilidade curta para longa, a reação imediata padronizada (o próprio z do detetor), e uma volatilidade só-de-queda. O modelo só-contexto foi re-treinado sobre estas sob o protocolo congelado (divisão temporal, calibração de Platt na validação, semente 42). A âncora de volatilidade reproduz o número congelado (0.537 contra o congelado 0.538, a pequena diferença vindo apenas do histórico mais estrito de sessenta dias que as features estendidas exigem). Acrescentar os cinco sinais move a PR-AUC para 0.535, sem nenhuma melhoria. Uma varredura leave-one-in / leave-one-out (Figura 5.12) explica porquê: a reação padronizada é o único sinal com sinal positivo, e apenas por 0.001; os outros são planos

ou ligeiramente negativos. A volatilidade deslizante já absorve quase tudo o que estas features baratas carregam, que é a mesma lição do resultado do texto, alcançada pela direção oposta: neste corpus, a materialidade de curto prazo é notavelmente bem resumida por um número. O achado é reportado exatamente como se revelou e não muda nada em produção; a tabela completa das features estendidas é reproduzida deterministicamente a partir dos inputs congelados.




Figura 5.12: Contribuição marginal de PR-AUC de cada feature de contexto estendida no bloco de teste, medida de duas formas: acrescentada isoladamente ao modelo de volatilidade (leave-one-in) e removida do conjunto completo (leave-one-out). Todos os efeitos estão dentro de ± 0.005 de zero: os sinais engendrados baratos são redundantes dada a volatilidade deslizante.

Regenerada deterministicamente.

5.6 Estudo de Caso 5: Estrutura de Tipo de Evento no Espaço de Embeddings

Pergunta: o espaço de embeddings de frase que sustenta a recuperação carrega alguma noção do tipo de acontecimento que uma manchete reporta, ou apenas do assunto de que ela trata? Resposta: carrega os dois, e o tipo de evento é o mais forte assim que a comparação é feita de forma justa; mas a separação é fraca em termos absolutos, e é por isso que a taxonomia resultante fica descritiva em vez de ser ligada à recuperação.

Porque é que a pergunta importa. O Estudo de Caso 3 mostrou uma manchete positiva a recuperar um cacho de precedentes cujos impactos medidos eram negativos, e atribuiu-o ao tema e não à direção. Esse diagnóstico deixa algo por explicar: se o espaço codificasse o *gênero* de acontecimento, os precedentes poderiam ser restringidos ao mesmo gênero e o desencontro estreitaria. A base de casos é, porém, uma coleção achatada de vetores sem qualquer noção de tipo de evento. Este estudo pergunta se é possível recuperar uma sem supervisão.

Preparação. Os embeddings MiniLM em cache das 78,933 manchetes do corpus foram agrupados por k -médias sobre vetores normalizados por L^2 , varrendo k de 6 a 20. Como

não existe verdade fundamental para tipo de evento, construiu-se uma referência à parte: uma rubrica de palavras-chave que cobre oito tipos (resultados, perspectivas, ação de analista, produto, legal ou regulatório, fusões e aquisições, pessoal, e macro ou mercado). A rubrica é deliberadamente de alta precisão e baixa cobertura. Abstém-se quando nenhum padrão dispara e também quando dispara *mais do que um*, porque uma manchete que é simultaneamente resultados e ação de analista é genuinamente ambígua, e uma referência que resolvesse a ambiguidade pela ordem da lista estaria a inventar precisão que não tem. Rotula 11,889 manchetes, 15.1% do corpus, e todos os valores de concordância são calculados nesse subconjunto, com a contagem reportada ao lado.

Duas decisões protegem a medição. A rubrica foi escrita e registada *antes* de qualquer agrupamento ter corrido, pelo que não pôde ser afinada até concordar com os grupos. E k foi escolhido pela silhueta e não pela concordância com a rubrica, já que escolher k para maximizar a métrica de avaliação seria afinar o método não supervisionado contra a sua própria avaliação.

Resultados. A Tabela 5.8 reporta o resultado em $k^* = 18$; a Figura 5.13 mostra o varrimento da silhueta e a comparação de concordância.

Tabela 5.8: Estrutura de tipo de evento não supervisionada em $k^* = 18$. A pureza e a concordância são medidas nas 11,889 manchetes que a rubrica de referência cobre.

Quantidade	Valor	Comparação
Silhueta (cosseno)	+0.084	separação fraca em termos absolutos
Pureza contra a rubrica	0.712	aleatório, mesmos tamanhos: 0.444
Concordância com tipo de evento (AMI)	0.358	a referência de interesse
Concordância com ticker (AMI)	0.188	assunto, não acontecimento
Concordância com setor (AMI)	0.130	assunto, não acontecimento
Estabilidade entre sementes (ARI)	0.786	média de três corridas resemeadas




Figura 5.13: Esquerda: o varrimento da silhueta. A curva é plana a partir de $k = 10$ (amplitude de 0.003), pelo que $k^* = 18$ é apenas fracamente preferido aos seus vizinhos, e é assim que se reporta. Direita: concordância corrigida para o acaso entre os grupos e três referências diferentes, todas medidas nas mesmas 11,889 linhas. O tipo de evento supera ambas as referências de assunto.

Dois controles, sem os quais o número principal diz pouco. Uma pureza de 0.712 parece convincente e é em grande medida um artefacto. A pureza calculada com rotulagem por maioria inflaciona quando a referência é desequilibrada e k é grande: um único tipo vale 44.4% dos rótulos e há dezoito grupos, pelo que muitos adquirem esse rótulo quase por omissão. Uma atribuição aleatória com exatamente os mesmos tamanhos de grupo já atinge 0.444, pelo que o ganho genuíno é +0.269 e não 0.712.

O segundo controlo decide a pergunta que de facto se coloca. A pureza não pode ser comparada entre referências com números de classes diferentes, porque o seu valor depende da cardinalidade e do desequilíbrio; oito tipos de evento, catorze tickers e cinco setores não estão na mesma escala. A informação mútua ajustada corrige para o acaso e para a cardinalidade, e as três referências são avaliadas em linhas idênticas. Nessa base, a concordância com tipo de evento (0.358) supera a concordância com ticker (0.188) e com setor (0.130).

Leitura do resultado. Uma leitura puramente qualitativa dos grupos sugere a conclusão oposta, e a tensão merece ser resolvida em vez de escondida. Vários grupos têm nomes de empresas e de setores entre os seus termos de maior peso, o que convida à conclusão de que o espaço apenas redescobre o assunto. As duas observações conciliam-se assim que a medição é posta em pé de igualdade: o espaço codifica assunto e tipo de evento em simultâneo, e num corpus de quinze tickers o assunto é o eixo mais visível a olho, porque os nomes das empresas dominam as listas de termos. Medido com uma estatística corrigida para o acaso, é o eixo do acontecimento que explica mais da partição.

Um confundimento tem de ser declarado, porque é a primeira objeção que um arguente levanta. A rubrica atribui rótulos a partir de palavras presentes na manchete, e os embeddings codificam essas mesmas palavras, pelo que parte da concordância de tipo de evento está garantida por construção. O que isso não destrói é a *comparação*: os nomes das empresas também estão nas manchetes, muitas vezes mais do que uma vez e no início, pelo que as três referências partilham o viés e a sua ordenação continua informativa mesmo que os valores absolutos estejam inflacionados.

Porque não é ligada à recuperação. A evidência sustenta uma conclusão descritiva e não uma mudança de produção, e a distinção é deliberada. A separação é fraca em termos absolutos, a escolha de k é apenas fracamente determinada, e a rotulagem dos grupos depende inteiramente de uma rubrica que cobre 15.1% do corpus. Filtrar precedentes por um tipo de evento errado removeria precedentes válidos em silêncio, o que é pior do que não filtrar. A taxonomia fica portanto como caracterização do corpus, e o caminho que a evidência sustenta, a rubrica transparente, é registado como trabalho futuro no Capítulo 6.

5.7 Estudo de Caso 6: Garantias Livres de Distribuição para o Score de Triagem

Pergunta: o score de triagem é uma probabilidade calibrada, mas a calibração nada promete sobre um item individual. Pode dar-se-lhe antes uma garantia? Resposta: sim, a predição conformal split fornece uma garantia de cobertura livre de distribuição, que se verifica sob divisão aleatória e se aguenta nos dois níveis mais folgados sob divisão temporal, falhando no mais exigente. O preço é cru: para prometer 90% de cobertura, o modelo só consegue uma decisão definida em 39.5% das manchetes.

O que a predição conformal acrescenta. A calibração de Platt faz do score de triagem uma afirmação *agregada* honesta: entre os itens pontuados perto de 0.6, cerca de 60% revelaram-se materiais. Descreve um registo histórico e nada promete sobre o item seguinte, nem oferece recurso algum se o modelo for usado fora do regime em que foi ajustado. A predição conformal split troca a estimativa pontual por um conjunto e obtém uma garantia livre de distribuição e de amostra finita: para um α escolhido, o conjunto contém a classe verdadeira em pelo menos $1 - \alpha$ dos casos. Não assume normalidade, nem um modelo bem especificado, nem sequer um modelo bom.

Num problema binário o conjunto devolvido tem uma leitura direta. Um único rótulo é uma decisão definida; o conjunto vazio significa que nenhuma classe é plausível ao nível pedido; e um conjunto que contém *ambos* os rótulos é um “*não sei*” explícito, produzido por um procedimento cuja garantia de cobertura vale em média sobre os casos. É esse terceiro caso o que aqui interessa: um sistema que se recusa a prever preços deve também poder declinar julgar a sua própria triagem, em vez de empurrar um 0.51 que apenas aparenta decidir.

Preparação. O modelo congelado só-contexto foi carregado exatamente como está implantado e a sua PR-AUC de teste reproduzida em 0.538479, idêntica ao valor congelado, antes de qualquer outro cálculo. Sem essa porta, nada do que se segue diria respeito ao modelo que a dissertação reporta. A não-conformidade é $1 - \hat{p}(\text{classe verdadeira})$, e o limiar é o quantil empírico $[(n + 1)(1 - \alpha)]/n$ das pontuações de calibração. A correção de amostra finita é o que converte “costuma cobrir” numa garantia; sem ela, a cobertura fica sistematicamente abaixo do nominal.

A experiência corre duas vezes, e o contraste é o achado. Uma divisão *aleatória* do bloco de teste satisfaz a permutabilidade por construção, pelo que a garantia tem de se verificar e a corrida serve de verificação da implementação. Uma divisão *temporal*, calibrando na metade anterior e prevendo a posterior, é o que o sistema implantado de facto faz, e aí a permutabilidade não está garantida.

Resultados. A Tabela 5.9 e a Figura 5.14 reportam ambas.

Tabela 5.9: Cobertura conformal split sobre o modelo de triagem congelado (bloco de teste, 32,649 linhas, dividido a meio entre calibração e avaliação). “Não sei” é a fração de itens cujo conjunto contém os dois rótulos.

Divisão	α	Nominal	Cobertura	Tam. conj.	“Não sei”
Aleatória	0.05	0.95	0.951	1.784	78,4%
Aleatória	0.10	0.90	0.902	1.605	60,5%
Aleatória	0.20	0.80	0.803	1.323	32,3%
Temporal	0.05	0.95	0.937	1.741	74,1%
Temporal	0.10	0.90	0.900	1.584	58,4%
Temporal	0.20	0.80	0.822	1.368	36,8%

Leitura do resultado. O padrão, e não um veredicto único, é o achado. Sob divisão aleatória a cobertura é atingida nos três níveis, o que confirma que a implementação está correta; se tivesse falhado aí, a culpa seria do método e não dos dados. Sob divisão temporal aguenta-se a 90% e a 80% e fica aquém a 95% (0.937).




Figura 5.14: Esquerda: cobertura empírica contra o nível nominal (tracejado) para as duas divisões. A cobertura é atingida em todo o lado exceto em $\alpha = 0.05$ sob divisão temporal. Direita: como a garantia é paga. A 90% de cobertura o modelo emite uma decisão definida em apenas 40% das manchetes e declara “não sei” nas restantes.

A direção é a que a teoria prevê, e vale a pena dizê-lo por extenso: *quanto mais apertada a cobertura exigida, mais frágil ela é à deriva*. Exigir 95% obriga o limiar a apoiar-se na cauda da distribuição de calibração, e a cauda é exatamente o que se move primeiro quando o regime muda. A 80% e a 90% há folga suficiente para absorver o desvio desta janela. Isto não é uma falha da predição conformal; é o método a detetar uma quebra de permutabilidade e a identificar o nível em que ela começa a doer. Uma garantia que falha de forma mensurável vale mais do que uma probabilidade que nunca prometeu nada e por isso nunca pode ser desmentida.

O preço, e o que ele diz sobre o modelo. O número mais duro aqui não é a cobertura, é o seu custo. Para prometer 90% de cobertura, o modelo de triagem só consegue emitir uma decisão definida em 39.5% das manchetes; nas restantes 60.5%, o conjunto honesto contém as duas classes. Isto não contradiz o Estudo de Caso 4, explica-o a partir de uma direção independente e sem treinar nada de novo: o sinal disponível simplesmente não separa a maioria dos itens aos níveis de confiança habitualmente exigidos. É também o instrumento que faltava ao limiar implantado, que por construção força uma decisão em todos os itens; esta medição quantifica com que frequência essa decisão forçada assenta em muito pouco.

A camada fica portanto como medição e não é ligada à produção. A razão é de desenho e não de tempo: o produto compromete-se com uma cadência legível, e um fluxo de alertas que declarasse “não sei” em 60% dos itens quebraria esse compromisso sem que ninguém tivesse decidido quebrá-lo.

5.8 Estudo de Caso 7: Medir a Distância até à Implantação

Pergunta: o modelo foi treinado num corpus de 2018–2023 e corre em 2026, uma distância que esta dissertação repetidamente nomeou como limitação. Qual é o seu tamanho real?
Resposta: mensurável e concentrada numa entrada. A volatilidade pré-evento deriva de forma significativa; as restantes entradas mantêm-se estáveis; e a prevalência do rótulo

não tem tendência, oscila, o que explica ao mesmo tempo por que os números congelados sobrevivem e por que a garantia conformal mais apertada não sobrevive.

Porque é preciso fazê-lo. Afirmar uma limitação é barato. Uma limitação afirmada é uma opinião; uma limitação medida é um resultado, e um resultado que se pode discutir numa prova com números em cima da mesa.

Preparação. Usam-se duas medidas porque veem coisas diferentes. O *Population Stability Index* compara massa de probabilidade por intervalo e traz bandas de interpretação convencionadas (< 0.10 estável, 0.10 a 0.25 moderada, > 0.25 significativa), herdadas da prática de risco de crédito. A estatística de Kolmogorov–Smirnov compara distribuições acumuladas e apanha desvios sistemáticos que a divisão em intervalos dilui.

Um ponto de método muda a forma de ler os resultados. Com dezenas de milhar de pontos um teste de Kolmogorov–Smirnov rejeita quase qualquer hipótese nula, pelo que o seu valor- p é aqui quase inútil: uma diferença estatisticamente significativa pode ser trivialmente pequena. O que se lê é a estatística D , um tamanho de efeito em $[0, 1]$ que não cresce só por a amostra ser grande. Reportar apenas o valor- p converteria “a amostra é grande” em “a deriva é grave”.

Resultados. A Tabela 5.10 e a Figura 5.15 comparam o bloco de treino (janeiro de 2018 a março de 2022) com o bloco de teste (fevereiro a dezembro de 2023), que é a deriva que os resultados congelados já atravessaram.

Tabela 5.10: Deriva das entradas entre os blocos de treino e de teste, por feature, ordenada por severidade.

Feature	PSI	Banda	KS D
Volatilidade pré-evento (20 d)	0.281	significativa	0.170
Comprimento da manchete	0.111	moderada	0.103
Retorno do dia do evento	0.020	estável	0.036
Momentum a cinco dias	0.014	estável	0.039

Leitura do resultado. A feature que deriva é a estimativa de volatilidade, e a razão não é misteriosa: a janela de treino contém o choque de 2020, e a volatilidade realizada nesse período não se parece com a de 2023. O modelo aprendeu num mundo mais agitado do que aquele em que foi avaliado.

O rótulo merece tratamento separado, porque é fácil confundi-lo com as entradas. A prevalência passa de 0.3854 no treino para 0.3781 no teste, uma variação relativa de apenas 1.9%. Tomado só nas pontas, o alvo parece estável. Não é: o bloco de validação, que fica entre os dois no tempo, atinge 0.4704. A sequência sobe e volta, pelo que comparar apenas as pontas esconderia uma excursão de cerca de um quinto. A formulação honesta é que *a deriva é sobretudo de volatilidade, e é cíclica em vez de direcional*. Essa única frase dá conta de duas coisas ao mesmo tempo: por que os números congelados sobrevivem, já que o protocolo atravessa uma dessas oscilações, e por que a garantia conformal mais apertada falha sob divisão temporal (Secção 5.7), já que uma cauda que oscila é precisamente o que uma garantia a 95% tem menos folga para absorver.




Figura 5.15: Deriva de distribuição para cada feature de contexto entre os blocos de treino e de teste, contra as bandas de interpretação convencionadas. Só a volatilidade pré-evento entra na banda significativa; as duas features baseadas em retornos quase não se movem.

Um instantâneo ao vivo, e a ressalva que o torna utilizável. As mesmas features baseadas em preços foram recalculadas a partir dos dados de mercado atuais para a watchlist. A volatilidade pré-evento devolve um PSI de 2.866, muito além da banda significativa. Esse número exagera o seu caso, e o próprio relatório denuncia a razão: a média desloca-se apenas +0.18 desvios-padrão. Um PSI perto de três a par de uma deslocação de média tão pequena não descreve um mercado irreconhecível; descreve uma amostra com poucas observações *independentes*. A causa é mecânica. Cerca de mil linhas vêm dos dez tickers então vigiados, ao longo de aproximadamente cem dias de negociação, e a volatilidade a vinte dias é uma estatística de janela deslizante, pelo que dois dias consecutivos partilham dezanove dos seus vinte retornos. As observações são quase repetições, a distribuição resultante fica aos carcos, e o índice penaliza com força os intervalos vazios. Os dois índices *não são portanto comparáveis em magnitude*, e pô-los lado a lado numa só tabela induziria em erro.

O que o instantâneo sustenta continua a valer a pena: a volatilidade é de novo a feature que mais se move, obtido de forma independente sobre dados de hoje; a deslocação da média é modesta; e as restantes features mantêm-se nas bandas estável e moderada, coerentes com a medição dentro do corpus. A resposta honesta a “*o vosso modelo foi treinado em dados velhos*” é portanto que a distância foi medida de duas formas independentes, está concentrada na volatilidade, é significativa mas não extrema, e implica que o resultado de 2023 não deve ser tratado como uma promessa sobre 2026. A medição fornece ainda um gatilho de re-treino verificável, o limiar convencional de 0.25, em vez de uma intuição.

5.9 Discussão e Ameaças à Validade

Os primeiros quatro estudos de caso sustentam o desenho central: a deteção normalizada pela volatilidade é consistente em todo o mercado onde um limiar fixo não é, a recuperação semântica traz à superfície muito mais precedentes análogos por setor do que as linhas de base lexical ou triviais, o alerta ponta a ponta é fiel ao seu próprio cálculo, e a triagem aprendida acrescenta um grande ganho de precisão orçamentada enquanto confirma, contra as suas próprias features de texto, que a evidência transparente da volatilidade carrega o sinal.

Os quatro últimos examinam o mesmo sistema por fora, perguntando o que ele *não* sabe. O espaço de embeddings acaba por carregar estrutura de tipo de evento, ainda que demasiado fraca para filtrar precedentes por ela (Secção 5.6); o score de triagem pode receber uma garantia livre de distribuição, ao custo de admitir incerteza na maioria dos itens (Secção 5.7); a distância entre o corpus de treino e o presente implantado está concentrada numa entrada e é cíclica em vez de direcional (Secção 5.8). Cada um dos três termina numa decisão de *não* mudar a produção, tomada com base na evidência e não por falta de tempo, e cada uma fica registada como tal. Todos os resultados assentam em dados reais e são reprodutíveis a partir de scripts versionados.

Os resultados também têm limites claros, que são expostos abaixo sob as quatro categorias padrão de validade para que nada seja passado por cima.

Validade de construto: medem as métricas o que é afirmado? Dois proxies pesam aqui. A relevância da recuperação é julgada por um rótulo de *setor*, um substituto automático para o juízo humano de “análogo”, pelo que um precedente do mesmo setor sobre um tópico não relacionado conta como acerto; a inspeção qualitativa na Secção 5.3 mostra que este proxy é razoável mas imperfeito. De igual modo, o rótulo de anomalia de “movimento extremo” é relativo à volatilidade, pelo que não é uma verdade de base independente, que é por que o argumento primário das anomalias é a *consistência da taxa de disparo* sem-rótulo, e não a concordância com esse rótulo. Por fim, o número de estudo de evento mede a variação de preço que se *seguir* a uma notícia, que é um resultado, não um efeito causal da notícia; é reportado como evidência, nunca como uma previsão.

Validade interna: poderia outra coisa explicar o efeito? A vantagem da recuperação poderia, em princípio, ser inflacionada ao corresponder trivialmente as notícias de uma empresa às suas próprias notícias passadas; isto é removido por construção, porque a avaliação proíbe precedentes do mesmo ticker e mede apenas a precisão *cross-ticker*. O lookahead é excluído em todo o lado: cada quantidade usa informação disponível na altura, e os impactos são acumulados estritamente para a frente a partir do fecho do dia do evento. A principal ameaça residual é o confundimento (um movimento de preço numa janela pós-evento pode ser movido por fatores de todo o mercado em vez da notícia), que as janelas curtas (+1, +3, +5 dias) limitam mas não eliminam, e que o enquadramento de não-causalidade reconhece abertamente.

Validade externa: até onde generalizam os achados? O estudo cobre quinze tickers de grande capitalização dos EUA em cinco setores, pelo que os números não têm de transferir-se para ações de pequena capitalização, para outros mercados, ou para outros períodos, e a cobertura de notícias é mais rala fora das grandes capitalizações. O estudo de recuperação corre sobre uma janela recente de um serviço gratuito; os estudos de triagem, taxonomia, conformal e deriva correm sobre o histórico multi-ano do FNSPID, o que alarga o período mas não o conjunto de tickers, que é fixado pelo cartão de dados nos dois casos.

Validade de conclusão estatística: são as comparações sólidas? Os resultados da recuperação são médias sobre cinco amostras aleatórias com desvios-padrão reportados (as barras de erro na Figura 5.5), e a diferença entre a recuperação semântica e cada linha de base é grande relativamente a essa dispersão; ainda assim, cinco corridas sobre um corpus é uma amostra modesta, e nenhum teste formal de significância é reclamado. A comparação

das anomalias é reportada descritivamente, como uma diferença nas taxas de disparo entre instrumentos, e não como um teste de hipótese.

Um limite é deliberado e não uma fraqueza: o sistema não faz previsão de preços e não avalia lucro de negociação, pelo que essas questões estão fora de âmbito por desenho. O corpus FNSPID completo, um estudo humano de relevância e utilidade, e uma análise de impacto multi-ano são os passos seguintes naturais, e são levados para as conclusões.

5.10 Conclusões do Capítulo

Ao longo de sete estudos de caso sobre dados reais, o gatilho de anomalias do InvestiGator disparou muito mais consistentemente do que um limiar fixo, o seu motor de correlação recuperou precedentes análogos por setor bem acima de todas as linhas de base e independentemente do modelo de embedding, as suas explicações foram fiéis ao cálculo subjacente por construção, e o seu modelo de triagem treinado melhorou a precisão de alertas dentro do orçamento enquanto honestamente não conseguiu bater a linha de base só-volatilidade com texto. Os três estudos seguintes mediram o que o sistema não sabe, e cada um deles terminou deixando a produção inalterada porque a evidência não sustentava a mudança. O próximo capítulo reúne estes achados face às questões de investigação.

Capítulo 6

Conclusões

Esta dissertação propôs-se desenhar, implementar e avaliar um sistema de alertas financeiros explicável e reproduzível para investidores de retalho dos EUA, movido por dois gatilhos independentes e entregue através do Telegram. Este capítulo resume o que foi alcançado face às questões de investigação, revisita as contribuições, e enuncia as limitações e as direções que elas abrem.

6.1 Conclusões Principais

O trabalho resume-se melhor voltando às quatro questões de investigação do Capítulo 1, reunidas num relance na Figura 6.1 e depois tomadas uma a uma.

Questão de investigação	Veredicto	Um número
RQ1: detetar movimentos abruptos de forma transparente	Sim	taxa de disparo 0.015 vs 0.344; F_1 0.516
RQ2: casos análogos, sem look-ahead	Sim (recuperação)	P@5 0.514 vs 0.346 lexical, 0.240 aleatório
RQ3: explicações fiéis e úteis	Fiel; utilidade em aberto	fiel por construção; ainda sem estudo humano
RQ4: triagem para além da volatilidade	Offline sim; texto não	quota 0.379 → 0.632; PR-AUC 0.542 vs 0.496

Figura 6.1: As quatro questões de investigação e os seus veredictos, reportados exatamente como se revelaram. Duas são um sim sem reservas; duas são divisões honestas. As explicações são fiéis por construção mas a sua utilidade aguarda um estudo humano. A triagem aprendida ajuda como mecanismo de produto *em dados retidos* e nenhum modelo de texto de manchetes bateu a linha de base da volatilidade neste corpus; medido em produção, o mesmo gate ordena ao acaso (Secção 6.5), e é por isso que o seu veredicto é qualificado e não verde. Os números são do Capítulo 5.

RQ1: deteção transparente de movimentos abruptos. Sim. Um detetor de z-score deslizante assinala retornos anormais e, mais importante, fá-lo a um ritmo estável *em ações de volatilidade muito diferente*, onde um limiar de percentagem fixa não consegue. Como reportado no Capítulo 5, a taxa de disparo variou apenas 0.015 entre os quinze tickers no

z-score, contra 0.344 na linha de base fixa, e o z-score atingiu um F_1 de 0.516 contra um indicador de movimentos extremos, mais do dobro da linha de base. O método é simples o suficiente para que cada alerta possa ser explicado ao investidor.

RQ2: casos análogos sem lookahead. Sim, para a recuperação. A recuperação semântica com Sentence-BERT recuperou muito mais itens análogos por setor do que qualquer alternativa trivial: uma precisão@5 cross-ticker de 0.514 ± 0.015 (em cinco corridas), contra 0.346 de uma linha de base lexical, 0.240 do aleatório e 0.126 da recência. Uma decomposição por setor mostrou que o ganho é maior onde o vocabulário do domínio é mais distintivo (energia, saúde). O estudo de caso ponta a ponta mostrou-a a trazer à superfície precedentes genuinamente temáticos a partir de fontes de empresas diferentes. O impacto é medido estritamente após o evento, ao estilo de um estudo de evento, pelo que nenhuma informação futura se infiltra no desfecho medido.

A redação deste veredicto é deliberadamente mais estreita do que a de um rascunho anterior, e a razão é uma propriedade do corpus e não do método. Como a janela da camada gratuita abrange 27 dias, a experiência de recuperação não pode ser descrita como recuperando *precedentes*: apenas 31,1% dos vizinhos que devolve são mais antigos do que a sua consulta (Secção 3.2.3). O que demonstra é que a semelhança por embeddings recupera itens do mesmo setor muito acima de todas as linhas de base, que é o que a *precision@5* mede e o que o número sustenta. A anterioridade é uma propriedade da configuração implantada, onde a base de conhecimento termina em 2023 e as consultas chegam em 2026, e da medição de impacto, que só olha para a frente a partir de um evento.

Isto foi depois validado à escala: no corpus FNSPID multi-ano (cerca de oitenta mil manchetes) o mesmo protocolo cross-ticker atingiu uma *precision@5* de 0.595, acima do valor preliminar, e a propriedade tema-não-direção foi quantificada diretamente, já que a consistência de direção dos clusters recuperados (0.71) fica logo acima do seu chão do acaso de 0.69.

RQ3: explicações fiéis e úteis. Fiéis, sim; úteis, ainda em aberto. Como cada alerta é composto diretamente a partir dos mesmos objetos que o sistema calcula (o z-score e os seus parâmetros, ou os precedentes recuperados com as suas pontuações e impactos medidos), a explicação não pode divergir da lógica subjacente, e cada alerta termina com um aviso explícito de não-previsão. A utilidade para um investidor de retalho é plausível por desenho mas ainda não foi medida com um estudo humano, sendo por isso reportada como um ponto em aberto e não como um resultado assente.

A metade da fidelidade foi posteriormente estendida do texto por template para linguagem *gerada*. Um modelo de linguagem foi introduzido estritamente como narrador, autorizado a redigir a evidência mas nunca a fornecê-la, e uma guarda em execução valida a sua saída contra a evidência antes da entrega: qualquer número ausente da evidência calculada, qualquer valor com o sinal invertido, qualquer formulação preditiva ou de aconselhamento, e qualquer atribuição que contradiga a calculada fazem descartar a resposta inteira a favor do texto determinístico. A garantia é, portanto, uma propriedade do sistema e não do bom comportamento do modelo.

É essa distinção que torna a afirmação mensurável, e ela produz dois números em vez de um. Sobre um conjunto fixo de casos e dois fornecedores, a saída crua do modelo violou a evidência num pequeno número de casos, que é o número que justifica a guarda existir; o texto efetivamente entregue não a violou em nenhum, que é o número que testa a guarda.

Ambos são reportados, juntamente com a observação honesta de que o segundo é em parte circular, já que o mesmo verificador decide e avalia. O contrapeso é um corpus adversário: um exercício independente de red team contra uma versão anterior da guarda produziu um conjunto de contornos confirmados, cada um reproduzido mecanicamente, e esses ataques são hoje testes de regressão permanentes. O primeiro desenho, uma lista de formulações proibidas, falhou contra eles de forma decisiva, e a lição generaliza-se: o espaço de paráfrases é ilimitado enquanto qualquer lista delas é finita, pelo que a guarda foi reconstruída como um vocabulário fechado em que tudo o que não é explicitamente permitido é recusado.

Acrescentou-se depois uma *segunda* superfície gerada, e a resposta honesta à RQ3 passa a ter de as distinguir em vez de as somar. O caminho de alerta acima é empurrado para um telemóvel sem ser pedido, e a sua garantia é absoluta. O relatório de situação e o analista conversacional (Secção 4.8) são puxados por um leitor que já está a olhar para a evidência, e a sua garantia é deliberadamente mais fraca quanto à *linguagem*: uma blocklist em vez de um vocabulário fechado, porque um relatório de cinco secções não cabe em duzentas e cinquenta palavras permitidas. O que é idêntico nos dois caminhos é a parte verificável — números de um conjunto fechado, sinais obrigatórios — e o caminho puxado é aí mais estrito, ligando cada número ao registo que a própria frase cita. O veredicto de fidelidade é, portanto, **sim nos dois caminhos para o que se verifica mecanicamente, e mais fraco num deles para o que não se verifica**, com as quatro lacunas residuais e o exercício adversário interrompido enunciados na Secção 6.5.

Essa segunda superfície também alarga a metade em aberto desta questão, em vez de a estreitar. Se um relatório ancorado ajuda um não-especialista a chegar a um juízo mais sólido do que os painéis subjacentes sozinhos é exatamente o tipo de pergunta que o estudo humano em falta responderia, e não se faz aqui nenhuma afirmação de utilidade para ele.

RQ4: triagem aprendida para além das linhas de base de volatilidade. Não na hipótese do texto; sim no mecanismo. Um modelo de materialidade supervisionado foi treinado, calibrado e testado em 79,753 exemplos do FNSPID (2018–2023) sob um protocolo temporal estrito. Como mecanismo de produto, a triagem aprendida é valiosa *em dados retidos do corpus em que foi ajustada*: dentro de um orçamento de cinco alertas por dia, elevou a quota de alertas materiais de 0.379 para 0.632, com probabilidades calibradas. Duas ressalvas assentam nesta frase e nenhuma é decorativa. A primeira é o chão: uma versão anterior deste veredicto comparava contra 0.163, que afinal media a seleção alfabética e não a seleção cega (Secção 5.5), pelo que o ganho é de um fator de 1.67 e não de quase quatro. A segunda é que não é a parte *aprendida* que o merece — um prior de volatilidade por empresa, de treze constantes, dá 0.662 na mesma métrica. Medido em produção, sobre uma população enriquecida pelos filtros a montante, o mesmo gate não mostra benefício significativo (Secção 6.5), pelo que a afirmação sobre o mecanismo é uma afirmação de conjunto de avaliação e é enunciada como tal. Mas a comparação decisiva pré-comprometida foi noutro sentido: nenhum modelo que lê o texto da manchete bateu a linha de base só-volatilidade (PR-AUC 0.542 contra 0.496 do modelo principal contexto+texto), pelo que neste corpus o sinal da triagem vive no contexto de mercado, não na redação da manchete. Juntamente com a comparação com a Isolation Forest do estudo de anomalias, este é o segundo teste justo e causal em que a escolha transparente venceu, e ambos os resultados são reportados exatamente como se revelaram. O resultado negativo no texto foi ainda sujeito a stress: um bootstrap por cluster (ticker, dia) confirma que adicionar o texto da manchete baixa a precisão de forma robusta e não por acaso, e um re-teste deliberadamente justo, com regularização afinada, um bloco de texto reduzido em dimensão

e um encoder de domínio financeiro, recupera o texto apenas até ao nível do contexto de mercado, nunca acima. O resultado é robusto, não um artefacto de um pipeline de texto sub-ajustado.

Uma observação final diz respeito a como o modelo de triagem é *usado*, e não a como pontua. O sistema implantado filtrava os alertas num limiar de probabilidade posto à mão, assente sobre um modelo calibrado sem nunca explorar essa calibração. Varrer o limiar sobre o conjunto de teste congelado, sob um rácio de custo explícito entre um movimento perdido e um falso alarme, transforma a constante num ponto de operação derivado, e expõe também o que a escolha original assumia em silêncio: o valor implantado corresponde a tratar um movimento perdido como custando aproximadamente o mesmo que um falso alarme. Sob custos iguais, o ótimo situa-se essencialmente onde a constante já estava, pelo que a escolha fica vindicada, mas passa a ser argumentada em vez de afirmada. A mesma análise re-testou o resultado negativo em termos operacionais, comparando políticas a orçamentos diários de alertas iguais em vez de por PR-AUC, e o score aprendido voltou a não bater a volatilidade de forma consistente. O negativo sobrevive, portanto, a uma mudança de métrica, o que é uma afirmação mais forte do que o resultado original por si só.

6.2 Posições Assumidas por Exclusão

Algumas das decisões de desenho mais claras deste trabalho são coisas que o sistema deliberadamente não faz. Enunciá-las como posições, e não como omissões, importa, porque cada uma era alcançável com os dados e o esforço disponíveis e foi recusada por princípio.

Previsões de terceiros. Os preços-alvo de analistas e as tendências de recomendação são livremente acessíveis e teriam melhorado a cobertura da pergunta “porque é que isto se mexeu”. Foram excluídos porque importar a previsão de outra parte para um sistema definido por não prever é uma contradição que nenhum enquadramento remove. Preferiu-se a coerência à cobertura.

Posições pessoais. As análises ao nível da carteira, concentração e exposição por correlação, são calculáveis apenas a partir de preços e estavam entre as capacidades mais pedidas. Foram excluídas por duas razões que se somam: as posições são dados financeiros pessoais, o que transforma um protótipo de investigação numa obrigação de proteção de dados em vez de numa discussão sobre proteção de dados, e qualquer afirmação do género “as tuas maiores posições são, na prática, uma só aposta” é aconselhamento, seja qual for a redação, o que atravessa a fronteira de que a posição ética do sistema depende para não atravessar.

Agência conversacional. O narrador é uma função pura da evidência para um parágrafo, não um assistente multi-turno nem um agente. Um único modelo a chamar várias ferramentas não é um sistema multi-agente, e descrevê-lo como tal teria sido a afirmação menos defensável da dissertação.

Registos de insiders e feeds de divulgação agendada. São genuinamente úteis e genuinamente gratuitos. Foram excluídos por âmbito e não por princípio: cada um acrescenta um caminho de ingestão e um modo de falha sem uma avaliação associada, e um componente por avaliar nada contribui para as perguntas que este trabalho faz. Aparecem antes no trabalho futuro.

Um score de convergência fundido. Ordenar alertas pelo acordo de vários sinais independentes é intuitivo, e a maquinaria para isso foi construída e medida. Foi recusada porque a medição não a sustentou: a fusão bateu o melhor sinal isolado num orçamento de alertas em três, e um ganho que só aparece no orçamento que se escolhe citar não é um resultado. O estudo não é reportado como estudo de caso porque uma capacidade recusada não precisa de um capítulo; a medição fica com os restantes registos de avaliação.

Um achado incidental dele merece ser levado adiante, porque justifica uma regra que este trabalho segue por todo o lado. Quando os pesos da fusão foram *derivados* em vez de escolhidos, o peso da intensidade de notícia saiu *negativo*: um dia com muitas manchetes é *menos* provável de ser material, porque esses dias tendem a trazer conteúdo gerado automaticamente e não acontecimentos. Escolher os pesos à mão teria quase de certeza posto esse termo positivo, porque é o que a intuição diz, e estaria errado. É o padrão que várias destas posições partilham: construir, medir, e deixar a medição decidir, incluindo quando a medição contradiz quem a construiu.

Streaming em vez de sondagem periódica. A latência de entrega é uma propriedade real de um produto de alertas, e a resposta óbvia de engenharia é uma ligação de streaming à fonte de preços. Foi recusada por razões que vale a pena separar, porque só uma delas é sobre esforço. O trabalho estimado era substancial, mas o argumento decisivo é que nenhuma pergunta de investigação desta tese se torna respondível por encurtar a entrega de minutos para segundos: o detetor está definido sobre barras diárias, e os precedentes recuperados têm dias por construção. Raciocinar sobre os dois perfis de utilizador do Capítulo 1 aponta no mesmo sentido, e isso deve ser rotulado pelo que é: nenhum dos perfis, tal como ali caracterizado, distinguiria plausivelmente cinco segundos de cinco minutos num alerta que existe para provocar reflexão e não uma ordem de compra. Isso é uma suposição sobre dois perfis construídos, não um achado sobre pessoas, e ficaria resolvido pelo mesmo estudo humano que a RQ3 continua a aguardar. O sistema sonda por isso num ciclo fixo, que chega para as afirmações que faz, e a latência resultante é *medida* em vez de prometida.

Uma versão anterior deste parágrafo afirmava que a latência está limitada pelo ciclo de sondagem. Medi-la mostrou que é falso, e a correção vale a pena ficar visível porque muda aquilo sobre que a decisão acima é uma decisão. Decompor os carimbos de tempo registados de cada alerta entregue em publicação → deteção e deteção → entrega dá uma mediana de cerca de um segundo para a segunda componente e de cerca de duas horas e meia para a primeira. Encurtar o ciclo do agendador *best-effort* usado antes, medido em uma hora e meia a duas horas, para um trabalhador de sessenta segundos moveu a mediana de ponta a ponta bem menos de uma hora, porque o ciclo nunca foi a restrição dominante. O atraso vive na descoberta: o serviço gratuito de notícias não é um canal em tempo real, e a manchete mais recente que passa o filtro de relevância é tipicamente mais velha do que a manchete mais recente do feed. Uma ligação de streaming aos preços não tocava em nenhuma das duas. A afirmação defensável é por isso mais estreita e, ao contrário da original, verificável: o sistema entrega em segundos o que a sua fonte lhe dá. Um produto dirigido a negociação intradiária precisaria do caminho de streaming e de um serviço de notícias pago; este não é esse produto, e dizê-lo é mais barato e mais verdadeiro do que construir uma capacidade que não se usa.

6.3 Questões de Investigação e Objetivos Alcançados

O objetivo geral, desenhar, implementar e avaliar um sistema de alertas explicável e reproduzível movido por dois gatilhos, foi cumprido: o *InvestiGator* é um sistema funcional cujos dois gatilhos foram provados de ponta a ponta e cujos componentes centrais, incluindo o modelo de triagem treinado, foram avaliados sobre dados reais. Tomando os cinco objetivos da Secção 1.3 um a um, quatro estão cumpridos por inteiro e um por metade:

- *Construir uma pipeline de alertas explicável movida pelos dois gatilhos.* Cumprido. Os dois gatilhos correm de ponta a ponta em implantação contínua, e cada alerta é renderizado a partir dos objetos calculados.
- *Avaliar o detetor de anomalias contra linhas de base transparentes.* Cumprido, e alargado para além do prometido: o detetor foi comparado não só com um limiar fixo mas com dois detetores aprendidos e um segundo estimador de volatilidade sob o mesmo protocolo causal.
- *Avaliar a recuperação de notícias históricas contra linhas de base triviais.* Cumprido, contra linhas de base aleatória, de recência e lexical, e repetido depois à escala sobre o corpus multi-ano.
- *Aferir se as explicações são fiéis e úteis.* Cumprido por metade, e a metade que falta é nomeada em vez de ser absorvida pela que resultou. A fidelidade foi estabelecida, primeiro por construção e depois, para linguagem gerada, por uma guarda em tempo de execução com um corpus adversário de regressão. A utilidade não foi medida: o instrumento existe e o limiar de análise foi fixado à partida, mas nenhum estudo humano foi conduzido, pelo que não se faz afirmação nenhuma.
- *Treinar, calibrar e avaliar honestamente um modelo de triagem de materialidade.* Cumprido, incluindo a parte menos confortável de reportar, já que a comparação decisiva pré-comprometida correu contra o modelo treinado.

Os compromissos metodológicos do Capítulo 3 também se mantiveram: uma fatia fina de ponta a ponta foi entregue primeiro, cada componente foi mantido na sua forma mais simples e defensável, a avaliação seguiu um desenho fixado à partida, e todo o sistema é reproduzível a partir de scripts versionados.

6.4 Contribuições Revisitadas

Enquanto dissertação de *Engenharia* de Inteligência Artificial, a contribuição é a integração, aplicação e avaliação crítica de componentes existentes num todo funcional, explicável e reproduzível, e não um novo algoritmo. Destacam-se cinco contribuições concretas. Primeira, uma metodologia documentada e reproduzível para **correlação notícia–mercado** que combina recuperação por embeddings de frase com janelas de impacto de estudo de evento, com escolhas explícitas de métrica de similaridade e horizonte e evitação explícita de lookahead. Segunda, o **InvestiGator**, um **sistema de alertas XAI-first** cuja cadeia de raciocínio inteira (deteção, evidência, fontes e precedentes) é exposta a um utilizador não-especialista e é fiel por construção. Terceira, um **modelo de triagem de materialidade** treinado e calibrado, rotulado pelo próprio código de estudo de evento do sistema sobre o corpus multi-ano, integrado nos alertas como evidência explicada atrás de uma porta de configuração, e monitorizado em produção contra os resultados que efetivamente se seguiram — monitorização que veio depois mostrar o gate a ordenar ao acaso na população implantada, o que é, em

si, parte da contribuição. Quarta, uma **avaliação crítica e honesta** de cada componente central contra linhas de base triviais, lexicais e de volatilidade sobre dados reais, incluindo duas comparações pré-comprometidas estatística-versus-aprendida que os métodos transparentes venceram; os resultados, ablações e limitações são todos reportados com clareza e regenerados a partir de scripts versionados.

Uma quinta contribuição junta-se a estas e é metodológica e não estatística: uma **camada de geração ancorada com uma verificação de fidelidade que liga cada número ao registo que a própria frase cita** (Secção 3.3.6). É a construção que a distingue de colar um modelo de linguagem a um painel. O gerador recebe um pacote de evidência cujos registos trazem proveniência declarada, nunca observa o mercado, e é verificado antes da entrega; a interface resolve cada citação de volta ao registo, portanto a afirmação de que o texto gerado se mantém ligado à sua evidência é uma travessia que o leitor pode fazer e não uma promessa sobre um prompt. A sua garantia é deliberadamente mais fraca do que a allowlist de vocabulário fechado do caminho de alerta, e tanto essa diferença como os riscos residuais são declarados e medidos em vez de afirmados — que é a parte da contribuição com maior probabilidade de transferir para outros sistemas que colocam texto gerado ao lado de resultados calculados.

6.5 Limitações

Restam várias limitações, enunciadas com clareza:

- **Corpus, e é mais estreito do que parece à primeira vista.** A avaliação de recuperação primária usou um corpus de camada gratuita que abrange *27 dias*, não meses. É curto o suficiente para excluir qualquer afirmação sobre generalização ao longo do tempo, razão pela qual esses números são preliminares e pela qual a recuperação foi repetida à escala sobre o corpus FNSPID multi-ano (precision@5 de 0.595). Tem uma segunda consequência, enunciada na Secção 3.2.3: dentro de uma janela de 27 dias apenas 31,1% dos vizinhos recuperados precedem a sua consulta, pelo que essa experiência mede recuperação semântica de itens do mesmo setor e não recuperação de precedentes. A distinção não chega ao sistema implantado, onde a base de conhecimento termina em 2023 e as consultas chegam em 2026. O estudo de triagem usou de facto o subconjunto multi-ano do FNSPID, mas com catorze dos quinze tickers (a Meta está indexada sob o seu símbolo antigo no corpus) e apenas o texto da manchete.
- **Indicadores aproximados.** A relevância é aproximada por concordância de setor, e o rótulo de anomalia é relativo à volatilidade, razão pela qual o argumento da taxa de disparo sem rótulos tem primazia.
- **Cobertura de notícias, agora medida e não apenas afirmada.** As afirmações anteriores de que o serviço gratuito de notícias é limitado nunca diziam *quanto*. Ao longo de um ano de manchetes captadas sobre os doze nomes, existia pelo menos uma manchete relevante em 88,5% dos dias que o detetor assinalou como invulgares ($|z| \geq 1,5$; 90,4% com $|z| \geq 3,0$). O complemento é a fração de dias invulgares em que *nenhuma correção de código ajuda*: se o fornecedor não associa a história ao ticker, ela nunca entra no funil e nenhum dos cinco *gates* chega a ser consultado. Isto separa duas limitações antes confundidas, o que o *desenho* descarta e o que a *fonte* nunca entregou, e só a primeira é uma decisão deste trabalho. O valor é um limite

superior, porque pergunta se existia *uma* história e não se existia a *certa*; estabelecer a segunda exigiria julgamento humano dia a dia. A cobertura é também marcadamente desigual: o nome pior coberto chega apenas a 50% enquanto cinco nomes ultrapassam 97%, e o pior coberto é simultaneamente o de maior densidade de manchetes, ou seja a sua cobertura chega aos arrancos. A explicação óbvia, truncagem contra o tecto de itens por pedido do fornecedor, foi testada e rejeitada: nenhuma janela de pedido do corpus chegou a um terço desse tecto.

- **Texto curto.** As notícias são representadas apenas por manchetes, o que limita a semântica captada.
- **Tema, não direcção.** A similaridade por embeddings capta o tema, não a direcção, pelo que um agrupamento recuperado pode misturar movimentos de subida e de descida; o impacto médio é evidência ao nível do tema, não um sinal direcional, razão pela qual os precedentes são sempre mostrados individualmente. O remédio natural, filtrar precedentes por tipo de evento, foi testado e não assumido (Secção 5.6): o espaço de embeddings carrega de facto estrutura de tipo de evento, e carrega-a com mais força do que carrega o assunto, mas demasiado fracamente para se filtrar por ela. Aplicar um tipo de evento errado deixaria fora precedentes válidos em silêncio, pelo que a taxonomia fica descritiva.
- **A confiança é fina, e está agora quantificada.** Envolver o modelo de triagem congelado em predição conformal split (Secção 5.7) mostra que garantir 90% de cobertura deixa uma decisão definida em apenas 39.5% das manchetes. É uma confirmação independente do achado do Capítulo 5 de que o sinal disponível é fraco, obtida sem treinar nada de novo, e é uma limitação da evidência e não da implementação.
- **A distância até à implantação é real, e o seu tamanho é conhecido.** O modelo foi treinado num corpus de 2018–2023 e corre mais tarde. Essa distância já não é apenas afirmada: está concentrada na volatilidade pré-evento, que deriva para a banda significativa, enquanto as features baseadas em retornos se mantêm estáveis, e a prevalência do rótulo oscila em vez de ter tendência (Secção 5.8). Os valores reportados devem portanto ler-se como medições sob uma dessas oscilações, e não como promessas sobre um período posterior.
- **O gate implantado não mostra benefício mensurável em dados ao vivo, e a razão é instrutiva.** O resultado offline do Capítulo 5 (precisão dentro do orçamento $0.379 \rightarrow 0.632$) é um resultado de conjunto de avaliação. Em produção o sistema regista cada decisão de triagem e rotula-a dias depois com o desfecho que se seguiu, pela mesma regra do treino. Sobre 530 decisões maturadas, os alertas que o gate *manteve* foram materiais 0.592 das vezes contra 0.647 nos que *suprimiu*: nenhum benefício, com a estimativa pontual na direcção errada e a diferença não significativa ($z = -1.28$, $p = 0.20$).

Perguntar *porquê* é o que transforma isto num resultado utilizável, porque duas falhas diferentes produzem-no e pedem remédios opostos. Se o score ainda *ordena* bem e só os números estão na escala errada, a correção é uma recalibração de dois parâmetros. Se o score não ordena de todo, nenhuma recalibração ajuda, porque uma sigmóide é monótona e preserva a ordenação exactamente. Medido sobre a população implantada, o ROC-AUC é 0.494, com um intervalo de bootstrap de cluster de $[0.391, 0.601]$ reamostrando pares (ticker, dia) inteiros, já que manchetes que partilham empresa e dia partilham um rótulo e a amostra efectiva é de 145 unidades e não de 530

linhas. O intervalo está centrado no acaso. Não há portanto capacidade de ordenação mensurável para preservar, e o gate está a selecionar ao acaso qualquer que seja o limiar que lhe derem. A calibração está, essa sim, genuinamente errada, e melhoraria (Brier 0.260 $\rightarrow$ 0.234), mas corrigi-la produziria um número melhor e um sistema idêntico.

A explicação mais provável não é que o modelo esteja avariado mas que seja *redundante*. A materialidade entre as decisões registadas corre a 0.626 contra uma prevalência de treino de 0.378, porque só se registam decisões para manchetes que já passaram os filtros de relevância e frescura. Essas etapas baratas a montante já removeram a maior parte do que a etapa aprendida foi treinada para remover, deixando-lhe pouco para separar. Isto é uma lição geral sobre colocar um componente aprendido dentro de uma pipeline e não um defeito do componente: um modelo avaliado isoladamente e implantado atrás de filtros não é avaliado sobre a distribuição que vai ver. O resultado offline do Capítulo 5 mantém-se como resultado de conjunto de avaliação; o gate implantado não ganhou o seu lugar com esta evidência, e dizê-lo é mais barato do que defendê-lo.

- **A garantia de geração é mais fraca no caminho puxado, e eis exatamente como.**

A verificação de fidelidade descrita na Secção 3.3.6 bloqueia 23 de 23 ataques adversários aceitando 8 de 8 controlos fiéis, e nenhuma secção com violação é entregue. Restam quatro riscos residuais, e nenhum deles é fechado por esses números. *Relevância da citação*: a verificação confirma que um registo citado existe e que os números da frase lhe pertencem, não que o registo *sustenta* a caracterização feita em palavras — uma frase pode citar um facto verdadeiro e descrevê-lo mal sem usar um número. *Paráfrase*: a defesa linguística é uma blocklist, e uma blocklist sobre linguagem natural perde no limite; é precisamente por isso que o caminho de alerta empurrado usa uma allowlist fechada e que os dois caminhos não são apresentados como equivalentes. *Qualificadores*: juízos sem número, como chamar invulgarmente grande a um movimento, são permitidos porque proibi-los tornaria o texto ilegível, e são verificáveis pelo leitor contra o registo citado ao lado. *Omissão*: nada obriga o gerador a mencionar um facto desfavorável, lacuna que a composição determinística fecha por construção e o texto gerado não.

O exercício adversário que produziu a guarda atual foi também *incompleto*, e a maneira como o foi merece registo. Encomendaram-se seis perspetivas de ataque; duas completaram, produzindo 114 tentativas das quais 21 foram reproduzidas, e as restantes terminaram por limite de gasto da conta — incluindo todas as etapas de verificação independente. O exercício devolveu assim um veredicto nominalmente limpo que era, de facto, a *ausência* de verificação, modo de falha que este projeto já encontrou repetidas vezes. Os achados sobre os quais se atuou foram confirmados à mão contra o código em execução, e o corpus retém-nos como regressões; mas a guarda não enfrentou quatro das seis perspetivas, e a afirmação honesta é que a sua força medida é um limite inferior estabelecido contra um adversário interrompido.

- **Sem estudo humano.** A utilidade para um investidor real ainda não foi medida. Isto passa a cobrir também o texto gerado: se um relatório ancorado ajuda um não-especialista a chegar a um juízo mais sólido do que os painéis subjacentes sozinhos é exatamente o tipo de pergunta que o estudo em falta responderia, e não se faz aqui nenhuma afirmação de utilidade para ele.

- **Por desenho.** O sistema não faz previsão de preços nem negociação, pelo que as questões baseadas em lucro estão fora de âmbito, não por responder.

6.6 Trabalho Futuro

As limitações mapeiam diretamente em trabalho futuro, resumido na Figura 6.2.




Figura 6.2: Cada limitação enunciada mapeia diretamente num passo concreto seguinte. Várias já viram uma primeira iteração do lado da produção (uma base de conhecimento viva maturada contra preços observados, sinalização explícita de divergência de direção, e uma cotação intradiária durante o horário de mercado), reportadas como seguimento de engenharia cuja avaliação formal fica para trabalho futuro.

- Avaliar as *magnitudes de impacto* no corpus FNSPID multi-ano. A própria recuperação já foi validada aí (precision@5 de 0.595, com estatísticas de dispersão e de consistência de direção); o que resta é o estudo das magnitudes de impacto ajustadas ao mercado sobre esses precedentes multi-ano.
- Realizar um pequeno estudo humano, aplicando uma rubrica de clareza, completude e acionabilidade a um conjunto de alertas, para resolver a questão em aberto da utilidade (RQ3).
- Atacar a lacuna de texto em aberto da RQ4: texto mais rico do que manchetes (corpo dos artigos, sentimento financeiro como feature), o ticker em falta recuperado sob o seu símbolo antigo, e o ciclo de pós-validação ao vivo a acumular decisões rotuladas frescas para re-treino periódico; um tratamento por contextual-bandit do limiar do alerta é a extensão aprendida natural.
- Fechar a metade que falta da questão da cobertura de notícias. A fração de dias invulgares em que *alguma* história relevante chegou ao funil está agora contada (88,5%,

acima), mas se chegou a história *certa* não está, e nenhum proxy automático o resolve: exige juízo humano por dia sobre uma amostra de dias sinalizados, que é o mesmo instrumento de que o estudo de utilidade precisa e poderia ser recolhido na mesma passagem.

A produção ao vivo, depois de a avaliação ter sido congelada, já motivou uma primeira iteração de vários destes pontos: o sistema em produção faz agora crescer uma base de conhecimento *viva* a partir das manchetes que varre (cada caso maturado contra preços observados dias depois), ordena os precedentes com um fator de decaimento por idade mostrando sempre a similaridade verdadeira e a idade de cada caso, sinaliza explicitamente a divergência de direção, e avalia o movimento do dia em curso a partir de uma cotação em tempo real durante o horário de mercado. A produção também ensinou a sua própria lição, reportada no Capítulo 4: uma única fonte de preços gratuita provou ser um ponto único de falha em infraestrutura alojada, e foi substituída por uma cadeia de fallback multi-fornecedor. Estas iterações do lado da produção reutilizam os componentes validados sem alterações e são aqui reportadas como seguimento de engenharia; a sua avaliação formal fica para trabalho futuro. Um ponto está já *validado* em vez de especulativo: a comparação estendida do Estudo de Caso 1 mostrou que uma estimativa de volatilidade com ponderação exponencial melhora substancialmente a concordância do detetor com o indicador, pelo que adotá-la é uma mudança medida, de uma linha, à espera apenas de uma decisão de explicabilidade. Em conjunto, estas mudanças transformariam um protótipo sólido num sistema mais exaustivamente validado, sem abdicar da simplicidade e transparência que o tornam defensável.

Bibliografia

- Aamodt, Agnar e Enric Plaza (1994). «Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches». Em: *AI Communications* 7.1, pp. 39–59. doi: 10.3233/AIC-1994-7104.
- Adadi, Amina e Mohammed Berrada (2018). «Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)». Em: *IEEE Access* 6, pp. 52138–52160. doi: 10.1109/ACCESS.2018.2870052.
- Ahmed, Mohiuddin, Abdun Naser Mahmood e Md. Rafiqul Islam (2016). «A Survey of Anomaly Detection Techniques in Financial Domain». Em: *Future Generation Computer Systems* 55, pp. 278–288. doi: 10.1016/j.future.2015.01.001.
- Angelopoulos, Anastasios N. e Stephen Bates (2023). «Conformal Prediction: A Gentle Introduction». Em: *Foundations and Trends in Machine Learning* 16.4, pp. 494–591. doi: 10.1561/22000000101.
- Araci, Dogu (2019). «FinBERT: Financial Sentiment Analysis with Pre-trained Language Models». Em: *arXiv preprint*. arXiv: 1908.10063 [cs.CL].
- Bansal, Gagan et al. (2021). «Does the Whole Exceed its Parts? The Effect of AI Explanations on Complementary Team Performance». Em: *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. doi: 10.1145/3411764.3445717.
- Barber, Brad M. e Terrance Odean (2008). «All That Glitters: The Effect of Attention and News on the Buying Behavior of Individual and Institutional Investors». Em: *The Review of Financial Studies* 21.2, pp. 785–818. doi: 10.1093/rfs/hhm079.
- Barberis, Nicholas e Richard Thaler (2003). «A Survey of Behavioral Finance». Em: *Handbook of the Economics of Finance*. Ed. por George M. Constantinides, Milton Harris e René M. Stulz. Vol. 1. Elsevier. Cap. 18, pp. 1053–1128. doi: 10.1016/S1574-0102(03)01027-6.
- Barredo Arrieta, Alejandro et al. (2020). «Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI». Em: *Information Fusion* 58, pp. 82–115. doi: 10.1016/j.inffus.2019.12.012.
- Blume, Marshall E. (1971). «On the Assessment of Risk». Em: *The Journal of Finance* 26.1, pp. 1–10. doi: 10.1111/j.1540-6261.1971.tb00584.x.
- Bollerslev, Tim (1986). «Generalized Autoregressive Conditional Heteroskedasticity». Em: *Journal of Econometrics* 31.3, pp. 307–327. doi: 10.1016/0304-4076(86)90063-1.
- Breunig, Markus M. et al. (2000). «LOF: Identifying Density-Based Local Outliers». Em: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104. doi: 10.1145/342009.335388.
- Brown, Stephen J. e Jerold B. Warner (1985). «Using Daily Stock Returns: The Case of Event Studies». Em: *Journal of Financial Economics* 14.1, pp. 3–31. doi: 10.1016/0304-405X(85)90042-X.
- Cambridge Centre for Alternative Finance (2026). *Global AI in Financial Services Report: Adoption, Impact and Risks*. Cambridge Judge Business School, University of Cambridge. url: <https://www.jbs.cam.ac.uk/faculty-research/centres/alternative->

- finance/publications/2026-global-ai-in-financial-services-report/ (accedido em 21/06/2026).
- Cardillo, Giovanni e Helen Chiappini (2024). «Robo-advisors: A Systematic Literature Review». Em: *Finance Research Letters* 62, p. 105119. doi: 10.1016/j.fr1.2024.105119.
- Chandola, Varun, Arindam Banerjee e Vipin Kumar (2009). «Anomaly Detection: A Survey». Em: *ACM Computing Surveys* 41.3, 15:1–15:58. doi: 10.1145/1541880.1541882.
- D. Sculley et al. (2015). «Hidden Technical Debt in Machine Learning Systems». Em: *Advances in Neural Information Processing Systems 28 (NIPS 2015)*. Curran Associates, Inc., pp. 2503–2511. url: https://papers.nips.cc/paper_files/paper/2015/hash/86df7dcfd896fc2674f757a2463eba-Abstract.html.
- D'Acunto, Francesco, Nagpurnanand Prabhala e Alberto G. Rossi (2019). «The Promises and Pitfalls of Robo-Advising». Em: *The Review of Financial Studies* 32.5, pp. 1983–2020. doi: 10.1093/rfs/hhz014.
- Da, Zhi, Joseph Engelberg e Pengjie Gao (2011). «In Search of Attention». Em: *The Journal of Finance* 66.5, pp. 1461–1499. doi: 10.1111/j.1540-6261.2011.01679.x.
- Devlin, Jacob et al. (2019). «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». Em: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, pp. 4171–4186. doi: 10.18653/v1/N19-1423. arXiv: 1810.04805.
- Ding, Xiao et al. (2015). «Deep Learning for Event-Driven Stock Prediction». Em: *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 2327–2333. url: <https://www.ijcai.org/Abstract/15/329>.
- Dong, Zihan, Xinyu Fan e Zhiyuan Peng (2024). «FNSPID: A Comprehensive Financial News Dataset in Time Series». Em: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '24)*. Association for Computing Machinery, pp. 4918–4927. doi: 10.1145/3637528.3671629. arXiv: 2402.06698 [q-fin.ST].
- Doshi-Velez, Finale e Been Kim (2017). «Towards a Rigorous Science of Interpretable Machine Learning». Em: *arXiv preprint*. arXiv: 1702.08608 [stat.ML].
- Engle, Robert F. (1982). «Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation». Em: *Econometrica* 50.4, pp. 987–1007. doi: 10.2307/1912773.
- Fama, Eugene F. (1970). «Efficient Capital Markets: A Review of Theory and Empirical Work». Em: *The Journal of Finance* 25.2, pp. 383–417. doi: 10.2307/2325486.
- Fama, Eugene F. et al. (1969). «The Adjustment of Stock Prices to New Information». Em: *International Economic Review* 10.1, pp. 1–21. doi: 10.2307/2525569.
- Friedman, Jerome H. (2001). «Greedy Function Approximation: A Gradient Boosting Machine». Em: *The Annals of Statistics* 29.5, pp. 1189–1232. doi: 10.1214/aos/1013203451.
- Gallup (2025). *What Percentage of Americans Own Stock?* url: <https://news.gallup.com/poll/266807/percentage-americans-owns-stock.aspx> (accedido em 21/06/2026).
- Gama, João et al. (2014). «A Survey on Concept Drift Adaptation». Em: *ACM Computing Surveys* 46.4, pp. 1–37. doi: 10.1145/2523813.
- Google (jun. de 2026). *Our latest Google Finance upgrades, including a new app*. url: <https://blog.google/products-and-platforms/products/search/google-finance-updates-june-2026/> (accedido em 07/08/2026).
- Guidotti, Riccardo et al. (2018). «A Survey of Methods for Explaining Black Box Models». Em: *ACM Computing Surveys* 51.5, 93:1–93:42. doi: 10.1145/3236009.

- Johnson, Jeff, Matthijs Douze e Hervé Jégou (2021). «Billion-Scale Similarity Search with GPUs». Em: *IEEE Transactions on Big Data* 7.3, pp. 535–547. doi: 10.1109/TBDATA.2019.2921572.
- Kahneman, Daniel e Amos Tversky (1979). «Prospect Theory: An Analysis of Decision under Risk». Em: *Econometrica* 47.2, pp. 263–291. doi: 10.2307/1914185.
- Kearney, Colm e Sha Liu (2014). «Textual Sentiment in Finance: A Survey of Methods and Models». Em: *International Review of Financial Analysis* 33, pp. 171–185. doi: 10.1016/j.irfa.2014.02.006.
- Lee, John D. e Katrina A. See (2004). «Trust in Automation: Designing for Appropriate Reliance». Em: *Human Factors* 46.1, pp. 50–80. doi: 10.1518/hfes.46.1.50_30392.
- Lipton, Zachary C. (2018). «The Mythos of Model Interpretability». Em: *Communications of the ACM* 61.10, pp. 36–43. doi: 10.1145/3233231.
- Liu, Fei Tony, Kai Ming Ting e Zhi-Hua Zhou (2008). «Isolation Forest». Em: *2008 Eighth IEEE International Conference on Data Mining (ICDM)*, pp. 413–422. doi: 10.1109/ICDM.2008.17.
- Loughran, Tim e Bill McDonald (2011). «When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks». Em: *The Journal of Finance* 66.1, pp. 35–65. doi: 10.1111/j.1540-6261.2010.01625.x.
- Lundberg, Scott M. e Su-In Lee (2017). «A Unified Approach to Interpreting Model Predictions». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 4765–4774. arXiv: 1705.07874.
- Manning, Christopher D., Prabhakar Raghavan e Hinrich Schütze (2008). *Introduction to Information Retrieval*. Cambridge, England: Cambridge University Press. isbn: 978-0-521-86571-5.
- Mikolov, Tomas et al. (2013). «Efficient Estimation of Word Representations in Vector Space». Em: *arXiv preprint*. arXiv: 1301.3781.
- Miller, Tim (2019). «Explanation in Artificial Intelligence: Insights from the Social Sciences». Em: *Artificial Intelligence* 267, pp. 1–38. doi: 10.1016/j.artint.2018.07.007.
- Niculescu-Mizil, Alexandru e Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». Em: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, pp. 625–632. doi: 10.1145/1102351.1102430.
- Pang, Guansong et al. (2021). «Deep Learning for Anomaly Detection: A Review». Em: *ACM Computing Surveys* 54.2, 38:1–38:38. doi: 10.1145/3439950.
- Pennington, Jeffrey, Richard Socher e Christopher D. Manning (2014). «GloVe: Global Vectors for Word Representation». Em: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1532–1543. doi: 10.3115/v1/D14-1162.
- Reimers, Nils e Iryna Gurevych (2019). «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». Em: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. doi: 10.18653/v1/D19-1410.
- Ribeiro, Marco Tulio, Sameer Singh e Carlos Guestrin (2016). «“Why Should I Trust You?”: Explaining the Predictions of Any Classifier». Em: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135–1144. doi: 10.1145/2939672.2939778.
- Robertson, Stephen e Hugo Zaragoza (2009). «The Probabilistic Relevance Framework: BM25 and Beyond». Em: *Foundations and Trends in Information Retrieval* 4.1–2, pp. 1–174. doi: 10.1561/15000000019.

- Robinhood Markets (mar. de 2025). *Introducing Robinhood Strategies, Robinhood Banking, and Robinhood Cortex*. url: <https://robinhood.com/us/en/newsroom/introducing-strategies-banking-and-cortex/> (acedido em 07/08/2026).
- Rousseeuw, Peter J. (1987). «Silhouettes: a graphical aid to the interpretation and validation of cluster analysis». Em: *Journal of Computational and Applied Mathematics* 20, pp. 53–65. doi: 10.1016/0377-0427(87)90125-7.
- Rudin, Cynthia (2019). «Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead». Em: *Nature Machine Intelligence* 1.5, pp. 206–215. doi: 10.1038/s42256-019-0048-x.
- Salton, Gerard, A. Wong e C. S. Yang (1975). «A Vector Space Model for Automatic Indexing». Em: *Communications of the ACM* 18.11, pp. 613–620. doi: 10.1145/361219.361220.
- Securities Industry and Financial Markets Association (SIFMA) (2025). *2025 Capital Markets Fact Book*. url: <https://www.sifma.org/resources/research/fact-book/> (acedido em 21/06/2026).
- Tetlock, Paul C. (2007). «Giving Content to Investor Sentiment: The Role of Media in the Stock Market». Em: *The Journal of Finance* 62.3, pp. 1139–1168. doi: 10.1111/j.1540-6261.2007.01232.x.
- Vasicek, Oldrich A. (1973). «A Note on Using Cross-Sectional Information in Bayesian Estimation of Security Betas». Em: *The Journal of Finance* 28.5, pp. 1233–1239. doi: 10.1111/j.1540-6261.1973.tb01452.x.
- Vaswani, Ashish et al. (2017). «Attention Is All You Need». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 5998–6008. arXiv: 1706.03762.
- Vinh, Nguyen Xuan, Julien Epps e James Bailey (2010). «Information Theoretic Measures for Clusterings Comparison: Variants, Properties, Normalization and Correction for Chance». Em: *Journal of Machine Learning Research* 11.95, pp. 2837–2854. url: <https://www.jmlr.org/papers/v11/vinh10a.html>.
- Vovk, Vladimir, Alexander Gammerman e Glenn Shafer (2005). *Algorithmic Learning in a Random World*. New York: Springer. isbn: 978-0-387-00152-4. doi: 10.1007/b106715.
- Welch, Ivo (2022). «The Wisdom of the Robinhood Crowd». Em: *The Journal of Finance* 77.3, pp. 1489–1527. doi: 10.1111/jofi.13128.
- Wu, Shijie et al. (2023). «BloombergGPT: A Large Language Model for Finance». Em: *arXiv preprint*. arXiv: 2303.17564 [cs.LG].
- Xing, Frank Z., Erik Cambria e Roy E. Welsch (2018). «Natural Language Based Financial Forecasting: A Survey». Em: *Artificial Intelligence Review* 50.1, pp. 49–73. doi: 10.1007/s10462-017-9588-9.
- Yang, Yi, Mark Christopher Siy Uy e Allen Huang (2020). «FinBERT: A Pretrained Language Model for Financial Communications». Em: *arXiv preprint*. arXiv: 2006.08097.

Apêndice A

Reprodutibilidade

Este apêndice reúne o material que permite reproduzir e inspecionar os resultados: o ambiente de software, os dados em cada fase, e as saídas de avaliação por detrás dos números reportados no corpo.

A.1 Ambiente

O sistema é implementado em Python 3.12, escolhido pela maturidade dos seus pacotes para a stack de aprendizagem automática. As dependências são fixadas e congeladas num ficheiro de lock para que o ambiente possa ser recriado entre máquinas. O tratamento numérico e de dados assenta em bibliotecas open-source estabelecidas; os embeddings de frase usam a framework Sentence-BERT sobre uma build CPU da biblioteca de deep learning subjacente, instalada a partir de um índice dedicado para evitar o download de GPU muito maior; as figuras são produzidas com uma biblioteca de plotting padrão. A Tabela A.1 lista as versões fixadas das dependências centrais; o conjunto completo está congelado num ficheiro de lock ao lado delas.

Tabela A.1: Versões fixadas das dependências centrais (Python 3.12).

Biblioteca	Versão
numpy	2.1.3
pandas	2.2.3
matplotlib	3.11.0
scikit-learn	1.9.0
yfinance	1.4.1
sentence-transformers	5.6.0
transformers	5.12.1
torch (build CPU)	2.12.1
pytest	8.3.4
ruff	0.8.6

A.2 Organização do Código

O código está organizado como um pacote por componente, espelhando a arquitetura da Figura 4.1: dados de mercado, recuperação de notícias, deteção de anomalias, o motor de correlação (similaridade e estudo de evento), a base de conhecimento histórica, o motor de explicação e a entrega de alertas, com uma pequena camada de orquestração a ligá-los nos

dois fluxos de ponta a ponta. A lógica pura é separada da entrada/saída, e as dependências pesadas ou de rede são carregadas de forma tardia, pelo que o núcleo numérico é testado unitariamente sem ligação de rede nem a stack de modelos. Os segredos são lidos apenas de um ficheiro de ambiente local e ignorado, e nunca são escritos em ficheiros versionados.

A.3 A Pipeline Completa numa Página

O corpo da dissertação apresenta deliberadamente o sistema através de vários diagramas pequenos e simples (arquitetura, modelo de dados, fluxos por gatilho, a vida de um alerta). A Figura A.1 é a vista oposta, mantida no apêndice precisamente por ser densa: a pipeline *completa* em produção numa única página em paisagem, com cada porta e o seu valor de configuração de produção anotado. Cada valor é um parâmetro de implantação divulgado (a avaliação do Capítulo 5 congela as suas próprias definições, mais estritas, como notado na figura).

A.4 Testes e Resultados Reprodutíveis

O sistema é coberto por uma suíte de testes automáticos que abrange o detetor de anomalias, o estudo de evento, a similaridade, a base de conhecimento, o parser de notícias, o motor de explicação e os módulos de avaliação, juntamente com um smoke test offline de ponta a ponta do gatilho de notícias. Os testes que exigem acesso à rede ou modelos pesados são marcados e excluídos da corrida por defeito para que esta seja rápida, determinística e offline.

Cada resultado experimental do Capítulo 5 é regenerado por um procedimento determinístico de semente fixa que escreve as suas tabelas e figuras diretamente nos diretórios de avaliação e de figuras, pelo que o ciclo entre computação e documento é fechado e auditável. Cada um dos quatro estudos de caso tem um desses procedimentos: a recuperação de precedentes e a sua decomposição por setor, a taxa de disparo de anomalias e a ablação de janela, a comparação de detetores estatístico-versus-aprendido, e a construção e treino do conjunto de dados de triagem de materialidade, e a decomposição de triagem trabalhada, a projeção do espaço de embeddings e o funil de produção são produzidos da mesma forma. Cada número de destaque no corpo é o valor escrito por um destes procedimentos. O passo de obtenção de dados que os precede, e a construção completa da base de conhecimento histórica, seguem a mesma receita determinística.

A.5 Cada Número Rastreado à Sua Fonte

Cada número é escrito pelo seu procedimento determinístico num registo de resultados congelado, e a tese cita esse registo verbatim, pelo que o ciclo entre computação e documento é fechado e auditável. A Tabela A.2 reúne cada resultado de destaque com o valor como reportado e o estudo de caso a que pertence; cada um pode ser regenerado, e verificado, isoladamente.

O bloco inferior dessa tabela foi produzido depois dos resultados do bloco superior e nunca os altera: cada um desses procedimentos lê os artefactos congelados, e os dois que dependem do modelo de triagem reproduzem exatamente a sua pontuação de teste congelada antes de reportarem seja o que for, parando caso contrário. É essa verificação que faz deles




Figura A.1: A pipeline completa em produção numa página: as bases de conhecimento offline e viva, o gatilho de notícias com as suas cinco portas de qualidade, os gatilhos de mercado de fecho e intradiário com a cadeia de fallback de preços multi-fonte, e as saídas partilhadas. As caixas tracejadas são portas que descartam itens; os valores anotados (limiares, tetos, half-life de decaimento) são a configuração de produção divulgada, distinta das definições de avaliação congeladas do Capítulo 5. Os capítulos do corpo apresentam o mesmo sistema como várias vistas mais simples; esta figura existe para que nenhuma fase fique implícita.

afirmações sobre o modelo que esta dissertação reporta, e não sobre um modelo que por acaso está ao lado.

Operação ao vivo. Para além da reprodutibilidade a pedido, o InvestiGator operou ao vivo. Um processo worker varreu a watchlist num ciclo de sessenta segundos e entregou alertas explicados a um canal público de Telegram, tendo substituído um workflow agendado anterior que corria após cada fecho do mercado dos EUA; o registo de alertas partilhado e versionado acumulou dezenas de alertas reais, incluindo a primeira anomalia de mercado genuína (NVDA, 13 de julho de 2026). A base de conhecimento viva maturou as suas manchetes capturadas contra os preços reais que se seguiram, e o ciclo de pós-validação rotulou decisões passadas reais com o seu resultado observado; o que esse ciclo mediu é reportado na Secção 6.5 e não aqui, porque qualifica uma afirmação em vez de a sustentar. Uma grande suíte automática de testes, offline e determinística, corre em cada push através de integração contínua. Números regeneráveis, uma implantação ao vivo e uma suíte de testes verde documentam, em conjunto, um sistema que corre de ponta a ponta e cuja cada figura reportada pode ser reproduzida isoladamente.

A.6 Matriz de Evidência

A tabela anterior lista resultados. Esta lista *afirmações*, o que é um teste mais exigente, porque uma afirmação pode sobreviver à evidência que outrora a sustentava. Cada asserção substantiva desta dissertação é confrontada com a evidência que a suporta, com a possibilidade de essa evidência ser regenerada a pedido, e com o que se decidiu sobre a afirmação em consequência. Várias entradas registam afirmações que foram *retiradas ou estreitadas* depois de medidas; ficam na tabela em vez de apagadas, porque uma matriz que só listasse as afirmações sobreviventes não seria uma auditoria.

A Tabela A.3 é essa auditoria. A coluna de reprodutibilidade distingue três casos. **Script** significa que um procedimento versionado regenera o valor de forma determinística a partir de dados eles próprios regeneráveis. **Teste** significa que uma asserção automática falha se a afirmação deixar de valer. **Vivo** significa que o valor é medido a partir da implantação em funcionamento e mudará à medida que mais dados se acumulem, pelo que o valor é um instantâneo com a sua data e o artefacto durável é o procedimento e não o número.

Duas observações sobre a tabela no seu conjunto, e não sobre qualquer linha em particular. Primeira, treze afirmações foram retiradas ou estreitadas, e todas elas o foram pelas *medições do próprio trabalho* e não por revisão externa. É o comportamento pretendido de uma avaliação desenhada antes das experiências: tem de ser capaz de dizer não. A mais recente é também a mais instrutiva, porque saiu de perguntar o que uma *linha de base* media e não que pontuação um modelo tinha: o chão contra o qual este trabalho vinha a comparar a sua triagem ordenava alfabeticamente, e substituí-lo por um que ordena ao acaso cortou o ganho anunciado de um fator de quatro para um fator de 1.67. Segunda, as linhas com a coluna de evidência mais fraca são também aquelas em que esta dissertação menos se apoia, e a afirmação mais forte que faz, a garantia de não-lookahead, é a que está imposta por um teste e não por prosa. Onde uma afirmação não pôde ser sustentada, aparece aqui como retirada e não como ausente.

A.7 Dados e Atribuição

Os ficheiros de dados grandes nunca são retidos; são regenerados pelos procedimentos de preparação de dados, e apenas pequenas amostras são guardadas. Os modelos de triagem treinados são a exceção por desenho: são pequenos, pelo que os bundles ajustados são mantidos sob controlo de versões juntamente com metadados JSON (janela de treino, semente, limiar e métricas), o que torna o próprio modelo em produção inspecionável e reproduzível. O conjunto de dados FNSPID (Dong, Fan e Peng 2024) é usado sob a sua licença CC BY-SA 4.0, com atribuição conforme exigido; os serviços de dados de mercado e de notícias ao vivo são usados dentro das suas camadas gratuitas.

Tabela A.2: Cada resultado de destaque, o seu valor reportado, e o estudo a que pertence.

Resultado	Valor	Estudo
Recuperação de precedentes, precisão@5 (MiniLM / MPNet / lexical)	0.514 / 0.538 / 0.346	CS2
Deteção de anomalias, F_1 (z-score vs limiar fixo)	0.516 vs 0.218	CS1
Regra estatística vs detetores aprendidos, F_1 (z-score / IF / LOF)	0.530 / 0.269 / 0.280	CS1
Volatilidade EWMA (futuro validado), F_1 vs deslizante	0.664 vs 0.516	CS1
Triagem de materialidade, PR-AUC (volatilidade / contexto / completo)	0.542 / 0.538 / 0.496	CS4
Precisão@5 da triagem por dia vs ordenação aleatória	0.632 vs 0.379	CS4
Precisão@5 da triagem por dia vs prior de volatilidade por ticker	0.632 vs 0.662	CS4
Ablação de features estendida, PR-AUC (contexto + 5 sinais)	0.535 ($\Delta=0.002$)	CS4
Decisão de triagem trabalhada (META, 12 Jul 2026)	$p = 0.539$ (54%)	CS4
Seletividade de produção (manchetes : alertas enviados)	22 : 1	CS2
Concordância de tipo de evento, informação mútua ajustada (evento / ticker / setor)	0.358 / 0.188 / 0.130	CS5
Pureza dos grupos contra a rubrica, versus atribuição aleatória de tamanhos iguais	0.712 vs 0.444	CS5
Cobertura conformal, divisão aleatória ($\alpha = 0.05/0.10/0.20$)	0.951 / 0.902 / 0.803	CS6
Cobertura conformal, divisão temporal (mesmo α)	0.937 / 0.900 / 0.822	CS6
Decisões definidas a 90 % de cobertura garantida	39.5 %	CS6
Deriva das entradas, índice de estabilidade (volatilidade / comprimento / retornos)	0.281 / 0.111 / ≤ 0.020	CS7
Prevalência do rótulo nos três blocos temporais	0.385 / 0.470 / 0.378	CS7
Guarda de ancoragem, ataques adversários bloqueados (determinístico)	23 / 23	§4.8
Guarda de ancoragem, controlos fiéis aceites (determinístico)	8 / 8	§4.8
Secções geradas conformes (amostrado, uma corrida de seis relatórios)	27 / 27	§4.8
Secções entregues com violação (invariante, todas as corridas)	0	§4.8

A.7. Dados e Atribuição

Tabela A.3: Cada afirmação substantiva, a sua evidência e o seu estado. “Estreitada” e “retirada” registam afirmações que este trabalho retratou depois de as medir.

Afirmação	Evidência	Onde	Repro.	Estado
RQ1 — detecção transparente				
Dispara a taxa comparável em ações de volatilidade muito diferente	Amplitude da taxa 0.015 vs 0.344 em 15 tickers, sem rótulos	§5.2	Script	Mantida
Bate um limiar fixo num proxy de movimento extremo	F_1 0.516 vs 0.218	§5.2	Script	Mantida (com ressalva do proxy)
Bate dois detetores aprendidos com features causais idênticas	F_1 0.530 vs 0.269 (IF) e 0.280 (LOF)	§5.2	Script	Mantida
Sem lookahead no detetor	A fatia da janela exclui o dia julgado	Excerto 3.1	Teste	Mantida
Um estimador EWMA faria melhor neste proxy	F_1 0.664 vs 0.516	§5.2	Script	Mantida, não implantada
RQ2 — recuperação de precedentes				
A recuperação semântica bate as linhas de base lexical e triviais	P@5 0.514 vs 0.346/0.240/0.126, 5 sementes	§5.3	Script	Mantida
Mantém-se à escala multi-ano	P@5 0.595 em ~80k manchetes	§5.3	Script	Mantida
A experiência de recuperação recupera <i>precedentes</i>	Só 31, 1% dos vizinhos precedem a consulta num corpus de 27 dias	§3.2.3	Script	Retirada (vale na implantação)
O corpus de avaliação abrange meses	27 dias, 28 mai–24 jun 2026	§3.2.3	Script	Retirada
A recuperação capta tema, não direção	Consistência de direção 0.71 vs chão de acaso 0.69	§5.3	Script	Mantida
Relevância = concordância de setor é um proxy, não verdade	Declarado; inspeção qualitativa por setor	§5.9	—	Limitação
RQ3 — explicação				
O texto do alerta não pode divergir do cálculo	Renderizado dos objetos calculados; verificado por precedente	§5.4	Teste	Mantida
A linha do “porquê” é exata, não uma aproximação	Termos aditivos dos log-odds	Excerto 3.4	Teste	Mantida
A linguagem gerada nunca fornece a evidência	Guarda em runtime; corpus de red team como regressão	§6.1	Teste	Mantida
A contagem de violações entregues é em parte circular	O mesmo verificador decide e avalia; declarado	§6.1	—	Limitação
As explicações são <i>úteis</i>	—	—	—	Não afirmado
RQ4 — triagem aprendida				
O treino é determinístico e reproduz os artefactos guardados	O bundle congelado regenera PR-AUC, ROC-AUC, Brier e precisão no orçamento exactamente	§5.5	Teste	Mantida
Sem lookahead nas features	Mutar o futuro deixa as features iguais e muda o rótulo	Excerto 3.2	Teste	Mantida
Os blocos não partilham janelas de rótulo	Divisão por dia único + embargo (820 linhas largadas)	Excerto 3.3	Teste	Mantida
Nenhum modelo com texto bate a linha de base de volatilidade	PR-AUC 0.542 vs 0.496; sobrevive a bootstrap de cluster, a um re-teste justo, a uma troca de métrica e às nove definições de rótulo	§5.5	Script	Mantida
A triagem eleva a precisão no orçamento 0.163 → 0.632, quase quatro vezes	O chão 0.163 ordena alfabeticamente, não às cegas; uma ordenação aleatória dá 0.379	§5.5	Script	Estreitada duas vezes: ao conjunto de avaliação, e depois 1.67×
É a aprendizagem que merece o ganho no orçamento	Um prior de volatilidade por ticker, de 13 constantes, dá 0.662 contra os 0.632 do	§5.5	Script	Retirada